

$$\min_{x \in \mathbb{R}^d} f(x)$$

- на пред. примере: f - выпукл
- гипотеза: все выпуклые функции: $f(x) = |x|$

$$|f'(0+\delta) - f'(0-\delta)| = \\ = |1 - (-1)| = 2 \not\leq L\delta \\ \delta \rightarrow 0$$

т.е., L -лимит. не выполняется

любое выпуклое

$f: \mathbb{R}^d \rightarrow \mathbb{R}$ f - M -лимитов, если $\forall x, y \in \mathbb{R}^d$ выполняется

$$|f(x) - f(y)| \leq M \|x - y\|_2$$

равным т.е. линейное, μ -свойство выпуклости \Rightarrow линейность
т.е. линейное на \mathbb{R}^d

выпуклое, M -лимитов f

Субградиент

$\Rightarrow f: \mathbb{R}^d \rightarrow \mathbb{R}$ выпукл. Вектор g называется субградиентом f в $x \in \mathbb{R}^d$, если $\forall y \in \mathbb{R}^d$ выполняется:

$$f(y) \geq f(x) + \langle g, y - x \rangle$$

Субдифференциал $\partial f(x)$ - мн-во всех субградиентов f в точке x

- f гиперградиентен $\partial f(x) = \{ \nabla f(x) \}$. Определение выполняется
- $\bigvee f(x) = |x| \quad \partial f(0)$
 $|y| \geq \langle g, y \rangle \quad g \in [-1; 1]$

Условие оптимальности

x^* - минимизирующий глобально $f \Leftrightarrow 0 \in \partial f(x^*)$

Док-во:

$\Leftarrow 0 \in \partial f(x^*), \text{ тогда } \forall x \in \mathbb{R}^d$

$$f(x) \geq f(x^*) + \langle 0; x - x^* \rangle = f(x^*) \leftarrow \text{минимум по } x$$

$\Rightarrow f(x) \geq f(x^*) \quad \forall x \in \mathbb{R}^d$

$$f(x) \geq f(x^*) + \langle 0; x - x^* \rangle \quad \forall x \in \mathbb{R}^d$$

\uparrow
субградиент в 0 (по определению)

Лемма

$f: \mathbb{R}^d \rightarrow \mathbb{R}$ - выпукло, тогда f M -лимитовна

$$\Leftrightarrow \forall x \in \mathbb{R}^d \text{ и } \forall g \in \partial f(x) \hookrightarrow \|g\|_2 \leq M.$$

Субградиентный метод

$$x^{k+1} = x^k - \gamma g^k \leftarrow \begin{matrix} \text{субградиент} \\ \in \partial f(x^k) \end{matrix} \text{ в точке } x^k$$

Док-во сходимости:

$$\|x^{k+1} - x^*\|_2^2 = \|x^k - \gamma g^k - x^*\|_2^2$$

$$= \|x^k - x^*\|_2^2 - 2\gamma \langle g^k; x^k - x^* \rangle + \gamma^2 \|g^k\|_2^2$$

$$M\text{-лимитовность} \Rightarrow \|g^k\|_2 \leq M$$

$$= \|x^k - x^*\|_2^2 - 2\gamma \langle g^k; x^k - x^* \rangle + \gamma^2 M^2$$

выпуклость и субградиент

$$\leq \|x^k - x^*\|_2^2 - 2\gamma (f(x^k) - f(x^*)) + \gamma^2 M^2$$

$$f(x^k) - f(x^*) \leq \frac{\|x^k - x^*\|_2^2 - \|x^{k+1} - x^*\|_2^2}{2\gamma} + \frac{\gamma M^2}{2}$$

$$\frac{1}{K} \sum_{k=0}^{K-1} f(x^k) - f(x^*) \leq \frac{\|x^0 - x^*\|_2^2 - \cancel{\|x^K - x^*\|_2^2}}{2\gamma K} + \frac{\gamma M^2}{2}$$

пер-во теорема

$$f\left(\frac{1}{K} \sum_{k=0}^{K-1} x^k\right) - f(x^*) \leq \underbrace{\frac{\|x^0 - x^*\|_2^2}{2\gamma K}}_{\min \gamma} + \frac{\gamma M^2}{2}$$

$$\gamma = \frac{\|x^0 - x^*\|_2}{M\sqrt{K}}$$

$$f\left(\frac{1}{K} \sum_{k=0}^{K-1} x^k\right) - f(x^*) \leq \frac{M \|x^0 - x^*\|_2}{\sqrt{K}}$$

эпизодическая

для любого ϵ выберем $\frac{1}{K}$, где $\frac{1}{\sqrt{K}}$

выбор γ и $\gamma_k = \frac{1}{\sqrt{K}}$

Теорема о сходимости

f - выпуклая и M -лимитовая, то для субград. точки
определенно эпизодическая сходимость

$$f\left(\frac{1}{K} \sum_{k=0}^{K-1} x^k\right) - f(x^*) \leq \frac{M \|x^0 - x^*\|_2}{\sqrt{K}}$$

$\sim \epsilon$

Два возможных ε -нормы:

$$K = \frac{M^2 \|x^0 - x^*\|_2^2}{\varepsilon^2}$$

Проблема: мы $\gamma_k = \frac{\|x^0 - x^*\|_2}{M\sqrt{k}}$ знаем $M, \|x^0 - x^*\|_2$

Как решить?

Ada Grad Norm \rightarrow

$$\gamma_k = \frac{\|x^0 - x^*\|_2}{\sqrt{k} M^2} \approx \frac{D}{\sqrt{\sum_{t=0}^k \|g^t\|_2^2}}$$

$\|x^0 - x^*\|_2 \leq D$ (мы знаем D и знаем ∇f \rightarrow знаем γ_k)

Ada Grad Norm \Rightarrow Ada Grad
(универсальность метода)

Ada Grad

$$\gamma_{k,i} = \frac{D_i}{\sqrt{\sum_{t=0}^k (g_i^t)^2}}$$

i - номер компонента

Док-во корректности:

$$\begin{aligned} \|x_i^{k+1} - x_i^*\|^2 &= \|x_i^k - \gamma_{k,i} g_i^k - x_i^*\|^2 \\ &= \|x_i^k - x_i^*\|^2 - 2\gamma_{k,i} g_i^k (x_i^k - x_i^*) \\ &\quad + \gamma_{k,i}^2 (g_i^k)^2 \end{aligned}$$

разрешим на $2\gamma_{k,i}$

$$g_i^k (x_i^k - x_i^*) = \frac{1}{2\gamma_{k,i}} |x_i^k - x_i^*|^2 - \frac{1}{2\gamma_{k,i}} |x_i^{k+1} - x_i^*|^2 + \frac{\gamma_{k,i}}{2} (g_i^k)^2$$

$\sum_{i=1}^d$ no better cooperation

$$\langle g^k, x^k - x^* \rangle = \sum_{i=1}^d \left[\frac{1}{2\gamma_{k,i}} |x_i^k - x_i^*|^2 - \frac{1}{2\gamma_{k,i}} |x_i^{k+1} - x_i^*|^2 + \frac{\gamma_{k,i}}{2} (g_i^k)^2 \right]$$

beginnings

$$f(x^k) - f(x^*) \leq \sum_{i=1}^d \left[\frac{1}{2\gamma_{k,i}} |x_i^k - x_i^*|^2 - \frac{1}{2\gamma_{k,i}} |x_i^{k+1} - x_i^*|^2 + \frac{\gamma_{k,i}}{2} (g_i^k)^2 \right]$$

$\frac{1}{K} \sum_{k=0}^{K-1}$ u. then

$$f\left(\frac{1}{K} \sum_{k=0}^{K-1} x^k\right) - f(x^*) \leq \frac{1}{K} \sum_{k=0}^{K-1} \sum_{i=1}^d \left[\frac{1}{2\gamma_{k,i}} |x_i^k - x_i^*|^2 - \frac{1}{2\gamma_{k,i}} |x_i^{k+1} - x_i^*|^2 + \frac{\gamma_{k,i}}{2} (g_i^k)^2 \right]$$

$$= \frac{1}{K} \sum_{i=1}^d \sum_{k=0}^{K-1} \left[\frac{1}{2\gamma_{k,i}} |x_i^k - x_i^*|^2 - \frac{1}{2\gamma_{k,i}} |x_i^{k+1} - x_i^*|^2 + \frac{\gamma_{k,i}}{2} (g_i^k)^2 \right]$$

convergence $|x_i^k - x_i^*|^2$
 $\gamma_{-1,i} = \infty$

$$\leq \frac{1}{K} \sum_{i=1}^d \sum_{k=0}^{K-2} \left[\left(\frac{1}{2\gamma_{k,i}} - \frac{1}{2\gamma_{k-1,i}} \right) |x_i^k - x_i^*|^2 \right. \\ \left. + \frac{1}{K} \sum_{i=1}^d \sum_{k=0}^{K-1} \frac{\gamma_{k,i}}{2} (g_i^k)^2 \right]$$

$$|x_i^k - x_i^*|^2 \leq D_i^2$$

$$\leq \frac{1}{K} \sum_{i=1}^d \sum_{k=0}^{K-2} \left[\left(\frac{1}{2\gamma_{k,i}} - \frac{1}{2\gamma_{k-1,i}} \right) D_i^2 \right. \\ \left. + \frac{1}{K} \sum_{i=1}^d \sum_{k=0}^{K-1} \frac{\gamma_{k,i}}{2} (g_i^k)^2 \right]$$

$$\gamma_{k,i} = \frac{D_i}{\sqrt{\sum_{t=0}^k (g_i^t)^2}}$$

$$= \frac{1}{2K} \sum_{i=1}^d \sum_{k=0}^{K-2} \left[\left(\sqrt{\sum_{t=0}^k (g_i^t)^2} - \sqrt{\sum_{t=0}^{k-1} (g_i^t)^2} \right) D_i \right] \\ + \frac{1}{2K} \sum_{i=1}^d \sum_{k=0}^{K-1} \frac{D_i (g_i^k)^2}{\sqrt{\sum_{t=0}^k (g_i^t)^2}}$$

$$= \frac{1}{2K} \sum_{i=1}^d \sqrt{\sum_{t=0}^{K-1} (g_i^t)^2} D_i \\ + \frac{1}{2K} \sum_{i=1}^d \sum_{k=0}^{K-1} \frac{D_i (g_i^k)^2}{\sqrt{\sum_{t=0}^k (g_i^t)^2}}$$

$$\{a_k\} \geq 0$$

$$\sum_{k=0}^{K-1} \frac{(a_k)^2}{\sum_{t=0}^k (a_t)^2} \leq 2 \sqrt{\sum_{k=0}^{K-1} (a_k)^2}$$

$$\leq \frac{1}{2K} \sum_{i=1}^d \sqrt{\sum_{t=0}^{K-1} (g_{i,t}^t)^2} D_i$$

$$+ \frac{1}{2K} \sum_{i=1}^d 2 \sqrt{\sum_{t=0}^{K-1} (g_{i,t}^t)^2} D_i$$

$$= \frac{3}{2K} \sum_{i=1}^d D_i \sqrt{\sum_{t=0}^{K-1} (g_{i,t}^t)^2}$$

M -normировано $\leq \sqrt{KM^2}$

$$\leq \frac{3M}{2\sqrt{K}} \underbrace{\sum_{i=1}^d D_i}_{\tilde{D}} = \frac{3M\tilde{D}}{2\sqrt{K}}$$

$\frac{1}{\sqrt{K}}$ — как у градиентного спуска.

Ada Grad \Rightarrow RMS Prop

$$\gamma_{k,i} = \frac{D_i}{\sqrt{\sum_{t=0}^k (g_{i,t}^t)^2}} \Rightarrow$$

$$\gamma_{k,i} = \frac{\gamma}{\sqrt{\beta_2 (h_i^k)^2 + (1-\beta_2) (g_{i,k}^k)^2}}$$

$$(h_i^{k+1})^2 = \beta_2 (h_i^k)^2 + (1-\beta_2) (g_{i,k}^k)^2$$

RMS Prop \Rightarrow Adam

$$\boxed{\beta_2 \Rightarrow \beta_{2,k}}$$

$$\boxed{\begin{array}{l} \beta \in (0,1) \\ \beta \approx 0.99 \end{array}}$$

Choisissez une matrice H

$$x^{k+1} = x^k - \gamma H_k^{-1} \nabla f(x^k)$$

RMS Prop:

$$H_{k+1}^2 = \beta H_k^2 + (1-\beta) \text{diag} \begin{pmatrix} g_{k,1}^2 & & \\ & \ddots & \\ 0 & & g_{k,d}^2 \end{pmatrix}$$

OASIS: $H_{k+1} = \beta H_k + (1-\beta) \text{diag} (u_k \odot \nabla^2 f(x^k) u_k)$

1) $\nabla f(x^k)$

2) $\langle \nabla f(x^k); u_k \rangle$ $u_{k,i} = \begin{cases} 1, & \text{if } i \leq p \\ -1, & \text{if } i > p \end{cases}$

3) $\nabla \langle \nabla f(x^k); u_k \rangle$

4) $\nabla^2 f(x^k) u_k$

5) $u_k \odot \nabla^2 f(x^k) u_k$

$\vec{E} = \text{diag} (\nabla^2 f(x^k))$