

для градиентного спуска:

f L -липушная и μ -сильно выпуклая

для градиентного спуска

$O\left(\frac{L}{\mu} \log \frac{\|x^0 - x^*\|^2}{\epsilon}\right)$ итераций / ораков. вызовов

для нахождения решения с точн. ϵ : $\|x^k - x^*\|^2 \leq \epsilon$

А можно и лучше? Другой метод?

Метод тяжелого шарика (Heavy Ball / HB)

Б.Т.К. Поляк 1964

Алгоритм 1 Метод тяжелого шарика

Вход: размер шагов $\{\gamma_k\}_{k=0} > 0$, моменты $\{\tau_k\}_{k=0} \in [0; 1]$,
стартовая точка $x^0 = x^{-1} \in \mathbb{R}^d$, количество итераций K

1: for $k = 0, 1, \dots, K-1$ do

2: Вычислить $\nabla f(x^k)$

3: $x^{k+1} = x^k - \gamma_k \nabla f(x^k) + \tau_k (x^k - x^{k-1})$



4: end for

Выход: x^K

инерция

хорошие моменты $\tau_k \geq 0$ $\tau_k \in [0; 1]$

Рисунки:



Плюсы:

- ⊕ не требует много, чем град. спуск
- ⊕ универс. оптимизаций параметров
- ⊕ легкость импле.

Минусы:

- ⊖ нужно подобрать параметры: γ и τ ($\tau \in (0, 0.5; 1)$)
- ⊖ для больших задач хранить x^{k-1} дорого
- ⊖ в теории нетоз НВ не лучше, чем GD

Особенности:

- ⊙ некон. сходимость

Градиентный спуск с моментом (pytorch):

$$\begin{aligned} v^{k+1} &= \beta v^k + \nabla f(x^k) \\ x^{k+1} &= x^k - \gamma v^{k+1} \end{aligned} \quad \beta \in (0, 1)$$

$$x^{k+1} = x^k - \gamma \nabla f(x^k) - \gamma \beta v^k$$

пред. см.: $x^k = x^{k-1} - \gamma v^k \Rightarrow -\gamma v^k = x^k - x^{k-1}$

$$\underline{x^{k+1} = x^k - \gamma \nabla f(x^k) + \beta(x^k - x^{k-1})} \quad \text{НВ}$$

Работа с точки зрения ML:

НВ моментум = сохранение старых значений с уменьш. весом

Ускоренный градиентный спуск (Nesterov)

Ю. Е. Нестеров 1983

Алгоритм 3 Ускоренный градиентный метод

Вход: размер шагов $\{\gamma_k\}_{k=0} > 0$, моменты $\{\tau_k\}_{k=0} \in [0; 1]$,
стартовая точка $x^0 = y^0 \in \mathbb{R}^d$, количество итераций K

- 1: for $k = 0, 1, \dots, K-1$ do
- 2: Вычислить $\nabla f(y^k)$
- 3: $x^{k+1} = y^k - \gamma_k \nabla f(y^k)$
- 4: $y^{k+1} = x^{k+1} + \tau_k(x^{k+1} - x^k)$
- 5: end for

Выход: x^K

$$y^k = x^k + \tau_{k-1}(x^k - x^{k-1})$$
$$x^{k+1} = y^k - \gamma_k \nabla f(y^k)$$

Nesterov: $x^{k+1} = x^k + \tau_{k-1}(x^k - x^{k-1}) - \gamma_k \nabla f(x^k + \tau_{k-1}(x^k - x^{k-1}))$

HB: $x^{k+1} = x^k + \tau_{k-1}(x^k - x^{k-1}) - \gamma_k \nabla f(x^k)$

↑
интерпол.
в точке
последнего шаг.

Плюсы:

- ⊕ плюсы HB
- ⊕ есть теория по выбору $\tau_k = \frac{k}{k+3}$; $\frac{k}{k+2}$
- ⊕ теор. лучше, чем град. спуск

Nesterov:

$$O\left(\sqrt{\frac{L}{\mu}} \log \frac{f(x^0) - f(x^*) + \|x^0 - x^*\|^2}{\varepsilon}\right)$$

итерацион./
опер. вызовов

лучше, чем $y \in D$ $O\left(\frac{L}{\mu}\right)$

- ⊕ отрицателен

Минусы:

- ⊖ минусы HB

Особенности:

- ⊖ как у HB

A nome m name?

functiune convexa:

(3)

μ -convexa b.m.
L-nagru

(M)

"maxima" M_k

- unu: $M_0 = \{x^0\} = \{\vec{0}\}$
- obnobi: $M_k = \text{span}\{x', \text{PF}(x'')\}$
 $x', x'' \in M_{k-1}$
- b.m.: $x \in M_K$

GD, HB, Nesterov gogor

Prosta zagada (qyryvnyu):

△ $f(x) = \frac{L-\mu}{8} x^T A x + \frac{\mu}{2} \|x\|^2 - \frac{L-\mu}{4} e_1^T x$

$$A = \begin{pmatrix} 2 & -1 & & 0 \\ -1 & 2 & -1 & \\ & -1 & 2 & \\ 0 & & & \ddots & 2 & -1 \\ & & & & -1 & \ddots \end{pmatrix}$$

$$e_1 = \begin{pmatrix} 1 \\ 0 \\ \vdots \\ 0 \end{pmatrix}$$

f - wogryvnyu gogor

- $A \geq 0$, moza f - μ -convexa b.m.
- $\|A\|_2 \leq 4$, moza f L-nagru

1) Temenne $\min_{x \in \mathbb{R}^d} f(x)$

$$\text{PF}(x^*) = 0 \Rightarrow \frac{L-\mu}{4} A x^* + \mu x^* - \frac{L-\mu}{4} e_1 = 0$$

no karmochennu

- первая вершина:

$$\frac{2(L+\mu)}{L-\mu} X_1^* - X_2^* = 1$$

кар. верш.

- остальные (кроме первой и последней):

$$-X_{k+1}^* + \frac{2(L+\mu)}{L-\mu} X_k^* - X_{k-1}^* = 0$$

линейно
рекур.

- последние верш:

.... (завис от ξ)

кар.
верш.

Решение рекуррент

$$X_k^* = q^k \quad q = \frac{\sqrt{L-\mu}}{\sqrt{L+\mu}}$$

~~q^k~~

за от ξ

$$X_{k+1} = AX_k + BX_{k-1}$$

$$\lambda^2 = A\lambda + B$$

λ_1, λ_2 - корни

$$\lambda_1 \neq \lambda_2$$

$$X_k = C_1 \lambda_1^k + C_2 \lambda_2^k$$

C_1, C_2 из
кар. вершин

2) Как расставить массы из условия:

$$\nabla f(x) = \frac{L-\mu}{4} Ax + \mu x - \frac{L-\mu}{4} e_1$$

$$\sim Ax + x + e_1$$

- старший из 0

возвращает грани ∇f

$$\text{span}\{0, \nabla f(0)\} = \text{span}\{e_1\}$$

расшириваем тип коор.

- 1ая коор. неизменна

возвращает грани ∇f

$$\text{span}\{e_1, \nabla f(x)\} = \text{span}\{e_1, e_2\}$$

$x \in \text{span}\{e_i\}$
 предполож. 2-го ранга.

- k собственных значений $\nabla f \Rightarrow k$ ненулевых
 векторов.
 ост. все нулевые

3) Действительно известно $d = 2\bar{K}$ (\bar{K} ненулевых
 значений ∇f)

В нечетных случаях мы знаем \bar{K} ненулевых
 векторов

то все ост. ноль в строке

$$\|X^{\bar{K}} - X^*\|^2 \geq \underbrace{\sum_{k=1}^{\bar{K}} 0}_{\text{все нулевые}} + \sum_{k=\bar{K}+1}^{2\bar{K}} (\underbrace{0}_{\text{строка}} - \underbrace{q^k}_{X_k^*})^2$$

$$= \sum_{k=\bar{K}+1}^{2\bar{K}} (q^k)^2 = q^{2\bar{K}} \sum_{k=1}^{\bar{K}} (q^k)^2$$

$$\|X^0 - X^*\|^2 = \|X^*\|^2 = \sum_{k=1}^{2\bar{K}} (q^k)^2 =$$

$$= \sum_{k=1}^{\bar{K}} (q^k)^2 + \underbrace{\sum_{k=\bar{K}+1}^{2\bar{K}} (q^k)^2}_{q^{2\bar{K}} \sum_{k=1}^{\bar{K}} (q^k)^2}$$

$$= (1 + q^{2\bar{K}}) \sum_{k=1}^{\bar{K}} (q^k)^2$$

$$\begin{aligned}
\|x^k - x^*\|^2 &\geq \frac{q^{2k}}{1 + q^{2k}} \|x^0 - x^*\|^2 \\
&\geq \frac{q^{2k}}{2} \|x^0 - x^*\|^2 \\
&= \left(1 - \frac{2\sqrt{\mu}}{\sqrt{L} + \sqrt{\mu}}\right)^{2k} \frac{\|x^0 - x^*\|^2}{2}
\end{aligned}$$

$$\varepsilon \sim \|x^k - x^*\|^2$$

ф-ка минимизации

f - L -выпукл, μ - число выпуклости,

тогда минимизация функции требует решения
 $(\|x^k - x^*\|^2 \leq \varepsilon)$ не более, чем

$$\Omega \left(\sqrt{\frac{L}{\mu}} \log \frac{\|x^0 - x^*\|^2}{\varepsilon} \right) \text{ операций}$$

Минимум достигается!