

• Угловой метод Рунге

★  $\varphi: \mathbb{R} \rightarrow \mathbb{R}$

Найти  $t^* : \varphi(t^*) = 0$

Углы:

выберем точку  $t^0 \in \mathbb{R}$

В углы найдем  $\Delta t : t^0 + \Delta t \approx t^*$

Запишем в ряд:

$$\varphi(t^0 + \Delta t) = \varphi(t^0) + \varphi'(t^0) \Delta t + o(\Delta t)$$

$$\varphi(t^*) = 0 \Rightarrow \varphi(t^0) + \varphi'(t^0) \Delta t \approx 0$$

$\Downarrow$

$$\Delta t = - \frac{\varphi(t^0)}{\varphi'(t^0)}$$

$$t^1 = t^0 - \frac{\varphi(t^0)}{\varphi'(t^0)}$$

$$t^{k+1} = t^k - \frac{\varphi(t^k)}{\varphi'(t^k)}$$

← метод Рунге  
в угловом варианте

• Пример работы

★  $\varphi(t) = \frac{t}{\sqrt{1+t^2}} \quad t^* = 0$

$$\varphi'(t) = \frac{1}{(1+t^2)^{3/2}}$$

Угловой метод Рунге:

$$t^{k+1} = t^k - \frac{\varphi(t^k)}{\varphi'(t^k)} = t^k - \frac{\frac{t^k}{(1+(t^k)^2)^{1/2}}}{\frac{1}{(1+(t^k)^2)^{3/2}}} = t^k - t^k (1+(t^k)^2)$$

$$= - (t^k)^3$$

Есть ли сходимость?

-  $|t^0| > 1$   $t^0 = 2 \rightarrow -8 \rightarrow 8^3 \rightarrow \dots$  *расходится*

-  $|t^0| = 1$   $t^0 = 1 \rightarrow -1 \rightarrow 1 \rightarrow -1$  *качается в -1; 1*

-  $|t^0| < 1$   $t^0 = 1/2 \rightarrow -1/8 \rightarrow 1/8^3 \rightarrow \dots$  *сходимость*  
*очень быстро*

Выводы из неогр. св-ва:

⊖ *локальная сходимость*

⊕ *глобальная сходимость*

Обратно к оптимизации:

$$\min_{x \in \mathbb{R}^d} f(x)$$

Плоше нуля, но  $\nabla f(x^*) = 0$

Метод Ньютона для  $\nabla f(x^*) = 0$

$$x^{k+1} = x^k - (\nabla^2 f(x^k))^{-1} \nabla f(x^k)$$

*метод Ньютона для Селленовей задачи оптимизации*

Другая итерация

Разлагается  $f$  в окр.  $x^k$

$$f(x) \approx f(x^k) + \langle \nabla f(x^k); x - x^k \rangle + \frac{1}{2} \langle x - x^k; \nabla^2 f(x^k) (x - x^k) \rangle$$

*минимизация квадратичного*  
*≈ решение*

Минимизация квадрат. аппроксимации:

$$\nabla f(x^k) + \nabla^2 f(x^k) (x - x^k) = 0$$

$$x_{k+1}^{\uparrow} = x^k - (\nabla^2 f(x^k))^{-1} \nabla f(x^k)$$

Две вложен. з.:  $\min \frac{1}{2} x^T A x \quad A \succ 0 \quad A \in S$

$$x^1 = x^0 - A^{-1} A x^0 = 0 \leftarrow \text{результат}$$

это вложен. задачи - за 1 шаг, не говоря

## • Свойства

Предположения:

- 1)  $f$  -  $\mu$ -сильно выпуклая  $\nabla^2 f(x) \succeq \mu I$
- 2)  $M$ -лимитный радиус  $\|\nabla^2 f(x) - \nabla^2 f(y)\|_2 \leq M \|x - y\|_2$   
↑  
лимитный радиус

Док-во свойства:

$$x^{k+1} - x^* = x^k - (\nabla^2 f(x^k))^{-1} \underbrace{\nabla f(x^k)}_{(1)} - x^*$$

группировка по формуле - Leibniz (1 раз)

$$\underbrace{\nabla f(x^k)}_{(2)} - \cancel{\nabla f(x^*)} = \int_0^1 \nabla^2 f(x^* + \tau(x^k - x^*)) (x^k - x^*) d\tau$$

Подстановка (2) в (1):

$$x^{k+1} - x^* = x^k - x^* - (\nabla^2 f(x^k))^{-1} \int_0^1 \nabla^2 f(x^* + \tau(x^k - x^*)) (x^k - x^*) d\tau$$

группировка "1":

$$x^{k+1} - x^* = \underbrace{(\nabla^2 f(x^k))^{-1}} \underbrace{\nabla^2 f(x^k)} \underbrace{(x^k - x^*)}_{(1)} - \underbrace{(\nabla^2 f(x^k))^{-1}} \int_0^1 \nabla^2 f(x^* + \tau(x^k - x^*)) \underline{(x^k - x^*)} d\tau$$

Выводим за "сумму"

$$\begin{aligned} x^{k+1} - x^* &= (\nabla^2 f(x^k))^{-1} \left( \nabla^2 f(x^k) - \int_0^1 \nabla^2 f(x^* + \tau(x^k - x^*)) d\tau \right) (x^k - x^*) \\ &= (\nabla^2 f(x^k))^{-1} \underbrace{\int_0^1 (\nabla^2 f(x^k) - \nabla^2 f(x^* + \tau(x^k - x^*))) d\tau}_{G_k} (x^k - x^*) \end{aligned}$$

$$\|x^{k+1} - x^*\|_2 = \|(\nabla^2 f(x^k))^{-1} G_k (x^k - x^*)\|_2$$

$$\leq \|(\nabla^2 f(x^k))^{-1} G_k\|_2 \|x^k - x^*\|_2$$

$$\leq \|(\nabla^2 f(x^k))^{-1}\|_2 \|G_k\|_2 \|x^k - x^*\|_2$$

$$\nabla^2 f(x) \succeq \mu I \Rightarrow (\nabla^2 f(x))^{-1} \preceq \frac{1}{\mu} I \Rightarrow \|(\nabla^2 f(x^k))^{-1}\|_2 \leq \frac{1}{\mu}$$

$$\leq \frac{1}{\mu} \|G_k\|_2 \|x^k - x^*\|_2 \Leftrightarrow$$

$$\|G_k\|_2 = \left\| \int_0^1 (\nabla^2 f(x^k) - \nabla^2 f(x^* + \tau(x^k - x^*))) d\tau \right\|_2$$

$$\leq \int_0^1 \|\nabla^2 f(x^k) - \nabla^2 f(x^* + \tau(x^k - x^*))\|_2 d\tau$$

$M$ -лимитное значение

$$\leq \int_0^1 M(1-\tau) \|x^k - x^*\|_2 d\tau$$

$$= \frac{M}{2} \|x^k - x^*\|_2$$

$$\Leftrightarrow \frac{M}{2\mu} \|x^k - x^*\|_2^2$$

Сходимость немого алгоритма

$$\boxed{\|x^{k+1} - x^*\|_2 \leq \frac{M}{2\mu} \|x^k - x^*\|_2^2}$$

квадратичная сходимость

Сходимость есть?

$$\|x^1 - x^*\|_2 < \|x^0 - x^*\|_2$$

выполняется, если  $\|x_0 - x^*\|_2 < \frac{2\mu}{L}$

покажем сходимость

Пример сходимости:

$$M=2 \quad \mu=1 \quad \|x^0 - x^*\|_2 = \frac{1}{2}$$

$$\|x^1 - x^*\|_2 = \left(\frac{1}{2}\right)^2 \rightarrow \left(\left(\frac{1}{2}\right)^2\right)^2 \rightarrow \left(\left(\left(\frac{1}{2}\right)^2\right)^2\right)^2 \text{ квадратичная}$$

Из чего не можем вывести:

⊕ квадратичная сходимость

⊖ локальная сходимость (из окр. решения)

⊖ глобальная минимизация

• Модификация для безусловной оптимизации

1) Демонстрирование (глобальное макс)

$$x^{k+1} = x^k - \gamma_k (\nabla^2 f(x^k))^{-1} \nabla f(x^k)$$

как подобрать шаг?

- см. 2 лекция

$$\argmin_{\gamma \in \mathbb{R}} f(x^k + \gamma p^k)$$

$$p^k = -(\nabla^2 f(x^k))^{-1} \nabla f(x^k)$$

выпускаю по  $\gamma$ : градиентный, золотое сечение

2) Кусаческий метод Ньютона

Уточнение:

$$x^{k+1} = \argmin_{x \in \mathbb{R}^d} \left( f(x^k) + \langle \nabla f(x^k); x - x^k \rangle + \frac{L}{2} \|x - x^k\|_2^2 \right)$$

$\Downarrow$  GD с шагом  $\frac{1}{L}$

$$x^{k+1} = x^k - \frac{1}{L} \nabla f(x^k)$$

Плюс не самая идея в смысле ввагр. сложности

$$x^{l+1} = \underset{x \in \mathbb{R}^d}{\operatorname{argmin}} \left( f(x^k) + \langle \nabla f(x^k); x - x^k \rangle + \frac{1}{2} \langle x - x^k; \nabla^2 f(x^k)(x - x^k) \rangle + \frac{M}{6} \|x - x^k\|_2^3 \right)$$

↑ гипотеза  
не самая простая задача
↑  
M-лимитированная версия

### • Квази-Ньютоновские методы

$$x^{l+1} = x^k - H_k \nabla f(x^k)$$

— в Ньютоне:  $H_k = (\nabla^2 f(x^k))^{-1}$  ← хотим избежать

— идея: не использовать  $\nabla^2 f$ , но  $H_k \rightarrow H_{k+1}$  за один двойной шаг

$$\nabla f(x^k) \approx \nabla f(x^{l+1}) + \underbrace{\nabla^2 f(x^{l+1})}_{H_{k+1}^{-1}} (x^k - x^{l+1})$$

$$H_{k+1} \underbrace{(\nabla f(x^k) - \nabla f(x^{l+1}))}_{y^k} \approx \underbrace{x^k - x^{l+1}}_{s^k}$$

скалярно решение  
не  $H_{k+1}$ ? ∞

$$\begin{aligned} s^k &= H_{k+1} y^k \\ H_{k+1}^T &= H_{k+1} \end{aligned}$$

← квази-Ньютоновские  
уравнения (сб-во решения)

↓  
улучшение  $H_{k+1}$   
( $H_{k+1}$  из  $H_k$ )

Частные случаи:

• SR1 / Broyden (одномерное улучшение):

$$H_{k+1} = H_k + \underbrace{\mu_k}_{\in \mathbb{R}} \underbrace{g^k}_{\in \mathbb{R}^d} (g^k)^T$$

Квадратичная форма

$$s^k = H_{k+1} y^k = H_k y^k + \mu_k q^k \underbrace{(q^k)^T y^k}_{\in \mathbb{R}}$$

$$= \underbrace{H_k y^k}_{\in \mathbb{R}^d} + \underbrace{\mu_k (q^k)^T y^k}_{\in \mathbb{R}} \underbrace{q^k}_{\in \mathbb{R}^d}$$

$$s^k - H_k y^k = \mu_k (q^k)^T y^k \cdot q^k$$

$$q^k \parallel s^k - H_k y^k \Rightarrow \boxed{q^k = s^k - H_k y^k}$$

$$\mu_k (q^k)^T y^k = 1 \Rightarrow \boxed{\mu_k = \frac{1}{(q^k)^T y^k}}$$

• BFGS

$$H_{k+1} = \arg \min_{H \in \mathbb{R}^{d \times d}} \text{ s.t.}$$

$$\|H - H_k\|^2$$

$$s^k = H y^k \quad \text{moder}$$

$$H^T = H$$

BFGS учн. бзбемн. дзбемн. нзбемн.

$$\|A\|_W = \|W^{1/2} A W^{1/2}\|_F$$

$$W y^k = s^k$$

$$H_{k+1} = \underbrace{\left( I - \frac{s^k (y^k)^T}{(y^k)^T s^k} \right) H_k \left( I - \frac{s^k (y^k)^T}{(y^k)^T s^k} \right) + \frac{s^k (s^k)^T}{(y^k)^T s^k}}_{\text{размерность не в бзбемн. mat x mat } O(d^3)}$$

нзбемн. нзбемн. нзбемн.

$$\Rightarrow B_{k+1} = H_{k+1}^{-1}$$

$$\text{где } B_k \text{ матрица размерности: } B_{k+1} s^k = y^k$$

SR1 для  $B_k$ : 
$$B_{k+1} = B_k + \frac{(y^k - B_k s^k)(y^k - B_k s^k)^T}{(y^k - B_k s^k)^T s^k}$$

иногда возникает  $y^k (y^k)^T$   $B_k s^k (B_k s^k)^T$   ~~$B_k s^k (y^k)^T$~~   
↑  
исчез

$$B_{k+1} = B_k + \mu_1 y^k (y^k)^T + \mu_2 (B_k s^k) (B_k s^k)^T$$

приведенный в скобках. гр-е

$$B_{k+1} = B_k + \frac{(y^k)(y^k)^T}{(y^k)^T s^k} + \frac{(B_k s^k)(B_k s^k)^T}{(s^k)^T B_k s^k}$$

Мерманс - Меркусонс - Вудберн (SMW)  
 (формула обрешена минимизации бага  $A + PCD$ )

$$H_{k+1} \xrightarrow{\text{SMW}} B_{k+1}$$

Условия по условиям-предположениям:

- ⊕ генерация матрицы  $O(d^2)$  и не надо вводить весов
- ⊕ модальная суперлинейная сложность  
(супер-линейная)  
(супер-линейная, ED)