

на прямой линии

градиентный спуск $\|x^k - x^*\|_2^2 \sim \varepsilon$
 $\frac{1}{\mu} \log\left(\frac{\|x^0 - x^*\|_2^2}{\varepsilon}\right)$ итераций /
градиент. спуск

а можно лучше?

1964 г. - Б.П. Телюк



Алгоритм 2 Метод тяжелого шарика

Вход: размер шагов $\{\gamma_k\}_{k=0} > 0$, моменты $\{\tau_k\}_{k=0} \in [0; 1]$,
стартовая точка $x^0 = x^{-1} \in \mathbb{R}^d$, количество итераций K

- 1: for $k = 0, 1, \dots, K-1$ do
- 2: Вычислить $\nabla f(x^k)$
- 3: $x^{k+1} = x^k - \gamma_k \nabla f(x^k) + \tau_k (x^k - x^{k-1})$
- 4: end for

Выход: x^K

Рисунок:



Пример: в pytorch

$$\begin{aligned} v^{k+1} &= \beta v^k + \nabla f(x^k) \\ x^{k+1} &= x^k - \gamma v^{k+1} \end{aligned} \quad \beta \in [0; 1]$$

во вводе не надо

$$\begin{aligned} x^{k+1} &= x^k - \gamma \beta v^k - \gamma \nabla f(x^k) \\ \text{на } k \text{ шаг } v^k: \quad x^k &= x^{k-1} - \gamma v^k \\ -\gamma v^k &= x^k - x^{k-1} \\ x^{k+1} &= x^k + \beta (x^k - x^{k-1}) - \gamma \nabla f(x^k) \end{aligned}$$

- ⊕ не требует градиента и итераций
- ⊕ легко имплементировать
- ⊕ генерация вогнутостей
- ⊖ два параметра: γ_k и τ_k $\tau_k \in [0, 9; 995]$
- ⊖ неясн. сходимость
- ⊖ метод не лучше, чем град. спуск

1983 г. - Ю.Е. Кестеров

Алгоритм 3 Ускоренный градиентный метод

Вход: размер шагов $\{\gamma_k\}_{k=0} > 0$, моменты $\{\tau_k\}_{k=0} \in [0; 1]$, стартовая точка $x^0 = y^0 \in \mathbb{R}^d$, количество итераций K

- 1: for $k = 0, 1, \dots, K-1$ do
- 2: Вычислить $\nabla f(y^k)$
- 3: $x^{k+1} = y^k - \gamma_k \nabla f(y^k)$
- 4: $y^{k+1} = x^{k+1} + \tau_k (x^{k+1} - x^k)$
- 5: end for

Выход: x^K

Полный шаг:

$$x^{k+1} = x^k - \gamma \nabla f(x^k) + \tau (x^k - x^{k-1})$$

Метод Кестерова:

$$x^{k+1} = y^k - \gamma \nabla f(y^k) \quad | \quad y^k = x^k + \tau (x^k - x^{k-1})$$

$$x^{k+1} = x^k + \underbrace{\tau (x^k - x^{k-1})}_{\text{итерация}} - \gamma \nabla f(\underbrace{x^k + \tau (x^k - x^{k-1})}_{\text{итерация в точке подвига}})$$

Другой ускоренный метод:

Алгоритм 5 Линейный каплинг: внутренний цикл

Вход: размер шагов $\gamma > 0$ и $\eta > 0$, момент $\tau \in [0; 1]$, стартовая точка $x^0 = y^0 = z^0 \in \mathbb{R}^d$, количество итераций K

- 1: for $k = 0, 1, \dots, K-1$ do
- 2: Вычислить $\nabla f(x^k)$
- 3: $y^{k+1} = x^k - \eta \nabla f(x^k) \leftarrow \text{"неделительный"} \quad \eta = \frac{1}{L} \text{ град. спуск}$
- 4: $z^{k+1} = z^k - \gamma \nabla f(x^k) \leftarrow \text{"близкий"} \quad \gamma = \frac{1}{5\mu L}$
- 5: $x^{k+1} = \tau z^{k+1} + (1-\tau)y^{k+1}$
- 6: end for

Выход: $\frac{1}{K} \sum_{k=0}^{K-1} x^k$

О сходимости линейного каплинга

Пусть задача безусловной оптимизации с L -гладкой, μ -сильно выпуклой целевой функцией f решается с помощью реставрированного линейного каплинга. Тогда при $\eta = \frac{1}{L}$, $\gamma = \sqrt{\frac{1}{\mu L}}$ и $K = \sqrt{\frac{16L}{\mu}}$, чтобы добиться точности ε по функции ($f(x) - f(x^*) \leq \varepsilon$), необходимо

для метода Кестерова оптимально $\rightarrow O\left(\sqrt{\frac{L}{\mu}} \log \frac{f(x^0) - f(x^*)}{\varepsilon}\right)$ вызовов оракула. лучше, чем град. спуск

Град. спуск: $\frac{L}{\mu} \log \frac{f(x^0) - f(x^*)}{\varepsilon}$ орак. вызовов

А можно и еще лучше?

линейные ограничения

линейные классы ограничений:

1) x^0 - опорная точка $M = \{x^0\}$
 "наименьший"

2) $\nabla f(x')$, где $x' \in M$

добавляя в M можно

$$x \in \text{span} \{x'', \nabla f(x')\} \quad \begin{matrix} x' \in M \\ x'' \in M \end{matrix}$$

$$M = \text{span} \{x, M\}$$

3) берем за I такое что $x_{\text{opt}} \in M$

- оптимальное решение здесь не будет
- здесь не все ограничения выполнены

линейные ограничения для этого класса

"Плюс" границы $x \in \mathbb{R}^d \leftarrow \text{размерность}$

$$f(x) = \frac{L-\mu}{8} x^T A x + \frac{\mu}{2} x^T x - \frac{L-\mu}{4} e_1^T x,$$

$$A = \begin{pmatrix} 2 & -1 & 0 & & \\ -1 & 2 & -1 & & \\ & -1 & 2 & \ddots & \\ & & \ddots & \ddots & -1 \\ 0 & & & -1 & \zeta \end{pmatrix}, \quad e_1 = \begin{pmatrix} 1 \\ 0 \\ \vdots \\ 0 \end{pmatrix},$$

0) f - μ -выпуклая функция и L -гладкая

1) Найдем f : $\arg \min_{x \in \mathbb{R}^d} f(x)$

$$\nabla f(x^*) = 0$$

$$\left(\frac{L-\mu}{4} A + \mu I \right) x^* - \frac{L-\mu}{4} e_1 = 0$$

$$A x^* + \frac{4\mu}{L-\mu} x^* - e_1 = 0$$

Далее по формулам:

$$2X_1^* - X_2^* + \frac{4\mu}{L-\mu} X_1^* - 1 = 0 \quad \leftarrow \text{1 шаг}$$

$$-X_{k-1}^* + \frac{2(L+\mu)}{L-\mu} X_k^* - X_{k+1}^* = 0 \quad \leftarrow \text{все шаги 1 и посл.}$$

где показан

переход 2 порядка:

$$-1 + \frac{2(L+\mu)}{L-\mu} \lambda - \lambda^2 = 0$$

$$X_k^* = C_1 \lambda_1^k + C_2 \lambda_2^k$$

NB ξ задан так, что

$$X_k^* = \lambda_1^k \quad \lambda_1 = \frac{\sqrt{L-\mu}}{\sqrt{L+\mu}}$$

один из корней

$$2) \quad X^0 = 0 \quad \leftarrow \text{точка} \quad M = \{0\}$$

$$\nabla f(x) = \frac{L-\mu}{4} Ax + \mu x - \frac{L-\mu}{4} e_1$$

$$\nabla f(x^0) \in \text{span} \{e_1\}$$

за один шаг шаг +1 требуется шаг.

за k шагов требуется шаг +1 требуется шаг в M

О.б.с.д.д.д.д.д. $d = 2K$ K - кол-во шагов ∇

за K шагов в точке $M = \text{span} \{e_1, \dots, e_K\}$

в точке M K первых в X^* градиент равен нулю, а все остальные равны 0

$$\|X^k - X^*\|_2^2 \geq \sum_{i=k+1}^{2K} \lambda_1^{2i} = \lambda^{2K} \sum_{i=1}^K \lambda_1^{2i} =$$

вектор

не градиент $K+1$ до $2K$

$$\|X^0 - X^*\|_2^2 = \|X^*\|_2^2 =$$

$$= \sum_{i=1}^{2K} \lambda_1^{2i} =$$

$$= (1 + \lambda_1^{2K}) \sum_{i=1}^K \lambda_1^{2i}$$

$$= \frac{\lambda_1^{2k}}{\lambda_1^{2k} + 1} \|x^0 - x^*\|_2^2 \geq \frac{\lambda_1^{2k}}{2} \|x^0 - x^*\|_2^2$$

$$= \left(1 - \frac{2\sqrt{\mu}}{\sqrt{L} + \sqrt{\mu}}\right)^{2k} \frac{\|x^0 - x^*\|_2^2}{2}$$

Нижняя оценка на оракульную сложность

Для любого метода из класса, описанного выше, существует безусловная задача оптимизации с L -гладкой, μ -сильно выпуклой целевой функцией f такая, что для решения этой задачи методу необходимо

$$\Omega\left(\sqrt{\frac{L}{\mu}} \log \frac{\|x^0 - x^*\|_2}{\varepsilon}\right) \text{ вызовов оракула.}$$

- ⊕ метод Каспарова / линейной внешней оптимизации и неограничен (NB в классе (где сильно выпуклых и выпуклых) span)
- ⊕ метод множественного интереса
- ⊖ методом. сходимость
- ⊖ гл. переопределенности