

Найти $x \in \mathbb{R}^d$: $Ax = b$ — СЛУ

$A \in \mathbb{R}^{d \times d}$ — квадрат. матрица (симм.)

$b \in \mathbb{R}^d$

Сопряженные направления

Определение сопряженных направлений

Множество векторов $\{p_i\}_{i=0}^{n-1}$ будем называть сопряженным относительно положительно определенной матрицы A , если для любых $i \neq j \in \{0, \dots, n-1\}$ следует

$$p_i^T A p_j = 0. \quad \leftarrow \text{ортонорм. сист. } A$$

$$\langle p_i, p_j \rangle = 0 \quad p_i^T p_j = 0 \quad (\text{ортонорм.})$$

Линейная независимость сопряженных направлений

Сопряженные векторы $\{p_i\}_{i=0}^{n-1}$ являются линейно независимыми.

Док-во: от противного

$$\exists \exists p_i : p_i = \sum_{j \neq i} \lambda_j p_j \quad \text{где } \exists \lambda_j \in \mathbb{R}$$

но сопр. сопр. напрвл. ($A p_m$ или $p_m^T A^T$
 $\quad \quad \quad m \neq i$ $\quad \quad \quad A$)

$$\underbrace{p_m^T A p_i}_{=0, m \neq i} = \sum_{j \neq i} \lambda_j \underbrace{p_m^T A p_j}_{\substack{j \neq m \\ p_m^T A p_j = 0}} = \lambda_m \underbrace{p_m^T A p_m}_{>0}$$

$\lambda_m = 0$
но все m $\lambda_m = 0 \Rightarrow$ противоречие

$\{p_i\}$ — базис

$$\nearrow x^* = \sum_{i=0}^{d-1} \lambda_i p_i$$

решение
СЛУ

из композиции $(p_j^T A \cdot)$:

$$\underbrace{p_j^T A x^*}_{\in \mathbb{R}} = \sum_{i=0}^{d-1} \lambda_i \underbrace{p_j^T A p_i}_{\substack{\uparrow \\ i \neq j \\ p_j^T A p_i = 0}} = \lambda_j \underbrace{p_j^T A p_j}_{\in \mathbb{R}}$$

$$\lambda_j = \frac{p_j^T A x^*}{p_j^T A p_j} = \frac{p_j^T b}{p_j^T A p_j}$$

\uparrow
 $Ax^* = b$

Итерационный метод

$$x^{k+1} = x^k + \alpha_k p_k$$

итерационно задано в x новое направление

$$\alpha = \lambda?$$

$$x^d = x^0 + \sum_{i=0}^{d-1} \alpha_i p_i$$

Значит

$$x^d = x^* = \sum_{i=0}^{d-1} \lambda_i p_i$$

• если $x^0 = 0$ $\alpha_i = \lambda_i$

• если $x^0 \neq 0$, то можно выбрать α_i

x^0 по p_i

$$x^0 = \sum_{i=0}^{d-1} \lambda_i p_i \quad \left| \begin{array}{l} p_j^T A \cdot \\ p_j^T A x^0 = p_j^T A p_j \cdot \lambda_j \end{array} \right.$$

$$\lambda_i = \frac{p_i^T A x^0}{p_i^T A p_i}$$

$$x^* = x^0 + \sum_{i=0}^{d-1} \alpha_i p_i = \sum_{i=0}^{d-1} \lambda_i p_i$$

$$\sum_{i=0}^{d-1} \frac{p_i^T A x^0}{p_i^T A p_i} p_i + \sum_{i=0}^{d-1} \alpha_i p_i = \sum_{i=0}^{d-1} \frac{p_i^T b}{p_i^T A p_i} p_i$$

$$\alpha_i = \frac{p_i^T (b - A x^0)}{p_i^T A p_i} \quad \text{удобен}$$

$$p_k^T A(x^k - x^0) = 0 \quad \Bigg| \quad \underbrace{x^k - x^0}_{p_k^T A} = \underbrace{\sum_{i=0}^{k-1} \alpha_i p_i}_{p_k^T A \uparrow \overset{\text{comp.}}{=} 0}$$

$$\Downarrow$$

$$-p_i^T A x^0 = -p_i^T A x^i$$

$$\Downarrow$$

$$\alpha_i = \frac{p_i^T (b - A x^i)}{p_i^T A p_i} = - \frac{p_i^T r_i}{p_i^T A p_i} = Ax^i - b$$

Optimization criteria



$$\triangleleft \quad \begin{aligned} f(x) &= \frac{1}{2} x^T A x - b^T x \\ \nabla f(x^*) &= A x^* - b = 0 \end{aligned} \quad \left. \vphantom{\begin{aligned} f(x) &= \frac{1}{2} x^T A x - b^T x \\ \nabla f(x^*) &= A x^* - b = 0 \end{aligned}} \right\} \begin{array}{l} \text{matrix symmetric} \\ \text{CAY} \end{array}$$

$$\triangleleft \quad g(\alpha) = f(x^k + \alpha p_k) \quad \Bigg| \quad f(x^k - \alpha \nabla f(x^k))$$


\uparrow
 $\arg\min_{\alpha}$

$$\alpha^* = \arg\min g(\alpha)$$

$$= \frac{p_k^T (b - A x^k)}{p_k^T A p_k} \quad \leftarrow \text{max } b \text{ minus } b_{\text{new}}!$$



comp. range
ke \perp



α -min

ggere \perp , ke ke
comp on A
ga 2 mura ke
comp.

Регрессионный смысл p

Физический смысл p

Если $\{p_i\}_{i=0}^k$ сопряженные направления, то для любого $k \geq 0$ и $i \leq k$ справедливо:

$$r_{k+1}^T p_i = 0 \text{ то же самое, что } \langle \nabla f(x^{k+1}), p_i \rangle = 0.$$

указывает
в какой
стороне \perp
к вектору p_i
идет шаг
 p_i все уг. орт.

$$r_k = Ax^k - b \quad \alpha_k = - \frac{p_k^T r_k}{p_k^T A p_k}$$

$$x^{k+1} = x^k + \alpha_k p_k$$

Доказ. по индукции

База: $p_0^T r_1 = 0$?

$$r_1 = Ax^1 - b = \underbrace{Ax^0 - b}_{r_0} + \alpha_0 A p_0 = r_0 + \alpha_0 A p_0$$

$$p_0^T r_1 = p_0^T (r_0 + \alpha_0 A p_0) = \cancel{p_0^T r_0} - \frac{\cancel{p_0^T r_0}}{\cancel{p_0^T A p_0}} \cdot \cancel{p_0^T A p_0} = 0$$

Шаг: верно $i \leq k$

Шаг: $p_k^T r_{k+1} = 0$? $p_i^T r_{k+1} = 0$?

$$r_{k+1} = \underbrace{Ax^{k+1} - b}_r = \underbrace{Ax^k - b}_{r_k} + \alpha_k A p_k = r_k + \alpha_k A p_k$$

$$p_k^T r_{k+1} = p_k^T r_k + \alpha_k p_k^T A p_k \stackrel{(\oplus)}{=} 0$$

$$i < k \quad p_i^T r_{k+1} = \underbrace{p_i^T r_k}_{0 \text{ (по)}} + \alpha_k \underbrace{p_i^T A p_k}_{0 \text{ (орт.)}} = 0 \quad (\oplus)$$

Цель: считать p_k итерационно
 "гембо" — не хочется хранить p_k
 не хочется пересч. по всем p_i

$$p_k = -\underbrace{r_k}_{\nabla f(x^k)} + \underbrace{\beta_k}_{\in \mathbb{R}} p_{k-1}$$

Найти: p_k и p_{k-1} сопряженные

$$0 = \underbrace{p_{k-1}^T}_{\text{сomp.}} A p_k = -\underbrace{p_{k-1}^T A r_k}_{\in \mathbb{R}} + \underbrace{\beta_k}_{\in \mathbb{R}} \underbrace{p_{k-1}^T A p_{k-1}}_{\in \mathbb{R}}$$

$$\beta_k = \frac{p_{k-1}^T A r_k}{p_{k-1}^T A p_{k-1}}$$

Алгоритм 1 Метод сопряженных градиентов

Вход: стартовая точка $x^0 \in \mathbb{R}^d$, $r_0 = Ax_0 - b$, $p_0 = -r_0$ количество итераций K

1: **for** $k = 0, 1, \dots, K-1$ **do**

2: $\alpha_k = -\frac{r_k^T p_k}{p_k^T A p_k}$

3: $x^{k+1} = x^k + \alpha_k p_k$

4: $r_{k+1} = Ax^{k+1} - b \leftarrow \nabla f$

5: $\beta_{k+1} = \frac{r_{k+1}^T A p_k}{p_k^T A p_k}$

6: $p_{k+1} = -r_{k+1} + \beta_{k+1} p_k$

7: **end for**

Выход: x^K

Свойства

$$x^{k+1} = x^k + \alpha_k p_k \quad r_{k+1} = Ax^{k+1} - b$$

→ Нужно, чтобы $\{p_i\}$ — сопряженные напрвл. ?
 Вот это гарантируем База: p_0 и p_1 — сопряжены (покажем β_1)
ПИ: $\{p_i\}_{i=0}^k$ — сопр. напрвл.

Переход:

- $i = k$ p_{k+1} и p_i - компоненты (возможн p_{k+1})
- $i < k$

$$p_{k+1}^T A p_i = -r_{k+1}^T A p_i + \beta_{k+1} \underbrace{p_k^T A p_i}_0 = -r_{k+1}^T A p_i \quad ? = 0$$

p_{k+1} (ну)

Вспомогательная

$$\text{span} \{r_0 \dots r_k\} = \text{span} \{r_0 \dots A^k r_0\}$$

$$\text{span} \{p_0, p_k\} = \text{span} \{r_0 \dots A^k r_0\}$$

Будем: $r_0 = -p_0$ (используем лемму 1)

ПН: берем $i \leq k$

Переход:

$$p_k \in \text{span} \{r_0 \dots A^k r_0\}$$

\Downarrow

$$A p_k \in \text{span} \{A r_0 \dots A^{k+1} r_0\}$$

$$r_k \in \text{span} \{r_0 \dots A^k r_0\}$$

$$\begin{aligned} r_{k+1} &= A x^{k+1} - b \\ &= A x^k - b \\ &\quad \underbrace{}_{r_k} \end{aligned}$$

$$+ \alpha_k A p_k$$

$$= r_k + \alpha_k A p_k$$

$$r_{k+1} \in \text{span} \{r_k; A p_k\} \subseteq \text{span} \{r_0 \dots A^{k+1} r_0\}$$

$$\bullet \text{span} \{r_0 \dots r_{k+1}\} \subseteq \text{span} \{r_0 \dots A^{k+1} r_0\} \quad (+)$$

таким образом

$$A^{k+1} r_0 = A(A^k r_0) \in \text{span} \{A p_0 \dots A p_k\}$$

$\in \text{span} \{p_0, p_k\}$

$$\frac{r_{i+1} - r_i}{\alpha_i} = A p_i \rightarrow \in \text{span} \{r_0 \dots r_{k+1}\}$$

- $\text{span}\{r_0 \dots r_{k+1}\} \supseteq \text{span}\{r_0 \dots A^{k+1}r_0\} \oplus$
первого графа \oplus

$$\text{span}\{p_0 \dots p_{k+1}\} = \text{span}\{p_0 \dots p_k, r_{k+1}\}$$

ни $\xrightarrow{\quad\quad\quad} \Downarrow$

$$= \text{span}\{r_0 \dots A^k r_0, r_{k+1}\}$$

ни $\xrightarrow{\quad\quad\quad} \Downarrow$

$$= \text{span}\{r_0 \dots r_k, r_{k+1}\}$$

$$= \text{span}\{r_0 \dots A^k r_0\}$$

ни

★: $-r_{k+1}^T A p_i = 0? \oplus$

1) $p_i \in \text{span}\{r_0 \dots A^i r_0\}$
 $A p_i \in \text{span}\{A r_0 \dots A^{i+1} r_0\}$

2) $\text{span}\{r_0 \dots A^{i+1} r_0\} = \text{span}\{p_0 \dots p_{i+1}\}$
 $A p_i \in \text{span}\{p_0 \dots p_{i+1}\}$

векторный граф p_i
 $\langle r_k, p_i \rangle = 0$

связь $i < k$

Теорема о сходимости метода сопряженных градиентов

Метод сопряженных градиентов для решения системы линейных уравнений с квадратной положительно определенной матрицей размера d находит точное решение за не более чем d итераций.

$$O(d^2) = \text{матрица решения с ненулевыми сопряженными градиентами}$$

Еще свойства

Теорема о сходимости метода сопряженных градиентов

Метод сопряженных градиентов для решения системы линейных уравнений с квадратной положительно определенной матрицей размера d находит точное решение за не более чем r итераций, где r — число уникальных собственных значений матрицы.

Теорема о сходимости метода сопряженных градиентов

Метод сопряженных градиентов для решения системы линейных уравнений с квадратной положительно определенной матрицей размера d имеет следующую оценку сходимости:

$$\|x^k - x^*\|_A \leq 2 \left(\frac{\sqrt{\kappa(A)} - 1}{\sqrt{\kappa(A)} + 1} \right)^k \|x^0 - x^*\|_A.$$

Здесь $\|x\|_A^2 = x^T A x$ и $\kappa(A) = \lambda_{\max}(A) / \lambda_{\min}(A)$.

работает на
хуже Кунера

Обобщение для произв. f

Алгоритм 5 Метод сопряженных градиентов (классическая версия)

Вход: стартовая точка $x^0 \in \mathbb{R}^d$, $r_0 = Ax_0 - b$, $p_0 = -r_0$ количество итераций K

1: **for** $k = 0, 1, \dots, K-1$ **do**

2: $\alpha_k = \frac{r_k^T r_k}{p_k^T A p_k}$

3: $x^{k+1} = x^k + \alpha_k p_k$

4: ~~$r_{k+1} = r_k - \alpha_k A p_k$~~

5: $\beta_{k+1} = \frac{r_{k+1}^T r_{k+1}}{r_k^T r_k}$

6: $p_{k+1} = -r_{k+1} + \beta_{k+1} p_k$

7: **end for**

Выход: x^K

$$v = \nabla f$$

Алгоритм 6 Метод сопряженных градиентов (Флетчер - Ривс)

Вход: стартовая точка $x^0 \in \mathbb{R}^d$, $p_0 = -\nabla f(x_0)$ количество итераций K

1: **for** $k = 0, 1, \dots, K-1$ **do**

2: $\alpha_k = ? \text{ argmin } f(x^k + \alpha p_k)$

3: $x^{k+1} = x^k + \alpha_k p_k$

4: $\beta_{k+1} = \frac{\langle \nabla f(x^{k+1}), \nabla f(x^{k+1}) \rangle}{\langle \nabla f(x^k), \nabla f(x^k) \rangle}$

5: $p_{k+1} = -\nabla f(x^{k+1}) + \beta_{k+1} p_k$

6: **end for**

Выход: x^K

Алгоритм 9 Метод сопряженных градиентов (Полак - Рибьер)

Вход: стартовая точка $x^0 \in \mathbb{R}^d$, $p_0 = -\nabla f(x_0)$ количество итераций K

```
1: for  $k = 0, 1, \dots, K - 1$  do  
2:    $\alpha_k = \text{Линейный поиск}$   
3:    $x^{k+1} = x^k + \alpha_k p_k$   
4:    $\beta_{k+1} = \frac{\langle \nabla f(x^{k+1}), \nabla f(x^{k+1}) - \nabla f(x^k) \rangle}{\langle \nabla f(x^k), \nabla f(x^k) \rangle}$   
5:    $p_{k+1} = -\nabla f(x^{k+1}) + \beta_{k+1} p_k$   
6: end for
```

Выход: x^K

⊕ генерация релаксатора на каждой итерации

⊕ функция

⊖ гарантии в общем случае некие

⊖ нулевой релаксатор ($\beta_{k+1} = 0$)