

- Градиентный шаг:

$$x^{k+1} = x^k - \gamma \nabla f(x^k)$$

$$x \in (E, \|\cdot\|)$$

а что тогда про  $\nabla f(x)$ ?  $\nabla f(x) \in (E^*, \|\cdot\|_*)$

то есть  $\|\cdot\| = \|\cdot\|_2 \Rightarrow (E^*, \|\cdot\|_*) = (E, \|\cdot\|)$

- Можно ли (А. Кемпоровский, Д. Козин)

$$\varphi(x^{k+1}) = \varphi(x^k) - \gamma \nabla f(x^k)$$

$$\varphi: E \rightarrow E^* \quad \varphi^{-1}: E^* \rightarrow E$$

или шаг шаг в "зеркальной" пр. бе.

Опр. (Сильно выпуклая оми. функ. норма)

$d: X \rightarrow \mathbb{R}$  является сильно выпуклой с  $\mu > 0$ , если

$$\forall x, y \in X \hookrightarrow d(x) \geq d(y) + \langle \nabla d(y); x-y \rangle + \frac{\mu}{2} \|x-y\|^2$$

↑  
норм. норма

Опр. (Дубернейс Брэнсона)

1-сильно выпуклая оми норма  $\|\cdot\|$  на  $\bar{X}$  порождает  $d$ .

Дубернейс Брэнсона, порождает  $\varphi, d$ , если

функция  $V(x, y): \bar{X} \times \bar{X} \rightarrow \mathbb{R}$

$$\forall x, y \in \bar{X} \quad V(x, y) = d(x) - d(y) - \langle \nabla d(y); x-y \rangle$$

## Формулы

- $d(x) = \frac{1}{2} \|x\|_2^2$  на  $\mathbb{R}^d$

$$\begin{aligned} V(x, y) &= \frac{1}{2} \|x\|_2^2 - \frac{1}{2} \|y\|_2^2 - \langle y, x-y \rangle \\ &= \frac{1}{2} \|x\|_2^2 - \frac{1}{2} \|y\|_2^2 + \|y\|_2^2 - \langle y, x \rangle \\ &= \frac{1}{2} (\|x\|_2^2 - 2\langle y, x \rangle + \|y\|_2^2) = \frac{1}{2} \|x-y\|_2^2 \end{aligned}$$

- $d(x) = \sum_{i=1}^d x_i \log x_i$  на  $\Delta = \{x \in \mathbb{R}^d \mid \sum_{i=1}^d x_i = 1, x_i \geq 0\}$

$$V(x, y) = \sum_{i=1}^d x_i \log \frac{x_i}{y_i} \quad \leftarrow \text{KL-расстояние (измерение расхож. между распределениями)}$$

- $d(x) = \text{tr}(X \log X)$   $X$ -матрица

$$V(X, Y) = \text{tr}(X \log X - X \log Y - X + Y)$$

(классическое расстояние по Шеннону)

## Свойства

- аккумулятивность (см. KL-расстояние)

- симметричность (из сопряженности)

$$V(x, y) \geq \frac{1}{2} \|x-y\|^2 \quad \left( \text{KL}(x||y) \geq \frac{1}{2} \|x-y\|_1^2 \right)$$

непр-во Пинкере

- теорема о переносе

- теорема о 2 сопряженности

- теорема Пинкере для  $V$ :

$$\forall x, y, z \in X \hookrightarrow V(z, x) + V(x, y) - V(z, y) = \langle \nabla d(y) - \nabla d(x), z-x \rangle$$

Доказ-во:  $V(x, y) = d(x) - d(y) - \langle \nabla d(y), x - y \rangle$

$V(z, x) + V(x, y) =$  (no overgenerance)

$$= d(z) - d(x) - \langle \nabla d(x), z - x \rangle$$

$$+ d(x) - d(y) - \langle \nabla d(y), x - y \rangle$$

$$= d(z) - d(y) - \langle \nabla d(y), z - y \rangle = V(z, y)$$

$$- \langle \nabla d(x), z - x \rangle + \langle \nabla d(y), z - x \rangle$$

$$= V(z, y) + \langle \nabla d(y) - \nabla d(x), z - x \rangle$$

$$\min_{x \in \bar{X}} f(x)$$

$f$  - convex

$\bar{X}$  - convex

- Метод зрешовного конуса:

$$x^{k+1} = \arg \min_{x \in \bar{X}} \{ \langle \gamma \nabla f(x^k), x \rangle + V(x, x^k) \}$$

Пример •  $d(x) = \frac{1}{2} \|x\|_2^2$      $\bar{X} = \mathbb{R}^d$

$$x^{k+1} = \arg \min_{x \in \mathbb{R}^d} \{ \underbrace{\langle \gamma \nabla f(x^k), x \rangle + \frac{1}{2} \|x - x^k\|_2^2}_{\Delta = 0} \}$$

$$\Delta = 0$$

$$\gamma \nabla f(x^k) + \underset{x^{k+1}}{\uparrow} x - x^k = 0$$

$$x^{k+1} = x^k - \gamma \nabla f(x^k)$$

(градиентний спусок)

- $d(x) = \frac{1}{2} \|x\|_2^2$

$$x^{k+1} = \arg \min_{x \in \mathbb{X}} \left\{ \underbrace{\langle \gamma \nabla f(x^k); x \rangle + \frac{1}{2} \|x - x^k\|_2^2}_{+ \frac{\gamma^2}{2} \|\nabla f(x^k)\|_2^2 - \langle \gamma \nabla f(x^k); x^k \rangle} \right\}$$

$$= \arg \min_{x \in \mathbb{X}} \left\{ \frac{1}{2} (\|x - x^k\|_2^2 + 2\gamma \langle \nabla f(x^k); x - x^k \rangle + \frac{\gamma^2}{2} \|\nabla f(x^k)\|_2^2) \right\}$$

$$= \arg \min_{x \in \mathbb{X}} \left\{ \frac{1}{2} \|x - x^k + \gamma \nabla f(x^k)\|_2^2 \right\}$$

$y^k \triangleq x^k - \gamma \nabla f(x^k)$

$$= \arg \min_{x \in \mathbb{X}} \left\{ \|x - y^k\|_2^2 \right\} \leftarrow \text{спроецировать } y^k \text{ на } \mathbb{X}$$

• ускоренная коммуникация града

$$x^{k+1} = \arg \min_{x \in \mathbb{R}^d} \left\{ \langle \gamma \nabla f(x^k); x \rangle + V(x, x^k) \right\}$$

$$= \arg \min_{x \in \mathbb{R}^d} \left\{ \underbrace{\langle \gamma \nabla f(x^k); x \rangle + d(x) - d(x^k) - \langle \nabla d(x^k), x - x^k \rangle}_{\nabla = 0} \right\}$$

$$\gamma \nabla f(x^k) + \nabla d(x) - \nabla d(x^k) = 0$$

$\uparrow$   
 $x^{k+1}$

$$\underbrace{\nabla d(x^{k+1})}_{\varphi} = \underbrace{\nabla d(x^k)}_{\varphi} - \gamma \nabla f(x^k)$$

$$x^{k+1} = (\nabla d)^{-1}(\nabla d(x^k) - \gamma \nabla f(x^k))$$

Def. Fréchet guter quadratischer  $f: X \rightarrow \mathbb{R}$   
 $f$  -  $L$ -mal unveränderlich norm  $\|\cdot\|$  in  $X$ ,  
 also  $\forall x, y \in X \hookrightarrow \|Df(x) - Df(y)\|_* \leq L \|x - y\|$

Theorem  $f: X \rightarrow \mathbb{R}$   $L$ -mal unveränderlich norm  $\|\cdot\|$ , also  
 $\forall x, y \in X \hookrightarrow |f(y) - f(x) - \langle Df(x); y - x \rangle| \leq \frac{L}{2} \|x - y\|^2$

Dok. so: gr. Hölder Leibniz

$$\begin{aligned} f(y) - f(x) &= \int_0^1 \langle Df(x + \tau(y-x)); y-x \rangle d\tau \\ &= \langle Df(x); y-x \rangle \\ &\quad + \int_0^1 \langle Df(x + \tau(y-x)) - Df(x); y-x \rangle d\tau \end{aligned}$$

$$\begin{aligned} |f(y) - f(x) - \langle Df(x); y-x \rangle| &= \left| \int_0^1 \langle Df(x + \tau(y-x)) - Df(x); y-x \rangle d\tau \right| \end{aligned}$$

$$|\Sigma| \leq \Sigma | |$$

$$\leq \int_0^1 |\langle Df(x + \tau(y-x)) - Df(x); y-x \rangle| d\tau$$

$$\text{K5W} \quad \langle a; b \rangle \leq \|a\|_* \|b\|$$

$$\leq \int_0^1 \|Df(x + \tau(y-x)) - Df(x)\|_* \|y-x\| d\tau$$

$$L\text{-mal} \text{ un} \text{ver} \text{änder} \text{lich} \text{ norm} \quad \| \quad \|$$

$$\leq \int_0^1 L \tau \|y-x\|^2 d\tau$$

$$= \frac{L \|y-x\|^2}{2} \quad \square$$

Доказательство

уравнение optimality

$$x^{k+1} = \arg \min_{x \in X} \underbrace{\{\langle \gamma \nabla f(x^k); x \rangle + V(x, x^k) \}}_{g(x)}$$

$$\forall x \in X \hookrightarrow \langle \nabla g(x^*); \overset{\uparrow}{x^{k+1}} - \overset{\uparrow}{x^{k+1}} \rangle \leq 0$$

$$\langle \gamma \nabla f(x^k) + \nabla d(x^{k+1}) - \nabla d(x^k); x^{k+1} - x \rangle \leq 0$$

$$\langle \gamma \nabla f(x^k); x^{k+1} - x \rangle \leq - \langle \nabla d(x^{k+1}) - \nabla d(x^k); x^{k+1} - x \rangle$$

Свойство V

$$V(z, x) + V(x, y) - V(z, y) = \underbrace{\langle \nabla d(y) - \nabla d(x), z - x \rangle}_{x = x^{k+1} \quad z = x^* \quad y = x^k}$$

$$\begin{aligned} \langle \gamma \nabla f(x^k); x^{k+1} - x^* \rangle &\leq - \left( V(x^*, x^{k+1}) + V(x^{k+1}, x^k) - V(x^*, x^k) \right) \\ &= V(x^*, x^k) - V(x^*, x^{k+1}) - V(x^{k+1}, x^k) \end{aligned}$$

$x^{k+1} \rightarrow x^k$  в среднем смысле.

$$\gamma \langle \nabla f(x^k); x^k - x^* \rangle \leq V(x^*, x^k) - V(x^*, x^{k+1}) - V(x^{k+1}, x^k) + \underbrace{\gamma \langle \nabla f(x^k); x^k - x^{k+1} \rangle}_{\text{red line}}$$

Теорема

$$\gamma \cdot \left( f(x^{k+1}) - f(x^k) + \underbrace{\langle \nabla f(x^k); x^k - x^{k+1} \rangle}_{\text{red line}} \right) \leq \frac{\gamma}{2} \|x^k - x^{k+1}\|^2$$

$$\gamma ( \nabla f(x^k); x^k - x^* ) + f(x^{k+1}) - f(x^k) \\ \leq V(x^*, x^k) - V(x^*, x^{k+1}) - V(x^{k+1}, x^k) \\ + \frac{\gamma L}{2} \|x^k - x^{k+1}\|^2$$

бонусная f:

$$\gamma ( \cancel{f(x^k)} - f(x^*) + f(x^{k+1}) - \cancel{f(x^k)} ) \\ \leq V(x^*, x^k) - V(x^*, x^{k+1}) - V(x^{k+1}, x^k) \\ + \frac{\gamma L}{2} \|x^k - x^{k+1}\|^2$$

$$\frac{1}{2} \|x^k - x^{k+1}\|^2 \leq V(x^{k+1}, x^k)$$

$$\gamma ( f(x^{k+1}) - f(x^*) ) \leq V(x^*, x^k) - V(x^*, x^{k+1}) \\ - \underbrace{(1 - \gamma L) V(x^{k+1}, x^k)}_{\geq 0}$$

$$\gamma \leq \frac{1}{L}$$

$$\gamma ( f(x^{k+1}) - f(x^*) ) \leq V(x^*, x^k) - V(x^*, x^{k+1})$$

$$\frac{1}{K} \sum_{k=0}^{K-1} \text{и } \bar{f}_{\text{текущая}}$$

$$\gamma \frac{1}{K} \sum_{k=0}^{K-1} (f(x^{k+1}) - f(x^*)) \leq \frac{V(x^*, x^0) - \cancel{V(x^*, x^K)}}{K}$$

$$\gamma \left( f \left( \frac{1}{K} \sum_{k=0}^{K-1} x^{k+1} \right) - f(x^*) \right) \leq \frac{V(x^*, x^0)}{K}$$

$\gamma = \frac{1}{L}$

Свойствам представлено функція градієнтного,  $L$ -магма

$$\left| f\left(\frac{1}{K} \sum_{k=0}^{K-1} x^{k+1}\right) - f(x^*) \right| \leq \frac{L V(x^*; x^0)}{K}$$

або маємо  $\frac{1}{K}$ , так як функція  
в градієнтній  $L_2$ ,  $\frac{1}{2} \|x^0 - x^*\|_2^2$

④  $L \leq L_2$

$$\| \nabla f(x) - \nabla f(y) \|_q \leq L \|x - y\|_p \quad \frac{1}{p} + \frac{1}{q} = 1$$

$p \in [1; 2] \quad q \in [2; +\infty)$

$$1 \leq p \leq 2 \Rightarrow \|\cdot\|_2 \leq \|\cdot\|_p, \quad \|\cdot\|_q \leq \|\cdot\|_2$$

⑤  $V(x, y) \geq \frac{1}{2} \|x - y\|_p^2 \geq \frac{1}{2} \|x - y\|_2^2 \quad p \in [1; 2]$

• Зеркальний градієнт на множині

$$x^{k+1} = \operatorname{argmin}_{x \in X} \{ \langle \gamma \nabla f(x^k); x \rangle + V(x, x^k) \}$$

$$V(x, y) = \sum_{i=1}^d x_i \log\left(\frac{x_i}{y_i}\right) \quad X = \Delta$$

Градієнтна функція:

$$\min_{x \in \mathbb{R}^d} \langle \gamma \nabla f(x^k); x \rangle + V(x, x^k)$$

$$\text{s.t.} \quad -x_i \leq 0$$

$$\sum_{i=1}^d x_i - 1 = 0$$

Лагранжівська:

$$L(x, \lambda, \nu) = \langle \gamma \nabla f(x^k); x \rangle + V(x, x^k) + \sum_{i=1}^d \lambda_i (-x_i) + \nu \left( \sum_{i=1}^d x_i - 1 \right)$$



no constraints

$$= \sum_{i=1}^d \left( \gamma [\nabla f(x^k)]_i + \log\left(\frac{x_i}{x_i^k}\right) - \lambda_i + \nu \right) x_i - \nu$$

maximize  $x_i$  give unique global maximum

$$(a + \log\left(\frac{x_i}{b}\right)) x_i \rightarrow \max$$

$$a + \log\left(\frac{x_i}{b}\right) + \frac{1}{x_i} = 0$$

$$x_i^* = b \exp(-a - \frac{1}{b})$$

$$\inf_x L(x, \lambda, \nu) = \sum_{i=1}^d (a + -\frac{1}{b}) b \exp(-a - \frac{1}{b}) - \nu$$

$$= \sum_{i=1}^d -x_i^k \exp(+\lambda_i - \gamma [\nabla f(x^k)]_i - \nu) - \nu$$

Global maximum reached

$$\max_{\lambda_i \geq 0, \nu \in \mathbb{R}} \left[ \sum_{i=1}^d -x_i^k \exp(-1 + \lambda_i - \gamma [\nabla f(x^k)]_i - \nu) - \nu \right]$$

$$\lambda_i^* = 0, \quad KKT$$

$$\nabla_x L(x, \lambda, \nu) = 0$$

$$\nabla_{x_i} \left[ \gamma \nabla f(x^k)_i x_i + \underbrace{V(x, x^k)}_{\sum x_i \log\left(\frac{x_i}{x_i^k}\right)} + \sum_{i=1}^d \lambda_i (-x_i) + \nu \left( \sum_{i=1}^d x_i - 1 \right) \right]_{\lambda_i^* = 0} = 0$$

$$= \log\left(\frac{x_i^*}{x_i^k}\right) + \nu^* + \gamma [\nabla f(x^k)]_i + 1 = 0$$

$$x_i^* = x_i^k \exp(-\gamma [\nabla f(x^k)]_i) \cdot \exp(1 + \nu^*)$$

?

$$\sum x_i^* = 1$$

$\exp(1+j^*)$  - нормировка

$$x_i^* = \frac{x_i^k \exp(-\gamma [\nabla f(x^k)]_i)}{\sum_{j=1}^d x_j^k \exp(-\gamma [\nabla f(x^k)]_j)}$$

softmax

⊕ где сумма нормованных значений  
нормировка  $\frac{d}{\log d}$ .