

# Задача стохастической оптимизации

$$\min_{x \in \mathbb{R}^d} [F(x) := \mathbb{E}_{f \sim D} [f(x, f)]]$$

Пример: в ML

$$f(x) := \mathbb{E}_{f \sim D} [L(g(x, f_a), f_b)]$$

Annotations:   
 -  $f_a$ : все   
 -  $f_b$ : метка   
 -  $L$ : loss   
 -  $D$ : распределение (красная точка)   
 -  $(f_a, f_b)$ : пара   
 -  $g$ : функция   
 -  $f$ : все   
 -  $f_b$ : метка

Вопрос:  $F$ ,  $\nabla F$  невозможны

Что делать?

1) Онлайн подход:

$$\nabla f(x, f) = \nabla_x L(g(x, f_a), f_b) \leftarrow \text{вычисляем по метке}$$

$$\mathbb{E}_{f \sim D} [\nabla f(x, f)] = \nabla F(x)$$

2) Оффлайн подход:

есть выборка  $\{f_i\}_{i=1}^n$

Аппроксимация  $\mathbb{E}_{f \sim D}$  по Monte-Carlo

$$\min_{x \in \mathbb{R}^d} [\tilde{F}(x) := \frac{1}{n} \sum_{i=1}^n L(g(x, f_{i,a}), f_{i,b})]$$

это грубая замена:  $\tilde{F} \approx F$  при достаточно  $n$   
можно считать  $\nabla \tilde{F}$ :

⊖ хорошо

⊖ переобучения ( $\tilde{F} \neq F$ )

⊕ функция не является упр., а упр. по своим  
выборкам - sample

## Смоделированный градиентный спуск

$$x^{k+1} = x^k - \gamma \nabla f(x^k, g^k)$$

смеш. гра. — по тому своему свойству

$g^k$  — независимое и равномерно

- Независимость:

$$\mathbb{E}_g [\nabla f(x^k, g^k)]$$

- Равномерность:

$$\mathbb{E}_g [\nabla f(x^k, g^k)] = (\text{описание равномерности})$$

$$= \sum_{i=1}^n \mathbb{P}\{g^k = g_i\} \nabla f(x^k, g_i) = \text{равномерность}$$

$$= \sum_{i=1}^n \frac{1}{n} \nabla f(x^k, g_i) = \frac{1}{n} \sum_{i=1}^n \nabla f(x^k, g_i) = \nabla f(x^k)$$

---

## Условное математическое ожидание

$$\mathbb{E}[\cdot | x^k] = \mathbb{E}[\cdot | \mathcal{F}_k]$$

$\mathcal{F}_k$  —  $\sigma$ -алгебра, порожд.  $x^0, g^0, \dots, g^{k-1}$

генерирует все, что произошло до  $x^k$  (включительно)

tower property:

$$\mathbb{E}[\mathbb{E}[X|Y]] = \mathbb{E}[X]$$

## Предположения

- $f$  —  $\mu$ -сильно выпуклая
- $f(x, \xi) - L$ -гладкая (матрица  $L = L_{\max}$  не бекн)
- $\mathbb{E}_{\xi} [\nabla f(x, \xi)] = \nabla f(x)$      $\mathbb{E}_{\xi} [f(x, \xi)] = f(x)$

Док-во сходимости:

$$\begin{aligned}\|x^{k+1} - x^*\|_2^2 &= \|x^k - \gamma \nabla f(x^k, \xi^k) - x^*\|_2^2 \\ &= \|x^k - x^*\|_2^2 - 2\gamma \langle \nabla f(x^k, \xi^k); x^k - x^* \rangle \\ &\quad + \gamma^2 \|\nabla f(x^k, \xi^k)\|_2^2\end{aligned}$$


Примем м.о. от обеих частей:

$$\begin{aligned}\mathbb{E}[\|x^{k+1} - x^*\|_2^2] &= \mathbb{E}[\|x^k - x^*\|_2^2] - 2\gamma \mathbb{E}[\langle \nabla f(x^k, \xi^k); x^k - x^* \rangle] \\ &\quad + \gamma^2 \mathbb{E}[\|\nabla f(x^k, \xi^k)\|_2^2]\end{aligned} \quad (*)$$

$$\mathbb{E}[\|\nabla f(x^k, \xi^k)\|_2^2]:$$

$$\mathbb{E}[\|\nabla f(x^k, \xi^k)\|_2^2] = \mathbb{E}[\|\underbrace{\nabla f(x^k, \xi^k)}_{\neq 0} - \underbrace{\nabla f(x^*, \xi^k)}_{\neq 0} + \nabla f(x^*, \xi^k)\|_2^2]$$

$$\nabla f(x^*) = 0 \quad \nabla f(x^*, \xi^k) \neq 0$$



К5Ш

$$\leq 2 \mathbb{E}[\|\nabla f(x^k, \xi^k) - \nabla f(x^*, \xi^k)\|_2^2] + 2 \mathbb{E}[\|\nabla f(x^*, \xi^k)\|_2^2]$$

$L$ -негравит  $f(x, g)$

$$\leq 4L \mathbb{E} \left[ f(x^k, g^k) - f(x^*, g^k) + \underbrace{\langle \nabla f(x^*, g^k); x^* - x^k \rangle}_{\neq 0} \right] + 2 \mathbb{E} [\|\nabla f(x^*, g^k)\|_2^2] \ominus$$

Tower property:  $\mathbb{E}[\mathbb{E}[x^k]] = \mathbb{E}[x]$

$$\mathbb{E}[\mathbb{E}[f(x^k, g^k) | x^k]] = \mathbb{E}[f(x^k)]$$

$$\mathbb{E}[f(x^*, g^k)] = f(x^*)$$

$$\mathbb{E}[\mathbb{E}[\langle \nabla f(x^k, g^k); x^* - x^k \rangle | x^k]] =$$

$$= \mathbb{E}[\langle \mathbb{E}[\nabla f(x^k, g^k) | x^k]; x^* - x^k \rangle]$$

$$= \mathbb{E}[\langle \nabla f(x^*), x^* - x^k \rangle] = 0$$

сложнее

$$\ominus 4L \mathbb{E}[f(x^k) - f(x^*)] + 2 \mathbb{E}[\|\nabla f(x^*, g^k)\|_2^2]$$

$$\mathbb{E}[\|\nabla f(x^*, g^k)\|_2^2] = \text{равнозначное}$$

$$= \frac{1}{n} \sum_{i=1}^n \|\nabla f(x^*, g_i)\|_2^2 = \sigma_g^2$$

$$= 4L \mathbb{E}[f(x^k) - f(x^*)] + 2\sigma_g^2 \quad (**)$$

Lemma (\*) b (\*)

$$\mathbb{E}[\|x^{k+1} - x^*\|_2^2] \leq \mathbb{E}[\|x^k - x^*\|_2^2] - 2\gamma \mathbb{E}[\langle \nabla f(x^k, g^k); x^k - x^* \rangle] + \gamma^2 (4L \mathbb{E}[f(x^k) - f(x^*)] + 2\sigma_*^2)$$

$\mathbb{E}[\langle \nabla f(x^k, g^k); x^k - x^* \rangle]$ , tower property:

$$\mathbb{E}[\mathbb{E}[\langle \nabla f(x^k, g^k); x^k - x^* \rangle | x^k]]$$

$$= \mathbb{E}[\langle \mathbb{E}[\nabla f(x^k, g^k) | x^k]; x^k - x^* \rangle]$$

$$= \mathbb{E}[\langle \nabla f(x^k); x^k - x^* \rangle]$$

Lemma (\*\*\*\*) b (\*\*\*\*)

$$\mathbb{E}[\|x^{k+1} - x^*\|_2^2] \leq \mathbb{E}[\|x^k - x^*\|_2^2] - 2\gamma \mathbb{E}[\langle \nabla f(x^k); x^k - x^* \rangle] + \gamma^2 (4L \mathbb{E}[f(x^k) - f(x^*)] + 2\sigma_*^2)$$

$\mu$ -convex bounded below  $f$

$$\mathbb{E}[\|x^{k+1} - x^*\|_2^2] \leq \mathbb{E}[\|x^k - x^*\|_2^2] - 2\gamma \mathbb{E}[\frac{\mu}{2} \|x^k - x^*\|_2^2 + f(x^k) - f(x^*)] + \gamma^2 (4L \mathbb{E}[f(x^k) - f(x^*)] + 2\sigma_*^2)$$

$$= (1 - \gamma\mu) \mathbb{E}[\|x^k - x^*\|_2^2] - 2\gamma(1 - 2\gamma L) \mathbb{E}[f(x^k) - f(x^*)] + 2\gamma^2 \sigma_*^2$$

20

$$\gamma \leq \frac{1}{2L}$$

$$\leq (1-\gamma\mu) \mathbb{E}[\|x^k - x^*\|_2^2] + 2\gamma^2 \sigma_*^2$$

$$\boxed{\mathbb{E}[\|x^{k+1} - x^*\|_2^2] \leq (1-\gamma\mu) \mathbb{E}[\|x^k - x^*\|_2^2] + 2\gamma^2 \sigma_*^2}$$

no need to use Gronwall's lemma, no need for  $\mathbb{E}$  or  $\mathbb{E}_j$

$$R_k^2 = \mathbb{E}[\|x^k - x^*\|_2^2]$$

$$R_{k+1}^2 \leq (1-\gamma\mu) R_k^2 + 2\gamma^2 \sigma_*^2$$

Convergence property:

$$\begin{aligned} &\leq (1-\gamma\mu) ((1-\gamma\mu) R_{k-1}^2 + 2\gamma^2 \sigma_*^2) + 2\gamma^2 \sigma_*^2 \\ &= (1-\gamma\mu)^2 R_{k-1}^2 + 2\gamma^2 \sigma_*^2 [1 + (1-\gamma\mu)] \end{aligned}$$

$$\begin{aligned} &\dots \\ &\leq (1-\gamma\mu)^{k+1} R_0^2 + 2\gamma^2 \sigma_*^2 \sum_{i=0}^k (1-\gamma\mu)^i \\ &\leq (1-\gamma\mu)^{k+1} R_0^2 + 2\gamma^2 \sigma_*^2 \underbrace{\sum_{i=0}^{\infty} (1-\gamma\mu)^i}_{= \frac{1}{\gamma\mu}} \end{aligned}$$


$$\leq (1-\gamma\mu)^{k+1} R_0^2 + \frac{2\gamma \sigma_*^2}{\mu}$$

Сходимость SGD с постоянн. шагом

$$\mathbb{E}[\|x^{k+1} - x^*\|_2^2] \leq (1 - \gamma \mu)^{k+1} \mathbb{E}[\|x^0 - x^*\|_2^2] + \frac{2\gamma\sigma_*^2}{\mu}$$

⊕ сходимость линейная, как у GD

⊖ сходимость до оптимальности:  $\sim \gamma$ ,  $\sim \sigma_*^2$




⊕ повышение + ML-непрерывность

Как бороться со сходимостью к субоптимальности?

1)  $\gamma$  уменьшать: ⊕ сходимость быстрее  
⊖ медленнее

$\gamma \rightarrow \gamma_k \sim \frac{1}{k}$ ;  $\frac{1}{\sqrt{k}}$ : ⊕ сходимость до решения  
⊖ вообще не сходится или сход.



2)  $\sigma_*^2$  уменьшать

$$\nabla f(x^t, g^k) \rightarrow \frac{1}{b} \sum_{g \in S^k} \nabla f(x^t, g)$$

$S^k$  - выбор, набор объектов из об. выборки, размера  $b$   
(все объекты берется независимо и равномерно)

$$\begin{aligned}
 & \bullet \mathbb{E}_{S^k} \left[ \frac{1}{b} \sum_{f \in S^k} \nabla f(x^k, f) \right] = \\
 & = \frac{1}{b} \sum_{f \in S^k} \mathbb{E}_f [\nabla f(x^k, f)] = (\text{рег. и публ.}) \\
 & = \frac{1}{b} \sum_{f \in S^k} \nabla f(x^k) = b \cdot \frac{1}{b} \nabla f(x^k) = \nabla f(x^k)
 \end{aligned}$$

$$\begin{aligned}
 & \bullet \mathbb{E}_{S^k} \left[ \left\| \frac{1}{b} \sum_{f \in S^k} \nabla f(x^*, f) \right\|_2^2 \right] = \\
 & = \mathbb{E}_{S^k} \left[ \frac{1}{b^2} \sum_{f \in S^k} \|\nabla f(x^*, f)\|_2^2 \right] \\
 & + \mathbb{E}_{S^k} \left[ \frac{1}{b^2} \sum_{f \neq \eta} \langle \nabla f(x^*, f); \nabla f(x^*, \eta) \rangle \right] \\
 & = \frac{1}{b^2} \sum_{f \in S^k} \mathbb{E}_f [\|\nabla f(x^*, f)\|_2^2] = \underbrace{\frac{1}{b^2} \cdot b \cdot \frac{1}{n} \sum_{i=1}^n \|\nabla f(x^*, f_i)\|_2^2}_{\sigma_p^2} \\
 & + \frac{1}{b^2} \sum_{f \neq \eta} \mathbb{E}_{f, \eta} [\langle \nabla f(x^*, f); \nabla f(x^*, \eta) \rangle] \frac{\sigma_p^2}{b}
 \end{aligned}$$

$f, \eta$  - независимые

$$\langle \mathbb{E}_f [\nabla f(x^*, f)]; \mathbb{E}_\eta [\nabla f(x^*, \eta)] \rangle$$

$$\parallel \langle \nabla f(x^*); \nabla f(x^*) \rangle = 0$$

$$= \boxed{\frac{\sigma_p^2}{(b)!}}$$

← эрмита симметричность

⊕ ортогональность градиентов в браз

⊖ множеств равен



на примере:

- $\varphi f_1 \rightarrow \varphi f_2 \rightarrow \varphi f_3 \dots \rightarrow \varphi f_n$   
↑  
re com. mem.

- замкнутое гетеро  $\rightarrow \varphi f_1 \dots \varphi f_n$  series reduction  
1 раз
- микробное квантовое шифрование  $\rightarrow$  еще меньше элементов  
network shuffling