

# Задача минимизации эмпирического риска

$$\min_{x \in \mathbb{R}^d} [f(x) := \mathbb{E}_{f \sim D} [f(x, f)]]$$

Пример из ML

$$f(x) := \mathbb{E}_{f \sim D} [L(g(x, f_a), f_b)]$$

Annotations:

- $g(x, f_a)$ : *оп. модель* (blue arrow to  $g$ )
- $f_a$ : *веса* (blue arrow to  $f_a$ )
- $f_b$ : *норма* (blue arrow to  $f_b$ )
- $(f_a, f_b)$ : *параметры* (blue arrow to  $(f_a, f_b)$ )
- $f$ : *функция потерь* (red arrow to  $f$ )
- $f_a, f_b$ : *формы* (blue arrow to  $f_a, f_b$ )
- $f$ : *норма* (blue arrow to  $f$ )

Что делать?

1) Оптимизация потерь

$$\nabla_x f(x, f) = \nabla_x L(g(x, f_a), f_b)$$

Annotation: *градиент по параметрам* (blue arrow to  $\nabla_x$ )

$$\mathbb{E}_{f \sim D} [\nabla f(x, f)] = \nabla f(x)$$

2) Аппроксимация потерь  
если выборка  $\{f_i\}_{i=1}^n$

$$\min_{x \in \mathbb{R}^d} [\tilde{f}(x) := \frac{1}{n} \sum_{i=1}^n L(g(x, f_{i,a}), f_{i,b})]$$

$\tilde{f}$  - эмпирический риск

$\tilde{f} \neq f$  - *разница*

$\tilde{f} \approx f$  — при достаточно  $n$  (аппроксимация  
 функции)  
 $\sim \frac{1}{\sqrt{n}}$

можно считать  $\nabla \tilde{f}$ :

⊖ *шум*

⊖ *пересортировка* ( $\tilde{f} \neq f$ )

⊕ *вычисления не  $\nabla f$ , а прих. по значениям  
 в точках*

Смешанный градиентный спуск

$$x^{(k+1)} = x^{(k)} - \gamma \underbrace{\nabla f(x^{(k)}, \xi^{(k)})}_{\text{смеш. град}}$$

$\xi^{(k)}$  — независимо из  $D$  / *равномерно*

*по той же схеме  
 от  $\nabla f$*

• *независимость*

$$\mathbb{E}_{\xi} [\nabla f(x, \xi)]$$

• *равномерно*

$$\mathbb{E}_{\xi} [\nabla f(x, \xi)] = \text{(описанием вероятности)}$$

$\tilde{f}$  же равно  $\tilde{f} \Rightarrow f$

$$= \sum_{i=1}^n \underbrace{\mathbb{P}\{\xi = \xi_i\}}_{= \frac{1}{n}} \nabla f(x, \xi_i)$$

$$= \sum_{i=1}^n \frac{1}{n} \nabla f(x, \xi_i) = \frac{1}{n} \sum \nabla f(x, \xi_i) = \nabla f(x)$$

## Условное математическое ожидание

$$E[\cdot | \mathcal{X}^k] = E[\cdot | \mathcal{F}_k]$$

$\mathcal{F}_k = \sigma$ -алгебра, порожд.  $X^0, \xi^0, \xi^1 \dots \xi^{k-1}$

связывает все случайное, которое  
происходит до  $X^k$  (в прошлом)

tower property:

$$E[E[X|Y]] = E[X]$$

---

## Док-во сходимости:

- $f$  —  $\mu$ -сильно выпуклая
- $f(\cdot, \xi)$  —  $L$ -гладкая ( $L_{\max}$  по выпукл.)
- $E_{\xi}[\nabla f(x, \xi)] = \nabla f(x)$       $E_{\xi}[f(x, \xi)] = f(x)$

## Док-во:

$$\begin{aligned} \|x^{k+1} - x^*\|_2^2 &= \|x^k - \gamma \nabla f(x^k, \xi^k) - x^*\|_2^2 \\ &= \|x^k - x^*\|_2^2 - 2\gamma \langle \nabla f(x^k, \xi^k), x^k - x^* \rangle \\ &\quad + \gamma^2 \|\nabla f(x^k, \xi^k)\|_2^2 \end{aligned}$$


Примем м.о. от обеих частей:

$$E[\|x^{k+1} - x^*\|_2^2] = E[\|x^k - x^*\|_2^2]$$

$$- 2\gamma \mathbb{E}[\langle \nabla f(x^k, \mathcal{F}^k); x^k - x^* \rangle] + \gamma^2 \mathbb{E}[\|\nabla f(x^k, \mathcal{F}^k)\|_2^2] \quad (\star)$$

$$\mathbb{E}[\|\nabla f(x^k, \mathcal{F}^k)\|_2^2]:$$

$$\mathbb{E}[\|\nabla f(x^k, \mathcal{F}^k)\|_2^2] = \mathbb{E}[\|\nabla f(x^k, \mathcal{F}^k) - \nabla f(x^*, \mathcal{F}^k) + \nabla f(x^*, \mathcal{F}^k)\|_2^2]$$



$$\text{K5LL: } \|a+b\|_2^2 \leq 2\|a\|_2^2 + 2\|b\|_2^2$$

$$\leq 2 \mathbb{E}[\|\nabla f(x^k, \mathcal{F}^k) - \nabla f(x^*, \mathcal{F}^k)\|_2^2] + 2 \mathbb{E}[\|\nabla f(x^*, \mathcal{F}^k)\|_2^2]$$

$L$ -smooth  $f(\cdot, \mathcal{F})$

$$\leq 4L \mathbb{E}[\|f(x^k, \mathcal{F}^k) - f(x^*, \mathcal{F}^k) + \langle \nabla f(x^*, \mathcal{F}^k), x^k - x^* \rangle\|] + 2 \mathbb{E}[\|\nabla f(x^*, \mathcal{F}^k)\|_2^2] \leftarrow \sigma_*^2 \leq$$

Tower property  $\mathbb{E}[\ ] = \mathbb{E}[\mathbb{E}[\ ] | x^k]$

$$\mathbb{E}[\langle \nabla f(x^*, \mathcal{F}^k); x^k - x^* \rangle] =$$

$$= \mathbb{E}[\mathbb{E}[\langle \nabla f(x^*, \mathcal{F}^k); x^k - x^* \rangle | x^k]]$$

$$= E \left[ \underbrace{\langle E[\nabla f(x^*, g^k) | x^k]; x^k - x^* \rangle}_{\nabla f(x^*) = 0} \right] = 0$$

$$\begin{aligned} \sigma_*^2 &= E_g [\|\nabla f(x^*, g)\|_2^2] \\ &= (\text{variance}) = \frac{1}{n} \sum_{i=1}^n \|\nabla f(x^*, g_i)\|_2^2 \end{aligned}$$

$$\leq 4L E[f(x^k) - f(x^*)] + 2\sigma_*^2 \quad (**)$$

Lemma (\*\*) b (\*)

$$\begin{aligned} E[\|x^{k+1} - x^*\|_2^2] &= E[\|x^k - x^*\|_2^2] \\ &\quad - 2\gamma E[\langle \nabla f(x^k, g^k); x^k - x^* \rangle] \\ &\quad + 4L^2 \gamma^2 E[f(x^k) - f(x^*)] + 2\gamma^2 \sigma_*^2 \quad (***) \end{aligned}$$

$E[\langle \nabla f(x^k, g^k); x^k - x^* \rangle]$ , tower property

$$\begin{aligned} &E \left[ E[\langle \nabla f(x^k, g^k); x^k - x^* \rangle | x^k] \right] \\ &= E \left[ \langle E[\nabla f(x^k, g^k) | x^k]; x^k - x^* \rangle \right] \\ &= E[\langle \nabla f(x^k); x^k - x^* \rangle] \quad (****) \end{aligned}$$

Thema (\*\*\*\*) b (\*\*\*\*)

$$\begin{aligned} \mathbb{E}[\|x^{k+1} - x^*\|_2^2] &= \mathbb{E}[\|x^k - x^*\|_2^2] \\ &\quad - 2\gamma \mathbb{E}[\langle \nabla f(x^k); x^k - x^* \rangle] \\ &\quad + 4L^2 \mathbb{E}[f(x^k) - f(x^*)] + 2\gamma^2 \sigma_*^2 \end{aligned}$$

$\mu$ -convex bounding

$$\begin{aligned} \mathbb{E}[\|x^{k+1} - x^*\|_2^2] &\leq \mathbb{E}[\|x^k - x^*\|_2^2] \\ &\quad - 2\gamma \mathbb{E}[\underbrace{f(x^k) - f(x^*)}_{\geq \frac{\mu}{2} \|x^k - x^*\|_2^2}] \\ &\quad + 4L^2 \mathbb{E}[\underbrace{f(x^k) - f(x^*)}_{\geq 0}] + 2\gamma^2 \sigma_*^2 \\ &\leq (1 - \gamma\mu) \mathbb{E}[\|x^k - x^*\|_2^2] \\ &\quad - 2\gamma(1 - 2\gamma L) \mathbb{E}[f(x^k) - f(x^*)] \\ &\quad + 2\gamma^2 \sigma_*^2 \quad \geq 0 \quad \geq 0 \end{aligned}$$

$$\gamma \leq \frac{1}{2L}$$

$$\mathbb{E}[\|x^{k+1} - x^*\|_2^2] \leq (1 - \gamma\mu) \mathbb{E}[\|x^k - x^*\|_2^2] + 2\gamma^2 \sigma_*^2$$

no sub convex, no  
a good GD

no source

$$R_k^2 = \mathbb{E}[\|x^k - x^*\|_2^2]$$

$$R_{k+1}^2 \leq (1-\gamma\mu) R_k^2 + 2\gamma^2 \sigma_*^2$$

Заменим рекурсию:

$$\begin{aligned} &\leq (1-\gamma\mu) \left( (1-\gamma\mu) R_{k-1}^2 + 2\gamma^2 \sigma_*^2 \right) + 2\gamma^2 \sigma_*^2 \\ &= (1-\gamma\mu)^2 R_{k-1}^2 + 2\gamma^2 \sigma_*^2 [1 + (1-\gamma\mu)] \end{aligned}$$

...

$$\leq (1-\gamma\mu)^{k+1} R_0^2 + 2\gamma^2 \sigma_*^2 \sum_{i=0}^k (1-\gamma\mu)^i$$

$$\leq (1-\gamma\mu)^{k+1} R_0^2 + 2\gamma^2 \sigma_*^2 \underbrace{\sum_{i=0}^{\infty} (1-\gamma\mu)^i}_{\frac{1}{\gamma\mu}}$$

$$\leq (1-\gamma\mu)^{k+1} R_0^2 + \frac{2\gamma \sigma_*^2}{\mu}$$

Свойства SGD с постоянным шагом

$$\boxed{\mathbb{E}[\|x^{k+1} - x^*\|_2^2] \leq (1-\gamma\mu)^{k+1} \|x^0 - x^*\|_2^2 + \frac{2\gamma \sigma_*^2}{\mu}}$$

⊕ свойства универсальны, для  $\gamma \in D$

⊖ свойства по определению:  $\sim \gamma, \sim \sigma_*^2$




⊕ универсальность + хорошие ML-результаты

Как бороться со смещением и дисперсией?

1)  $\sigma$  уменьшаем:  $\oplus$  сокращаем шаг  
 $\ominus$  меньше

$\sigma \rightarrow \sigma_k \sim \frac{1}{k}; \frac{1}{\sqrt{k}}$   $\leftarrow$  для минимизации см.



2)  $\sigma_*^2$  уменьшаем

$$\mathbb{E}f(x_{i,j}) \rightarrow \frac{1}{b} \sum_{j \in S} \mathbb{E}f(x_{i,j})$$

$S$  - выбор (каждый абстракт и точек) размера  $b$

$$\sigma_*^2 \rightarrow \frac{\sigma_*^2}{b} \quad \text{эквивалентно уменьшению}$$

$\oplus$  уменьшаем шаг

$\ominus$  уменьшаем количество точек