

# Негладкая оптимизация. Проксимальный метод

## Методы оптимизации

Александр Безносиков

Московский физико-технический институт

23 ноября 2023



# Негладкие задачи

- Вопрос: функция  $f(x) = |x|$  выпукла?

# Негладкие задачи

- **Вопрос:** функция  $f(x) = |x|$  выпукла? Безусловно. А дифференцируемая и гладкая?

$$\| \nabla f(x) - \nabla f(0) \| = 2$$

~~$$\angle \|x - y\|$$~~



# Негладкие задачи

- **Вопрос:** функция  $f(x) = |x|$  выпукла? Безусловно. А дифференцируемая и гладкая? Нет.
- Получается, что даже довольно простые выпуклые задачи могут быть негладким. До этого мы смотрели только на гладкие задачи.

# Негладкие задачи

- **Вопрос:** функция  $f(x) = |x|$  выпукла? Безусловно. А дифференцируемая и гладкая? Нет.
- Получается, что даже довольно простые выпуклые задачи могут быть негладким. До этого мы смотрели только на гладкие задачи.
- Будем рассматривать следующее предположение вместо гладкости (Липшицевости градиента):

## Определение $M$ -Липшецевой функции

Пусть дана функция  $f : \mathbb{R}^d \rightarrow \mathbb{R}$ . Будем говорить, что она является  $M$ -Липшицева, если для любых  $x, y \in \mathbb{R}^d$  выполнено

$$|f(x) - f(y)| \leq M \|x - y\|_2.$$

# Негладкие задачи

- **Вопрос:** функция  $f(x) = |x|$  выпукла? Безусловно. А дифференцируемая и гладкая? Нет.
- Получается, что даже довольно простые выпуклые задачи могут быть негладким. До этого мы смотрели только на гладкие задачи.
- Будем рассматривать следующее предположение вместо гладкости (Липшицевости градиента):

## Определение $M$ -Липшецевой функции

Пусть дана функция  $f : \mathbb{R}^d \rightarrow \mathbb{R}$ . Будем говорить, что она является  $M$ -Липшицева, если для любых  $x, y \in \mathbb{R}^d$  выполнено

$$|f(x) - f(y)| \leq M \|x - y\|_2.$$

Понятие (и все результаты далее) можно перенести на некоторое ограниченное выпуклое множество  $\mathcal{X}$ . Связано это в том числе с тем, что не бывает сильно выпуклых и Липшецевых на  $\mathbb{R}^d$  функций.

**Вопрос:** почему?

# Негладкие задачи

- **Вопрос:** функция  $f(x) = |x|$  выпукла? Безусловно. А дифференцируемая и гладкая? Нет.
- Получается, что даже довольно простые выпуклые задачи могут быть негладким. До этого мы смотрели только на гладкие задачи.
- Будем рассматривать следующее предположение вместо гладкости (Липшицевости градиента):

## Определение $M$ -Липшецевой функции

Пусть дана функция  $f : \mathbb{R}^d \rightarrow \mathbb{R}$ . Будем говорить, что она является  $M$ -Липшицева, если для любых  $x, y \in \mathbb{R}^d$  выполнено

$$|f(x) - f(y)| \leq M \|x - y\|_2.$$

Понятие (и все результаты далее) можно перенести на некоторое ограниченное выпуклое множество  $\mathcal{X}$ . Связано это в том числе с тем, что не бывает сильно выпуклых и Липшецевых на  $\mathbb{R}^d$  функций.

**Вопрос:** почему? Линейный и квадратичный рост не сочетаются.

# Субградиент и субдифференциал

Если функция не дифференцируема *в* точке *е*, а значит градиента нет.  
Что может существовать вместо градиент?



# Субградиент и субдифференциал

Если функция не дифференцируема с точки зрения градиента, а значит градиента нет. Что может существовать вместо градиента?

## Субградиент и субдифференциал

Пусть дана выпуклая функция  $f : \mathbb{R}^d \rightarrow \mathbb{R}$ . Вектор  $g$  будем называть субградиентом этой функции  $f$  в точке  $x \in \mathbb{R}^d$ , если для любого  $y \in \mathbb{R}^d$  выполняется:

$$f(y) \geq f(x) + \langle \overset{\partial f(x)}{g}, y - x \rangle.$$

Множество  $\partial f(x)$  всех субградиентов  $f$  в  $x$  будем называть субдифференциалом.

# Условие оптимальности

## Теорема (условие оптимальности)

$x^*$  – минимум выпуклой функции  $f$  тогда и только тогда, когда

$$0 \in \partial f(x^*).$$

$$\Leftarrow 0 \in \partial f(x^*)$$

$$f(x) \geq f(x^*) + \langle g; x - x^* \rangle = f(x^*)$$

$g \in \partial f(x^*) \quad g=0$

$$\Rightarrow f(x) \geq f(x^*) \quad \forall x$$

$$\underline{f(x) \geq f(x^*) + \langle 0; x - x^* \rangle}_{\forall x} \Rightarrow 0 \in \partial f(x^*)$$

# Условие оптимальности

## Теорема (условие оптимальности)

$x^*$  – минимум выпуклой функции  $f$  тогда и только тогда, когда

$$0 \in \partial f(x^*).$$

Доказательство:

$\Leftarrow$  Если  $0 \in \partial f(x^*)$ , то по выпуклости и определению субградиента:  
 $f(x) \geq f(x^*) + \langle 0, x - x^* \rangle = f(x^*)$ . Доказано по определению глобального минимума.

# Условие оптимальности

## Теорема (условие оптимальности)

$x^*$  – минимум выпуклой функции  $f$  тогда и только тогда, когда

$$0 \in \partial f(x^*).$$

Доказательство:

$\Leftarrow$  Если  $0 \in \partial f(x^*)$ , то по выпуклости и определению субградиента:  
 $f(x) \geq f(x^*) + \langle 0, x - x^* \rangle = f(x^*)$ . Доказано по определению глобального минимума.

$\Rightarrow$  Если  $f(x) \geq f(x^*)$  для любых  $x \in \mathbb{R}^d$ , то для вектора 0 выполнено  $f(x) \geq f(x^*) + \langle 0, x - x^* \rangle$  для любого  $x \in \mathbb{R}^d$ . Доказано по определению субградиента.

# Свойство $M$ -Липшицевой функции

## Лемма (свойство $M$ -Липшицевой функции)

Пусть дана выпуклая функция  $f : \mathbb{R}^d \rightarrow \mathbb{R}$ . Тогда функция  $f$  является  $M$ -Липшицевой тогда и только тогда, когда для любого  $x \in \mathbb{R}^d$  и  $g \in \partial f(x)$  имеем  $\|g\|_2 \leq M$ .

# Доказательство

⇒ Пусть дополнительно к выпуклости функция  $f$  еще и  $M$ -Липшицева, тогда

$$f(x) \geq f(y) + \underline{\langle g; x - y \rangle} \quad \begin{matrix} g \in \partial f(y) \\ \forall x \in \mathbb{R}^d \end{matrix}$$

$$f(x) \geq f(y) + \langle g; g \rangle = f(y) + \|g\|_2^2$$

$x = y + g$  ←

$$\|g\|_2^2 \leq f(x) - f(y) \leq M \|x - y\|_2 = M \|g\|_2$$
$$\|g\|_2 \leq M$$

# Доказательство

⇒ Пусть дополнительно к выпуклости функция  $f$  еще и  $M$ -Липшицева, тогда

- Рассмотрим  $g \in \partial f(x)$ , тогда по выпуклости и определению субградиента для любого  $y \in \mathbb{R}^d$ :

$$f(y) - f(x) \geq \langle g, y - x \rangle.$$

# Доказательство

⇒ Пусть дополнительно к выпуклости функция  $f$  еще и  $M$ -Липшицева, тогда

- Рассмотрим  $g \in \partial f(x)$ , тогда по выпуклости и определению субградиента для любого  $y \in \mathbb{R}^d$ :

$$f(y) - f(x) \geq \langle g, y - x \rangle.$$

- Из Липшицевости  $f$ :

$$M\|y - x\|_2 \geq f(y) - f(x) \geq \langle g, y - x \rangle.$$



# Доказательство

⇒ Пусть дополнительно к выпуклости функция  $f$  еще и  $M$ -Липшицева, тогда

- Рассмотрим  $g \in \partial f(x)$ , тогда по выпуклости и определению субградиента для любого  $y \in \mathbb{R}^d$ :

$$f(y) - f(x) \geq \langle g, y - x \rangle.$$

- Из Липшицевости  $f$ :

$$M\|y - x\|_2 \geq f(y) - f(x) \geq \langle g, y - x \rangle.$$

- Возьмем  $y = g + x$ , тогда

$$M\|g\|_2 = M\|y - x\|_2 \geq \langle g, y - x \rangle = \|g\|_2^2.$$

# Доказательство

⇒ Пусть дополнительно к выпуклости функция  $f$  еще и  $M$ -Липшицева, тогда

- Рассмотрим  $g \in \partial f(x)$ , тогда по выпуклости и определению субградиента для любого  $y \in \mathbb{R}^d$ :

$$f(y) - f(x) \geq \langle g, y - x \rangle.$$

- Из Липшицевости  $f$ :

$$M\|y - x\|_2 \geq f(y) - f(x) \geq \langle g, y - x \rangle.$$

- Возьмем  $y = g + x$ , тогда

$$M\|g\|_2 = M\|y - x\|_2 \geq \langle g, y - x \rangle = \|g\|_2^2.$$

Что и требовалось.

# Доказательство

$\Leftarrow$  Пусть дополнительно к выпуклости у функции  $f$  все субградиенты равномерно ограничены:  $\|g\|_2 \leq M$  для любого  $x \in R^d$  и  $g \in \partial f(x)$ .

Тогда

$$f(x) \geq f(y) - \underbrace{\langle g; y - x \rangle}_{\uparrow} \quad g \in \partial f(y)$$

$$\underbrace{\langle g; y - x \rangle}_{\wedge} \geq f(y) - f(x)$$

$$\|g\|_2 \|y - x\|_2$$

$$f(y) - f(x) \leq \|g\|_2 \|y - x\|_2$$

$$f(x) - f(y) \leq \|g\|_2 \|y - x\|$$

# Доказательство

$\Leftarrow$  Пусть дополнительно к выпуклости у функции  $f$  все субградиенты равномерно ограничены:  $\|g\|_2 \leq M$  для любого  $x \in \mathbb{R}^d$  и  $g \in \partial f(x)$ .

Тогда

- Рассмотрим  $g \in \partial f(x)$ , тогда по выпуклости и определению субградиента для любого  $y \in \mathbb{R}^d$ :

$$f(y) - f(x) \leq \langle g, x - y \rangle.$$

# Доказательство

$\Leftarrow$  Пусть дополнительно к выпуклости у функции  $f$  все субградиенты равномерно ограничены:  $\|g\|_2 \leq M$  для любого  $x \in R^d$  и  $g \in \partial f(x)$ .

Тогда

- Рассмотрим  $g \in \partial f(x)$ , тогда по выпуклости и определению субградиента для любого  $y \in \mathbb{R}^d$ :

$$f(y) - f(x) \leq \langle g, x - y \rangle.$$

- КБШ:

$$f(y) - f(x) \leq \|g\|_2 \cdot \|x - y\|_2.$$

# Доказательство

$\Leftarrow$  Пусть дополнительно к выпуклости у функции  $f$  все субградиенты равномерно ограничены:  $\|g\|_2 \leq M$  для любого  $x \in \mathbb{R}^d$  и  $g \in \partial f(x)$ .

Тогда

- Рассмотрим  $g \in \partial f(x)$ , тогда по выпуклости и определению субградиента для любого  $y \in \mathbb{R}^d$ :

$$f(y) - f(x) \leq \langle g, x - y \rangle.$$

- КБШ:

$$f(y) - f(x) \leq \|g\|_2 \cdot \|x - y\|_2.$$

- Пользуемся предположением и получаем:

$$f(y) - f(x) \leq M\|x - y\|_2.$$

# Доказательство

$\Leftarrow$  Пусть дополнительно к выпуклости у функции  $f$  все субградиенты равномерно ограничены:  $\|g\|_2 \leq M$  для любого  $x \in R^d$  и  $g \in \partial f(x)$ .

Тогда

- Рассмотрим  $g \in \partial f(x)$ , тогда по выпуклости и определению субградиента для любого  $y \in \mathbb{R}^d$ :

$$f(y) - f(x) \leq \langle g, x - y \rangle.$$

- КБШ:

$$f(y) - f(x) \leq \|g\|_2 \cdot \|x - y\|_2.$$

- Пользуемся предположением и получаем:

$$f(y) - f(x) \leq M\|x - y\|_2.$$

Что и требовалось.

# Субградиентный метод

- Рассматриваем задачу:

$$\min_{x \in \mathbb{R}^d} f(x),$$

где  $f$  выпуклая и  $M$ -Липшицева.



# Субградиентный метод

- Рассматриваем задачу:

$$\min_{x \in \mathbb{R}^d} f(x),$$

где  $f$  выпуклая и  $M$ -Липшицева.

- Простая идея – вместо градиента использовать какой-то субградиент в текущей точке:

---

## Алгоритм 2 Субградиентный метод

---

**Вход:** размеры шага  $\gamma > 0$ , стартовая точка  $x^0 \in \mathbb{R}^d$ , количество итераций  $K$

```
1: for  $k = 0, 1, \dots, K - 1$  do  
2:   Вычислить  $g^k \in \partial f(x^k)$   
3:    $x^{k+1} = x^k - \gamma g^k$   
4: end for
```

**Выход:**  $\frac{1}{K} \sum_{k=0}^{K-1} x^k$

---

# Доказательство сходимости

- Ничего сверхъестественного:

$$\begin{aligned}\|x^{k+1} - x^*\|_2^2 &= \|x^k - \gamma g^k - x^*\|_2^2 \quad \in J f(x^k) \\ &= \|x^k - x^*\|_2^2 - 2\gamma \langle g^k, x^k - x^* \rangle + \gamma^2 \|g^k\|_2^2\end{aligned}$$

$$1) \|g^k\|_2^2 \in M^2$$

$$2) \quad + 2\gamma (f(x^*) - f(x^k)) \gamma^2 M^2$$

$$\|x^{k+1} - x^*\|_2^2 = \|x^k - x^*\|_2^2 + 2\gamma (f(x^*) - f(x^k)) + \gamma^2 M^2$$

$$2\gamma (f(x^k) - f(x^*)) = \|x^k - x^*\|_2^2 - \|x^{k+1} - x^*\|_2^2 + \gamma^2 M^2$$

$$\sum_k \frac{1}{K}$$

$$\frac{2\gamma}{K} \sum (f(x^k) - f(x^*)) \leq \frac{\|x^0 - x^*\|_2^2 - \cancel{\|x^K - x^*\|_2^2}}{K} + \gamma^2 M^2$$

# Доказательство сходимости

- Ничего сверхъестественного:

$$\begin{aligned}\|x^{k+1} - x^*\|_2^2 &= \|x^k - \gamma g^k - x^*\|_2^2 \\ &= \|x^k - x^*\|_2^2 - 2\gamma \langle g^k, x^k - x^* \rangle + \gamma^2 \|g^k\|_2^2\end{aligned}$$

- Из  $M$ -Липшицевости  $f$  следует, что субградиенты ограничены:

$$\|x^{k+1} - x^*\|_2^2 \leq \|x^k - x^*\|_2^2 - 2\gamma \langle g^k, x^k - x^* \rangle + \gamma^2 M^2$$

# Доказательство сходимости

- Ничего сверхъестественного:

$$\begin{aligned}\|x^{k+1} - x^*\|_2^2 &= \|x^k - \gamma g^k - x^*\|_2^2 \\ &= \|x^k - x^*\|_2^2 - 2\gamma \langle g^k, x^k - x^* \rangle + \gamma^2 \|g^k\|_2^2\end{aligned}$$

- Из  $M$ -Липшицевости  $f$  следует, что субградиенты ограничены:

$$\|x^{k+1} - x^*\|_2^2 \leq \|x^k - x^*\|_2^2 - 2\gamma \langle g^k, x^k - x^* \rangle + \gamma^2 M^2$$

- Из выпуклости и определения субградиента:

$$\|x^{k+1} - x^*\|_2^2 \leq \|x^k - x^*\|_2^2 - 2\gamma(f(x^k) - f(x^*)) + \gamma^2 M^2$$

# Доказательство сходимости

- С предыдущего слайда:

$$2\gamma(f(x^k) - f(x^*)) \leq \|x^k - x^*\|_2^2 - \|x^{k+1} - x^*\|_2^2 + \gamma^2 M^2$$

# Доказательство сходимости

- С предыдущего слайда:

$$2\gamma(f(x^k) - f(x^*)) \leq \|x^k - x^*\|_2^2 - \|x^{k+1} - x^*\|_2^2 + \gamma^2 M^2$$

- Суммируем по всем  $k$  и усредняем:

$$\frac{2\gamma}{K} \sum_{k=0}^{K-1} (f(x^k) - f(x^*)) \leq \frac{\|x^0 - x^*\|_2^2}{K} + \gamma^2 M^2$$

# Доказательство сходимости

- С предыдущего слайда:

$$2\gamma(f(x^k) - f(x^*)) \leq \|x^k - x^*\|_2^2 - \|x^{k+1} - x^*\|_2^2 + \gamma^2 M^2$$

- Суммируем по всем  $k$  и усредняем:

$$\frac{2\gamma}{K} \sum_{k=0}^{K-1} (f(x^k) - f(x^*)) \leq \frac{\|x^0 - x^*\|_2^2}{K} + \gamma^2 M^2$$

- Откуда

$$f\left(\frac{1}{K} \sum x^k\right) - f(x^*) \leq$$

$$\frac{1}{K} \sum_{k=0}^{K-1} (f(x^k) - f(x^*)) \leq \frac{\|x^0 - x^*\|_2^2}{2\gamma K} + \frac{\gamma M^2}{2}$$

$$-\frac{\|x^0 - x^*\|_2^2}{2\gamma^2 K} + \frac{M^2}{2} = 0 \quad \gamma = \frac{\|x^0 - x^*\|}{M\sqrt{K}}$$

# Доказательство сходимости

- С предыдущего слайда:

$$\frac{1}{K} \sum_{k=0}^{K-1} (f(x^k) - f(x^*)) \leq \frac{\|x^0 - x^*\|_2^2}{2\gamma K} + \frac{\gamma M^2}{2}$$

- Гладкости нет, поэтому не получится доказать, что  $f(x^k) \leq f(x^{k-1})$ . Поэтому просто неравенство Йенсена для выпуклой функции:

$$f\left(\frac{1}{K} \sum_{k=0}^{K-1} x^k\right) - f(x^*) \leq \frac{\|x^0 - x^*\|_2^2}{2\gamma K} + \frac{\gamma M^2}{2}$$



# Доказательство сходимости

- С предыдущего слайда:

$$f\left(\frac{1}{K} \sum_{k=0}^{K-1} x^k\right) - f(x^*) \leq \frac{\|x^0 - x^*\|_2^2}{2\gamma K} + \frac{\gamma M^2}{2}$$

- **Вопрос:** как подобрать шаг?

# Доказательство сходимости

- С предыдущего слайда:

$$f\left(\frac{1}{K} \sum_{k=0}^{K-1} x^k\right) - f(x^*) \leq \frac{\|x^0 - x^*\|_2^2}{2\gamma K} + \frac{\gamma M^2}{2}$$

- Вопрос:** как подобрать шаг? минимизировать правую часть по  $\gamma$ :

$$\gamma = \frac{\|x^0 - x^*\|_2}{M\sqrt{K}}. \text{ Откуда}$$

$$f\left(\frac{1}{K} \sum_{k=0}^{K-1} x^k\right) - f(x^*) \leq \frac{M\|x^0 - x^*\|_2}{\sqrt{K}}$$

- Можно более практично:  $\gamma_k \sim \frac{1}{\sqrt{k}}$ .

## Теорема сходимость субградиентного спуска для $M$ -Липшицевых и выпуклых функций

Пусть задача безусловной оптимизации с  $M$ -Липшицевой, выпуклой целевой функцией  $f$  решается с помощью субградиентного спуска.

Тогда справедлива следующая оценка сходимости

$$\varepsilon \sim f\left(\frac{1}{K} \sum_{k=0}^{K-1} x^k\right) - f(x^*) \leq \frac{M \|x^0 - x^*\|_2}{\sqrt{K}}$$

$$\frac{1}{\sqrt{K}}$$

Более того, чтобы добиться точности  $\varepsilon$  по функции, необходимо

$$K = O\left(\frac{M^2 \|x^0 - x^*\|_2^2}{\varepsilon^2}\right) \text{ итераций.}$$

$$\frac{1}{\varepsilon^2} \quad \frac{1}{K}$$

для каждого  $\varepsilon$ :

сложн. мн.  $(1-q)^k$   
вот  $\frac{1}{K}$

# Субградиентный метод: итог

- Обобщение градиентного спуска на негладкие задачи.

# Субградиентный метод: итог

- Обобщение градиентного спуска на негладкие задачи.
- Оценки сходимости в выпуклом случае:  $\sim \frac{1}{\sqrt{K}}$ , в сильно выпуклом случае:  $\sim \frac{1}{K}$ . **Вопрос:** какие были у градиентного спуска в гладком случае?

# Субградиентный метод: итог

- Обобщение градиентного спуска на негладкие задачи.
- Оценки сходимости в выпуклом случае:  $\sim \frac{1}{\sqrt{K}}$ , в сильно выпуклом случае:  $\sim \frac{1}{K}$ . **Вопрос:** какие были у градиентного спуска в гладком случае?  $\sim \frac{1}{K}$  и линейная соответственно. Сходимость медленнее.

# Субградиентный метод: итог

- Обобщение градиентного спуска на негладкие задачи.
- Оценки сходимости в выпуклом случае:  $\sim \frac{1}{\sqrt{K}}$ , в сильно выпуклом случае:  $\sim \frac{1}{K}$ . **Вопрос:** какие были у градиентного спуска в гладком случае?  $\sim \frac{1}{K}$  и линейная соответственно. Сходимость медленнее.
- Может возможно улучшить результат? Например, улучшить анализ или использовать моментум.

# Субградиентный метод: итог

- Обобщение градиентного спуска на негладкие задачи.
- Оценки сходимости в выпуклом случае:  $\sim \frac{1}{\sqrt{K}}$ , в сильно выпуклом случае:  $\sim \frac{1}{K}$ . **Вопрос:** какие были у градиентного спуска в гладком случае?  $\sim \frac{1}{K}$  и линейная соответственно. Сходимость медленнее.
- Может возможно улучшить результат? Например, улучшить анализ или использовать моментум. В общем случае результат для субградиентного метода является неулучшаемым для выпуклых и сильно-выпуклых задач, т.е. он оптимален.



# Субградиентный метод: итог

- Обобщение градиентного спуска на негладкие задачи.
- Оценки сходимости в выпуклом случае:  $\sim \frac{1}{\sqrt{K}}$ , в сильно выпуклом случае:  $\sim \frac{1}{K}$ . **Вопрос:** какие были у градиентного спуска в гладком случае?  $\sim \frac{1}{K}$  и линейная соответственно. Сходимость медленнее.
- Может возможно улучшить результат? Например, улучшить анализ или использовать моментум. В общем случае результат для субградиентного метода является неулучшаемым для выпуклых и сильно-выпуклых задач, т.е. он оптимален. **Вопрос:** а что в невыпуклом случае?

# Субградиентный метод: итог

- Обобщение градиентного спуска на негладкие задачи.
- Оценки сходимости в выпуклом случае:  $\sim \frac{1}{\sqrt{K}}$ , в сильно выпуклом случае:  $\sim \frac{1}{K}$ . **Вопрос:** какие были у градиентного спуска в гладком случае?  $\sim \frac{1}{K}$  и линейная соответственно. Сходимость медленнее.
- Может возможно улучшить результат? Например, улучшить анализ или использовать моментум. В общем случае результат для субградиентного метода является неулучшаемым для выпуклых и сильно-выпуклых задач, т.е. он оптимален. **Вопрос:** а что в невыпуклом случае? С этого мы начинали курс – лучше, чем полный перебор там ничего не придумать.

# Субградиентный метод: итог

- Обобщение градиентного спуска на негладкие задачи.
- Оценки сходимости в выпуклом случае:  $\sim \frac{1}{\sqrt{K}}$ , в сильно выпуклом случае:  $\sim \frac{1}{K}$ . **Вопрос:** какие были у градиентного спуска в гладком случае?  $\sim \frac{1}{K}$  и линейная соответственно. Сходимость медленнее.
- Может возможно улучшить результат? Например, улучшить анализ или использовать моментум. В общем случае результат для субградиентного метода является неулучшаемым для выпуклых и сильно-выпуклых задач, т.е. он оптимален. **Вопрос:** а что в невыпуклом случае? С этого мы начинали курс – лучше, чем полный перебор там ничего не придумать.
- Можно обобщить на метод с проекцией, а также на произвольную Брэгмановскую постановку (зеркальный спуск).

# Проксимальный оператор

- Поняли, что негладкие задачи «более сложные» по сравнению с гладкими задачами.
- Может быть получится «спрятать под ковер» отсутствие гладкости.

# Проксимальный оператор

- Поняли, что негладкие задачи «более сложные» по сравнению с гладкими задачами.
- Может быть получится «спрятать под ковер» отсутствие гладкости.
- Такую возможность дает проксимальный оператор:

## Определение проксимального оператора

Для функции  $r: \mathbb{R}^d \rightarrow \mathbb{R} \cup \{+\infty\}$  проксимальный оператор определяется следующим образом:

$$\text{prox}_r(x) = \arg \min_{\tilde{x} \in \mathbb{R}^d} \left( r(\tilde{x}) + \frac{1}{2} \|x - \tilde{x}\|^2 \right).$$

# Свойства проксимального оператора

## Лемма (свойство проксимального оператора)

Пусть  $r : \mathbb{R}^d \rightarrow \mathbb{R} \cup \{+\infty\}$  выпуклая функция, для которой определен  $\text{prox}_r$ . Если существует такая  $\hat{x} \in \mathbb{R}^d$ , что  $r(x) < +\infty$ . Тогда проксимальный оператор однозначно определен (т.е. всегда возвращает единственное уникальное значение).

# Свойства проксимального оператора

## Лемма (свойство проксимального оператора)

Пусть  $r : \mathbb{R}^d \rightarrow \mathbb{R} \cup \{+\infty\}$  выпуклая функция, для которой определен  $\text{prox}_r$ . Если существует такая  $\hat{x} \in \mathbb{R}^d$ , что  $r(\hat{x}) < +\infty$ . Тогда проксимальный оператор однозначно определен (т.е. всегда возвращает единственное уникальное значение).

Доказательство: Проксимальный оператор возвращает минимум некоторой задачи оптимизации. Вопрос: что можно сказать про эту задачу?

# Свойства проксимального оператора

## Лемма (свойство проксимального оператора)

Пусть  $r : \mathbb{R}^d \rightarrow \mathbb{R} \cup \{+\infty\}$  выпуклая функция, для которой определен  $\text{prox}_r$ . Если существует такая  $\hat{x} \in \mathbb{R}^d$ , что  $r(\hat{x}) < +\infty$ . Тогда проксимальный оператор однозначно определен (т.е. всегда возвращает единственное уникальное значение).

Доказательство: Проксимальный оператор возвращает минимум некоторой задачи оптимизации. Вопрос: что можно сказать про эту задачу? Она сильно выпуклая, а значит имеет строго один уникальный минимум (существование  $\hat{x}$  необходимо для того, чтобы  $r(\tilde{x}) + \frac{1}{2}\|x - \tilde{x}\|^2$  где-то принимала конечное значение).




# Примеры проксимального оператора

- $r(x) = \lambda \|x\|_1$ , где  $\lambda > 0$ . Тогда

$$[\text{prox}_r(x)]_i = \underbrace{[|x_i| - \lambda]_+}_{\text{thresholding}} \cdot \text{sign}(x_i)$$

Такой проксимальный оператор еще называют трешхолдом.



# Примеры проксимального оператора

- $r(x) = \lambda \|x\|_1$ , где  $\lambda > 0$ . Тогда

$$[\text{prox}_r(x)]_i = [|x_i| - \lambda]_+ \cdot \text{sign}(x_i)$$

Такой проксимальный оператор еще называют трешхолдом.

- $r(x) = \frac{\lambda}{2} \|x\|_2^2$ , где  $\lambda > 0$ . Тогда

$$\text{prox}_r(x) = \frac{x}{1 + \lambda}.$$

# Примеры проксимального оператора

- $r(x) = \lambda \|x\|_1$ , где  $\lambda > 0$ . Тогда

$$\underline{[\text{prox}_r(x)]_i = [|x_i| - \lambda]_+ \cdot \text{sign}(x_i)}$$

Такой проксимальный оператор еще называют трешхолдом.

- $r(x) = \frac{\lambda}{2} \|x\|_2^2$ , где  $\lambda > 0$ . Тогда

$$\text{prox}_r(x) = \frac{x}{1 + \lambda}.$$

- $r(x) = \mathbb{I}_{\mathcal{X}}^{(x)}$ , где  $\mathcal{X}$  – выпуклое множество, и

$$\mathbb{I}_{\mathcal{X}} = \begin{cases} 0, & x \in \mathcal{X} \\ +\infty, & x \notin \mathcal{X} \end{cases}.$$

Вопрос: чему равен прох?

$$\begin{aligned} \text{prox}_r(x) &= \arg\min_{\tilde{x} \in \mathbb{R}^d} \left( \mathbb{I}(\tilde{x}) + \frac{\lambda}{2} \|\tilde{x} - \hat{x}\|_2^2 \right) \\ &= \arg\min_{\tilde{x} \in \mathcal{X}} \left( \|\tilde{x} - \hat{x}\|_2^2 \right) \end{aligned}$$

# Примеры проксимального оператора

- $r(x) = \lambda \|x\|_1$ , где  $\lambda > 0$ . Тогда

$$[\text{prox}_r(x)]_i = [|x_i| - \lambda]_+ \cdot \text{sign}(x_i)$$

Такой проксимальный оператор еще называют трешхолдом.

- $r(x) = \frac{\lambda}{2} \|x\|_2^2$ , где  $\lambda > 0$ . Тогда

$$\text{prox}_r(x) = \frac{x}{1 + \lambda}.$$

- $r(x) = \mathbb{I}_{\mathcal{X}}$ , где  $\mathcal{X}$  – выпуклое множество, и

$$\mathbb{I}_{\mathcal{X}} = \begin{cases} 0, & x \in \mathcal{X} \\ +\infty, & x \notin \mathcal{X} \end{cases}.$$

**Вопрос:** чему равен  $\text{prox}$ ?

$$\text{prox}_r(x) = \text{proj}_{\mathcal{X}}(x).$$

# Примеры проксимального оператора

- $r(x) = \lambda \|x\|_1$ , где  $\lambda > 0$ . Тогда

$$[\text{prox}_r(x)]_i = [|x_i| - \lambda]_+ \cdot \text{sign}(x_i)$$

Такой проксимальный оператор еще называют трешхолдом.

- $r(x) = \frac{\lambda}{2} \|x\|_2^2$ , где  $\lambda > 0$ . Тогда

$$\text{prox}_r(x) = \frac{x}{1 + \lambda}.$$

- $r(x) = \mathbb{I}_{\mathcal{X}}$ , где  $\mathcal{X}$  – выпуклое множество, и

$$\mathbb{I}_{\mathcal{X}} = \begin{cases} 0, & x \in \mathcal{X} \\ +\infty, & x \notin \mathcal{X} \end{cases}.$$

**Вопрос:** чему равен  $\text{prox}$ ?

$$\text{prox}_r(x) = \text{proj}_{\mathcal{X}}(x).$$

- И еще множество других примеров и их комбинаций.

# Свойства проксимального оператора

$$\begin{aligned}
 2 \Leftrightarrow 3 & \Rightarrow x - y \in \partial r(y) \\
 & \quad \downarrow \\
 & \quad \langle x - y; z - y \rangle \leq r(z) - r(y) \quad \forall z \\
 \Leftarrow & \quad \forall z \quad \langle x - y; z - y \rangle \leq r(z) - r(y)
 \end{aligned}$$

## Лемма (свойство проксимального оператора)

Пусть  $r : \mathbb{R}^d \rightarrow \mathbb{R} \cup \{+\infty\}$  выпуклая функция, для которой определен  $\text{prox}_r$ . Тогда для любых  $x, y \in \mathbb{R}^d$  следующие три условия являются эквивалентными:

- $\text{prox}_r(x) = y,$
- $x - y \in \partial r(y),$
- $\langle x - y, z - y \rangle \leq r(z) - r(y)$  для любого  $z \in \mathbb{R}^d.$

1  $\Rightarrow$  2

$$\text{prox}_r(x) = \arg \min \left( r(\tilde{x}) + \frac{1}{2} \|x - \tilde{x}\|_2^2 \right)$$

$$\begin{aligned}
 0 & \in \partial \left( r(\tilde{x}) + \frac{1}{2} \|\tilde{x} - x\|_2^2 \right) \Big|_{\tilde{x}=y} \\
 0 & \in \partial r(y) + y - x \\
 -(y - x) & \in \partial r(y)
 \end{aligned}$$

# Доказательство

- Первое условие переписывается, как

$$y = \arg \min_{\tilde{x} \in \mathbb{R}^d} \left( r(\tilde{x}) + \frac{1}{2} \|x - \tilde{x}\|_2^2 \right).$$

- Первое условие переписывается, как

$$y = \arg \min_{\tilde{x} \in \mathbb{R}^d} \left( r(\tilde{x}) + \frac{1}{2} \|x - \tilde{x}\|_2^2 \right).$$

- Из условия оптимальности для выпуклой функции  $r$  это эквивалентно **вопрос**: чему?



# Доказательство

- Первое условие переписывается, как

$$y = \arg \min_{\tilde{x} \in \mathbb{R}^d} \left( r(\tilde{x}) + \frac{1}{2} \|x - \tilde{x}\|_2^2 \right).$$

- Из условия оптимальности для выпуклой функции  $r$  это эквивалентно **вопрос**: чему?

$$0 \in \partial \left( r(\tilde{x}) + \frac{1}{2} \|x - \tilde{x}\|_2^2 \right) \Big|_{\tilde{x}=y} = \partial r(y) + y - x.$$

# Доказательство

- Первое условие переписывается, как

$$y = \arg \min_{\tilde{x} \in \mathbb{R}^d} \left( r(\tilde{x}) + \frac{1}{2} \|x - \tilde{x}\|_2^2 \right).$$

- Из условия оптимальности для выпуклой функции  $r$  это эквивалентно **вопрос**: чему?

$$0 \in \partial \left( r(\tilde{x}) + \frac{1}{2} \|x - \tilde{x}\|_2^2 \right) \Big|_{\tilde{x}=y} = \partial r(y) + y - x.$$

Получили эквивалентность первого и второго условий.

- Первое условие переписывается, как

$$y = \arg \min_{\tilde{x} \in \mathbb{R}^d} \left( r(\tilde{x}) + \frac{1}{2} \|x - \tilde{x}\|_2^2 \right).$$

- Из условия оптимальности для выпуклой функции  $r$  это эквивалентно **вопрос**: чему?

$$0 \in \partial \left( r(\tilde{x}) + \frac{1}{2} \|x - \tilde{x}\|_2^2 \right) \Big|_{\tilde{x}=y} = \partial r(y) + y - x.$$

Получили эквивалентность первого и второго условий.

- Из определения субдифференциала, для любого субградиента  $g \in \partial f(y)$  и для любого  $z \in \mathbb{R}^d$ :

$$\langle g, z - y \rangle \leq r(z) - r(y).$$

# Доказательство

- Первое условие переписывается, как

$$y = \arg \min_{\tilde{x} \in \mathbb{R}^d} \left( r(\tilde{x}) + \frac{1}{2} \|x - \tilde{x}\|_2^2 \right).$$

- Из условия оптимальности для выпуклой функции  $r$  это эквивалентно **вопрос**: чему?

$$0 \in \partial \left( r(\tilde{x}) + \frac{1}{2} \|x - \tilde{x}\|_2^2 \right) \Big|_{\tilde{x}=y} = \partial r(y) + y - x.$$

Получили эквивалентность первого и второго условий.

- Из определения субдифференциала, для любого субградиента  $g \in \partial f(y)$  и для любого  $z \in \mathbb{R}^d$ :

$$\langle g, z - y \rangle \leq r(z) - r(y).$$

В частности справедливо и для  $g = x - y$ .

# Доказательство

- Первое условие переписывается, как

$$y = \arg \min_{\tilde{x} \in \mathbb{R}^d} \left( r(\tilde{x}) + \frac{1}{2} \|x - \tilde{x}\|_2^2 \right).$$

- Из условия оптимальности для выпуклой функции  $r$  это эквивалентно **вопрос**: чему?

$$0 \in \partial \left( r(\tilde{x}) + \frac{1}{2} \|x - \tilde{x}\|_2^2 \right) \Big|_{\tilde{x}=y} = \partial r(y) + y - x.$$

Получили эквивалентность первого и второго условий.

- Из определения субдифференциала, для любого субградиента  $g \in \partial f(y)$  и для любого  $z \in \mathbb{R}^d$ :

$$\langle g, z - y \rangle \leq r(z) - r(y).$$

В частности справедливо и для  $g = x - y$ . В обратную сторону тоже очевидно: для  $g = x - y$  выполнено соотношение выше, значит  $g \in \partial r(y)$ .

# Доказательство

- Первое условие переписывается, как

$$y = \arg \min_{\tilde{x} \in \mathbb{R}^d} \left( r(\tilde{x}) + \frac{1}{2} \|x - \tilde{x}\|_2^2 \right).$$

- Из условия оптимальности для выпуклой функции  $r$  это эквивалентно **вопрос**: чему?

$$0 \in \partial \left( r(\tilde{x}) + \frac{1}{2} \|x - \tilde{x}\|_2^2 \right) \Big|_{\tilde{x}=y} = \partial r(y) + y - x.$$

Получили эквивалентность первого и второго условий.

- Из определения субдифференциала, для любого субградиента  $g \in \partial f(y)$  и для любого  $z \in \mathbb{R}^d$ :

$$\langle g, z - y \rangle \leq r(z) - r(y).$$

В частности справедливо и для  $g = x - y$ . В обратную сторону тоже очевидно: для  $g = x - y$  выполнено соотношение выше, значит  $g \in \partial r(y)$ . Лемма доказана.

# Свойства проксимального оператора

$$\begin{aligned}\langle x-y, z_1-y \rangle &\leq r(z_1) - r(y) \\ \langle y-x, z_2-x \rangle &\leq r(z_2) - r(x)\end{aligned}$$

## Лемма (свойство проксимального оператора)

Пусть  $r : \mathbb{R}^d \rightarrow \mathbb{R} \cup \{+\infty\}$  выпуклая функция, для которой определен  $\text{prox}_r$ . Тогда для любых  $x, y \in \mathbb{R}^d$  выполнено следующее:

- $\langle x - y, \text{prox}_r(x) - \text{prox}_r(y) \rangle \geq \|\text{prox}_r(x) - \text{prox}_r(y)\|_2^2,$
- $\|\text{prox}_r(x) - \text{prox}_r(y)\|_2 \leq \|x - y\|_2.$

$$u = \text{prox}_r(x) \quad v = \text{prox}_r(y)$$

- Пусть  $u = \text{prox}_r(x)$ ,  $v = \text{prox}_r(y)$ .



# Доказательство

$$y = \text{prox}_r(x)$$

- Пусть  $\underline{u} = \text{prox}_r(x)$ ,  $v = \text{prox}_r(y)$ . Тогда из предыдущего свойства:

$$\langle x - u, z_1 - u \rangle \leq r(z_1) - r(u), \quad \forall z_1$$

$$\langle y - v, z_2 - v \rangle \leq r(z_2) - r(v), \quad \forall z_2$$

$$z_1 = v \quad z_2 = u$$

$$+ \begin{cases} \langle x - u; v - u \rangle \leq r(v) - r(u) \\ \langle y - v; u - v \rangle \leq r(u) - r(v) \end{cases}$$

$$\underline{\| \text{prox} - \text{prox} \| \leq \| x - y \|}$$

$$\langle x - u - y + v; v - u \rangle \leq 0$$

$$\langle x - y; v - u \rangle + \|v - u\|_2^2 \leq 0$$

$$\|v - u\|_2^2 \leq \langle x - y; u - v \rangle$$

$$\| \text{prox}(x) - \text{prox}(y) \|_2^2 \leq \frac{\langle \text{prox}(x) - \text{prox}(y); x - y \rangle}{\| \text{prox} - \text{prox} \|_2} \leq \| \text{prox} - \text{prox} \|_2 \cdot \| x - y \|_2$$

- Пусть  $u = \text{prox}_r(x)$ ,  $v = \text{prox}_r(y)$ . Тогда из предыдущего свойства:

$$\langle x - u, z_1 - u \rangle \leq r(z_1) - r(u),$$

$$\langle y - v, z_2 - v \rangle \leq r(z_2) - r(v).$$

- Подставляем  $z_1 = v$  и  $z_2 = u$ . Суммируем:

$$\langle x - u, v - u \rangle + \langle y - v, u - v \rangle \leq 0$$

- Пусть  $u = \text{prox}_r(x)$ ,  $v = \text{prox}_r(y)$ . Тогда из предыдущего свойства:

$$\langle x - u, z_1 - u \rangle \leq r(z_1) - r(u),$$

$$\langle y - v, z_2 - v \rangle \leq r(z_2) - r(v).$$

- Подставляем  $z_1 = v$  и  $z_2 = u$ . Суммируем:

$$\langle x - u, v - u \rangle + \langle y - v, u - v \rangle \leq 0$$

Откуда

$$\langle x - y, v - u \rangle + \|v - u\|_2^2 \leq 0.$$

- Пусть  $u = \text{prox}_r(x)$ ,  $v = \text{prox}_r(y)$ . Тогда из предыдущего свойства:

$$\langle x - u, z_1 - u \rangle \leq r(z_1) - r(u),$$

$$\langle y - v, z_2 - v \rangle \leq r(z_2) - r(v).$$

- Подставляем  $z_1 = v$  и  $z_2 = u$ . Суммируем:

$$\langle x - u, v - u \rangle + \langle y - v, u - v \rangle \leq 0$$

Откуда

$$\langle x - y, v - u \rangle + \|v - u\|_2^2 \leq 0.$$

А это и требовалось доказать. **Вопрос:** как быстро доказать второе утверждение леммы?

- Пусть  $u = \text{prox}_r(x)$ ,  $v = \text{prox}_r(y)$ . Тогда из предыдущего свойства:

$$\langle x - u, z_1 - u \rangle \leq r(z_1) - r(u),$$

$$\langle y - v, z_2 - v \rangle \leq r(z_2) - r(v).$$

- Подставляем  $z_1 = v$  и  $z_2 = u$ . Суммируем:

$$\langle x - u, v - u \rangle + \langle y - v, u - v \rangle \leq 0$$

Откуда

$$\langle x - y, v - u \rangle + \|v - u\|_2^2 \leq 0.$$

А это и требовалось доказать. **Вопрос:** как быстро доказать второе утверждение леммы? КБШ.

# Композитная задача

- Рассмотрим следующую задачу:

$$\min_{x \in \mathbb{R}^d} \underbrace{f(x)} + \underbrace{r(x)}.$$

# Композитная задача

- Рассмотрим следующую задачу:

$$\min_{x \in \mathbb{R}^d} [f(x) + r(x)].$$

- Такая задача называется композитной.
- Предположим, что  $f$  является  $L$ -гладкой выпуклой функцией,  $r$  выпуклой (необязательно гладкой, но) проксимально дружественной функцией.

# Композитная задача

- Рассмотрим следующую задачу:

$$\min_{x \in \mathbb{R}^d} [f(x) + r(x)].$$

- Такая задача называется композитной.
- Предположим, что  $f$  является  $L$ -гладкой выпуклой функцией,  $r$  выпуклой (необязательно гладкой, но) проксимально дружественной функцией.
- Получается целевая функция состоит из гладкой и в общем случае негладкой части. Если  $r \equiv 0$ , то получаем гладкую задачу, которую умеем решать. Если  $f \equiv 0$ , то получаем негладкую задачу.



# Проксимальный градиентный метод

## Алгоритм 3 Проксимальный градиентный метод

**Вход:** размеры шагов  $\{\gamma_k\}_{k=0} > 0$ , стартовая точка  $x^0 \in \mathbb{R}^d$ , количество итераций  $K$

- 1: **for**  $k = 0, 1, \dots, K - 1$  **do**
- 2:     Вычислить  $\nabla f(x^k)$
- 3:      $x^{k+1} = \text{prox}_{\gamma_k} (x^k - \gamma_k \nabla f(x^k))$
- 4: **end for**

**Выход:**  $x^K$

$$\arg \min_x \left( \gamma_k r(x) + \frac{1}{2} \|x^k - \gamma_k \nabla f(x^k) - x\|_2^2 \right)$$

$$\nabla = 0$$

$$\gamma_k \nabla r(x^{k+1}) + x^{k+1} - x^k + \gamma_k \nabla f(x^k) = 0$$

$$x^{k+1} = x^k - \gamma_k (\nabla f(x^k) + \nabla r(x^{k+1}))$$

# Проксимальный градиентный метод

---

## Алгоритм 4 Проксимальный градиентный метод

---

**Вход:** размеры шагов  $\{\gamma_k\}_{k=0} > 0$ , стартовая точка  $x^0 \in \mathbb{R}^d$ , количество итераций  $K$

```
1: for  $k = 0, 1, \dots, K - 1$  do  
2:   Вычислить  $\nabla f(x^k)$   
3:    $x^{k+1} = \text{prox}_{\gamma r}(x^k - \gamma_k \nabla f(x^k))$   
4: end for
```

**Выход:**  $x^K$

---

- Если  $r$  непрерывно дифференцируема, то условие оптимальности для подзадачи подсчета проксимального оператора записывается, как:

$$0 = \gamma \nabla r(x^{k+1}) + x^{k+1} - \gamma \nabla f(x^k).$$

# Проксимальный градиентный метод

---

## Алгоритм 5 Проксимальный градиентный метод

---

**Вход:** размеры шагов  $\{\gamma_k\}_{k=0} > 0$ , стартовая точка  $x^0 \in \mathbb{R}^d$ , количество итераций  $K$

```
1: for  $k = 0, 1, \dots, K - 1$  do  
2:   Вычислить  $\nabla f(x^k)$   
3:    $x^{k+1} = \text{prox}_{\gamma r}(x^k - \gamma_k \nabla f(x^k))$   
4: end for
```

**Выход:**  $x^K$

---

- Если  $r$  непрерывно дифференцируема, то условие оптимальности для подзадачи подсчета проксимального оператора записывается, как:

$$0 = \gamma \nabla r(x^{k+1}) + x^{k+1} - \gamma \nabla f(x^k).$$

- Откуда получаем так называемую неявную запись метода:

$$x^{k+1} = x^k - \gamma(\nabla f(x^k) + \nabla r(x^{k+1}))$$

## Лемма (свойство проксимального оператора)

Пусть  $f : \mathbb{R}^d \rightarrow \mathbb{R} \cup \{+\infty\}$ ,  $r : \mathbb{R}^d \rightarrow \mathbb{R} \cup \{+\infty\}$  выпуклые функции. Дополнительно предположим, что  $f$  является непрерывно дифференцируемой и  $L$ -гладкой, а для  $r$  определен  $\text{prox}_r$ . Тогда  $x^*$  – решение комбинитной задачи оптимизации тогда и только тогда, когда для любого  $\gamma > 0$  выполнено:

$$x^* = \text{prox}_{\gamma r}(x^* - \gamma \nabla f(x^*)).$$

$$\begin{aligned} & \arg\min (\gamma r(x) + \frac{1}{2} \|x - x^* + \gamma \nabla f(x^*)\|^2) \\ & 0 \in \partial (\gamma r(x) + \frac{1}{2} \|x - x^* + \gamma \nabla f(x^*)\|^2) \\ & 0 \in \gamma \partial r(x) + \underline{x - x^*} + \gamma \nabla f(x^*) \quad x = x^* \end{aligned}$$

- Условие оптимальности:

$$0 \in \nabla f(x^*) + \partial r(x^*).$$

- Условие оптимальности:

$$0 \in \nabla f(x^*) + \partial r(x^*).$$

- Откуда

$$\underbrace{x^* - \gamma \nabla f(x^*)}_{\text{blue arc}} - \underbrace{x^*}_{\text{blue arc}} \in \gamma \partial r(x^*).$$

- Условие оптимальности:

$$0 \in \nabla f(x^*) + \partial r(x^*).$$

- Откуда

$$x^* - \gamma \nabla f(x^*) - x^* \in \gamma \partial r(x^*).$$

$$x - y \in \gamma \partial r(x^*)$$

- Из свойств проксимального оператора

$$\underline{x^* = \text{prox}_{\gamma r}(x^* - \gamma \nabla f(x^*))}.$$

А это и требовалось.

- В итоге имеем следующие свойства:

$$\begin{aligned} & \|\text{prox}_r(x) - \text{prox}_r(y)\|_2 \leq \|x - y\|_2 \\ & x^* = \text{prox}_{\gamma r}(x^* - \gamma \nabla f(x^*)). \end{aligned}$$

**Вопрос:** в доказательстве какого метода уже нам нужны были такие свойства?



- В итоге имеем следующие свойства:

$$\|\text{prox}_r(x) - \text{prox}_r(y)\|_2 \leq \|x - y\|_2$$
$$x^* = \text{prox}_{\gamma r}(x^* - \gamma \nabla f(x^*)).$$

**Вопрос:** в доказательстве какого метода уже нам нужны были такие свойства? Градиентный спуск с проекцией. Вспомним, что проксимальный оператор включает в себя и оператор проекции.

- В итоге имеем следующие свойства:

$$\begin{aligned}\|\text{prox}_r(x) - \text{prox}_r(y)\|_2 &\leq \|x - y\|_2 \\ x^* &= \text{prox}_{\gamma r}(x^* - \gamma \nabla f(x^*)).\end{aligned}$$

**Вопрос:** в доказательстве какого метода уже нам нужны были такие свойства? Градиентный спуск с проекцией. Вспомним, что проксимальный оператор включает в себя и оператор проекции.

- Поэтому доказательство будет один в один.

# Доказательства сходимости

- Рассматриваем:

$$\nabla f(x^*) + \nabla r(x^*) = 0$$

$$\|x^{k+1} - x^*\|_2^2 = \|\text{prox}_{\gamma f}(x^k - \gamma_k \nabla f(x^k)) - x^*\|_2^2$$

$$\begin{aligned} x^* &= \text{prox}_{\gamma r}(x^* - \gamma \nabla f(x^*)) \\ &= \|\text{prox}_{\gamma r}(x^k - \gamma \nabla f(x^k)) - \\ &\quad - \text{prox}_{\gamma r}(x^* - \gamma \nabla f(x^*))\|_2^2 \\ &\leq \|x^k - \gamma \nabla f(x^k) - x^* + \gamma \nabla f(x^*)\|_2^2 \end{aligned}$$

# Доказательства сходимости

- Рассматриваем:

$$\|x^{k+1} - x^*\|_2^2 = \|\text{prox}_{\gamma f}(x^k - \gamma_k \nabla f(x^k)) - x^*\|_2^2$$

- Используем второе свойство с предыдущего слайда:

$$\begin{aligned}\|x^{k+1} - x^*\|_2^2 &= \|\text{prox}_{\gamma f}(x^k - \gamma_k \nabla f(x^k)) - x^*\|_2^2 \\ &= \|\text{prox}_{\gamma f}(x^k - \gamma_k \nabla f(x^k)) - \text{prox}_{\gamma f}(x^* - \gamma_k \nabla f(x^*))\|_2^2\end{aligned}$$

# Доказательства сходимости

- Рассматриваем:

$$\|x^{k+1} - x^*\|_2^2 = \|\text{prox}_{\gamma f}(x^k - \gamma_k \nabla f(x^k)) - x^*\|_2^2$$

- Используем второе свойство с предыдущего слайда:

$$\begin{aligned}\|x^{k+1} - x^*\|_2^2 &= \|\text{prox}_{\gamma f}(x^k - \gamma_k \nabla f(x^k)) - x^*\|_2^2 \\ &= \|\text{prox}_{\gamma f}(x^k - \gamma_k \nabla f(x^k)) - \text{prox}_{\gamma f}(x^* - \gamma_k \nabla f(x^*))\|_2^2\end{aligned}$$

- Теперь первое свойство с предыдущего слайда:

$$\begin{aligned}\|x^{k+1} - x^*\|_2^2 &\leq \|x^k - \gamma_k \nabla f(x^k) - x^* + \gamma_k \nabla f(x^*)\|_2^2 \\ &= \underbrace{\|x^k - x^*\|_2^2 - 2\gamma_k \langle \nabla f(x^k) - \nabla f(x^*), x^k - x^* \rangle}_{\text{blue line}} \\ &\quad + \underbrace{\gamma_k^2 \|\nabla f(x^k) - \nabla f(x^*)\|_2^2}_{\text{blue line}}\end{aligned}$$

- С предыдущего слайда:

$$\begin{aligned}\|x^{k+1} - x^*\|_2^2 &\leq \|x^k - x^*\|_2^2 - 2\gamma_k \langle \nabla f(x^k) - \nabla f(x^*), x^k - x^* \rangle \\ &\quad + \gamma_k^2 \|\nabla f(x^k) - \nabla f(x^*)\|_2^2\end{aligned}$$

# Доказательства сходимости

- С предыдущего слайда:

$$\begin{aligned}\|x^{k+1} - x^*\|_2^2 &\leq \|x^k - x^*\|_2^2 - 2\gamma_k \langle \nabla f(x^k) - \nabla f(x^*), x^k - x^* \rangle \\ &\quad + \gamma_k^2 \|\nabla f(x^k) - \nabla f(x^*)\|_2^2\end{aligned}$$

- Вспомним такой объект, как дивергенция Брэгмана, порожденную выпуклой функцией  $f$ :

$$f(x^k) - f(x^*) - \langle \nabla f(x^*), x^k - x^* \rangle \geq 0$$

$$V_f(x, y) = f(x) - f(y) - \langle \nabla f(y), x - y \rangle \geq 0.$$

$$\begin{aligned}\nabla f(y) &= 0 \\ (x^*)\end{aligned}$$

# Доказательства сходимости

- Воспользуемся сильной выпуклостью и гладкостью:

$$\begin{aligned}\|x^{k+1} - x^*\|_2^2 &\leq \|x^k - x^*\|_2^2 \\ &\quad - 2\gamma_k \left( f(x^k) - f(x^*) - \langle \nabla f(x^*), x^k - x^* \rangle + \frac{\mu}{2} \|x^k - x^*\|_2^2 \right) \\ &\quad + 2\gamma_k^2 L \left( f(x^k) - f(x^*) - \langle \nabla f(x^*), x^k - x^* \rangle \right) \\ &= (1 - \mu\gamma_k) \|x^k - x^*\|_2^2 + 2\gamma_k(\gamma_k L - 1) V_f(x^k, x^*)\end{aligned}$$

$\gamma \leq \frac{1}{L}$        $\geq 0$

- Дальше как раньше подбирает  $\gamma_k$ , пользуемся неотрицательности дивергенции Брэгмана.



# Проксимальный метод: итог

- Проксимальный градиентный спуск для композитной задачи с  $L$ -гладкой выпуклой функцией  $f$  и выпуклой проксимально дружественной функцией  $r$  имеет такую же сходимость, что и метод градиентного спуска для функции  $f$ . Свойства гладкости/негладкости  $r$  при этом не влияют.
- Кажется, что положив  $f \equiv 0$ , с помощью такого метода можно решать любую негладкую задачу.

# Проксимальный метод: итог

- Проксимальный градиентный спуск для композитной задачи с  $L$ -гладкой выпуклой функцией  $f$  и выпуклой проксимально дружественной функцией  $r$  имеет такую же сходимость, что и метод градиентного спуска для функции  $f$ . Свойства гладкости/негладкости  $r$  при этом не влияют.
- Кажется, что положив  $f \equiv 0$ , с помощью такого метода можно решать любую негладкую задачу. **Вопрос:** так ли это?

# Проксимальный метод: итог

- Проксимальный градиентный спуск для композитной задачи с  $L$ -гладкой выпуклой функцией  $f$  и выпуклой проксимально дружественной функцией  $r$  имеет такую же сходимость, что и метод градиентного спуска для функции  $f$ . Свойства гладкости/негладкости  $r$  при этом не влияют.
- Кажется, что положив  $f \equiv 0$ , с помощью такого метода можно решать любую негладкую задачу. **Вопрос:** так ли это? если разрешить считать проксимальный оператор неточно (численно), то и правда можно решать любую задачу негладкой оптимизации.

# Проксимальный метод: итог

- Проксимальный градиентный спуск для композитной задачи с  $L$ -гладкой выпуклой функцией  $f$  и выпуклой проксимально дружественной функцией  $r$  имеет такую же сходимость, что и метод градиентного спуска для функции  $f$ . Свойства гладкости/негладкости  $r$  при этом не влияют.
- Кажется, что положив  $f \equiv 0$ , с помощью такого метода можно решать любую негладкую задачу. **Вопрос:** так ли это? если разрешить считать проксимальный оператор неточно (численно), то и правда можно решать любую задачу негладкой оптимизации. НО это с точки зрения теории не лучше, чем решать задачу субградиентным спуском, потому что при решении подзадачи проксимального используется какой-то вспомогательный метод (например, тот же субградиентный спуск).