


Задача минимизации эмпирического (ERM реш.):

$$\min_{x \in \mathbb{R}^d} \bar{f}(x) := \frac{1}{M} \sum_{m=1}^M f_m(x) = \frac{1}{M} \sum_{m=1}^M \frac{1}{n_m} \sum_{i=1}^{n_m} L(g(x, a_i^m), b_i^m)$$

↑
геминг на n y_i -be

- f_m - на геминг-бе m (∇f_m , f_m можно брать на m геминг-бе)



Децентрализованный градиентный спуск

- 1) $\nabla f_m(x^k)$ на свое y_i -be
- 2) геминг-бе $\nabla f_m(x^k)$ на сервер
- 3) сервер получает все и агрегирует $\frac{1}{M} \sum_{m=1}^M \nabla f_m(x^k) = \nabla f(x^k)$
- 4) сервер получает $\nabla f(x^k)$ на все геминг-бе
- 5) геминг-бе делают $x^{k+1} = x^k - \gamma \nabla f(x^k)$

Проблема: Коммуникация - дорого
и метрикой работы параллелизации

Теорема N1 - локальный

Объемов работы сервера = дорого
Давление сервера на работу сервера

Parallel GD / FedAvg / Local GD:

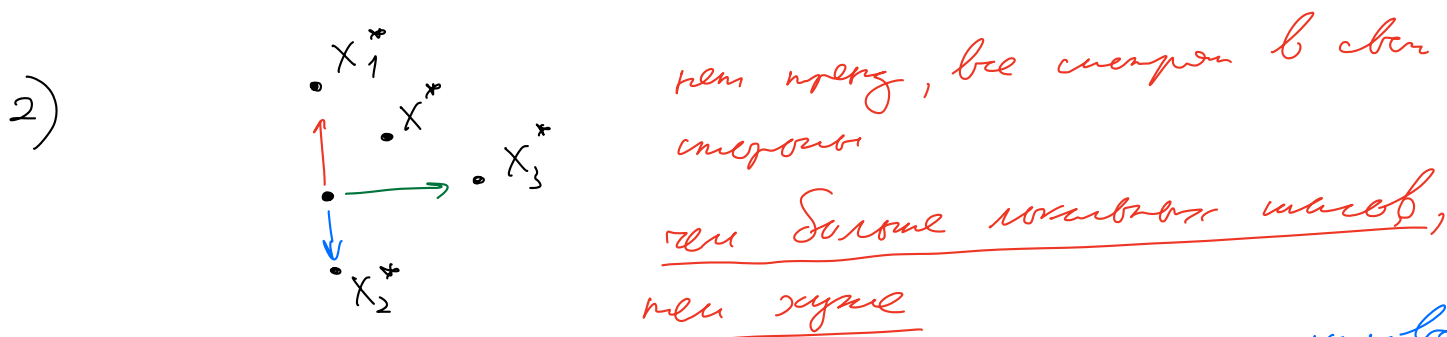

$$x_m^{k+1} = x_m^k - \gamma \nabla f_m(x_m^k)$$

при t итерации $x^k = \frac{1}{M} \sum_{m=1}^M x_m^k$, $x_m^k = x^k$

⊕ строение минимизации. замкнут

⊖ метод сложился только до оптимизации

Пример:



Теорема

$$\|\bar{x}^k - x^*\|_2^2 \leq (1 - \mu\gamma)^k \|x^0 - x^*\|_2^2 + \frac{\gamma \theta_{\text{opt}}^2}{\mu} \frac{t}{k}$$

$\bar{x}^k = \frac{1}{M} \sum_{m=1}^M x_m^k$

слож. до опт.

$\frac{1}{M} \sum_{m=1}^M \|\nabla f_m(x^*)\|_2^2$

вер.-бо. миним.

Хотим метод, чтобы сходился при любых нач.

Идея: локальные миним. = переобучение

регуляризаторы = защита от переобучения

локальный миним.: минимизация $f_m(x)$

минимизация $\mathcal{F}_m(x) = f_m(x) + \frac{\lambda}{2} \|x - v\|_2^2$

регуляризатор

Fed Prox:

$$\begin{aligned} X_m^{k+1} &= X_m^k - \gamma (\nabla f_m(X_m^k) + \lambda(X_m^k - \mathcal{V}^k)) \\ \mathcal{V}^{k+1} &= \mathcal{V}^k \end{aligned}$$

$$\text{при } t \text{ итерациях} \quad X^k = \frac{1}{M} \sum_{m=1}^M X_m^k, \quad X_m^k = X^k \\ \mathcal{V}^k = X^k$$

Fed Prox:

$$X_m^{k+1} = X_m^k - \gamma (\nabla f_m(X_m^k) + \lambda X_m^k - \lambda \mathcal{V}^k)$$

Scaffold

$$X_m^{k+1} = X_m^k - \gamma (\nabla f_m(X_m^k) + \underbrace{C_m^k - C^k}_{\text{регуляризатор}})$$

⊕ нулевое локальное GD

⊕ сходимость за релаксацией

Проблема локальных минимумов:

или не игра, или GD (сн. правило выпуклости)

Но если хотим найти глобальный минимум (f_n)

минимум достигается только в глобальном экстремуме

• Как оценить сходимость?

$$1) \|\nabla f_m(x) - \nabla f(x)\| \leq \Delta$$

то есть: $\|A_m x - Ax\| \sim \|A_m - A\| \|x\|$

x не ограничено, но Δ не нуль.

$$2) \|\nabla^2 f_m(x) - \nabla^2 f(x)\| \leq \delta$$

то есть: $\|A_m - A\| \leq \delta$

не пер. вг. Херсхмана
 $\frac{L}{\sqrt{N}}$ — константа Липшица
 градиент f
 кол-во генераторов
 в f_m

Схема метода зеркального спуска:

$$x^{k+1} = \arg \min_{x \in \mathbb{R}^d} \{ \gamma \langle \nabla f(x^k); x \rangle + V(x, x^k) \}$$

$$V(x, y) = \varphi(x) - \varphi(y) - \langle \nabla \varphi(y); x - y \rangle$$

здесь φ задан нормой в нек. пространстве

$$\varphi(x) = f_1(x) + \frac{\delta}{2} \|x\|_2^2$$

Решение $\arg \min$ на генераторе с f_1

Вектор 1-компонентного градиента

Сходимость метода зеркального спуска:

$$\gamma = 1$$

$$V(x^*, x^k) \leq \left(1 - \frac{\mu}{\mu + 2\delta}\right)^k V(x^*, x^0)$$

минимум функции f

$\sim \varepsilon$

нормы векторов

то для достижения точности ε нужно

$$k = \frac{2\delta + \mu}{\mu} \log \frac{V(x^*, x^0)}{\varepsilon}$$

gew GD

$$k = \frac{L}{\mu} \log \frac{\|x^* - x^q\|_2^2}{\varepsilon}$$

$$\sigma \sim \frac{L}{\sqrt{N}}$$