

$$\min_{x \in \mathbb{R}^d} \left[f(x) = \frac{1}{n} \sum_{i=1}^n f_i(x) \right]$$

Идея:

$$\begin{aligned} x^{k+1} &= x^k - \gamma g^k \\ g^k &\rightarrow O(\nabla f(x^*)) \quad x^k \rightarrow x^* \\ \nabla f_i(x^k) &\not\rightarrow 0 \\ \mathbb{E}[g^k | x^k] &= \nabla f(x^k) \end{aligned}$$

Алгоритм 1 SAGA

Вход: размер шага $\gamma > 0$, стартовая точка $x^0 \in \mathbb{R}^d$, значения памяти $y_i^0 = 0$ для всех $i \in [n]$, количество итераций K

- 1: **for** $k = 0, 1, \dots, K - 1$ **do**
- 2: Сгенерировать независимо i_k
- 3: Вычислить $g^k = \nabla f_{i_k}(x^k) - y_{i_k}^k + \frac{1}{n} \sum_{j=1}^n y_j^k$
- 4: Обновить $y_i^{k+1} = \begin{cases} \nabla f_i(x^k), & \text{если } i = i_k \\ y_i^k, & \text{иначе} \end{cases}$
- 5: $x^{k+1} = x^k - \gamma g^k$
- 6: **end for**

Выход: x^K

Суть:

y_j^k - где индекс $j = 1 \dots n$
 - хранит инд. о граде ∇f_j

$\frac{1}{n} \sum_{j=1}^n y_j^k$ - "запас." градиент

g^k ? да, можно

$$\begin{aligned} \mathbb{E} \left[\frac{1}{n} \sum_{j=1}^n y_j^k | x^k \right] &= \mathbb{E}_{i_k} \left[\frac{1}{n} \sum_{j=1}^n y_j^k \right] \\ &= \frac{1}{n} \sum_{j=1}^n \left[\frac{1}{n} \nabla f_j(x^k) + \left(1 - \frac{1}{n}\right) y_j^{k-1} \right] \end{aligned}$$

$$= \frac{1}{n^2} \sum_{j=1}^n \nabla f_j(x^k) + (1 - \frac{1}{n}) \cdot \frac{1}{n} \sum y_j^{k-1}$$

$$= \frac{1}{n} \nabla f(x^k) + \dots \neq \nabla f(x^k)$$

- g^k - шум ($E \neq \nabla f(x^k)$)
- шум removed (по мере уменьшения)

Примеры в SAGA

$$g^k = \underbrace{\nabla f_{i_k}(x^k)}_{\frac{1}{n}} - \underbrace{y_{i_k}^k}_{\frac{1}{n}} + \frac{1}{n} \sum_{j=1}^n y_j^k$$

б. шаг. берем

$$\begin{aligned} E[g^k | x^k] &= E_{i_k} [\nabla f_{i_k}(x^k) - y_{i_k}^k] + \frac{1}{n} \sum_{j=1}^n y_j^k \\ &= \sum_{j=1}^n \frac{1}{n} \nabla f_j(x^k) - \cancel{\sum_{j=1}^n \frac{1}{n} y_j^k} + \cancel{\frac{1}{n} \sum_{j=1}^n y_j^k} \\ &= \nabla f(x^k) \end{aligned}$$

Гипотеза:

$$g^k \xrightarrow{?} 0 \quad x^k \rightarrow x^*$$

$$\nabla f_{i_k}(x^k) - y_{i_k}^k + \frac{1}{n} \sum y_j^k$$

$$\begin{aligned} &\left(\begin{array}{l} x^k \rightarrow x^* \quad y_j^k \rightarrow \nabla f_j(x^*) \\ \nabla f_{i_k}(x^*) - \cancel{\nabla f_{i_k}(x^*)} + \frac{1}{n} \sum \nabla f_j(x^*) \end{array} \right) \\ &\qquad \qquad \qquad \nabla f(x^*) \rightarrow 0 \end{aligned}$$

Док-во сходимости:

- f_i - L -линейна
- f - μ -сильно выпукла

$$\begin{aligned} E[\|x^{k+1} - x^*\|_2^2 | x^k] &= \|x^k - x^*\|_2^2 - 2\gamma \langle E[g^k | x^k], x^k - x^* \rangle \\ &\quad + \gamma^2 E[\|g^k\|_2^2 | x^k] \end{aligned}$$

$$\mathbb{E}[g^k | x^k] = \nabla f(x^k) \quad \text{Strongly convex}$$

$$\begin{aligned} \text{Therefore } \mathbb{E}[\|g^k\|_2^2 | x^k] &= \\ &= \mathbb{E}[\|g^k - \nabla f(x^*)\|_2^2 | x^k] \\ &\quad \left(\mathbb{E}[x^k] = \mathbb{E}_{i_k} \right) \end{aligned}$$

$$\begin{aligned} \mathbb{E}_{i_k}[\|g^k - \nabla f(x^*)\|_2^2] &= \\ = \mathbb{E}_{i_k}[\| \nabla f_{i_k}(x^k) - y_{i_k}^k + \underbrace{\frac{1}{n} \sum_j y_j^k - \nabla f(x^*)}_{\frac{1}{n} \sum_j (y_j^k - \nabla f_j(x^*))} \|_2^2] \end{aligned}$$

$$\begin{aligned} &= \mathbb{E}_{i_k}[\| \nabla f_{i_k}(x^k) - \nabla f_{i_k}(x^*) - y_{i_k}^k + \nabla f_{i_k}(x^*) + \underbrace{\frac{1}{n} \sum_j y_j^k - \nabla f_j(x^*)}_{\frac{1}{n} \sum_j (y_j^k - \nabla f_j(x^*))} \|_2^2] \\ &\leq 2 \mathbb{E}_{i_k}[\| \nabla f_{i_k}(x^k) - \nabla f_{i_k}(x^*) \|_2^2] + \frac{1}{n} \sum_j \mathbb{E}_{i_k}[\| y_j^k - \nabla f_j(x^*) \|_2^2] \\ &\leq 2 \mathbb{E}_{i_k}[\| \nabla f_{i_k}(x^k) - \nabla f_{i_k}(x^*) \|_2^2] + 2 \mathbb{E}_{i_k}[\| y_{i_k}^k - \nabla f_{i_k}(x^*) - \frac{1}{n} \sum_j (y_j^k - \nabla f_j(x^*)) \|_2^2] \end{aligned}$$

$$\mathbb{E}_{i_k}[\| y_{i_k}^k - \nabla f_{i_k}(x^*) \|_2^2] = \frac{1}{n} \sum_j \| y_j^k - \nabla f_j(x^*) \|_2^2$$

$$\mathbb{E} \|g - \mathbb{E}g\|_2^2 \leq \mathbb{E} \|g\|_2^2$$

$$\begin{aligned} &\leq 2 \mathbb{E}_{i_k}[\| \nabla f_{i_k}(x^k) - \nabla f_{i_k}(x^*) \|_2^2] \\ &\quad + 2 \mathbb{E}_{i_k}[\| y_{i_k}^k - \nabla f_{i_k}(x^*) \|_2^2] \\ &= 2 \sum_{j=1}^n \frac{1}{n} \| \nabla f_j(x^k) - \nabla f_j(x^*) \|_2^2 \\ &\quad + 2 \sum_{j=1}^n \frac{1}{n} \| y_j^k - \nabla f_j(x^*) \|_2^2 \end{aligned}$$

L - Lipschitz f_j $\nabla f(x^*) = 0$

$$\leq 2 \cdot \frac{1}{n} \sum_{j=1}^n 2L (f_j(x^k) - f_j(x^*) - \langle \nabla f_j(x^*), x^k - x^* \rangle) + 2 \sum_{j=1}^n \frac{1}{n} \|y_j^k - \nabla f_j(x^*)\|_2^2$$

$$= 4L (f(x^k) - f(x^*)) + 2 \sum_{j=1}^n \frac{1}{n} \|y_j^k - \nabla f_j(x^*)\|_2^2$$

Богданов:

$$\mathbb{E}[\|x^{k+1} - x^*\|_2^2 | x^k] = \|x^k - x^*\|_2^2 - 2\gamma \langle \nabla f(x^k); x^k - x^* \rangle + 4\gamma^2 (f(x^k) - f(x^*)) + 2\gamma^2 \cdot \frac{1}{n} \sum \|y_j^k - \nabla f_j(x^*)\|_2^2$$

$y_j^k \rightarrow \nabla f_j(x^*)$

var. берем $\frac{1}{n} \sum \|y_j^k - \nabla f_j(x^*)\|_2^2$:

$$\mathbb{E} \left[\frac{1}{n} \sum_{j=1}^n \|y_j^{k+1} - \nabla f_j(x^*)\|_2^2 | x^k \right]$$

$$= \frac{1}{n} \sum_{j=1}^n \mathbb{E} [\|y_j^{k+1} - \nabla f_j(x^*)\|_2^2 | x^k]$$

$$= \frac{1}{n} \sum_{j=1}^n \left(\frac{1}{n} \cdot \|\nabla f_j(x^k) - \nabla f_j(x^*)\|_2^2 + \left(1 - \frac{1}{n}\right) \cdot \|y_j^k - \nabla f_j(x^*)\|_2^2 \right)$$

$$= \frac{1}{n} \cdot \frac{1}{n} \sum \|\nabla f_j(x^k) - \nabla f_j(x^*)\|_2^2 + \left(1 - \frac{1}{n}\right) \cdot \underbrace{\frac{1}{n} \sum \|y_j^k - \nabla f_j(x^*)\|_2^2}_{\sigma_k^2}$$

$$\mathbb{E}[G_{k+1}^2 | X^k] = \left(1 - \frac{1}{n}\right) G_k^2 + \frac{1}{n} \cdot \frac{1}{n} \sum_{j=1}^n \|\nabla f_j(x^k) - \nabla f_j(x^*)\|_2^2$$

L-improves

$$\mathbb{E}[G_{k+1}^2 | X^k] = \left(1 - \frac{1}{n}\right) G_k^2 + \frac{1}{n} \cdot 2L (f(x^k) - f(x^*))$$

Умова:

$$\begin{aligned} 1) \mathbb{E}[\|X^{k+1} - x^*\|_2^2 | X^k] &= \|x^k - x^*\|_2^2 - 2\gamma \langle \nabla f(x^k); x^k - x^* \rangle \\ &\quad + 4L\gamma^2 (f(x^k) - f(x^*)) \\ &\quad + 2\gamma^2 \cdot G_k^2 \\ &\leq (1 - \gamma\mu) \|x^k - x^*\|_2^2 \quad \text{мн. суж.} \\ &\quad + 2\gamma(2L\gamma - 1) (f(x^k) - f(x^*)) \\ &\quad + 2\gamma^2 G_k^2 \quad ? \quad \gamma \leq \frac{\mu}{2L} \end{aligned}$$

$$\begin{aligned} 2) \mathbb{E}[G_{k+1}^2 | X^k] &= \left(1 - \frac{1}{n}\right) G_k^2 \quad \text{мн. суж.} \\ &\quad + \frac{1}{n} \cdot 2L (f(x^k) - f(x^*)) \quad ? \end{aligned}$$

Суммарен с умовом $M > 0$

$$\begin{aligned} \mathbb{E}[\|X^{k+1} - x^*\|_2^2 + M G_{k+1}^2 | X^k] &\leq (1 - \gamma\mu) \|x^k - x^*\|_2^2 \\ &\quad + 2\gamma(2L\gamma - 1) (f(x^k) - f(x^*)) \\ &\quad + 2\gamma^2 G_k^2 \\ &\quad + M \cdot \left(1 - \frac{1}{n}\right) G_k^2 \end{aligned}$$

$$+ \mu \cdot 2L \cdot \frac{1}{n} (f(x^k) - f(x^*))$$

$$= (1 - \gamma\mu) \|x^k - x^*\|_2^2 + \left[\left(1 - \frac{1}{2n}\right) + \frac{2\gamma^2}{\mu} \right] \cdot M \sigma_k^2 + \left[2\gamma(2L\gamma - 1) + 2L \cdot \frac{\mu}{n} \right] (f(x^k) - f(x^*))$$

$$1 - \frac{1}{n} + \frac{2\gamma^2}{\mu} \leq 1 - \frac{1}{2n} \quad \boxed{\mu = 4\gamma^2 n}$$

$$= (1 - \gamma\mu) \|x^k - x^*\|_2^2 + \left(1 - \frac{1}{2n}\right) \cdot M \sigma_k^2 + \underbrace{\left(2\gamma(2L\gamma - 1) + 8\gamma^2 L\right)}_{\geq 0} (f(x^k) - f(x^*))$$

$$2\gamma(6L\gamma - 1) \leq 0 \quad \boxed{\gamma \leq \frac{1}{6L}}$$

$$\leq (1 - \gamma\mu) \|x^k - x^*\|_2^2 + \left(1 - \frac{1}{2n}\right) \cdot M \sigma_k^2 \leq \max \left\{ (1 - \mu\gamma), \left(1 - \frac{1}{2n}\right) \right\} \cdot \left[\|x^k - x^*\|_2^2 + M \sigma_k^2 \right]$$

Теорема сходимость SAGA

Пусть задача безусловной стохастической оптимизации вида конечной суммы с L -гладкими, выпуклыми функциями f_i и μ -сильно выпуклой целевой функцией f решается с помощью SAGA с $\gamma \leq \frac{1}{6L}$. Тогда справедлива следующая оценка сходимости

$$\mathbb{E}[\|x^k - x^*\|_2^2] \leq \mathbb{E}[V_k] \leq \max \left\{ (1 - \mu\gamma), \left(1 - \frac{1}{2n}\right) \right\}^k \mathbb{E}[V_0],$$

$$\text{где } V_k = \|x^k - x^*\|_2^2 + 4n\gamma^2 \cdot \frac{1}{n} \sum_{i=1}^n \|y_i^k - \nabla f_i(x^*)\|_2^2.$$

$$\|x^k - x^*\|_2^2 \leq V_k$$

Оценка по числу итераций:

$$\gamma = \frac{1}{6L}$$

$$\max \left\{ \left(1 - \frac{\mu}{6L}\right); \left(1 - \frac{1}{2n}\right) \right\}^k$$

$$O \left(\frac{L}{\mu} \log \frac{1}{\varepsilon} + n \log \frac{1}{\varepsilon} \right) \text{ итераций}$$

для граф спуска

$$O \left(\frac{L}{\mu} \log \frac{1}{\varepsilon} \right)$$

n f_i за итерацию

граф спуска:

$$O \left(n \frac{L}{\mu} \log \frac{1}{\varepsilon} \right) f_i \text{ на}$$

SAGA:

$$O \left(\left(\frac{L}{\mu} + n \right) \log \frac{1}{\varepsilon} \right) f_i \text{ на}$$

⊕ значительное ускорение, если граф спуска

⊖ $O(nd)$ на итерацию

Алгоритм 2 SVRG

Вход: размер шага $\gamma > 0$, стартовая точка $x^0 \in \mathbb{R}^d$, количество итераций в эпохе K , количество эпох S

- 1: **for** $s = 0, 1, \dots, S - 1$ **do**
- 2: Обновить $w^s = x^{s-1, K}$
- 3: Посчитать и сохранить $\nabla f(w^s)$
- 4: **for** $k = 0, 1, \dots, K - 1$ **do**
- 5: $x^{s, k+1} = x^{s, k} - \gamma g^k$
- 6: Сгенерировать независимо i_k
- 7: Вычислить $g^{k+1} = \nabla f_{i_k}(x^{s, k+1}) - \nabla f_{i_k}(w^s) + \nabla f(w^s)$
- 8: **end for**
- 9: **end for**

Выход: $x^{S-1, K}$

Идея:

$\nabla f(w^s)$ — град. в референсной точке

$$g^k = \nabla f_{i_k}(x^k) - \nabla f_{i_k}(w) + \nabla f(w)$$

$$\begin{array}{l} x^k \rightarrow x^* \\ w \rightarrow x^* \end{array} \quad \nabla f_{i_k}(x^*) - \nabla f_{i_k}(x^*) + \nabla f(x^*) \rightarrow \nabla f(x^*) \rightarrow 0$$

Сложность:

$$O\left(\left(n + \frac{L}{\mu}\right) \log \frac{1}{\varepsilon}\right) \quad \text{Size}$$

⊕ нет памяти $O(nd)$, только $O(d)$

⊖ подградиент немого градиента

Ускорение:

• 2 пометки

$$O\left(\sqrt{n} \frac{L}{\mu} \log \frac{1}{\varepsilon}\right) \quad \text{Size}$$

Кеслеров:

$$O\left(n \sqrt{\frac{L}{\mu}} \log \frac{1}{\varepsilon}\right)$$

Алгоритм 3 SARAH

Вход: размер шага $\gamma > 0$, стартовая точка $x^0 \in \mathbb{R}^d$, количество итераций в эпохе K , количество эпох S

```
1: for  $s = 0, 1, \dots, S-1$  do
2:   Посчитать  $g^0 = \nabla f(x^{s-1, K})$ 
3:   for  $k = 0, 1, \dots, K-1$  do
4:      $x^{s, k+1} = x^{s, k} - \gamma g^k$ 
5:     Сгенерировать независимо  $i_k$ 
6:     Вычислить  $g^{k+1} = \nabla f_{i_k}(x^{s, k+1}) - \nabla f_{i_k}(x^{s, k}) + g^k$ 
7:   end for
8: end for
```

Выход: $x^{S-1, K}$

Ugese:

Seriele matrică SVRG

$$\nabla f(w) \rightarrow g^k - \text{ca nu se știe}$$

SVRG $\approx \nabla f(x^k)$

$$\begin{aligned} \mathbb{E}_{i_k}[g^{k+1}] &= \mathbb{E}_{i_k}[\nabla f_{i_k}(x^{k+1}) - \nabla f_{i_k}(x^k)] + g^k \\ &= \nabla f(x^{k+1}) - \nabla f(x^k) + g^k \neq 0 \end{aligned}$$

⊕ seriale matrică, nu SVRG

⊖ nu se știe