

Вводная лекция

Методы оптимизации

Александр Безносиков

Московский физико-технический институт

4 сентября 2025



Команда курса: лектор

- Безносиков Александр Николаевич
- почта: beznosikov.an@phystech.edu, anbeznosikov@gmail.com
- tg: @abeznosikov

Команда курса: семинаристы

- Андреев Артем Викторович
tg: @artyomandreyev
- Богданов Александр Иванович
tg: @d0dos
- Былинкин Дмитрий Андреевич
tg: @lxstsvund
- Кормаков Георгий Владимирович
tg: @gkormakov
- Корнилов Никита Максимович
tg: @Tugnir

Команда курса: лектор и семинаристы

- Моложавенко Александр Александрович
tg: @MetaMelon
- Ребриков Алексей Витальевич
tg: @NoblFriend
- Ткаченко Светлана
tg: @Aikiseito
- Чежегов Савелий Андреевич
tg: @Savochak
- Хафизов Фанис Адикович
tg: @faniskhafizov

Команда курса: ассистенты

- Давыденко Григорий
- Иванов Максим
- Левин Леонид
- Максимов Роман
- Парфенова Анна
- Терехова Ольга
- Трифонов Степан
- Чирков Георгий
- Шалыгин Игорь

Правила игры: система оценивания

Вид активности	Баллы
тесты на 10 минут в начале каждого семинара по теме прошлой лекции и прошлого семинара	3
домашнее задание (выдается каждую неделю)	3 + 3
контрольная работа в середине семестра по темам лекций и семинаров	3
коллоквиум в конце семестра по темам лекций и семинаров	3
Итого:	15

Правила игры: система оценивания

- Для получения оценки удовлетворительно и выше необходимо, чтобы было выполнено хотя бы одно из следующих условий: оценка за коллоквиум ≥ 1 , оценка за КР ≥ 1 .
- Для получения оценки хорошо и выше необходимо, чтобы было выполнено оба следующих условия: оценка за коллоквиум ≥ 1 , оценка за КР ≥ 1 .

Правила игры: комментарии

- Ни один из видов активности не является 100% обязательным, но смотри дополнительные правила выше.
- Тесты будут проводиться на каждом семинаре.
- ДЗ будут появляться в четверг. Время на выполнение: 2 недели
- ДЗ состоит из двух частей: основной и дополнительной.
Основная часть легче и предполагается, что ее достаточно для хорошего погружения в курс, дополнительная часть – для более глубокого погружения в заинтересовавшие темы.
- При подозрении в списывании ДЗ баллы за конкретное домашнее задание обнуляются у всех авторов, подозреваемых в списывании (в том числе и у тех, кто дал списать).
- КР состоится 8 ноября в 9:00.

Правила игры: комментарии

- Коллоквиум проходит в конце семестра во время последнего семинара и на зачетной неделе (на выбор). Программа коллоквиума соответствует всей программе курса, изученной в рамках лекций и семинаров. Принимают коллоквиум семинарист и несколько приглашенных преподавателей. Процедура коллоквиума соответствует процедуре проведения обычного устного экзамена на Физтехе с билетами, дополнительными вопросами/задачами и беседой в рамках курса.

Немного истории

- 1847: Коши и градиентный спуск для линейных систем
- 1950ые: линейное программирование (быстро перешло в нелинейное программирование), появление стохастических методов
- 1980ые: появление теории для общих задач.
- 2010ые: задачи оптимизации большого размера, теория стохастических методов

Задача оптимизации

$$\min_{\substack{f(x) \\ g_i(x) \leq 0, \\ i=1, \dots, m, \\ x \in Q}} f(x)$$

- $Q \subseteq \mathbb{R}^d$ — подмножество d -мерного пространства
- $f : Q \rightarrow \mathbb{R}$ — некоторая функция, заданная на множестве Q
- В качестве $\&$ берётся \leq либо $=$
- $g_i(x) : Q \rightarrow \mathbb{R}, i = 1, \dots, m$ — функции, задающие ограничения

Задачи оптимизации. Первые наблюдения.

- 1 В общем случае задачи оптимизации могут не иметь решения.
Например, задача $\min_{x \in \mathbb{R}} x$ не имеет решения.
- 2 Задачи оптимизации часто нельзя решить аналитически.
- 3 Их сложность зависит от вида целевой функции f , множества Q и может зависеть от размерности x .

Задачи оптимизации. Первые наблюдения.

- 1 В общем случае задачи оптимизации могут не иметь решения. Например, задача $\min_{x \in \mathbb{R}} x$ не имеет решения.
- 2 Задачи оптимизации часто нельзя решить аналитически.
- 3 Их сложность зависит от вида целевой функции f , множества Q и может зависеть от размерности x .

Если же задача оптимизации имеет решение, то на практике её обычно решают, вообще говоря, приближённо. Для этого применяются специальные алгоритмы, которые и называют методами оптимизации.

Методы оптимизации

- Нет смысла искать лучший метод для решения конкретной задачи. Например, лучший метод для решений задачи $\min_{x \in \mathbb{R}^d} \|x\|^2$ сходится за 1 итерацию: этот метод просто всегда выдаёт ответ $x^* = 0$. Очевидно, что для других задач такой метод не пригоден.
- Эффективность метода определяется для класса задач, т.к. обычно численные методы разрабатываются для *приближённого* решения множества однотипных задач.
- Метод разрабатывается для класса задач \implies метод не может иметь с самого начала полной информации о задаче. Вместо этого метод использует модель задачи, например, формулировку задачи, описание функциональных компонент, множества, на котором происходит оптимизация и т.д.

- Предполагается, что численный метод может накапливать специфическую информацию о задаче при помощи некоторого *оракула*. Под оракулом можно понимать некоторое устройство (программу, процедуру), которое отвечает на последовательные вопросы численного метода.

- Предполагается, что численный метод может накапливать специфическую информацию о задаче при помощи некоторого *оракула*. Под оракулом можно понимать некоторое устройство (программу, процедуру), которое отвечает на последовательные вопросы численного метода.

Вопрос: Какого рода вопросы хочется задавать оракулу?

- Предполагается, что численный метод может накапливать специфическую информацию о задаче при помощи некоторого *оракула*. Под оракулом можно понимать некоторое устройство (программу, процедуру), которое отвечает на последовательные вопросы численного метода.

Вопрос: Какого рода вопросы хочется задавать оракулу?

- Предполагается, что численный метод может накапливать специфическую информацию о задаче при помощи некоторого *оракула*. Под оракулом можно понимать некоторое устройство (программу, процедуру), которое отвечает на последовательные вопросы численного метода.

Вопрос: Какого рода вопросы хочется задавать оракулу?

Примеры оракулов

- **Оракул нулевого порядка** в запрашиваемой точке x возвращает значение целевой функции $f(x)$.
- **Оракул первого порядка** в запрашиваемой точке возвращает значение функции $f(x)$ и её градиент в данной точке
$$\nabla f(x) = \left(\frac{\partial f(x)}{\partial x_1}, \dots, \frac{\partial f(x)}{\partial x_n} \right).$$
- **Оракул второго порядка** в запрашиваемой точке возвращает значение и градиент функции $f(x)$, $\nabla f(x)$, а также её гессиан в данной точке $(\nabla^2 f(x))_{ij} = \frac{\partial^2 f(x)}{\partial x_j \partial x_i}.$

Общая итеративная схема метода оптимизации \mathcal{M}

Входные данные: начальная точка x^0 (0 – верхний индекс),
требуемая точность решения задачи $\varepsilon > 0$.

Общая итеративная схема метода оптимизации \mathcal{M}

Входные данные: начальная точка x^0 (0 – верхний индекс),
требуемая точность решения задачи $\varepsilon > 0$.

Настройка. Задать $k = 0$ (счётчик итераций) и $I_{-1} = \emptyset$
(накапливаемая информационная модель решаемой задачи).

Общая итеративная схема метода оптимизации \mathcal{M}

Входные данные: начальная точка x^0 (0 – верхний индекс),
требуемая точность решения задачи $\varepsilon > 0$.

Настройка. Задать $k = 0$ (счётчик итераций) и $I_{-1} = \emptyset$
(накапливаемая информационная модель решаемой задачи).

Основной цикл

- 1 Задать вопрос к оракулу \mathcal{O} в точке x^k .

Общая итеративная схема метода оптимизации \mathcal{M}

Входные данные: начальная точка x^0 (0 – верхний индекс), требуемая точность решения задачи $\varepsilon > 0$.

Настройка. Задать $k = 0$ (счётчик итераций) и $I_{-1} = \emptyset$ (накапливаемая информационная модель решаемой задачи).

Основной цикл

- ① Задать вопрос к оракулу \mathcal{O} в точке x^k .
- ② Пересчитать информационную модель: $I_k = I_{k-1} \cup (x^k, \mathcal{O}(x^k))$.
- ③ Применить правило метода \mathcal{M} для получения новой точки x^{k+1} по модели I_k .

Общая итеративная схема метода оптимизации \mathcal{M}

Входные данные: начальная точка x^0 (0 – верхний индекс), требуемая точность решения задачи $\varepsilon > 0$.

Настройка. Задать $k = 0$ (счётчик итераций) и $I_{-1} = \emptyset$ (накапливаемая информационная модель решаемой задачи).

Основной цикл

- ① Задать вопрос к оракулу \mathcal{O} в точке x^k .
- ② Пересчитать информационную модель: $I_k = I_{k-1} \cup (x^k, \mathcal{O}(x^k))$.
- ③ Применить правило метода \mathcal{M} для получения новой точки x^{k+1} по модели I_k .
- ④ Проверить критерий остановки \mathcal{T}_ε . Если критерий выполнен, то выдать ответ \bar{x} , иначе положить $k := k + 1$ и вернуться на шаг 1.

Примеры итерационных методов. Градиентный спуск

Рассмотрим задачу оптимизации

$$\min_{x \in \mathbb{R}^d} f(x),$$

где функция $f(x)$ дифференцируема. Предположим, что в любой точке мы можем посчитать её градиент.

Примеры итерационных методов. Градиентный спуск

Рассмотрим задачу оптимизации

$$\min_{x \in \mathbb{R}^d} f(x),$$

где функция $f(x)$ дифференцируема. Предположим, что в любой точке мы можем посчитать её градиент.

Алгоритм 1 Градиентный спуск с постоянным размером шага

Вход: размер шага $\gamma > 0$, стартовая точка $x^0 \in \mathbb{R}^d$, количество итераций K

1: **for** $k = 0, 1, \dots, K - 1$ **do**

2: Вычислить $\nabla f(x^k)$

3: $x^{k+1} = x^k - \gamma \nabla f(x^k)$

4: **end for**

Выход: x^K

Примеры итерационных методов. Градиентный спуск

Рассмотрим задачу оптимизации

$$\min_{x \in \mathbb{R}^d} f(x),$$

где функция $f(x)$ дифференцируема. Предположим, что в любой точке мы можем посчитать её градиент.

Алгоритм 1 Градиентный спуск с постоянным размером шага

Вход: размер шага $\gamma > 0$, стартовая точка $x^0 \in \mathbb{R}^d$, количество итераций K

- 1: **for** $k = 0, 1, \dots, K - 1$ **do**
- 2: Вычислить $\nabla f(x^k)$
- 3: $x^{k+1} = x^k - \gamma \nabla f(x^k)$
- 4: **end for**

Выход: x^K

Вопрос: в чем Алгоритм 1 отличается от определения общей итеративной схемы?

Примеры итерационных методов. Градиентный спуск

Рассмотрим задачу оптимизации

$$\min_{x \in \mathbb{R}^d} f(x),$$

где функция $f(x)$ дифференцируема. Предположим, что в любой точке мы можем посчитать её градиент.

Алгоритм 1 Градиентный спуск с постоянным размером шага

Вход: размер шага $\gamma > 0$, стартовая точка $x^0 \in \mathbb{R}^d$, количество итераций K

- 1: **for** $k = 0, 1, \dots, K - 1$ **do**
- 2: Вычислить $\nabla f(x^k)$
- 3: $x^{k+1} = x^k - \gamma \nabla f(x^k)$
- 4: **end for**

Выход: x^K

Вопрос: в чем Алгоритм 1 отличается от определения общей итеративной схемы? В итеративной схеме использовался \mathcal{T}_ϵ .

Критерии останова

- По аргументу: $\|x^k - x^*\| \leq \varepsilon.$

Вопрос: какие проблемы тут видим?

Критерии останова

- По аргументу: $\|x^k - x^*\| \leq \varepsilon$.

Вопрос: какие проблемы тут видим?

- x^* – неизвестно, но можно так:

$$\|x^{k+1} - x^k\| \leq \|x^{k+1} - x^*\| + \|x^k - x^*\|.$$

Тогда если $\|x^{k+1} - x^*\| \leq \|x^k - x^*\| \leq \varepsilon$, следует $\|x^{k+1} - x^k\| \leq 2\varepsilon$ (в обратную сторону, очевидно, неверно). $\|x^{k+1} - x^k\| \leq \varepsilon$ – это скорее практический вариант критерия, который работает, если есть понимание (интуиция), что $\|x^k - x^*\| \rightarrow 0$.

Критерии останова

- По аргументу: $\|x^k - x^*\| \leq \varepsilon.$

Вопрос: какие проблемы тут видим?

- X^* – неизвестно, но можно так:

$$\|x^{k+1} - x^k\| \leq \|x^{k+1} - x^*\| + \|x^k - x^*\|.$$

Тогда если $\|x^{k+1} - x^*\| \leq \|x^k - x^*\| \leq \varepsilon$, следует $\|x^{k+1} - x^k\| \leq 2\varepsilon$ (в обратную сторону, очевидно, неверно). $\|x^{k+1} - x^k\| \leq \varepsilon$ – это скорее практический вариант критерия, который работает, если есть понимание (интуиция), что $\|x^k - x^*\| \rightarrow 0$.

- x^* – не уникально. Тогда можно поменять следующий критерий

Критерии останова

- По аргументу: $\|x^k - x^*\| \leq \varepsilon$.

Вопрос: какие проблемы тут видим?

- x^* – неизвестно, но можно так:

$$\|x^{k+1} - x^k\| \leq \|x^{k+1} - x^*\| + \|x^k - x^*\|.$$

Тогда если $\|x^{k+1} - x^*\| \leq \|x^k - x^*\| \leq \varepsilon$, следует $\|x^{k+1} - x^k\| \leq 2\varepsilon$ (в обратную сторону, очевидно, неверно). $\|x^{k+1} - x^k\| \leq \varepsilon$ – это скорее практический вариант критерия, который работает, если есть понимание (интуиция), что $\|x^k - x^*\| \rightarrow 0$.

- x^* – не уникально. Тогда можно поменять следующий критерий
- По функции: $f(x^k) - f^* \leq \varepsilon$.

Часто f^* известно, например, для $f(x) = \|Ax - b\|^2$. На практике можно использовать $|f(x^k) - f(x^{k+1})|$.

Критерии останова

- По аргументу: $\|x^k - x^*\| \leq \varepsilon$.

Вопрос: какие проблемы тут видим?

- x^* – неизвестно, но можно так:

$$\|x^{k+1} - x^k\| \leq \|x^{k+1} - x^*\| + \|x^k - x^*\|.$$

Тогда если $\|x^{k+1} - x^*\| \leq \|x^k - x^*\| \leq \varepsilon$, следует $\|x^{k+1} - x^k\| \leq 2\varepsilon$ (в обратную сторону, очевидно, неверно). $\|x^{k+1} - x^k\| \leq \varepsilon$ – это скорее практический вариант критерия, который работает, если есть понимание (интуиция), что $\|x^k - x^*\| \rightarrow 0$.

- x^* – не уникально. Тогда можно поменять следующий критерий
- По функции: $f(x^k) - f^* \leq \varepsilon$.

Часто f^* известно, например, для $f(x) = \|Ax - b\|^2$. На практике можно использовать $|f(x^k) - f(x^{k+1})|$.

- По норме градиента: $\|\nabla f(x^k)\| \leq \varepsilon$.

Вопрос: когда такой критерий можно использовать?

Критерии останова

- По аргументу: $\|x^k - x^*\| \leq \varepsilon$.

Вопрос: какие проблемы тут видим?

- x^* – неизвестно, но можно так:

$$\|x^{k+1} - x^k\| \leq \|x^{k+1} - x^*\| + \|x^k - x^*\|.$$

Тогда если $\|x^{k+1} - x^*\| \leq \|x^k - x^*\| \leq \varepsilon$, следует $\|x^{k+1} - x^k\| \leq 2\varepsilon$ (в обратную сторону, очевидно, неверно). $\|x^{k+1} - x^k\| \leq \varepsilon$ – это скорее практический вариант критерия, который работает, если есть понимание (интуиция), что $\|x^k - x^*\| \rightarrow 0$.

- x^* – не уникально. Тогда можно поменять следующий критерий
- По функции: $f(x^k) - f^* \leq \varepsilon$.

Часто f^* известно, например, для $f(x) = \|Ax - b\|^2$. На практике можно использовать $|f(x^k) - f(x^{k+1})|$.

- По норме градиента: $\|\nabla f(x^k)\| \leq \varepsilon$.

Вопрос: когда такой критерий можно использовать? В безусловной оптимизации

Сложность методов оптимизации

- **Аналитическая/Оракульная сложность** — число обращений к оракулу, необходимое для решения задачи с точностью ε .
- **Арифметическая/Временная сложность** — общее число вычислений (включая работу оракула), необходимых для решения задачи с точностью ε .

Сложность задач оптимизации. Класс задач минимизации липшицевых функций

Наблюдение

Множество B_d является ограниченным и замкнутым, т.е. компактом, а из липшицевости функции f следует и её непрерывность, поэтому задача (22) имеет решение, ибо непрерывная на компакте функция достигает своих минимального и максимального значений. Пусть $f^* = \min_{x \in B_d} f(x)$.

- **Класс методов.** Для данной задачи рассмотрим методы нулевого порядка.
- **Цель:** найти $\bar{x} \in B_d$: $f(\bar{x}) - f^* \leq \varepsilon$.

Сложность задач оптимизации. Класс задач минимизации липшицевых функций

Рассмотрим один из самых простых способов решения этой задачи — метод равномерного перебора.

Алгоритм 2 Метод равномерного перебора

Вход: целочисленный параметр перебора $p \geq 1$

- 1: Сформировать $(p + 1)^d$ точек вида $x_{(i_1, \dots, i_d)} = \left(\frac{i_1}{p}, \frac{i_2}{p}, \dots, \frac{i_d}{p} \right)^T$, где $(i_1, \dots, i_d) \in \{0, 1, \dots, p\}^d$
- 2: Среди точек $x_{(i_1, \dots, i_d)}$ найти точку \bar{x} с наименьшим значением целевой функции f .

Выход: $\bar{x}, f(\bar{x})$

Сложность задач оптимизации. Класс задач минимизации липшицевых функций

Теорема 1

Алгоритм 2 с параметром p возвращает такую точку \bar{x} , что

$$f(\bar{x}) - f^* \leq \frac{M}{2p},$$

откуда следует, что методу равномерного перебора нужно в худшем случае

$$\left(\left\lfloor \frac{M}{2\varepsilon} \right\rfloor + 2 \right)^d$$

обращений к оракулу, чтобы гарантировать $f(\bar{x}) - f^* \leq \varepsilon$.

Сложность задач оптимизации. Класс задач минимизации липшицевых функций

Доказательство Теоремы 1

Пусть x^* — решение задачи (точка минимума функции f). Тогда в построенной «сетке» из точек найдётся такая точка $x_{(i_1, \dots, i_d)}$, что $x := x_{(i_1, \dots, i_d)} \leq x^* \leq x_{(i_1+1, \dots, i_d+1)} =: y$, где знак « \leq » применяется покомпонентно.

Сложность задач оптимизации. Класс задач минимизации липшицевых функций

Доказательство Теоремы 1

Пусть x^* — решение задачи (точка минимума функции f). Тогда в построенной «сетке» из точек найдётся такая точка $x_{(i_1, \dots, i_d)}$, что $x := x_{(i_1, \dots, i_d)} \leq x^* \leq x_{(i_1+1, \dots, i_d+1)} =: y$, где знак « \leq » применяется покомпонентно. Во-первых, $y_i - x_i = \frac{1}{p}$ и $x_i^* \in [x_i, y_i]$ для всех $i = 1, \dots, d$.

Сложность задач оптимизации. Класс задач минимизации липшицевых функций

Доказательство Теоремы 1

Пусть x^* — решение задачи (точка минимума функции f). Тогда в построенной «сетке» из точек найдётся такая точка $x_{(i_1, \dots, i_d)}$, что $x := x_{(i_1, \dots, i_d)} \leq x^* \leq x_{(i_1+1, \dots, i_d+1)} =: y$, где знак « \leq » применяется покомпонентно. Во-первых, $y_i - x_i = \frac{1}{p}$ и $x_i^* \in [x_i, y_i]$ для всех $i = 1, \dots, d$. Кроме того, рассмотрим точки \hat{x} и \tilde{x} такие, что $\hat{x} = \frac{x+y}{2}$ и

$$\tilde{x}_i = \begin{cases} y_i, & \text{если } x_i^* \geq \hat{x}_i, \\ x_i, & \text{иначе.} \end{cases}$$

Сложность задач оптимизации. Класс задач минимизации липшицевых функций

Доказательство Теоремы 1 (продолжение)

Заметим, что \tilde{x} принадлежит «сетке» и $|\tilde{x}_i - x_i^*| \leq \frac{1}{2p}$, а значит, $\|\tilde{x} - x^*\|_\infty \leq \frac{1}{2p}$.

Сложность задач оптимизации. Класс задач минимизации липшицевых функций

Доказательство Теоремы 1 (продолжение)

Заметим, что \tilde{x} принадлежит «сетке» и $|\tilde{x}_i - x_i^*| \leq \frac{1}{2p}$, а значит, $\|\tilde{x} - x^*\|_\infty \leq \frac{1}{2p}$. Поскольку $f(\bar{x}) \leq f(\tilde{x})$ (по определению), получаем

Сложность задач оптимизации. Класс задач минимизации липшицевых функций

Доказательство Теоремы 1 (продолжение)

Заметим, что \tilde{x} принадлежит «сетке» и $|\tilde{x}_i - x_i^*| \leq \frac{1}{2p}$, а значит, $\|\tilde{x} - x^*\|_\infty \leq \frac{1}{2p}$. Поскольку $f(\bar{x}) \leq f(\tilde{x})$ (по определению), получаем

$$f(\bar{x}) - f^* \leq f(\tilde{x}) - f^* \leq M\|\tilde{x} - x^*\|_\infty \leq \frac{M}{2p}.$$

Сложность задач оптимизации. Класс задач минимизации липшицевых функций

Доказательство Теоремы 1 (продолжение)

Заметим, что \tilde{x} принадлежит «сетке» и $|\tilde{x}_i - x_i^*| \leq \frac{1}{2p}$, а значит, $\|\tilde{x} - x^*\|_\infty \leq \frac{1}{2p}$. Поскольку $f(\bar{x}) \leq f(\tilde{x})$ (по определению), получаем

$$f(\bar{x}) - f^* \leq f(\tilde{x}) - f^* \leq M \|\tilde{x} - x^*\|_\infty \leq \frac{M}{2p}.$$

Выписанная выше оценка достигается методом равномерного перебора за $(p+1)^d$ обращений к оракулу. Следовательно, чтобы гарантировать $f(\bar{x}) - f^* \leq \varepsilon$, необходимо взять $p = \lfloor \frac{M}{2\varepsilon} \rfloor + 1$, т.е. метод сделает $(\lfloor \frac{M}{2\varepsilon} \rfloor + 2)^d$ обращений к оракулу.

Сложность задач оптимизации. Класс задач минимизации липшицевых функций

Вопрос: хороший результат получили или нет?

Сложность задач оптимизации. Класс задач минимизации липшицевых функций

Вопрос: хороший результат получили или нет?

- Предположим $M = 2$, $d = 13$ И $\varepsilon = 0.01$, то есть размерность задачи сравнительно небольшая и точность решения задачи не слишком высокая.

Сложность задач оптимизации. Класс задач минимизации липшицевых функций

Вопрос: хороший результат получили или нет?

- Предположим $M = 2$, $d = 13$ И $\varepsilon = 0.01$, то есть размерность задачи сравнительно небольшая и точность решения задачи не слишком высокая.
- Необходимое число обращений к оракулу:
$$\left(\left\lfloor \frac{M}{2\varepsilon} \right\rfloor + 2\right)^d = 102^{13} > 10^{26}.$$
- Сложность одного вызова оракула не менее 1, но если потребовать, чтобы он обязательно считал, переданную ему точки, то сложность не менее d операции.

Сложность задач оптимизации. Класс задач минимизации липшицевых функций

Вопрос: хороший результат получили или нет?

- Предположим $M = 2$, $d = 13$ И $\varepsilon = 0.01$, то есть размерность задачи сравнительно небольшая и точность решения задачи не слишком высокая.
- Необходимое число обращений к оракулу:
 $(\lfloor \frac{M}{2\varepsilon} \rfloor + 2)^d = 102^{13} > 10^{26}$.
- Сложность одного вызова оракула не менее 1, но если потребовать, чтобы он обязательно считал, переданную ему точки, то сложность не менее d операции.
- Производительность компьютера: 10^{11} арифметических операций в секунду.
- Общее время: хотя бы 10^{15} секунд, что больше 30 миллионов лет.

Сложность задач оптимизации. Класс задач минимизации липшицевых функций

- **Вопрос:** что мы сейчас получили? верхнюю или нижнюю оценку? что такое верхняя оценка?

Сложность задач оптимизации. Класс задач минимизации липшицевых функций

- **Вопрос:** что мы сейчас получили? верхнюю или нижнюю оценку? что такое верхняя оценка?
- **Верхняя оценка** – гарантии нахождения решения определённым методом из рассматриваемого класса методов (например, методы с оракулом нулевого порядка) для любой задачи из класса (липшицева целевая функция).
- **Нижняя оценка** – гарантия, что существует «плохая» задача из класса, что любой метод из класса методов будет сходиться не лучше утверждает нижняя оценка.
- Возникает вопрос: может мы плохо вывели верхнюю оценку (неидеальный анализ), может ли предложить другой метод из рассматриваемого класса, который будет находить приближённое решение существенно быстрее? На этот вопрос и даст ответ нижняя оценка.

Сложность задач оптимизации. Класс задач минимизации липшицевых функций

Теорема 2

Пусть $\varepsilon < \frac{M}{2}$. Тогда аналитическая сложность описанного класса задач, т.е. аналитическая сложность метода на «худшей» для него задаче из данного класса, составляет по крайней мере

$$\left(\left\lfloor \frac{M}{2\varepsilon} \right\rfloor \right)^d \text{ вызовов оракула.}$$

Сложность задач оптимизации. Класс задач минимизации липшицевых функций

Схема доказательства Теоремы 2

Пусть $p = \lfloor \frac{M}{2\varepsilon} \rfloor$. Доказываем от противного: предположим, что существует такой метод, который решает задачу за $N < (p^d - 1)$ обращений к оракулу, чтобы решить задачу с точностью ε (по функции).

Сложность задач оптимизации. Класс задач минимизации липшицевых функций

Схема доказательства Теоремы 2

Пусть $p = \lfloor \frac{M}{2\varepsilon} \rfloor$. Доказываем от противного: предположим, что существует такой метод, который решает задачу за $N < (p^d - 1)$ обращений к оракулу, чтобы решить задачу с точностью ε (по функции). Построим такую функцию, на которой метод не сможет найти ε -решение, при помощи сопротивляющегося оракула: пусть изначально наша целевая функция $f(x)$ всюду равна 0.

Сложность задач оптимизации. Класс задач минимизации липшицевых функций

Схема доказательства Теоремы 2

Пусть $p = \lfloor \frac{M}{2\varepsilon} \rfloor$. Доказываем от противного: предположим, что существует такой метод, который решает задачу за $N < (p^d - 1)$ обращений к оракулу, чтобы решить задачу с точностью ε (по функции). Построим такую функцию, на которой метод не сможет найти ε -решение, при помощи сопротивляющегося оракула: пусть изначально наша целевая функция $f(x)$ всюду равна 0. Запустим метод, он запросит значение f в N точках, везде получит 0 и выдаст какую-то точку (возможно, отличную от всех предыдущих N , как ответ). В итоге мы в ходе работы алгоритма заглянули в $N + 1 < p^d$ точку.

Сложность задач оптимизации. Класс задач минимизации липшицевых функций

Схема доказательства Теоремы 2

Пусть $p = \lfloor \frac{M}{2\varepsilon} \rfloor$. Доказываем от противного: предположим, что существует такой метод, который решает задачу за $N < (p^d - 1)$ обращений к оракулу, чтобы решить задачу с точностью ε (по функции). Построим такую функцию, на которой метод не сможет найти ε -решение, при помощи сопротивляющегося оракула: пусть изначально наша целевая функция $f(x)$ всюду равна 0. Запустим метод, он запросит значение f в N точках, везде получит 0 и выдаст какую-то точку (возможно, отличную от всех предыдущих N , как ответ). В итоге мы в ходе работы алгоритма заглянули в $N + 1 < p^d$ точку. Тогда по принципу Дирихле найдётся такой «кубик» $B = \{x \mid \hat{x} \preceq x \preceq \hat{x} + \frac{1}{p}e\}$ (где \hat{x} и $\hat{x} + \frac{1}{p}e$ — точки из «сетки» с шагом p , e — вектор из единиц), который не содержит ни одной из $N + 1$ точки (в том числе и выхода метода).

Сложность задач оптимизации. Класс задач минимизации липшицевых функций

Схема доказательства Теоремы 2 (продолжение)

Пусть x^* — это центр «кубика» B , т.е. $x^* = \hat{x} + \frac{1}{2p}e$.

Сложность задач оптимизации. Класс задач минимизации липшицевых функций

Схема доказательства Теоремы 2 (продолжение)

Пусть x^* — это центр «кубика» B , т.е. $x^* = \hat{x} + \frac{1}{2p}e$. Немного модифицируем функцию $\bar{f}(x) = \min\{0, M\|x - x^*\|_\infty - \varepsilon\}$.

Сложность задач оптимизации. Класс задач минимизации липшицевых функций

Схема доказательства Теоремы 2 (продолжение)

Пусть x^* — это центр «кубика» B , т.е. $x^* = \hat{x} + \frac{1}{2\rho}e$. Немного модифицируем функцию $\bar{f}(x) = \min\{0, M\|x - x^*\|_\infty - \varepsilon\}$. Функция $\bar{f}(x)$ липшицева с константой M относительно ℓ_∞ -нормы и принимает своё минимальное значение $-\varepsilon$ в точке x^* .

Сложность задач оптимизации. Класс задач минимизации липшицевых функций

Схема доказательства Теоремы 2 (продолжение)

Пусть x^* — это центр «кубика» B , т.е. $x^* = \hat{x} + \frac{1}{2p}e$. Немного модифицируем функцию $\bar{f}(x) = \min\{0, M\|x - x^*\|_\infty - \varepsilon\}$. Функция $\bar{f}(x)$ липшицева с константой M относительно ℓ_∞ -нормы и принимает своё минимальное значение $-\varepsilon$ в точке x^* . Более того, функция $\bar{f}(x)$ отлична от нуля только внутри куба $B' = \{x \mid \|x - x^*\| \leq \frac{\varepsilon}{M}\}$, который лежит внутри куба B , т.к. $2p \leq \frac{M}{\varepsilon}$.

Сложность задач оптимизации. Класс задач минимизации липшицевых функций

Схема доказательства Теоремы 2 (продолжение)

Пусть x^* — это центр «кубика» B , т.е. $x^* = \hat{x} + \frac{1}{2p}e$. Немного модифицируем функцию $\bar{f}(x) = \min\{0, M\|x - x^*\|_\infty - \varepsilon\}$. Функция $\bar{f}(x)$ липшицева с константой M относительно ℓ_∞ -нормы и принимает своё минимальное значение $-\varepsilon$ в точке x^* . Более того, функция $\bar{f}(x)$ отлична от нуля только внутри куба $B' = \{x \mid \|x - x^*\| \leq \frac{\varepsilon}{M}\}$, который лежит внутри куба B , т.к. $2p \leq \frac{M}{\varepsilon}$. Следовательно, рассмотренный метод на данной функции не может найти ε -решение. Противоречие.

Сложность задач оптимизации. Класс задач минимизации липшицевых функций

Схема доказательства Теоремы 2 (продолжение)

Пусть x^* — это центр «кубика» B , т.е. $x^* = \hat{x} + \frac{1}{2p}e$. Немного модифицируем функцию $\bar{f}(x) = \min\{0, M\|x - x^*\|_\infty - \varepsilon\}$. Функция $\bar{f}(x)$ липшицева с константой M относительно ℓ_∞ -нормы и принимает своё минимальное значение $-\varepsilon$ в точке x^* . Более того, функция $\bar{f}(x)$ отлична от нуля только внутри куба $B' = \{x \mid \|x - x^*\| \leq \frac{\varepsilon}{M}\}$, который лежит внутри куба B , т.к. $2p \leq \frac{M}{\varepsilon}$. Следовательно, рассмотренный метод на данной функции не может найти ε -решение. Противоречие.

Итак, в указанном классе у любого метода оценки на скорость сходимости весьма пессимистичные. Возникает вопрос: какие свойства нужно потребовать от класса оптимизируемых функций, чтобы оценки стали более оптимистичными?

Сложность задач оптимизации. Класс задач минимизации липшицевых функций

Схема доказательства Теоремы 2 (продолжение)

Пусть x^* — это центр «кубика» B , т.е. $x^* = \hat{x} + \frac{1}{2p}e$. Немного модифицируем функцию $\bar{f}(x) = \min\{0, M\|x - x^*\|_\infty - \varepsilon\}$. Функция $\bar{f}(x)$ липшицева с константой M относительно ℓ_∞ -нормы и принимает своё минимальное значение $-\varepsilon$ в точке x^* . Более того, функция $\bar{f}(x)$ отлична от нуля только внутри куба $B' = \{x \mid \|x - x^*\| \leq \frac{\varepsilon}{M}\}$, который лежит внутри куба B , т.к. $2p \leq \frac{M}{\varepsilon}$. Следовательно, рассмотренный метод на данной функции не может найти ε -решение. Противоречие.

Итак, в указанном классе у любого метода оценки на скорость сходимости весьма пессимистичные. Возникает вопрос: какие свойства нужно потребовать от класса оптимизируемых функций, чтобы оценки стали более оптимистичными? Вернемся к этим вопросам на следующей лекции.