

Л1 Градиентный спуск

Рассмотрим задачу безусловной оптимизации

$$\min_{x \in \mathbb{R}^d} f(x), \quad (\text{Л1.1})$$

где функция $f(x)$ дифференцируема.

Алгоритм Л1.1 Градиентный спуск

Вход: стартовая точка $x^0 \in \mathbb{R}^d$, размеры шагов $\{\gamma_k\}_{k=0} > 0$, количество итераций K

1: **for** $k = 0, 1, \dots, K - 1$ **do**


2: $x^{k+1} = x^k - \gamma_k \nabla f(x^k)$

3: **end for**

Выход: x^K

Метод был придуман в середине XIX века Огюстеном Коши [1] для решения систем уравнений $Ax = b$, что эквивалентно решению задачи $\min_{x \in \mathbb{R}^d} \|Ax - b\|_2^2$. Идея метода очень естественна и понятна: градиент показывает направление роста функции, тогда антиградиент — направление убывания. Поэтому давайте пойдем вдоль текущего антиградиента. Сразу же возникает вопрос: а насколько далеко вообще стоит идти по направлению, указанному антиградиентом? Кажется, что не особо далеко, потому что градиент дает только локальную информацию в окрестности текущей точки о функции f , поэтому совсем непонятно, что же происходит вдали от неё.

Пример Л1.1. Рассмотрим градиентный спуск с постоянным шагом $\gamma_k = \gamma$ для простейшей задачи оптимизации $\min_{x \in \mathbb{R}} x^2$. Пусть наш метод стартует из точки $x^0 = 1$. Попробуем различные шаги γ .



1. $\gamma = \frac{1}{10}$: медленная, но монотонная сходимость.
2. $\gamma = \frac{1}{2}$: оптимальный шаг — метод достигает минимума за одну итерацию.
3. $\gamma \approx \frac{1}{1.1}$: наблюдаются колебания между ветвями параболы, но метод сходится.

4. $\gamma = 1$: критический шаг — метод циклично возвращается в исходную точку.

5. $\gamma \approx \frac{1}{0.95}$: метод расходится.

Попробуем построить теорию и доказать сходимость метода градиентного спуска, а также понять допустимые диапазоны шагов γ_k .

П1.1 Градиентный спуск для гладких сильно выпуклых задач

Отметим сразу, что мы не оформляем дальнейшие рассуждения в виде теоремы, так как они приведут к «топорному» результату. Это пример того, что анализ даже самых простых методов может быть выполнен не лучшим образом. Из Теоремы ?? мы знаем, что для сильно выпуклых функций решение x^* уникально. Попытаемся оценить, как меняется расстояние до него. Используя итерацию градиентного спуска, получаем

$$\begin{aligned}\|x^{k+1} - x^*\|_2^2 &= \|x^k - \gamma_k \nabla f(x^k) - x^*\|_2^2 \\ &= \|x^k - x^*\|_2^2 - 2\gamma_k \langle \nabla f(x^k), x^k - x^* \rangle + \gamma_k^2 \|\nabla f(x^k)\|_2^2.\end{aligned}$$

Нужно как-то оценить полученное выражение. Воспользуемся условием оптимальности $\nabla f(x^*) = 0$ (Определение ??) и запишем:

$$\|x^{k+1} - x^*\|_2^2 = \|x^k - x^*\|_2^2 - 2\gamma_k \langle \nabla f(x^k), x^k - x^* \rangle + \gamma_k^2 \|\nabla f(x^k) - \nabla f(x^*)\|_2^2. \quad (\text{П1.2})$$

Для точек x^k и x^* воспользуемся μ -сильной выпуклостью (Определение ??):

$$f^* \geq f(x^k) + \langle \nabla f(x^k), x^* - x^k \rangle + \frac{\mu}{2} \|x^k - x^*\|_2^2$$

и гладкостью (Определение ??):

$$\|\nabla f(x^k) - \nabla f(x^*)\|_2^2 \leq L^2 \|x^k - x^*\|_2^2.$$

Тогда после подстановки неравенств, имеем:

$$\begin{aligned}\|x^{k+1} - x^*\|_2^2 &\leq \|x^k - x^*\|_2^2 + 2\gamma_k \left(-\frac{\mu}{2} \|x^k - x^*\|_2^2 + f^* - f(x^k) \right) \\ &\quad + \gamma_k^2 L^2 \|x^k - x^*\|_2^2 \\ &= (1 - \gamma_k \mu + \gamma_k^2 L^2) \|x^k - x^*\|_2^2 + 2\gamma_k (f^* - f(x^k)).\end{aligned}$$

Оценим нулем последнее слагаемое в силу того, что $f(x^k) \geq f^*$:

$$\|x^{k+1} - x^*\|_2^2 \leq (1 - \gamma_k \mu + \gamma_k^2 L^2) \|x^k - x^*\|_2^2.$$

Хочется, чтобы расстояние до решения уменьшалось, а именно, $(1 - \gamma_k \mu + \gamma_k^2 L^2) < 1$, а лучше вообще найти $\arg\min_{\gamma_k} (1 - \gamma_k \mu + \gamma_k^2 L^2)$. Это несложно — минимизируем одномерную параболу по γ_k и получаем оптимальный шаг: $\gamma_k^* = \frac{\mu}{2L^2}$ и

$$1 - \gamma_k^* \mu + (\gamma_k^*)^2 L^2 = 1 - \frac{\mu^2}{4L^2}.$$

А значит,

$$\|x^{k+1} - x^*\|_2^2 \leq \left(1 - \frac{\mu^2}{4L^2}\right) \|x^k - x^*\|_2^2.$$

Это неравенство выполняется для всех $k = \overline{0, K-1}$. Подставим $k = K-1$:

$$\|x^K - x^*\|_2^2 \leq \left(1 - \frac{\mu^2}{4L^2}\right) \|x^{K-1} - x^*\|_2^2.$$

Теперь продолжим неравенство, подставляя $k = K-2$:

$$\|x^K - x^*\|_2^2 \leq \left(1 - \frac{\mu^2}{4L^2}\right) \left(1 - \frac{\mu^2}{4L^2}\right) \|x^{K-2} - x^*\|_2^2 = \left(1 - \frac{\mu^2}{4L^2}\right)^2 \|x^{K-2} - x^*\|_2^2.$$

И так можно продолжать, вплоть до $k = 0$. Запустим рекурсию:

$$\begin{aligned} \|x^K - x^*\|_2^2 &\leq \left(1 - \frac{\mu^2}{4L^2}\right) \|x^{K-1} - x^*\|_2^2 \leq \left(1 - \frac{\mu^2}{4L^2}\right)^2 \|x^{K-2} - x^*\|_2^2 \\ &\leq \left(1 - \frac{\mu^2}{4L^2}\right)^3 \|x^{K-3} - x^*\|_2^2 \leq \dots \leq \left(1 - \frac{\mu^2}{4L^2}\right)^K \|x^0 - x^*\|_2^2. \end{aligned}$$

Получили линейную сходимость (Определение ??). Попробуем найти оценку на число итераций, необходимых для достижения точности ε по аргументу: $\|x^K - x^*\|_2 \leq \varepsilon$. Для дальнейшего анализа часто применяют неравенство (??)

$$(1 - \alpha)^k \leq \exp(-\alpha k),$$

где $\alpha \in [0, 1]$, $k \in \mathbb{N}$. Его можно получить, записав определение выпуклости $\exp(-x)$ в точке 0:

$$\exp(-x) \geq 1 - x,$$

после чего возвести неравенство в степень k , поскольку обе части неравенства неотрицательны.

Заметим, что $\mu \leq L$ (Теорема ?? и Определение ??), а значит

$$\|x^K - x^*\|_2^2 \leq \left(1 - \frac{\mu^2}{4L^2}\right)^K \|x^0 - x^*\|_2^2 \leq \exp\left(-\frac{\mu^2}{4L^2} \cdot K\right) \|x^0 - x^*\|_2^2.$$

Мы хотим гарантировать, что

$$\|x^K - x^*\|_2^2 \leq \exp\left(-\frac{\mu^2}{4L^2} \cdot K\right) \|x^0 - x^*\|_2^2 \leq \varepsilon^2.$$

Тогда логарифмируем и получаем

$$K \geq \frac{4L^2}{\mu^2} \log\left(\frac{\|x^0 - x^*\|_2^2}{\varepsilon^2}\right).$$

Но этот результат далеко не самый лучший. Анализ можно провести «тоньше».

Теорема Л1.1. Пусть задача безусловной оптимизации (Л1.1) с L -гладкой μ -сильно выпуклой целевой функцией f решается с помощью градиентного спуска (Алгоритм Л1.1). Тогда при $\gamma_k \leq \frac{1}{L}$ справедлива следующая оценка сходимости:

$$\|x^K - x^*\|_2^2 \leq \left(\prod_{k=0}^{K-1} (1 - \mu\gamma_k)\right) \|x^0 - x^*\|_2^2. \quad (\text{Л1.3})$$

Доказательство. Начинаем с применения итерации градиентного спуска и условия оптимальности $\nabla f(x^*) = 0$ (Определение ??):

$$\begin{aligned}\|x^{k+1} - x^*\|_2^2 &= \|x^k - \gamma_k \nabla f(x^k) - x^*\|_2^2 \\ &= \|x^k - x^*\|_2^2 - 2\gamma_k \langle \nabla f(x^k), x^k - x^* \rangle + \gamma_k^2 \|\nabla f(x^k)\|_2^2 \\ &= \|x^k - x^*\|_2^2 + 2\gamma_k \langle \nabla f(x^k), x^* - x^k \rangle + \gamma_k^2 \|\nabla f(x^k) - \nabla f(x^*)\|_2^2.\end{aligned}$$

Для точек x^k и x^* воспользуемся сильной выпуклостью (Определение ??):

$$f^* \geq f(x^k) + \langle \nabla f(x^k), x^* - x^k \rangle + \frac{\mu}{2} \|x^k - x^*\|_2^2$$

и гладкостью (Теорема ??):

$$\frac{1}{2L} \|\nabla f(x^k) - \nabla f(x^*)\|_2^2 \leq f(x^k) - f^* - \langle \nabla f(x^*), x^k - x^* \rangle,$$

в использовании последнего факта и кроется отличие. Тогда после подстановки неравенств, имеем:

$$\begin{aligned}\|x^{k+1} - x^*\|_2^2 &\leq \|x^k - x^*\|_2^2 - 2\gamma_k \left(\frac{\mu}{2} \|x^k - x^*\|_2^2 + f(x^k) - f^* \right) \\ &\quad + \gamma_k^2 \|\nabla f(x^k) - \nabla f(x^*)\|_2^2 \\ &\leq \|x^k - x^*\|_2^2 - 2\gamma_k \left(\frac{\mu}{2} \|x^k - x^*\|_2^2 + f(x^k) - f^* \right) \\ &\quad + 2\gamma_k^2 L (f(x^k) - f^* - \langle \nabla f(x^*), x^k - x^* \rangle) \\ &= (1 - \mu\gamma_k) \|x^k - x^*\|_2^2 + 2\gamma_k(\gamma_k L - 1)(f(x^k) - f^*).\end{aligned}\tag{Л1.4}$$

Воспользуемся тем, что $\gamma_k \leq \frac{1}{L}$, а $f(x^k) \geq f^*$, и оценим сверху нулем второе слагаемое:

$$\|x^{k+1} - x^*\|_2^2 \leq (1 - \mu\gamma_k) \|x^k - x^*\|_2^2.$$

Запустим рекурсию:

$$\begin{aligned}\|x^K - x^*\|_2^2 &\leq (1 - \mu\gamma_{K-1}) \|x^{K-1} - x^*\|_2^2 \\ &\leq (1 - \mu\gamma_{K-1})(1 - \mu\gamma_{K-2}) \|x^{K-2} - x^*\|_2^2 \\ &\leq \dots \leq \left(\prod_{k=0}^{K-1} (1 - \mu\gamma_k) \right) \|x^0 - x^*\|_2^2.\end{aligned}$$

■

Проведем анализ полученной оценки. Исходя из неравенства (Л1.3), можем заключить, что шаг γ_k следует брать максимально допустимым. В условии теоремы было наложено ограничение $\gamma_k \leq \frac{1}{L}$, поэтому, сформулируем утверждение о скорости сходимости при $\gamma_k = \frac{1}{L}$.

Утверждение Л1.1. Пусть задача удовлетворяет условиям Теоремы Л1.1 и выбрано значение шага $\gamma_k = \frac{1}{L}$. Тогда справедлива следующая оценка сходимости:

$$\|x^K - x^*\|_2^2 \leq \left(1 - \frac{\mu}{L}\right)^K \|x^0 - x^*\|_2^2.$$

Более того, чтобы добиться точности ε по аргументу ($\|x^K - x^*\|_2 \leq \varepsilon$), необходимо

$$K = \mathcal{O}\left(\frac{L}{\mu} \log \frac{\|x^0 - x^*\|_2}{\varepsilon}\right) \text{ итераций.}$$

Доказательство. Запишем оценку сходимости из Теоремы Л1.1:

$$\|x^K - x^*\|_2^2 \leq \left(\prod_{k=0}^{K-1} (1 - \mu\gamma_k)\right) \|x^0 - x^*\|_2^2.$$

При $\gamma_k = \frac{1}{L}$ получаем:

$$\|x^K - x^*\|_2^2 \leq \left(1 - \frac{\mu}{L}\right)^K \|x^0 - x^*\|_2^2.$$

Получили линейную сходимость (Определение ??). Найдём оценку на число итераций. Заметим, что $\mu \leq L$ (Теорема ?? и Определение ??), а значит

$$\|x^K - x^*\|_2^2 \leq \left(1 - \frac{\mu}{L}\right)^K \|x^0 - x^*\|_2^2 \leq \exp\left(-\frac{\mu}{L} \cdot K\right) \|x^0 - x^*\|_2^2.$$

Мы хотим гарантировать, что

$$\|x^K - x^*\|_2^2 \leq \exp\left(-\frac{\mu}{L} \cdot K\right) \|x^0 - x^*\|_2^2 \leq \varepsilon^2.$$

Тогда логарифмируем и получаем

$$K \geq \frac{L}{\mu} \log \left(\frac{\|x^0 - x^*\|_2^2}{\varepsilon^2} \right).$$

■

Замечание Л1.1. В дальнейшем будем использовать $\mathcal{O}$ -нотацию для того, чтобы опускать численные константы, так как нас интересует величина, зависящая от параметров задачи. Формально, $f(L, \mu, \varepsilon) \in \mathcal{O}(g(L, \mu, \varepsilon))$, если существует число $C > 0$ такое, что при всех L, μ, ε выполняется

$$f(L, \mu, \varepsilon) \leq C \cdot g(L, \mu, \varepsilon).$$

Однако результат Теоремы Л1.1 можно ещё немного улучшить. Для этого понадобится следующее утверждение.

Утверждение Л1.2. Пусть функция $f: \mathbb{R}^d \rightarrow \mathbb{R}$ является μ -сильно выпуклой и L -гладкой, тогда для любых $x, y \in \mathbb{R}^d$ выполнено следующее неравенство:

$$\langle \nabla f(x) - \nabla f(y), x - y \rangle \geq \frac{\mu L}{\mu + L} \|x - y\|_2^2 + \frac{1}{\mu + L} \|\nabla f(x) - \nabla f(y)\|_2^2.$$

Доказательство. Рассмотрим функцию $\phi(x) = f(x) - \frac{\mu}{2}\|x\|_2^2$. Докажем, что эта функция является выпуклой и $(L - \mu)$ -гладкой. Выпуклость проверим по Определению ??:

$$\begin{aligned}
\phi(y) - \phi(x) - \langle \nabla \phi(x), y - x \rangle &= f(y) - \frac{\mu}{2}\|y\|_2^2 - f(x) + \frac{\mu}{2}\|x\|_2^2 \\
&\quad - \langle \nabla f(x) - \mu x, y - x \rangle \\
&= f(y) - f(x) - \langle \nabla f(x), y - x \rangle \\
&\quad + \frac{\mu}{2}(\|x\|_2^2 - \|y\|_2^2 + 2\langle x, y - x \rangle) \\
&= f(y) - f(x) - \langle \nabla f(x), y - x \rangle - \frac{\mu}{2}\|y - x\|_2^2 \geq 0.
\end{aligned} \tag{Л11.5}$$

Последнее следует в силу сильной выпуклости f (Определение ??). Таким образом показали выпуклость ϕ .

Для нахождения константы гладкости воспользуемся L -гладкостью f и неравенством (??) из Теоремы ??:

$$f(y) - f(x) - \langle \nabla f(x), y - x \rangle \leq \frac{L}{2}\|y - x\|_2^2. \tag{Л11.6}$$

Тогда, подставляя оценку (Л11.6) в цепочку равенств (Л11.5), получаем для ϕ :

$$\begin{aligned}
\phi(y) - \phi(x) - \langle \nabla \phi(x), y - x \rangle &= f(y) - f(x) - \langle \nabla f(x), y - x \rangle - \frac{\mu}{2}\|y - x\|_2^2 \\
&\leq \frac{L - \mu}{2}\|x - y\|_2^2.
\end{aligned}$$

Из этого неравенства по Теореме ?? следует $(L - \mu)$ -гладкость функции ϕ . По той же Теореме ?? для ϕ можно записать неравенство (??):

$$(L - \mu)\langle \nabla \phi(x) - \nabla \phi(y), x - y \rangle \geq \|\nabla \phi(x) - \nabla \phi(y)\|_2^2.$$

Преобразуем обе части неравенства, подставив $\phi(x) = f(x) - \frac{\mu}{2}\|x\|_2^2$. Для левой части получим:

$$\begin{aligned}
(L - \mu)\langle \nabla \phi(x) - \nabla \phi(y), x - y \rangle &= (L - \mu)\langle \nabla f(x) - \mu x - \nabla f(y) + \mu y, x - y \rangle \\
&= (L - \mu)\langle \nabla f(x) - \nabla f(y), x - y \rangle - (L - \mu)\mu\|x - y\|_2^2.
\end{aligned}$$

Теперь для правой части неравенства:

$$\begin{aligned}
\|\nabla \phi(x) - \nabla \phi(y)\|_2^2 &= \|\nabla f(x) - \mu x - \nabla f(y) + \mu y\|_2^2 \\
&= \|\nabla f(x) - \nabla f(y)\|_2^2 - 2\mu\langle \nabla f(x) - \nabla f(y), x - y \rangle + \mu^2\|x - y\|_2^2.
\end{aligned}$$

Подставляем обе части:

$$\begin{aligned}
(L - \mu)\langle \nabla f(x) - \nabla f(y), x - y \rangle - (L - \mu)\mu\|x - y\|_2^2 \\
\geq \|\nabla f(x) - \nabla f(y)\|_2^2 - 2\mu\langle \nabla f(x) - \nabla f(y), x - y \rangle + \mu^2\|x - y\|_2^2.
\end{aligned}$$

После небольшого упрощения:

$$(L + \mu)\langle \nabla f(x) - \nabla f(y), x - y \rangle - L\mu\|x - y\|_2^2 \geq \|\nabla f(x) - \nabla f(y)\|_2^2.$$

Приведём к требуемому виду:

$$\langle \nabla f(x) - \nabla f(y), x - y \rangle \geq \frac{\mu L}{\mu + L}\|x - y\|_2^2 + \frac{1}{\mu + L}\|\nabla f(x) - \nabla f(y)\|_2^2.$$

■

Используя доказанное утверждение, можно получить следующий результат.

Теорема Л1.2. [Теорема 2.1.15. из [4]] Пусть задача безусловной оптимизации (Л1.1) с L -гладкой μ -сильно выпуклой целевой функцией f решается с помощью градиентного спуска (Алгоритм Л1.1). Тогда при $\gamma_k \leq \frac{2}{\mu+L}$ справедлива следующая оценка сходимости:

$$\|x^K - x^*\|_2^2 \leq \left(\prod_{k=0}^{K-1} \left(1 - \frac{2\gamma_k \mu L}{\mu + L} \right) \right) \|x^0 - x^*\|_2^2.$$

Доказательство. Пойдем по уже известному пути (Л1.2):

$$\begin{aligned} \|x^{k+1} - x^*\|_2^2 &= \|x^k - x^*\|_2^2 - 2\gamma_k \langle \nabla f(x^k), x^k - x^* \rangle \\ &\quad + \gamma_k^2 \|\nabla f(x^k) - \nabla f(x^*)\|_2^2. \end{aligned}$$

Вычтем из первого аргумента скалярного произведения $\nabla f(x^*) = 0$:

$$\begin{aligned} \|x^{k+1} - x^*\|_2^2 &= \|x^k - x^*\|_2^2 - 2\gamma_k \langle \nabla f(x^k) - \nabla f(x^*), x^k - x^* \rangle \\ &\quad + \gamma_k^2 \|\nabla f(x^k) - \nabla f(x^*)\|_2^2. \end{aligned}$$

Теперь используем результат Утверждения Л1.2, чтобы оценить скалярное произведение:

$$\begin{aligned} \|x^{k+1} - x^*\|_2^2 &= \|x^k - x^*\|_2^2 - 2\gamma_k \langle \nabla f(x^k) - \nabla f(x^*), x^k - x^* \rangle \\ &\quad + \gamma_k^2 \|\nabla f(x^k) - \nabla f(x^*)\|_2^2 \\ &\leq \|x^k - x^*\|_2^2 - 2\gamma_k \left(\frac{\mu L}{\mu + L} \|x^k - x^*\|_2^2 + \frac{1}{\mu + L} \|\nabla f(x^k) - \nabla f(x^*)\|_2^2 \right) \\ &\quad + \gamma_k^2 \|\nabla f(x^k) - \nabla f(x^*)\|_2^2 \\ &= \left(1 - \frac{2\gamma_k \mu L}{\mu + L} \right) \|x^k - x^*\|_2^2 + \gamma_k \left(\gamma_k - \frac{2}{\mu + L} \right) \|\nabla f(x^k) - \nabla f(x^*)\|_2^2. \end{aligned}$$

Выбрав $\gamma_k \leq \frac{2}{\mu+L}$, имеем

$$\|x^{k+1} - x^*\|_2^2 \leq \left(1 - \frac{2\gamma_k \mu L}{\mu + L} \right) \|x^k - x^*\|_2^2.$$

Запустив рекурсию, получаем

$$\|x^K - x^*\|_2^2 \leq \left(\prod_{k=0}^{K-1} \left(1 - \frac{2\gamma_k \mu L}{\mu + L} \right) \right) \|x^0 - x^*\|_2^2.$$

■

Как и в случае с предыдущей оценкой сходимости с произвольным достаточно малым шагом (Теорема Л1.1), сформулируем утверждение с теоретически максимально допустимым значением шага $\gamma_k = \frac{2}{\mu+L}$.

Утверждение Л1.3. Пусть задача удовлетворяет условиям Теоремы Л1.2 и выбрано значение шага $\gamma_k = \frac{2}{\mu+L}$. Тогда справедлива следующая оценка сходи-

мости:

$$\|x^K - x^*\|_2^2 \leq \left(1 - \frac{4\mu L}{(\mu + L)^2}\right)^K \|x^0 - x^*\|_2^2.$$

Более того, чтобы добиться точности ε по аргументу ($\|x^k - x^*\|_2 \leq \varepsilon$), необходимо

$$K = \mathcal{O}\left(\frac{L}{\mu} \log \frac{\|x^0 - x^*\|_2}{\varepsilon}\right) \text{ итераций.}$$

Доказательство. Доказательство аналогично доказательству Утверждения Л1.1. ■

Сравним результаты Теорем Л1.1 и Л1.2. С точки зрения $\mathcal{O}$ -оценок, результаты одинаковы, но можно сравнить $(1 - \frac{\mu}{L})$ и $(1 - \frac{4\mu L}{(\mu + L)^2})$. Легко заметить, что

$$\left(1 - \frac{4\mu L}{(\mu + L)^2}\right) < \left(1 - \frac{\mu}{L}\right)$$

при $\mu \neq L$, а значит, результаты Теоремы Л1.2 лучше. Однако более классическим является первый результат. Отчасти это из-за того, что оптимальное значение шага для той оценки $\gamma_k = \frac{1}{L}$ не требует от нас знания константы сильной выпуклости. В Примере Л1.1 можно видеть, что лучшая сходимость достигается при $\gamma_k = \gamma = \frac{1}{L} = \frac{2}{\mu + L} = \frac{1}{2}$.


Рассмотрим другой пример.

Пример Л1.2. Возьмём целевую функцию

$$f(x) = x^2 + \sqrt{1 + x^4}, \quad x \in \mathbb{R}.$$

Для нее константа сильной выпуклости $\mu = 2$, гладкости $L = 2 + 2\sqrt{2}$.

Построим график сходимости градиентного спуска при различных шагах из Теорем Л1.1 и Л1.2 для такой задачи, стартовая точка $x^0 \in \mathbb{R}^d$ одинаковая. Видим, что шаг $\frac{2}{L+\mu}$ показывает сходимость быстрее, чем $\frac{1}{L}$.



Л1.2 Градиентный спуск для гладких выпуклых задач

Рассматривается задача (Л1.1) с выпуклой целевой функцией f . Если мы попытаемся оценивать расстояние до решения $\|x^k - x^*\|_2$, то можем столкнуться с проблемой, что решение для выпуклой задачи может быть не единственным. Это иллюстрирует Пример ???. Следовательно, надо строить другие оценки. Одним из решений является построение оценок на сходимость по функции. То есть будем наблюдать за разностью

$$f(x^k) - f^*.$$

Однако встаёт проблема существования конечного решения. В Примере ?? был показан случай, когда минимум $f^* = -\infty$ достигается на бесконечности. Поэтому будем требовать конечности $f^* > -\infty$, чтобы гарантировать сходимость к некоторому существующему минимуму x^* . Здесь и далее в выпуклом случае под x^* будем понимать некоторую (необязательно единственную, но существующую) точку глобального минимума.

Докажем сперва вспомогательное утверждение о том, что значение функции убывает от итерации к итерации.

Утверждение Л1.4. Пусть задача безусловной оптимизации (Л1.1) с L -гладкой, выпуклой целевой функцией f решается с помощью градиентного спуска (Алгоритм Л1.1). Тогда при $\gamma_k \in (0, \frac{2}{L})$ справедливо, что $f(x^{k+1}) \leq f(x^k)$.

Доказательство. Воспользуемся L -гладкостью (Теорема ??):

$$f(x^{k+1}) \leq f(x^k) + \langle \nabla f(x^k), x^{k+1} - x^k \rangle + \frac{L}{2} \|x^{k+1} - x^k\|_2^2.$$

Подставим итерационный шаг градиентного спуска:

$$\begin{aligned} f(x^{k+1}) &\leq f(x^k) - \gamma_k \|\nabla f(x^k)\|_2^2 + \frac{L\gamma_k^2}{2} \|\nabla f(x^k)\|_2^2 \\ &= f(x^k) - \gamma_k \left(1 - \frac{L\gamma_k}{2}\right) \|\nabla f(x^k)\|_2^2. \end{aligned} \tag{Л1.7}$$

Если $\gamma_k \in (0, \frac{2}{L})$, то $f(x^{k+1}) \leq f(x^k)$. ■

Это предложение не просто является вспомогательным фактом, оно отражает и физику градиентного спуска. Шаг метода подбирается исходя из верхней ограничивающей квадратичной функции/параболы, возникающей из-за гладкости. Как и в Примере Л1.1, нам нельзя делать большие шаги, иначе мы перескочим на противоположную ветвь параболы относительно оптимума и можем оказаться выше той точки, где находились до этого. Поэтому и подбирается шаг «осторожно», исходя из худшего варианта скорости/резкости роста функции (верхней оценки). При этом можно заметить, что если мы выбираем $\gamma_k = \frac{1}{L}$, то мы минимизируем выражение (Л1.7):

$$f(x^k) - \gamma_k \left(1 - \frac{L\gamma_k}{2}\right) \|\nabla f(x^k)\|_2^2,$$

то есть каждый раз мы минимизируем локальную верхнюю ограничивающую параболу на поведение нашей функции (Рисунок Л1.1).

Теорема Л1.3. Пусть задача безусловной оптимизации (Л1.1) с L -гладкой выпуклой целевой функцией f решается с помощью градиентного спуска (Алго-




Рис. Л1.1: Иллюстрация шага градиентного спуска с оптимальным $\gamma_k = \frac{1}{L}$.

ритм Л1.1). Тогда при $\gamma_k \leq \frac{1}{2L}$ справедлива следующая оценка сходимости:

$$f(x^K) - f^* \leq \frac{\|x^0 - x^*\|_2^2}{\sum_{k=0}^{K-1} \gamma_k}.$$

Доказательство. Начнем доказательство с оценки (Л1.4) с $\mu = 0$:

$$\|x^{k+1} - x^*\|_2^2 \leq \|x^k - x^*\|_2^2 + 2\gamma_k(\gamma_k L - 1)(f(x^k) - f^*).$$

Учтем, что $\gamma_k L - 1 \leq -\frac{1}{2}$ из-за ограничения на размер шага $\gamma_k \leq \frac{1}{2L}$:

$$\begin{aligned} \|x^{k+1} - x^*\|_2^2 &\leq \|x^k - x^*\|_2^2 + 2\gamma_k(\gamma_k L - 1)(f(x^k) - f^*) \\ &\leq \|x^k - x^*\|_2^2 - \gamma_k(f(x^k) - f^*). \end{aligned}$$

Перетасуем неравенство:

$$\gamma_k(f(x^k) - f^*) \leq \|x^k - x^*\|_2^2 - \|x^{k+1} - x^*\|_2^2.$$

Суммируя по всем итерациям от 0 до $K - 1$:

$$\begin{aligned} \sum_{k=0}^{K-1} \gamma_k(f(x^k) - f^*) &\leq \sum_{k=0}^{K-1} (\|x^k - x^*\|_2^2 - \|x^{k+1} - x^*\|_2^2) \\ &= \|x^0 - x^*\|_2^2 - \|x^K - x^*\|_2^2 \leq \|x^0 - x^*\|_2^2. \end{aligned}$$

Воспользуемся Утверждением Л1.4 и заметим, что $f(x^K) \leq f(x^k)$, $k = \overline{0, K}$:

$$(f(x^K) - f^*) \sum_{k=0}^{K-1} \gamma_k \leq \|x^0 - x^*\|_2^2.$$

Откуда получаем, что

$$f(x^K) - f^* \leq \frac{\|x^0 - x^*\|_2^2}{\sum_{k=0}^{K-1} \gamma_k}.$$

■

Утверждение Л1.5. Пусть задача удовлетворяет условиям Теоремы Л1.3 и выбрано значение шага $\gamma_k = \frac{1}{2L}$. Тогда справедлива следующая оценка сходимости:

$$f(x^K) - f^* \leq \frac{2L\|x^0 - x^*\|_2^2}{K}.$$

Более того, чтобы добиться точности ε по функции ($f(x^K) - f^* \leq \varepsilon$), необходимо

$$K = \mathcal{O}\left(\frac{L\|x^0 - x^*\|_2^2}{\varepsilon}\right) \text{ итераций.}$$

Доказательство. Начнем с оценки из Теоремы Л1.3:

$$f(x^K) - f^* \leq \frac{\|x^0 - x^*\|_2^2}{\sum_{k=0}^{K-1} \gamma_k}.$$

Подставим фиксированный шаг $\gamma_k = \frac{1}{2L}$, получим требуемое:

$$f(x^K) - f^* \leq \frac{\|x^0 - x^*\|_2^2}{\sum_{k=0}^{K-1} \gamma_k} = \frac{2L\|x^0 - x^*\|_2^2}{K}.$$

Это сублинейная сходимость (Определение ??). Чтобы получить оценку на число итераций, отметим, что мы хотим гарантировать:

$$f(x^K) - f^* \leq \frac{2L\|x^0 - x^*\|_2^2}{K} \leq \varepsilon.$$

Тогда получаем

$$K \geq \frac{2L\|x^0 - x^*\|_2^2}{\varepsilon}.$$

■

Как и в сильно выпуклом случае, данный анализ можно немного улучшить.

Теорема Л1.4. Пусть задача безусловной оптимизации (Л1.1) с L -гладкой выпуклой целевой функцией f решается с помощью градиентного спуска (Алго-

ритм ЛП1.1). Тогда при $\gamma_k \in [0, \frac{1}{L}]$ справедлива следующая оценка сходимости:

$$f(x^K) - f(x^*) \leq \frac{\|x^0 - x^*\|_2^2}{2 \sum_{k=0}^{K-1} \gamma_k}.$$

Доказательство. Начнём уже привычным образом:

$$\begin{aligned} \|x^{k+1} - x^*\|_2^2 &= \|x^k - \gamma_k \nabla f(x^k) - x^*\|_2^2 \\ &= \|x^k - x^*\|_2^2 - 2\gamma_k \langle \nabla f(x^k), x^k - x^* \rangle + \gamma_k^2 \|\nabla f(x^k)\|_2^2. \end{aligned}$$

Воспользуемся выпуклостью: $f(x^*) \geq f(x^k) + \langle \nabla f(x^k), x^* - x^k \rangle$ (Определение ??):

$$\|x^{k+1} - x^*\|_2^2 \leq \|x^k - x^*\|_2^2 - 2\gamma_k (f(x^k) - f^*) + \gamma_k^2 \|\nabla f(x^k)\|_2^2. \quad (\text{ЛП1.8})$$

Далее применим результат (ЛП1.7), а именно оценим $\|\nabla f(x^k)\|_2^2$:

$$\|\nabla f(x^k)\|_2^2 \leq \frac{2}{\gamma_k(2 - L\gamma_k)} (f(x^k) - f(x^{k+1})).$$

Здесь учитывается, что $\gamma_k \in (0, \frac{2}{L})$. Объединяя два предыдущих выражения, получаем

$$\|x^{k+1} - x^*\|_2^2 \leq \|x^k - x^*\|_2^2 - 2\gamma_k (f(x^k) - f^*) + \frac{2\gamma_k}{2 - L\gamma_k} (f(x^k) - f(x^{k+1})).$$

Продолжим цепочку неравенств, приняв во внимание $f^* \leq f(x^{k+1}) \leq f(x^k)$ (Утверждение ЛП1.4):

$$\begin{aligned} \|x^{k+1} - x^*\|_2^2 &\leq \|x^k - x^*\|_2^2 - 2\gamma_k (f(x^k) - f^*) + \frac{2\gamma_k}{2 - L\gamma_k} (f(x^k) - f(x^{k+1})) \\ &= \|x^k - x^*\|_2^2 - 2\gamma_k \left(1 - \frac{1}{2 - L\gamma_k}\right) f(x^k) - \frac{2\gamma_k}{2 - L\gamma_k} f(x^{k+1}) + 2\gamma_k f^* \\ &\leq \|x^k - x^*\|_2^2 - 2\gamma_k \left(1 - \frac{1}{2 - L\gamma_k}\right) f(x^{k+1}) - \frac{2\gamma_k}{2 - L\gamma_k} f(x^{k+1}) + 2\gamma_k f^* \\ &= \|x^k - x^*\|_2^2 - 2\gamma_k (f(x^{k+1}) - f^*). \end{aligned}$$

После небольшой перестановки:

$$2\gamma_k (f(x^{k+1}) - f^*) \leq \|x^k - x^*\|_2^2 - \|x^{k+1} - x^*\|_2^2.$$

Суммируем по всем k от 0 до $K-1$, имеем:

$$\begin{aligned} 2 \sum_{k=0}^{K-1} \gamma_k (f(x^{k+1}) - f^*) &\leq \sum_{k=0}^{K-1} (\|x^k - x^*\|_2^2 - \|x^{k+1} - x^*\|_2^2) \\ &= \|x^0 - x^*\|_2^2 - \|x^K - x^*\|_2^2 \leq \|x^0 - x^*\|_2^2. \end{aligned}$$

Воспользуемся Утверждением ЛП1.4:

$$2(f(x^K) - f^*) \sum_{k=0}^{K-1} \gamma_k \leq \|x^0 - x^*\|_2^2.$$

Откуда получаем, что

$$f(x^K) - f^* \leq \frac{\|x^0 - x^*\|_2^2}{2 \sum_{k=0}^{K-1} \gamma_k}.$$

■

Подберем оптимальное значение шага. Как видно из оценки, шаг стоит выбирать максимальным из возможных. Сформулируем отдельное утверждение для $\gamma_k = \frac{1}{L}$.

Утверждение Л1.6. Пусть задача удовлетворяет условиям Теоремы Л1.4 и выбрано значение шага $\gamma_k = \frac{1}{L}$. Тогда справедлива следующая оценка сходимости:

$$f(x^K) - f^* \leq \frac{L\|x^0 - x^*\|_2^2}{2K}.$$

Более того, чтобы добиться точности ε по функции ($f(x^K) - f^* \leq \varepsilon$), необходимо

$$K = \mathcal{O}\left(\frac{L\|x^0 - x^*\|_2^2}{\varepsilon}\right) \text{ итераций.}$$

Доказательство. Доказательство аналогично доказательству Утверждения Л1.5. ■

Сравним результаты Теорем Л1.3 и Л1.4. С точки зрения $\mathcal{O}$ -оценок, результаты одинаковы, но численный фактор в Теореме Л1.4 лучше.

Л1.3 Градиентный спуск для гладких невыпуклых задач

Теорема Л1.5. Пусть задача безусловной оптимизации (Л1.1) с L -гладкой целевой функцией f решается с помощью градиентного спуска (Алгоритм Л1.1). Тогда при $\gamma_k = \frac{1}{L}$ справедлива следующая оценка сходимости:

$$\|\nabla f(\hat{x}^K)\|_2^2 \leq \frac{2L(f(x^0) - f^*)}{K},$$

где $\hat{x}^K$ — специально выбранная точка из $\{x^k\}$. Более того, чтобы добиться точности ε по норме градиента ($\|\nabla f(x^K)\|_2 \leq \varepsilon$), необходимо

$$K = \mathcal{O}\left(\frac{2L(f(x^0) - f^*)}{\varepsilon^2}\right) \text{ итераций.}$$

Здесь $f^* > -\infty$ — глобальный минимум функции.

В данной теореме есть сходимость только к стационарной точке (для невыпуклых функций нет гарантий, что это экстремум), и предполагается существование конечного глобального минимума f^* .

Доказательство. Воспользуемся L -гладкостью (Теорема ??):

$$f(x^{k+1}) \leq f(x^k) + \langle \nabla f(x^k), x^{k+1} - x^k \rangle + \frac{L}{2} \|x^{k+1} - x^k\|_2^2.$$

Подставим итерационный шаг градиентного спуска:

$$\begin{aligned} f(x^{k+1}) &\leq f(x^k) - \gamma_k \|\nabla f(x^k)\|_2^2 + \frac{L\gamma_k^2}{2} \|\nabla f(x^k)\|_2^2 \\ &\leq f(x^k) - \gamma_k \left(1 - \frac{L\gamma_k}{2}\right) \|\nabla f(x^k)\|_2^2. \end{aligned}$$

Возьмем $\gamma_k = \frac{1}{L}$. Тогда

$$f(x^{k+1}) \leq f(x^k) - \frac{1}{2L} \|\nabla f(x^k)\|_2^2,$$

или после небольших перестановок:

$$\|\nabla f(x^k)\|_2^2 \leq 2L(f(x^k) - f(x^{k+1})).$$

Суммируя по всем итерациям от 0 до $K-1$, получаем:

$$\sum_{k=0}^{K-1} \|\nabla f(x^k)\|_2^2 \leq 2L(f(x^0) - f(x^K)) \leq 2L(f(x^0) - f^*).$$

Здесь мы воспользовались существованием глобального минимума f^* . Усредним по K :

$$\frac{1}{K} \sum_{k=0}^{K-1} \|\nabla f(x^k)\|_2^2 \leq \frac{2L(f(x^0) - f^*)}{K}.$$

Из левой части непонятно, для какой точки мы получили гарантии сходимости. С такой мы проблемой еще не сталкивались, есть несколько способов ее решить:

- Равномерный случайный выбор $\hat{x}^K$ из $x^0, \dots, x^{K-1}$:

$$\mathbb{E} \left[\|\nabla f(\hat{x}^K)\|_2^2 \right] = \frac{1}{K} \sum_{k=0}^{K-1} \|\nabla f(x^k)\|_2^2 \leq \frac{2L(f(x^0) - f^*)}{K};$$

- Выбор точки с минимальным по норме градиентом $\hat{x}^K = \operatorname{argmin}_{k \in \{0, K-1\}} \|\nabla f(x^k)\|_2^2$:

$$\|\nabla f(\hat{x}^K)\|_2^2 = \min_{k \in \{0, K-1\}} \|\nabla f(x^k)\|_2^2 \leq \frac{1}{K} \sum_{k=0}^{K-1} \|\nabla f(x^k)\|_2^2 \leq \frac{2L(f(x^0) - f^*)}{K}.$$

В любом случае получаем сублинейную сходимость (Определение ??). Чтобы получить оценку на число итераций, потребуем

$$\|\nabla f(\hat{x}^K)\|_2^2 \leq \frac{2L(f(x^0) - f^*)}{K} \leq \varepsilon^2.$$

Тогда получаем

$$K \geq \frac{2L(f(x^0) - f^*)}{\varepsilon^2}.$$

■

Л1.4 Выбор шага градиентного спуска

До этого момента мы доказывали сходимость градиентного спуска для L -гладких функций при достаточно малом шаге γ_k , а затем формулировали утверждения, в которых фиксировали максимально допустимый шаг. Однако в реальных задачах мы не всегда знаем, как подбирать шаг. Во-первых, это может происходить, поскольку нам может не быть известно, является ли функция L -гладкой, но это не означает, что градиентный спуск не будет работать. Во-вторых, нам может быть неизвестна константа липшицевости градиента L , от которой зависит теоретическое значение оптимального размера шага. Начнем с метода, который опирается на L -гладкость функции.

Л1.4.1 Линейный поиск значения L

Обратимся к результатам Утверждения Л1.4. В ходе доказательства мы получили оценку (Л1.7) на значение функции f на следующей итерации:

$$f(x^{k+1}) \leq f(x^k) + \underbrace{\left(\frac{L\gamma^2}{2} - \gamma\right)}_{\rightarrow \min} \|\nabla f(x^k)\|_2^2 = \left[\gamma = \frac{1}{L}\right] = f(x^k) - \frac{1}{2L} \|\nabla f(x^k)\|_2^2.$$

Из оценки выше сразу же появляется идея для поиска L и шага $\frac{1}{L}$: увеличиваем L в ρ раз, пока условие выше не начинает выполняться. Такого рода подбор называется линейным поиском. Полученную идею можно встроить в метод градиентного спуска (Алгоритм Л1.1), добавив поиск L на каждой итерации.

Алгоритм Л1.2 Градиентный спуск с линейным поиском L

Вход: стартовая точка $x^0 \in \mathbb{R}^d$, начальное значение $L_0 > 0$, параметр $\rho > 1$, число итераций K

```
1: for  $k = 0, 1, \dots, K - 1$  do
2:    $L_{k+1} = \frac{1}{\rho} \cdot L_k$ 
3:    $x^{k+1} = x^k - \frac{1}{L_{k+1}} \nabla f(x^k)$ 
4:   while  $f(x^{k+1}) > f(x^k) - \frac{1}{2L_{k+1}} \|\nabla f(x^k)\|_2^2$  do
5:      $L_{k+1} = \rho \cdot L_{k+1}$ 
6:      $x^{k+1} = x^k - \frac{1}{L_{k+1}} \nabla f(x^k)$ 
7:   end while
8: end for
Выход:  $x^K$ 
```

В процедуру поиска L добавлена строка 2 с уменьшением L , чтобы на каждой итерации пытаться увеличить шаг для лучшей сходимости.

Замечание Л1.2. При использовании линейного поиска L (Алгоритм Л1.2) к итоговой оракульной и итерационной сложности метода добавляется лишь логарифмическое слагаемое.

Замечание Л1.3. Для μ -сильно выпуклых L -гладких функций можно построить критерий выбора шага, зависящий одновременно от μ и от L , но поиск пары (μ, L) становится двумерным и несколько усложняет процедуру. При этом при выборе $\gamma_k = \frac{1}{L}$ линейный характер сходимости сохраняется, хотя может наблюдаться потеря в эффективной константе сходимости.

Л1.4.2 Степенной шаг

В качестве простой альтернативы можно использовать убывающий с номером итерации шаг:

$$\gamma_k := \frac{\gamma}{\delta + (ak + b)^p}, \quad \gamma, \delta, a, b, p > 0.$$

Наиболее часто применяются на практике $\gamma_k = \frac{1}{k+1}$ и $\gamma_k = \frac{1}{\sqrt{k+1}}$.

Л1.4.3 Наискорейший спуск

Итерация градиентного спуска выглядит следующим образом:

$$x^{k+1} = x^k - \gamma_k \nabla f(x^k).$$

Посмотрим на значение целевой функции после сделанного шага как на функцию от одного аргумента γ_k :

$$\phi(\gamma_k) := f(x^k - \gamma_k \nabla f(x^k)). \quad (\text{Л1.9})$$

Поскольку стоит задача минимизации f , то будем выбирать шаг γ_k так, чтобы минимизировать значение функции $\phi(\gamma_k)$:

$$\gamma_k^* = \operatorname{argmin}_{\gamma_k > 0} \phi(\gamma_k) = \operatorname{argmin}_{\gamma_k > 0} f(x^k - \gamma_k \nabla f(x^k)).$$

Такой выбор шага называется *наискорейшим спуском*. Получим важное свойство шага, выпишем необходимое условие оптимума:

$$\begin{aligned} \phi'(\gamma_k^*) &= \left. \frac{\partial f(x^k - \gamma_k \nabla f(x^k))}{\partial \gamma_k} \right|_{\gamma_k = \gamma_k^*} = -\langle \nabla f(x^k - \gamma_k^* \nabla f(x^k)), \nabla f(x^k) \rangle \\ &= -\langle \nabla f(x^{k+1}), \nabla f(x^k) \rangle = 0. \end{aligned}$$

Итак, свойство заключается в следующем: градиент в точке, куда мы шагаем, ортогонален направлению, вдоль которого мы шагаем. Действительно, если бы это было не так, то можно было бы сделать шаг в направлении градиента, чтобы уменьшить значение функции, что противоречит определению шага наискорейшего спуска. Рисунок Л1.2 иллюстрирует это свойство. В качестве целевой функции взята квадратичная функция на $\mathbb{R}^2$, эллипсами показаны линии уровня этой функции. Градиенты в каждой точке направлены ортогонально линии уровня, проходящей через эту точку.

Замечание Л1.4. Если функция f — сильно выпуклая, то её одномерное сужение вдоль направления градиента $\phi(\gamma_k) = f(x^k - \gamma_k \nabla f(x^k))$ в точке $x^k \neq x^*$ — также сильно выпуклая функция.

Оптимальное значение шага γ_k можно находить с помощью методов одномерной оптимизации. Эти методы используют лишь значения функции и не требуют дополнительных вычислений градиента, что делает их особенно эффективными, когда вычисление функции существенно дешевле вычисления градиента. На практике часто бывает достаточно приближённого значения γ_k^* . При этом методы одномерной оптимизации не предъявляют требований ни к липшицевости, ни даже к выпуклости минимизируемой функции скалярного аргумента — достаточно, чтобы функция ϕ была унимодальной на рассматриваемом отрезке.




Рис. Л1.2: Наискорейший градиентный спуск для квадратичной задачи. Эллипсы соответствуют уровням функции. Черным показано направление градиента, пунктиром — продолжение направления градиента.

Определение Л1.1. Одномерная функция $\phi : [a, b] \rightarrow \mathbb{R}$ называется *унимодальной* на $[a, b]$, если существует $c^* \in [a, b]$ такое, что:

1. Для произвольных $x, y \in [a, c^*]$, таких что $x < y$, выполнено $\phi(x) > \phi(y)$;
2. Для произвольных $x, y \in [c^*, b]$, таких что $x < y$, выполнено $\phi(x) < \phi(y)$.

Замечание Л1.5. Если функция f является сильно выпуклой, то полученная в точке $x^k \neq x^*$ функция ϕ (Уравнение (Л1.9)) будет унимодальной.

Первым методом для поиска минимума унимодальных функций будет метод дихотомии. Дополнительно предположим, что нам известен отрезок $[a_0, b_0]$, на котором находится оптимум ϕ . В случае с градиентным спуском, это может быть отрезок $[0, \frac{2}{L}]$, если нам известна константа гладкости, либо $[0, b]$, где b взято достаточно большим, если L нам неизвестна. Будем искать $\gamma^* = \operatorname{argmin}_{\gamma \in [a, b]} \phi(\gamma)$.

Алгоритм Л1.3 Вычисление γ_k с помощью метода дихотомии

Вход: отрезок поиска $[a_0, b_0]$, количество итераций K

```
1: for  $k = 0, \dots, K - 1$  do
2:    $\gamma_k = \frac{a_k + b_k}{2}$ 
3:    $\delta_k = \frac{a_k - b_k}{4}$ 
4:    $x_k = \gamma_k - \delta_k$ 
5:    $y_k = \gamma_k + \delta_k$ 
6:   if  $\phi(\gamma_k) \leq \min\{\phi(x_k), \phi(y_k)\}$  then
7:      $a_{k+1} = x_k$ 
8:      $b_{k+1} = y_k$ 
9:   else if  $\phi(x_k) < \phi(\gamma_k)$  then
10:     $a_{k+1} = a_k$ 
11:     $b_{k+1} = \gamma_k$ 
12:   else
13:     $a_{k+1} = \gamma_k$ 
14:     $b_{k+1} = b_k$ 
15:   end if
16: end for
Выход:  $\gamma_K = \frac{a_K + b_K}{2}$ 
```

Упражнение Л1.1. Докажите корректность метода дихотомии (Алгоритм Л1.3) для унимодальных функций и выведите следующую оценку сходимости метода по аргументу:

$$\left| \gamma^K - \gamma^* \right| \leq \left(\frac{1}{2} \right)^K \frac{b_0 - a_0}{2}.$$

Другой метод для поиска минимума унимодальной функции — метод золотого сечения. Постановка задачи такая же: ищем $\gamma^* = \operatorname{argmin}_{\gamma \in [a, b]} \phi(\gamma)$. Отличие от метода дихотомии заключается в том, в каких точках мы смотрим значения функции.

Алгоритм Л1.4 Вычисление γ_k с помощью золотого сечения

Вход: отрезок поиска $[a_0, b_0]$, число итераций K

```
1:  $\varphi = \frac{\sqrt{5}-1}{2}$ 
2:  $x_0 = b_0 - \varphi(b_0 - a_0)$ 
3:  $y_0 = a_0 + \varphi(b_0 - a_0)$ 
4: for  $k = 0, \dots, K - 1$  do
5:   if  $\phi(x_k) < \phi(y_k)$  then
6:      $a_{k+1} = a_k$ 
7:      $b_{k+1} = y_k$ 
8:      $y_{k+1} = x_k$ 
9:      $x_{k+1} = b_{k+1} - \varphi(b_{k+1} - a_{k+1})$ 
10:  else
11:     $a_{k+1} = x_k$ 
12:     $b_{k+1} = b_k$ 
13:     $x_{k+1} = y_k$ 
14:     $y_{k+1} = a_{k+1} + \varphi(b_{k+1} - a_{k+1})$ 
15:  end if
16: end for
Выход:  $\gamma_k = \frac{a_k + b_k}{2}$ 
```

Разбиение с помощью золотого сечения позволяет нам переиспользовать точки с преды-

дущей итерации: это заметно по строкам 7 и 11 алгоритма. Это приводит к уменьшению количества обращений к функции.

Упражнение Л1.2. Докажите корректность метода золотого сечения (Алгоритм Л1.4) для унимодальных функций и выведите оценку сложности метода по аргументу:

$$|\gamma^K - \gamma^*| \leq \left(\frac{\sqrt{5} - 1}{2} \right)^K \frac{b_0 - a_0}{2}.$$

Упражнение Л1.3. Сравните теорию методов дихотомии и золотого сечения. Какой из них быстрее сходится с точки зрения количества итераций? А с точки зрения обращений к функции?

Л1.4.4 Шаг Поляка–Шора

Рассмотрим другой подход к выбору шага, основанный на минимизации верхней оценки на расстояние до решения, полученной ранее. В ходе доказательства Теоремы Л1.4 о сходимости градиентного спуска для гладких выпуклых функций мы получили неравенство (Л1.8):

$$\|x^{k+1} - x^*\|_2^2 \leq \|x^k - x^*\|_2^2 - 2\gamma_k(f(x^k) - f^*) + \gamma_k^2 \|\nabla f(x^k)\|_2^2.$$

Правая часть неравенства является квадратичной функцией относительно шага γ_k . Попробуем выбрать γ_k так, чтобы минимизировать эту верхнюю оценку. Для этого найдем производную по γ_k и приравняем ее к нулю:

$$-2(f(x^k) - f^*) + 2\gamma_k^* \|\nabla f(x^k)\|_2^2 = 0.$$

Отсюда получаем оптимальное значение шага, минимизирующее данную оценку:

$$\gamma_k^* = \frac{f(x^k) - f^*}{\|\nabla f(x^k)\|_2^2}.$$

Этот выбор шага известен как *шаг Поляка–Шора* (Параграф 5.3 из [3]). В общем виде шаг Поляка–Шора записывается с параметром $\alpha > 0$:

$$\gamma_k^* := \frac{f(x^k) - f^*}{\alpha \|\nabla f(x^k)\|_2^2}.$$

Значение функции в оптимуме часто неизвестно, поэтому в формуле вместо f^* используют некоторую нижнюю оценку. Например, для задачи наименьших квадратов целевая функция неотрицательна $f(x) = \|Ax - b\|_2^2 \geq 0$. При использовании оценки параметр α позволяет корректировать шаг в зависимости от точности оценки минимума.

Л1.4.5 Стратегия бэктрекинга для подбора размера шага

Введем в рассмотрение $\phi(\gamma_k) = f(x^k + \gamma_k h^k)$, где h^k — произвольное направление, также рассмотрим некоторые константы β_1, β_2 , удовлетворяющие условию $0 < \beta_1 < \beta_2 < 1$ (обычно $0 < \beta_1 < 0.3, 0.9 < \beta_2 < 1$). Сформулируем несколько эвристик, которые будут полезными при выборе размера шага:

- **Условие достаточного убывания** гарантирует, что функция в точке x^{k+1} не превосходит линейной аппроксимации с коэффициентом наклона β_1 :

$$f(x^{k+1}) \leq f(x^k) + \beta_1 \gamma_k \langle \nabla f(x^k), h^k \rangle,$$

что эквивалентно

$$\phi(\gamma_k) \leq \phi(0) + \beta_1 \gamma_k \phi'(0).$$

Это условие возникает из первого порядка разложения функции вдоль направления h^k и требует, чтобы новое значение оказалось ниже касательной с запасом, обеспечивая контролируемое убывание функции и гарантируя конечность процедуры подбора шага.

- **Условие существенного убывания** гарантирует, что функция в точке x^{k+1} не меньше линейной аппроксимации с коэффициентом наклона β_2 :

$$f(x^{k+1}) \geq f(x^k) + \beta_2 \gamma_k \langle \nabla f(x^k), h^k \rangle,$$

или в другой записи

$$\phi(\gamma_k) \geq \phi(0) + \beta_2 \gamma_k \phi'(0).$$

Данное условие добавляет нижнюю границу на допустимое уменьшение функции, отсекая слишком малые шаги, при которых уменьшение происходит чересчур медленно и сходимость ухудшается.

- **Условие кривизны** гарантирует, что угол наклона касательной в точке x^{k+1} не меньше, чем угол наклона касательной в точке x^k , умноженный на β_2 :

$$\langle \nabla f(x^{k+1}), h^k \rangle \geq \beta_2 \langle \nabla f(x^k), h^k \rangle,$$

что можно также записать как:

$$\phi'(\gamma_k) \geq \beta_2 \phi'(0).$$

Оно контролирует скорость изменения функции вдоль направления h^k , предотвращая выбор слишком больших шагов, после которых производная становится близкой к нулю и функция перестаёт заметно убывать.

Рассмотрим комбинации условий:

- Правило Армихо (достаточное убывание).

Алгоритм Л1.5 Вычисление γ_k с помощью правила Армихо

Вход: стартовая точка $x^0 \in \mathbb{R}^d$, начальное значение $\gamma_k > 0$, $0 < \beta_1 < 1$, $0 < \rho < 1$,
 $\langle \nabla f(x^k), h^k \rangle < 0$
1: $x^{k+1} = x^k + \gamma_k h^k$
2: **while** $f(x^{k+1}) > f(x^k) + \beta_1 \gamma_k \langle \nabla f(x^k), h^k \rangle$ **do**
3: $\gamma_k = \rho \cdot \gamma_k$
4: $x^{k+1} = x^k + \gamma_k h^k$
5: **end while**
Выход: $\frac{\gamma_k}{\rho}$




Рис. Л1.3: Иллюстрация правила Армихо.

- Вольфа (достаточное убывание + кривизна).

Алгоритм Л1.6 Вычисление γ_k с помощью правила Вольфа

Вход: стартовая точка $x^0 \in \mathbb{R}^d$, начальное значение $\gamma_k > 0$, $l = 0$, $u = \infty$, $\varepsilon > 0$, $0 < \beta_1 < \beta_2 < 1$, $\langle \nabla f(x^k), h^k \rangle < 0$

```

1: while  $u - l > \varepsilon$  do
2:   if  $f(x^{k+1}) > f(x^k) + \beta_1 \gamma_k \langle \nabla f(x^k), h^k \rangle$  then
3:      $u = \gamma_k$ 
4:      $\gamma_k = \frac{l+u}{2}$ 
5:   else
6:     if  $\langle \nabla f(x^{k+1}), h^k \rangle < \beta_2 \langle \nabla f(x^k), h^k \rangle$  then
7:        $l = \gamma_k$ 
8:       if  $u = \infty$  then
9:          $\gamma_k = 2 \cdot l$ 
10:      else
11:         $\gamma_k = \frac{l+u}{2}$ 
12:      end if
13:    end if
14:  end if
15: end while
Выход:  $\gamma_k$ 

```

Иллюстрация условий на Рисунке Л1.4.

- Усиленное правило Вольфа (достаточное убывание + кривизна с двух сторон).
В этом случае условие на строке 6 в Алгоритме Л1.6 заменяется на

$$\left| \langle \nabla f(x^{k+1}), h^k \rangle \right| < \beta_2 \left| \langle \nabla f(x^k), h^k \rangle \right|, \quad \beta_2 \in (0, 1). \quad (\text{Л1.10})$$

Иллюстрация условий на Рисунке Л1.5.

- Правильно Гольдштейна (достаточное убывание + существенное убывание):

Рассматриваются $\beta_2 = 1 - \beta_1$ и $\beta_1 \in (0, \frac{1}{2})$. В этом случае условие на строке 6 в Алгоритме Л1.6 заменяется на

$$f(x^{k+1}) < f(x^k) + (1 - \beta_1)\gamma_k \langle \nabla f(x^k), h^k \rangle.$$

Иллюстрация условий на Рисунке Л1.6.




Рис. Л1.4: Иллюстрация условия Вольфа.

Про условия Вольфа верно утверждение, что подходящее значение шага существует.

Утверждение Л1.7 (Лемма 3.1 из [2]). Пусть $f : \mathbb{R}^d \rightarrow \mathbb{R}$ — непрерывно дифференцируема. Пусть h_k — направление убывания в точке x^k , и предположим, что f ограничена снизу на луче $\{x^k + \gamma_k h^k \mid \gamma_k > 0\}$. Тогда при $0 < \beta_1 < \beta_2 < 1$ существуют интервалы шагов, удовлетворяющие правилу Вольфа (Алгоритм Л1.6) и усиленному правилу Вольфа (Алгоритм Л1.6 и неравенство (Л1.10)).

Список литературы

- [1] А. Cauchy. Méthode générale pour la résolution des systèmes d'équations simultanées. *Comptes rendus hebdomadaires des séances de l'Académie des sciences*, 55:536–538, 1847.




Рис. Л1.5: Иллюстрация усиленного правила Вольфа.

- [2] J. Nocedal and S. Wright. *Numerical Optimization*. Springer Series in Operations Research and Financial Engineering. Springer New York, 2006.
- [3] В.Т. Полиак. *Введение в оптимизацию*. "Наука", Глав. ред. физико-математической литры, 1983.
- [4] Ю. Е. Нестеров. *Методы выпуклой оптимизации*. Изд-во МЦНМО, Москва, 2010.




Рис. Л1.6: Иллюстрация правила Гольдштейна.