

Градиентный спуск

Методы оптимизации

Александр Безносиков

Московский физико-технический институт

17 сентября 2026



Градиентный спуск

Задача: найти решение безусловной оптимизации

$$\min_{x \in \mathbb{R}^d} f(x).$$






Алгоритм Градиентный спуск

Вход: стартовая точка $x^0 \in \mathbb{R}^d$, размеры шагов $\{\gamma_k\}_{k=0} > 0$, количество итераций K

- 1: **for** $k = 0, 1, \dots, K - 1$ **do**
- 2: $x^{k+1} = x^k - \gamma_k \nabla f(x^k)$
- 3: **end for**

Выход: x^K

Зачем нужен шаг?



Сходимость μ -сильно выпуклых функций

Зная, что для сильно выпуклых функций решение уникально, попытаемся оценить, как меняется расстояние до него. Подставим итерацию:

$$\begin{aligned}\|x^{k+1} - x^*\|_2^2 &= \|x^k - \gamma_k \nabla f(x^k) - x^*\|_2^2 \\ &= \|x^k - x^*\|_2^2 - 2\gamma_k \langle \nabla f(x^k), x^k - x^* \rangle + \gamma_k^2 \|\nabla f(x^k)\|_2^2.\end{aligned}$$

Сходимость μ -сильно выпуклых функций

Зная, что для сильно выпуклых функций решение уникально, попытаемся оценить, как меняется расстояние до него. Подставим итерацию:

$$\begin{aligned}\|x^{k+1} - x^*\|_2^2 &= \|x^k - \gamma_k \nabla f(x^k) - x^*\|_2^2 \\ &= \|x^k - x^*\|_2^2 - 2\gamma_k \langle \nabla f(x^k), x^k - x^* \rangle + \gamma_k^2 \|\nabla f(x^k)\|_2^2.\end{aligned}$$

Вопрос: что дальше?

Сходимость μ -сильно выпуклых функций

Зная, что для сильно выпуклых функций решение уникально, попытаемся оценить, как меняется расстояние до него. Подставим итерацию:

$$\begin{aligned}\|x^{k+1} - x^*\|_2^2 &= \|x^k - \gamma_k \nabla f(x^k) - x^*\|_2^2 \\ &= \|x^k - x^*\|_2^2 - 2\gamma_k \langle \nabla f(x^k), x^k - x^* \rangle + \gamma_k^2 \|\nabla f(x^k)\|_2^2.\end{aligned}$$

Вопрос: что дальше? Воспользуемся условием оптимальности $\nabla f(x^*) = 0$ и запишем:

$$\begin{aligned}\|x^{k+1} - x^*\|_2^2 &= \|x^k - x^*\|_2^2 - 2\gamma_k \langle \nabla f(x^k), x^k - x^* \rangle \\ &\quad + \gamma_k^2 \|\nabla f(x^k) - \nabla f(x^*)\|_2^2.\end{aligned}$$

Сходимость μ -сильно выпуклых функций

Для точек x^k и x^* воспользуемся μ -сильной выпуклостью:

$$f^* \geq f(x^k) + \langle \nabla f(x^k), x^* - x^k \rangle + \frac{\mu}{2} \|x^k - x^*\|_2^2$$

и гладкостью:

$$\|\nabla f(x^k) - \nabla f(x^*)\|_2^2 \leq L^2 \|x^k - x^*\|_2^2.$$

Сходимость μ -сильно выпуклых функций

Для точек x^k и x^* воспользуемся μ -сильной выпуклостью:

$$f^* \geq f(x^k) + \langle \nabla f(x^k), x^* - x^k \rangle + \frac{\mu}{2} \|x^k - x^*\|_2^2$$

и гладкостью:

$$\|\nabla f(x^k) - \nabla f(x^*)\|_2^2 \leq L^2 \|x^k - x^*\|_2^2.$$

Тогда после подстановки неравенств, имеем:

$$\begin{aligned} \|x^{k+1} - x^*\|_2^2 &\leq \|x^k - x^*\|_2^2 + 2\gamma_k \left(-\frac{\mu}{2} \|x^k - x^*\|_2^2 + f^* - f(x^k) \right) \\ &\quad + \gamma_k^2 L^2 \|x^k - x^*\|_2^2 \\ &= (1 - \gamma_k \mu + \gamma_k^2 L^2) \|x^k - x^*\|_2^2 + 2\gamma_k (f^* - f(x^k)). \end{aligned}$$

Сходимость μ -сильно выпуклых функций

Откинем $f(x^k) \geq f^*$ в силу отрицательности последнего слагаемого:

$$\|x^{k+1} - x^*\|_2^2 \leq (1 - \gamma_k \mu + \gamma_k^2 L^2) \|x^k - x^*\|_2^2.$$

Вопрос: что делать дальше?

Сходимость μ -сильно выпуклых функций

Откинем $f(x^k) \geq f^*$ в силу отрицательности последнего слагаемого:

$$\|x^{k+1} - x^*\|_2^2 \leq (1 - \gamma_k \mu + \gamma_k^2 L^2) \|x^k - x^*\|_2^2.$$

Вопрос: что делать дальше? Хочется, чтобы расстояние до решения уменьшалось, а именно, $(1 - \gamma_k \mu + \gamma_k^2 L^2) < 1$, а лучше вообще найти $\operatorname{argmin}_{\gamma_k} (1 - \gamma_k \mu + \gamma_k^2 L^2)$. Как это сделать?

Сходимость μ -сильно выпуклых функций

Откинем $f(x^k) \geq f^*$ в силу отрицательности последнего слагаемого:

$$\|x^{k+1} - x^*\|_2^2 \leq (1 - \gamma_k \mu + \gamma_k^2 L^2) \|x^k - x^*\|_2^2.$$

Вопрос: что делать дальше? Хочется, чтобы расстояние до решения уменьшалось, а именно, $(1 - \gamma_k \mu + \gamma_k^2 L^2) < 1$, а лучше вообще найти $\operatorname{argmin}_{\gamma_k} (1 - \gamma_k \mu + \gamma_k^2 L^2)$. Как это сделать? Найдём минимум одномерной параболы: $\gamma_k^* = \frac{\mu}{2L^2}$. Получим

$$\|x^{k+1} - x^*\|_2^2 \leq \left(1 - \frac{\mu^2}{4L^2}\right) \|x^k - x^*\|_2^2.$$

Сходимость μ -сильно выпуклых функций

Запустим рекурсию:

$$\|x^K - x^*\|_2^2 \leq \left(1 - \frac{\mu^2}{4L^2}\right)^K \|x^0 - x^*\|_2^2.$$

Вопрос: какая это скорость сходимости?

Сходимость μ -сильно выпуклых функций

Запустим рекурсию:

$$\|x^K - x^*\|_2^2 \leq \left(1 - \frac{\mu^2}{4L^2}\right)^K \|x^0 - x^*\|_2^2.$$

Вопрос: какая это скорость сходимости? Линейная. А как получить оценку на число итераций?

Сходимость μ -сильно выпуклых функций

Запустим рекурсию:

$$\|x^K - x^*\|_2^2 \leq \left(1 - \frac{\mu^2}{4L^2}\right)^K \|x^0 - x^*\|_2^2.$$

Вопрос: какая это скорость сходимости? Линейная. А как получить оценку на число итераций?

$$\|x^K - x^*\|_2^2 \leq \left(1 - \frac{\mu^2}{4L^2}\right)^K \|x^0 - x^*\|_2^2 \leq \exp\left(-\frac{\mu^2}{4L^2} \cdot K\right) \|x^0 - x^*\|_2^2.$$

Сходимость μ -сильно выпуклых функций

Запустим рекурсию:

$$\|x^K - x^*\|_2^2 \leq \left(1 - \frac{\mu^2}{4L^2}\right)^K \|x^0 - x^*\|_2^2.$$

Вопрос: какая это скорость сходимости? Линейная. А как получить оценку на число итераций?

$$\|x^K - x^*\|_2^2 \leq \left(1 - \frac{\mu^2}{4L^2}\right)^K \|x^0 - x^*\|_2^2 \leq \exp\left(-\frac{\mu^2}{4L^2} \cdot K\right) \|x^0 - x^*\|_2^2.$$

Мы хотим гарантировать

$$\|x^K - x^*\|_2^2 \leq \exp\left(-\frac{\mu^2}{4L^2} \cdot K\right) \|x^0 - x^*\|_2^2 \leq \varepsilon^2.$$

Сходимость μ -сильно выпуклых функций

Тогда логарифмируем и получаем

$$K \geq \frac{4L^2}{\mu^2} \log \left(\frac{\|x^0 - x^*\|_2^2}{\varepsilon^2} \right).$$

Сходимость μ -сильно выпуклых функций

Тогда логарифмируем и получаем

$$K \geq \frac{4L^2}{\mu^2} \log \left(\frac{\|x^0 - x^*\|_2^2}{\varepsilon^2} \right).$$

Итого: Можно лучше. Пример того, как в получении верхних оценок можно «заглубить». Будем исправлять.

Сходимость μ -сильно выпуклых функций

Начинаем с применения итерации градиентного спуска и условия оптимальности $\nabla f(x^*) = 0$:

$$\begin{aligned}\|x^{k+1} - x^*\|_2^2 &= \|x^k - \gamma_k \nabla f(x^k) - x^*\|_2^2 \\ &= \|x^k - x^*\|_2^2 - 2\gamma_k \langle \nabla f(x^k), x^k - x^* \rangle + \gamma_k^2 \|\nabla f(x^k)\|_2^2 \\ &= \|x^k - x^*\|_2^2 + 2\gamma_k \langle \nabla f(x^k), x^* - x^k \rangle \\ &\quad + \gamma_k^2 \|\nabla f(x^k) - \nabla f(x^*)\|_2^2.\end{aligned}$$

Сходимость μ -сильно выпуклых функций

Начинаем с применения итерации градиентного спуска и условия оптимальности $\nabla f(x^*) = 0$:

$$\begin{aligned}\|x^{k+1} - x^*\|_2^2 &= \|x^k - \gamma_k \nabla f(x^k) - x^*\|_2^2 \\ &= \|x^k - x^*\|_2^2 - 2\gamma_k \langle \nabla f(x^k), x^k - x^* \rangle + \gamma_k^2 \|\nabla f(x^k)\|_2^2 \\ &= \|x^k - x^*\|_2^2 + 2\gamma_k \langle \nabla f(x^k), x^* - x^k \rangle \\ &\quad + \gamma_k^2 \|\nabla f(x^k) - \nabla f(x^*)\|_2^2.\end{aligned}$$

Для точек x^k и x^* воспользуемся μ -сильной выпуклостью:

$$f^* \geq f(x^k) + \langle \nabla f(x^k), x^* - x^k \rangle + \frac{\mu}{2} \|x^k - x^*\|_2^2.$$

Сходимость μ -сильно выпуклых функций

Воспользуемся не L -гладкостью, а теоремой с прошлой лекции:

$$\frac{1}{2L} \left\| \nabla f(x^k) - \nabla f(x^*) \right\|_2^2 \leq f(x^k) - f^* - \left\langle \nabla f(x^*), x^k - x^* \right\rangle.$$

Сходимость μ -сильно выпуклых функций

Воспользуемся не L -гладкостью, а теоремой с прошлой лекции:

$$\frac{1}{2L} \left\| \nabla f(x^k) - \nabla f(x^*) \right\|_2^2 \leq f(x^k) - f^* - \left\langle \nabla f(x^*), x^k - x^* \right\rangle.$$

Подставим неравенства:

$$\begin{aligned} \|x^{k+1} - x^*\|_2^2 &\leq \|x^k - x^*\|_2^2 - 2\gamma_k \left(\frac{\mu}{2} \|x^k - x^*\|_2^2 + f(x^k) - f^* \right) \\ &\quad + \gamma_k^2 \left\| \nabla f(x^k) - \nabla f(x^*) \right\|_2^2 \\ &\leq \|x^k - x^*\|_2^2 - 2\gamma_k \left(\frac{\mu}{2} \|x^k - x^*\|_2^2 + f(x^k) - f^* \right) \\ &\quad + 2\gamma_k^2 L \left(f(x^k) - f^* - \left\langle \nabla f(x^*), x^k - x^* \right\rangle \right) \\ &= (1 - \mu\gamma_k) \|x^k - x^*\|_2^2 + 2\gamma_k(\gamma_k L - 1) (f(x^k) - f^*). \end{aligned}$$

Сходимость μ -сильно выпуклых функций

Заметим, что $f(x^k) \geq f^*$, тогда при $\gamma_k \leq \frac{1}{L}$, получаем:

$$\|x^{k+1} - x^*\|_2^2 \leq (1 - \mu\gamma_k) \|x^k - x^*\|_2^2.$$

Сходимость μ -сильно выпуклых функций

Заметим, что $f(x^k) \geq f^*$, тогда при $\gamma_k \leq \frac{1}{L}$, получаем:

$$\|x^{k+1} - x^*\|_2^2 \leq (1 - \mu\gamma_k) \|x^k - x^*\|_2^2.$$

Запустим рекурсию:

$$\|x^K - x^*\|_2^2 \leq \left(\prod_{k=0}^{K-1} (1 - \mu\gamma_k) \right) \|x^0 - x^*\|_2^2.$$

Сходимость μ -сильно выпуклых функций

Заметим, что $f(x^k) \geq f^*$, тогда при $\gamma_k \leq \frac{1}{L}$, получаем:

$$\|x^{k+1} - x^*\|_2^2 \leq (1 - \mu\gamma_k) \|x^k - x^*\|_2^2.$$

Запустим рекурсию:

$$\|x^K - x^*\|_2^2 \leq \left(\prod_{k=0}^{K-1} (1 - \mu\gamma_k) \right) \|x^0 - x^*\|_2^2.$$

При $\gamma_k = \frac{1}{L}$ получаем:

$$\|x^K - x^*\|_2^2 \leq \left(1 - \frac{\mu}{L}\right)^K \|x^0 - x^*\|_2^2 \implies K \geq \frac{L}{\mu} \log \left(\frac{\|x^0 - x^*\|_2^2}{\varepsilon^2} \right).$$

Сходимость μ -сильно выпуклых функций

Утверждение

Пусть выбрано значение шага $\gamma_k = \frac{1}{L}$. Тогда справедлива следующая оценка сходимости:

$$\|x^K - x^*\|_2^2 \leq \left(1 - \frac{\mu}{L}\right)^K \|x^0 - x^*\|_2^2.$$

Более того, чтобы добиться точности ε по аргументу необходимо

$$K = \mathcal{O}\left(\frac{L}{\mu} \log \frac{\|x^0 - x^*\|_2}{\varepsilon}\right) \text{ итераций.}$$

В дальнейшем будем использовать $\mathcal{O}$ -нотацию для того, чтобы опускать численные константы, так как нас интересует величина, зависящая от параметров задачи.

Сходимость выпуклых функций

Утверждение

Пусть задача безусловной оптимизации с L -гладкой выпуклой целевой функцией f решается с помощью градиентного спуска. Тогда при $\gamma_k \in (0, \frac{2}{L})$ справедливо, что $f(x^{k+1}) \leq f(x^k)$.

Сходимость выпуклых функций

Воспользуемся теоремой с прошлой лекции:

$$f(x^{k+1}) \leq f(x^k) + \langle \nabla f(x^k), x^{k+1} - x^k \rangle + \frac{L}{2} \|x^{k+1} - x^k\|_2^2.$$

Сходимость выпуклых функций

Воспользуемся теоремой с прошлой лекции:


$$f(x^{k+1}) \leq f(x^k) + \langle \nabla f(x^k), x^{k+1} - x^k \rangle + \frac{L}{2} \|x^{k+1} - x^k\|_2^2.$$

Подставим итерационный шаг градиентного спуска:

$$\begin{aligned} f(x^{k+1}) &\leq f(x^k) - \gamma_k \|\nabla f(x^k)\|_2^2 + \frac{L\gamma_k^2}{2} \|\nabla f(x^k)\|_2^2 \\ &= f(x^k) - \gamma_k \left(1 - \frac{L\gamma_k}{2}\right) \|\nabla f(x^k)\|_2^2. \end{aligned}$$

Если $\gamma_k \in (0, \frac{2}{L})$, то $f(x^{k+1}) \leq f(x^k)$.

Сходимость выпуклых функций



Сходимость выпуклых функций

Начнем доказательство с оценки, полученной в прошлом доказательстве, с $\mu = 0$:

$$\|x^{k+1} - x^*\|_2^2 \leq \|x^k - x^*\|_2^2 + 2\gamma_k(\gamma_k L - 1)(f(x^k) - f^*).$$

Сходимость выпуклых функций

Начнем доказательство с оценки, полученной в прошлом доказательстве, с $\mu = 0$:

$$\|x^{k+1} - x^*\|_2^2 \leq \|x^k - x^*\|_2^2 + 2\gamma_k(\gamma_k L - 1)(f(x^k) - f^*).$$

Потребуем, чтобы $2(\gamma_k L - 1) \leq -1$, тогда $\gamma_k \leq \frac{1}{2L}$ и:

$$\begin{aligned}\|x^{k+1} - x^*\|_2^2 &\leq \|x^k - x^*\|_2^2 + 2\gamma_k(\gamma_k L - 1)(f(x^k) - f^*) \\ &\leq \|x^k - x^*\|_2^2 - \gamma_k(f(x^k) - f^*).\end{aligned}$$

Сходимость выпуклых функций

Начнем доказательство с оценки, полученной в прошлом доказательстве, с $\mu = 0$:

$$\|x^{k+1} - x^*\|_2^2 \leq \|x^k - x^*\|_2^2 + 2\gamma_k(\gamma_k L - 1)(f(x^k) - f^*).$$

Потребуем, чтобы $2(\gamma_k L - 1) \leq -1$, тогда $\gamma_k \leq \frac{1}{2L}$ и:

$$\begin{aligned}\|x^{k+1} - x^*\|_2^2 &\leq \|x^k - x^*\|_2^2 + 2\gamma_k(\gamma_k L - 1)(f(x^k) - f^*) \\ &\leq \|x^k - x^*\|_2^2 - \gamma_k(f(x^k) - f^*).\end{aligned}$$

Перепишем неравенство:

$$\gamma_k(f(x^k) - f^*) \leq \|x^k - x^*\|_2^2 - \|x^{k+1} - x^*\|_2^2.$$

Сходимость выпуклых функций

Просуммируем по всем итерациям от 0 до $K - 1$:

$$\begin{aligned}\sum_{k=0}^{K-1} \gamma_k \left(f(x^k) - f^* \right) &\leq \sum_{k=0}^{K-1} \left(\|x^k - x^*\|_2^2 - \|x^{k+1} - x^*\|_2^2 \right) \\ &= \|x^0 - x^*\|_2^2 - \|x^K - x^*\|_2^2 \leq \|x^0 - x^*\|_2^2.\end{aligned}$$

Сходимость выпуклых функций

Просуммируем по всем итерациям от 0 до $K - 1$:

$$\begin{aligned}\sum_{k=0}^{K-1} \gamma_k (f(x^k) - f^*) &\leq \sum_{k=0}^{K-1} (\|x^k - x^*\|_2^2 - \|x^{k+1} - x^*\|_2^2) \\ &= \|x^0 - x^*\|_2^2 - \|x^K - x^*\|_2^2 \leq \|x^0 - x^*\|_2^2.\end{aligned}$$

Воспользуемся Утверждением, из которого $f(x^K) \leq f(x^k)$:

$$(f(x^K) - f^*) \sum_{k=0}^{K-1} \gamma_k \leq \|x^0 - x^*\|_2^2 \implies f(x^K) - f^* \leq \frac{\|x^0 - x^*\|_2^2}{\sum_{k=0}^{K-1} \gamma_k}.$$

Сходимость выпуклых функций

Утверждение

Пусть выбрано значение шага $\gamma_k = \frac{1}{2L}$. Тогда справедлива следующая оценка сходимости:

$$f(x^K) - f^* \leq \frac{2L \|x^0 - x^*\|_2^2}{K}.$$

Более того, чтобы добиться точности ε по функции необходимо

$$K = \mathcal{O}\left(\frac{L \|x^0 - x^*\|_2^2}{\varepsilon}\right) \text{ итераций.}$$

Сходимость невыпуклых функций

Воспользуемся теоремой с прошлой лекции:

$$f(x^{k+1}) \leq f(x^k) + \langle \nabla f(x^k), x^{k+1} - x^k \rangle + \frac{L}{2} \|x^{k+1} - x^k\|_2^2.$$

Сходимость невыпуклых функций

Воспользуемся теоремой с прошлой лекции:

$$f(x^{k+1}) \leq f(x^k) + \langle \nabla f(x^k), x^{k+1} - x^k \rangle + \frac{L}{2} \|x^{k+1} - x^k\|_2^2.$$

Подставим итерационный шаг градиентного спуска:

$$\begin{aligned} f(x^{k+1}) &\leq f(x^k) - \gamma_k \|\nabla f(x^k)\|_2^2 + \frac{L\gamma_k^2}{2} \|\nabla f(x^k)\|_2^2 \\ &\leq f(x^k) - \gamma_k \left(1 - \frac{L\gamma_k}{2}\right) \|\nabla f(x^k)\|_2^2. \end{aligned}$$

Сходимость невыпуклых функций

Воспользуемся теоремой с прошлой лекции:

$$f(x^{k+1}) \leq f(x^k) + \langle \nabla f(x^k), x^{k+1} - x^k \rangle + \frac{L}{2} \|x^{k+1} - x^k\|_2^2.$$

Подставим итерационный шаг градиентного спуска:

$$\begin{aligned} f(x^{k+1}) &\leq f(x^k) - \gamma_k \|\nabla f(x^k)\|_2^2 + \frac{L\gamma_k^2}{2} \|\nabla f(x^k)\|_2^2 \\ &\leq f(x^k) - \gamma_k \left(1 - \frac{L\gamma_k}{2}\right) \|\nabla f(x^k)\|_2^2. \end{aligned}$$

Возьмем $\gamma_k = \frac{1}{L}$. Тогда

$$f(x^{k+1}) \leq f(x^k) - \frac{1}{2L} \|\nabla f(x^k)\|_2^2.$$

Сходимость выпуклых функций

После небольших перестановок получаем:

$$\left\| \nabla f(x^k) \right\|_2^2 \leq 2L \left(f(x^k) - f(x^{k+1}) \right).$$

Сходимость выпуклых функций

После небольших перестановок получаем:

$$\left\| \nabla f(x^k) \right\|_2^2 \leq 2L \left(f(x^k) - f(x^{k+1}) \right).$$

Суммируя по всем итерациям от 0 до $K - 1$, получаем:

$$\sum_{k=0}^{K-1} \left\| \nabla f(x^k) \right\|_2^2 \leq 2L \left(f(x^0) - f(x^K) \right) \leq 2L \left(f(x^0) - f^* \right).$$

Сходимость выпуклых функций

После небольших перестановок получаем:

$$\left\| \nabla f(x^k) \right\|_2^2 \leq 2L \left(f(x^k) - f(x^{k+1}) \right).$$

Суммируя по всем итерациям от 0 до $K - 1$, получаем:

$$\sum_{k=0}^{K-1} \left\| \nabla f(x^k) \right\|_2^2 \leq 2L \left(f(x^0) - f(x^K) \right) \leq 2L(f(x^0) - f^*).$$

Усредним по K :

$$\frac{1}{K} \sum_{k=0}^{K-1} \left\| \nabla f(x^k) \right\|_2^2 \leq \frac{2L(f(x^0) - f^*)}{K}.$$

Сходимость невыпуклых функций

Вопрос: как выбирать точку?

Сходимость невыпуклых функций

Вопрос: как выбирать точку?

- Равномерный случайный выбор $\hat{x}^K$ из $x^0, \dots, x^{K-1}$:

$$\mathbb{E} \left[\left\| \nabla f(\hat{x}^K) \right\|_2^2 \right] = \frac{1}{K} \sum_{k=0}^{K-1} \left\| \nabla f(x^k) \right\|_2^2 \leq \frac{2L(f(x^0) - f^*)}{K};$$

Сходимость невыпуклых функций

Вопрос: как выбирать точку?

- Равномерный случайный выбор $\hat{x}^K$ из $x^0, \dots, x^{K-1}$:

$$\mathbb{E} \left[\left\| \nabla f(\hat{x}^K) \right\|_2^2 \right] = \frac{1}{K} \sum_{k=0}^{K-1} \left\| \nabla f(x^k) \right\|_2^2 \leq \frac{2L(f(x^0) - f^*)}{K};$$

- Выбор точки $\hat{x}^K$ с минимальным по норме градиентом:

$$\begin{aligned} \left\| \nabla f(\hat{x}^K) \right\|_2^2 &= \min_{k \in \{0, \dots, K-1\}} \left\| \nabla f(x^k) \right\|_2^2 \leq \frac{1}{K} \sum_{k=0}^{K-1} \left\| \nabla f(x^k) \right\|_2^2 \\ &\leq \frac{2L(f(x^0) - f^*)}{K}. \end{aligned}$$

Сходимость невыпуклых функций

Вопрос: как выбирать точку?

- Равномерный случайный выбор $\hat{x}^K$ из $x^0, \dots, x^{K-1}$:

$$\mathbb{E} \left[\left\| \nabla f(\hat{x}^K) \right\|_2^2 \right] = \frac{1}{K} \sum_{k=0}^{K-1} \left\| \nabla f(x^k) \right\|_2^2 \leq \frac{2L(f(x^0) - f^*)}{K};$$

- Выбор точки $\hat{x}^K$ с минимальным по норме градиентом:

$$\begin{aligned} \left\| \nabla f(\hat{x}^K) \right\|_2^2 &= \min_{k \in \{0, \dots, K-1\}} \left\| \nabla f(x^k) \right\|_2^2 \leq \frac{1}{K} \sum_{k=0}^{K-1} \left\| \nabla f(x^k) \right\|_2^2 \\ &\leq \frac{2L(f(x^0) - f^*)}{K}. \end{aligned}$$

В любом случае получаем сублинейную сходимость.

Сходимость невыпуклых функций

Теорема

Пусть задача безусловной оптимизации с L -гладкой целевой функцией f решается с помощью градиентного спуска. Тогда при $\gamma_k = \frac{1}{L}$ справедлива следующая оценка сходимости:

$$\left\| \nabla f(\hat{x}^K) \right\|_2^2 \leq \frac{2L(f(x^0) - f^*)}{K},$$

где $\hat{x}^K$ — специально выбранная точка из $\{x^k\}$. Более того, чтобы добиться точности ε по норме градиента ($\|\nabla f(x^K)\|_2 \leq \varepsilon$), необходимо

$$K = \mathcal{O}\left(\frac{2L(f(x^0) - f^*)}{\varepsilon^2}\right) \text{ итераций.}$$

Линейный поиск значения L

В доказательстве Утверждения для выпуклой функции мы получали оценку на значение функции f на следующей итерации:

$$\begin{aligned} f(x^{k+1}) &\leq f(x^k) + \underbrace{\left(\frac{L\gamma^2}{2} - \gamma\right)}_{\rightarrow \min} \|\nabla f(x^k)\|_2^2 = \left[\gamma = \frac{1}{L}\right] \\ &= f(x^k) - \frac{1}{2L} \|\nabla f(x^k)\|_2^2. \end{aligned}$$

Линейный поиск значения L

В доказательстве Утверждения для выпуклой функции мы получали оценку на значение функции f на следующей итерации:

$$\begin{aligned} f(x^{k+1}) &\leq f(x^k) + \underbrace{\left(\frac{L\gamma^2}{2} - \gamma\right)}_{\rightarrow \min} \|\nabla f(x^k)\|_2^2 = \left[\gamma = \frac{1}{L}\right] \\ &= f(x^k) - \frac{1}{2L} \|\nabla f(x^k)\|_2^2. \end{aligned}$$

Из оценки выше сразу же появляется идея для поиска L и шага $\frac{1}{L}$: увеличиваем L в ρ раз, пока условие выше не начинает выполняться.

Линейный поиск значения L

Алгоритм Градиентный спуск с линейным поиском L

Вход: стартовая точка $x^0 \in \mathbb{R}^d$, начальное значение $L_0 > 0$, параметр $\rho > 1$, число итераций K

- 1: **for** $k = 0, 1, \dots, K - 1$ **do**
 - 2: $L_{k+1} = \frac{1}{\rho} \cdot L_k$
 - 3: $x^{k+1} = x^k - \frac{1}{L_{k+1}} \nabla f(x^k)$
 - 4: **while** $f(x^{k+1}) > f(x^k) - \frac{1}{2L_{k+1}} \|\nabla f(x^k)\|_2^2$ **do**
 - 5: $L_{k+1} = \rho \cdot L_{k+1}$
 - 6: $x^{k+1} = x^k - \frac{1}{L_{k+1}} \nabla f(x^k)$
 - 7: **end while**
 - 8: **end for**
- Выход:** x^K
-

Степенной шаг

В качестве простой альтернативы можно использовать убывающий с номером итерации шаг:

$$\gamma_k := \frac{\gamma}{\delta + (ak + b)^p}, \quad \gamma, \delta, a, b, p > 0.$$

Наиболее часто применяются на практике $\gamma_k = \frac{1}{k+1}$ и $\gamma_k = \frac{1}{\sqrt{k+1}}$.

Наискорейший спуск

Итерация градиентного спуска выглядит следующим образом:

$$x^{k+1} = x^k - \gamma_k \nabla f(x^k).$$

Наискорейший спуск

Итерация градиентного спуска выглядит следующим образом:

$$x^{k+1} = x^k - \gamma_k \nabla f(x^k).$$

Посмотрим на значение целевой функции после сделанного шага как на функцию от одного аргумента γ_k :

$$\phi(\gamma_k) := f(x^k - \gamma_k \nabla f(x^k)).$$

Наискорейший спуск

Итерация градиентного спуска выглядит следующим образом:

$$x^{k+1} = x^k - \gamma_k \nabla f(x^k).$$

Посмотрим на значение целевой функции после сделанного шага как на функцию от одного аргумента γ_k :

$$\phi(\gamma_k) := f(x^k - \gamma_k \nabla f(x^k)).$$

Поскольку стоит задача минимизации f , то будем выбирать шаг γ_k так, чтобы минимизировать значение функции $\phi(\gamma_k)$.

Наискорейший спуск

Итерация градиентного спуска выглядит следующим образом:

$$x^{k+1} = x^k - \gamma_k \nabla f(x^k).$$


Посмотрим на значение целевой функции после сделанного шага как на функцию от одного аргумента γ_k :

$$\phi(\gamma_k) := f(x^k - \gamma_k \nabla f(x^k)).$$

Поскольку стоит задача минимизации f , то будем выбирать шаг γ_k так, чтобы минимизировать значение функции $\phi(\gamma_k)$. Получим важное свойство шага, выпишем необходимое условие оптимума:

$$\begin{aligned} \phi'(\gamma_k^*) &= \frac{\partial f(x^k - \gamma_k \nabla f(x^k))}{\partial \gamma_k} \bigg|_{\gamma_k = \gamma_k^*} = -\langle \nabla f(x^k - \gamma_k^* \nabla f(x^k)), \nabla f(x^k) \rangle \\ &= -\langle \nabla f(x^{k+1}), \nabla f(x^k) \rangle = 0. \end{aligned}$$

Наискорейший спуск



Шаг Поляка–Шора

В ходе доказательства Теоремы о сходимости градиентного спуска для гладких выпуклых функций мы получили неравенство:

$$\|x^{k+1} - x^*\|_2^2 \leq \|x^k - x^*\|_2^2 - 2\gamma_k(f(x^k) - f^*) + \gamma_k^2 \|\nabla f(x^k)\|_2^2.$$

Шаг Поляка–Шора

В ходе доказательства Теоремы о сходимости градиентного спуска для гладких выпуклых функций мы получили неравенство:

$$\|x^{k+1} - x^*\|_2^2 \leq \|x^k - x^*\|_2^2 - 2\gamma_k(f(x^k) - f^*) + \gamma_k^2 \|\nabla f(x^k)\|_2^2.$$

Попробуем выбрать γ_k так, чтобы минимизировать верхнюю оценку. Для этого найдем производную по γ_k и приравняем ее к нулю:

$$-2(f(x^k) - f^*) + 2\gamma_k^* \|\nabla f(x^k)\|_2^2 = 0.$$

Шаг Поляка–Шора

В ходе доказательства Теоремы о сходимости градиентного спуска для гладких выпуклых функций мы получили неравенство:

$$\|x^{k+1} - x^*\|_2^2 \leq \|x^k - x^*\|_2^2 - 2\gamma_k(f(x^k) - f^*) + \gamma_k^2 \|\nabla f(x^k)\|_2^2.$$

Попробуем выбрать γ_k так, чтобы минимизировать верхнюю оценку. Для этого найдем производную по γ_k и приравняем ее к нулю:

$$-2(f(x^k) - f^*) + 2\gamma_k^* \|\nabla f(x^k)\|_2^2 = 0.$$

Отсюда получаем оптимальное значение шага, минимизирующее данную оценку:

$$\gamma_k^* = \frac{f(x^k) - f^*}{\|\nabla f(x^k)\|_2^2}.$$

Шаг Поляка–Шора

В общем виде шаг Поляка–Шора записывается с параметром $\alpha > 0$:

$$\gamma_k^* := \frac{f(x^k) - f^*}{\alpha \|\nabla f(x^k)\|_2^2}.$$

Вопрос: Зачем?

Шаг Поляка–Шора

В общем виде шаг Поляка–Шора записывается с параметром $\alpha > 0$:

$$\gamma_k^* := \frac{f(x^k) - f^*}{\alpha \|\nabla f(x^k)\|_2^2}.$$

Вопрос: Зачем? Значение функции в оптимуме часто неизвестно, поэтому в формуле вместо f^* используют некоторую нижнюю оценку. При использовании оценки параметр α позволяет корректировать шаг в зависимости от точности оценки минимума.

Стратегия бэктрекинга для подбора размера шага

Введем в рассмотрение $\phi(\gamma_k) = f(x^k + \gamma_k h^k)$, где h^k — произвольное направление, также рассмотрим некоторые константы β_1, β_2 , удовлетворяющие условию $0 < \beta_1 < \beta_2 < 1$. Рассмотрим эвристики.

● **Условие достаточного убывания:**

$$f(x^{k+1}) \leq f(x^k) + \beta_1 \gamma_k \langle \nabla f(x^k), h^k \rangle \implies \phi(\gamma_k) \leq \phi(0) + \beta_1 \gamma_k \phi'(0).$$


● **Условие существенного убывания:**

$$f(x^{k+1}) \geq f(x^k) + \beta_2 \gamma_k \langle \nabla f(x^k), h^k \rangle \implies \phi(\gamma_k) \geq \phi(0) + \beta_2 \gamma_k \phi'(0).$$


● **Условие кривизны:**

$$\langle \nabla f(x^{k+1}), h^k \rangle \geq \beta_2 \langle \nabla f(x^k), h^k \rangle \implies \phi'(\gamma_k) \geq \beta_2 \phi'(0).$$


Правило Армихо (достаточное убывание)



Правильно Гольдштейна (достаточное убывание + существенное убывание)



Вольфа (достаточное убывание + кривизна)



Усиленное правило Вольфа (достаточное убывание + кривизна с двух сторон)

