Градиентный спуск

Методы оптимизации

Александр Безносиков

Московский физико-технический институт

17 сентября 2026



Градиентный спуск

Задача: найти решение безусловной оптимизации

$$\min_{x \in \mathbb{R}^d} f(x).$$

Алгоритм Градиентный спуск

Вход: стартовая точка $x^0 \in \mathbb{R}^d$, размеры шагов $\{\gamma_k\}_{k=0} > 0$, количество итераций K

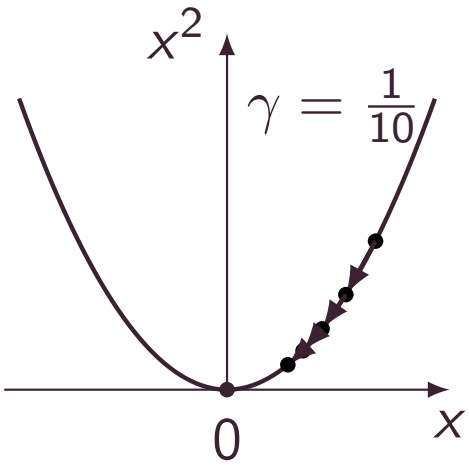
1: **for** $k = 0, 1, \ldots, K-1$ **do**

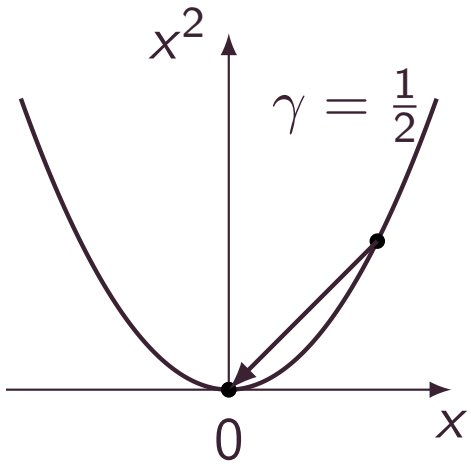
2: $\quad x^{k+1} = x^k - \gamma_k \nabla f(x^k)$

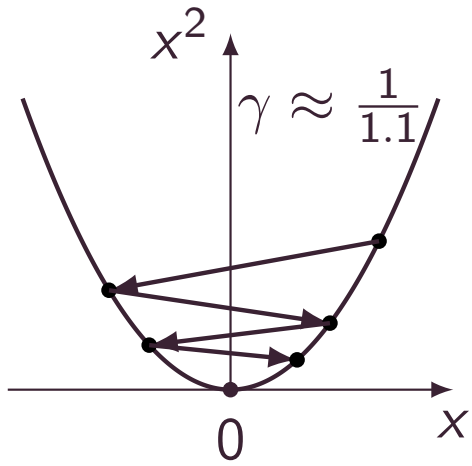
3: **end for**

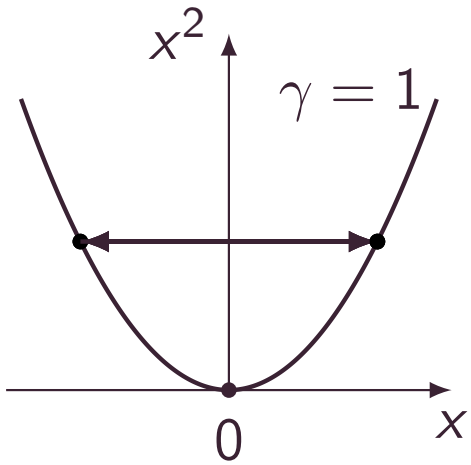
Выход: x^K

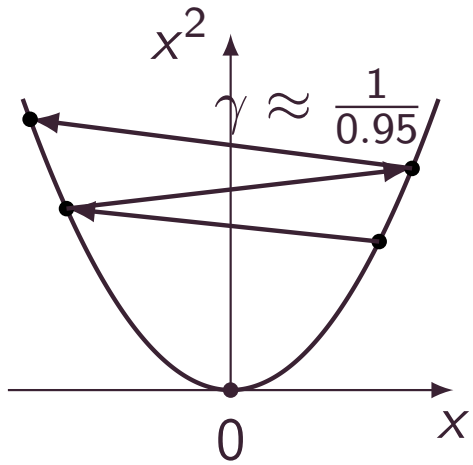
Зачем нужен шаг?











Сходимость μ–сильно выпуклых функций

Зная, что для сильно выпуклых функций решение единственно, попытаемся оценить, как меняется расстояние до него. Подставим итерацию:

$$\begin{aligned}\left\|x^{k+1}-x^*\right\|_2^2 &= \left\|x^k-\gamma_k\nabla f\left(x^k\right)-x^*\right\|_2^2 \\ &= \left\|x^k-x^*\right\|_2^2-2\gamma_k\left\langle\nabla f\left(x^k\right),x^k-x^*\right\rangle+\gamma_k^2\left\|\nabla f\left(x^k\right)\right\|_2^2.\end{aligned}$$

Сходимость μ–сильно выпуклых функций

Зная, что для сильно выпуклых функций решение единственно, попытаемся оценить, как меняется расстояние до него. Подставим итерацию:

$$\begin{aligned}\left\|x^{k+1} - x^*\right\|_2^2 &= \left\|x^k - \gamma_k \nabla f\left(x^k\right) - x^*\right\|_2^2 \\ &= \left\|x^k - x^*\right\|_2^2 - 2\gamma_k \left\langle \nabla f\left(x^k\right), x^k - x^* \right\rangle + \gamma_k^2 \left\|\nabla f\left(x^k\right)\right\|_2^2.\end{aligned}$$

Вопрос: что дальше?

Сходимость μ–сильно выпуклых функций

Зная, что для сильно выпуклых функций решение единственно, попытаемся оценить, как меняется расстояние до него. Подставим итерацию:

$$\begin{aligned}\left\|x^{k+1}-x^*\right\|_2^2 &= \left\|x^k-\gamma_k\nabla f\left(x^k\right)-x^*\right\|_2^2 \\ &= \left\|x^k-x^*\right\|_2^2 - 2\gamma_k\left\langle\nabla f\left(x^k\right),x^k-x^*\right\rangle + \gamma_k^2\left\|\nabla f\left(x^k\right)\right\|_2^2.\end{aligned}$$

Вопрос: что дальше? Воспользуемся условием оптимальности $\nabla f\left(x^*\right)=0$ и запишем:

$$\begin{aligned}\left\|x^{k+1}-x^*\right\|_2^2 &= \left\|x^k-x^*\right\|_2^2 - 2\gamma_k\left\langle\nabla f\left(x^k\right),x^k-x^*\right\rangle \\ &\quad + \gamma_k^2\left\|\nabla f\left(x^k\right)-\nabla f\left(x^*\right)\right\|_2^2.\end{aligned}$$

Сходимость μ–сильно выпуклых функций

Для точек x^k и x^* воспользуемся μ–сильной выпуклостью:

$$f^* \geq f\left(x^k\right) + \left\langle \nabla f\left(x^k\right), x^* - x^k \right\rangle + \frac{\mu}{2}\left\|x^k - x^*\right\|_2^2$$

и гладкостью:

$$\left\|\nabla f\left(x^k\right) - \nabla f\left(x^*\right)\right\|_2^2 \leq L^2\left\|x^k - x^*\right\|_2^2.$$

Сходимость μ–сильно выпуклых функций

Для точек x^k и x^* воспользуемся μ–сильной выпуклостью:

$$f^* \geq f\left(x^k\right) + \left\langle \nabla f\left(x^k\right), x^* - x^k \right\rangle + \frac{\mu}{2}\left\|x^k - x^*\right\|_2^2$$

и гладкостью:

$$\left\|\nabla f\left(x^k\right) - \nabla f\left(x^*\right)\right\|_2^2 \leq L^2\left\|x^k - x^*\right\|_2^2.$$

Тогда после подстановки неравенств, имеем:

$$\begin{aligned}\left\|x^{k+1} - x^*\right\|_2^2 \leq \left\|x^k - x^*\right\|_2^2 &+ 2\gamma_k\left(-\frac{\mu}{2}\left\|x^k - x^*\right\|_2^2 + f^* - f\left(x^k\right)\right) \\ &+ \gamma_k^2 L^2\left\|x^k - x^*\right\|_2^2 \\ &= \left(1 - \gamma_k\mu + \gamma_k^2 L^2\right)\left\|x^k - x^*\right\|_2^2 + 2\gamma_k\left(f^* - f\left(x^k\right)\right).\end{aligned}$$

Сходимость μ–сильно выпуклых функций

Откинем $f\left(x^k\right) \geq f^*$ в силу отрицательности последнего слагаемого:

$$\left\|x^{k+1} - x^*\right\|_2^2 \leq \left(1 - \gamma_k \mu + \gamma_k^2 L^2\right) \left\|x^k - x^*\right\|_2^2.$$

Вопрос: что делать дальше?

Сходимость μ–сильно выпуклых функций

Откинем $f\left(x^k\right) \geq f^*$ в силу отрицательности последнего слагаемого:

$$\left\|x^{k+1} - x^*\right\|_2^2 \leq \left(1 - \gamma_k\mu + \gamma_k^2 L^2\right)\left\|x^k - x^*\right\|_2^2.$$

Вопрос: что делать дальше? Хочется, чтобы расстояние до решения уменьшалось, а именно, $\left(1 - \gamma_k\mu + \gamma_k^2 L^2\right) < 1$, а лучше вообще найти $\operatorname{argmin}_{\gamma_k}\left(1 - \gamma_k\mu + \gamma_k^2 L^2\right)$. Как это сделать?

Сходимость μ–сильно выпуклых функций

Откинем $f\left(x^k\right) \geq f^*$ в силу отрицательности последнего слагаемого:

$$\left\|x^{k+1} - x^*\right\|_2^2 \leq \left(1 - \gamma_k\mu + \gamma_k^2 L^2\right)\left\|x^k - x^*\right\|_2^2.$$

Вопрос: что делать дальше? Хочется, чтобы расстояние до решения уменьшалось, а именно, $\left(1 - \gamma_k\mu + \gamma_k^2 L^2\right) < 1$, а лучше вообще найти $\operatorname{argmin}_{\gamma_k}\left(1 - \gamma_k\mu + \gamma_k^2 L^2\right)$. Как это сделать? Найдем минимум одномерной параболы: $\gamma_k^* = \frac{\mu}{2L^2}$. Получим

$$\left\|x^{k+1} - x^*\right\|_2^2 \leq \left(1 - \frac{\mu^2}{4L^2}\right)\left\|x^k - x^*\right\|_2^2.$$

Сходимость μ–сильно выпуклых функций

Запустим рекурсию:

$$\left\|x^K - x^*\right\|_2^2 \leq \left(1 - \frac{\mu^2}{4L^2}\right)^K \left\|x^0 - x^*\right\|_2^2.$$

Вопрос: какая это скорость сходимости?

Сходимость μ–сильно выпуклых функций

Запустим рекурсию:

$$\left\|x^K - x^*\right\|_2^2 \leq \left(1 - \frac{\mu^2}{4L^2}\right)^K \left\|x^0 - x^*\right\|_2^2.$$

Вопрос: какая это скорость сходимости? Линейная. А как получить оценку на число итераций?

Сходимость μ–сильно выпуклых функций

Запустим рекурсию:

$$\left\|x^K - x^*\right\|_2^2 \leq \left(1 - \frac{\mu^2}{4L^2}\right)^K \left\|x^0 - x^*\right\|_2^2.$$

Вопрос: какая это скорость сходимости? Линейная. А как получить оценку на число итераций?

$$\left\|x^K - x^*\right\|_2^2 \leq \left(1 - \frac{\mu^2}{4L^2}\right)^K \left\|x^0 - x^*\right\|_2^2 \leq \exp\left(-\frac{\mu^2}{4L^2} \cdot K\right) \left\|x^0 - x^*\right\|_2^2.$$

Сходимость μ–сильно выпуклых функций

Запустим рекурсию:

$$\left\|x^K - x^*\right\|_2^2 \leq \left(1 - \frac{\mu^2}{4L^2}\right)^K \left\|x^0 - x^*\right\|_2^2.$$

Вопрос: какая это скорость сходимости? Линейная. А как получить оценку на число итераций?

$$\left\|x^K - x^*\right\|_2^2 \leq \left(1 - \frac{\mu^2}{4L^2}\right)^K \left\|x^0 - x^*\right\|_2^2 \leq \exp\left(-\frac{\mu^2}{4L^2} \cdot K\right) \left\|x^0 - x^*\right\|_2^2.$$

Мы хотим гарантировать

$$\left\|x^K - x^*\right\|_2^2 \leq \exp\left(-\frac{\mu^2}{4L^2} \cdot K\right) \left\|x^0 - x^*\right\|_2^2 \leq \varepsilon^2.$$

Сходимость μ–сильно выпуклых функций

Тогда логарифмируем и получаем

$$K \geq \frac{4L^2}{\mu^2} \log \left(\frac{\|x^0 - x^*\|_2^2}{\varepsilon^2} \right).$$

Сходимость μ–сильно выпуклых функций

Тогда логарифмируем и получаем

$$K \geq \frac{4L^2}{\mu^2} \log \left(\frac{\|x^0 - x^*\|_2^2}{\varepsilon^2} \right).$$

Итого: Можно лучше. Пример того, как в получении верхних оценок можно «загрубить». Будем исправлять.

Сходимость μ–сильно выпуклых функций

Начинаем с применения итерации градиентного спуска и условия оптимальности $\nabla f\left(x^*\right) = 0$:

$$\begin{aligned}\left\|x^{k+1} - x^*\right\|_2^2 &= \left\|x^k - \gamma_k \nabla f\left(x^k\right) - x^*\right\|_2^2 \\ &= \left\|x^k - x^*\right\|_2^2 - 2\gamma_k \left\langle \nabla f\left(x^k\right), x^k - x^* \right\rangle + \gamma_k^2 \left\|\nabla f\left(x^k\right)\right\|_2^2 \\ &= \left\|x^k - x^*\right\|_2^2 + 2\gamma_k \left\langle \nabla f\left(x^k\right), x^* - x^k \right\rangle \\ &\quad + \gamma_k^2 \left\|\nabla f\left(x^k\right) - \nabla f\left(x^*\right)\right\|_2^2.\end{aligned}$$

Сходимость μ–сильно выпуклых функций

Начинаем с применения итерации градиентного спуска и условия оптимальности $\nabla f(x^*) = 0$:

$$\begin{aligned}\left\|x^{k+1} - x^*\right\|_2^2 &= \left\|x^k - \gamma_k \nabla f(x^k) - x^*\right\|_2^2 \\ &= \left\|x^k - x^*\right\|_2^2 - 2\gamma_k \left\langle \nabla f(x^k), x^k - x^* \right\rangle + \gamma_k^2 \left\|\nabla f(x^k)\right\|_2^2 \\ &= \left\|x^k - x^*\right\|_2^2 + 2\gamma_k \left\langle \nabla f(x^k), x^* - x^k \right\rangle \\ &\quad + \gamma_k^2 \left\|\nabla f(x^k) - \nabla f(x^*)\right\|_2^2.\end{aligned}$$

Для точек x^k и x^* воспользуемся μ–сильной выпуклостью:

$$f^* \geq f(x^k) + \left\langle \nabla f(x^k), x^* - x^k \right\rangle + \frac{\mu}{2}\left\|x^k - x^*\right\|_2^2.$$

Сходимость μ–сильно выпуклых функций

Воспользуемся не L–гладкостью, а теоремой с прошлой лекции:

$$\frac{1}{2L}\left\|\nabla f\left(x^k\right)-\nabla f\left(x^*\right)\right\|_2^2 \leq f\left(x^k\right)-f^*-\left\langle \nabla f\left(x^*\right), x^k-x^*\right\rangle.$$

Сходимость μ–сильно выпуклых функций

Воспользуемся не L–гладкостью, а теоремой с прошлой лекции:

$$\frac{1}{2L}\left\|\nabla f(x^k) - \nabla f(x^*)\right\|_2^2 \leq f(x^k) - f^* - \left\langle \nabla f(x^*), x^k - x^* \right\rangle.$$

Подставим неравенства:

$$\begin{aligned}
\left\|x^{k+1} - x^*\right\|_2^2 &\leq \left\|x^k - x^*\right\|_2^2 - 2\gamma_k\left(\frac{\mu}{2}\left\|x^k - x^*\right\|_2^2 + f(x^k) - f^*\right) \\
&\quad + \gamma_k^2\left\|\nabla f(x^k) - \nabla f(x^*)\right\|_2^2 \\
&\leq \left\|x^k - x^*\right\|_2^2 - 2\gamma_k\left(\frac{\mu}{2}\left\|x^k - x^*\right\|_2^2 + f(x^k) - f^*\right) \\
&\quad + 2\gamma_k^2 L\left(f(x^k) - f^* - \left\langle \nabla f(x^*), x^k - x^* \right\rangle\right) \\
&= (1 - \mu\gamma_k)\left\|x^k - x^*\right\|_2^2 + 2\gamma_k(\gamma_k L - 1)\left(f(x^k) - f^*\right).
\end{aligned}$$

Сходимость μ–сильно выпуклых функций

Заметим, что $f\left(x^k\right) \geq f^*$, тогда при $\gamma_k \leq \frac{1}{L}$, получаем:

$$\left\|x^{k+1} - x^*\right\|_2^2 \leq \left(1 - \mu\gamma_k\right)\left\|x^k - x^*\right\|_2^2.$$

Сходимость μ–сильно выпуклых функций

Заметим, что $f\left(x^k\right) \geq f^*$, тогда при $\gamma_k \leq \frac{1}{L}$, получаем:

$$\left\|x^{k+1} - x^*\right\|_2^2 \leq \left(1 - \mu\gamma_k\right)\left\|x^k - x^*\right\|_2^2.$$

Запустим рекурсию:

$$\left\|x^K - x^*\right\|_2^2 \leq \left(\prod_{k=0}^{K-1}\left(1 - \mu\gamma_k\right)\right)\left\|x^0 - x^*\right\|_2^2.$$

Сходимость μ–сильно выпуклых функций

Заметим, что $f\left(x^k\right) \geq f^*$, тогда при $\gamma_k \leq \frac{1}{L}$, получаем:

$$\left\|x^{k+1} - x^*\right\|_2^2 \leq \left(1 - \mu\gamma_k\right)\left\|x^k - x^*\right\|_2^2.$$

Запустим рекурсию:

$$\left\|x^K - x^*\right\|_2^2 \leq \left(\prod_{k=0}^{K-1}\left(1 - \mu\gamma_k\right)\right)\left\|x^0 - x^*\right\|_2^2.$$

При $\gamma_k = \frac{1}{L}$ получаем:

$$\left\|x^K - x^*\right\|_2^2 \leq \left(1 - \frac{\mu}{L}\right)^K \left\|x^0 - x^*\right\|_2^2 \implies K \geq \frac{L}{\mu}\log\left(\frac{\left\|x^0 - x^*\right\|_2^2}{\varepsilon^2}\right).$$

Сходимость μ–сильно выпуклых функций

Утверждение

Пусть выбрано значение шага $\gamma_k = \frac{1}{L}$. Тогда справедлива следующая оценка сходимости:

$$\left\|x^K - x^*\right\|_2^2 \leq \left(1 - \frac{\mu}{L}\right)^K \left\|x^0 - x^*\right\|_2^2.$$

Более того, чтобы добиться точности ε по аргументу достаточно

$$K = \mathcal{O}\left(\frac{L}{\mu} \log \frac{\left\|x^0 - x^*\right\|_2}{\varepsilon}\right) \quad \textit{итераций.}$$

В дальнейшем будем использовать $\mathcal{O}$–нотацию для того, чтобы опускать численные константы, так как нас интересует величина, зависящая от параметров задачи.

Сходимость выпуклых функций

Утверждение

Пусть задача безусловной оптимизации с L–гладкой целевой функцией f решается с помощью градиентного спуска. Тогда при $\gamma_k \in \left(0, \frac{2}{L}\right)$ справедливо, что $f\left(x^{k+1}\right) \leq f\left(x^k\right)$.

Сходимость выпуклых функций

Воспользуемся теоремой с прошлой лекции:

$$f\left(x^{k+1}\right) \leq f\left(x^k\right) + \left\langle \nabla f\left(x^k\right), x^{k+1} - x^k \right\rangle + \frac{L}{2}\left\|x^{k+1} - x^k\right\|_2^2.$$

Сходимость выпуклых функций

Воспользуемся теоремой с прошлой лекции:

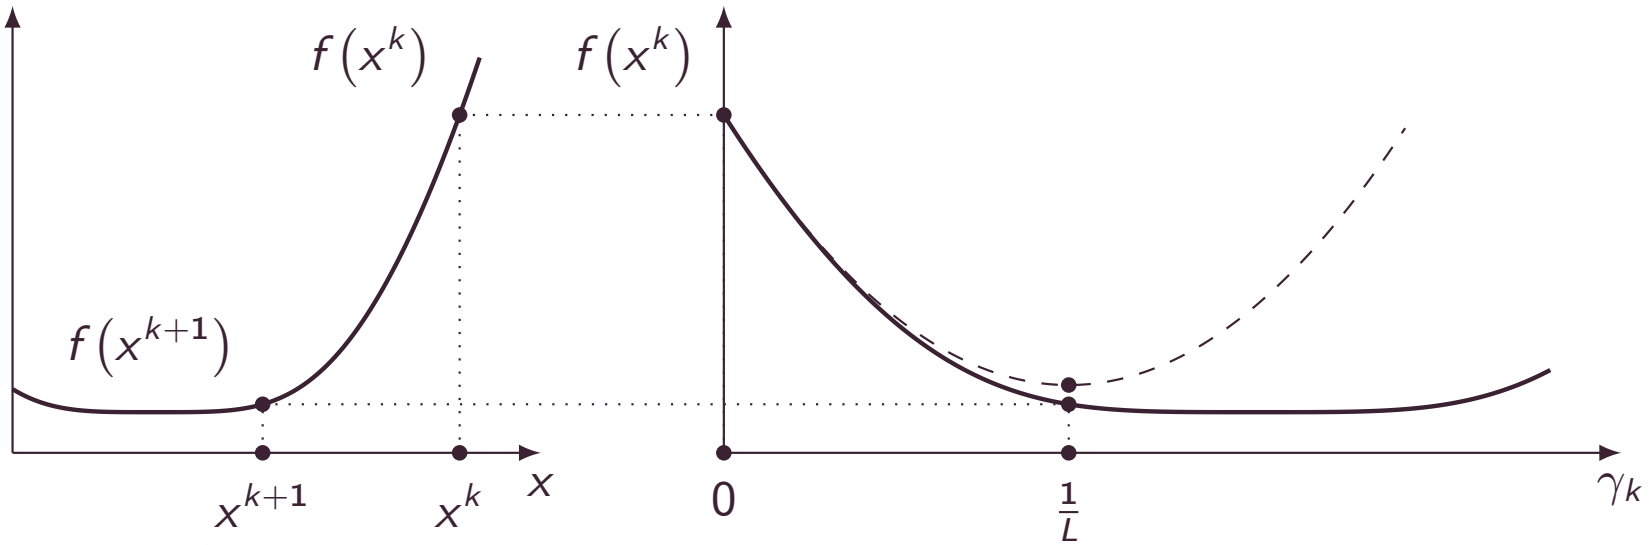
$$f\left(x^{k+1}\right) \leq f\left(x^k\right) + \left\langle \nabla f\left(x^k\right), x^{k+1} - x^k \right\rangle + \frac{L}{2}\left\|x^{k+1} - x^k\right\|_2^2.$$

Подставим итерационный шаг градиентного спуска:

$$\begin{aligned} f\left(x^{k+1}\right) &\leq f\left(x^k\right) - \gamma_k \left\|\nabla f\left(x^k\right)\right\|_2^2 + \frac{L\gamma_k^2}{2}\left\|\nabla f\left(x^k\right)\right\|_2^2 \\ &= f\left(x^k\right) - \gamma_k\left(1 - \frac{L\gamma_k}{2}\right)\left\|\nabla f\left(x^k\right)\right\|_2^2. \end{aligned}$$

Если $\gamma_k \in \left(0, \frac{2}{L}\right)$, то $f\left(x^{k+1}\right) \leq f\left(x^k\right)$.

Сходимость выпуклых функций



— $f(x)$

— $g(\gamma_k) = f(x^k - \gamma_k \nabla f(x^k))$

- - - $f(x^k) - \gamma_k \|\nabla f(x^k)\|_2^2 + \frac{L\gamma_k^2}{2} \|\nabla f(x^k)\|_2^2$

Сходимость выпуклых функций

Начнем доказательство с оценки, полученной в прошлом доказательстве, с $\mu = 0$:

$$\left\|x^{k+1} - x^*\right\|_2^2 \leq \left\|x^k - x^*\right\|_2^2 + 2\gamma_k\left(\gamma_k L - 1\right)\Big(f\left(x^k\right) - f^*\Big).$$

Сходимость выпуклых функций

Начнем доказательство с оценки, полученной в прошлом доказательстве, с $\mu = 0$:

$$\left\|x^{k+1} - x^*\right\|_2^2 \leq \left\|x^k - x^*\right\|_2^2 + 2\gamma_k(\gamma_k L - 1)\Big(f\left(x^k\right) - f^*\Big).$$

Потребуем, чтобы $2(\gamma_k L - 1) \leq -1$, тогда $\gamma_k \leq \frac{1}{2L}$ и:

$$\begin{aligned}\left\|x^{k+1} - x^*\right\|_2^2 &\leq \left\|x^k - x^*\right\|_2^2 + 2\gamma_k(\gamma_k L - 1)\Big(f\left(x^k\right) - f^*\Big) \\ &\leq \left\|x^k - x^*\right\|_2^2 - \gamma_k\Big(f\left(x^k\right) - f^*\Big).\end{aligned}$$

Сходимость выпуклых функций

Начнем доказательство с оценки, полученной в прошлом доказательстве, с $\mu = 0$:

$$\left\|x^{k+1} - x^*\right\|_2^2 \leq \left\|x^k - x^*\right\|_2^2 + 2\gamma_k(\gamma_k L - 1)\Big(f\left(x^k\right) - f^*\Big).$$

Потребуем, чтобы $2(\gamma_k L - 1) \leq -1$, тогда $\gamma_k \leq \frac{1}{2L}$ и:

$$\begin{aligned}\left\|x^{k+1} - x^*\right\|_2^2 &\leq \left\|x^k - x^*\right\|_2^2 + 2\gamma_k(\gamma_k L - 1)\Big(f\left(x^k\right) - f^*\Big) \\ &\leq \left\|x^k - x^*\right\|_2^2 - \gamma_k\Big(f\left(x^k\right) - f^*\Big).\end{aligned}$$

Перепишем неравенство:

$$\gamma_k\Big(f\left(x^k\right) - f^*\Big) \leq \left\|x^k - x^*\right\|_2^2 - \left\|x^{k+1} - x^*\right\|_2^2.$$

Сходимость выпуклых функций

Просуммируем по всем итерациям от 0 до $K-1$:

$$\sum_{k=0}^{K-1} \gamma_k \left(f\left(x^k\right) - f^* \right) \leq \sum_{k=0}^{K-1} \left(\left\|x^k - x^*\right\|_2^2 - \left\|x^{k+1} - x^*\right\|_2^2 \right)$$

$$= \left\|x^0 - x^*\right\|_2^2 - \left\|x^K - x^*\right\|_2^2 \leq \left\|x^0 - x^*\right\|_2^2.$$

Сходимость выпуклых функций

Просуммируем по всем итерациям от 0 до $K-1$:

$$\sum_{k=0}^{K-1} \gamma_k \left(f\left(x^k\right) - f^* \right) \leq \sum_{k=0}^{K-1} \left(\left\|x^k - x^*\right\|_2^2 - \left\|x^{k+1} - x^*\right\|_2^2 \right)$$
$$= \left\|x^0 - x^*\right\|_2^2 - \left\|x^K - x^*\right\|_2^2 \leq \left\|x^0 - x^*\right\|_2^2.$$

Воспользуемся Утверждением, из которого $f\left(x^K\right) \leq f\left(x^k\right)$:

$$\left(f\left(x^K\right) - f^* \right) \sum_{k=0}^{K-1} \gamma_k \leq \left\|x^0 - x^*\right\|_2^2 \implies f\left(x^K\right) - f^* \leq \frac{\left\|x^0 - x^*\right\|_2^2}{\sum\limits_{k=0}^{K-1} \gamma_k}.$$

Сходимость выпуклых функций

Утверждение

Пусть выбрано значение шага $\gamma_k = \frac{1}{2L}$. *Тогда справедлива следующая оценка сходимости:*

$$f\left(x^K\right) - f^* \leq \frac{2L\left\|x^0 - x^*\right\|_2^2}{K}.$$

Более того, чтобы добиться точности ε *по функции достаточно*

$$K = \mathcal{O}\left(\frac{L\left\|x^0 - x^*\right\|_2^2}{\varepsilon}\right) \quad \textit{итераций.}$$

Сходимость невыпуклых функций

Воспользуемся теоремой с прошлой лекции:

$$f\left(x^{k+1}\right) \leq f\left(x^k\right) + \left\langle \nabla f\left(x^k\right), x^{k+1} - x^k \right\rangle + \frac{L}{2}\left\|x^{k+1} - x^k\right\|_2^2.$$

Сходимость невыпуклых функций

Воспользуемся теоремой с прошлой лекции:

$$f\left(x^{k+1}\right) \leq f\left(x^k\right) + \left\langle \nabla f\left(x^k\right), x^{k+1} - x^k \right\rangle + \frac{L}{2}\left\|x^{k+1} - x^k\right\|_2^2.$$

Подставим итерационный шаг градиентного спуска:

$$\begin{aligned} f\left(x^{k+1}\right) &\leq f\left(x^k\right) - \gamma_k \left\|\nabla f\left(x^k\right)\right\|_2^2 + \frac{L\gamma_k^2}{2}\left\|\nabla f\left(x^k\right)\right\|_2^2 \\ &= f\left(x^k\right) - \gamma_k\left(1 - \frac{L\gamma_k}{2}\right)\left\|\nabla f\left(x^k\right)\right\|_2^2. \end{aligned}$$

Сходимость невыпуклых функций

Воспользуемся теоремой с прошлой лекции:

$$f\left(x^{k+1}\right) \leq f\left(x^k\right) + \left\langle \nabla f\left(x^k\right), x^{k+1} - x^k \right\rangle + \frac{L}{2}\left\|x^{k+1} - x^k\right\|_2^2.$$

Подставим итерационный шаг градиентного спуска:

$$\begin{aligned} f\left(x^{k+1}\right) &\leq f\left(x^k\right) - \gamma_k \left\|\nabla f\left(x^k\right)\right\|_2^2 + \frac{L\gamma_k^2}{2}\left\|\nabla f\left(x^k\right)\right\|_2^2 \\ &= f\left(x^k\right) - \gamma_k\left(1 - \frac{L\gamma_k}{2}\right)\left\|\nabla f\left(x^k\right)\right\|_2^2. \end{aligned}$$

Возьмем $\gamma_k = \frac{1}{L}$. Тогда

$$f\left(x^{k+1}\right) \leq f\left(x^k\right) - \frac{1}{2L}\left\|\nabla f\left(x^k\right)\right\|_2^2.$$

Сходимость невыпуклых функций

После небольших перестановок получаем:

$$\left\|\nabla f\left(x^k\right)\right\|_2^2 \leq 2L\left(f\left(x^k\right) - f\left(x^{k+1}\right)\right).$$

Сходимость невыпуклых функций

После небольших перестановок получаем:

$$\left\|\nabla f\left(x^k\right)\right\|_2^2 \leq 2L\Big(f\left(x^k\right) - f\left(x^{k+1}\right)\Big).$$

Суммируя по всем итерациям от 0 до $K-1$ и считая, что f ограничена снизу ($f^* = \inf f > -\infty$), получаем:

$$\sum_{k=0}^{K-1}\left\|\nabla f\left(x^k\right)\right\|_2^2 \leq 2L\Big(f\left(x^0\right) - f\left(x^K\right)\Big) \leq 2L\big(f\left(x^0\right) - f^*\big).$$

Сходимость невыпуклых функций

После небольших перестановок получаем:

$$\left\|\nabla f\left(x^k\right)\right\|_2^2 \leq 2L\Big(f\left(x^k\right) - f\left(x^{k+1}\right)\Big).$$

Суммируя по всем итерациям от 0 до $K-1$ и считая, что f ограничена снизу ($f^* = \inf f > -\infty$), получаем:

$$\sum_{k=0}^{K-1}\left\|\nabla f\left(x^k\right)\right\|_2^2 \leq 2L\Big(f\left(x^0\right) - f\left(x^K\right)\Big) \leq 2L\big(f\left(x^0\right) - f^*\big).$$

Усредним по K:

$$\frac{1}{K}\sum_{k=0}^{K-1}\left\|\nabla f\left(x^k\right)\right\|_2^2 \leq \frac{2L\big(f\left(x^0\right) - f^*\big)}{K}.$$

Сходимость невыпуклых функций

Вопрос: как выбирать точку?

Сходимость невыпуклых функций

Вопрос: как выбирать точку?

- Равномерный случайный выбор $\hat{x}^K$ из $x^0, \ldots, x^{K-1}$:

$$\mathbb{E}\left[\left\|\nabla f\left(\hat{x}^K\right)\right\|_2^2\right] = \frac{1}{K}\sum_{k=0}^{K-1}\left\|\nabla f\left(x^k\right)\right\|_2^2 \leq \frac{2L\left(f\left(x^0\right) - f^*\right)}{K};$$

Сходимость невыпуклых функций

Вопрос: как выбирать точку?

- Равномерный случайный выбор $\hat{x}^K$ из $x^0, \ldots, x^{K-1}$:

$$\mathbb{E}\left[\left\|\nabla f\left(\hat{x}^K\right)\right\|_2^2\right] = \frac{1}{K}\sum_{k=0}^{K-1}\left\|\nabla f\left(x^k\right)\right\|_2^2 \leq \frac{2L\left(f\left(x^0\right) - f^*\right)}{K};$$

- Выбор точки $\hat{x}^K$ с минимальным по норме градиентом:

$$\left\|\nabla f\left(\hat{x}^K\right)\right\|_2^2 = \min_{k \in 0, K-1}\left\|\nabla f\left(x^k\right)\right\|_2^2 \leq \frac{1}{K}\sum_{k=0}^{K-1}\left\|\nabla f\left(x^k\right)\right\|_2^2 \leq \frac{2L\left(f\left(x^0\right) - f^*\right)}{K}.$$

Сходимость невыпуклых функций

Вопрос: как выбирать точку?

- Равномерный случайный выбор $\hat{x}^K$ из $x^0, \ldots, x^{K-1}$:

$$\mathbb{E}\left[\left\|\nabla f\left(\hat{x}^K\right)\right\|_2^2\right] = \frac{1}{K}\sum_{k=0}^{K-1}\left\|\nabla f\left(x^k\right)\right\|_2^2 \leq \frac{2L\left(f\left(x^0\right) - f^*\right)}{K};$$

- Выбор точки $\hat{x}^K$ с минимальным по норме градиентом:

$$\left\|\nabla f\left(\hat{x}^K\right)\right\|_2^2 = \min_{k \in 0, K-1}\left\|\nabla f\left(x^k\right)\right\|_2^2 \leq \frac{1}{K}\sum_{k=0}^{K-1}\left\|\nabla f\left(x^k\right)\right\|_2^2 \leq \frac{2L\left(f\left(x^0\right) - f^*\right)}{K}.$$

В любом случае получаем сублинейную сходимость.

Сходимость невыпуклых функций

Теорема

Пусть задача безусловной оптимизации с L–гладкой целевой функцией f решается с помощью градиентного спуска. Тогда при $\gamma_k = \frac{1}{L}$ справедлива следующая оценка сходимости:

$$\left\|\nabla f\left(\hat{x}^K\right)\right\|_2^2 \leq \frac{2L\left(f\left(x^0\right) - f^*\right)}{K},$$

где $\hat{x}^K$ — специально выбранная точка из $\{x^k\}$. Более того, чтобы добиться точности ε по норме градиента $\left(\left\|\nabla f\left(\hat{x}^K\right)\right\|_2 \leq \varepsilon\right)$, достаточно

$$K = \mathcal{O}\left(\frac{L\left(f\left(x^0\right) - f^*\right)}{\varepsilon^2}\right) \quad \text{итераций.}$$

Линейный поиск значения L

В доказательстве Утверждения для выпуклой функции мы получали оценку на значение функции f на следующей итерации:

$$f\left(x^{k+1}\right) \leq f\left(x^k\right) + \underbrace{\left(\frac{L\gamma^2}{2} - \gamma\right)}_{\to \min} \left\|\nabla f\left(x^k\right)\right\|_2^2 = \left[\gamma = \frac{1}{L}\right]$$

$$= f\left(x^k\right) - \frac{1}{2L}\left\|\nabla f\left(x^k\right)\right\|_2^2.$$

Линейный поиск значения L

В доказательстве Утверждения для выпуклой функции мы получали оценку на значение функции f на следующей итерации:

$$f\left(x^{k+1}\right) \leq f\left(x^k\right) + \underbrace{\left(\frac{L\gamma^2}{2} - \gamma\right)}_{\to \min} \left\|\nabla f\left(x^k\right)\right\|_2^2 = \left[\gamma = \frac{1}{L}\right]$$

$$= f\left(x^k\right) - \frac{1}{2L}\left\|\nabla f\left(x^k\right)\right\|_2^2.$$

Из оценки выше сразу же появляется идея для поиска L и шага $\frac{1}{L}$: увеличиваем L в ρ раз, пока условие выше не выполнится.

Линейный поиск значения L

Алгоритм Градиентный спуск с линейным поиском L

Вход: стартовая точка $x^0 \in \mathbb{R}^d$, начальное значение $L_0 > 0$, параметр $\rho > 1$, число итераций K

for $k = 0, 1, \ldots, K-1$ **do**
  $L_{k+1} = \frac{1}{\rho} \cdot L_k$
  $x^{k+1} = x^k - \frac{1}{L_{k+1}} \nabla f\left(x^k\right)$
  while $f\left(x^{k+1}\right) > f\left(x^k\right) - \frac{1}{2L_{k+1}} \left\|\nabla f\left(x^k\right)\right\|_2^2$ **do**
    $L_{k+1} = \rho \cdot L_{k+1}$
    $x^{k+1} = x^k - \frac{1}{L_{k+1}} \nabla f\left(x^k\right)$
  end while
end for

Выход: x^K

Степенной шаг

В качестве простой альтернативы можно использовать убывающий с номером итерации шаг:

$$\gamma_k := \frac{\gamma}{\delta + (ak + b)^p}, \ \gamma, \delta, a, b, p > 0.$$

Наиболее часто применяются на практике $\gamma_k = \frac{1}{k+1}$ и $\gamma_k = \frac{1}{\sqrt{k+1}}$.

Наискорейший спуск

Итерация градиентного спуска выглядит следующим образом:

$$x^{k+1} = x^k - \gamma_k \nabla f\left(x^k\right).$$

Наискорейший спуск

Итерация градиентного спуска выглядит следующим образом:

$$x^{k+1} = x^k - \gamma_k \nabla f\left(x^k\right).$$

Посмотрим на значение целевой функции после сделанного шага как на функцию от одного аргумента γ_k:

$$\phi(\gamma_k) := f\left(x^k - \gamma_k \nabla f\left(x^k\right)\right).$$

Наискорейший спуск

Итерация градиентного спуска выглядит следующим образом:

$$x^{k+1} = x^k - \gamma_k \nabla f\left(x^k\right).$$

Посмотрим на значение целевой функции после сделанного шага как на функцию от одного аргумента γ_k:

$$\phi(\gamma_k) := f\left(x^k - \gamma_k \nabla f\left(x^k\right)\right).$$

Поскольку стоит задача минимизации f, то будем выбирать шаг γ_k так, чтобы минимизировать значение функции $\phi(\gamma_k)$.

Наискорейший спуск

Итерация градиентного спуска выглядит следующим образом:

$$x^{k+1} = x^k - \gamma_k \nabla f\left(x^k\right).$$

Посмотрим на значение целевой функции после сделанного шага как на функцию от одного аргумента γ_k:

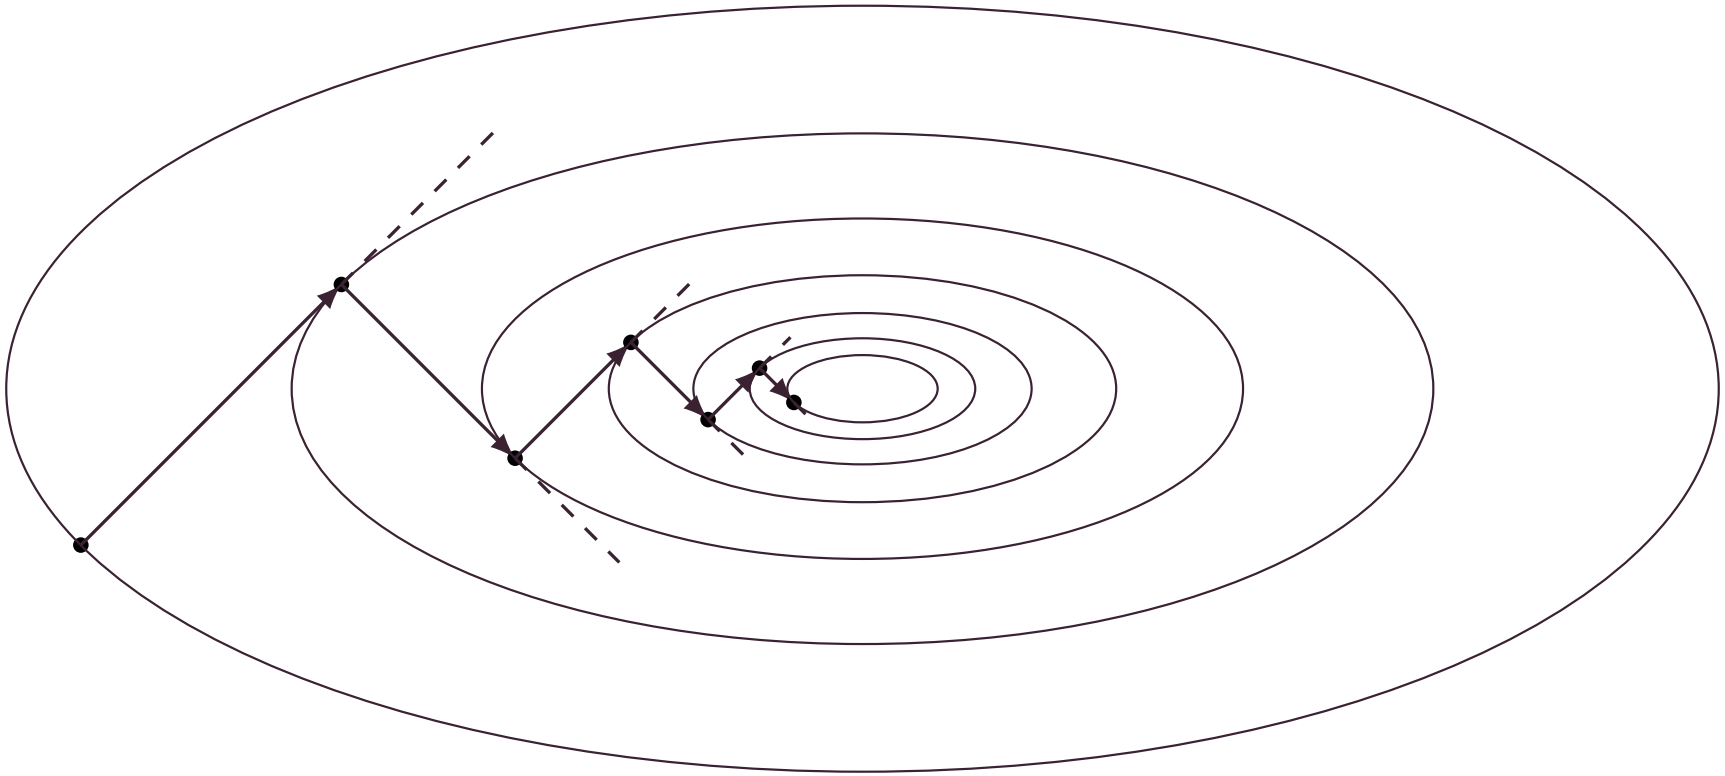
$$\phi(\gamma_k) := f\left(x^k - \gamma_k \nabla f\left(x^k\right)\right).$$

Поскольку стоит задача минимизации f, то будем выбирать шаг γ_k так, чтобы минимизировать значение функции $\phi(\gamma_k)$. Получим важное свойство шага, выпишем необходимое условие оптимума:

$$\phi'(\gamma_k^*) = \left.\frac{\partial f\left(x^k - \gamma_k \nabla f\left(x^k\right)\right)}{\partial \gamma_k}\right|_{\gamma_k = \gamma_k^*} = -\left\langle \nabla f\left(x^k - \gamma_k^* \nabla f\left(x^k\right)\right), \nabla f\left(x^k\right)\right\rangle$$

$$= -\left\langle \nabla f\left(x^{k+1}\right), \nabla f\left(x^k\right)\right\rangle = 0.$$

Наискорейший спуск



Шаг Поляка–Шора

В ходе доказательства Теоремы о сходимости градиентного спуска для гладких выпуклых функций мы получили неравенство:

$$\left\|x^{k+1} - x^*\right\|_2^2 \leq \left\|x^k - x^*\right\|_2^2 - 2\gamma_k\left(f\left(x^k\right) - f^*\right) + \gamma_k^2\left\|\nabla f\left(x^k\right)\right\|_2^2.$$

Шаг Поляка–Шора

В ходе доказательства Теоремы о сходимости градиентного спуска для гладких выпуклых функций мы получили неравенство:

$$\left\|x^{k+1} - x^*\right\|_2^2 \leq \left\|x^k - x^*\right\|_2^2 - 2\gamma_k(f\left(x^k\right) - f^*) + \gamma_k^2\left\|\nabla f\left(x^k\right)\right\|_2^2.$$

Попробуем выбрать γ_k так, чтобы минимизировать верхнюю оценку. Для этого найдем производную по γ_k и приравняем ее к нулю:

$$-2\left(f\left(x^k\right) - f^*\right) + 2\gamma_k^*\left\|\nabla f\left(x^k\right)\right\|_2^2 = 0.$$

Шаг Поляка–Шора

В ходе доказательства Теоремы о сходимости градиентного спуска для гладких выпуклых функций мы получили неравенство:

$$\left\|x^{k+1} - x^*\right\|_2^2 \leq \left\|x^k - x^*\right\|_2^2 - 2\gamma_k(f\left(x^k\right) - f^*) + \gamma_k^2\left\|\nabla f\left(x^k\right)\right\|_2^2.$$

Попробуем выбрать γ_k так, чтобы минимизировать верхнюю оценку. Для этого найдем производную по γ_k и приравняем ее к нулю:

$$-2\left(f\left(x^k\right) - f^*\right) + 2\gamma_k^*\left\|\nabla f\left(x^k\right)\right\|_2^2 = 0.$$

Отсюда получаем оптимальное значение шага, минимизирующее данную оценку:

$$\gamma_k^* = \frac{f\left(x^k\right) - f^*}{\left\|\nabla f\left(x^k\right)\right\|_2^2}.$$

Шаг Поляка–Шора

В общем виде шаг Поляка–Шора записывается с параметром $\alpha > 0$:

$$\gamma_k^* := \frac{f\left(x^k\right) - f^*}{\alpha \left\| \nabla f\left(x^k\right) \right\|_2^2}.$$

Вопрос: Зачем?

Шаг Поляка–Шора

В общем виде шаг Поляка–Шора записывается с параметром $\alpha > 0$:

$$\gamma_k^* := \frac{f\left(x^k\right) - f^*}{\alpha \left\| \nabla f\left(x^k\right) \right\|_2^2}.$$

Вопрос: Зачем? Значение функции в оптимуме часто неизвестно, поэтому в формуле вместо f^* используют некоторую нижнюю оценку. При использовании оценки параметр α позволяет корректировать шаг в зависимости от точности оценки минимума.

Стратегия бэктрекинга для подбора размера шага

Введем в рассмотрение $\phi(\gamma_k) = f\left(x^k + \gamma_k h^k\right)$, где h^k — направление убывания, то есть $\left\langle \nabla f\left(x^k\right), h^k \right\rangle < 0$, также рассмотрим некоторые константы β_1, β_2, удовлетворяющие условию $0 < \beta_1 < \beta_2 < 1$.
Рассмотрим эвристики.

- **Условие достаточного убывания**:

$$f\left(x^{k+1}\right) \leq f\left(x^k\right) + \beta_1 \gamma_k \left\langle \nabla f\left(x^k\right), h^k \right\rangle \implies \phi(\gamma_k) \leq \phi(0) + \beta_1 \gamma_k \phi'(0).$$

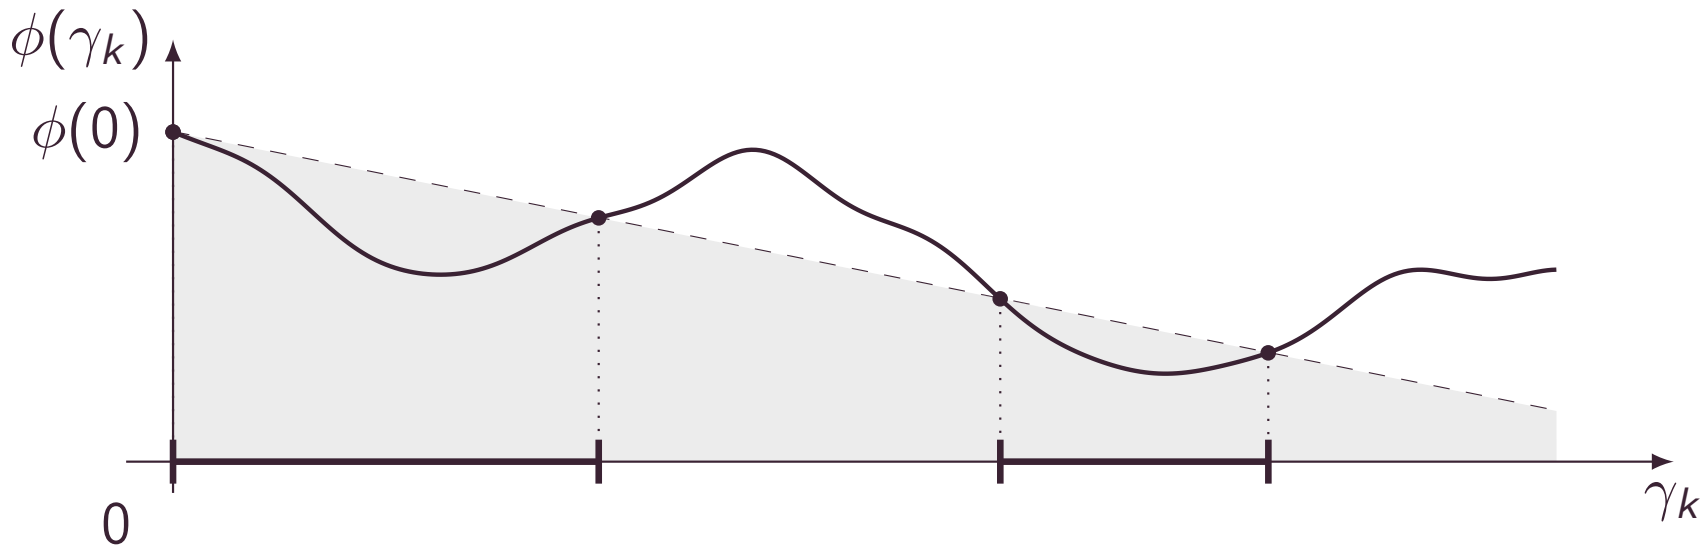
- **Условие существенного убывания**:

$$f\left(x^{k+1}\right) \geq f\left(x^k\right) + \beta_2 \gamma_k \left\langle \nabla f\left(x^k\right), h^k \right\rangle \implies \phi(\gamma_k) \geq \phi(0) + \beta_2 \gamma_k \phi'(0).$$

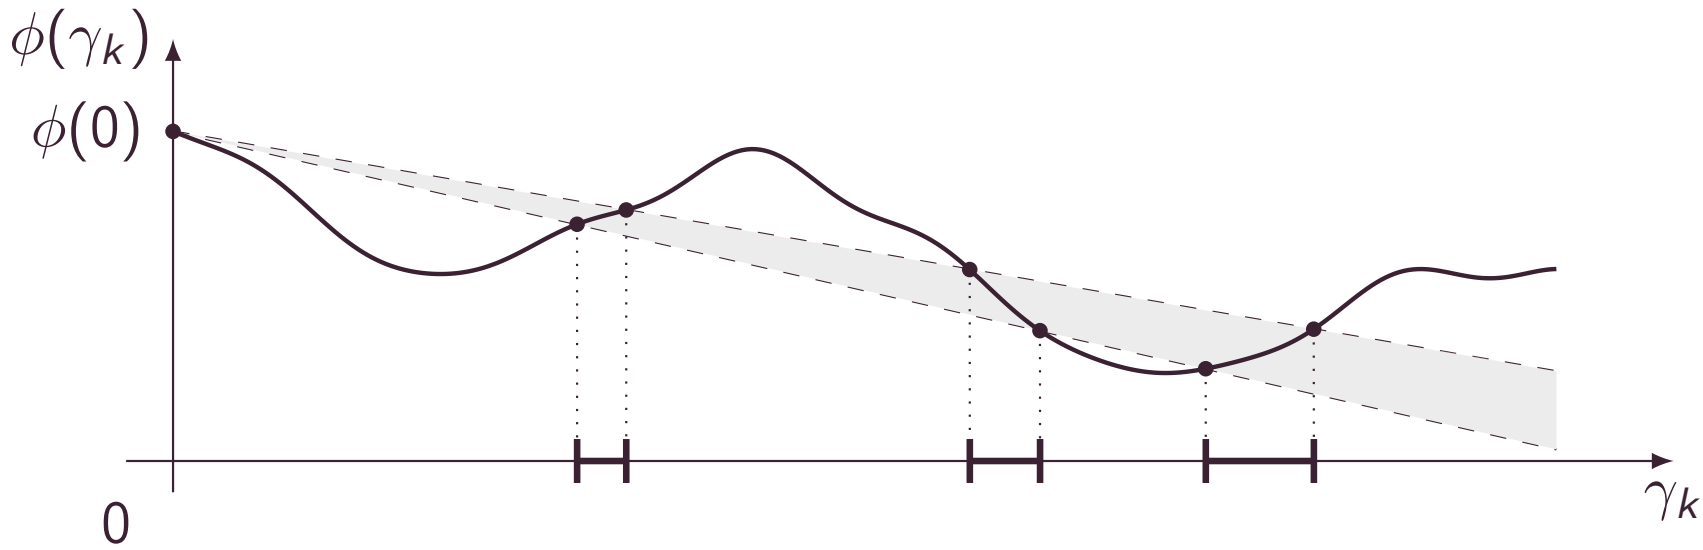
- **Условие кривизны**:

$$\left\langle \nabla f\left(x^{k+1}\right), h^k \right\rangle \geq \beta_2 \left\langle \nabla f\left(x^k\right), h^k \right\rangle \implies \phi'(\gamma_k) \geq \beta_2 \phi'(0).$$

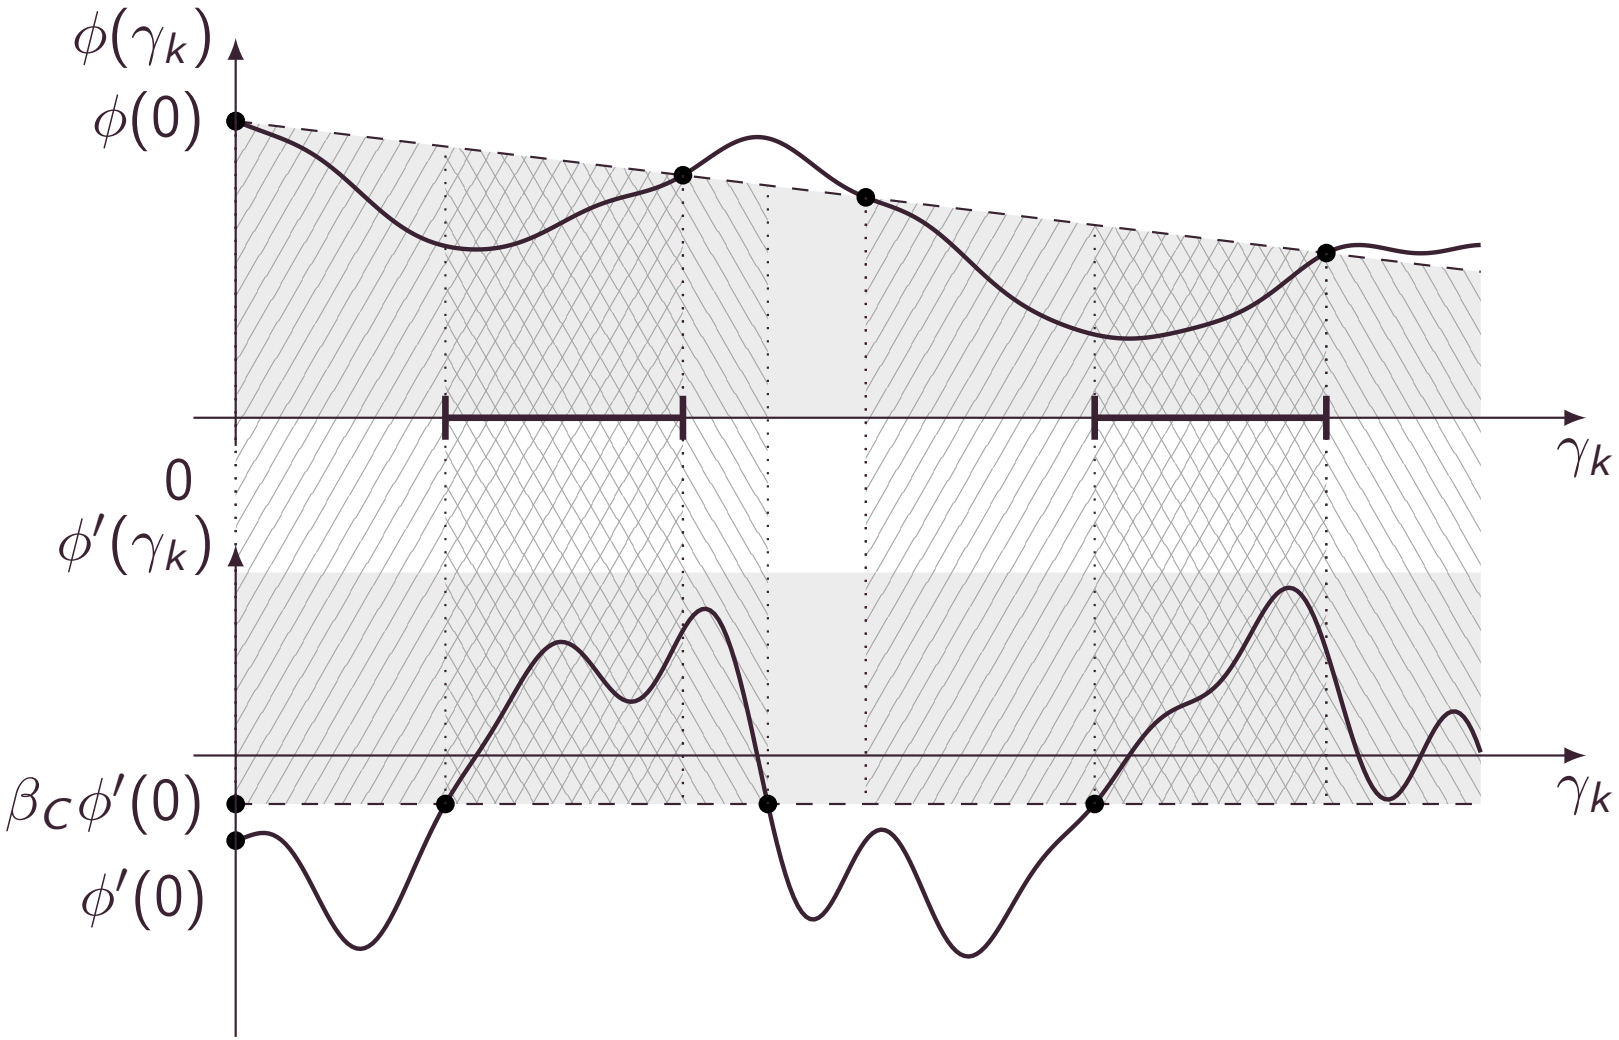
Правило Армихо (достаточное убывание)



Правило Гольдштейна (достаточное убывание + существенное убывание)



Правило Вольфа (достаточное убывание + кривизна)



Усиленное правило Вольфа (достаточное убывание + кривизна с двух сторон)

