

Л1 Ускоренные и оптимальные методы

В Параграфе ?? была доказана сходимость градиентного спуска для L -гладких и μ -сильно выпуклых задач. В ней было показано, что для получения ε -решения по аргументу необходимо совершить $\mathcal{O}\left(\frac{L}{\mu} \log \frac{\|x^0 - x^*\|_2}{\varepsilon}\right)$ оракульных вызовов. Логичный вопрос — хорошая ли это оценка, или её можно улучшить? Обсудим это в этом параграфе.

Л1.1 Метод тяжёлого шарика

Первое предложение по усовершенствованию градиентного спуска — использовать память с предыдущих итераций, добавив к алгоритму «инерцию». Такую эвристику Б.Т. Поляк в 1964 году предложил в методе тяжёлого шарика [6]:

Алгоритм Л1.1 Метод тяжёлого шарика


Вход: стартовая точка $x^0 = x^{-1} \in \mathbb{R}^d$, размеры шагов $\{\gamma_k\}_{k=0} > 0$, моменты $\{\tau_k\}_{k=0} \in [0, 1]$, количество итераций K

1: **for** $k = 0, 1, \dots, K - 1$ **do**


2: $x^{k+1} = x^k - \gamma_k \nabla f(x^k) + \tau_k (x^k - x^{k-1})$

3: **end for**

Выход: x^K



(а) Градиентный спуск.



(б) Метод тяжёлого шарика с $\tau = 0.9$.

Рис. Л1.1: Сравнение 6 шагов траекторий градиентного спуска и метода тяжёлого шарика с постоянным шагом $\gamma = 0.1$ при минимизации квадратичной функции $f(x) = \frac{1}{2} \langle x, Ax \rangle$, где $A = \text{diag}(1, 5)$. Эллипсы соответствуют уровням функции. На рисунке справа черным пунктиром показано направление градиента, серым пунктиром — инерция с прошлого шага.

У такой модели есть несколько плюсов. Во-первых, у метода понятная физика и интуиция: направления шага на новой итерации не должно сильно расходиться с направлением, в котором двигались ранее. Во-вторых, этот метод легок в имплементации: мы должны дополнительно хранить только координаты предыдущего состояния, а при вычислении нового просто добавлять слагаемое, отвечающее за «моментум». Однако у такого метода есть и ряд минусов. Помимо подбора шага, теперь необходимо подбирать параметр τ_k , который отвечает за инерцию, хотя обычно его берут близким к единице. Кроме того, мы должны найти ответ на исходный вопрос — лучше ли теоретические оценки сходимости? Для начала, рассмотрим оценки для метода на квадратичной задаче оптимизации.

Теорема Л1.1 (Теорема 3 из [6]). Пусть имеется квадратичная функция $f : \mathbb{R}^d \rightarrow \mathbb{R}$:

$$f(x) = \frac{1}{2} \langle x, Ax \rangle - \langle b, x \rangle,$$

где A — матрица с положительными собственными числами на отрезке $[\mu, L]$. Пусть задача безусловной оптимизации (??) решается методом тяжёлого шарика (Алгоритм Л1.1). Тогда при

$$\gamma_k = \gamma = \frac{4}{(\sqrt{L} + \sqrt{\mu})^2}, \quad \tau_k = \tau = \left(\frac{\sqrt{L} - \sqrt{\mu}}{\sqrt{L} + \sqrt{\mu}} \right)^2$$

справедлива следующая оценка сходимости:

$$\|x^K - x^*\|_2 \leq \sqrt{2} \cdot \left(\frac{\sqrt{L}}{\sqrt{L} + \sqrt{\mu}} \right)^K \|x^0 - x^*\|_2.$$

Более того, чтобы добиться точности ε по аргументу ($\|x^K - x^*\|_2 \leq \varepsilon$), необходимо

$$K = \mathcal{O} \left(\sqrt{\frac{L}{\mu}} \log \frac{\|x^0 - x^*\|_2}{\varepsilon} \right) \text{ итераций.}$$

Доказательство. Функция f является μ -сильно выпуклой (Упражнение ??), поэтому решение единственное (Теорема ??). И так как метод тяжёлого шарика использует в итерации две точки, то модифицируем критерий сходимости и будем рассматривать не только последнюю точку, но и предыдущую. Для этого перепишем метод тяжёлого шарика в векторной форме:

$$\begin{pmatrix} x^{k+1} \\ x^k \end{pmatrix} = \begin{pmatrix} (1+\tau)I_d & -\tau I_d \\ I_d & 0 \end{pmatrix} \begin{pmatrix} x^k \\ x^{k-1} \end{pmatrix} + \begin{pmatrix} -\gamma \nabla f(x^k) \\ 0 \end{pmatrix}. \quad (\text{Л1.1})$$

Введём вектор отклонения от решения: $e^k = x^k - x^*$ и заметим, что для квадратичной функции $f(x) = \frac{1}{2} \langle x, Ax \rangle - \langle b, x \rangle$ градиент $\nabla f(x) = Ax - b$. В точке минимума x^* градиент обнуляется: $Ax^* = b$, поэтому:

$$\nabla f(x^k) = Ax^k - b = A(x^k - x^*) = Ae^k.$$

Тогда (Л1.1) можно переписать как

$$\begin{pmatrix} e^{k+1} \\ e^k \end{pmatrix} = \begin{pmatrix} (1+\tau)I_d - \gamma A & -\tau I_d \\ I_d & 0 \end{pmatrix} \begin{pmatrix} e^k \\ e^{k-1} \end{pmatrix}.$$

Это задаёт рекуррентное соотношение с матрицей итераций

$$\hat{A} = \begin{pmatrix} (1+\tau)I_d - \gamma A & -\tau I_d \\ I_d & 0 \end{pmatrix}.$$

Запустим рекурсию:

$$\begin{pmatrix} e^K \\ e^{K-1} \end{pmatrix} = \hat{A}^K \begin{pmatrix} e^0 \\ e^{-1} \end{pmatrix}$$

и оценим норму $\begin{pmatrix} e^K \\ e^{K-1} \end{pmatrix}$:

$$\left\| \begin{pmatrix} e^K \\ e^{K-1} \end{pmatrix} \right\|_2 = \left\| \hat{A}^K \begin{pmatrix} e^0 \\ e^{-1} \end{pmatrix} \right\|_2 \leq \|\hat{A}^K\|_2 \left\| \begin{pmatrix} e^0 \\ e^{-1} \end{pmatrix} \right\|_2.$$

Здесь мы воспользовались свойством из Замечания ??.

Теперь нам необходимо оценить $\|\hat{A}^K\|_2$. Воспользуемся неравенством Гельфанда (Задача 1 Лекции 37 из [7]): для любого положительного δ найдётся K такое, что $\|\hat{A}^K\|_2 \leq (\rho(\hat{A}) + \delta)^K$, где $\rho(\hat{A})$ — спектральный радиус матрицы $\hat{A}$. Мы возьмём $\delta = \frac{\sqrt{\mu}}{\sqrt{L} + \sqrt{\mu}}$.

Оценим спектральный радиус матрицы $\hat{A}$. Так как A симметрична, то её можно диагонализировать (Теорема Параграфа 6 Лекции 20 из [7]):

$$A = U \Lambda U^\top, \text{ где } \Lambda = \text{diag}(\lambda_1, \dots, \lambda_d), \quad U^\top U = I_d.$$

Тогда заметим, что

$$\hat{A} = \begin{pmatrix} U & 0 \\ 0 & U \end{pmatrix} \begin{pmatrix} (1 + \tau)I_d - \gamma\Lambda & -\tau I_d \\ I_d & 0 \end{pmatrix} \begin{pmatrix} U^\top & 0 \\ 0 & U^\top \end{pmatrix}.$$

Спектр центральной матрицы совпадает со спектром матрицы $\hat{A}$, так как ортогональные преобразования не меняют спектр матрицы (Теорема Параграфа 6 Лекции 29 из [7]). Заметим, что перестановка строк и столбцов не меняет спектр, тогда спектр $\hat{A}$ совпадает со спектром $\tilde{A}$:

$$\tilde{A} = \text{diag}(T_1, \dots, T_d), \quad T_i = \begin{pmatrix} 1 + \tau_k - \gamma_k \lambda_i & -\tau_k \\ 1 & 0 \end{pmatrix}.$$

Тогда спектральный радиус матрицы $\hat{A}$ равен

$$\rho(\hat{A}) = \max_{i=1, d} \rho(T_i).$$

Найдём собственные числа u матрицы T_i по характеристическому уравнению:

$$\det \begin{pmatrix} 1 + \tau - \gamma \lambda_i - u & -\tau \\ 1 & -u \end{pmatrix} = 0,$$

что даёт:

$$u^2 - u(1 + \tau - \gamma \lambda_i) + \tau = 0.$$

Это квадратное уравнение имеет корни

$$u_{1,2} = \frac{(1 + \tau - \gamma \lambda_i) \pm \sqrt{(1 + \tau - \gamma \lambda_i)^2 - 4\tau}}{2}.$$

При выборе параметров:

$$\gamma = \frac{4}{(\sqrt{L} + \sqrt{\mu})^2}, \quad \tau = \left(\frac{\sqrt{L} - \sqrt{\mu}}{\sqrt{L} + \sqrt{\mu}} \right)^2,$$

получаем, что

$$u_{1,2} = \frac{(L + \mu - 2\lambda_i) \pm 2\sqrt{(L - \lambda_i)(\mu - \lambda_i)}}{(\sqrt{L} + \sqrt{\mu})^2} = \frac{(\sqrt{L - \lambda_i} \pm i\sqrt{\lambda_i - \mu})^2}{(\sqrt{L} + \sqrt{\mu})^2}.$$

Здесь мы воспользовались тем, что $\lambda_i \in [\mu, L]$. Тогда

$$|u_1| = |u_2| = \frac{L - \mu}{(\sqrt{L} + \sqrt{\mu})^2} = \frac{\sqrt{L} - \sqrt{\mu}}{\sqrt{L} + \sqrt{\mu}},$$

Получаем, что

$$\rho(\hat{A}) = \frac{\sqrt{L} - \sqrt{\mu}}{\sqrt{L} + \sqrt{\mu}}.$$

Тогда

$$\left\| \begin{pmatrix} e^K \\ e^{K-1} \end{pmatrix} \right\|_2 \leq \left(\frac{\sqrt{L} - \sqrt{\mu}}{\sqrt{L} + \sqrt{\mu}} + \frac{\sqrt{\mu}}{\sqrt{L} + \sqrt{\mu}} \right)^K \left\| \begin{pmatrix} e^0 \\ e^{-1} \end{pmatrix} \right\|_2,$$

откуда получаем,

$$\|x^K - x^*\|_2 \leq \left\| \begin{pmatrix} e^K \\ e^{K-1} \end{pmatrix} \right\|_2 \leq \sqrt{2} \left(\frac{\sqrt{L}}{\sqrt{L} + \sqrt{\mu}} \right)^K \|x^0 - x^*\|_2.$$

Воспользуемся тем, что $\mu \leq L$, и применим неравенство (??):

$$\begin{aligned} \|x^K - x^*\|_2 &\leq \sqrt{2} \left(\frac{\sqrt{L}}{\sqrt{L} + \sqrt{\mu}} \right)^K \|x^0 - x^*\|_2 = \sqrt{2} \left(1 - \frac{\sqrt{\mu}}{\sqrt{L} + \sqrt{\mu}} \right)^K \|x^0 - x^*\|_2 \\ &\leq \sqrt{2} \left(1 - \frac{\sqrt{\mu}}{2\sqrt{L}} \right)^K \|x^0 - x^*\|_2 \leq \sqrt{2} \exp \left(-\frac{1}{2} \sqrt{\frac{\mu}{L}} K \right) \|x^0 - x^*\|_2. \end{aligned}$$

Ограничим правую часть неравенства ε :

$$\|x^K - x^*\|_2 \leq \sqrt{2} \exp \left(-\frac{1}{2} \sqrt{\frac{\mu}{L}} K \right) \|x^0 - x^*\|_2 \leq \varepsilon.$$

Тогда после логарифмирования и преобразования получаем:

$$K \geq 2\sqrt{\frac{L}{\mu}} \log \left(\frac{\sqrt{2} \|x^0 - x^*\|_2}{\varepsilon} \right) = \mathcal{O} \left(\sqrt{\frac{L}{\mu}} \log \frac{\|x^0 - x^*\|_2}{\varepsilon} \right).$$

■

Таким образом, на квадратичной задаче метод тяжёлого шарика действительно оказывается быстрее метода градиентного спуска: у градиентного спуска оценка на количество итераций $\mathcal{O} \left(\frac{L}{\mu} \log \frac{\|x^0 - x^*\|_2}{\varepsilon} \right)$, а у метода тяжёлого шарика $\mathcal{O} \left(\sqrt{\frac{L}{\mu}} \log \frac{\|x^0 - x^*\|_2}{\varepsilon} \right)$.

Но будет ли метод тяжёлого шарика быстрее на более общем классе задач, а именно на μ -сильно выпуклых и L -гладких функциях? Оказывается, что нет. Приведем пример такой μ -сильно выпуклой L -гладкой функции, что при выборе параметров метода, как на квадратичной задаче, метод тяжёлого шарика не сходится вовсе.

Пример Л1.1 (Секция 4.6 из [2]). Рассмотрим функцию

$$f(x) = \begin{cases} \frac{25}{2}x^2 + 12, & x < 1, \\ \frac{1}{2}x^2 + 24x, & 1 \leq x < 2, \\ \frac{25}{2}x^2 - 24x + 48, & x \geq 2, \end{cases}$$

её градиент

$$\nabla f(x) = \begin{cases} 25x, & x < 1, \\ x + 24, & 1 \leq x < 2, \\ 25x - 24, & x \geq 2. \end{cases}$$

Константы гладкости и сильной выпуклости для f : $\mu = 1$, $L = 25$. Однако если выбрать начальное приближение $x_0 \in [3.07, 3.46]$, метод тяжёлого шарика с параметрами из Теоремы Л11.1

$$\gamma_k = \frac{4}{(\sqrt{L} + \sqrt{\mu})^2} = \frac{1}{9}, \quad \tau_k = \left(\frac{\sqrt{L} - \sqrt{\mu}}{\sqrt{L} + \sqrt{\mu}} \right)^2 = \frac{4}{9}$$

не сходится, а порождает предельный цикл, как показано на Рисунке Л11.2.




Рис. Л11.2: Иллюстрация предельного цикла в методе тяжёлого шарика на кусочно-гладкой функции $f(x)$.

Действительно, итерация метода тяжёлого шарика в точке x^k выглядит следующим образом:

$$x^{k+1} = \frac{13}{9}x^k - \frac{4}{9}x^{k-1} - \frac{1}{9}\nabla f(x^k).$$

И тогда точки $q = -\frac{2208}{1225}$, $p = \frac{792}{1225}$, $r = \frac{2592}{1225}$ образуют предельный цикл, как показано на Рисунке Л11.2. При этом, если выбрать начальное приближение $x_0 \in [3.07, 3.46]$, то траектория метода будет асимптотически стремиться к предельному циклу.

Таким образом, мы убедились, что оптимальные параметры, подобранные для квадратичной задачи, не гарантируют сходимости на более общем классе μ -сильно выпуклых и L -гладких функций. Для этого класса метод тяжёлого шарика даёт ускорение $\sim \mathcal{O}\left(\sqrt{\frac{L}{\mu}} \log \frac{\|x^0 - x^*\|_2}{\varepsilon}\right)$ только в случае локальной сходимости [6], когда стартовая точка x^0 уже достаточно близка к решению x^* . Если же рассматривать глобальную сходимость, то есть из произвольной точки x^0 , то при других значениях гиперпараметров можно получить оценки совпадающие с оценками для градиентного спуска: $\mathcal{O}\left(\frac{L}{\mu} \log \frac{\|x^0 - x^*\|_2}{\varepsilon}\right)$. Справиться с этой проблемой должен следующий метод.

Л1.2 Ускоренный градиентный метод

В 1983 году Ю.Е. Нестеров предложил ускоренный градиентный метод [5]:

Алгоритм Л1.2 Ускоренный градиентный метод (Метод Нестерова)

Вход: стартовые точки $x^0 = x^{-1} \in \mathbb{R}^d$, размеры шагов $\{\gamma_k\}_{k=0} > 0$, моменты $\{\tau_k\}_{k=0} \in [0, 1]$, количество итераций K

- 1: **for** $k = 0, 1, \dots, K - 1$ **do**
- 2: $y^k = x^k + \tau_k(x^k - x^{k-1})$
- 3: $x^{k+1} = y^k - \gamma_k \nabla f(y^k)$
- 4: **end for**

Выход: x^K

Этот алгоритм с первого взгляда очень похож на метод тяжёлого шарика. Однако если подробно написать его итерацию:

$$x^{k+1} = x^k + \tau_k(x^k - x^{k-1}) - \gamma_k \nabla f(x^k + \tau_k(x^k - x^{k-1})),$$

то можно заметить, что градиент, как бы, считается из «будущего» состояния. Разницу между градиентным спуском, методом тяжёлого шарика и методом Нестерова можно увидеть на Рисунках Л1.3 и Л1.4. Как можно заметить, метод Нестерова приближается к оптимуму быстрее. Эта техника позволяет добиться $\mathcal{O}\left(\sqrt{\frac{L}{\mu}} \log \frac{f(x^0) - f(x^*)}{\varepsilon}\right)$ вызовов оракула для ε -сходимости по функции.






Рис. Л1.3: Сравнение шага методов, серым пунктиром показан $\tau_k(x^k - x^{k-1})$.

Теорема Л1.2 (Теорема 1 из [1]). Пусть задача безусловной оптимизации (??) с L -гладкой μ -сильно выпуклой целевой функцией f решается с помощью ускоренного градиентного метода (Алгоритм Л1.2). Тогда при $\gamma_k = \frac{1}{L}$, $\tau_k = \frac{\sqrt{L} - \sqrt{\mu}}{\sqrt{L} + \sqrt{\mu}}$ справедлива следующая оценка сходимости:

$$f(x^K) - f^* \leq \left(1 - \sqrt{\frac{\mu}{L}}\right)^K \cdot L \|x^0 - x^*\|_2^2.$$



(а) Метод тяжёлого шарика с $\tau = 0.9$.



(б) Метод Нестерова с $\tau = 0.9$.

Рис. Л11.4: Сравнение траекторий: метод тяжёлого шарика и метод Нестерова с $\gamma = 0.1$.

Более того, чтобы добиться точности ε по аргументу ($\|x^K - x^*\|_2 \leq \varepsilon$), необходимо

$$K = \mathcal{O}\left(\sqrt{\frac{L}{\mu}} \log\left(\frac{\|x^0 - x^*\|_2}{\varepsilon}\right)\right) \text{ итераций.}$$

Доказательство. Подставим в итерацию ускоренного градиентного метода γ_k и τ_k из условия:

$$\begin{aligned} y^k &= x^k + \frac{\sqrt{L} - \sqrt{\mu}}{\sqrt{L} + \sqrt{\mu}}(x^k - x^{k-1}), \\ x^{k+1} &= y^k - \frac{1}{L} \nabla f(y^k). \end{aligned}$$

Введём *функцию Ляпунова*, которая используется в теории устойчивости:

$$V_k := f(x^k) - f^* + \frac{L}{2} \|x^k - x^* - \rho^2(x^{k-1} - x^*)\|_2^2,$$

где $\rho^2 = 1 - \sqrt{\frac{\mu}{L}}$. Покажем, что для неё выполняется $V_{k+1} \leq \rho^2 V_k$.

Для выпуклой L -гладкой функции f запишем неравенство (??) из Теоремы ?? для точек x^{k+1}, y^k :

$$\begin{aligned} V_{k+1} &= f(x^{k+1}) - f^* + \frac{L}{2} \|x^{k+1} - x^* - \rho^2(x^k - x^*)\|_2^2 \\ &\leq f(y^k) + \langle \nabla f(y^k), x^{k+1} - y^k \rangle + \frac{L}{2} \|x^{k+1} - y^k\|_2^2 - f^* \\ &\quad + \frac{L}{2} \|x^{k+1} - x^* - \rho^2(x^k - x^*)\|_2^2. \end{aligned}$$

Подставляем формулу итерации $x^{k+1} - y^k = -\frac{1}{L} \nabla f(y^k)$:

$$\begin{aligned} V_{k+1} &\leq f(y^k) + \left\langle \nabla f(y^k), -\frac{1}{L} \nabla f(y^k) \right\rangle + \frac{L}{2} \left\| -\frac{1}{L} \nabla f(y^k) \right\|_2^2 - f^* \\ &\quad + \frac{L}{2} \|x^{k+1} - x^* - \rho^2(x^k - x^*)\|_2^2 \\ &= f(y^k) - \frac{1}{2L} \|\nabla f(y^k)\|_2^2 - f^* + \frac{L}{2} \|x^{k+1} - x^* - \rho^2(x^k - x^*)\|_2^2. \end{aligned}$$

Прибавим и вычтем $\rho^2(f(y^k) - f^* + \langle \nabla f(y^k), x^k - y^k \rangle)$:

$$\begin{aligned}
V_{k+1} &\leq f(y^k) - f^* - \frac{1}{2L} \|\nabla f(y^k)\|_2^2 + \frac{L}{2} \|x^{k+1} - x^* - \rho^2(x^k - x^*)\|_2^2 \\
&\quad + \rho^2(f(y^k) - f^* + \langle \nabla f(y^k), x^k - y^k \rangle) - \rho^2(f(y^k) - f^* + \langle \nabla f(y^k), x^k - y^k \rangle) \\
&= \underbrace{\rho^2(f(y^k) - f^* + \langle \nabla f(y^k), x^k - y^k \rangle)}_{(1)} - \rho^2 \langle \nabla f(y^k), x^k - y^k \rangle \\
&\quad + (1 - \rho^2)(f(y^k) - \underbrace{f^*}_{(2)} - \langle \nabla f(y^k), y^k \rangle) + (1 - \rho^2) \langle \nabla f(y^k), y^k \rangle \\
&\quad - \frac{1}{2L} \|\nabla f(y^k)\|_2^2 + \frac{L}{2} \|x^{k+1} - x^* - \rho^2(x^k - x^*)\|_2^2.
\end{aligned}$$

Далее воспользуемся μ -сильной выпуклостью f (Определение ??) для точек x^k, y^k и x^*, y^k :

$$\begin{aligned}
f(y^k) &\leq f(x^k) + \langle \nabla f(y^k), y^k - x^k \rangle - \frac{\mu}{2} \|x^k - y^k\|_2^2, \\
f^* &\geq f(y^k) + \langle \nabla f(y^k), x^* - y^k \rangle + \frac{\mu}{2} \|y^k - x^*\|_2^2.
\end{aligned}$$

Подставляем эти два неравенства в (1) и (2) соответственно и получаем:

$$\begin{aligned}
V_{k+1} &\leq \rho^2 \left(f(x^k) - f^* - \frac{\mu}{2} \|x^k - y^k\|_2^2 \right) - \rho^2 \langle \nabla f(y^k), x^k - y^k \rangle \\
&\quad - (1 - \rho^2) \frac{\mu}{2} \|y^k - x^*\|_2^2 + (1 - \rho^2) \langle \nabla f(y^k), y^k - x^* \rangle \\
&\quad - \frac{1}{2L} \|\nabla f(y^k)\|_2^2 + \frac{L}{2} \|x^{k+1} - x^* - \rho^2(x^k - x^*)\|_2^2 \\
&= \rho^2 V_k + R_k,
\end{aligned}$$

где введено обозначение

$$\begin{aligned}
R_k &= -\frac{\rho^2 \mu}{2} \|x^k - y^k\|_2^2 - (1 - \rho^2) \frac{\mu}{2} \|y^k - x^*\|_2^2 + \langle \nabla f(y^k), y^k - x^* - \rho^2(x^k - x^*) \rangle \\
&\quad - \frac{1}{2L} \|\nabla f(y^k)\|_2^2 + \frac{L}{2} \|x^{k+1} - x^* - \rho^2(x^k - x^*)\|_2^2 \\
&\quad - \frac{\rho^2 L}{2} \|x^k - x^* - \rho^2(x^{k-1} - x^*)\|_2^2.
\end{aligned}$$

Докажем, что $R_k \leq 0$. Подставим x^{k+1} и преобразуем:

$$\begin{aligned}
R_k &= -\frac{\rho^2 \mu}{2} \|x^k - y^k\|_2^2 - \sqrt{\frac{\mu}{L}} \frac{\mu}{2} \|y^k - x^*\|_2^2 + \langle \nabla f(y^k), y^k - x^* - \rho^2(x^k - x^*) \rangle \\
&\quad - \frac{1}{2L} \|\nabla f(y^k)\|_2^2 + \frac{L}{2} \left\| y^k - \frac{1}{L} \nabla f(y^k) - x^* - \rho^2(x^k - x^*) \right\|_2^2 \\
&\quad - \frac{\rho^2 L}{2} \|x^k - x^* - \rho^2(x^{k-1} - x^*)\|_2^2 \\
&= -\frac{\rho^2 \mu}{2} \|x^k - y^k\|_2^2 - \sqrt{\frac{\mu}{L}} \frac{\mu}{2} \|y^k - x^*\|_2^2 + \frac{L}{2} \|y^k - x^* - \rho^2(x^{k-1} - x^*)\|_2^2 \\
&\quad - \frac{\rho^2 L}{2} \|x^k - x^* - \rho^2(x^{k-1} - x^*)\|_2^2.
\end{aligned}$$

Подставим y^k :

$$\begin{aligned}
R_k &= -\frac{\rho^2 \mu}{2} \|x^k - y^k\|_2^2 \\
&\quad - \sqrt{\frac{\mu}{L}} \frac{\mu}{2(\sqrt{L} + \sqrt{\mu})^2} \|2\sqrt{L}(x^k - x^*) - (\sqrt{L} - \sqrt{\mu})(x^{k-1} - x^*)\|_2^2 \\
&\quad + \frac{L}{2(\sqrt{L} + \sqrt{\mu})^2} \left\| \left(\sqrt{L} + \frac{\mu}{\sqrt{L}} \right) (x^k - x^*) - (\sqrt{L} - \sqrt{\mu})(x^{k-1} - x^*) \right\|_2^2 \\
&\quad - \frac{\sqrt{L} - \sqrt{\mu}}{2\sqrt{L}} \| \sqrt{L}(x^k - x^*) - (\sqrt{L} - \sqrt{\mu})(x^{k-1} - x^*) \|_2^2.
\end{aligned}$$

Раскроем квадраты норм и преобразуем:

$$\begin{aligned}
R_k &= -\frac{\rho^2 \mu}{2} \|x^k - y^k\|_2^2 \\
&\quad - \sqrt{\frac{\mu}{L}} \frac{\rho^2 L}{2} \left(\frac{\sqrt{L} - \sqrt{\mu}}{\sqrt{L} + \sqrt{\mu}} \right)^2 \left(\|x^k - x^*\|_2^2 - 2\langle x^k - x^*, x^{k-1} - x^* \rangle + \|x^{k-1} - x^*\|_2^2 \right) \\
&= -\frac{\rho^2 \mu}{2} \|x^k - y^k\|_2^2 - \sqrt{\frac{\mu}{L}} \frac{\rho^2 L}{2} \left(\frac{\sqrt{L} - \sqrt{\mu}}{\sqrt{L} + \sqrt{\mu}} \right)^2 \|x^k - x^{k-1}\|_2^2 \\
&= -\frac{\rho^2 \mu}{2} \|x^k - y^k\|_2^2 - \sqrt{\frac{\mu}{L}} \frac{\rho^2 L}{2} \|x^k - y^k\|_2^2 = -\frac{\rho^2 L}{2} \left(\frac{\mu}{L} + \sqrt{\frac{\mu}{L}} \right) \|x^k - y^k\|_2^2 \leq 0.
\end{aligned}$$

Таким образом, $V_{k+1} \leq \rho^2 V_k$. Тогда $V_K \leq \rho^{2K} V_0$.

Заметим, что $f(x^K) - f^* \leq V_K$. Покажем, что $V_0 \leq L \|x^0 - x^*\|_2^2$, используем свойство гладкости (??):

$$\begin{aligned}
V_0 &= f(x^0) - f^* + \frac{L}{2} \|x^0 - x^*\|_2^2 - \rho^2 \|x^0 - x^*\|_2^2 \\
&= f(x^0) - f^* + \frac{L}{2} (1 - \rho^2) \|x^0 - x^*\|_2^2 \\
&\leq \langle \nabla f(x^*), x^0 - x^* \rangle + \frac{L}{2} \|x^0 - x^*\|_2^2 + \frac{L}{2} \frac{\mu}{L} \|x^0 - x^*\|_2^2 \leq L \|x^0 - x^*\|_2^2.
\end{aligned}$$

Резюмируя, получаем:

$$f(x^K) - f^* \leq \left(1 - \sqrt{\frac{\mu}{L}}\right)^K \cdot L \|x^0 - x^*\|_2^2.$$

Найдём оценку на число итераций:

$$f(x^K) - f^* \leq \left(1 - \sqrt{\frac{\mu}{L}}\right)^K L \|x^0 - x^*\|_2^2 \leq \exp\left(-\sqrt{\frac{\mu}{L}} \cdot K\right) L \|x^0 - x^*\|_2^2.$$

Запишем определение μ -сильной выпуклости (Определение ??) в точке x^* :

$$f(x^K) \geq f^* + \langle \nabla f(x^*), x^K - x^* \rangle + \frac{\mu}{2} \|x^K - x^*\|_2^2 = f^* + \frac{\mu}{2} \|x^K - x^*\|_2^2.$$

Воспользуемся им, чтобы гарантировать, что

$$\|x^K - x^*\|_2^2 \leq \frac{2}{\mu} (f(x^K) - f^*) \leq \exp\left(-\sqrt{\frac{\mu}{L}} \cdot K\right) \frac{2L \|x^0 - x^*\|_2^2}{\mu} \leq \varepsilon^2.$$

Тогда логарифмируем и получаем

$$K \geq 2\sqrt{\frac{2L}{\mu}} \log \left(\sqrt{\frac{L}{\mu}} \frac{\|x^0 - x^*\|_2}{\varepsilon} \right).$$

■

Таким образом, для сильно выпуклого случая ускоренный градиентный метод действительно показывает превосходство над методом градиентного спуска.




Рис. Л1.5: Сравнение методов GD (Алгоритм ??), Heavy Ball (Алгоритм Л1.1) и AGD (Алгоритм Л1.2) при неоптимальном подборе параметров на квадратичной задаче.

Однако что же можно сказать про просто выпуклый случай? Для него формулируется следующая теорема о сходимости.

Теорема Л1.3 (Теорема 6 из [4]). Пусть задача безусловной оптимизации (??) с L -гладкой выпуклой целевой функцией f решается с помощью ускоренного градиентного метода (Алгоритм Л1.2). Тогда при $\gamma_k = \gamma \leq \frac{1}{L}$, $\tau_k = \frac{k}{k+3}$ справедлива следующая оценка сходимости:

$$f(x^K) - f^* \leq \frac{2\|x^0 - x^*\|_2^2}{\gamma(K+2)^2}.$$

Доказательство. Обозначим $a_k = \frac{k+2}{2}$, $k \geq 0$ и $a_0 = 0$, тогда

$$\tau_k = \frac{k}{k+3} = \frac{\frac{k+2}{2} - 1}{\frac{k+3}{2}} = \frac{a_k - 1}{a_{k+1}}. \quad (\text{Л1.2})$$

Введём вектор $p^k = (a_k - 1)(x^k - x^{k-1})$. Из формулы обновления y_k выразим:

$$x^{k-1} = \frac{(1 + \tau_k)x^k - y^k}{\tau_k}.$$

Подставим это в формулу для p^k :

$$p^k = (a_k - 1) \left(x^k - \frac{(1 + \tau_k)x^k - y^k}{\tau_k} \right) = a_{k+1}(y^k - x^k).$$

Последнее верно в силу (Л1.2). Пользуясь формулой итерации метода и (Л1.2), имеем:

$$\begin{aligned} p^{k+1} + x^{k+1} &= (a_{k+1} - 1)(x^{k+1} - x^k) + x^{k+1} \\ &= a_{k+1}x^{k+1} - (a_{k+1} - 1)x^k \\ &= a_{k+1}(y^k - \gamma \nabla f(y^k)) - (a_{k+1} - 1)x^k \\ &= a_{k+1}(y^k - x^k) + x^k - a_{k+1}\gamma \nabla f(y^k) \\ &= p^k + x^k - a_{k+1}\gamma \nabla f(y^k). \end{aligned}$$

Оценим $\|p^{k+1} + x^{k+1} - x^*\|_2^2$, где x^* — одна из точек минимума:

$$\begin{aligned} \|p^{k+1} + x^{k+1} - x^*\|_2^2 &= \|p^k + x^k - x^* - a_{k+1}\gamma \nabla f(y^k)\|_2^2 \\ &= \|p^k + x^k - x^*\|_2^2 - 2a_{k+1}\gamma \langle p^k + x^k - x^*, \nabla f(y^k) \rangle \\ &\quad + a_{k+1}^2 \gamma^2 \|\nabla f(y^k)\|_2^2. \end{aligned}$$

Разобьём скалярное произведение:

$$\begin{aligned} \langle p^k + x^k - x^*, \nabla f(y^k) \rangle &= \langle a_{k+1}(y^k - x^k) + x^k - x^*, \nabla f(y^k) \rangle \\ &= (a_{k+1} - 1) \langle y^k - x^k, \nabla f(y^k) \rangle + \langle y^k - x^*, \nabla f(y^k) \rangle. \end{aligned}$$

Применим выпуклость в точках y^k, x^* и y^k, x^k :

$$\begin{aligned} \langle y^k - x^*, \nabla f(y^k) \rangle &\geq f(y^k) - f^*, \\ \langle y^k - x^k, \nabla f(y^k) \rangle &\geq f(y^k) - f(x^k). \end{aligned}$$

Тогда:

$$\begin{aligned} \langle p^k + x^k - x^*, \nabla f(y^k) \rangle &\geq (a_{k+1} - 1)(f(y^k) - f(x^k)) + (f(y^k) - f^*) \\ &= a_{k+1}(f(y^k) - f^*) - (a_{k+1} - 1)(f(x^k) - f^*) \quad (\text{Л1.3}) \\ &\geq a_{k+1}(f(y^k) - f^*) - \frac{a_k^2}{a_{k+1}}(f(x^k) - f^*). \end{aligned}$$

Последний переход получен благодаря неравенству $(a_{k+1} - 1)a_{k+1} \leq a_k^2$, которое проверяется прямой подстановкой определения a_k . Теперь получим соотношение между $f(y^k)$ и $f(x^{k+1})$, применив свойство выпуклых гладких функций (??):

$$\begin{aligned} f(x^{k+1}) &\leq f(y^k) + \langle \nabla f(y^k), x^{k+1} - y^k \rangle + \frac{L}{2} \|x^{k+1} - y^k\|_2^2 \\ &= f(y^k) + \gamma \left(-1 + \frac{\gamma L}{2} \right) \|\nabla f(y^k)\|_2^2. \end{aligned}$$

Или, переставив слагаемые:

$$f(y^k) \geq f(x^{k+1}) - \gamma \left(-1 + \frac{\gamma L}{2} \right) \|\nabla f(y^k)\|_2^2.$$

Подставим в неравенство (Л1.3):

$$\begin{aligned} \langle p^k + x^k - x^*, \nabla f(y^k) \rangle &\geq a_{k+1}(f(x^{k+1}) - f^*) - \frac{a_k^2}{a_{k+1}}(f(x^k) - f^*) \\ &\quad - a_{k+1}\gamma \left(-1 + \frac{\gamma L}{2} \right) \|\nabla f(y^k)\|_2^2. \end{aligned}$$

Подставим в оценку $\|p^{k+1} + x^{k+1} - x^*\|_2^2$:

$$\begin{aligned} \|p^{k+1} + x^{k+1} - x^*\|_2^2 &\leq \|p^k + x^k - x^*\|_2^2 \\ &\quad - 2a_{k+1}^2\gamma(f(x^{k+1}) - f^*) + 2a_k^2\gamma(f(x^k) - f^*) \\ &\quad + a_{k+1}^2\gamma^2(\gamma L - 2)\|\nabla f(y^k)\|_2^2 + a_{k+1}^2\gamma^2\|\nabla f(y^k)\|_2^2 \\ &\leq \|p^k + x^k - x^*\|_2^2 \\ &\quad + 2a_k^2\gamma(f(x^k) - f^*) - 2\gamma a_{k+1}^2(f(x^{k+1}) - f^*) \\ &\quad + a_{k+1}^2\gamma^2(\gamma L - 1)\|\nabla f(y^k)\|_2^2 \\ &\leq \|p^k + x^k - x^*\|_2^2 \\ &\quad + 2a_k^2\gamma(f(x^k) - f^*) - 2a_{k+1}^2\gamma(f(x^{k+1}) - f^*). \end{aligned}$$

Слагаемое с градиентом оценено сверху нулем, поскольку $\gamma \leq \frac{1}{L}$. Введём функцию Ляпунова:

$$V_k := \|p_k + x^k - x^*\|_2^2 + 2a_k^2\gamma(f(x^k) - f^*).$$

Будем считать, что γ постоянна, тогда получаем, что $V_{k+1} \leq V_k$ — то есть функция убывает по k . Тогда:

$$2a_K^2\gamma(f(x^K) - f^*) \leq V_K \leq V_0 = \|x^0 - x^*\|_2^2,$$

откуда

$$f(x^K) - f^* \leq \frac{\|x^0 - x^*\|_2^2}{2a_K^2\gamma} = \frac{2\|x^0 - x^*\|_2^2}{\gamma(K+2)^2}.$$

■

Утверждение Л1.1. Пусть задача удовлетворяет условиям Теоремы Л1.3 и выбрано значение шага $\gamma_k = \frac{1}{L}$. Тогда справедлива следующая оценка сходимости:

$$f(x^K) - f^* \leq \frac{2L\|x^0 - x^*\|_2^2}{(K+2)^2}.$$

Более того, чтобы достичь точности ε по функции ($f(x^K) - f^* \leq \varepsilon$), необходимо

$$K = \mathcal{O} \left(\sqrt{\frac{L\|x^0 - x^*\|_2^2}{\varepsilon}} \right) \text{ итераций.}$$

Доказательство. Подставим $\gamma = \frac{1}{L}$ в оценку из Теоремы Л1.3:

$$f(x^K) - f^* \leq \frac{2\|x^0 - x^*\|_2^2}{\gamma(K+2)^2} = \frac{2L\|x^0 - x^*\|_2^2}{(K+2)^2}.$$

Чтобы получить оценку на число итераций, потребуем:

$$\frac{2L\|x^0 - x^*\|_2^2}{(K+2)^2} \leq \varepsilon.$$

Откуда:

$$(K+2)^2 \geq \frac{2L\|x^0 - x^*\|_2^2}{\varepsilon} \implies K \geq \sqrt{\frac{2L\|x^0 - x^*\|_2^2}{\varepsilon}} - 2.$$

■

Л1.3 Нижние оценки

Снова вернемся к классу L -гладких μ -сильно выпуклых задач. Хочется понять, существует ли метод их решения лучше, чем ускоренный градиентный метод. Для этого прибегнем к построению нижних оценок для класса методов, где лежит рассматриваемый метод. То есть мы хотим показать, что для любого метода из класса существует плохая задача, на которой он работает за нижнюю оценку. Поскольку мы говорим об ускоренном градиентном методе, то целесообразно говорить о методах первого порядка, то есть имеющих доступ к градиенту целевой функции. Будем рассматривать следующий класс алгоритмов:

$$x^{k+1} \in x^0 + \text{span} \{ \nabla f(x^0), \dots, \nabla f(x^k) \},$$

где линейной оболочкой множества S называется множество всех линейных комбинаций элементов S :

$$\text{span } S = \bigcup_{k \in \mathbb{N}} \left\{ \sum_{i=1}^k \alpha_i x_i \mid \alpha_i \in \mathbb{R}, x_i \in S, i = \overline{1, k} \right\}.$$

Выбор такого класса достаточно логичен: на итерации $k+1$ нам известны все предыдущие точки x^i , $i \leq k$, а также градиенты в них $\nabla f(x^i)$, $i \leq k$, а строить новую точку x^{k+1} мы будем как их линейную комбинацию. Но если мы предыдущие точки конструировали как линейные комбинации точек и градиентов, то все точки выражаются только через x^0 и градиенты $\nabla f(x^i)$, $i \leq k$. Выходит, что и x^{k+1} выражается через них же. Отсюда получается, что градиентный спуск (Алгоритм ??), метод тяжёлого шарика (Алгоритм Л1.1) и ускоренный градиентный метод (Алгоритм Л1.2) лежат в описанном классе алгоритмов.

Сформулируем теорему о нижних оценках для этого класса.

Теорема Л1.4. Пусть задача безусловной оптимизации (??) с L -гладкой μ -сильно выпуклой функцией f решается методом первого порядка, удовлетворяющим Л1.3. Тогда для достижения точности ε по аргументу ($\|x^K - x^*\|_2 \leq \varepsilon$)

потребуется не менее

$$\Omega\left(\sqrt{\frac{L}{\mu}} \log \frac{\|x^0 - x^*\|_2}{\varepsilon}\right) \text{ оракульных вызовов.}$$

Доказательство. Сконструируем «плохую» функцию, покажем её L -гладкость и μ -сильную выпуклость. Затем покажем, что любой метод из описанного класса решает её «достаточно долго».

Зафиксируем количество итераций метода K , размерность матрицы $d = 2K$ и построим квадратичную функцию

$$f(x) = \frac{L-\mu}{8} \langle x, Ax \rangle - \frac{L-\mu}{4} \langle e_1, x \rangle + \frac{\mu}{2} \|x\|_2^2,$$

где A задана следующим образом:

$$A = \begin{pmatrix} 2 & -1 & 0 & \dots & 0 \\ -1 & 2 & -1 & \dots & 0 \\ 0 & -1 & 2 & \dots & 0 \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & 0 & \dots & 2 \end{pmatrix}.$$

Градиент f будет равен:

$$\nabla f(x) = \frac{L-\mu}{4} Ax - \frac{L-\mu}{4} e_1 + \mu x.$$

1. Проверим свойства задачи. Покажем, что f будет L -гладкой:

$$\left\| \frac{L-\mu}{4} A(x-y) + \mu(x-y) \right\|_2 \leq \frac{L-\mu}{4} \|A\|_2 \|x-y\|_2 + \mu \|x-y\|_2 \leq L \|x-y\|_2,$$

спектральная норма матрицы A ограничена 4, так как $A - 4I_d$ отрицательно полуопределена.

Проверим, что f будет μ -сильно выпуклой:

$$\begin{aligned} \frac{L-\mu}{8} \langle y, Ay \rangle - \frac{L-\mu}{4} \langle e_1, y \rangle + \frac{\mu}{2} \|y\|_2^2 &\geq \frac{L-\mu}{8} \langle x, Ax \rangle - \frac{L-\mu}{4} \langle e_1, x \rangle + \frac{\mu}{2} \|x\|_2^2 \\ &\quad + \left\langle \frac{L-\mu}{4} Ax - \frac{L-\mu}{4} e_1 + \mu x, y - x \right\rangle \\ &\quad + \frac{\mu}{2} \|y - x\|_2^2. \end{aligned}$$

Преобразуем выражение:

$$\frac{L-\mu}{8} (\langle y, Ay \rangle + \langle x, Ax \rangle - 2\langle y, Ax \rangle) \geq \frac{\mu}{2} \|y - x\|_2^2 - \frac{\mu}{2} \|y\|_2^2 - \frac{\mu}{2} \|x\|_2^2 + \mu \langle x, y \rangle = 0.$$

Получаем, что $\langle (y-x), A(y-x) \rangle \geq 0$ — это верно, так как A положительно полуопределена.

2. Найдём решение задачи. Из условия оптимальности — равенства градиента нулю, находим координаты оптимума:

$$\begin{aligned}\frac{L+\mu}{2}x_1^* - \frac{L-\mu}{4}x_2^* &= \frac{L-\mu}{4}, \\ -\frac{L-\mu}{4}x_{i-1}^* + \frac{L+\mu}{2}x_i^* - \frac{L-\mu}{4}x_{i+1}^* &= 0, \quad i = \overline{2, d-1}, \\ -\frac{L-\mu}{4}x_{d-1}^* + \frac{L+\mu}{2}x_d^* &= 0.\end{aligned}$$

Введём искусственные ограничения $x_0^* = 1$, а $x_{d+1}^* = 0$, тогда:

$$-(L-\mu)x_{i-1}^* + 2(L+\mu)x_i^* - (L-\mu)x_{i+1}^* = 0, \quad i = \overline{1, d}.$$

Решим полученную рекурренту, для этого запишем характеристическое уравнение:

$$\lambda^2 - 2\frac{L+\mu}{L-\mu}\lambda + 1 = 0 \implies \lambda_{1,2} = \frac{L+\mu}{L-\mu} \pm \sqrt{\left(\frac{L+\mu}{L-\mu}\right)^2 - 1} = \frac{L \pm 2\sqrt{L\mu} + \mu}{L-\mu}.$$

Тогда решение представимо в виде:

$$x_i^* = c_1 \left(\frac{\sqrt{L} + \sqrt{\mu}}{\sqrt{L} - \sqrt{\mu}} \right)^i + c_2 \left(\frac{\sqrt{L} - \sqrt{\mu}}{\sqrt{L} + \sqrt{\mu}} \right)^i.$$

Учтём ограничения на x_0^* и x_{d+1}^* :

$$\begin{aligned}c_1 + c_2 &= 1, \\ c_1 \left(\frac{\sqrt{L} + \sqrt{\mu}}{\sqrt{L} - \sqrt{\mu}} \right)^{d+1} + c_2 \left(\frac{\sqrt{L} - \sqrt{\mu}}{\sqrt{L} + \sqrt{\mu}} \right)^{d+1} &= 0.\end{aligned}$$

Введём обозначение

$$q = \frac{\sqrt{L} - \sqrt{\mu}}{\sqrt{L} + \sqrt{\mu}},$$

тогда

$$x_i^* = -\frac{q^{2d+2}}{1-q^{2d+2}} \frac{1}{q^i} + \frac{1}{1-q^{2d+2}} q^i.$$

3. Найдём выход метода, удовлетворяющего Л1.3. Так как алгоритм должен сходиться из любой точки, то рассмотрим начальную точку $x^0 = (0, 0, \dots, 0)^\top$. Заметим, что из градиента задачи и начальной точки следует, что $\nabla f(x^0) \in \text{span}(e_1)$, поэтому после первого вызова оракула только первая ктамнаордината может быть ненулевой. После второго — первые две и так далее. То есть $\nabla f(x^k) \in \text{span}(e_1, e_2, \dots, e_{k+1})$, тогда $x^{k+1} \in \text{span}(e_1, e_2, \dots, e_{k+1})$. Таким образом, получается, что только первые K компонент вектора могут совпадать с компонентами решения, остальные компоненты нулевые. Тогда:

$$\|x^K - x^*\|_2^2 \geq \sum_{i=K+1}^d (x_i^*)^2.$$

Таким образом:

$$\begin{aligned}
\|x^K - x^*\|_2^2 &\geq \sum_{i=K+1}^d \left(-\frac{q^{2d+2}}{1-q^{2d+2}} \frac{1}{q^i} + \frac{1}{1-q^{2d+2}} q^i \right)^2 \\
&= \frac{1}{(1-q^{2d+2})^2} \sum_{i=K+1}^d \left(q^i - \frac{q^{2d+2}}{q^i} \right)^2 \\
&= \frac{1}{(1-q^{2d+2})^2} \sum_{i=K+1}^d q^{2i} (1-q^{2d+2-2i})^2.
\end{aligned}$$

Воспользуемся тем, что $q^{2d+2-2i} \leq q^2$:

$$\begin{aligned}
\|x^K - x^*\|_2^2 &\geq \frac{(1-q^2)^2}{(1-q^{2d+2})^2} \sum_{i=K+1}^d q^{2i} = \frac{(1-q^2)^2}{(1-q^{2d+2})^2} \sum_{i=K+1}^{2K} q^{2i} \\
&= \frac{(1-q^2)^2}{(1-q^{2d+2})^2} q^{2K} \sum_{i=1}^K q^{2i} \\
&= (1-q^2)^2 \frac{q^{2K}}{1+q^{2K}} \frac{1}{(1-q^{2d+2})^2} \left(\sum_{i=1}^K q^{2i} + q^{2K} \sum_{i=1}^K q^{2i} \right) \\
&\geq (1-q^2)^2 \frac{q^{2K}}{1+q^{2K}} \|x^0 - x^*\|_2^2 \geq (1-q^2)^2 q^{2K} \frac{\|x^0 - x^*\|_2^2}{2} \\
&= \frac{L}{\mu} \left(\frac{\sqrt{L} - \sqrt{\mu}}{\sqrt{L} + \sqrt{\mu}} \right)^{2K} \frac{\|x^0 - x^*\|_2^2}{2}.
\end{aligned}$$

Воспользуемся неравенствами:

$$\log(1+x) \leq x, \quad \log(1-x) \geq -\frac{x}{1-x}, \quad x \in [0, 1).$$

Тогда

$$\log \frac{1-x}{1+x} = \log(1-x) - \log(1+x) \geq -\frac{x}{1-x} - x = -\frac{2x}{1-x}.$$

Продолжим оценку:

$$\|x^K - x^*\|_2^2 \geq \exp\left(-\frac{4K\sqrt{\mu/L}}{1-\sqrt{\mu/L}}\right) \frac{L}{\mu} \frac{\|x^0 - x^*\|_2^2}{2}.$$

Тогда получаем:

$$K \geq \frac{1-\sqrt{\mu/L}}{4\sqrt{\mu/L}} \log\left(\frac{L}{\mu} \cdot \frac{\|x^0 - x^*\|_2^2}{2\varepsilon^2}\right).$$

Таким образом:

$$K = \Omega\left(\sqrt{\frac{L}{\mu}} \log \frac{\|x^0 - x^*\|_2}{\varepsilon}\right).$$

■

Мы видим, что верхние оценки ускоренного градиентного метода асимптотически совпали с нижними оценками методов первого порядка на классе L -гладких μ -сильно выпуклых задач. То есть асимптотически улучшить метод Нестерова нельзя. Отсюда заключаем, что ускоренный градиентный метод является *оптимальным* в классе методов первого порядка на L -гладких μ -сильно выпуклых задачах.

Л1.4 Линейный каплинг

К текущему моменту мы рассмотрели уже три метода первого порядка: градиентный спуск, метод тяжёлого шарика и ускоренный градиентный метод. В градиентном спуске мы двигаемся против направления роста функции. В методе тяжёлого шарика мы добавляем инерцию к нашему движению, а в методе Нестерова мы вычисляем градиент в будущей точке. Однако класс методов, который мы описали перед теоремой с нижними оценками, позволяет нам конструировать и менее очевидные с точки зрения физики методы. Например, при обновлении точки, мы можем прибавлять градиент в другой точке, или брать выпуклую комбинацию нескольких точек в качестве третьей. Чтобы проиллюстрировать этот подход, рассмотрим один из методов, который тоже получает оптимальные оценки в сильно выпуклом случае.

Алгоритм Л1.3 Линейный каплинг: внутренний цикл

Вход: стартовые точки $x^0 = y^0 = z^0 \in \mathbb{R}^d$, размеры шагов $\{\gamma_k\}_{k=0} > 0$ и $\{\eta_k\}_{k=0} > 0$, моменты $\{\tau_k\}_{k=0} \in [0, 1]$, количество итераций K

- 1: **for** $k = 0, 1, \dots, K - 1$ **do**
- 2: $y^{k+1} = x^k - \eta_k \nabla f(x^k)$
- 3: $z^{k+1} = z^k - \gamma_k \nabla f(x^k)$
- 4: $x^{k+1} = \tau_k z^{k+1} + (1 - \tau_k) y^{k+1}$
- 5: **end for**

Выход: $\frac{1}{K} \sum_{k=0}^{K-1} x^k$




Рис. Л1.6: Три шага линейного каплинга. Пунктир — градиентные шаги для y и z вдоль градиента в точке x , сплошные линии — вычисление x^k как выпуклой комбинации.

Разберём, что происходит на итерации линейного каплинга. Точка y^{k+1} получается шагом градиентного спуска из x^k . Точка z^{k+1} обновляется через градиентный шаг из z^k вдоль направления $\nabla f(x^k)$. В каком-то смысле она живет сама по себе, однако движется согласно градиенту в точке x^k . Саму же точку x^{k+1} мы получаем как выпуклую комбинацию y^{k+1} и z^{k+1} . Если попытаться интерпретировать, что происходит в методе, то можно сказать, что точки y^k отвечают за классические шаги против градиента, а z^k добавляют инерцию.

Важным замечанием является, что метод линейного каплинга отличается от предыдущих ещё и выходом: раньше мы всегда возвращали точку с последней итерации, теперь возвращаем среднее арифметическое всех точек. В теореме о сходимости будем смотреть за значением функции в средней точке.

Теорема Л1.5. Пусть задача безусловной оптимизации (??) с L -гладкой выпуклой целевой функцией f решается с помощью линейного каплинга (Алгоритм Л1.3). Тогда при $\eta < \frac{2}{L}$, $\frac{1-\tau}{\tau} = \frac{\gamma}{\eta(2-L\eta)}$ справедлива следующая оценка сходимости:

$$f\left(\frac{1}{K} \sum_{k=0}^{K-1} x^k\right) - f^* \leq \frac{\|x^0 - x^*\|_2^2}{2\gamma K} + \frac{\gamma(f(x^0) - f^*)}{\eta(2 - L\eta)K}.$$

Доказательство. Воспользуемся строкой 3 Алгоритма Л1.3:

$$\begin{aligned} \|z^{k+1} - x^*\|_2^2 &= \|z^k - \gamma \nabla f(x^k) - x^*\|_2^2 \\ &= \|z^k - x^*\|_2^2 - 2\gamma \langle \nabla f(x^k), z^k - x^* \rangle + \gamma^2 \|\nabla f(x^k)\|_2^2 \\ &= \|z^k - x^*\|_2^2 - 2\gamma \langle \nabla f(x^k), x^k - x^* \rangle \\ &\quad - 2\gamma \langle \nabla f(x^k), z^k - x^k \rangle + \gamma^2 \|\nabla f(x^k)\|_2^2. \end{aligned} \quad (\text{Л1.4})$$

Оценим $\|\nabla f(x^k)\|_2^2$, для этого применим свойство гладкой функции из Теоремы ??:

$$f(y^{k+1}) \leq f(x^k) + \langle \nabla f(x^k), y^{k+1} - x^k \rangle + \frac{L}{2} \|y^{k+1} - x^k\|_2^2.$$

Воспользуемся строкой 2 Алгоритма Л1.3:

$$f(y^{k+1}) \leq f(x^k) - \eta \|\nabla f(x^k)\|_2^2 + \frac{L\eta^2}{2} \|\nabla f(x^k)\|_2^2 = f(x^k) - \eta \left(1 - \frac{L\eta}{2}\right) \|\nabla f(x^k)\|_2^2.$$

Если $\eta_k \leq \frac{2}{L}$, то $(1 - \frac{L\eta}{2}) > 0$. Получаем оценку на квадрат нормы градиента:

$$\|\nabla f(x^k)\|_2^2 \leq \frac{2}{\eta(2 - L\eta)} (f(x^k) - f(y^{k+1})). \quad (\text{Л1.5})$$

Подставим (Л1.5) в (Л1.4):

$$\begin{aligned} \|z^{k+1} - x^*\|_2^2 &\leq \|z^k - x^*\|_2^2 - 2\gamma \langle \nabla f(x^k), x^k - x^* \rangle \\ &\quad + \frac{2\gamma^2}{\eta(2 - L\eta)} (f(x^k) - f(y^{k+1})) + 2\gamma \langle \nabla f(x^k), x^k - z^k \rangle. \end{aligned} \quad (\text{Л1.6})$$

Теперь оценим $\langle \nabla f(x^k), z^k - x^k \rangle$, для этого задействуем строку 4 Алгоритма Л1.3:

$$\langle \nabla f(x^k), x^k - z^k \rangle = \left\langle \nabla f(x^k), x^k - \frac{1}{\tau} (x^k - (1 - \tau)y^k) \right\rangle = \frac{1 - \tau}{\tau} \langle \nabla f(x^k), y^k - x^k \rangle.$$

Воспользуемся выпуклостью функции f (Определение ??):

$$\langle \nabla f(x^k), x^k - z^k \rangle \leq \frac{1-\tau}{\tau} (f(y^k) - f(x^k)). \quad (\text{Л11.7})$$

Объединяя оценки (Л11.6) и (Л11.7):

$$\begin{aligned} \|z^{k+1} - x^*\|_2^2 &\leq \|z^k - x^*\|_2^2 - 2\gamma \langle \nabla f(x^k), x^k - x^* \rangle \\ &\quad + \frac{2\gamma^2}{\eta(2-L\eta)} (f(x^k) - f(y^{k+1})) + 2\gamma \frac{1-\tau}{\tau} (f(y^k) - f(x^k)). \end{aligned}$$

Подберем τ так, что $\frac{1-\tau}{\tau} = \frac{\gamma}{\eta(2-L\eta)}$, тогда

$$\|z^{k+1} - x^*\|_2^2 \leq \|z^k - x^*\|_2^2 - 2\gamma \langle \nabla f(x^k), x^k - x^* \rangle + \frac{2\gamma^2}{\eta(2-L\eta)} (f(y^k) - f(y^{k+1})).$$

Сделаем перестановку:

$$2\gamma \langle \nabla f(x^k), x^k - x^* \rangle \leq \|z^k - x^*\|_2^2 - \|z^{k+1} - x^*\|_2^2 + \frac{2\gamma^2}{\eta(2-L\eta)} (f(y^k) - f(y^{k+1})),$$

а потом снова применяем выпуклость:

$$2\gamma (f(x^k) - f(x^*)) \leq \|z^k - x^*\|_2^2 - \|z^{k+1} - x^*\|_2^2 + \frac{2\gamma^2}{\eta(2-L\eta_k)} (f(y^k) - f(y^{k+1})).$$

Суммируем по всем k от 0 до $K-1$, а потом делим на K :

$$\begin{aligned} \frac{2\gamma}{K} \sum_{k=0}^{K-1} (f(x^k) - f^*) &\leq \frac{1}{K} \sum_{k=0}^{K-1} (\|z^k - x^*\|_2^2 - \|z^{k+1} - x^*\|_2^2) \\ &\quad + \frac{2\gamma^2}{\eta(2-L\eta)K} \sum_{k=0}^{K-1} (f(y^k) - f(y^{k+1})) \\ &= \frac{1}{K} (\|z^0 - x^*\|_2^2 - \|z^K - x^*\|_2^2) + \frac{2\gamma^2}{\eta(2-L\eta)K} (f(y^0) - f(y^K)) \\ &\leq \frac{\|z^0 - x^*\|_2^2}{K} + \frac{2\gamma^2 (f(y^0) - f^*)}{\eta(2-L\eta)K}. \end{aligned}$$

Учитывая инициализацию $x^0 = y^0 = z^0$ и применяя неравенство Йенсена для выпуклой функции f (??), имеем

$$f\left(\frac{1}{K} \sum_{k=0}^{K-1} x^k\right) - f^* \leq \frac{\|x^0 - x^*\|_2^2}{2\gamma K} + \frac{\gamma(f(x^0) - f^*)}{\eta(2-L\eta)K}.$$

■

Казалось бы, полученный результат не является оптимальным: в выпуклом случае мы получили сублинейную скорость сходимости $\mathcal{O}(1/K)$, как у обычного градиентного спуска. У метода Нестерова мы получили $\mathcal{O}(1/K^2)$ (Теорема Л11.3). Дальше мы

рассмотрим технику, которая позволит получить оптимальную скорость сходимости в сильно выпуклом случае — рестарты линейного каплинга.

Алгоритм Л1.4 Линейный каплинг: рестарты

Вход: стартовая точка $x^0 \in \mathbb{R}^d$, количество итераций T

- 1: **for** $t = 0, 1, \dots, T - 1$ **do**
 - 2: Запустить Алгоритм Л1.3 из x^t с параметрами γ, η, τ на K итераций
 - 3: Получить x^{t+1} на выходе Алгоритма Л1.3
 - 4: **end for**
- Выход:** x^T
-

Появляется логичный вопрос: зачем нам делать внешний цикл, вся суть которого перезапускать метод с прошлого выхода внутреннего метода. Чем это отличается от одного цикла на $T \cdot K$ итераций? Ответ стоит искать в том, что мы получаем на выход из внутреннего цикла, а именно, среднюю точку. И теперь уже становится понятно отличие одного цикла от двух вложенных. Более того, с техникой рестартов удастся получить хорошие оценки сходимости. Стоит заметить, что результат прошлой теоремы справедлив для выпуклых функций, а следующую теорему мы формулируем для сильно выпуклых задач.

Теорема Л1.6 (Теорема 3.1 из [3]). Пусть задача безусловной оптимизации (??) с L -гладкой, μ -сильно выпуклой целевой функцией f решается с помощью рестартов линейного каплинга (Алгоритм Л1.4). Тогда при $\gamma = \frac{1}{\sqrt{\mu L}}, \eta = \frac{1}{L}, \frac{1-\tau}{\tau} = \frac{\gamma}{\eta(2-L\eta)}, K = \sqrt{\frac{16L}{\mu}}$, чтобы добиться точности ε по функции ($f(x^T) - f^* \leq \varepsilon$), необходимо

$$O\left(\sqrt{\frac{L}{\mu}} \log \frac{f(x^0) - f^*}{\varepsilon}\right) \text{ оракульных вызовов.}$$

Доказательство. Применим к результату Теоремы Л1.5 сильную выпуклость (Определение ??), учитывая, что $\nabla f(x^*) = 0$:

$$\begin{aligned} f\left(\frac{1}{K} \sum_{k=0}^{K-1} x^k\right) - f^* &\leq \frac{f(x^0) - f^*}{\mu\gamma K} + \frac{\gamma(f(x^0) - f^*)}{\eta(2-L\eta)K} \\ &= \left(\frac{1}{\mu\gamma K} + \frac{\gamma}{\eta(2-L\eta)K}\right)(f(x^0) - f^*). \end{aligned}$$

Подберем η оптимально, чтобы минимизировать правую часть оценки выше: $\eta = \frac{1}{L}$. Тогда

$$f\left(\frac{1}{K} \sum_{k=0}^{K-1} x^k\right) - f^* \leq \left(\frac{1}{\mu\gamma K} + \frac{\gamma L}{K}\right)(f(x^0) - f^*).$$

Подберем теперь оптимальное $\gamma = \frac{1}{\sqrt{\mu L}}$:

$$f\left(\frac{1}{K} \sum_{k=0}^{K-1} x^k\right) - f^* \leq \sqrt{\frac{4L}{\mu K^2}}(f(x^0) - f^*).$$

Положим $K = \sqrt{\frac{16L}{\mu}}$ и получим:

$$f\left(\frac{1}{K} \sum_{k=0}^{K-1} x^k\right) - f^* \leq \frac{1}{2}(f(x^0) - f^*).$$

Получается, что за один запуск линейного каплинга на K итераций, мы гарантированно уменьшаем расстояние до решения по функции в 2 раза. А значит для одной итерации Алгоритма Л1.4 имеем

$$f(x^{t+1}) - f^* \leq \frac{1}{2}(f(x^t) - f^*).$$

Запустим теперь рекурсию по t :

$$f(x^T) - f^* \leq \frac{1}{2^T}(f(x^0) - f^*).$$

Отсюда легко выразить число итераций Алгоритма Л1.4 для достижения точности ε по функции:

$$T \geq \log\left(\frac{f(x^0) - f^*}{\varepsilon}\right).$$

В данном случае оракульная сложность Алгоритма Л1.4 не совпадает с итерационной. Оракульную сложность можно получить следующим образом:

$$K \cdot T = O\left(\sqrt{\frac{L}{\mu}} \log \frac{f(x^0) - f^*}{\varepsilon}\right).$$

■

Л1.5 Catalyst

В методе Нестерова мы получили ускорение благодаря добавлению инерции и вычислению градиента в будущей точке. Однако метод можно ускорить и другими способами. Давайте модифицируем саму целевую функцию, чтобы получить ускорение для всех методов, обращающихся к градиенту функции. Это позволяет сделать общую схему ускорения Catalyst, предложенную в 2015 году [3].

Алгоритм Л1.5 Catalyst

Вход: стартовые точки $x^0 = y^0 \in \mathbb{R}^d$, коэффициент регуляризации κ , параметры α_0 и $q = \frac{\mu}{\mu + \kappa}$, последовательность $\{\varepsilon_k\}_{k \geq 0}$, метод оптимизации $\mathcal{M}$

1: **while** не выполнен критерий остановки $\mathcal{T}$ **do**

2: Найти приближенное решение следующей задачи, используя $\mathcal{M}$:

$$\begin{aligned} x^k &\approx \operatorname{argmin}_{x \in \mathbb{R}^d} & g_k(x) &= f(x) + \frac{\kappa}{2} \|x - y^{k-1}\|_2^2 \\ \text{s.t.} & & g_k(x^k) - g_k^* &\leq \varepsilon_k. \end{aligned}$$

3: Выбрать $\alpha_k \in (0, 1)$ из уравнения $\alpha_k^2 = (1 - \alpha_k)\alpha_{k-1}^2 + q\alpha_k$

4: $\beta_k = \frac{\alpha_{k-1}(1 - \alpha_{k-1})}{\alpha_{k-1}^2 + \alpha_k}$

5: $y^k = x^k + \beta_k(x^k - x^{k-1})$

6: **end while**

Выход: x^k

Проанализируем этот метод. Эта схема напоминает метод рестартов: есть внешний цикл, который запускает внутренний метод $\mathcal{M}$. Но дальше идут различия. На каждой итерации внешнего цикла отрешиваются разные задачи. К исходной целевой функции $f(x)$ добавляется регуляризатор $\frac{\kappa}{2} \|x - y^{k-1}\|_2^2$, который «тянет» точку x к y^{k-1} . А затем точка y^k обновляется наподобие тому, как это было в ускоренном градиентном методе, то есть с моментумом. Можно сказать, что моментум мы вынесли в виде регуляризатора в модифицированную целевую функцию. Эта идея позволяет, например, ускорить метод градиентного спуска до скорости метода Нестерова. Далее сформулируем конкретные теоремы из оригинальной статьи.

Теорема Л1.7 (Теорема 3.1 из [3]). Пусть задача безусловной оптимизации (??) с L -гладкой, μ -сильно выпуклой целевой функцией f решается с помощью схемы Catalyst (Алгоритм Л1.5). Тогда при $\rho \leq \sqrt{\kappa}$, $\alpha_0 = \sqrt{q}$ и последовательности

$$\varepsilon_k = \frac{2}{9} (f(x^0) - f^*) (1 - \rho)^k$$

справедлива следующая оценка сходимости:

$$f(x^k) - f^* \leq C(1 - \rho)^{k+1} (f(x^0) - f^*), \quad C = \frac{8}{(\sqrt{q} - \rho)^2}.$$

В таком виде теорема не делает никаких предположений о том методе, который используется для решения подзадач. Мы лишь можем наблюдать за последовательностью x^k , генерируемой алгоритмом. Для того, чтобы понять, насколько дорого обходится работа метода целиком, необходимо сделать предположение о скорости сходимости внутреннего метода $\mathcal{M}$.

Предположение Л1.1. Пусть выполняются условия теоремы Л1.7, а метод $\mathcal{M}$ генерирует последовательность $\{z^t\}_{t \geq 0}$ при минимизации функции g_k с линейной скоростью сходимости:

$$g_k(z^t) - g_k^* \leq A(1 - \tau_{\mathcal{M}})^t (g_k(z^0) - g_k^*).$$

При этом предположении и при $z_0 = x^{k-1}$, точность решения ε_k достигается за $T_{\mathcal{M}} = \tilde{\mathcal{O}}(1/\tau_{\mathcal{M}})$ итераций внутреннего метода. Теперь мы можем оценить точность решения и константу сходимости всей схемы Catalyst. Итак, после общего количества итераций метода $\mathcal{M}$, а именно $s = kT_{\mathcal{M}}$, получаем

$$f\left(x^{\frac{s}{T_{\mathcal{M}}}}\right) - f^* \leq C(1 - \rho)^{\frac{s}{T_{\mathcal{M}}}} (f(x^0) - f^*) \leq C\left(1 - \frac{\rho}{T_{\mathcal{M}}}\right)^s (f(x^0) - f^*).$$

Таким образом, константа $\tau_{\mathcal{A}}$ итогового метода равна $\tau_{\mathcal{A}} = \frac{\rho}{T_{\mathcal{M}}} = \tilde{\mathcal{O}}\left(\tau_{\mathcal{M}} \sqrt{\frac{\mu}{\mu + \kappa}}\right)$. При этом $\tau_{\mathcal{M}}$ обычно также зависит от κ , так что κ подбирается так, чтобы максимизировать $\tau_{\mathcal{M}}/\sqrt{\mu + \kappa}$.

Сформулируем аналогичную теорему и предположение для выпуклого случая, а затем рассмотрим, какое ускорение удастся получить для изученных методов.

Теорема Л1.8 (Теорема 3.3 из [3]). Пусть задача безусловной оптимизации (??) с L -гладкой выпуклой целевой функцией f решается с помощью схемы Catalyst (Алгоритм Л1.5). Тогда при $\alpha_0 = \frac{\sqrt{5}-1}{2}$ и последовательности

$$\varepsilon_k = \frac{2}{9} (f(x^0) - f^*) (k + 2)^{-4-\eta}, \quad \eta > 0$$

справедлива следующая оценка сходимости:

$$f(x^k) - f^* \leq \frac{8}{(k+2)^2} \left(\left(1 + \frac{2}{\eta}\right)^2 (f(x^0) - f^*) + \frac{\kappa}{2} \|x^0 - x^*\|^2 \right).$$

Снова потребуется сделать предположение о сходимости внутреннего алгоритма для решения подзадачи.

Предположение Л1.2. Пусть выполняются условия Теоремы Л1.8, а метод $\mathcal{M}$ генерирует последовательность $\{z^t\}_{t \geq 0}$ при минимизации функции g_k с линейной скоростью сходимости:

$$g_k(z^t) - g_k^* \leq A(1 - \tau_{\mathcal{M}})^t (g_k(z^0) - g_k^*).$$

Мы потребовали линейной скорости сходимости, но рассматриваем выпуклый случай. Почему такое возможно? На самом деле, выпуклой является функция f , а когда мы к ней добавили регуляризатор $\frac{\kappa}{2} \|x - y^{k-1}\|_2^2$, мы сделали задачу сильно выпуклой с константой $\mu = \kappa$. А для такой задачи уже многие градиентные методы будут иметь линейную скорость сходимости.

При этом предположении и при $z_0 = x^{k-1}$, точность решения ε_k достигается за $T_{\mathcal{M}} = \tilde{O}(1/\tau_{\mathcal{M}})$ итераций внутреннего метода. Если мы захотим более точную оценку, то для k -ой подзадачи число итераций метода $\mathcal{M}$ составляет $T_{\mathcal{M}} \log(k+2)$ из-за полиномиального убывания точности ε_k .

Теперь мы можем оценить точность решения и константу сходимости всей схемы Catalyst. После общего количества итераций внутреннего метода $s = kT_{\mathcal{M}} \log(k+2)$, получаем

$$f\left(x^{\frac{s}{T_{\mathcal{M}} \log(k+2)}}\right) - f^* \leq \frac{8T_{\mathcal{M}}^2 \log^2(s)}{s^2} \left(\left(1 + \frac{2}{\eta}\right)^2 (f(x^0) - f^*) + \frac{\kappa}{2} \|x^0 - x^*\|^2 \right).$$

Если метод $\mathcal{M}$ является методом первого порядка, то данная оценка является почти оптимальной (near-optimal), с точностью до логарифмического множителя, по сравнению с оптимальной скоростью $\mathcal{O}(1/s^2)$, что может быть разумной платой за универсальность схемы Catalyst.

Рассмотрим как метод Catalyst позволяет ускорить метод градиентного спуска, сравним со скоростью метода Нестерова. Все асимптотики написаны для количества итераций, необходимых для достижения ε -точности решения по функции $(f(x) - f^* \leq \varepsilon)$. Параметры были подобраны оптимально. Как мы видим, Catalyst ускоряет метод гра-

	Без Catalyst		Catalyst	
	$\mu > 0$	$\mu = 0$	$\mu > 0$	$\mu = 0$
GD	$\mathcal{O}\left(\frac{L}{\mu} \log\left(\frac{1}{\varepsilon}\right)\right)$	$\mathcal{O}\left(\frac{L}{\varepsilon}\right)$	$\mathcal{O}\left(\sqrt{\frac{L}{\mu}} \log\left(\frac{1}{\varepsilon}\right)\right)$	$\mathcal{O}\left(\frac{L}{\sqrt{\varepsilon}}\right)$
AGD	$\mathcal{O}\left(\sqrt{\frac{L}{\mu}} \log\left(\frac{1}{\varepsilon}\right)\right)$	$\mathcal{O}\left(\frac{L}{\sqrt{\varepsilon}}\right)$	нет ускорения	

Таблица 1: Сравнение методов GD (Алгоритм ??), AGD (Алгоритм Л1.2) с использованием Catalyst и без.

диентного спуска так, что получаются асимптотики аналогичные методу Нестерова с точностью до логарифмических факторов. Метод Нестерова дополнительно ускорить

не удастся. Объясняется это тем, что даже с применением схемы ускорения Catalyst ускоренный градиентный метод остается методом первого порядка. А как мы знаем из верхних и нижних оценок, он является оптимальным среди методов первого порядка на классе гладких сильно выпуклых задач.

Список литературы

- [1] Yudong Chen. Lecture 9–10: Accelerated gradient descent, 2023. UW-Madison CS/ISyE/Math/Stat 726 Spring 2023 Lecture Notes.
- [2] Laurent Lessard, Benjamin Recht, and Andrew Packard. Analysis and design of optimization algorithms via integral quadratic constraints. *SIAM Journal on Optimization*, 26(1):57–95, January 2016.
- [3] Hongzhou Lin, Julien Mairal, and Zaid Harchaoui. A universal catalyst for first-order optimization, 2015.
- [4] Jun Liu. A concise lyapunov analysis of nesterov’s accelerated gradient method, 2025.
- [5] Y. Nesterov. A method for solving the convex programming problem with convergence rate $o(1/k^2)$, 1983.
- [6] B.T. Polyak. Some methods of speeding up the convergence of iteration methods. *USSR Computational Mathematics and Mathematical Physics*, 4(5):1–17, 1964.
- [7] Е. Е. Тыртышников. Матричный анализ и линейная алгебра. 2007.