# Ускоренные и оптимальные методы

## Методы оптимизации

Александр Безносиков

Московский физико-технический институт

24 сентября 2026



# Вопрос с прошлой лекции

- Была получена верхняя оценка на сходимость градиентного спуска для $L$–гладких и $\mu$–сильно выпуклых задач.
  **Вопрос:** сколько оракульных вызовов нужно сделать, чтобы найти $\varepsilon$-решение?

# Вопрос с прошлой лекции

- Была получена верхняя оценка на сходимость градиентного спуска для $L$–гладких и $\mu$–сильно выпуклых задач.
  **Вопрос:** сколько оракульных вызовов нужно сделать, чтобы найти $\varepsilon$-решение?

$$K = \mathcal{O}\left(\frac{L}{\mu}\log\frac{\|x^0 - x^*\|_2}{\varepsilon}\right) \quad \text{оракульных вызовов.}$$

# Вопрос с прошлой лекции

- Была получена верхняя оценка на сходимость градиентного спуска для $L$–гладких и $\mu$–сильно выпуклых задач.
  **Вопрос:** сколько оракульных вызовов нужно сделать, чтобы найти $\varepsilon$-решение?

$$K = \mathcal{O}\left(\frac{L}{\mu}\log\frac{\|x^0 - x^*\|_2}{\varepsilon}\right) \quad \text{оракульных вызовов.}$$

- **Вопрос:** можно ли сделать лучше?

# Вопрос с прошлой лекции

- Была получена верхняя оценка на сходимость градиентного спуска для $L$–гладких и $\mu$–сильно выпуклых задач.
  **Вопрос:** сколько оракульных вызовов нужно сделать, чтобы найти $\varepsilon$-решение?

$$K = \mathcal{O}\left(\frac{L}{\mu}\log\frac{\|x^0 - x^*\|_2}{\varepsilon}\right) \quad \text{оракульных вызовов.}$$

- **Вопрос:** можно ли сделать лучше? Да, можно.

# Метод тяжелого шарика

Б.Т. Поляк в 1964 году предложил метод тяжелого шарика.

**Алгоритм** Метод тяжёлого шарика

**Вход:** стартовая точка $x^0 = x^{-1} \in \mathbb{R}^d$, размеры шагов $\{\gamma_k\}_{k=0} > 0$, моментумы $\{\tau_k\}_{k=0} \in [0, 1]$, количество итераций $K$

1: **for** $k = 0, 1, \ldots, K-1$ **do**

2: $\quad x^{k+1} = x^k - \gamma_k \nabla f(x^k) + \tau_k (x^k - x^{k-1})$

3: **end for**

**Выход:** $x^K$

# Метод тяжелого шарика

Б.Т. Поляк в 1964 году предложил метод тяжелого шарика.

**Алгоритм** Метод тяжёлого шарика

**Вход:** стартовая точка $x^0 = x^{-1} \in \mathbb{R}^d$, размеры шагов $\{\gamma_k\}_{k=0} > 0$, моментумы $\{\tau_k\}_{k=0} \in [0, 1]$, количество итераций $K$

1: **for** $k = 0, 1, \ldots, K-1$ **do**

2: $\quad x^{k+1} = x^k - \gamma_k \nabla f(x^k) + \tau_k (x^k - x^{k-1})$

3: **end for**

**Выход:** $x^K$

Добавим к градиентному спуску моментумный член — предположим, что у точки $x^k$, отвечающей за текущее положение, есть инерция.

# Сравнение тяжелого шарика и градиентного спуска

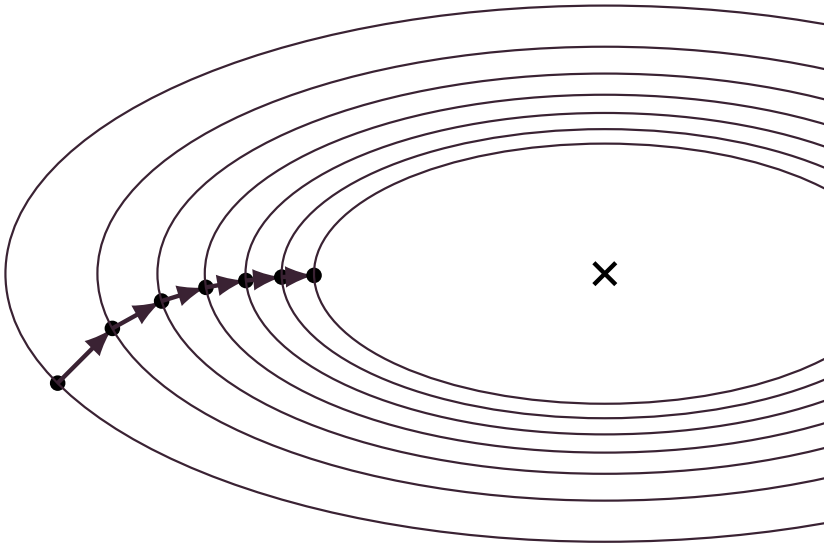


Рис. 1: Градиентный спуск.

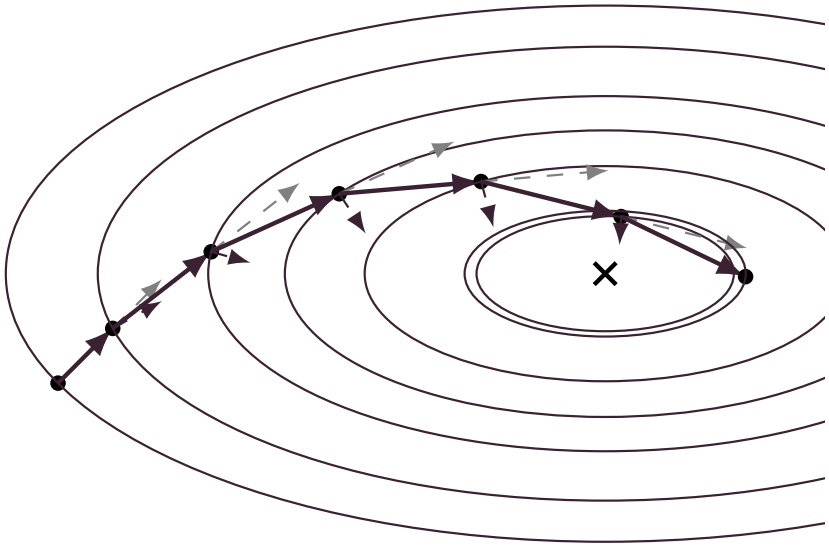


Рис. 2: Метод тяжёлого шарика.

# Связь с PyTorch

- В библиотеке PyTorch реализован следующий метод:

$$v^{k+1} = \beta v^k + \nabla f\left(x^k\right) \quad \beta \in [0, 1]$$
$$x^{k+1} = x^k - \gamma v^{k+1}$$

# Связь с PyTorch

- В библиотеке PyTorch реализован следующий метод:

$$v^{k+1} = \beta v^k + \nabla f\left(x^k\right) \quad \beta \in [0, 1]$$
$$x^{k+1} = x^k - \gamma v^{k+1}$$

**Вопрос:** как этот метод связан с методом тяжелого шарика?

# Связь с PyTorch

- В библиотеке PyTorch реализован следующий метод:

$$v^{k+1} = \beta v^k + \nabla f\left(x^k\right) \quad \beta \in [0, 1]$$
$$x^{k+1} = x^k - \gamma v^{k+1}$$

**Вопрос:** как этот метод связан с методом тяжелого шарика? Это практически он и есть. Подставим первую строку во вторую:

$$x^{k+1} = x^k - \gamma \nabla f\left(x^k\right) - \gamma \beta v^k$$

# Связь с PyTorch

- В библиотеке PyTorch реализован следующий метод:

$$v^{k+1} = \beta v^k + \nabla f\left(x^k\right) \quad \beta \in [0, 1]$$
$$x^{k+1} = x^k - \gamma v^{k+1}$$

**Вопрос:** как этот метод связан с методом тяжелого шарика? Это практически он и есть. Подставим первую строку во вторую:

$$x^{k+1} = x^k - \gamma \nabla f\left(x^k\right) - \gamma \beta v^k$$

Из второй строки для $k$ шага:

$$-\gamma v^k = x^k - x^{k-1}$$

# Связь с PyTorch

- В библиотеке PyTorch реализован следующий метод:

$$v^{k+1} = \beta v^k + \nabla f\left(x^k\right) \quad \beta \in [0, 1]$$
$$x^{k+1} = x^k - \gamma v^{k+1}$$

**Вопрос:** как этот метод связан с методом тяжелого шарика? Это практически он и есть. Подставим первую строку во вторую:

$$x^{k+1} = x^k - \gamma \nabla f\left(x^k\right) - \gamma\beta v^k$$

Из второй строки для $k$ шага:

$$-\gamma v^k = x^k - x^{k-1}$$

Тогда подставим в предыдущие и получим

$$x^{k+1} = x^k - \gamma \nabla f\left(x^k\right) + \beta\left(x^k - x^{k-1}\right)$$

Это показывает еще одну физику метода тяжелого шарика — мы идем по аккумулированному градиенту.

# Плюсы и минусы

**Вопрос:** какие плюсы и минусы видите у метода тяжелого шарика?

# Плюсы и минусы

**Вопрос:** какие плюсы и минусы видите у метода тяжелого шарика?

Плюсы

- Понятная физика и интуиция.
- Легкость в имплементации.
- Дешевизна вычислений.

Минусы

- Нужно подбирать теперь 2 параметра. Мы сейчас умеем только в теории оценивать $\gamma_k$. Теперь что-то нужно делать с $\tau_k$.
- Мы шли за ускорением градиентного спуска. А оно вообще есть в общем случае?

# Сходимость

## Теорема

*Пусть имеется квадратичная функция* $f(x) = \frac{1}{2}\langle x, Ax\rangle - \langle b, x\rangle$, *где* $A$ *— симметричная матрица с положительными собственными числами на отрезке* $[\mu, L]$. *Пусть задача безусловной оптимизации решается методом тяжёлого шарика. Тогда при*

$$\gamma_k = \gamma = \frac{4}{\left(\sqrt{L} + \sqrt{\mu}\right)^2}, \quad \tau_k = \tau = \left(\frac{\sqrt{L} - \sqrt{\mu}}{\sqrt{L} + \sqrt{\mu}}\right)^2$$

*для точности сходимости* $\varepsilon$ *по аргументу, достаточно*

$$K = \mathcal{O}\left(\sqrt{\frac{L}{\mu}} \log \frac{\|x^0 - x^*\|_2}{\varepsilon}\right) \quad \text{итераций.}$$

# Сходимость

## Теорема

*Пусть имеется квадратичная функция* $f(x) = \frac{1}{2}\langle x, Ax\rangle - \langle b, x\rangle$, *где* $A$ *— симметричная матрица с положительными собственными числами на отрезке* $[\mu, L]$. *Пусть задача безусловной оптимизации решается методом тяжёлого шарика. Тогда при*

$$\gamma_k = \gamma = \frac{4}{\left(\sqrt{L} + \sqrt{\mu}\right)^2}, \quad \tau_k = \tau = \left(\frac{\sqrt{L} - \sqrt{\mu}}{\sqrt{L} + \sqrt{\mu}}\right)^2$$

*для точности сходимости* $\varepsilon$ *по аргументу, достаточно*

$$K = \mathcal{O}\left(\sqrt{\frac{L}{\mu}} \log \frac{\|x^0 - x^*\|_2}{\varepsilon}\right) \quad \text{итераций.}$$

В общем случае ускорения нет.

# Ускоренный градиентный метод

Ю.Е. Нестеров в 1983 году предложил ускоренный градиентный метод.

---

**Алгоритм** Ускоренный градиентный метод (Метод Нестерова)

---

**Вход:** стартовые точки $x^0 = x^{-1} \in \mathbb{R}^d$, размеры шагов $\{\gamma_k\}_{k=0} > 0$, моментумы $\{\tau_k\}_{k=0} \in [0, 1]$, количество итераций $K$

1: **for** $k = 0, 1, \ldots, K-1$ **do**

2: $\quad y^k = x^k + \tau_k\left(x^k - x^{k-1}\right)$

3: $\quad x^{k+1} = y^k - \gamma_k \nabla f\left(y^k\right)$

4: **end for**

**Выход:** $x^K$

---

# Ускоренный градиентный метод и тяжелый шарик

**Вопрос:** в чем ключевое отличие метода Нестерова от тяжелого шарика?

Тяжелый шарик:

$$x^{k+1} = x^k - \gamma_k \nabla f\left(x^k\right) + \tau_k \left(x^k - x^{k-1}\right)$$

Ускоренный градиентный метод:

$$\begin{aligned} y^k &= x^k + \tau_k \left(x^k - x^{k-1}\right) \\ x^{k+1} &= y^k - \gamma_k \nabla f\left(y^k\right) \end{aligned}$$

# Ускоренный градиентный метод и тяжелый шарик

**Вопрос:** в чем ключевое отличие метода Нестерова от тяжелого шарика?

Тяжелый шарик:

$$x^{k+1} = x^k - \gamma_k \nabla f\left(x^k\right) + \tau_k\left(x^k - x^{k-1}\right)$$

Ускоренный градиентный метод:

$$y^k = x^k + \tau_k\left(x^k - x^{k-1}\right)$$
$$x^{k+1} = y^k - \gamma_k \nabla f\left(y^k\right)$$

Перепишем ускоренный градиентный метод:

$$x^{k+1} = x^k - \gamma_k \nabla f\left(x^k + \tau_k\left(x^k - x^{k-1}\right)\right) + \tau_k\left(x^k - x^{k-1}\right)$$

# Сравнение

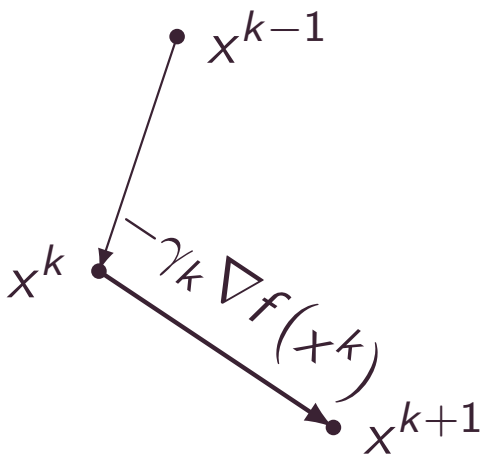



Рис. 3: Градиентный спуск

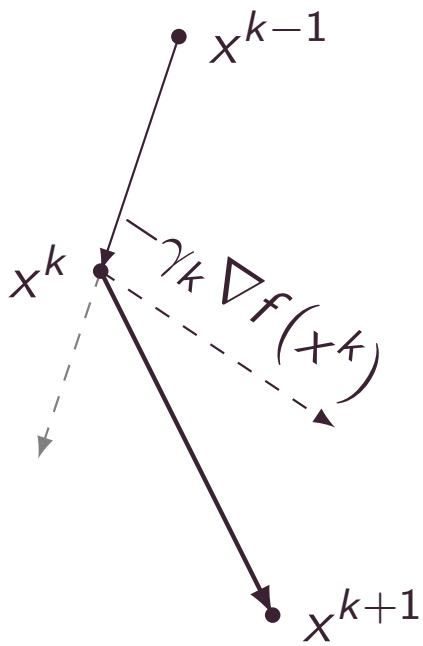



Рис. 4: Метод тяжёлого шарика

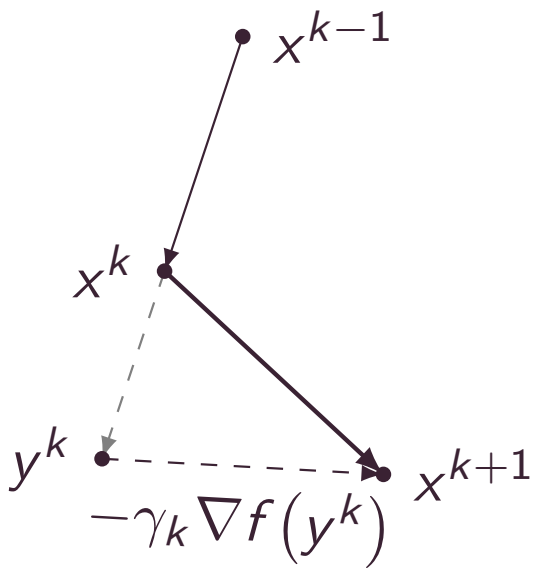



Рис. 5: Метод Нестерова

# Сходимость метода Нестерова

## Теорема

*Пусть задача безусловной оптимизации с $L$–гладкой $\mu$–сильно выпуклой целевой функцией $f$ решается с помощью ускоренного градиентного метода. Тогда при $\gamma_k = \frac{1}{L}$, $\tau_k = \frac{\sqrt{L}-\sqrt{\mu}}{\sqrt{L}+\sqrt{\mu}}$ справедлива следующая оценка сходимости:*

$$f\left(x^K\right) - f^* \leq \left(1 - \sqrt{\frac{\mu}{L}}\right)^K \cdot L\left\|x^0 - x^*\right\|_2^2.$$

*Более того, чтобы добиться точности $\varepsilon$ по аргументу, достаточно*

$$K = \mathcal{O}\left(\sqrt{\frac{L}{\mu}} \log\left(\frac{\left\|x^0 - x^*\right\|_2}{\varepsilon}\right)\right) \quad \text{итераций.}$$

**Замечание:** В доказательстве используется **функция Ляпунова**:
$V_k := f\left(x^k\right) - f^* + \frac{L}{2}\left\|x^k - x^* - \rho^2\left(x^{k-1} - x^*\right)\right\|_2^2$

# Сходимость метода Нестерова

## Утверждение

*Пусть задача безусловной оптимизации с $L$–гладкой выпуклой целевой функцией $f$ решается с помощью ускоренного градиентного метода. Тогда при $\gamma_k = \frac{1}{L}$, $\tau_k = \frac{k}{k+3}$ справедлива следующая оценка сходимости:*

$$f\left(x^K\right) - f^* \leq \frac{2L\left\|x^0 - x^*\right\|_2^2}{\left(K+2\right)^2}.$$

*Более того, чтобы достичь точности $\varepsilon$ по функции, достаточно*

$$K = \mathcal{O}\left(\sqrt{\frac{L\left\|x^0 - x^*\right\|_2^2}{\varepsilon}}\right) \quad \text{итераций.}$$

# Вопросы остаются

- Метод лучше градиентного спуска.
- Но можно ли еще лучше?
- **Вопрос:** как понять, можно ли лучше?

# Вопросы остаются

- Метод лучше градиентного спуска.
- Но можно ли еще лучше?
- **Вопрос:** как понять, можно ли лучше? Получить нижние оценки.

# Вопросы остаются

- Метод лучше градиентного спуска.
- Но можно ли еще лучше?
- **Вопрос:** как понять, можно ли лучше? Получить нижние оценки.
- Для получения нижних оценок нужно придумать не метод, а «плохую» функцию, которую будет «долго» оптимизировать любой метод. **Вопрос:** а что здесь значит «любой метод»?

# Вопросы остаются

- Метод лучше градиентного спуска.
- Но можно ли еще лучше?
- **Вопрос:** как понять, можно ли лучше? Получить нижние оценки.
- Для получения нижних оценок нужно придумать не метод, а «плохую» функцию, которую будет «долго» оптимизировать любой метод. **Вопрос:** а что здесь значит «любой метод»? Надо определить класс методов.

# Класс алгоритмов

- Дана начальная точка $x^0$. Эта начальная точка порождает множество всех достигнутых на данный момент точек.

# Класс алгоритмов

- Дана начальная точка $x^0$. Эта начальная точка порождает множество всех достигнутых на данный момент точек.
- На текущем оракульном вызове метод может считать градиент функции во всех точках, которых уже достиг. Изначально можем посчитать градиент только в $x^0$.

# Класс алгоритмов

- Дана начальная точка $x^0$. Эта начальная точка порождает множество всех достигнутых на данный момент точек.
- На текущем оракульном вызове метод может считать градиент функции во всех точках, которых уже достиг. Изначально можем посчитать градиент только в $x^0$.
-

$$x^{k+1} \in x^0 + \text{span}\left\{\nabla f\left(x^0\right), \ldots, \nabla f\left(x^k\right)\right\}$$

# Класс алгоритмов

- Дана начальная точка $x^0$. Эта начальная точка порождает множество всех достигнутых на данный момент точек.
- На текущем оракульном вызове метод может считать градиент функции во всех точках, которых уже достиг. Изначально можем посчитать градиент только в $x^0$.
-

$$x^{k+1} \in x^0 + \text{span}\left\{\nabla f\left(x^0\right), \ldots, \nabla f\left(x^k\right)\right\}$$

# Класс алгоритмов

- Дана начальная точка $x^0$. Эта начальная точка порождает множество всех достигнутых на данный момент точек.
- На текущем оракульном вызове метод может считать градиент функции во всех точках, которых уже достиг. Изначально можем посчитать градиент только в $x^0$.
-

$$x^{k+1} \in x^0 + \text{span}\left\{\nabla f\left(x^0\right), \ldots, \nabla f\left(x^k\right)\right\}$$

**Вопрос:** подходят ли изученные методы под такое определение?

# Класс алгоритмов

- Дана начальная точка $x^0$. Эта начальная точка порождает множество всех достигнутых на данный момент точек.
- На текущем оракульном вызове метод может считать градиент функции во всех точках, которых уже достиг. Изначально можем посчитать градиент только в $x^0$.
-

$$x^{k+1} \in x^0 + \text{span}\left\{\nabla f\left(x^0\right), \ldots, \nabla f\left(x^k\right)\right\}$$

**Вопрос:** подходят ли изученные методы под такое определение? Да, градиентный спуск, метод тяжелого шарика, ускоренный градиентный метод.

# Класс алгоритмов

- Дана начальная точка $x^0$. Эта начальная точка порождает множество всех достигнутых на данный момент точек.
- На текущем оракульном вызове метод может считать градиент функции во всех точках, которых уже достиг. Изначально можем посчитать градиент только в $x^0$.
-

$$x^{k+1} \in x^0 + \text{span}\left\{\nabla f\left(x^0\right), \ldots, \nabla f\left(x^k\right)\right\}$$

**Вопрос:** подходят ли изученные методы под такое определение? Да, градиентный спуск, метод тяжелого шарика, ускоренный градиентный метод.
**Вопрос:** все ли методы, которые считают градиент, здесь учтены?

# Класс алгоритмов

- Дана начальная точка $x^0$. Эта начальная точка порождает множество всех достигнутых на данный момент точек.
- На текущем оракульном вызове метод может считать градиент функции во всех точках, которых уже достиг. Изначально можем посчитать градиент только в $x^0$.
-

$$x^{k+1} \in x^0 + \text{span}\left\{\nabla f\left(x^0\right), \ldots, \nabla f\left(x^k\right)\right\}$$

**Вопрос:** подходят ли изученные методы под такое определение? Да, градиентный спуск, метод тяжелого шарика, ускоренный градиентный метод.
**Вопрос:** все ли методы, которые считают градиент, здесь учтены? Нет, почему?

# Класс алгоритмов

- Дана начальная точка $x^0$. Эта начальная точка порождает множество всех достигнутых на данный момент точек.
- На текущем оракульном вызове метод может считать градиент функции во всех точках, которых уже достиг. Изначально можем посчитать градиент только в $x^0$.
-

$$x^{k+1} \in x^0 + \text{span}\left\{\nabla f\left(x^0\right), \ldots, \nabla f\left(x^k\right)\right\}$$

**Вопрос:** подходят ли изученные методы под такое определение? Да, градиентный спуск, метод тяжелого шарика, ускоренный градиентный метод.
**Вопрос:** все ли методы, которые считают градиент, здесь учтены? Нет, почему? Нельзя скалярно перемножать градиенты.

# «Плохая» функция

Зафиксируем количество итераций метода $K$, размерность матрицы $d = 2K$ и построим квадратичную функцию

$$f(x) = \frac{L-\mu}{8}\langle x, Ax\rangle - \frac{L-\mu}{4}\langle e_1, x\rangle + \frac{\mu}{2}\|x\|_2^2,$$

где $A$ задана следующим образом:

$$A = \begin{pmatrix} 2 & -1 & 0 & \dots & 0 \\ -1 & 2 & -1 & \dots & 0 \\ 0 & -1 & 2 & \dots & 0 \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & 0 & \dots & 2 \end{pmatrix}.$$

# «Плохая» функция

Зафиксируем количество итераций метода $K$, размерность матрицы $d = 2K$ и построим квадратичную функцию

$$f(x) = \frac{L-\mu}{8}\langle x, Ax\rangle - \frac{L-\mu}{4}\langle e_1, x\rangle + \frac{\mu}{2}\|x\|_2^2,$$

где $A$ задана следующим образом:

$$A = \begin{pmatrix} 2 & -1 & 0 & \dots & 0 \\ -1 & 2 & -1 & \dots & 0 \\ 0 & -1 & 2 & \dots & 0 \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & 0 & \dots & 2 \end{pmatrix}.$$

Градиент $f$ будет равен:

$$\nabla f(x) = \frac{L-\mu}{4}Ax - \frac{L-\mu}{4}e_1 + \mu x.$$

# $L$–гладкость

Покажем, что $f$ будет $L$–гладкой:

$$\left\|\frac{L-\mu}{4}A(x-y)+\mu(x-y)\right\|_2 \leq \frac{L-\mu}{4}\|A\|_2\|x-y\|_2+\mu\|x-y\|_2$$
$$\leq L\|x-y\|_2,$$

спектральная норма матрицы $A$ ограничена 4, так как $A-4I_d$ отрицательно полуопределена.

# $\mu$–сильная выпуклость

Проверим, что $f$ будет $\mu$–сильно выпуклой:

$$\frac{L-\mu}{8}\langle y, Ay\rangle - \frac{L-\mu}{4}\langle e_1, y\rangle + \frac{\mu}{2}\|y\|_2^2$$
$$\geq \frac{L-\mu}{8}\langle x, Ax\rangle - \frac{L-\mu}{4}\langle e_1, x\rangle + \frac{\mu}{2}\|x\|_2^2$$
$$+ \left\langle \frac{L-\mu}{4}Ax - \frac{L-\mu}{4}e_1 + \mu x, y - x\right\rangle + \frac{\mu}{2}\|y-x\|_2^2.$$

Преобразуем выражение:

$$\frac{L-\mu}{8}\left(\langle y, Ay\rangle + \langle x, Ax\rangle - 2\langle y, Ax\rangle\right)$$
$$\geq \frac{\mu}{2}\|y-x\|_2^2 - \frac{\mu}{2}\|y\|_2^2 - \frac{\mu}{2}\|x\|_2^2 + \mu\langle x, y\rangle = 0.$$

Получаем, что $\langle (y-x), A(y-x)\rangle \geq 0$ — это верно, так как $A$ положительно полуопределена.

# Решение

**Вопрос:** что можем сказать про решение?

# Решение

**Вопрос:** что можем сказать про решение? У сильно выпуклой задачи единственное решение.

**Вопрос:** как найти?

# Решение

**Вопрос:** что можем сказать про решение? У сильно выпуклой задачи единственное решение.

**Вопрос:** как найти? Условие оптимальности: $\nabla f\left(x^*\right) = 0$. Распишем покомпонентно:

$$\frac{L+\mu}{2}x_1^* - \frac{L-\mu}{4}x_2^* = \frac{L-\mu}{4},$$

$$-\frac{L-\mu}{4}x_{i-1}^* + \frac{L+\mu}{2}x_i^* - \frac{L-\mu}{4}x_{i+1}^* = 0, \ i = \overline{2, d-1},$$

$$-\frac{L-\mu}{4}x_{d-1}^* + \frac{L+\mu}{2}x_d^* = 0.$$

# Решение

**Вопрос:** что можем сказать про решение? У сильно выпуклой задачи единственное решение.

**Вопрос:** как найти? Условие оптимальности: $\nabla f\left(x^*\right) = 0$. Распишем покомпонентно:

$$\frac{L+\mu}{2}x_1^* - \frac{L-\mu}{4}x_2^* = \frac{L-\mu}{4},$$
$$-\frac{L-\mu}{4}x_{i-1}^* + \frac{L+\mu}{2}x_i^* - \frac{L-\mu}{4}x_{i+1}^* = 0,\ i = \overline{2, d-1},$$
$$-\frac{L-\mu}{4}x_{d-1}^* + \frac{L+\mu}{2}x_d^* = 0.$$

Введём искусственные ограничения $x_0^* = 1$, а $x_{d+1}^* = 0$, тогда:

$$-\left(L-\mu\right)x_{i-1}^* + 2\left(L+\mu\right)x_i^* - \left(L-\mu\right)x_{i+1}^* = 0,\ i = \overline{1, d}.$$

# Решение

Решим полученную рекурренту, для этого запишем характеристическое уравнение:

$$\lambda^2 - 2\frac{L+\mu}{L-\mu}\lambda + 1 = 0 \implies \lambda_{1,2} = \frac{L+\mu}{L-\mu} \pm \sqrt{\left(\frac{L+\mu}{L-\mu}\right)^2 - 1} = \frac{L \pm 2\sqrt{L\mu} + \mu}{L-\mu}.$$

Тогда решение представимо в виде:

$$x_i^* = c_1\left(\frac{\sqrt{L}+\sqrt{\mu}}{\sqrt{L}-\sqrt{\mu}}\right)^i + c_2\left(\frac{\sqrt{L}-\sqrt{\mu}}{\sqrt{L}+\sqrt{\mu}}\right)^i.$$

# Решение

Учтём ограничения на $x_0^*$ и $x_{d+1}^*$:

$$c_1 + c_2 = 1,$$

$$c_1 \left( \frac{\sqrt{L} + \sqrt{\mu}}{\sqrt{L} - \sqrt{\mu}} \right)^{d+1} + c_2 \left( \frac{\sqrt{L} - \sqrt{\mu}}{\sqrt{L} + \sqrt{\mu}} \right)^{d+1} = 0.$$

Введём обозначение

$$q = \frac{\sqrt{L} - \sqrt{\mu}}{\sqrt{L} + \sqrt{\mu}},$$

тогда

$$x_i^* = -\frac{q^{2d+2}}{1 - q^{2d+2}} \frac{1}{q^i} + \frac{1}{1 - q^{2d+2}} q^i.$$

# Выход метода

Возьмём стартовую точку $x^0 = (0, \ldots, 0)^\top$. Градиент:

$$\nabla f(x) = \frac{L-\mu}{4} Ax - \frac{L-\mu}{4} e_1 + \mu x.$$

# Выход метода

Возьмём стартовую точку $x^0 = (0, \ldots, 0)^\top$. Градиент:

$$\nabla f(x) = \frac{L-\mu}{4} Ax - \frac{L-\mu}{4} e_1 + \mu x.$$

Заметим, что $\nabla f(x^0) \in \text{span}(e_1)$, поэтому получается, что за первый оракульный вызов только первая координата выхода метода может быть ненулевой.

# Выход метода

Возьмём стартовую точку $x^0 = (0, \ldots, 0)^\top$. Градиент:

$$\nabla f(x) = \frac{L-\mu}{4} Ax - \frac{L-\mu}{4} e_1 + \mu x.$$

Заметим, что $\nabla f(x^0) \in \text{span}(e_1)$, поэтому получается, что за первый оракульный вызов только первая координата выхода метода может быть ненулевой.
После второго — первые две и так далее. То есть
$\nabla f(x^k) \in \text{span}(e_1, e_2, \ldots, e_{k+1})$, тогда $x^{k+1} \in \text{span}(e_1, e_2, \ldots, e_{k+1})$.

# Выход метода

Возьмём стартовую точку $x^0 = (0, \ldots, 0)^\top$. Градиент:

$$\nabla f(x) = \frac{L-\mu}{4} Ax - \frac{L-\mu}{4} e_1 + \mu x.$$

Заметим, что $\nabla f(x^0) \in \text{span}(e_1)$, поэтому получается, что за первый оракульный вызов только первая координата выхода метода может быть ненулевой.
После второго — первые две и так далее. То есть
$\nabla f(x^k) \in \text{span}(e_1, e_2, \ldots, e_{k+1})$, тогда $x^{k+1} \in \text{span}(e_1, e_2, \ldots, e_{k+1})$.
После $K$ оракульных вызовов только первые $K$ координат могут быть ненулевыми, остальные точно нулевые.

# Гарантии

После $K$ вызовов оракула итоговый вывод можно оценить так (только первые $K$ координат ненулевые):

$$\left\|x^K - x^*\right\|_2^2 \geq \sum_{i=K+1}^{d} (x_i^*)^2.$$

# Гарантии

После $K$ вызовов оракула итоговый вывод можно оценить так (только первые $K$ координат ненулевые):

$$\left\|x^K - x^*\right\|_2^2 \geq \sum_{i=K+1}^{d} (x_i^*)^2.$$

Таким образом:

$$\begin{aligned}\left\|x^K - x^*\right\|_2^2 &\geq \sum_{i=K+1}^{d} \left(-\frac{q^{2d+2}}{1-q^{2d+2}}\frac{1}{q^i} + \frac{1}{1-q^{2d+2}}q^i\right)^2 \\ &= \frac{1}{\left(1-q^{2d+2}\right)^2}\sum_{i=K+1}^{d}\left(q^i - \frac{q^{2d+2}}{q^i}\right)^2 \\ &= \frac{1}{\left(1-q^{2d+2}\right)^2}\sum_{i=K+1}^{d} q^{2i}\left(1-q^{2d+2-2i}\right)^2.\end{aligned}$$

# Гарантии

Воспользуемся тем, что $q^{2d+2-2i} \leq q^2$:

$$\left\|x^K - x^*\right\|_2^2 \geq \frac{\left(1-q^2\right)^2}{(1-q^{2d+2})^2} \sum_{i=K+1}^{d} q^{2i} = \frac{\left(1-q^2\right)^2}{\left(1-q^{2d+2}\right)^2} \sum_{i=K+1}^{2K} q^{2i}$$

$$= \frac{\left(1-q^2\right)^2}{\left(1-q^{2d+2}\right)^2} q^{2K} \sum_{i=1}^{K} q^{2i}$$

$$= \left(1-q^2\right)^2 \frac{q^{2K}}{1+q^{2K}} \frac{1}{(1-q^{2d+2})^2} \left( \sum_{i=1}^{K} q^{2i} + q^{2K} \sum_{i=1}^{K} q^{2i} \right)$$

$$\geq \left(1-q^2\right)^2 \frac{q^{2K}}{1+q^{2K}} \left\|x^0 - x^*\right\|_2^2 \geq \left(1-q^2\right)^2 q^{2K} \frac{\left\|x^0 - x^*\right\|_2^2}{2}$$

$$\geq \frac{\mu}{L} \left( \frac{\sqrt{L} - \sqrt{\mu}}{\sqrt{L} + \sqrt{\mu}} \right)^{2K} \frac{\left\|x^0 - x^*\right\|_2^2}{2}.$$

# Гарантии

Воспользуемся неравенствами:

$$\log(1+x) \leq x, \quad \log(1-x) \geq -\frac{x}{1-x}, \quad x \in [0,1).$$

Тогда

$$\log\frac{1-x}{1+x} = \log(1-x) - \log(1+x) \geq -\frac{x}{1-x} - x = -\frac{2x}{1-x}.$$

Продолжим оценку:

$$\left\|x^K - x^*\right\|_2^2 \geq \exp\left(-\frac{4K\sqrt{\mu/L}}{1-\sqrt{\mu/L}}\right)\frac{\mu}{L}\frac{\left\|x^0 - x^*\right\|_2^2}{2}.$$

Тогда получаем:

$$K \geq \frac{1-\sqrt{\mu/L}}{4\sqrt{\mu/L}}\log\left(\frac{\mu}{L}\cdot\frac{\left\|x^0 - x^*\right\|_2^2}{2\varepsilon^2}\right) \implies K = \Omega\left(\sqrt{\frac{L}{\mu}}\log\frac{\left\|x^0 - x^*\right\|_2}{\varepsilon}\right).$$

# Нижняя оценка на оракульную сложность

**Теорема**

*Пусть задача безусловной оптимизации с $L$–гладкой $\mu$–сильно выпуклой функцией $f$ решается методом первого порядка. Тогда для достижения точности $\varepsilon$ по аргументу потребуется не менее*

$$\Omega\left(\sqrt{\frac{L}{\mu}}\log\frac{\left\|x^0 - x^*\right\|_2}{\varepsilon}\right) \quad \textit{оракульных вызовов.}$$

# Нижняя оценка на оракульную сложность

**Теорема**

*Пусть задача безусловной оптимизации с $L$–гладкой $\mu$–сильно выпуклой функцией $f$ решается методом первого порядка. Тогда для достижения точности $\varepsilon$ по аргументу потребуется не менее*

$$\Omega\left(\sqrt{\frac{L}{\mu}}\log\frac{\left\|x^0 - x^*\right\|_2}{\varepsilon}\right) \quad \textit{оракульных вызовов.}$$

- Ускоренный градиентный метод является оптимальным.

# Нижняя оценка на оракульную сложность

**Теорема**

*Пусть задача безусловной оптимизации с $L$–гладкой $\mu$–сильно выпуклой функцией $f$ решается методом первого порядка. Тогда для достижения точности $\varepsilon$ по аргументу потребуется не менее*

$$\Omega\left(\sqrt{\frac{L}{\mu}}\log\frac{\left\|x^0 - x^*\right\|_2}{\varepsilon}\right) \quad \textit{оракульных вызовов.}$$

- Ускоренный градиентный метод является оптимальным.
- Для $L$–гладких и выпуклых задач тоже.

# Линейный каплинг

Сейчас существуют модификации идеи Нестерова, которые также позволяют добиваться того же результата.

**Алгоритм** Линейный каплинг: внутренний цикл

**Вход:** стартовые точки $x^0 = y^0 = z^0 \in \mathbb{R}^d$, размеры шагов $\{\gamma_k\}_{k=0} > 0$ и $\{\eta_k\}_{k=0} > 0$, моментумы $\{\tau_k\}_{k=0} \in [0, 1]$, количество итераций $K$

**for** $k = 0, 1, \ldots, K-1$ **do**

$y^{k+1} = x^k - \eta_k \nabla f(x^k)$

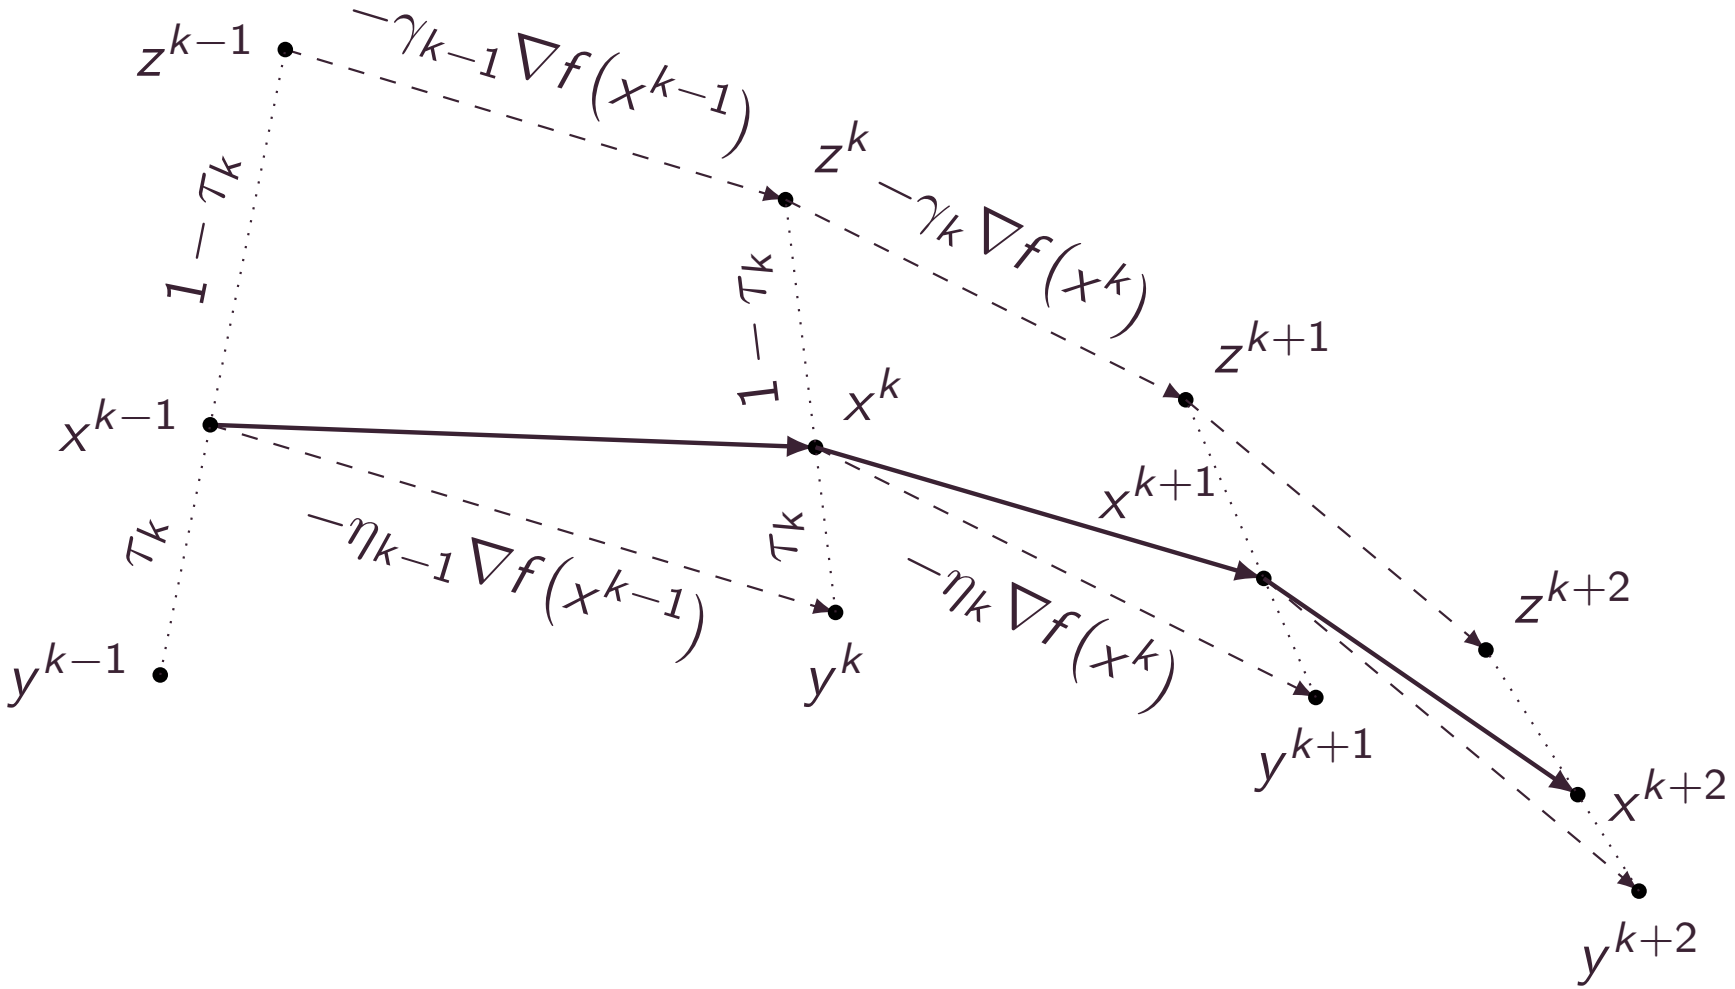
$z^{k+1} = z^k - \gamma_k \nabla f(x^k)$

$x^{k+1} = \tau_k z^{k+1} + (1 - \tau_k) y^{k+1}$

**end for**

**Выход:** $\frac{1}{K} \sum_{k=0}^{K-1} x^k$

# Линейный каплинг



# Доказательство

Воспользуемся строкой 3 Алгоритма:

$$\begin{aligned}\left\|z^{k+1}-x^*\right\|_2^2 &= \left\|z^k-\gamma\nabla f\left(x^k\right)-x^*\right\|_2^2\\ &= \left\|z^k-x^*\right\|_2^2-2\gamma\left\langle\nabla f\left(x^k\right),z^k-x^*\right\rangle+\gamma^2\left\|\nabla f\left(x^k\right)\right\|_2^2\\ &= \left\|z^k-x^*\right\|_2^2-2\gamma\left\langle\nabla f\left(x^k\right),x^k-x^*\right\rangle\\ &\quad-2\gamma\left\langle\nabla f\left(x^k\right),z^k-x^k\right\rangle+\gamma^2\left\|\nabla f\left(x^k\right)\right\|_2^2.\end{aligned}$$

# Доказательство

Воспользуемся строкой 3 Алгоритма:

$$\begin{aligned}\left\|z^{k+1}-x^*\right\|_2^2 &= \left\|z^k-\gamma\nabla f\left(x^k\right)-x^*\right\|_2^2\\ &= \left\|z^k-x^*\right\|_2^2-2\gamma\left\langle\nabla f\left(x^k\right),z^k-x^*\right\rangle+\gamma^2\left\|\nabla f\left(x^k\right)\right\|_2^2\\ &= \left\|z^k-x^*\right\|_2^2-2\gamma\left\langle\nabla f\left(x^k\right),x^k-x^*\right\rangle\\ &\quad-2\gamma\left\langle\nabla f\left(x^k\right),z^k-x^k\right\rangle+\gamma^2\left\|\nabla f\left(x^k\right)\right\|_2^2.\end{aligned}$$

Оценим $\left\|\nabla f\left(x^k\right)\right\|_2^2$, для этого применим свойство гладкой функции:

$$f\left(y^{k+1}\right)\leq f\left(x^k\right)+\left\langle\nabla f\left(x^k\right),y^{k+1}-x^k\right\rangle+\frac{L}{2}\left\|y^{k+1}-x^k\right\|_2^2.$$

# Доказательство

Воспользуемся строкой 2 Алгоритма:

$$f\left(y^{k+1}\right) \leq f\left(x^k\right) - \eta\left\|\nabla f\left(x^k\right)\right\|_2^2 + \frac{L\eta^2}{2}\left\|\nabla f\left(x^k\right)\right\|_2^2$$
$$= f\left(x^k\right) - \eta\left(1 - \frac{L\eta}{2}\right)\left\|\nabla f\left(x^k\right)\right\|_2^2.$$

Если $\eta < \frac{2}{L}$, то $\left(1 - \frac{L\eta}{2}\right) > 0$. Получаем оценку на квадрат нормы градиента:

$$\left\|\nabla f\left(x^k\right)\right\|_2^2 \leq \frac{2}{\eta\left(2 - L\eta\right)}\left(f\left(x^k\right) - f\left(y^{k+1}\right)\right).$$

# Доказательство

Воспользуемся строкой 2 Алгоритма:

$$f\left(y^{k+1}\right) \leq f\left(x^k\right) - \eta\left\|\nabla f\left(x^k\right)\right\|_2^2 + \frac{L\eta^2}{2}\left\|\nabla f\left(x^k\right)\right\|_2^2$$
$$= f\left(x^k\right) - \eta\left(1 - \frac{L\eta}{2}\right)\left\|\nabla f\left(x^k\right)\right\|_2^2.$$

Если $\eta < \frac{2}{L}$, то $\left(1 - \frac{L\eta}{2}\right) > 0$. Получаем оценку на квадрат нормы градиента:

$$\left\|\nabla f\left(x^k\right)\right\|_2^2 \leq \frac{2}{\eta\left(2 - L\eta\right)}\left(f\left(x^k\right) - f\left(y^{k+1}\right)\right).$$

Подставляя полученное выражение в исходное, получаем:

$$\left\|z^{k+1} - x^*\right\|_2^2 \leq \left\|z^k - x^*\right\|_2^2 - 2\gamma\left\langle\nabla f\left(x^k\right), x^k - x^*\right\rangle$$
$$+ \frac{2\gamma^2}{\eta\left(2 - L\eta\right)}\left(f\left(x^k\right) - f\left(y^{k+1}\right)\right) + 2\gamma\left\langle\nabla f\left(x^k\right), x^k - z^k\right\rangle.$$

# Доказательство

Теперь оценим $\left\langle \nabla f\left(x^k\right), x^k - z^k \right\rangle$, для этого задействуем строку 4 Алгоритма:

$$\left\langle \nabla f\left(x^k\right), x^k - z^k \right\rangle = \left\langle \nabla f\left(x^k\right), x^k - \frac{1}{\tau}\left(x^k - (1-\tau)y^k\right) \right\rangle$$
$$= \frac{1-\tau}{\tau}\left\langle \nabla f\left(x^k\right), y^k - x^k \right\rangle.$$

# Доказательство

Теперь оценим $\left\langle \nabla f\left(x^k\right), x^k - z^k \right\rangle$, для этого задействуем строку 4 Алгоритма:

$$\left\langle \nabla f\left(x^k\right), x^k - z^k \right\rangle = \left\langle \nabla f\left(x^k\right), x^k - \frac{1}{\tau}\left(x^k - (1-\tau)y^k\right) \right\rangle$$
$$= \frac{1-\tau}{\tau}\left\langle \nabla f\left(x^k\right), y^k - x^k \right\rangle.$$

Воспользуемся выпуклостью функции $f$:

$$\left\langle \nabla f\left(x^k\right), x^k - z^k \right\rangle \leq \frac{1-\tau}{\tau}\left(f\left(y^k\right) - f\left(x^k\right)\right).$$

# Доказательство

Теперь оценим $\left\langle \nabla f\left(x^k\right), x^k - z^k \right\rangle$, для этого задействуем строку 4 Алгоритма:

$$\left\langle \nabla f\left(x^k\right), x^k - z^k \right\rangle = \left\langle \nabla f\left(x^k\right), x^k - \frac{1}{\tau}\left(x^k - (1-\tau)y^k\right) \right\rangle$$
$$= \frac{1-\tau}{\tau}\left\langle \nabla f\left(x^k\right), y^k - x^k \right\rangle.$$

Воспользуемся выпуклостью функции $f$:

$$\left\langle \nabla f\left(x^k\right), x^k - z^k \right\rangle \leq \frac{1-\tau}{\tau}\left(f\left(y^k\right) - f\left(x^k\right)\right).$$

Объединим полученные оценки:

$$\left\|z^{k+1} - x^*\right\|_2^2 \leq \left\|z^k - x^*\right\|_2^2 - 2\gamma\left\langle \nabla f\left(x^k\right), x^k - x^* \right\rangle$$
$$+ \frac{2\gamma^2}{\eta\left(2 - L\eta\right)}\left(f\left(x^k\right) - f\left(y^{k+1}\right)\right) + 2\gamma\frac{1-\tau}{\tau}\left(f\left(y^k\right) - f\left(x^k\right)\right.$$

# Доказательство

Подберем $\tau$ так, что $\frac{1-\tau}{\tau} = \frac{\gamma}{\eta\left(2-L\eta\right)}$, тогда

$$\left\|z^{k+1} - x^*\right\|_2^2 \leq \left\|z^k - x^*\right\|_2^2 - 2\gamma\left\langle \nabla f\left(x^k\right), x^k - x^*\right\rangle + \frac{2\gamma^2}{\eta\left(2-L\eta\right)}\left(f\left(y^k\right) - f\left(y^{k+1}\right)\right).$$

# Доказательство

Подберем $\tau$ так, что $\frac{1-\tau}{\tau} = \frac{\gamma}{\eta\left(2-L\eta\right)}$, тогда

$$\left\|z^{k+1} - x^*\right\|_2^2 \leq \left\|z^k - x^*\right\|_2^2 - 2\gamma\left\langle \nabla f\left(x^k\right), x^k - x^*\right\rangle + \frac{2\gamma^2}{\eta\left(2-L\eta\right)}\left(f\left(y^k\right) - f\left(y^{k+1}\right)\right).$$

Сделаем перестановку:

$$2\gamma\left\langle \nabla f\left(x^k\right), x^k - x^*\right\rangle \leq \left\|z^k - x^*\right\|_2^2 - \left\|z^{k+1} - x^*\right\|_2^2 + \frac{2\gamma^2}{\eta\left(2-L\eta\right)}\left(f\left(y^k\right) - f\left(y^{k+1}\right)\right).$$

# Доказательство

Подберем $\tau$ так, что $\frac{1-\tau}{\tau} = \frac{\gamma}{\eta\left(2-L\eta\right)}$, тогда

$$\left\|z^{k+1} - x^*\right\|_2^2 \leq \left\|z^k - x^*\right\|_2^2 - 2\gamma\left\langle \nabla f\left(x^k\right), x^k - x^*\right\rangle + \frac{2\gamma^2}{\eta\left(2-L\eta\right)}\left(f\left(y^k\right) - f\left(y^{k+1}\right)\right).$$

Сделаем перестановку:

$$2\gamma\left\langle \nabla f\left(x^k\right), x^k - x^*\right\rangle \leq \left\|z^k - x^*\right\|_2^2 - \left\|z^{k+1} - x^*\right\|_2^2 + \frac{2\gamma^2}{\eta\left(2-L\eta\right)}\left(f\left(y^k\right) - f\left(y^{k+1}\right)\right).$$

Снова применяем выпуклость:

$$2\gamma\left(f\left(x^k\right) - f\left(x^*\right)\right) \leq \left\|z^k - x^*\right\|_2^2 - \left\|z^{k+1} - x^*\right\|_2^2 + \frac{2\gamma^2}{\eta\left(2-L\eta\right)}\left(f\left(y^k\right) - f\left(y^{k+1}\right)\right).$$

# Доказательство

Суммируем по всем $k$ от 0 до $K-1$, а потом делим на $K$:

$$\begin{aligned}
\frac{2\gamma}{K}\sum_{k=0}^{K-1}\left(f\left(x^k\right)-f^*\right) &\leq \frac{1}{K}\sum_{k=0}^{K-1}\left(\left\|z^k-x^*\right\|_2^2-\left\|z^{k+1}-x^*\right\|_2^2\right)\\
&\quad+\frac{2\gamma^2}{\eta\left(2-L\eta\right)K}\sum_{k=0}^{K-1}\left(f\left(y^k\right)-f\left(y^{k+1}\right)\right)\\
&=\frac{1}{K}\left(\left\|z^0-x^*\right\|_2^2-\left\|z^K-x^*\right\|_2^2\right)\\
&\quad+\frac{2\gamma^2}{\eta\left(2-L\eta\right)K}\left(f\left(y^0\right)-f\left(y^K\right)\right)\\
&\leq\frac{\left\|z^0-x^*\right\|_2^2}{K}+\frac{2\gamma^2\left(f\left(y^0\right)-f^*\right)}{\eta\left(2-L\eta\right)K}.
\end{aligned}$$

# Доказательство

Учитывая инициализацию $x^0 = y^0 = z^0$ и применяя неравенство Йенсена для выпуклой функции $f$, имеем

$$f\left(\frac{1}{K}\sum_{k=0}^{K-1} x^k\right) - f^* \leq \frac{\left\|x^0 - x^*\right\|_2^2}{2\gamma K} + \frac{\gamma\left(f\left(x^0\right) - f^*\right)}{\eta\left(2 - L\eta\right)K}.$$

# Доказательство

Учитывая инициализацию $x^0 = y^0 = z^0$ и применяя неравенство Йенсена для выпуклой функции $f$, имеем

$$f\left(\frac{1}{K}\sum_{k=0}^{K-1} x^k\right) - f^* \leq \frac{\left\|x^0 - x^*\right\|_2^2}{2\gamma K} + \frac{\gamma\left(f\left(x^0\right) - f^*\right)}{\eta\left(2 - L\eta\right)K}.$$

Казалось бы, полученный результат не является оптимальным: в выпуклом случае мы получили сублинейную скорость сходимости $\mathcal{O}(1/K)$, как у обычного градиентного спуска. У метода Нестерова мы получили $\mathcal{O}\left(1/K^2\right)$.

# Доказательство

Учитывая инициализацию $x^0 = y^0 = z^0$ и применяя неравенство Йенсена для выпуклой функции $f$, имеем

$$f\left(\frac{1}{K}\sum_{k=0}^{K-1} x^k\right) - f^* \leq \frac{\left\|x^0 - x^*\right\|_2^2}{2\gamma K} + \frac{\gamma\left(f\left(x^0\right) - f^*\right)}{\eta\left(2 - L\eta\right)K}.$$

Казалось бы, полученный результат не является оптимальным: в выпуклом случае мы получили сублинейную скорость сходимости $\mathcal{O}(1/K)$, как у обычного градиентного спуска. У метода Нестерова мы получили $\mathcal{O}\left(1/K^2\right)$. Дальше мы рассмотрим технику, которая позволит получить оптимальную скорость сходимости в сильно выпуклом случае — рестарты линейного каплинга.

# Линейный каплинг: рестарты

**Алгоритм** Линейный каплинг: рестарты

**Вход:** стартовая точка $x^0 \in \mathbb{R}^d$, количество итераций $T$

1: **for** $t = 0, 1, \ldots, T-1$ **do**
2: Запустить Алгоритм из $x^t$ с параметрами $\gamma$, $\eta$, $\tau$ на $K$ итераций
3: Получить $x^{t+1}$ на выходе Алгоритма
4: **end for**

**Выход:** $x^T$

# Доказательство

Применим к полученному неравенству сильную выпуклость, учитывая, что $\nabla f(x^*) = 0$:

$$f\left(\frac{1}{K}\sum_{k=0}^{K-1} x^k\right) - f^* \leq \frac{f(x^0) - f^*}{\mu\gamma K} + \frac{\gamma\left(f(x^0) - f^*\right)}{\eta(2 - L\eta)K}$$

$$= \left(\frac{1}{\mu\gamma K} + \frac{\gamma}{\eta(2 - L\eta)K}\right)\left(f(x^0) - f^*\right).$$

# Доказательство

Применим к полученному неравенству сильную выпуклость, учитывая, что $\nabla f(x^*) = 0$:

$$f\left(\frac{1}{K}\sum_{k=0}^{K-1} x^k\right) - f^* \leq \frac{f(x^0) - f^*}{\mu\gamma K} + \frac{\gamma\left(f(x^0) - f^*\right)}{\eta(2 - L\eta)K}$$

$$= \left(\frac{1}{\mu\gamma K} + \frac{\gamma}{\eta(2 - L\eta)K}\right)\left(f(x^0) - f^*\right).$$

Подберем $\eta$ оптимально, чтобы минимизировать правую часть оценки выше: $\eta = \frac{1}{L}$. Тогда

$$f\left(\frac{1}{K}\sum_{k=0}^{K-1} x^k\right) - f^* \leq \left(\frac{1}{\mu\gamma K} + \frac{\gamma L}{K}\right)\left(f(x^0) - f^*\right).$$

# Доказательство

Подберем теперь оптимальное $\gamma = \frac{1}{\sqrt{\mu L}}$:

$$f\left(\frac{1}{K}\sum_{k=0}^{K-1} x^k\right) - f^* \leq \sqrt{\frac{4L}{\mu K^2}}\left(f\left(x^0\right) - f^*\right).$$

# Доказательство

Подберем теперь оптимальное $\gamma = \frac{1}{\sqrt{\mu L}}$:

$$f\left(\frac{1}{K}\sum_{k=0}^{K-1} x^k\right) - f^* \leq \sqrt{\frac{4L}{\mu K^2}}\left(f\left(x^0\right) - f^*\right).$$

Положим $K = \sqrt{\frac{16L}{\mu}}$ и получим:

$$f\left(\frac{1}{K}\sum_{k=0}^{K-1} x^k\right) - f^* \leq \frac{1}{2}\left(f\left(x^0\right) - f^*\right).$$

# Доказательство

Подберем теперь оптимальное $\gamma = \frac{1}{\sqrt{\mu L}}$:

$$f\left(\frac{1}{K}\sum_{k=0}^{K-1} x^k\right) - f^* \leq \sqrt{\frac{4L}{\mu K^2}}\left(f\left(x^0\right) - f^*\right).$$

Положим $K = \sqrt{\frac{16L}{\mu}}$ и получим:

$$f\left(\frac{1}{K}\sum_{k=0}^{K-1} x^k\right) - f^* \leq \frac{1}{2}\left(f\left(x^0\right) - f^*\right).$$

Получается, что за один запуск линейного каплинга на $K$ итераций, мы гарантированно уменьшаем расстояние до решения по функции в 2 раза. А значит для одной итерации Алгоритма имеем

$$f\left(x^{t+1}\right) - f^* \leq \frac{1}{2}\left(f\left(x^t\right) - f^*\right).$$

# Доказательство

Запустим теперь рекурсию по $t$:

$$f\left(x^T\right) - f^* \leq \frac{1}{2^T}\left(f\left(x^0\right) - f^*\right).$$

Отсюда легко выразить число итераций Алгоритма для достижения точности $\varepsilon$ по функции:

$$T \geq \log_2 \left(\frac{f\left(x^0\right) - f^*}{\varepsilon}\right).$$

В данном случае оракульная сложность Алгоритма не совпадает с итерационной. Оракульную сложность можно получить следующим образом:

$$K \cdot T = \mathcal{O}\left(\sqrt{\frac{L}{\mu}} \log \frac{f\left(x^0\right) - f^*}{\varepsilon}\right).$$

# Сходимость линейного каплинга

## Теорема

*Пусть задача безусловной оптимизации с $L$–гладкой $\mu$–сильно выпуклой целевой функцией $f$ решается с помощью рестартов линейного каплинга. Тогда при* $\gamma = \frac{1}{\sqrt{\mu L}}$, $\eta = \frac{1}{L}$, $\frac{1-\tau}{\tau} = \frac{\gamma}{\eta\left(2-L\eta\right)}$,

$K = \sqrt{\frac{16L}{\mu}}$, *чтобы добиться точности* $\varepsilon$ *по функции, достаточно*

$$\mathcal{O}\left(\sqrt{\frac{L}{\mu}}\log\frac{f\left(x^0\right)-f^*}{\varepsilon}\right) \quad \textit{оракульных вызовов.}$$