

Градиентный спуск

Методы оптимизации

Александр Безносиков

Московский физико-технический институт

24 сентября 2026



Вопрос с прошлой лекции

- Была получена верхняя оценка на сходимость градиентного спуска для L -гладких и μ -сильно выпуклых задач.
Вопрос: сколько оракульных вызовов нужно сделать, чтобы найти ε -решение?

Вопрос с прошлой лекции

- Была получена верхняя оценка на сходимость градиентного спуска для L -гладких и μ -сильно выпуклых задач.

Вопрос: сколько оракульных вызовов нужно сделать, чтобы найти ε -решение?

$$K = \mathcal{O}\left(\frac{L}{\mu} \log \frac{\|x^0 - x^*\|_2}{\varepsilon}\right) \text{ оракульных вызовов.}$$

Вопрос с прошлой лекции

- Была получена верхняя оценка на сходимость градиентного спуска для L -гладких и μ -сильно выпуклых задач.

Вопрос: сколько оракульных вызовов нужно сделать, чтобы найти ε -решение?

$$K = \mathcal{O}\left(\frac{L}{\mu} \log \frac{\|x^0 - x^*\|_2}{\varepsilon}\right) \text{ оракульных вызовов.}$$

- **Вопрос:** можно ли сделать лучше?

Вопрос с прошлой лекции

- Была получена верхняя оценка на сходимость градиентного спуска для L -гладких и μ -сильно выпуклых задач.

Вопрос: сколько оракульных вызовов нужно сделать, чтобы найти ε -решение?

$$K = \mathcal{O}\left(\frac{L}{\mu} \log \frac{\|x^0 - x^*\|_2}{\varepsilon}\right) \text{ оракульных вызовов.}$$

- Вопрос:** можно ли сделать лучше? Да, можно.

Метод тяжелого шарика

Б.Т. Поляк в 1964 году предложил метод тяжелого шарика.

Алгоритм Метод тяжёлого шарика

Вход: стартовая точка $x^0 = x^{-1} \in \mathbb{R}^d$, размеры шагов $\{\gamma_k\}_{k=0} > 0$,
моментумы $\{\tau_k\}_{k=0} \in [0, 1]$, количество итераций K

1: **for** $k = 0, 1, \dots, K - 1$ **do**

2: $x^{k+1} = x^k - \gamma_k \nabla f(x^k) + \tau_k (x^k - x^{k-1})$

3: **end for**

Выход: x^K

Метод тяжелого шарика

Б.Т. Поляк в 1964 году предложил метод тяжелого шарика.

Алгоритм Метод тяжёлого шарика

Вход: стартовая точка $x^0 = x^{-1} \in \mathbb{R}^d$, размеры шагов $\{\gamma_k\}_{k=0} > 0$,
моментумы $\{\tau_k\}_{k=0} \in [0, 1]$, количество итераций K

1: **for** $k = 0, 1, \dots, K - 1$ **do**

2: $x^{k+1} = x^k - \gamma_k \nabla f(x^k) + \tau_k (x^k - x^{k-1})$

3: **end for**

Выход: x^K

Добавим к градиентному спуску моментумный член — предположим, что у точки, отвечающей за текущее положение значение x^k есть инерция.

Сравнение тяжелого шарика и градиентного спуска




Рис. 1: Градиентный спуск.




Рис. 2: Метод тяжёлого шарика.

Связь с PyTorch

- В библиотеке PyTorch реализован следующий метод:

$$v^{k+1} = \beta v^k + \nabla f(x^k) \quad \beta \in [0, 1]$$

$$x^{k+1} = x^k - \gamma v^{k+1}$$

Связь с PyTorch

- В библиотеке PyTorch реализован следующий метод:

$$v^{k+1} = \beta v^k + \nabla f(x^k) \quad \beta \in [0, 1]$$

$$x^{k+1} = x^k - \gamma v^{k+1}$$

Вопрос: как это метод связан с методом тяжелого шарика?

Связь с PyTorch

- В библиотеке PyTorch реализован следующий метод:

$$v^{k+1} = \beta v^k + \nabla f(x^k) \quad \beta \in [0, 1]$$

$$x^{k+1} = x^k - \gamma v^{k+1}$$

Вопрос: как это метод связан с методом тяжелого шарика? Это практически он и есть. Поставим первую строку во вторую:

$$x^{k+1} = x^k - \gamma \nabla f(x^k) - \gamma \beta v^k$$

Связь с PyTorch

- В библиотеке PyTorch реализован следующий метод:

$$v^{k+1} = \beta v^k + \nabla f(x^k) \quad \beta \in [0, 1]$$

$$x^{k+1} = x^k - \gamma v^{k+1}$$

Вопрос: как это метод связан с методом тяжелого шарика? Это практически он и есть. Поставим первую строку во вторую:

$$x^{k+1} = x^k - \gamma \nabla f(x^k) - \gamma \beta v^k$$

Из второй строки для k шага:

$$-\gamma v^k = x^k - x^{k-1}$$

Связь с PyTorch

- В библиотеке PyTorch реализован следующий метод:

$$\begin{aligned}v^{k+1} &= \beta v^k + \nabla f(x^k) \quad \beta \in [0, 1] \\x^{k+1} &= x^k - \gamma v^{k+1}\end{aligned}$$

Вопрос: как это метод связан с методом тяжелого шарика? Это практически он и есть. Поставим первую строку во вторую:

$$x^{k+1} = x^k - \gamma \nabla f(x^k) - \gamma \beta v^k$$

Из второй строки для k шага:

$$-\gamma v^k = x^k - x^{k-1}$$

Тогда подставим в предыдущие и получим

$$x^{k+1} = x^k - \gamma \nabla f(x^k) + \beta(x^k - x^{k-1})$$

Это показывает еще одну физику метода тяжелого шарика — мы идем по аккумулярованному градиенту.

Плюсы и минусы

Вопрос: какие плюсы и минусы видите у методы тяжелого шарика?

Плюсы и минусы

Вопрос: какие плюсы и минусы видите у методы тяжелого шарика?

Плюсы

- Понятная физика и интуиция.
- Легкость в имплементации.
- Дешевизна вычислений.

Минусы

- Нужно подбирать теперь 2 параметра. Мы сейчас умеем только в теории оценивать γ_k . Теперь что-то нужно делать с τ_k .
- Мы шли за ускорением градиентного спуска. А оно вообще есть в общем случае?

Сходимость

Теорема

Пусть имеется квадратичная функция $f(x) = \frac{1}{2}\langle x, Ax \rangle - \langle b, x \rangle$, где A — матрица с положительными собственными числами на отрезке $[\mu, L]$. Пусть задача безусловной оптимизации решается методом тяжёлого шарика. Тогда при

$$\gamma_k = \gamma = \frac{4}{(\sqrt{L} + \sqrt{\mu})^2}, \quad \tau_k = \tau = \left(\frac{\sqrt{L} - \sqrt{\mu}}{\sqrt{L} + \sqrt{\mu}} \right)^2$$

для точности сходимости ε по аргументу, необходимо

$$K = \mathcal{O}\left(\sqrt{\frac{L}{\mu}} \log \frac{\|x^0 - x^*\|_2}{\varepsilon}\right) \text{ итераций.}$$

Сходимость

Теорема

Пусть имеется квадратичная функция $f(x) = \frac{1}{2}\langle x, Ax \rangle - \langle b, x \rangle$, где A — матрица с положительными собственными числами на отрезке $[\mu, L]$. Пусть задача безусловной оптимизации решается методом тяжёлого шарика. Тогда при

$$\gamma_k = \gamma = \frac{4}{(\sqrt{L} + \sqrt{\mu})^2}, \quad \tau_k = \tau = \left(\frac{\sqrt{L} - \sqrt{\mu}}{\sqrt{L} + \sqrt{\mu}} \right)^2$$

для точности сходимости ε по аргументу, необходимо

$$K = \mathcal{O}\left(\sqrt{\frac{L}{\mu}} \log \frac{\|x^0 - x^*\|_2}{\varepsilon}\right) \text{ итераций.}$$

В общем случае ускорения нет.

Ускоренный градиентный метод

Ю.Е. Нестеров в 1983 году предложил ускоренный градиентный метод.

Алгоритм Ускоренный градиентный метод (Метод Нестерова)

Вход: стартовые точки $x^0 = x^{-1} \in \mathbb{R}^d$, размеры шагов $\{\gamma_k\}_{k=0} > 0$,
моментумы $\{\tau_k\}_{k=0} \in [0, 1]$, количество итераций K

- 1: **for** $k = 0, 1, \dots, K - 1$ **do**
- 2: $y^k = x^k + \tau_k(x^k - x^{k-1})$
- 3: $x^{k+1} = y^k - \gamma_k \nabla f(y^k)$
- 4: **end for**

Выход: x^K

Ускоренный градиентный метод и тяжелый шарик

Вопрос: в чем ключевое отличие метода Нестерова от тяжелого шарика?

Тяжелый шарик:

$$x^{k+1} = x^k - \gamma_k \nabla f(x^k) + \tau_k (x^k - x^{k-1})$$

Ускоренный градиентный метод:

$$\begin{aligned} y^k &= x^k + \tau_k (x^k - x^{k-1}) \\ x^{k+1} &= y^k - \gamma_k \nabla f(y^k) \end{aligned}$$

Ускоренный градиентный метод и тяжелый шарик

Вопрос: в чем ключевое отличие метода Нестерова от тяжелого шарика?

Тяжелый шарик:

$$x^{k+1} = x^k - \gamma_k \nabla f(x^k) + \tau_k (x^k - x^{k-1})$$

Ускоренный градиентный метод:

$$\begin{aligned} y^k &= x^k + \tau_k (x^k - x^{k-1}) \\ x^{k+1} &= y^k - \gamma_k \nabla f(y^k) \end{aligned}$$

Перепишем ускоренный градиентный метод:

$$x^{k+1} = x^k - \gamma_k \nabla f\left(x^k + \tau_k (x^k - x^{k-1})\right) + \tau_k (x^k - x^{k-1})$$

Сравнение




Рис. 3: Градиентный спуск




Рис. 4: Метод тяжёлого шарика




Рис. 5: Метод Нестерова

Сходимость метода Нестерова

Теорема

Пусть задача безусловной оптимизации с L -гладкой μ -сильно выпуклой целевой функцией f решается с помощью ускоренного градиентного метода. Тогда при $\gamma_k = \frac{1}{L}$, $\tau_k = \frac{\sqrt{L} - \sqrt{\mu}}{\sqrt{L} + \sqrt{\mu}}$ справедлива следующая оценка сходимости:

$$f(x^K) - f^* \leq \left(1 - \sqrt{\frac{\mu}{L}}\right)^K \cdot L \|x^0 - x^*\|_2^2.$$

Более того, чтобы добиться точности ε по аргументу, необходимо

$$K = \mathcal{O}\left(\sqrt{\frac{L}{\mu}} \log\left(\frac{\|x^0 - x^*\|_2}{\varepsilon}\right)\right) \text{ итераций.}$$

Замечание: В доказательстве используется **функция Ляпунова**:

$$V_k := f(x^k) - f^* + \frac{L}{2} \|x^k - x^* - \rho^2(x^{k-1} - x^*)\|_2^2$$

Сходимость метода Нестерова

Утверждение

Пусть задача безусловной оптимизации с L -гладкой выпуклой целевой функцией f решается с помощью ускоренного градиентного метода. Тогда при $\gamma_k = \frac{1}{L}$, $\tau_k = \frac{k}{k+3}$ справедлива следующая оценка сходимости:

$$f(x^K) - f^* \leq \frac{2L \|x^0 - x^*\|_2^2}{(K+2)^2}.$$

Более того, чтобы достичь точности ε по функции, необходимо

$$K = \mathcal{O}\left(\sqrt{\frac{L \|x^0 - x^*\|_2^2}{\varepsilon}}\right) \text{ итераций.}$$

Вопросы остаются

- Метод лучше градиентного спуска.
- Но можно ли еще лучше?
- **Вопрос:** как понять, можно ли лучше?

Вопросы остаются

- Метод лучше градиентного спуска.
- Но можно ли еще лучше?
- **Вопрос:** как понять, можно ли лучше? Получить нижние оценки.

Вопросы остаются

- Метод лучше градиентного спуска.
- Но можно ли еще лучше?
- **Вопрос:** как понять, можно ли лучше? Получить нижние оценки.
- Для получения нижних оценок нужно придумать не метод, а «плохую» функцию, которую будет «долго» оптимизировать любой метод. **Вопрос:** а что здесь значит «любой метод»?

Вопросы остаются

- Метод лучше градиентного спуска.
- Но можно ли еще лучше?
- **Вопрос:** как понять, можно ли лучше? Получить нижние оценки.
- Для получения нижних оценок нужно придумать не метод, а «плохую» функцию, которую будет «долго» оптимизировать любой метод. **Вопрос:** а что здесь значит «любой метод»? Надо определить класс методов.

Класс алгоритмов

- Дана начальная точка x^0 . Эта начальная точка порождает множество всех достигнутых на данный момент точек.

Класс алгоритмов

- Дана начальная точка x^0 . Эта начальная точка порождает множество всех достигнутых на данный момент точек.
- На текущем оракульном вызове метод может считать градиент функции во всех точках, которых уже достиг. Изначально можем посчитать градиент только в x^0 .

Класс алгоритмов

- Дана начальная точка x^0 . Эта начальная точка порождает множество всех достигнутых на данный момент точек.
- На текущем оракульном вызове метод может считать градиент функции во всех точках, которых уже достиг. Изначально можем посчитать градиент только в x^0 .
-

$$x^{k+1} \in x^0 + \text{span} \left\{ \nabla f(x^0), \dots, \nabla f(x^k) \right\}$$

Класс алгоритмов

- Дана начальная точка x^0 . Эта начальная точка порождает множество всех достигнутых на данный момент точек.
- На текущем оракульном вызове метод может считать градиент функции во всех точках, которых уже достиг. Изначально можем посчитать градиент только в x^0 .
-

$$x^{k+1} \in x^0 + \text{span} \left\{ \nabla f(x^0), \dots, \nabla f(x^k) \right\}$$

Класс алгоритмов

- Дана начальная точка x^0 . Эта начальная точка порождает множество всех достигнутых на данный момент точек.
- На текущем оракульном вызове метод может считать градиент функции во всех точках, которых уже достиг. Изначально можем посчитать градиент только в x^0 .
-

$$x^{k+1} \in x^0 + \text{span} \left\{ \nabla f(x^0), \dots, \nabla f(x^k) \right\}$$

Вопрос: подходят ли изученные методы, под такое определение?

Класс алгоритмов

- Дана начальная точка x^0 . Эта начальная точка порождает множество всех достигнутых на данный момент точек.
- На текущем оракульном вызове метод может считать градиент функции во всех точках, которых уже достиг. Изначально можем посчитать градиент только в x^0 .
-

$$x^{k+1} \in x^0 + \text{span} \left\{ \nabla f(x^0), \dots, \nabla f(x^k) \right\}$$

Вопрос: подходят ли изученные методы, под такое определение? Да, градиентный спуск, метод тяжелого шарика, ускоренный градиентный метод.

Класс алгоритмов

- Дана начальная точка x^0 . Эта начальная точка порождает множество всех достигнутых на данный момент точек.
- На текущем оракульном вызове метод может считать градиент функции во всех точках, которых уже достиг. Изначально можем посчитать градиент только в x^0 .
-

$$x^{k+1} \in x^0 + \text{span} \left\{ \nabla f(x^0), \dots, \nabla f(x^k) \right\}$$

Вопрос: подходят ли изученные методы, под такое определение? Да, градиентный спуск, метод тяжелого шарика, ускоренный градиентный метод.

Вопрос: все ли методы, которые считают градиент здесь учтены?

Класс алгоритмов

- Дана начальная точка x^0 . Эта начальная точка порождает множество всех достигнутых на данный момент точек.
- На текущем оракульном вызове метод может считать градиент функции во всех точках, которых уже достиг. Изначально можем посчитать градиент только в x^0 .
-

$$x^{k+1} \in x^0 + \text{span} \left\{ \nabla f(x^0), \dots, \nabla f(x^k) \right\}$$

Вопрос: подходят ли изученные методы, под такое определение? Да, градиентный спуск, метод тяжелого шарика, ускоренный градиентный метод.

Вопрос: все ли методы, которые считают градиент здесь учтены? Нет, почему?

Класс алгоритмов

- Дана начальная точка x^0 . Эта начальная точка порождает множество всех достигнутых на данный момент точек.
- На текущем оракульном вызове метод может считать градиент функции во всех точках, которых уже достиг. Изначально можем посчитать градиент только в x^0 .
-

$$x^{k+1} \in x^0 + \text{span} \left\{ \nabla f(x^0), \dots, \nabla f(x^k) \right\}$$

Вопрос: подходят ли изученные методы, под такое определение? Да, градиентный спуск, метод тяжелого шарика, ускоренный градиентный метод.

Вопрос: все ли методы, которые считают градиент здесь учтены? Нет, почему? Нельзя скалярно перемножать градиенты.

«Плохая» функция

Зафиксируем количество итераций метода K , размерность матрицы $d = 2K$ и построим квадратичную функцию

$$f(x) = \frac{L - \mu}{8} \langle x, Ax \rangle - \frac{L - \mu}{4} \langle e_1, x \rangle + \frac{\mu}{2} \|x\|_2^2,$$

где A задана следующим образом:

$$A = \begin{pmatrix} 2 & -1 & 0 & \dots & 0 \\ -1 & 2 & -1 & \dots & 0 \\ 0 & -1 & 2 & \dots & 0 \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & 0 & \dots & 2 \end{pmatrix}.$$

«Плохая» функция

Зафиксируем количество итераций метода K , размерность матрицы $d = 2K$ и построим квадратичную функцию

$$f(x) = \frac{L - \mu}{8} \langle x, Ax \rangle - \frac{L - \mu}{4} \langle e_1, x \rangle + \frac{\mu}{2} \|x\|_2^2,$$

где A задана следующим образом:

$$A = \begin{pmatrix} 2 & -1 & 0 & \dots & 0 \\ -1 & 2 & -1 & \dots & 0 \\ 0 & -1 & 2 & \dots & 0 \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & 0 & \dots & 2 \end{pmatrix}.$$

Градиент f будет равен:

$$\nabla f(x) = \frac{L - \mu}{4} Ax - \frac{L - \mu}{4} e_1 + \mu x.$$

L -гладкость

Покажем, что f будет L -гладкой:

$$\begin{aligned}\left\| \frac{L - \mu}{4} A(x - y) + \mu(x - y) \right\|_2 &\leq \frac{L - \mu}{4} \|A\|_2 \|x - y\|_2 + \mu \|x - y\|_2 \\ &\leq L \|x - y\|_2,\end{aligned}$$

спектральная норма матрицы A ограничена 4, так как $A - 4I_d$ отрицательно полуопределена.

μ -сильная выпуклость

Проверим, что f будет μ -сильно выпуклой:

$$\begin{aligned} & \frac{L-\mu}{8} \langle y, Ay \rangle - \frac{L-\mu}{4} \langle e_1, y \rangle + \frac{\mu}{2} \|y\|_2^2 \\ & \geq \frac{L-\mu}{8} \langle x, Ax \rangle - \frac{L-\mu}{4} \langle e_1, x \rangle + \frac{\mu}{2} \|x\|_2^2 \\ & \quad + \left\langle \frac{L-\mu}{4} Ax - \frac{L-\mu}{4} e_1 + \mu x, y - x \right\rangle + \frac{\mu}{2} \|y - x\|_2^2. \end{aligned}$$

Преобразуем выражение:

$$\begin{aligned} & \frac{L-\mu}{8} (\langle y, Ay \rangle + \langle x, Ax \rangle - 2\langle y, Ax \rangle) \\ & \geq \frac{\mu}{2} \|y - x\|_2^2 - \frac{\mu}{2} \|y\|_2^2 - \frac{\mu}{2} \|x\|_2^2 + \mu \langle x, y \rangle = 0. \end{aligned}$$

Получаем, что $\langle (y - x), A(y - x) \rangle \geq 0$ — это верно, так как A положительно полуопределена.

Решение

Вопрос: что можем сказать про решение?

Решение

Вопрос: что можем сказать про решение? У сильно выпуклой задачи единственное решение.

Вопрос: как найти?

Решение

Вопрос: что можем сказать про решение? У сильно выпуклой задачи единственное решение.

Вопрос: как найти? Условие оптимальности: $\nabla f(x^*) = 0$. Распишем покомпонентно:

$$\begin{aligned}\frac{L + \mu}{2}x_1^* - \frac{L - \mu}{4}x_2^* &= \frac{L - \mu}{4}, \\ -\frac{L - \mu}{4}x_{i-1}^* + \frac{L + \mu}{2}x_i^* - \frac{L - \mu}{4}x_{i+1}^* &= 0, \quad i = \overline{2, d-1}, \\ -\frac{L - \mu}{4}x_{d-1}^* + \frac{L + \mu}{2}x_d^* &= 0.\end{aligned}$$

Решение

Вопрос: что можем сказать про решение? У сильно выпуклой задачи единственное решение.

Вопрос: как найти? Условие оптимальности: $\nabla f(x^*) = 0$. Распишем покомпонентно:

$$\begin{aligned}\frac{L + \mu}{2}x_1^* - \frac{L - \mu}{4}x_2^* &= \frac{L - \mu}{4}, \\ -\frac{L - \mu}{4}x_{i-1}^* + \frac{L + \mu}{2}x_i^* - \frac{L - \mu}{4}x_{i+1}^* &= 0, \quad i = \overline{2, d-1}, \\ -\frac{L - \mu}{4}x_{d-1}^* + \frac{L + \mu}{2}x_d^* &= 0.\end{aligned}$$

Введём искусственные ограничения $x_0^* = 1$, а $x_{d+1}^* = 0$, тогда:

$$-(L - \mu)x_{i-1}^* + 2(L + \mu)x_i^* - (L - \mu)x_{i+1}^* = 0, \quad i = \overline{1, d}.$$

Решение

Решим полученную рекурренту, для этого запишем характеристическое уравнение:

$$\lambda^2 - 2\frac{L+\mu}{L-\mu}\lambda + 1 = 0 \implies \lambda_{1,2} = \frac{L+\mu}{L-\mu} \pm \sqrt{\left(\frac{L+\mu}{L-\mu}\right)^2 - 1}$$
$$= \frac{L \pm 2\sqrt{L\mu} + \mu}{L - \mu}.$$

Тогда решение представимо в виде:

$$x_i^* = c_1 \left(\frac{\sqrt{L} + \sqrt{\mu}}{\sqrt{L} - \sqrt{\mu}} \right)^i + c_2 \left(\frac{\sqrt{L} - \sqrt{\mu}}{\sqrt{L} + \sqrt{\mu}} \right)^i.$$

Решение

Учтём ограничения на x_0^* и x_{d+1}^* :

$$\begin{aligned} c_1 + c_2 &= 1, \\ c_1 \left(\frac{\sqrt{L} + \sqrt{\mu}}{\sqrt{L} - \sqrt{\mu}} \right)^{d+1} + c_2 \left(\frac{\sqrt{L} - \sqrt{\mu}}{\sqrt{L} + \sqrt{\mu}} \right)^{d+1} &= 0. \end{aligned}$$

Введём обозначение

$$q = \frac{\sqrt{L} - \sqrt{\mu}}{\sqrt{L} + \sqrt{\mu}},$$

тогда

$$x_i^* = -\frac{q^{2d+2}}{1 - q^{2d+2}} \frac{1}{q^i} + \frac{1}{1 - q^{2d+2}} q^i.$$

Выход метода

Возьмём стартовую точку $x^0 = (0, \dots, 0)^\top$. Градиент:

$$\nabla f(x) = \frac{L - \mu}{4} Ax - \frac{L - \mu}{4} e_1 + \mu x.$$

Выход метода

Возьмём стартовую точку $x^0 = (0, \dots, 0)^\top$. Градиент:

$$\nabla f(x) = \frac{L - \mu}{4} Ax - \frac{L - \mu}{4} e_1 + \mu x.$$

Заметим, что $\nabla f(x^0) \in \text{span}(e_1)$, поэтому получается, что за первый оракульный вызов только первая координата выхода метода может быть ненулевой.

Выход метода

Возьмём стартовую точку $x^0 = (0, \dots, 0)^\top$. Градиент:

$$\nabla f(x) = \frac{L - \mu}{4} Ax - \frac{L - \mu}{4} e_1 + \mu x.$$

Заметим, что $\nabla f(x^0) \in \text{span}(e_1)$, поэтому получается, что за первый оракульный вызов только первая координата выхода метода может быть ненулевой.

После второго — первые две и так далее. То есть $\nabla f(x^k) \in \text{span}(e_1, e_2, \dots, e_{k+1})$, тогда $x^{k+1} \in \text{span}(e_1, e_2, \dots, e_{k+1})$.

Выход метода

Возьмём стартовую точку $x^0 = (0, \dots, 0)^\top$. Градиент:

$$\nabla f(x) = \frac{L - \mu}{4} Ax - \frac{L - \mu}{4} e_1 + \mu x.$$

Заметим, что $\nabla f(x^0) \in \text{span}(e_1)$, поэтому получается, что за первый оракульный вызов только первая координата выхода метода может быть ненулевой.

После второго — первые две и так далее. То есть $\nabla f(x^k) \in \text{span}(e_1, e_2, \dots, e_{k+1})$, тогда $x^{k+1} \in \text{span}(e_1, e_2, \dots, e_{k+1})$. После K оракульных вызовов только первые K координат могут быть ненулевыми, остальные точно нулевые.

Гарантии

После K вызовов оракула итоговый вывод можно оценить так (только первые K координат ненулевые):

$$\|x^K - x^*\|_2^2 \geq \sum_{i=K+1}^d (x_i^*)^2.$$

Гарантии

После K вызовов оракула итоговый вывод можно оценить так (только первые K координат ненулевые):

$$\|x^K - x^*\|_2^2 \geq \sum_{i=K+1}^d (x_i^*)^2.$$

Таким образом:

$$\begin{aligned} \|x^K - x^*\|_2^2 &\geq \sum_{i=K+1}^d \left(-\frac{q^{2d+2}}{1 - q^{2d+2}} \frac{1}{q^i} + \frac{1}{1 - q^{2d+2}} q^i \right)^2 \\ &= \frac{1}{(1 - q^{2d+2})^2} \sum_{i=K+1}^d \left(q^i - \frac{q^{2d+2}}{q^i} \right)^2 \\ &= \frac{1}{(1 - q^{2d+2})^2} \sum_{i=K+1}^d q^{2i} (1 - q^{2d+2-2i})^2. \end{aligned}$$

Гарантии

Воспользуемся тем, что $q^{2d+2-2i} \leq q^2$:

$$\begin{aligned}\|x^K - x^*\|_2^2 &\geq \frac{(1 - q^2)^2}{(1 - q^{2d+2})^2} \sum_{i=K+1}^d q^{2i} = \frac{(1 - q^2)^2}{(1 - q^{2d+2})^2} \sum_{i=K+1}^{2K} q^{2i} \\&= \frac{(1 - q^2)^2}{(1 - q^{2d+2})^2} q^{2K} \sum_{i=1}^K q^{2i} \\&= (1 - q^2)^2 \frac{q^{2K}}{1 + q^{2K}} \frac{1}{(1 - q^{2d+2})^2} \left(\sum_{i=1}^K q^{2i} + q^{2K} \sum_{i=1}^K q^{2i} \right) \\&\geq (1 - q^2)^2 \frac{q^{2K}}{1 + q^{2K}} \|x^0 - x^*\|_2^2 \geq (1 - q^2)^2 q^{2K} \frac{\|x^0 - x^*\|_2^2}{2} \\&= \frac{L}{\mu} \left(\frac{\sqrt{L} - \sqrt{\mu}}{\sqrt{L} + \sqrt{\mu}} \right)^{2K} \frac{\|x^0 - x^*\|_2^2}{2}.\end{aligned}$$

Гарантии

Воспользуемся неравенствами:

$$\log(1+x) \leq x, \quad \log(1-x) \geq -\frac{x}{1-x}, \quad x \in [0,1).$$

Тогда

$$\log \frac{1-x}{1+x} = \log(1-x) - \log(1+x) \geq -\frac{x}{1-x} - x = -\frac{2x}{1-x}.$$

Продолжим оценку:

$$\|x^K - x^*\|_2^2 \geq \exp\left(-\frac{4K\sqrt{\mu/L}}{1-\sqrt{\mu/L}}\right) \frac{L}{\mu} \frac{\|x^0 - x^*\|_2^2}{2}.$$

Тогда получаем:

$$K \geq \frac{1-\sqrt{\mu/L}}{4\sqrt{\mu/L}} \log\left(\frac{L}{\mu} \cdot \frac{\|x^0 - x^*\|_2^2}{2\varepsilon^2}\right) \implies K = \Omega\left(\sqrt{\frac{L}{\mu}} \log \frac{\|x^0 - x^*\|_2}{\varepsilon}\right).$$

Нижняя оценка на оракульную сложность

Теорема

Пусть задача безусловной оптимизации с L -гладкой μ -сильно выпуклой функцией f решается методом первого порядка. Тогда для достижения точности ε по аргументу потребуется не менее

$$\Omega\left(\sqrt{\frac{L}{\mu}} \log \frac{\|x^0 - x^*\|_2}{\varepsilon}\right) \text{ оракульных вызовов.}$$

Нижняя оценка на оракульную сложность

Теорема

Пусть задача безусловной оптимизации с L -гладкой μ -сильно выпуклой функцией f решается методом первого порядка. Тогда для достижения точности ε по аргументу потребуется не менее

$$\Omega\left(\sqrt{\frac{L}{\mu}} \log \frac{\|x^0 - x^*\|_2}{\varepsilon}\right) \text{ оракульных вызовов.}$$

- Ускоренный градиентный метод является оптимальным.

Нижняя оценка на оракульную сложность

Теорема

Пусть задача безусловной оптимизации с L -гладкой μ -сильно выпуклой функцией f решается методом первого порядка. Тогда для достижения точности ε по аргументу потребуется не менее

$$\Omega\left(\sqrt{\frac{L}{\mu}} \log \frac{\|x^0 - x^*\|_2}{\varepsilon}\right) \text{ оракульных вызовов.}$$

- Ускоренный градиентный метод является оптимальным.
- Для L -гладких и выпуклых задач тоже.

Линейный каплинг

Сейчас существуют модификации идеи Нестерова, которые также позволяют добиваться того же результата.


Алгоритм Линейный каплинг: внутренний цикл

Вход: стартовые точки $x^0 = y^0 = z^0 \in \mathbb{R}^d$, размеры шагов $\{\gamma_k\}_{k=0} > 0$ и $\{\eta_k\}_{k=0} > 0$, моменты $\{\tau_k\}_{k=0} \in [0, 1]$, количество итераций K

- 1: **for** $k = 0, 1, \dots, K - 1$ **do**
- 2: $y^{k+1} = x^k - \eta_k \nabla f(x^k)$
- 3: $z^{k+1} = z^k - \gamma_k \nabla f(x^k)$
- 4: $x^{k+1} = \tau_k z^{k+1} + (1 - \tau_k) y^{k+1}$
- 5: **end for**

Выход: $\frac{1}{K} \sum_{k=0}^{K-1} x^k$

Линейный каплинг



Доказательство

Воспользуемся строкой 3 Алгоритма:

$$\begin{aligned}\|z^{k+1} - x^*\|_2^2 &= \|z^k - \gamma \nabla f(x^k) - x^*\|_2^2 \\&= \|z^k - x^*\|_2^2 - 2\gamma \langle \nabla f(x^k), z^k - x^* \rangle + \gamma^2 \|\nabla f(x^k)\|_2^2 \\&= \|z^k - x^*\|_2^2 - 2\gamma \langle \nabla f(x^k), x^k - x^* \rangle \\&\quad - 2\gamma \langle \nabla f(x^k), z^k - x^k \rangle + \gamma^2 \|\nabla f(x^k)\|_2^2.\end{aligned}$$

Доказательство

Воспользуемся строкой 3 Алгоритма:

$$\begin{aligned}\|z^{k+1} - x^*\|_2^2 &= \|z^k - \gamma \nabla f(x^k) - x^*\|_2^2 \\&= \|z^k - x^*\|_2^2 - 2\gamma \langle \nabla f(x^k), z^k - x^* \rangle + \gamma^2 \|\nabla f(x^k)\|_2^2 \\&= \|z^k - x^*\|_2^2 - 2\gamma \langle \nabla f(x^k), x^k - x^* \rangle \\&\quad - 2\gamma \langle \nabla f(x^k), z^k - x^k \rangle + \gamma^2 \|\nabla f(x^k)\|_2^2.\end{aligned}$$

Оценим $\|\nabla f(x^k)\|_2^2$, для этого применим свойство гладкой функции:

$$f(y^{k+1}) \leq f(x^k) + \langle \nabla f(x^k), y^{k+1} - x^k \rangle + \frac{L}{2} \|y^{k+1} - x^k\|_2^2.$$

Доказательство

Воспользуемся строкой 2 Алгоритма:

$$\begin{aligned} f(y^{k+1}) &\leq f(x^k) - \eta \left\| \nabla f(x^k) \right\|_2^2 + \frac{L\eta^2}{2} \left\| \nabla f(x^k) \right\|_2^2 \\ &= f(x^k) - \eta \left(1 - \frac{L\eta}{2} \right) \left\| \nabla f(x^k) \right\|_2^2. \end{aligned}$$

Если $\eta_k \leq \frac{2}{L}$, то $\left(1 - \frac{L\eta}{2} \right) > 0$. Получаем оценку на квадрат нормы градиента:

$$\left\| \nabla f(x^k) \right\|_2^2 \leq \frac{2}{\eta(2 - L\eta)} (f(x^k) - f(y^{k+1})).$$

Доказательство

Воспользуемся строкой 2 Алгоритма:

$$\begin{aligned} f(y^{k+1}) &\leq f(x^k) - \eta \left\| \nabla f(x^k) \right\|_2^2 + \frac{L\eta^2}{2} \left\| \nabla f(x^k) \right\|_2^2 \\ &= f(x^k) - \eta \left(1 - \frac{L\eta}{2} \right) \left\| \nabla f(x^k) \right\|_2^2. \end{aligned}$$

Если $\eta_k \leq \frac{2}{L}$, то $\left(1 - \frac{L\eta}{2} \right) > 0$. Получаем оценку на квадрат нормы градиента:

$$\left\| \nabla f(x^k) \right\|_2^2 \leq \frac{2}{\eta(2 - L\eta)} (f(x^k) - f(y^{k+1})).$$

Подставляя полученное выражение в исходное, получаем:

$$\begin{aligned} \left\| z^{k+1} - x^* \right\|_2^2 &\leq \left\| z^k - z^* \right\|_2^2 - 2\gamma \left\langle \nabla f(x^k), x^k - x^* \right\rangle \\ &\quad + \frac{2\gamma^2}{\eta(2 - L\eta)} (f(x^k) - f(y^{k+1})) + 2\gamma \left\langle \nabla f(x^k), x^k - z^k \right\rangle. \end{aligned}$$

Доказательство

Теперь оценим $\langle \nabla f(x^k), z^k - x^k \rangle$, для этого задействуем строку 4 Алгоритма:

$$\begin{aligned}\langle \nabla f(x^k), x^k - z^k \rangle &= \left\langle \nabla f(x^k), x^k - \frac{1}{\tau}(x^k - (1 - \tau)y^k) \right\rangle \\ &= \frac{1 - \tau}{\tau} \langle \nabla f(x^k), y^k - x^k \rangle.\end{aligned}$$

Доказательство

Теперь оценим $\langle \nabla f(x^k), z^k - x^k \rangle$, для этого задействуем строку 4 Алгоритма:

$$\begin{aligned}\langle \nabla f(x^k), x^k - z^k \rangle &= \left\langle \nabla f(x^k), x^k - \frac{1}{\tau}(x^k - (1 - \tau)y^k) \right\rangle \\ &= \frac{1 - \tau}{\tau} \langle \nabla f(x^k), y^k - x^k \rangle.\end{aligned}$$

Воспользуемся выпуклостью функции f :

$$\langle \nabla f(x^k), x^k - z^k \rangle \leq \frac{1 - \tau}{\tau} (f(y^k) - f(x^k)).$$

Доказательство

Теперь оценим $\langle \nabla f(x^k), z^k - x^k \rangle$, для этого задействуем строку 4 Алгоритма:

$$\begin{aligned}\langle \nabla f(x^k), x^k - z^k \rangle &= \left\langle \nabla f(x^k), x^k - \frac{1}{\tau}(x^k - (1 - \tau)y^k) \right\rangle \\ &= \frac{1 - \tau}{\tau} \langle \nabla f(x^k), y^k - x^k \rangle.\end{aligned}$$

Воспользуемся выпуклостью функции f :

$$\langle \nabla f(x^k), x^k - z^k \rangle \leq \frac{1 - \tau}{\tau} (f(y^k) - f(x^k)).$$

Объединим полученные оценки:

$$\begin{aligned}\|z^{k+1} - x^*\|_2^2 &\leq \|z^k - x^*\|_2^2 - 2\gamma \langle \nabla f(x^k), x^k - x^* \rangle \\ &\quad + \frac{2\gamma^2}{\eta(2 - L\eta)} (f(x^k) - f(y^{k+1})) + 2\gamma \frac{1 - \tau}{\tau} (f(y^k) - f(x^k)).\end{aligned}$$

Доказательство

Подберем τ так, что $\frac{1-\tau}{\tau} = \frac{\gamma}{\eta(2-L\eta)}$, тогда

$$\begin{aligned} \|z^{k+1} - x^*\|_2^2 &\leq \|z^k - x^*\|_2^2 - 2\gamma \langle \nabla f(x^k), x^k - x^* \rangle \\ &\quad + \frac{2\gamma^2}{\eta(2-L\eta)} (f(y^k) - f(y^{k+1})). \end{aligned}$$

Доказательство

Подберем τ так, что $\frac{1-\tau}{\tau} = \frac{\gamma}{\eta(2-L\eta)}$, тогда

$$\begin{aligned}\|z^{k+1} - x^*\|_2^2 &\leq \|z^k - x^*\|_2^2 - 2\gamma \langle \nabla f(x^k), x^k - x^* \rangle \\ &\quad + \frac{2\gamma^2}{\eta(2-L\eta)} (f(y^k) - f(y^{k+1})).\end{aligned}$$

Сделаем перестановку:

$$\begin{aligned}2\gamma \langle \nabla f(x^k), x^k - x^* \rangle &\leq \|z^k - x^*\|_2^2 - \|z^{k+1} - x^*\|_2^2 \\ &\quad + \frac{2\gamma^2}{\eta(2-L\eta)} (f(y^k) - f(y^{k+1})),\end{aligned}$$

Доказательство

Подберем τ так, что $\frac{1-\tau}{\tau} = \frac{\gamma}{\eta(2-L\eta)}$, тогда

$$\begin{aligned}\|z^{k+1} - x^*\|_2^2 &\leq \|z^k - x^*\|_2^2 - 2\gamma \langle \nabla f(x^k), x^k - x^* \rangle \\ &\quad + \frac{2\gamma^2}{\eta(2-L\eta)} (f(y^k) - f(y^{k+1})).\end{aligned}$$

Сделаем перестановку:

$$\begin{aligned}2\gamma \langle \nabla f(x^k), x^k - x^* \rangle &\leq \|z^k - x^*\|_2^2 - \|z^{k+1} - x^*\|_2^2 \\ &\quad + \frac{2\gamma^2}{\eta(2-L\eta)} (f(y^k) - f(y^{k+1})),\end{aligned}$$

Снова применяем выпуклость:

$$\begin{aligned}2\gamma (f(x^k) - f(x^*)) &\leq \|z^k - x^*\|_2^2 - \|z^{k+1} - x^*\|_2^2 \\ &\quad + \frac{2\gamma^2}{\eta(2-L\eta)} (f(y^k) - f(y^{k+1})).\end{aligned}$$

Доказательство

Суммируем по всем k от 0 до $K - 1$, а потом делим на K :

$$\begin{aligned} \frac{2\gamma}{K} \sum_{k=0}^{K-1} (f(x^k) - f^*) &\leq \frac{1}{K} \sum_{k=0}^{K-1} (\|z^k - x^*\|_2^2 - \|z^{k+1} - x^*\|_2^2) \\ &\quad + \frac{2\gamma^2}{\eta(2 - L\eta)K} \sum_{k=0}^{K-1} (f(y^k) - f(y^{k+1})) \\ &= \frac{1}{K} (\|z^0 - x^*\|_2^2 - \|z^K - x^*\|_2^2) \\ &\quad + \frac{2\gamma^2}{\eta(2 - L\eta)K} (f(y^0) - f(y^K)) \\ &\leq \frac{\|z^0 - x^*\|_2^2}{K} + \frac{2\gamma^2(f(y^0) - f^*)}{\eta(2 - L\eta)K}. \end{aligned}$$

Доказательство

Учитывая инициализацию $x^0 = y^0 = z^0$ и применяя неравенство Йенсена для выпуклой функции f , имеем

$$f\left(\frac{1}{K} \sum_{k=0}^{K-1} x^k\right) - f^* \leq \frac{\|x^0 - x^*\|_2^2}{2\gamma K} + \frac{\gamma(f(x^0) - f^*)}{\eta(2 - L\eta)K}.$$

Доказательство

Учитывая инициализацию $x^0 = y^0 = z^0$ и применяя неравенство Йенсена для выпуклой функции f , имеем

$$f\left(\frac{1}{K} \sum_{k=0}^{K-1} x^k\right) - f^* \leq \frac{\|x^0 - x^*\|_2^2}{2\gamma K} + \frac{\gamma(f(x^0) - f^*)}{\eta(2 - L\eta)K}.$$

Казалось бы, полученный результат не является оптимальным: в выпуклом случае мы получили сублинейную скорость сходимости $\mathcal{O}(1/K)$, как у обычного градиентного спуска. У метода Нестерова мы получили $\mathcal{O}(1/K^2)$.

Доказательство

Учитывая инициализацию $x^0 = y^0 = z^0$ и применяя неравенство Йенсена для выпуклой функции f , имеем

$$f\left(\frac{1}{K} \sum_{k=0}^{K-1} x^k\right) - f^* \leq \frac{\|x^0 - x^*\|_2^2}{2\gamma K} + \frac{\gamma(f(x^0) - f^*)}{\eta(2 - L\eta)K}.$$

Казалось бы, полученный результат не является оптимальным: в выпуклом случае мы получили сублинейную скорость сходимости $\mathcal{O}(1/K)$, как у обычного градиентного спуска. У метода Нестерова мы получили $\mathcal{O}(1/K^2)$. Далее мы рассмотрим технику, которая позволит получить оптимальную скорость сходимости в сильно выпуклом случае — рестарты линейного каплинга.

Линейный каплинг: рестарты

Алгоритм Линейный каплинг: рестарты

Вход: стартовая точка $x^0 \in \mathbb{R}^d$, количество итераций T

- 1: **for** $t = 0, 1, \dots, T - 1$ **do**
- 2: Запустить Алгоритм из x^t с параметрами γ, η, τ на K итераций
- 3: Получить x^{t+1} на выходе Алгоритма
- 4: **end for**

Выход: x^T

Доказательство

Применим к полученному неравенству сильную выпуклость, учитывая, что $\nabla f(x^*) = 0$:

$$\begin{aligned} f\left(\frac{1}{K} \sum_{k=0}^{K-1} x^k\right) - f^* &\leq \frac{f(x^0) - f^*}{\mu\gamma K} + \frac{\gamma(f(x^0) - f^*)}{\eta(2 - L\eta)K} \\ &= \left(\frac{1}{\mu\gamma K} + \frac{\gamma}{\eta(2 - L\eta)K}\right)(f(x^0) - f^*). \end{aligned}$$

Доказательство

Применим к полученному неравенству сильную выпуклость, учитывая, что $\nabla f(x^*) = 0$:

$$\begin{aligned} f\left(\frac{1}{K} \sum_{k=0}^{K-1} x^k\right) - f^* &\leq \frac{f(x^0) - f^*}{\mu\gamma K} + \frac{\gamma(f(x^0) - f^*)}{\eta(2 - L\eta)K} \\ &= \left(\frac{1}{\mu\gamma K} + \frac{\gamma}{\eta(2 - L\eta)K}\right)(f(x^0) - f^*). \end{aligned}$$

Подберем η оптимально, чтобы минимизировать правую часть оценки выше: $\eta = \frac{1}{L}$. Тогда

$$f\left(\frac{1}{K} \sum_{k=0}^{K-1} x^k\right) - f^* \leq \left(\frac{1}{\mu\gamma K} + \frac{\gamma L}{K}\right)(f(x^0) - f^*).$$

Доказательство

Подберем теперь оптимальное $\gamma = \frac{1}{\sqrt{\mu L}}$:

$$f\left(\frac{1}{K} \sum_{k=0}^{K-1} x^k\right) - f^* \leq \sqrt{\frac{4L}{\mu K^2}} (f(x^0) - f^*).$$

Доказательство

Подберем теперь оптимальное $\gamma = \frac{1}{\sqrt{\mu L}}$:

$$f\left(\frac{1}{K} \sum_{k=0}^{K-1} x^k\right) - f^* \leq \sqrt{\frac{4L}{\mu K^2}} (f(x^0) - f^*).$$

Положим $K = \sqrt{\frac{16L}{\mu}}$ и получим:

$$f\left(\frac{1}{K} \sum_{k=0}^{K-1} x^k\right) - f^* \leq \frac{1}{2} (f(x^0) - f^*).$$

Доказательство

Подберем теперь оптимальное $\gamma = \frac{1}{\sqrt{\mu L}}$:

$$f\left(\frac{1}{K} \sum_{k=0}^{K-1} x^k\right) - f^* \leq \sqrt{\frac{4L}{\mu K^2}} (f(x^0) - f^*).$$

Положим $K = \sqrt{\frac{16L}{\mu}}$ и получим:

$$f\left(\frac{1}{K} \sum_{k=0}^{K-1} x^k\right) - f^* \leq \frac{1}{2} (f(x^0) - f^*).$$

Получается, что за один запуск линейного каплинга на K итераций, мы гарантированно уменьшаем расстояние до решения по функции в 2 раза. А значит для одной итерации Алгоритма имеем

$$f(x^{t+1}) - f^* \leq \frac{1}{2} (f(x^t) - f^*).$$

Доказательство

Запустим теперь рекурсию по t :

$$f(x^T) - f^* \leq \frac{1}{2^T} (f(x^0) - f^*).$$

Отсюда легко выразить число итераций Алгоритма для достижения точности ε по функции:

$$T \geq \log \left(\frac{f(x^0) - f^*}{\varepsilon} \right).$$

В данном случае оракульная сложность Алгоритма не совпадает с итерационной. Оракульную сложность можно получить следующим образом:

$$K \cdot T = \mathcal{O} \left(\sqrt{\frac{L}{\mu}} \log \frac{f(x^0) - f^*}{\varepsilon} \right).$$

Сходимость линейного каплинга

Теорема

Пусть задача безусловной оптимизации с L -гладкой μ -сильно выпуклой целевой функцией f решается с помощью рестартов линейного каплинга. Тогда при $\gamma = \frac{1}{\sqrt{\mu L}}$, $\eta = \frac{1}{L}$, $\frac{1-\tau}{\tau} = \frac{\gamma}{\eta(2-L\eta)}$,

$K = \sqrt{\frac{16L}{\mu}}$, чтобы добиться точности ε по функции, необходимо

$$\mathcal{O}\left(\sqrt{\frac{L}{\mu}} \log \frac{f(x^0) - f^*}{\varepsilon}\right) \text{ оракульных вызовов.}$$