

Л1 Стохастический градиентный спуск

Стохастическая оптимизация возникает в тех случаях, когда точный градиент функции либо невозможно вычислить, либо его вычисление слишком дорого. В таких случаях мы используем приближённые градиенты, построенные на основе случайной информации о функции.

Придём к этой идее через пример из Параграфа ??, а именно через оптимизацию в машинном обучении ??. В этом примере мы приходили к задаче минимизации эмпирического риска, которую можно записать как:

$$\min_{x \in \mathbb{R}^d} \left[f(x) := \frac{1}{n} \sum_{i=1}^n f_i(x) = \frac{1}{n} \sum_{i=1}^n \ell(g(x, \xi_i^a), \xi_i^b) \right], \quad (\text{Л1.1})$$

где введены обозначения:

- $\xi_i = (\xi_i^a, \xi_i^b)$ — элементы выборки: ξ_i^a — объект (картинка, текст) и ξ_i^b — метка (ответ) на i -м объекте,
- g — модель машинного обучения (линейная модель, нейросеть), принимает на вход объект и настраиваемые веса x ,
- ℓ — функция потерь (штрафует модель за несовпадения с реальной меткой ξ^b).

Такую постановку называют *оффлайн* (данные фиксированы, а не поступают в режиме реального времени).

В оффлайн постановке можно считать полный и честный градиент целевой функции f , но в машинном обучении часто этого не делают. Основная причина — полные градиенты дорого и долго считать, поэтому вместо них вызывают лишь приближённый градиент по случайному элементу выборки: $\nabla f_i(x, \xi_i)$, где i генерируется независимо и равномерно из $\overline{1, n}$. Если рассматривать случайный элемент выборки ξ как случайную величину, сэмплируемую из общего пула данных $\mathcal{D} = \{\xi_1, \dots, \xi_n\}$ с одинаковой вероятностью $\mathbb{P}(\xi = \xi_i) = \frac{1}{n}$, то можно переписать оффлайн постановку (Л1.1) как:

$$\min_{x \in \mathbb{R}^d} \left[f(x) = \mathbb{E}_{\xi \sim \mathcal{D}} [f(x, \xi)] = \mathbb{E}_{\xi \sim \mathcal{D}} [\ell(g(x, \xi^a), \xi^b)] \right]. \quad (\text{Л1.2})$$

Теперь продемонстрируем более общий подход. До этого мы рассматривали задачи, где все функции и градиенты были детерминированными:

$$\min_{x \in \mathbb{R}^d} f(x).$$

А сейчас пусть целевая функция — это математическое ожидание от случайной величины ξ из неизвестного распределения $\mathcal{D}$:

$$\min_{x \in \mathbb{R}^d} [f(x) := \mathbb{E}_{\xi \sim \mathcal{D}} [f(x, \xi)]] . \quad (\text{Л1.3})$$

Такую постановку называют *онлайн* (данные поступают потоком в режиме реального времени). При этом оффлайн постановку можно свести к онлайн варианту, как мы показали в (Л1.2), но сведение в обратную сторону уже не работает, так как в онлайн постановке мы можем даже и не увидеть все данные в процессе обучения.

Цель онлайн формата: в ходе минимизации случайной функции потерь мы «подстраиваемся» под природу, чтобы потери модели в среднем по всему распределению были наименьшими. Так модель сможет найти хорошие зависимости для любых данных ξ .

Проблема онлайн формата: Функция f , а также градиенты и более старшие производные не считаются точно, так как мы не знаем $\mathcal{D}$, а даже если и знаем, то интеграл в математическом ожидании часто не взять так просто.

Решение проблемы: Возникает потребность в методе, который может оперировать с неточными оценками градиента $\nabla f(x, \xi)$ (например, с градиентом по конкретному объекту из распределения данных или с градиентом с шумом). То есть мы хотим работать в *онлайн* режиме, где данные поступают, а мы их обрабатываем (считаем градиент).

Замечание Л1.1. Всякого рода рандомизированные подходы, основанные на сэмплировании, называются *Монте–Карло подходами*.

Оффлайн постановка — это Монте–Карло аппроксимация исходного математического ожидания. С ростом количества элементов в выборке, аппроксимация через конечную сумму будет стремиться к реальному ожиданию (при определенных предположениях).

Л1.1 Стохастический градиентный спуск

Идея — модифицировать градиентный спуск, заменив полный градиент $\nabla f(x^k)$ в точке x^k на стохастическую оценку $\nabla f(x^k, \xi^k)$.

Алгоритм Л1.1 Стохастический градиентный спуск

Вход: стартовая точка $x^0 \in \mathbb{R}^d$, размеры шагов $\{\gamma_k\}_{k=0} > 0$, количество итераций K

```

1: for  $k = 0, 1, \dots, K - 1$  do
2:   Сгенерировать независимо  $\xi^k \sim \mathcal{D}$ 
3:    $x^{k+1} = x^k - \gamma_k \nabla f(x^k, \xi^k)$ 
4: end for
Выход:  $x^K$ 

```

Для дальнейшего повествования напомним определение условного математического ожидания и закон полного математического ожидания.

Определение Л1.1. *Условное математическое ожидание:*

$$\mathbb{E} \left[\cdot \mid x^k \right] := \mathbb{E} [\cdot \mid \mathcal{F}_k],$$

где $\mathcal{F}_k$ — σ -алгебра, порождённая $\xi^0, \dots, \xi^{k-1}$.

Суть — фиксируем всю случайность, которая произошла до k итерации, и ожидаем только по случайности, которая осталась размороженной. Такое математическое ожидание даёт на выходе величину, зависящую от случайных величин $\xi^0, \dots, \xi^{k-1}$.

Теорема Л1.1 (Закон полного математического ожидания (Утверждение G из части 4 Параграфа 7 из [5])). Для двух случайных величин X, Y из одного вероятностного пространства верно равенство:

$$\mathbb{E} [\mathbb{E} [X \mid Y]] = \mathbb{E} [X].$$

Суть — чтобы посчитать сложное математическое ожидание для величины X , мы можем сначала заморозить часть случайности Y и посчитать условное ожидание, а потом проожидать оставшуюся замороженную часть Y .

Перейдём к описанию предположений, которые будут использованы при доказательстве сходимости. На функцию f мы оставляем стандартные предположения об L -гладкости и μ -сильной выпуклости. Но если ранее градиент функции был детерминированным, то теперь стохастический градиент — это случайная величина, и нам

потребуется два новых предположения на него: несмещённость (стохастический градиент в среднем даёт полный градиент) и ограниченность дисперсии (разброс оценки градиента не слишком велик).

Предположение Л1.1 (*Несмещённость стохастического градиента*). Положим, что $\{\mathcal{F}\}_{k \geq 0}$ — семейство вложенных σ -алгебр, случайная величина $x^0 \sim \mathcal{F}_0$ — измерима, для любых $x^k \in \mathbb{R}^d$ и $k \in \mathbb{N}$ случайная величина $\nabla f(x^k, \xi^k)$ является $\mathcal{F}_k$ -измеримой, и выполняется равенство:

$$\mathbb{E} \left[\nabla f(x^k, \xi^k) \mid x^k \right] = \nabla f(x^k).$$

Предположение Л1.2 (*Ограниченность дисперсии стохастического градиента*). Существует константа $\sigma^2 \geq 0$, такая, что для любых $x^k \in \mathbb{R}^d$ и $k \in \mathbb{N}$ верна оценка:

$$\mathbb{E} \left[\|\nabla f(x^k, \xi^k) - \nabla f(x^k)\|_2^2 \mid x^k \right] \leq \sigma^2.$$

Теперь можем доказывать сходимость. Начнём с сильно выпуклого случая.

Теорема Л1.2. Пусть задача безусловной стохастической оптимизации (Л1.3) с L -гладкой, μ -сильно выпуклой целевой функцией f решается с помощью стохастического градиентного спуска (Алгоритм Л1.1) с $\gamma_k = \gamma \leq \frac{1}{L}$ в предположениях несмещённости (Предположение Л1.1) и ограниченности дисперсии стохастического градиента (Предположение Л1.2). Тогда справедлива следующая оценка:

$$\mathbb{E} \left[\|x^K - x^*\|_2^2 \right] \leq (1 - \gamma\mu)^K \|x^0 - x^*\|_2^2 + \frac{\gamma\sigma^2}{\mu}. \quad (\text{Л1.4})$$

Доказательство. Начинаем, как и раньше:

$$\|x^{k+1} - x^*\|_2^2 = \|x^k - x^*\|_2^2 - 2\gamma \langle \nabla f(x^k, \xi^k), x^k - x^* \rangle + \gamma^2 \|\nabla f(x^k, \xi^k)\|_2^2.$$

Вспомним, что мы знаем предположения про функцию f , а в выражении выше её нет (есть только её стохастический градиент). Значит, надо как-то перейти к этой функции в неравенствах. Для этого берём условное математическое ожидание по случайности только на итерации k (важно, что x^k — это неслучайная величина относительно условного математического ожидания по разбиению $\mathcal{F}_k$, случайными здесь будут только величины x^{k+1} и градиент $\nabla f(x^k, \xi^k)$):

$$\begin{aligned} \mathbb{E} \left[\|x^{k+1} - x^*\|_2^2 \mid x^k \right] &= \|x^k - x^*\|_2^2 - 2\gamma \mathbb{E} \left[\langle \nabla f(x^k, \xi^k), x^k - x^* \rangle \mid x^k \right] \\ &\quad + \gamma^2 \mathbb{E} \left[\|\nabla f(x^k, \xi^k)\|_2^2 \mid x^k \right]. \end{aligned} \quad (\text{Л1.5})$$

Рассмотрим $\mathbb{E} \left[\langle \nabla f(x^k, \xi^k), x^k - x^* \rangle \mid x^k \right]$ и воспользуемся линейностью условного математического ожидания, а также Предположением Л1.1:

$$\begin{aligned} \mathbb{E} \left[\langle \nabla f(x^k, \xi^k), x^k - x^* \rangle \mid x^k \right] &= \left\langle \mathbb{E} \left[\nabla f(x^k, \xi^k) \mid x^k \right], x^k - x^* \right\rangle \\ &= \langle \nabla f(x^k), x^k - x^* \rangle. \end{aligned}$$

Рассмотрим $\mathbb{E} \left[\|\nabla f(x^k, \xi^k)\|_2^2 \mid x^k \right]$, добавим и вычтем градиент, после чего раскроем квадрат нормы:

$$\begin{aligned} \mathbb{E} \left[\|\nabla f(x^k, \xi^k)\|_2^2 \mid x^k \right] &= \mathbb{E} \left[\|\nabla f(x^k, \xi^k) - \nabla f(x^k) + \nabla f(x^k)\|_2^2 \mid x^k \right] \\ &= \mathbb{E} \left[\|\nabla f(x^k, \xi^k) - \nabla f(x^k)\|_2^2 \mid x^k \right] \\ &\quad + \mathbb{E} \left[\|\nabla f(x^k)\|_2^2 \mid x^k \right] \\ &\quad + 2\mathbb{E} \left[\langle \nabla f(x^k, \xi^k) - \nabla f(x^k), \nabla f(x^k) \rangle \mid x^k \right]. \end{aligned} \tag{Л11.6}$$

Теперь мы можем воспользоваться Предположением Л11.1 и Предположением Л11.2:

$$\begin{aligned} \mathbb{E} \left[\|\nabla f(x^k, \xi^k)\|_2^2 \mid x^k \right] &= \mathbb{E} \left[\|\nabla f(x^k, \xi^k) - \nabla f(x^k)\|_2^2 \mid x^k \right] + \|\nabla f(x^k)\|_2^2 \\ &\quad + 2\langle \mathbb{E} [\nabla f(x^k, \xi^k) \mid x^k] - \nabla f(x^k), \nabla f(x^k) \rangle \\ &\leq \sigma^2 + \|\nabla f(x^k)\|_2^2 + 2 \cdot 0. \end{aligned}$$

Объединим все промежуточные шаги, подставим в (Л11.5) и получим:

$$\mathbb{E} \left[\|x^{k+1} - x^*\|_2^2 \mid x^k \right] \leq \|x^k - x^*\|_2^2 - 2\gamma \langle \nabla f(x^k), x^k - x^* \rangle + \gamma^2 \|\nabla f(x^k)\|_2^2 + \gamma^2 \sigma^2.$$

Выглядит похоже на то, что было в градиентном спуске, только появляется $\gamma^2 \sigma^2$. Поэтому далее воспользуемся L -гладкостью (Теорема ??) и μ -сильной выпуклостью (Определение ??):

$$\begin{aligned} \mathbb{E} \left[\|x^{k+1} - x^*\|_2^2 \mid x^k \right] &\leq \|x^k - x^*\|_2^2 - 2\gamma \left(f(x^k) - f^* + \frac{\mu}{2} \|x^k - x^*\|_2^2 \right) \\ &\quad + 2\gamma^2 L(f(x^k) - f^*) + \gamma^2 \sigma^2 \\ &= (1 - \gamma\mu) \|x^k - x^*\|_2^2 - 2\gamma(1 - \gamma L)(f(x^k) - f^*) + \gamma^2 \sigma^2. \end{aligned}$$

При выборе $\gamma \leq \frac{1}{L}$ слагаемое $-2\gamma(1 - \gamma L)(f(x^k) - f^*)$ отрицательно, и от него можно избавиться:

$$\mathbb{E} \left[\|x^{k+1} - x^*\|_2^2 \mid x^k \right] \leq (1 - \gamma\mu) \|x^k - x^*\|_2^2 + \gamma^2 \sigma^2.$$

Сейчас запустить рекурсию мешает то, что слева и справа стоят случайные величины, причем оценок на $\|x^k - x^*\|_2$ у нас нет. Чтобы перейти к неслучайным величинам, в неравенстве выше берем полное математическое ожидание и применяем результат Теоремы Л11.1:

$$\mathbb{E} \left[\|x^{k+1} - x^*\|_2^2 \right] \leq (1 - \gamma\mu) \mathbb{E} \left[\|x^k - x^*\|_2^2 \right] + \gamma^2 \sigma^2.$$

Разворачиваем рекурсию:

$$\begin{aligned} \mathbb{E} \left[\|x^K - x^*\|_2^2 \right] &\leq (1 - \gamma\mu) \mathbb{E} \left[\|x^{K-1} - x^*\|_2^2 \right] + \gamma^2 \sigma^2 \\ &\leq (1 - \gamma\mu)^2 \mathbb{E} \left[\|x^{K-2} - x^*\|_2^2 \right] + (1 - \gamma\mu) \gamma^2 \sigma^2 + \gamma^2 \sigma^2 \\ &\leq (1 - \gamma\mu)^K \|x^0 - x^*\|_2^2 + \gamma^2 \sigma^2 \sum_{i=0}^{K-1} (1 - \gamma\mu)^i. \end{aligned}$$

Второе слагаемое — сумма первых k членов геометрической прогрессии, оценим её:

$$\sum_{i=0}^{K-1} (1 - \gamma\mu)^i \leq \sum_{i=0}^{+\infty} (1 - \gamma\mu)^i = \frac{1}{\gamma\mu}.$$

После подстановки в выражение выше:

$$\mathbb{E} \left[\|x^k - x^*\|_2^2 \right] \leq (1 - \gamma\mu)^k \|x^0 - x^*\|_2^2 + \frac{\gamma\sigma^2}{\mu}.$$

■

Эта оценка состоит из двух слагаемых: «детерминированного» слагаемого из обычного градиентного спуска с линейной сходимостью к решению, и нового «стохастического» слагаемого — некоторой неточности, зависящей от γ , σ и μ . Эту неточность метод преодолеть не может и начинает осциллировать, больше не приближаясь к решению. В таком случае говорят, что имеет место сходимость к окрестности решения x^* . Пример поведения стохастического градиентного спуска на практике показан на Рисунке Л1.1: большие шаги γ сначала убывают быстрее, но в итоге сходятся к худшим окрестностям.




Рис. Л1.1: Характерная «дрожь» сходимости стохастического градиентного спуска.

Теперь рассмотрим выпуклый случай.

Теорема Л1.3. Пусть задача безусловной стохастической оптимизации (Л1.3) с L -гладкой, выпуклой целевой функцией f решается с помощью стохастического градиентного спуска (Алгоритм Л1.1) с $\gamma_k = \gamma \leq \frac{1}{2L}$ в предположениях несмещённости (Предположение Л1.1) и ограниченности дисперсии стохастического градиента (Предположение Л1.2). Тогда справедлива следующая оценка:

$$\mathbb{E} \left[f \left(\frac{1}{K} \sum_{k=0}^{K-1} x^k \right) - f^* \right] \leq \frac{\|x^0 - x^*\|_2^2}{\gamma K} + \gamma\sigma^2. \quad (\text{Л1.7})$$

Доказательство. Как и раньше, разложим квадрат нормы:

$$\|x^{k+1} - x^*\|_2^2 = \|x^k - x^*\|_2^2 - 2\gamma \langle \nabla f(x^k, \xi^k), x^k - x^* \rangle + \gamma^2 \|\nabla f(x^k, \xi^k)\|_2^2.$$

Берём условное ожидание по $\mathcal{F}_k$ и пользуемся несмещённостью стохастического градиента (Предположение Л11.1):

$$\mathbb{E} \left[\|x^{k+1} - x^*\|_2^2 \mid x^k \right] = \|x^k - x^*\|_2^2 - 2\gamma \langle \nabla f(x^k), x^k - x^* \rangle + \gamma^2 \mathbb{E} \left[\|\nabla f(x^k, \xi^k)\|_2^2 \mid x^k \right].$$

Аналогично сильно выпуклому случаю, воспользуемся оценкой на второй момент градиента (Л11.6):

$$\mathbb{E} \left[\|\nabla f(x^k, \xi^k)\|_2^2 \mid x^k \right] \leq \sigma^2 + \|\nabla f(x^k)\|_2^2.$$

Подставим в неравенство:

$$\mathbb{E} \left[\|x^{k+1} - x^*\|_2^2 \mid x^k \right] \leq \|x^k - x^*\|_2^2 - 2\gamma \langle \nabla f(x^k), x^k - x^* \rangle + \gamma^2 \|\nabla f(x^k)\|_2^2 + \gamma^2 \sigma^2.$$

Вспомним определение выпуклой функции (Определение ??):

$$\langle \nabla f(x^k), x^k - x^* \rangle \geq f(x^k) - f^*,$$

и неравенство для L -гладкой функции (неравенство ??) из Теоремы ??):

$$\|\nabla f(x^k)\|_2^2 \leq 2L(f(x^k) - f^*).$$

Продолжим основное неравенство:

$$\begin{aligned} \mathbb{E} \left[\|x^{k+1} - x^*\|_2^2 \mid x^k \right] &\leq \|x^k - x^*\|_2^2 - 2\gamma(f(x^k) - f^*) + 2\gamma^2 L(f(x^k) - f^*) + \gamma^2 \sigma^2 \\ &= \|x^k - x^*\|_2^2 - 2\gamma(1 - \gamma L)(f(x^k) - f^*) + \gamma^2 \sigma^2. \end{aligned}$$

Возьмём $\gamma \leq \frac{1}{2L}$, чтобы $1 - \gamma L \geq \frac{1}{2}$, тогда:

$$\mathbb{E} \left[\|x^{k+1} - x^*\|_2^2 \mid x^k \right] \leq \|x^k - x^*\|_2^2 - \gamma(f(x^k) - f^*) + \gamma^2 \sigma^2.$$

Берем полное математическое ожидание и суммируем по всем k от 0 до K :

$$\mathbb{E} \left[\|x^K - x^*\|_2^2 \right] \leq \|x^0 - x^*\|_2^2 - \gamma \sum_{k=0}^{K-1} \mathbb{E} [f(x^k) - f^*] + \gamma^2 \sigma^2 K.$$

Так как $\mathbb{E} \left[\|x^K - x^*\|_2^2 \right]$ — неотрицательное, то:

$$\sum_{k=0}^{K-1} \mathbb{E} [f(x^k) - f^*] \leq \frac{\|x^0 - x^*\|_2^2}{\gamma} + \gamma \sigma^2 K.$$

Воспользуемся линейностью математического ожидания и неравенством Йенсена (??):

$$\begin{aligned} \mathbb{E} \left[f \left(\frac{1}{K} \sum_{k=0}^{K-1} x^k \right) - f^* \right] &\leq \mathbb{E} \left[\frac{1}{K} \sum_{k=0}^{K-1} f(x^k) - f^* \right] = \frac{1}{K} \sum_{k=0}^{K-1} \mathbb{E} [f(x^k) - f^*] \\ &\leq \frac{\|x^0 - x^*\|_2^2}{\gamma K} + \gamma \sigma^2. \end{aligned}$$

■

Результат теоремы похож на классическую оценку для градиентного спуска из Теоремы ?? с точностью до стохастической добавки в виде дисперсии решения $\gamma \sigma^2$.

Л1.2 Модификации стохастического градиентного спуска

Стохастический градиентный спуск с постоянным шагом обладает существенным недостатком — сходимостью к окрестности решения. Рассмотрим простые техники, которые помогают решить проблему неточной сходимости.

В сильно выпуклом случае даже маленький постоянный шаг не работает, так как полностью затухает линейная сходимость в (Л1.4), поэтому шаги нужно постепенно уменьшать с большого значения. В работе [2] проведён анализ сходимости метода для таких шагов. Получим следствия из Теоремы 1 этой статьи.

Теорема Л1.4. Пусть задача безусловной стохастической оптимизации (Л1.3) с L -гладкой, μ -сильно выпуклой целевой функцией f решается с помощью стохастического градиентного спуска (Алгоритм Л1.1) с $\gamma_k = \frac{2}{\mu(k+1)}$ в предположениях несмещённости (Предположение Л1.1) и ограниченности дисперсии стохастического градиента (Предположение Л1.2). Тогда справедлива следующая оценка:

$$\mathbb{E} \left[\|x^K - x^*\|_2^2 \right] \leq \frac{\exp(8L^2/\mu^2)}{K^2} \left(\|x^0 - x^*\|_2^2 + \frac{\sigma^2}{L^2} \right) + \frac{8\sigma^2 \log K}{\mu^2 K}.$$

При такой стратегии подбора шага дисперсия решения убывает сублинейно, но мы теряем в скорости сходимости детерминированной части (была линейная, стала сублинейная). Так происходит, потому что размер шага слишком быстро уменьшается ($\sim 1/k$), и метод не успевает быстро сойтись. Можно получить оценку и для менее агрессивно убывающего γ_k .

Теорема Л1.5. Пусть задача безусловной стохастической оптимизации (Л1.3) с L -гладкой, μ -сильно выпуклой целевой функцией f решается с помощью стохастического градиентного спуска (Алгоритм Л1.1) с $\gamma_k = \frac{2}{\mu\sqrt{k+1}}$ в предположениях несмещённости (Предположение Л1.1) и ограниченности дисперсии стохастического градиента (Предположение Л1.2). Тогда справедлива следующая оценка:

$$\mathbb{E} \left[\|x^K - x^*\|_2^2 \right] \leq 2K^{16L^2/\mu^2} \exp\left(-\frac{\sqrt{K}}{2}\right) \left(\|x^0 - x^*\|_2^2 + \frac{\sigma^2}{L^2} \right) + \frac{8\sigma^2}{\mu^2\sqrt{K}}.$$

Сравнивая оценки для шагов $\gamma_k \sim 1/\sqrt{k}$ с $\gamma_k \sim 1/k$, наблюдаем, что дисперсия решения стала убывать медленнее, но сходимость первого слагаемого осталась линейной, хоть и с плохим коэффициентом. Лучшие оценки были получены в работе [4].

Теорема Л1.6. Пусть задача безусловной стохастической оптимизации (Л1.3) с L -гладкой, μ -сильно выпуклой целевой функцией f решается с помощью стохастического градиентного спуска (Алгоритм Л1.1) в предположениях несмещённости (Предположение Л1.1) и ограниченности дисперсии стохастического градиента (Предположение Л1.2). Тогда при выборе:

$$\gamma_k = \begin{cases} \frac{1}{2L}, & k < \lceil \frac{K}{2} \rceil, \\ \frac{2}{\mu\left(\frac{4L}{\mu} + k - \lceil \frac{K}{2} \rceil\right)}, & k \geq \lceil \frac{K}{2} \rceil, \end{cases}$$

$$w_k = \begin{cases} 0, & k < \lceil \frac{K}{2} \rceil, \\ \left(\frac{4L}{\mu} + k - \lceil \frac{K}{2} \rceil\right)^2, & k \geq \lceil \frac{K}{2} \rceil, \end{cases}$$

справедлива следующая оценка:

$$\begin{aligned} \mathbb{E} \left[f(\bar{x}^K) - f^* \right] + \mu \mathbb{E} \left[\|x^{K+1} - x^*\|_2^2 \right] \\ \leq \min \left\{ 64LR^2 \exp \left(-\frac{\mu K}{4L} \right) + \frac{36\sigma^2}{\mu K}, \frac{2LR^2}{K} + \frac{2\sigma R}{\sqrt{K}} \right\}, \end{aligned}$$

где $R = \|x^0 - x^*\|_2$, $W_K = \sum_{i=1}^K w_i$, $\bar{x}^K = \frac{1}{W_K} \sum_{i=1}^K w_i x^i$.

Эта оценка сочетает в себе линейную сходимость детерминированного слагаемого из классической оценки, и сублинейный спад слагаемого с шумом, при этом с лучшими скоростями. Стратегию выбора шагов спуска и весов для усреднения точек можно описать следующим образом: первую половину делаем большие шаги с константным значением $\gamma = \frac{1}{2L}$ и не учитываем эти $\lceil \frac{K}{2} \rceil$ точек при усреднении, а затем берём уменьшающийся шаг, получаем сходимость к более точной окрестности, усредняем эти точки с ненулевыми возрастающими весами.

Замечание Л1.2. Усреднение точек ближе к концу, когда они осциллируют вокруг решения, помогает уменьшить колебания и достичь лучшего решения и в других стохастических алгоритмах. Этот подход также известен как *скользящее среднее* и особо полезен в обучении больших нейронных сетей.

В выпуклом случае первое слагаемое в оценке (Л1.7) имеет сублинейную сходимость, поэтому достаточно взять постоянный, но маленький шаг, чтобы достичь:

$$\mathbb{E} \left[f \left(\frac{1}{K} \sum_{k=0}^{K-1} x^k \right) - f^* \right] \leq \min_{\gamma \leq \frac{1}{2L}} \left\{ \frac{R^2}{\gamma K} + \gamma \sigma^2 \right\} \leq \frac{2LR^2}{K} + \frac{2\sigma R}{\sqrt{K}}, \quad (\text{Л1.8})$$

где $R^2 = \|x^0 - x^*\|_2^2$ и $\gamma = \min \left\{ \frac{1}{2L}, \frac{R}{\sigma\sqrt{K}} \right\}$. Мы видим, что у первого детерминированного слагаемого осталась скорость обычного градиентного спуска, а плато стало убывать сублинейно. На практике применяют просто уменьшающийся шаг $\gamma_k = \min \left\{ \frac{1}{2L}, \frac{R}{\sigma\sqrt{k}} \right\}$ без фиксированного горизонта K , при том оценка становится хуже лишь на фактор $\log K$. В общем случае, можно легко обобщить доказательство Теоремы Л1.3 на непостоянные шаги $\gamma_k \leq \frac{1}{2L}$:

$$\mathbb{E} \left[f \left(\frac{\sum_{k=0}^{K-1} \gamma_k x^k}{\sum_{k=0}^{K-1} \gamma_k} \right) - f^* \right] \leq \frac{R^2}{\sum_{k=0}^{K-1} \gamma_k} + \frac{\sigma^2 \sum_{k=0}^{K-1} \gamma_k^2}{\sum_{k=0}^{K-1} \gamma_k}.$$

Из этой оценки вытекают необходимые сходимости для γ_k , чтобы и с любой начальной точки сойтись, и шум уменьшить:

$$\sum_{k=0}^{K-1} \gamma_k \xrightarrow{K \rightarrow +\infty} +\infty, \quad \frac{\sum_{k=0}^{K-1} \gamma_k^2}{\sum_{k=0}^{K-1} \gamma_k} \xrightarrow{K \rightarrow \infty} 0.$$

Например, для шагов $\gamma_k \sim 1/\sqrt{K}$ и $\gamma_k \sim 1/\sqrt{k}$ эти условия выполнены (при $\gamma_k \sim 1/\sqrt{k}$ ряд $\sum_{k=0}^{K-1} \gamma_k^2 \sim \log K$ и даёт экстр. фактор в оценку).

Другим подходом борьбы с неточностью решения является уменьшение σ с помощью батчирования. Идея заключается в замене стохастической оценки градиента по одному сэмплу на среднее арифметическое по подвыборке (батчу):

$$\nabla f(x^k, \xi^k) \rightarrow \frac{1}{b} \sum_{j \in S^k} \nabla f(x^k, \xi_j),$$

где S^k — набор случайных индексов из $\overline{1, n}$, $|S^k| = b$, где все индексы генерируются независимо друг от друга (возможны повторы). Оценка по батчу позволяет уменьшить шум σ^2 в стохастических слагаемых, не изменяя детерминированные части.

Утверждение Л1.1. Пусть задача удовлетворяет условиям Теоремы Л1.2 и применена техника батчирования по b независимым сэмплам. Тогда справедлива следующая оценка:

$$\mathbb{E} \left[\|x^K - x^*\|_2^2 \right] \leq (1 - \gamma\mu)^K \|x^0 - x^*\|_2^2 + \frac{\gamma\sigma^2}{\mu b}.$$

Доказательство. Посмотрим, что становится со свойствами несмещённости и конечности дисперсии при замене стохастического градиента по одному сэмплу на среднее значение по батчу размера b .

Несмещённость остаётся, так как у каждого сэмпла j есть несмещённость стохастического градиента и выполняется линейность математического ожидания:

$$\mathbb{E} \left[\frac{1}{b} \sum_{j \in S^k} \nabla f(x^k, \xi_j) \middle| x^k \right] = \frac{1}{b} \sum_{j \in S^k} \mathbb{E} \left[\nabla f(x^k, \xi_j) \middle| x^k \right] = \frac{1}{b} \sum_{j \in S^k} \nabla f(x^k) = \nabla f(x^k).$$

А с дисперсией интереснее, её величина убывает как $\frac{\sigma^2}{b}$ с ростом размера выборки b . Обозначим разность $\delta_j := \nabla f(x^k, \xi_j) - \nabla f(x^k)$ и раскроем квадрат нормы в дисперсии:

$$\begin{aligned} \mathbb{E} \left[\left\| \left(\sum_{j \in S^k} \frac{\nabla f(x^k, \xi_j)}{b} \right) - \nabla f(x^k) \right\|_2^2 \middle| x^k \right] &= \mathbb{E} \left[\left\| \sum_{j \in S^k} \frac{(\nabla f(x^k, \xi_j) - \nabla f(x^k))}{b} \right\|_2^2 \middle| x^k \right] \\ &= \frac{1}{b^2} \mathbb{E} \left[\left\| \sum_{j \in S^k} \delta_j \right\|_2^2 \middle| x^k \right] = \frac{1}{b^2} \mathbb{E} \left[\sum_{j \in S^k} \|\delta_j\|_2^2 + 2 \sum_{i \neq j \in S^k} \langle \delta_j, \delta_i \rangle \middle| x^k \right] \\ &= \frac{1}{b^2} \sum_{j \in S^k} \mathbb{E} \left[\|\delta_j\|_2^2 \middle| x^k \right] + \frac{2}{b^2} \sum_{i \neq j \in S^k} 2 \langle \mathbb{E} [\delta_j \middle| x^k], \mathbb{E} [\delta_i \middle| x^k] \rangle \leq \frac{\sigma^2}{b}, \end{aligned}$$

где в предпоследнем равенстве мы воспользовались свойством математического ожидания для произведения независимых различных сэмплов δ_i и δ_j . Далее последовали оценка дисперсии и несмещённость для одного сэмпла. Остается лишь подставить оценки в (Л1.4) и получить требуемое. ■

Если теперь объединить батчирование и стратегию подбора шага из Теоремы Л1.6, то получится добиться оценки сходимости с меньшей стохастической частью:

$$\mathbb{E} \left[\|x^K - x^*\|_2^2 \right] = O \left(\frac{L}{\mu} \exp \left(-\frac{\mu}{4L} K \right) \|x^0 - x^*\|_2^2 + \frac{\sigma^2}{\mu^2 b K} \right). \quad (\text{Л1.9})$$

Получается, дисперсию можно уменьшить в b раз, но тогда на каждой итерации нужно считать в b раз больше стохастических градиентов. К счастью, это вычисление для независимых сэмплов из подвыборки можно эффективно распараллелить так, что итоговое время одной итерации на практике не сильно изменится. Даже если в b раз дольше считать весь батч последовательно, то выигрыш в количестве итераций при уменьшении дисперсии получается не меньше чем в те же самые b раз: для просто выпуклой оценки (Л1.8) и сильно выпуклой оценки (Л1.9) это как раз $K \sim 1/b$ с σ^2/b .

Таким образом, батчирование — это эффективный инструмент для борьбы с шумом, но стоит помнить, что оно не может повлиять на детерминированные части методов. Поэтому увеличивать размер батча стоит до тех пор, пока шумовые слагаемые в оценках всё ещё доминируют.

Ранее мы показали, что детерминированный градиентный спуск можно ускорить с помощью инерции так, как это сделано в алгоритме Нестерова (Алгоритм ??). Аналогичным образом алгоритм Нестерова со стохастическими градиентами улучшает оценки по сравнению со стохастическим градиентным спуском, но только их детерминированные части. Если объединить батчирование и результат работы [1], то получается оценка:

$$\mathbb{E} \left[f(x^{K+1}) - f^* \right] = \mathcal{O} \left(\exp \left(-\frac{1}{2} \sqrt{\frac{\mu}{L}} K \right) (f(x^0) - f^*) + \frac{\sigma^2}{\mu b K} \right), \quad (\text{J1.10})$$

где в первом слагаемом появляется оптимальный фактор $\sqrt{\mu/L}$ вместо μ/L , но при этом шумовое слагаемое остаётся без изменений (оно уменьшается батчированием).

На практике моментум из метода тяжелого шарика (Алгоритм ??) также обладает эффектом накопления и сглаживания градиента и улучшает динамику обучения.

Замечание J1.3. Для борьбы с выбросами в стохастических градиентах полезно дополнительно обрезать их, и только потом подавать в шаг метода. Например, с помощью клиппирования — обрезания нормы оценки, если она превышает заранее задаваемое значение λ_k ; нормализации — деления оценки на норму; или покоординатного взятия знака от компонент оценки:

$$\nabla f(x^k, \xi^k) \rightarrow \min \left\{ 1, \frac{\lambda_k}{\|\nabla f(x^k, \xi^k)\|_2} \right\} \nabla f(x^k, \xi^k); \quad \frac{\nabla f(x^k, \xi^k)}{\|\nabla f(x^k, \xi^k)\|_2}; \quad \text{sign}(\nabla f(x^k, \xi^k)).$$

Эти модификации делают алгоритмы более устойчивыми, особенно к тяжелым шумам, и гарантируют сходимость не по математическому ожиданию (в среднем по множеству запусков), а с высокой вероятностью (для каждого отдельного запуска).

J1.3 Нижние оценки

Оценки сходимости (J1.8), (J1.9) и (J1.10) для стохастических методов состоят из двух частей: детерминированной и стохастической. Ранее мы уже построили нижние оценки для детерминированных задач оптимизации (Теорема ??). Эти оценки остаются справедливыми и для детерминированных слагаемых в стохастических методах. Так что в этот раз мы сфокусируемся на стохастической части. Для этого мы применим знания из математической статистики. Следующий результат был получен в работе [3].

Теорема J1.7. Пусть задача безусловной стохастической оптимизации (J1.3) с L -гладкой, μ -сильно выпуклой целевой функцией f решается методом с доступом к стохастическому оракулу первого порядка, для которого выполняются предположения несмещённости (Предположение J1.1) и ограниченности дисперсии стохастического градиента (Предположение J1.2). Тогда выполняется:

$$\mathbb{E} \left[\|x^K - x^*\|_2^2 \right] = \Omega \left(\exp \left(-\sqrt{\frac{\mu}{L}} K \right) \|x^0 - x^*\|_2^2 + \frac{\sigma^2}{\mu^2 K} \right).$$

Доказательство. Нам придется сконструировать не только «плохую» функцию, но и описать стохастический оракул. С одной стороны, задача стала сложнее: стало больше свободы. С другой же, можно не выдумывать сложную функцию, а всю «плохость»

задачи сосредоточить в том, насколько зашумленные ответы будет выдавать оракул. Так и поступим — возьмём примитивную целевую функцию $f : \mathbb{R} \rightarrow \mathbb{R}$:

$$f(x) = \frac{\mu}{2} \|x - x^*\|_2^2, \quad \nabla f(x) = \mu(x - x^*).$$

Она μ -сильно выпуклая и μ -гладкая. Считаем, что x^* нам неизвестно, но имеется доступ к зашумленному оракулу первого порядка. На запрос в точке x оракул будет возвращать стохастический градиент:

$$\nabla f(x, \xi) = \mu(x - x^* + \xi), \quad \xi \sim \mathcal{N}\left(0, \frac{\sigma^2}{\mu^2}\right).$$

Проверим предположения о стохастическом градиенте. Несмещённость:

$$\mathbb{E} [\nabla f(x, \xi)] = \mathbb{E} [\mu(x - x^* + \xi)] = \mu(x - x^*) = \nabla f(x).$$

Ограниченность дисперсии:

$$\mathbb{E} [\|\nabla f(x, \xi) - \nabla f(x)\|_2^2] = \mathbb{E} [\|\mu(x - x^* + \xi) - \mu(x - x^*)\|_2^2] = \mathbb{E} [\mu^2 \|\xi\|_2^2] = \sigma^2.$$

Таким образом, все требования на функцию и стохастический градиент выполняются. Пусть мы обратились к оракулу в K точках $\{x^k\}_{k=0}^{K-1}$ и получили в ответ значения $y^k = \mu(x^k + \xi^k - x^*)$, где $\xi^k \sim \mathcal{N}(0, \sigma^2/\mu^2)$ независимы. Хотим получить наилучшую оценку на x^* , используя имеющиеся данные. Введём z^k :

$$z^k = x^k - y^k/\mu = x^* - \xi^k.$$

Тогда задачу можно переформулировать следующим образом: по набору значений $z^k \sim \mathcal{N}(x^*, \sigma^2/\mu^2)$ необходимо восстановить константу x^* . Это можно сделать с помощью оценки максимального правдоподобия:

$$\hat{x} = \frac{1}{K} \sum_{k=0}^{K-1} z^k \sim \mathcal{N}\left(x^*, \frac{\sigma^2}{\mu^2 K}\right).$$

Из математической статистики известно, что для квадратичной функции потерь оценка максимального правдоподобия является оптимальной в смысле минимизации максимального эмпирического риска, то есть получить предсказание лучше оценки максимального правдоподобия невозможно. Из такого распределения на $\hat{x}$, мы сразу видим, что оценка является несмещенной, а ее дисперсия:

$$\mathbb{E} [\|\hat{x} - x^*\|_2^2] = \frac{\sigma^2}{\mu^2 K}.$$

Остается заключить, что поскольку такое значение дисперсии достигается для оптимальной оценки, то все остальные будут не лучше, а значит, они лежат в $\Omega\left(\frac{\sigma^2}{\mu^2 K}\right)$. ■

Смысл этой нижней оценки в том, что дисперсия решения не может убывать быстрее чем $1/K$. Следующий логичный вопрос: являются ли какие-то из ранее полученных оценок оптимальными? Обратимся к результатам Теоремы Л11.6. Из неё можно получить, что $\mathbb{E} [\|x^K - x^*\|_2^2] = \mathcal{O}\left(\frac{\sigma^2}{\mu^2 K}\right)$, то есть обычный стохастический градиентный спуск с описанным подбором шага является оптимальным с точки зрения борьбы с шумом в классе методов с доступом к зашумленному оракулу первого порядка. Ускоренные же методы (Л11.10) помогают лишь быстрее справиться с детерминированной частью, а с точки зрения шума (который обычно и доминирует) никакой разницы нет.

Список литературы

- [1] Necdet Serhat Aybat, Alireza Fallah, Mert Gurbuzbalaban, and Asuman Ozdaglar. A universally optimal multistage accelerated stochastic gradient method, 2019.
- [2] Francis Bach and Eric Moulines. Non-asymptotic analysis of stochastic approximation algorithms for machine learning. In *Advances in Neural Information Processing Systems*, volume 24, pages 451–459, December 2011.
- [3] Aleksandr Beznosikov, Valentin Samokhin, and Alexander Gasnikov. Distributed saddle point problems: lower bounds, near-optimal and robust algorithms*. *Optimization Methods and Software*, page 1–18, March 2025.
- [4] Sebastian U. Stich. Unified optimal analysis of the (stochastic) gradient method, 2019.
- [5] Альберт Николаевич Ширяев. *Вероятность – 1: Элементарная теория вероятностей. Математические основания. Предельные теоремы*. Московский центр непрерывного математического образования, Москва, 3-е, перераб. и доп. edition, 2004.