Стохастический градиентный спуск

Методы оптимизации

Александр Безносиков

Московский физико-технический институт

1 октября 2026



Оффлайн постановка

Задачу обучения в машинном обучении можно записать в виде минимизации эмпирического риска:

$$\min_{x \in \mathbb{R}^d} \left[f(x) := \frac{1}{n} \sum_{i=1}^{n} f_i(x) = \frac{1}{n} \sum_{i=1}^{n} \ell\Big(g\big(x, \xi_i^a\big), \xi_i^b\Big) \right],$$

где введены обозначения:

- $\xi_i = (\xi_i^a, \xi_i^b)$ — элементы выборки: ξ_i^a — объект (картинка, текст) и ξ_i^b — метка (ответ) на i-м объекте,
- g — модель машинного обучения (линейная модель, нейросеть), принимает на вход объект и настраиваемые веса x,
- ℓ — функция потерь (штрафует модель за несовпадения с реальной меткой ξ_i^b).

Оффлайн постановка

Задачу обучения в машинном обучении можно записать в виде минимизации эмпирического риска:

$$\min_{x \in \mathbb{R}^d} \left[f(x) := \frac{1}{n} \sum_{i=1}^{n} f_i(x) = \frac{1}{n} \sum_{i=1}^{n} \ell\Big(g\big(x, \xi_i^a\big), \xi_i^b\Big) \right],$$

где введены обозначения:

- $\xi_i = (\xi_i^a, \xi_i^b)$ — элементы выборки: ξ_i^a — объект (картинка, текст) и ξ_i^b — метка (ответ) на i-м объекте,
- g — модель машинного обучения (линейная модель, нейросеть), принимает на вход объект и настраиваемые веса x,
- ℓ — функция потерь (штрафует модель за несовпадения с реальной меткой ξ_i^b).

Такую постановку называют **оффлайн** (данные фиксированы, а не поступают в режиме реального времени).

Онлайн постановка

Теперь продемонстрируем чуть более общий подход. До этого мы рассматривали задачу:

$$\min_{x \in \mathbb{R}^d} f(x).$$

Теперь сформулируем задачу следующим образом:

$$\min_{x \in \mathbb{R}^d} \left[f(x) := \mathbb{E}_{\xi \sim \mathcal{D}} f(x, \xi) \right].$$

Онлайн постановка

- Мы хотим «подстроиться» под природу, чтобы потери модели по всему распределению были наименьшими, то есть модель наилучшим образом аппроксимировала зависимость ξ^b от ξ^a.

Онлайн постановка

- Мы хотим «подстроиться» под природу, чтобы потери модели по всему распределению были наименьшими, то есть модель наилучшим образом аппроксимировала зависимость ξ^b от ξ^a.
- **Вопрос:** в чем проблема?

Онлайн постановка

- Мы хотим «подстроиться» под природу, чтобы потери модели по всему распределению были наименьшими, то есть модель наилучшим образом аппроксимировала зависимость ξ^b от ξ^a.
- **Вопрос:** в чем проблема? Функция f, а также градиенты и более старшие производные не считаются, так как не знаем $\mathcal{D}$, да даже если и знаем, интеграл часто не взять так просто.

Онлайн постановка

- Мы хотим «подстроиться» под природу, чтобы потери модели по всему распределению были наименьшими, то есть модель наилучшим образом аппроксимировала зависимость ξ^b от ξ^a.
- **Вопрос:** в чем проблема? Функция f, а также градиенты и более старшие производные не считаются, так как не знаем $\mathcal{D}$, да даже если и знаем, интеграл часто не взять так просто.
- Возникает потребность в методе, который может оперировать с $\nabla f(x, \xi)$ (градиентом по конкретному объекту из распределения данных). То есть хотим работать в **онлайн** режиме: поступают данные, мы их обрабатываем (можем считать градиент).

Онлайн постановка

- Мы хотим «подстроиться» под природу, чтобы потери модели по всему распределению были наименьшими, то есть модель наилучшим образом аппроксимировала зависимость ξ^b от ξ^a.
- **Вопрос:** в чем проблема? Функция f, а также градиенты и более старшие производные не считаются, так как не знаем $\mathcal{D}$, да даже если и знаем, интеграл часто не взять так просто.
- Возникает потребность в методе, который может оперировать с $\nabla f(x, \xi)$ (градиентом по конкретному объекту из распределения данных). То есть хотим работать в **онлайн** режиме: поступают данные, мы их обрабатываем (можем считать градиент).
- Оффлайн постановка — это Монте-Карло аппроксимация исходного интеграла (математического ожидания).

Стохастический градиентный спуск

Идея — модифицировать градиентный спуск, заменив полный градиент на стохастический.

Алгоритм Стохастический градиентный спуск

Вход: стартовая точка $x^0 \in \mathbb{R}^d$, размеры шагов $\{\gamma_k\}_{k=0} > 0$, количество итераций K

1: **for** $k = 0, 1, \ldots, K-1$ **do**
2: Сгенерировать независимо $\xi^k \sim \mathcal{D}$
3: $x^{k+1} = x^k - \gamma_k \nabla f\left(x^k, \xi^k\right)$
4: **end for**

Выход: x^K

Условное математическое ожидание

- В ходе доказательства сходимости потребуется ввести **условное математическое ожидание**:

$$\mathbb{E}\left[\cdot \,\middle|\, x^k\right] = \mathbb{E}\left[\cdot \,|\, \mathcal{F}_k\right],$$

где $\mathcal{F}_k$ — σ–алгебра, порождённая $x^0, \xi^0, \ldots, \xi^{k-1}$.

Условное математическое ожидание

- В ходе доказательства сходимости потребуется ввести **условное математическое ожидание**:

$$\mathbb{E}\left[\cdot \,\middle|\, x^k\right] = \mathbb{E}\left[\cdot \,|\, \mathcal{F}_k\right],$$

где $\mathcal{F}_k$ — σ–алгебра, порождённая $x^0, \xi^0, \ldots, \xi^{k-1}$.

- Суть — фиксируем всю случайность, которая произошла до k-й итерации, и ожидаем только по случайности, которая осталась размороженной.

Условное математическое ожидание

- В ходе доказательства сходимости потребуется ввести **условное математическое ожидание**:

$$\mathbb{E}\left[\cdot \,\middle|\, x^k\right] = \mathbb{E}\left[\cdot \,|\, \mathcal{F}_k\right],$$

где $\mathcal{F}_k$ — σ–алгебра, порождённая $x^0, \xi^0, \ldots, \xi^{k-1}$.

- Суть — фиксируем всю случайность, которая произошла до k-й итерации, и ожидаем только по случайности, которая осталась размороженной. **Вопрос:** такое математическое ожидание, что дает на выходе: что-то детерминистическое или случайное?

Условное математическое ожидание

- В ходе доказательства сходимости потребуется ввести **условное математическое ожидание**:

$$\mathbb{E}\left[\cdot \,\middle|\, x^k\right] = \mathbb{E}\left[\cdot \,|\, \mathcal{F}_k\right],$$

где $\mathcal{F}_k$ — σ–алгебра, порождённая $x^0, \xi^0, \ldots, \xi^{k-1}$.

- Суть — фиксируем всю случайность, которая произошла до k-й итерации, и ожидаем только по случайности, которая осталась размороженной. **Вопрос:** такое математическое ожидание, что дает на выходе: что-то детерминистическое или случайное? Такое математическое ожидание дает на выходе что-то, зависящее от случайных величин $x^0, \xi^0, \ldots, \xi^{k-1}$.

Условное математическое ожидание

- В ходе доказательства сходимости потребуется ввести **условное математическое ожидание**:

$$\mathbb{E}\left[\cdot \,\middle|\, x^k\right] = \mathbb{E}\left[\cdot \,|\, \mathcal{F}_k\right],$$

где $\mathcal{F}_k$ — σ–алгебра, порождённая $x^0, \xi^0, \ldots, \xi^{k-1}$.

- Суть — фиксируем всю случайность, которая произошла до k-й итерации, и ожидаем только по случайности, которая осталась размороженной. **Вопрос:** такое математическое ожидание, что дает на выходе: что-то детерминистическое или случайное? Такое математическое ожидание дает на выходе что-то, зависящее от случайных величин $x^0, \xi^0, \ldots, \xi^{k-1}$.
- Также понадобится закон полного математического ожидания (tower property):

$$\mathbb{E}\left[\mathbb{E}\left[X \,|\, Y\right]\right] = \mathbb{E}\left[X\right].$$

Сходимость

- Будем доказывать в случае, когда f является L–гладкой и μ–сильно выпуклой.

Сходимость

- Будем доказывать в случае, когда f является L–гладкой и μ–сильно выпуклой.
- **Несмещённость стохастического градиента.**
  Положим $\{\mathcal{F}_k\}_{k\geq 0}$ — семейство вложенных σ–алгебр. Случайная величина x^0 — $\mathcal{F}_0$–измерима, и для любых $x^k \in \mathbb{R}^d$ и $k \in \mathbb{N}$ случайная величина $\nabla f\left(x^k, \xi^k\right)$ является $\mathcal{F}_{k+1}$–измеримой и выполняется

$$\mathbb{E}\left[\nabla f\left(x^k, \xi^k\right) \middle| x^k\right] = \nabla f\left(x^k\right).$$

Сходимость

- Будем доказывать в случае, когда f является L–гладкой и μ–сильно выпуклой.
- **Несмещённость стохастического градиента.** Положим $\{\mathcal{F}_k\}_{k\geq 0}$ — семейство вложенных σ–алгебр. Случайная величина x^0 — $\mathcal{F}_0$–измерима, и для любых $x^k \in \mathbb{R}^d$ и $k \in \mathbb{N}$ случайная величина $\nabla f\left(x^k, \xi^k\right)$ является $\mathcal{F}_{k+1}$–измеримой и выполняется

$$\mathbb{E}\left[\nabla f\left(x^k, \xi^k\right) \middle| x^k\right] = \nabla f\left(x^k\right).$$

- **Ограниченность дисперсии стохастического градиента.** Существует $\sigma^2 \in \mathbb{R}_+$, такое, что для любых $x^k \in \mathbb{R}^d$ и $k \in \mathbb{N}$:

$$\mathbb{E}\left[\left\|\nabla f\left(x^k, \xi^k\right) - \nabla f\left(x^k\right)\right\|_2^2 \middle| x^k\right] \leq \sigma^2.$$

Доказательство

Начинаем, как и раньше:

$$\left\|x^{k+1} - x^*\right\|_2^2 = \left\|x^k - x^*\right\|_2^2 - 2\gamma\left\langle \nabla f\left(x^k, \xi^k\right), x^k - x^*\right\rangle + \gamma^2\left\|\nabla f\left(x^k, \xi^k\right)\right\|_2^2.$$

Доказательство

Начинаем, как и раньше:

$$\left\|x^{k+1} - x^*\right\|_2^2 = \left\|x^k - x^*\right\|_2^2 - 2\gamma\left\langle \nabla f\left(x^k, \xi^k\right), x^k - x^*\right\rangle + \gamma^2\left\|\nabla f\left(x^k, \xi^k\right)\right\|_2^2.$$

Берем условное математическое ожидание по случайности только на итерации k:

$$\mathbb{E}\left[\left\|x^{k+1} - x^*\right\|_2^2 \middle| x^k\right] = \left\|x^k - x^*\right\|_2^2 - 2\gamma\mathbb{E}\left[\left\langle \nabla f\left(x^k, \xi^k\right), x^k - x^*\right\rangle \middle| x^k\right] + \gamma^2\mathbb{E}\left[\left\|\nabla f\left(x^k, \xi^k\right)\right\|_2^2 \middle| x^k\right].$$

Доказательство

Начинаем, как и раньше:

$$\left\|x^{k+1} - x^*\right\|_2^2 = \left\|x^k - x^*\right\|_2^2 - 2\gamma\left\langle \nabla f\left(x^k, \xi^k\right), x^k - x^*\right\rangle + \gamma^2\left\|\nabla f\left(x^k, \xi^k\right)\right\|_2^2.$$

Берем условное математическое ожидание по случайности только на итерации k:

$$\mathbb{E}\left[\left\|x^{k+1} - x^*\right\|_2^2 \middle| x^k\right] = \left\|x^k - x^*\right\|_2^2 - 2\gamma\mathbb{E}\left[\left\langle \nabla f\left(x^k, \xi^k\right), x^k - x^*\right\rangle \middle| x^k\right] + \gamma^2\mathbb{E}\left[\left\|\nabla f\left(x^k, \xi^k\right)\right\|_2^2 \middle| x^k\right].$$

Рассмотрим $\mathbb{E}\left[\left\langle \nabla f\left(x^k, \xi^k\right), x^k - x^*\right\rangle \middle| x^k\right]$:

$$\mathbb{E}\left[\left\langle \nabla f\left(x^k, \xi^k\right), x^k - x^*\right\rangle \middle| x^k\right] = \left\langle \mathbb{E}\left[\nabla f\left(x^k, \xi^k\right) \middle| x^k\right], x^k - x^*\right\rangle = \left\langle \nabla f\left(x^k\right), x^k - x^*\right\rangle.$$

Доказательство

Рассмотрим $\mathbb{E}\left[\left\|\nabla f\left(x^k, \xi^k\right)\right\|_2^2 \middle| x^k\right]$:

$$\begin{aligned}\mathbb{E}\left[\left\|\nabla f\left(x^k, \xi^k\right)\right\|_2^2 \middle| x^k\right] &= \mathbb{E}\left[\left\|\nabla f\left(x^k, \xi^k\right) - \nabla f\left(x^k\right) + \nabla f\left(x^k\right)\right\|_2^2 \middle| x^k\right] \\ &= \mathbb{E}\left[\left\|\nabla f\left(x^k, \xi^k\right) - \nabla f\left(x^k\right)\right\|_2^2 \middle| x^k\right] \\ &\quad + \mathbb{E}\left[\left\|\nabla f\left(x^k\right)\right\|_2^2 \middle| x^k\right] \\ &\quad + 2\mathbb{E}\left[\left\langle \nabla f\left(x^k, \xi^k\right) - \nabla f\left(x^k\right), \nabla f\left(x^k\right)\right\rangle \middle| x^k\right].\end{aligned}$$

Доказательство

Продолжим:

$$\mathbb{E}\left[\left\|\nabla f\left(x^k, \xi^k\right)\right\|_2^2 \middle| x^k\right] = \mathbb{E}\left[\left\|\nabla f\left(x^k, \xi^k\right) - \nabla f\left(x^k\right)\right\|_2^2 \middle| x^k\right] + \left\|\nabla f\left(x^k\right)\right\|_2^2$$
$$+ 2\left\langle \mathbb{E}\left[\nabla f\left(x^k, \xi^k\right) \middle| x^k\right] - \nabla f\left(x^k\right), \nabla f\left(x^k\right)\right\rangle$$
$$\leq \sigma^2 + \left\|\nabla f\left(x^k\right)\right\|_2^2.$$

Доказательство

Продолжим:

$$\mathbb{E}\left[\left\|\nabla f\left(x^k, \xi^k\right)\right\|_2^2 \middle| x^k\right] = \mathbb{E}\left[\left\|\nabla f\left(x^k, \xi^k\right) - \nabla f\left(x^k\right)\right\|_2^2 \middle| x^k\right] + \left\|\nabla f\left(x^k\right)\right\|_2^2$$
$$+ 2\left\langle \mathbb{E}\left[\nabla f\left(x^k, \xi^k\right) \middle| x^k\right] - \nabla f\left(x^k\right), \nabla f\left(x^k\right)\right\rangle$$
$$\leq \sigma^2 + \left\|\nabla f\left(x^k\right)\right\|_2^2.$$

Объединим все промежуточные шаги и получим:

$$\mathbb{E}\left[\left\|x^{k+1} - x^*\right\|_2^2 \middle| x^k\right] \leq \left\|x^k - x^*\right\|_2^2 - 2\gamma\left\langle \nabla f\left(x^k\right), x^k - x^*\right\rangle$$
$$+ \gamma^2\left\|\nabla f\left(x^k\right)\right\|_2^2 + \gamma^2\sigma^2.$$

Доказательство

Воспользуемся L–гладкостью и μ–сильной выпуклостью:

$$\begin{aligned}\mathbb{E}\left[\left\|x^{k+1}-x^*\right\|_2^2 \middle| x^k\right] &\leq \left\|x^k-x^*\right\|_2^2 - 2\gamma\left(f\left(x^k\right)-f^*+\frac{\mu}{2}\left\|x^k-x^*\right\|_2^2\right)\\ &\quad + 2\gamma^2 L\left(f\left(x^k\right)-f^*\right)+\gamma^2\sigma^2\\ &= \left(1-\gamma\mu\right)\left\|x^k-x^*\right\|_2^2 - 2\gamma\left(1-\gamma L\right)\left(f\left(x^k\right)-f^*\right)\\ &\quad + \gamma^2\sigma^2.\end{aligned}$$

Доказательство

Воспользуемся L–гладкостью и μ–сильной выпуклостью:

$$\begin{aligned}\mathbb{E}\left[\left\|x^{k+1}-x^*\right\|_2^2 \middle| x^k\right] &\leq \left\|x^k-x^*\right\|_2^2 - 2\gamma\left(f\left(x^k\right)-f^*+\frac{\mu}{2}\left\|x^k-x^*\right\|_2^2\right)\\ &\quad + 2\gamma^2 L\left(f\left(x^k\right)-f^*\right)+\gamma^2\sigma^2\\ &= \left(1-\gamma\mu\right)\left\|x^k-x^*\right\|_2^2 - 2\gamma\left(1-\gamma L\right)\left(f\left(x^k\right)-f^*\right)\\ &\quad + \gamma^2\sigma^2.\end{aligned}$$

При выборе $\gamma \leq \frac{1}{L}$ можно упростить:

$$\mathbb{E}\left[\left\|x^{k+1}-x^*\right\|_2^2 \middle| x^k\right] \leq \left(1-\gamma\mu\right)\left\|x^k-x^*\right\|_2^2+\gamma^2\sigma^2.$$

Доказательство

Чтобы перейти к неслучайным величинам, возьмем полное математическое ожидание:

$$\mathbb{E}\left[\left\|x^{k+1} - x^*\right\|_2^2\right] \leq (1 - \gamma\mu)\mathbb{E}\left[\left\|x^k - x^*\right\|_2^2\right] + \gamma^2\sigma^2.$$

Доказательство

Чтобы перейти к неслучайным величинам, возьмем полное математическое ожидание:

$$\mathbb{E}\left[\left\|x^{k+1}-x^*\right\|_2^2\right] \leq (1-\gamma\mu)\mathbb{E}\left[\left\|x^k-x^*\right\|_2^2\right] + \gamma^2\sigma^2.$$

Разворачиваем рекурсию:

$$\begin{aligned}
\mathbb{E}\left[\left\|x^K-x^*\right\|_2^2\right] &\leq (1-\gamma\mu)\mathbb{E}\left[\left\|x^{K-1}-x^*\right\|_2^2\right] + \gamma^2\sigma^2 \\
&\leq (1-\gamma\mu)^2\mathbb{E}\left[\left\|x^{K-2}-x^*\right\|_2^2\right] + (1-\gamma\mu)\gamma^2\sigma^2 + \gamma^2\sigma^2 \\
&\leq (1-\gamma\mu)^K\mathbb{E}\left[\left\|x^0-x^*\right\|_2^2\right] + \gamma^2\sigma^2\sum_{i=0}^{K-1}(1-\gamma\mu)^i.
\end{aligned}$$

Доказательство

Второе слагаемое — сумма первых K членов геометрической прогрессии, оценим её:

$$\sum_{i=0}^{K-1} (1-\gamma\mu)^i \leq \sum_{i=0}^{+\infty} (1-\gamma\mu)^i = \frac{1}{\gamma\mu}.$$

Доказательство

Второе слагаемое — сумма первых K членов геометрической прогрессии, оценим её:

$$\sum_{i=0}^{K-1} (1-\gamma\mu)^i \leq \sum_{i=0}^{+\infty} (1-\gamma\mu)^i = \frac{1}{\gamma\mu}.$$

После подстановки в выражение выше:

$$\mathbb{E}\left[\left\|x^K - x^*\right\|_2^2\right] \leq (1-\gamma\mu)^K \left\|x^0 - x^*\right\|_2^2 + \frac{\gamma\sigma^2}{\mu}.$$

Сходимость стохастического градиентного спуска

Теорема

Пусть задача безусловной стохастической оптимизации с L–гладкой μ–сильно выпуклой целевой функцией f решается с помощью стохастического градиентного спуска с $\gamma_k = \gamma \leq \frac{1}{L}$ в предположениях несмещённости и ограниченности дисперсии стохастического градиента. Тогда справедлива следующая оценка сходимости

$$\mathbb{E}\left[\left\|x^K - x^*\right\|_2^2\right] \leq \left(1 - \gamma\mu\right)^K \left\|x^0 - x^*\right\|_2^2 + \frac{\gamma\sigma^2}{\mu}.$$

Анализ

- Результат вида:

$$\mathbb{E}\left[\left\|x^K - x^*\right\|_2^2\right] \leq (1-\gamma\mu)^K \left\|x^0 - x^*\right\|_2^2 + \frac{\gamma\sigma^2}{\mu}$$

похож на то, что мы уже видели для градиентного спуска.

Анализ

- Результат вида:

$$\mathbb{E}\left[\left\|x^K - x^*\right\|_2^2\right] \leq (1-\gamma\mu)^K \left\|x^0 - x^*\right\|_2^2 + \frac{\gamma\sigma^2}{\mu}$$

  похож на то, что мы уже видели для градиентного спуска.
- Первый член — линейная сходимость к решению.

Анализ

- Результат вида:

$$\mathbb{E}\left[\left\|x^K - x^*\right\|_2^2\right] \leq (1-\gamma\mu)^K \left\|x^0 - x^*\right\|_2^2 + \frac{\gamma\sigma^2}{\mu}$$

  похож на то, что мы уже видели для градиентного спуска.
- Первый член — линейная сходимость к решению.
- Второй член говорит о том, что некоторую точность (зависящую от γ, σ и μ) метод преодолеть не может и начинает осциллировать, больше не приближаясь к решению.
- **Вопрос:** как можно попробовать решить проблему неточной сходимости?

Анализ

- Результат вида:

$$\mathbb{E}\left[\left\|x^K - x^*\right\|_2^2\right] \leq (1-\gamma\mu)^K \left\|x^0 - x^*\right\|_2^2 + \frac{\gamma\sigma^2}{\mu}$$

  похож на то, что мы уже видели для градиентного спуска.
- Первый член — линейная сходимость к решению.
- Второй член говорит о том, что некоторую точность (зависящую от γ, σ и μ) метод преодолеть не может и начинает осциллировать, больше не приближаясь к решению.
- **Вопрос:** как можно попробовать решить проблему неточной сходимости? Сделать шаг уменьшающимся.

Уменьшающийся шаг

Теорема

Пусть задача безусловной стохастической оптимизации с L–гладкой μ–сильно выпуклой целевой функцией f решается с помощью стохастического градиентного спуска. Тогда при выборе

$$\gamma_k = \begin{cases} \frac{1}{2L}, & k < \lceil \frac{K}{2} \rceil, \\ \frac{2}{\mu\left(\frac{4L}{\mu} + k - \lceil \frac{K}{2} \rceil\right)}, & k \geq \lceil \frac{K}{2} \rceil, \end{cases} \quad w_k = \begin{cases} 0, & k < \lceil \frac{K}{2} \rceil, \\ \left(\frac{4L}{\mu} + k - \lceil \frac{K}{2} \rceil\right)^2, & k \geq \lceil \frac{K}{2} \rceil, \end{cases}$$

справедлива следующая оценка сходимости

$$\mathbb{E}\left[f\left(\bar{x}^K\right) - f^*\right] + \mu\mathbb{E}\left[\left\|x^{K+1} - x^*\right\|_2^2\right] \leq \min\left\{64LR^2 \exp\left(-\frac{\mu K}{4L}\right) + \frac{36\sigma^2}{\mu K}, \frac{2LR^2}{K} + \frac{2\sigma R}{\sqrt{K}}\right\},$$

где $R = \left\|x^0 - x^*\right\|_2$, $W_K = \sum_{i=1}^K w_i$, $\bar{x}^K = \frac{1}{W_K}\sum_{i=1}^K w_i x^i$.

Батчинг

Идея заключается в замене стохастической оценки градиента по одному сэмплу на среднее арифметическое по подвыборке:

$$\nabla f\left(x^k, \xi^k\right) \to \frac{1}{b} \sum_{j \in S^k} \nabla f\left(x^k, \xi_j\right),$$

где S^k — набор из b индексов, а сэмплы $\xi_j \sim \mathcal{D}$, $j \in S^k$, генерируются независимо друг от друга (в оффлайн постановке это индексы из $\overline{1, n}$, возможны повторы).

Батчинг

Несмещённость сохраняется по линейности математического ожидания:

$$\mathbb{E}\left[\frac{1}{b}\sum_{j\in S^k}\nabla f\left(x^k,\xi_j\right)\middle|\, x^k\right] = \nabla f\left(x^k\right).$$

Батчинг

Несмещённость сохраняется по линейности математического ожидания:

$$\mathbb{E}\left[\frac{1}{b}\sum_{j\in S^k}\nabla f\left(x^k,\xi_j\right)\middle|\, x^k\right] = \nabla f\left(x^k\right).$$

С дисперсией интереснее: она убывает как $\frac{\sigma^2}{b}$. Пусть $\delta_j := \nabla f\left(x^k,\xi_j\right) - \nabla f\left(x^k\right)$. Так как ξ_j независимы и $\mathbb{E}\left[\delta_j \,\middle|\, x^k\right] = 0$, вторая сумма ниже равна нулю:

$$\mathbb{E}\left[\left\|\frac{1}{b}\sum_{j\in S^k}\delta_j\right\|_2^2\middle|\, x^k\right] = \frac{1}{b^2}\sum_{j\in S^k}\mathbb{E}\left[\left\|\delta_j\right\|_2^2\middle|\, x^k\right] + \frac{1}{b^2}\sum_{i\neq j}\left\langle\mathbb{E}\left[\delta_i\middle|\, x^k\right],\mathbb{E}\left[\delta_j\middle|\, x^k\right]\right\rangle \leq \frac{\sigma^2}{b}.$$

Батчинг

Утверждение

Пусть применена техника батчирования по b независимым сэмплам. Тогда справедлива следующая оценка сходимости:

$$\mathbb{E}\left[\left\|x^K - x^*\right\|_2^2\right] \leq \left(1 - \gamma\mu\right)^K \left\|x^0 - x^*\right\|_2^2 + \frac{\gamma\sigma^2}{\mu b}.$$

Сходимость стохастического градиентного спуска

- Если теперь объединить батчирование и стратегию подбора шага, то получается добиться следующей оценки сходимости:

$$\mathbb{E}\left[\left\|x^K - x^*\right\|_2^2\right] = \mathcal{O}\left(\frac{L}{\mu}\exp\left(-\frac{\mu}{4L}K\right)\left\|x^0 - x^*\right\|_2^2 + \frac{\sigma^2}{\mu^2 bK}\right).$$

Получается линейная сходимость по «детерминистической» части и сублинейная по «стохастической».

Сходимость стохастического градиентного спуска

- Если теперь объединить батчирование и стратегию подбора шага, то получается добиться следующей оценки сходимости:

$$\mathbb{E}\left[\left\|x^K - x^*\right\|_2^2\right] = \mathcal{O}\left(\frac{L}{\mu}\exp\left(-\frac{\mu}{4L}K\right)\left\|x^0 - x^*\right\|_2^2 + \frac{\sigma^2}{\mu^2 bK}\right).$$

  Получается линейная сходимость по «детерминистической» части и сублинейная по «стохастической».
- Ускорение Нестерова возможно:

$$\mathbb{E}\left[f\left(x^{K+1}\right) - f^*\right] = \mathcal{O}\left(\exp\left(-\frac{1}{2}\sqrt{\frac{\mu}{L}}K\right)\left(f\left(x^0\right) - f^*\right) + \frac{\sigma^2}{\mu bK}\right).$$

Сходимость стохастического градиентного спуска

- Если теперь объединить батчирование и стратегию подбора шага, то получается добиться следующей оценки сходимости:

$$\mathbb{E}\left[\left\|x^K - x^*\right\|_2^2\right] = \mathcal{O}\left(\frac{L}{\mu}\exp\left(-\frac{\mu}{4L}K\right)\left\|x^0 - x^*\right\|_2^2 + \frac{\sigma^2}{\mu^2 bK}\right).$$

  Получается линейная сходимость по «детерминистической» части и сублинейная по «стохастической».

- Ускорение Нестерова возможно:

$$\mathbb{E}\left[f\left(x^{K+1}\right) - f^*\right] = \mathcal{O}\left(\exp\left(-\frac{1}{2}\sqrt{\frac{\mu}{L}}K\right)\left(f\left(x^0\right) - f^*\right) + \frac{\sigma^2}{\mu bK}\right).$$

  Важной деталью является ускорение только первого члена, второй член (который и возникает из-за стохастики) остался прежним. Оказывается, его нельзя изменить, и результат выше является оптимальным.