

Л1 Метод сопряжённых градиентов

Метод сопряжённых градиентов изначально был разработан для решения систем линейных уравнений:

$$Ax = b, \quad (\text{Л1.1})$$

где $A \in \mathbb{S}_{++}^d$, $b \in \mathbb{R}^d$.

Эту систему можно переписать в виде задачи безусловной оптимизации:

$$\min_{x \in \mathbb{R}^d} \left\{ f(x) = \frac{1}{2} \langle x, Ax \rangle - \langle b, x \rangle \right\}. \quad (\text{Л1.2})$$

В самом деле, функция f сильно выпукла, поскольку матрица A положительно определена, а её градиент $\nabla f(x) = Ax - b$ зануляется в точке x^* — решении исходной системы (Л1.1).

Далее мы увидим, что метод сопряжённых градиентов можно обобщить за пределы квадратичных функций.

Л1.1 Сопряжённые направления

Ключевым определением в этом параграфе станут сопряжённые направления.

Определение Л1.1. Множество ненулевых векторов $\{p^i\}_{i=0}^{n-1}$ будем называть *сопряжённым* относительно матрицы $A \in \mathbb{S}_{++}^d$, если для любых $i \neq j \in \overline{0, n-1}$ следует

$$\langle p^i, Ap^j \rangle = 0.$$

Свойство сопряжённости во многом похоже на ортогональность. В частности, для сопряжённых векторов выполняется свойство линейной независимости.

Теорема Л1.1. Множество сопряжённых векторов $\{p^i\}_{i=0}^{n-1}$ относительно матрицы $A \in \mathbb{S}_{++}^d$ является линейно независимым.

Доказательство. Пойдём от противного: пусть найдется нетривиальная линейная комбинация сопряжённых векторов, равная нулю. То есть существует набор не равных одновременно нулю чисел $\alpha_0, \dots, \alpha_{n-1} \in \mathbb{R}$: $\sum_{i=0}^{n-1} \alpha_i^2 \neq 0$, для которых:

$$\sum_{i=0}^{n-1} \alpha_i p^i = 0.$$

Домножим на матрицу A и возьмём скалярное произведение с произвольным p^j :

$$\sum_{i=0}^{n-1} \alpha_i \langle p^j, Ap^i \rangle = \alpha_j \langle p^j, Ap^j \rangle = 0.$$

При переходе от суммы к одному слагаемому мы воспользовались определением сопряжённых векторов. Так как $p^j \neq 0$, а матрица A положительно определена, то

$$\langle p^j, Ap^j \rangle > 0.$$

Следовательно, равенство нулю возможно только при $\alpha_j = 0$ для всех $j = \overline{0, n-1}$ — противоречие. ■

Следствием из Теоремы Л1.1 будет полезный факт, что d сопряжённых векторов формируют базис в $\mathbb{R}^d$. Разложим по нему решение x^* :

$$x^* = \sum_{i=0}^{d-1} \lambda_i p^i. \quad (\text{Л1.3})$$

Для нахождения λ_i подействуем матрицей A на обе части (Л1.3) и возьмём скалярное произведение с p^j :

$$\langle p^j, Ax^* \rangle = \sum_{i=0}^{d-1} \lambda_i \langle p^j, Ap^i \rangle = \lambda_j \langle p^j, Ap^j \rangle.$$

При переходе от суммы к одному слагаемому мы опять воспользовались определением сопряжённости векторов.

Так как x^* — решение, то $Ax^* = b$ и получаем, что:

$$\langle p^j, b \rangle = \lambda_j \langle p^j, Ap^j \rangle.$$

Откуда выражается

$$\lambda_j = \frac{\langle p^j, b \rangle}{\langle p^j, Ap^j \rangle}.$$

Л1.2 Метод сопряжённых градиентов

Теперь можно придумать схему обновления x^k для поиска решения:

$$x^{k+1} = x^k + \alpha_k p^k. \quad (\text{Л1.4})$$

Эта схема называется схемой сопряжённых градиентов.

Разложение по сопряжённым направлениям (Л1.3) совпадает с итеративной схемой при $\alpha_k = \lambda_k$ и $x^0 = 0$. А для того, чтобы метод сходился из произвольной точки x^0 , потребуется модифицировать выбор коэффициентов α_k .

Теорема Л1.2 (Теорема 5.1 из [1]). Пусть задача безусловной оптимизации (Л1.2) решается схемой сопряжённых градиентов (Л1.4). Тогда при

$$\alpha_k = -\frac{\langle r^k, p^k \rangle}{\langle p^k, Ap^k \rangle},$$

где $r^k = Ax^k - b$ — вектор невязки, метод сходится к точному решению x^* за не более чем d итераций.

Доказательство. Как ранее уже обсуждалось, по следствию из Теоремы Л1.1 набор из d сопряжённых векторов образует базис в $\mathbb{R}^d$. Разложим по нему вектор $x^* - x^0$:

$$x^* - x^0 = \sum_{i=0}^{d-1} \lambda_i p^i.$$

Подействуем матрицей A и возьмём скалярное произведение с p^j :

$$\lambda_j = \frac{\langle p^j, A(x^* - x^0) \rangle}{\langle p^j, Ap^j \rangle}, \quad j = 0, d-1.$$

Принимая во внимание, что $A(x^* - x^0) = b - Ax^0 = -r^0$, можно записать:

$$x^* = x^0 + \sum_{i=0}^{d-1} \lambda_i p^i = x^0 - \sum_{i=0}^{d-1} \frac{\langle r^0, p^i \rangle}{\langle p^i, Ap^i \rangle} p^i.$$

Чтобы получить результат теоремы, остаётся показать, что $\langle r^0, p^k \rangle = \langle r^k, p^k \rangle$. Действительно:

$$\langle r^k, p^k \rangle = \langle Ax^k - b, p^k \rangle = \left\langle Ax^0 + \sum_{i=0}^{k-1} A\alpha_i p^i - b, p^k \right\rangle = \langle Ax^0 - b, p^k \rangle = \langle r^0, p^k \rangle.$$

Теперь становится видно, что с выбором коэффициентов $\alpha_k = -\frac{\langle r^k, p^k \rangle}{\langle p^k, Ap^k \rangle}$ схема сопряжённых градиентов (Л1.4) на итерации d достигнет точного решения x^* :

$$x^d = x^0 - \sum_{i=0}^{d-1} \frac{\langle r^i, p^i \rangle}{\langle p^i, Ap^i \rangle} p^i = x^*.$$

При этом, возможна ситуация, когда точное решение достигается и на более ранней итерации. Например, когда $\langle p^k, r^k \rangle = 0$, начиная с некоторого $k < d$. ■

Добавим другую интерпретацию схеме сопряжённых градиентов. Как мы отметили в самом начале, решение системы (Л1.1) эквивалентно решению безусловной задачи оптимизации (Л1.2). Это минимизация квадратичной функции на $\mathbb{R}^d$. Линии её уровня — это эллипсоиды с центром в x^* .

Рассмотрим задачу минимизации функции $f(x) = \frac{1}{2} \langle x, Ax \rangle - \langle b, x \rangle$ из точки x^k вдоль p^k . Если записать в виде задачи оптимизации, то получится

$$\min_{\alpha \in \mathbb{R}} f(x^k + \alpha p^k).$$

Приравняем производную к нулю:

$$\langle \nabla f(x^k + \alpha^* p^k), p^k \rangle = \langle A(x^k + \alpha^* p^k) - b, p^k \rangle = 0 \implies \alpha^* = \alpha_k = -\frac{\langle Ax^k - b, p^k \rangle}{\langle p^k, Ap^k \rangle}.$$

То есть шаг схемы сопряжённых направлений — это шаг наискорейшего спуска для минимизации f вдоль направления p^k .

Наглядно сравним итерации схемы сопряжённых градиентов и наискорейшего покоординатного спуска. Из этой иллюстрации можно сделать несколько выводов.


- Схема сопряжённых градиентов находит точное решение за d итераций, наискорейший покоординатный спуск не сходится точно.
- Сопряжённые направления не ортогональны в привычном смысле этого слова.

Докажем некоторые полезные факты для схемы сопряжённых градиентов.


Теорема Л1.3 (Теорема 5.2 из [1]). Пусть схема сопряжённых градиентов (Л1.4)

решает задачу (Л1.2) с выбором коэффициентов $\alpha_k = -\frac{\langle r^k, p^k \rangle}{\langle p^k, Ap^k \rangle}$. Тогда

1. $\langle r^k, p^j \rangle = 0$, для всех $j < k$;



(a) Наискорейший спуск (несколько шагов).



(b) Сопряжённые градиенты (2 шага).

Рис. 11.1: Сравнение траекторий на квадратичной задаче с $A = \text{diag}(1, 5)$.

$$2. \ x^k = \underset{x \in P}{\operatorname{argmin}} f(x), \text{ где } P = x^0 + \operatorname{span}\{p^0, \dots, p^{k-1}\}.$$

Доказательство. Обратимся к доказательству Теоремы 11.2. В нем показывалось, что коэффициенты α_k можно записать как

$$\alpha_k = -\frac{\langle r^0, p^k \rangle}{\langle p^k, Ap^k \rangle}.$$

Подставим их в формулу итерации (11.4) в скалярное произведение:

$$\begin{aligned} \langle r^k, p^j \rangle &= \langle Ax^k - b, p^j \rangle = \left\langle A \left(x^0 - \sum_{i=0}^{k-1} \frac{\langle r^0, p^i \rangle}{\langle p^i, Ap^i \rangle} p^i \right) - b, p^j \right\rangle \\ &= \langle Ax^0 - b, p^j \rangle - \sum_{i=0}^{k-1} \frac{\langle r^0, p^i \rangle}{\langle p^i, Ap^i \rangle} \langle p^j, Ap^i \rangle \\ &= \langle r^0, p^j \rangle - \frac{\langle r^0, p^j \rangle}{\langle p^j, Ap^j \rangle} \langle p^j, Ap^j \rangle = 0. \end{aligned}$$

Покажем равносильность 1 и 2. Введём функцию $\phi: \mathbb{R}^k \rightarrow \mathbb{R}$, определённую как

$$\phi(\gamma) = f(x^0 + \gamma_0 p^0 + \dots + \gamma_{k-1} p^{k-1}).$$

По сути, это сужение функции f на множество P . Поскольку функция f — сильно выпукла, а все векторы p^i ненулевые, то и композиция f с линейным взаимно однозначным преобразованием из $\mathbb{R}^k$ в P , будет сильно выпуклой функцией. Отсюда следует, что у ϕ существует единственный минимум γ^* (Теорема ??). Тогда, пользуясь необходимым и достаточным условием глобального минимума сильно выпуклой функции, получаем:

$$\frac{\partial \phi(\gamma^*)}{\partial \gamma_j} = \langle \nabla f(x^0 + \gamma_0^* p^0 + \dots + \gamma_{k-1}^* p^{k-1}), p^j \rangle = 0.$$

Воспользуемся явным видом f :

$$\nabla f(x^0 + \gamma_0^* p^0 + \dots + \gamma_{k-1}^* p^{k-1}) = \nabla f(x^k) = Ax^k - b = r^k.$$

■

Суть этой теоремы в том, что вектор невязки на k -ой итерации ортогонален всем найденным направлениям. Этот факт нам понадобится позже для ускорения вычислений и доказательства корректности выбора направлений.

Теперь перейдём к способу поиска p^{k+1} . Если вспомнить формулу обновления x^k (Л1.4), то можно заметить, что она похожа на градиентный спуск. Поэтому в качестве нулевого направления можно взять антиградиент в стартовой точке:

$$p^0 = -\nabla f(x^0) = -r^0.$$

Множество из одного вектора всегда сопряжено, поэтому ничего дополнительно требовать не надо. Последующие направления надо конструировать так, чтобы они были сопряжены всем уже найденным. Для этого предложим следующую формулу:

$$p^{k+1} = -r^{k+1} + \beta_k p^k, \quad (\text{Л1.5})$$

где β_k будем подбирать, требуя сопряжённость p^k и p^{k+1} :

$$\langle p^{k+1}, Ap^k \rangle = \langle -r^{k+1} + \beta_k p^k, Ap^k \rangle = -\langle r^{k+1}, Ap^k \rangle + \beta_k \langle p^k, Ap^k \rangle = 0.$$

Откуда получаем

$$\beta_k = \frac{\langle r^{k+1}, Ap^k \rangle}{\langle p^k, Ap^k \rangle}.$$

Применяя этот алгоритм поиска p^i , можем записать метод сопряжённых градиентов.

Алгоритм Л1.1 Метод сопряжённых градиентов (теоретическая версия)

Вход: стартовая точка $x^0 \in \mathbb{R}^d$, стартовая невязка $r^0 = Ax^0 - b$, стартовый сопряжённый вектор $p^0 = -r^0$, количество итераций K

1: **for** $k = 0, 1, \dots, K - 1$ **do**

2: $\alpha_k = -\frac{\langle r^k, p^k \rangle}{\langle p^k, Ap^k \rangle}$

3: $x^{k+1} = x^k + \alpha_k p^k$

4: $r^{k+1} = Ax^{k+1} - b$

5: $\beta_k = \frac{\langle r^{k+1}, Ap^k \rangle}{\langle p^k, Ap^k \rangle}$

6: $p^{k+1} = -r^{k+1} + \beta_k p^k$

7: **end for**

Выход: x^K

Сейчас мы можем гарантировать только сопряжённость p^k и p^{k+1} . А по тому, как мы строили метод, нам нужна сопряжённость p^{k+1} со всеми $p^i, i \leq k$. Для этого докажем соответствующую теорему.

Теорема Л1.4 (Теорема 5.3 из [1]). Пусть на k -ой итерации метод сопряжённых градиентов (Алгоритм Л1.1) получил точку x^k , которая не является решением x^* . Тогда верны следующие свойства:

1. $\text{span}\{r^0, r^1, \dots, r^k\} = \text{span}\{r^0, Ar^0, \dots, A^k r^0\};$

2. $\text{span}\{p^0, p^1, \dots, p^k\} = \text{span}\{r^0, Ar^0, \dots, A^k r^0\};$

3. $\langle p^k, Ap^i \rangle = 0, \quad i = \overline{0, k-1};$

4. $\langle r^k, r^i \rangle = 0, \quad i = \overline{0, k-1}.$

Более того, метод сходится к решению x^* не более чем за d шагов.

Доказательство. Предположим, что утверждения (1), (2) и (3) верны для некоторого k и докажем их для $k+1$. Утверждения тривиально верны для $k=0$, а утверждение (3) верно для $k=1$ из-за выбора β .

Доказательство (1). Сначала покажем, что левая часть включена в правую. По предположению индукции:

$$\begin{aligned} r^k &\in \text{span}\{r^0, Ar^0, \dots, A^k r^0\}, \\ p^k &\in \text{span}\{r^0, Ar^0, \dots, A^k r^0\}. \end{aligned}$$

Тогда:

$$Ap^k \in \text{span}\{Ar^0, A^2 r^0, \dots, A^{k+1} r^0\}.$$

По формуле обновления

$$r^{k+1} = Ax^{k+1} - b = A(x^k + \alpha_k p^k) - b = r^k + \alpha_k Ap^k. \quad (\text{Л1.6})$$

Получаем:

$$r^{k+1} \in \text{span}\{r^0, Ar^0, \dots, A^{k+1} r^0\}.$$

Отсюда получаем вложение:

$$\text{span}\{r^0, r^1, \dots, r^k, r^{k+1}\} \subseteq \text{span}\{r^0, Ar^0, \dots, A^{k+1} r^0\}.$$

Для доказательства обратного включения воспользуемся (2) и заметим:

$$A^{k+1} r^0 = A(A^k r^0) \in A \text{span}\{p^0, \dots, p^k\}.$$

Поскольку по формуле обновления невязки:

$$Ap^i = \frac{r^{i+1} - r^i}{\alpha_i}, \quad i = \overline{0, k},$$

то получаем:

$$A^{k+1} r^0 \in \text{span}\{r^0, r^1, \dots, r^{k+1}\},$$

и, следовательно:

$$\text{span}\{r^0, r^1, \dots, r^{k+1}\} \supseteq \text{span}\{r^0, Ar^0, \dots, A^{k+1} r^0\}.$$

Таким образом, утверждение (1) выполнено при $k+1$.

Доказательство (2). Используем формулу для получения нового вектора p^{k+1} (Л1.5) и утверждение (1):

$$\begin{aligned} \text{span}\{p^0, \dots, p^k, p^{k+1}\} &= \text{span}\{p^0, \dots, p^k, r^{k+1}\} \\ &= \text{span}\{r^0, Ar^0, \dots, A^k r^0, r^{k+1}\} \\ &= \text{span}\{r^0, r^1, \dots, r^k, r^{k+1}\} \\ &= \text{span}\{r^0, Ar^0, \dots, A^{k+1} r^0\}, \end{aligned}$$

что и требовалось.

Доказательство (3). Скалярно умножим (Л1.5) на Ap^i при $i = \overline{0, k}$:

$$\langle p^{k+1}, Ap^i \rangle = -\langle r^{k+1}, Ap^i \rangle + \beta_k \langle p^k, Ap^i \rangle.$$

При $i = k$ правая часть обнуляется по определению β_k . Покажем это и при $i < k$.

По предположению индукции направления $p^0, \dots, p^k$ — сопряжённые, а значит по Теореме ЛП.3:

$$\langle r^{k+1}, p^i \rangle = 0, \quad i = \overline{0, k}.$$

Воспользуемся утверждением (2):

$$Ap^i \in A \operatorname{span}\{r^0, Ar^0, \dots, A^i r^0\} = \operatorname{span}\{Ar^0, A^2 r^0, \dots, A^{i+1} r^0\} \subset \operatorname{span}\{p^0, \dots, p^{i+1}\}.$$

Следовательно:

$$\langle r^{k+1}, Ap^i \rangle = 0, \quad i = \overline{0, k-1}.$$

Кроме того, по предположению индукции для (3):

$$\langle p^k, Ap^i \rangle = 0, \quad i = \overline{0, k-1}.$$

Таким образом, $\langle p^{k+1}, Ap^i \rangle = 0$ для всех $i = \overline{0, k}$, что завершает доказательство.

Доказательство (4). Покажем, что невязка r^k ортогональна предыдущим. Так как $p^0, \dots, p^{k-1}$ — сопряжены, то по Теореме ЛП.3:

$$\langle r^k, p^i \rangle = 0, \quad i = \overline{0, k-1}.$$

Из формулы обновления направления (ЛП.5):

$$p^i = -r^i + \beta_i p^{i-1},$$

получаем:

$$r^i \in \operatorname{span}\{p^i, p^{i-1}\}, \quad i = \overline{1, k-1}.$$

Следовательно:

$$\langle r^k, r^i \rangle = 0, \quad i = \overline{1, k-1}.$$

Кроме того, $p^0 = -r^0 \implies \langle r^k, r^0 \rangle = 0$, то есть утверждение также доказано.

Все четыре утверждения выполнены, и по Теореме ЛП.2, метод сходится к решению x^* не более чем за d шагов. ■

Теперь, когда доказана корректность и скорость сходимости метода до точного решения, можно проанализировать результаты. Итак, для решения системы из d линейных уравнений методу требуется d итераций. На каждой итерации несколько перемножений векторов, а также два перемножения матрицы A на вектор. Последнее наиболее дорого с точки зрения вычислений, каждое умножение порядка d^2 арифметических операций. При выполнении d итераций, получаем $\mathcal{O}(d^3)$ арифметических операций суммарно. А если вспомнить классические алгоритмы решения систем линейных уравнений, например, метод Гаусса, то мы не получили никакого выигрыша по скорости. Тогда появляется вопрос: чем метод сопряжённых градиентов лучше? Ответ заключается в том, что метод сопряжённых градиентов итеративный, то есть на каждой итерации мы получаем какое-то приближение решения. И зачастую нас устроит неточное, но достаточно хорошее решение. Тогда мы можем сделать не все d итераций, а оборвать цикл раньше.

К тому же, мы на данный момент получили много полезных фактов про сопряжённые направления, векторы невязки и их обновления. Это нам позволит ускорить медленную версию метода в константу раз. Начнем с α_k :

$$\alpha_k = -\frac{\langle r^k, p^k \rangle}{\langle p^k, Ap^k \rangle} = -\frac{\langle r^k, -r^k + \beta_k p^{k-1} \rangle}{\langle p^k, Ap^k \rangle} = \frac{\langle r^k, r^k \rangle}{\langle p^k, Ap^k \rangle}.$$

Также по формуле (ЛП.6) можно записать:

$$r^{k+1} = r^k + \alpha_k Ap^k.$$

Остается поработать с β_k . Выражаем $Ap^k = \frac{1}{\alpha_k}(r^{k+1} - r^k)$ и подставляем:

$$\beta_k = \frac{\langle r^{k+1}, Ap^k \rangle}{\langle p^k, Ap^k \rangle} = \frac{\langle r^{k+1}, r^{k+1} - r^k \rangle}{\langle -r^k + \beta_k p^{k-1}, r^{k+1} - r^k \rangle} = \frac{\langle r^{k+1}, r^{k+1} \rangle}{\langle r^k, r^k \rangle}.$$

Запишем обновленную версию алгоритма.

Алгоритм Л1.2 Метод сопряжённых градиентов

Вход: стартовая точка $x^0 \in \mathbb{R}^d$, стартовая невязка $r^0 = Ax^0 - b$, стартовый сопряжённый вектор $p^0 = -r^0$, количество итераций K

1: **for** $k = 0, 1, \dots, K-1$ **do**

2: $\alpha_k = \frac{\langle r^k, r^k \rangle}{\langle p^k, Ap^k \rangle}$

3: $x^{k+1} = x^k + \alpha_k p^k$

4: $r^{k+1} = r^k + \alpha_k Ap^k$

5: $\beta_k = \frac{\langle r^{k+1}, r^{k+1} \rangle}{\langle r^k, r^k \rangle}$

6: $p^{k+1} = -r^{k+1} + \beta_k p^k$

7: **end for**

Выход: x^K

По итогу сэкономили 1 умножение матрицы на вектор и получили ускорение за счёт константы. Проведем теоретический анализ.

Определение Л1.2. Пусть даны матрица $A \in \mathbb{S}_{++}^d$ и вектор $x \in \mathbb{R}^d$. Функцию $\|\cdot\|_A$, определённую как

$$\|x\|_A = \sqrt{\langle x, Ax \rangle},$$

будем называть *A-нормой*.

Теорема Л1.5 (Формула (5.32) из [1]). Пусть система линейных уравнений (Л1.1) решается с помощью метода сопряжённых градиентов (Алгоритм Л1.2). Тогда справедлива следующая оценка скорости сходимости:

$$\|x^K - x^*\|_A^2 \leq \min_{P_{K-1}} \max_{i=1, \dots, d} [1 + \lambda_i P_{K-1}(\lambda_i)]^2 \|x^0 - x^*\|_A^2,$$

где λ_i , $i = \overline{1, d}$ — собственные значения матрицы A , а минимум берется по P_K — все полиномы степени K .

Доказательство. Точку x^{k+1} мы строим как

$$x^{k+1} = x^0 + \sum_{i=0}^k \alpha_i p^i.$$

В Теореме Л1.4 мы показали, что

$$\text{span}\{p^0, \dots, p^k\} = \text{span}\{r^0, Ar^0, \dots, A^k r^0\}.$$

Тогда $x^{k+1} \in x^0 + \text{span}\{r^0, Ar^0, \dots, A^k r^0\}$ и мы можем представить x^{k+1} как линейную комбинацию:

$$x^{k+1} = x^0 + \gamma_0 r^0 + \gamma_1 Ar^0 + \dots + \gamma_k A^k r^0.$$

Можем ввести полином P_k^* степени k . И поскольку A — квадратная матрица, можно взять её в качестве аргумента P_k^* :

$$P_k^*(A) = \gamma_0 I_d + \gamma_1 A + \dots + \gamma_k A^k.$$

Тогда справедлива запись:

$$x^{k+1} = x^0 + P_k^*(A)r^0.$$

Воспользуемся A -нормой и запишем:

$$\frac{1}{2}\|x - x^*\|_A^2 = \frac{1}{2}\langle x - x^*, A(x - x^*) \rangle = f(x) - f^*,$$

где $f(x) = \frac{1}{2}\langle x, Ax \rangle - \langle b, x \rangle$.

Согласно Теореме Л1.3 x^{k+1} минимизирует f на множестве

$$P = x^0 + \text{span}\{p^0, \dots, p^k\} = x^0 + \text{span}\{r^0, Ar^0, \dots, A^k r^0\},$$

а следовательно, минимизирует и $\|x - x^*\|_A^2$.

Любой точке из P можно сопоставить свой полином P_k степени k . Объединяя это с предыдущим фактом, имеем, что

$$P_k^* = \underset{P_k}{\text{argmin}} \|x^0 + P_k(A)r^0 - x^*\|_A.$$

Поскольку

$$r^0 = Ax^0 - b = A(x^0 - x^*),$$

то верно

$$x^{k+1} - x^* = x^0 + P_k^*(A)r^0 - x^* = (I_d + P_k^*(A)A)(x^0 - x^*). \quad (\text{Л1.7})$$

Пусть $0 < \lambda_1 \leq \lambda_2 \leq \dots \leq \lambda_d$ — собственные числа A , а $v^1, v^2, \dots, v^d$ — соответствующие ортонормированные собственные векторы. Так как они являются ортонормированным базисом в $\mathbb{R}^d$, то можно разложить по ним:

$$x^0 - x^* = \sum_{i=1}^d \xi_i v^i. \quad (\text{Л1.8})$$

Посмотрим, как матрица $P_k^*(A)$ действует на v^i :

$$P_k^*(A)v^i = \sum_{j=0}^k \gamma_j A^j v^i = \sum_{j=0}^k \gamma_j \lambda_i^j v^i = P_k^*(\lambda_i)v^i, \quad i = \overline{1, d}.$$

Получается, что $P_k^*(\lambda_1), \dots, P_k^*(\lambda_d)$ — собственные значения $P_k^*(A)$, отвечающие собственным векторам $v^1, \dots, v^d$.

Подставляя разложение (Л1.8) в (Л1.7), получим:

$$x^{k+1} - x^* = \sum_{i=1}^d (1 + \lambda_i P_k^*(\lambda_i)) \xi_i v^i,$$

откуда для A -нормы:

$$\|x^{k+1} - x^*\|_A^2 = \langle x^{k+1} - x^*, A(x^{k+1} - x^*) \rangle = \sum_{i=1}^d \lambda_i (1 + \lambda_i P_k^*(\lambda_i))^2 \xi_i^2.$$

Теперь применяем оптимальность P_k^* по отношению к A -норме:

$$\|x^{k+1} - x^*\|_A^2 = \min_{P_k} \sum_{i=1}^d \lambda_i (1 + \lambda_i P_k(\lambda_i))^2 \xi_i^2.$$

Вынося самый большой множитель $(1 + \lambda_i P_k(\lambda_i))^2$ из суммы, получаем оценку:

$$\begin{aligned} \|x^K - x^*\|_A^2 &\leq \min_{P_{K-1}} \max_{i=1, d} (1 + \lambda_i P_{K-1}(\lambda_i))^2 \left(\sum_{i=1}^d \lambda_i \xi_i^2 \right) \\ &= \min_{P_{K-1}} \max_{i=1, d} (1 + \lambda_i P_{K-1}(\lambda_i))^2 \|x^0 - x^*\|_A^2. \end{aligned}$$

■

Теорема Л1.6 (Теорема 5.4 из [1]). Пусть система линейных уравнений (Л1.1) решается с помощью метода сопряжённых градиентов (Алгоритм Л1.2). Тогда если матрица A имеет только r различных собственных значений, то метод сойдётся к точному решению x^* не более чем за r итераций.

Доказательство. Пусть собственные значения матрицы A равны $\lambda_1, \lambda_2, \dots, \lambda_d$ и принимают r различных значений $\tau_1 < \tau_2 < \dots < \tau_r$. Определим полином $Q_r(\lambda)$:

$$Q_r(\lambda) = \frac{(-1)^r}{\tau_1 \tau_2 \dots \tau_r} (\lambda - \tau_1)(\lambda - \tau_2) \dots (\lambda - \tau_r).$$

Его корнями являются $\tau_1, \tau_2, \dots, \tau_r$, а в нуле он принимает значение $Q_r(0) = 1$. Следовательно, многочлен $Q_r(\lambda) - 1$ имеет степень r и корень 0. Тогда, определённый как

$$\bar{P}_{r-1}(\lambda) = \frac{Q(\lambda) - 1}{\lambda}$$

многочлен имеет степень $r-1$. Применяем оценку из Теоремы Л1.5, и в качестве оценки минимума сверху возьмём $\bar{P}_{r-1}$:

$$0 \leq \min_{P_{r-1}} \max_{i=1, d} (1 + \lambda_i P_{r-1}(\lambda_i))^2 \leq \max_{i=1, d} (1 + \lambda_i \bar{P}_{r-1}(\lambda_i))^2 = \max_{i=1, d} Q_r^2(\lambda_i) = 0.$$

Таким образом, мы подобрали многочлен $\bar{P}_{r-1}$, который даёт точную оценку в неравенстве выше. Тогда согласно оценке из Теоремы Л1.5:

$$\|x^r - x^*\|_A^2 \leq \min_{P_{r-1}} \max_{i=1, d} [1 + \lambda_i P_{r-1}(\lambda_i)]^2 \|x^0 - x^*\|_A^2 = 0.$$

■

Помимо оценок для достижения точного решения, есть оценка и для ошибки на k -ой итерации.

Теорема Л1.7 (Теорема 5.5 из [1]). Пусть система линейных уравнений (Л1.1) решается с помощью метода сопряжённых градиентов (Алгоритм Л1.2). Тогда справедлива следующая оценка сходимости:

$$\|x^K - x^*\|_A^2 \leq \left(\frac{\lambda_{d-K+1} - \lambda_1}{\lambda_{d-K+1} + \lambda_1} \right)^2 \|x^0 - x^*\|_A^2,$$

где $\lambda_1 \leq \lambda_2 \leq \dots \leq \lambda_d$ — собственные числа матрицы A .

Доказательство. Запишем оценку сходимости из Теоремы Л1.5:

$$\|x^{K+1} - x^*\|_A^2 \leq \min_{P_K} \max_{i=1,d} [1 + \lambda_i P_K(\lambda_i)]^2 \|x^0 - x^*\|_A^2.$$

Построим многочлен $\bar{P}_K(\lambda)$, который позволит оценить минимум сверху. Для этого определим многочлен $Q_{K+1}(\lambda)$:

$$Q_{K+1}(\lambda) = \frac{(-1)^{K+1} \cdot (\lambda - \lambda_d)(\lambda - \lambda_{d-1}) \dots (\lambda - \lambda_{d-K+1}) \left(\lambda - \frac{\lambda_1 + \lambda_{d-K}}{2} \right)}{\lambda_d \lambda_{d-1} \dots \lambda_{d-K+1} \cdot \frac{\lambda_1 + \lambda_{d-K}}{2}}.$$

В нуле он принимает значение 1, поэтому многочлен $Q_{K+1}(\lambda) - 1$ степени $K + 1$ и имеет корень в нуле. Полином $\bar{P}_K$ степени K определим как

$$\bar{P}_K(\lambda) = \frac{Q_{K+1}(\lambda) - 1}{\lambda}.$$

Его и подставим для нашей оценки:

$$0 \leq \min_{P_K} \max_{i=1,d} [1 + \lambda_i P_K(\lambda_i)]^2 \leq \max_{i=1,d} [1 + \lambda_i \bar{P}_K(\lambda_i)]^2 = \max_{i=1,d} Q_{K+1}^2(\lambda_i).$$

Внимательнее посмотрим, как выглядит выражение справа:

$$\max_{i=1,d} Q_{K+1}^2(\lambda_i) = \max_{i=1,d} \frac{(\lambda_i - \lambda_d)^2 (\lambda_i - \lambda_{d-1})^2 \dots (\lambda_i - \lambda_{d-K+1})^2 \left(\lambda_i - \frac{\lambda_1 + \lambda_{d-K}}{2} \right)^2}{\lambda_d^2 \lambda_{d-1}^2 \dots \lambda_{d-K+1}^2 \cdot \left(\frac{\lambda_1 + \lambda_{d-K}}{2} \right)^2}.$$

В знаменателе константы, которые не зависят от i . Остаётся максимизировать только числитель. На значениях $\lambda_d, \dots, \lambda_{d-K+1}$ числитель равен нулю. Среди оставшихся собственных чисел скобка $\left(\lambda_i - \frac{\lambda_1 + \lambda_{d-K}}{2} \right)^2$ максимальна и принимает одинаковые значения в точках λ_1 и λ_{d-K} . Однако другие члены в произведении монотонно растут при движении от λ_{d-K} к λ_1 . Отсюда делаем вывод, что в λ_1 достигается максимум каждого отдельного неотрицательного члена в произведении, поэтому и всего произведения. Продолжаем оценку значением в точке λ_1 :

$$\begin{aligned} \max_{i=1,d} Q_{K+1}^2(\lambda_i) &= \frac{(\lambda_1 - \lambda_d)^2 (\lambda_1 - \lambda_{d-1})^2 \dots (\lambda_1 - \lambda_{d-K+1})^2 \left(\lambda_1 - \frac{\lambda_1 + \lambda_{d-K}}{2} \right)^2}{\lambda_d^2 \lambda_{d-1}^2 \dots \lambda_{d-K+1}^2 \cdot \left(\frac{\lambda_1 + \lambda_{d-K}}{2} \right)^2} \\ &\leq \frac{\left(\lambda_1 - \frac{\lambda_1 + \lambda_{d-K}}{2} \right)^2}{\left(\frac{\lambda_1 + \lambda_{d-K}}{2} \right)^2} = \left(\frac{\lambda_{d-K} - \lambda_1}{\lambda_{d-K} + \lambda_1} \right)^2. \end{aligned}$$

Эта оценка завершает доказательство. ■

Таким образом, если мы сделали k итераций, и разница между λ_{d-k} и λ_1 уже достаточно мала, то можно остановить метод. На практике часто бывает, что у матрицы 5–10 больших собственных значений, а остальные сильно меньше. В таких случаях метод сопряжённых градиентов находит достаточно хорошее решение быстрее остальных методов (метода тяжёлого шарика, метода Нестерова). На самом деле, имеет место и другая оценка, более напоминающая ранее полученные оценки для ускоренных методов.

Теорема Л1.8 (Формула (5.35) из [1]). Пусть система линейных уравнений (Л1.1) решается с помощью метода сопряжённых градиентов (Алгоритм Л1.2). Тогда справедлива следующая оценка сходимости:

$$\|x^K - x^*\|_A \leq 4 \left(\frac{\sqrt{\kappa(A)} - 1}{\sqrt{\kappa(A)} + 1} \right)^{2K} \|x^0 - x^*\|_A,$$

где $\kappa(A) = \lambda_{\max}(A)/\lambda_{\min}(A)$ — число обусловленности матрицы A .

Доказательство. Обратимся к оценке из Теоремы Л1.5:

$$\|x^K - x^*\|_A^2 \leq \min_{P_{K-1}} \max_{i=1, d} [1 + \lambda_i P_{K-1}(\lambda_i)]^2 \|x^0 - x^*\|_A^2.$$

Обозначим

$$Q_K(\lambda) = 1 + \lambda P_{K-1}(\lambda).$$

Теперь мы можем искать минимум по всем многочленам $Q_K(\lambda)$ степени K с ограничением $Q_K(0) = 1$:

$$\|x^K - x^*\|_A^2 \leq \min_{Q_K: Q_K(0)=1} \max_{i=1, d} Q_K^2(\lambda_i) \|x^0 - x^*\|_A^2.$$

В желаемой оценке должны присутствовать только максимальное и минимальное собственные значения, поэтому подберём многочлен, который минимально отклоняется от нуля на отрезке $[\lambda_{\min}, \lambda_{\max}]$, при этом удовлетворяет ограничению $Q_K(0) = 1$:

$$\|x^K - x^*\|_A^2 \leq \min_{Q_K: Q_K(0)=1} \max_{\lambda \in [\lambda_{\min}, \lambda_{\max}]} Q_K^2(\lambda) \|x^0 - x^*\|_A^2.$$

Такой многочлен можно построить, используя полиномы Чебышёва. Определяются они следующим образом:

$$T_k(z) = \begin{cases} \frac{1}{2} \left((z + \sqrt{z^2 - 1})^k + (z - \sqrt{z^2 - 1})^k \right), & |z| > 1, \\ \cos(k \arccos z), & |z| \leq 1. \end{cases}$$

Главное их свойство, что на отрезке $[-1, 1]$ они наименьшим образом отклоняются от 0, ровно то свойство, что нам хочется. Остается только биективно отобразить отрезок $[\lambda_{\min}, \lambda_{\max}]$ на $[-1, 1]$ и выполнить ограничение в нуле. Из этих рассуждений, получаем многочлен

$$Q_K(\lambda) = T_K \left(\frac{\lambda_{\min} + \lambda_{\max} - 2\lambda}{\lambda_{\max} - \lambda_{\min}} \right) / T_K \left(\frac{\lambda_{\max} + \lambda_{\min}}{\lambda_{\max} - \lambda_{\min}} \right).$$

Действительно, это многочлен от λ степени K , линейное преобразование под аргументом биективно отображает отрезок $[\lambda_{\min}, \lambda_{\max}]$ в $[-1, 1]$. Это обеспечивает минимальное отклонение от нуля на заданном отрезке. Деление на константу необходимо, чтобы выполнить ограничение на значение в нуле. Теперь найдём максимум. Известно, что на $[-1, 1]$ максимальное значение модуля многочленов Чебышёва равно 1. С этого начинаем оценку:

$$\begin{aligned} \max_{\lambda \in [\lambda_{\min}, \lambda_{\max}]} Q_K^2(\lambda) &= \max_{\lambda \in [\lambda_{\min}, \lambda_{\max}]} \left(T_K \left(\frac{\lambda_{\min} + \lambda_{\max} - 2\lambda}{\lambda_{\max} - \lambda_{\min}} \right) / T_K \left(\frac{\lambda_{\max} + \lambda_{\min}}{\lambda_{\max} - \lambda_{\min}} \right) \right)^2 \\ &= T_K^{-2} \left(\frac{\lambda_{\max} + \lambda_{\min}}{\lambda_{\max} - \lambda_{\min}} \right). \end{aligned}$$

Подставляем выражение для полинома Чебышёва при $|z| > 1$:

$$\begin{aligned}
\max_{\lambda \in [\lambda_{\min}, \lambda_{\max}]} Q_K^2(\lambda) &= 4 \left(\left(\frac{\lambda_{\max} + \lambda_{\min}}{\lambda_{\max} - \lambda_{\min}} + \sqrt{\frac{(\lambda_{\max} + \lambda_{\min})^2}{(\lambda_{\max} - \lambda_{\min})^2} - 1} \right)^K \right. \\
&\quad \left. + \left(\frac{\lambda_{\max} + \lambda_{\min}}{\lambda_{\max} - \lambda_{\min}} - \sqrt{\frac{(\lambda_{\max} + \lambda_{\min})^2}{(\lambda_{\max} - \lambda_{\min})^2} - 1} \right)^K \right)^{-2} \\
&= 4 \left(\left(\frac{\lambda_{\max} + \lambda_{\min} + 2\sqrt{\lambda_{\max}\lambda_{\min}}}{\lambda_{\max} - \lambda_{\min}} \right)^K \right. \\
&\quad \left. + \left(\frac{\lambda_{\max} + \lambda_{\min} - 2\sqrt{\lambda_{\max}\lambda_{\min}}}{\lambda_{\max} - \lambda_{\min}} \right)^K \right)^{-2} \\
&= 4 \left(\left(\frac{\sqrt{\lambda_{\max}} + \sqrt{\lambda_{\min}}}{\sqrt{\lambda_{\max}} - \sqrt{\lambda_{\min}}} \right)^K + \left(\frac{\sqrt{\lambda_{\max}} - \sqrt{\lambda_{\min}}}{\sqrt{\lambda_{\max}} + \sqrt{\lambda_{\min}}} \right)^K \right)^{-2}.
\end{aligned}$$

Переписывая через число обусловленности $\kappa = \lambda_{\max}/\lambda_{\min}$:

$$\begin{aligned}
\max_{\lambda \in [\lambda_{\min}, \lambda_{\max}]} Q_K^2(\lambda) &= 4 \left(\left(\frac{\sqrt{\kappa} + 1}{\sqrt{\kappa} - 1} \right)^K + \left(\frac{\sqrt{\kappa} - 1}{\sqrt{\kappa} + 1} \right)^K \right)^{-2} \\
&\leq 4 \left(\frac{\sqrt{\kappa} + 1}{\sqrt{\kappa} - 1} \right)^{-2K} = 4 \left(\frac{\sqrt{\kappa} - 1}{\sqrt{\kappa} + 1} \right)^{2K}.
\end{aligned}$$

■

Эта оценка более грубая, поскольку появляется зависимость от числа обусловленности. Если внимательно посмотреть на прошлую оценку, то в ней спустя k итераций мы обрабатываем k самых больших собственных чисел, и они более не дают свой вклад в оценку. В этой же формуле зависимость от самого большого собственного числа присутствует на всех итерациях. Сама же оценка похожа на оценки для ускоренных методов. Действительно, если перегруппировать и оценить, то можно получить множитель в правой части

$$\left(1 - 2 \frac{1}{\sqrt{\kappa(A)} + 1} \right)^{2K} \leq \left(1 - \sqrt{\frac{\mu}{L}} \right)^{2K}.$$

По этой оценке можно сделать вывод, что метод сопряжённых градиентов сходится как метод Нестерова на квадратичной задаче.

Л1.3 Нелинейные методы сопряжённых градиентов

Мы получили метод сопряжённых градиентов (Алгоритм Л1.2) для решения систем линейных уравнений (Л1.1) или, эквивалентно, минимизации квадратичной функции (Л1.2). Но что делать, если мы хотим решать более общую задачу, а именно безусловную задачу минимизации:

$$\min_{x \in \mathbb{R}^d} f(x),$$

где на f мы как и ранее будем накладывать условия L -гладкости и выпуклости.

Обобщить метод сопряжённых градиентов действительно возможно. Ранее мы подбирали шаг α_k как шаг наискорейшего спуска вдоль p^k . Для квадратичной функции он вычисляется аналитически. Для функции общего вида же требуется осуществлять линейный поиск, например, как это было описано в Параграфе ?? в разделе про подбор шага. Другим изменением будет замена r^k на $\nabla f(x^k)$. Это мотивировано тем, что для нелинейной функции нет понятия невязки, зато есть градиент, который в случае квадратичной функции совпадал с невязкой. Полученный модифицированный метод сопряжённых градиентов называется методом Флетчера–Ривса.

Алгоритм Л1.3 Метод сопряжённых градиентов (Флетчер–Ривс)

Вход: стартовая точка $x^0 \in \mathbb{R}^d$, стартовый сопряжённый вектор $p^0 = -\nabla f(x^0)$, количество итераций K

- 1: **for** $k = 0, 1, \dots, K - 1$ **do**
- 2: α_k = линейный поиск
- 3: $x^{k+1} = x^k + \alpha_k p^k$
- 4: $\beta_k = \frac{\langle \nabla f(x^{k+1}), \nabla f(x^{k+1}) \rangle}{\langle \nabla f(x^k), \nabla f(x^k) \rangle}$
- 5: $p^{k+1} = -\nabla f(x^{k+1}) + \beta_k p^k$
- 6: **end for**

Выход: x^K

В случае когда f — сильно выпуклая квадратичная функция и производится точный поиск α_k , итерации метода Флетчера–Ривса совпадают с классическим методом сопряжённых градиентов. Теоретические гарантии для метода достаточно слабые, и только если использовать сильные условия Вольфа для линейного поиска.

Есть также модификации метода Флетчера–Ривса, например, Полак и Рибьер предложили другой вариант для подсчёта β_k .

Алгоритм Л1.4 Метод сопряжённых градиентов (Полак–Рибьер)

Вход: стартовая точка $x^0 \in \mathbb{R}^d$, стартовый сопряжённый вектор $p^0 = -\nabla f(x^0)$, количество итераций K

- 1: **for** $k = 0, 1, \dots, K - 1$ **do**
- 2: α_k = линейный поиск
- 3: $x^{k+1} = x^k + \alpha_k p^k$
- 4: $\beta_k = \frac{\langle \nabla f(x^{k+1}), \nabla f(x^{k+1}) - \nabla f(x^k) \rangle}{\langle \nabla f(x^k), \nabla f(x^k) \rangle}$
- 5: $p^{k+1} = -\nabla f(x^{k+1}) + \beta_k p^k$
- 6: **end for**

Выход: x^K

Если бы функция f была квадратичной и сильно выпуклой, то градиенты на соседних итерациях были бы ортогональны и итерации снова совпали с классическим вариантом (Алгоритм Л1.2). Для выпуклых гладких функций это не всегда правда, поэтому эта поправка действительно влияет на сходимость. На практике метод Полака–Рибьера сходится быстрее, чем метод Флетчера–Ривса.

Еще один вариант выбора β_k предложили Хестенс и Штифель. На практике такой метод сходится примерно как метод Полака–Рибьера.

Алгоритм Л1.5 Метод сопряжённых градиентов (Хестенс–Штифель)

Вход: стартовая точка $x^0 \in \mathbb{R}^d$, стартовый сопряжённый вектор $p^0 = -\nabla f(x^0)$, количество итераций K

1: **for** $k = 0, 1, \dots, K - 1$ **do**

2: $\alpha_k =$ линейный поиск

3: $x^{k+1} = x^k + \alpha_k p^k$

4: $\beta_k = \frac{\langle \nabla f(x^{k+1}), \nabla f(x^{k+1}) - \nabla f(x^k) \rangle}{\langle p^k, \nabla f(x^{k+1}) - \nabla f(x^k) \rangle}$

5: $p^{k+1} = -\nabla f(x^{k+1}) + \beta_k p^k$

6: **end for**

Выход: x^K

Список литературы

- [1] J. Nocedal and S. Wright. *Numerical Optimization*. Springer Series in Operations Research and Financial Engineering. Springer New York, 2006.