Л1 Метод Ньютона. Квазиньютоновские методы

Ранее мы рассматривали градиентные методы, которые благодаря низкой вычислительной стоимости шага остаются основным инструментом для задач с очень большой размерностью. Их скорость сходимости обычно линейная — этого достаточно во многих практических случаях. Но если использовать больше информации о целевой функции, можно продвигаться к решению быстрее. Методы второго порядка, такие как метод Ньютона, используют не только значения функции и градиента, но и информацию о гессиане, что позволяет достигать квадратичной скорости сходимости и существенно сокращать число итераций.

Л1.1 Задача поиска нуля

Рассмотрим задачу поиска «корня» функции. Формально требуется для непрерывно дифференцируемой функции $\varphi : \mathbb{R} \to \mathbb{R}$ найти точку x^*, для которой верно

$$\varphi(x^*) = 0.$$

Пусть мы находимся в точке x^0 и хотим найти такую поправку Δx, что $x^0 + \Delta x \approx x^*$. Разложим φ по формуле Тейлора до первого порядка:

$$\varphi(x^0 + \Delta x) = \varphi(x^0) + \varphi'(x^0)\Delta x + o(\Delta x).$$

Поскольку $x^0 + \Delta x \approx x^*$, то:

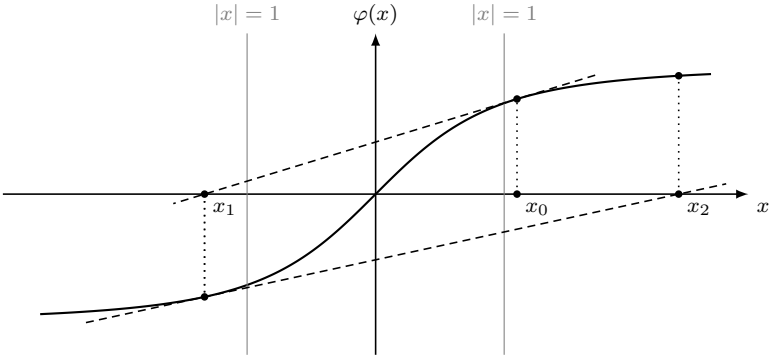
$$\varphi(x^0 + \Delta x) \approx \varphi(x^*) = 0 \implies \varphi(x^0) + \varphi'(x^0)\Delta x \approx 0.$$

Таким образом, $\Delta x \approx -\frac{\varphi(x^0)}{\varphi'(x^0)}$, $x^1 = x^0 - \frac{\varphi(x^0)}{\varphi'(x^0)}$. Продолжая строить новые точки, получаем выражение для итерации метода, предложенного Ньютоном в 17-м веке [6]:

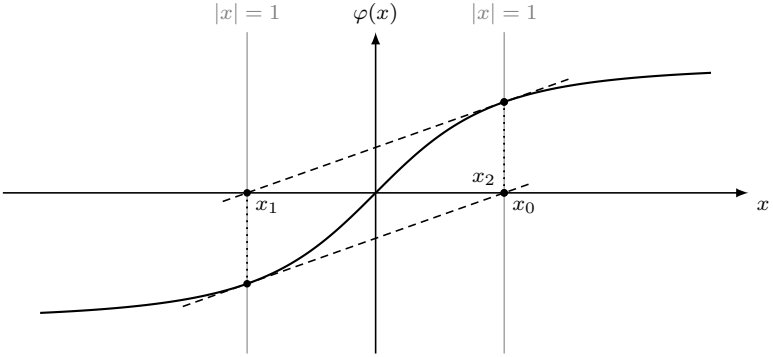
$$x^{k+1} = x^k - \frac{\varphi(x^k)}{\varphi'(x^k)}. \tag{Л1.1}$$

Пример Л1.1. Важно отметить ключевую особенность предложенного метода — сходимость к решению только в некоторой его окрестности. В качестве примера можно рассмотреть $\varphi(x) = \frac{x}{\sqrt{1+x^2}}$. Выберем в качестве начального приближения некоторую точку x^0. Тогда нетрудно видеть, что:

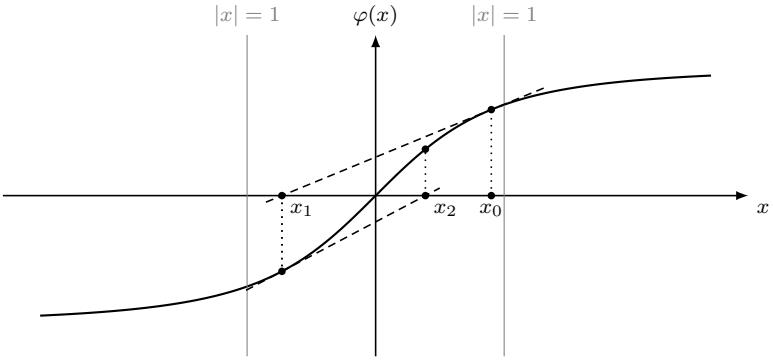
- $|x^0| < 1$ — метод сходится;
- $|x^0| = 1$ — метод колеблется в точках -1 и 1;
- $|x^0| > 1$ — метод расходится.



$|x^0| > 1$: расходимость



$|x^0| = 1$: колебания $1 \rightleftarrows -1$



$|x^0| < 1$: сходимость к 0

Л1.2 Метод Ньютона

Вернемся к задаче безусловной минимизации:

$$\min_{x \in \mathbb{R}^d} f(x). \tag{Л1.2}$$

Ранее уже обсуждалось, что для выпуклой целевой функции она эквивалентна задаче поиска нуля градиента:

$$\nabla f\big(x^*\big) = 0,$$

где $\nabla f : \mathbb{R}^d \to \mathbb{R}^d$.
Применим рассмотренный ранее подход к этой задаче. Заменяя в формуле (Л1.1) $\varphi = \nabla f$ и $\varphi' = \nabla^2 f$, мы ожидаем получить шаг:

$$x^{k+1} = x^k - \big(\nabla^2 f(x)\big)^{-1} \nabla f(x).$$

Как ещё можно посчитать такую операцию? Будем минимизировать квадратичную аппроксимацию целевой функции:

$$f(x) \approx f\big(x^k\big) + \big\langle \nabla f\big(x^k\big), x - x^k \big\rangle + \frac{1}{2} \big\langle \nabla^2 f\big(x^k\big)\big(x - x^k\big), x - x^k \big\rangle.$$

Построим x^{k+1} как точку, где зануляется градиент квадратичной аппроксимации:

$$\nabla f\big(x^k\big) + \nabla^2 f\big(x^k\big)\big(x - x^k\big) = 0 \implies x^{k+1} = x^k - \big(\nabla^2 f\big(x^k\big)\big)^{-1} \nabla f\big(x^k\big).$$

Действительно, получили то, что ожидали:

Алгоритм Л1.1 Метод Ньютона

Вход: стартовая точка $x^0 \in \mathbb{R}^d$, количество итераций K
for $k = 0, 1, \ldots, K-1$ **do**
  $x^{k+1} = x^k - \big(\nabla^2 f\big(x^k\big)\big)^{-1} \nabla f\big(x^k\big)$
end for
Выход: x^K

Пример Л1.2. Рассмотрим задачу:

$$\min_{x \in \mathbb{R}^d} \left[f(x) = \frac{1}{2} \langle x, Ax \rangle - \langle b, x \rangle + c \right],$$

где $A \in \mathbb{S}^d_+$.
Пусть x^* — решение задачи. Тогда нетрудно заметить, что

$$\nabla f\big(x^*\big) = Ax^* - b = 0,$$

то есть $x^* = A^{-1}b$. При этом также нетрудно заметить, что

$$\big(\nabla^2 f(x)\big)^{-1} \nabla f(x) = A^{-1}\big(Ax - b\big) = x - A^{-1}b.$$

Таким образом, метод Ньютона для квадратичной задачи сходится за одну итерацию. Важно отметить, что вычислительная стоимость этой итерации очень велика не только из-за использования гессиана, но еще и из-за его обращения за $\mathcal{O}\big(d^3\big)$.

Далее будем работать в предположении, что целевая функция в задаче безусловной минимизации является дважды непрерывно дифференцируемой, μ–сильно выпуклой, а также имеет M–Липшицев гессиан:

Определение Л1.1. Пусть дана дважды непрерывно дифференцируемая на $\mathbb{R}^d$ функция $f : \mathbb{R}^d \to \mathbb{R}$. Будем говорить, что данная функция имеет *M–Липшицев гессиан*, если для любых $x, y \in \mathbb{R}^d$ выполнено

$$\|\nabla^2 f(x) - \nabla^2 f(y)\|_2 \leq M\|x - y\|_2.$$

Утверждение Л1.1. Пусть функция f имеет M–Липшицев гессиан. Введём обозначение

$$G = \nabla^2 f(x) - \int\limits_0^1 \nabla^2 f\big(x^* + \tau(x - x^*)\big)\,\mathrm{d}\tau\,.$$

Тогда справедлива оценка:

$$\|G\|_2 \leq \frac{M}{2}\|x - x^*\|_2.$$

Доказательство. Распишем норму, воспользуемся неравенством треугольника и M-липшицевостью гессиана:

$$\begin{aligned}
\|G\|_2 &= \left\|\nabla^2 f(x) - \int\limits_0^1 \nabla^2 f\big(x^* + \tau(x - x^*)\big)\,\mathrm{d}\tau\right\|_2 \\
&= \left\|\int\limits_0^1 \big(\nabla^2 f(x) - \nabla^2 f\big(x^* + \tau(x - x^*)\big)\big)\,\mathrm{d}\tau\right\|_2 \\
&\leq \int\limits_0^1 \|\nabla^2 f(x) - \nabla^2 f\big(x^* + \tau(x - x^*)\big)\|_2\,\mathrm{d}\tau \\
&\leq \int\limits_0^1 M(1-\tau)\|x - x^*\|_2\,\mathrm{d}\tau \\
&= M\|x - x^*\|_2 \int\limits_0^1 (1-\tau)\,\mathrm{d}\tau \\
&= \frac{M}{2}\|x - x^*\|_2.
\end{aligned}$$

Получили требуемую оценку. ■

Теперь можем сформулировать теорему о сходимости метода Ньютона.

Теорема Л1.1. Пусть задача безусловной оптимизации (Л1.2) с μ–сильно выпуклой целевой функцией f, имеющей M–Липшицев гессиан, решается с помощью метода Ньютона (Алгоритм Л1.1). Тогда справедлива следующая оценка сходимости:

$$\|x^{k+1} - x^*\|_2 \leq \frac{M}{2\mu}\|x^k - x^*\|_2^2.$$

Доказательство. Будем изучать, как меняется расстояние до решения:

$$x^{k+1} - x^* = x^k - \left(\nabla^2 f(x^k)\right)^{-1} \nabla f(x^k) - x^*.$$

Воспользуемся формулой Ньютона-Лейбница для интеграла вдоль кривой:

$$\nabla f(x^k) - \nabla f(x^*) = \int\limits_0^1 \nabla^2 f\big(x^* + \tau(x^k - x^*)\big)(x^k - x^*)\,\mathrm{d}\tau\,.$$

Зная, что $\nabla f(x^*) = 0$, получим:

$$x^{k+1} - x^* = x^k - x^* - \left(\nabla^2 f(x^k)\right)^{-1} \int\limits_0^1 \nabla^2 f\big(x^* + \tau(x^k - x^*)\big)(x^k - x^*)\,\mathrm{d}\tau\,.$$

Домножим $x^k - x^*$ на «умную единицу» ($I = (\nabla^2 f(x^k))^{-1}\nabla^2 f(x^k)$):

$$\begin{aligned} x^{k+1} - x^* &= x^k - x^* - \left(\nabla^2 f(x^k)\right)^{-1} \int\limits_0^1 \nabla^2 f\big(x^* + \tau(x^k - x^*)\big)(x^k - x^*)\,\mathrm{d}\tau \\ &= \left(\nabla^2 f(x^k)\right)^{-1} \nabla^2 f(x^k)(x^k - x^*) \\ &\quad - \left(\nabla^2 f(x^k)\right)^{-1} \int\limits_0^1 \nabla^2 f\big(x^* + \tau(x^k - x^*)\big)(x^k - x^*)\,\mathrm{d}\tau\,. \end{aligned}$$

Заметим, что $x^k - x^*$ можно вынести за пределы интеграла:

$$\begin{aligned} x^{k+1} - x^* &= \left(\nabla^2 f(x^k)\right)^{-1} \underbrace{\left(\nabla^2 f(x^k) - \int\limits_0^1 \nabla^2 f\big(x^* + \tau(x^k - x^*)\big)\,\mathrm{d}\tau\right)}_{=G_k} (x^k - x^*) \\ &= \left(\nabla^2 f(x^k)\right)^{-1} G_k (x^k - x^*). \end{aligned}$$

Спектральная норма матрицы согласована с евклидовой нормой вектора. Таким образом:

$$\left\|x^{k+1} - x^*\right\|_2 \le \left\|\left(\nabla^2 f(x^k)\right)^{-1}\right\|_2 \|G_k\|_2 \|x^k - x^*\|_2.$$

Норму обратного гессиана оценим как $\left\|\left(\nabla^2 f(x^k)\right)^{-1}\right\|_2 = \frac{1}{\lambda_{\min}\left(\nabla^2 f(x^k)\right)} \le \frac{1}{\mu}$. Остается лишь применить результат Утверждения Л1.1, и получим требуемое:

$$\left\|x^{k+1} - x^*\right\|_2 \le \frac{M}{2\mu}\left\|x^k - x^*\right\|_2^2.$$

■

Замечание Л1.1. Сходимость является локальной. А именно, чтобы гарантировать

$$\left\|x^1 - x^*\right\|_2 < \left\|x^0 - x^*\right\|_2,$$

нужно предположить, что:

$$\left\|x^0 - x^*\right\|_2 < \frac{2\mu}{M}.$$

Приведем пример, когда метод Ньютона расходится при старте из плохого приближения.

Пример Л1.3. Рассмотрим функцию $f : \mathbb{R} \to \mathbb{R}$:

$$f\big(x\big) = \frac{x^2}{2} + 10 \log \cosh x.$$

Её минимум находится в точке $x^* = 0$.
Найдём константу сильной выпуклости μ и константу липшицевости гессиана M.
Первые три производные имеют вид:

$$f'(x) = x + 10 \tanh x,$$
$$f''(x) = 1 + \frac{10}{\cosh^2 x},$$
$$f'''(x) = -20 \frac{\tanh x}{\cosh^2 x}.$$

Так как $\cosh^2 x \geq 1$, имеем

$$\mu = \min_{x \in \mathbb{R}} f''(x) = 1.$$

Для константы липшицевости гессиана в одномерном случае:

$$M = \sup_{x \in \mathbb{R}} \big|f'''(x)\big|.$$

Положим $t = \tanh x \in (-1, 1)$, тогда $\frac{1}{\cosh^2 x} = 1 - t^2$ и

$$\big|f'''(t)\big| = 20|t|\big(1 - t^2\big).$$

Это выражение достигает максимума при $t = \pm\frac{1}{\sqrt{3}}$, и, следовательно,

$$M = \frac{40}{3\sqrt{3}} \approx 7.692.$$

Согласно теоретическим оценкам, метод сходится при начальном приближении x^0:

$$\big|x^0 - x^*\big| \leq \frac{2\mu}{M} = \frac{3\sqrt{3}}{20} \approx 0.260.$$

Однако оценка достаточно грубая, поскольку использует всего 2 константы, связанных с функцией. Найдем точно, где метод начинает расходиться.
Итерация метода Ньютона имеет вид

$$x^{k+1} = x^k - \frac{x^k + 10 \tanh x^k}{1 + \frac{10}{\cosh^2 x^k}}.$$

Поскольку минимум находится в нуле, функция f четная, то на границе области сходимости модуль следующей точки совпадает с текущим, а знак меняется:

$$x^{k+1} = -x^k.$$

Это условие даёт уравнение

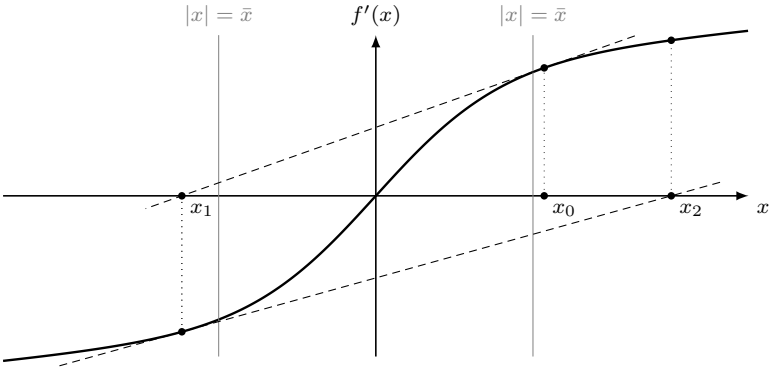
$$2x = \frac{x + 10 \tanh x}{1 + \frac{10}{\cosh^2 x}},$$

положительный корень которого:

$$\bar{x} \approx 1.22258$$

и задаёт границу области сходимости.
Итого, поведение метода Ньютона:

- $\left|x^0\right| < \bar{x}$ — сходимость к 0 квадратичная.
- $\left|x^0\right| = \bar{x}$ — колебания.
- $\left|x^0\right| > \bar{x}$ — расходимость.



Замечание Л1.2. Существует несколько способов сделать сходимость метода Ньютона глобальной. Один из них — так называемый демпфированный метод с шагом

$$x^{k+1} = x^k - \gamma_k \big(\nabla^2 f\big(x^k\big)\big)^{-1} \nabla f\big(x^k\big).$$

Стоит отметить, что на практике демпфированные методы сходятся медленнее.

Л1.3 Метод Ньютона с кубической регуляризацией

Вспомним идейно один из способов получить интуицию метода градиентного спуска. Пользуясь гладкостью градиента целевой функции, можно аппроксимировать её значение некоторым эллиптическим параболоидом. Далее можно явно выписать его минимум — это и будет шаг градиентного спуска. Попробуем распространить эту идею на методы высших порядков. Предположим, что целевая функция имеет M–липшицев гессиан. Тогда можно записать аппроксимацию второго порядка:

$$\xi_{2,x}(y) = f\big(x\big) + \big\langle \nabla f\big(x\big), y - x\big\rangle + \frac{1}{2}\big\langle \nabla^2 f\big(x\big)\big(y - x\big), y - x\big\rangle + \frac{M}{6}\big\|x - y\big\|_2^3.$$

Она устроена так же, как и квадратичная парабола, которая строилась для L–гладких функций. Эта аппроксимация подпирает сверху целевую функцию, поэтому $f(y) \leq \xi_{2,x}(y)$. Построим итерационную схему, минимизирующую верхнюю оценку:

$$x^{k+1} = \operatorname*{argmin}_{y \in \mathbb{R}^d} \xi_{2,x^k}(y).$$

Для простоты анализа определим

$$T_M(x) \in \operatorname*{argmin}_{y \in \mathbb{R}^d} \left[\big\langle \nabla f\big(x\big), y - x\big\rangle + \frac{1}{2}\big\langle \nabla^2 f\big(x\big)\big(y - x\big), y - x\big\rangle + \frac{M}{6}\big\|x - y\big\|_2^3\right].$$

Здесь константа Липшица гессиана будет параметром, чтобы иметь возможность варьировать шаг. Такой подход называется кубической регуляризацией метода Ньютона.

Алгоритм Л1.2 Метод Ньютона с кубической регуляризацией

Вход: стартовая точка $x^0 \in \mathbb{R}^d$, параметры $\{M_k\}_{k=0}^{K-1}$, количество итераций K

1: **for** $k = 0, \ldots, K-1$ **do**

2: $\quad x^{k+1} = T_{M_k}(x^k)$

3: **end for**

Выход: x^K

Далее мы предполагаем, что собственные значения гессиана пронумерованы в порядке убывания.

Теорема Л1.2 (Теорема 3 из [5]). Пусть задача безусловной оптимизации (Л1.2) с M–липшицевым гессианом целевой функции f решается с помощью метода Ньютона с кубической регуляризацией (Алгоритм Л1.2). Тогда при

$$\nabla^2 f(x^0) \succ 0, \quad \frac{M\|\nabla f(x^0)\|_2}{\lambda_d^2(\nabla^2 f(x^0))} \leq \frac{1}{4}$$

справедлива следующая оценка сходимости:

$$\|\nabla f(x^k)\|_2 \leq \lambda_d^2(\nabla^2 f(x^0)) \frac{9e^{3/2}}{16M} \left(\frac{1}{2}\right)^{2^k}.$$

Полученный метод представляет интерес, поскольку не требует выпуклости, только M–липшицевость гессиана и условия из теоремы в стартовой точке. Сходимость при этом квадратичная по норме градиента, то есть очень быстрая.

Стоит отметить, что рассматриваемая задача поиска аргминимума, вообще говоря, не выпуклая из-за кубического члена и может иметь локальные минимумы, в то время как нам нужно отыскать глобальный. Тем не менее, эта задача эквивалентна задаче выпуклой одномерной оптимизации.

Теорема Л1.3 (Теорема 10 из [5]). Задача

$$\min_{y \in \mathbb{R}^d} \left[\langle \nabla f(x), y - x \rangle + \frac{1}{2} \langle \nabla^2 f(x)(y - x), y - x \rangle + \frac{M}{6} \|x - y\|_2^3 \right]$$

эквивалентна задаче

$$\min_{r \in \mathcal{D}} \left[\frac{1}{2} \left\langle \left(\nabla^2 f(x) + \frac{Mr}{2} I_d \right)^{-1} \nabla f(x), \nabla f(x) \right\rangle + \frac{M}{12} r^3 \right],$$

где

$$\mathcal{D} = \left\{ r \in \mathbb{R}_+ \;\middle|\; \nabla^2 f(x) + \frac{Mr}{2} I_d \succ 0 \right\}.$$

Л1.4 Метод Ньютона с квадратичной регуляризацией

Недостаток стандартной версии метода Ньютона — расходимость даже для некоторых выпуклых задачах. Преимущество — явный вид итерации: необходимо обращать матрицу гессиана или же находить матрично–векторное произведение обратного гессиана на градиент. В то же время метод Ньютона с кубической регуляризацией мало того, что теоретически сходится для выпуклых задач, так ещё и показывает более лучшие

результаты на практике. Недостаток данного метода — для того, чтобы сделать одну итерацию необходимо решить новую оптимизационную задачу.
Чтобы совместить преимущества обоих методов: простоту итерации и хорошую сходимость, был предложен метод Ньютона с квадратичной регуляризацией, или же, регуляризацией Левенберга-Марквардта:

$$x^{k+1} = \operatorname*{argmin}_{y\in\mathbb{R}^d}\left\{\langle\nabla f(x^k), y-x^k\rangle + \frac{1}{2}\langle\nabla^2 f(x^k)(y-x^k), y-x^k\rangle + \frac{\lambda_k}{2}\|y-x^k\|_2^2\right\}.$$

Преимуществом данной итерации является то, что у x^{k+1} есть явная запись:

$$x^{k+1} = x^k - \left(\nabla^2 f(x^k) + \lambda_k I_d\right)^{-1}\nabla f(x^k).$$

То есть сложность итерации такая же, как у метода Ньютона, но в то же время мы сохраняем регуляризацию.
Отдельной задачей является выбор λ на каждой итерации. Один из существующих подходов аналогичен Trust–Region подходу — деление на 2 в случае удачной итерации и домножение на 2 в случае неудачной. Данный подход прост в имплементации, но требователен к вычислительным ресурсам, так как в случае «неудачных итераций» обновление x^k не происходит, но вычисляются матрично–векторные произведения.
Недавно в [2] был предложен новый способ выбора множителя λ_k, который каждую итерацию делает успешной и порядки сходимости которого совпадают с методом Ньютона с кубической регуляризацией с точностью до аддитивного логарифмического члена. Для этого достаточно взять

$$\lambda_k \sim \sqrt{M\|\nabla f(x^k)\|_2}.$$

Кроме того, что данный метод применим для выпуклых функций, также, он работает и для невыпуклых [1].

Л1.5 Квазиньютоновские методы

Метод Ньютона обеспечивает быструю локальную сходимость, однако вычислительная стоимость одной итерации часто оказывается слишком высокой: требуется находить обратный гессиан $\left(\nabla^2 f(x^k)\right)^{-1}$. Идея квазиньютоновских методов заключается в том, чтобы заменить его на приближение H_k, сохраняющее ключевые свойства обратного гессиана, но гораздо более дешёвое в обновлении.
Начнём с линейной аппроксимации приращения градиента:

$$\nabla f(x^{k+1}) - \nabla f(x^k) \approx \nabla^2 f(x^{k+1})(x^{k+1} - x^k).$$

Введём обозначения

$$s^k = x^{k+1} - x^k, \quad y^k = \nabla f(x^{k+1}) - \nabla f(x^k)$$

и положим

$$B_{k+1} \approx \nabla^2 f(x^{k+1}), \quad H_{k+1} \approx \left(\nabla^2 f(x^{k+1})\right)^{-1}.$$

Тогда аппроксимация выше принимает вид

$$y^k = B_{k+1}s^k \iff s^k = H_{k+1}y^k. \tag{Л1.3}$$

Это уравнение называют *квазиньютоновским.*

Замечание Л1.3. Условие симметричности и квазиньютоновское уравнение дают

$$\frac{d(d-1)}{2} + d = \frac{d(d+1)}{2}$$

линейно независимых ограничений на $d \times d$ матрицу. Поскольку общее число элементов матрицы равно d^2, остаётся $\frac{d(d-1)}{2}$ свободных параметров. Это означает, что множество допустимых приближений очень велико и существует широкий спектр стратегий построения H_{k+1} или B_{k+1}. Ниже мы рассмотрим наиболее популярные из них.

Общая схема квазиньютоновских методов выглядит следующим образом:

Алгоритм Л1.3 Общая схема квазиньютоновских методов

Вход: стартовая точка $x^0 \in \mathbb{R}^d$, стартовая матрица H_0, размеры шагов $\{\gamma_k\}_{k=0} > 0$, количество итераций K

1: **for** $k = 0, 1, \ldots, K-1$ **do**
2: $x^{k+1} = x^k - \gamma_k H_k \nabla f\left(x^k\right)$
3: Обновить $H_k \to H_{k+1}$ так, чтобы выполнялось (Л1.3)
4: **end for**

Выход: x^K

Замечание Л1.4. Размеры шагов $\{\gamma_k\}_{k=0}^{K-1}$ могут выбираться с помощью процедуры линейного поиска. При этом можно как находить шаг наискорейшего спуска вдоль направления $H_k \nabla f\left(x^k\right)$, так и требовать выполнения условий Вольфа (Алгоритм **??**).

Л1.5.1 SR1

Будем использовать для обновления матрицы дешевую с точки зрения вычислений симметричную одноранговую добавку (отсюда и название Symmetric Rank 1):

$$H_{k+1} = H_k + \mu_k q^k \left(q^k\right)^\top,$$

где $\mu_k \in \mathbb{R}$ и $q^k \in \mathbb{R}^d$. Их мы подбираем исходя из квазиньютоновского уравнения:

$$s^k = H_{k+1} y^k = \left(H_k + \mu_k q^k \left(q^k\right)^\top\right) y^k = H_k y^k + \mu_k \left(\left(q^k\right)^\top y^k\right) q^k.$$

Откуда

$$\mu_k \left(\left(q^k\right)^\top y^k\right) q^k = s^k - H_k y^k.$$

Возьмём $\mu_k = \frac{1}{\left(q^k\right)^\top y^k}$ и получим, что $q^k = s^k - H_k y^k$.

Итак, `SR1` способ обновления матрицы H_k:

$$H_{k+1} = H_k + \frac{\left(s^k - H_k y^k\right)\left(s^k - H_k y^k\right)^\top}{\left(s^k - H_k y^k\right)^\top y^k}.$$

Л1.5.2 Broyden

Подойдем к задаче иначе. Запишем квазиньютоновское уравнение для матрицы B:

$$y^k = B_{k+1}s^k.$$

Потребуем минимальность фробениусовой нормы поправки при ограничении в виде квазиньютоновского уравнения:

$$\begin{aligned} B_{k+1} = &\operatorname*{argmin}_{B\in\mathbb{R}^{d\times d}} \left\|B - B_k\right\|_F^2 \\ \text{s.t.} \quad &Bs^k = y^k. \end{aligned}$$

Иными словами, хотим найти наиболее близкую матрицу к B_k, которая будет удовлетворять квазиньютоновскому уравнению. Решением такой задачи будет формула обновления:

$$B_{k+1} = B_k + \frac{\left(y^k - B_k s^k\right)\left(s^k\right)^\top}{\left(s^k\right)^\top s^k}.$$

Обратим внимание, что полученная поправка является одноранговой, хотя явно мы этого не требовали. Однако она не является симметричной, что плохо согласуется со свойствами гессиана, который мы хотим аппроксимировать.
Чтобы не обращать матрицу B_{k+1} и не решать системы линейных уравнений, можем получить явную формулу для $H_{k+1} = B_{k+1}^{-1}$, используя формулу Шермана–Моррисона–Вудбери, впервые предложенную в [10].

Утверждение Л1.2. Пусть $A \in \mathbb{R}^{d\times d}$ — обратимая матрица, а $U, V \in \mathbb{R}^{d\times n}$. Тогда, если также обратима матрица $I_d + V^\top A^{-1}U$, то верна формула:

$$\left(A + UV^\top\right)^{-1} = A^{-1} - A^{-1}U\left(I_d + V^\top A^{-1}U\right)^{-1}V^\top A^{-1}.$$

После ее применения получаем обновление H_k:

$$H_{k+1} = H_k + \frac{\left(s^k - H_k y^k\right)\left(s^k\right)^\top H_k}{\left(s^k\right)^\top H_k y^k}.$$

Л1.5.3 DFP

Модифицируем задачу поиска B_{k+1}. Добавим требование на симметричность матрицы и заменим обычную норму Фробениуса на взвешенную:

$$\left\|A\right\|_W = \left\|W^{1/2}AW^{1/2}\right\|_F,$$

где W — произвольная матрица, для которой выполняется $Wy^k = s^k$. Для определенности, такой матрицей может быть обратный усредненный гессиан $W = \bar{G}_k^{-1}$, определяющийся следующим образом:

$$\bar{G}_k = \int_0^1 \nabla^2 f\left(x^k - \tau\gamma_k H_k \nabla f\left(x^k\right)\right) \mathrm{d}\tau\,.$$

Получим задачу оптимизации для поиска B_{k+1}:

$$\begin{aligned} B_{k+1} = & \operatorname*{argmin}_{B \in \mathbb{R}^{d \times d}} \|B - B_k\|_W^2 \\ \text{s.t.} \quad & Bs^k = y^k, \\ & B^\top = B. \end{aligned}$$

Решением этой задачи является формула обновления `DFP` (Davidon–Fletcher–Powell):

$$B_{k+1} = \left(I_d - \frac{y^k \left(s^k\right)^\top}{\left(y^k\right)^\top s^k}\right) B_k \left(I_d - \frac{s^k \left(y^k\right)^\top}{\left(y^k\right)^\top s^k}\right) + \frac{y^k \left(y^k\right)^\top}{\left(y^k\right)^\top s^k}.$$

Обращая ее по формуле Шермана-Моррисона-Вудбери, получаем выражение для H_{k+1}:

$$H_{k+1} = H_k - \frac{H_k y^k \left(y^k\right)^\top H_k}{\left(y^k\right)^\top H_k y^k} + \frac{s^k \left(s^k\right)^\top}{\left(s^k\right)^\top y^k}. \tag{Л1.4}$$

Теорема Л1.4 (Теорема 4.2 из [8])**.** Пусть задача безусловной оптимизации (Л1.2) с M–липшицевым гессианом, L–гладкой, μ–сильно выпуклой целевой функцией f решается с помощью метода `DFP` (Алгоритм Л1.3 с формулой обновления (Л1.4)). Введём обозначение

$$\lambda_f(x) = \sqrt{\left\langle \nabla f(x), \left(\nabla^2 f(x)\right)^{-1} \nabla f(x) \right\rangle}.$$

Тогда при выборе шагов $\gamma_k = 1$ и начальной точке x^0 достаточно близкой к решению, что выполняется

$$\lambda_f(x^0) \leq \frac{\log \frac{3}{2}}{4} \frac{\mu^{5/2}}{LM},$$

справедлива следующая оценка сходимости:

$$\lambda_f(x^K) \leq \left(\frac{11 d L^2}{\mu^2 K}\right)^{K/2} \lambda_f(x^0).$$

Л1.5.4 BFGS

Поступим так же, как и в `DFP`, только будем решать задачу сразу для H. Она получена из таких же рассуждений, меняется только ограничение:

$$\begin{aligned} H_{k+1} = & \operatorname*{argmin}_{H \in \mathbb{R}^{d \times d}} \|H - H_k\|_W^2 \\ \text{s.t.} \quad & s^k = Hy^k, \\ & H^\top = H. \end{aligned}$$

Решением будет формула `BFGS` (Broyden–Fletcher–Goldfarb–Shanno):

$$H_{k+1} = \left(I_d - \frac{s^k \left(y^k\right)^\top}{\left(y^k\right)^\top s^k}\right) H_k \left(I_d - \frac{y^k \left(s^k\right)^\top}{\left(y^k\right)^\top s^k}\right) + \frac{s^k \left(s^k\right)^\top}{\left(y^k\right)^\top s^k}. \tag{Л1.5}$$

Теорема Л1.5 (Теорема 4.2 из [8])**.** Пусть задача безусловной оптимизации (Л1.2) с M–липшицевым гессианом, L–гладкой, μ–сильно выпуклой целевой функцией f решается с помощью метода `BFGS` (Алгоритм Л1.3 с формулой обновления (Л1.5)). Введём обозначение

$$\lambda_f(x) = \sqrt{\left\langle \nabla f(x), \left(\nabla^2 f(x)\right)^{-1} \nabla f(x) \right\rangle}.$$

Тогда при выборе шагов $\gamma_k = 1$ и начальной точке x^0 достаточно близкой к решению, что выполняется

$$\lambda_f\left(x^0\right) \leq \frac{\log \frac{3}{2}}{4} \frac{\mu^{5/2}}{LM},$$

справедлива следующая оценка сходимости:

$$\lambda_f\left(x^K\right) \leq \left(\frac{11dL}{\mu K}\right)^{K/2} \lambda_f\left(x^0\right).$$

Замечание Л1.5. Существует много способов инициализировать матрицу H_0, но на практике достаточно брать $H_0 = I_d$.

Замечание Л1.6. Сложность всех арифметических операций на одной итерации квазиньютоновских методов составляет $\mathcal{O}\left(d^2\right)$. Это дешевле обращения гессиана, но все еще довольно плохой результат для задач экстремально больших размерностей.

Замечание Л1.7. Гессиан (или его аппроксимации) на самом деле не обращают. Вместо это либо используют метод сопряженных градиентов для решения системы $Hy = \nabla f\left(x^k\right)$ с решением $y = H^{-1}\nabla f\left(x^k\right)$, либо используют MINRES: находят $y \in \operatorname{argmin}_{y \in \mathbb{R}^d} \left\|Hy - \nabla f\left(x^k\right)\right\|_2^2$, что более предпочтительно в случаях когда система линейных уравнений нерешаема, либо используют backward propagation для того, чтобы посчитать $\nabla^2 f(x)v$ для любого фиксированного вектора v дифференцируют $\left\langle v, \nabla f(x)\right\rangle$ (Параграф **??**).

Л1.5.5 Сравнительная таблица

Соберем все формулы для рассмотренных методов в одном месте.

Метод	B^{new}	$H^{\text{new}} = \left(B^{\text{new}}\right)^{-1}$
`SR1`	$B + \frac{(y-Bs)(y-Bs)^\top}{(y-Bs)^\top s}$	$H + \frac{(s-Hy)(s-Hy)^\top}{(s-Hy)^\top y}$
`Broyden`	$B + \frac{y-Bs}{s^\top s} s^\top$	$H + \frac{(s-Hy)s^\top H}{s^\top Hy}$
`DFP`	$\left(I_d - \frac{ys^\top}{y^\top s}\right) B \left(I_d - \frac{sy^\top}{y^\top s}\right) + \frac{yy^\top}{y^\top s}$	$H + \frac{ss^\top}{s^\top y} - \frac{Hyy^\top H}{y^\top Hy}$
`BFGS`	$B + \frac{yy^\top}{y^\top s} - \frac{Bss^\top B}{s^\top Bs}$	$\left(I_d - \frac{sy^\top}{y^\top s}\right) H \left(I_d - \frac{ys^\top}{y^\top s}\right) + \frac{ss^\top}{y^\top s}$

Таблица 1: Обновления матриц B и H в различных квазиньютоновских методах. Здесь B, H, s и y соответствуют последней итерации, а B^{new} и H^{new} — их новые значения.

Л1.5.6 L-BFGS

При переходе от метода Ньютона к квазиньютоновским методам мы уже получили ускорение с $\mathcal{O}(d^3)$ до $\mathcal{O}(d^2)$ арифметических операций на итерацию. В памяти же в обоих подходах требуется хранить $\mathcal{O}(d^2)$ значений. Квадратичная стоимость итерации и по арифметическим операциям, и по памяти — это очень дорого для задач большой размерности.

Это подводит нас к следующему методу — `L-BFGS` из [3], где `L` означает Limited-memory. Базовая идея — вместо матрицы $H_k \in \mathbb{R}^{d\times d}$, аппроксимирующей Гессиан, хранить несколько подходящих векторов длины d. За улучшение по памяти приходится платить ухудшением скорости сходимости. Тем не менее, оказывается возможным показать линейную сходимость такого метода.

В случае `BFGS` имели следующее обновление матрицы после применения формулы Шермана–Моррисона–Вудбери:

$$H_{k+1} = V_k^\top H_k V_k + \frac{s^k \left(s^k\right)^\top}{\left(y^k\right)^\top s^k},$$

где $V_k = I_d - \frac{y^k\left(s^k\right)^\top}{\left(y^k\right)^\top s^k}$. Предлагается на итерации k выбирать некоторое начальное приближение Гессиана H_k^0 и затем последовательно применить (Л1.5) по последним m парам $\{s^k, y^k\}$:

$$\begin{aligned} H_{k+1} = &\left(V_{k-1}^\top \dots V_{k-m}^\top\right) H_k^0 \left(V_{k-m} \dots V_{k-1}\right) \\ &+ \rho^{k-m}\left(V_{k-1}^\top \dots V_{k-m+1}^\top\right) s^{k-m}\left(s^{k-m}\right)^\top \left(V_{k-m+1} \dots V_{k-1}\right) \\ &+ \dots \\ &+ \rho^{k-1} s^{k-1}\left(s^{k-1}\right)^\top. \end{aligned}$$

Здесь мы обозначили $\rho^k = \frac{1}{\left(y^k\right)^\top s^k}$. Экспериментальные результаты показывают, что m может быть выбрано относительно небольшим (меньше двадцати). Это дает существенное улучшение метода по памяти. Начальное приближение H_k^0 рекомендуется выбирать следующим образом:

$$H_k^0 = \frac{\left(s^{k-1}\right)^\top y^{k-1}}{\left(y^{k-1}\right)^\top y^{k-1}} I_d.$$

Множитель перед единичной матрицей реализует шкалирование матрицы вдоль последнего направления поиска. Для поиска шага для робастности важно использовать условия Вольфа (либо сильные условия Вольфа).

Основные недостатки метода `L-BFGS` заключаются в том, что он часто сходится медленно, особенно на плохо обусловленных задачах.

Л1.6 Trust-Region шаг

Методы линейного поиска основаны на поиске подходящего размера шага γ_k вдоль фиксированного направления p^k, которым может быть градиент $\nabla f\left(x^k\right)$ в случае градиентного спуска или $\left(\nabla^2 f\left(x^k\right)\right)^{-1}\nabla f\left(x^k\right)$ в случае демпфированного метода Ньютона.

Метод области доверия (Trust-Region) работает иначе. На каждом шаге алгоритма строится квадратичная модель m_k целевой функции f:

$$m_k(p) = f\big(x^k\big) + \big\langle \nabla f\big(x^k\big), p\big\rangle + \frac{1}{2}\big\langle p, B_k p\big\rangle,$$

где B_k — некоторая симметричная матрица, приближающая гессиан $\nabla^2 f\big(x^k\big)$. Например, в квазиньютоновских методах мы знаем аппроксимацию гессиана B_k.
Эта квадратичная модель совпадает с разложением Тейлора целевой функции f с точностью до первых двух членов. Если B_k в точности равна $\nabla^2 f\big(x^k\big)$, то имеем совпадение в первых трех членах.
Чтобы получить шаг согласно стратегии Trust-Region, решается подзадача

$$\begin{aligned} \min_{p\in\mathbb{R}^d} \quad & m_k(p) = f\big(x^k\big) + \big\langle \nabla f\big(x^k\big), p\big\rangle + \frac{1}{2}\big\langle p, B_k p\big\rangle \\ \text{s.t.} \quad & \big\|p\big\|_2 \le \Delta_k, \end{aligned} \tag{Л1.6}$$

где Δ_k — радиус области доверия. Эта подзадача является квадратичной: и целевая функция m_k, и ограничение, которое можно переписать как

$$\big\langle p, p\big\rangle \le \Delta_k^2,$$

являются квадратичными.
Понять принцип Trust-Region шага можно при сравнении с демпфированным методом Ньютона со значением шага $\gamma_k = \frac{\Delta_k}{\left\|p^k\right\|}$.

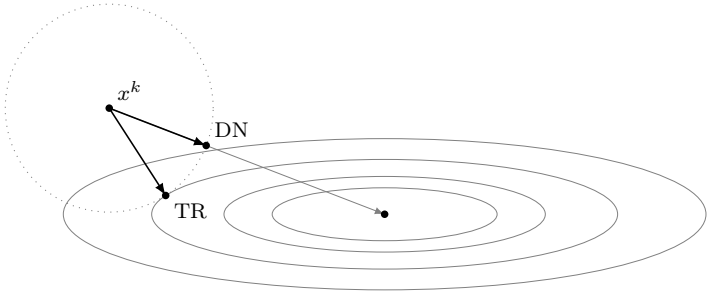


Рис. Л1.1: Линии уровня квадратичной модели $m_k(p)$, область доверия ограничена пунктиром, показаны шаги Trust-Region и демпфированного метода Ньютона.

Демпфированный метод Ньютона делает шаг в направлении минимума построенной модели m_k, а Trust-Region минимизирует значение модели $m_k(p)$, оставаясь в области доверия $\big\|p\big\|_2 \le \Delta_k$. Рисунок позволяет понять, почему эти шаги не эквивалентны. Trust-Region существенно учитывает ограничение на размер шага при его поиске.
В случае, когда

$$\big\|B_k^{-1}\nabla f\big(x^k\big)\big\|_2 \le \Delta_k,$$

решение (Л1.6) просто

$$p^k = -B_k^{-1}\nabla f\big(x^k\big).$$

В ином случае решение не так очевидно, однако может быть найдено не так дорого. Но зачастую достаточно найти лишь приближенное решение для хорошей сходимости на практике.

Поговорим о стратегии подбора радиуса Δ_k. Если выбирать его слишком маленьким, шаги в направлении оптимума будут небольшими, и метод сходиться будет медленно. Если же брать Δ_k чересчур большим, то построенная модель m_k будет плохо приближать целевую функцию f вдали от нуля. Шаги будут большими, но неточными, и можем получить расходимость. Чтобы численно описывать, насколько наша модель точно приближает целевую функцию, определим соотношение

$$\rho_k = \frac{f\left(x^k\right) - f\left(x^k + p^k\right)}{m_k(0) - m_k\left(p^k\right)}. \tag{Л1.7}$$

Числитель этой дроби назовем *действительным убыванием*, а знаменатель — *предсказанным убыванием*. Поскольку p^k — точка оптимума m_k, то предсказанное убывание всегда неотрицательно. Отсюда следует, что если $\rho_k < 0$, то $f\left(x^k + p^k\right) > f\left(x^k\right)$, и такой шаг должен быть отклонен. С другой стороны, если $\rho_k \approx 1$, то модель и функция хорошо согласуются, и можно увеличивать доверительную область на последующих итерациях. Если ρ_k положительно, но не вблизи 1, то не изменяем Δ_k. Эту стратегию можно описать с помощью алгоритма.

Алгоритм Л1.4 Метод доверительной области

Вход: максимальное значение доверительного радиуса $\overline{\Delta} > 0$, начальный доверительный радиус $\Delta_0 \in (0, \overline{\Delta})$, ограничение снизу на отношение убываний $\eta \in \left[0, \frac{1}{4}\right]$

for $k = 0, \ldots, K-1$ **do**
  Найти p_k (приближённо) решением (Л1.6)
  Вычислить ρ_k по формуле (Л1.7)
  if $\rho_k < \frac{1}{4}$ **then**
    $\Delta_{k+1} = \frac{1}{4}\left\|p_k\right\|_2$
  else
    if $\rho_k > \frac{3}{4}$ **and** $\left\|p_k\right\|_2 = \Delta_k$ **then**
      $\Delta_{k+1} = \min\left(2\Delta_k, \overline{\Delta}\right)$
    else
      $\Delta_{k+1} = \Delta_k$
    end if
  end if
  if $\rho_k > \eta$ **then**
    $x_{k+1} = x_k + p_k$
  else
    $x_{k+1} = x_k$
  end if
end for

В алгоритме мы дополнительно добавили ограничение на максимальный размер шага $\overline{\Delta}$, а также ограничение на минимальное значение отношения ρ_k, при котором совершается шаг, в виде константы η.
Более подробно про приближенное решение подзадачи (Л1.6) рассказано в работе [7].

Л1.7 Метод Гаусса–Ньютона

Для того, чтобы вывести аппроксимацию Гаусса-Ньютона, для начала рассмотрим задачу регрессии $L : \mathbb{R}^d \to \mathbb{R}$:

$$L(\theta) = \frac{1}{2n}\sum_{i=1}^{n}\left(\theta^\top x_i - y_i\right)^2, \quad x \in \mathbb{R}^d, y \in \mathbb{R}^n,$$

где $\{x_i, y_i\}_{i=1}^n$ — данные. Соответственно, производные данной функции следующие:

$$\nabla L(\theta) = \frac{1}{2n}\sum_{i=1}^{n} \theta\big(\theta^\top x_i - y_i\big), \quad \nabla^2 L(\theta) = \frac{1}{n}\sum_{i=1}^{n} \theta\theta^\top.$$

Если рассматривать нелинейные модели:

$$L(\theta) = \frac{1}{2n}\sum_{i=1}^{n} \big(f(x_i, \theta) - y_i\big)^2,$$

то гессиан будет иметь вид

$$\nabla^2 L(\theta) = \frac{1}{n}\sum_{i=1}^{n} \nabla_\theta f(x_i, \theta)\nabla_\theta f(x_i, \theta)^\top + \frac{1}{n}\sum_{i=1}^{n} \nabla^2_\theta f(x_i, \theta)(f(x_i, \theta) - y_i).$$

Обозначим первое слагаемое в этой сумме за $G(\theta)$, а второе за $R(\theta)$. Если модель переопределена, то вблизи решения мы ожидаем остатки $(f(x_i, \theta) - y_i)$ близкими к нулю, соответственно, вклад от $R(\theta)$ в гессиан будет небольшой. Соответственно, аппроксимация гессиана $G(\theta)$ называется аппроксимацией Гаусса–Ньютона.
В [9] этот подход был обобщен для функций потерь более общего вида

$$L(\theta) = \frac{1}{n}\sum_{i=1}^{n} a_i(y_i, b_i(x_i, \theta)),$$

В такой постановке аналогично можно вывести

$$G(\theta) = \frac{1}{n}\sum_{i=1}^{n} \big[J_\theta b_i(x_i, \theta)\big]^\top \nabla^2_b a_i(y_i, b_i(x_i, \theta))\big[J_\theta b_i(x_i, \theta)\big].$$

Если a_i — выпуклая функция, то приближение Гаусс–Ньютона всегда положительно полуопределенная матрица, даже если Гессиан не является таковой, что делает данный метод применимым даже для невыпуклых задач.

Л1.8 Natural Gradient Descent

Один из существующих взглядов на методы второго порядка — это подходы, учитывающие кривизну функции. Возвращаясь ещё раз к градиентному спуску, который можно вывести из квадратичной регуляризации линейного приближения:

$$x^{k+1} = \operatorname*{argmin}_{y\in\mathbb{R}^d}\left\{\big\langle \nabla f\big(x^k\big), y - x^k\big\rangle + \frac{1}{2\gamma_k}\big\|y - x^k\big\|_2^2\right\},$$
$$x^{k+1} = x^k - \gamma_k \nabla f\big(x^k\big).$$

Если мы знаем, что не все направления оптимизации равноценные, то можем заменить стандартное скалярное произведение на индуцированное $\|x\|_A := \langle x, Ax\rangle^{1/2}$, где A — симметричная положительно определенная матрица. В таком случае итерация будет иметь вид

$$x^{k+1} = \operatorname*{argmin}_{y\in\mathbb{R}^d}\left\{\big\langle \nabla f\big(x^k\big), y - x^k\big\rangle + \frac{1}{2\gamma_k}\big\|y - x^k\big\|_A^2\right\},$$
$$x^{k+1} = x^k - \gamma_k A^{-1} \nabla f\big(x^k\big).$$

Например, если взять $A = \nabla^2 f(x^k)$, то мы получим стандартный демпфированный метод Ньютона.
Можно пойти дальше и выделять не конкретные направления, а использовать более сложные штрафы на отклонение от предыдущей итерации, если у нас есть дополнительные сведения о внутренней структуре задачи. Например, если есть семейства распределений p_θ, зависящих от параметра, то измеряя близость между распределениями в дивергенции Кульбака–Лейблера, мы получаем

$$\theta^{k+1} = \operatorname*{argmin}_{\delta\theta} \left\{ \langle \nabla L(\theta^k), \delta\theta \rangle + \frac{1}{\gamma_k} \mathrm{KL}(p_\theta \,||\, p_{\theta+\delta\theta}) \right\}.$$

Явный вид такой итерации трудоемок для вычисления, поэтому мы будем использовать приближение дивергенции Кульбака-Лейблера:

$$\begin{aligned}
\mathbb{E}_{p_\theta}\left[\log \frac{p_\theta}{p_{\theta+\delta\theta}}\right] &= \mathbb{E}_{p_\theta}\left[\log p_\theta - \log p_{\theta+\delta\theta}\right] \\
&\approx \mathbb{E}_{p_\theta}\left[\log p_\theta - \log p_\theta - \delta\theta^\top \nabla_\theta \log p_\theta - \frac{1}{2}\delta\theta^\top \nabla^2_\theta \log p_\theta \delta\theta\right] \\
&= \mathbb{E}_{p_\theta}\left[-\delta\theta^\top \nabla_\theta \log p_\theta - \frac{1}{2}\delta\theta^\top \nabla^2_\theta \log p_\theta \delta\theta\right].
\end{aligned}$$

Первое слагаемое можно посчитать следующим образом:

$$\begin{aligned}
\mathbb{E}_{p_\theta}\left[\nabla_\theta \log p_\theta\right] &= \int p_\theta(z) \nabla_\theta \log p_\theta(z)\, \mathrm{d}z = \int p_\theta(z) \frac{\nabla_\theta p_\theta(z)}{p_\theta(z)}\, \mathrm{d}z = \int \nabla_\theta p_\theta(z)\, \mathrm{d}z \\
&= \nabla_\theta \int p_\theta(z)\, \mathrm{d}z = \nabla_\theta 1 = 0.
\end{aligned}$$

Второе слагаемое оценивается следующим образом:

$$\begin{aligned}
\mathbb{E}_{p_\theta}\left[\nabla^2_\theta \log p_\theta\right] &= \mathbb{E}_{p_\theta}\left[\nabla_\theta \left(\frac{\nabla_\theta p_\theta}{p_\theta}\right)\right] = \mathbb{E}_{p_\theta}\left[\frac{\nabla^2_\theta p_\theta}{p_\theta} - \frac{\nabla_\theta p_\theta \nabla_\theta p_\theta^\top}{p_\theta^2}\right] \\
&= \int p_\theta(z) \frac{\nabla^2_\theta p_\theta(z)}{p_\theta(z)}\, \mathrm{d}z - \int p_\theta(z) \left(\frac{\nabla_\theta p_\theta(z)}{p_\theta(z)}\right)\left(\frac{\nabla_\theta p_\theta(z)}{p_\theta(z)}\right)^\top \mathrm{d}z \\
&= \int \nabla^2_\theta p_\theta(z)\, \mathrm{d}z - \int p_\theta(z) \nabla_\theta \log p_\theta(z) \nabla_\theta \log p_\theta(z)^\top\, \mathrm{d}z \\
&= \nabla^2_\theta \int p_\theta(z)\, \mathrm{d}z - \mathbb{E}_{p_\theta}\left[\nabla_\theta \log p_\theta \nabla_\theta \log p_\theta^\top\right] \\
&= \nabla^2_\theta 1 - \mathbb{E}_{p_\theta}\left[\nabla_\theta \log p_\theta \nabla_\theta \log p_\theta^\top\right] \\
&= -\mathbb{E}_{p_\theta}\left[\nabla_\theta \log p_\theta \nabla_\theta \log p_\theta^\top\right].
\end{aligned}$$

Таким образом, в квадратичном приближении итерация метода следующая:

$$\begin{aligned}
F(\theta) &= \frac{1}{n}\sum_{i=1}^n \mathbb{E}_{y\sim p_\theta}\left[\nabla_\theta \log p_\theta(y|x_i,\theta) \nabla_\theta \log p_\theta(y|x_i,\theta)^\top\right] \\
\theta^{k+1} &= \theta^k - \gamma_k F(\theta^k)^{-1} \nabla L(\theta^k).
\end{aligned}$$

Этот метод называется Natural Gradient Descent, а матрица $F(\theta)$ — *матрица Фишера*.

Рассмотрим пример. Предположим, что $y|x \sim \mathcal{N}\big(f(x,\theta),\sigma^2\big)$. Тогда

$$\log p_\theta(y|x,\theta) = -\frac{1}{2\sigma^2}(y - f(x,\theta))^2 - \frac{1}{2}\log\big(2\pi\sigma^2\big),$$
$$\nabla_\theta \log p_\theta(y|x,\theta) = -\frac{1}{\sigma^2}(y - f(x,\theta))\nabla_\theta f(x,\theta).$$

Посчитаем математическое ожидание:

$$\mathbb{E}_{y\sim p_\theta}\left[\nabla_\theta \log p_\theta(y|x,\theta)\nabla_\theta \log p_\theta(y|x,\theta)^\top\right] = \mathbb{E}_{y\sim p_\theta}\left[\frac{1}{\sigma^4}(y - f(x,\theta))^2\nabla_\theta f(x,\theta)\nabla_\theta f(x,\theta)^\top\right]$$
$$= \frac{1}{\sigma^4}\nabla_\theta f(x,\theta)\nabla_\theta f(x,\theta)^\top \mathbb{E}_{y\sim p_\theta}\left[\big(y - f(x,\theta)\big)^2\right]$$
$$= \frac{1}{\sigma^2}\nabla_\theta f(x,\theta)\nabla_\theta f(x,\theta)^\top,$$

где последнее равенство следует из $y|x \sim \mathcal{N}(f(x,\theta),\sigma^2)$. Таким образом, матрица Фишера будет иметь следующий вид:

$$F(\theta) = \frac{1}{\sigma^2 n}\sum_{i=1}^{n}\nabla_\theta f(x_i,\theta)\nabla_\theta f(x_i,\theta)^\top.$$

Мы получили метод, идентичный методу Гаусса–Ньютона, исходя из вероятностной постановки задачи. На самом деле, это не совпадение.
Теорема 9.2 работы [4] утверждает, что если $p(y|x,\theta)$ — распределение из экспоненциального семейства с параметром θ, то матрица Фишера совпадает с матрицей Гаусса–Ньютона.

Л1.9 Аппроксимации матрицы Фишера

Несмотря на хорошую сходимость методов, проблема Natural Gradient Descent кроется в трудоемком посчёте математического ожидания $\mathbb{E}_{p_\theta}$. Самый естественный способ оценить ожидание — это использовать Монте–Карло оценку. Однако это зачастую затратно в имплементации. Для того, чтобы сделать это эффективно, применяются следующие эвристики
Самый простой вариант — приближать это математическое ожидание напрямую по данным из обучающей выборки. Вместо

$$F(\theta) = \frac{1}{n}\sum_{i=1}^{n}\mathbb{E}_{y\sim p_\theta}\left[\nabla_\theta \log p_\theta(y|x_i,\theta)\nabla_\theta \log p_\theta(y|x_i,\theta)^\top\right]$$

использовать

$$\widehat{F}(\theta) = \frac{1}{n}\sum_{i=1}^{n}\nabla_\theta \log p_\theta(y_i|x_i,\theta)\nabla_\theta \log p_\theta(y_i|x_i,\theta)^\top.$$

Матрица $\widehat{F}(\theta)$ называется *эмпирической матрицей Фишера*. Простота имплементации компенсируется грубостью аппроксимации, в случая больших градиентов модель медленно сходится, так как $\widehat{F}^{-1}(\theta)\nabla L(\theta)$ обратно пропорционально норме градиента. Тем не менее для некоторых задач подобная аппроксимация может показывать хорошие результаты.

Если дополнительно знать структуру задачи, то можно использовать более хорошие аппроксимации вместо эмпирической матрицы Фишера. Если наша модель — это полносвязная нейронная сеть, со слоями W_i, предактивациями a_i и backward propagation градиентами g_i, то матрицу Фишера можно приближать следующим образом:

$$F_{i,j} = \mathbb{E}\left[\bar{a}_{i-1}\bar{a}_{j-1}^\top \otimes g_i\, g_j^\top\right] \approx \mathbb{E}\left[\bar{a}_{i-1}\bar{a}_{j-1}^\top\right] \otimes \mathbb{E}\left[g_i g_j^\top\right] = \bar{A}_{i-1,j-1} \otimes G_{i,j} = \tilde{F}_{i,j}.$$

Это даёт

$$\tilde{F} = \begin{pmatrix} \bar{A}_{0,0} \otimes G_{1,1} & \bar{A}_{0,1} \otimes G_{1,2} & \cdots & \bar{A}_{0,\ell-1} \otimes G_{1,\ell} \\ \bar{A}_{1,0} \otimes G_{2,1} & \bar{A}_{1,1} \otimes G_{2,2} & \cdots & \bar{A}_{1,\ell-1} \otimes G_{2,\ell} \\ \vdots & \vdots & \ddots & \vdots \\ \bar{A}_{\ell-1,0} \otimes G_{\ell,1} & \bar{A}_{\ell-1,1} \otimes G_{\ell,2} & \cdots & \bar{A}_{\ell-1,\ell-1} \otimes G_{\ell,\ell} \end{pmatrix}.$$

В свою очередь матрица $\tilde{F}$ аппроксимируется через Монте–Карло оценки или по выборке. Такой метод называется K-FAC (Kronecker–factored Approximate Curvature).

Л1.10 Вероятностная формулировка задачи

Вместо простого предсказывания значения величины y можно искать её распределение. Формализовывается это следующим образом: допустим, перед нами стоит задача приблизить целевое вероятностное распределение с плотностью $q(x, y)$ распределением из параметрического семейства $p_\theta(x, y)$. Тогда нам надо минимизировать дивергенцию Кульбака–Лейблера между этими распределениями:

$$\mathrm{KL}(q(x,y) \mid\mid p_\theta(x,y)) = \int q(x,y) \log \frac{q(x,y)}{p(x,y|\theta)}\,\mathrm{d}y\,\mathrm{d}x = \int q(x,y) \log \frac{q(y|x)q(x)}{p(y|x,\theta)p(x|\theta)}\,\mathrm{d}y\,\mathrm{d}x\,.$$

Считая, что предсказываемое нами распределение на исходных данных не зависит от параметра, и более того, совпадает с настоящим распределением, то есть $p(x|\theta) = p(x) = q(x)$, мы получаем

$$\mathrm{KL}(q(x,y) \mid\mid p(x,y)) = \int q(x,y) \log \frac{q(y|x)}{p(y|x,\theta)}\,\mathrm{d}y\,\mathrm{d}x = \int q(x)\left(\int q(y|x) \log \frac{q(y|x)}{p(y|x,\theta)}\,\mathrm{d}y\right)\mathrm{d}x$$

$$= \mathbb{E}_{q(x)}\mathrm{KL}(q(y|x) \mid\mid p(y|x,\theta)) \approx \frac{1}{n}\sum_{i=1}^{n} \mathrm{KL}(q(y|x_i) \mid\mid p(y|x_i,\theta)).$$

Если у нас нет доступа к $q(y|x)$, а только к отдельным элементам, то дивергенции под суммой считаются по сэмплам:

$$\mathrm{KL}(q(y|x_i) \mid\mid p(y|x_i,\theta)) \sim -\log p(y_i|x_i,\theta).$$

Тогда изначальная задача минимизации сводится к

$$L(\theta) = -\frac{1}{n}\sum_{i=1}^{n} \log p(y_i|x_i,\theta).$$

Список литературы

[1] Nikita Doikov, Konstantin Mishchenko, and Yurii Nesterov. Super-universal regularized newton method. 2022.

[2] Nikita Doikov and Yurii Nesterov. Gradient regularization of newton method with bregman distances. 2021.

[3] Dong C. Liu and Jorge Nocedal. On the limited memory bfgs method for large scale optimization. *Mathematical Programming, Series B*, 45(3):503–528, 1989.

[4] James Martens. New insights and perspectives on the natural gradient method. 2020.

[5] Yurii Nesterov and B. T. Polyak. Cubic regularization of newton method and its global performance. *Mathematical Programming*, 108(1):177–205, 2006.

[6] Isaac Newton. *De analysi per aequationes numero terminorum infinitas.* 1669. Unpublished manuscript; first printed edition in 1711.

[7] J. Nocedal and S. Wright. *Numerical Optimization.* Springer Series in Operations Research and Financial Engineering. Springer New York, 2006.

[8] Anton Rodomanov and Yurii Nesterov. New results on superlinear convergence of classical quasi-newton methods. *Journal of Optimization Theory and Applications*, 188(3):744–769, 2021.

[9] Nicol N. Schraudolph. Fast curvature matrix-vector products for second-order gradient descent. 14(7):1723–1738, 2002.

[10] Jack Sherman and Winifred J. Morrison. Adjustment of an inverse matrix corresponding to changes in the elements of a given column or a given row of the original matrix. *Annals of Mathematical Statistics*, 1949. Abstract.