Метод Ньютона. Квазиньютоновские методы

Методы оптимизации

Александр Безносиков

Московский физико-технический институт

15 октября 2026



Задача поиска нуля

- Рассмотрим задачу поиска «корня» функции. Формально требуется для непрерывно дифференцируемой функции $\varphi : \mathbb{R} \to \mathbb{R}$ найти точку x^*, для которой верно

$$\varphi\left(x^*\right) = 0.$$

Задача поиска нуля

- Рассмотрим задачу поиска «корня» функции. Формально требуется для непрерывно дифференцируемой функции $\varphi : \mathbb{R} \to \mathbb{R}$ найти точку x^*, для которой верно

$$\varphi\left(x^*\right) = 0.$$

- Пусть мы находимся в точке x^0 и хотим найти такую поправку Δx, что $x^0 + \Delta x \approx x^*$.

Задача поиска нуля

- Рассмотрим задачу поиска «корня» функции. Формально требуется для непрерывно дифференцируемой функции $\varphi : \mathbb{R} \to \mathbb{R}$ найти точку x^*, для которой верно

$$\varphi(x^*) = 0.$$

- Пусть мы находимся в точке x^0 и хотим найти такую поправку Δx, что $x^0 + \Delta x \approx x^*$.
- Разложим φ по формуле Тейлора до первого порядка:

$$\varphi(x^0 + \Delta x) = \varphi(x^0) + \varphi'(x^0)\Delta x + o(\Delta x).$$

Задача поиска нуля

- Рассмотрим задачу поиска «корня» функции. Формально требуется для непрерывно дифференцируемой функции $\varphi : \mathbb{R} \to \mathbb{R}$ найти точку x^*, для которой верно

$$\varphi(x^*) = 0.$$

- Пусть мы находимся в точке x^0 и хотим найти такую поправку Δx, что $x^0 + \Delta x \approx x^*$.
- Разложим φ по формуле Тейлора до первого порядка:

$$\varphi(x^0 + \Delta x) = \varphi(x^0) + \varphi'(x^0)\Delta x + o(\Delta x).$$

- Поскольку $x^0 + \Delta x \approx x^*$, то:

$$\varphi(x^0 + \Delta x) \approx \varphi(x^*) = 0 \implies \varphi(x^0) + \varphi'(x^0)\Delta x \approx 0.$$

Задача поиска нуля

- Таким образом, $\Delta x \approx -\dfrac{\varphi\left(x^0\right)}{\varphi'\left(x^0\right)}$.

Задача поиска нуля

- Таким образом, $\Delta x \approx -\dfrac{\varphi\left(x^0\right)}{\varphi'\left(x^0\right)}$.
- Продолжая строить новые точки, получаем выражение для итерации метода, предложенного Ньютоном в 17-м веке:

$$x^{k+1} = x^k - \frac{\varphi\left(x^k\right)}{\varphi'\left(x^k\right)}.$$

Локальная сходимость

- **Вопрос:** какие есть вопросы к интуиции получения итерации метода Ньютона?

Локальная сходимость

- **Вопрос:** какие есть вопросы к интуиции получения итерации метода Ньютона? Важно, что x^0 из «хорошей окрестности» x^*.

Локальная сходимость

- **Вопрос:** какие есть вопросы к интуиции получения итерации метода Ньютона? Важно, что x^0 из «хорошей окрестности» x^*.
- Рассмотрим $\varphi(x) = \frac{x}{\sqrt{1+x^2}}$. **Вопрос:** какое решение?

Локальная сходимость

- **Вопрос:** какие есть вопросы к интуиции получения итерации метода Ньютона? Важно, что x^0 из «хорошей окрестности» x^*.
- Рассмотрим $\varphi(x) = \frac{x}{\sqrt{1+x^2}}$. **Вопрос:** какое решение? $x^* = 0$.

Локальная сходимость

- **Вопрос:** какие есть вопросы к интуиции получения итерации метода Ньютона? Важно, что x^0 из «хорошей окрестности» x^*.
- Рассмотрим $\varphi(x) = \frac{x}{\sqrt{1+x^2}}$. **Вопрос:** какое решение? $x^* = 0$.
- Производная: $\varphi'(x) = \frac{1}{\left(1+x^2\right)^{3/2}}$.

Локальная сходимость

- **Вопрос:** какие есть вопросы к интуиции получения итерации метода Ньютона? Важно, что x^0 из «хорошей окрестности» x^*.
- Рассмотрим $\varphi(x) = \frac{x}{\sqrt{1+x^2}}$. **Вопрос:** какое решение? $x^* = 0$.
- Производная: $\varphi'(x) = \frac{1}{\left(1+x^2\right)^{3/2}}$. Итерация метода Ньютона:

$$x^{k+1} = x^k - \frac{\varphi\left(x^k\right)}{\varphi'\left(x^k\right)} = -\left(x^k\right)^3.$$

Локальная сходимость

- **Вопрос:** какие есть вопросы к интуиции получения итерации метода Ньютона? Важно, что x^0 из «хорошей окрестности» x^*.
- Рассмотрим $\varphi(x) = \frac{x}{\sqrt{1+x^2}}$. **Вопрос:** какое решение? $x^* = 0$.
- Производная: $\varphi'(x) = \frac{1}{\left(1+x^2\right)^{3/2}}$. Итерация метода Ньютона:

$$x^{k+1} = x^k - \frac{\varphi\left(x^k\right)}{\varphi'\left(x^k\right)} = -\left(x^k\right)^3.$$

- **Вопрос:** что можем сказать о сходимости к решению?

Локальная сходимость

- **Вопрос:** какие есть вопросы к интуиции получения итерации метода Ньютона? Важно, что x^0 из «хорошей окрестности» x^*.
- Рассмотрим $\varphi(x) = \frac{x}{\sqrt{1+x^2}}$. **Вопрос:** какое решение? $x^* = 0$.
- Производная: $\varphi'(x) = \frac{1}{\left(1+x^2\right)^{3/2}}$. Итерация метода Ньютона:

$$x^{k+1} = x^k - \frac{\varphi\left(x^k\right)}{\varphi'\left(x^k\right)} = -\left(x^k\right)^3.$$

- **Вопрос:** что можем сказать о сходимости к решению?
  - $\left|x^0\right| < 1$ — метод сходится;

Локальная сходимость

- **Вопрос:** какие есть вопросы к интуиции получения итерации метода Ньютона? Важно, что x^0 из «хорошей окрестности» x^*.
- Рассмотрим $\varphi(x) = \frac{x}{\sqrt{1+x^2}}$. **Вопрос:** какое решение? $x^* = 0$.
- Производная: $\varphi'(x) = \frac{1}{\left(1+x^2\right)^{3/2}}$. Итерация метода Ньютона:

$$x^{k+1} = x^k - \frac{\varphi\left(x^k\right)}{\varphi'\left(x^k\right)} = -\left(x^k\right)^3.$$

- **Вопрос:** что можем сказать о сходимости к решению?
  - $\left|x^0\right| < 1$ — метод сходится;
  - $\left|x^0\right| = 1$ — метод колеблется в точках -1 и 1;

Локальная сходимость

- **Вопрос:** какие есть вопросы к интуиции получения итерации метода Ньютона? Важно, что x^0 из «хорошей окрестности» x^*.
- Рассмотрим $\varphi(x) = \frac{x}{\sqrt{1+x^2}}$. **Вопрос:** какое решение? $x^* = 0$.
- Производная: $\varphi'(x) = \frac{1}{\left(1+x^2\right)^{3/2}}$. Итерация метода Ньютона:

$$x^{k+1} = x^k - \frac{\varphi\left(x^k\right)}{\varphi'\left(x^k\right)} = -\left(x^k\right)^3.$$

- **Вопрос:** что можем сказать о сходимости к решению?
  - $\left|x^0\right| < 1$ — метод сходится;
  - $\left|x^0\right| = 1$ — метод колеблется в точках -1 и 1;
  - $\left|x^0\right| > 1$ — метод расходится.

Локальная сходимость

- **Вопрос:** какие есть вопросы к интуиции получения итерации метода Ньютона? Важно, что x^0 из «хорошей окрестности» x^*.
- Рассмотрим $\varphi(x) = \frac{x}{\sqrt{1+x^2}}$. **Вопрос:** какое решение? $x^* = 0$.
- Производная: $\varphi'(x) = \frac{1}{\left(1+x^2\right)^{3/2}}$. Итерация метода Ньютона:

$$x^{k+1} = x^k - \frac{\varphi\left(x^k\right)}{\varphi'\left(x^k\right)} = -\left(x^k\right)^3.$$

- **Вопрос:** что можем сказать о сходимости к решению?
  - $\left|x^0\right| < 1$ — метод сходится;
  - $\left|x^0\right| = 1$ — метод колеблется в точках -1 и 1;
  - $\left|x^0\right| > 1$ — метод расходится.
- Метод Ньютона имеет локальную сходимость (только в окрестности решения).

Метод Ньютона

- Рассмотрим задачу безусловной оптимизации с выпуклой дважды непрерывно дифференцируемой целевой функцией:

$$\min_{x \in \mathbb{R}^d} f\left(x\right).$$

- **Вопрос:** для такой задачи мы тоже ищем 0, но чего?

Метод Ньютона

- Рассмотрим задачу безусловной оптимизации с выпуклой дважды непрерывно дифференцируемой целевой функцией:

$$\min_{x \in \mathbb{R}^d} f\left(x\right).$$

- **Вопрос:** для такой задачи мы тоже ищем 0, но чего? $\nabla f\left(x^*\right) = 0$.

Метод Ньютона

- Рассмотрим задачу безусловной оптимизации с выпуклой дважды непрерывно дифференцируемой целевой функцией:

$$\min_{x \in \mathbb{R}^d} f\left(x\right).$$

- **Вопрос:** для такой задачи мы тоже ищем 0, но чего? $\nabla f\left(x^*\right) = 0$. Откуда метод Ньютона:

Алгоритм Метод Ньютона

Вход: стартовая точка $x^0 \in \mathbb{R}^d$, количество итераций K

1: **for** $k = 0, 1, \ldots, K-1$ **do**

2: $\quad x^{k+1} = x^k - \left(\nabla^2 f\left(x^k\right)\right)^{-1} \nabla f\left(x^k\right)$

3: **end for**

Выход: x^K

Метод Ньютона и градиентный спуск

- Градиентный спуск работает с линейной аппроксимацией в текущей точке, метод Ньютона — с квадратичной:

$$f(x) \approx f(x^k) + \left\langle \nabla f(x^k), x - x^k \right\rangle + \frac{1}{2}\left\langle \nabla^2 f(x^k)(x - x^k), x - x^k \right\rangle.$$

Метод Ньютона и градиентный спуск

- Градиентный спуск работает с линейной аппроксимацией в текущей точке, метод Ньютона — с квадратичной:

$$f(x) \approx f(x^k) + \left\langle \nabla f(x^k), x - x^k \right\rangle + \frac{1}{2}\left\langle \nabla^2 f(x^k)(x - x^k), x - x^k \right\rangle.$$

Построим x^{k+1} как точку, где зануляется градиент квадратичной аппроксимации:

$$\nabla f(x^k) + \nabla^2 f(x^k)(x - x^k) = 0.$$

Метод Ньютона и градиентный спуск

- Градиентный спуск работает с линейной аппроксимацией в текущей точке, метод Ньютона — с квадратичной:

$$f(x) \approx f(x^k) + \left\langle \nabla f(x^k), x - x^k \right\rangle + \frac{1}{2}\left\langle \nabla^2 f(x^k)(x - x^k), x - x^k \right\rangle.$$

Построим x^{k+1} как точку, где зануляется градиент квадратичной аппроксимации:

$$\nabla f(x^k) + \nabla^2 f(x^k)(x - x^k) = 0.$$

Тогда:

$$x^{k+1} = x^k - \left(\nabla^2 f(x^k)\right)^{-1} \nabla f(x^k).$$

Постановка задачи

- Стоимость итерации значительно возрастает (по сравнению с градиентным спуском) не только из-за гессиана, но и его обращения.

Постановка задачи

- Стоимость итерации значительно возрастает (по сравнению с градиентным спуском) не только из-за гессиана, но и его обращения. **Вопрос:** за сколько итераций метод Ньютона сойдется для квадратичной задачи с положительно определенной матрицей?

Постановка задачи

- Стоимость итерации значительно возрастает (по сравнению с градиентным спуском) не только из-за гессиана, но и его обращения. **Вопрос:** за сколько итераций метод Ньютона сойдется для квадратичной задачи с положительно определенной матрицей? За 1 (но дорогую).

Постановка задачи

- Стоимость итерации значительно возрастает (по сравнению с градиентным спуском) не только из-за гессиана, но и его обращения. **Вопрос:** за сколько итераций метод Ньютона сойдется для квадратичной задачи с положительно определенной матрицей? За 1 (но дорогую).
- То, что для квадратичной задачи метод Ньютона сходится за 1 итерацию, наталкивает на мысль о том, что при всех своих минусах (локальная сходимость, дороговизна итерации) ключевым плюсом является скорость сходимости.

Постановка задачи

- Стоимость итерации значительно возрастает (по сравнению с градиентным спуском) не только из-за гессиана, но и его обращения. **Вопрос:** за сколько итераций метод Ньютона сойдется для квадратичной задачи с положительно определенной матрицей? За 1 (но дорогую).
- То, что для квадратичной задачи метод Ньютона сходится за 1 итерацию, наталкивает на мысль о том, что при всех своих минусах (локальная сходимость, дороговизна итерации) ключевым плюсом является скорость сходимости.
- Пусть целевая функция в задаче безусловной минимизации является дважды непрерывно дифференцируемой, μ–сильно выпуклой и имеет M–липшицев гессиан, то есть для любых $x, y \in \mathbb{R}^d$ выполнено

$$\left\|\nabla^2 f(x) - \nabla^2 f(y)\right\|_2 \leq M\left\|x - y\right\|_2.$$

Сходимость

Утверждение

Пусть функция f имеет M–липшицев гессиан. Введем обозначение

$$G_k = \nabla^2 f(x^k) - \int_0^1 \nabla^2 f\Big(x^* + \tau\big(x^k - x^*\big)\Big)\,\mathrm{d}\tau\,.$$

Тогда справедлива оценка:

$$\big\|G_k\big\|_2 \leq \frac{M}{2}\big\|x^k - x^*\big\|_2.$$

Сходимость

$$
\begin{aligned}
\left\| G_k \right\|_2 &= \left\| \nabla^2 f\left(x^k\right) - \int\limits_0^1 \nabla^2 f\left(x^* + \tau\left(x^k - x^*\right)\right) \mathrm{d}\tau \right\|_2 \\
&= \left\| \int\limits_0^1 \left(\nabla^2 f\left(x^k\right) - \nabla^2 f\left(x^* + \tau\left(x^k - x^*\right)\right)\right) \mathrm{d}\tau \right\|_2 \\
&\leq \int\limits_0^1 \left\| \nabla^2 f\left(x^k\right) - \nabla^2 f\left(x^* + \tau\left(x^k - x^*\right)\right) \right\|_2 \mathrm{d}\tau \\
&\leq \int\limits_0^1 M(1-\tau) \left\| x^k - x^* \right\|_2 \mathrm{d}\tau \\
&= M \left\| x^k - x^* \right\|_2 \int\limits_0^1 (1-\tau)\, \mathrm{d}\tau = \frac{M}{2} \left\| x^k - x^* \right\|_2.
\end{aligned}
$$

Сходимость

Будем изучать, как меняется расстояние до решения:

$$x^{k+1} - x^* = x^k - \left(\nabla^2 f\left(x^k\right)\right)^{-1} \nabla f\left(x^k\right) - x^*.$$

Сходимость

Будем изучать, как меняется расстояние до решения:

$$x^{k+1} - x^* = x^k - \left(\nabla^2 f\left(x^k\right)\right)^{-1} \nabla f\left(x^k\right) - x^*.$$

Снова вспомним формулу Ньютона–Лейбница для интеграла вдоль кривой:

$$\nabla f\left(x^k\right) - \nabla f\left(x^*\right) = \int_0^1 \nabla^2 f\Big(x^* + \tau\left(x^k - x^*\right)\Big)\left(x^k - x^*\right) \mathrm{d}\tau\,.$$

Сходимость

Будем изучать, как меняется расстояние до решения:

$$x^{k+1} - x^* = x^k - \left(\nabla^2 f\left(x^k\right)\right)^{-1} \nabla f\left(x^k\right) - x^*.$$

Снова вспомним формулу Ньютона–Лейбница для интеграла вдоль кривой:

$$\nabla f\left(x^k\right) - \nabla f\left(x^*\right) = \int_0^1 \nabla^2 f\left(x^* + \tau\left(x^k - x^*\right)\right)\left(x^k - x^*\right) \mathrm{d}\tau\,.$$

Зная, что $\nabla f\left(x^*\right) = 0$, получим:

$$x^{k+1} - x^* = x^k - x^* - \left(\nabla^2 f\left(x^k\right)\right)^{-1} \int_0^1 \nabla^2 f\left(x^* + \tau\left(x^k - x^*\right)\right)\left(x^k - x^*\right) \mathrm{d}\tau\,.$$

Сходимость

Используем «умную единицу»:

$$x^{k+1} - x^* = x^k - x^* - \left(\nabla^2 f(x^k)\right)^{-1} \int_0^1 \nabla^2 f\left(x^* + \tau(x^k - x^*)\right)(x^k - x^*)\,\mathrm{d}\tau$$

$$= \left(\nabla^2 f(x^k)\right)^{-1} \nabla^2 f(x^k)(x^k - x^*)$$

$$- \left(\nabla^2 f(x^k)\right)^{-1} \int_0^1 \nabla^2 f\left(x^* + \tau(x^k - x^*)\right)(x^k - x^*)\,\mathrm{d}\tau\,.$$

Сходимость

Используем «умную единицу»:

$$x^{k+1} - x^* = x^k - x^* - \left(\nabla^2 f(x^k)\right)^{-1} \int_0^1 \nabla^2 f\left(x^* + \tau(x^k - x^*)\right)(x^k - x^*)\,\mathrm{d}\tau$$

$$= \left(\nabla^2 f(x^k)\right)^{-1} \nabla^2 f(x^k)(x^k - x^*)$$

$$- \left(\nabla^2 f(x^k)\right)^{-1} \int_0^1 \nabla^2 f\left(x^* + \tau(x^k - x^*)\right)(x^k - x^*)\,\mathrm{d}\tau\,.$$

Заметим, что $x^k - x^*$ можно вынести за пределы интеграла:

$$x^{k+1} - x^* = \left(\nabla^2 f(x^k)\right)^{-1} \left(\nabla^2 f(x^k) - \int_0^1 \nabla^2 f\left(x^* + \tau(x^k - x^*)\right)\mathrm{d}\tau\right)(x^k - x^*)$$

$$= \left(\nabla^2 f(x^k)\right)^{-1} G_k(x^k - x^*).$$

Сходимость

Спектральная норма матрицы согласована с евклидовой нормой вектора. Таким образом:

$$\left\|x^{k+1} - x^*\right\|_2 \leq \left\|\left(\nabla^2 f\left(x^k\right)\right)^{-1}\right\|_2 \left\|G_k\right\|_2 \left\|x^k - x^*\right\|_2.$$

Сходимость

Спектральная норма матрицы согласована с евклидовой нормой вектора. Таким образом:

$$\left\|x^{k+1} - x^*\right\|_2 \leq \left\|\left(\nabla^2 f\left(x^k\right)\right)^{-1}\right\|_2 \left\|G_k\right\|_2 \left\|x^k - x^*\right\|_2.$$

Вопрос: как оценить $\left\|\left(\nabla^2 f\left(x^k\right)\right)^{-1}\right\|_2$?

Сходимость

Спектральная норма матрицы согласована с евклидовой нормой вектора. Таким образом:

$$\left\|x^{k+1} - x^*\right\|_2 \leq \left\|\left(\nabla^2 f\left(x^k\right)\right)^{-1}\right\|_2 \left\|G_k\right\|_2 \left\|x^k - x^*\right\|_2.$$

Вопрос: как оценить $\left\|\left(\nabla^2 f\left(x^k\right)\right)^{-1}\right\|_2$? Оценим как $\left\|\left(\nabla^2 f\left(x^k\right)\right)^{-1}\right\|_2 = \frac{1}{\lambda_{\min}(\nabla^2 f\left(x^k\right))} \leq \frac{1}{\mu}$.

Сходимость

Спектральная норма матрицы согласована с евклидовой нормой вектора. Таким образом:

$$\left\|x^{k+1} - x^*\right\|_2 \leq \left\|\left(\nabla^2 f\left(x^k\right)\right)^{-1}\right\|_2 \left\|G_k\right\|_2 \left\|x^k - x^*\right\|_2.$$

Вопрос: как оценить $\left\|\left(\nabla^2 f\left(x^k\right)\right)^{-1}\right\|_2$? Оценим как $\left\|\left(\nabla^2 f\left(x^k\right)\right)^{-1}\right\|_2 = \frac{1}{\lambda_{\min}(\nabla^2 f\left(x^k\right))} \leq \frac{1}{\mu}$. Тогда применяя результат Утверждения, получаем:

$$\left\|x^{k+1} - x^*\right\|_2 \leq \frac{M}{2\mu}\left\|x^k - x^*\right\|_2^2.$$

Сходимость

Теорема

Пусть задача безусловной оптимизации с M–липшицевым гессианом, μ–сильно выпуклой целевой функцией f, решается с помощью метода Ньютона. Тогда справедлива следующая оценка сходимости:

$$\left\|x^{k+1} - x^*\right\|_2 \leq \frac{M}{2\mu}\left\|x^k - x^*\right\|_2^2.$$

Сходимость

Теорема

Пусть задача безусловной оптимизации с M–липшицевым гессианом, μ–сильно выпуклой целевой функцией f, решается с помощью метода Ньютона. Тогда справедлива следующая оценка сходимости:

$$\left\|x^{k+1} - x^*\right\|_2 \leq \frac{M}{2\mu}\left\|x^k - x^*\right\|_2^2.$$

Мы уже знаем, что такого рода оценки дают квадратичную скорость сходимости.

Сходимость

- Сходимость, как и в случае исходного метода Ньютона, является локальной.

Сходимость

- Сходимость, как и в случае исходного метода Ньютона, является локальной. А именно, чтобы гарантировать $\left\|x^1 - x^*\right\|_2 < \left\|x^0 - x^*\right\|_2$, нужно предположить, что

$$\left\|x^0 - x^*\right\|_2 < \frac{2\mu}{M}.$$

Сходимость

- Сходимость, как и в случае исходного метода Ньютона, является локальной. А именно, чтобы гарантировать $\left\|x^1 - x^*\right\|_2 < \left\|x^0 - x^*\right\|_2$, нужно предположить, что

$$\left\|x^0 - x^*\right\|_2 < \frac{2\mu}{M}.$$

- Поймем насколько быстро сходится метод. Пусть $M = 2$, $\mu = 1$, а $\left\|x^0 - x^*\right\|_2 = \frac{1}{2}$.

Сходимость

- Сходимость, как и в случае исходного метода Ньютона, является локальной. А именно, чтобы гарантировать $\left\|x^1 - x^*\right\|_2 < \left\|x^0 - x^*\right\|_2$, нужно предположить, что

$$\left\|x^0 - x^*\right\|_2 < \frac{2\mu}{M}.$$

- Поймем насколько быстро сходится метод. Пусть $M = 2$, $\mu = 1$, а $\left\|x^0 - x^*\right\|_2 = \frac{1}{2}$. Тогда мы можем гарантировать, что $\left\|x^1 - x^*\right\|_2 \leq \frac{1}{2^2}$, $\left\|x^2 - x^*\right\|_2 \leq \frac{1}{\left(2^2\right)^2}$ и так далее.

Модификации

- Пытаемся решить проблему локальной сходимости. Действуем по аналогии с градиентным спуском. **Вопрос:** идеи?

Модификации

- Пытаемся решить проблему локальной сходимости. Действуем по аналогии с градиентным спуском. **Вопрос:** идеи?
- Идея первая — шаг:

$$x^{k+1} = x^k - \gamma_k \left(\nabla^2 f\left(x^k\right) \right)^{-1} \nabla f\left(x^k\right).$$

Такой метод называется **демпфированным** методом Ньютона.
Вопрос: как выбирать шаг?

Модификации

- Пытаемся решить проблему локальной сходимости. Действуем по аналогии с градиентным спуском. **Вопрос:** идеи?
- Идея первая — шаг:

$$x^{k+1} = x^k - \gamma_k \left(\nabla^2 f\left(x^k\right)\right)^{-1} \nabla f\left(x^k\right).$$

Такой метод называется **демпфированным** методом Ньютона. **Вопрос:** как выбирать шаг? Много разных способов, например, линейный поиск:

$$\operatorname*{argmin}_{\gamma} f\left(x^k + \gamma p_k\right), \quad \text{где } p_k = -\left(\nabla^2 f\left(x^k\right)\right)^{-1} \nabla f\left(x^k\right).$$

Модификации

- Идея вторая — «оценки сверху». В основе анализа градиентного спуска лежала оптимизация «оценки сверху» на функцию:

$$x^{k+1} = \operatorname*{argmin}_{x \in \mathbb{R}^d} \left(f\left(x^k\right) + \left\langle \nabla f\left(x^k\right), x - x^k \right\rangle + \frac{L}{2}\left\|x - x^k\right\|_2^2 \right).$$

Модификации

- Идея вторая — «оценки сверху». В основе анализа градиентного спуска лежала оптимизация «оценки сверху» на функцию:

$$x^{k+1} = \operatorname*{argmin}_{x \in \mathbb{R}^d} \left(f\left(x^k\right) + \left\langle \nabla f\left(x^k\right), x - x^k \right\rangle + \frac{L}{2}\left\|x - x^k\right\|_2^2 \right).$$

Вопрос: чему равно x^{k+1}?

Модификации

- Идея вторая — «оценки сверху». В основе анализа градиентного спуска лежала оптимизация «оценки сверху» на функцию:

$$x^{k+1} = \operatorname*{argmin}_{x \in \mathbb{R}^d} \left(f\left(x^k\right) + \left\langle \nabla f\left(x^k\right), x - x^k \right\rangle + \frac{L}{2}\left\|x - x^k\right\|_2^2 \right).$$

Вопрос: чему равно x^{k+1}? $x^{k+1} = x^k - \frac{1}{L}\nabla f\left(x^k\right)$.

Модификации

- Идея вторая — «оценки сверху». В основе анализа градиентного спуска лежала оптимизация «оценки сверху» на функцию:

$$x^{k+1} = \operatorname*{argmin}_{x \in \mathbb{R}^d} \left(f\left(x^k\right) + \left\langle \nabla f\left(x^k\right), x - x^k \right\rangle + \frac{L}{2}\left\|x - x^k\right\|_2^2 \right).$$

Вопрос: чему равно x^{k+1}? $x^{k+1} = x^k - \frac{1}{L}\nabla f\left(x^k\right)$. Запишем похожее для аппроксимации 2-го порядка:

$$x^{k+1} = \operatorname*{argmin}_{y \in \mathbb{R}^d} \left(f\left(x^k\right) + \left\langle \nabla f\left(x^k\right), y - x^k \right\rangle + \frac{1}{2}\left\langle \nabla^2 f\left(x^k\right)\left(y - x^k\right), y - x^k \right\rangle + \frac{M}{6}\left\|y - x^k\right\|_2^3 \right).$$

Такой метод называется **кубическим** методом Ньютона.

Квазиньютоновское уравнение

- Запишем метод Ньютона следующим образом:

$$x^{k+1} = x^k - \gamma_k H_k \nabla f\left(x^k\right)$$

Квазиньютоновское уравнение

- Запишем метод Ньютона следующим образом:

$$x^{k+1} = x^k - \gamma_k H_k \nabla f\left(x^k\right)$$

  В случае метода Ньютона вместо H_k стоит $\left(\nabla^2 f\left(x^k\right)\right)^{-1}$.
- Хочется заменить $\left(\nabla^2 f\left(x^k\right)\right)^{-1}$ на что-то более дешевое с точки зрения вычислений.

Квазиньютоновское уравнение

- Запишем метод Ньютона следующим образом:

$$x^{k+1} = x^k - \gamma_k H_k \nabla f\left(x^k\right)$$

  В случае метода Ньютона вместо H_k стоит $\left(\nabla^2 f\left(x^k\right)\right)^{-1}$.
- Хочется заменить $\left(\nabla^2 f\left(x^k\right)\right)^{-1}$ на что-то более дешевое с точки зрения вычислений.
- Идея — выудить какие-то свойства, присущие гессиану.

Квазиньютоновское уравнение

- Запишем метод Ньютона следующим образом:

$$x^{k+1} = x^k - \gamma_k H_k \nabla f\left(x^k\right)$$

  В случае метода Ньютона вместо H_k стоит $\left(\nabla^2 f\left(x^k\right)\right)^{-1}$.
- Хочется заменить $\left(\nabla^2 f\left(x^k\right)\right)^{-1}$ на что-то более дешевое с точки зрения вычислений.
- Идея — выудить какие-то свойства, присущие гессиану.
- Связь градиента и гессиана:

$$\nabla f\left(x^{k+1}\right) - \nabla f\left(x^k\right) \approx \nabla^2 f\left(x^{k+1}\right)\left(x^{k+1} - x^k\right).$$

Квазиньютоновское уравнение

- Запишем метод Ньютона следующим образом:

$$x^{k+1} = x^k - \gamma_k H_k \nabla f\left(x^k\right)$$

  В случае метода Ньютона вместо H_k стоит $\left(\nabla^2 f\left(x^k\right)\right)^{-1}$.
- Хочется заменить $\left(\nabla^2 f\left(x^k\right)\right)^{-1}$ на что-то более дешевое с точки зрения вычислений.
- Идея — выудить какие-то свойства, присущие гессиану.
- Связь градиента и гессиана:

$$\nabla f\left(x^{k+1}\right) - \nabla f\left(x^k\right) \approx \nabla^2 f\left(x^{k+1}\right)\left(x^{k+1} - x^k\right).$$

  Введём обозначения

$$s^k = x^{k+1} - x^k, \quad y^k = \nabla f\left(x^{k+1}\right) - \nabla f\left(x^k\right)$$

  и положим

$$B_{k+1} \approx \nabla^2 f\left(x^{k+1}\right), \quad H_{k+1} \approx \left(\nabla^2 f\left(x^{k+1}\right)\right)^{-1}.$$

Квазиньютоновское уравнение

- Квазиньютоновское уравнение:

$$y^k = B_{k+1}s^k \iff s^k = H_{k+1}y^k.$$

Квазиньютоновское уравнение

- Квазиньютоновское уравнение:

$$y^k = B_{k+1}s^k \iff s^k = H_{k+1}y^k.$$

- Ещё потребуем, чтобы H_{k+1} была симметричной: $H_{k+1}^\top = H_{k+1}$.

Квазиньютоновское уравнение

- Квазиньютоновское уравнение:

$$y^k = B_{k+1}s^k \iff s^k = H_{k+1}y^k.$$

- Ещё потребуем, чтобы H_{k+1} была симметричной: $H_{k+1}^\top = H_{k+1}$.
- **Вопрос:** сколько решений имеет система уравнений $s^k = H_{k+1}y^k$ относительно H_{k+1} при условии, что $H_{k+1}^\top = H_{k+1}$?

Квазиньютоновское уравнение

- Квазиньютоновское уравнение:

$$y^k = B_{k+1}s^k \iff s^k = H_{k+1}y^k.$$

- Ещё потребуем, чтобы H_{k+1} была симметричной: $H_{k+1}^\top = H_{k+1}$.
- **Вопрос:** сколько решений имеет система уравнений $s^k = H_{k+1}y^k$ относительно H_{k+1} при условии, что $H_{k+1}^\top = H_{k+1}$?
  $\frac{d(d-1)}{2} + d = \frac{d(d+1)}{2}$ уравнений. Поскольку общее число элементов матрицы равно d^2, остаётся $\frac{d(d-1)}{2}$ свободных параметров. Это означает, что множество допустимых приближений очень велико и существует широкий спектр стратегий построения H_{k+1} или B_{k+1}.

SR1 (Symmetric Rank 1)

- Идея первая — одноранговая добавка:

$$H_{k+1} = H_k + \mu_k q^k \left(q^k\right)^\top,$$

где $\mu_k \in \mathbb{R}$ и $q^k \in \mathbb{R}^d$ нужно подобрать.

SR1 (Symmetric Rank 1)

- Идея первая — одноранговая добавка:

$$H_{k+1} = H_k + \mu_k q^k \left(q^k\right)^\top,$$

где $\mu_k \in \mathbb{R}$ и $q^k \in \mathbb{R}^d$ нужно подобрать.

- Подбираем исходя из квазиньютоновского уравнения:

$$s^k = H_{k+1} y^k = \left(H_k + \mu_k q^k \left(q^k\right)^\top\right) y^k = H_k y^k + \mu_k \left(\left(q^k\right)^\top y^k\right) q^k.$$

SR1 (Symmetric Rank 1)

- Идея первая — одноранговая добавка:

$$H_{k+1} = H_k + \mu_k q^k \left(q^k\right)^\top,$$

где $\mu_k \in \mathbb{R}$ и $q^k \in \mathbb{R}^d$ нужно подобрать.

- Подбираем исходя из квазиньютоновского уравнения:

$$s^k = H_{k+1} y^k = \left(H_k + \mu_k q^k \left(q^k\right)^\top\right) y^k = H_k y^k + \mu_k \left(\left(q^k\right)^\top y^k\right) q^k.$$

Откуда

$$\mu_k \left(\left(q^k\right)^\top y^k\right) q^k = s^k - H_k y^k.$$

SR1 (Symmetric Rank 1)

- С предыдущего слайда:

$$\mu_k \left(\left(q^k \right)^\top y^k \right) q^k = s^k - H_k y^k.$$

- **Вопрос:** что можно сказать про вектор q^k?

SR1 (Symmetric Rank 1)

- С предыдущего слайда:

$$\mu_k \left(\left(q^k \right)^\top y^k \right) q^k = s^k - H_k y^k.$$

- **Вопрос:** что можно сказать про вектор q^k? Коллинеарен $s^k - H_k y^k$.

SR1 (Symmetric Rank 1)

- С предыдущего слайда:

$$\mu_k \left(\left(q^k \right)^\top y^k \right) q^k = s^k - H_k y^k.$$

- **Вопрос:** что можно сказать про вектор q^k? Коллинеарен $s^k - H_k y^k$. Пусть

$$q^k = s^k - H_k y^k,$$

тогда

$$\mu_k = \frac{1}{(q^k)^\top y^k}.$$

SR1 (Symmetric Rank 1)

- С предыдущего слайда:

$$\mu_k \left(\left(q^k \right)^\top y^k \right) q^k = s^k - H_k y^k.$$

- **Вопрос:** что можно сказать про вектор q^k? Коллинеарен $s^k - H_k y^k$. Пусть

$$q^k = s^k - H_k y^k,$$

тогда

$$\mu_k = \frac{1}{(q^k)^\top y^k}.$$

- Получаем SR1 способ подсчета матриц H:

$$H_{k+1} = H_k + \frac{\left(s^k - H_k y^k\right)\left(s^k - H_k y^k\right)^\top}{\left(s^k - H_k y^k\right)^\top y^k}.$$

Broyden

- Подойдем к задаче иначе. Запишем квазиньютоновское уравнение для матрицы B:

$$y^k = B_{k+1} s^k.$$

Broyden

- Подойдем к задаче иначе. Запишем квазиньютоновское уравнение для матрицы B:

$$y^k = B_{k+1}s^k.$$

- Потребуем минимальность фробениусовой нормы поправки при ограничении в виде квазиньютоновского уравнения:

$$B_{k+1} = \underset{B \in \mathbb{R}^{d\times d}}{\operatorname{argmin}} \left\| B - B_k \right\|_F^2$$
$$\text{s.t.} \quad Bs^k = y^k.$$

Broyden

- Подойдем к задаче иначе. Запишем квазиньютоновское уравнение для матрицы B:

$$y^k = B_{k+1}s^k.$$

- Потребуем минимальность фробениусовой нормы поправки при ограничении в виде квазиньютоновского уравнения:

$$B_{k+1} = \underset{B\in\mathbb{R}^{d\times d}}{\operatorname{argmin}} \left\|B - B_k\right\|_F^2$$
$$\text{s.t.} \quad Bs^k = y^k.$$

- Получаем:

$$B_{k+1} = B_k + \frac{\left(y^k - B_k s^k\right)\left(s^k\right)^\top}{\left(s^k\right)^\top s^k}.$$

DFP (Davidon–Fletcher–Powell)

- Добавим требование на симметричность матрицы и заменим обычную норму Фробениуса на взвешенную:

$$\|A\|_W = \|W^{1/2} A W^{1/2}\|_F,$$

где W — матрица, для которой выполняется $Wy^k = s^k$.

DFP (Davidon–Fletcher–Powell)

- Добавим требование на симметричность матрицы и заменим обычную норму Фробениуса на взвешенную:

$$\|A\|_W = \|W^{1/2} A W^{1/2}\|_F,$$

где W — матрица, для которой выполняется $Wy^k = s^k$.

- Задача оптимизации для поиска B_{k+1}:

$$\begin{aligned} B_{k+1} = \underset{B \in \mathbb{R}^{d \times d}}{\operatorname{argmin}} & \|B - B_k\|_W^2 \\ \text{s.t.} \quad & Bs^k = y^k, \\ & B^\top = B. \end{aligned}$$

DFP (Davidon–Fletcher–Powell)

- Добавим требование на симметричность матрицы и заменим обычную норму Фробениуса на взвешенную:

$$\|A\|_W = \|W^{1/2} A W^{1/2}\|_F,$$

где W — матрица, для которой выполняется $Wy^k = s^k$.

- Задача оптимизации для поиска B_{k+1}:

$$\begin{aligned} B_{k+1} = \underset{B \in \mathbb{R}^{d \times d}}{\operatorname{argmin}} & \|B - B_k\|_W^2 \\ \text{s.t.} \quad & Bs^k = y^k, \\ & B^\top = B. \end{aligned}$$

- Получаем:

$$B_{k+1} = \left(I_d - \frac{y^k \left(s^k\right)^\top}{\left(y^k\right)^\top s^k}\right) B_k \left(I_d - \frac{s^k \left(y^k\right)^\top}{\left(y^k\right)^\top s^k}\right) + \frac{y^k \left(y^k\right)^\top}{\left(y^k\right)^\top s^k}.$$

BFGS (Broyden–Fletcher–Goldfarb–Shanno)

- Поступим так же, как и в DFP, только будем решать задачу сразу для H (теперь весовая матрица W удовлетворяет $Ws^k = y^k$):

$$H_{k+1} = \underset{H \in \mathbb{R}^{d \times d}}{\operatorname{argmin}} \left\| H - H_k \right\|_W^2$$
$$\text{s.t.} \quad s^k = Hy^k,$$
$$H^\top = H.$$

BFGS (Broyden–Fletcher–Goldfarb–Shanno)

- Поступим так же, как и в DFP, только будем решать задачу сразу для H (теперь весовая матрица W удовлетворяет $Ws^k = y^k$):

$$\begin{aligned} H_{k+1} = \underset{H \in \mathbb{R}^{d \times d}}{\operatorname{argmin}} & \left\| H - H_k \right\|_W^2 \\ \text{s.t.} \quad & s^k = Hy^k, \\ & H^\top = H. \end{aligned}$$

- Получаем:

$$H_{k+1} = \left(I_d - \frac{s^k \left(y^k\right)^\top}{\left(y^k\right)^\top s^k} \right) H_k \left(I_d - \frac{y^k \left(s^k\right)^\top}{\left(y^k\right)^\top s^k} \right) + \frac{s^k \left(s^k\right)^\top}{\left(y^k\right)^\top s^k}.$$

BFGS (Broyden–Fletcher–Goldfarb–Shanno)

- **Вопрос:** чтобы посчитать новую матрицу нужно $\mathcal{O}(d^2)$ операций. Кажется, что в BFGS подсчет дороже (есть перемножение трех матриц). Так ли это?

$$H_{k+1} = \left(I_d - \frac{s^k \left(y^k\right)^\top}{\left(y^k\right)^\top s^k}\right) H_k \left(I_d - \frac{y^k \left(s^k\right)^\top}{\left(y^k\right)^\top s^k}\right) + \frac{s^k \left(s^k\right)^\top}{\left(y^k\right)^\top s^k}.$$

BFGS (Broyden–Fletcher–Goldfarb–Shanno)

- **Вопрос:** чтобы посчитать новую матрицу нужно $\mathcal{O}(d^2)$ операций. Кажется, что в BFGS подсчет дороже (есть перемножение трех матриц). Так ли это?

$$H_{k+1} = \left(I_d - \frac{s^k \left(y^k\right)^\top}{\left(y^k\right)^\top s^k}\right) H_k \left(I_d - \frac{y^k \left(s^k\right)^\top}{\left(y^k\right)^\top s^k}\right) + \frac{s^k \left(s^k\right)^\top}{\left(y^k\right)^\top s^k}.$$

- Нужно раскрыть скобки в матричном умножении. В подсчете $s^k \left(y^k\right)^\top H_k$ нужно сначала умножить $\left(y^k\right)^\top H_k$, а потом вектор на вектор. Аналогично для $H_k y^k \left(s^k\right)^\top$. Получается, что сложность BFGS есть $\mathcal{O}(d^2)$ операций (не учитывая подсчет градиентов).

BFGS (Broyden–Fletcher–Goldfarb–Shanno)

- **Вопрос:** чтобы посчитать новую матрицу нужно $\mathcal{O}(d^2)$ операций. Кажется, что в BFGS подсчет дороже (есть перемножение трех матриц). Так ли это?

$$H_{k+1} = \left(I_d - \frac{s^k \left(y^k\right)^\top}{\left(y^k\right)^\top s^k}\right) H_k \left(I_d - \frac{y^k \left(s^k\right)^\top}{\left(y^k\right)^\top s^k}\right) + \frac{s^k \left(s^k\right)^\top}{\left(y^k\right)^\top s^k}.$$

- Нужно раскрыть скобки в матричном умножении. В подсчете $s^k \left(y^k\right)^\top H_k$ нужно сначала умножить $\left(y^k\right)^\top H_k$, а потом вектор на вектор. Аналогично для $H_k y^k \left(s^k\right)^\top$. Получается, что сложность BFGS есть $\mathcal{O}(d^2)$ операций (не учитывая подсчет градиентов).
- При инициализации матрицу H_0 достаточно брать равной единичной. Есть и более хитрые способы, но особо разницы нет.

Переход от B_{k+1} к H_{k+1}

Чтобы не обращать матрицу B_{k+1} и не решать системы линейных уравнений, можем получить явную формулу для $H_{k+1} = B_{k+1}^{-1}$, используя формулу Шермана–Моррисона–Вудбери.

Утверждение

Пусть $A \in \mathbb{R}^{d \times d}$ — обратимая матрица, а $U, V \in \mathbb{R}^{d \times n}$. Тогда, если также обратима матрица $I_n + V^\top A^{-1} U$, то верна формула:

$$\left(A + UV^\top\right)^{-1} = A^{-1} - A^{-1}U\left(I_n + V^\top A^{-1} U\right)^{-1} V^\top A^{-1}.$$

Сравнительная таблица

Метод	B^{new}	$H^{\text{new}} = \left(B^{\text{new}}\right)^{-1}$
SR1	$B + \frac{(y-Bs)(y-Bs)^\top}{(y-Bs)^\top s}$	$H + \frac{(s-Hy)(s-Hy)^\top}{(s-Hy)^\top y}$
Broyden	$B + \frac{y-Bs}{s^\top s}s^\top$	$H + \frac{(s-Hy)s^\top H}{s^\top Hy}$
DFP	$\left(I_d - \frac{ys^\top}{y^\top s}\right)B\left(I_d - \frac{sy^\top}{y^\top s}\right) + \frac{yy^\top}{y^\top s}$	$H + \frac{ss^\top}{s^\top y} - \frac{Hyy^\top H}{y^\top Hy}$
BFGS	$B + \frac{yy^\top}{y^\top s} - \frac{Bss^\top B}{s^\top Bs}$	$\left(I_d - \frac{sy^\top}{y^\top s}\right)H\left(I_d - \frac{ys^\top}{y^\top s}\right) + \frac{ss^\top}{y^\top s}$

Метод Ньютона и квазиньютоновские методы

- Квазиньютоновские методы не требуют подсчёта гессиана и его обращения. Сложность всех арифметических операций на одной итерации $\mathcal{O}\left(d^2\right)$, что дешевле обращения гессиана за $\mathcal{O}\left(d^3\right)$.

Метод Ньютона и квазиньютоновские методы

- Квазиньютоновские методы не требуют подсчёта гессиана и его обращения. Сложность всех арифметических операций на одной итерации $\mathcal{O}(d^2)$, что дешевле обращения гессиана за $\mathcal{O}(d^3)$.
- Квазиньютоновские методы имеют глобальную сверхлинейную скорость сходимости. Это медленнее, чем метод Ньютона, но не нужна «хорошая» окрестность решения.

Метод Ньютона и квазиньютоновские методы

- Квазиньютоновские методы не требуют подсчёта гессиана и его обращения. Сложность всех арифметических операций на одной итерации $\mathcal{O}(d^2)$, что дешевле обращения гессиана за $\mathcal{O}(d^3)$.
- Квазиньютоновские методы имеют глобальную сверхлинейную скорость сходимости. Это медленнее, чем метод Ньютона, но не нужна «хорошая» окрестность решения.
- Квазиньютоновские методы используют только градиент, но в теории сходятся быстрее ускоренного градиентного метода. **Вопрос:** почему так, ведь метод Нестерова оптимальный?

Метод Ньютона и квазиньютоновские методы

- Квазиньютоновские методы не требуют подсчёта гессиана и его обращения. Сложность всех арифметических операций на одной итерации $\mathcal{O}(d^2)$, что дешевле обращения гессиана за $\mathcal{O}(d^3)$.
- Квазиньютоновские методы имеют глобальную сверхлинейную скорость сходимости. Это медленнее, чем метод Ньютона, но не нужна «хорошая» окрестность решения.
- Квазиньютоновские методы используют только градиент, но в теории сходятся быстрее ускоренного градиентного метода. **Вопрос:** почему так, ведь метод Нестерова оптимальный? В определении класса методов, для которого метод Нестерова оптимален, не разрешены скалярные произведения градиентов.

Метод Ньютона и квазиньютоновские методы

- Квазиньютоновские методы не требуют подсчёта гессиана и его обращения. Сложность всех арифметических операций на одной итерации $\mathcal{O}(d^2)$, что дешевле обращения гессиана за $\mathcal{O}(d^3)$.
- Квазиньютоновские методы имеют глобальную сверхлинейную скорость сходимости. Это медленнее, чем метод Ньютона, но не нужна «хорошая» окрестность решения.
- Квазиньютоновские методы используют только градиент, но в теории сходятся быстрее ускоренного градиентного метода. **Вопрос:** почему так, ведь метод Нестерова оптимальный? В определении класса методов, для которого метод Нестерова оптимален, не разрешены скалярные произведения градиентов.
- Метод Ньютона и квазиньютоновские методы на практике быстро находят точный локальный минимум. Их спокойно можно использовать в качестве «дорешивателей». Квазиньютоновские методы и как «стартовый» метод.