Л1 Негладкая оптимизация. Адаптивные методы

До сих пор мы рассматривали только безусловные гладкие выпуклые задачи оптимизации, то есть задачи поиска минимума выпуклой функции с липшицевым градиентом на $\mathbb{R}^d$. Оказывается, что это достаточно сильные требования на целевую функцию, следующий пример это показывает.

Пример Л1.1. Рассмотрим функцию $f : \mathbb{R} \to \mathbb{R}$ следующего вида:

$$f(x) = |x|.$$

Эта функция достаточно простая и часто встречается, например, в виде ℓ_1–регуляризатора. При этом из-за отсутствия дифференцируемости в нуле она не является гладкой. Более того, наше определение выпуклости (Определение **??**) работает только для дифференцируемых функций, то есть не применимо для модуля.

Это подталкивает нас к развитию теории для негладких задач.

Л1.1 Негладкие задачи

Хотелось бы ослабить требования на функции, в частности перестать требовать дифференцируемость целевой функции. В Параграфе **??** было введено определение выпуклости для дифференцируемой функции (Определение **??**). Теперь обобщим его, не требуя дифференцируемости.

Определение Л1.1. Рассмотрим функцию $f : \mathbb{R}^d \to \mathbb{R}$. Функция f называется *выпуклой*, если для любых $x_1, \ldots, x_k \in \mathbb{R}^d$ и любых $\alpha_1, \ldots, \alpha_k$, $\alpha_i \geq 0$, $\sum\limits_{i=1}^{k} \alpha_i = 1$ выполняется

$$f\left(\sum_{i=1}^{k} \alpha_i x_i\right) \leq \sum_{i=1}^{k} \alpha_i f(x_i).$$

Замечание Л1.1. В Параграфе **??** более подробно изучаются различные определения выпуклых функций. В частности, в случае дифференцируемой функции показывается, что Определения **??** и Л1.1 эквивалентны (Теорема **??**).

Требование на дифференцируемость функции осталось только в гладкости. Заменим условие L–липшицевости градиента на M–липшицевость самой функции.

Определение Л1.2. Пусть дана функция $f : \mathbb{R}^d \to \mathbb{R}$. Будем говорить, что она является *M–липшицевой*, если для любых $x, y \in \mathbb{R}^d$ выполнено:

$$|f(x) - f(y)| \leq M\|x - y\|_2.$$

Мы отказались от дифференцируемости целевой функции. Однако можно ввести новую сущность, которая будет обладать некоторыми такими же полезными свойствами, что и градиент для дифференцируемых выпуклых функций.

Определение Л1.3. Пусть дана выпуклая функция $f : \mathbb{R}^d \to \mathbb{R}$. Вектор $g \in \mathbb{R}^d$ будем называть *субградиентом* функции f в точке $x \in \mathbb{R}^d$, если для любого $y \in \mathbb{R}^d$ выполнено

$$f(y) \geq f(x) + \langle g, y - x \rangle.$$

Множество $\partial f(x)$ всех субградиентов f в точке x называется *субдифференциалом*.

Сформулируем критерий минимума выпуклой функции по аналогии с тем, как было для дифференцируемых функций (Теорема **??** и Теорема **??**).

Теорема Л1.1. Точка x^* — минимум выпуклой функции f тогда и только тогда, когда

$$0 \in \partial f(x^*).$$

Доказательство. $\Rightarrow$ Если $f(x) \geq f(x^*)$ для любых $x \in \mathbb{R}^d$, то для вектора 0 выполнено

$$f(x) \geq f(x^*) + \langle 0, x - x^* \rangle$$

для любого $x \in \mathbb{R}^d$. Следовательно,

$$0 \in \partial f(x^*).$$

Доказано по определению субградиента.
$\Leftarrow$ Пусть $0 \in \partial f(x^*)$. Тогда по определению субградиента (Определение Л1.3):

$$f(x) \geq f(x^*) + \langle 0, x - x^* \rangle = f(x^*)$$

для любого $x \in \mathbb{R}^d$. Доказано по определению минимума на множестве (Определение **??**).

■

Теорема Л1.2. Пусть дана выпуклая функция $f : \mathbb{R}^d \to \mathbb{R}$. Тогда функция f является M–липшицевой тогда и только тогда, когда для любого $x \in \mathbb{R}^d$ и $g \in \partial f(x)$ имеем $\|g\|_2 \leq M$.

Доказательство. $\Rightarrow$ Рассмотрим $g \in \partial f(x)$, тогда по определению субградиента (Определение Л1.3) для любого $y \in \mathbb{R}^d$:

$$f(y) - f(x) \geq \langle g, y - x \rangle.$$

Из M–липшицевости f (Определение Л1.2):

$$M\|y - x\|_2 \geq f(y) - f(x) \geq \langle g, y - x \rangle.$$

Возьмем $y = g + x \in \mathbb{R}^d$, тогда

$$M\|g\|_2 = M\|y - x\|_2 \geq \langle g, y - x \rangle = \|g\|_2^2.$$

Откуда и получаем:

$$\|g\|_2 \leq M.$$

$\Leftarrow$ Рассмотрим $g \in \partial f(x)$, тогда по определению субградиента (Определение Л1.3) для любого $y \in \mathbb{R}^d$:

$$f(x) - f(y) \leq \langle g, x - y \rangle.$$

Используем неравенство Коши–Буняковского–Шварца (**??**):

$$f(x) - f(y) \leq \|g\|_2 \|x - y\|_2.$$

Воспользуемся предположением об ограниченности нормы субградиента и получим:

$$f(x) - f(y) \leq M\|x - y\|_2.$$

Если переобозначить $x \to y$, $y \to x$, то можем записать:

$$f(y) - f(x) \leq M\|y - x\|_2.$$

Если объединить оба неравенства, то можем прийти к более краткой записи:

$$|f(y) - f(x)| \leq M\|x - y\|_2.$$

Это и есть свойство M–липшицевости f.

■

Л1.2 Субградиентный метод

Рассматриваем безусловную задачу:

$$\min_{x \in \mathbb{R}^d} f(x), \tag{Л1.1}$$

где функция f выпуклая на $\mathbb{R}^d$ и M–липшицева.
Простая идея — снова модифицировать градиентный спуск, теперь вместо градиента используя какой-то субградиент в текущей точке:

Алгоритм Л1.1 Субградиентный метод

Вход: стартовая точка $x^0 \in \mathbb{R}^d$, размеры шагов $\{\gamma_k\}_{k=0} > 0$, количество итераций K

1: **for** $k = 0, 1, \ldots, K-1$ **do**
2: Вычислить $g^k \in \partial f(x^k)$
3: $x^{k+1} = x^k - \gamma_k g^k$
4: **end for**

Выход: $\frac{1}{K}\sum_{k=0}^{K-1} x^k$

Замечание Л1.2. Сходимость у субградиентного метода (Алгоритм Л1.1) по средней точке, а не по последней.

Теорема Л1.3. Пусть задача безусловной оптимизации с M–липшицевой выпуклой целевой функцией f решается с помощью субградиентного метода (Алгоритм Л1.1). Тогда при $\gamma_k = \gamma$ справедлива следующая оценка сходимости:

$$f\left(\frac{1}{K}\sum_{k=0}^{K-1} x^k\right) - f^* \leq \frac{\|x^0 - x^*\|_2^2}{2\gamma K} + \frac{\gamma M^2}{2}.$$

Доказательство. Начнем с рассмотрения квадрата нормы $\|x^{k+1} - x^*\|_2^2$. Подставим формулу обновления

$$x^{k+1} = x^k - \gamma g^k,$$

после чего раскроем квадрат нормы:

$$\begin{aligned}\|x^{k+1} - x^*\|_2^2 &= \|x^k - \gamma g^k - x^*\|_2^2 \\ &= \|x^k - x^*\|_2^2 - 2\gamma\langle g^k, x^k - x^*\rangle + \gamma^2\|g^k\|_2^2.\end{aligned}$$

Из M–липшицевости f следует, что норма субградиента g^k ограничена M (Теорема Л1.2):

$$\left\|x^{k+1} - x^*\right\|_2^2 \leq \left\|x^k - x^*\right\|_2^2 - 2\gamma\langle g^k, x^k - x^*\rangle + \gamma^2 M^2.$$

Из определения субградиента (Определение Л1.3) оценим скалярное произведение:

$$\left\|x^{k+1} - x^*\right\|_2^2 \leq \left\|x^k - x^*\right\|_2^2 - 2\gamma\big(f(x^k) - f^*\big) + \gamma^2 M^2.$$

Перенесем разность значений функции f влево, а норму вправо:

$$2\gamma\big(f(x^k) - f^*\big) \leq \left\|x^k - x^*\right\|_2^2 - \left\|x^{k+1} - x^*\right\|_2^2 + \gamma^2 M^2.$$

Просуммируем по всем k от 0 до $K-1$:

$$2\gamma \sum_{k=0}^{K-1} \big(f(x^k) - f^*\big) \leq \sum_{k=0}^{K-1} \Big(\left\|x^k - x^*\right\|_2^2 - \left\|x^{k+1} - x^*\right\|_2^2 + \gamma^2 M^2\Big).$$

Раскроем телескопическую сумму справа, из которой остается только два слагаемых с нормой, а также разделим на $2\gamma K$:

$$\frac{1}{K}\sum_{k=0}^{K-1} \big(f(x^k) - f^*\big) \leq \frac{\left\|x^0 - x^*\right\|_2^2 - \left\|x^K - x^*\right\|_2^2}{2\gamma K} + \frac{\gamma M^2}{2}.$$

Можно откинуть неположительное $-\frac{\left\|x^K - x^*\right\|_2^2}{2\gamma K}$ в правой части, а также воспользоваться выпуклостью функции f (Определение Л1.1) в левой:

$$f\left(\frac{1}{K}\sum_{k=0}^{K-1} x^k\right) - f^* \leq \frac{1}{K}\sum_{k=0}^{K-1} \big(f(x^k) - f^*\big) \leq \frac{\left\|x^0 - x^*\right\|_2^2}{2\gamma K} + \frac{\gamma M^2}{2}.$$

■

Утверждение Л1.1. Пусть задача удовлетворяет условиям Теоремы Л1.3 и выбрано значение шага $\gamma_k = \frac{\left\|x^0 - x^*\right\|_2}{M\sqrt{K}}$. Тогда справедлива следующая оценка сходимости:

$$f\left(\frac{1}{K}\sum_{k=0}^{K-1} x^k\right) - f^* \leq \frac{M\left\|x^0 - x^*\right\|_2}{\sqrt{K}}.$$

Более того, чтобы добиться точности ε по функции $\big(f\big(\frac{1}{K}\sum_{k=0}^{K-1} x^k\big) - f^* \leq \varepsilon\big)$, необходимо

$$K = \mathcal{O}\left(\frac{M^2\left\|x^0 - x^*\right\|_2^2}{\varepsilon^2}\right) \text{ итераций.}$$

Доказательство. Запишем оценку сходимости из Теоремы Л1.3:

$$f\left(\frac{1}{K}\sum_{k=0}^{K-1} x^k\right) - f^* \leq \frac{\left\|x^0 - x^*\right\|_2^2}{2\gamma K} + \frac{\gamma M^2}{2}. \tag{Л1.2}$$

Минимизируя правую часть оценки по $\gamma > 0$, находим оптимальное значение шага $\gamma^* = \frac{\left\|x^0 - x^*\right\|_2}{M\sqrt{K}}$.

Подставим его в (Л1.2) и получим:

$$f\left(\frac{1}{K}\sum_{k=0}^{K-1} x^k\right) - f^* \leq \frac{M\left\|x^0 - x^*\right\|_2}{\sqrt{K}}.$$

Теперь потребуем точность ε по функции, ограничив правую часть неравенства:

$$\frac{M\left\|x^0 - x^*\right\|_2}{\sqrt{K}} \leq \varepsilon.$$

Решая это неравенство относительно K, приходим к

$$K \geq \left(\frac{M\left\|x^0 - x^*\right\|_2}{\varepsilon}\right)^2,$$

что и даёт заявленную оценку на число итераций. ■

Субградиентный метод является обобщением градиентного спуска на негладкие задачи. Его сходимость оказывается медленнее, чем у градиентного спуска. В общем случае результат для субградиентного метода является неулучшаемым для выпуклых и сильно выпуклых задач, то есть он оптимален.

Л1.3 Адаптивные методы

В полученной оценке для субградиентного метода шаг выбирается равным

$$\gamma = \frac{\left\|x^0 - x^*\right\|_2}{M\sqrt{K}}.$$

Однако такая формула требует знания заранее числа итераций K, константы Липшица M и расстояния $\left\|x^0 - x^*\right\|_2$ до решения. На практике эти параметры обычно неизвестны, и их использование существенно ограничивает применимость метода. Возникает естественный вопрос: как построить выбор шага, который не требует этих величин, но при этом сохраняет их смысл и обеспечивает аналогичное поведение алгоритма?

Л1.3.1 AdaGradNorm

Первым шагом можно избавиться от необходимости знать константу Липшица M. Согласно Теореме Л1.2 имеем неравенство:

$$\left\|g\right\|_2 \leq M$$

для всех $g \in \partial f(x)$ во всех точках $x \in \mathbb{R}^d$. Отсюда можно оценить

$$M \sim \left\|g\right\|_2.$$

Однако этого недостаточно: в оптимальном значении шага в знаменателе стоит $M\sqrt{K}$. Тогда мы можем брать норму не одного субградиента в какой-то точке, а суммировать по всем предыдущим:

$$M\sqrt{K} \sim \sqrt{\sum_{t=0}^{K-1} \left\|g^t\right\|_2^2}.$$

Неизвестным остается только расстояние до решения $\left\|x^0 - x^*\right\|_2$. Его можно оценить лишь какой-то константой D, на практике часто подбираемой эмпирически:

$$\left\|x^0 - x^*\right\|_2 \leq D.$$

Замечание Л1.3. Условие $\left\|x^0 - x^*\right\|_2 \leq D$ выглядит менее искусственным, если мы знаем, что решение x^* лежит в некотором ограниченном множестве $\mathcal{X}$. Тогда константу D можно оценить как диаметр множества:

$$D = \sup_{x,y \in \mathcal{X}} \left\|x - y\right\|_2.$$

Собирая все вместе, имеем шаг

$$\gamma_k = \frac{D}{\sqrt{\sum_{t=0}^{k} \left\|g^t\right\|_2^2 + \varepsilon}},$$

где для вычислительной устойчивости в знаменатель была добавлена константа ε, обычно выбирающаяся достаточно малой.
Таким образом, шаг автоматически уменьшается по мере роста накопленной нормы градиента и метод работает без знания M и K. Метод с таким адаптивным подбором шага называется AdaGradNorm [6].

Алгоритм Л1.2 AdaGradNorm

Вход: стартовая точка $x^0 \in \mathbb{R}^d$, сумма квадратов норм субградиентов $G^{-1} = 0$, параметры $\varepsilon \sim 10^{-8}$, $D > 0$, количество итераций K

1: **for** $k = 0, 1, \ldots, K-1$ **do**
2: Вычислить $g^k \in \partial f(x^k)$
3: $G^k = G^{k-1} + \left\|g^k\right\|_2^2$
4: $x^{k+1} = x^k - \frac{D}{\sqrt{G^k + \varepsilon}} g^k$
5: **end for**

Выход: $\frac{1}{K} \sum_{k=0}^{K-1} x^k$

Л1.3.2 DoG: Distance over Gradients

В методе AdaGradNorm шаг имеет вид

$$\gamma_k = \frac{D}{\sqrt{\sum_{t=0}^{k} \left\|g^t\right\|_2^2 + \varepsilon}},$$

где $D = \left\|x^0 - x^*\right\|_2$ остаётся неизвестным параметром. Для его замены предлагается использовать наблюдаемую величину

$$d_k = \max_{t=\overline{0,k}} \left\|x^t - x^0\right\|_2,$$

которая служит естественной оценкой D по траектории метода. В самом деле, мы заменили оценку на диаметр множества максимальным расстоянием, на которое удалялись от стартовой точки.
Подставляя эту оценку вместо D, получаем метод без гиперпараметров.

Алгоритм Л1.3 DoG (Distance over Gradients)

Вход: стартовая точка $x^0 \in \mathbb{R}^d$, сумма квадратов норм субградиентов $G^{-1} = 0$, оценка диаметра $d_{-1} > 0$, параметр $\varepsilon \sim 10^{-8}$, количество итераций K

1: **for** $k = 0, 1, \ldots, K-1$ **do**
2: Вычислить $g^k \in \partial f(x^k)$
3: $G^k = G^{k-1} + \left\|g^k\right\|_2^2$
4: $d_k = \max\left(d_{k-1}, \left\|x^k - x^0\right\|_2\right)$
5: $x^{k+1} = x^k - \frac{d_k}{\sqrt{G^k + \varepsilon}} g^k$
6: **end for**

Выход: $\frac{1}{K}\sum_{k=0}^{K-1} x^k$

Л1.3.3 AdaGrad

Следующий шаг — учесть неоднородность по координатам. Тогда оптимальный шаг для каждой i-ой компоненты зависит от своей константы Липшица M_i и своего расстояния $\left|x_i^0 - x_i^*\right|$. Вместо глобального масштаба можно адаптивно накапливать информацию о каждом направлении:

$$M_i\sqrt{K} \sim \sqrt{\sum_{t=0}^{K-1} \left(g_i^t\right)^2},$$

а также оценивать расстояние до решения по каждой координате:

$$\left|x_i^0 - x_i^*\right| \leq D_i.$$

Тогда шаг для каждой координаты берётся как

$$\gamma_{k,i} = \frac{D_i}{\sqrt{\sum_{t=0}^{k} \left(g_i^t\right)^2 + \varepsilon}}.$$

Такой метод учитывает частоту и величину обновлений в каждой компоненте и особенно эффективен при разреженных признаках. Этот алгоритм получил название AdaGrad [2].

Алгоритм Л1.4 AdaGrad

Вход: стартовая точка $x^0 \in \mathbb{R}^d$, суммы квадратов компонент субградиентов $G_i^{-1} = 0$, параметры $\varepsilon \sim 10^{-8}$, $D_i > 0$, количество итераций K

1: **for** $k = 0, 1, \ldots, K-1$ **do**
2: Вычислить $g^k \in \partial f(x^k)$
3: $G_i^k = G_i^{k-1} + \left(g_i^k\right)^2$
4: $x_i^{k+1} = x_i^k - \frac{D_i}{\sqrt{G_i^k + \varepsilon}} g_i^k$
5: **end for**

Выход: $\frac{1}{K}\sum_{k=0}^{K-1} x^k$

Для алгоритма сформулируем и докажем теорему о сходимости.

Теорема Л1.4. Пусть задача оптимизации (Л1.1) с M–липшицевой выпуклой целевой функцией f решается с помощью AdaGrad (Алгоритм Л1.4). Тогда спра-

ведлива следующая оценка сходимости:

$$f\left(\frac{1}{K}\sum_{k=0}^{K-1} x^k\right) - f^* \leq \frac{3M\tilde{D}}{2\sqrt{K}},$$

где $\tilde{D} = \sum_{i=1}^{d} D_i$, $\left|x_i^k - x_i^*\right| \leq D_i$ для любых $i = \overline{1,d}$ и любых $k = \overline{0,K-1}$.
Более того, чтобы добиться точности ε по функции $\left(f\left(\frac{1}{K}\sum_{k=0}^{K-1} x^k\right) - f^* \leq \varepsilon\right)$, необходимо

$$K = \mathcal{O}\left(\frac{M^2\tilde{D}^2}{\varepsilon^2}\right) \text{ итераций.}$$

Доказательство. Начнем с квадрата ошибки по i-ой координате $\left(x_i^{k+1} - x_i^*\right)^2$. Подставим итерацию метода:

$$\begin{aligned}\left(x_i^{k+1} - x_i^*\right)^2 &= \left(x_i^k - \gamma_{k,i} g_i^k - x_i^*\right)^2 \\ &= \left(x_i^k - x_i^*\right)^2 - 2\gamma_{k,i} g_i^k (x_i^k - x_i^*) + \gamma_{k,i}^2 \left(g_i^k\right)^2.\end{aligned}$$

Откуда выражаем перекрестное слагаемое:

$$g_i^k (x_i^k - x_i^*) = \frac{1}{2\gamma_{k,i}}\left(x_i^k - x_i^*\right)^2 - \frac{1}{2\gamma_{k,i}}\left(x_i^{k+1} - x_i^*\right)^2 + \frac{\gamma_{k,i}}{2}\left(g_i^k\right)^2.$$

Собираем скалярное произведение, суммируя по всем координатам i от 1 до d:

$$\left\langle g^k, x^k - x^*\right\rangle = \frac{1}{2}\sum_{i=1}^{d}\left[\frac{1}{\gamma_{k,i}}\left(x_i^k - x_i^*\right)^2 - \frac{1}{\gamma_{k,i}}\left(x_i^{k+1} - x_i^*\right)^2 + \gamma_{k,i}\left(g_i^k\right)^2\right].$$

Оцениваем левую часть, пользуясь определением субградиента (Определение Л1.3):

$$f\left(x^k\right) - f^* \leq \frac{1}{2}\sum_{i=1}^{d}\left[\frac{1}{\gamma_{k,i}}\left(x_i^k - x_i^*\right)^2 - \frac{1}{\gamma_{k,i}}\left(x_i^{k+1} - x_i^*\right)^2 + \gamma_{k,i}\left(g_i^k\right)^2\right].$$

Суммируем по всем k от 0 до $K-1$ и усредняем, а также меняем порядок суммирования:

$$\begin{aligned}\frac{1}{K}\sum_{k=0}^{K-1}\left(f\left(x^k\right) - f^*\right) &\leq \frac{1}{2K}\sum_{k=0}^{K-1}\sum_{i=1}^{d}\left[\frac{1}{\gamma_{k,i}}\left(x_i^k - x_i^*\right)^2 - \frac{1}{\gamma_{k,i}}\left(x_i^{k+1} - x_i^*\right)^2 + \gamma_{k,i}\left(g_i^k\right)^2\right] \\ &= \frac{1}{2K}\sum_{i=1}^{d}\sum_{k=0}^{K-1}\left[\frac{1}{\gamma_{k,i}}\left(x_i^k - x_i^*\right)^2 - \frac{1}{\gamma_{k,i}}\left(x_i^{k+1} - x_i^*\right)^2 + \gamma_{k,i}\left(g_i^k\right)^2\right].\end{aligned}$$

Следующим шагом будет приведение подобных слагаемых. Для этого сдвинем индекс суммирования k и аккуратно поработаем с крайними слагаемыми. Для удобства по-

ложим $\gamma_{-1,i} = +\infty$ и преобразуем:

$$\begin{aligned}\frac{1}{K}\sum_{k=0}^{K-1}\left(f(x^k)-f^*\right) &\le \frac{1}{2K}\sum_{i=1}^{d}\sum_{k=0}^{K-1}\left[\frac{1}{\gamma_{k,i}}\left(x_i^k - x_i^*\right)^2 + \gamma_{k,i}\left(g_i^k\right)^2\right] \\ &\quad - \frac{1}{2K}\sum_{i=1}^{d}\sum_{k=0}^{K-1}\left[\frac{1}{\gamma_{k,i}}\left(x_i^{k+1} - x_i^*\right)^2\right] \\ &= \frac{1}{2K}\sum_{i=1}^{d}\sum_{k=0}^{K-1}\left[\frac{1}{\gamma_{k,i}}\left(x_i^k - x_i^*\right)^2 + \gamma_{k,i}\left(g_i^k\right)^2\right] \\ &\quad - \frac{1}{2K}\sum_{i=1}^{d}\sum_{k=0}^{K-1}\left[\frac{1}{\gamma_{k-1,i}}\left(x_i^k - x_i^*\right)^2\right] - \frac{1}{2K}\sum_{i=1}^{d}\frac{1}{\gamma_{K-1,i}}\left(x_i^K - x_i^*\right)^2 \\ &\le \frac{1}{2K}\sum_{i=1}^{d}\sum_{k=0}^{K-1}\left[\left(\frac{1}{\gamma_{k,i}} - \frac{1}{\gamma_{k-1,i}}\right)\left(x_i^k - x_i^*\right)^2 + \gamma_{k,i}\left(g_i^k\right)^2\right].\end{aligned}$$

В последнем переходе мы откинули неположительное слагаемое. Теперь воспользуемся константами $D_i : \left(x_i^k - x_i^*\right)^2 \le D_i^2$:

$$\frac{1}{K}\sum_{k=0}^{K-1}\left(f(x^k)-f^*\right) \le \frac{1}{2K}\sum_{i=1}^{d}\sum_{k=0}^{K-1}\left[\left(\frac{1}{\gamma_{k,i}} - \frac{1}{\gamma_{k-1,i}}\right)D_i^2 + \gamma_{k,i}\left(g_i^k\right)^2\right].$$

Подставим $\gamma_{k,i} = \frac{D_i}{\sqrt{\sum_{t=0}^{k}\left(g_i^t\right)^2}}$ и свернём телескопическую сумму по k:

$$\begin{aligned}\frac{1}{K}\sum_{k=0}^{K-1}\left(f(x^k)-f^*\right) &\le \frac{1}{2K}\sum_{i=1}^{d}\sum_{k=0}^{K-1}\left[\left(\sqrt{\sum_{t=0}^{k}\left(g_i^t\right)^2} - \sqrt{\sum_{t=0}^{k-1}\left(g_i^t\right)^2}\right)D_i + \frac{D_i\left(g_i^k\right)^2}{\sqrt{\sum_{t=0}^{k}\left(g_i^t\right)^2}}\right] \\ &= \frac{1}{2K}\sum_{i=1}^{d}D_i\left[\sqrt{\sum_{t=0}^{K-1}\left(g_i^t\right)^2} + \sum_{k=0}^{K-1}\frac{\left(g_i^k\right)^2}{\sqrt{\sum_{t=0}^{k}\left(g_i^t\right)^2}}\right].\end{aligned}$$

Воспользуемся техническим фактом, который говорит, что для любых неотрицательных чисел $\{a_k\} \ge 0$ выполнено:

$$\sum_{k=0}^{K-1}\frac{a_k^2}{\sqrt{\sum_{t=0}^{k}a_t^2}} \le 2\sqrt{\sum_{k=0}^{K-1}a_k^2}.$$

Применяем его для второго слагаемого в сумме, получаем:

$$\frac{1}{K}\sum_{k=0}^{K-1}\left(f(x^k)-f^*\right) \le \frac{3}{2K}\sum_{i=1}^{d}D_i\sqrt{\sum_{t=0}^{K-1}\left(g_i^t\right)^2}.$$

Из неизвестных значений в правой части остается только $\sum_{t=0}^{K-1}\left(g_i^t\right)^2$. Оценим её с помощью свойства M–липшицевых функций (Теорема Л1.2):

$$\sum_{t=0}^{K-1}\left(g_i^t\right)^2 \le \sum_{t=0}^{K-1}\left\|g^t\right\|_2^2 \le KM^2.$$

Подставляем в основное неравенство:

$$\frac{1}{K}\sum_{k=0}^{K-1}\left(f(x^k)-f^*\right) \le \frac{3}{2K}\sum_{i=1}^{d} D_i\sqrt{KM^2} = \frac{3M}{2\sqrt{K}}\sum_{i=1}^{d} D_i = \frac{3M\tilde{D}}{2\sqrt{K}}.$$

Чтобы получить оценку из условия, остается применить определение выпуклости функции (Определение Л1.1):

$$f\left(\frac{1}{K}\sum_{k=0}^{K-1} x^k\right) - f^* \le \frac{3M\tilde{D}}{2\sqrt{K}}.$$

Чтобы получить оценку на количество итераций для достижения точности ε по функции $\left(f\left(\frac{1}{K}\sum_{k=0}^{K-1} x^k\right) - f^* \le \varepsilon\right)$, ограничим правую часть:

$$\frac{3M\tilde{D}}{2\sqrt{K}} \le \varepsilon.$$

Откуда и получаем:

$$K \ge \frac{9M^2\tilde{D}^2}{4\varepsilon^2}.$$

■

Замечание Л1.4. Константы D_i могут выглядеть немного искусственными, однако их можно обосновать. Например, когда нам известно, что решение x^* лежит в ограниченном множестве $\mathcal{X}$, а стартовая и все последующие точки также лежат внутри этого множества.

Замечание Л1.5. Константы D_i можно также оценивать динамически. В частности, можно использовать идею DoG, адаптированную под координатную запись:

$$d_{k,i} = \max_{0\le t\le k}\left|x_i^t - x_i^0\right|.$$

Л1.3.4 RMSProp

У AdaGrad знаменатель монотонно растёт, и шаг со временем может становиться слишком малым. Чтобы избежать затухания шага, вместо суммы используют экспоненциальное скользящее среднее квадратов градиентов:

$$G_i^k = \beta G_i^{k-1} + (1-\beta)\left(g_i^k\right)^2,$$

где моментум $\beta \in [0,1]$ выбирается порядка ~ 0.99. Такой приём позволяет учитывать преимущественно недавнюю историю и адаптироваться к меняющейся геометрии задачи. Метод получил название RMSProp [5].

Алгоритм Л1.5 RMSProp

Вход: стартовая точка $x^0 \in \mathbb{R}^d$, сглаженные суммы квадратов компонент субградиентов $G_i^{-1} = 0$, параметры $\varepsilon \sim 10^{-8}$, $D_i > 0$, $\beta \in [0,1]$, количество итераций K

1: **for** $k = 0, 1, \ldots, K-1$ **do**
2: Вычислить $g^k \in \partial f(x^k)$
3: $G_i^k = \beta G_i^{k-1} + (1-\beta)\left(g_i^k\right)^2$
4: $x_i^{k+1} = x_i^k - \frac{D_i}{\sqrt{G_i^k+\varepsilon}} g_i^k$
5: **end for**

Выход: $\frac{1}{K}\sum_{k=0}^{K-1} x^k$

Л1.3.5 Adam

Алгоритм Adam объединяет идеи RMSProp и моментума. Помимо экспоненциального сглаживания квадратов градиентов, он усредняет сами градиенты:

$$v^k = \beta_1 v^{k-1} + (1-\beta_1) g^k,$$
$$G_i^k = \beta_2 G_i^{k-1} + (1-\beta_2)\big(g_i^k\big)^2,$$

где два моментума $\beta_1, \beta_2 \in [0,1]$ обычно выбираются 0.9 и 0.999 соответственно. Чтобы устранить смещение на ранних итерациях, вводится коррекция:

$$\hat{v}^k = \frac{v^k}{1-\beta_1^{k+1}},$$
$$\widehat{G}^k = \frac{G^k}{1-\beta_2^{k+1}}.$$

В итоге шаг получается

$$x_i^{k+1} = x_i^k - \frac{D_i}{\sqrt{\widehat{G}_i^k + \varepsilon}} \hat{v_i}^k.$$

Такой метод даёт устойчивые шаги при шумных и разреженных градиентах и требует минимальной настройки гиперпараметров [3].

Алгоритм Л1.6 Adam

Вход: стартовая точка $x^0 \in \mathbb{R}^d$, сглаженные суммы квадратов компонент субградиентов $G_i^{-1} = 0$, сглаженные суммы субградиентов $v^{-1} = 0$, параметры $\beta_1, \beta_2 \in [0,1]$, $\varepsilon \sim 10^{-8}$, $D_i > 0$, количество итераций K

1: **for** $k = 0, 1, \ldots, K-1$ **do**
2: Вычислить $g^k \in \partial f\big(x^k\big)$
3: $v^k = \beta_1 v^{k-1} + (1-\beta_1) g^k$
4: $\hat{v}^k = v^k / \big(1-\beta_1^{k+1}\big)$
5: $G_i^k = \beta_2 G_i^{k-1} + (1-\beta_2)\big(g_i^k\big)^2$
6: $\widehat{G}^k = G^k / \big(1-\beta_2^{k+1}\big)$
7: $x_i^{k+1} = x_i^k - \frac{D_i}{\sqrt{\widehat{G}_i^k + \varepsilon}} \hat{v}_i^k$
8: **end for**

Выход: $\frac{1}{K}\sum_{k=0}^{K-1} x^k$

Л1.3.6 NAdam

Вариант NAdam сочетает Adam с идеей ускорения Нестерова. То есть сначала делаем шаг по инерции, потом вычисляем субградиент и делаем шаг вдоль него [1].

Алгоритм Л1.7 NAdam

Вход: стартовая точка $x^0 \in \mathbb{R}^d$, сглаженные суммы квадратов компонент субградиентов $G_i^{-1} = 0$, сглаженные суммы субградиентов $v^{-1} = 0$, параметры $\beta_1, \beta_2 \in [0,1]$, $\varepsilon \sim 10^{-8}$, $D_i > 0$, количество итераций K

1: **for** $k = 0, 1, \ldots, K-1$ **do**
2: Вычислить $g^k \in \partial f(x^k)$
3: $v^k = \beta_1 v^{k-1} + (1-\beta_1) g^k$
4: $\hat{v}^k = v^k / (1 - \beta_1^{k+1})$
5: $G_i^k = \beta_2 G_i^{k-1} + (1-\beta_2)(g_i^k)^2$
6: $\widehat{G}^k = G^k / (1 - \beta_2^{k+1})$
7: $m^k = \beta_1 \hat{v}^k + \frac{1-\beta_1}{1-\beta_1^{k+1}} g^k$
8: $x_i^{k+1} = x_i^k - \frac{D_i}{\sqrt{\widehat{G}_i^k + \varepsilon}} m_i^k$
9: **end for**

Выход: $\frac{1}{K} \sum_{k=0}^{K-1} x^k$

Л1.3.7 AdamW

В классическом Adam, если применяется ℓ_2-регуляризация, то градиент от слагаемого $\frac{\lambda}{2}\|x\|_2^2$ добавляется в общий градиент и масштабируется адаптивным шагом, что делает её неэквивалентной классической регуляризации. AdamW отделяет регуляризацию: стягивание весов $-\lambda x^k$ добавляется отдельно от градиентного обновления. Это позволяет контролировать регуляризацию независимо от величины шага и улучшает обобщающую способность моделей [4].

Алгоритм Л1.8 AdamW

Вход: стартовая точка $x^0 \in \mathbb{R}^d$, сглаженные суммы квадратов компонент субградиентов $G_i^{-1} = 0$, сглаженные суммы субградиентов $v^{-1} = 0$, параметры $\beta_1, \beta_2 \in [0,1]$, $\lambda > 0$, $\varepsilon \sim 10^{-8}$, $D_i > 0$, количество итераций K

1: **for** $k = 0, 1, \ldots, K-1$ **do**
2: Вычислить $g^k \in \partial f(x^k)$
3: $v^k = \beta_1 v^{k-1} + (1-\beta_1) g^k$
4: $\hat{v}^k = v^k / (1 - \beta_1^{k+1})$
5: $G_i^k = \beta_2 G_i^{k-1} + (1-\beta_2)(g_i^k)^2$
6: $\widehat{G}^k = G^k / (1 - \beta_2^{k+1})$
7: $x_i^{k+1} = x_i^k - \frac{D_i}{\sqrt{\widehat{G}_i^k + \varepsilon}} \hat{v}_i^k - \lambda D_i x_i^k$
8: **end for**

Выход: $\frac{1}{K} \sum_{k=0}^{K-1} x^k$

Л1.4 Проксимальный оператор

Негладкие задачи «более сложные» по сравнению с гладкими задачами. Но отсутствие гладкости может получиться «спрятать под ковер» с помощью проксимального оператора.

Определение Л1.4. Для функции $r : \mathbb{R}^d \to \mathbb{R} \cup \{+\infty\}$ *проксимальный оператор*

определяется следующим образом:

$$\operatorname{prox}_r(x) = \operatorname*{argmin}_{\tilde{x}\in\mathbb{R}^d} \left(r(\tilde{x}) + \frac{1}{2}\|x - \tilde{x}\|_2^2 \right).$$

Пока что мы не потребовали ничего от функции r и мало что можем сказать про проксимальный оператор. Оказывается, что если наложить на r условие выпуклости, то проксимальный оператор для нее становится однозначно определён.

Утверждение Л1.2. Пусть $r : \mathbb{R}^d \to \mathbb{R} \cup \{+\infty\}$ — выпуклая функция. Если существует $\hat{x} \in \mathbb{R}^d$ с $r(\hat{x}) < +\infty$, то проксимальный оператор однозначно определен.

Доказательство. Проксимальный оператор возвращает минимум некоторой задачи оптимизации. Задача сильно выпуклая, так как целевая функция — это сумма выпуклой и сильно выпуклой функции. А значит, существует строго один минимум (Теорема **??**). А существование $\hat{x}$ необходимо для того, чтобы $r(\tilde{x}) + \frac{1}{2}\|x - \tilde{x}\|_2^2$ хотя бы где-то принимала конечное значение. ■

Л1.4.1 Примеры проксимального оператора

Рассмотрим операторы, которые мы будем получать в зависимости от того, какую проксимальную функцию мы используем.

- **ℓ_1-норма.**
  Пусть $r(x) = \lambda\|x\|_1$, где $\lambda > 0$. Тогда

  $$[\operatorname{prox}_r(x)]_i = \big[|x_i| - \lambda\big]_+ \cdot \operatorname{sign}(x_i),$$

  что известно как *оператор трешхолдинга*.

  Доказательство. Рассмотрим задачу

  $$\begin{aligned}\operatorname{prox}_r(x) &= \operatorname*{argmin}_{\tilde{x}\in\mathbb{R}^d} \left(\lambda\|\tilde{x}\|_1 + \frac{1}{2}\|x - \tilde{x}\|_2^2 \right) \\ &= \operatorname*{argmin}_{\tilde{x}\in\mathbb{R}^d} \sum_{i=1}^d \left(\frac{1}{2}(\tilde{x}_i - x_i)^2 + \lambda|\tilde{x}_i| \right).\end{aligned}$$

  Задача распадается по координатам. Для каждой координаты условие оптимальности имеет вид

  $$0 \in \tilde{x}_i^* - x_i + \lambda \cdot \partial|\tilde{x}_i^*|,$$

  что приводит к правилу софт-трешхолдинга:

  $$\tilde{x}_i^* = \big[|x_i| - \lambda\big]_+ \cdot \operatorname{sign}(x_i).$$

  ■

- **ℓ_2-норма.**
  Пусть $r(x) = \frac{\lambda}{2}\|x\|_2^2$, где $\lambda > 0$. Тогда

  $$\operatorname{prox}_r(x) = \frac{x}{1+\lambda}.$$

Доказательство. Рассмотрим

$$\operatorname{prox}_r(x) = \operatorname*{argmin}_{\tilde{x}\in\mathbb{R}^d} \left(\frac{\lambda}{2}\|\tilde{x}\|_2^2 + \frac{1}{2}\|x-\tilde{x}\|_2^2 \right).$$

Необходимое условие минимума (Теорема **??**):

$$\lambda\tilde{x}^* + \tilde{x}^* - x = 0.$$

Откуда и получаем решение:

$$\tilde{x}^* = \frac{x}{1+\lambda}.$$

■

- **Индикатор множества.**
  Пусть $r(x) = \mathbb{I}_{\mathcal{X}}(x)$ для замкнутого множества $\mathcal{X} \subseteq \mathbb{R}^d$, где

$$\mathbb{I}_{\mathcal{X}}(x) = \begin{cases} 0, & x \in \mathcal{X}, \\ +\infty, & x \notin \mathcal{X}. \end{cases}$$

  Тогда

$$\operatorname{prox}_r(x) = \operatorname*{argmin}_{\tilde{x}\in\mathcal{X}} \frac{1}{2}\|x-\tilde{x}\|_2^2.$$

  Смысл такого оператора в том, что он возвращает ближайшую к x точку из множества $\mathcal{X}$.

  Доказательство. Имеем

$$\begin{aligned} \operatorname{prox}_r(x) &= \operatorname*{argmin}_{\tilde{x}\in\mathbb{R}^d} \left(\mathbb{I}_{\mathcal{X}}(\tilde{x}) + \frac{1}{2}\|x-\tilde{x}\|_2^2 \right) \\ &= \operatorname*{argmin}_{\tilde{x}\in\mathcal{X}} \frac{1}{2}\|x-\tilde{x}\|_2^2. \end{aligned}$$

  ■

Л1.4.2 Свойства проксимального оператора

Для последующего теоретического анализа алгоритмов на основе проксимального оператора, докажем полезные свойства.

Утверждение Л1.3. Пусть $r : \mathbb{R}^d \to \mathbb{R} \cup \{+\infty\}$ — выпуклая функция. Тогда для любых $x, y \in \mathbb{R}^d$ следующие три условия являются эквивалентными:

1. $\operatorname{prox}_r(x) = y$,
2. $x - y \in \partial r(y)$,
3. $\langle x-y, z-y\rangle \leq r(z) - r(y)$ для любого $z \in \mathbb{R}^d$.

Доказательство. Запишем первое условие по определению проксимального оператора (Определение Л1.4):

$$y = \operatorname*{argmin}_{\tilde{x}\in\mathbb{R}^d} \left(r(\tilde{x}) + \frac{1}{2}\|x - \tilde{x}\|_2^2 \right).$$

Из условия оптимальности для выпуклой функции r (Теорема Л1.1) это эквивалентно

$$0 \in \partial \left(r(\tilde{x}) + \frac{1}{2}\|x - \tilde{x}\|_2^2 \right)\Big|_{\tilde{x}=y} = \partial r(y) + y - x.$$

Получили эквивалентность первого и второго условий.
Теперь свяжем второе и третье. Из определения субдифференциала (Определение Л1.3), для любого субградиента $g \in \partial f(y)$ и для любого $z \in \mathbb{R}^d$:

$$\langle g, z - y\rangle \le r(z) - r(y).$$

В частности, справедливо и для $g = x - y \in \partial r(y)$ по предположению:

$$\langle x - y, z - y\rangle \le r(z) - r(y).$$

Получили следствие из второго в третье. Теперь в обратную сторону. Пусть выполняется соотношение три:

$$\langle x - y, z - y\rangle \le r(z) - r(y).$$

Но это же означает, что $x - y$ является субградиентом r в точке y, то есть $g \in \partial r(y)$. ■

Этим свойством мы связали действие проксимального оператора и субградиент. Следующее утверждение позволит работать с действиями проксимального оператора под знаками скалярного произведения и нормы.

Утверждение Л1.4. Пусть $r : \mathbb{R}^d \to \mathbb{R} \cup \{+\infty\}$ — выпуклая функция. Тогда для любых $x, y \in \mathbb{R}^d$ выполнено следующее:

- $\langle x - y, \operatorname{prox}_r(x) - \operatorname{prox}_r(y)\rangle \ge \|\operatorname{prox}_r(x) - \operatorname{prox}_r(y)\|_2^2$,
- $\|\operatorname{prox}_r(x) - \operatorname{prox}_r(y)\|_2 \le \|x - y\|_2$.

Доказательство. Для удобства обозначим $u = \operatorname{prox}_r(x), v = \operatorname{prox}_r(y)$. Начнем с неравенства из Утверждения Л1.3. Запишем для троек точек (x, u, v) и (y, v, u):

$$\langle x - u, v - u\rangle \le r(v) - r(u),$$
$$\langle y - v, u - v\rangle \le r(u) - r(v).$$

Сложим неравенства, справа получим 0:

$$\langle x - u - (y - v), v - u\rangle \le 0.$$

Разнесем слагаемые в разные стороны:

$$\langle x - y, u - v\rangle \ge \|u - v\|_2^2.$$

Это и есть первое свойство. Из него логично вытекает и второе свойство. Достаточно лишь применить к неравенству выше неравенство Коши–Буняковского–Шварца (**??**):

$$\|u - v\|_2^2 \le \langle x - y, u - v\rangle \le \|x - y\|_2 \|u - v\|_2.$$

Случай $u = v$ тривиален и удовлетворяет неравенству, так что имеем:

$$\|u - v\|_2 \le \|x - y\|_2.$$

■

Л1.4.3 Проксимальный градиентный метод

Настало время применить проксимальный оператор для построения метода оптимизации. Рассмотрим следующую задачу:

$$\min_{x\in\mathbb{R}^d} f\big(x\big) + r(x), \tag{Л1.3}$$

где f является L–гладкой выпуклой функцией, а r — просто выпуклой. Она не обязана быть гладкой, но должна быть проксимально-дружественной, то есть для нее должен считаться проксимальный оператор. Задача (Л1.3) называется *композитной*.
Вновь модифицируем градиентный спуск: добавим применение проксимального оператора $\text{prox}_{\gamma r}$ после градиентного шага $-\gamma_k \nabla f\big(x^k\big)$.

Алгоритм Л1.9 Проксимальный градиентный метод

Вход: стартовая точка $x^0 \in \mathbb{R}^d$, размеры шагов $\{\gamma_k\}_{k=0} > 0$, количество итераций K

1: **for** $k = 0, 1, \ldots, K-1$ **do**
2: $\quad x^{k+1} = \text{prox}_{\gamma_k r}\big(x^k - \gamma_k \nabla f\big(x^k\big)\big)$
3: **end for**

Выход: x^K

Покажем, какую физику несёт метод. Для этого воспользуемся результатами Утверждения Л1.3, тогда $x^{k+1} = \text{prox}_{\gamma_k r}\big(x^k - \gamma_k \nabla f\big(x^k\big)\big)$ эквивалентно записи:

$$x^k - \gamma_k \nabla f\big(x^k\big) - x^{k+1} \in \gamma_k \partial r\big(x^{k+1}\big).$$

Или, если переписать в более привычном виде:

$$x^{k+1} \in x^k - \gamma_k \big(\nabla f\big(x^k\big) + \partial r\big(x^{k+1}\big)\big).$$

Получили неявную запись метода, из которой видно, что мы делаем шаг вдоль $\nabla f\big(x^k\big) + g$, где $g \in \partial r\big(x^{k+1}\big)$.

Утверждение Л1.5. Пусть $f : \mathbb{R}^d \to \mathbb{R} \cup \{+\infty\}$, $r : \mathbb{R}^d \to \mathbb{R} \cup \{+\infty\}$ — выпуклые функции. Тогда x^* — решение композитной задачи оптимизации тогда и только тогда, когда для любого $\gamma > 0$ выполнено:

$$x^* = \text{prox}_{\gamma r}\big(x^* - \gamma \nabla f\big(x^*\big)\big).$$

Доказательство. Обратимся к Утверждению Л1.3. Согласно нему, выражение

$$x^* = \text{prox}_{\gamma r}\big(x^* - \gamma \nabla f\big(x^*\big)\big)$$

эквивалентно записи:

$$x^* - \gamma \nabla f\big(x^*\big) - x^* \in \gamma \partial r\big(x^*\big).$$

Сокращаем на $\gamma > 0$ и получаем условие оптимальности:

$$0 \in \nabla f\big(x^*\big) + \partial r\big(x^*\big).$$

■

Теперь мы готовы доказывать теорему о скорости сходимости.

Теорема Л1.5. Пусть композитная задача оптимизации (Л1.3) с L–гладкой μ–сильно выпуклой целевой функцией f и выпуклой (необязательно гладкой) проксимально–дружественной функцией r решается с помощью проксимального градиентного метода (Алгоритм Л1.9). Тогда при $\gamma_k \leq \frac{1}{L}$ справедлива следующая оценка сходимости:

$$\left\|x^K - x^*\right\|_2^2 \leq \left(\prod_{k=0}^{K-1}\left(1 - \mu\gamma_k\right)\right)\left\|x^0 - x^*\right\|_2^2.$$

Доказательство. Рассматриваем $\left\|x^{k+1} - x^*\right\|_2^2$. Подставим итерацию метода:

$$\left\|x^{k+1} - x^*\right\|_2^2 = \left\|\operatorname{prox}_{\gamma_k r}\left(x^k - \gamma_k \nabla f\left(x^k\right)\right) - x^*\right\|_2^2.$$

Воспользуемся Утверждением Л1.5:

$$\left\|x^{k+1} - x^*\right\|_2^2 = \left\|\operatorname{prox}_{\gamma_k r}\left(x^k - \gamma_k \nabla f\left(x^k\right)\right) - \operatorname{prox}_{\gamma_k r}\left(x^* - \gamma_k \nabla f\left(x^*\right)\right)\right\|_2^2.$$

А теперь применяем неравенство из Утверждения Л1.4:

$$\left\|x^{k+1} - x^*\right\|_2^2 \leq \left\|\left(x^k - \gamma_k \nabla f\left(x^k\right)\right) - \left(x^* - \gamma_k \nabla f\left(x^*\right)\right)\right\|_2^2.$$

Раскрываем квадрат нормы:

$$\left\|x^{k+1} - x^*\right\|_2^2 \leq \left\|x^k - x^*\right\|_2^2 - 2\gamma_k\left\langle x^k - x^*, \nabla f\left(x^k\right) - \nabla f\left(x^*\right)\right\rangle + \gamma_k^2\left\|\nabla f\left(x^k\right) - \nabla f\left(x^*\right)\right\|_2^2.$$

Оценим последнее слагаемое, используя свойство L–гладкой выпуклой f (неравенство (**??**) из Теоремы **??**):

$$\begin{aligned}\left\|x^{k+1} - x^*\right\|_2^2 &\leq \left\|x^k - x^*\right\|_2^2 - 2\gamma_k\left\langle x^k - x^*, \nabla f\left(x^k\right) - \nabla f\left(x^*\right)\right\rangle \\ &\quad + \gamma_k^2 L\left\langle \nabla f\left(x^k\right) - \nabla f\left(x^*\right), x^k - x^*\right\rangle \\ &= \left\|x^k - x^*\right\|_2^2 - \gamma_k\left(2 - \gamma_k L\right)\left\langle \nabla f\left(x^k\right) - \nabla f\left(x^*\right), x^k - x^*\right\rangle.\end{aligned}$$

Два раза запишем определение μ–сильной выпуклости f (Определение **??**):

$$\begin{aligned}f\left(x^k\right) &\geq f\left(x^*\right) + \left\langle \nabla f\left(x^*\right), x^k - x^*\right\rangle + \frac{\mu}{2}\left\|x^k - x^*\right\|_2^2, \\ f\left(x^*\right) &\geq f\left(x^k\right) + \left\langle \nabla f\left(x^k\right), x^* - x^k\right\rangle + \frac{\mu}{2}\left\|x^* - x^k\right\|_2^2.\end{aligned} \tag{Л1.4}$$

Сложим их и получим:

$$\left\langle \nabla f\left(x^k\right) - \nabla f\left(x^*\right), x^k - x^*\right\rangle \geq \mu\left\|x^k - x^*\right\|_2^2.$$

Подставляем в основное неравенство (Л1.4):

$$\begin{aligned}\left\|x^{k+1} - x^*\right\|_2^2 &\leq \left\|x^k - x^*\right\|_2^2 - \mu\gamma_k\left(2 - \gamma_k L\right)\left\|x^k - x^*\right\|_2^2 \\ &= \left(1 - \mu\gamma_k\left(2 - \gamma_k L\right)\right)\left\|x^k - x^*\right\|_2^2.\end{aligned}$$

Поскольку $\gamma_k \leq \frac{1}{L}$, то $2 - \gamma_k L > 1$. Продолжая цепочку неравенств, имеем:

$$\left\|x^{k+1} - x^*\right\|_2^2 \leq \left(1 - \mu\gamma_k\right)\left\|x^k - x^*\right\|_2^2.$$

Остается лишь развернуть рекурсию с K-ой итерации по нулевую:

$$\begin{aligned}\left\|x^K - x^*\right\|_2^2 &\leq \left(1 - \mu\gamma_{K-1}\right)\left\|x^{K-1} - x^*\right\|_2^2 \\ &\leq \left(1 - \mu\gamma_{K-1}\right)\left(1 - \mu\gamma_{K-2}\right)\left\|x^{K-2} - x^*\right\|_2^2 \\ &\leq \dots \\ &\leq \left(\prod_{k=0}^{K-1}\left(1 - \mu\gamma_k\right)\right)\left\|x^0 - x^*\right\|_2^2.\end{aligned}$$

■

Утверждение Л1.6. Пусть задача удовлетворяет условиям Теоремы Л1.5 и выбрано значение шага $\gamma_k = \frac{1}{L}$. Тогда справедлива следующая оценка сходимости:

$$\left\|x^K - x^*\right\|_2^2 \leq \left(1 - \frac{\mu}{L}\right)^K \left\|x^0 - x^*\right\|_2^2.$$

Более того, чтобы добиться точности ε по аргументу $\left(\left\|x^K - x^*\right\|_2 \leq \varepsilon\right)$, необходимо

$$K = \mathcal{O}\left(\frac{L}{\mu}\log\frac{\left\|x^0 - x^*\right\|_2}{\varepsilon}\right) \text{ итераций.}$$

Доказательство. Повторяет доказательство Утверждения **??**. ■

Замечание Л1.6. Проксимальный градиентный спуск для композитной задачи с L–гладкой μ–сильно выпуклой функцией f и выпуклой проксимально-дружественной функцией r имеет такую же скорость сходимости, что и метод градиентного спуска для функции f (Теорема **??**). Свойства гладкости/негладкости r при этом не влияют.

Кажется, что положив $f \equiv 0$, с помощью такого метода можно решать любую негладкую задачу. Действительно, если разрешить приближенное вычисление проксимального оператора, то формально можно решать любую выпуклую негладкую задачу. Однако с теоретической точки зрения это не приводит к преимуществам по сравнению с субградиентным методом: для нахождения значения проксимального оператора приходится решать подзадачу, которая сама по себе требует использования дополнительного метода (например, того же субградиентного спуска).

Список литературы

[1] Timothy Dozat. Incorporating nesterov momentum into adam. ICLR Workshop, 2016. OpenReview; NAdam method.

[2] John Duchi, Elad Hazan, and Yoram Singer. Adaptive subgradient methods for online learning and stochastic optimization. *Journal of Machine Learning Research*, 12:2121–2159, 2011.

[3] Diederik P. Kingma and Jimmy Ba. Adam: A method for stochastic optimization. In *International Conference on Learning Representations*, 2015.

[4] Ilya Loshchilov and Frank Hutter. Decoupled weight decay regularization. In *International Conference on Learning Representations*, 2019.

[5] Tijmen Tieleman and Geoffrey Hinton. Lecture 6.5 – rmsprop: Divide the gradient by a running average of its recent magnitude. COURSERA: Neural Networks for Machine Learning, 2012.

[6] Rachel Ward, Xiaoxia Wu, and Léon Bottou. Adagrad stepsizes: Sharp convergence over nonconvex landscapes. *Journal of Machine Learning Research*, 21(1):1–30, 2020.