Негладкая оптимизация. Адаптивные методы

Методы оптимизации

Александр Безносиков

Московский физико-технический институт

22 октября 2026

ФПМИ

Негладкие задачи

- **Вопрос:** функция $f(x) = |x|$ выпукла?

Негладкие задачи

- **Вопрос:** функция $f(x) = |x|$ выпукла? По нашему определению с начала курса — нет. А почему?

Негладкие задачи

- **Вопрос:** функция $f(x) = |x|$ выпукла? По нашему определению с начала курса — нет. А почему? Потому что мы требовали дифференцируемость.
- Обобщим определение выпуклости

Определение

Рассмотрим функцию $f : \mathbb{R}^d \to \mathbb{R}$. *Функция* f *называется* ***выпуклой***, *если для любых* $x_1, \ldots, x_k \in \mathbb{R}^d$ *и любых* $\alpha_1, \ldots, \alpha_k$, $\alpha_i \geq 0$, $\sum\limits_{i=1}^{k} \alpha_i = 1$ *выполняется*

$$f\left(\sum_{i=1}^{k} \alpha_i x_i\right) \leq \sum_{i=1}^{k} \alpha_i f\left(x_i\right).$$

Негладкие задачи

- **Вопрос:** функция $f(x) = |x|$ выпукла? По нашему определению с начала курса — нет. А почему? Потому что мы требовали дифференцируемость.
- Обобщим определение выпуклости

Определение

Рассмотрим функцию $f : \mathbb{R}^d \to \mathbb{R}$. *Функция* f *называется* ***выпуклой***, *если для любых* $x_1, \ldots, x_k \in \mathbb{R}^d$ *и любых* $\alpha_1, \ldots, \alpha_k$, $\alpha_i \geq 0$, $\sum\limits_{i=1}^{k} \alpha_i = 1$ *выполняется*

$$f\left(\sum_{i=1}^{k} \alpha_i x_i\right) \leq \sum_{i=1}^{k} \alpha_i f\left(x_i\right).$$

- Получается, что даже довольно простые выпуклые задачи могут быть негладкими. До этого мы смотрели только на гладкие задачи.

Негладкие задачи

- Будем рассматривать следующее предположение вместо гладкости:

Определение

Пусть дана функция $f : \mathbb{R}^d \to \mathbb{R}$. *Будем говорить, что она является* M*–**липшицевой**, если для любых* $x, y \in \mathbb{R}^d$ *выполнено:*

$$\left|f\left(x\right) - f\left(y\right)\right| \leq M\left\|x - y\right\|_2.$$

Субградиент и субдифференциал

Если функция не дифференцируема в точке, то градиента нет. Что может существовать вместо градиента?

Субградиент и субдифференциал

Если функция не дифференцируема в точке, то градиента нет. Что может существовать вместо градиента?

Определение

Пусть дана выпуклая функция $f : \mathbb{R}^d \to \mathbb{R}$. *Вектор* $g \in \mathbb{R}^d$ *будем называть* ***субградиентом*** *функции* f *в точке* $x \in \mathbb{R}^d$, *если для любого* $y \in \mathbb{R}^d$ *выполнено*

$$f(y) \geq f(x) + \langle g, y - x \rangle.$$

Множество $\partial f(x)$ *всех субградиентов* f *в точке* x *называется* ***субдифференциалом***.

Условие оптимальности

Теорема

Точка x^* — минимум выпуклой функции f тогда и только тогда, когда

$$0 \in \partial f\left(x^*\right).$$

Условие оптимальности

Теорема

Точка x^* — минимум выпуклой функции f тогда и только тогда, когда

$$0 \in \partial f\left(x^*\right).$$

$\Leftarrow$ Если $f\left(x\right) \geq f\left(x^*\right)$ для любых $x \in \mathbb{R}^d$, то для вектора 0 выполнено

$$f\left(x\right) \geq f\left(x^*\right) + \left\langle 0, x - x^* \right\rangle$$

для любого $x \in \mathbb{R}^d$. Следовательно, $0 \in \partial f\left(x^*\right)$.

Условие оптимальности

Теорема

Точка x^* — минимум выпуклой функции f тогда и только тогда, когда

$$0 \in \partial f\left(x^*\right).$$

$\Leftarrow$ Если $f\left(x\right) \geq f\left(x^*\right)$ для любых $x \in \mathbb{R}^d$, то для вектора 0 выполнено

$$f\left(x\right) \geq f\left(x^*\right) + \left\langle 0, x - x^* \right\rangle$$

для любого $x \in \mathbb{R}^d$. Следовательно, $0 \in \partial f\left(x^*\right)$.

$\Rightarrow$ Пусть $0 \in \partial f\left(x^*\right)$. Тогда по определению субградиента:

$$f\left(x\right) \geq f\left(x^*\right) + \left\langle 0, x - x^* \right\rangle = f\left(x^*\right)$$

для любого $x \in \mathbb{R}^d$.

Свойство M–липшицевой функции

Теорема

Пусть дана выпуклая функция $f : \mathbb{R}^d \to \mathbb{R}$. Тогда функция f является M–липшицевой тогда и только тогда, когда для любого $x \in \mathbb{R}^d$ и $g \in \partial f(x)$ имеем $\|g\|_2 \leq M$.

Свойство M–липшицевой функции

Теорема

Пусть дана выпуклая функция $f : \mathbb{R}^d \to \mathbb{R}$. Тогда функция f является M–липшицевой тогда и только тогда, когда для любого $x \in \mathbb{R}^d$ и $g \in \partial f(x)$ имеем $\|g\|_2 \leq M$.

$\Leftarrow$ Рассмотрим $g \in \partial f(x)$, тогда по определению субградиента:

$$f(y) - f(x) \geq \langle g, y - x \rangle.$$

Свойство M–липшицевой функции

Теорема

Пусть дана выпуклая функция $f : \mathbb{R}^d \to \mathbb{R}$. Тогда функция f является M–липшицевой тогда и только тогда, когда для любого $x \in \mathbb{R}^d$ и $g \in \partial f(x)$ имеем $\|g\|_2 \leq M$.

$\Leftarrow$ Рассмотрим $g \in \partial f(x)$, тогда по определению субградиента:

$$f(y) - f(x) \geq \langle g, y - x \rangle.$$

Из M–липшицевости f:

$$M\|y - x\|_2 \geq f(y) - f(x) \geq \langle g, y - x \rangle.$$

Свойство M–липшицевой функции

Теорема

Пусть дана выпуклая функция $f : \mathbb{R}^d \to \mathbb{R}$. Тогда функция f является M–липшицевой тогда и только тогда, когда для любого $x \in \mathbb{R}^d$ и $g \in \partial f(x)$ имеем $\|g\|_2 \leq M$.

$\Leftarrow$ Рассмотрим $g \in \partial f(x)$, тогда по определению субградиента:

$$f(y) - f(x) \geq \langle g, y - x \rangle.$$

Из M–липшицевости f:

$$M\|y - x\|_2 \geq f(y) - f(x) \geq \langle g, y - x \rangle.$$

Возьмем $y = g + x \in \mathbb{R}^d$, тогда

$$M\|g\|_2 = M\|y - x\|_2 \geq \langle g, y - x \rangle = \|g\|_2^2.$$

Свойство M–липшицевой функции

Теорема

Пусть дана выпуклая функция $f : \mathbb{R}^d \to \mathbb{R}$. Тогда функция f является M–липшицевой тогда и только тогда, когда для любого $x \in \mathbb{R}^d$ и $g \in \partial f(x)$ имеем $\|g\|_2 \leq M$.

$\Leftarrow$ Рассмотрим $g \in \partial f(x)$, тогда по определению субградиента:

$$f(y) - f(x) \geq \langle g, y - x \rangle.$$

Из M–липшицевости f:

$$M\|y - x\|_2 \geq f(y) - f(x) \geq \langle g, y - x \rangle.$$

Возьмем $y = g + x \in \mathbb{R}^d$, тогда

$$M\|g\|_2 = M\|y - x\|_2 \geq \langle g, y - x \rangle = \|g\|_2^2.$$

Откуда и получаем: $\|g\|_2 \leq M$.

Доказательство

$\Leftarrow$ Рассмотрим $g \in \partial f\left(x\right)$, тогда по определению субградиента:

$$f(x) - f(y) \leq \left\langle g, x - y \right\rangle.$$

Доказательство

$\Leftarrow$ Рассмотрим $g \in \partial f(x)$, тогда по определению субградиента:

$$f(x) - f(y) \leq \langle g, x - y \rangle.$$

Используем неравенство Коши–Буняковского–Шварца:

$$f(x) - f(y) \leq \|g\|_2 \|x - y\|_2.$$

Доказательство

$\Leftarrow$ Рассмотрим $g \in \partial f(x)$, тогда по определению субградиента:

$$f(x) - f(y) \leq \langle g, x - y \rangle.$$

Используем неравенство Коши–Буняковского–Шварца:

$$f(x) - f(y) \leq \|g\|_2 \|x - y\|_2.$$

Воспользуемся предположением об ограниченности нормы субградиента и получим:

$$f(x) - f(y) \leq M\|x - y\|_2.$$

Доказательство

$\Leftarrow$ Рассмотрим $g \in \partial f(x)$, тогда по определению субградиента:

$$f(x) - f(y) \leq \langle g, x - y \rangle.$$

Используем неравенство Коши–Буняковского–Шварца:

$$f(x) - f(y) \leq \|g\|_2 \|x - y\|_2.$$

Воспользуемся предположением об ограниченности нормы субградиента и получим:

$$f(x) - f(y) \leq M\|x - y\|_2.$$

Если переобозначить $x \to y$, $y \to x$, то можем записать:

$$f(y) - f(x) \leq M\|y - x\|_2.$$

Доказательство

$\Leftarrow$ Рассмотрим $g \in \partial f(x)$, тогда по определению субградиента:

$$f(x) - f(y) \leq \langle g, x - y \rangle.$$

Используем неравенство Коши–Буняковского–Шварца:

$$f(x) - f(y) \leq \|g\|_2 \|x - y\|_2.$$

Воспользуемся предположением об ограниченности нормы субградиента и получим:

$$f(x) - f(y) \leq M\|x - y\|_2.$$

Если переобозначить $x \to y$, $y \to x$, то можем записать:

$$f(y) - f(x) \leq M\|y - x\|_2.$$

Если объединить оба неравенства, то можем прийти к более краткой записи:

$$|f(y) - f(x)| \leq M\|x - y\|_2.$$

Субградиентный метод

Рассматриваем безусловную задачу:

$$\min_{x \in \mathbb{R}^d} f(x),$$

где функция f выпуклая на $\mathbb{R}^d$ и M–липшицева.

Субградиентный метод

Рассматриваем безусловную задачу:

$$\min_{x \in \mathbb{R}^d} f(x),$$

где функция f выпуклая на $\mathbb{R}^d$ и M–липшицева.
Простая идея — снова модифицировать градиентный спуск, теперь вместо градиента используя какой-то субградиент в текущей точке:

Алгоритм Субградиентный метод

Вход: стартовая точка $x^0 \in \mathbb{R}^d$, размеры шагов $\{\gamma_k\}_{k=0} > 0$, количество итераций K

1: **for** $k = 0, 1, \ldots, K-1$ **do**
2: Вычислить $g^k \in \partial f(x^k)$
3: $x^{k+1} = x^k - \gamma_k g^k$
4: **end for**

Выход: $\frac{1}{K} \sum_{k=0}^{K-1} x^k$

Сходимость

Раскроем квадрат нормы:

$$\begin{aligned}\left\|x^{k+1} - x^*\right\|_2^2 &= \left\|x^k - \gamma g^k - x^*\right\|_2^2 \\ &= \left\|x^k - x^*\right\|_2^2 - 2\gamma\left\langle g^k, x^k - x^*\right\rangle + \gamma^2\left\|g^k\right\|_2^2.\end{aligned}$$

Сходимость

Раскроем квадрат нормы:

$$\begin{aligned}\left\|x^{k+1} - x^*\right\|_2^2 &= \left\|x^k - \gamma g^k - x^*\right\|_2^2 \\ &= \left\|x^k - x^*\right\|_2^2 - 2\gamma\left\langle g^k, x^k - x^*\right\rangle + \gamma^2\left\|g^k\right\|_2^2.\end{aligned}$$

Из M–липшицевости f следует, что норма субградиента g^k ограничена:

$$\left\|x^{k+1} - x^*\right\|_2^2 \leq \left\|x^k - x^*\right\|_2^2 - 2\gamma\left\langle g^k, x^k - x^*\right\rangle + \gamma^2 M^2.$$

Сходимость

Раскроем квадрат нормы:

$$\begin{aligned}\left\|x^{k+1} - x^*\right\|_2^2 &= \left\|x^k - \gamma g^k - x^*\right\|_2^2 \\ &= \left\|x^k - x^*\right\|_2^2 - 2\gamma\left\langle g^k, x^k - x^*\right\rangle + \gamma^2\left\|g^k\right\|_2^2.\end{aligned}$$

Из M–липшицевости f следует, что норма субградиента g^k ограничена:

$$\left\|x^{k+1} - x^*\right\|_2^2 \leq \left\|x^k - x^*\right\|_2^2 - 2\gamma\left\langle g^k, x^k - x^*\right\rangle + \gamma^2 M^2.$$

Из определения субградиента оценим скалярное произведение:

$$\left\|x^{k+1} - x^*\right\|_2^2 \leq \left\|x^k - x^*\right\|_2^2 - 2\gamma\left(f\left(x^k\right) - f^*\right) + \gamma^2 M^2.$$

Сходимость

Раскроем квадрат нормы:

$$\begin{aligned}\left\|x^{k+1}-x^*\right\|_2^2 &= \left\|x^k-\gamma g^k-x^*\right\|_2^2 \\ &= \left\|x^k-x^*\right\|_2^2 - 2\gamma\left\langle g^k, x^k-x^*\right\rangle + \gamma^2\left\|g^k\right\|_2^2.\end{aligned}$$

Из M–липшицевости f следует, что норма субградиента g^k ограничена:

$$\left\|x^{k+1}-x^*\right\|_2^2 \leq \left\|x^k-x^*\right\|_2^2 - 2\gamma\left\langle g^k, x^k-x^*\right\rangle + \gamma^2 M^2.$$

Из определения субградиента оценим скалярное произведение:

$$\left\|x^{k+1}-x^*\right\|_2^2 \leq \left\|x^k-x^*\right\|_2^2 - 2\gamma\left(f\left(x^k\right)-f^*\right) + \gamma^2 M^2.$$

Перенесем разность значений функции f влево, а норму вправо:

$$2\gamma\left(f\left(x^k\right)-f^*\right) \leq \left\|x^k-x^*\right\|_2^2 - \left\|x^{k+1}-x^*\right\|_2^2 + \gamma^2 M^2.$$

Сходимость

Просуммируем по всем k от 0 до $K-1$:

$$2\gamma \sum_{k=0}^{K-1} \left(f\left(x^k\right) - f^* \right) \leq \sum_{k=0}^{K-1} \left(\left\| x^k - x^* \right\|_2^2 - \left\| x^{k+1} - x^* \right\|_2^2 + \gamma^2 M^2 \right).$$

Сходимость

Просуммируем по всем k от 0 до $K-1$:

$$2\gamma \sum_{k=0}^{K-1} \left(f\left(x^k\right) - f^* \right) \leq \sum_{k=0}^{K-1} \left(\left\| x^k - x^* \right\|_2^2 - \left\| x^{k+1} - x^* \right\|_2^2 + \gamma^2 M^2 \right).$$

Раскроем телескопическую сумму и воспользуемся выпуклостью f:

$$f\left(\frac{1}{K} \sum_{k=0}^{K-1} x^k \right) - f^* \leq \frac{\left\| x^0 - x^* \right\|_2^2 - \left\| x^K - x^* \right\|_2^2}{2\gamma K} + \frac{\gamma M^2}{2}.$$

Сходимость

Просуммируем по всем k от 0 до $K-1$:

$$2\gamma \sum_{k=0}^{K-1} \left(f\left(x^k\right) - f^* \right) \leq \sum_{k=0}^{K-1} \left(\left\| x^k - x^* \right\|_2^2 - \left\| x^{k+1} - x^* \right\|_2^2 + \gamma^2 M^2 \right).$$

Раскроем телескопическую сумму и воспользуемся выпуклостью f:

$$f\left(\frac{1}{K} \sum_{k=0}^{K-1} x^k \right) - f^* \leq \frac{\left\| x^0 - x^* \right\|_2^2 - \left\| x^K - x^* \right\|_2^2}{2\gamma K} + \frac{\gamma M^2}{2}.$$

Минимизируя правую часть, при $\gamma^* = \frac{\left\| x^0 - x^* \right\|_2}{M\sqrt{K}}$, получаем:

$$f\left(\frac{1}{K} \sum_{k=0}^{K-1} x^k \right) - f^* \leq \frac{M \left\| x^0 - x^* \right\|_2}{\sqrt{K}}.$$

Сходимость

Теорема

Пусть задача безусловной оптимизации с M–липшицевой выпуклой целевой функцией f решается с помощью субградиентного метода.

Тогда при $\gamma_k = \frac{\left\|x^0 - x^*\right\|_2}{M\sqrt{K}}$ *справедлива следующая оценка сходимости:*

$$f\left(\frac{1}{K}\sum_{k=0}^{K-1} x^k\right) - f^* \leq \frac{M\left\|x^0 - x^*\right\|_2}{\sqrt{K}}.$$

Итог

- Обобщение градиентного спуска на негладкие задачи.

Итог

- Обобщение градиентного спуска на негладкие задачи.
- Оценки сходимости в выпуклом случае: $\sim \frac{1}{\sqrt{K}}$, в сильно выпуклом случае: $\sim \frac{1}{K}$. **Вопрос:** какие были у градиентного спуска в гладком случае?

Итог

- Обобщение градиентного спуска на негладкие задачи.
- Оценки сходимости в выпуклом случае: $\sim \frac{1}{\sqrt{K}}$, в сильно выпуклом случае: $\sim \frac{1}{K}$. **Вопрос:** какие были у градиентного спуска в гладком случае? $\sim \frac{1}{K}$ и линейная соответственно. Сходимость медленнее.

Итог

- Обобщение градиентного спуска на негладкие задачи.
- Оценки сходимости в выпуклом случае: $\sim \frac{1}{\sqrt{K}}$, в сильно выпуклом случае: $\sim \frac{1}{K}$. **Вопрос:** какие были у градиентного спуска в гладком случае? $\sim \frac{1}{K}$ и линейная соответственно. Сходимость медленнее.
- Можно ли улучшить результат? Например, улучшить анализ или использовать моментум.

Итог

- Обобщение градиентного спуска на негладкие задачи.
- Оценки сходимости в выпуклом случае: $\sim \frac{1}{\sqrt{K}}$, в сильно выпуклом случае: $\sim \frac{1}{K}$. **Вопрос:** какие были у градиентного спуска в гладком случае? $\sim \frac{1}{K}$ и линейная соответственно. Сходимость медленнее.
- Можно ли улучшить результат? Например, улучшить анализ или использовать моментум. В общем случае результат для субградиентного метода является неулучшаемым для выпуклых и сильно выпуклых задач, то есть он оптимален.

Итог

- Обобщение градиентного спуска на негладкие задачи.
- Оценки сходимости в выпуклом случае: $\sim \frac{1}{\sqrt{K}}$, в сильно выпуклом случае: $\sim \frac{1}{K}$. **Вопрос:** какие были у градиентного спуска в гладком случае? $\sim \frac{1}{K}$ и линейная соответственно. Сходимость медленнее.
- Можно ли улучшить результат? Например, улучшить анализ или использовать моментум. В общем случае результат для субградиентного метода является неулучшаемым для выпуклых и сильно выпуклых задач, то есть он оптимален. **Вопрос:** а что в невыпуклом случае?

Итог

- Обобщение градиентного спуска на негладкие задачи.
- Оценки сходимости в выпуклом случае: $\sim \frac{1}{\sqrt{K}}$, в сильно выпуклом случае: $\sim \frac{1}{K}$. **Вопрос:** какие были у градиентного спуска в гладком случае? $\sim \frac{1}{K}$ и линейная соответственно. Сходимость медленнее.
- Можно ли улучшить результат? Например, улучшить анализ или использовать моментум. В общем случае результат для субградиентного метода является неулучшаемым для выпуклых и сильно выпуклых задач, то есть он оптимален. **Вопрос:** а что в невыпуклом случае? С этого мы начинали курс — лучше, чем полный перебор, ничего не придумать.

Адаптивные методы

В полученной оценке для субградиентного метода шаг выбирается равным

$$\gamma = \frac{\left\|x^0 - x^*\right\|_2}{M\sqrt{K}}.$$

Вопрос: какие есть проблемы у такого шага?

Адаптивные методы

В полученной оценке для субградиентного метода шаг выбирается равным

$$\gamma = \frac{\left\|x^0 - x^*\right\|_2}{M\sqrt{K}}.$$

Вопрос: какие есть проблемы у такого шага? Такая формула требует знания заранее числа итераций K, константы Липшица M и расстояния $\left\|x^0 - x^*\right\|_2$ до решения. На практике эти параметры обычно неизвестны, и их использование существенно ограничивает применимость метода.

AdaGradNorm

- Избавимся от необходимости знать константу Липшица M.

AdaGradNorm

- Избавимся от необходимости знать константу Липшица M. Так как субградиент ограничен, то можем оценить $M \sim \|g\|_2$.

AdaGradNorm

- Избавимся от необходимости знать константу Липшица M. Так как субградиент ограничен, то можем оценить $M \sim \|g\|_2$.
- Однако этого недостаточно: в оптимальном значении шага в знаменателе стоит $M\sqrt{K}$. Тогда мы можем брать норму не одного субградиента в какой-то точке, а суммировать по всем предыдущим:

$$M\sqrt{K} \sim \sqrt{\sum_{t=0}^{K-1} \|g^t\|_2^2}.$$

AdaGradNorm

- Избавимся от необходимости знать константу Липшица M. Так как субградиент ограничен, то можем оценить $M \sim \|g\|_2$.
- Однако этого недостаточно: в оптимальном значении шага в знаменателе стоит $M\sqrt{K}$. Тогда мы можем брать норму не одного субградиента в какой-то точке, а суммировать по всем предыдущим:

$$M\sqrt{K} \sim \sqrt{\sum_{t=0}^{K-1} \|g^t\|_2^2}.$$

- Неизвестным остается только расстояние до решения $\|x^0 - x^*\|_2$. Его можно оценить лишь какой-то константой D, на практике часто подбираемой эмпирически:

$$\|x^0 - x^*\|_2 \leq D.$$

AdaGradNorm

Алгоритм AdaGradNorm

Вход: стартовая точка $x^0 \in \mathbb{R}^d$, сумма квадратов норм субградиентов $G^{-1} = 0$, параметры $\varepsilon \sim 10^{-8}$, $D > 0$, количество итераций K

1: **for** $k = 0, 1, \ldots, K-1$ **do**

2: Вычислить $g^k \in \partial f\left(x^k\right)$

3: $G^k = G^{k-1} + \left\|g^k\right\|_2^2$

4: $x^{k+1} = x^k - \frac{D}{\sqrt{G^k + \varepsilon}} g^k$

5: **end for**

Выход: $\frac{1}{K}\sum_{k=0}^{K-1} x^k$

DoG: Distance over Gradients

В методе AdaGradNorm шаг имеет вид

$$\gamma_k = \frac{D}{\sqrt{\sum_{t=0}^{k} \left\|g^t\right\|_2^2 + \varepsilon}},$$

где $D = \left\|x^0 - x^*\right\|_2$ остаётся неизвестным параметром.

DoG: Distance over Gradients

В методе AdaGradNorm шаг имеет вид

$$\gamma_k = \frac{D}{\sqrt{\sum_{t=0}^{k} \left\|g^t\right\|_2^2 + \varepsilon}},$$

где $D = \left\|x^0 - x^*\right\|_2$ остаётся неизвестным параметром.
Для его замены предлагается использовать наблюдаемую величину

$$d_k = \max_{t=\overline{0,k}} \left\|x^t - x^0\right\|_2.$$

DoG: Distance over Gradients

Алгоритм DoG (Distance over Gradients)

Вход: стартовая точка $x^0 \in \mathbb{R}^d$, сумма квадратов норм субградиентов $G^{-1} = 0$, оценка диаметра $d_{-1} > 0$, параметр $\varepsilon \sim 10^{-8}$, количество итераций K

1: **for** $k = 0, 1, \ldots, K-1$ **do**

2: Вычислить $g^k \in \partial f\left(x^k\right)$

3: $G^k = G^{k-1} + \left\|g^k\right\|_2^2$

4: $d_k = \max\left(d_{k-1}, \left\|x^k - x^0\right\|_2\right)$

5: $x^{k+1} = x^k - \frac{d_k}{\sqrt{G^k + \varepsilon}} g^k$

6: **end for**

Выход: $\frac{1}{K}\sum_{k=0}^{K-1} x^k$

AdaGrad

Следующий шаг — учесть неоднородность по координатам. Тогда шаг для каждой координаты берётся как

$$\gamma_{k,i} = \frac{D_i}{\sqrt{\sum_{t=0}^{k} \left(g_i^t\right)^2 + \varepsilon}}.$$

AdaGrad

Алгоритм AdaGrad

Вход: стартовая точка $x^0 \in \mathbb{R}^d$, суммы квадратов компонент субградиентов $G_i^{-1} = 0$, параметры $\varepsilon \sim 10^{-8}$, $D_i > 0$, количество итераций K

1: **for** $k = 0, 1, \ldots, K-1$ **do**

2: Вычислить $g^k \in \partial f\left(x^k\right)$

3: $G_i^k = G_i^{k-1} + \left(g_i^k\right)^2$

4: $x_i^{k+1} = x_i^k - \frac{D_i}{\sqrt{G_i^k + \varepsilon}} g_i^k$

5: **end for**

Выход: $\frac{1}{K} \sum_{k=0}^{K-1} x^k$

Сходимость

Распишем шаг по каждой координате:

$$\begin{aligned}\left(x_i^{k+1} - x_i^*\right)^2 &= \left(x_i^k - \gamma_{k,i} g_i^k - x_i^*\right)^2 \\ &= \left(x_i^k - x_i^*\right)^2 - 2\gamma_{k,i} g_i^k (x_i^k - x_i^*) + \gamma_{k,i}^2 \left(g_i^k\right)^2.\end{aligned}$$

Сходимость

Распишем шаг по каждой координате:

$$\begin{aligned}\left(x_i^{k+1} - x_i^*\right)^2 &= \left(x_i^k - \gamma_{k,i} g_i^k - x_i^*\right)^2 \\ &= \left(x_i^k - x_i^*\right)^2 - 2\gamma_{k,i} g_i^k (x_i^k - x_i^*) + \gamma_{k,i}^2 \left(g_i^k\right)^2.\end{aligned}$$

Откуда выражаем перекрестное слагаемое:

$$g_i^k \left(x_i^k - x_i^*\right) = \frac{1}{2\gamma_{k,i}} \left(x_i^k - x_i^*\right)^2 - \frac{1}{2\gamma_{k,i}} \left(x_i^{k+1} - x_i^*\right)^2 + \frac{\gamma_{k,i}}{2} \left(g_i^k\right)^2.$$

Сходимость

Распишем шаг по каждой координате:

$$\begin{aligned}\left(x_i^{k+1} - x_i^*\right)^2 &= \left(x_i^k - \gamma_{k,i} g_i^k - x_i^*\right)^2 \\ &= \left(x_i^k - x_i^*\right)^2 - 2\gamma_{k,i} g_i^k (x_i^k - x_i^*) + \gamma_{k,i}^2 \left(g_i^k\right)^2.\end{aligned}$$

Откуда выражаем перекрестное слагаемое:

$$g_i^k \left(x_i^k - x_i^*\right) = \frac{1}{2\gamma_{k,i}} \left(x_i^k - x_i^*\right)^2 - \frac{1}{2\gamma_{k,i}} \left(x_i^{k+1} - x_i^*\right)^2 + \frac{\gamma_{k,i}}{2} \left(g_i^k\right)^2.$$

Собираем скалярное произведение, суммируя по всем координатам i от 1 до d:

$$\left\langle g^k, x^k - x^* \right\rangle = \frac{1}{2} \sum_{i=1}^{d} \left[\frac{1}{\gamma_{k,i}} \left(x_i^k - x_i^*\right)^2 - \frac{1}{\gamma_{k,i}} \left(x_i^{k+1} - x_i^*\right)^2 + \gamma_{k,i} \left(g_i^k\right)^2 \right].$$

Сходимость

Оцениваем левую часть, пользуясь определением субградиента:

$$f\left(x^k\right) - f^* \leq \frac{1}{2}\sum_{i=1}^{d}\left[\frac{1}{\gamma_{k,i}}\left(x_i^k - x_i^*\right)^2 - \frac{1}{\gamma_{k,i}}\left(x_i^{k+1} - x_i^*\right)^2 + \gamma_{k,i}\left(g_i^k\right)^2\right].$$

Сходимость

Оцениваем левую часть, пользуясь определением субградиента:

$$f\left(x^k\right) - f^* \leq \frac{1}{2}\sum_{i=1}^{d}\left[\frac{1}{\gamma_{k,i}}\left(x_i^k - x_i^*\right)^2 - \frac{1}{\gamma_{k,i}}\left(x_i^{k+1} - x_i^*\right)^2 + \gamma_{k,i}\left(g_i^k\right)^2\right].$$

Суммируем по всем k от 0 до $K-1$ и усредняем, а также меняем порядок суммирования:

$$\begin{aligned}
&\frac{1}{K}\sum_{k=0}^{K-1}\left(f\left(x^k\right) - f^*\right) \\
&\quad\leq \frac{1}{2K}\sum_{k=0}^{K-1}\sum_{i=1}^{d}\left[\frac{1}{\gamma_{k,i}}\left(x_i^k - x_i^*\right)^2 - \frac{1}{\gamma_{k,i}}\left(x_i^{k+1} - x_i^*\right)^2 + \gamma_{k,i}\left(g_i^k\right)^2\right] \\
&\quad= \frac{1}{2K}\sum_{i=1}^{d}\sum_{k=0}^{K-1}\left[\frac{1}{\gamma_{k,i}}\left(x_i^k - x_i^*\right)^2 - \frac{1}{\gamma_{k,i}}\left(x_i^{k+1} - x_i^*\right)^2 + \gamma_{k,i}\left(g_i^k\right)^2\right].
\end{aligned}$$

Сходимость

Сдвинем индекс суммирования k и положим $\gamma_{-1,i} = +\infty$:

$$\frac{1}{K}\sum_{k=0}^{K-1}\left(f\left(x^k\right) - f^*\right)$$

$$\leq \frac{1}{2K}\sum_{i=1}^{d}\sum_{k=0}^{K-1}\left[\frac{1}{\gamma_{k,i}}\left(x_i^k - x_i^*\right)^2 + \gamma_{k,i}\left(g_i^k\right)^2\right]$$

$$- \frac{1}{2K}\sum_{i=1}^{d}\sum_{k=0}^{K-1}\left[\frac{1}{\gamma_{k,i}}\left(x_i^{k+1} - x_i^*\right)^2\right]$$

$$= \frac{1}{2K}\sum_{i=1}^{d}\sum_{k=0}^{K-1}\left[\frac{1}{\gamma_{k,i}}\left(x_i^k - x_i^*\right)^2 + \gamma_{k,i}\left(g_i^k\right)^2\right]$$

$$- \frac{1}{2K}\sum_{i=1}^{d}\sum_{k=0}^{K-1}\left[\frac{1}{\gamma_{k-1,i}}\left(x_i^k - x_i^*\right)^2\right] - \frac{1}{2K}\sum_{i=1}^{d}\frac{1}{\gamma_{K-1,i}}\left(x_i^K - x_i^*\right)^2$$

$$\leq \frac{1}{2K}\sum_{i=1}^{d}\sum_{k=0}^{K-1}\left[\left(\frac{1}{\gamma_{k,i}} - \frac{1}{\gamma_{k-1,i}}\right)\left(x_i^k - x_i^*\right)^2 + \gamma_{k,i}\left(g_i^k\right)^2\right].$$

Сходимость

Так как G_i^k не убывает, то $\frac{1}{\gamma_{k,i}} - \frac{1}{\gamma_{k-1,i}} \geq 0$. Воспользуемся константами $D_i : \left(x_i^k - x_i^*\right)^2 \leq D_i^2$:

$$\frac{1}{K}\sum_{k=0}^{K-1}\left(f\left(x^k\right) - f^*\right) \leq \frac{1}{2K}\sum_{i=1}^{d}\sum_{k=0}^{K-1}\left[\left(\frac{1}{\gamma_{k,i}} - \frac{1}{\gamma_{k-1,i}}\right)D_i^2 + \gamma_{k,i}\left(g_i^k\right)^2\right].$$

Сходимость

Так как G_i^k не убывает, то $\frac{1}{\gamma_{k,i}} - \frac{1}{\gamma_{k-1,i}} \geq 0$. Воспользуемся константами $D_i : \left(x_i^k - x_i^*\right)^2 \leq D_i^2$:

$$\frac{1}{K}\sum_{k=0}^{K-1}\left(f\left(x^k\right) - f^*\right) \leq \frac{1}{2K}\sum_{i=1}^{d}\sum_{k=0}^{K-1}\left[\left(\frac{1}{\gamma_{k,i}} - \frac{1}{\gamma_{k-1,i}}\right)D_i^2 + \gamma_{k,i}\left(g_i^k\right)^2\right].$$

Подставим $\gamma_{k,i} = \frac{D_i}{\sqrt{\sum_{t=0}^{k}\left(g_i^t\right)^2}}$ и свернём телескопическую сумму:

$$\frac{1}{K}\sum_{k=0}^{K-1}\left(f\left(x^k\right) - f^*\right) \leq \frac{1}{2K}\sum_{i=1}^{d} D_i\left[\sqrt{\sum_{t=0}^{K-1}\left(g_i^t\right)^2} + \sum_{k=0}^{K-1}\frac{\left(g_i^k\right)^2}{\sqrt{\sum_{t=0}^{k}\left(g_i^t\right)^2}}\right].$$

Сходимость

Воспользуемся техническим фактом, который говорит, что для любых неотрицательных чисел $\{a_k\} \geq 0$ выполнено:

$$\sum_{k=0}^{K-1} \frac{a_k^2}{\sqrt{\sum_{t=0}^{k} a_t^2}} \leq 2\sqrt{\sum_{k=0}^{K-1} a_k^2}.$$

Сходимость

Воспользуемся техническим фактом, который говорит, что для любых неотрицательных чисел $\{a_k\} \geq 0$ выполнено:

$$\sum_{k=0}^{K-1} \frac{a_k^2}{\sqrt{\sum_{t=0}^{k} a_t^2}} \leq 2\sqrt{\sum_{k=0}^{K-1} a_k^2}.$$

Применяем его для второго слагаемого в сумме, получаем:

$$\frac{1}{K}\sum_{k=0}^{K-1}\left(f\left(x^k\right) - f^*\right) \leq \frac{3}{2K}\sum_{i=1}^{d} D_i \sqrt{\sum_{t=0}^{K-1}\left(g_i^t\right)^2}.$$

Сходимость

Из неизвестных значений в правой части остается только $\sum_{t=0}^{K-1} \left(g_i^t\right)^2$.
Оценим её с помощью свойства M–липшицевых функций:

$$\sum_{t=0}^{K-1} \left(g_i^t\right)^2 \leq \sum_{t=0}^{K-1} \left\|g^t\right\|_2^2 \leq KM^2.$$

Сходимость

Из неизвестных значений в правой части остается только $\sum_{t=0}^{K-1} \left(g_i^t\right)^2$.
Оценим её с помощью свойства M–липшицевых функций:

$$\sum_{t=0}^{K-1} \left(g_i^t\right)^2 \leq \sum_{t=0}^{K-1} \left\|g^t\right\|_2^2 \leq KM^2.$$

Подставляем в основное неравенство:

$$\frac{1}{K}\sum_{k=0}^{K-1}\left(f\left(x^k\right) - f^*\right) \leq \frac{3}{2K}\sum_{i=1}^{d} D_i\sqrt{KM^2} = \frac{3M}{2\sqrt{K}}\sum_{i=1}^{d} D_i = \frac{3M\tilde{D}}{2\sqrt{K}}.$$

Сходимость

Из неизвестных значений в правой части остается только $\sum_{t=0}^{K-1} \left(g_i^t\right)^2$. Оценим её с помощью свойства M–липшицевых функций:

$$\sum_{t=0}^{K-1} \left(g_i^t\right)^2 \leq \sum_{t=0}^{K-1} \left\|g^t\right\|_2^2 \leq KM^2.$$

Подставляем в основное неравенство:

$$\frac{1}{K} \sum_{k=0}^{K-1} \left(f\left(x^k\right) - f^*\right) \leq \frac{3}{2K} \sum_{i=1}^{d} D_i \sqrt{KM^2} = \frac{3M}{2\sqrt{K}} \sum_{i=1}^{d} D_i = \frac{3M\tilde{D}}{2\sqrt{K}}.$$

Чтобы получить оценку из теоремы, остается применить неравенство Йенсена:

$$f\left(\frac{1}{K} \sum_{k=0}^{K-1} x^k\right) - f^* \leq \frac{3M\tilde{D}}{2\sqrt{K}}.$$

Сходимость

Теорема

Пусть задача оптимизации с M–липшицевой выпуклой целевой функцией f решается с помощью AdaGrad. Тогда справедлива следующая оценка сходимости:

$$f\left(\frac{1}{K}\sum_{k=0}^{K-1} x^k\right) - f^* \leq \frac{3M\tilde{D}}{2\sqrt{K}},$$

где $\tilde{D} = \sum_{i=1}^{d} D_i$, $\left|x_i^k - x_i^*\right| \leq D_i$.
Более того, чтобы добиться точности ε *по функции, достаточно*

$$K = \mathcal{O}\left(\frac{M^2\tilde{D}^2}{\varepsilon^2}\right) \quad \text{итераций.}$$

RMSProp

- Проблема AdaGrad в том, что старые градиенты в шаге могут быть уже не особо релевантны. **Вопрос:** как можно попробовать их «забывать»?

RMSProp

- Проблема AdaGrad в том, что старые градиенты в шаге могут быть уже не особо релевантны. **Вопрос:** как можно попробовать их «забывать»?
- Чтобы избежать затухания шага, вместо суммы используют экспоненциальное скользящее среднее квадратов градиентов:

$$G_i^k = \beta G_i^{k-1} + (1-\beta)\left(g_i^k\right)^2,$$

где моментум $\beta \in [0, 1]$ выбирается порядка 0.99.

RMSProp

Алгоритм RMSProp

Вход: стартовая точка $x^0 \in \mathbb{R}^d$, сглаженные суммы квадратов компонент субградиентов $G_i^{-1} = 0$, параметры $\varepsilon \sim 10^{-8}$, $D_i > 0$, $\beta \in [0, 1]$, количество итераций K

1: **for** $k = 0, 1, \ldots, K-1$ **do**

2: Вычислить $g^k \in \partial f\left(x^k\right)$

3: $G_i^k = \beta G_i^{k-1} + (1-\beta)\left(g_i^k\right)^2$

4: $x_i^{k+1} = x_i^k - \frac{D_i}{\sqrt{G_i^k + \varepsilon}} g_i^k$

5: **end for**

Выход: $\frac{1}{K}\sum_{k=0}^{K-1} x^k$

Adam

- Алгоритм Adam объединяет идеи RMSProp и моментума. Помимо экспоненциального сглаживания квадратов градиентов, он усредняет сами градиенты:

$$v^k = \beta_1 v^{k-1} + (1-\beta_1) g^k,$$
$$G_i^k = \beta_2 G_i^{k-1} + (1-\beta_2)\left(g_i^k\right)^2,$$

где два моментума $\beta_1, \beta_2 \in [0, 1]$ обычно выбираются 0.9 и 0.999.

Adam

- Алгоритм Adam объединяет идеи RMSProp и моментума. Помимо экспоненциального сглаживания квадратов градиентов, он усредняет сами градиенты:

$$v^k = \beta_1 v^{k-1} + (1-\beta_1) g^k,$$
$$G_i^k = \beta_2 G_i^{k-1} + (1-\beta_2)\left(g_i^k\right)^2,$$

где два моментума $\beta_1, \beta_2 \in [0, 1]$ обычно выбираются 0.9 и 0.999.

- Чтобы устранить смещение на ранних итерациях, вводится коррекция:

$$\hat{v}^k = \frac{v^k}{1-\beta_1^{k+1}},$$
$$\widehat{G}_i^k = \frac{G_i^k}{1-\beta_2^{k+1}}.$$

Adam

Алгоритм Adam

Вход: стартовая точка $x^0 \in \mathbb{R}^d$, сглаженные суммы квадратов компонент субградиентов $G_i^{-1} = 0$, сглаженные суммы субградиентов $v^{-1} = 0$, параметры $\beta_1, \beta_2 \in [0, 1]$, $\varepsilon \sim 10^{-8}$, $D_i > 0$, количество итераций K

for $k = 0, 1, \ldots, K-1$ **do**

  Вычислить $g^k \in \partial f(x^k)$

  $v^k = \beta_1 v^{k-1} + (1 - \beta_1) g^k$

  $\hat{v}^k = v^k / (1 - \beta_1^{k+1})$

  $G_i^k = \beta_2 G_i^{k-1} + (1 - \beta_2)(g_i^k)^2$

  $\widehat{G}_i^k = G_i^k / (1 - \beta_2^{k+1})$

  $x_i^{k+1} = x_i^k - \dfrac{D_i}{\sqrt{\widehat{G}_i^k + \varepsilon}} \hat{v}_i^k$

end for

Выход: $\frac{1}{K} \sum_{k=0}^{K-1} x^k$

Итог

- Суть — подбирать шаг, исходя из локальных свойств задачи, что кажется более эффективным и удобным подходом.

Итог

- Суть — подбирать шаг, исходя из локальных свойств задачи, что кажется более эффективным и удобным подходом.
- Подбор параметров все еще нужен: шаги D_i, моментумы β_1, β_2.
- Часто рекомендуют брать $\beta_1 = 0.9$, $\beta_2 = 0.999$ и $D_i = D$ для всех i, но все равно нужно подбирать D.

Итог

- Суть — подбирать шаг, исходя из локальных свойств задачи, что кажется более эффективным и удобным подходом.
- Подбор параметров все еще нужен: шаги D_i, моментумы β_1, β_2.
- Часто рекомендуют брать $\beta_1 = 0.9$, $\beta_2 = 0.999$ и $D_i = D$ для всех i, но все равно нужно подбирать D.
- Сейчас и эта проблема решена в так называемых parameter-free методах. Они вообще не требуют подбора, а запускаются из «коробки».

Итог

- Суть — подбирать шаг, исходя из локальных свойств задачи, что кажется более эффективным и удобным подходом.
- Подбор параметров все еще нужен: шаги D_i, моментумы β_1, β_2.
- Часто рекомендуют брать $\beta_1 = 0.9$, $\beta_2 = 0.999$ и $D_i = D$ для всех i, но все равно нужно подбирать D.
- Сейчас и эта проблема решена в так называемых parameter-free методах. Они вообще не требуют подбора, а запускаются из «коробки».
- Adam и его модификации являются самыми популярными методами решения задач оптимизации, лежащих в основе обучения нейронных сетей.

Проксимальный оператор

Негладкие задачи «более сложные» по сравнению с гладкими задачами. Но отсутствие гладкости может получиться «спрятать под ковер» с помощью проксимального оператора.

Определение

Для функции $r : \mathbb{R}^d \to \mathbb{R} \cup \{+\infty\}$ ***проксимальный оператор*** *определяется следующим образом:*

$$prox_r(x) = \operatorname*{argmin}_{\tilde{x} \in \mathbb{R}^d} \left(r(\tilde{x}) + \frac{1}{2}\|x - \tilde{x}\|_2^2 \right).$$

Свойства проксимального оператора

Утверждение

Пусть $r : \mathbb{R}^d \to \mathbb{R} \cup \{+\infty\}$ *— выпуклая функция. Если существует* $\hat{x} \in \mathbb{R}^d$ *с* $r(\hat{x}) < +\infty$, *то проксимальный оператор однозначно определен.*

Свойства проксимального оператора

Утверждение

Пусть $r : \mathbb{R}^d \to \mathbb{R} \cup \{+\infty\}$ *— выпуклая функция. Если существует* $\hat{x} \in \mathbb{R}^d$ *с* $r(\hat{x}) < +\infty$*, то проксимальный оператор однозначно определен.*

Проксимальный оператор возвращает минимум некоторой задачи оптимизации. Задача сильно выпуклая, так как целевая функция — это сумма выпуклой и сильно выпуклой функции. А значит, существует ровно один минимум. А существование $\hat{x}$ необходимо для того, чтобы $r(\tilde{x}) + \frac{1}{2}\|x - \tilde{x}\|_2^2$ хотя бы где-то принимала конечное значение.

Примеры проксимального оператора

- **ℓ_1-норма.**
  Пусть $r(x) = \lambda\|x\|_1$, где $\lambda > 0$. Тогда

$$[\text{prox}_r(x)]_i = \left[|x_i| - \lambda\right]_+ \cdot \text{sign}(x_i),$$

  что известно как **оператор трешхолдинга**.

Примеры проксимального оператора

- **ℓ_1-норма.**
  Пусть $r(x) = \lambda\|x\|_1$, где $\lambda > 0$. Тогда

$$[\text{prox}_r(x)]_i = \left[|x_i| - \lambda\right]_+ \cdot \text{sign}(x_i),$$

  что известно как **оператор трешхолдинга**.

- **ℓ_2-норма.**
  Пусть $r(x) = \frac{\lambda}{2}\|x\|_2^2$, где $\lambda > 0$. Тогда

$$\text{prox}_r(x) = \frac{x}{1+\lambda}.$$

- **Индикатор множества.**
  Пусть $r(x) = \mathbb{I}_{\mathcal{X}}(x)$ для замкнутого выпуклого множества $\mathcal{X} \subseteq \mathbb{R}^d$. Тогда

$$\text{prox}_r(x) = \underset{\tilde{x}\in\mathcal{X}}{\text{argmin}} \frac{1}{2}\|x - \tilde{x}\|_2^2.$$

Свойства проксимального оператора

Утверждение

Пусть $r : \mathbb{R}^d \to \mathbb{R} \cup \{+\infty\}$ *— выпуклая функция. Тогда для любых* $x, y \in \mathbb{R}^d$ *следующие три условия являются эквивалентными:*

1. $prox_r(x) = y$,
2. $x - y \in \partial r(y)$,
3. $\langle x - y, z - y \rangle \leq r(z) - r(y)$ *для любого* $z \in \mathbb{R}^d$.

Свойства проксимального оператора

Утверждение

Пусть $r : \mathbb{R}^d \to \mathbb{R} \cup \{+\infty\}$ *— выпуклая функция. Тогда для любых* $x, y \in \mathbb{R}^d$ *следующие три условия являются эквивалентными:*

1. $prox_r(x) = y$,
2. $x - y \in \partial r(y)$,
3. $\langle x - y, z - y \rangle \leq r(z) - r(y)$ *для любого* $z \in \mathbb{R}^d$.

Запишем первое условие по определению проксимального оператора:

$$y = \operatorname*{argmin}_{\tilde{x} \in \mathbb{R}^d} \left(r(\tilde{x}) + \frac{1}{2} \|x - \tilde{x}\|_2^2 \right).$$

Свойства проксимального оператора

Утверждение

Пусть $r : \mathbb{R}^d \to \mathbb{R} \cup \{+\infty\}$ *— выпуклая функция. Тогда для любых* $x, y \in \mathbb{R}^d$ *следующие три условия являются эквивалентными:*

1. $prox_r(x) = y$,
2. $x - y \in \partial r(y)$,
3. $\langle x - y, z - y \rangle \leq r(z) - r(y)$ *для любого* $z \in \mathbb{R}^d$.

Запишем первое условие по определению проксимального оператора:

$$y = \operatorname*{argmin}_{\tilde{x} \in \mathbb{R}^d} \left(r(\tilde{x}) + \frac{1}{2}\|x - \tilde{x}\|_2^2 \right).$$

Из условия оптимальности для выпуклой функции r это эквивалентно

$$0 \in \partial \left(r(\tilde{x}) + \frac{1}{2}\|x - \tilde{x}\|_2^2 \right)\Big|_{\tilde{x}=y} = \partial r(y) + y - x.$$

Получили эквивалентность первого и второго условий.

Доказательство

Теперь свяжем второе и третье. Из определения субдифференциала, для любого субградиента $g \in \partial r(y)$ и для любого $z \in \mathbb{R}^d$:

$$\langle g, z - y \rangle \leq r(z) - r(y).$$

В частности, справедливо и для $g = x - y \in \partial r(y)$ по предположению:

$$\langle x - y, z - y \rangle \leq r(z) - r(y).$$

Получили, что из второго следует третье. Теперь в обратную сторону. Пусть выполнено третье соотношение:

$$\langle x - y, z - y \rangle \leq r(z) - r(y).$$

Но это же означает, что $x - y$ является субградиентом r в точке y, то есть $x - y \in \partial r(y)$.

Свойства проксимального оператора

Утверждение

Пусть $r : \mathbb{R}^d \to \mathbb{R} \cup \{+\infty\}$ *— выпуклая функция. Тогда для любых* $x, y \in \mathbb{R}^d$ *выполнено следующее:*

- $\langle x - y, prox_r(x) - prox_r(y) \rangle \geq \|prox_r(x) - prox_r(y)\|_2^2$,
- $\|prox_r(x) - prox_r(y)\|_2 \leq \|x - y\|_2$.

Свойства проксимального оператора

Утверждение

Пусть $r : \mathbb{R}^d \to \mathbb{R} \cup \{+\infty\}$ *— выпуклая функция. Тогда для любых* $x, y \in \mathbb{R}^d$ *выполнено следующее:*

- $\langle x - y, prox_r(x) - prox_r(y) \rangle \geq \|prox_r(x) - prox_r(y)\|_2^2$,
- $\|prox_r(x) - prox_r(y)\|_2 \leq \|x - y\|_2$.

Для удобства обозначим $u = \text{prox}_r(x), v = \text{prox}_r(y)$. Начнем с неравенства из прошлого утверждения. Запишем для троек точек (x, u, v) и (y, v, u):

$$\langle x - u, v - u \rangle \leq r(v) - r(u),$$
$$\langle y - v, u - v \rangle \leq r(u) - r(v).$$

Свойства проксимального оператора

Утверждение

Пусть $r : \mathbb{R}^d \to \mathbb{R} \cup \{+\infty\}$ *— выпуклая функция. Тогда для любых* $x, y \in \mathbb{R}^d$ *выполнено следующее:*

- $\langle x - y, prox_r(x) - prox_r(y) \rangle \geq \|prox_r(x) - prox_r(y)\|_2^2$,
- $\|prox_r(x) - prox_r(y)\|_2 \leq \|x - y\|_2$.

Для удобства обозначим $u = \text{prox}_r(x), v = \text{prox}_r(y)$. Начнем с неравенства из прошлого утверждения. Запишем для троек точек (x, u, v) и (y, v, u):

$$\langle x - u, v - u \rangle \leq r(v) - r(u),$$
$$\langle y - v, u - v \rangle \leq r(u) - r(v).$$

Сложим неравенства, справа получим 0:

$$\langle x - u - (y - v), v - u \rangle \leq 0.$$

Доказательство

Разнесем слагаемые в разные стороны:

$$\langle x - y, u - v \rangle \geq \|u - v\|_2^2.$$

Это и есть первое свойство. Из него логично вытекает и второе свойство.

Доказательство

Разнесем слагаемые в разные стороны:

$$\langle x - y, u - v \rangle \geq \|u - v\|_2^2.$$

Это и есть первое свойство. Из него логично вытекает и второе свойство. Достаточно лишь применить к неравенству выше неравенство Коши–Буняковского–Шварца:

$$\|u - v\|_2^2 \leq \langle x - y, u - v \rangle \leq \|x - y\|_2 \|u - v\|_2.$$

Доказательство

Разнесем слагаемые в разные стороны:

$$\langle x - y, u - v \rangle \geq \|u - v\|_2^2.$$

Это и есть первое свойство. Из него логично вытекает и второе свойство. Достаточно лишь применить к неравенству выше неравенство Коши–Буняковского–Шварца:

$$\|u - v\|_2^2 \leq \langle x - y, u - v \rangle \leq \|x - y\|_2 \|u - v\|_2.$$

Случай $u = v$ тривиален и удовлетворяет неравенству, так что имеем:

$$\|u - v\|_2 \leq \|x - y\|_2.$$

Композитная задача

Рассмотрим следующую задачу:

$$\min_{x \in \mathbb{R}^d} f\left(x\right) + r(x),$$

где f является L–гладкой выпуклой функцией, а r — просто выпуклой.

Композитная задача

Рассмотрим следующую задачу:

$$\min_{x \in \mathbb{R}^d} f(x) + r(x),$$

где f является L–гладкой выпуклой функцией, а r — просто выпуклой. Она не обязана быть гладкой, но должна быть проксимально-дружественной, то есть для нее должен считаться проксимальный оператор. Задача называется **композитной**.

Проксимальный градиентный метод

Алгоритм Проксимальный градиентный метод

Вход: стартовая точка $x^0 \in \mathbb{R}^d$, размеры шагов $\{\gamma_k\}_{k=0} > 0$, количество итераций K

1: **for** $k = 0, 1, \ldots, K-1$ **do**

2: $\quad x^{k+1} = \text{prox}_{\gamma_k r}\left(x^k - \gamma_k \nabla f\left(x^k\right)\right)$

3: **end for**

Выход: x^K

- Запишем условие оптимальности

$$x^k - \gamma_k \nabla f\left(x^k\right) - x^{k+1} \in \gamma_k \partial r\left(x^{k+1}\right).$$

Проксимальный градиентный метод

Алгоритм Проксимальный градиентный метод

Вход: стартовая точка $x^0 \in \mathbb{R}^d$, размеры шагов $\{\gamma_k\}_{k=0} > 0$, количество итераций K

1: **for** $k = 0, 1, \ldots, K-1$ **do**

2: $\quad x^{k+1} = \text{prox}_{\gamma_k r}\left(x^k - \gamma_k \nabla f\left(x^k\right)\right)$

3: **end for**

Выход: x^K

- Запишем условие оптимальности

$$x^k - \gamma_k \nabla f\left(x^k\right) - x^{k+1} \in \gamma_k \partial r\left(x^{k+1}\right).$$

- Или, если переписать в более привычном виде:

$$x^{k+1} \in x^k - \gamma_k \left(\nabla f\left(x^k\right) + \partial r\left(x^{k+1}\right)\right).$$

Свойство проксимального оператора

Утверждение

Пусть $f : \mathbb{R}^d \to \mathbb{R}$ *— выпуклая дифференцируемая функция,* $r : \mathbb{R}^d \to \mathbb{R} \cup \{+\infty\}$ *— выпуклая функция. Тогда* x^* *— решение композитной задачи оптимизации тогда и только тогда, когда для любого* $\gamma > 0$ *выполнено:*

$$x^* = prox_{\gamma r}\left(x^* - \gamma \nabla f\left(x^*\right)\right).$$

Выражение из условия эквивалентно записи:

$$x^* - \gamma \nabla f\left(x^*\right) - x^* \in \gamma \partial r\left(x^*\right).$$

Свойство проксимального оператора

Утверждение

Пусть $f : \mathbb{R}^d \to \mathbb{R}$ *— выпуклая дифференцируемая функция,* $r : \mathbb{R}^d \to \mathbb{R} \cup \{+\infty\}$ *— выпуклая функция. Тогда* x^* *— решение композитной задачи оптимизации тогда и только тогда, когда для любого* $\gamma > 0$ *выполнено:*

$$x^* = prox_{\gamma r}\left(x^* - \gamma \nabla f\left(x^*\right)\right).$$

Выражение из условия эквивалентно записи:

$$x^* - \gamma \nabla f\left(x^*\right) - x^* \in \gamma \partial r\left(x^*\right).$$

Сокращаем на $\gamma > 0$ и получаем условие оптимальности:

$$0 \in \nabla f\left(x^*\right) + \partial r\left(x^*\right).$$

Сходимость

Подставим итерацию метода:

$$\left\|x^{k+1} - x^*\right\|_2^2 = \left\|\text{prox}_{\gamma_k r}\left(x^k - \gamma_k \nabla f\left(x^k\right)\right) - x^*\right\|_2^2.$$

Сходимость

Подставим итерацию метода:

$$\left\|x^{k+1} - x^*\right\|_2^2 = \left\|\text{prox}_{\gamma_k r}\left(x^k - \gamma_k \nabla f\left(x^k\right)\right) - x^*\right\|_2^2.$$

Воспользуемся доказанным выше Утверждением:

$$\left\|x^{k+1} - x^*\right\|_2^2 = \left\|\text{prox}_{\gamma_k r}\left(x^k - \gamma_k \nabla f\left(x^k\right)\right) - \text{prox}_{\gamma_k r}\left(x^* - \gamma_k \nabla f\left(x^*\right)\right)\right\|_2^2.$$

Сходимость

Подставим итерацию метода:

$$\left\|x^{k+1} - x^*\right\|_2^2 = \left\|\text{prox}_{\gamma_k r}\left(x^k - \gamma_k \nabla f\left(x^k\right)\right) - x^*\right\|_2^2.$$

Воспользуемся доказанным выше Утверждением:

$$\left\|x^{k+1} - x^*\right\|_2^2 = \left\|\text{prox}_{\gamma_k r}\left(x^k - \gamma_k \nabla f\left(x^k\right)\right) - \text{prox}_{\gamma_k r}\left(x^* - \gamma_k \nabla f\left(x^*\right)\right)\right\|_2^2.$$

Применим нерастягиваемость проксимального оператора (второе свойство):

$$\left\|x^{k+1} - x^*\right\|_2^2 \leq \left\|\left(x^k - \gamma_k \nabla f\left(x^k\right)\right) - \left(x^* - \gamma_k \nabla f\left(x^*\right)\right)\right\|_2^2.$$

Сходимость

Подставим итерацию метода:

$$\left\|x^{k+1} - x^*\right\|_2^2 = \left\|\text{prox}_{\gamma_k r}\left(x^k - \gamma_k \nabla f\left(x^k\right)\right) - x^*\right\|_2^2.$$

Воспользуемся доказанным выше Утверждением:

$$\left\|x^{k+1} - x^*\right\|_2^2 = \left\|\text{prox}_{\gamma_k r}\left(x^k - \gamma_k \nabla f\left(x^k\right)\right) - \text{prox}_{\gamma_k r}\left(x^* - \gamma_k \nabla f\left(x^*\right)\right)\right\|_2^2.$$

Применим нерастягиваемость проксимального оператора (второе свойство):

$$\left\|x^{k+1} - x^*\right\|_2^2 \leq \left\|\left(x^k - \gamma_k \nabla f\left(x^k\right)\right) - \left(x^* - \gamma_k \nabla f\left(x^*\right)\right)\right\|_2^2.$$

Раскроем квадрат нормы:

$$\left\|x^{k+1} - x^*\right\|_2^2 \leq \left\|x^k - x^*\right\|_2^2 - 2\gamma_k \left\langle x^k - x^*, \nabla f\left(x^k\right) - \nabla f\left(x^*\right)\right\rangle + \gamma_k^2 \left\|\nabla f\left(x^k\right) - \nabla f\left(x^*\right)\right\|_2^2.$$

Сходимость

Оценим последнее слагаемое, используя свойство L–гладкой выпуклой функции:

$$\begin{aligned}\left\|x^{k+1}-x^*\right\|_2^2 &\leq \left\|x^k-x^*\right\|_2^2 - 2\gamma_k\left\langle x^k-x^*, \nabla f\left(x^k\right)-\nabla f\left(x^*\right)\right\rangle \\ &\quad + \gamma_k^2 L\left\langle \nabla f\left(x^k\right)-\nabla f\left(x^*\right), x^k-x^*\right\rangle \\ &= \left\|x^k-x^*\right\|_2^2 - \gamma_k\left(2-\gamma_k L\right)\left\langle \nabla f\left(x^k\right)-\nabla f\left(x^*\right), x^k-x^*\right\rangle.\end{aligned}$$

Сходимость

Оценим последнее слагаемое, используя свойство L–гладкой выпуклой функции:

$$\begin{aligned}\left\|x^{k+1}-x^*\right\|_2^2 &\leq \left\|x^k-x^*\right\|_2^2 - 2\gamma_k\left\langle x^k-x^*, \nabla f\left(x^k\right)-\nabla f\left(x^*\right)\right\rangle \\ &\quad + \gamma_k^2 L\left\langle \nabla f\left(x^k\right)-\nabla f\left(x^*\right), x^k-x^*\right\rangle \\ &= \left\|x^k-x^*\right\|_2^2 - \gamma_k\left(2-\gamma_k L\right)\left\langle \nabla f\left(x^k\right)-\nabla f\left(x^*\right), x^k-x^*\right\rangle.\end{aligned}$$

Два раза запишем определение μ–сильной выпуклости f:

$$\begin{aligned}f\left(x^k\right) &\geq f\left(x^*\right) + \left\langle \nabla f\left(x^*\right), x^k-x^*\right\rangle + \frac{\mu}{2}\left\|x^k-x^*\right\|_2^2, \\ f\left(x^*\right) &\geq f\left(x^k\right) + \left\langle \nabla f\left(x^k\right), x^*-x^k\right\rangle + \frac{\mu}{2}\left\|x^*-x^k\right\|_2^2.\end{aligned}$$

Сходимость

Сложим их и получим:

$$\left\langle \nabla f\left(x^k\right) - \nabla f\left(x^*\right), x^k - x^* \right\rangle \geq \mu \left\| x^k - x^* \right\|_2^2.$$

Сходимость

Сложим их и получим:

$$\left\langle \nabla f\left(x^k\right) - \nabla f\left(x^*\right), x^k - x^* \right\rangle \geq \mu \left\| x^k - x^* \right\|_2^2.$$

Подставляем в основное неравенство:

$$\begin{aligned} \left\| x^{k+1} - x^* \right\|_2^2 &\leq \left\| x^k - x^* \right\|_2^2 - \mu\gamma_k\left(2 - \gamma_k L\right)\left\| x^k - x^* \right\|_2^2 \\ &= \left(1 - \mu\gamma_k\left(2 - \gamma_k L\right)\right)\left\| x^k - x^* \right\|_2^2. \end{aligned}$$

Сходимость

Сложим их и получим:

$$\left\langle \nabla f\left(x^k\right) - \nabla f\left(x^*\right), x^k - x^* \right\rangle \geq \mu \left\| x^k - x^* \right\|_2^2.$$

Подставляем в основное неравенство:

$$\begin{aligned} \left\| x^{k+1} - x^* \right\|_2^2 &\leq \left\| x^k - x^* \right\|_2^2 - \mu\gamma_k\left(2 - \gamma_k L\right)\left\| x^k - x^* \right\|_2^2 \\ &= \left(1 - \mu\gamma_k\left(2 - \gamma_k L\right)\right)\left\| x^k - x^* \right\|_2^2. \end{aligned}$$

Возьмём $\gamma_k \leq \frac{1}{L}$, тогда $2 - \gamma_k L \geq 1$. Продолжая цепочку неравенств, имеем:

$$\left\| x^{k+1} - x^* \right\|_2^2 \leq \left(1 - \mu\gamma_k\right)\left\| x^k - x^* \right\|_2^2.$$

Остается лишь развернуть рекурсию с K-ой итерации по нулевую:

$$\left\| x^K - x^* \right\|_2^2 \leq \cdots \leq \left(\prod_{k=0}^{K-1}\left(1 - \mu\gamma_k\right)\right)\left\| x^0 - x^* \right\|_2^2.$$

Сходимость

Теорема

Пусть композитная задача оптимизации с L–гладкой μ–сильно выпуклой целевой функцией f и выпуклой (необязательно гладкой) проксимально–дружественной функцией r решается с помощью проксимального градиентного метода. Тогда при $\gamma_k \leq \frac{1}{L}$ справедлива следующая оценка сходимости:

$$\left\|x^K - x^*\right\|_2^2 \leq \left(\prod_{k=0}^{K-1} (1 - \mu\gamma_k)\right) \left\|x^0 - x^*\right\|_2^2.$$

Итог

- Проксимальный градиентный спуск для композитной задачи с L-гладкой выпуклой функцией f и выпуклой проксимально дружественной функцией r имеет такую же сходимость, что и метод градиентного спуска для функции f. Свойства гладкости/негладкости r при этом не влияют.

Итог

- Проксимальный градиентный спуск для композитной задачи с L-гладкой выпуклой функцией f и выпуклой проксимально дружественной функцией r имеет такую же сходимость, что и метод градиентного спуска для функции f. Свойства гладкости/негладкости r при этом не влияют.
- Кажется, что положив $f \equiv 0$, с помощью такого метода можно решать любую негладкую задачу.

Итог

- Проксимальный градиентный спуск для композитной задачи с L-гладкой выпуклой функцией f и выпуклой проксимально дружественной функцией r имеет такую же сходимость, что и метод градиентного спуска для функции f. Свойства гладкости/негладкости r при этом не влияют.
- Кажется, что положив $f \equiv 0$, с помощью такого метода можно решать любую негладкую задачу. **Вопрос:** так ли это?

Итог

- Проксимальный градиентный спуск для композитной задачи с L-гладкой выпуклой функцией f и выпуклой проксимально дружественной функцией r имеет такую же сходимость, что и метод градиентного спуска для функции f. Свойства гладкости/негладкости r при этом не влияют.
- Кажется, что положив $f \equiv 0$, с помощью такого метода можно решать любую негладкую задачу. **Вопрос:** так ли это? Если разрешить считать проксимальный оператор неточно (численно), то и правда можно решать любую задачу негладкой оптимизации.

Итог

- Проксимальный градиентный спуск для композитной задачи с L-гладкой выпуклой функцией f и выпуклой проксимально дружественной функцией r имеет такую же сходимость, что и метод градиентного спуска для функции f. Свойства гладкости/негладкости r при этом не влияют.
- Кажется, что положив $f \equiv 0$, с помощью такого метода можно решать любую негладкую задачу. **Вопрос:** так ли это? Если разрешить считать проксимальный оператор неточно (численно), то и правда можно решать любую задачу негладкой оптимизации. НО это с точки зрения теории не лучше, чем решать задачу субградиентным спуском, потому что при решении подзадачи для проксимального оператора используется какой-то вспомогательный метод (например, тот же субградиентный спуск).