

Л9 Градиентный спуск с проекцией. Алгоритм Франк–Вульфа

В предыдущих параграфах рассматривались безусловные задачи оптимизации, то есть, задачи без ограничений на всем пространстве $\mathbb{R}^d$. Однако, не все задачи имеют такой вид. В этом параграфе речь пойдет об оптимизации на выпуклых множествах. Определим этот класс множеств.

Определение Л9.1. Множество $S \subseteq \mathbb{R}^d$ называется *выпуклым*, если для любых двух точек $x_1, x_2 \in S$ и любого числа $\alpha \in [0, 1]$, точка $\alpha x_1 + (1 - \alpha)x_2$ также принадлежит S .

Физический смысл заключается в том, что вместе с любыми двумя точками выпуклого множества в него входит и отрезок с концами в этих точках. На выпуклые множества естественно переносится определение выпуклой функции.

Определение Л9.2. Рассмотрим функцию $f : \mathcal{X} \rightarrow \mathbb{R}$. Функция f называется *выпуклой* на выпуклом множестве $\mathcal{X}$, если для любых $x_1, \dots, x_k \in \mathcal{X}$ и любых $\alpha_1, \dots, \alpha_k, \alpha_i \geq 0, \sum_{i=1}^k \alpha_i = 1$ выполняется

$$f\left(\sum_{i=1}^k \alpha_i x_i\right) \leq \sum_{i=1}^k \alpha_i f(x_i).$$

Теперь мы готовы перейти к постановке задачи.

Л9.1 Задача оптимизации с ограничениями

Ставится задача на множестве

$$\min_{x \in \mathcal{X}} f(x), \quad (\text{Л9.1})$$

где $\mathcal{X} \subset \mathbb{R}^d$ — выпуклое замкнутое множество (Определение Л9.1), f — выпуклая на $\mathcal{X}$ функция. Графически понять, как выглядит задача поможет иллюстрация. Здесь $\mathcal{X}$ — выпуклое замкнутое множество: пятиугольник в $\mathbb{R}^2$, а по вертикальной оси отложено значение функции f . Решением задачи будет точка $x \in \mathcal{X}$, лежащая в множестве и доставляющая минимум функции f .

Важным замечанием будет, что минимум выпуклой функции на множестве может не совпадать с глобальным для $\mathbb{R}^d$. Более того, условия оптимальности (Утверждения Л2.1 и Л2.2) для $\mathbb{R}^d$ не будут работать для задачи на выпуклом множестве. Чтобы в этом убедиться, можно рассмотреть пример $\min_{x \in [1, 2]} x^2$. Минимум достигается в точке $x^* = 1$, градиент в ней не равен нулю. Это подводит нас к следующему критерию.

Теорема Л9.1. [Параграф 4.2.3. из [4]] Пусть дана выпуклая непрерывно дифференцируемая на $\mathbb{R}^d$ функция $f : \mathbb{R}^d \rightarrow \mathbb{R}$ и выпуклое множество $\mathcal{X} \subseteq \mathbb{R}^d$. Тогда $x^* \in \mathcal{X}$ — глобальный минимум f на $\mathcal{X}$ тогда и только тогда, когда для всех $x \in \mathcal{X}$ выполнено:

$$\langle \nabla f(x^*), x - x^* \rangle \geq 0.$$




Рис. Л9.1: Пример задачи с ограничением

Доказательство. $\ominus$ Пусть x^* — глобальный минимум на $\mathcal{X}$. Хотим доказать, что $\langle \nabla f(x^*), x - x^* \rangle \geq 0$ для любого $x \in \mathcal{X}$. Пойдем от противного: предположим, что существует $x \in \mathcal{X}$ такой, что:

$$\langle \nabla f(x^*), x - x^* \rangle < 0.$$

Рассмотрим точки вида:

$$x_\lambda = \lambda x + (1 - \lambda)x^*, \quad \lambda \in [0, 1].$$

В силу выпуклости множества $\mathcal{X}$ (Определение Л9.1) точки $x_\lambda \in \mathcal{X}$.

Посмотрим, как ведет себя функция $\phi : [0, 1] \rightarrow \mathbb{R}$ вида:

$$\phi(\lambda) = f(x_\lambda) = f(\lambda x + (1 - \lambda)x^*).$$

Её производная вычисляется как:

$$\frac{d\phi}{d\lambda} = \frac{d}{d\lambda} f(\lambda x + (1 - \lambda)x^*) = \langle \nabla f(x^* + \lambda(x - x^*)), x - x^* \rangle.$$

Обратим внимание, что в нуле по предположению

$$\left. \frac{d\phi}{d\lambda} \right|_{\lambda=0} = \langle \nabla f(x^*), x - x^* \rangle < 0.$$

Это значит, что функция ϕ убывает в окрестности нуля. Следовательно, для достаточно малых $\lambda > 0$ выполнено:

$$f(x_\lambda) = \phi(\lambda) < \phi(0) = f(x^*).$$

Пришли к противоречию, что x^* — глобальный минимум на $\mathcal{X}$.

$\ominus$ Пусть $\langle \nabla f(x^*), x - x^* \rangle \geq 0$ для всех $x \in \mathcal{X}$. Тогда воспользуемся выпуклостью f на $\mathbb{R}^d$ (Определение Л2.3):

$$f(x) \geq f(x^*) + \langle \nabla f(x^*), x - x^* \rangle \geq f(x^*).$$

Откуда следует, что x^* — глобальный минимум на $\mathcal{X}$. ■




Рис. Л9.2: Геометрическая иллюстрация условия оптимальности для выпуклого множества.

Физический смысл Теоремы Л9.1 проиллюстрирован на Рисунке Л9.2.

С новым условием оптимальности можно переходить к построению методов.

Л9.2 Градиентный спуск с проекцией

Вновь обратимся к методу градиентного спуска (Алгоритм Л3.1). Он работал на безусловных задачах, то есть, на всем $\mathbb{R}^d$. Если просто попытаться его запустить для задачи на множестве, то возникнет проблема: мы можем «выпасть» из множества. Иными словами, на какой-то итерации k может случиться так, что градиентный шаг выводит нас из множества:

$$x^{k+1} = x^k - \gamma_k \nabla f(x^k) \notin \mathcal{X}.$$

Чтобы избежать такого поведения, можем на каждой итерации проецироваться на множество:

$$x^{k+1} = \Pi_{\mathcal{X}}(x^k - \gamma_k \nabla f(x^k)) \in \mathcal{X},$$

где введен оператор проекции $\Pi_{\mathcal{X}} : \mathbb{R}^d \rightarrow \mathcal{X}$, который задается как:

$$\Pi_{\mathcal{X}}(x) := \operatorname{argmin}_{y \in \mathcal{X}} \frac{1}{2} \|x - y\|_2^2. \quad (\text{Л9.2})$$

Эта идея и лежит в основе метода градиентного спуска с проекцией. Запишем формальный алгоритм.

Алгоритм Л9.1 Градиентный спуск с проекцией

Вход: размеры шагов $\{\gamma_k\}_{k=0} > 0$, стартовая точка $x^0 \in \mathbb{R}^d$, количество итераций K

- 1: **for** $k = 0, 1, \dots, K - 1$ **do**
- 2: $x^{k+1} = \Pi_{\mathcal{X}}[x^k - \gamma_k \nabla f(x^k)]$
- 3: **end for**

Выход: x^k

Геометрически принцип работы алгоритма показан на Рисунке Л9.3.




Рис. Л9.3: Проекция точки на множество $\mathcal{X}$

Л9.2.1 Свойства оператора проекции

Для последующего анализа метода, потребуется изучить оператор проекции подробнее.

Утверждение Л9.1. Для выпуклого замкнутого множества $\mathcal{X}$ и любой точки оператор проекции существует и принимает единственное значение.

Доказательство. Задача проекции — это минимизация сильно выпуклой функции на выпуклом множестве:

$$\Pi_{\mathcal{X}}(x) := \operatorname{argmin}_{y \in \mathcal{X}} \frac{1}{2} \|x - y\|_2^2.$$

Существование и единственность решения в безусловном случае рассматривалось в Теореме Л2.3. Этот результат легко переносится на случай минимизации на выпуклом множестве: достаточно шар $B(x^0, R)$ заменить на пересечение $B(x^0, R) \cap \mathcal{X}$, а условие оптимальности для $\mathbb{R}^d$:

$$\nabla f(x^*) = 0$$

заменить на условие для выпуклого $\mathcal{X}$:

$$\langle \nabla f(x^*), x - x^* \rangle \geq 0$$

для всех $x \in \mathcal{X}$. Остальные рассуждения и переходы остаются неизменными. Тогда получаем, что решение такой задачи существует и единственно. ■

Утверждение Л9.2. Пусть $\mathcal{X} \subseteq \mathbb{R}^d$ — выпуклое замкнутое множество, $y \in \mathcal{X}$, $x \in \mathbb{R}^d$. Тогда

$$\langle y - \Pi_{\mathcal{X}}(x), x - \Pi_{\mathcal{X}}(x) \rangle \leq 0.$$

Доказательство. Заметим, что $\Pi_{\mathcal{X}}(x)$ минимизирует дифференцируемую выпуклую функцию $d(z) = \frac{1}{2} \|x - z\|_2^2$ на выпуклом множестве $\mathcal{X}$. Запишем условие оптимальности:

$$\langle \nabla d(\Pi_{\mathcal{X}}(x)), y - \Pi_{\mathcal{X}}(x) \rangle \geq 0$$

для всех $y \in \mathcal{X}$. Подставим $\nabla d(\Pi_{\mathcal{X}}(x)) = x - \Pi_{\mathcal{X}}(x)$ и поменяем местами аргументы скалярного произведения:

$$\langle y - \Pi_{\mathcal{X}}(x), x - \Pi_{\mathcal{X}}(x) \rangle \leq 0$$

для всех $y \in \mathcal{X}$. ■

В следующем утверждении формулируется 1-липшицевость оператора проекции.

Утверждение Л9.3. Пусть $\mathcal{X} \subseteq \mathbb{R}^d$ — выпуклое замкнутое множество, $x_1, x_2 \in \mathbb{R}^d$. Тогда

$$\|\Pi_{\mathcal{X}}(x_1) - \Pi_{\mathcal{X}}(x_2)\|_2 \leq \|x_1 - x_2\|_2.$$

Доказательство. Пользуемся результатом Утверждения Л9.2 для $x_1, x_2 \in \mathbb{R}^d$, $x \in \mathcal{X}$:

$$\langle x_1 - \Pi_{\mathcal{X}}(x_1), x - \Pi_{\mathcal{X}}(x_1) \rangle \leq 0,$$

$$\langle x_2 - \Pi_{\mathcal{X}}(x_2), x - \Pi_{\mathcal{X}}(x_2) \rangle \leq 0.$$

Подставим $x = \Pi_{\mathcal{X}}(x_2)$ в первое неравенство и $x = \Pi_{\mathcal{X}}(x_1)$ во второе:

$$\langle x_1 - \Pi_{\mathcal{X}}(x_1), \Pi_{\mathcal{X}}(x_2) - \Pi_{\mathcal{X}}(x_1) \rangle \leq 0,$$

$$\langle x_2 - \Pi_{\mathcal{X}}(x_2), \Pi_{\mathcal{X}}(x_1) - \Pi_{\mathcal{X}}(x_2) \rangle \leq 0.$$

Сложим и получим:

$$\langle \Pi_{\mathcal{X}}(x_2) - \Pi_{\mathcal{X}}(x_1), \Pi_{\mathcal{X}}(x_2) - \Pi_{\mathcal{X}}(x_1) \rangle \leq \langle \Pi_{\mathcal{X}}(x_2) - \Pi_{\mathcal{X}}(x_1), x_2 - x_1 \rangle.$$

Применим неравенство Коши–Буняковского–Шварца (0.3):

$$\|\Pi_{\mathcal{X}}(x_2) - \Pi_{\mathcal{X}}(x_1)\|_2^2 \leq \|\Pi_{\mathcal{X}}(x_2) - \Pi_{\mathcal{X}}(x_1)\|_2 \|x_2 - x_1\|_2.$$

Откуда имеем:

$$\|\Pi_{\mathcal{X}}(x_2) - \Pi_{\mathcal{X}}(x_1)\|_2 \leq \|x_2 - x_1\|_2. ■$$

Утверждение Л9.4. Пусть x^* — решение условной задачи (Л9.1) минимизации с выпуклой непрерывно дифференцируемой функции f на выпуклом замкнутом множестве $\mathcal{X}$. Тогда справедливо

$$x^* = \Pi_{\mathcal{X}}(x^* - \gamma \nabla f(x^*))$$

Доказательство. Распишем определение оператора проекции (Л9.2):

$$\begin{aligned} \Pi_{\mathcal{X}}(x^* - \gamma \nabla f(x^*)) &= \operatorname{argmin}_{y \in \mathcal{X}} \frac{1}{2} \|x^* - \gamma \nabla f(x^*) - y\|_2^2 \\ &= \operatorname{argmin}_{y \in \mathcal{X}} \frac{1}{2} [\|x^* - y\|_2^2 + 2\gamma \langle \nabla f(x^*), y - x^* \rangle + \gamma^2 \|\nabla f(x^*)\|_2^2]. \end{aligned}$$

Откуда:

$$\Pi_{\mathcal{X}}(x^* - \gamma \nabla f(x^*)) = \operatorname{argmin}_{y \in \mathcal{X}} \frac{1}{2} [\|x^* - y\|_2^2 + 2\gamma \langle \nabla f(x^*), y - x^* \rangle].$$

Оба слагаемых под argmin неотрицательны: первое в силу неотрицательности квадрата нормы, второе в силу Теоремы Л9.1. Следовательно, минимум равен 0, и достигается он на x^* . ■

Этих свойств оператора проекции нам будет достаточно, чтобы произвести анализ сходимости метода.

Л9.2.2 Теоретические оценки сходимости

Теорема Л9.2. Пусть задача на ограниченном выпуклом замкнутом множестве $\mathcal{X}$ (Л9.1) с L -гладкой μ -сильно выпуклой целевой функцией f решается с помощью градиентного спуска с проекцией (Алгоритм Л9.1). Тогда при $\gamma_k \leq \frac{1}{L}$ справедлива следующая оценка сходимости:

$$\|x^K - x^*\|_2^2 \leq \left(\prod_{k=0}^{K-1} (1 - \mu\gamma_k) \right) \|x^0 - x^*\|_2^2.$$

Доказательство. Рассмотрим $\|x^{k+1} - x^*\|_2^2$. Подставим итерацию метода:

$$\|x^{k+1} - x^*\|_2^2 = \|\Pi_{\mathcal{X}}(x^k - \gamma_k \nabla f(x^k)) - x^*\|_2^2.$$

Воспользуемся Утверждением Л9.4:

$$\|x^{k+1} - x^*\|_2^2 = \|\Pi_{\mathcal{X}}(x^k - \gamma_k \nabla f(x^k)) - \Pi_{\mathcal{X}}(x^* - \gamma_k \nabla f(x^*))\|_2^2.$$

А теперь применяем неравенство из Утверждения Л9.3:

$$\|x^{k+1} - x^*\|_2^2 \leq \|(x^k - \gamma_k \nabla f(x^k)) - (x^* - \gamma_k \nabla f(x^*))\|_2^2.$$

Раскроем квадрат нормы:

$$\|x^{k+1} - x^*\|_2^2 \leq \|x^k - x^*\|_2^2 - 2\gamma_k \langle x^k - x^*, \nabla f(x^k) - \nabla f(x^*) \rangle + \gamma_k^2 \|\nabla f(x^k) - \nabla f(x^*)\|.$$

Оценим последнее слагаемое, используя свойство L -гладкой выпуклой f (неравенство (Л2.5) из Теоремы Л2.5):

$$\begin{aligned} \|x^{k+1} - x^*\|_2^2 &\leq \|x^k - x^*\|_2^2 - 2\gamma_k \langle x^k - x^*, \nabla f(x^k) - \nabla f(x^*) \rangle \\ &\quad + \gamma_k^2 L \langle \nabla f(x^k) - \nabla f(x^*), x^k - x^* \rangle \\ &= \|x^k - x^*\|_2^2 - \gamma_k (2 - \gamma_k L) \langle \nabla f(x^k) - \nabla f(x^*), x^k - x^* \rangle. \end{aligned} \quad (\text{Л9.3})$$

Два раза запишем определение μ -сильной выпуклости f (Определение Л2.4):

$$\begin{aligned} f(x^k) &\geq f(x^*) + \langle \nabla f(x^*), x^k - x^* \rangle + \frac{\mu}{2} \|x^k - x^*\|_2^2, \\ f(x^*) &\geq f(x^k) + \langle \nabla f(x^k), x^* - x^k \rangle + \frac{\mu}{2} \|x^* - x^k\|_2^2. \end{aligned} \quad (\text{Л9.4})$$

Сложим их и получим:

$$\langle \nabla f(x^k) - \nabla f(x^*), x^k - x^* \rangle \geq \mu \|x^k - x^*\|_2^2.$$

Подставляем в неравенство (Л9.3) неравенство (Л9.4):

$$\begin{aligned} \|x^{k+1} - x^*\|_2^2 &\leq \|x^k - x^*\|_2^2 - \mu\gamma_k (2 - \gamma_k L) \|x^k - x^*\|_2^2 \\ &= (1 - \mu\gamma_k (2 - \gamma_k L)) \|x^k - x^*\|_2^2. \end{aligned}$$

Поскольку $\gamma_k \leq \frac{1}{L}$, то $2 - \gamma_k L > 1$. Продолжая цепочку неравенств, имеем:

$$\|x^{k+1} - x^*\|_2^2 \leq (1 - \mu\gamma_k) \|x^k - x^*\|_2^2.$$

Остается лишь развернуть рекурсию с K -ой итерации до нулевой:

$$\begin{aligned} \|x^K - x^*\|_2^2 &\leq (1 - \mu\gamma_{K-1}) \|x^{K-1} - x^*\|_2^2 \\ &\leq (1 - \mu\gamma_{K-1})(1 - \mu\gamma_{K-2}) \|x^{K-2} - x^*\|_2^2 \\ &\leq \dots \\ &\leq \left(\prod_{k=0}^{K-1} (1 - \mu\gamma_k) \right) \|x^0 - x^*\|_2^2. \end{aligned}$$

■

Утверждение Л9.5. Пусть задача удовлетворяет условиям Теоремы Л9.2 и выбрано значение шага $\gamma_k = \frac{1}{L}$. Тогда справедлива следующая оценка сходимости:

$$\|x^K - x^*\|_2^2 \leq \left(1 - \frac{\mu}{L}\right)^K \|x^0 - x^*\|_2^2.$$

Более того, чтобы добиться точности ε по аргументу ($\|x^K - x^*\|_2 \leq \varepsilon$), необходимо

$$K = \mathcal{O}\left(\frac{L}{\mu} \log \frac{\|x^0 - x^*\|_2}{\varepsilon}\right) \text{ итераций.}$$

Доказательство. Повторяет доказательство Утверждения Л3.1. ■

Л9.2.3 Проекция как отдельная задача

Рассмотрим задачу поиска проекции:

$$\operatorname{argmin}_{y \in \mathcal{X}} \frac{1}{2} \|x - y\|_2^2. \quad (\text{Л9.5})$$

Получим аналитическое решение для некоторых простых множеств $\mathcal{X}$.

Утверждение Л9.6. Пусть задача проекции (Л9.5) решается на ℓ_1 -шаре радиуса R с центром в 0:

$$\mathcal{X} = \left\{ y \in \mathbb{R}^d \mid \|y\|_1 \leq R \right\}.$$

Тогда оператор проекции имеет вид:

$$\Pi_{\mathcal{X}}(x) = \begin{cases} x, & \|x\|_1 \leq R, \\ \operatorname{sign}(x_i)(|x_i| - \lambda)_+ \quad \forall i \in \overline{1, d}, & \|x\|_1 > R, \end{cases}$$

где λ определяется из уравнения

$$\sum_{i=1}^d (|x_i| - \lambda)_+ = R.$$

Доказательство. Запишем лагранжиан:

$$\mathcal{L}(y, \lambda) = \frac{1}{2} \|x - y\|_2^2 + \lambda (\|y\|_1 - R) = \sum_{i=1}^d \left(\frac{1}{2} (y_i - x_i)^2 + \lambda |y_i| \right) - \lambda R.$$

Воспользуемся теоремой Каруша–Куна–Таккера (Теорема С8.1):

1. Ограничения: $\|y\|_1 - R \leq 0$;
2. Неотрицательность: $\lambda \geq 0$;
3. Дополняющая нежёсткость: $\lambda (\|y\|_1 - R) = 0$;
4. Стационарность: $0 \in y_i - x_i + \lambda \partial |y_i|$.

Последнему условию удовлетворяет:

$$y_i = \text{sign}(x_i) (|x_i| - \lambda)_+.$$

- Если $\lambda = 0$, то $y = x$ и требуется $\|x\|_1 \leq R$.
- Если $\lambda > 0$, то $\sum_{i=1}^d |y_i| = R$, что даёт уравнение на λ : $g(\lambda) = \sum_{i=1}^d (|x_i| - \lambda)_+ - R$. Единственность следует из монотонного убывания.

■

Утверждение Л9.7. Пусть задача проекции (Л9.5) решается на ℓ_2 -шаре радиуса R с центром в 0:

$$\mathcal{X} = \left\{ y \in \mathbb{R}^d \mid \|y\|_2 \leq R \right\}.$$

Тогда оператор проекции имеет вид:

$$\Pi_{\mathcal{X}}(x) = \min \left\{ 1, \frac{R}{\|x\|_2} \right\} x.$$

Доказательство. Запишем лагранжиан:

$$\mathcal{L}(y, \lambda) = \frac{1}{2} \|x - y\|_2^2 + \lambda (\|y\|_2^2 - R^2).$$

Воспользуемся теоремой Каруша–Куна–Таккера (Теорема С8.1):

1. Ограничения: $\|y\|_2 - R \leq 0$;
2. Неотрицательность: $\lambda \geq 0$;
3. Дополняющая нежёсткость: $\lambda (\|y\|_2 - R) = 0$;
4. Стационарность: $y - x + 2\lambda y = 0$.

Из стационарности имеем $(1 + 2\lambda)y = x$.

- Если $\lambda = 0$, то $y = x$, и из ограничений имеем $\|x\|_2 \leq R$.

- Если $\lambda > 0$, то из дополняющей нежёсткости $\|y\|_2 = R$, а потому

$$y = \frac{x}{1+2\lambda}, \quad R = \|y\|_2 = \frac{\|x\|_2}{1+2\lambda} \implies y = \frac{R}{\|x\|_2} x.$$

Это случай для $\|x\|_2 > R$.

■

Утверждение Л9.8. Пусть задача проекции (Л9.5) решается на ℓ_∞ -шаре радиуса R с центром в 0:

$$\mathcal{X} = \left\{ y \in \mathbb{R}^d \mid \|y\|_\infty \leq R \right\}.$$

Тогда оператор проекции имеет вид:

$$[\Pi_{\mathcal{X}}(x)]_i = \begin{cases} -R, & x_i < -R, \\ x_i, & -R \leq x_i \leq R, \\ R, & x_i > R. \end{cases}$$

Доказательство. Запишем лагранжиан с двумя покоординатными множителями неравенств $\lambda_1, \lambda_2 \geq 0$ для ограничений $y - \mathbf{R} \preceq 0$ и $-y - \mathbf{R} \preceq 0$:

$$\mathcal{L}(y, \lambda_1, \lambda_2) = \frac{1}{2} \|x - y\|_2^2 + \lambda_1^\top (y - \mathbf{R}) + \lambda_2^\top (-y - \mathbf{R}).$$

Воспользуемся теоремой Каруша–Куна–Таккера (Теорема С8.1):

1. Ограничения: $-\mathbf{R} \preceq y \preceq \mathbf{R}$;
2. Неотрицательность: $\lambda_1 \succeq 0, \lambda_2 \succeq 0$;
3. Дополняющая нежёсткость: $\lambda_1^i (y_i - R) = 0, \lambda_2^i (-y_i - R) = 0$;
4. Стационарность: $y - x + \lambda_1 - \lambda_2 = 0$.

Рассмотрим покоординатно:

- Если $-R < x_i < R$, то $y_i = x_i$, при этом $\lambda_1^i = \lambda_2^i = 0$;
- Если $x_i > R$, то $y_i = R$, при этом условие дополняющей нежёсткости требует $\lambda_2^i = 0$, а стационарность даёт $\lambda_1^i = x_i - R > 0$;
- Если $x_i < -R$, то $y_i = -R$, при этом условие дополняющей нежёсткости требует $\lambda_1^i = 0$, а стационарность даёт $\lambda_2^i = -x_i - R > 0$.

■

Утверждение Л9.9. Пусть задача проекции (Л9.5) решается на симплексе размера R :

$$\mathcal{X} = \left\{ y \in \mathbb{R}^d \mid y \succeq 0, \mathbf{1}^\top y = R \right\}.$$

Тогда оператор проекции имеет вид:

$$[\Pi_{\mathcal{X}}(x)]_i = (x_i + \nu)_+,$$

где ν определяется из уравнения

$$\sum_{i=1}^d (x_i + \nu)_+ = R.$$

Доказательство. Запишем лагранжиан:

$$\mathcal{L}(y, \lambda, \nu) = \frac{1}{2} \|x - y\|_2^2 - \lambda^\top y - \nu(\mathbf{1}^\top y - R).$$

Воспользуемся теоремой Каруша–Куна–Таккера (Теорема С8.1):

1. Ограничения: $y \succeq 0$, $\mathbf{1}^\top y = R$;
2. Неотрицательность: $\lambda \succeq 0$;
3. Дополняющая нежесткость: $\lambda_i y_i = 0$;
4. Стационарность: $y - x - \lambda - \nu = 0$.

Из стационарности имеем

$$y = x + \lambda + \nu.$$

Используя дополняющую нежесткость, получаем:

$$\begin{aligned} y_i &= \frac{1}{2} ((x_i + \nu) + |x_i + \nu|) = (x_i + \nu)_+, \\ \lambda_i &= \frac{1}{2} (|x_i + \nu| - (x_i + \nu)) = (-x_i - \nu)_+. \end{aligned}$$

Подставляя это выражение в ограничение $\mathbf{1}^\top y = R$, получаем уравнение на ν :

$$\sum_{i=1}^d (x_i + \nu)_+ = R.$$

Поскольку функция монотонно возрастает, то решение для ν единственно. ■

Утверждение Л9.10. Пусть задача проекции (Л9.5) решается на гиперпрямоугольнике:

$$\mathcal{X} = \left\{ y \in \mathbb{R}^d \mid a \preceq y \preceq b \right\}.$$

Тогда оператор проекции имеет вид:

$$[\Pi_{\mathcal{X}}(x)]_i = \begin{cases} a_i, & x_i < a_i, \\ x_i, & a_i \leq x_i \leq b_i, \\ b_i, & x_i > b_i. \end{cases}$$

Доказательство. Запишем лагранжиан с двумя покомпонентными множителями неравенств $\lambda_1, \lambda_2 \geq 0$ для ограничений $y - b \preceq 0$ и $-y + a \preceq 0$:

$$\mathcal{L}(y, \lambda_1, \lambda_2) = \frac{1}{2} \|x - y\|_2^2 + \lambda_1^\top (y - b) + \lambda_2^\top (-y + a).$$

Воспользуемся теоремой Каруша–Куна–Таккера (Теорема С8.1):

1. Ограничения: $a \preceq y \preceq b$;
2. Неотрицательность: $\lambda_1 \succeq 0, \lambda_2 \succeq 0$;
3. Дополняющая нежесткость: $\lambda_1^i(y_i - b_i) = 0, \lambda_2^i(-y_i + a_i) = 0$;
4. Стационарность: $y - x + \lambda_1 - \lambda_2 = 0$.

Рассмотрим покомпонентно:

- Если $a_i < x_i < b_i$, то $y_i = x_i$, при этом $\lambda_1^i = \lambda_2^i = 0$;
- Если $x_i > b_i$, то $y_i = b_i$, при этом условие дополняющей нежесткости требует $\lambda_2^i = 0$, а стационарность даёт $\lambda_1^i = x_i - b_i > 0$;
- Если $x_i < a_i$, то $y_i = a_i$, при этом условие дополняющей нежесткости требует $\lambda_1^i = 0$, а стационарность даёт $\lambda_2^i = -x_i + a_i > 0$.

■

Утверждение Л9.11. Пусть задача проекции (Л9.5) решается на множестве линейных равенств:

$$\mathcal{X} = \left\{ y \in \mathbb{R}^d \mid Ay = b \right\},$$

где предполагается, что $AA^\top$ невырождена. Тогда оператор проекции имеет вид:

$$\Pi_{\mathcal{X}}(x) = x - A^\top (AA^\top)^{-1} (Ax - b).$$

Доказательство. Запишем лагранжиан:

$$\mathcal{L}(y, \nu) = \frac{1}{2} \|x - y\|_2^2 + \nu^\top (Ay - b).$$

Воспользуемся теоремой Каруша–Куна–Таккера (Теорема С8.1):

1. Ограничения: $Ay = b$;
2. Стационарность: $y - x + A^\top \nu = 0$.

Из стационарности

$$y = x - A^\top \nu.$$

Подставляя в ограничение, получаем

$$Ax - AA^\top \nu = b \implies \nu = (AA^\top)^{-1} (Ax - b).$$

Следовательно:

$$y = x - A^\top (AA^\top)^{-1} (Ax - b).$$

■

Л9.3 Метод Франк–Вульфа

В методе градиентного спуска с проекцией (Алгоритм Л9.1) операция проекции для некоторых множеств $\mathcal{X}$ может быть вычислительно дорогой или вовсе не иметь аналитического выражения. Однако во многих случаях доступна более простая процедура — решение задачи линейной минимизации:

$$s^k = \operatorname{argmin}_{s \in \mathcal{X}} \langle s, \nabla f(x^k) \rangle.$$

Иными словами, мы умеем находить такую точку $s^k \in \mathcal{X}$, которая минимизирует линейное приближение функции f в окрестности x^k . Эту операцию часто записывают через, так называемый оракул, линейной минимизации (Linear Minimization Oracle):

$$\text{LMO}(c) = \operatorname{argmin}_{s \in \mathcal{X}} \langle c, s \rangle.$$

Алгоритм, использующий на каждом шаге вызов LMO и последующее усреднение с текущей точкой, был предложен Маргаритой Франк и Филипом Вульфом в 1956 году [9]. Он известен как *метод условного градиента* или *метод Франк–Вульфа*.

Алгоритм Л9.2 Метод Франк–Вульфа

Вход: стартовая точка $x^0 \in \mathbb{R}^d$, размеры шагов $\{\gamma_k\}_{k=0} > 0$, количество итераций K

```

1: for  $k = 0, 1, \dots, K - 1$  do
2:    $s^k = \operatorname{argmin}_{s \in \mathcal{X}} \langle s, \nabla f(x^k) \rangle$ 
3:    $x^{k+1} = (1 - \gamma_k)x^k + \gamma_k s^k$ 
4: end for
```

Выход: x^k

LMO указывает на экстремальную точку множества $\mathcal{X}$ (интуитивно это «уголок» множества $\mathcal{X}$), а обновление

$$x^{k+1} = (1 - \gamma_k)x^k + \gamma_k s^k$$

усредняет её с текущим приближением, так что последовательность x^k строится как выпуклая комбинация найденных экстремальных точек.

Замечание Л9.1. В Алгоритме Л9.2 шаг взят произвольным. Классическим выбором считается

$$\gamma_k = \frac{2}{k+2},$$

поскольку для него получаются хорошие теоретические оценки и он легко вычислим на практике. Однако, возможен выбор шага линейным поиском:

$$\gamma_k = \operatorname{argmin}_{\gamma \in [0,1]} f(x^k + \gamma(s^k - x^k)).$$

Докажем сходимость для классического выбора шага.

Теорема Л9.3. Пусть задача оптимизации на выпуклом замкнутом множестве (Л9.1) с L -гладкой выпуклой целевой функцией f решается с помощью метода Франк–Вульфа (Алгоритм Л9.2). Тогда при $\gamma_k = \frac{2}{k+2}$ справедлива следующая оценка сходимости:

$$f(x^k) - f^* \leq \frac{2 \max \{L \operatorname{diam}(\mathcal{X})^2, f(x^0) - f^*\}}{K+2}, \quad (\text{Л9.6})$$




Рис. 19.4: Шаг Франк-Вульфа

где $\text{diam}(\mathcal{X}) := \max_{x, y \in \mathcal{X}} \|x - y\|_2$ — диаметр множества $\mathcal{X}$.

Более того, чтобы добиться точности ε по функции ($f(x^K) - f^* \leq \varepsilon$), необходимо

$$K = O\left(\frac{\max\{L \text{diam}(\mathcal{X})^2, f(x^0) - f^*\}}{\varepsilon}\right) \text{ итераций.}$$

Доказательство. Запишем итерацию метода и применим неравенство (12.3) из Теоремы 12.5:

$$\begin{aligned} f(x^{k+1}) - f^* &= f(x^k + \gamma_k(s^k - x^k)) - f^* \\ &\leq f(x^k) - f^* + \gamma_k \langle s^k - x^k, \nabla f(x^k) \rangle + \frac{\gamma_k^2}{2} L \|s^k - x^k\|_2^2 \\ &\leq f(x^k) - f^* + \gamma_k \langle s^k - x^k, \nabla f(x^k) \rangle + \gamma_k^2 C. \end{aligned} \quad (19.7)$$

В последнем переходе мы применили, что $x^k, s^k \in \mathcal{X}$, и $\|s^k - x^k\|_2 \leq \text{diam } \mathcal{X}$, а также ввели обозначение $C = \frac{L(\text{diam } \mathcal{X})^2}{2}$.

Примем во внимание, что s^k ищется как решение линейной минимизации:

$$s^k = \underset{s \in \mathcal{X}}{\text{argmin}} \langle s, \nabla f(x^k) \rangle = \underset{s \in \mathcal{X}}{\text{argmin}} \gamma_k \langle s - x^k, \nabla f(x^k) \rangle,$$

откуда следует неравенство:

$$\gamma_k \langle s^k - x^k, \nabla f(x^k) \rangle \leq \gamma_k \langle x^* - x^k, \nabla f(x^k) \rangle.$$

Правую часть можно оценить по выпуклости (Определение 12.3) и получить:

$$\gamma_k \langle s^k - x^k, \nabla f(x^k) \rangle \leq \gamma_k (f^* - f(x^k)).$$

Подставляем в основное неравенство (19.7):

$$\begin{aligned} f(x^{k+1}) - f^* &\leq f(x^k) - f^* + \gamma_k (f^* - f(x^k)) + \gamma_k^2 C \\ &= (1 - \gamma_k)(f(x^k) - f^*) + \gamma_k^2 C. \end{aligned}$$

Докажем по индукции, что для всех целых $k \geq 0$ выполняется:

$$f(x^k) - f^* \leq \frac{2 \max\{2C, f(x^0) - f^*\}}{k+2}.$$

База индукции: для $k = 0$ верное тождество. Рассмотрим $k \geq 1$:

$$\begin{aligned} f(x^{k+1}) - f^* &\leq (1 - \gamma_k)(f(x^k) - f^*) + \gamma_k^2 C \\ &= \left(1 - \frac{2}{k+2}\right)(f(x^k) - f^*) + \left(\frac{2}{k+2}\right)^2 C \\ &\leq \left(1 - \frac{2}{k+2}\right) \frac{2 \max\{2C, f(x^0) - f^*\}}{k+2} + \left(\frac{1}{k+2}\right)^2 2 \cdot 2C, \end{aligned}$$

где в последнем шаге мы использовали предположение индукции. Далее последнее слагаемое оценим максимумом:

$$2 \cdot 2C \leq 2 \max\{2C, f(x^0) - f^*\}.$$

Продолжим неравенство:

$$\begin{aligned} f(x^{k+1}) - f^* &\leq \frac{2 \max\{2C, f(x^0) - f^*\}}{k+2} \left(1 - \frac{2}{k+2} + \frac{1}{k+2}\right) \\ &= \frac{2 \max\{2C, f(x^0) - f^*\}}{k+2} \left(1 - \frac{1}{k+2}\right) \\ &= \frac{2 \max\{2C, f(x^0) - f^*\}}{k+2} \frac{k+1}{k+2}. \end{aligned}$$

Докажем неравенство:

$$\frac{k+1}{(k+2)^2} \leq \frac{1}{k+3}.$$

Оно эквивалентно:

$$(k+1)(k+3) \leq (k+2)^2,$$

что после раскрытия скобок равносильно: $3 \leq 4$.

Получили верное тождество, значит, и исходное неравенство верно, так как все переходы равносильны. Завершим доказательство индукционного перехода и основного утверждения теоремы:

$$f(x^{k+1}) - f^* \leq \frac{2 \max\{2C, f(x^0) - f^*\}}{k+3}.$$

Для получения оценки количества итераций для достижения точности ε запишем оценку (Л9.6) и ограничим правую часть:

$$f(x^K) - f^* \leq \frac{2 \max\{L(\text{diam } \mathcal{X})^2, f(x^0) - f^*\}}{K+2} \leq \varepsilon.$$

Откуда выражается K :

$$K = \mathcal{O}\left(\frac{\max\{L(\text{diam } \mathcal{X})^2, f(x^0) - f^*\}}{\varepsilon}\right).$$

■

Получили сублинейную сходимость по функции в выпуклом случае. Для безусловной задачи градиентный спуск имел такие же оценки $\mathcal{O}\left(\frac{1}{\varepsilon}\right)$. Появляется логичный вопрос об оптимальности метода Франк-Вульфа в классе методов, использующих ЛМО и $\nabla f(x)$, для решения выпуклых задач. Оказывается, имеют место нижние оценки.

Л9.3.1 Нижние оценки для ЛМО

Л9.3.2 Линейная минимизация как отдельная задача

Рассмотрим линейную задачу на выпуклом замкнутом множестве $\mathcal{X}$:

$$\operatorname{argmin}_{y \in \mathcal{X}} \langle x, y \rangle \quad (\text{Л9.8})$$

Получим аналитическое решение для некоторых простых множеств $\mathcal{X}$.

Утверждение Л9.12. Пусть задача линейной минимизации (Л9.8) решается на ℓ_1 -шаре радиуса R с центром в 0

$$\mathcal{X} = \left\{ y \in \mathbb{R}^d \mid \|y\|_1 \leq R \right\}.$$

Тогда её решение:

$$y^* = -R \operatorname{sign}(x_i) e_i, \text{ где } i = \operatorname{argmax}_{j=\overline{1,d}} |x_j|.$$

Доказательство. Запишем Лагранжиан:

$$\mathcal{L}(y, \lambda) = \langle x, y \rangle + \lambda(\|y\|_1 - R) = \sum_{i=1}^d (y_i x_i + \lambda |y_i|) - \lambda R.$$

Лагранжиан распадается по координатам, введём обозначение:

$$\mathcal{L}_i(y, \lambda) = y_i x_i + \lambda |y_i|.$$

Воспользуемся теоремой Каруша–Куна–Таккера (Теорема С8.1):

1. Ограничения: $\|y\|_1 - R \leq 0$;
2. Неотрицательность: $\lambda \geq 0$;
3. Дополняющая нежесткость: $\lambda(\|y\|_1 - R) = 0$;
4. Стационарность: $0 \in x_i + \lambda \partial |y_i|$:

$$0 \in x_i + \lambda \begin{cases} -1, & y_i < 0, \\ [-1, 1], & y_i = 0, \\ 1, & y_i > 0. \end{cases}$$

Всем этим условиям удовлетворяет решение:

$$y^* = -R \operatorname{sign}(x_i) e_i, \quad \lambda = |x_i|,$$

где $i = \operatorname{argmax}_{j=\overline{1,d}} |x_j|$. ■

Утверждение Л9.13. Пусть задача линейной минимизации (Л9.8) решается на ℓ_2 -шаре радиуса R с центром в 0

$$\mathcal{X} = \left\{ y \in \mathbb{R}^d \mid \|y\|_2 \leq R \right\}.$$

Тогда её решение:

$$y^* = \begin{cases} -\frac{x}{\|x\|_2} R, & x \neq 0, \\ 0, & x = 0. \end{cases}$$

Доказательство. Запишем лагранжиан:

$$\mathcal{L}(y, \lambda) = \langle x, y \rangle + \lambda (\|y\|_2^2 - R^2).$$

Воспользуемся теоремой Каруша–Куна–Таккера (Теорема С8.1):

1. Ограничения: $\|y\|_2 - R \leq 0$;
2. Неотрицательность: $\lambda \geq 0$;
3. Дополняющая нежёсткость: $\lambda (\|y\|_2 - R) = 0$;
4. Стационарность: $x + 2\lambda y = 0$.

Рассмотрим варианты:

- Для $x = 0$ пара $y^* = 0$ и $\lambda^* = 0$ удовлетворяет всем условиям.
- Для $x \neq 0$ из стационарности получаем, что $\lambda > 0$ и

$$y = -\frac{x}{2\lambda},$$

а из дополняющей нежёсткости:

$$\|y\|_2 = R.$$

Тогда, собирая все вместе, получаем:

$$\frac{\|x\|_2}{2\lambda} = \|y\|_2 = R \implies \lambda = \frac{\|x\|_2}{2R}, \quad y^* = -\frac{x}{\|x\|_2} R.$$

■

Утверждение Л9.14. Пусть задача линейной минимизации (Л9.8) решается на ℓ_∞ -шаре радиуса R с центром в 0:

$$\mathcal{X} = \left\{ y \in \mathbb{R}^d \mid \|y\|_\infty \leq R \right\}.$$

Тогда её решение:

$$y^* = -R \operatorname{sign}(x).$$

Доказательство. Запишем лагранжиан с двумя покомпонентными множителями неравенств $\lambda_1, \lambda_2 \geq 0$ для ограничений $y - \mathbf{R} \preceq 0$ и $-y - \mathbf{R} \preceq 0$:

$$\mathcal{L}(y, \lambda_1, \lambda_2) = \langle x, y \rangle + \lambda_1^\top (y - \mathbf{R}) + \lambda_2^\top (-y - \mathbf{R}).$$

Воспользуемся теоремой Каруша–Куна–Таккера (Теорема С8.1):

1. Ограничения: $-\mathbf{R} \preceq y \preceq \mathbf{R}$;

2. Неотрицательность: $\lambda_1 \succeq 0, \lambda_2 \succeq 0$;
3. Дополняющая нежёсткость: $\lambda_1^i(y_i - R) = 0, \lambda_2^i(-y_i - R) = 0$;
4. Стационарность: $x + \lambda_1 - \lambda_2 = 0$.

Рассмотрим варианты:

- Если $x_i > 0$, то $y_i^* = -R, \lambda_1^i = 0$ и $\lambda_2^i = x_i$.
- Если $x_i < 0$, то $y_i^* = R, \lambda_1^i = -x_i$ и $\lambda_2^i = 0$.
- Если $x_i = 0$, то $y_i^* = 0, \lambda_1^i = 0$ и $\lambda_2^i = 0$.

■

Утверждение Л9.15. Пусть задача линейной минимизации (Л9.8) решается на симплексе размера R :

$$\mathcal{X} = \left\{ y \in \mathbb{R}^d \mid y \succeq 0, \mathbf{1}^\top y = R \right\}.$$

Тогда её решение:

$$y^* = Re_i, \text{ где } i = \operatorname{argmin}_{j=1, d} x_j.$$

Доказательство. Запишем лагранжиан:

$$\mathcal{L}(y, \lambda, \nu) = \langle x, y \rangle - \lambda^\top y - \nu(\mathbf{1}^\top y - R).$$

Воспользуемся теоремой Каруша–Куна–Таккера (Теорема С8.1):

1. Ограничения: $y \succeq 0, \mathbf{1}^\top y = R$;
2. Неотрицательность: $\lambda \succeq 0$;
3. Дополняющая нежёсткость: $\lambda_i y_i = 0$;
4. Стационарность: $x - \lambda - \nu = 0$.

Возьмем

$$y^* = Re_i, \lambda_j = x_j - x_i, \nu = -x_i,$$

где $i = \operatorname{argmin}_{j=1, d} x_j$.

■

Утверждение Л9.16. Пусть задача линейной минимизации (Л9.8) решается на гиперпрямоугольнике:

$$\mathcal{X} = \left\{ y \in \mathbb{R}^d \mid a \preceq y \preceq b \right\}.$$

Тогда её решение:

$$y^* = \frac{a+b}{2} + \frac{a-b}{2} \operatorname{sign}(x).$$

Доказательство. Запишем лагранжиан с двумя покомпонатными множителями неравенств $\lambda_1, \lambda_2 \geq 0$ для ограничений $y - b \preceq 0$ и $-y + a \preceq 0$:

$$\mathcal{L}(y, \lambda_1, \lambda_2) = \langle x, y \rangle + \lambda_1^\top (y - b) + \lambda_2^\top (-y + a).$$

Воспользуемся теоремой Каруша–Куна–Таккера (Теорема С8.1):

1. Ограничения: $a \preceq y \preceq b$;
2. Неотрицательность: $\lambda_1 \succeq 0, \lambda_2 \succeq 0$;
3. Дополняющая нежёсткость: $\lambda_1^i (y_i - b_i) = 0, \lambda_2^i (-y_i + a_i) = 0$;
4. Стационарность: $x + \lambda_1 - \lambda_2 = 0$.

Рассмотрим покомпонатно:

- Если $x_i > 0$, то $y_i^* = a_i, \lambda_1^i = 0$ и $\lambda_2^i = a_i$.
- Если $x_i < 0$, то $y_i^* = b_i, \lambda_1^i = -b_i$ и $\lambda_2^i = 0$.
- Если $x_i = 0$, то $y_i^* = 0, \lambda_1^i = 0$ и $\lambda_2^i = 0$.

■

Л9.3.3 Критерий сходимости

В ходе работы метода Франк–Вульфа (Алгоритм Л9.2) надо как-то оценивать точность текущего решения. В безусловных задачах мы использовали такие классические критерии, как норма градиента, значение целевой функции с известным минимумом. При оптимизации на ограниченном множестве они не применимы — вспоминаем пример $\min_{x \in [1,2]} x^2$. В оптимальном $x^* = 1$ градиент не равен нулю.

Решением этой проблемы будет метрика гар, которая определяется следующим образом:

$$\text{гар}(x^k) = \max_{y \in \mathcal{X}} \langle \nabla f(x^k), x^k - y \rangle = \langle \nabla f(x^k), x^k \rangle - \min_{y \in \mathcal{X}} \langle \nabla f(x^k), y \rangle. \quad (\text{Л9.9})$$

Её физический смысл становится ясным при применении выпуклости f (Определение Л2.3):

$$\text{гар}(x^k) = \max_{y \in \mathcal{X}} \langle \nabla f(x^k), x^k - y \rangle \geq \max_{y \in \mathcal{X}} (f(x^k) - f(y)) = f(x^k) - f^*.$$

Иными словами, если мы потребуем точность ε по гар, то получим точность ε и по функции:

$$f(x^k) - f^* \leq \text{гар}(x^k) \leq \varepsilon.$$

Другим преимуществом метрики гар является легкость её вычисления. В самом деле, ЛМО возвращает нам решение линейной задачи оптимизации, умножив его скалярно на градиент, получаем второе слагаемое в записи (Л9.9). Первое слагаемое находится так же просто.

Получим аналитические выражения для метрики гар для «простых» множеств.

- ℓ_1 -шар радиуса R с центром в 0:

$$\mathcal{X} = \left\{ y \in \mathbb{R}^d \mid \|y\|_1 \leq R \right\},$$

$$\text{гар}(x^k) = \langle \nabla f(x^k), x^k \rangle + R \left| (\nabla f(x^k))_i \right|, \text{ где } i = \operatorname{argmax}_{j=\overline{1,d}} |x_j|.$$

- ℓ_2 -шар радиуса R с центром в 0:

$$\mathcal{X} = \left\{ y \in \mathbb{R}^d \mid \|y\|_2 \leq R \right\},$$

$$\text{gap}(x^k) = \langle \nabla f(x^k), x^k \rangle + R \|\nabla f(x^k)\|_2.$$

- ℓ_∞ -шар радиуса R с центром в 0:

$$\mathcal{X} = \left\{ y \in \mathbb{R}^d \mid \|y\|_\infty \leq R \right\},$$

$$\text{gap}(x^k) = \langle \nabla f(x^k), x^k \rangle + R \|\nabla f(x^k)\|_1.$$

- Симплекс $\triangle_{d-1}$ размера R :

$$\mathcal{X} = \left\{ y \in \mathbb{R}^d \mid y \succeq 0, \mathbf{1}^\top y = R \right\},$$

$$\text{gap}(x^k) = \langle \nabla f(x^k), x^k \rangle - R(\nabla f(x^k))_i, \text{ где } i = \underset{j=1, d}{\operatorname{argmin}} x_j.$$

- Гиперпрямоугольник:

$$\mathcal{X} = \left\{ y \in \mathbb{R}^d \mid a \preceq y \preceq b \right\},$$

$$\text{gap}(x^k) = \langle \nabla f(x^k), x^k \rangle - \frac{1}{2} \langle \nabla f(x^k) + |\nabla f(x^k)|, a \rangle - \frac{1}{2} \langle \nabla f(x^k) - |\nabla f(x^k)|, b \rangle.$$