Л1 Градиентный спуск с проекцией. Алгоритм Франк–Вульфа

В предыдущих параграфах рассматривались безусловные задачи оптимизации, то есть задачи без ограничений на всем пространстве $\mathbb{R}^d$. Однако не все задачи на практике можно сформулировать в такой постановке — чаще всего, решается задача с ограничением оптимизируемых переменных на некоторое множество $\mathcal{X} \subseteq \mathbb{R}^d$. В этом параграфе речь пойдет об оптимизации на выпуклых множествах. Определим этот класс множеств.

Определение Л1.1. Множество $\mathcal{X} \subseteq \mathbb{R}^d$ называется *выпуклым*, если для любых двух точек x_1, $x_2 \in \mathcal{X}$ и любого числа $\alpha \in [0, 1]$, точка $\alpha x_1 + (1 - \alpha)x_2$ также принадлежит $\mathcal{X}$.

Физический смысл заключается в том, что вместе с любыми двумя точками выпуклого множества в него входит и отрезок с концами в этих точках. Подробнее выпуклые множества обсуждаются в рамках данного пособия в разделе **??**. На выпуклые множества естественно переносится определение выпуклой функции.

Определение Л1.2. Рассмотрим функцию $f : \mathcal{X} \to \mathbb{R}$. Функция f называется *выпуклой* на выпуклом множестве $\mathcal{X}$, если для любых $x_1, \dots, x_k \in \mathcal{X}$ и любых $\alpha_1, \dots, \alpha_k$, $\alpha_i \geq 0$, $\sum\limits_{i=1}^{k} \alpha_i = 1$ выполняется

$$f\left(\sum_{i=1}^{k} \alpha_i x_i\right) \leq \sum_{i=1}^{k} \alpha_i f(x_i).$$

Теперь мы готовы перейти к постановке задачи.

Л1.1 Задача оптимизации с ограничениями

Ставится задача на множестве

$$\min_{x \in \mathcal{X}} f(x), \tag{Л1.1}$$

где $\mathcal{X} \subset \mathbb{R}^d$ — выпуклое множество (Определение Л1.1), f — выпуклая на $\mathcal{X}$ функция (Определение Л1.2).

Замечание Л1.1. Графически понять, как выглядит задача, поможет иллюстрация Рис. Л1.1.
Здесь $\mathcal{X}$ — выпуклое замкнутое множество: пятиугольник в $\mathbb{R}^2$, а по вертикальной оси отложено значение функции f. Решением задачи будет точка $x \in \mathcal{X}$, лежащая в множестве и доставляющая минимум функции f.

Важным замечанием будет, что минимум выпуклой функции на множестве может не совпадать с глобальным для $\mathbb{R}^d$. Более того, условия оптимальности (Утверждения **??** и **??**) для $\mathbb{R}^d$ не будут работать для задачи на выпуклом множестве. Чтобы в этом убедиться, можно рассмотреть пример $\min_{x \in [1,2]} x^2$. Минимум достигается в точке $x^* = 1$, градиент в ней не равен нулю. Это подводит нас к следующему критерию.

Теорема Л1.1. [Параграф 4.2.3. из [1]] Пусть дана выпуклая непрерывно дифференцируемая на $\mathbb{R}^d$ функция $f : \mathbb{R}^d \to \mathbb{R}$ и выпуклое множество $\mathcal{X} \subseteq \mathbb{R}^d$. Тогда $x^* \in \mathcal{X}$ — глобальный минимум f на $\mathcal{X}$ тогда и только тогда, когда для всех

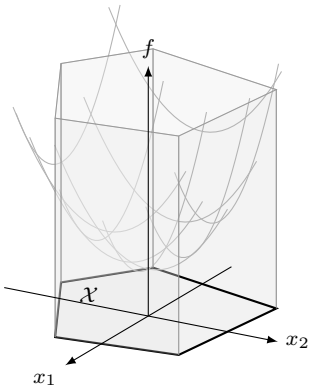


Рис. Л1.1: Пример задачи с ограничением.

$x \in \mathcal{X}$ выполнено:

$$\langle \nabla f(x^*), x - x^* \rangle \geq 0.$$

Доказательство. $\Rightarrow$ Пусть x^* — глобальный минимум на $\mathcal{X}$. Хотим доказать, что $\langle \nabla f(x^*), x - x^* \rangle \geq 0$ для любого $x \in \mathcal{X}$. Пойдем от противного: предположим, что существует $x \in \mathcal{X}$ такой, что:

$$\langle \nabla f(x^*), x - x^* \rangle < 0.$$

Рассмотрим точки вида:

$$x_\lambda = \lambda x + (1 - \lambda)x^*, \ \lambda \in [0, 1].$$

В силу выпуклости множества $\mathcal{X}$ (Определение Л1.1) точки $x_\lambda \in \mathcal{X}$.
Посмотрим, как ведет себя функция $\phi : [0, 1] \to \mathbb{R}$ вида:

$$\phi(\lambda) = f(x_\lambda) = f(\lambda x + (1 - \lambda)x^*).$$

Её производная вычисляется как:

$$\frac{\mathrm{d}\phi}{\mathrm{d}\lambda} = \frac{\mathrm{d}}{\mathrm{d}\lambda} f(\lambda x + (1 - \lambda)x^*) = \langle \nabla f(x^* + \lambda(x - x^*)), x - x^* \rangle.$$

Обратим внимание, что в нуле по предположению

$$\left.\frac{\mathrm{d}\phi}{\mathrm{d}\lambda}\right|_{\lambda=0} = \langle \nabla f(x^*), x - x^* \rangle < 0.$$

Это значит, что функция ϕ убывает в окрестности нуля. Следовательно, для достаточно малых $\lambda > 0$ выполнено:

$$f(x_\lambda) = \phi(\lambda) < \phi(0) = f(x^*).$$

Пришли к противоречию с тем, что x^* — глобальный минимум на $\mathcal{X}$.
$\Leftarrow$ Пусть $\langle \nabla f(x^*), x - x^* \rangle \geq 0$ для всех $x \in \mathcal{X}$. Тогда воспользуемся выпуклостью f на $\mathbb{R}^d$ (Определение **??**):

$$f(x) \geq f(x^*) + \langle \nabla f(x^*), x - x^* \rangle \geq f(x^*).$$

Откуда следует, что x^* — глобальный минимум на $\mathcal{X}$.

■

Физический смысл Теоремы Л1.1 проиллюстрирован на Рисунке Л1.2.

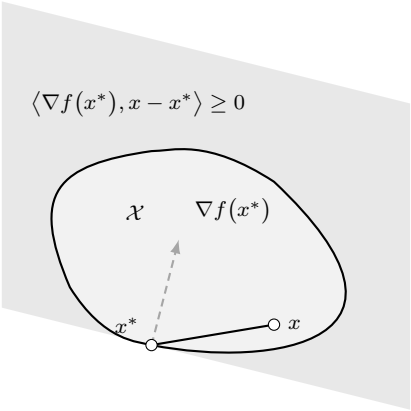


Рис. Л1.2: Геометрическая иллюстрация условия оптимальности для выпуклого множества.

С новым условием оптимальности можно переходить к построению методов.

Л1.2 Градиентный спуск с проекцией

Вновь обратимся к методу градиентного спуска (Алгоритм **??**). Он работал на безусловных задачах, то есть на всем $\mathbb{R}^d$. Если просто попытаться его запустить для задачи на множестве, то возникнет проблема: мы можем «выпасть» из множества. Иными словами, на какой-то итерации k может случиться так, что градиентный шаг выводит нас из множества:

$$x^{k+1} = x^k - \gamma_k \nabla f(x^k) \notin \mathcal{X}.$$

Чтобы избежать такого поведения, вводится *операция проектирования*.

Определение Л1.3. *Проекцией* точки $x \in \mathbb{R}^d$ на замкнутое множество $\mathcal{X} \subset \mathbb{R}^d$ называется точка $\Pi_{\mathcal{X}}(x) \in \mathcal{X}$, находящаяся на кратчайшем расстоянии от x, т.е.

$$\|x - \Pi_{\mathcal{X}}(x)\|_2 = \inf_{y \in \mathcal{X}} \|x - y\|_2$$

Замечание Л1.2. Существование проекции гарантируется замкнутостью множества $\mathcal{X}$ и теоремой Вейерштрасса (Теорема 2 Параграфа 7 Главы 2 из [6]), поскольку для непрерывной нормы минимум достигается при заданных условиях.

Из Л1.3 и существования проекции для замкнутого множества можем ввести оператор проекции $\Pi_{\mathcal{X}} : \mathbb{R}^d \to \mathcal{X}$, который задается как:

$$\Pi_{\mathcal{X}}(x) := \operatorname*{argmin}_{y \in \mathcal{X}} \frac{1}{2} \|x - y\|_2^2. \tag{Л1.2}$$

С помощью оператора $\Pi_{\mathcal{X}}(x)$ можно на каждой итерации проецироваться шаг градиентного спуска на множество, чтобы не выходить за его ограничения:

$$x^{k+1} = \Pi_{\mathcal{X}}\left(x^k - \gamma_k \nabla f(x^k)\right) \in \mathcal{X},$$

Эта идея и лежит в основе метода градиентно го спуска с проекцией. Запишем формальный алгоритм.

Алгоритм Л1.1 Градиентный спуск с проекцией

Вход: стартовая точка $x^0 \in \mathbb{R}^d$, размеры шагов $\{\gamma_k\}_{k=0} > 0$, количество итераций K

1: **for** $k = 0, 1, \ldots, K-1$ **do**
2: $\quad x^{k+1} = \Pi_{\mathcal{X}}\left(x^k - \gamma_k \nabla f\left(x^k\right)\right)$
3: **end for**

Выход: x^K

Геометрически принцип работы алгоритма показан на Рисунке Л1.3.

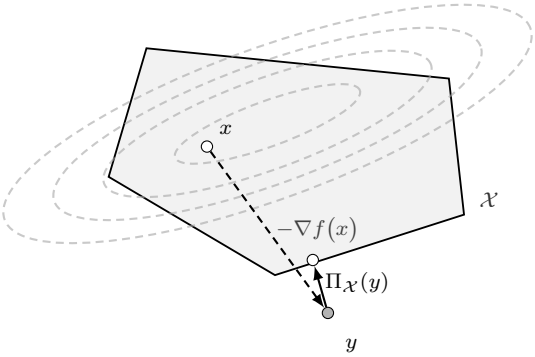


Рис. Л1.3: Проекция точки на множество $\mathcal{X}$.

Л1.2.1 Свойства оператора проекции

Для последующего анализа метода потребуется изучить оператор проекции подробнее.

Утверждение Л1.1. Для выпуклого замкнутого множества $\mathcal{X}$ и любой точки оператор проекции существует и принимает единственное значение.

Доказательство. Задача проекции — это минимизация сильно выпуклой функции на выпуклом множестве:

$$\Pi_{\mathcal{X}}(x) := \operatorname*{argmin}_{y \in \mathcal{X}} \frac{1}{2}\|x - y\|_2^2.$$

Существование и единственность решения в безусловном случае рассматривалось в Теореме **??**. Этот результат легко переносится на случай минимизации на выпуклом множестве: достаточно шар $\overline{B}^2\left(R, x^0\right)$ заменить на пересечение $\overline{B}^2\left(R, x^0\right) \cap \mathcal{X}$, а условие оптимальности для $\mathbb{R}^d$:

$$\nabla f\left(x^*\right) = 0$$

заменить на условие для выпуклого $\mathcal{X}$:

$$\left\langle \nabla f\left(x^*\right), x - x^* \right\rangle \geq 0$$

для всех $x \in \mathcal{X}$. Остальные рассуждения и переходы остаются неизменными. Тогда получаем, что решение такой задачи существует и единственно. ■

Утверждение Л1.2. Пусть $\mathcal{X} \subseteq \mathbb{R}^d$ — выпуклое замкнутое множество, $y \in \mathcal{X}$, $x \in \mathbb{R}^d$. Тогда

$$\langle y - \Pi_{\mathcal{X}}(x), x - \Pi_{\mathcal{X}}(x) \rangle \leq 0.$$

Доказательство. Заметим, что $\Pi_{\mathcal{X}}(x)$ минимизирует дифференцируемую выпуклую функцию $d(z) = \frac{1}{2}\|x - z\|_2^2$ на выпуклом множестве $\mathcal{X}$. Запишем условие оптимальности:

$$\langle \nabla d(\Pi_{\mathcal{X}}(x)), y - \Pi_{\mathcal{X}}(x) \rangle \geq 0$$

для всех $y \in \mathcal{X}$. Подставим $\nabla d(\Pi_{\mathcal{X}}(x)) = \Pi_{\mathcal{X}}(x) - x$ и поменяем местами аргументы скалярного произведения:

$$\langle y - \Pi_{\mathcal{X}}(x), x - \Pi_{\mathcal{X}}(x) \rangle \leq 0$$

для всех $y \in \mathcal{X}$. ■

В следующем утверждении формулируется 1–липшицевость оператора проекции.

Утверждение Л1.3. Пусть $\mathcal{X} \subseteq \mathbb{R}^d$ — выпуклое замкнутое множество, $x_1, x_2 \in \mathbb{R}^d$. Тогда

$$\|\Pi_{\mathcal{X}}(x_1) - \Pi_{\mathcal{X}}(x_2)\|_2 \leq \|x_1 - x_2\|_2.$$

Доказательство. Пользуемся результатом Утверждения Л1.2 для $x_1, x_2 \in \mathbb{R}^d$, $x \in \mathcal{X}$:

$$\langle x_1 - \Pi_{\mathcal{X}}(x_1), x - \Pi_{\mathcal{X}}(x_1) \rangle \leq 0,$$
$$\langle x_2 - \Pi_{\mathcal{X}}(x_2), x - \Pi_{\mathcal{X}}(x_2) \rangle \leq 0.$$

Подставим $x = \Pi_{\mathcal{X}}(x_2)$ в первое неравенство и $x = \Pi_{\mathcal{X}}(x_1)$ во второе:

$$\langle x_1 - \Pi_{\mathcal{X}}(x_1), \Pi_{\mathcal{X}}(x_2) - \Pi_{\mathcal{X}}(x_1) \rangle \leq 0,$$
$$\langle x_2 - \Pi_{\mathcal{X}}(x_2), \Pi_{\mathcal{X}}(x_1) - \Pi_{\mathcal{X}}(x_2) \rangle \leq 0.$$

Сложим и получим:

$$\langle \Pi_{\mathcal{X}}(x_2) - \Pi_{\mathcal{X}}(x_1), \Pi_{\mathcal{X}}(x_2) - \Pi_{\mathcal{X}}(x_1) \rangle \leq \langle \Pi_{\mathcal{X}}(x_2) - \Pi_{\mathcal{X}}(x_1), x_2 - x_1 \rangle.$$

Применим неравенство Коши–Буняковского–Шварца (**??**):

$$\|\Pi_{\mathcal{X}}(x_2) - \Pi_{\mathcal{X}}(x_1)\|_2^2 \leq \|\Pi_{\mathcal{X}}(x_2) - \Pi_{\mathcal{X}}(x_1)\|_2 \|x_2 - x_1\|_2.$$

Откуда имеем:

$$\|\Pi_{\mathcal{X}}(x_2) - \Pi_{\mathcal{X}}(x_1)\|_2 \leq \|x_2 - x_1\|_2.$$

■

Утверждение Л1.4. Пусть x^* — решение условной задачи (Л1.1) минимизации выпуклой непрерывно дифференцируемой функции f на выпуклом замкнутом множестве $\mathcal{X}$. Тогда справедливо

$$x^* = \Pi_{\mathcal{X}}\big(x^* - \gamma \nabla f(x^*)\big)$$

Доказательство. Распишем определение оператора проекции (Л1.2):

$$\begin{aligned}\Pi_{\mathcal{X}}\big(x^* - \gamma\nabla f(x^*)\big) &= \operatorname*{argmin}_{y\in\mathcal{X}} \frac{1}{2}\big\|x^* - \gamma\nabla f(x^*) - y\big\|_2^2 \\ &= \operatorname*{argmin}_{y\in\mathcal{X}} \frac{1}{2}\Big[\big\|x^* - y\big\|_2^2 + 2\gamma\big\langle\nabla f(x^*), y - x^*\big\rangle + \gamma^2\big\|\nabla f(x^*)\big\|_2^2\Big].\end{aligned}$$

Откуда:

$$\Pi_{\mathcal{X}}\big(x^* - \gamma\nabla f(x^*)\big) = \operatorname*{argmin}_{y\in\mathcal{X}} \frac{1}{2}\Big[\big\|x^* - y\big\|_2^2 + 2\gamma\big\langle\nabla f(x^*), y - x^*\big\rangle\Big].$$

Оба слагаемых под argmin неотрицательны: первое в силу неотрицательности квадрата нормы, второе в силу Теоремы Л1.1. Следовательно, минимум равен 0, и достигается он на x^*. ■

Этих свойств оператора проекции нам будет достаточно, чтобы произвести анализ сходимости метода.

Л1.2.2 Теоретические оценки сходимости

Теорема Л1.2. Пусть задача на ограниченном выпуклом замкнутом множестве $\mathcal{X}$ (Л1.1) с L–гладкой μ–сильно выпуклой целевой функцией f решается с помощью градиентного спуска с проекцией (Алгоритм Л1.1). Тогда при $\gamma_k \leq \frac{1}{L}$ справедлива следующая оценка сходимости:

$$\big\|x^K - x^*\big\|_2^2 \leq \left(\prod_{k=0}^{K-1}\big(1 - \mu\gamma_k\big)\right)\big\|x^0 - x^*\big\|_2^2.$$

Доказательство. Рассмотрим $\big\|x^{k+1} - x^*\big\|_2^2$. Подставим итерацию метода:

$$\big\|x^{k+1} - x^*\big\|_2^2 = \big\|\Pi_{\mathcal{X}}\big(x^k - \gamma_k\nabla f(x^k)\big) - x^*\big\|_2^2.$$

Воспользуемся Утверждением Л1.4:

$$\big\|x^{k+1} - x^*\big\|_2^2 = \big\|\Pi_{\mathcal{X}}\big(x^k - \gamma_k\nabla f(x^k)\big) - \Pi_{\mathcal{X}}\big(x^* - \gamma_k\nabla f(x^*)\big)\big\|_2^2.$$

А теперь применяем неравенство из Утверждения Л1.3:

$$\big\|x^{k+1} - x^*\big\|_2^2 \leq \big\|\big(x^k - \gamma_k\nabla f(x^k)\big) - \big(x^* - \gamma_k\nabla f(x^*)\big)\big\|_2^2.$$

Раскроем квадрат нормы:

$$\big\|x^{k+1} - x^*\big\|_2^2 \leq \big\|x^k - x^*\big\|_2^2 - 2\gamma_k\big\langle x^k - x^*, \nabla f(x^k) - \nabla f(x^*)\big\rangle + \gamma_k^2\big\|\nabla f(x^k) - \nabla f(x^*)\big\|_2^2.$$

Оценим последнее слагаемое, используя свойство L–гладкой выпуклой f (неравенство (**??**) из Теоремы **??**):

$$\begin{aligned}\big\|x^{k+1} - x^*\big\|_2^2 &\leq \big\|x^k - x^*\big\|_2^2 - 2\gamma_k\big\langle x^k - x^*, \nabla f(x^k) - \nabla f(x^*)\big\rangle \\ &\quad + \gamma_k^2 L\big\langle\nabla f(x^k) - \nabla f(x^*), x^k - x^*\big\rangle \\ &= \big\|x^k - x^*\big\|_2^2 - \gamma_k\big(2 - \gamma_k L\big)\big\langle\nabla f(x^k) - \nabla f(x^*), x^k - x^*\big\rangle.\end{aligned} \tag{Л1.3}$$

Два раза запишем определение μ–сильной выпуклости f (Определение **??**):

$$\begin{aligned} f(x^k) &\geq f(x^*) + \langle \nabla f(x^*), x^k - x^* \rangle + \frac{\mu}{2}\|x^k - x^*\|_2^2, \\ f(x^*) &\geq f(x^k) + \langle \nabla f(x^k), x^* - x^k \rangle + \frac{\mu}{2}\|x^* - x^k\|_2^2. \end{aligned} \tag{Л1.4}$$

Сложим их и получим:

$$\langle \nabla f(x^k) - \nabla f(x^*), x^k - x^* \rangle \geq \mu \|x^k - x^*\|_2^2.$$

Подставляем в неравенство (Л1.3) неравенство (Л1.4):

$$\begin{aligned} \|x^{k+1} - x^*\|_2^2 &\leq \|x^k - x^*\|_2^2 - \mu\gamma_k(2 - \gamma_k L)\|x^k - x^*\|_2^2 \\ &= (1 - \mu\gamma_k(2 - \gamma_k L))\|x^k - x^*\|_2^2. \end{aligned}$$

Поскольку $\gamma_k \leq \frac{1}{L}$, то $2 - \gamma_k L > 1$. Продолжая цепочку неравенств, имеем:

$$\|x^{k+1} - x^*\|_2^2 \leq (1 - \mu\gamma_k)\|x^k - x^*\|_2^2.$$

Остается лишь развернуть рекурсию с K-ой итерации до нулевой:

$$\begin{aligned} \|x^K - x^*\|_2^2 &\leq (1 - \mu\gamma_{K-1})\|x^{K-1} - x^*\|_2^2 \\ &\leq (1 - \mu\gamma_{K-1})(1 - \mu\gamma_{K-2})\|x^{K-2} - x^*\|_2^2 \\ &\leq \dots \\ &\leq \left(\prod_{k=0}^{K-1}(1 - \mu\gamma_k)\right)\|x^0 - x^*\|_2^2. \end{aligned}$$

■

Утверждение Л1.5. Пусть задача удовлетворяет условиям Теоремы Л1.2 и выбрано значение шага $\gamma_k = \frac{1}{L}$. Тогда справедлива следующая оценка сходимости:

$$\|x^K - x^*\|_2^2 \leq \left(1 - \frac{\mu}{L}\right)^K \|x^0 - x^*\|_2^2.$$

Более того, чтобы добиться точности ε по аргументу $\left(\|x^K - x^*\|_2 \leq \varepsilon\right)$, необходимо

$$K = \mathcal{O}\left(\frac{L}{\mu}\log\frac{\|x^0 - x^*\|_2}{\varepsilon}\right) \text{ итераций.}$$

Доказательство. Повторяет доказательство Утверждения **??**. ■

Л1.2.3 Проекция как отдельная задача

Рассмотрим задачу поиска проекции:

$$\operatorname*{argmin}_{y \in \mathcal{X}} \frac{1}{2}\|x - y\|_2^2. \tag{Л1.5}$$

Получим аналитическое решение для некоторых простых множеств $\mathcal{X}$.

Утверждение Л1.6. Пусть задача проекции (Л1.5) решается на ℓ_1–шаре радиуса R с центром в 0:

$$\mathcal{X} = \left\{ y \in \mathbb{R}^d \;\middle|\; \|y\|_1 \leq R \right\}.$$

Тогда оператор проекции имеет вид:

$$\Pi_{\mathcal{X}}(x) = \begin{cases} x, & \|x\|_1 \leq R, \\ \operatorname{sign}(x_i)\big(|x_i| - \lambda\big)_+ \;\forall i \in \overline{1,d}, & \|x\|_1 > R, \end{cases}$$

где λ определяется из уравнения

$$\sum_{i=1}^{d} (|x_i| - \lambda)_+ = R.$$

Доказательство. Запишем лагранжиан:

$$\mathcal{L}(y, \lambda) = \frac{1}{2}\|x - y\|_2^2 + \lambda\big(\|y\|_1 - R\big) = \sum_{i=1}^{d} \left(\frac{1}{2}(y_i - x_i)^2 + \lambda |y_i| \right) - \lambda R.$$

Воспользуемся теоремой Каруша–Куна–Таккера (Теорема **??**):

1. Ограничения: $\|y\|_1 - R \leq 0$;
2. Неотрицательность: $\lambda \geq 0$;
3. Дополняющая нежёсткость: $\lambda\big(\|y\|_1 - R\big) = 0$;
4. Стационарность: $0 \in y_i - x_i + \lambda \partial |y_i|$.

Последнему условию удовлетворяет:

$$y_i = \operatorname{sign}(x_i)\big(|x_i| - \lambda\big)_+.$$

- Если $\lambda = 0$, то $y = x$ и требуется $\|x\|_1 \leq R$.
- Если $\lambda > 0$, то $\sum_{i=1}^{d} |y_i| = R$, что даёт уравнение на λ: $g(\lambda) = \sum_{i=1}^{d} (|x_i| - \lambda)_+ - R$. Единственность следует из монотонного убывания.

■

Утверждение Л1.7. Пусть задача проекции (Л1.5) решается на ℓ_2–шаре радиуса R с центром в 0:

$$\mathcal{X} = \left\{ y \in \mathbb{R}^d \;\middle|\; \|y\|_2 \leq R \right\}.$$

Тогда оператор проекции имеет вид:

$$\Pi_{\mathcal{X}}(x) = \min\left\{ 1, \frac{R}{\|x\|_2} \right\} x.$$

Доказательство. Запишем лагранжиан:

$$\mathcal{L}(y, \lambda) = \frac{1}{2}\|x - y\|_2^2 + \lambda\Big(\|y\|_2^2 - R^2\Big).$$

Воспользуемся теоремой Каруша–Куна–Таккера (Теорема **??**):

1. Ограничения: $\|y\|_2 - R \le 0$;
2. Неотрицательность: $\lambda \ge 0$;
3. Дополняющая нежёсткость: $\lambda(\|y\|_2 - R) = 0$;
4. Стационарность: $y - x + 2\lambda y = 0$.

Из стационарности имеем $(1 + 2\lambda)y = x$.

- Если $\lambda = 0$, то $y = x$, и из ограничений имеем $\|x\|_2 \le R$.
- Если $\lambda > 0$, то из дополняющей нежёсткости $\|y\|_2 = R$, а потому

$$y = \frac{x}{1 + 2\lambda},\ R = \|y\|_2 = \frac{\|x\|_2}{1 + 2\lambda} \implies y = \frac{R}{\|x\|_2}x.$$

  Это случай для $\|x\|_2 > R$.

■

Утверждение Л1.8. Пусть задача проекции (Л1.5) решается на ℓ_∞–шаре радиуса R с центром в 0:

$$\mathcal{X} = \Big\{\, y \in \mathbb{R}^d \;\Big|\; \|y\|_\infty \le R \,\Big\}.$$

Тогда оператор проекции имеет вид:

$$[\Pi_{\mathcal{X}}(x)]_i = \begin{cases} -R, & x_i < -R, \\ x_i, & -R \le x_i \le R, \\ R, & x_i > R. \end{cases}$$

Доказательство. Запишем лагранжиан с двумя покоординатными множителями неравенств $\lambda_1, \lambda_2 \ge 0$ для ограничений $y - \mathbf{R} \preceq 0$ и $-y - \mathbf{R} \preceq 0$:

$$\mathcal{L}(y, \lambda_1, \lambda_2) = \frac{1}{2}\|x - y\|_2^2 + \lambda_1^\top (y - \mathbf{R}) + \lambda_2^\top (-y - \mathbf{R}).$$

Воспользуемся теоремой Каруша–Куна–Таккера (Теорема **??**):

1. Ограничения: $-\mathbf{R} \preceq y \preceq \mathbf{R}$;
2. Неотрицательность: $\lambda_1 \succeq 0$, $\lambda_2 \succeq 0$;
3. Дополняющая нежёсткость: $\lambda_1^i(y_i - R) = 0$, $\lambda_2^i(-y_i - R) = 0$;
4. Стационарность: $y - x + \lambda_1 - \lambda_2 = 0$.

Рассмотрим покоординатно:

- Если $-R < x_i < R$, то $y_i = x_i$, при этом $\lambda_1^i = \lambda_2^i = 0$;

- Если $x_i > R$, то $y_i = R$, при этом условие дополняющей нежёсткости требует $\lambda_2^i = 0$, а стационарность даёт $\lambda_1^i = x_i - R > 0$;
- Если $x_i < -R$, то $y_i = -R$, при этом условие дополняющей нежёсткости требует $\lambda_1^i = 0$, а стационарность даёт $\lambda_2^i = -x_i - R > 0$.

■

Утверждение Л1.9. Пусть задача проекции (Л1.5) решается на симплексе размера R:

$$\mathcal{X} = \left\{ y \in \mathbb{R}^d \;\middle|\; y \succeq 0,\ \mathbf{1}^\top y = R \right\}.$$

Тогда оператор проекции имеет вид:

$$[\Pi_{\mathcal{X}}(x)]_i = (x_i + \nu)_+,$$

где ν определяется из уравнения

$$\sum_{i=1}^{d} (x_i + \nu)_+ = R.$$

Доказательство. Запишем лагранжиан:

$$\mathcal{L}(y, \lambda, \nu) = \frac{1}{2}\|x - y\|_2^2 - \lambda^\top y - \nu\big(\mathbf{1}^\top y - R\big).$$

Воспользуемся теоремой Каруша–Куна–Таккера (Теорема **??**):

1. Ограничения: $y \succeq 0$, $\mathbf{1}^\top y = R$;
2. Неотрицательность: $\lambda \succeq 0$;
3. Дополняющая нежёсткость: $\lambda_i y_i = 0$;
4. Стационарность: $y - x - \lambda - \boldsymbol{\nu} = 0$.

Из стационарности имеем

$$y = x + \lambda + \boldsymbol{\nu}.$$

Используя дополняющую нежёсткость, получаем:

$$y_i = \frac{1}{2}\big((x_i + \nu) + |x_i + \nu|\big) = (x_i + \nu)_+,$$
$$\lambda_i = \frac{1}{2}\big(|x_i + \nu| - (x_i + \nu)\big) = (-x_i - \nu)_+.$$

Подставляя это выражение в ограничение $\mathbf{1}^\top y = R$, получаем уравнение на ν:

$$\sum_{i=1}^{d} (x_i + \nu)_+ = R.$$

Поскольку функция монотонно возрастает, то решение для ν единственно. ■

Утверждение Л1.10. Пусть задача проекции (Л1.5) решается на гиперпрямоугольнике:

$$\mathcal{X} = \left\{ y \in \mathbb{R}^d \;\middle|\; a \preceq y \preceq b \right\}.$$

Тогда оператор проекции имеет вид:

$$[\Pi_{\mathcal{X}}(x)]_i = \begin{cases} a_i, & x_i < a_i, \\ x_i, & a_i \le x_i \le b_i, \\ b_i, & x_i > b_i. \end{cases}$$

Доказательство. Запишем лагранжиан с двумя покоординатными множителями неравенств $\lambda_1, \lambda_2 \succeq 0$ для ограничений $y - b \preceq 0$ и $-y + a \preceq 0$:

$$\mathcal{L}(y, \lambda_1, \lambda_2) = \frac{1}{2}\|x - y\|_2^2 + \lambda_1^\top (y - b) + \lambda_2^\top (-y + a).$$

Воспользуемся теоремой Каруша–Куна–Таккера (Теорема **??**):

1. Ограничения: $a \preceq y \preceq b$;
2. Неотрицательность: $\lambda_1 \succeq 0$, $\lambda_2 \succeq 0$;
3. Дополняющая нежёсткость: $\lambda_1^i (y_i - b_i) = 0$, $\lambda_2^i (-y_i + a_i) = 0$;
4. Стационарность: $y - x + \lambda_1 - \lambda_2 = 0$.

Рассмотрим покоординатно:

- Если $a_i < x_i < b_i$, то $y_i = x_i$, при этом $\lambda_1^i = \lambda_2^i = 0$;
- Если $x_i > b_i$, то $y_i = b_i$, при этом условие дополняющей нежёсткости требует $\lambda_2^i = 0$, а стационарность даёт $\lambda_1^i = x_i - b_i > 0$;
- Если $x_i < a_i$, то $y_i = a_i$, при этом условие дополняющей нежёсткости требует $\lambda_1^i = 0$, а стационарность даёт $\lambda_2^i = -x_i + a_i > 0$.

■

Утверждение Л1.11. Пусть задача проекции (Л1.5) решается на множестве линейных равенств:

$$\mathcal{X} = \left\{ y \in \mathbb{R}^d \;\middle|\; Ay = b \right\},$$

где предполагается, что $AA^\top$ невырождена. Тогда оператор проекции имеет вид:

$$\Pi_{\mathcal{X}}(x) = x - A^\top \left(AA^\top\right)^{-1}(Ax - b).$$

Доказательство. Запишем лагранжиан:

$$\mathcal{L}(y, \nu) = \frac{1}{2}\|x - y\|_2^2 + \nu^\top (Ay - b).$$

Воспользуемся теоремой Каруша–Куна–Таккера (Теорема **??**):

1. Ограничения: $Ay = b$;

2. Стационарность: $y - x + A^\top \nu = 0$.

Из стационарности

$$y = x - A^\top \nu.$$

Подставляя в ограничение, получаем

$$Ax - AA^\top \nu = b \implies \nu = \left(AA^\top\right)^{-1}(Ax - b).$$

Следовательно:

$$y = x - A^\top \left(AA^\top\right)^{-1}(Ax - b).$$

■

Л1.3 Метод Франк–Вульфа

В методе градиентного спуска с проекцией (Алгоритм Л1.1) операция проекции для некоторых множеств $\mathcal{X}$ может быть вычислительно дорогой или вовсе не иметь аналитического выражения. Однако во многих случаях доступна более простая процедура — решение задачи линейной минимизации:

$$s^k = \operatorname*{argmin}_{s \in \mathcal{X}} \langle s, \nabla f(x^k) \rangle.$$

Иными словами, мы умеем находить такую точку $s^k \in \mathcal{X}$, которая минимизирует линейное приближение функции f в окрестности x^k. Эту операцию часто записывают через оракул линейной минимизации (Linear Minimization Oracle):

$$\mathrm{LMO}(c) = \operatorname*{argmin}_{s \in \mathcal{X}} \langle s, c \rangle.$$

Алгоритм, использующий на каждом шаге вызов LMO и последующее усреднение с текущей точкой, был предложен Маргаритой Франк и Филипом Вульфом в 1956 году [3]. Он известен как *метод условного градиента* или *метод Франк–Вульфа*.

Алгоритм Л1.2 Метод Франк–Вульфа

Вход: стартовая точка $x^0 \in \mathcal{X}$, размеры шагов $\{\gamma_k\}_{k=0} \in [0, 1]$, количество итераций K

1: **for** $k = 0, 1, \ldots, K-1$ **do**
2: $\quad s^k = \operatorname{argmin}_{s \in \mathcal{X}} \langle s, \nabla f(x^k) \rangle$
3: $\quad x^{k+1} = (1 - \gamma_k) x^k + \gamma_k s^k$
4: **end for**

Выход: x^K

LMO указывает на экстремальную точку множества $\mathcal{X}$ (интуитивно это «уголок» множества $\mathcal{X}$), а обновление

$$x^{k+1} = \left(1 - \gamma_k\right) x^k + \gamma_k s^k$$

усредняет её с текущим приближением, так что последовательность x^k строится как выпуклая комбинация найденных экстремальных точек.

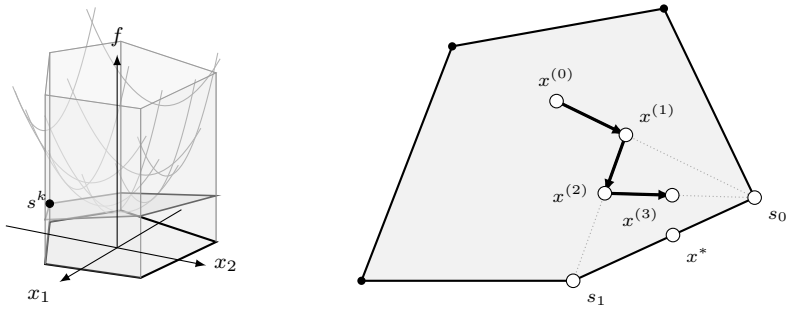


Рис. Л1.4: Шаг Франк–Вульфа.

Замечание Л1.3. В Алгоритме Л1.2 шаг взят произвольным. Классическим выбором считается

$$\gamma_k = \frac{2}{k+2},$$

поскольку для него получаются хорошие теоретические оценки и он легко вычислим на практике. Однако возможен выбор шага линейным поиском:

$$\gamma_k = \operatorname*{argmin}_{\gamma \in [0,1]} f\big(x^k + \gamma\big(s^k - x^k\big)\big).$$

Докажем сходимость для классического выбора шага.

Теорема Л1.3. Пусть задача оптимизации на выпуклом замкнутом множестве (Л1.1) с L–гладкой выпуклой целевой функцией f решается с помощью метода Франк–Вульфа (Алгоритм Л1.2). Тогда при $\gamma_k = \frac{2}{k+2}$ справедлива следующая оценка сходимости:

$$f\big(x^K\big) - f^* \leq \frac{2\max\big\{L\operatorname{diam}(\mathcal{X})^2, f\big(x^0\big) - f^*\big\}}{K+2}, \tag{Л1.6}$$

где $\operatorname{diam}(\mathcal{X}) := \max\limits_{x,y \in \mathcal{X}} \big\|x - y\big\|_2$ — диаметр множества $\mathcal{X}$.

Более того, чтобы добиться точности ε по функции $\big(f\big(x^K\big) - f^* \leq \varepsilon\big)$, необходимо

$$K = \mathcal{O}\left(\frac{\max\{L\operatorname{diam}(\mathcal{X})^2, f\big(x^0\big) - f^*\}}{\varepsilon}\right) \text{ итераций.}$$

Доказательство. Запишем итерацию метода и применим неравенство (**??**) из Теоремы **??**:

$$\begin{aligned} f\big(x^{k+1}\big) - f^* &= f\big(x^k + \gamma_k\big(s^k - x^k\big)\big) - f^* \\ &\leq f\big(x^k\big) - f^* + \gamma_k\big\langle s^k - x^k, \nabla f\big(x^k\big)\big\rangle + \frac{\gamma_k^2}{2} L\big\|s^k - x^k\big\|_2^2 \qquad \text{(Л1.7)} \\ &\leq f\big(x^k\big) - f^* + \gamma_k\big\langle s^k - x^k, \nabla f\big(x^k\big)\big\rangle + \gamma_k^2 C. \end{aligned}$$

В последнем переходе мы применили, что $x^k, s^k \in \mathcal{X}$, и $\big\|s^k - x^k\big\|_2 \leq \operatorname{diam}\mathcal{X}$, а также ввели обозначение $C = \frac{L(\operatorname{diam}\mathcal{X})^2}{2}$.

Примем во внимание, что s^k ищется как решение линейной минимизации:

$$s^k = \operatorname*{argmin}_{s \in \mathcal{X}} \langle s, \nabla f(x^k) \rangle = \operatorname*{argmin}_{s \in \mathcal{X}} \gamma_k \langle s - x^k, \nabla f(x^k) \rangle,$$

откуда следует неравенство:

$$\gamma_k \langle s^k - x^k, \nabla f(x^k) \rangle \leq \gamma_k \langle x^* - x^k, \nabla f(x^k) \rangle.$$

Правую часть можно оценить по выпуклости (Определение **??**) и получить:

$$\gamma_k \langle s^k - x^k, \nabla f(x^k) \rangle \leq \gamma_k (f^* - f(x^k)).$$

Подставляем в основное неравенство (Л1.7):

$$\begin{aligned} f(x^{k+1}) - f^* &\leq f(x^k) - f^* + \gamma_k (f^* - f(x^k)) + \gamma_k^2 C \\ &= (1 - \gamma_k)(f(x^k) - f^*) + \gamma_k^2 C. \end{aligned}$$

Докажем по индукции, что для всех целых $k \geq 0$ выполняется:

$$f(x^k) - f^* \leq \frac{2 \max\{2C, f(x^0) - f^*\}}{k + 2}.$$

База индукции: для $k = 0$ верное тождество. Рассмотрим $k \geq 1$:

$$\begin{aligned} f(x^{k+1}) - f^* &\leq (1 - \gamma_k)(f(x^k) - f^*) + \gamma_k^2 C \\ &= \left(1 - \frac{2}{k+2}\right)(f(x^k) - f^*) + \left(\frac{2}{k+2}\right)^2 C \\ &\leq \left(1 - \frac{2}{k+2}\right) \frac{2 \max\{2C, f(x^0) - f^*\}}{k+2} + \left(\frac{1}{k+2}\right)^2 2 \cdot 2C, \end{aligned}$$

где в последнем шаге мы использовали предположение индукции. Далее последнее слагаемое оценим максимумом:

$$2 \cdot 2C \leq 2 \max\{2C, f(x^0) - f^*\}.$$

Продолжим неравенство:

$$\begin{aligned} f(x^{k+1}) - f^* &\leq \frac{2 \max\{2C, f(x^0) - f^*\}}{k+2} \left(1 - \frac{2}{k+2} + \frac{1}{k+2}\right) \\ &= \frac{2 \max\{2C, f(x^0) - f^*\}}{k+2} \left(1 - \frac{1}{k+2}\right) \\ &= \frac{2 \max\{2C, f(x^0) - f^*\}}{k+2} \frac{k+1}{k+2}. \end{aligned}$$

Докажем неравенство:

$$\frac{k+1}{(k+2)^2} \leq \frac{1}{k+3}.$$

Оно эквивалентно:

$$(k+1)(k+3) \leq (k+2)^2,$$

что после раскрытия скобок равносильно: $3 \leq 4$.

Получили верное тождество, значит, и исходное неравенство верно, так как все переходы равносильны. Завершим доказательство индукционного перехода и основного утверждения теоремы:

$$f\big(x^{k+1}\big) - f^* \leq \frac{2\max\{2C, f\big(x^0\big) - f^*\}}{k+3}.$$

Для получения оценки количества итераций для достижения точности ε запишем оценку (Л1.6) и ограничим правую часть:

$$f\big(x^K\big) - f^* \leq \frac{2\max\left\{L(\operatorname{diam}\mathcal{X})^2, f\big(x^0\big) - f^*\right\}}{K+2} \leq \varepsilon.$$

Откуда выражается K:

$$K = \mathcal{O}\left(\frac{\max\{L(\operatorname{diam}\mathcal{X})^2, f\big(x^0\big) - f^*\}}{\varepsilon}\right).$$

■

Получили сублинейную сходимость по функции в выпуклом случае. Для безусловной задачи градиентный спуск имел такие же оценки $\mathcal{O}\big(\frac{1}{\varepsilon}\big)$. Появляется логичный вопрос об оптимальности метода Франк–Вульфа в классе методов, использующих LMO и $\nabla f(x)$, для решения выпуклых задач. Оказывается, имеют место нижние оценки.

Л1.3.1 Нижние оценки для LMO

Метод Франк–Вульфа обладает сублинейной скоростью сходимости $\mathcal{O}(\frac{1}{K})$ в классе выпуклых гладких задач. Возникает естественный вопрос — можно ли добиться более быстрой сходимости, используя тот же набор инструментов: градиент $\nabla f(x)$ и оракул линейной минимизации LMO? Оказывается, ответ отрицательный: существует фундаментальное ограничение, определяемое самой структурой допустимого множества и характером направлений, которые предоставляет LMO.

Оператор линейной минимизации выбирает на каждом шаге одну из экстремальных точек множества $s_i \in \mathcal{X}$. Следовательно, каждое новое направление $s^k - x^k$ формируется как комбинация уже выбранных вершин. Итерации метода Франк–Вульфа, таким образом, представляют собой последовательность выпуклых комбинаций всё большего числа вершин (для простоты возьмем в качестве стартовой точки одну из экстремальных точек $\mathcal{I}_0 = \{s_0\} \subset \mathcal{X}$):

$$x^k = \sum_{i \in \mathcal{I}_k} \alpha_i^{(k)} s_i, \quad \sum_{i \in \mathcal{I}_k} \alpha_i^{(k)} = 1, \quad \alpha_i^{(k)} \geq 0.$$

Чтобы достичь оптимума, лежащего во внутренней точке некоторой грани допустимого множества, алгоритму необходимо постепенно «вымывать» веса вершин ($\alpha_i^{(k)} \to 0$), не принадлежащих этой грани. Но каждое усреднение даёт лишь малое смещение в сторону нужной грани, и процесс удаления неактуальных компонент происходит очень медленно. Следовательно, за k итераций метод может исследовать не более чем k направлений, что накладывает фундаментальное ограничение на скорость сходимости.

Утверждение Л1.12. Пусть задача оптимизации (Л1.1) с L–гладкой целевой функцией f решается методом, использующим LMO. Тогда чтобы добиться точ-

ности ε по функции $\big(f(x^K) - f^* \le \varepsilon\big)$ необходимо

$$K = \Omega\left(\frac{L(\operatorname{diam}\mathcal{X})^2}{\varepsilon}\right) \text{ итераций.}$$

Доказательство. Рассмотрим задачу минимизации квадратичной функции

$$\min_{x\in\mathcal{X}} \quad f(x) = \frac{L}{2}\|x\|_2^2,$$

где множество $\mathcal{X} = \operatorname{conv}\{e_1, \dots, e_d\}$ представляет собой симплекс размера R в пространстве $\mathbb{R}^d$. Тогда $\operatorname{diam}\mathcal{X} = \sqrt{2}R$. Оптимальное решение определяется из неравенства Коши–Буняковского–Шварца (**??**): для любых $x \in \Delta_{d-1}$ справедливо $\|x\|_2^2 \ge \frac{R^2}{d}$, причём равенство достигается тогда и только тогда, когда все координаты равны. Отсюда

$$x^* = \frac{R}{d}\mathbf{1}, \qquad f(x^*) = \frac{LR^2}{2d} = \frac{L(\operatorname{diam}\mathcal{X})^2}{4d}. \tag{Л1.8}$$

Пусть метод стартует из некоторой вершины симплекса, например e_1. Так как каждая итерация добавляет не более одной новой вершины, то после $K < d$ вызовов LMO множество всех вершин, которые могли быть использованы в выпуклых комбинациях, имеет мощность не более $K+1$. Обозначим это множество через $\mathcal{S}_K \subseteq \{e_1, \dots, e_d\}$, где $|\mathcal{S}_K| \le K+1$. Тогда

$$x^K \in \operatorname{conv}(\mathcal{S}_K).$$

Минимизируя $f(x) = \frac{L}{2}\|x\|_2^2$ на выпуклой оболочке на не более чем $K+1$ вершинах, получаем

$$f(x^K) \ge \min_{\substack{x\in\operatorname{conv}(\mathcal{S}_K)\\ |\mathcal{S}_K|\le K+1}} f(x) = \frac{L(\operatorname{diam}\mathcal{X})^2}{4(K+1)}.$$

Из (Л1.8) следует

$$f(x^K) - f(x^*) \ge \frac{L(\operatorname{diam}\mathcal{X})^2}{4}\left(\frac{1}{K+1} - \frac{1}{d}\right).$$

Устремляя d к бесконечности, получаем, что чтобы достичь точности $f(x^K) - f(x^*) \le \varepsilon$, требуется не менее чем

$$K = \Omega\left(\frac{L(\operatorname{diam}\mathcal{X})^2}{\varepsilon}\right) \text{ итераций.}$$

■

Этот пример [4, 5] демонстрирует компромисс между разреженностью и оптимальностью: в рассматриваемой задаче в силу построения функции после K вызовов LMO решение ограничено подпространством, порождённым не более чем $K+1$ вершинами, и потому не может быть лучше минимума на этом подпространстве.

Мы рассмотрели замедление, связанное с разреженностью решения, возникающей из-за ограниченного числа вершин, добавляемых при работе LMO. Иной источник замедления — геометрический. Предположим, что решается задача оптимизации на многограннике и предположим, что оптимум лежит во внутренности некоторой грани F. По мере приближения решения к оптимуму «угол обзора» из текущей точки на экстремальные вершины грани F становится очень большим. В результате эффективная

часть шага, направленная к оптимуму, начинает затухать, и возникает зигзагообразное поведение: алгоритм постепенно приближается к решению, но каждое последующее направление движения оказывается почти противоположным предыдущему.
Для L–гладких и μ–сильно выпуклых функций на многограннике P в работе [2] установлено, что даже при оптимальном выборе шага и сильной выпуклости функции скорость сходимости метода Франк–Вульфа не может быть улучшена сверх

$$f\left(x^k\right) - f^* \geq \frac{L(\operatorname{diam}\mathcal{X})^2}{k\log^{2+\delta} k},\ \forall \delta > 0.$$

Таким образом, даже при более сильных предположениях улучшение относительно стандартной оценки $\Omega(\frac{1}{k})$ ограничивается лишь логарифмическим множителем.

Л1.3.2 Линейная минимизация как отдельная задача

Рассмотрим линейную задачу на выпуклом замкнутом множестве $\mathcal{X}$:

$$\operatorname*{argmin}_{s\in\mathcal{X}} \langle s, c\rangle \tag{Л1.9}$$

Получим аналитическое решение для некоторых простых множеств $\mathcal{X}$.

Утверждение Л1.13. Пусть задача линейной минимизации (Л1.9) решается на ℓ_1–шаре радиуса R с центром в 0

$$\mathcal{X} = \left\{ s \in \mathbb{R}^d \;\middle|\; \|s\|_1 \leq R \right\}.$$

Тогда её решение:

$$s^* = -R\operatorname{sign}(c_i)e_i,\ \text{где } i = \operatorname*{argmax}_{j=\overline{1,d}} |c_j|.$$

Доказательство. Запишем Лагранжиан:

$$\mathcal{L}(s,\lambda) = \langle s, c\rangle + \lambda\left(\|s\|_1 - R\right) = \sum_{i=1}^{d}\left(s_i c_i + \lambda|s_i|\right) - \lambda R.$$

Лагранжиан распадается по координатам, введём обозначение:

$$\mathcal{L}_i(s,\lambda) = s_i c_i + \lambda|s_i|.$$

Воспользуемся теоремой Каруша–Куна–Таккера (Теорема **??**):

1. Ограничения: $\|s\|_1 - R \leq 0$;
2. Неотрицательность: $\lambda \geq 0$;
3. Дополняющая нежёсткость: $\lambda\left(\|s\|_1 - R\right) = 0$;
4. Стационарность: $0 \in c_i + \lambda\partial|s_i|$:

$$0 \in c_i + \lambda\begin{cases} -1, & s_i < 0, \\ [-1,1], & s_i = 0, \\ 1, & s_i > 0. \end{cases}$$

Всем этим условиям удовлетворяет решение:

$$s^* = -R\,\mathrm{sign}(c_i)e_i,\ \lambda = |c_i|,$$

где $i = \underset{j=\overline{1,d}}{\mathrm{argmax}}\,|c_j|$. ■

Утверждение Л1.14. Пусть задача линейной минимизации (Л1.9) решается на ℓ_2–шаре радиуса R с центром в 0

$$\mathcal{X} = \left\{ s \in \mathbb{R}^d \;\middle|\; \|s\|_2 \le R \right\}.$$

Тогда её решение:

$$s^* = \begin{cases} -\frac{c}{\|c\|_2}R, & c \neq 0, \\ 0, & c = 0. \end{cases}$$

Доказательство. Запишем лагранжиан:

$$\mathcal{L}(s, \lambda) = \langle s, c \rangle + \lambda\Big(\|s\|_2^2 - R^2\Big).$$

Воспользуемся теоремой Каруша–Куна–Таккера (Теорема **??**):

1. Ограничения: $\|s\|_2 - R \le 0$;
2. Неотрицательность: $\lambda \ge 0$;
3. Дополняющая нежёсткость: $\lambda(\|s\|_2 - R) = 0$;
4. Стационарность: $c + 2\lambda s = 0$.

Рассмотрим варианты:

- Для $c = 0$ пара $s^* = 0$ и $\lambda^* = 0$ удовлетворяет всем условиям.
- Для $c \neq 0$ из стационарности получаем, что $\lambda > 0$ и

  $$s = -\frac{c}{2\lambda},$$

  а из дополняющей нежёсткости:

  $$\|s\|_2 = R.$$

Тогда, собирая все вместе, получаем:

$$\frac{\|c\|_2}{2\lambda} = \|s\|_2 = R \implies \lambda = \frac{\|c\|_2}{2R},\ s^* = -\frac{c}{\|c\|_2}R.$$

■

Утверждение Л1.15. Пусть задача линейной минимизации (Л1.9) решается на ℓ_∞–шаре радиуса R с центром в 0:

$$\mathcal{X} = \left\{ s \in \mathbb{R}^d \;\middle|\; \|s\|_\infty \le R \right\}.$$

Тогда её решение:

$$s^* = -R\,\mathrm{sign}(c).$$

Доказательство. Запишем лагранжиан с двумя покоординатными множителями неравенств $\lambda_1, \lambda_2 \geq 0$ для ограничений $s - \mathbf{R} \preceq 0$ и $-s - \mathbf{R} \preceq 0$:

$$\mathcal{L}(s, \lambda_1, \lambda_2) = \langle s, c\rangle + \lambda_1^\top \big(s - \mathbf{R}\big) + \lambda_2^\top \big(-s - \mathbf{R}\big).$$

Воспользуемся теоремой Каруша–Куна–Таккера (Теорема **??**):

1. Ограничения: $-\mathbf{R} \preceq s \preceq \mathbf{R}$;
2. Неотрицательность: $\lambda_1 \succeq 0$, $\lambda_2 \succeq 0$;
3. Дополняющая нежёсткость: $\lambda_1^i(s_i - R) = 0$, $\lambda_2^i(-s_i - R) = 0$;
4. Стационарность: $c + \lambda_1 - \lambda_2 = 0$.

Рассмотрим варианты:

- Если $c_i > 0$, то $s_i^* = -R$, $\lambda_1^i = 0$ и $\lambda_2^i = c_i$.
- Если $c_i < 0$, то $s_i^* = R$, $\lambda_1^i = -c_i$ и $\lambda_2^i = 0$.
- Если $c_i = 0$, то $s_i^* = 0$, $\lambda_1^i = 0$ и $\lambda_2^i = 0$.

■

Утверждение Л1.16. Пусть задача линейной минимизации (Л1.9) решается на симплексе размера R:

$$\mathcal{X} = \Big\{\, s \in \mathbb{R}^d \;\Big|\; s \succeq 0,\ \mathbf{1}^\top s = R \,\Big\}.$$

Тогда её решение:

$$s^* = Re_i,\ \text{где } i = \operatorname*{argmin}_{j=\overline{1,d}} c_j.$$

Доказательство. Запишем лагранжиан:

$$\mathcal{L}(s, \lambda, \nu) = \langle s, c\rangle - \lambda^\top s - \nu\big(\mathbf{1}^\top s - R\big).$$

Воспользуемся теоремой Каруша–Куна–Таккера (Теорема **??**):

1. Ограничения: $s \succeq 0$, $\mathbf{1}^\top s = R$;
2. Неотрицательность: $\lambda \succeq 0$;
3. Дополняющая нежёсткость: $\lambda_i s_i = 0$;
4. Стационарность: $c - \lambda - \boldsymbol{\nu} = 0$.

Возьмем

$$s^* = Re_i,\ \lambda_j = c_j - c_i,\ \nu = -c_i,$$

где $i = \operatorname*{argmin}_{j=\overline{1,d}} c_j$. ■

Утверждение Л1.17. Пусть задача линейной минимизации (Л1.9) решается на гиперпрямоугольнике:

$$\mathcal{X} = \left\{ s \in \mathbb{R}^d \;\middle|\; a \preceq s \preceq b \right\}.$$

Тогда её решение:

$$s^* = \frac{a+b}{2} + \frac{a-b}{2}\operatorname{sign}(c).$$

Доказательство. Запишем лагранжиан с двумя покоординатными множителями неравенств $\lambda_1, \lambda_2 \geq 0$ для ограничений $s - b \preceq 0$ и $-s + a \preceq 0$:

$$\mathcal{L}(s, \lambda_1, \lambda_2) = \langle s, c \rangle + \lambda_1^\top (s - b) + \lambda_2^\top (-s + a).$$

Воспользуемся теоремой Каруша–Куна–Таккера (Теорема **??**):

1. Ограничения: $a \preceq s \preceq b$;
2. Неотрицательность: $\lambda_1 \succeq 0$, $\lambda_2 \succeq 0$;
3. Дополняющая нежёсткость: $\lambda_1^i (s_i - b_i) = 0$, $\lambda_2^i (-s_i + a_i) = 0$;
4. Стационарность: $c + \lambda_1 - \lambda_2 = 0$.

Рассмотрим покоординатно:

- Если $c_i > 0$, то $s_i^* = a_i$, $\lambda_1^i = 0$ и $\lambda_2^i = c_i$.
- Если $c_i < 0$, то $s_i^* = b_i$, $\lambda_1^i = -c_i$ и $\lambda_2^i = 0$.
- Если $c_i = 0$, то $s_i^* \in [a_i, b_i]$, $\lambda_1^i = 0$ и $\lambda_2^i = 0$.

■

Л1.3.3 Критерий сходимости

В ходе работы метода Франк–Вульфа (Алгоритм Л1.2) надо как-то оценивать точность текущего решения. В безусловных задачах мы использовали такие классические критерии, как норма градиента, значение целевой функции с известным минимумом. При оптимизации на ограниченном множестве они не применимы — вспоминаем пример $\min\limits_{x \in [1,2]} x^2$. В оптимуме $x^* = 1$ градиент не равен нулю.

Решением этой проблемы будет метрика gap, которая определяется следующим образом:

$$\operatorname{gap}\left(x^k\right) = \max_{y \in \mathcal{X}} \left\langle \nabla f\left(x^k\right), x^k - y \right\rangle = \left\langle \nabla f\left(x^k\right), x^k \right\rangle - \min_{y \in \mathcal{X}} \left\langle \nabla f\left(x^k\right), y \right\rangle. \quad \text{(Л1.10)}$$

Её физический смысл становится ясным при применении выпуклости f (Определение **??**):

$$\operatorname{gap}\left(x^k\right) = \max_{y \in \mathcal{X}} \left\langle \nabla f\left(x^k\right), x^k - y \right\rangle \geq \max_{y \in \mathcal{X}} \left(f\left(x^k\right) - f\left(y\right)\right) = f\left(x^k\right) - f^*.$$

Иными словами, если мы потребуем точность ε по gap, то получим точность ε и по функции:

$$f\left(x^k\right) - f^* \leq \operatorname{gap}\left(x^k\right) \leq \varepsilon.$$

Другим преимуществом метрики gap является легкость её вычисления. В самом деле, LMO возвращает нам решение линейной задачи оптимизации, умножив его скалярно на градиент, получаем второе слагаемое в записи (Л1.10). Первое слагаемое находится так же просто.
Получим аналитические выражения для метрики gap для «простых» множеств.

- ℓ_1–шар радиуса R с центром в 0:

$$\mathcal{X} = \left\{ y \in \mathbb{R}^d \;\middle|\; \|y\|_1 \leq R \right\},$$

$$\text{gap}\left(x^k\right) = \left\langle \nabla f\left(x^k\right), x^k \right\rangle + R\left|\left(\nabla f\left(x^k\right)\right)_i\right|, \text{ где } i = \underset{j=\overline{1,d}}{\text{argmax}} \left|\left(\nabla f\left(x^k\right)\right)_j\right|.$$

- ℓ_2–шар радиуса R с центром в 0:

$$\mathcal{X} = \left\{ y \in \mathbb{R}^d \;\middle|\; \|y\|_2 \leq R \right\},$$

$$\text{gap}\left(x^k\right) = \left\langle \nabla f\left(x^k\right), x^k \right\rangle + R\left\|\nabla f\left(x^k\right)\right\|_2.$$

- ℓ_∞–шар радиуса R с центром в 0:

$$\mathcal{X} = \left\{ y \in \mathbb{R}^d \;\middle|\; \|y\|_\infty \leq R \right\},$$

$$\text{gap}\left(x^k\right) = \left\langle \nabla f\left(x^k\right), x^k \right\rangle + R\left\|\nabla f\left(x^k\right)\right\|_1.$$

- Симплекс $\triangle_{d-1}$ размера R:

$$\mathcal{X} = \left\{ y \in \mathbb{R}^d \;\middle|\; y \succeq 0,\ \mathbf{1}^\top y = R \right\},$$

$$\text{gap}\left(x^k\right) = \left\langle \nabla f\left(x^k\right), x^k \right\rangle - R\left(\nabla f\left(x^k\right)\right)_i, \text{ где } i = \underset{j=\overline{1,d}}{\text{argmin}} \left(\nabla f\left(x^k\right)\right)_j.$$

- Гиперпрямоугольник:

$$\mathcal{X} = \left\{ y \in \mathbb{R}^d \;\middle|\; a \preceq y \preceq b \right\},$$

$$\text{gap}\left(x^k\right) = \left\langle \nabla f\left(x^k\right), x^k \right\rangle - \frac{1}{2}\left\langle \nabla f\left(x^k\right) + \left|\nabla f\left(x^k\right)\right|, a \right\rangle - \frac{1}{2}\left\langle \nabla f\left(x^k\right) - \left|\nabla f\left(x^k\right)\right|, b \right\rangle.$$

Список литературы

[1] Stephen Boyd and Lieven Vandenberghe. *Convex Optimization*. Cambridge University Press, Cambridge, 2004.

[2] Gábor Braun, Alejandro Carderera, Cyrille W Combettes, Hamed Hassani, Amin Karbasi, Aryan Mokhtari, and Sebastian Pokutta. Conditional gradient methods. *arXiv preprint arXiv:2211.14103*, 2022.

[3] Marguerite Frank and Philip Wolfe. An algorithm for quadratic programming. *Naval Research Logistics Quarterly*, 3(1–2):95–110, 1956.

[4] Martin Jaggi. Revisiting frank-wolfe: Projection-free sparse convex optimization. volume 28, 01 2013.

[5] Guanghui Lan. The complexity of large-scale convex programming under a linear optimization oracle. 09 2013.

[6] Г. Е. Иванов. *Лекции по математическому анализу. Часть 1*. МФТИ, Москва, 2011.