Л1 Метод зеркального спуска

В предыдущем параграфе мы рассмотрели модификацию алгоритма градиентного спуска для решения задачи с ограничениями на множестве — градиентный спуск с проекцией. Однако для градиентного спуска существуют и другие способы учета геометрии задачи. Вновь обратимся к итерации метода (Алгоритм **??**):

$$x^{k+1} = x^k - \gamma_k \nabla f\big(x^k\big). \tag{Л1.1}$$

Здесь точка x^k рассматривается как элемент конечномерного линейного нормированного пространства $E = \big(U, \|\cdot\|\big)$ с нормой $\|\cdot\|$. При этом градиент $\nabla f\big(x^k\big)$ как линейный дифференциальный оператор принадлежит уже не исходному пространству, а сопряжённому $E^* = \big(U, \|\cdot\|_*\big)$ с сопряжённой векторной нормой $\|\cdot\|_*$ из Определения **??**. Поэтому в общем случае итерация (Л1.1) складывает объекты из разных пространств.

Утверждение Л1.1. Норма дифференциального оператора $\|df(x)\|$ совпадает с сопряжённой векторной нормой градиента $\|\nabla f(x)\|_*$ из Определения **??**.

Доказательство. Норма дифференциального оператора $df\big(x\big)[h] : U \to \mathbb{R}$ определяется по формуле $\|df\big(x\big)\| := \sup_{\|h\|=1} |df\big(x\big)[h]|$, аналогично подчинённой матричной норме из Определения **??**. Распишем дифференциал $df\big(x\big)[h]$ через градиент $\nabla f\big(x\big)$:

$$\|df\big(x\big)\| = \sup_{\|h\|=1} |df\big(x\big)[h]| = \sup_{\|h\|=1} |\langle \nabla f\big(x\big), h\rangle| = \|\nabla f\big(x\big)\|_*.$$

■

В ситуации, когда $\|\cdot\| = \|\cdot\|_2$, исходное и двойственное пространства совпадают, и итерация градиентного спуска корректна.
Однако норма в пространстве задачи не обязана быть евклидовой. Хотя в конечномерных пространствах все нормы эквивалентны (подробно это описано в конце параграфа, где данное утверждение используется для иллюстрации преимуществ зеркального спуска), в случае произвольного E записывать итерацию в виде (Л1.1) некорректно.
Эти соображения приводят к идее, предложенной А. Немировским и Д. Юдиным [1]: шаг градиентного спуска должен выполняться не в исходном пространстве, а в сопряжённом. Для этого, введем обратимое отображение $\varphi : E \to E^*$, требования к которому будут определены ниже. Тогда итерация метода примет вид:

$$x^{k+1} = \varphi^{-1}\big(\varphi\big(x^k\big) - \gamma_k \nabla f\big(x^k\big)\big), \tag{Л1.2}$$

где обратное отображение $\varphi^{-1} : E^* \to E$ возвращает результат в пространство E.

Замечание Л1.1. Пространство E^* в этом контексте называют «зеркальным». Именно в нём выполняется шаг градиентного спуска, а затем с помощью φ^{-1} результат отображается обратно в исходное пространство.

Л1.1 Дивергенция Брэгмана

Хотя теперь шаг метода стал корректным, остается непонятным, как сходу построить функцию φ, подходящую к геометрии конкретной задачи. Поэтому мы предлагаем пойти по альтернативному пути: мы сначала выберем новую, неевклидовую функцию расстояния под геометрию задачи, а уже потом выведем модифицированный шаг метода с этим новым расстоянием. В частности, в качестве класса функций расстояния будут использоваться дивергенции Брэгмана.
Для начала обобщим Определение **??** μ–сильной выпуклости для произвольной нормы.

Определение Л1.1. Пусть дана непрерывно дифференцируемая на выпуклом множестве $\mathcal{X}$ функция $d : \mathcal{X} \to \mathbb{R}$. Будем говорить, что она является *μ–сильно выпуклой относительно нормы* $\|\cdot\|$ на множестве $\mathcal{X}$, если для любых $x, y \in \mathcal{X}$ выполнено

$$d(x) - d(y) - \langle \nabla d(y), x - y \rangle \geq \frac{\mu}{2}\|x - y\|^2.$$

Теперь мы можем ввести формальное определение для дивергенции Брэгмана.

Определение Л1.2. Пусть дана непрерывно дифференцируемая 1–сильно выпуклая относительно нормы $\|\cdot\|$ на множестве $\mathcal{X}$ функция d. *Дивергенцией Брэгмана*, порожденной функцией d на множестве $\mathcal{X}$, называется функция двух аргументов $V(x, y) : \mathcal{X} \times \mathcal{X} \to \mathbb{R}_+$ такая, что для любых $x, y \in \mathcal{X}$ выполняется

$$V(x, y) = d(x) - d(y) - \langle \nabla d(y), x - y \rangle.$$

Выражение для $V(x, y)$ в точности совпадает с левой частью неравенства из определения μ–сильной выпуклости. Рассмотрим несколько примеров $V(x, y)$ и, то какими функциями $d(x)$ они порождаются.

Пример Л1.1. Квадрат евклидовой нормы $d : \mathbb{R}^d \to \mathbb{R}$ с евклидовой дивергенцией:

$$d(x) = \frac{1}{2}\|x\|_2^2, \quad V(x, y) = \frac{1}{2}\|x - y\|_2^2.$$

Решение. В этом примере 1–сильная выпуклость $d(x)$ относительно $\|\cdot\|_2$ тривиальна. Далее мы выводим дивергенцию Брэгмана по Определению Л1.2:

$$\begin{aligned} V(x, y) &= \frac{1}{2}\|x\|_2^2 - \frac{1}{2}\|y\|_2^2 - \langle y, x - y \rangle = \frac{1}{2}\Big(\|x\|_2^2 - \|y\|_2^2 - 2\langle y, x \rangle + 2\|y\|_2^2\Big) \\ &= \frac{1}{2}\Big(\|x\|_2^2 - 2\langle y, x \rangle + \|y\|_2^2\Big) = \frac{1}{2}\|x - y\|_2^2. \end{aligned}$$

Мы получили просто квадрат евклидова расстояния. ■

Пример Л1.2. Энтропия Шеннона $d : \triangle_{d-1} \to \mathbb{R}$ с дивергенцией Кульбака–Лейблера (KL-дивергенцией):

$$d(x) = \sum_{i=1}^{d} x_i \log x_i, \quad V(x, y) = \sum_{i=1}^{d} x_i \log \frac{x_i}{y_i},$$

где

$$\triangle_{d-1} = \left\{ x \in \mathbb{R}^d \;\middle|\; \sum_{i=1}^{d} x_i = 1,\ x_i > 0 \right\}.$$

Эта дивергенция позволяет измерить расстояние между двумя дискретными вероятностными распределениями, заданными своими векторами вероятности $x, y \in \triangle_{d-1}$.

Решение. Градиент $d(y)$ в точке y считается как:

$$\big[\nabla d(y)\big]_i = 1 + \log y_i,$$

Подставляя этот градиент в определение дивергенции Брэгмана (Определение Л1.2), мы получаем:

$$V(x,y) = \sum_{i=1}^d x_i \log x_i - \sum_{i=1}^d y_i \log y_i - \sum_{i=1}^d \big(1 + \log y_i\big)\big(x_i - y_i\big)$$
$$= \sum_{i=1}^d x_i \big(\log x_i - \log y_i\big) - \sum_{i=1}^d (x_i - y_i) = \sum_{i=1}^d x_i \log \frac{x_i}{y_i},$$

где слагаемое $\sum_{i=1}^d \big(x_i - y_i\big) = 0$, так как $x, y \in \triangle_{d-1}$ и $\sum_{i=1}^d x_i = \sum_{i=1}^d y_i = 1$. Таким образом, мы получили дивергенцию Кульбака–Лейблера.
К тому же, согласно неравенству Пинскера, энтропия $d(x)$ является 1–сильно выпуклой относительно $\|\cdot\|_1$ на симплексе $\triangle_{d-1}$, то есть:

$$V(x,y) = \sum_{i=1}^d x_i \log \frac{x_i}{y_i} \geq \frac{1}{2}\|x - y\|_1^2.$$

■

Пример Л1.3. Логарифмический барьер $d : \mathbb{S}^d_{(0,1]} \to \mathbb{R}$ (Пример **??**):

$$d(X) = -\log(\det X), \quad V(X,Y) = \operatorname{Tr}\big(XY^{-1} - I_d\big) - \log\det\big(XY^{-1}\big),$$

где

$$\mathbb{S}^d_{(0,1]} := \Big\{ X \in \mathbb{S}^d_{++} \;\Big|\; \Big\|X^{\frac{1}{2}}\Big\|_F \leq 1 \Big\},$$

Эта дивергенция также применяется для измерения расстояния между вероятностными распределениями. В частности, она является KL-дивергенцией между двумя многомерными нормальными распределениями с ковариациями X и Y и одинаковыми средними.

Решение. Вычислим дифференциал:

$$\mathrm{d}(-\log(\det X)) = -\frac{1}{\det X}\,\mathrm{d}(\det X) = -\frac{1}{\det X}\det X\big\langle X^{-\top}, \mathrm{d}X\big\rangle = -\big\langle X^{-\top}, \mathrm{d}X\big\rangle.$$

Подставляем в определение дивергенции Брэгмана (Определение Л1.2):

$$V(X,Y) = -\log(\det X) + \log(\det Y) - \big\langle -Y^{-\top}, X - Y\big\rangle$$
$$= -\log(\det X/\det Y) + \operatorname{Tr}\big(XY^{-1} - I_d\big)$$
$$= \operatorname{Tr}\big(XY^{-1} - I_d\big) - \log\det\big(XY^{-1}\big).$$

Для подсчета константы сильной выпуклости относительно Фробениусовой нормы $\|\cdot\|_F$, воспользуемся критерием выпуклости второго порядка. Из Примера **??** мы знаем, что второй дифференциал для логарифмического барьера равен:

$$\mathrm{d}^2 d(X)\,[H,H] = \Big\|X^{-\frac{1}{2}} H X^{-\frac{1}{2}}\Big\|_F^2.$$

Воспользовавшись неравенством норм для произведения матриц и условием на матрицы $\Big\|X^{\frac{1}{2}}\Big\|_F \leq 1$, получим:

$$\|H\|_F^2 = \Big\|X^{\frac{1}{2}} X^{-\frac{1}{2}} H X^{-\frac{1}{2}} X^{\frac{1}{2}}\Big\|_F^2 \leq \Big\|X^{\frac{1}{2}}\Big\|_F^2 \Big\|X^{-\frac{1}{2}} H X^{-\frac{1}{2}}\Big\|_F = \Big\|X^{\frac{1}{2}}\Big\|_F^2 \cdot \mathrm{d}^2 d(X)\,[H,H],$$

и как следствие:

$$\mathrm{d}^2 d(X)\,[H,H] \geq \frac{\|H\|_F^2}{\left\|X^{\frac{1}{2}}\right\|_F^2} \geq \|H\|_F^2.$$

■

Изучим подробнее свойства нового объекта.

Утверждение Л1.2. Пусть $\mathcal{X}$ — выпуклое множество. Дивергенция Брэгмана в общем случае обладает следующими свойствами:

1. Асимметричность: в общем случае $V(x,y) \neq V(y,x)$.
2. Ограниченность снизу:
$$V(x,y) \geq \frac{1}{2}\|x-y\|^2 \text{ для всех } x,y \in \mathcal{X}.$$
3. Неотрицательность: $V(x,y) \geq 0$ для всех $x,y \in \mathcal{X}$.
4. Выпуклость по первому аргументу: $V(x,y)$ является 1–сильно выпуклой по x для любого y.
5. Невыпуклость по второму аргументу: $V(x,y)$ может быть невыпуклой по y.

Замечание Л1.2. Дивергенцию Брэгмана можно воспринимать как расстояние между векторами или матрицами, но стоит обратить внимание, что формально она не является метрикой и даже не симметрична относительно перестановки переменных.

Доказательство. Кратко поясним каждый пункт.

1. В качестве примера асимметричной дивергенции Брэгмана рассмотрим дивергенцию Кульбака–Лейблера (Пример Л1.2). Из записи видно отсутствие симметрии:
$$V(x,y) = \sum_{i=1}^{d} x_i \log \frac{x_i}{y_i}.$$
2. Ограниченность снизу получается из Определения Л1.2 для дивергенции и 1-сильной выпуклости d (Определение Л1.1):
$$V(x,y) = d(x) - d(y) - \langle \nabla d(y), x-y \rangle \geq \frac{1}{2}\|x-y\|^2 \text{ для всех } x,y \in \mathcal{X}.$$
3. Неотрицательность следует из предыдущего пункта. Также можем утверждать, что равенство нулю $V(x,y) = 0$ достигается тогда и только тогда, когда аргументы равны: $x = y$.
4. Относительно первого аргумента дивергенция Брэгмана является суммой 1–сильно выпуклой d и линейной функции, то есть 1–сильно выпуклой функцией.
5. Рассмотрим функцию $d(x) = -\log x$, $x \in (0,1]$ из Примера Л1.3. Соответствующая дивергенция Брэгмана имеет вид:
$$V(x,y) = d(x) - d(y) - d'(y)(x-y) = -\log x + \log y + \frac{x}{y} - 1.$$

Зафиксируем $x = \frac{1}{4}$ и введём функцию:

$$g(y) = V\left(\frac{1}{4}, y\right) = -\log\frac{1}{4} + \log y + \frac{1}{4y} - 1,\ y \in (0, 1].$$

Запишем критерий выпуклости второго порядка:

$$g''(y) = -\frac{1}{y^2} + \frac{1}{2y^3} = \frac{1}{y^2}\left(\frac{1}{2y} - 1\right) \geq 0,\ \forall y \in (0, 1].$$

Однако при $y > \frac{1}{2}$ мы получаем противоречие.

■

Утверждение Л1.3 (Равенство параллелограмма/теорема Пифагора). Пусть $\mathcal{X}$ — выпуклое множество. Для любых точек $x, y, z \in \mathcal{X}$ выполняется

$$V(x, y) + V(y, z) - V(x, z) = \langle \nabla d(z) - \nabla d(y), x - y \rangle.$$

Доказательство. Распишем по Определению Л1.2:

$$\begin{aligned} V(x, y) + V(y, z) &= d(x) - d(y) - \langle \nabla d(y), x - y \rangle + d(y) - d(z) - \langle \nabla d(z), y - z \rangle \\ &= d(x) - d(z) - \langle \nabla d(z), x - z \rangle - \langle \nabla d(y) - \nabla d(z), x - y \rangle \\ &= V(x, z) - \langle \nabla d(y) - \nabla d(z), x - y \rangle. \end{aligned}$$

■

Л1.2 Зеркальный спуск

После того как мы ввели новую функцию расстояния через дивергенцию Брэгмана $V(x, y)$, мы приступаем к модификации шага градиентного спуска. Мы повторим вывод классического шага, но вместо квадрата евклидового расстояния $\frac{1}{2}\|x - y\|^2$ мы будем использовать новую функцию $V(x, y)$, подходящую под геометрию конкретной задачи. Решаем задачу оптимизации на множестве $\mathcal{X}$:

$$\min_{x \in \mathcal{X}} f(x). \tag{Л1.3}$$

Запишем итерацию градиентного спуска (Алгоритм **??**) на $\mathbb{R}^d$ в готовом виде:

$$x^{k+1} = x^k - \gamma_k \nabla f(x^k).$$

С точки зрения оптимизации данная итерация является решением следующей задачи:

$$x^{k+1} = \operatorname*{argmin}_{x \in \mathbb{R}^d} \left\{ f(x^k) + \langle \nabla f(x^k), x - x^k \rangle + \frac{1}{2\gamma_k}\|x - x^k\|_2^2 \right\}.$$

В самом деле, Теоремы **??** и **??** дают нам необходимое и достаточное условия глобального минимума выпуклой функции:

$$\nabla_x \left(f(x^k) + \langle \nabla f(x^k), x - x^k \rangle + \frac{1}{2\gamma_k}\|x - x^k\|_2^2 \right) = \nabla f(x^k) + \frac{1}{\gamma_k}(x - x^k) = 0,$$

откуда и получается формула для шага градиентного спуска. Можно упростить запись, избавившись от константы $f(x^k)$ и домножив целевую функцию на положительное γ_k:

$$x^{k+1} = \operatorname*{argmin}_{x \in \mathbb{R}^d} \left\{ \langle \gamma_k \nabla f(x^k), x - x^k \rangle + \frac{1}{2} \|x - x^k\|_2^2 \right\}.$$

Теперь учтем множество $\mathcal{X}$ с помощью евклидовой проекции, как в Алгоритме **??**:

$$x^{k+1} = \operatorname*{argmin}_{x \in \mathcal{X}} \left\{ \langle \gamma_k \nabla f(x^k), x - x^k \rangle + \frac{1}{2} \|x - x^k\|_2^2 \right\}. \tag{Л1.4}$$

Действительно, добавим слагаемые не зависящие от x и выделим квадрат нормы, чтобы получить знакомую форму:

$$\begin{aligned} x^{k+1} &= \operatorname*{argmin}_{x \in \mathcal{X}} \left\{ \frac{1}{2} \gamma_k^2 \|\nabla f(x^k)\|_2^2 + \langle \gamma_k \nabla f(x^k), x - x^k \rangle + \frac{1}{2} \|x - x^k\|_2^2 \right\} \\ &= \operatorname*{argmin}_{x \in \mathcal{X}} \|x - (x^k - \gamma_k \nabla f(x^k))\|_2^2 = \Pi_{\mathcal{X}}(x^k - \gamma_k \nabla f(x^k)). \end{aligned}$$

Наконец, мы учтем геометрию множества $\mathcal{X}$ через дивергенцию Брэгмана, которая имеет смысл расстояния. Мы можем заменить евклидову норму $\frac{1}{2}\|x - x^k\|_2^2$ на $V(x, x^k)$ в задаче (Л1.4), чтобы получить новый итеративный метод:

$$x^{k+1} = \operatorname*{argmin}_{x \in \mathcal{X}} \{ \langle \gamma_k \nabla f(x^k), x - x^k \rangle + V(x, x^k) \}.$$

Алгоритм Л1.1 Зеркальный спуск

Вход: стартовая точка $x^0 \in \mathcal{X}$, размеры шагов $\{\gamma_k\}_{k=0} > 0$, дивергенция Брэгмена V, количество итераций K

1: **for** $k = 0, 1, \ldots, K-1$ **do**

2: $\quad x^{k+1} = \operatorname{argmin}_{x \in \mathcal{X}} \{ \langle \gamma_k \nabla f(x^k), x - x^k \rangle + V(x, x^k) \}$

3: **end for**

Выход: $\frac{1}{K} \sum_{k=1}^K x^k$

Чтобы понять, почему данный метод называется «зеркальным спуском», покажем, как соотносятся Алгоритм Л1.1 и идея шага в сопряжённом пространстве.

Пример Л1.4. Рассмотрим метод при $\mathcal{X} = \mathbb{R}^d$ и некоторой $d : \mathbb{R}^d \to \mathbb{R}$:

$$\begin{aligned} x^{k+1} &= \operatorname*{argmin}_{x \in \mathcal{X}} \{ \langle \gamma_k \nabla f(x^k), x - x^k \rangle + V(x, x^k) \} \\ &= \operatorname*{argmin}_{x \in \mathbb{R}^d} \{ \langle \gamma_k \nabla f(x^k), x - x^k \rangle + d(x) - d(x^k) - \langle \nabla d(x^k), x - x^k \rangle \}. \end{aligned}$$

Запишем условие оптимальности (Теорема **??**):

$$\gamma_k \nabla f(x^k) + \nabla d(x) - \nabla d(x^k) = 0.$$

Это и есть идея Немировского и Юдина, идея «зеркальности»:

$$\nabla d(x^{k+1}) = \nabla d(x^k) - \gamma_k \nabla f(x^k). \tag{Л1.5}$$

То есть $\nabla d : E \to E^*$ — это и есть то самое преобразование ϕ из (Л1.2), переносящее шаг градиентного спуска в зеркальное пространство.

Если множество $\mathcal{X}$ не совпадает со всем пространством $\mathbb{R}^d$, то после основного шага (Л1.5) нужно дополнительно найти проекцию точки x^{k+1} на $\mathcal{X}$. Для этого минимизируется дивергенция Брэгмана: $\operatorname{argmin}_{x\in\mathcal{X}} V(x, x^{k+1})$.

Замечание Л1.3. С помощью такого инструмента, как дивергенция Брэгмана, мы научились переходить от задачи в «зеркальном» пространстве к простому поиску argmin, который во многих случаях либо имеет аналитическое решение, либо может быть найден численно с хорошей точностью.

Рассмотрим, какие формулы итераций будут получаться при выборе различных дивергенций Брэгмана.

Пример Л1.5. Квадрат евклидовой нормы $V : \mathcal{X} \times \mathcal{X} \to \mathbb{R}$:

$$V(x, y) = \frac{1}{2}\|x - y\|_2^2,\ x, y \in \mathcal{X},$$

как обсуждалось, даёт градиентный спуск с евклидовой проекцией (Алгоритм **??**):

$$x^{k+1} = \operatorname*{argmin}_{x\in\mathcal{X}} \left\{ \langle \gamma_k \nabla f(x^k), x - x^k \rangle + \frac{1}{2}\|x - x^k\|_2^2 \right\} = \Pi_{\mathcal{X}}\left(x^k - \gamma_k \nabla f(x^k)\right).$$

Пример Л1.6. Дивергенция Кульбака–Лейблера $V : \triangle_{d-1} \times \triangle_{d-1} \to \mathbb{R}$:

$$V(x, y) = \sum_{i=1}^{d} x_i \log \frac{x_i}{y_i},\ x, y \in \triangle_{d-1}$$

даёт аналитическую итерацию:

$$x_i^{k+1} = x_i^k \frac{\exp\left(-\gamma_k \left[\nabla f(x^k)\right]_i\right)}{\sum_{i=1}^d x_i^k \exp\left(-\gamma_k \left[\nabla f(x^k)\right]_i\right)}.$$

Решение. Запишем итерацию зеркального спуска как задачу с ограничениями:

$$\begin{aligned} \min_{x\in\mathbb{R}^d} \quad & \langle \gamma_k \nabla f(x^k), x \rangle + V(x, x^k) \\ \text{s.t.} \quad & -x_i \le 0 \\ & \sum_{i=1}^d x_i - 1 = 0. \end{aligned}$$

Для решения этой задачи воспользуемся условиями Каруша-Куна-Таккера (Определение **??**), которые в данном случае являются необходимыми и достаточными условиями условного минимума (Теорема **??**).
Лагранжиан для такой задачи имеет вид:

$$\begin{aligned} \mathcal{L}(x, \lambda, \nu) &= \langle \gamma_k \nabla f(x^k), x \rangle + V(x, x^k) - \sum_{i=1}^d \lambda_i x_i + \nu\left(\sum_{i=1}^d x_i - 1\right) \\ &= \sum_{i=1}^d \left(\gamma_k \left[\nabla f(x^k)\right]_i + \log \frac{x_i}{x_i^k} - \lambda_i + \nu\right) x_i - \nu, \quad \lambda \in \mathbb{R}^d, \nu \ge 0. \end{aligned}$$

Градиент лагранжиана по x_i:

$$\frac{\partial \mathcal{L}}{\partial x_i}(x, \lambda, \nu) = 1 + \gamma_k \big[\nabla f\big(x^k\big)\big]_i + \log \frac{x_i}{x_i^k} - \lambda_i + \nu.$$

Из условий стационарности по x находим x^*, доставляющий минимум лагранжиана:

$$\frac{\partial \mathcal{L}}{\partial x_i}(x^*, \lambda^*, \nu^*) = 0 \Rightarrow x_i^* = x_i^k \exp\big(-1 - \gamma_k \big[\nabla f\big(x^k\big)\big]_i + \lambda_i^* - \nu^*\big), \quad i = \overline{1, d}.$$

Условия дополняющей нежёсткости:

$$\lambda_i^* \cdot (-x_i^*) = 0 \Rightarrow -\lambda_i^* \cdot x_i^k \exp\big(-1 - \gamma_k \big[\nabla f\big(x^k\big)\big]_i + \lambda_i^* - \nu^*\big) = 0, \quad i = \overline{1, d}.$$

Точка x_i^k лежит на симплексе $\triangle_{d-1}$ и $x_i^k > 0$, и при этом экспонента также всегда положительна. Следовательно, единственный способ удовлетворить условиям нежёсткости — это принять $\lambda_i^* = 0,\ i = \overline{1, d}$ и получить:

$$x_i^* = x_i^k \exp\big(-1 - \gamma_k \big[\nabla f\big(x^k\big)\big]_i - \nu^*\big), \quad i = \overline{1, d}.$$

Чтобы избавиться от $-1 - \nu^*$, вспомним ограничение задачи $\sum_{i=1}^d x_i^* = 1$. Отсюда получаем нормировку и можно записать:

$$x_i^{k+1} = x_i^k \frac{\exp\big(-\gamma_k \big[\nabla f\big(x^k\big)\big]_i\big)}{\sum_{i=1}^d x_i^k \exp\big(-\gamma_k \big[\nabla f\big(x^k\big)\big]_i\big)}.$$

Это и есть итерации зеркального спуска для KL-дивергенции на симплексе. ■

Прежде чем переходить к доказательству сходимости зеркального спуска, мы обобщим свойство гладкости функции для произвольной нормы, как это было сделано для сильной выпуклости в Определении Л1.1.

Определение Л1.3. Пусть дана непрерывно дифференцируемая на выпуклом множестве $\mathcal{X}$ функция $f : \mathcal{X} \to \mathbb{R}$. Будем говорить, что данная функция имеет *L-Липшицев градиент (является L–гладкой) относительно нормы $\|\cdot\|$ на $\mathcal{X}$*, если для любых $x, y \in \mathcal{X}$ выполнено:

$$\big\|\nabla f(x) - \nabla f(y)\big\|_* \leq L\|x - y\|,$$

где $\|\cdot\|_*$ — это сопряженная векторная норма из Определения **??**

Теорема Л1.1. Пусть $\mathcal{X}$ — выпуклое множество. Для L–гладкой относительно нормы $\|\cdot\|$ функции $f : \mathcal{X} \to \mathbb{R}$ выполнено:

$$\big|f(y) - f(x) - \big\langle \nabla f(x), y - x\big\rangle\big| \leq \frac{L}{2}\|x - y\|^2.$$

Доказательство. Используем (Страница 84 из [2]) формулу Ньютона–Лейбница для криволинейного интеграла второго рода по кривой, заданной вектор функцией $r(\tau)$:

$$\int_a^b \big\langle \nabla f\big(r(\tau)\big), \mathrm{d}r(\tau)\big\rangle = f\big(r(b)\big) - f\big(r(a)\big).$$

В нашем случае выберем кривую следующим образом $r(\tau) = x + \tau(y - x)$, где $\tau \in [0, 1]$:

$$f(y) - f(x) = \int_0^1 \langle \nabla f(x + \tau(y - x)), y - x \rangle \, \mathrm{d}\tau$$

$$= \langle \nabla f(x), y - x \rangle + \int_0^1 \langle \nabla f(x + \tau(y - x)) - \nabla f(x), y - x \rangle \, \mathrm{d}\tau \, .$$

Переместив скалярное произведение влево и взяв модуль от обеих частей, получим:

$$\left| f(y) - f(x) - \langle \nabla f(x), y - x \rangle \right| = \left| \int_0^1 \langle \nabla f(x + \tau(y - x)) - \nabla f(x), y - x \rangle \, \mathrm{d}\tau \right|$$

$$\leq \int_0^1 \left| \langle \nabla f(x + \tau(y - x)) - \nabla f(x), y - x \rangle \right| \mathrm{d}\tau \, .$$

В последнем переходе мы использовали факт, что модуль суммы не превосходит сумму модулей слагаемых. Далее воспользуемся неравенством Гёльдера (**??**), а затем L–гладкостью относительно нормы $\|\cdot\|$ (Определение Л1.3):

$$\left| f(y) - f(x) - \langle \nabla f(x), y - x \rangle \right| \leq \int_0^1 \left\| \nabla f(x + \tau(y - x)) - \nabla f(x) \right\|_* \|y - x\| \, \mathrm{d}\tau$$

$$\leq L \|y - x\|^2 \int_0^1 \tau \, \mathrm{d}\tau = \frac{L}{2} \|x - y\|^2 .$$

■

Теперь мы готовы перейти к доказательству сходимости зеркального спуска.

Теорема Л1.2. Пусть задача оптимизации на выпуклом замкнутом множестве $\mathcal{X}$ (Л1.3) с L–гладкой относительно нормы $\|\cdot\|$ выпуклой целевой функцией f решается с помощью зеркального спуска (Алгоритм Л1.1). Тогда при $\gamma_k = \gamma \leq \frac{1}{L}$ справедлива следующая оценка сходимости:

$$f\left(\frac{1}{K} \sum_{k=1}^{K} x^k \right) - f^* \leq \frac{V(x^*, x^0)}{\gamma K} .$$

Доказательство. Начнем с итерации зеркального спуска:

$$x^{k+1} = \operatorname*{argmin}_{x \in \mathcal{X}} \left\{ \langle \gamma \nabla f(x^k), x - x^k \rangle + V(x, x^k) \right\}$$

$$= \operatorname*{argmin}_{x \in \mathcal{X}} \left\{ \langle \gamma \nabla f(x^k), x - x^k \rangle + d(x) - d(x^k) - \langle \nabla d(x^k), x - x^k \rangle \right\} .$$

Запишем условие оптимальности на выпуклом множестве $\mathcal{X}$ (Теорема **??**) для функции под argmin:

$$\langle \gamma \nabla f(x^k) + \nabla d(x^{k+1}) - \nabla d(x^k), x - x^{k+1} \rangle \geq 0$$

для всех $x \in \mathcal{X}$. Далее применяем равенство параллелограмма для дивергенции Брэгмана (Утверждение Л1.3) с $x = x,\ y = x^{k+1},\ z = x^k$:

$$V\big(x, x^{k+1}\big) + V\big(x^{k+1}, x^k\big) - V\big(x, x^k\big) = \big\langle \nabla d\big(x^k\big) - \nabla d\big(x^{k+1}\big), x - x^{k+1}\big\rangle.$$

Подставляем в неравенство выше, учитывая знак, получаем:

$$\big\langle \gamma \nabla f\big(x^k\big), x^{k+1} - x\big\rangle + V\big(x, x^{k+1}\big) + V\big(x^{k+1}, x^k\big) - V\big(x, x^k\big) \le 0. \tag{Л1.6}$$

Теперь запишем свойство L–гладкости (Теорема Л1.1) для $y = x^{k+1},\ x = x^k$:

$$f\big(x^{k+1}\big) - f\big(x^k\big) - \big\langle \nabla f\big(x^k\big), x^{k+1} - x^k\big\rangle \le \frac{L}{2}\big\|x^k - x^{k+1}\big\|^2. \tag{Л1.7}$$

Сложим неравенство (Л1.6) и домноженное на γ неравенство (Л1.7):

$$\begin{aligned}\big\langle \gamma \nabla f\big(x^k\big), x^{k+1} - x\big\rangle + V\big(x, x^{k+1}\big) + V\big(x^{k+1}, x^k\big) - V\big(x, x^k\big)\\ +\gamma\big(f\big(x^{k+1}\big) - f\big(x^k\big) - \big\langle \nabla f\big(x^k\big), x^{k+1} - x^k\big\rangle\big) \le \frac{\gamma L}{2}\big\|x^k - x^{k+1}\big\|^2.\end{aligned}$$

Перепишем, оставив слева только слагаемые с f:

$$\begin{aligned}\big\langle \gamma \nabla f\big(x^k\big), x^k - x\big\rangle + \gamma\big(f\big(x^{k+1}\big) - f\big(x^k\big)\big) \le V\big(x, x^k\big) - V\big(x, x^{k+1}\big)\\ - V\big(x^{k+1}, x^k\big) + \frac{\gamma L}{2}\big\|x^k - x^{k+1}\big\|^2.\end{aligned} \tag{Л1.8}$$

Из определения выпуклости (Определение **??**) можно оценить:

$$f\big(x^k\big) - f(x) + \big\langle \nabla f\big(x^k\big), x - x^k\big\rangle \le 0. \tag{Л1.9}$$

Домножим неравенство (Л1.9) на γ и сложим с неравенством (Л1.8) (скалярное произведение $\big\langle \gamma \nabla f\big(x^k\big), x^k - x\big\rangle$ и $f\big(x^k\big)$ сокращаются):

$$\gamma\big(f\big(x^{k+1}\big) - f(x)\big) \le V\big(x, x^k\big) - V\big(x, x^{k+1}\big) - V\big(x^{k+1}, x^k\big) + \frac{\gamma L}{2}\big\|x^k - x^{k+1}\big\|^2. \tag{Л1.10}$$

Запишем ограниченность снизу дивергенции Брэгмана из Утверждения Л1.2:

$$\frac{1}{2}\big\|x^{k+1} - x^k\big\|^2 \le V\big(x^{k+1}, x^k\big).$$

и подставим его в неравенство (Л1.10):

$$\gamma\big(f\big(x^{k+1}\big) - f(x)\big) \le V\big(x, x^k\big) - V\big(x, x^{k+1}\big) + \big(\gamma L - 1\big)V\big(x^{k+1}, x^k\big).$$

Воспользуемся тем, что $\gamma \le \frac{1}{L}$ и ограничим нулём сверху последнее слагаемое:

$$\gamma\big(f\big(x^{k+1}\big) - f(x)\big) \le V\big(x, x^k\big) - V\big(x, x^{k+1}\big).$$

Усредним по всем k итераций от 0 до $K-1$:

$$\frac{\gamma}{K}\sum_{k=0}^{K-1}\big(f\big(x^{k+1}\big) - f(x)\big) \le \frac{1}{K}\sum_{k=0}^{K-1}\big(V\big(x, x^k\big) - V\big(x, x^{k+1}\big)\big).$$

Справа свернем телескопическую сумму:

$$\frac{1}{K}\sum_{k=0}^{K-1}\big(f\big(x^{k+1}\big) - f(x)\big) \le \frac{1}{\gamma K}\big(V\big(x, x^0\big) - V\big(x, x^K\big)\big) \le \frac{V\big(x, x^0\big)}{\gamma K}.$$

Для левой части применяем неравенство Йенсена (Неравенство (**??**)):

$$f\left(\frac{1}{K}\sum_{k=1}^{K}x^k\right) - f(x) \leq \frac{V(x, x^0)}{\gamma K}.$$

В силу произвольности x, можем взять $x = x^*$:

$$f\left(\frac{1}{K}\sum_{k=1}^{K}x^k\right) - f^* \leq \frac{V(x^*, x^0)}{\gamma K}.$$

■

Сформулируем следствие о сходимости и оценке на количество итераций при оптимальном значении шага.

Утверждение Л1.4. Пусть задача удовлетворяет условиям Теоремы **??** и выбрано значение шага $\gamma_k = \frac{1}{L}$. Тогда справедлива следующая оценка сходимости:

$$f\left(\frac{1}{K}\sum_{k=1}^{K}x^k\right) - f^* \leq \frac{LV(x^*, x^0)}{K}.$$

Более того, чтобы добиться точности ε по функции $(f\left(\frac{1}{K}\sum_{k=1}^{K}x^k\right) - f^* \leq \varepsilon)$, необходимо

$$K = \mathcal{O}\left(\frac{LV(x^*, x^0)}{\varepsilon}\right) \text{ итераций.}$$

Доказательство. Выпишем оценку из Теоремы Л1.2 и подставим $\gamma = \frac{1}{L}$:

$$f\left(\frac{1}{K}\sum_{k=1}^{K}x^k\right) - f^* \leq \frac{V(x^*, x^0)}{\gamma K} = \frac{LV(x^*, x^0)}{K}.$$

Чтобы получить оценку на число итераций, отметим, что мы хотим гарантировать:

$$f\left(\frac{1}{K}\sum_{k=1}^{K}x^k\right) - f^* \leq \frac{LV(x^*, x^0)}{K} \leq \varepsilon.$$

Тогда:

$$K \geq \frac{LV(x^*, x^0)}{\varepsilon}. \tag{Л1.11}$$

■

Полученный результат сходимости зеркального спуска по форме аналогичен оценке для градиентного спуска. Это объясняется тем, что зеркальный спуск является обобщением градиентного спуска для произвольной дивергенции Брэгмана. В чем тогда преимущество такого метода перед градиентным спуском с проекцией?
Посмотрим внимательно на выражение (Л1.11): константа гладкости L в нем определяется относительно произвольной нормы $\|\cdot\|$ на $\mathcal{X}$, а начальное расстояние $V(x^*, x^0)$ относительно дивергенции V, в отличие от градиентного спуска с проекцией, где $L \equiv L_2$

и $V(x^*, x^0) \equiv \frac{1}{2}\|x^* - x^0\|_2^2$. Это означает, что может существовать такая дивергенция Брэгмана, при которой мы получим улучшение $LV(x^*, x^0) \ll \frac{1}{2}L_2\|x^* - x^0\|_2^2$.
Проиллюстрируем это более детально на векторных нормах $\|\cdot\| = \|\cdot\|_p$ и $\|\cdot\|_* = \|\cdot\|_q$, где $p, q \in [1, +\infty]$ образуют гёльдеровскую пару, то есть $\frac{1}{p} + \frac{1}{q} = 1$.
Для подмножеств $\mathcal{X} \in \mathbb{R}^d$, константа L определяется через условие гладкости функции следующим образом:

$$\|\nabla f(x) - \nabla f(y)\|_q \leq L\|x - y\|_p.$$

Выбор нормы в этом определении влияет на значение L. Если $1 \leq p \leq 2$, то выполняются соотношения:

$$\|z\|_q \leq \|z\|_2 \leq \|z\|_p,$$

что влечёт $L \leq L_2$. В некоторых задачах константа L может быть существенно меньше евклидовой константы L_2, например, для функций с плотными градиентами.
Однако из неравенств на нормы выше ясно, что дивергенция Брэгмана не всегда улучшает оценку по сравнению с евклидовой нормой. Действительно, при $1 \leq p \leq 2$ для дивергенции Брэгмана справедлива нижняя оценка (Утверждение Л1.2):

$$V(x, y) \geq \frac{1}{2}\|x - y\|_p^2 \geq \frac{1}{2}\|x - y\|_2^2.$$

Следовательно, преимущество зеркального спуска проявляется тогда, когда уменьшение константы гладкости компенсирует рост дивергенции Брэгмана. Более точно, выигрыш достигается в случае:

$$\frac{L_2}{L} \gg \sup_{x,y \in \mathcal{X}} \frac{2V(x, y)}{\|x - y\|_2^2}.$$

Пример Л1.7. В случае симплекса и KL-дивергенции можно получить выигрыш в $\frac{d}{\log d}$ раз по сравнению с градиентным спуском с евклидовой проекцией.

Решение. Возьмём в качестве начальной точки x^0 равномерный вектор $x^0 = (\frac{1}{d}, \ldots, \frac{1}{d})^\top$. Тогда максимальная дивергенция Брэгмана $V(x, x^0) = \sum_{i=1}^d x_i \log \frac{x_i}{x_i^0}$ на симплексе оценивается сверху как:

$$\max_{x \in \triangle_{d-1}} V(x, x^0) = \max_{x \in \triangle_{d-1}} \underbrace{\left\{\sum_{i=1}^d x_i \log x_i\right\}}_{\leq 0} + \log d \leq \log d.$$

В это же время евклидово расстояние ограничено куда меньшей константой для любых $x, x^0 \in \triangle_{d-1}$, так как $\|x\|_1 = 1$ и $\|x^0\|_1 = 1$:

$$\frac{1}{2}\|x - x^0\|_2^2 \leq \frac{1}{2}\|x - x^0\|_1^2 \leq \frac{1}{2}(\|x\|_1 + \|x^0\|_1)^2 = 2.$$

Однако евклидова константа L_2 в худшем случае в d раз больше, чем константа L_1, так как выполняются соотношения $\|\cdot\|_1 \leq \sqrt{d}\|\cdot\|_2$ и $\|\cdot\|_2 \leq \sqrt{d}\|\cdot\|_\infty$ (Пример **??**):

$$\|\nabla f(x) - \nabla f(y)\|_2 \leq \sqrt{d}\|\nabla f(x) - \nabla f(y)\|_\infty \leq \sqrt{d}L_1\|x - y\|_1 \leq \underbrace{dL_1}_{\leq L_2}\|x - y\|_2.$$

В случае выполнения всех неравенств как равенств, мы получаем:

$$\frac{L_2}{L_1} \approx d, \quad \sup_{x \in \triangle_{d-1}} \frac{2V(x, x^0)}{\|x - x^0\|_2^2} \approx \log d.$$

То есть для зеркального спуска с KL-дивергенцией выигрыш по итерациям может составить до $\frac{d}{\log d}$ раз.

■

Список литературы

[1] A.S. Nemirovskii and D.B. Iudin. *Problem Complexity and Method Efficiency in Optimization*. A Wiley-Interscience publication. Wiley, 1983.

[2] Г. Е. Иванов. *Лекции по математическому анализу. Часть 2*. МФТИ, Москва, 2016.