Метод зеркального спуска

Методы оптимизации

Александр Безносиков

Московский физико-технический институт

5 ноября 2026



Историческая мотивация

- Посмотрим на итерацию градиентного спуска:

$$x^{k+1} = x^k - \gamma \nabla f\left(x^k\right).$$

Историческая мотивация

- Посмотрим на итерацию градиентного спуска:

$$x^{k+1} = x^k - \gamma \nabla f\left(x^k\right).$$

- Точка x^k рассматривается как элемент конечномерного линейного нормированного пространства $E = \left(U, \|\cdot\|\right)$. **Вопрос:** а что можем сказать про $\nabla f\left(x^k\right)$?

Историческая мотивация

- Посмотрим на итерацию градиентного спуска:

$$x^{k+1} = x^k - \gamma \nabla f\left(x^k\right).$$

- Точка x^k рассматривается как элемент конечномерного линейного нормированного пространства $E = \left(U, \|\cdot\|\right)$. **Вопрос:** а что можем сказать про $\nabla f\left(x^k\right)$? В общем случае $\nabla f\left(x^k\right)$ лежит в $E^* = \left(U, \|\cdot\|_*\right)$, а не в исходном. Тогда с чего мы вдруг начали складывать векторы из абсолютно разных пространств...

Историческая мотивация

- Посмотрим на итерацию градиентного спуска:
$$x^{k+1} = x^k - \gamma \nabla f\left(x^k\right).$$
- Точка x^k рассматривается как элемент конечномерного линейного нормированного пространства $E = \left(U, \|\cdot\|\right)$. **Вопрос:** а что можем сказать про $\nabla f\left(x^k\right)$? В общем случае $\nabla f\left(x^k\right)$ лежит в $E^* = \left(U, \|\cdot\|_*\right)$, а не в исходном. Тогда с чего мы вдруг начали складывать векторы из абсолютно разных пространств...
- Ничего страшного тут нет в случае, когда $\|\cdot\| = \|\cdot\|_2$, тогда $E = E^*$ и всё, что мы делали было валидно.

Историческая мотивация

- Посмотрим на итерацию градиентного спуска:
$$x^{k+1} = x^k - \gamma \nabla f\left(x^k\right).$$
- Точка x^k рассматривается как элемент конечномерного линейного нормированного пространства $E = \left(U, \|\cdot\|\right)$. **Вопрос:** а что можем сказать про $\nabla f\left(x^k\right)$? В общем случае $\nabla f\left(x^k\right)$ лежит в $E^* = \left(U, \|\cdot\|_*\right)$, а не в исходном. Тогда с чего мы вдруг начали складывать векторы из абсолютно разных пространств...
- Ничего страшного тут нет в случае, когда $\|\cdot\| = \|\cdot\|_2$, тогда $E = E^*$ и всё, что мы делали было валидно.
- Хотим попробовать выйти за пределы евклидовости. Расстояние не обязательно мерить в евклидовой норме. «Геометрия» задачи может подталкивать использовать другие способы измерения расстояния. Зачем, например, мерить расстояние между распределениями вероятности в евклидовой норме, есть более «физичные» способы.

Историческая мотивация

- А. Немировский и Д. Юдин предложили:

$$x^{k+1} = \left(\nabla d\right)^{-1}\Big(\nabla d\left(x^k\right) - \gamma \nabla f\left(x^k\right)\Big),$$

где обратное отображение $\left(\nabla d\right)^{-1} : E^* \to E$ возвращает результат в исходное пространство E.

Историческая мотивация

- А. Немировский и Д. Юдин предложили:

$$x^{k+1} = \left(\nabla d\right)^{-1}\Big(\nabla d\left(x^k\right) - \gamma \nabla f\left(x^k\right)\Big),$$

  где обратное отображение $\left(\nabla d\right)^{-1} : E^* \to E$ возвращает результат в исходное пространство E.
- Получается, мы переходим в «зеркальное» пространство E^*, там делаем шаг градиентного спуска, а потом с помощью $\left(\nabla d\right)^{-1}$ возвращаемся к x^{k+1} из E.

Историческая мотивация

- А. Немировский и Д. Юдин предложили:

$$x^{k+1} = (\nabla d)^{-1}\Big(\nabla d(x^k) - \gamma \nabla f(x^k)\Big),$$

  где обратное отображение $(\nabla d)^{-1} : E^* \to E$ возвращает результат в исходное пространство E.
- Получается, мы переходим в «зеркальное» пространство E^*, там делаем шаг градиентного спуска, а потом с помощью $(\nabla d)^{-1}$ возвращаемся к x^{k+1} из E.
- Это и есть идея «зеркальности» градиентного спуска.

Дивергенция Брэгмана

Определение

*Пусть дана непрерывно дифференцируемая на выпуклом множестве $\mathcal{X}$ функция $d : \mathcal{X} \to \mathbb{R}$. Будем говорить, что она является μ–**сильно выпуклой относительно нормы** $\|\cdot\|$ на множестве $\mathcal{X}$, если для любых $x, y \in \mathcal{X}$ выполнено*

$$d(x) \geq d(y) + \langle \nabla d(y), x - y \rangle + \frac{\mu}{2}\|x - y\|^2.$$

Дивергенция Брэгмана

Определение

Пусть дана непрерывно дифференцируемая 1–сильно выпуклая относительно нормы $\|\cdot\|$ на множестве $\mathcal{X}$ функция d. ***Дивергенцией Брэгмана****, порожденной функцией d на множестве $\mathcal{X}$, называется функция двух аргументов $V : \mathcal{X} \times \mathcal{X} \to \mathbb{R}$ такая, что для любых $x, y \in \mathcal{X}$ выполняется*

$$V(x, y) = d(x) - d(y) - \langle \nabla d(y), x - y \rangle.$$

Примеры

- Квадрат евклидовой нормы $d : \mathbb{R}^d \to \mathbb{R}$:

$$d(x) = \frac{1}{2}\|x\|_2^2 \quad V(x, y) = \frac{1}{2}\|x - y\|_2^2.$$

Примеры

- Квадрат евклидовой нормы $d : \mathbb{R}^d \to \mathbb{R}$:

$$d(x) = \frac{1}{2}\|x\|_2^2 \quad V(x, y) = \frac{1}{2}\|x - y\|_2^2.$$

- Энтропия Шеннона $d : \triangle_{d-1} \to \mathbb{R}$:

$$d(x) = \sum_{i=1}^{d} x_i \log x_i \quad V(x, y) = \sum_{i=1}^{d} x_i \log \frac{x_i}{y_i}.$$

Примеры

- Квадрат евклидовой нормы $d : \mathbb{R}^d \to \mathbb{R}$:

$$d(x) = \frac{1}{2}\|x\|_2^2 \quad V(x, y) = \frac{1}{2}\|x - y\|_2^2.$$

- Энтропия Шеннона $d : \triangle_{d-1} \to \mathbb{R}$:

$$d(x) = \sum_{i=1}^{d} x_i \log x_i \quad V(x, y) = \sum_{i=1}^{d} x_i \log \frac{x_i}{y_i}.$$

- Энтропия фон Неймана $d : \mathbb{S}_1^d \to \mathbb{R}$:

$$d(X) = \mathrm{Tr}(X \log X) \quad V(X, Y) = \mathrm{Tr}(X \log X - X \log Y).$$

Примеры

- Квадрат евклидовой нормы $d : \mathbb{R}^d \to \mathbb{R}$:

$$d(x) = \frac{1}{2}\|x\|_2^2 \quad V(x, y) = \frac{1}{2}\|x - y\|_2^2.$$

- Энтропия Шеннона $d : \triangle_{d-1} \to \mathbb{R}$:

$$d(x) = \sum_{i=1}^{d} x_i \log x_i \quad V(x, y) = \sum_{i=1}^{d} x_i \log \frac{x_i}{y_i}.$$

- Энтропия фон Неймана $d : \mathbb{S}_1^d \to \mathbb{R}$:

$$d(X) = \operatorname{Tr}(X \log X) \quad V(X, Y) = \operatorname{Tr}(X \log X - X \log Y).$$

- Логарифмический барьер $d : \mathbb{S}_{++}^d \to \mathbb{R}$:

$$d(X) = -\log(\det X) \quad V(X, Y) = \operatorname{Tr}\left(XY^{-1} - I_d\right) - \log\det\left(XY^{-1}\right).$$

Свойства дивергенции Брэгмана

Утверждение

Пусть $\mathcal{X}$ — выпуклое множество. Дивергенция Брэгмана в общем случае обладает следующими свойствами:

1. *Асимметричность: в общем случае $V(x, y) \neq V(y, x)$.*

Свойства дивергенции Брэгмана

Утверждение

Пусть $\mathcal{X}$ — выпуклое множество. Дивергенция Брэгмана в общем случае обладает следующими свойствами:

1. *Асимметричность: в общем случае $V(x, y) \neq V(y, x)$.*
2. *Ограниченность снизу:*

$$V(x, y) \geq \frac{1}{2}\|x - y\|^2 \text{ для всех } x, y \in \mathcal{X}.$$

Свойства дивергенции Брэгмана

Утверждение

Пусть $\mathcal{X}$ — выпуклое множество. Дивергенция Брэгмана в общем случае обладает следующими свойствами:

1. *Асимметричность: в общем случае $V(x, y) \neq V(y, x)$.*
2. *Ограниченность снизу:*

$$V(x, y) \geq \frac{1}{2}\|x - y\|^2 \text{ для всех } x, y \in \mathcal{X}.$$

3. *Неотрицательность: $V(x, y) \geq 0$ для всех $x, y \in \mathcal{X}$.*

Свойства дивергенции Брэгмана

Утверждение

Пусть $\mathcal{X}$ — выпуклое множество. Дивергенция Брэгмана в общем случае обладает следующими свойствами:

1. *Асимметричность: в общем случае $V(x, y) \neq V(y, x)$.*
2. *Ограниченность снизу:*

$$V(x, y) \geq \frac{1}{2}\|x - y\|^2 \text{ для всех } x, y \in \mathcal{X}.$$

3. *Неотрицательность: $V(x, y) \geq 0$ для всех $x, y \in \mathcal{X}$.*
4. *1–сильная выпуклость по первому аргументу.*

Свойства дивергенции Брэгмана

Утверждение

Пусть $\mathcal{X}$ — выпуклое множество. Дивергенция Брэгмана в общем случае обладает следующими свойствами:

1. *Асимметричность: в общем случае $V(x, y) \neq V(y, x)$.*
2. *Ограниченность снизу:*

$$V(x, y) \geq \frac{1}{2}\|x - y\|^2 \text{ для всех } x, y \in \mathcal{X}.$$

3. *Неотрицательность: $V(x, y) \geq 0$ для всех $x, y \in \mathcal{X}$.*
4. *1–сильная выпуклость по первому аргументу.*
5. *По второму аргументу может не быть выпуклости.*

Равенство параллелограмма/теорема Пифагора

Утверждение

Пусть $\mathcal{X}$ — выпуклое множество. Для любых точек $x, y, z \in \mathcal{X}$:

$$V(z,x) + V(x,y) - V(z,y) = \langle \nabla d(y) - \nabla d(x), z - x \rangle.$$

Равенство параллелограмма/теорема Пифагора

Утверждение

Пусть $\mathcal{X}$ — выпуклое множество. Для любых точек $x, y, z \in \mathcal{X}$:

$$V(z,x) + V(x,y) - V(z,y) = \langle \nabla d(y) - \nabla d(x), z - x \rangle.$$

$$\begin{aligned} V(z,x) + V(x,y) &= d(z) - d(x) - \langle \nabla d(x), z - x \rangle \\ &\quad + d(x) - d(y) - \langle \nabla d(y), x - y \rangle \\ &= d(z) - d(y) - \langle \nabla d(y), z - y \rangle \\ &\quad - \langle \nabla d(x) - \nabla d(y), z - x \rangle \\ &= V(z,y) - \langle \nabla d(x) - \nabla d(y), z - x \rangle. \end{aligned}$$

Метод зеркального спуска

Решаем задачу

$$\min_{x \in \mathcal{X}} f\left(x\right),$$

где множество $\mathcal{X}$ выпуклое и замкнутое, а функция f — выпуклая.

Метод зеркального спуска

Решаем задачу

$$\min_{x \in \mathcal{X}} f\left(x\right),$$

где множество $\mathcal{X}$ выпуклое и замкнутое, а функция f — выпуклая.

- Итерация градиентного спуска:

$$x^{k+1} = x^k - \gamma_k \nabla f\left(x^k\right).$$

Метод зеркального спуска

Решаем задачу

$$\min_{x \in \mathcal{X}} f\left(x\right),$$

где множество $\mathcal{X}$ выпуклое и замкнутое, а функция f — выпуклая.

- Итерация градиентного спуска:

$$x^{k+1} = x^k - \gamma_k \nabla f\left(x^k\right).$$

- С точки зрения оптимизации данная итерация является решением следующей задачи:

$$\operatorname*{argmin}_{x \in \mathbb{R}^d} \left\{ f\left(x^k\right) + \left\langle \nabla f\left(x^k\right), x - x^k \right\rangle + \frac{1}{2\gamma_k} \left\| x - x^k \right\|_2^2 \right\}.$$

Метод зеркального спуска

Решаем задачу

$$\min_{x \in \mathcal{X}} f(x),$$

где множество $\mathcal{X}$ выпуклое и замкнутое, а функция f — выпуклая.

- Итерация градиентного спуска:

$$x^{k+1} = x^k - \gamma_k \nabla f(x^k).$$

- С точки зрения оптимизации данная итерация является решением следующей задачи:

$$\operatorname*{argmin}_{x \in \mathbb{R}^d} \left\{ f(x^k) + \left\langle \nabla f(x^k), x - x^k \right\rangle + \frac{1}{2\gamma_k} \left\| x - x^k \right\|_2^2 \right\}.$$

- Заменим евклидову норму $\frac{1}{2}\left\| x - x^k \right\|_2^2$ на $V(x, x^k)$:

$$\operatorname*{argmin}_{x \in \mathcal{X}} \left\{ f(x^k) + \left\langle \nabla f(x^k), x - x^k \right\rangle + \frac{1}{\gamma_k} V(x, x^k) \right\}.$$

Метод зеркального спуска

Алгоритм Зеркальный спуск

Вход: стартовая точка $x^0 \in \mathcal{X}$, размеры шагов $\{\gamma_k\}_{k=0} > 0$, количество итераций K

1: **for** $k = 0, 1, \ldots, K-1$ **do**

2: $\quad x^{k+1} = \operatorname{argmin}_{x \in \mathcal{X}} \left\{ \left\langle \gamma_k \nabla f\left(x^k\right), x - x^k \right\rangle + V\left(x, x^k\right) \right\}$

3: **end for**

Выход: $\frac{1}{K} \sum_{k=1}^{K} x^k$

Примеры

Квадрат евклидовой нормы $V : \mathcal{X} \times \mathcal{X} \to \mathbb{R}$:

$$V(x, y) = \frac{1}{2}\|x - y\|_2^2, \; x, y \in \mathcal{X}.$$

Примеры

Квадрат евклидовой нормы $V : \mathcal{X} \times \mathcal{X} \to \mathbb{R}$:

$$V(x, y) = \frac{1}{2}\|x - y\|_2^2, \; x, y \in \mathcal{X}.$$

Чтобы посчитать argmin, добавим слагаемые не зависящие от x и выделим квадрат нормы:

$$\begin{aligned} x^{k+1} &= \operatorname*{argmin}_{x \in \mathcal{X}} \left\{ \frac{1}{2}\gamma_k^2 \left\| \nabla f\left(x^k\right) \right\|_2^2 + \left\langle \gamma_k \nabla f\left(x^k\right), x - x^k \right\rangle + \frac{1}{2}\|x - x^k\|_2^2 \right\} \\ &= \operatorname*{argmin}_{x \in \mathcal{X}} \left\| x - \left(x^k - \gamma_k \nabla f\left(x^k\right) \right) \right\|_2^2 = \Pi_{\mathcal{X}}\left(x^k - \gamma_k \nabla f\left(x^k\right) \right). \end{aligned}$$

Получился градиентный спуск с евклидовой проекцией.

Примеры

Рассмотрим метод при $\mathcal{X} = \mathbb{R}^d$ и некоторой d:

$$x^{k+1} = \operatorname*{argmin}_{x \in \mathcal{X}} \left\{ \left\langle \gamma_k \nabla f\left(x^k\right), x - x^k \right\rangle + V\left(x, x^k\right) \right\}$$
$$= \operatorname*{argmin}_{x \in \mathbb{R}^d} \left\{ \left\langle \gamma_k \nabla f\left(x^k\right), x - x^k \right\rangle + d(x) - d\left(x^k\right) - \left\langle \nabla d\left(x^k\right), x - x^k \right\rangle \right\}.$$

Примеры

Рассмотрим метод при $\mathcal{X} = \mathbb{R}^d$ и некоторой d:

$$x^{k+1} = \operatorname*{argmin}_{x \in \mathcal{X}} \left\{ \left\langle \gamma_k \nabla f\left(x^k\right), x - x^k \right\rangle + V\left(x, x^k\right) \right\}$$
$$= \operatorname*{argmin}_{x \in \mathbb{R}^d} \left\{ \left\langle \gamma_k \nabla f\left(x^k\right), x - x^k \right\rangle + d(x) - d\left(x^k\right) - \left\langle \nabla d\left(x^k\right), x - x^k \right\rangle \right\}.$$

Запишем условие оптимальности:

$$\gamma_k \nabla f\left(x^k\right) + \nabla d(x) - \nabla d\left(x^k\right) = 0.$$

Примеры

Рассмотрим метод при $\mathcal{X} = \mathbb{R}^d$ и некоторой d:

$$x^{k+1} = \operatorname*{argmin}_{x \in \mathcal{X}} \left\{ \left\langle \gamma_k \nabla f\left(x^k\right), x - x^k \right\rangle + V\left(x, x^k\right) \right\}$$
$$= \operatorname*{argmin}_{x \in \mathbb{R}^d} \left\{ \left\langle \gamma_k \nabla f\left(x^k\right), x - x^k \right\rangle + d(x) - d\left(x^k\right) - \left\langle \nabla d\left(x^k\right), x - x^k \right\rangle \right\}.$$

Запишем условие оптимальности:

$$\gamma_k \nabla f\left(x^k\right) + \nabla d(x) - \nabla d\left(x^k\right) = 0.$$

Это и есть идея Немировского и Юдина, идея «зеркальности».

$$\nabla d\left(x^{k+1}\right) = \nabla d\left(x^k\right) - \gamma_k \nabla f\left(x^k\right).$$

Примеры

Дивергенция Кульбака–Лейблера $V : \triangle_{d-1} \times \triangle_{d-1} \to \mathbb{R}$:

$$V(x, y) = \sum_{i=1}^{d} x_i \log \frac{x_i}{y_i}, \; x, y \in \triangle_{d-1}.$$

Примеры

Дивергенция Кульбака–Лейблера $V : \triangle_{d-1} \times \triangle_{d-1} \to \mathbb{R}$:

$$V(x, y) = \sum_{i=1}^{d} x_i \log \frac{x_i}{y_i}, \; x, y \in \triangle_{d-1}.$$

Запишем итерацию зеркального спуска как задачу с ограничениями:

$$\begin{aligned} \min_{x \in \mathbb{R}^d} \quad & \left\langle \gamma_k \nabla f\left(x^k\right), x \right\rangle + V\left(x, x^k\right) \\ \text{s.t.} \quad & -x_i \leq 0 \\ & \sum_{i=1}^{d} x_i - 1 = 0. \end{aligned}$$

Примеры

Лагранжиан для такой задачи:

$$\mathcal{L}(x, \lambda, \nu) = \left\langle \gamma_k \nabla f\left(x^k\right), x \right\rangle + V\left(x, x^k\right) - \sum_{i=1}^{d} \lambda_i x_i + \nu \left(\sum_{i=1}^{d} x_i - 1 \right)$$

$$= \sum_{i=1}^{d} \left(\gamma_k \left[\nabla f\left(x^k\right) \right]_i + \log \frac{x_i}{x_i^k} - \lambda_i + \nu \right) x_i - \nu.$$

Примеры

Лагранжиан для такой задачи:

$$\mathcal{L}(x, \lambda, \nu) = \left\langle \gamma_k \nabla f\left(x^k\right), x \right\rangle + V\left(x, x^k\right) - \sum_{i=1}^{d} \lambda_i x_i + \nu \left(\sum_{i=1}^{d} x_i - 1 \right)$$

$$= \sum_{i=1}^{d} \left(\gamma_k \left[\nabla f\left(x^k\right) \right]_i + \log \frac{x_i}{x_i^k} - \lambda_i + \nu \right) x_i - \nu.$$

Условие оптимальности по x_i:

$$\frac{\partial \mathcal{L}}{\partial x_i}(x, \lambda, \nu) = 1 + \gamma_k \left[\nabla f\left(x^k\right) \right]_i + \log \frac{x_i}{x_i^k} - \lambda_i + \nu = 0.$$

Примеры

Лагранжиан для такой задачи:

$$\mathcal{L}(x, \lambda, \nu) = \left\langle \gamma_k \nabla f\left(x^k\right), x \right\rangle + V\left(x, x^k\right) - \sum_{i=1}^{d} \lambda_i x_i + \nu \left(\sum_{i=1}^{d} x_i - 1 \right)$$

$$= \sum_{i=1}^{d} \left(\gamma_k \left[\nabla f\left(x^k\right) \right]_i + \log \frac{x_i}{x_i^k} - \lambda_i + \nu \right) x_i - \nu.$$

Условие оптимальности по x_i:

$$\frac{\partial \mathcal{L}}{\partial x_i}(x, \lambda, \nu) = 1 + \gamma_k \left[\nabla f\left(x^k\right) \right]_i + \log \frac{x_i}{x_i^k} - \lambda_i + \nu = 0.$$

Отсюда находим x, доставляющий минимум лагранжиана:

$$x_i = x_i^k \exp\left(-1 - \gamma_k \left[\nabla f\left(x^k\right) \right]_i + \lambda_i - \nu \right), \quad i = \overline{1, d}.$$

Примеры

Из условия дополняющей нежесткости получаем:

$$x_i = x_i^k \exp\left(-1 - \gamma_k \left[\nabla f\left(x^k\right)\right]_i - \nu\right), \quad i = \overline{1, d}.$$

Примеры

Из условия дополняющей нежесткости получаем:

$$x_i = x_i^k \exp\left(-1 - \gamma_k \left[\nabla f\left(x^k\right)\right]_i - \nu\right), \quad i = \overline{1, d}.$$

Чтобы записать выражение для ν, вспомним ограничения задачи $\sum_{i=1}^d x_i = 1$. Отсюда получаем нормировку и можно записать:

$$x_i^{k+1} = x_i^k \frac{\exp\left(-\gamma_k \left[\nabla f\left(x^k\right)\right]_i\right)}{\sum_{j=1}^d x_j^k \exp\left(-\gamma_k \left[\nabla f\left(x^k\right)\right]_j\right)}.$$

Обобщение L–гладкости

Определение

Пусть дана непрерывно дифференцируемая на выпуклом множестве $\mathcal{X}$ функция $f : \mathcal{X} \to \mathbb{R}$. Будем говорить, что данная функция имеет ***L-липшицев градиент (является L–гладкой) относительно нормы $\|\cdot\|$ на $\mathcal{X}$****, если для любых $x, y \in \mathcal{X}$ выполнено*

$$\|\nabla f(x) - \nabla f(y)\|_* \leq L\|x - y\|.$$

Свойство L–гладкой функции

Теорема

Пусть $\mathcal{X}$ — выпуклое множество. Для L–гладкой относительно нормы $\|\cdot\|$ функции $f : \mathcal{X} \to \mathbb{R}$ выполнено

$$\left|f(y) - f(x) - \langle \nabla f(x), y - x \rangle\right| \leq \frac{L}{2}\|x - y\|^2.$$

Доказательство

Используем формулу Ньютона–Лейбница для криволинейного интеграла второго рода по кривой, заданной вектор-функцией $r(\tau)$:

$$\int_a^b \left\langle \nabla f\big(r(\tau)\big), \mathrm{d}r(\tau) \right\rangle = f\big(r(b)\big) - f\big(r(a)\big).$$

Доказательство

Используем формулу Ньютона–Лейбница для криволинейного интеграла второго рода по кривой, заданной вектор-функцией $r(\tau)$:

$$\int_a^b \langle \nabla f\big(r(\tau)\big), \mathrm{d}r(\tau)\rangle = f\big(r(b)\big) - f\big(r(a)\big).$$

В нашем случае выберем кривую следующим образом: $r(\tau) = x + \tau(y - x)$, где $\tau \in [0, 1]$. Тогда

$$f(y) - f(x) = \int_0^1 \langle \nabla f\big(x + \tau(y - x)\big), y - x\rangle \,\mathrm{d}\tau$$

$$= \langle \nabla f(x), y - x\rangle + \int_0^1 \langle \nabla f\big(x + \tau(y - x)\big) - \nabla f(x), y - x\rangle \,\mathrm{d}\tau\,.$$

Доказательство

Переместив скалярное произведение влево и взяв модуль от обеих частей, получим:

$$\left|f(y) - f(x) - \langle \nabla f(x), y - x \rangle\right| = \left|\int_0^1 \langle \nabla f(x + \tau(y - x)) - \nabla f(x), y - x \rangle \, \mathrm{d}\tau\right|$$

$$\leq \int_0^1 \left|\langle \nabla f(x + \tau(y - x)) - \nabla f(x), y - x \rangle\right| \mathrm{d}\tau \, .$$

Доказательство

Переместив скалярное произведение влево и взяв модуль от обеих частей, получим:

$$\left|f(y) - f(x) - \langle \nabla f(x), y - x \rangle\right| = \left|\int_0^1 \langle \nabla f(x + \tau(y - x)) - \nabla f(x), y - x \rangle \, \mathrm{d}\tau\right|$$

$$\leq \int_0^1 \left|\langle \nabla f(x + \tau(y - x)) - \nabla f(x), y - x \rangle\right| \mathrm{d}\tau \, .$$

Далее воспользуемся неравенством Гёльдера, а затем L–гладкостью относительно нормы $\|\cdot\|$:

$$\left|f(y) - f(x) - \langle \nabla f(x), y - x \rangle\right| \leq \int_0^1 \|\nabla f(x + \tau(y - x)) - \nabla f(x)\|_* \|y - x\| \, \mathrm{d}\tau$$

$$\leq L\|y - x\|^2 \int_0^1 \tau \, \mathrm{d}\tau = \frac{L}{2}\|x - y\|^2.$$

Сходимость

Начнем с итерации зеркального спуска:

$$x^{k+1} = \operatorname*{argmin}_{x \in \mathcal{X}} \left\{ \left\langle \gamma \nabla f\left(x^k\right), x - x^k \right\rangle + V\left(x, x^k\right) \right\}$$
$$= \operatorname*{argmin}_{x \in \mathcal{X}} \left\{ \left\langle \gamma \nabla f\left(x^k\right), x - x^k \right\rangle + d(x) - d\left(x^k\right) - \left\langle \nabla d\left(x^k\right), x - x^k \right\rangle \right\}.$$

Сходимость

Начнем с итерации зеркального спуска:

$$x^{k+1} = \operatorname*{argmin}_{x \in \mathcal{X}} \left\{ \left\langle \gamma \nabla f\left(x^k\right), x - x^k \right\rangle + V\left(x, x^k\right) \right\}$$
$$= \operatorname*{argmin}_{x \in \mathcal{X}} \left\{ \left\langle \gamma \nabla f\left(x^k\right), x - x^k \right\rangle + d(x) - d\left(x^k\right) - \left\langle \nabla d\left(x^k\right), x - x^k \right\rangle \right\}.$$

Запишем условие оптимальности на выпуклом множестве $\mathcal{X}$ для функции под argmin:

$$\left\langle \gamma \nabla f\left(x^k\right) + \nabla d\left(x^{k+1}\right) - \nabla d\left(x^k\right), x - x^{k+1} \right\rangle \geq 0,$$

для всех $x \in \mathcal{X}$.

Сходимость

Применим равенство параллелограмма для дивергенции Брэгмана:

$$V\left(x, x^{k+1}\right)+V\left(x^{k+1}, x^{k}\right)-V\left(x, x^{k}\right)=\left\langle \nabla d\left(x^{k}\right)-\nabla d\left(x^{k+1}\right), x-x^{k+1}\right\rangle.$$

Сходимость

Применим равенство параллелограмма для дивергенции Брэгмана:

$$V\left(x, x^{k+1}\right)+V\left(x^{k+1}, x^k\right)-V\left(x, x^k\right)=\left\langle \nabla d\left(x^k\right)-\nabla d\left(x^{k+1}\right), x-x^{k+1}\right\rangle.$$

Подставляем в неравенство выше, учитывая знак, получаем:

$$\left\langle \gamma \nabla f\left(x^k\right), x^{k+1}-x\right\rangle + V\left(x, x^{k+1}\right) + V\left(x^{k+1}, x^k\right) - V\left(x, x^k\right) \leq 0.$$

Сходимость

Применим равенство параллелограмма для дивергенции Брэгмана:

$$V\left(x, x^{k+1}\right)+V\left(x^{k+1}, x^k\right)-V\left(x, x^k\right) = \left\langle \nabla d\left(x^k\right) - \nabla d\left(x^{k+1}\right), x - x^{k+1} \right\rangle.$$

Подставляем в неравенство выше, учитывая знак, получаем:

$$\left\langle \gamma \nabla f\left(x^k\right), x^{k+1} - x \right\rangle + V\left(x, x^{k+1}\right) + V\left(x^{k+1}, x^k\right) - V\left(x, x^k\right) \leq 0.$$

Запишем свойство L–гладкости:

$$f\left(x^{k+1}\right) - f\left(x^k\right) - \left\langle \nabla f\left(x^k\right), x^{k+1} - x^k \right\rangle \leq \frac{L}{2}\left\|x^k - x^{k+1}\right\|^2.$$

Сходимость

Сложим основное неравенство и предыдущее неравенство домноженное на γ:

$$\left\langle \gamma \nabla f\left(x^k\right), x^{k+1} - x \right\rangle + V\left(x, x^{k+1}\right) + V\left(x^{k+1}, x^k\right) - V\left(x, x^k\right)$$
$$+ \gamma\left(f\left(x^{k+1}\right) - f\left(x^k\right) - \left\langle \nabla f\left(x^k\right), x^{k+1} - x^k \right\rangle\right) \leq \frac{\gamma L}{2}\left\|x^k - x^{k+1}\right\|^2.$$

Сходимость

Сложим основное неравенство и предыдущее неравенство домноженное на γ:

$$\left\langle \gamma \nabla f\left(x^k\right), x^{k+1} - x \right\rangle + V\left(x, x^{k+1}\right) + V\left(x^{k+1}, x^k\right) - V\left(x, x^k\right) + \gamma\left(f\left(x^{k+1}\right) - f\left(x^k\right) - \left\langle \nabla f\left(x^k\right), x^{k+1} - x^k \right\rangle\right) \leq \frac{\gamma L}{2}\left\|x^k - x^{k+1}\right\|^2.$$

Перепишем, оставив слева только слагаемые с f:

$$\left\langle \gamma \nabla f\left(x^k\right), x^k - x \right\rangle + \gamma\left(f\left(x^{k+1}\right) - f\left(x^k\right)\right) \leq V\left(x, x^k\right) - V\left(x, x^{k+1}\right) - V\left(x^{k+1}, x^k\right) + \frac{\gamma L}{2}\left\|x^k - x^{k+1}\right\|^2.$$

Сходимость

Из определения выпуклости можно оценить:

$$f\left(x^k\right) - f\left(x\right) + \left\langle \nabla f\left(x^k\right), x - x^k \right\rangle \leq 0.$$

Сходимость

Из определения выпуклости можно оценить:

$$f\left(x^k\right) - f\left(x\right) + \left\langle \nabla f\left(x^k\right), x - x^k \right\rangle \leq 0.$$

Домножим предыдущее неравенство на γ и сложим с основным неравенством:

$$\gamma\left(f\left(x^{k+1}\right) - f\left(x\right)\right) \leq V\left(x, x^k\right) - V\left(x, x^{k+1}\right) - V\left(x^{k+1}, x^k\right) + \frac{\gamma L}{2}\left\|x^k - x^{k+1}\right\|^2.$$

Сходимость

Запишем второе свойство дивергенции Брэгмана:

$$\frac{1}{2}\left\|x^{k+1} - x^k\right\|^2 \leq V\left(x^{k+1}, x^k\right).$$

Сходимость

Запишем второе свойство дивергенции Брэгмана:

$$\frac{1}{2}\left\|x^{k+1} - x^k\right\|^2 \leq V\left(x^{k+1}, x^k\right).$$

Подставим его в основное неравенство:

$$\gamma\Big(f\left(x^{k+1}\right) - f\left(x\right)\Big) \leq V\left(x, x^k\right) - V\left(x, x^{k+1}\right) + \left(\gamma L - 1\right) V\left(x^{k+1}, x^k\right).$$

Сходимость

Запишем второе свойство дивергенции Брэгмана:

$$\frac{1}{2}\left\|x^{k+1} - x^k\right\|^2 \leq V\left(x^{k+1}, x^k\right).$$

Подставим его в основное неравенство:

$$\gamma\Big(f\left(x^{k+1}\right) - f\left(x\right)\Big) \leq V\left(x, x^k\right) - V\left(x, x^{k+1}\right) + \left(\gamma L - 1\right) V\left(x^{k+1}, x^k\right).$$

Возьмём $\gamma \leq \frac{1}{L}$ и откинем последнее слагаемое:

$$\gamma\Big(f\left(x^{k+1}\right) - f\left(x\right)\Big) \leq V\left(x, x^k\right) - V\left(x, x^{k+1}\right).$$

Сходимость

Усредним по всем k от 0 до $K-1$:

$$\frac{\gamma}{K}\sum_{k=0}^{K-1}\left(f\left(x^{k+1}\right)-f\left(x\right)\right)\leq\frac{1}{K}\sum_{k=0}^{K-1}\left(V\left(x,x^{k}\right)-V\left(x,x^{k+1}\right)\right).$$

Сходимость

Усредним по всем k от 0 до $K-1$:

$$\frac{\gamma}{K}\sum_{k=0}^{K-1}\left(f\left(x^{k+1}\right)-f(x)\right)\leq\frac{1}{K}\sum_{k=0}^{K-1}\left(V\left(x,x^{k}\right)-V\left(x,x^{k+1}\right)\right).$$

Справа свернем телескопическую сумму:

$$\frac{1}{K}\sum_{k=0}^{K-1}\left(f\left(x^{k+1}\right)-f(x)\right)\leq\frac{1}{\gamma K}\left(V\left(x,x^{0}\right)-V\left(x,x^{K}\right)\right)\leq\frac{V\left(x,x^{0}\right)}{\gamma K}.$$

Сходимость

Усредним по всем k от 0 до $K-1$:

$$\frac{\gamma}{K}\sum_{k=0}^{K-1}\left(f\left(x^{k+1}\right)-f\left(x\right)\right)\leq\frac{1}{K}\sum_{k=0}^{K-1}\left(V\left(x,x^{k}\right)-V\left(x,x^{k+1}\right)\right).$$

Справа свернем телескопическую сумму:

$$\frac{1}{K}\sum_{k=0}^{K-1}\left(f\left(x^{k+1}\right)-f\left(x\right)\right)\leq\frac{1}{\gamma K}\left(V\left(x,x^{0}\right)-V\left(x,x^{K}\right)\right)\leq\frac{V\left(x,x^{0}\right)}{\gamma K}.$$

Для левой части применяем неравенство Йенсена

$$f\left(\frac{1}{K}\sum_{k=1}^{K}x^{k}\right)-f\left(x\right)\leq\frac{V\left(x,x^{0}\right)}{\gamma K}.$$

Сходимость

Усредним по всем k от 0 до $K-1$:

$$\frac{\gamma}{K}\sum_{k=0}^{K-1}\left(f\left(x^{k+1}\right)-f(x)\right)\leq\frac{1}{K}\sum_{k=0}^{K-1}\left(V\left(x,x^{k}\right)-V\left(x,x^{k+1}\right)\right).$$

Справа свернем телескопическую сумму:

$$\frac{1}{K}\sum_{k=0}^{K-1}\left(f\left(x^{k+1}\right)-f(x)\right)\leq\frac{1}{\gamma K}\left(V\left(x,x^{0}\right)-V\left(x,x^{K}\right)\right)\leq\frac{V\left(x,x^{0}\right)}{\gamma K}.$$

Для левой части применяем неравенство Йенсена

$$f\left(\frac{1}{K}\sum_{k=1}^{K}x^{k}\right)-f(x)\leq\frac{V\left(x,x^{0}\right)}{\gamma K}.$$

В силу произвольности x, можем взять $x=x^{*}$:

$$f\left(\frac{1}{K}\sum_{k=1}^{K}x^{k}\right)-f^{*}\leq\frac{V\left(x^{*},x^{0}\right)}{\gamma K}.$$

Сходимость

Теорема

Пусть задача оптимизации на выпуклом замкнутом множестве $\mathcal{X}$ с L–гладкой относительно нормы $\|\cdot\|$ выпуклой целевой функцией f решается с помощью зеркального спуска. Тогда при $\gamma_k = \gamma \leq \frac{1}{L}$ справедлива следующая оценка сходимости:

$$f\left(\frac{1}{K}\sum_{k=1}^{K} x^k\right) - f^* \leq \frac{V\left(x^*, x^0\right)}{\gamma K}.$$

Итог

- Результат очень похож на сходимость градиентного спуска и обобщает его.

Итог

- Результат очень похож на сходимость градиентного спуска и обобщает его.
- **Вопрос:** а может ли оценка зеркального спуска быть лучше, чем для градиентного? Где проявится этот эффект?

Итог

- Результат очень похож на сходимость градиентного спуска и обобщает его.
- **Вопрос:** а может ли оценка зеркального спуска быть лучше, чем для градиентного? Где проявится этот эффект? В L и V.
- Если $1 \leq p \leq 2$, то $\|\cdot\|_2 \leq \|\cdot\|_p$, $\|\cdot\|_q \leq \|\cdot\|_2$, где $\frac{1}{p} + \frac{1}{q} = 1$.

Итог

- Результат очень похож на сходимость градиентного спуска и обобщает его.
- **Вопрос:** а может ли оценка зеркального спуска быть лучше, чем для градиентного? Где проявится этот эффект? В L и V.
- Если $1 \leq p \leq 2$, то $\|\cdot\|_2 \leq \|\cdot\|_p$, $\|\cdot\|_q \leq \|\cdot\|_2$, где $\frac{1}{p} + \frac{1}{q} = 1$.
- **Вопрос:** что тогда можно сказать про отношение L и L_2?

Итог

- Результат очень похож на сходимость градиентного спуска и обобщает его.
- **Вопрос:** а может ли оценка зеркального спуска быть лучше, чем для градиентного? Где проявится этот эффект? В L и V.
- Если $1 \leq p \leq 2$, то $\|\cdot\|_2 \leq \|\cdot\|_p$, $\|\cdot\|_q \leq \|\cdot\|_2$, где $\frac{1}{p} + \frac{1}{q} = 1$.
- **Вопрос:** что тогда можно сказать про отношение L и L_2? $L \leq L_2$, а в хорошем случае L значительно меньше.

Итог

- Результат очень похож на сходимость градиентного спуска и обобщает его.
- **Вопрос:** а может ли оценка зеркального спуска быть лучше, чем для градиентного? Где проявится этот эффект? В L и V.
- Если $1 \leq p \leq 2$, то $\|\cdot\|_2 \leq \|\cdot\|_p$, $\|\cdot\|_q \leq \|\cdot\|_2$, где $\frac{1}{p} + \frac{1}{q} = 1$.
- **Вопрос:** что тогда можно сказать про отношение L и L_2? $L \leq L_2$, а в хорошем случае L значительно меньше.
- **Вопрос:** с дивергенцией тоже всё хорошо?

Итог

- Результат очень похож на сходимость градиентного спуска и обобщает его.
- **Вопрос:** а может ли оценка зеркального спуска быть лучше, чем для градиентного? Где проявится этот эффект? В L и V.
- Если $1 \leq p \leq 2$, то $\|\cdot\|_2 \leq \|\cdot\|_p$, $\|\cdot\|_q \leq \|\cdot\|_2$, где $\frac{1}{p} + \frac{1}{q} = 1$.
- **Вопрос:** что тогда можно сказать про отношение L и L_2? $L \leq L_2$, а в хорошем случае L значительно меньше.
- **Вопрос:** с дивергенцией тоже всё хорошо? Там ситуация обратная для $1 \leq p \leq 2$:

$$V(x, y) \geq \frac{1}{2}\|x - y\|_p^2 \geq \frac{1}{2}\|x - y\|_2^2.$$

Итог

- Результат очень похож на сходимость градиентного спуска и обобщает его.
- **Вопрос:** а может ли оценка зеркального спуска быть лучше, чем для градиентного? Где проявится этот эффект? В L и V.
- Если $1 \leq p \leq 2$, то $\|\cdot\|_2 \leq \|\cdot\|_p$, $\|\cdot\|_q \leq \|\cdot\|_2$, где $\frac{1}{p} + \frac{1}{q} = 1$.
- **Вопрос:** что тогда можно сказать про отношение L и L_2? $L \leq L_2$, а в хорошем случае L значительно меньше.
- **Вопрос:** с дивергенцией тоже всё хорошо? Там ситуация обратная для $1 \leq p \leq 2$:

$$V(x, y) \geq \frac{1}{2}\|x - y\|_p^2 \geq \frac{1}{2}\|x - y\|_2^2.$$

- Выигрыш будет, если

$$\frac{L_2}{L} \gg \sup_{x,y \in \mathcal{X}} \frac{2V(x, y)}{\|x - y\|_2^2}.$$