

$$\min_{x \in \mathbb{R}^d} \{f(x) = \frac{1}{n} \sum_{i=1}^n f_i(x)\}$$

$\uparrow$ ML-обучение $\nwarrow$ неограниченно
 на i объектах

Проблема:

$$\text{GD} \quad \nabla f(x^k) \quad \rightarrow \quad \text{SGD} \quad \nabla f_{i_k}(x^k)$$

$\uparrow$ выборка

Заметим, что


$$\text{GD: } x^{k+1} = x^k - \gamma \nabla f(x^k)$$

$x^k \rightarrow x^* \quad \nabla f(x^k) \rightarrow \nabla f(x^*) = 0$

типичная модель имеет много локальных экстремумов

$$\text{SGD: } x^{k+1} = x^k - \gamma \nabla f_{i_k}(x^k)$$

$x^k \rightarrow x^* \quad \nabla f_{i_k}(x^k) \rightarrow \nabla f_{i_k}(x^*) \neq 0$



$$\nabla f_{i_k}(x^*) \neq 0$$

$$x^1 = x^* - \gamma \nabla f_{i_k}(x^*)$$

$\nwarrow$ шаг в сторону

Типичная модель SGD сходится до оптимума и осциллирует

- Хотим не возмущать наст. решение градиента
- Хотим сделать не до оптим., а лучше

Идея:

$$x^{l+1} = x^k - \sigma g^k$$

← такое градиент (вернее)

$$x^k \rightarrow x^* \quad g^k \rightarrow \nabla f(x^*) = 0$$

- SAGA — сохранять старые градиенты

близкие $\{y_i^k\}_{i=1}^n$

← "память"
"сохранять старые градиенты"

Алгоритм 1 SAGA

Вход: размер шага $\gamma > 0$, стартовая точка $x^0 \in \mathbb{R}^d$, значения памяти $y_i^0 = 0$ для всех $i \in [n]$, количество итераций K

1: **for** $k = 0, 1, \dots, K-1$ **do**

2: Сгенерировать независимо i_k

3: Вычислить $g^k = \nabla f_{i_k}(x^k) - y_{i_k}^k + \frac{1}{n} \sum_{j=1}^n y_j^k$

← как в SGD

← запоминать вернее ∇f

4: Обновить $y_i^{k+1} = \begin{cases} \nabla f_i(x^k), & \text{если } i = i_k \\ y_i^k, & \text{иначе} \end{cases}$

5: $x^{k+1} = x^k - \gamma g^k$

6: **end for**

Выход: x^K

← хранить их-то про какой шаг пока i обнов.

1) Можно Show:

$$x^{l+1} = x^k - \gamma \cdot \frac{1}{n} \sum_{j=1}^n g_j^k$$

← можно Show
имеет
на градиенте

2) Здесь интерес

$$\mathbb{E}[g^k | x^k] \quad (\text{где SGD} \quad \mathbb{E}[\nabla f_{i_k}(x^k) | x^k] = \nabla f(x^k))$$

$$= \mathbb{E}\left[\nabla f_{i_k}(x^k) - y_{i_k}^k + \frac{1}{n} \sum_{j=1}^n y_j^k | x^k\right]$$

← симметрично от

$$\begin{aligned}
&= \sum_{i=1}^n \frac{1}{n} \cdot \left[\nabla f_i(x^k) - y_i^k + \frac{1}{n} \sum_{j=1}^n y_j^k \right] \\
&\quad \uparrow \\
&\quad \text{IP} \\
&= \frac{1}{n} \sum \nabla f_i(x^k) - \frac{1}{n} \sum y_i^k + \frac{1}{n} \sum y_i^k \\
&\quad \underbrace{\qquad\qquad\qquad}_{\nabla f(x^k)} \\
&= \nabla f(x^k)
\end{aligned}$$

Тогда получаем

$$\begin{aligned}
g^k &= \nabla f_{i_k}(x^k) - y_{i_k}^k + \frac{1}{n} \sum y_j^k \\
x^k \rightarrow x^* &\quad \rightarrow \nabla f_{i_k}(x^*) \rightarrow \nabla f_{i_k}(x^*) \rightarrow \frac{1}{n} \sum \nabla f_i(x^*) \rightarrow 0 \\
&\quad \underbrace{\qquad\qquad\qquad}_{\rightarrow \nabla f(x^*) \rightarrow 0}
\end{aligned}$$

Тогда: **если** $x^k \rightarrow x^*$, **то** $g^k \rightarrow \nabla f(x^*) = 0$

Уже: гарантированно сходимость $x^k \rightarrow x^*$
 $g^k \rightarrow \nabla f(x^*)$

Доказательство сходимости:

- f_i — L -выпуклы
- f — μ -сильно выпуклы

$$\begin{aligned}
\|x^{k+1} - x^*\|_2^2 &= \|x^k - \gamma g^k - x^*\|_2^2 \\
&= \|x^k - x^*\|_2^2 - 2\gamma \langle g^k, x^k - x^* \rangle \\
&\quad + \gamma^2 \|g^k - \nabla f(x^*)\|_2^2 \\
&\quad \quad \quad = 0
\end{aligned}$$

$$\mathbb{E}[|x^k|] \quad g^k \sim x^{k+1} - \text{c. b.}$$

$$\mathbb{E}[\|x^{k+1} - x^*\|_2^2 | x^k] = \|x^k - x^*\|_2^2 - 2\gamma \langle \underbrace{\mathbb{E}[g^k | x^k]}_{\nabla f(x^k)}; x^k - x^* \rangle + \gamma^2 \mathbb{E}[\|g^k - \nabla f(x^*)\|_2^2 | x^k]$$

$$\|g^k - \nabla f(x^*)\|_2^2 = \|\nabla f_{i_k}(x^k) - g_{i_k}^k + \frac{1}{n} \sum_j g_j^k - \nabla f(x^*)\|_2^2 \pm \nabla f_{i_k}(x^*) = \|\nabla f_{i_k}(x^k) - \nabla f_{i_k}(x^*) + \nabla f_{i_k}(x^*) - g_{i_k}^k + \frac{1}{n} \sum_j (g_j^k - \nabla f_j(x^*))\|_2^2$$

$$\begin{aligned} \text{K544} & \leq 2 \|\nabla f_{i_k}(x^k) - \nabla f_{i_k}(x^*)\|_2^2 \\ \|a+b\|_2^2 & \leq 2\|a\|_2^2 + 2\|b\|_2^2 \\ \mathbb{D}g & \leq \mathbb{E}g^2 \leq 2 \|\nabla f_{i_k}(x^k) - \nabla f_{i_k}(x^*)\|_2^2 + 2 \|\nabla f_{i_k}(x^*) - g_{i_k}^k\|_2^2 \end{aligned}$$

Trickman

$$\mathbb{E}[\|x^{k+1} - x^*\|_2^2 | x^k] = \|x^k - x^*\|_2^2 - 2\gamma \langle \nabla f(x^k); x^k - x^* \rangle + 2\mathbb{E}[\|\nabla f_{i_k}(x^k) - \nabla f_{i_k}(x^*)\|_2^2 | x^k] \cdot \gamma^2 + 2\mathbb{E}[\|\nabla f_{i_k}(x^*) - g_{i_k}^k\|_2^2 | x^k] \cdot \gamma^2$$

μ -convex f , L -smooth f_i

$$\mathbb{E}[\|x^{k+1} - x^*\|_2^2 | x^k] = \|x^k - x^*\|_2^2 - 2\gamma \left(\frac{\mu}{2} \|x^k - x^*\|_2^2 + f(x^k) - f(x^*) \right) + 2\gamma^2 \mathbb{E} \left[2L(f_{i_k}(x^k) - f_{i_k}(x^*)) - \langle \nabla f_{i_k}(x^k); x^k - x^* \rangle | x^k \right]$$

$$E[x^k] = E_{i_k}$$

$$E_{i_k}(f_{i_k}(x^k)) = f(x^k)$$

$$E[\|x^{k+1} - x^*\|_2^2 | x^k] = \|x^k - x^*\|_2^2 - 2\gamma \left(\frac{1}{2} \|x^k - x^*\|_2^2 + f(x^k) - f(x^*) \right) + 2\gamma^2 \cdot 2L(f(x^k) - f(x^*)) - \langle \nabla f(x^*), x^k - x^* \rangle + 2 \frac{1}{n} \sum_{i=1}^n \|\nabla f_i(x^*) - g_i^k\|_2^2 \cdot \gamma^2$$

Короче $g_i^k \rightarrow \nabla f_i(x^*)$

Требуются условия - постоянство var $\frac{1}{n} \sum_{i=1}^n \|\nabla f_i(x^*) - g_i^k\|_2^2$

$$E\left[\frac{1}{n} \sum_{i=1}^n \|g_i^{k+1} - \nabla f_i(x^*)\|_2^2 | x^k\right]$$

$$= \frac{1}{n} \sum E[\|g_i^{k+1} - \nabla f_i(x^*)\|_2^2 | x^k] = \frac{1}{n} \sum_{i=1}^n \left(\frac{1}{n} \|\nabla f_i(x^k) - \nabla f_i(x^*)\|_2^2 \right) + \left(1 - \frac{1}{n}\right) \|g_i^k - \nabla f_i(x^*)\|_2^2$$

$\uparrow$
 $P_{\{i=i_k\}}$

$$= \left(1 - \frac{1}{n}\right) \cdot \frac{1}{n} \sum_{i=1}^n \|g_i^k - \nabla f_i(x^*)\|_2^2$$

L -Lipschitz

$$+ \frac{2L}{n} (f(x^k) - f(x^*))$$

Умова:

$$1) E[\|x^{k+1} - x^*\|_2^2 | x^k] = (1 - \gamma\mu) \|x^k - x^*\|_2^2 \quad \text{mm. cx.} \\ - 2\gamma (f(x^k) - f(x^*)) \\ + 2\gamma^2 \cdot 2L (f(x^k) - f(x^*)) \\ + 2\gamma^2 H_{1k} \quad \text{т.е. слагаемое?}$$

слагаемое
с коэф.

$$2) E[H_{k+1} | x^k] \leq (1 - \frac{1}{n}) H_{1k} + \frac{2L}{n} (f(x^k) - f(x^*)) \quad \text{mm. cx.}$$

$$E[\|x^{k+1} - x^*\|_2^2 + M H_{k+1} | x^k] \\ \leq (1 - \gamma\mu) \|x^k - x^*\|_2^2 \quad (+) \\ + (M - \frac{M}{n} + 2\gamma^2) H_{1k} \quad (+) \\ - \gamma(2 - 4L\gamma - \frac{2L M}{\gamma n}) (f(x^k) - f(x^*)) \quad \geq 0$$

$$(1 - \gamma) M H_k$$

$$(1 - \frac{1}{n} + \frac{2\gamma^2}{n}) M H_k$$

$$(1 - \frac{1}{2n})$$

$$M = 4\gamma^2 n$$

$$\text{Получим: } 2 - 4L\gamma - \frac{2L \cdot 4\gamma^2 n}{n\gamma} = 2 - 4L\gamma - 8L\gamma$$

$$= 2 - 12L\gamma \geq 0 \Rightarrow \gamma \leq \frac{1}{6L}$$

$$\mathbb{E} [\|x^{(k+1)} - x^*\|_2^2 + MH_{k+1} | x^k] \\ \leq (1 - \gamma\mu) \|x^k - x^*\|_2^2 + \left(1 - \frac{1}{2n}\right) MH_k$$

$\mathbb{E}$

$$\mathbb{E} [\|x^{(k+1)} - x^*\|_2^2 + MH_{k+1}] \\ \leq \max \left\{ 1 - \gamma\mu, 1 - \frac{1}{2n} \right\} \mathbb{E} [\|x^k - x^*\|_2^2 + MH_k]$$

Итерации:

$$\mathbb{E} [\|x^k - x^*\|_2^2] \leq \mathbb{E} [\|x^k - x^*\|_2^2 + MH_k] \\ \leq \max \left\{ 1 - \gamma\mu, 1 - \frac{1}{2n} \right\}^k \cdot (\|x^0 - x^*\|_2^2 + MH_0)$$

Теорема сходимость SAGA

Пусть задача безусловной стохастической оптимизации вида конечной суммы с L -гладкими, выпуклыми функциями f_i и μ -сильно выпуклой целевой функцией f решается с помощью SAGA с $\gamma \leq \frac{1}{6L}$. Тогда справедлива следующая оценка сходимости

$$\mathbb{E} [V_k] \leq \max \left\{ (1 - \mu\gamma); \left(1 - \frac{1}{2n}\right) \right\}^k \mathbb{E} [V_0],$$

где $V_k = \|x^k - x^*\|_2^2 + 4n\gamma^2 \cdot \frac{1}{n} \sum_{i=1}^n \|y_i^k - \nabla f_i(x^*)\|_2^2$.

где GD since $\frac{1}{L}$

Итераций до ε : $\gamma = \frac{1}{6L}$

$$\left(n + \frac{L}{\mu}\right) \log \frac{1}{\varepsilon}$$

сложность итер = 1
сложность итер

GD: итераций

$$\frac{L}{\mu} \log \frac{1}{\varepsilon}$$

сложность итераций n

$$\frac{L}{\mu}$$

⊕ за счет специфичных записей ($\mathcal{F} = \frac{1}{n} \sum f_i$)
 SAGA имеет GD в н раз с точки
 зрения скорости
 имеет SGD - сходится быстрее
 ↳ меньше

⊖ точное решение не нужно - достаточно
 отработать

⊖ $O(nd)$ памяти

Аналог Seq $O(nd)$ памяти

Алгоритм 2 SVRG

Вход: размер шага $\gamma > 0$, стартовая точка $x^0 \in \mathbb{R}^d$, количество итераций в эпохе K , количество эпох S

```

1: for  $s = 0, 1, \dots, S-1$  do
2:   Обновить  $w^s = x^{s-1, K}$ 
3:   Посчитать и сохранить  $\nabla f(w^s)$ 
4:   for  $k = 0, 1, \dots, K-1$  do
5:      $x^{s, k+1} = x^{s, k} - \gamma g^k$ 
6:     Сгенерировать независимо  $i_k$ 
7:     Вычислить  $g^{k+1} = \nabla f_{i_k}(x^{s, k+1}) - \nabla f_{i_k}(w^s) + \nabla f(w^s)$ 
8:   end for
9: end for
  
```

$$x^k \rightarrow x^*$$

$$\nabla f_{i_k}(x^*) - \nabla f_{i_k}(x^*) + \nabla f(x^*) \rightarrow \nabla f(x^*) = 0$$

выб. i_k

Алгоритм 3 SARAH

Вход: размер шага $\gamma > 0$, стартовая точка $x^0 \in \mathbb{R}^d$, количество итераций в эпохе K , количество эпох S

```

1: for  $s = 0, 1, \dots, S-1$  do
2:   Посчитать  $g^0 = \nabla f(x^{s-1, K})$ 
3:   for  $k = 0, 1, \dots, K-1$  do
4:      $x^{s, k+1} = x^{s, k} - \gamma g^k$ 
5:     Сгенерировать независимо  $i_k$ 
6:     Вычислить  $g^{k+1} = \nabla f_{i_k}(x^{s, k+1}) - \nabla f_{i_k}(x^{s, k}) + g^k$ 
7:   end for
8: end for
  
```

$$\approx \nabla f(x^{s, k})$$

Выход: $x^{S-1, K}$

⊖ Легко считать новые значения

⊕ Нет нужн $O(nd)$

⊖ Точное решение за ML не нужно

④ Given var SAGA

$$\left(n + \frac{L}{\mu}\right) \log \frac{1}{\epsilon}$$

Comparison below:

var 1) Seq $O(nd)$

2) Seq variance reg. bound

3) $\left(n + \frac{L}{\mu}\right) \log \frac{1}{\epsilon}$