

Л14 Методы редукции дисперсии

В Параграфе Л5 мы рассмотрели стохастический градиентный спуск и увидели, что его точность ограничена дисперсией стохастических градиентов. Рассмотрим методы, которые уменьшают ее — *методы редукции дисперсии*. Они предназначены для решения задачи минимизации эмпирического риска:

$$\min_{x \in \mathbb{R}^d} \left[f(x) = \frac{1}{n} \sum_{i=1}^n f_i(x) \right].$$

Далее будем считать, что $\nabla f(x, \xi) = \nabla f_i(x)$, то есть выбор случайной реализации ξ эквивалентен выбору индекса i .

На практике при использовании стохастического градиентного спуска (Алгоритм Л5.1) с постоянным шагом γ на первых итерациях метод ведёт себя почти так же, как градиентный спуск (Алгоритм Л3.1), однако вокруг минимума он начинает осциллировать. В классическом градиентном спуске градиент стремится к нулю по мере приближения к решению, тогда как стохастический градиент, вообще говоря, не обязан обращаться в ноль в точке минимума. Рассмотрим пример, пусть в задаче машинного обучения x^* минимизирует потери по всей выборке, а $f(x, \xi)$ отражает потери только на отдельном сэмпле ξ . Хотя x^* оптимальна в среднем, но нет никаких гарантий, что x^* оптимальна для отдельного элемента выборки. Поэтому в общем случае $\nabla f(x^*, \xi) \neq 0$, и возникает осциллирующий эффект. Это приводит сразу к двум большим недостаткам стохастического градиентного спуска:

1. Метод не сходится к решению при константном γ , только лишь к его окрестности, размер которой зависит от дисперсии стохастических градиентов $\nabla f(x^*, \xi)$ и размера γ ;
2. Скорость сходимости метода даже с уменьшающимся шагом при оптимизации μ -сильно выпуклой целевой функции сублинейная [34].

Основная идея методов редукции дисперсии заключается в том, чтобы сконструировать аппроксимацию полного градиента g^k на каждой итерации так, чтобы при стремлении траектории метода к решению $x^k \rightarrow x^*$, эта аппроксимация стремилась к нулю $g^k \rightarrow \nabla f(x^*) = 0$. На каждой итерации такой метод производит шаг по g^k :

$$x^{k+1} = x^k - \gamma g^k.$$

Прежде чем перейти к конкретным примерам выбора g^k , отметим, что все g^k должны удовлетворять предположению несмещенности (Предположение Л5.1). Начнем обзор конкретных методов с подходов, использующих несмещенные аппроксиматоры.

Л14.1 SAGA

Идея алгоритма SAGA заключается в том, что на каждой итерации k , считая стохастический градиент по индексу i_k , он сохраняет его в y_{i_k} , а затем использует y_i для конструкции аппроксиматора полного градиента.

Алгоритм Л14.1 SAGA

Вход: стартовая точка $x^0 \in \mathbb{R}^d$, значения памяти $y_i^0 = 0$, размеры шагов $\{\gamma_k\}_{k=0} > 0$, количество итераций K

```

1: for  $k = 0, 1, \dots, K - 1$  do
2:   Сгенерировать независимо  $i_k \sim U(\overline{1, n})$ 
3:    $g^k = \nabla f_{i_k}(x^k) - y_{i_k}^k + \frac{1}{n} \sum_{i=1}^n y_i^k$ 
4:    $y_i^{k+1} = \begin{cases} \nabla f_i(x^k), & i = i_k \\ y_i^k, & i \neq i_k \end{cases}$ 
5:    $x^{k+1} = x^k - \gamma_k g^k$ 
6: end for

```

Выход: x^K

Отметим, что аппроксиматор g^k обладает свойством несмещенности. Действительно, ввиду равномерного и независимого сэмплирования индекса i_k , имеем

$$\mathbb{E} \left[g^k \mid x^k \right] = \frac{1}{n} \sum_{i=1}^n \nabla f_i(x^k) - \frac{1}{n} \sum_{i=1}^n y_i^k + \frac{1}{n} \sum_{i=1}^n y_i^k = \nabla f(x^k).$$

Перейдем к утверждению о сходимости метода SAGA.

Теорема Л14.1. Пусть задача безусловной стохастической оптимизации Л14 суммы с L -гладкими, выпуклыми функциями f_i и μ -сильно выпуклой целевой функцией f решается с помощью SAGA (Алгоритм Л14.1) с $\gamma_k = \gamma \leq \frac{1}{6L}$. Тогда справедлива следующая оценка сходимости

$$\mathbb{E} [V_k] \leq \max \left\{ (1 - \mu\gamma), \left(1 - \frac{1}{2n} \right) \right\}^k \mathbb{E} [V_0],$$

$$\text{где } V_k = \|x^k - x^*\|_2^2 + 4n\gamma^2 \cdot \frac{1}{n} \sum_{i=1}^n \|y_i^k - \nabla f_i(x^*)\|_2^2.$$

Более того, при оптимальном выборе шага для достижения точности ε необходимо

$$\mathcal{O} \left(\left[n + \frac{L}{\mu} \right] \log \frac{1}{\varepsilon} \right) \text{ итераций.}$$

Доказательство. Начнем с подстановки шага $x^{k+1} = x^k - \gamma g^k$ в квадрат нормы разности:

$$\|x^{k+1} - x^*\|_2^2 = \|x^k - x^*\|_2^2 - 2\gamma \langle g^k, x^k - x^* \rangle + \gamma^2 \|g^k - \nabla f(x^*)\|_2^2.$$

Возьмем условное математическое ожидание по случайности на итерации k :

$$\begin{aligned} \mathbb{E} \left[\|x^{k+1} - x^*\|_2^2 \mid x^k \right] &= \|x^k - x^*\|_2^2 - 2\gamma \left\langle \mathbb{E} [g^k \mid x^k], x^k - x^* \right\rangle \\ &\quad + \gamma^2 \mathbb{E} \left[\|g^k - \nabla f(x^*)\|_2^2 \mid x^k \right]. \end{aligned}$$

Рассмотрим слагаемое $\mathbb{E} [g^k \mid x^k]$:

$$\begin{aligned}\mathbb{E} [g^k \mid x^k] &= \mathbb{E} \left[\nabla f_{i_k}(x^k) - y_{i_k}^k + \frac{1}{n} \sum_{i=1}^n y_i^k \mid x^k \right] \\ &= \mathbb{E} \left[\nabla f_{i_k}(x^k) - y_{i_k}^k \mid x^k \right] + \frac{1}{n} \sum_{i=1}^n y_i^k \\ &= \frac{1}{n} \sum_{i=1}^n (\nabla f_i(x^k) - y_i^k) + \frac{1}{n} \sum_{i=1}^n y_i^k = \nabla f(x^k).\end{aligned}$$

Теперь рассмотрим $\mathbb{E} [\|g^k - \nabla f(x^*)\|_2^2 \mid x^k]$:

$$\begin{aligned}\mathbb{E} [\|g^k - \nabla f(x^*)\|_2^2 \mid x^k] &= \mathbb{E} \left[\left\| \nabla f_{i_k}(x^k) - y_{i_k}^k + \frac{1}{n} \sum_{i=1}^n y_i^k - \nabla f(x^*) \right\|_2^2 \mid x^k \right] \\ &= \mathbb{E} \left[\left\| \nabla f_{i_k}(x^k) - \nabla f_{i_k}(x^*) \right. \right. \\ &\quad \left. \left. + \nabla f_{i_k}(x^*) - y_{i_k}^k + \frac{1}{n} \sum_{i=1}^n y_i^k - \nabla f(x^*) \right\|_2^2 \mid x^k \right].\end{aligned}$$

Воспользуемся тем, что $\|a + b\|_2^2 \leq 2\|a\|_2^2 + 2\|b\|_2^2$:

$$\begin{aligned}\mathbb{E} [\|g^k - \nabla f(x^*)\|_2^2 \mid x^k] &\leq 2\mathbb{E} [\|\nabla f_{i_k}(x^k) - \nabla f_{i_k}(x^*)\|_2^2 \mid x^k] \\ &\quad + 2\mathbb{E} \left[\left\| \nabla f_{i_k}(x^*) - y_{i_k}^k + \frac{1}{n} \sum_{i=1}^n y_i^k - \nabla f(x^*) \right\|_2^2 \mid x^k \right].\end{aligned}$$

Заметим, что если во втором слагаемом взять ξ равным $\nabla f_{i_k}(x^*) - y_{i_k}^k$, то получим дисперсию $\mathbb{E} [\|\xi - \mathbb{E} [\xi \mid x^k]\|_2^2 \mid x^k]$. Воспользуемся тем, что $\mathbb{D}\xi \leq \mathbb{E} [\xi^2]$:

$$\begin{aligned}\mathbb{E} [\|g^k - \nabla f(x^*)\|_2^2 \mid x^k] &\leq 2\mathbb{E} [\|\nabla f_{i_k}(x^k) - \nabla f_{i_k}(x^*)\|_2^2 \mid x^k] \\ &\quad + 2\mathbb{E} [\|\nabla f_{i_k}(x^*) - y_{i_k}^k\|_2^2 \mid x^k].\end{aligned}$$

Раскроем математическое ожидание, пользуясь гладкостью и выпуклостью f_i (Теорема Л2.5):

$$\begin{aligned}\mathbb{E} [\|g^k - \nabla f(x^*)\|_2^2 \mid x^k] &\leq 4L \cdot \frac{1}{n} \sum_{i=1}^n (f_i(x^k) - f_i(x^*) - \langle \nabla f_i(x^*), x^k - x^* \rangle) \\ &\quad + 2 \cdot \frac{1}{n} \sum_{i=1}^n \|\nabla f_i(x^*) - y_i^k\|_2^2 \\ &= 4L(f(x^k) - f^*) + 2 \cdot \frac{1}{n} \sum_{i=1}^n \|\nabla f_i(x^*) - y_i^k\|_2^2.\end{aligned}$$

Собирая все вместе, получаем:

$$\begin{aligned} \mathbb{E} \left[\|x^{k+1} - x^*\|_2^2 \middle| x^k \right] &\leq \|x^k - x^*\|_2^2 - 2\gamma \langle \nabla f(x^k), x^k - x^* \rangle \\ &\quad + \gamma^2 \left(4L(f(x^k) - f^*) + 2 \cdot \frac{1}{n} \sum_{i=1}^n \|\nabla f_i(x^*) - y_i^k\|_2^2 \right). \end{aligned}$$

Воспользуемся μ -сильной выпуклостью функции f :

$$\begin{aligned} \mathbb{E} \left[\|x^{k+1} - x^*\|_2^2 \middle| x^k \right] &\leq (1 - \mu\gamma) \|x^k - x^*\|_2^2 - 2\gamma(1 - 2\gamma L)(f(x^k) - f^*) \\ &\quad + 2\gamma^2 \cdot \frac{1}{n} \sum_{i=1}^n \|\nabla f_i(x^*) - y_i^k\|_2^2. \end{aligned}$$

Пришли к тому, что если $y_i^k \rightarrow f_i(x^*)$, то есть линейная сходимости. Возьмем полное математическое ожидание:

$$\begin{aligned} \mathbb{E} \left[\|x^{k+1} - x^*\|_2^2 \right] &\leq (1 - \mu\gamma) \mathbb{E} \left[\|x^k - x^*\|_2^2 \right] - 2\gamma(1 - 2\gamma L) \mathbb{E} \left[f(x^k) - f^* \right] \\ &\quad + 2\gamma^2 \mathbb{E} \left[\frac{1}{n} \sum_{i=1}^n \|\nabla f_i(x^*) - y_i^k\|_2^2 \right]. \end{aligned}$$

Теперь рассмотрим, как ведет себя $\mathbb{E} \left[\frac{1}{n} \sum_{i=1}^n \|\nabla f_i(x^*) - y_i^k\|_2^2 \middle| x^k \right]$:

$$\begin{aligned} \mathbb{E} \left[\frac{1}{n} \sum_{i=1}^n \|y_i^{k+1} - \nabla f_i(x^*)\|_2^2 \middle| x^k \right] &= \left(1 - \frac{1}{n} \right) \cdot \frac{1}{n} \sum_{i=1}^n \|y_i^k - \nabla f_i(x^*)\|_2^2 \\ &\quad + \frac{1}{n} \cdot \frac{1}{n} \sum_{i=1}^n \|\nabla f_i(x^k) - \nabla f_i(x^*)\|_2^2. \end{aligned}$$

Воспользуемся выпуклостью и гладкостью f_i (Теорема Л2.5):

$$\begin{aligned} \mathbb{E} \left[\frac{1}{n} \sum_{i=1}^n \|y_i^{k+1} - \nabla f_i(x^*)\|_2^2 \middle| x^k \right] &\leq \left(1 - \frac{1}{n} \right) \cdot \frac{1}{n} \sum_{i=1}^n \|y_i^k - \nabla f_i(x^*)\|_2^2 \\ &\quad + \frac{2L}{n} (f(x^k) - f^*). \end{aligned}$$

Возьмем полное математическое ожидание:

$$\begin{aligned} \mathbb{E} \left[\frac{1}{n} \sum_{i=1}^n \|y_i^{k+1} - \nabla f_i(x^*)\|_2^2 \right] &\leq \left(1 - \frac{1}{n} \right) \mathbb{E} \left[\frac{1}{n} \sum_{i=1}^n \|y_i^k - \nabla f_i(x^*)\|_2^2 \right] \\ &\quad + \frac{2L}{n} \mathbb{E} \left[f(x^k) - f^* \right]. \end{aligned}$$

Получилось две «сходящиеся» последовательности, осталось их аккуратно «сшить». Возьмем $M > 0$ и сложим две рекурренты, которые получились выше:

$$\begin{aligned} &\mathbb{E} \left[\|x^{k+1} - x^*\|_2^2 + M\gamma^2 \cdot \frac{1}{n} \sum_{i=1}^n \|y_i^{k+1} - \nabla f_i(x^*)\|_2^2 \right] \\ &\leq (1 - \mu\gamma) \mathbb{E} \left[\|x^k - x^*\|_2^2 \right] + \left(1 + \frac{2}{M} - \frac{1}{n} \right) \mathbb{E} \left[\frac{M\gamma^2}{n} \sum_{i=1}^n \|y_i^k - \nabla f_i(x^*)\|_2^2 \right] \\ &\quad - 2\gamma \left(1 - 2\gamma L - \frac{\gamma ML}{n} \right) \mathbb{E} \left[f(x^k) - f^* \right]. \end{aligned}$$

Возьмем $M = 4n$:

$$\begin{aligned} & \mathbb{E} \left[\|x^{k+1} - x^*\|_2^2 + 4n\gamma^2 \cdot \frac{1}{n} \sum_{i=1}^n \|y_i^{k+1} - \nabla f_i(x^*)\|_2^2 \right] \\ & \leq (1 - \mu\gamma) \mathbb{E} [\|x^k - x^*\|_2^2] + \left(1 - \frac{1}{2n}\right) \mathbb{E} \left[4n\gamma^2 \cdot \frac{1}{n} \sum_{i=1}^n \|y_i^k - \nabla f_i(x^*)\|_2^2 \right] \\ & \quad - 2\gamma(1 - 6\gamma L) \mathbb{E} [f(x^k) - f^*]. \end{aligned}$$

Теперь потребуем $\gamma \leq \frac{1}{6L}$:

$$\begin{aligned} & \mathbb{E} \left[\|x^{k+1} - x^*\|_2^2 + 4n\gamma^2 \cdot \frac{1}{n} \sum_{i=1}^n \|y_i^{k+1} - \nabla f_i(x^*)\|_2^2 \right] \\ & \leq \max \left\{ (1 - \mu\gamma), \left(1 - \frac{1}{2n}\right) \right\} \mathbb{E} \left[\|x^k - x^*\|_2^2 + 4n\gamma^2 \cdot \frac{1}{n} \sum_{i=1}^n \|y_i^k - \nabla f_i(x^*)\|_2^2 \right]. \end{aligned}$$

■

Получили сходимость, но не по обычному критерию. Суть критерия в отражении физики как сходимости $x^k \rightarrow x^*$, так и $y_i^k \rightarrow \nabla f_i(x^*)$, что и закладывалось в метод.

Замечание Л14.1. Из сходимости по $\mathbb{E}[V_k]$ следует и сходимость по $\mathbb{E}[\|x^k - x^*\|_2^2]$.

Замечание Л14.2. Нельзя взять M огромным, так как M влияет на критерий сходимости, который также будет расти с ростом M . При этом сходимости лучше, чем $(1 - \frac{1}{n})$, не добиться.

Л14.2 SVRG

В предыдущем разделе мы рассмотрели метод SAGA, который воплощает основную идею редукции дисперсии. Однако, этот метод обладает существенным недостатком — он требует хранения матрицы размера $n \times d$, где d — размерность задачи, а n — количество функций в постановке конечной суммы. В тоже время, классический стохастический градиентный спуск тратит $\mathcal{O}(d)$ памяти, ведь хранит только текущее состояние оптимизируемых параметров модели. В этом разделе мы рассмотрим метод SVRG, который эффективно по памяти реализует идею редукции дисперсии. Основная идея этого метода заключается в том, чтобы уйти от запоминания стохастических градиентов по каждому индексу i . Вместо восстановления полного градиента с запозданием, как это делает SAGA, SVRG считает полный градиент раз в некоторое время. Такая точка называется *референсной*, а промежуток между подсчетами полного градиента — *эпохой*.

Алгоритм Л14.2 SVRG

Вход: стартовая точка $y^0 \in \mathbb{R}^d$, размеры шагов $\{\gamma_k\}_{k=0} > 0$, количество итераций в эпохе K , количество эпох T

```

1: for  $t = 0, 1, \dots, T - 1$  do
2:    $x^0 = y^t$ 
3:   for  $k = 0, 1, \dots, K - 1$  do
4:     Сгенерировать независимо  $i_k \sim U(1, n)$ 
5:      $g^k = \nabla f_{i_k}(x^k) - \nabla f_{i_k}(y^t) + \nabla f(y^t)$ 
6:      $x^{k+1} = x^k - \gamma_k g^k$ 
7:   end for
8:    $y^{t+1} = x^K$ 
9: end for
Выход:  $y^T$ 

```

Аппроксиматор в SVRG несмещенный:

$$\mathbb{E}[g^k | x^k] = \frac{1}{n} \sum_{i=1}^n \nabla f_i(x^k) - \frac{1}{n} \sum_{i=1}^n \nabla f_i(y^t) + \nabla f(y^t) = \nabla f(x^k).$$

Аналогично SAGA можно показать, что из того что $y^k \rightarrow x^*$, следует, что $g^k \rightarrow 0$. Итерационная сложность сходимости метода — $\mathcal{O}\left(n + \frac{L}{\mu}\right) \log \frac{1}{\varepsilon}$ совпадает с SAGA. Однако, необходимость вычислять полный градиент даже раз в эпоху, а также два стохастических градиента на каждой итерации требует дополнительных вычислительных мощностей.

Л14.3 SARAH

В предыдущем разделе мы рассмотрели метод редукции дисперсии SVRG, эффективный по памяти. При этом, SVRG не ухудшает теоретическую оценку сходимости SAGA. Однако на практике оказывается, что использование градиента в начальной точке эпохи дестабилизирует траекторию сходимости метода. Решая квадратичную задачу минимизации всего лишь с $d = 2$, $n = 5$, мы наблюдаем траекторию, как на Рисунке Л14.1.




Рис. Л14.1: Сравнение методов SVRG и SARAH на квадратичной функции.

По этой причине, был разработан метод SARAH, конструирующий аппроксиматор таким образом, чтобы использовать градиенты в недавних точках. Он использует идею рекурсивного накопления градиентов. Такая схема на каждой итерации добавляет к аппроксиматору направление градиента в новой точке, при этом вычитая старое направление. В то время как полный градиент в референсной точке из SVRG мешает сходиться к решению, добавляя вклад старого направления в текущий шаг, SARAH динамично подставляет траекторию под правильное направление к минимуму (Рисунок Л14.1).

Алгоритм Л14.3 SARAH

Вход: стартовая точка $y^0 \in \mathbb{R}^d$, размеры шагов $\{\gamma_k\}_{k=0} > 0$, количество итераций в эпохе K , количество эпох T

```

1: for  $t = 0, 1, \dots, T - 1$  do
2:    $x^0 = y^t$ 
3:    $g^{-1} = \nabla f(x^0)$ 
4:   for  $k = 0, 1, \dots, K - 1$  do
5:     Сгенерировать независимо  $i_k \sim U(\overline{1}, n)$ 
6:      $g^k = \nabla f_{i_k}(x^k) - \nabla f_{i_k}(x^{k-1}) + g^{k-1}$ 
7:      $x^{k+1} = x^k - \gamma_k g^k$ 
8:   end for
9:    $y^{t+1} = x^K$ 
10: end for
Выход:  $y^K$ 

```

Ввиду такой конструкции аппроксиматора, он является смещенным, что усложняет теоретический анализ. Однако SARAH все еще сохраняет идею редукции дисперсии: при $x^k \rightarrow x^*$ имеем, что $g^k \rightarrow 0$. SARAH, аналогично SVRG имеет итерационную сложность $\mathcal{O}\left(\left[n + \frac{L}{\mu}\right] \log \frac{1}{\varepsilon}\right)$, а также требует периодического вычисления полного градиента и подсчета двух стохастических градиентов на каждой итерации. Тем не менее, SARAH решает проблему с нестабильной траекторией сходимости.

Л14.4 Loopless версии алгоритмов

Отличительной чертой разобранных выше методов SVRG и SARAH является структура, состоящая из двух циклов. Такое построение алгоритма обладает двумя недостатками:

1. Фиксированная длина эпохи в классическом анализе SVRG имеет порядок $\frac{L}{\mu}$, что делает эпоху очень большой ввиду маленьких значений μ на практике;
2. При естественной длине эпохи порядка n метод не достигает скорости сходимости $\mathcal{O}\left(\left[n + \frac{L}{\mu}\right] \log \frac{1}{\varepsilon}\right)$.

По этим причинам были предложены методы редукции дисперсии, которые не используют фиксированную длину эпохи, а значит ограничиваются структурой с одним циклом. Такие модификации называются *loopless* версиями, и как правило используют случайность для решения сделать шаг по аппроксиматору или по полному градиенту:

$$x^{k+1} = x^k - \gamma_k \begin{cases} g^k, & \text{с вероятностью } p \\ \nabla f(x^k), & \text{с вероятностью } 1 - p \end{cases}.$$

Алгоритм Л14.4 L-SVRG (Loopless SVRG)

Вход: стартовая точка $x^0 = y^0 \in \mathbb{R}^d$, размеры шагов $\{\gamma_k\}_{k=0} > 0$, вероятность обновления $p \in (0, 1]$, количество итераций K

- 1: **for** $k = 0, 1, \dots, K - 1$ **do**
- 2: Сгенерировать независимо $i_k \sim U(\overline{1, n})$
- 3: $g^k = \nabla f_{i_k}(x^k) - \nabla f_{i_k}(y^k) + \nabla f(y^k)$
- 4: $x^{k+1} = x^k - \gamma_k g^k$
- 5: $y^{k+1} = \begin{cases} x^k, & \text{с вероятностью } p \\ y^k, & \text{с вероятностью } 1 - p \end{cases}$
- 6: **end for**

Выход: x^K

Алгоритм Л14.5 PAGE (Loopless SARAH)

Вход: стартовая точка $x^{-1} = x^0 \in \mathbb{R}^d$, стартовый аппроксиматор $g^{-1} = \nabla f(x^{-1})$, размеры шагов $\{\gamma_k\}_{k=0} > 0$, вероятность обновления $p \in (0, 1]$, количество итераций K

- 1: **for** $k = 0, 1, \dots, K - 1$ **do**
- 2: Сгенерировать независимо $i_k \sim U(\overline{1, n})$
- 3: $g^k = \begin{cases} \nabla f(x^k), & \text{с вероятностью } p \\ \nabla f_{i_k}(x^k) - \nabla f_{i_k}(x^{k-1}) + g^{k-1}, & \text{с вероятностью } 1 - p \end{cases}$
- 4: $x^{k+1} = x^k - \gamma_k g^k$
- 5: **end for**

Выход: x^T

Итерационная сложность алгоритмов равна $\mathcal{O}\left(\frac{1}{p} + n + \frac{L}{\mu} + \frac{Lpn}{\mu}\right)$. Таким образом можно выбрать вероятность подсчета полного градиента $p = \frac{1}{n}$, естественным образом связав ее с количеством функций из постановки, а не с числом обусловленности задачи. При этом, сложность сходимости остается $\mathcal{O}\left(n + \frac{L}{\mu}\right)$, как и в базовых версиях алгоритмов.

Л14.5 Унифицированный анализ методов редукции дисперсии

Ранее были изучены отдельные методы редукции дисперсии и их особенности. Однако все эти подходы можно рассматривать как частные случаи единого более общего метода. Такой взгляд позволяет описывать и анализировать различные стохастические алгоритмы редукции дисперсии в рамках одной унифицированной модели. Ниже мы сформулируем ключевое предположение, на котором основан этот подход. Схема обновления стохастических методов может быть обобщена следующим образом:

Алгоритм Л14.6 Общая схема стохастического градиентного спуска

Вход: начальная точка x^0 , число итераций K

- 1: **for** $k = 0, 1, \dots, K - 1$ **do**
- 2: Сгенерировать стохастическую переменную ξ^k
- 3: Вычислить стохастическую оценку градиента: $g^k = g^k(x^k, \xi^k, \text{history})$
- 4: Обновить точку: $x^{k+1} = x^k - \gamma_k g^k$
- 5: **end for**

Предположение Л14.1. Пусть $\{x^t\}$ — последовательность итераций Алгоритма Л14.6, а $\{\xi_t\}$ — случайные величины, порождаемые им. Предположим, что существуют неотрицательные константы A, B, C и параметры $\rho_1, \rho_2 \in (0, 1]$, а также (возможно случайная) последовательность $\{\sigma_t^2\}$, такие что для всех k выполняются неравенства:

$$\begin{aligned} \mathbb{E} \left[\|g^k - \nabla f(x^k)\|_2^2 \mid x^k \right] &\leq (1 - \rho_1) \|g^{k-1} - \nabla f(x^{k-1})\|_2^2 + A\sigma_{k-1}^2 \\ &\quad + BL^2 \|x^k - x^{k-1}\|_2^2, \\ \mathbb{E} \left[\sigma_k^2 \mid x^k \right] &\leq (1 - \rho_2) \sigma_{k-1}^2 + CL^2 \|x^k - x^{k-1}\|_2^2. \end{aligned}$$

Это предположение описывает, как ведёт себя ошибка стохастического аппроксиматора градиента при последовательных итерациях алгоритма. Параметры ρ_1 и ρ_2 определяют степень сжатия ошибок: чем они больше, тем быстрее различие между стохастической оценкой и истинным градиентом уменьшается при приближении к оптимуму. Константы A, B и C контролируют влияние стохастичности и длины шага на поведение метода. Таким образом, предположение Л14.1 задаёт общую схему, в рамках которой можно описывать как простейший стохастический градиентный спуск, так и более сложные методы с редукцией дисперсии, включая SAGA, SVRG, SARAH. Важно, что данное предположение не требует, чтобы g^k являлся несмещённой оценкой градиента. Кроме того, оно не предполагает использования больших батчей или строгих свойств задачи, что повышает общность получаемых результатов. После введения основного предположения, описывающего поведение стохастической ошибки градиентного оценщика, мы можем перейти к выводам, характеризующим сходимость рассматриваемых алгоритмов. Чтобы обосновать сделанные предположения, начнём с анализа невыпуклой и RL-задачи (условие Поляка–Лоясиевича).

Определение Л14.1. Непрерывно дифференцируемая функция $f : \mathbb{R}^d \rightarrow \mathbb{R}$ удовлетворяет условию Поляка–Лоясиевича с константой $\mu > 0$, если для всех $x \in \mathbb{R}^d$ выполнено

$$f(x) - f^* \leq \frac{1}{2\mu} \|\nabla f(x)\|_2^2.$$

В невыпуклом случае любой метод, описываемый Алгоритмом Л14.6, обладает сублинейной скоростью сходимости.

Утверждение Л14.1 (Лемма 2 из [18]). Пусть задача безусловной стохастической оптимизации Л14 суммы с L -гладкой целевой функцией f решается с помощью Алгоритма Л14.1. Тогда справедлива следующая оценка сходимости

$$\begin{aligned} f(x^{k+1}) &\leq f(x^k) - \frac{\gamma_k}{2} \|\nabla f(x^k)\|_2^2 + \left(\frac{L}{2} - \frac{1}{2\gamma_k} \right) \|x^{k+1} - x^k\|_2^2 \\ &\quad + \frac{\gamma_k}{2} \|g^k - \nabla f(x^k)\|_2^2. \end{aligned}$$

Теорема Л14.2. Пусть задача безусловной стохастической оптимизации Л14 с L -гладкой целевой функцией f решается с помощью Алгоритма Л14.6 с

$$\gamma_k = \gamma \leq \frac{1}{L} \left(1 + \sqrt{\frac{B\rho_2 + AC}{\rho_1\rho_2}} \right)^{-1}$$

в Предположении Л14.6. Тогда справедлива следующая оценка сходимости:

$$\frac{1}{K} \sum_{k=0}^{K-1} \mathbb{E} \left[\|\nabla f(x^k)\|_2^2 \right] \leq \frac{2V^0}{\gamma K},$$

где $V_0 = f(x^0) - f^* + \frac{\gamma}{2\rho_1} \|g^0 - \nabla f(x^0)\|_2^2 + \frac{\gamma A}{2\rho_1 \rho_2} \sigma_0^2$.

Доказательство. Запишем результат Утверждения Л14.1:

$$\begin{aligned} f(x^{k+1}) - f^* &\leq f(x^k) - f^* - \frac{\gamma}{2} \|\nabla f(x^k)\|_2^2 + \left(\frac{L}{2} - \frac{1}{2\gamma} \right) \|x^{k+1} - x^k\|_2^2 \\ &\quad + \frac{\gamma}{2} \|g^k - \nabla f(x^k)\|_2^2. \end{aligned}$$

Добавим $\frac{\gamma}{2\rho_1} \|g^{k+1} - \nabla f(x^{k+1})\|_2^2$, $\frac{\gamma A}{2\rho_1 \rho_2} \sigma_{k+1}^2$ к обоим частям и возьмем условное математическое ожидание:

$$\begin{aligned} \mathbb{E} [V_{k+1} \mid x^{k+1}] &\leq f(x^k) - f^* - \frac{\gamma}{2} \|\nabla f(x^k)\|_2^2 + \left(\frac{L}{2} - \frac{1}{2\gamma} \right) \|x^{k+1} - x^k\|_2^2 \\ &\quad + \frac{\gamma}{2} \|g^k - \nabla f(x^k)\|_2^2 \\ &\quad + \frac{\gamma}{2\rho_1} \mathbb{E} \left[\|g^{k+1} - \nabla f(x^{k+1})\|_2^2 \mid x^{k+1} \right] + \frac{\gamma A}{2\rho_1 \rho_2} \mathbb{E} [\sigma_{k+1}^2 \mid x^{k+1}]. \end{aligned}$$

Воспользуемся Предположением Л14.6:

$$\begin{aligned} \mathbb{E} [V_{k+1} \mid x^{k+1}] &\leq f(x^k) - f^* + \frac{\gamma}{2\rho_1} \|g^k - \nabla f(x^k)\|_2^2 + \frac{\gamma A}{2\rho_1 \rho_2} \sigma_k^2 - \frac{\gamma}{2} \|\nabla f(x^k)\|_2^2 \\ &\quad + \frac{1}{2\gamma} \left(\gamma L - 1 + \gamma^2 L^2 \frac{B\rho_2 + AC}{\rho_1 \rho_2} \right) \|x^{k+1} - x^k\|_2^2. \end{aligned}$$

Учтем, что $\gamma^2 L^2 \frac{B\rho_2 + AC}{\rho_1 \rho_2} + \gamma L \leq 1$ и возьмем полное математическое ожидание:

$$\mathbb{E} [V_{k+1}] \leq \mathbb{E} [V_k] - \frac{\gamma}{2} \mathbb{E} \left[\|\nabla f(x^k)\|_2^2 \right],$$

откуда получаем, что

$$\frac{1}{K} \sum_{k=0}^{K-1} \mathbb{E} \left[\|\nabla f(x^k)\|_2^2 \right] \leq \frac{2V^0}{\gamma K}.$$

■

Таким образом, даже без дополнительных условий на выпуклость функции, алгоритм демонстрирует уменьшение нормы градиента в среднем со скоростью $\mathcal{O}(\frac{1}{K})$, что соответствует классическому сублинейному поведению стохастических методов. Далее приведем теорему сходимости для функции, удовлетворяющей условию Поляка–Лоясиевича.

Теорема Л14.3. Пусть задача безусловной стохастической оптимизации Л14 с L -гладкой целевой функцией f , удовлетворяющей условию Поляка–Лоясиевича,

решается с помощью Алгоритма Л14.6 с

$$\gamma_k = \gamma \leq \min \left\{ \frac{1}{L} \left(1 + \sqrt{\frac{B\rho_2 + 2AC}{\rho_1\rho_2}} \right)^{-1}, \frac{\min\{\rho_1, \rho_2\}}{2\mu} \right\}$$

в Предположении Л14.6. Тогда справедлива следующая оценка сходимости:

$$\mathbb{E}[V_K] \leq (1 - \gamma\mu)^K V_0,$$

где $V_k = f(x^k) - f^* + \frac{\gamma}{\rho_1} \|g^k - \nabla f(x^k)\|_2^2 + \frac{2\gamma A}{\rho_1\rho_2} \sigma_k^2$.

Доказательство. Запишем результат Утверждения Л14.1:

$$\begin{aligned} f(x^{k+1}) - f^* &\leq f(x^k) - f^* - \frac{\gamma}{2} \|\nabla f(x^k)\|_2^2 + \left(\frac{L}{2} - \frac{1}{2\gamma} \right) \|x^{k+1} - x^k\|_2^2 \\ &\quad + \frac{\gamma}{2} \|g^k - \nabla f(x^k)\|_2^2. \end{aligned}$$

Добавим $\frac{\gamma}{\rho_1} \|g^{k+1} - \nabla f(x^{k+1})\|_2^2$, $\frac{2\gamma A}{\rho_1\rho_2} \sigma_{k+1}^2$ к обоим частям и возьмем условное математическое ожидание:

$$\begin{aligned} \mathbb{E}[V_{k+1} | x^k] &\leq f(x^k) - f^* - \frac{\gamma}{2} \|\nabla f(x^k)\|_2^2 + \left(\frac{L}{2} - \frac{1}{2\gamma} \right) \|x^{k+1} - x^k\|_2^2 \\ &\quad + \frac{\gamma}{2} \|g^k - \nabla f(x^k)\|_2^2 \\ &\quad + \frac{\gamma}{\rho_1} \mathbb{E}[\|g^{k+1} - \nabla f(x^{k+1})\|_2^2 | x^{k+1}] + \frac{2\gamma A}{\rho_1\rho_2} \mathbb{E}[\sigma_{k+1}^2 | x^{k+1}]. \end{aligned}$$

Воспользуемся Предположением Л14.6:

$$\begin{aligned} \mathbb{E}[V_{k+1} | x^{k+1}] &\leq f(x^k) - f^* - \frac{\gamma}{2} \|\nabla f(x^k)\|_2^2 \\ &\quad + \frac{\gamma}{\rho_1} \left(1 - \frac{\rho_1}{2} \right) \|g^k - \nabla f(x^k)\|_2^2 + \frac{2\gamma A}{\rho_1\rho_2} \left(1 - \frac{\rho_2}{2} \right) \sigma_k^2 \\ &\quad + \frac{1}{2\gamma} \left(\gamma L - 1 + 2\gamma^2 L^2 \frac{B\rho_2 + 2AC}{\rho_1\rho_2} \right) \|x^{k+1} - x^k\|_2^2. \end{aligned}$$

Воспользуемся условием Поляка–Лоясиевича:

$$\begin{aligned} \mathbb{E}[V_{k+1} | x^{k+1}] &\leq (1 - \gamma\mu)(f(x^k) - f^*) \\ &\quad + \frac{\gamma}{\rho_1} \left(1 - \frac{\rho_1}{2} \right) \|g^k - \nabla f(x^k)\|_2^2 + \frac{2\gamma A}{\rho_1\rho_2} \left(1 - \frac{\rho_2}{2} \right) \sigma_k^2 \\ &\quad + \frac{1}{2\gamma} \left(\gamma L - 1 + 2\gamma^2 L^2 \frac{B\rho_2 + 2AC}{\rho_1\rho_2} \right) \|x^{k+1} - x^k\|_2^2. \end{aligned}$$

Учтем, что $\gamma^2 L^2 \frac{B\rho_2 + 2AC}{\rho_1\rho_2} + \gamma L \leq 1$ и возьмем полное математическое ожидание:

$$\mathbb{E}[V_{k+1}] \leq (1 - \gamma\mu)(f(x^k) - f^*) + \frac{\gamma}{\rho_1} \left(1 - \frac{\rho_1}{2} \right) \|g^k - \nabla f(x^k)\|_2^2 + \frac{2\gamma A}{\rho_1\rho_2} \left(1 - \frac{\rho_2}{2} \right) \sigma_k^2,$$

Следовательно, если $\gamma \leq \frac{\min\{\rho_1, \rho_2\}}{2\mu}$, то

$$V_{k+1} \leq (1 - \gamma\mu)V_k \leq (1 - \gamma\mu)^{k+1} V_0.$$

■

Этот результат показывает, что при выполнении условия Поляка–Лоясиевича и разумном выборе шага γ методы редукции дисперсии достигают экспоненциального уменьшения функционального разрыва, объединяя тем самым свойства как стохастического градиентного спуска, так и его ускоренных вариантов. Далее докажем, что обобщаемые выше методы удовлетворяют Предположению Л14.1. Будем рассматривать батчированные версии и для начала остановимся на вспомогательном утверждении.

Утверждение Л14.2 (Лемма А.1 из [16]). Пусть $x_1, \dots, x_n \in \mathbb{R}^d$ — произвольные вектора с нулевой суммой:

$$\sum_{i=1}^n x_i = 0$$

и S размера b из $U(1, n)$. Тогда

$$\mathbb{E} \left[\left\| \frac{1}{b} \sum_{i \in S} x_i \right\|_2^2 \right] \leq \frac{1}{bn} \sum_{i=1}^n \|x_i\|_2^2.$$

Л14.5.1 SAGA

Сформулируем теорему, устанавливающую параметры Предположения Л14.1 для SAGA.

Теорема Л14.4. SAGA (Алгоритм Л14.1) удовлетворяет предположению Л14.1 с:

$$A = \frac{1}{b} \left(1 + \frac{b}{2n} \right), \quad B = \frac{1}{b} \left(1 + \frac{2n}{b} \right), \quad C = \frac{2n}{b},$$

$$\rho_1 = 1, \quad \rho_2 = \frac{b}{2n},$$

$$\sigma_k^2 = \frac{1}{n} \sum_{i=1}^n \|\nabla f_i(x^k) - y_i^{k+1}\|_2^2.$$

Доказательство. Ограничим разницу между аппроксиматором градиента и реальным градиентом:

$$\begin{aligned} \mathbb{E} \left[\|g^k - \nabla f(x^k)\|_2^2 \mid x^k \right] &= \mathbb{E} \left[\left\| \frac{1}{b} \sum_{i_k \in S} (\nabla f_{i_k}(x^k) - y_{i_k}^k) + \frac{1}{n} \sum_{i=1}^n y_i^k - \nabla f(x^k) \right\|_2^2 \mid x^k \right] \\ &= \mathbb{E} \left[\left\| \frac{1}{b} \sum_{i_k \in S} \left(\nabla f_{i_k}(x^k) - y_{i_k}^k - \frac{1}{n} \sum_{i=1}^n (\nabla f_i(x^k) - y_i^k) \right) \right\|_2^2 \mid x^k \right]. \end{aligned}$$

Воспользуемся Утверждением Л14.2:

$$\mathbb{E} \left[\|g^k - \nabla f(x^k)\|_2^2 \mid x^k \right] \leq \frac{1}{bn} \sum_{i=1}^n \left\| \nabla f_i(x^k) - y_i^k - \left(\frac{1}{n} \sum_{j=1}^n (\nabla f_j(x^k) - y_j^k) \right) \right\|_2^2$$

Если взять ξ равным $\nabla f_i(x^k) - y_i^k$, то получим дисперсию $\mathbb{E} \left[\|\xi - \mathbb{E}[\xi]\|_2^2 \right]$. Воспользуемся тем, что $\mathbb{D}\xi \leq \mathbb{E}[\xi^2]$:

$$\mathbb{E} \left[\|g^k - \nabla f(x^k)\|_2^2 \mid x^k \right] \leq \frac{1}{bn} \sum_{i=1}^n \|\nabla f_i(x^k) - y_i^k\|_2^2$$

Воспользуемся неравенством Юнга:

$$\begin{aligned} \mathbb{E} \left[\|g^k - \nabla f(x^k)\|_2^2 \mid x^k \right] &\leq \frac{1}{bn} \left(1 + \frac{2n}{b} \right) \sum_{i=1}^n \|\nabla f_i(x^k) - \nabla f_i(x^{k-1})\|_2^2 \\ &\quad + \frac{1}{bn} \left(1 + \frac{b}{2n} \right) \sum_{i=1}^n \|\nabla f_i(x^{k-1}) - y_i^k\|_2^2. \end{aligned}$$

Воспользуемся L -гладкостью:

$$\mathbb{E} \left[\|g^k - \nabla f(x^k)\|_2^2 \mid x^k \right] \leq \frac{1}{b} \left(1 + \frac{b}{2n} \right) \sigma_{k-1}^2 + \frac{1}{b} \left(1 + \frac{2n}{b} \right) \cdot L^2 \|x^k - x^{k-1}\|_2^2.$$

Теперь посмотрим на σ_k^2 :

$$\begin{aligned} \mathbb{E} \left[\sigma_k^2 \mid x^k \right] &= \mathbb{E} \left[\frac{1}{n} \sum_{i=1}^n \|\nabla f_i(x^k) - y_i^{k+1}\|_2^2 \mid x^k \right] = \left(1 - \frac{b}{n} \right) \frac{1}{n} \sum_{i=1}^n \|\nabla f_i(x^k) - y_i^k\|_2^2 \\ &= \left(1 - \frac{b}{n} \right) \frac{1}{n} \sum_{i=1}^n \|\nabla f_i(x^k) - \nabla f_i(x^{k-1}) + \nabla f_i(x^{k-1}) - y_i^{k-1}\|_2^2. \end{aligned}$$

Воспользуемся неравенством Юнга:

$$\begin{aligned} \mathbb{E} \left[\sigma_k^2 \mid x^k \right] &\leq \left(1 - \frac{b}{n} \right) \left(1 + \frac{b}{2n} \right) \frac{1}{n} \sum_{i=1}^n \|\nabla f_i(x^{k-1}) - y_i^{k-1}\|_2^2 \\ &\quad + \left(1 - \frac{b}{n} \right) \left(1 + \frac{2n}{b} \right) \|\nabla f_i(x^k) - \nabla f_i(x^{k-1})\|_2^2. \end{aligned}$$

Воспользуемся L -гладкостью:

$$\mathbb{E} \left[\sigma_k^2 \mid x^k \right] \leq \left(1 - \frac{b}{2n} \right) \sigma_{k-1}^2 + \frac{2n}{b} \cdot L^2 \|x^k - x^{k-1}\|_2^2.$$

■

Л14.5.2 L-SVRG

Сформулируем теорему, показывающую соответствие L-SVRG унифицированной схеме анализа.

Теорема Л14.5. L-SVRG (Алгоритм Л14.4) удовлетворяет Предположе-

нию Л14.1 с:

$$\begin{aligned} A &= \frac{2}{b}, \quad B = \frac{2}{b}, \quad C = 1 + \frac{2}{p}, \\ \rho_1 &= 1, \quad \rho_2 = \frac{p}{2}, \\ \sigma_k^2 &= \frac{1}{n} \sum_{i=1}^n \|\nabla f_i(y^{k+1}) - \nabla f_i(x^k)\|_2^2. \end{aligned}$$

Доказательство. Ограничим разницу между аппроксиматором градиента и реальным градиентом:

$$\begin{aligned} & \mathbb{E} \left[\|g^k - \nabla f(x^k)\|_2^2 \mid x^k \right] \\ &= \mathbb{E} \left[\left\| \frac{1}{b} \sum_{i_k \in S} (\nabla f_{i_k}(x^k) - \nabla f_{i_k}(y^k)) + \frac{1}{n} \sum_{i=1}^n \nabla f_i(y^k) - \nabla f(x^k) \right\|_2^2 \mid x^k \right] \\ &= \mathbb{E} \left[\left\| \frac{1}{b} \sum_{i_k \in S} \left(\nabla f_{i_k}(x^k) - \nabla f_{i_k}(y^k) - \frac{1}{n} \sum_{i=1}^n (\nabla f_i(x^k) - \nabla f_i(y^k)) \right) \right\|_2^2 \mid x^k \right]. \end{aligned}$$

Воспользуемся Утверждением Л14.2:

$$\mathbb{E} \left[\|g^k - \nabla f(x^k)\|_2^2 \mid x^k \right] \leq \frac{1}{bn} \sum_{i=1}^n \left\| \nabla f_i(x^k) - \nabla f_i(y^k) - \left(\frac{1}{n} \sum_{j=1}^n (\nabla f_j(x^k) - \nabla f_j(y^k)) \right) \right\|_2^2$$

Если взять ξ равным $\nabla f_i(x^k) - \nabla f_i(y^k)$, то получим дисперсию $\mathbb{E} \left[\|\xi - \mathbb{E}[\xi]\|_2^2 \right]$. Воспользуемся тем, что $\mathbb{D}\xi \leq \mathbb{E}[\xi^2]$:

$$\mathbb{E} \left[\|g^k - \nabla f(x^k)\|_2^2 \mid x^k \right] \leq \frac{1}{bn} \sum_{i=1}^n \|\nabla f_i(x^k) - \nabla f_i(y^k)\|_2^2.$$

Продолжим преобразования:

$$\mathbb{E} \left[\|g^k - \nabla f(x^k)\|_2^2 \mid x^k \right] \leq \frac{2}{bn} \sum_{i=1}^n \|\nabla f_i(y^k) - \nabla f_i(x^{k-1})\|_2^2 + \frac{2}{bn} \sum_{i=1}^n \|f_i(x^k) - f_i(x^{k-1})\|_2^2.$$

Воспользуемся L -гладкостью:

$$\mathbb{E} \left[\|g^k - \nabla f(x^k)\|_2^2 \mid x^k \right] \leq \frac{2}{b} \sigma_{k-1}^2 + \frac{2}{b} \cdot L^2 \|x^k - x^{k-1}\|_2^2.$$

Теперь посмотрим на σ_k^2 :

$$\begin{aligned} \mathbb{E} \left[\sigma_k^2 \mid x^k \right] &= \mathbb{E} \left[\frac{1}{n} \sum_{i=1}^n \|\nabla f_i(y^{k+1}) - \nabla f_i(x^k)\|_2^2 \mid x^k \right] \\ &= (1-p) \frac{1}{n} \sum_{i=1}^n \|\nabla f_i(y^k) - \nabla f_i(x^k)\|_2^2. \end{aligned}$$

Воспользуемся неравенством Юнга:

$$\begin{aligned}
\mathbb{E} \left[\sigma_k^2 \mid x^k \right] &\leq (1-p) \left(1 + \frac{p}{2} \right) \frac{1}{n} \sum_{i=1}^n \left\| \nabla f_i(y^k) - \nabla f_i(x^{k-1}) \right\|_2^2 \\
&\quad + (1-p) \left(1 + \frac{2}{p} \right) \frac{1}{n} \sum_{i=1}^n \left\| \nabla f_i(x^k) - \nabla f_i(x^{k-1}) \right\|_2^2 \\
&\leq \left(1 - \frac{p}{2} \right) \frac{1}{n} \sum_{i=1}^n \left\| \nabla f_i(y^k) - \nabla f_i(x^{k-1}) \right\|_2^2 \\
&\quad + \left(1 + \frac{2}{p} \right) \frac{1}{n} \sum_{i=1}^n \left\| \nabla f_i(x^k) - \nabla f_i(x^{k-1}) \right\|_2^2.
\end{aligned}$$

Воспользуемся L -гладкостью:

$$\mathbb{E} \left[\sigma_k^2 \mid x^k \right] \leq \left(1 - \frac{p}{2} \right) \sigma_{k-1}^2 + \left(1 + \frac{2}{p} \right) \cdot L^2 \|x^k - x^{k-1}\|_2^2.$$

■

Л14.5.3 PAGE

Сформулируем теорему для PAGE. Примечательно, что в отличие от SAGA и L-SVRG, здесь $\sigma_k^2 = 0$, что радикально упрощает потенциальную функцию и структуру доказательства сходимости.

Теорема Л14.6. PAGE (Алгоритм Л14.5) удовлетворяет Предположению Л14.1 с:

$$\begin{aligned}
A &= 0, \quad B = \frac{1-p}{b}, \quad C = 0, \\
\rho_1 &= p, \quad \rho_2 = 1, \\
\sigma_k^2 &= 0.
\end{aligned}$$

Доказательство. Воспользуемся Леммой 3 из [18]:

$$\mathbb{E} \left[\left\| \nabla f(x^k) - g^k \right\|_2^2 \mid x^k \right] \leq (1-p) \left\| \nabla f(x^{k-1}) - g^{k-1} \right\|_2^2 + \frac{1-p}{b} \cdot L^2 \|x^k - x^{k-1}\|_2^2.$$

■

Л15 Методы нулевого порядка и координатный спуск

В этом параграфе рассматриваются методы, направленные на снижение вычислительной стоимости одной итерации градиентного спуска. Сначала обсуждаются координатные методы, далее показывается, что та же идея может быть использована, когда градиент недоступен (zero-order оптимизация). Рассмотрим задачу безусловной оптимизации

$$\min_{x \in \mathbb{R}^d} f(x). \quad (\text{Л15.1})$$

Л15.1 Координатный спуск

Координатные методы — это алгоритмы оптимизации, где на каждой итерации обновляется лишь одна (или несколько) координат вектора параметров, при этом остальные фиксируются. Приведем мотивационный пример с линейной регрессией.

Пример Л15.1. Рассмотрим квадратичную задачу

$$\min_{x \in \mathbb{R}^d} f(x) := \frac{1}{2} \|Ax - b\|_2^2 = \frac{1}{2} \sum_{i=1}^n (A_{i,:}x - b_i)^2 = \frac{1}{2} \sum_{j=1}^d \langle A_{:,j}, Ax - b \rangle x_j - \frac{1}{2} \langle b, Ax - b \rangle.$$

где $A \in \mathbb{R}^{n \times d}$ — матрица объект-признак, $A_{i,:}$ — i -ая строка матрицы A , $A_{:,j}$ — j -ый столбец матрицы A , $b \in \mathbb{R}^n$ — метки. Полный градиент в этой задаче имеет вид

$$\nabla f(x) = A^\top (Ax - b) = \sum_{i=1}^n A_{i,:}^\top (A_{i,:}x - b_i) = \sum_{j=1}^d \langle A_{:,j}, Ax - b \rangle e_j, \quad (\text{Л15.2})$$

где e_j — j -ый базисный вектор. Рассмотрим два классических подхода к удешевлению стоимости одной итерации вычисления градиентного шага.

1. Стохастический выбор строки (стохастический градиентный спуск по объектам).

На итерации k равномерно выбираем объект $i_k = \overline{1, n}$ и формируем оценку градиента как одно слагаемое из суммы (Л15.2):

$$g^k = n A_{i_k,:}^\top (A_{i_k,:}x^k - b_{i_k}), \\ x^{k+1} = x^k - \gamma_k g^k.$$

Этот шаг использует только одну строку матрицы A , множитель n нужен для несмещенности: $\mathbb{E}[g^k] = \nabla f(x^k)$. Стоимость одной итерации в n раз дешевле, чем полный градиент, так как выбирается 1 объект из суммы с n слагаемыми.

2. Стохастический выбор столбца (координатный шаг).

На итерации k равномерно выбираем координату градиента $j_k = \overline{1, d}$ и формируем оценку градиента как одну координату из вектора (Л15.2):

$$g^k = d \langle Ax^k - b, A_{:,j_k} \rangle e_{j_k}, \\ x^{k+1} = x^k - \gamma_k g^k.$$

Этот шаг использует только один столбец матрицы A . Множитель d нужен для несмещенности: $\mathbb{E}[g^k] = \nabla f(x^k)$. Стоимость одной итерации в d раз дешевле, чем полный градиент, так как делается 1 скалярное произведение вместо d .

Таким образом в квадратичной задаче две симметричные экономии достигаются выбором строк или столбцов, что соответствует домножению каждую итерацию на одну случайную строку или столбец матрицы A соответственно.

В этом параграфе мы сосредоточимся на втором подходе, со стохастическими методами можно ознакомиться в Параграфах Л15 и Л14. Перейдём к формальному описанию алгоритма координатного спуска, в котором вместо полного градиента оценивается и используется одна его координата.

Алгоритм Л15.1 Координатный спуск

Вход: стартовая точка $x^0 \in \mathbb{R}^d$, размеры шагов $\{\gamma_k\}_{k=0} > 0$, количество итераций K

- 1: **for** $k = 0, 1, \dots, K - 1$ **do**
 - 2: Сгенерировать независимую $i_k \sim U(\overline{1, n})$
 - 3: $x^{k+1} = x^k - \gamma_k d[\nabla f(x^k)]_{i_k} e_{i_k}$
 - 4: **end for**
- Выход:** x^K
-

Заметим, что при равномерном выборе координаты стохастический градиент обладает двумя ключевыми свойствами — он остаётся несмещённой оценкой полного градиента и имеет контролируруемую дисперсию.

Утверждение Л15.1. Пусть индекс $i_k = \overline{1, d}$ выбирается независимо и равномерно на каждой итерации. Тогда для любой точки $x \in \mathbb{R}^d$ выполняются равенства:

$$\mathbb{E} [d[\nabla f(x)]_{i_k} e_{i_k}] = \nabla f(x), \quad \mathbb{E} [\|d[\nabla f(x)]_{i_k} e_{i_k}\|_2^2] = d \|\nabla f(x)\|_2^2.$$

Доказательство. Покажем первое равенство:

$$\mathbb{E} [d[\nabla f(x)]_{i_k} e_{i_k}] = \sum_{i=1}^d \frac{1}{d} d[\nabla f(x)]_i e_i = \nabla f(x).$$

Покажем второе равенство:

$$\mathbb{E} [\|d[\nabla f(x)]_{i_k} e_{i_k}\|_2^2] = \sum_{i=1}^d \frac{1}{d} d^2 [\nabla f(x)]_i^2 \|e_i\|_2^2 = d \|\nabla f(x)\|_2^2.$$

■

Утверждение Л15.1 показывает, что стохастическая координатная оценка градиента $d[\nabla f(x)]_{i_k} e_{i_k}$ несмещена, однако её разброс не является константой: дисперсия масштабируется величиной $\|\nabla f(x)\|_2^2$. Интуитивная причина проста: мы наблюдаем только одну координату из d и затем восстанавливаем масштаб умножением на d . Опираясь на Утверждение Л15.1, которое гарантирует несмещённость и контролируруемую дисперсию стохастической оценки градиента, зафиксируем величину шага и выведем оценку скорости сходимости алгоритма Л15.1.

Теорема Л15.1. Пусть задача безусловной оптимизации (Л15.1) с L -гладкой μ -сильно выпуклой целевой функцией f решается с помощью координатного спус-

ка (Алгоритм Л15.1). Тогда при $\gamma_k = \gamma \leq \frac{1}{dL}$ справедлива следующая оценка сходимости:

$$\mathbb{E} \left[\|x^k - x^*\|_2^2 \right] \leq (1 - \mu\gamma)^k \|x^0 - x^*\|_2^2.$$

Доказательство. По определению итерации:

$$\|x^{k+1} - x^*\|_2^2 = \|x^k - x^*\|_2^2 - 2\gamma \langle d[\nabla f(x^k)]_{i_k} e_{i_k}, x^k - x^* \rangle + \gamma^2 \|d[\nabla f(x^k)]_{i_k} e_{i_k}\|_2^2.$$

Возьмем условное ожидание по случайности на шаге k :

$$\begin{aligned} \mathbb{E} \left[\|x^{k+1} - x^*\|_2^2 \mid x^k \right] &= \|x^k - x^*\|_2^2 - 2\gamma \left\langle \mathbb{E} \left[d[\nabla f(x^k)]_{i_k} e_{i_k} \mid x^k \right], x^k - x^* \right\rangle \\ &\quad + \gamma^2 \mathbb{E} \left[\|d[\nabla f(x^k)]_{i_k} e_{i_k}\|_2^2 \mid x^k \right]. \end{aligned}$$

Применим Утверждение Л15.1:

$$\mathbb{E} \left[\|x^{k+1} - x^*\|_2^2 \mid x^k \right] \leq \|x^k - x^*\|_2^2 - 2\gamma \langle \nabla f(x^k), x^k - x^* \rangle + d\gamma^2 \|\nabla f(x^k)\|_2^2.$$

Воспользуемся μ -сильной выпуклостью и L -гладкостью:

$$\mathbb{E} \left[\|x^{k+1} - x^*\|_2^2 \mid x^k \right] \leq (1 - \mu\gamma) \|x^k - x^*\|_2^2 - 2\gamma(1 - d\gamma L)(f(x^k) - f^*).$$

При $\gamma \leq \frac{1}{dL}$ последнее слагаемое отрицательно, и остаётся

$$\mathbb{E} \left[\|x^{k+1} - x^*\|_2^2 \mid x^k \right] \leq (1 - \mu\gamma) \|x^k - x^*\|_2^2.$$

Возьмем полное математическое ожидание и раскроем рекурсию:

$$\mathbb{E} \left[\|x^k - x^*\|_2^2 \right] \leq (1 - \mu\gamma)^k \|x^0 - x^*\|_2^2.$$

■

Одна координатная итерация примерно в d раз дешевле шага полного градиентного спуска, но обычно требуется порядка в d раз больше итераций. В чистом виде это не улучшает асимптотику, однако на практике координатные методы часто выигрывают по времени до заданной точности за счёт разреженности данных и дешёвых локальных операций по столбцам, неравномерного выбора координат с вероятностями, пропорциональными координатным константам Липшица, а также блочно-координатных, параллельных и асинхронных обновлений, эффективно использующих современную вычислительную архитектуру. В неквадратичных задачах вычислить одну координату градиента не всегда дешевле, чем полный градиент. Чтобы получить $[\nabla f(x)]_i$, нередко требуется выполнить почти всю вычислительную цепочку и лишь затем извлечь i -ую компоненту. Поэтому координатный шаг не всегда экономит ресурсы. Характерный неблагоприятный пример — логистическая регрессия: градиент есть сумма по всем объектам, и для любой координаты нужен полный проход по данным. Фактически стоимость одной координаты совпадает со стоимостью полного градиента. В то же время при обучении нейронных сетей ситуация благоприятнее из-за структуры обратного распространения ошибки: градиенты считаются от последнего слоя к первому, и, если обновлять только слой i , можно не вычислять градиенты для слоёв $1, \dots, i-1$. Это уменьшает объём обратных вычислений и снижает пиковые требования к памяти, что даёт реальное ускорение и экономию ресурсов при координатных или

блочно-координатных обновлениях по слоям. Когда прямой градиент недоступен или слишком дорог, координатная логика получает «вторую жизнь», переходя к оценкам направленных производных по случайным направлениям, мы естественно приходим к методам нулевого порядка (ZO), где двухточечные разности выступают оценками градиента.

Л15.2 Координатные идеи в безградиентной постановке

В оптимизации нулевого порядка алгоритм взаимодействует с целевой функцией через её значение. Отсутствие доступа к градиенту вынуждает заменять его на аппроксимацию по значениям функции, что естественным образом сочетается с координатными идеями — можно оценивать лишь нужные координатные направления и выполнять дешёвые обновления. Ключевой приём — аппроксимация направленной производной по значениям функции вдоль направления $e \in \mathbb{R}^d$. Рассмотрим три стандартные схемы.

$$g(x, e) = \begin{cases} d \frac{f(x+\tau e) - f(x-\tau e)}{2\tau} e & \text{(двухточечная симметричная)} \\ \frac{f(x+\tau e) - f(x)}{\tau} e & \text{(двухточечная односторонняя)} \\ \frac{f(x+\tau e)}{\tau} e & \text{(одноточечная),} \end{cases} \quad (\text{Л15.3})$$

где $\tau > 0$ — параметр сглаживания. Двухточечная симметричная схема имеет наименьшее смещение. Двухточечная Односторонняя схема используется, когда $f(x)$ уже было посчитано. Одноточечная схема наиболее дешёвая по вычислениям, но обладает большим смещением. Множитель d в (Л15.3) появляется по той же причине, что и в координатных методах: усреднение по случайно выбранному направлению «размывает» вклад по d осям, и чтобы восстановить исходный масштаб градиента, требуется умножение на d . Перейдём к самой интересной части формулы (Л15.3) — выбору направления e , по которому мы будем оптимизировать целевую функцию. Координатный базис $e = e_i$ воспроизводит по координатный шаг, но охватывает лишь одну компоненту за вызов оракула. Лучше сразу смотреть на все координаты через случайные направления. Самый простой вариант — брать $e \sim \mathcal{N}(0, I_d)$ — такая выборка случайно смешивает все координаты в каждом направлении и в среднем захватывает всю структуру. Ещё лучше выбирать e равномерно на сфере $S^{d-1} := \{e \in \mathbb{R}^d \mid \|e\|_2 = 1\}$: все направления имеют одинаковую норму, что стабилизирует шаги и улучшает оценки, при этом мы так же охватываем все координаты.

У читателя мог возникнуть вопрос: почему в (Л15.3) не устремить $\tau \rightarrow 0$ и не получить градиент по определению? В оптимизации нулевого порядка это невозможно из-за доминирующей роли ошибок оракула: на запрос точки возвращается не истинное значение, а зашумлённая величина $\hat{f}$. В оптимизации первого порядка шум также присутствует, однако его влияние обычно существенно слабее, поскольку градиент сглаживает часть вариативности. Исходя из этих соображений, в формуле (Л15.3) следует везде заменить f на $\hat{f}$. Для двухточечной симметричной оценки:

$$g(x, e) = d \frac{\hat{f}(x + \tau e) - \hat{f}(x - \tau e)}{2\tau} e.$$

Л15.2.1 Гладкий μ -сильно выпуклый случай

Подобно координатной оценке первого порядка, двухточечная схема $g(x, e)$ служит стохастической заменой градиента. Ниже формализуем её несмещённость, характер погрешности, а также оценку второго момента.

Утверждение Л15.2. Пусть дана L -гладкая функция $f : \mathbb{R}^d \rightarrow \mathbb{R}$ и пусть

$\hat{f}(x) = f(x) + \xi(x)$, где $|\xi(x)| \leq \Delta$ для всех $x \in \mathbb{R}^d$. Определим оценку градиента

$$g(x, e) = d \frac{\hat{f}(x + \tau e) - \hat{f}(x - \tau e)}{2\tau} e, \quad e \sim U(S^{d-1}).$$

Тогда для любого $x \in \mathbb{R}^d$ справедливы оценки:

1. $\|\mathbb{E}_{e \sim U(S^{d-1})}[g(x, e)] - \nabla f(x)\|_2 \leq L\tau + \frac{d\Delta}{\tau},$
2. $\mathbb{E}_{e \sim U(S^{d-1})}\|g(x, e)\|_2^2 = 4d\|\nabla f(x)\|_2^2 + 4L^2d^2\tau^2 + 2\frac{d^2\Delta^2}{\tau^2}.$

Доказательство. Разложим оценку на две части $g(x, e) = g^{\det} + g^{\text{noise}}$:

$$g^{\det} = d \frac{f(x + \tau e) - f(x - \tau e)}{2\tau} e, \quad g^{\text{noise}} = d \frac{\xi(x + \tau e) - \xi(x - \tau e)}{2\tau} e.$$

1. Для шумовой составляющей имеем:

$$\|\mathbb{E}[g^{\text{noise}}]\|_2 = \frac{d}{2\tau} \|\mathbb{E}[(\xi(x + \tau e) - \xi(x - \tau e))e]\|_2 \leq \frac{d}{2\tau} \cdot 2\Delta \cdot \mathbb{E}[\|e\|_2] = \frac{d\Delta}{\tau}.$$

Рассмотрим детерминированную часть, представим симметричную разность в форме интеграла:

$$g^{\det} = d \frac{f(x + \tau e) - f(x - \tau e)}{2\tau} e = de \int_{-1}^1 \frac{1}{2} \langle \nabla f(x + t\tau e), e \rangle dt.$$

Перейдём к математическому ожиданию по равномерному e , воспользуемся тем, что $\mathbb{E}[ee^\top] = \frac{1}{d}I_d$:

$$\mathbb{E}[g^{\det}] = d\mathbb{E}\left[\frac{f(x + \tau e) - f(x - \tau e)}{2\tau} e\right] = \mathbb{E}[\nabla f(x + t\tau e)].$$

Тогда имеем:

$$\begin{aligned} \|\mathbb{E}[g^{\det}] - \nabla f(x)\|_2 &= \|\mathbb{E}[\nabla f(x + t\tau e)] - \mathbb{E}[\nabla f(x)]\|_2 \\ &= \|\mathbb{E}[\nabla f(x + t\tau e) - \nabla f(x)]\|_2 \\ &\leq \mathbb{E}[\|\nabla f(x + t\tau e) - \nabla f(x)\|_2] \\ &\leq L\tau\|e\|_2 = L\tau. \end{aligned}$$

Воспользуемся неравенством треугольника:

$$\|\mathbb{E}[g(x, e)] - \nabla f(x)\|_2 \leq \|\mathbb{E}[g^{\det}] - \nabla f(x)\|_2 + \|\mathbb{E}[g^{\text{noise}}]\|_2 \leq L\tau + \frac{d\Delta}{\tau}.$$

2. Для шумовой составляющей имеем:

$$\mathbb{E}[\|g^{\text{noise}}\|_2^2] = \frac{d^2}{4\tau^2} \mathbb{E}[\|(\xi(x + \tau e) - \xi(x - \tau e))e\|_2^2] \leq \frac{d^2}{4\tau^2} \cdot 4\Delta^2 \cdot \mathbb{E}[\|e\|_2^2] = \frac{d^2\Delta^2}{\tau^2}.$$

Посмотрим на детерминированную часть, добавим умный ноль $\pm \langle \nabla f(x), e \rangle e$:

$$\mathbb{E} \left[\|g^{\text{det}}(x, e)\|_2^2 \right] = d^2 \mathbb{E} \left[\left\| \frac{f(x + \tau e) - f(x - \tau e)}{2\tau} e + \langle \nabla f(x), e \rangle e - \langle \nabla f(x), e \rangle e \right\|_2^2 \right].$$

Воспользуемся тем, что $\|a + b\|_2^2 \leq 2\|a\|_2^2 + 2\|b\|_2^2$:

$$\begin{aligned} \mathbb{E} \left[\|g^{\text{det}}(x, e)\|_2^2 \right] &\leq 2d^2 \mathbb{E} \left[|\langle \nabla f(x), e \rangle|^2 \right] \\ &\quad + \frac{d^2}{2\tau^2} \mathbb{E} \left[|f(x + \tau e) - f(x - \tau e) - \langle \nabla f(x), 2\tau e \rangle|^2 \right]. \end{aligned}$$

Воспользуемся изотропией равномерного направления на сфере и Теоремой Л2.4:

$$\mathbb{E} \left[\|g^{\text{det}}(x, e)\|_2^2 \right] \leq 2d \|\nabla f(x)\|_2^2 + 2L^2 d^2 \tau^2.$$

Получим итоговую оценку:

$$\begin{aligned} \mathbb{E} \left[\|g(x, e)\|_2^2 \right] &= \mathbb{E} \left[\|g^{\text{det}} + g^{\text{noise}}\|_2^2 \right] \leq 2\mathbb{E} \left[\|g^{\text{det}}\|_2^2 \right] + 2\mathbb{E} \left[\|g^{\text{noise}}\|_2^2 \right] \\ &\leq 4d \|\nabla f(x)\|_2^2 + 4L^2 d^2 \tau^2 + 2 \frac{d^2 \Delta^2}{\tau^2}. \end{aligned}$$

■

Используя двухточечную оценку градиента из Утверждения Л15.2, построим базовый стохастический метод нулевого порядка.

Алгоритм Л15.2 ZO-GD с двухточечной оценкой

Вход: стартовая точка $x^0 \in \mathbb{R}^d$, размеры шагов $\{\gamma_k\}_{k=0} > 0$, параметр сглаживания $\tau > 0$, количество итераций K

- 1: **for** $k = 0, 1, \dots, K - 1$ **do**
- 2: Сгенерировать независимо $e_k \sim U(S^{d-1})$
- 3: $g^k = d \frac{\hat{f}(x^k + \tau e_k) - \hat{f}(x^k - \tau e_k)}{2\tau} e_k$
- 4: $x^{k+1} = x^k - \gamma_k g^k$
- 5: **end for**

Выход: x^K

Утверждение Л15.2 даёт контролируемую оценку второго момента, в которой естественным образом появляются параметр сглаживания τ и уровень шумовой погрешности оракула Δ . Это позволяет сформулировать и проанализировать базовый алгоритм нулевого порядка.

Теорема Л15.2. Пусть задача безусловной оптимизации (Л15.1) с L -гладкой μ -сильно выпуклой целевой функцией f решается с помощью градиентного спуска нулевого порядка (Алгоритм Л15.2). Тогда при $\gamma_k = \gamma \leq \frac{1}{8dL}$ справедлива следующая оценка сходимости:

$$\mathbb{E} \left[\|x^k - x^*\|_2^2 \right] \leq \left(1 - \frac{\mu\gamma}{2}\right)^k \|x^0 - x^*\|_2^2 + \frac{4}{\mu} \left(L^2 \tau^2 \left(2\gamma d^2 + \frac{1}{\mu} \right) + \frac{2d^2 \Delta^2}{\mu \tau^2} \right).$$

Доказательство. Распишем итерацию:

$$\|x^{k+1} - x^*\|_2^2 = \|x^k - x^*\|_2^2 - 2\gamma \langle g^k, x^k - x^* \rangle + \gamma^2 \|g^k\|_2^2.$$

Возьмем условное ожидание по случайности на шаге k :

$$\begin{aligned} \mathbb{E} \left[\|x^{k+1} - x^*\|_2^2 \mid x^k \right] &= \|x^k - x^*\|_2^2 - 2\gamma \langle \mathbb{E} [g^k \mid x^k], x^k - x^* \rangle \\ &\quad + \gamma^2 \mathbb{E} \left[\|g^k\|_2^2 \mid x^k \right] \\ &= \|x^k - x^*\|_2^2 - 2\gamma \langle \nabla f(x^k), x^k - x^* \rangle \\ &\quad + 2\gamma \langle \nabla f(x^k) - \mathbb{E} [g^k \mid x^k], x^k - x^* \rangle + \gamma^2 \mathbb{E} \left[\|g^k\|_2^2 \mid x^k \right]. \end{aligned}$$

Воспользуемся неравенством Юнга:

$$\begin{aligned} \mathbb{E} \left[\|x^{k+1} - x^*\|_2^2 \mid x^k \right] &= \|x^k - x^*\|_2^2 - 2\gamma \langle \nabla f(x^k), x^k - x^* \rangle \\ &\quad + \frac{2\gamma}{\mu} \left\| \mathbb{E} [g^k \mid x^k] - \nabla f(x^k) \right\|_2^2 + \frac{\mu\gamma}{2} \|x^k - x^*\|_2^2 \\ &\quad + \gamma^2 \mathbb{E} \left[\|g^k\|_2^2 \mid x^k \right]. \end{aligned}$$

Воспользуемся Утверждением Л15.2:

$$\begin{aligned} \mathbb{E} \left[\|x^{k+1} - x^*\|_2^2 \mid x^k \right] &\leq \left(1 + \frac{\mu\gamma}{2} \right) \|x^k - x^*\|_2^2 - 2\gamma \langle \nabla f(x^k), x^k - x^* \rangle \\ &\quad + \frac{2\gamma}{\mu} \left(L^2 \tau^2 + \frac{d^2 \Delta^2}{\tau^2} \right) \\ &\quad + \gamma^2 \left(4d \|\nabla f(x^k)\|_2^2 + 4L^2 d^2 \tau^2 + 2 \frac{d^2 \Delta^2}{\tau^2} \right). \end{aligned}$$

Воспользуемся μ -сильной выпуклостью и L -гладкостью:

$$\begin{aligned} \mathbb{E} \left[\|x^{k+1} - x^*\|_2^2 \mid x^k \right] &\leq \left(1 - \frac{\mu\gamma}{2} \right) \|x^k - x^*\|_2^2 - 2\gamma (1 - 4d\gamma L) (f(x^k) - f^*) \\ &\quad + 2\gamma \left(L^2 \tau^2 \left(2\gamma d^2 + \frac{1}{\mu} \right) + \frac{d^2 \Delta^2}{\tau^2} \left(\gamma + \frac{1}{\mu} \right) \right). \end{aligned}$$

Выбирая $\gamma \leq \frac{1}{8dL}$, получаем:

$$\mathbb{E} \left[\|x^{k+1} - x^*\|_2^2 \mid x^k \right] \leq \left(1 - \frac{\mu\gamma}{2} \right) \|x^k - x^*\|_2^2 + 2\gamma \left(2L^2 \tau^2 \left(\gamma d^2 + \frac{1}{\mu} \right) + \frac{2d^2 \Delta^2}{\mu \tau^2} \right).$$

Возьмем полное математическое ожидание и раскроем рекурсию:

$$\mathbb{E} \left[\|x^k - x^*\|_2^2 \right] \leq \left(1 - \frac{\mu\gamma}{2} \right)^k \|x^0 - x^*\|_2^2 + \frac{4}{\mu} \left(L^2 \tau^2 \left(2\gamma d^2 + \frac{1}{\mu} \right) + \frac{2d^2 \Delta^2}{\mu \tau^2} \right).$$

■

Появление τ отражает баланс смещения/дисперсии: уменьшение τ снижает смещение, но повышает вариативность из-за деления на τ в двухточечной формуле. Наоборот, увеличение τ уменьшает дисперсию, но усиливает сглаживающее смещение. В отсутствие шума оптимальной оказывается $\tau = 0$, при наличии шума целесообразно фиксировать τ близкой к балансу $\tau^* \sim \sqrt{\Delta d/L}$.

Л15.2.2 Негладкий выпуклый случай

В отличие от рассмотренного ранее гладкого μ -сильно выпуклого случая, теперь мы не предполагаем L -Липшицевость, а работаем с M -Липшицевой выпуклой функцией:

$$|f(x) - f(y)| \leq M\|x - y\|_2.$$

Дополнительно мы полагаем отсутствие шума оракула значений, то есть $\Delta = 0$, чтобы не перегружать изложение сложными балансами смещения/дисперсии и сосредоточиться на ключевой идее сферического сглаживания и базовой конвергенции ZO-методов. Случай $\Delta > 0$ приводит лишь к стандартной шумовой добавке в итоговых оценках и разбирается аналогично. В этом разделе ключевым понятием является сферически сглаженная функция f_τ , которая позволит нам перенести технику анализа методов первого порядка в настройках нулевого порядка.

Определение Л15.1. Пусть $f : \mathbb{R}^d \rightarrow \mathbb{R}$ — выпуклая функция. Будем называть *сглаженной функцией*, функцию

$$f_\tau(x) = \mathbb{E}_{e \sim U(S^{d-1})}[f(x + \tau e)].$$

Формально, Определение Л15.1 представляет собой сферическое усреднение значения f по равномерному направлению на сфере радиуса τ , в результате чего f_τ становится дифференцируемой, а её градиент естественным образом согласуется с двухточечной ZO-оценкой. Формальные свойства функции $f_\tau(x)$ изложены в следующем утверждении.

Утверждение Л15.3. Для M -Липшицевой выпуклой функции $f : \mathbb{R}^d \rightarrow \mathbb{R}$ выполняется:

1. f_τ дифференцируема и

$$\nabla f_\tau(x) = \mathbb{E}_{e \sim U(S^{d-1})} \left[d \frac{f(x + \tau e) - f(x - \tau e)}{2\tau} e \right];$$

2. f_τ выпукла и

$$0 \leq f_\tau(x) - f(x) \leq \tau M;$$

3. Градиент $f_\tau(x)$ ограничен:

$$\|\nabla f_\tau(x)\|_2 \leq dM.$$

Доказательство.

1. Рассмотрим приращение:

$$f_\tau(x + th) - f_\tau(x) = \mathbb{E}_e [f(x + th + \tau e) - f(x + \tau e)].$$

Поделим на t и рассмотрим предел:

$$\lim_{t \rightarrow 0} \frac{f_\tau(x + th) - f_\tau(x)}{t} = \mathbb{E} \left[\lim_{t \rightarrow 0} \frac{f(x + th + \tau e) - f(x + \tau e)}{t} \right] = \langle \mathbb{E} [\nabla f(x + \tau e)], h \rangle.$$

Заметим, что для любого $t \in [-1, 1]$:

$$\mathbb{E}[\nabla f(x + \tau e)] = \mathbb{E}[\nabla f(x + t\tau e)].$$

А в Теореме Л15.2 мы получили, что

$$\mathbb{E}[\nabla f(x + t\tau e)] = \mathbb{E}\left[d \frac{f(x + \tau e) - f(x - \tau e)}{2\tau} e\right].$$

Таким образом получили требуемое.

2. Выпуклость f_τ следует из выпуклости f . Для доказательства второго факта воспользуемся выпуклостью f :

$$f(x) \leq f(x + \tau e) + \langle \nabla f(x), x - (x + \tau e) \rangle = f(x + \tau e) - \tau \langle \nabla f(x), e \rangle.$$

Возьмем математическое ожидание и используем симметрию распределения:

$$f(x) \leq \mathbb{E}[f(x + \tau e)] = f_\tau(x),$$

то есть $f_\tau(x) - f(x) \geq 0$. Для верхней оценки используем M -Липшицевость f :

$$f(x + \tau e) - f(x) \leq M \|\tau e\|_2 = M\tau.$$

Усредняя по e , получим $f_\tau(x) - f(x) \leq \tau G$.

3. Из первого пункта имеем

$$\nabla f_\tau(x) = \mathbb{E}\left[d \frac{f(x + \tau e) - f(x - \tau e)}{2\tau} e\right].$$

Воспользуемся M -Липшицевостью f :

$$\begin{aligned} \|\nabla f_\tau(x)\|_2 &\leq \mathbb{E}\left[d \frac{|f(x + \tau e) - f(x - \tau e)|}{2\tau} \|e\|_2\right] \\ &\leq \mathbb{E}\left[d \frac{M\|(x + \tau e) - (x - \tau e)\|_2}{2\tau}\right] = dM. \end{aligned}$$

■

Утверждение Л15.3 формализует, что сферическое сглаживание делает целевую функцию «хорошей» в аналитическом и алгоритмическом смысле даже тогда, когда исходная f может быть негладкой.

Утверждение Л15.4. Пусть дана M -Липшицева функция $f : \mathbb{R}^d \rightarrow \mathbb{R}$. Определим оценку градиента

$$g(x, e) = d \frac{f(x + \tau e) - f(x - \tau e)}{2\tau} e, \quad e \sim U(S^{d-1}).$$

Тогда для любого $x \in \mathbb{R}^d$ справедливо:

1. $\mathbb{E}_{e \sim U(S^{d-1})}[g(x, e)] = \nabla f_\tau(x)$,
2. $\mathbb{E}_{e \sim U(S^{d-1})}\|g(x, e)\|_2^2 \leq d^2 M^2$.

Доказательство.

1. Следует из первого пункта Утверждения Л15.3.
2. Воспользуемся M -Липшицевостью:

$$\mathbb{E} \left[\|g(x, e)\|_2^2 \right] = \frac{d^2}{4\tau^2} \mathbb{E} \left[|f(x + \tau e) - f(x - \tau e)|^2 \right] \leq d^2 M^2.$$

■

Покажем сходимость Алгоритма Л15.2 для выпуклой негладкой f .

Теорема Л15.3. Пусть задача безусловной оптимизации (Л15.1) с γ -Липшицевой выпуклой целевой функцией f решается с помощью градиентного спуска нулевого порядка (Алгоритм Л15.2). Тогда при

$$\gamma_k = \gamma \leq \frac{\|x^0 - x^*\|_2}{dM\sqrt{K}}$$

справедлива следующая оценка сходимости:

$$\mathbb{E} \left[f \left(\frac{1}{K} \sum_{k=0}^{K-1} x^k \right) - f^* \right] \leq \frac{dM\|x^0 - x^*\|_2}{\sqrt{K}} + \tau M.$$

В частности, при выборе

$$\tau \leq \frac{d\|x^0 - x^*\|_2}{\sqrt{K}}$$

имеем

$$\mathbb{E} \left[f \left(\frac{1}{K} \sum_{k=0}^{K-1} x^k \right) - f^* \right] \leq \frac{dM\|x^0 - x^*\|_2}{\sqrt{K}}.$$

Доказательство. Распишем итерацию:

$$\|x^{k+1} - x^*\|_2^2 = \|x^k - x^*\|_2^2 - 2\gamma \langle g^k, x^k - x^* \rangle + \gamma^2 \|g^k\|_2^2.$$

Возьмем условное математическое ожидание:

$$\mathbb{E} \left[\|x^{k+1} - x^*\|_2^2 \mid x^k \right] = \|x^k - x^*\|_2^2 - 2\gamma \langle \nabla f_\tau(x^k), x^k - x^* \rangle + \gamma^2 \mathbb{E} \left[\|g^k\|_2^2 \mid x^k \right].$$

Запишем выпуклость f_τ :

$$\langle \nabla f_\tau(x^k), x^k - x^* \rangle \geq f_\tau(x^k) - f_\tau(x^*)$$

и, используя результат Утверждения Л15.4, получим:

$$\mathbb{E} \left[\|x^{k+1} - x^*\|_2^2 \mid x^k \right] \leq \|x^k - x^*\|_2^2 - 2\gamma (f_\tau(x^k) - f_\tau(x^*)) + \gamma^2 d^2 M^2.$$

Перейдем к полному математическому ожиданию и раскроем рекурсию:

$$\mathbb{E} \left[\|x^K - x^*\|_2^2 \right] \leq \|x^0 - x^*\|_2^2 - 2\gamma \sum_{k=0}^{K-1} \mathbb{E} \left[f_\tau(x^k) - f_\tau(x^*) \right] + K\gamma^2 d^2 M^2.$$

Отбросим неотрицательный левый член и поделим на $2\gamma K$:

$$\frac{1}{K} \sum_{k=0}^{K-1} \mathbb{E} [f_\tau(x^k) - f_\tau(x^*)] \leq \frac{\|x^0 - x^*\|_2^2}{2\gamma K} + \frac{\gamma d^2 M^2}{2}.$$

Воспользуемся выпуклостью f_τ :

$$\mathbb{E} \left[f_\tau \left(\frac{1}{K} \sum_{k=0}^{K-1} x^k \right) - f_\tau(x^*) \right] \leq \frac{\|x^0 - x^*\|_2^2}{2\gamma K} + \frac{\gamma d^2 M^2}{2}.$$

Минимизируя правую часть по γ , получаем, что

$$\gamma = \frac{\|x^0 - x^*\|_2}{dM\sqrt{K}}.$$

Тогда

$$\mathbb{E} \left[f_\tau \left(\frac{1}{K} \sum_{k=0}^{K-1} x^k \right) - f_\tau(x^*) \right] \leq \frac{dM\|x^0 - x^*\|_2}{\sqrt{K}}.$$

Пользуясь тем, что $0 \leq f_\tau(x) - f(x) \leq \tau M$,

$$\begin{aligned} \mathbb{E} \left[f \left(\frac{1}{K} \sum_{k=0}^{K-1} x^k \right) - f(x^*) \right] &\leq \mathbb{E} \left[f_\tau \left(\frac{1}{K} \sum_{k=0}^{K-1} x^k \right) - f_\tau(x^*) \right] + \tau M \\ &\leq \frac{dM\|x^0 - x^*\|_2}{\sqrt{K}} + \tau M. \end{aligned}$$

При выборе $\tau \leq \frac{d\|x^0 - x^*\|_2}{\sqrt{K}}$ получаем

$$\mathbb{E} \left[f \left(\frac{1}{K} \sum_{k=0}^{K-1} x^k \right) - f(x^*) \right] \leq \frac{2dM\|x^0 - x^*\|_2}{\sqrt{K}}.$$

■

Л15.2.3 Ключевые работы

Методы оптимизации нулевого порядка для дообучения больших языковых моделей представляют собой активно развивающуюся область исследований. Ниже представлены ключевые работы, которые расширяют и углубляют понимание данного направления.

- MeZO (Memory-efficient Zeroth-Order) представляет собой основополагающую работу в области применения методов нулевого порядка для дообучения LLM. Авторы адаптируют классический ZO-SGD для работы in-place, обеспечивая дообучение моделей с тем же объемом памяти, что и инференс, достигая при этом производительности, сопоставимой с методами первого порядка при снижении потребления памяти до 12 раз.
- LeZO (Layer-wise Zeroth-Order) вводит послынную разреженную вычислительную стратегию для ZO-оптимизации, обрабатывая слои как фундаментальные единицы разреживания. Метод динамически возмущает различные подмножества параметров на каждом шаге, достигая ускорения более чем в 3 раза по сравнению с MeZO на задачах классификации без дополнительных накладных расходов на память.

- ZO-AdaMU предлагает оригинальное решение проблем осцилляций и вычислительных издержек в MeZO путем адаптации возмущений с моментумом в стохастической аппроксимации градиента. В отличие от существующих адаптивных методов моментума, алгоритм перемещает моментум на симулируемое возмущение в стохастической аппроксимации градиента, что теоретически и эмпирически доказано как более эффективный способ улучшения стабильности и скорости сходимости в ZO-SGD для дообучения LLM.
- HiZOO (Hessian-informed Zeroth-Order Optimizer) впервые интегрирует информацию о диагональном гессиане в оптимизацию нулевого порядка для дообучения LLM. Данный подход решает проблему гетерогенных кривизн в различных размерностях параметров, обеспечивая существенное ускорение сходимости при сохранении преимуществ в потреблении памяти.
- LOZO (Low-rank Zeroth-Order) предлагает новый подход к оценке градиентов нулевого порядка через использование низкоранговых структур. Метод эффективно захватывает низкоранговую структуру градиентов, характерную для дообучения LLM, что позволяет значительно улучшить сходимость по сравнению с существующими ZO-методами, приближаясь к производительности алгоритмов первого порядка.
- MeZO-SVRG интегрирует техники редукции дисперсии в ZO-оптимизацию для повышения стабильности и скорости сходимости при дообучении на основе инференса. Метод превосходит MeZO на 20% по точности тестирования при двукратном снижении времени GPU-часов, существенно уменьшая требования к памяти по сравнению с стохастическим градиентным спуском первого порядка.
- JAGUAR SignSGD / Muon представляют первые методы ZO-оптимизации с гарантиями сходимости для алгоритмов SignSGD и Muon в стохастическом невыпуклом случае. Подходы используют JAGUAR-аппроксимацию градиента и координатный моментум, требуя лишь $\mathcal{O}(1)$ вычислений оракула за итерацию и демонстрируя конкурентную производительность с методами первого порядка при значительной экономии памяти.

Список литературы

- [1] Necdet Serhat Aybat, Alireza Fallah, Mert Gurbuzbalaban, and Asuman Ozdaglar. A universally optimal multistage accelerated stochastic gradient method, 2019.
- [2] Francis Bach and Eric Moulines. Non-asymptotic analysis of stochastic approximation algorithms for machine learning. In *Advances in Neural Information Processing Systems*, volume 24, pages 451–459, December 2011.
- [3] Aleksandr Beznosikov, Valentin Samokhin, and Alexander Gasnikov. Distributed saddle point problems: lower bounds, near-optimal and robust algorithms*. *Optimization Methods and Software*, page 1–18, March 2025.
- [4] Christopher M. Bishop. *Neural Networks for Pattern Recognition*. Oxford University Press, 1995.
- [5] Christopher M. Bishop. *Pattern Recognition and Machine Learning (Information Science and Statistics)*. Springer, 1 edition, 2007.
- [6] Stephen Boyd and Lieven Vandenbergh. *Convex Optimization*. Cambridge University Press, Cambridge, 2004.