Методы редукции дисперсии

Методы оптимизации

Александр Безносиков

Московский физико-технический институт

3 декабря 2026



Задача

- До этого мы рассмотрели стохастический градиентный спуск и увидели, что его точность ограничена дисперсией стохастических градиентов.

Задача

- До этого мы рассмотрели стохастический градиентный спуск и увидели, что его точность ограничена дисперсией стохастических градиентов.
- Рассмотрим методы, которые уменьшают её — **методы редукции дисперсии**.

Задача

- До этого мы рассмотрели стохастический градиентный спуск и увидели, что его точность ограничена дисперсией стохастических градиентов.
- Рассмотрим методы, которые уменьшают её — **методы редукции дисперсии**.
- Они предназначены для решения задачи минимизации эмпирического риска:

$$\min_{x \in \mathbb{R}^d} \left[f(x) = \frac{1}{n} \sum_{i=1}^{n} f_i(x) \right].$$

Задача

- До этого мы рассмотрели стохастический градиентный спуск и увидели, что его точность ограничена дисперсией стохастических градиентов.
- Рассмотрим методы, которые уменьшают её — **методы редукции дисперсии**.
- Они предназначены для решения задачи минимизации эмпирического риска:

$$\min_{x \in \mathbb{R}^d} \left[f(x) = \frac{1}{n} \sum_{i=1}^{n} f_i(x) \right].$$

- Будем считать, что $\nabla f(x, \xi) = \nabla f_i(x)$, то есть выбор случайной реализации ξ эквивалентен выбору индекса i.

Почему стохастический градиентный спуск не сходится?

- На практике при использовании стохастического градиентного спуска с постоянным шагом γ на первых итерациях метод ведёт себя почти так же, как градиентный спуск, однако вокруг минимума он начинает осциллировать. **Вопрос:** с чем это связано?

Почему стохастический градиентный спуск не сходится?

- На практике при использовании стохастического градиентного спуска с постоянным шагом γ на первых итерациях метод ведёт себя почти так же, как градиентный спуск, однако вокруг минимума он начинает осциллировать. **Вопрос:** с чем это связано? В классическом градиентном спуске градиент стремится к нулю по мере приближения к решению, тогда как стохастический градиент, вообще говоря, не обязан обращаться в ноль в точке минимума.

Почему стохастический градиентный спуск не сходится?

- На практике при использовании стохастического градиентного спуска с постоянным шагом γ на первых итерациях метод ведёт себя почти так же, как градиентный спуск, однако вокруг минимума он начинает осциллировать. **Вопрос:** с чем это связано? В классическом градиентном спуске градиент стремится к нулю по мере приближения к решению, тогда как стохастический градиент, вообще говоря, не обязан обращаться в ноль в точке минимума.
- Рассмотрим пример, пусть в задаче машинного обучения x^* минимизирует потери по всей выборке, а $f\left(x, \xi\right)$ отражает потери только на отдельном сэмпле ξ. Хотя x^* оптимальна в среднем, но нет никаких гарантий, что x^* оптимальна для отдельного элемента выборки. Поэтому в общем случае $\nabla f\left(x^*, \xi\right) \neq 0$, и возникает осциллирующий эффект.

Модификация стохастического градиентного спуска

- Аппроксимируем полный градиент g^k на каждой итерации так, чтобы при стремлении траектории метода к решению $x^k \to x^*$, эта аппроксимация стремилась к нулю $g^k \to \nabla f\left(x^*\right) = 0$.

Модификация стохастического градиентного спуска

- Аппроксимируем полный градиент g^k на каждой итерации так, чтобы при стремлении траектории метода к решению $x^k \to x^*$, эта аппроксимация стремилась к нулю $g^k \to \nabla f\left(x^*\right) = 0$.
- На каждой итерации такой метод производит шаг по g^k:

$$x^{k+1} = x^k - \gamma g^k.$$

Модификация стохастического градиентного спуска

- Аппроксимируем полный градиент g^k на каждой итерации так, чтобы при стремлении траектории метода к решению $x^k \to x^*$, эта аппроксимация стремилась к нулю $g^k \to \nabla f\left(x^*\right) = 0$.
- На каждой итерации такой метод производит шаг по g^k:

$$x^{k+1} = x^k - \gamma g^k.$$

- g^k должны удовлетворять предположению несмещенности.

SAGA

Алгоритм SAGA

Вход: стартовая точка $x^0 \in \mathbb{R}^d$, значения памяти $y_i^0 = 0$, размеры шагов $\{\gamma_k\}_{k=0} > 0$, количество итераций K

for $k = 0, 1, \ldots, K-1$ **do**

Сгенерировать независимо $i_k \sim U(\overline{1, n})$

$$g^k = \nabla f_{i_k}(x^k) - y_{i_k}^k + \frac{1}{n}\sum_{i=1}^{n} y_i^k$$

$$y_i^{k+1} = \begin{cases} \nabla f_i(x^k), & i = i_k \\ y_i^k, & i \neq i_k \end{cases}$$

$$x^{k+1} = x^k - \gamma_k g^k$$

end for

Выход: x^K

SAGA

Отметим, что аппроксиматор g^k обладает свойством несмещенности:

$$\mathbb{E}\left[g^k \,\middle|\, x^k\right] = \frac{1}{n}\sum_{i=1}^{n} \nabla f_i\left(x^k\right) - \frac{1}{n}\sum_{i=1}^{n} y_i^k + \frac{1}{n}\sum_{i=1}^{n} y_i^k = \nabla f\left(x^k\right).$$

Сходимость

Начнем с подстановки шага $x^{k+1} = x^k - \gamma g^k$ в квадрат нормы разности:

$$\left\|x^{k+1} - x^*\right\|_2^2 = \left\|x^k - x^*\right\|_2^2 - 2\gamma\left\langle g^k, x^k - x^*\right\rangle + \gamma^2\left\|g^k - \nabla f\left(x^*\right)\right\|_2^2.$$

Сходимость

Начнем с подстановки шага $x^{k+1} = x^k - \gamma g^k$ в квадрат нормы разности:

$$\left\|x^{k+1} - x^*\right\|_2^2 = \left\|x^k - x^*\right\|_2^2 - 2\gamma\left\langle g^k, x^k - x^*\right\rangle + \gamma^2\left\|g^k - \nabla f\left(x^*\right)\right\|_2^2.$$

Возьмем условное математическое ожидание по случайности на итерации k:

$$\mathbb{E}\left[\left\|x^{k+1} - x^*\right\|_2^2 \middle| x^k\right] = \left\|x^k - x^*\right\|_2^2 - 2\gamma\left\langle \mathbb{E}\left[g^k \middle| x^k\right], x^k - x^*\right\rangle + \gamma^2\mathbb{E}\left[\left\|g^k - \nabla f\left(x^*\right)\right\|_2^2 \middle| x^k\right].$$

Сходимость

Рассмотрим слагаемое $\mathbb{E}\left[g^k \,\middle|\, x^k\right]$:

$$\begin{aligned}\mathbb{E}\left[g^k \,\middle|\, x^k\right] &= \mathbb{E}\left[\nabla f_{i_k}(x^k) - y_{i_k}^k + \frac{1}{n}\sum_{i=1}^n y_i^k \,\middle|\, x^k\right] \\ &= \mathbb{E}\left[\nabla f_{i_k}(x^k) - y_{i_k}^k \,\middle|\, x^k\right] + \frac{1}{n}\sum_{i=1}^n y_i^k \\ &= \frac{1}{n}\sum_{i=1}^n \left(\nabla f_i(x^k) - y_i^k\right) + \frac{1}{n}\sum_{i=1}^n y_i^k = \nabla f(x^k).\end{aligned}$$

Сходимость

Рассмотрим $\mathbb{E}\left[\left\|g^k - \nabla f(x^*)\right\|_2^2 \middle| x^k\right]$:

$$\mathbb{E}\left[\left\|g^k - \nabla f(x^*)\right\|_2^2 \middle| x^k\right]$$
$$= \mathbb{E}\left[\left\|\nabla f_{i_k}(x^k) - y_{i_k}^k + \frac{1}{n}\sum_{i=1}^n y_i^k - \nabla f(x^*)\right\|_2^2 \middle| x^k\right]$$
$$= \mathbb{E}\left[\left\|\nabla f_{i_k}(x^k) - \nabla f_{i_k}(x^*) + \nabla f_{i_k}(x^*) - y_{i_k}^k + \frac{1}{n}\sum_{i=1}^n y_i^k - \nabla f(x^*)\right\|_2^2 \middle| x^k\right].$$

Сходимость

Воспользуемся тем, что $\left\|a+b\right\|_2^2 \leq 2\left\|a\right\|_2^2 + 2\left\|b\right\|_2^2$:

$$\begin{aligned}
&\mathbb{E}\left[\left\|g^k - \nabla f\left(x^*\right)\right\|_2^2 \middle| x^k\right] \\
&\leq 2\mathbb{E}\left[\left\|\nabla f_{i_k}\left(x^k\right) - \nabla f_{i_k}\left(x^*\right)\right\|_2^2 \middle| x^k\right] \\
&\quad + 2\mathbb{E}\left[\left\|\nabla f_{i_k}\left(x^*\right) - y_{i_k}^k + \frac{1}{n}\sum_{i=1}^n y_i^k - \nabla f\left(x^*\right)\right\|_2^2 \middle| x^k\right].
\end{aligned}$$

Сходимость

Заметим, что если во втором слагаемом взять ξ равным $\nabla f_{i_k}\left(x^*\right) - y_{i_k}^k$, то получим дисперсию $\mathbb{E}\left[\left\|\xi - \mathbb{E}\left[\xi \,\middle|\, x^k\right]\right\|_2^2 \,\middle|\, x^k\right]$. Воспользуемся тем, что

$$\mathbb{E}\left[\left\|\xi - \mathbb{E}\left[\xi \,\middle|\, x^k\right]\right\|_2^2 \,\middle|\, x^k\right] \leq \mathbb{E}\left[\left\|\xi\right\|_2^2 \,\middle|\, x^k\right] :$$

$$\mathbb{E}\left[\left\|g^k - \nabla f\left(x^*\right)\right\|_2^2 \,\middle|\, x^k\right] \leq 2\mathbb{E}\left[\left\|\nabla f_{i_k}\left(x^k\right) - \nabla f_{i_k}\left(x^*\right)\right\|_2^2 \,\middle|\, x^k\right] + 2\mathbb{E}\left[\left\|\nabla f_{i_k}\left(x^*\right) - y_{i_k}^k\right\|_2^2 \,\middle|\, x^k\right].$$

Сходимость

Раскроем математическое ожидание, пользуясь гладкостью и выпуклостью f_i:

$$\begin{aligned}
&\mathbb{E}\left[\left\|g^k - \nabla f\left(x^*\right)\right\|_2^2 \middle| x^k\right] \\
&\leq 4L \cdot \frac{1}{n}\sum_{i=1}^{n}\left(f_i\left(x^k\right) - f_i\left(x^*\right) - \left\langle \nabla f_i\left(x^*\right), x^k - x^*\right\rangle\right) \\
&\quad + 2 \cdot \frac{1}{n}\sum_{i=1}^{n}\left\|\nabla f_i\left(x^*\right) - y_i^k\right\|_2^2 \\
&= 4L\left(f\left(x^k\right) - f^*\right) + 2 \cdot \frac{1}{n}\sum_{i=1}^{n}\left\|\nabla f_i\left(x^*\right) - y_i^k\right\|_2^2.
\end{aligned}$$

Сходимость

Собирая всё вместе, получаем:

$$\begin{aligned}
&\mathbb{E}\left[\left\|x^{k+1}-x^*\right\|_2^2 \,\middle|\, x^k\right] \\
&\leq \left\|x^k-x^*\right\|_2^2 - 2\gamma\left\langle \nabla f\left(x^k\right), x^k-x^*\right\rangle \\
&\quad + \gamma^2\left(4L\left(f\left(x^k\right)-f^*\right) + 2\cdot\frac{1}{n}\sum_{i=1}^n\left\|\nabla f_i\left(x^*\right)-y_i^k\right\|_2^2\right).
\end{aligned}$$

Сходимость

Собирая всё вместе, получаем:

$$\mathbb{E}\left[\left\|x^{k+1}-x^*\right\|_2^2 \,\middle|\, x^k\right]$$
$$\leq \left\|x^k-x^*\right\|_2^2 - 2\gamma\left\langle \nabla f\left(x^k\right), x^k-x^*\right\rangle$$
$$+\gamma^2\left(4L\left(f\left(x^k\right)-f^*\right)+2\cdot\frac{1}{n}\sum_{i=1}^n\left\|\nabla f_i\left(x^*\right)-y_i^k\right\|_2^2\right).$$

Воспользуемся μ–сильной выпуклостью функции f:

$$\mathbb{E}\left[\left\|x^{k+1}-x^*\right\|_2^2 \,\middle|\, x^k\right] \leq (1-\mu\gamma)\left\|x^k-x^*\right\|_2^2 - 2\gamma(1-2\gamma L)\left(f\left(x^k\right)-f^*\right)$$
$$+2\gamma^2\cdot\frac{1}{n}\sum_{i=1}^n\left\|\nabla f_i\left(x^*\right)-y_i^k\right\|_2^2.$$

Сходимость

Пришли к тому, что если $y_i^k \to \nabla f_i(x^*)$, то будет линейная сходимость.

Сходимость

Пришли к тому, что если $y_i^k \to \nabla f_i(x^*)$, то будет линейная сходимость. Возьмем полное математическое ожидание:

$$\mathbb{E}\left[\left\|x^{k+1} - x^*\right\|_2^2\right] \leq (1 - \mu\gamma)\mathbb{E}\left[\left\|x^k - x^*\right\|_2^2\right] - 2\gamma(1 - 2\gamma L)\mathbb{E}\left[f\left(x^k\right) - f^*\right] + 2\gamma^2\mathbb{E}\left[\frac{1}{n}\sum_{i=1}^n \left\|\nabla f_i(x^*) - y_i^k\right\|_2^2\right].$$

Сходимость

Пришли к тому, что если $y_i^k \to \nabla f_i(x^*)$, то будет линейная сходимость. Возьмем полное математическое ожидание:

$$\mathbb{E}\left[\left\|x^{k+1} - x^*\right\|_2^2\right] \leq (1 - \mu\gamma)\mathbb{E}\left[\left\|x^k - x^*\right\|_2^2\right] - 2\gamma(1 - 2\gamma L)\mathbb{E}\left[f(x^k) - f^*\right] + 2\gamma^2\mathbb{E}\left[\frac{1}{n}\sum_{i=1}^n \left\|\nabla f_i(x^*) - y_i^k\right\|_2^2\right].$$

Теперь рассмотрим, как ведет себя $\mathbb{E}\left[\frac{1}{n}\sum_{i=1}^n \left\|y_i^{k+1} - \nabla f_i(x^*)\right\|_2^2 \middle| x^k\right]$:

$$\mathbb{E}\left[\frac{1}{n}\sum_{i=1}^n \left\|y_i^{k+1} - \nabla f_i(x^*)\right\|_2^2 \middle| x^k\right] = \left(1 - \frac{1}{n}\right)\cdot\frac{1}{n}\sum_{i=1}^n \left\|y_i^k - \nabla f_i(x^*)\right\|_2^2 + \frac{1}{n}\cdot\frac{1}{n}\sum_{i=1}^n \left\|\nabla f_i(x^k) - \nabla f_i(x^*)\right\|_2^2.$$

Сходимость

Воспользуемся выпуклостью и гладкостью f_i:

$$\mathbb{E}\left[\frac{1}{n}\sum_{i=1}^{n}\left\|y_i^{k+1} - \nabla f_i(x^*)\right\|_2^2 \middle| x^k\right] \leq \left(1 - \frac{1}{n}\right)\cdot\frac{1}{n}\sum_{i=1}^{n}\left\|y_i^{k} - \nabla f_i(x^*)\right\|_2^2 + \frac{2L}{n}\left(f(x^k) - f^*\right).$$

Сходимость

Воспользуемся выпуклостью и гладкостью f_i:

$$\mathbb{E}\left[\frac{1}{n}\sum_{i=1}^{n}\left\|y_i^{k+1}-\nabla f_i(x^*)\right\|_2^2\middle| x^k\right] \leq \left(1-\frac{1}{n}\right)\cdot\frac{1}{n}\sum_{i=1}^{n}\left\|y_i^{k}-\nabla f_i(x^*)\right\|_2^2 + \frac{2L}{n}\Big(f(x^k)-f^*\Big).$$

Возьмем полное математическое ожидание:

$$\mathbb{E}\left[\frac{1}{n}\sum_{i=1}^{n}\left\|y_i^{k+1}-\nabla f_i(x^*)\right\|_2^2\right] \leq \left(1-\frac{1}{n}\right)\mathbb{E}\left[\frac{1}{n}\sum_{i=1}^{n}\left\|y_i^{k}-\nabla f_i(x^*)\right\|_2^2\right] + \frac{2L}{n}\mathbb{E}\left[f(x^k)-f^*\right].$$

Сходимость

Получилось две «сходящиеся» последовательности, осталось их аккуратно «сшить».

Сходимость

Получилось две «сходящиеся» последовательности, осталось их аккуратно «сшить». Возьмем $M > 0$ и сложим две рекурренты, которые получились выше:

$$\mathbb{E}\left[\left\|x^{k+1} - x^*\right\|_2^2 + M\gamma^2 \cdot \frac{1}{n}\sum_{i=1}^n \left\|y_i^{k+1} - \nabla f_i(x^*)\right\|_2^2\right]$$

$$\leq (1-\mu\gamma)\mathbb{E}\left[\left\|x^k - x^*\right\|_2^2\right] + \left(1 + \frac{2}{M} - \frac{1}{n}\right)\mathbb{E}\left[\frac{M\gamma^2}{n}\sum_{i=1}^n \left\|y_i^k - \nabla f_i(x^*)\right\|_2^2\right]$$

$$- 2\gamma\left(1 - 2\gamma L - \frac{\gamma ML}{n}\right)\mathbb{E}\left[f(x^k) - f^*\right].$$

Сходимость

Возьмем $M = 4n$:

$$\mathbb{E}\left[\left\|x^{k+1} - x^*\right\|_2^2 + 4n\gamma^2 \cdot \frac{1}{n}\sum_{i=1}^{n}\left\|y_i^{k+1} - \nabla f_i(x^*)\right\|_2^2\right]$$

$$\leq (1-\mu\gamma)\mathbb{E}\left[\left\|x^k - x^*\right\|_2^2\right] + \left(1 - \frac{1}{2n}\right)\mathbb{E}\left[4n\gamma^2 \cdot \frac{1}{n}\sum_{i=1}^{n}\left\|y_i^k - \nabla f_i(x^*)\right\|_2^2\right]$$

$$- 2\gamma(1 - 6\gamma L)\mathbb{E}\left[f\left(x^k\right) - f^*\right].$$

Сходимость

Потребуем $\gamma \leq \frac{1}{6L}$:

$$\mathbb{E}\left[\left\|x^{k+1} - x^*\right\|_2^2 + 4n\gamma^2 \cdot \frac{1}{n}\sum_{i=1}^{n}\left\|y_i^{k+1} - \nabla f_i(x^*)\right\|_2^2\right]$$

$$\leq \max\left\{(1-\mu\gamma), \left(1 - \frac{1}{2n}\right)\right\}\mathbb{E}\left[\left\|x^k - x^*\right\|_2^2 + 4n\gamma^2 \cdot \frac{1}{n}\sum_{i=1}^{n}\left\|y_i^k - \nabla f_i(x^*)\right\|_2^2\right].$$

Сходимость

Потребуем $\gamma \leq \frac{1}{6L}$:

$$\mathbb{E}\left[\left\|x^{k+1} - x^*\right\|_2^2 + 4n\gamma^2 \cdot \frac{1}{n}\sum_{i=1}^{n}\left\|y_i^{k+1} - \nabla f_i\left(x^*\right)\right\|_2^2\right]$$

$$\leq \max\left\{(1-\mu\gamma), \left(1 - \frac{1}{2n}\right)\right\}\mathbb{E}\left[\left\|x^k - x^*\right\|_2^2 + 4n\gamma^2 \cdot \frac{1}{n}\sum_{i=1}^{n}\left\|y_i^k - \nabla f_i\left(x^*\right)\right\|_2^2\right].$$

- Получили сходимость, но не по обычному критерию. Суть критерия в отражении физики как сходимости $x^k \to x^*$, так и $y_i^k \to \nabla f_i\left(x^*\right)$, что и закладывалось в метод.

Сходимость

Потребуем $\gamma \leq \frac{1}{6L}$:

$$\mathbb{E}\left[\left\|x^{k+1} - x^*\right\|_2^2 + 4n\gamma^2 \cdot \frac{1}{n}\sum_{i=1}^{n}\left\|y_i^{k+1} - \nabla f_i\left(x^*\right)\right\|_2^2\right]$$

$$\leq \max\left\{(1-\mu\gamma), \left(1 - \frac{1}{2n}\right)\right\}\mathbb{E}\left[\left\|x^k - x^*\right\|_2^2 + 4n\gamma^2 \cdot \frac{1}{n}\sum_{i=1}^{n}\left\|y_i^k - \nabla f_i\left(x^*\right)\right\|_2^2\right].$$

- Получили сходимость, но не по обычному критерию. Суть критерия в отражении физики как сходимости $x^k \to x^*$, так и $y_i^k \to \nabla f_i\left(x^*\right)$, что и закладывалось в метод.
- Из такой сходимости следует и сходимость по $\mathbb{E}\left[\left\|x^k - x^*\right\|_2^2\right]$.

Сходимость

Теорема

Пусть задача безусловной стохастической оптимизации суммы с L–гладкими, выпуклыми функциями f_i и μ–сильно выпуклой целевой функцией f решается с помощью SAGA с $\gamma_k = \gamma \leq \frac{1}{6L}$. Тогда справедлива следующая оценка сходимости:

$$\mathbb{E}\left[V_k\right] \leq \max\left\{(1-\mu\gamma), \left(1-\frac{1}{2n}\right)\right\}^k \mathbb{E}\left[V_0\right],$$

где $V_k = \left\|x^k - x^*\right\|_2^2 + 4n\gamma^2 \cdot \frac{1}{n}\sum\limits_{i=1}^{n}\left\|y_i^k - \nabla f_i(x^*)\right\|_2^2$.

Более того, при оптимальном выборе шага для достижения точности ε достаточно

$$\mathcal{O}\left(\left[n + \frac{L}{\mu}\right]\log\frac{1}{\varepsilon}\right) \quad \textit{итераций.}$$

Сходимость

- **Вопрос:** почему не взять M огромным, тогда сходимость будет лучше?

Сходимость

- **Вопрос:** почему не взять M огромным, тогда сходимость будет лучше? Нельзя взять M огромным, так как M влияет на критерий сходимости, который также будет расти с ростом M. При этом сходимости лучше, чем $\left(1 - \frac{1}{n}\right)$, не добиться.

Сходимость

- **Вопрос:** почему не взять M огромным, тогда сходимость будет лучше? Нельзя взять M огромным, так как M влияет на критерий сходимости, который также будет расти с ростом M. При этом сходимости лучше, чем $\left(1 - \frac{1}{n}\right)$, не добиться.
- Получили следующую оценку на число итераций:

$$\mathcal{O}\left(\left[n + \frac{L}{\mu}\right] \log \frac{1}{\varepsilon}\right).$$

Сходимость

- **Вопрос:** почему не взять M огромным, тогда сходимость будет лучше? Нельзя взять M огромным, так как M влияет на критерий сходимости, который также будет расти с ростом M. При этом сходимости лучше, чем $\left(1 - \frac{1}{n}\right)$, не добиться.
- Получили следующую оценку на число итераций:

$$\mathcal{O}\left(\left[n + \frac{L}{\mu}\right] \log \frac{1}{\varepsilon}\right).$$

- У классического градиентного спуска оценка:

$$\mathcal{O}\left(\frac{L}{\mu} \log \frac{1}{\varepsilon}\right),$$

но оракульная сложность (подсчет градиентов ∇f_i) у градиентного спуска в n раз больше.

SVRG

- SAGA обладает существенным недостатком — требует хранения матрицы размера $n \times d$, где d — размерность задачи, а n — количество функций в постановке конечной суммы.

SVRG

- SAGA обладает существенным недостатком — требует хранения матрицы размера $n \times d$, где d — размерность задачи, а n — количество функций в постановке конечной суммы.
- Классический стохастический градиентный спуск тратит $\mathcal{O}(d)$ памяти, ведь хранит только текущее состояние оптимизируемых параметров модели.

SVRG

- SAGA обладает существенным недостатком — требует хранения матрицы размера $n \times d$, где d — размерность задачи, а n — количество функций в постановке конечной суммы.
- Классический стохастический градиентный спуск тратит $\mathcal{O}(d)$ памяти, ведь хранит только текущее состояние оптимизируемых параметров модели.
- Рассмотрим метод SVRG, который эффективно по памяти реализует идею редукции дисперсии. Основная идея этого метода заключается в том, чтобы уйти от запоминания стохастических градиентов по каждому индексу i. Вместо восстановления полного градиента с запозданием, как это делает SAGA, SVRG считает полный градиент раз в некоторое время. Такая точка называется **референсной**, а промежуток между подсчетами полного градиента — **эпохой**.

SVRG

Алгоритм SVRG

Вход: стартовая точка $y^0 \in \mathbb{R}^d$, размеры шагов $\{\gamma_k\}_{k=0} > 0$, количество итераций в эпохе K, количество эпох T

for $t = 0, 1, \ldots, T-1$ **do**
  $x^0 = y^t$
  for $k = 0, 1, \ldots, K-1$ **do**
    Сгенерировать независимо $i_k \sim U(\overline{1, n})$
    $g^k = \nabla f_{i_k}(x^k) - \nabla f_{i_k}(y^t) + \nabla f(y^t)$
    $x^{k+1} = x^k - \gamma_k g^k$
  end for
  $y^{t+1} = x^K$
end for

Выход: y^T

SVRG

- Аппроксиматор в SVRG несмещенный:

$$\mathbb{E}\left[g^k \,\middle|\, x^k\right] = \frac{1}{n}\sum_{i=1}^{n}\nabla f_i(x^k) - \frac{1}{n}\sum_{i=1}^{n}\nabla f_i(y^t) + \nabla f(y^t) = \nabla f(x^k).$$

SVRG

- Аппроксиматор в SVRG несмещенный:

$$\mathbb{E}\left[g^k \,\middle|\, x^k\right] = \frac{1}{n}\sum_{i=1}^{n}\nabla f_i(x^k) - \frac{1}{n}\sum_{i=1}^{n}\nabla f_i(y^t) + \nabla f(y^t) = \nabla f(x^k).$$

- Итерационная сложность сходимости метода — $\mathcal{O}\left(\left[n + \frac{L}{\mu}\right]\log\frac{1}{\varepsilon}\right)$ совпадает с SAGA.

SVRG

- Аппроксиматор в SVRG несмещенный:

$$\mathbb{E}\left[g^k \,\middle|\, x^k\right] = \frac{1}{n}\sum_{i=1}^{n}\nabla f_i(x^k) - \frac{1}{n}\sum_{i=1}^{n}\nabla f_i(y^t) + \nabla f(y^t) = \nabla f(x^k).$$

- Итерационная сложность сходимости метода — $\mathcal{O}\left(\left[n + \frac{L}{\mu}\right]\log\frac{1}{\varepsilon}\right)$ совпадает с SAGA.
- Необходимость вычислять полный градиент даже раз в эпоху, а также два стохастических градиента на каждой итерации требует дополнительных вычислительных мощностей.

SARAH

- Алгоритм SVRG эффективен по памяти и при этом не ухудшает теоретическую оценку сходимости SAGA. Однако на практике оказывается, что использование градиента в начальной точке эпохи дестабилизирует траекторию сходимости метода.

SARAH

- Алгоритм SVRG эффективен по памяти и при этом не ухудшает теоретическую оценку сходимости SAGA. Однако на практике оказывается, что использование градиента в начальной точке эпохи дестабилизирует траекторию сходимости метода.
- По этой причине был разработан метод SARAH, конструирующий аппроксиматор таким образом, чтобы использовать градиенты в недавних точках.

SARAH

- Алгоритм SVRG эффективен по памяти и при этом не ухудшает теоретическую оценку сходимости SAGA. Однако на практике оказывается, что использование градиента в начальной точке эпохи дестабилизирует траекторию сходимости метода.
- По этой причине был разработан метод SARAH, конструирующий аппроксиматор таким образом, чтобы использовать градиенты в недавних точках.
- SARAH использует идею рекурсивного накопления градиентов. Такая схема на каждой итерации добавляет к аппроксиматору направление градиента в новой точке, при этом вычитая старое направление. В то время как полный градиент в референсной точке из SVRG мешает сходиться к решению, добавляя вклад старого направления в текущий шаг, SARAH динамично подстраивает траекторию под правильное направление к минимуму.

SARAH

Алгоритм SARAH

Вход: стартовая точка $y^0 \in \mathbb{R}^d$, размеры шагов $\{\gamma_k\}_{k=0} > 0$, количество итераций в эпохе K, количество эпох T

for $t = 0, 1, \ldots, T-1$ **do**
  $x^0 = y^t$
  $x^{-1} = x^0$, $g^{-1} = \nabla f(x^0)$
  for $k = 0, 1, \ldots, K-1$ **do**
    Сгенерировать независимо $i_k \sim U(\overline{1, n})$
    $g^k = \nabla f_{i_k}(x^k) - \nabla f_{i_k}(x^{k-1}) + g^{k-1}$
    $x^{k+1} = x^k - \gamma_k g^k$
  end for
  $y^{t+1} = x^K$
end for

Выход: y^T

SARAH

- Ввиду такой конструкции аппроксиматора, он является смещенным, что усложняет теоретический анализ.

SARAH

- Ввиду такой конструкции аппроксиматора, он является смещенным, что усложняет теоретический анализ.
- SARAH все еще сохраняет идею редукции дисперсии: при $x^k \to x^*$ имеем, что $g^k \to 0$.

SARAH

- Ввиду такой конструкции аппроксиматора, он является смещенным, что усложняет теоретический анализ.
- SARAH все еще сохраняет идею редукции дисперсии: при $x^k \to x^*$ имеем, что $g^k \to 0$.
- SARAH, аналогично SVRG, имеет итерационную сложность $\mathcal{O}\left(\left[n + \frac{L}{\mu}\right] \log \frac{1}{\varepsilon}\right)$, а также требует периодического вычисления полного градиента и подсчета двух стохастических градиентов на каждой итерации. Тем не менее, SARAH решает проблему с нестабильной траекторией сходимости.

Итог

- Методы редукции дисперсии предназначены для стохастических задач вида конечной суммы.

Итог

- Методы редукции дисперсии предназначены для стохастических задач вида конечной суммы.
- Обеспечивают сходимость, как у градиентного спуска:

$$\mathcal{O}\left(\left[n + \frac{L}{\mu}\right] \log \frac{1}{\varepsilon}\right),$$

но итерация в n раз дешевле (считаем не полный градиент, а только 1 слагаемое).

Итог

- Методы редукции дисперсии предназначены для стохастических задач вида конечной суммы.
- Обеспечивают сходимость, как у градиентного спуска:

$$\mathcal{O}\left(\left[n + \frac{L}{\mu}\right] \log \frac{1}{\varepsilon}\right),$$

  но итерация в n раз дешевле (считаем не полный градиент, а только 1 слагаемое).
- Обладают недостатками: траты памяти, подсчет полного градиента.

Итог

- Методы редукции дисперсии предназначены для стохастических задач вида конечной суммы.
- Обеспечивают сходимость, как у градиентного спуска:

$$\mathcal{O}\left(\left[n + \frac{L}{\mu}\right] \log \frac{1}{\varepsilon}\right),$$

  но итерация в n раз дешевле (считаем не полный градиент, а только 1 слагаемое).
- Обладают недостатками: траты памяти, подсчет полного градиента.
- Могут быть ускорены.