

Пример: минимизация функции с вл. гр. нормой

$$\min_{x \in \mathbb{R}^d} f(x) = \frac{1}{n} \sum_{i=1}^n (a_i^T x - b_i)^2$$

$\uparrow \in \mathbb{R}^d$ $\uparrow \in \mathbb{R}$

Блок-схемы
(SGD, SVRG...)

- выбирать $i_k \in [1 \dots n]$
- $g^k = \nabla f_{i_k}(x^k)$
 $= 2a_{i_k} a_{i_k}^T x^k - 2a_{i_k} b_{i_k}$

- повторять за всем блоком в n раз

Блок-схемы
(user)

- выбирать $j_k \in [1 \dots d]$
- $g^k =$ (матрица по $x_{j_k}^k$
 $\uparrow$
непер. коорд.)

$$\begin{aligned} &= [\nabla f(x^k)]_{j_k} \\ &= 2[A^T A]_{j_k} x^k - 2[A^T b]_{j_k} \end{aligned}$$

$\uparrow$ матрица $\uparrow$ коорд

- повторять за всем блоком коорд. в d раз

Координатный спуск

Мотивация:

- в координатном спуске — генерация новых точек
(в обычном спуске не всегда)
- можно избежать перебора

$$\frac{f(x + \tau e) - f(x - \tau e)}{2\tau}$$

$\approx$ производная по направлению e

остаток

как выбрать τ ? τ маленьким, но очень маленьким (миним. возможн.)

как выбрать e ? e — вектор координат

- $e \in N(0; I)$
- $e \in \text{Unif}[\text{евкл. сфере рад. 1}]$

$$\hat{e} \in N(0; I)$$

$$e = \frac{\hat{e}}{\|\hat{e}\|_2} \in \text{Unif}[\text{сфера}]$$

• нейросети — backprop не go wrong

Алгоритм 4 Координатный метод

Вход: размер шага $\gamma > 0$, стартовая точка $x^0 \in \mathbb{R}^d$, значения памяти $y_i^0 = 0$ для всех $i \in [n]$, количество итераций K

- 1: **for** $k = 0, 1, \dots, K - 1$ **do**
- 2: Сгенерировать независимо i_k из $[d]$
- 3: Вычислить $[\nabla f(x^k)]_{i_k}$
- 4: $x^{k+1} = x^k - \gamma \cdot d[\nabla f(x^k)]_{i_k} e_{i_k}$
- 5: **end for**

Выход: x^K

Случайный вектор

нужно для несущей спос. упр.
 невед. нужно

Док-во сходимости:

• f L -гладкая μ -сильно-выпуклая

$$\begin{aligned}
\|x^{k+1} - x^*\|_2^2 &= \|x^k - \gamma d [\nabla f(x^k)]_{i_k} e_{i_k}\|_2^2 \\
&= \|x^k - x^*\|_2^2 \\
&\quad - 2\gamma \langle d [\nabla f(x^k)]_{i_k} e_{i_k}; x^k - x^* \rangle \\
&\quad + \gamma^2 d^2 \underbrace{\| [\nabla f(x^k)]_{i_k} e_{i_k} \|_2^2}_{=1} \\
&\quad \quad \quad \gamma^2 d^2 [\nabla f(x^k)]_{i_k}^2
\end{aligned}$$

$$\mathbb{E} [\|x^k\|]$$

$$\begin{aligned}
\mathbb{E} [\|x^{k+1} - x^*\|_2^2 | x^k] &= \|x^k - x^*\|_2^2 \\
&\quad - 2\gamma \mathbb{E} [\langle d [\nabla f(x^k)]_{i_k} e_{i_k}; x^k - x^* \rangle | x^k] \\
&\quad + \gamma^2 d^2 \mathbb{E} [[\nabla f(x^k)]_{i_k}^2 | x^k]
\end{aligned}$$

convergence proof.

$$\langle d \cdot \mathbb{E} [[\nabla f(x^k)]_{i_k} e_{i_k} | x^k] ; x^k - x^* \rangle =$$

$$\sum_{i=1}^d \underbrace{\frac{1}{d}}_{\mathbb{P}_{\xi_{i_k}=i}} \begin{pmatrix} 0 \\ \vdots \\ [\nabla f]_i \\ \vdots \\ 0 \end{pmatrix} = \frac{1}{d} \sum \begin{pmatrix} 0 \\ \vdots \\ [\nabla f]_i \\ \vdots \\ 0 \end{pmatrix} = \frac{1}{d} \nabla f(x^k)$$

$$= \langle \nabla f(x^k); x^k - x^* \rangle$$

блогини номон

$$\begin{aligned} \mathbb{E}[\|\nabla f(x^k)\|_2^2 | x^k] &= \sum_{i=1}^d \frac{1}{d} [\nabla f(x^k)]_i^2 \\ &= \frac{1}{d} \sum_{i=1}^d [\nabla f(x^k)]_i^2 \\ &= \frac{1}{d} \|\nabla f(x^k)\|_2^2 \end{aligned}$$

Coegunzen

$$\begin{aligned} \mathbb{E}[\|x^{k+1} - x^*\|_2^2 | x^k] &= \|x^k - x^*\|_2^2 \quad (+) \\ &\quad - 2\gamma \langle \nabla f(x^k); x^k - x^* \rangle \quad (+) \\ &\quad + \gamma^2 d \|\nabla f(x^k)\|_2^2 \quad (-) \end{aligned}$$

positive for recovery.

$$\mathbb{E}[\mathbb{E}[x^k]] = \mathbb{E}[x]$$

$$\begin{aligned} \mathbb{E}[\|x^{k+1} - x^*\|_2^2] &= \mathbb{E}[\|x^k - x^*\|_2^2] \\ &\quad - 2\gamma \mathbb{E}[\langle \nabla f(x^k); x^k - x^* \rangle] \\ &\quad + \gamma^2 d \mathbb{E}[\|\nabla f(x^k)\|_2^2] \end{aligned}$$

L - μ -curvature longman

$$\begin{aligned} \mathbb{E}[\|x^{k+1} - x^*\|_2^2] &= (1 - \gamma\mu) \mathbb{E}[\|x^k - x^*\|_2^2] \\ &\quad - 2\gamma \underbrace{(1 - \gamma dL)}_{\text{common} \geq 0} \underbrace{\mathbb{E}[f(x^k) - f(x^*)]}_{\geq 0} \end{aligned}$$

$$\gamma \leq \frac{1}{dL} \quad \text{так меньше}$$

$$\mathbb{E} [\|x^{k+1} - x^*\|_2^2] \leq (1 - \gamma\mu) \mathbb{E} [\|x^k - x^*\|_2^2]$$

Теорема сходимости (координатный метод)

Пусть задача безусловной оптимизации с L -гладкой и μ -сильно выпуклой целевой функцией f решается с помощью координатного метода с $\gamma \leq \frac{1}{dL}$. Тогда справедлива следующая оценка сходимости

$$\mathbb{E} [\|x^k - x^*\|_2^2] \leq (1 - \mu\gamma)^k \mathbb{E} [\|x^0 - x^*\|_2^2]$$

$$\gamma = \frac{1}{dL} \quad \text{и подставить рекуррентно}$$

$$\mathbb{E} [\|x^k - x^*\|_2^2] \leq \left(1 - \frac{\mu}{dL}\right)^k \|x^0 - x^*\|_2^2$$

Какое количество итераций нужно, чтобы $\|x - x^*\|_2 \leq \varepsilon$

$$O\left(\frac{dL}{\mu} \log \frac{\|x^0 - x^*\|_2}{\varepsilon}\right)$$

⊕ итерации зависят от d и μ и L

⊖ количество итераций зависит от d и μ

Пример: $\min_{x \in \mathbb{R}^d} x_1^2 + x_2^2 + \dots + x_d^2$

↑
сложно решить вручную

или можно решить $\frac{L}{\mu} \log \frac{1}{\varepsilon}$

или на d раз $\frac{dL}{\mu} \log \frac{1}{\varepsilon}$

где n — количество итераций:

$$\left(1 + \frac{d}{n}\right) \frac{L}{\mu} \log \frac{1}{\varepsilon}$$