Л1 Методы нулевого порядка и координатный спуск

В этом параграфе рассматриваются методы, направленные на снижение вычислительной стоимости одной итерации градиентного спуска. Сначала обсуждаются координатные методы, далее показывается, что та же идея может быть использована, когда градиент недоступен (zero–order оптимизация). Рассмотрим задачу безусловной оптимизации

$$\min_{x\in\mathbb{R}^d} f(x). \tag{Л1.1}$$

Л1.1 Координатный спуск

Координатные методы — это алгоритмы оптимизации, где на каждой итерации обновляется лишь одна (или несколько) координат вектора параметров, при этом остальные фиксируются. Приведем мотивационный пример с линейной регрессией.

Пример Л1.1. Рассмотрим квадратичную задачу

$$\min_{x\in\mathbb{R}^d} f(x) := \frac{1}{2}\|Ax-b\|_2^2 = \frac{1}{2}\sum_{i=1}^{n}\left(A_{i,:}x-b_i\right)^2 = \frac{1}{2}\sum_{j=1}^{d}\langle A_{:,j}, Ax-b\rangle x_j - \frac{1}{2}\langle b, Ax-b\rangle.$$

где $A\in\mathbb{R}^{n\times d}$ — матрица объект-признак, $A_{i,:}$ — i-ая строка матрицы A, $A_{:,j}$ — j-ый столбец матрицы A, $b\in\mathbb{R}^n$ — метки. Полный градиент в этой задаче имеет вид

$$\nabla f(x) = A^\top(Ax-b) = \sum_{i=1}^{n} A_{i,:}^\top\left(A_{i,:}x-b_i\right) = \sum_{j=1}^{d}\langle A_{:,j}, Ax-b\rangle e_j, \tag{Л1.2}$$

где e_j — j-ый базисный вектор. Рассмотрим два классических подхода к удешевлению стоимости одной итерации вычисления градиентного шага.

1. Стохастический выбор строки (стохастический градиентный спуск по объектам).

   На итерации k равновероятно выбираем объект $i_k = \overline{1,n}$ и формируем оценку градиента как одно слагаемое из суммы (Л1.2):

   $$g^k = nA_{i_k,:}^\top\left(A_{i_k,:}x^k - b_{i_k}\right),$$
   $$x^{k+1} = x^k - \gamma_k g^k.$$

   Этот шаг использует только одну строку матрицы A. Множитель n нужен для несмещенности: $\mathbb{E}\left[g^k\right] = \nabla f(x^k)$. Стоимость одной итерации в n раз дешевле, чем полный градиент, так как выбирается 1 объект из суммы с n слагаемыми.

2. Стохастический выбор столбца (координатный шаг).

   На итерации k равновероятно выбираем координату градиента $j_k = \overline{1,d}$ и формируем оценку градиента как одну координату из вектора (Л1.2):

   $$g^k = d\langle Ax^k - b, A_{:,j_k}\rangle e_{j_k},$$
   $$x^{k+1} = x^k - \gamma_k g^k.$$

   Этот шаг использует только один столбец матрицы A. Множитель d нужен для несмещенности: $\mathbb{E}\left[g^k\right] = \nabla f(x^k)$. Стоимость одной итерации в d раз дешевле, чем полный градиент, так как делается 1 скалярное произведение вместо d.

Таким образом, в квадратичной задаче две симметричные экономии достигаются выбором строк или столбцов, что соответствует домножению каждую итерацию на одну случайную строку или столбец матрицы A соответственно.

В этом параграфе мы сосредоточимся на втором подходе, со стохастическими методами можно ознакомиться в Параграфах **??** и **??**. Перейдём к формальному описанию алгоритма координатного спуска, в котором вместо полного градиента оценивается и используется одна его координата.

Алгоритм Л1.1 Координатный спуск

Вход: стартовая точка $x^0 \in \mathbb{R}^d$, размеры шагов $\{\gamma_k\}_{k=0} > 0$, количество итераций K

1: **for** $k = 0, 1, \ldots, K-1$ **do**
2: Сгенерировать независимо $i_k \sim U(\overline{1,d})$
3: $x^{k+1} = x^k - \gamma_k d\big[\nabla f(x^k)\big]_{i_k} e_{i_k}$
4: **end for**

Выход: x^K

Заметим, что при равномерном выборе координаты стохастический градиент обладает двумя ключевыми свойствами — он остаётся несмещённой оценкой полного градиента и имеет контролируемую дисперсию.

Утверждение Л1.1. Пусть индекс $i_k = \overline{1,d}$ выбирается независимо и равновероятно на каждой итерации. Тогда для любой точки $x \in \mathbb{R}^d$ выполняются равенства:

$$\mathbb{E}\left[d[\nabla f(x)]_{i_k} e_{i_k}\right] = \nabla f(x), \quad \mathbb{E}\left[\left\|d[\nabla f(x)]_{i_k} e_{i_k}\right\|_2^2\right] = d\left\|\nabla f(x)\right\|_2^2.$$

Доказательство. Покажем первое равенство:

$$\mathbb{E}\left[d[\nabla f(x)]_{i_k} e_{i_k}\right] = \sum_{i=1}^{d} \frac{1}{d} d[\nabla f(x)]_i e_i = \nabla f(x).$$

Покажем второе равенство:

$$\mathbb{E}\left[\left\|d[\nabla f(x)]_{i_k} e_{i_k}\right\|_2^2\right] = \sum_{i=1}^{d} \frac{1}{d} d^2 [\nabla f(x)]_i^2 \left\|e_i\right\|_2^2 = d\left\|\nabla f(x)\right\|_2^2.$$

■

Утверждение Л1.1 показывает, что стохастическая координатная оценка градиента $d[\nabla f(x)]_{i_k} e_{i_k}$ несмещена, однако её разброс не является константой: дисперсия масштабируется величиной $\left\|\nabla f(x)\right\|_2^2$. Интуитивная причина проста: мы наблюдаем только одну координату из d и затем восстанавливаем масштаб умножением на d. Опираясь на Утверждение Л1.1, которое гарантирует несмещённость и контролируемую дисперсию стохастической оценки градиента, зафиксируем величину шага и выведем оценку скорости сходимости алгоритма Л1.1.

Теорема Л1.1. Пусть задача безусловной оптимизации (Л1.1) с L–гладкой μ–сильно выпуклой целевой функцией f решается с помощью координатного спус-

ка (Алгоритм Л1.1). Тогда при $\gamma_k = \gamma \le \frac{1}{dL}$ справедлива следующая оценка сходимости:

$$\mathbb{E}\left[\left\|x^k - x^*\right\|_2^2\right] \le (1-\mu\gamma)^k \left\|x^0 - x^*\right\|_2^2.$$

Доказательство. По определению итерации:

$$\left\|x^{k+1} - x^*\right\|_2^2 = \left\|x^k - x^*\right\|_2^2 - 2\gamma\left\langle d\left[\nabla f\left(x^k\right)\right]_{i_k} e_{i_k}, x^k - x^*\right\rangle + \gamma^2 \left\|d\left[\nabla f\left(x^k\right)\right]_{i_k} e_{i_k}\right\|_2^2.$$

Возьмем условное ожидание по случайности на шаге k:

$$\mathbb{E}\left[\left\|x^{k+1} - x^*\right\|_2^2 \,\middle|\, x^k\right] = \left\|x^k - x^*\right\|_2^2 - 2\gamma\left\langle \mathbb{E}\left[d\left[\nabla f\left(x^k\right)\right]_{i_k} e_{i_k} \,\middle|\, x^k\right], x^k - x^*\right\rangle + \gamma^2 \mathbb{E}\left[\left\|d\left[\nabla f\left(x^k\right)\right]_{i_k} e_{i_k}\right\|_2^2 \,\middle|\, x^k\right].$$

Применим Утверждение Л1.1:

$$\mathbb{E}\left[\left\|x^{k+1} - x^*\right\|_2^2 \,\middle|\, x^k\right] \le \left\|x^k - x^*\right\|_2^2 - 2\gamma\left\langle \nabla f\left(x^k\right), x^k - x^*\right\rangle + d\gamma^2 \left\|\nabla f\left(x^k\right)\right\|_2^2.$$

Воспользуемся μ–сильной выпуклостью и L–гладкостью:

$$\mathbb{E}\left[\left\|x^{k+1} - x^*\right\|_2^2 \,\middle|\, x^k\right] \le (1-\mu\gamma)\left\|x^k - x^*\right\|_2^2 - 2\gamma(1 - d\gamma L)\left(f\left(x^k\right) - f^*\right).$$

При $\gamma \le \frac{1}{dL}$ последнее слагаемое отрицательно, и остаётся

$$\mathbb{E}\left[\left\|x^{k+1} - x^*\right\|_2^2 \,\middle|\, x^k\right] \le (1-\mu\gamma)\left\|x^k - x^*\right\|_2^2.$$

Возьмем полное математическое ожидание и раскроем рекурсию:

$$\mathbb{E}\left[\left\|x^k - x^*\right\|_2^2\right] \le (1-\mu\gamma)^k \left\|x^0 - x^*\right\|_2^2.$$

■

Одна координатная итерация примерно в d раз дешевле шага полного градиентного спуска, но обычно требуется порядка в d раз больше итераций. В чистом виде это не улучшает асимптотику, однако на практике координатные методы часто выигрывают по времени до заданной точности за счёт разреженности данных и дешёвых локальных операций по столбцам, неравномерного выбора координат с вероятностями, пропорциональными координатным константам Липшица, а также блочно-координатных, параллельных и асинхронных обновлений, эффективно использующих современную вычислительную архитектуру. В неквадратичных задачах вычислить одну координату градиента не всегда дешевле, чем полный градиент. Чтобы получить $\left[\nabla f(x)\right]_i$, нередко требуется выполнить почти всю вычислительную цепочку и лишь затем извлечь i-ую компоненту. Поэтому координатный шаг не всегда экономит ресурсы. Характерный неблагоприятный пример — логистическая регрессия: градиент есть сумма по всем объектам, и для любой координаты нужен полный проход по данным. Фактически стоимость одной координаты совпадает со стоимостью полного градиента. В то же время при обучении нейронных сетей ситуация благоприятнее из-за структуры обратного распространения ошибки: градиенты считаются от последнего слоя к первому, и, если обновлять только слой i, можно не вычислять градиенты для слоёв $1, \dots, i-1$. Это уменьшает объём обратных вычислений и снижает пиковые требования к памяти, что даёт реальное ускорение и экономию ресурсов при координатных или

блочно-координатных обновлениях по слоям. Когда прямой градиент недоступен или слишком дорог, координатная логика получает «вторую жизнь», переходя к оценкам направленных производных по случайным направлениям, мы естественно приходим к методам нулевого порядка (ZO), где двухточечные разности выступают оценками градиента.

Л1.2 Координатные идеи в безградиентной постановке

В оптимизации нулевого порядка алгоритм взаимодействует с целевой функцией через её значение. Отсутствие доступа к градиенту вынуждает заменять его на аппроксимацию по значениям функции, что естественным образом сочетается с координатными идеями — можно оценивать лишь нужные координатные направления и выполнять дешёвые обновления. Ключевой приём — аппроксимация направленной производной по значениям функции вдоль направления $e \in \mathbb{R}^d$. Рассмотрим три стандартные схемы.

$$g(x,e) = \begin{cases} d\frac{f(x+\tau e)-f(x-\tau e)}{2\tau}e & \text{(двухточечная симметричная)} \\ \frac{f(x+\tau e)-f(x)}{\tau}e & \text{(двухточечная односторонняя)} \\ \frac{f(x+\tau e)}{\tau}e & \text{(одноточечная),} \end{cases} \tag{Л1.3}$$

где $\tau > 0$ — *параметр сглаживания.* Двухточечная симметричная схема имеет наименьшее смещение. Двухточечная односторонняя схема используется, когда $f(x)$ уже было посчитано. Одноточечная схема наиболее дешёвая по вычислениям, но обладает большим смещением. Множитель d в (Л1.3) появляется по той же причине, что и в координатных методах: усреднение по случайно выбранному направлению «размазывает» вклад по d осям, и чтобы восстановить исходный масштаб градиента, требуется умножение на d. Перейдём к самой интересной части формулы (Л1.3) — выбору направления e, по которому мы будем оптимизировать целевую функцию. Координатный базис $e = e_i$ воспроизводит покоординатный шаг, но охватывает лишь одну компоненту за вызов оракула. Лучше сразу смотреть на все координаты через случайные направления. Самый простой вариант — брать $e \sim \mathcal{N}(0, I_d)$ — такая выборка случайно смешивает все координаты в каждом направлении и в среднем захватывает всю структуру. Ещё лучше выбирать e равномерно на сфере $S^{d-1} := \{\, e \in \mathbb{R}^d \mid \|e\|_2 = 1 \,\}$: все направления имеют одинаковую норму, что стабилизирует шаги и улучшает оценки, при этом мы также охватываем все координаты.

У читателя мог возникнуть вопрос: почему в (Л1.3) не устремить $\tau \to 0$ и не получить градиент по определению? В оптимизации нулевого порядка это невозможно из-за доминирующей роли ошибок оракула: на запрос точки возвращается не истинное значение, а зашумлённая величина $\hat{f}$. В оптимизации первого порядка шум также присутствует, однако его влияние обычно существенно слабее, поскольку градиент сглаживает часть вариативности. Исходя из этих соображений, в формуле (Л1.3) следует везде заменить f на $\hat{f}$. Для двухточечной симметричной оценки:

$$g(x,e) = d\frac{\hat{f}(x+\tau e) - \hat{f}(x-\tau e)}{2\tau}e.$$

Л1.2.1 Гладкий μ–сильно выпуклый случай

Подобно координатной оценке первого порядка, двухточечная схема $g(x,e)$ служит стохастической заменой градиента. Ниже формализуем её несмещённость, характер погрешности, а также оценку второго момента.

Утверждение Л1.2. Пусть дана L–гладкая функция $f : \mathbb{R}^d \to \mathbb{R}$ и пусть $\hat{f}(x) =$

$f(x) + \xi(x)$, где $|\xi(x)| \le \Delta$ для всех $x \in \mathbb{R}^d$. Определим оценку градиента

$$g(x, e) = d\frac{\hat{f}(x + \tau e) - \hat{f}(x - \tau e)}{2\tau} e, \quad e \sim U\big(S^{d-1}\big).$$

Тогда для любого $x \in \mathbb{R}^d$ справедливы оценки:

1. $\big\|\mathbb{E}_{e\sim U(S^{d-1})}[g(x, e)] - \nabla f(x)\big\|_2 \le L\tau + \frac{d\Delta}{\tau}$,
2. $\mathbb{E}_{e\sim U(S^{d-1})}\big\|g(x, e)\big\|_2^2 = 4d\big\|\nabla f(x)\big\|_2^2 + 4L^2d^2\tau^2 + 2\frac{d^2\Delta^2}{\tau^2}$.

Доказательство. Разложим оценку на две части $g(x, e) = g^{\text{det}} + g^{\text{noise}}$:

$$g^{\text{det}} = d\frac{f(x + \tau e) - f(x - \tau e)}{2\tau} e, \quad g^{\text{noise}} = d\frac{\xi(x + \tau e) - \xi(x - \tau e)}{2\tau} e.$$

1. Для шумовой составляющей имеем:

$$\Big\|\mathbb{E}\left[g^{\text{noise}}\right]\Big\|_2 = \frac{d}{2\tau}\big\|\mathbb{E}\left[(\xi(x + \tau e) - \xi(x - \tau e))e\right]\big\|_2 \le \frac{d}{2\tau} \cdot 2\Delta \cdot \mathbb{E}\left[\big\|e\big\|_2\right] = \frac{d\Delta}{\tau}.$$

Рассмотрим детерминированную часть, представим симметричную разность в форме интеграла:

$$g^{\text{det}} = d\frac{f(x + \tau e) - f(x - \tau e)}{2\tau} e = de\int_{-1}^{1} \frac{1}{2}\big\langle \nabla f(x + t\tau e), e\big\rangle \,\mathrm{d}t\,.$$

Перейдём к математическому ожиданию по равномерному e, воспользуемся тем, что $\mathbb{E}\left[ee^\top\right] = \frac{1}{d} I_d$:

$$\mathbb{E}\left[g^{\text{det}}\right] = d\mathbb{E}\left[\frac{f(x + \tau e) - f(x - \tau e)}{2\tau} e\right] = \mathbb{E}\left[\nabla f(x + t\tau e)\right].$$

Тогда имеем:

$$\begin{aligned}\Big\|\mathbb{E}\left[g^{\text{det}}\right] - \nabla f(x)\Big\|_2 &= \big\|\mathbb{E}\left[\nabla f(x + t\tau e)\right] - \mathbb{E}\left[\nabla f(x)\right]\big\|_2 \\ &= \big\|\mathbb{E}\left[\nabla f(x + t\tau e) - \nabla f(x)\right]\big\|_2 \\ &\le \mathbb{E}\left[\big\|\nabla f(x + t\tau e) - \nabla f(x)\big\|_2\right] \\ &\le L\tau\big\|e\big\|_2 = L\tau.\end{aligned}$$

Воспользуемся неравенством треугольника:

$$\big\|\mathbb{E}\left[g(x, e)\right] - \nabla f(x)\big\|_2 \le \Big\|\mathbb{E}\left[g^{\text{det}}\right] - \nabla f(x)\Big\|_2 + \Big\|\mathbb{E}\left[g^{\text{noise}}\right]\Big\|_2 \le L\tau + \frac{d\Delta}{\tau}.$$

2. Для шумовой составляющей имеем:

$$\mathbb{E}\left[\big\|g^{\text{noise}}\big\|_2^2\right] = \frac{d^2}{4\tau^2}\mathbb{E}\left[\big\|(\xi(x + \tau e) - \xi(x - \tau e))e\big\|_2^2\right] \le \frac{d^2}{4\tau^2} \cdot 4\Delta^2 \cdot \mathbb{E}\left[\big\|e\big\|_2^2\right] = \frac{d^2\Delta^2}{\tau^2}.$$

Посмотрим на детерминированную часть, добавим умный ноль $\pm\langle\nabla f(x), e\rangle e$:

$$\mathbb{E}\left[\left\|g^{\text{det}}(x,e)\right\|_2^2\right] = d^2\mathbb{E}\left[\left\|\frac{f(x+\tau e)-f(x-\tau e)}{2\tau}e + \langle\nabla f(x),e\rangle e - \langle\nabla f(x),e\rangle e\right\|_2^2\right].$$

Воспользуемся тем, что $\|a+b\|_2^2 \le 2\|a\|_2^2 + 2\|b\|_2^2$:

$$\begin{aligned}\mathbb{E}\left[\left\|g^{\text{det}}(x,e)\right\|_2^2\right] &\le 2d^2\mathbb{E}\left[\left|\langle\nabla f(x),e\rangle\right|^2\right] \\ &\quad + \frac{d^2}{2\tau^2}\mathbb{E}\left[\left|f(x+\tau e)-f(x-\tau e)-\langle\nabla f(x),2\tau e\rangle\right|^2\right].\end{aligned}$$

Воспользуемся изотропией равномерного направления на сфере и Теоремой **??**:

$$\mathbb{E}\left[\left\|g^{\text{det}}(x,e)\right\|_2^2\right] \le 2d\left\|\nabla f(x)\right\|_2^2 + 2L^2d^2\tau^2.$$

Получим итоговую оценку:

$$\begin{aligned}\mathbb{E}\left[\left\|g(x,e)\right\|_2^2\right] = \mathbb{E}\left[\left\|g^{\text{det}}+g^{\text{noise}}\right\|_2^2\right] &\le 2\mathbb{E}\left[\left\|g^{\text{det}}\right\|_2^2\right] + 2\mathbb{E}\left[\left\|g^{\text{noise}}\right\|_2^2\right] \\ &\le 4d\left\|\nabla f(x)\right\|_2^2 + 4L^2d^2\tau^2 + 2\frac{d^2\Delta^2}{\tau^2}.\end{aligned}$$

■

Используя двухточечную оценку градиента из Утверждения Л1.2, построим базовый стохастический метод нулевого порядка.

Алгоритм Л1.2 ZO–GD с двухточечной оценкой

Вход: стартовая точка $x^0 \in \mathbb{R}^d$, размеры шагов $\{\gamma_k\}_{k=0} > 0$, параметр сглаживания $\tau > 0$, количество итераций K

1: **for** $k = 0, 1, \ldots, K-1$ **do**
2: Сгенерировать независимо $e_k \sim U\left(S^{d-1}\right)$
3: $g^k = d\frac{\hat{f}\left(x^k+\tau e_k\right)-\hat{f}\left(x^k-\tau e_k\right)}{2\tau}e_k$
4: $x^{k+1} = x^k - \gamma_k g^k$
5: **end for**

Выход: x^K

Утверждение Л1.2 даёт контролируемую оценку второго момента, в которой естественным образом появляются параметр сглаживания τ и уровень шумовой погрешности оракула Δ. Это позволяет сформулировать и проанализировать базовый алгоритм нулевого порядка.

Теорема Л1.2. Пусть задача безусловной оптимизации (Л1.1) с L–гладкой μ–сильно выпуклой целевой функцией f решается с помощью градиентного спуска нулевого порядка (Алгоритм Л1.2). Тогда при $\gamma_k = \gamma \le \frac{1}{8dL}$ справедлива следующая оценка сходимости:

$$\mathbb{E}\left[\left\|x^k - x^*\right\|_2^2\right] \le \left(1-\frac{\mu\gamma}{2}\right)^k\left\|x^0-x^*\right\|_2^2 + \frac{4}{\mu}\left(L^2\tau^2\left(2\gamma d^2+\frac{1}{\mu}\right)+\frac{2d^2\Delta^2}{\mu\tau^2}\right).$$

Доказательство. Распишем итерацию:

$$\|x^{k+1} - x^*\|_2^2 = \|x^k - x^*\|_2^2 - 2\gamma\langle g^k, x^k - x^*\rangle + \gamma^2\|g^k\|_2^2.$$

Возьмем условное ожидание по случайности на шаге k:

$$\begin{aligned}\mathbb{E}\left[\|x^{k+1} - x^*\|_2^2 \,\middle|\, x^k\right] &= \|x^k - x^*\|_2^2 - 2\gamma\left\langle \mathbb{E}\left[g^k \,\middle|\, x^k\right], x^k - x^*\right\rangle \\ &\quad + \gamma^2\mathbb{E}\left[\|g^k\|_2^2 \,\middle|\, x^k\right] \\ &= \|x^k - x^*\|_2^2 - 2\gamma\langle \nabla f(x^k), x^k - x^*\rangle \\ &\quad + 2\gamma\left\langle \nabla f(x^k) - \mathbb{E}\left[g^k \,\middle|\, x^k\right], x^k - x^*\right\rangle + \gamma^2\mathbb{E}\left[\|g^k\|_2^2 \,\middle|\, x^k\right].\end{aligned}$$

Воспользуемся неравенством Юнга:

$$\begin{aligned}\mathbb{E}\left[\|x^{k+1} - x^*\|_2^2 \,\middle|\, x^k\right] &= \|x^k - x^*\|_2^2 - 2\gamma\langle \nabla f(x^k), x^k - x^*\rangle \\ &\quad + \frac{2\gamma}{\mu}\left\|\mathbb{E}\left[g^k \,\middle|\, x^k\right] - \nabla f(x^k)\right\|_2^2 + \frac{\mu\gamma}{2}\|x^k - x^*\|_2^2 \\ &\quad + \gamma^2\mathbb{E}\left[\|g^k\|_2^2 \,\middle|\, x^k\right].\end{aligned}$$

Воспользуемся Утверждением Л1.2:

$$\begin{aligned}\mathbb{E}\left[\|x^{k+1} - x^*\|_2^2 \,\middle|\, x^k\right] &\le \left(1 + \frac{\mu\gamma}{2}\right)\|x^k - x^*\|_2^2 - 2\gamma\langle \nabla f(x^k), x^k - x^*\rangle \\ &\quad + \frac{2\gamma}{\mu}\left(L^2\tau^2 + \frac{d^2\Delta^2}{\tau^2}\right) \\ &\quad + \gamma^2\left(4d\|\nabla f(x^k)\|_2^2 + 4L^2d^2\tau^2 + 2\frac{d^2\Delta^2}{\tau^2}\right).\end{aligned}$$

Воспользуемся μ–сильной выпуклостью и L–гладкостью:

$$\begin{aligned}\mathbb{E}\left[\|x^{k+1} - x^*\|_2^2 \,\middle|\, x^k\right] &\le \left(1 - \frac{\mu\gamma}{2}\right)\|x^k - x^*\|_2^2 - 2\gamma(1 - 4d\gamma L)\left(f(x^k) - f^*\right) \\ &\quad + 2\gamma\left(L^2\tau^2\left(2\gamma d^2 + \frac{1}{\mu}\right) + \frac{d^2\Delta^2}{\tau^2}\left(\gamma + \frac{1}{\mu}\right)\right).\end{aligned}$$

Выбирая $\gamma \le \frac{1}{8dL}$, получаем:

$$\mathbb{E}\left[\|x^{k+1} - x^*\|_2^2 \,\middle|\, x^k\right] \le \left(1 - \frac{\mu\gamma}{2}\right)\|x^k - x^*\|_2^2 + 2\gamma\left(2L^2\tau^2\left(\gamma d^2 + \frac{1}{\mu}\right) + \frac{2d^2\Delta^2}{\mu\tau^2}\right).$$

Возьмем полное математическое ожидание и раскроем рекурсию:

$$\mathbb{E}\left[\|x^k - x^*\|_2^2\right] \le \left(1 - \frac{\mu\gamma}{2}\right)^k\|x^0 - x^*\|_2^2 + \frac{4}{\mu}\left(L^2\tau^2\left(2\gamma d^2 + \frac{1}{\mu}\right) + \frac{2d^2\Delta^2}{\mu\tau^2}\right).$$

■

Появление τ отражает баланс смещения/дисперсии: уменьшение τ снижает смещение, но повышает вариативность из-за деления на τ в двухточечной формуле. Наоборот, увеличение τ уменьшает дисперсию, но усиливает сглаживающее смещение. В отсутствие шума оптимальной оказывается $\tau = 0$, при наличии шума целесообразно фиксировать τ близкой к балансу $\tau^* \sim \sqrt{\Delta d/L}$.

Л1.2.2 Негладкий выпуклый случай

В отличие от рассмотренного ранее гладкого μ–сильно выпуклого случая, теперь мы не предполагаем L–Липшицевость, а работаем с M–Липшицевой выпуклой функцией:

$$\big|f(x) - f(y)\big| \leq M\big\|x - y\big\|_2.$$

Дополнительно мы полагаем отсутствие шума оракула значений, то есть $\Delta = 0$, чтобы не перегружать изложение сложными балансами смещения/дисперсии и сосредоточиться на ключевой идее сферического сглаживания и базовой конвергенции ZO–методов. Случай $\Delta > 0$ приводит лишь к стандартной шумовой добавке в итоговых оценках и разбирается аналогично. В этом разделе ключевым понятием является сферически сглаженная функция f_τ, которая позволит нам перенести технику анализа методов первого порядка в настройках нулевого порядка.

Определение Л1.1. Пусть $f : \mathbb{R}^d \to \mathbb{R}$ — выпуклая функция. Будем называть *сглаженной* функцией функцию

$$f_\tau(x) = \mathbb{E}_{e\sim U(S^{d-1})}\big[f(x + \tau e)\big].$$

Формально, Определение Л1.1 представляет собой сферическое усреднение значения f по равномерному направлению на сфере радиуса τ, в результате чего f_τ становится дифференцируемой, а её градиент естественным образом согласуется с двухточечной ZO–оценкой. Формальные свойства функции $f_\tau(x)$ изложены в следующем утверждении.

Утверждение Л1.3. Для M–Липшицевой выпуклой функции $f : \mathbb{R}^d \to \mathbb{R}$ выполняется:

1. f_τ дифференцируема и
$$\nabla f_\tau(x) = \mathbb{E}_{e\sim U(S^{d-1})}\left[d\frac{f(x + \tau e) - f(x - \tau e)}{2\tau}e\right];$$
2. f_τ выпукла и
$$0 \leq f_\tau(x) - f(x) \leq \tau M;$$
3. Градиент $f_\tau(x)$ ограничен:
$$\big\|\nabla f_\tau(x)\big\|_2 \leq dM.$$

Доказательство.

1. Рассмотрим приращение:
$$f_\tau(x + th) - f_\tau(x) = \mathbb{E}_e\big[f(x + th + \tau e) - f(x + \tau e)\big].$$
Поделим на t и рассмотрим предел:
$$\lim_{t\to 0}\frac{f_\tau(x + th) - f_\tau(x)}{t} = \mathbb{E}\left[\lim_{t\to 0}\frac{f(x + th + \tau e) - f(x + \tau e)}{t}\right] = \big\langle\mathbb{E}\left[\nabla f(x + \tau e)\right], h\big\rangle.$$

Заметим, что для любого $t \in [-1, 1]$:

$$\mathbb{E}\left[\nabla f(x + \tau e)\right] = \mathbb{E}\left[\nabla f(x + t\tau e)\right].$$

А в Теореме Л1.2 мы получили, что

$$\mathbb{E}\left[\nabla f(x + t\tau e)\right] = \mathbb{E}\left[d\frac{f(x + \tau e) - f(x - \tau e)}{2\tau}e\right].$$

Таким образом получили требуемое.

2. Выпуклость f_τ следует из выпуклости f. Для доказательства второго факта воспользуемся выпуклостью f:

$$f(x) \leq f(x + \tau e) + \big\langle \nabla f(x), x - (x + \tau e)\big\rangle = f(x + \tau e) - \tau\big\langle \nabla f(x), e\big\rangle.$$

Возьмем математическое ожидание и используем симметрию распределения:

$$f(x) \leq \mathbb{E}\left[f(x + \tau e)\right] = f_\tau(x),$$

то есть $f_\tau(x) - f(x) \geq 0$. Для верхней оценки используем M–Липшицевость f:

$$f(x + \tau e) - f(x) \leq M\big\|\tau e\big\|_2 = M\tau.$$

Усредняя по e, получим $f_\tau(x) - f(x) \leq \tau M$.

3. Из первого пункта имеем

$$\nabla f_\tau(x) = \mathbb{E}\left[d\frac{f(x + \tau e) - f(x - \tau e)}{2\tau}e\right].$$

Воспользуемся M–Липшицевостью f:

$$\begin{aligned}\big\|\nabla f_\tau(x)\big\|_2 &\leq \mathbb{E}\left[d\frac{|f(x + \tau e) - f(x - \tau e)|}{2\tau}\big\|e\big\|_2\right] \\ &\leq \mathbb{E}\left[d\frac{M\big\|(x + \tau e) - (x - \tau e)\big\|_2}{2\tau}\right] = dM.\end{aligned}$$

■

Утверждение Л1.3 формализует, что сферическое сглаживание делает целевую функцию «хорошей» в аналитическом и алгоритмическом смысле даже тогда, когда исходная f может быть негладкой.

Утверждение Л1.4. Пусть дана M–Липшицева функция $f : \mathbb{R}^d \to \mathbb{R}$. Определим оценку градиента

$$g(x, e) = d\frac{f(x + \tau e) - f(x - \tau e)}{2\tau}e, \quad e \sim U\big(S^{d-1}\big).$$

Тогда для любого $x \in \mathbb{R}^d$ справедливо:

1. $\mathbb{E}_{e\sim U(S^{d-1})}[g(x, e)] = \nabla f_\tau(x)$,
2. $\mathbb{E}_{e\sim U(S^{d-1})}\big\|g(x, e)\big\|_2^2 \leq d^2M^2$.

Доказательство.

1. Следует из первого пункта Утверждения Л1.3.

2. Воспользуемся M–Липшицевостью:

$$\mathbb{E}\left[\left\|g(x,e)\right\|_2^2\right] = \frac{d^2}{4\tau^2}\mathbb{E}\left[|f(x+\tau e) - f(x-\tau e)|^2\right] \leq d^2M^2.$$

■

Покажем сходимость Алгоритма Л1.2 для выпуклой негладкой f.

Теорема Л1.3. Пусть задача безусловной оптимизации (Л1.1) с M–Липшицевой выпуклой целевой функцией f решается с помощью градиентного спуска нулевого порядка (Алгоритм Л1.2). Тогда при

$$\gamma_k = \gamma \leq \frac{\left\|x^0 - x^*\right\|_2}{dM\sqrt{K}}$$

справедлива следующая оценка сходимости:

$$\mathbb{E}\left[f\left(\frac{1}{K}\sum_{k=0}^{K-1} x^k\right) - f^*\right] \leq \frac{dM\|x^0 - x^*\|_2}{\sqrt{K}} + \tau M.$$

В частности, при выборе

$$\tau \leq \frac{d\left\|x^0 - x^*\right\|_2}{\sqrt{K}}$$

имеем

$$\mathbb{E}\left[f\left(\frac{1}{K}\sum_{k=0}^{K-1} x^k\right) - f^*\right] \leq \frac{dM\|x^0 - x^*\|_2}{\sqrt{K}}.$$

Доказательство. Распишем итерацию:

$$\left\|x^{k+1} - x^*\right\|_2^2 = \left\|x^k - x^*\right\|_2^2 - 2\gamma\langle g^k, x^k - x^*\rangle + \gamma^2\left\|g^k\right\|_2^2.$$

Возьмем условное математическое ожидание:

$$\mathbb{E}\left[\left\|x^{k+1} - x^*\right\|_2^2 \middle| x^k\right] = \left\|x^k - x^*\right\|_2^2 - 2\gamma\langle\nabla f_\tau(x^k), x^k - x^*\rangle + \gamma^2\mathbb{E}\left[\left\|g^k\right\|_2^2 \middle| x^k\right].$$

Запишем выпуклость f_τ:

$$\langle\nabla f_\tau(x^k), x^k - x^*\rangle \geq f_\tau(x^k) - f_\tau(x^*)$$

и, используя результат Утверждения Л1.4, получим:

$$\mathbb{E}\left[\left\|x^{k+1} - x^*\right\|_2^2 \middle| x^k\right] \leq \left\|x^k - x^*\right\|_2^2 - 2\gamma\left(f_\tau(x^k) - f_\tau(x^*)\right) + \gamma^2 d^2M^2.$$

Перейдем к полному математическому ожиданию и раскроем рекурсию:

$$\mathbb{E}\left[\left\|x^K - x^*\right\|_2^2\right] \leq \left\|x^0 - x^*\right\|_2^2 - 2\gamma\sum_{k=0}^{K-1}\mathbb{E}\left[f_\tau(x^k) - f_\tau(x^*)\right] + K\gamma^2 d^2M^2.$$

Отбросим неотрицательный левый член и поделим на $2\gamma K$:

$$\frac{1}{K}\sum_{k=0}^{K-1}\mathbb{E}\left[f_\tau\left(x^k\right)-f_\tau\left(x^*\right)\right]\leq\frac{\left\|x^0-x^*\right\|_2^2}{2\gamma K}+\frac{\gamma d^2M^2}{2}.$$

Воспользуемся выпуклостью f_τ:

$$\mathbb{E}\left[f_\tau\left(\frac{1}{K}\sum_{k=0}^{K-1}x^k\right)-f_\tau\left(x^*\right)\right]\leq\frac{\left\|x^0-x^*\right\|_2^2}{2\gamma K}+\frac{\gamma d^2M^2}{2}.$$

Минимизируя правую часть по γ, получаем, что

$$\gamma=\frac{\left\|x^0-x^*\right\|_2}{dM\sqrt{K}}.$$

Тогда

$$\mathbb{E}\left[f_\tau\left(\frac{1}{K}\sum_{k=0}^{K-1}x^k\right)-f_\tau\left(x^*\right)\right]\leq\frac{dM\left\|x^0-x^*\right\|_2}{\sqrt{K}}.$$

Пользуясь тем, что $0\leq f_\tau(x)-f(x)\leq\tau M$,

$$\begin{aligned}\mathbb{E}\left[f\left(\frac{1}{K}\sum_{k=0}^{K-1}x^k\right)-f\left(x^*\right)\right]&\leq\mathbb{E}\left[f_\tau\left(\frac{1}{K}\sum_{k=0}^{K-1}x^k\right)-f_\tau\left(x^*\right)\right]+\tau M\\&\leq\frac{dM\left\|x^0-x^*\right\|_2}{\sqrt{K}}+\tau M.\end{aligned}$$

При выборе $\tau\leq\frac{d\left\|x^0-x^*\right\|_2}{\sqrt{K}}$ получаем

$$\mathbb{E}\left[f\left(\frac{1}{K}\sum_{k=0}^{K-1}x^k\right)-f\left(x^*\right)\right]\leq\frac{2dM\left\|x^0-x^*\right\|_2}{\sqrt{K}}.$$

■

Л1.2.3 Ключевые работы

Методы оптимизации нулевого порядка для дообучения больших языковых моделей представляют собой активно развивающуюся область исследований. Ниже представлены ключевые работы, которые расширяют и углубляют понимание данного направления.

- MeZO (Memory–efficient Zeroth–Order) представляет собой основополагающую работу в области применения методов нулевого порядка для дообучения LLM. Авторы адаптируют классический ZO-SGD для работы in-place, обеспечивая дообучение моделей с тем же объемом памяти, что и инференс, достигая при этом производительности, сопоставимой с методами первого порядка при снижении потребления памяти до 12 раз.

- LeZO (Layer–wise Zeroth–Order) вводит послойную разреженную вычислительную стратегию для ZO–оптимизации, обрабатывая слои как фундаментальные единицы разреживания. Метод динамически возмущает различные подмножества параметров на каждом шаге, достигая ускорения более чем в 3 раза по сравнению с MeZO на задачах классификации без дополнительных накладных расходов на память.

- ZO–AdaMU предлагает оригинальное решение проблем осцилляций и вычислительных издержек в MeZO путем адаптации возмущений с моментумом в стохастической аппроксимации градиента. В отличие от существующих адаптивных методов моментума, алгоритм перемещает моментум на симулируемое возмущение в стохастической аппроксимации градиента, что теоретически и эмпирически доказано как более эффективный способ улучшения стабильности и скорости сходимости в ZO-SGD для дообучения LLM.

- HiZOO (Hessian–informed Zeroth–Order Optimizer) впервые интегрирует информацию о диагональном гессиане в оптимизацию нулевого порядка для дообучения LLM. Данный подход решает проблему гетерогенных кривизн в различных размерностях параметров, обеспечивая существенное ускорение сходимости при сохранении преимуществ в потреблении памяти.

- LOZO (Low–rank Zeroth–Order) предлагает новый подход к оценке градиентов нулевого порядка через использование низкоранговых структур. Метод эффективно захватывает низкоранговую структуру градиентов, характерную для дообучения LLM, что позволяет значительно улучшить сходимость по сравнению с существующими ZO–методами, приближаясь к производительности алгоритмов первого порядка.

- MeZO-SVRG интегрирует техники редукции дисперсии в ZO–оптимизацию для повышения стабильности и скорости сходимости при дообучении на основе инференса. Метод превосходит MeZO на 20% по точности тестирования при двукратном снижении времени GPU–часов, существенно уменьшая требования к памяти по сравнению со стохастическим градиентным спуском первого порядка.

- JAGUAR SignSGD / Muon представляют первые методы ZO–оптимизации с гарантиями сходимости для алгоритмов SignSGD и Muon в стохастическом невыпуклом случае. Подходы используют JAGUAR–аппроксимацию градиента и координатный моментум, требуя лишь $\mathcal{O}(1)$ вычислений оракула за итерацию и демонстрируя конкурентную производительность с методами первого порядка при значительной экономии памяти.

Список литературы