Координатный спуск

Методы оптимизации

Александр Безносиков

Московский физико-технический институт

10 декабря 2026



Пример

Рассмотрим квадратичную задачу

$$\min_{x \in \mathbb{R}^d} f(x) := \frac{1}{2}\|Ax - b\|_2^2 = \frac{1}{2}\sum_{i=1}^{n}\left(A_{i,:}x - b_i\right)^2$$

$$= \frac{1}{2}\sum_{j=1}^{d}\langle A_{:,j}, Ax - b\rangle x_j - \frac{1}{2}\langle b, Ax - b\rangle,$$

где $A \in \mathbb{R}^{n \times d}$ — матрица объект-признак, $A_{i,:}$ — i-я строка матрицы A, $A_{:,j}$ — j-й столбец матрицы A, $b \in \mathbb{R}^n$ — метки.

Пример

Рассмотрим квадратичную задачу

$$\min_{x \in \mathbb{R}^d} f(x) := \frac{1}{2}\|Ax - b\|_2^2 = \frac{1}{2}\sum_{i=1}^{n}\left(A_{i,:}x - b_i\right)^2$$

$$= \frac{1}{2}\sum_{j=1}^{d}\left\langle A_{:,j}, Ax - b\right\rangle x_j - \frac{1}{2}\left\langle b, Ax - b\right\rangle,$$

где $A \in \mathbb{R}^{n \times d}$ — матрица объект-признак, $A_{i,:}$ — i-я строка матрицы A, $A_{:,j}$ — j-й столбец матрицы A, $b \in \mathbb{R}^n$ — метки.
Полный градиент в этой задаче имеет вид

$$\nabla f(x) = A^\top(Ax - b) = \sum_{i=1}^{n} A_{i,:}^\top\left(A_{i,:}x - b_i\right) = \sum_{j=1}^{d}\left\langle A_{:,j}, Ax - b\right\rangle e_j,$$

где e_j — j-й базисный вектор.

Стохастический выбор строки

- На итерации k равновероятно выбираем объект $i_k \in \overline{1, n}$ и формируем оценку градиента как одно слагаемое из суммы:

$$g^k = nA_{i_k,:}^\top \left(A_{i_k,:}x^k - b_{i_k}\right),$$
$$x^{k+1} = x^k - \gamma_k g^k.$$

Стохастический выбор строки

- На итерации k равновероятно выбираем объект $i_k \in \overline{1, n}$ и формируем оценку градиента как одно слагаемое из суммы:

$$g^k = nA_{i_k,:}^\top \left(A_{i_k,:}x^k - b_{i_k}\right),$$
$$x^{k+1} = x^k - \gamma_k g^k.$$

- Этот шаг использует только одну строку матрицы A.

Стохастический выбор строки

- На итерации k равновероятно выбираем объект $i_k \in \overline{1, n}$ и формируем оценку градиента как одно слагаемое из суммы:

$$g^k = nA_{i_k,:}^\top \left(A_{i_k,:}x^k - b_{i_k}\right),$$
$$x^{k+1} = x^k - \gamma_k g^k.$$

- Этот шаг использует только одну строку матрицы A.
- Множитель n нужен для несмещенности: $\mathbb{E}\left[g^k \,\middle|\, x^k\right] = \nabla f\left(x^k\right)$.

Стохастический выбор строки

- На итерации k равновероятно выбираем объект $i_k \in \overline{1, n}$ и формируем оценку градиента как одно слагаемое из суммы:

$$g^k = nA_{i_k,:}^\top \left(A_{i_k,:}x^k - b_{i_k}\right),$$
$$x^{k+1} = x^k - \gamma_k g^k.$$

- Этот шаг использует только одну строку матрицы A.
- Множитель n нужен для несмещенности: $\mathbb{E}\left[g^k \,\middle|\, x^k\right] = \nabla f\left(x^k\right)$.
- Одна итерация в n раз дешевле подсчёта полного градиента, так как выбирается 1 объект из суммы с n слагаемыми.

Стохастический выбор столбца

- На итерации k равновероятно выбираем координату градиента $i_k \in \overline{1, d}$ и формируем оценку градиента как одну координату из вектора:

$$g^k = d\left\langle Ax^k - b, A_{:,i_k}\right\rangle e_{i_k},$$
$$x^{k+1} = x^k - \gamma_k g^k.$$

Стохастический выбор столбца

- На итерации k равновероятно выбираем координату градиента $i_k \in \overline{1, d}$ и формируем оценку градиента как одну координату из вектора:

$$g^k = d\left\langle Ax^k - b, A_{:,i_k}\right\rangle e_{i_k},$$
$$x^{k+1} = x^k - \gamma_k g^k.$$

- Этот шаг использует только один столбец матрицы A.

Стохастический выбор столбца

- На итерации k равновероятно выбираем координату градиента $i_k \in \overline{1, d}$ и формируем оценку градиента как одну координату из вектора:

$$g^k = d\left\langle Ax^k - b, A_{:,i_k}\right\rangle e_{i_k},$$
$$x^{k+1} = x^k - \gamma_k g^k.$$

- Этот шаг использует только один столбец матрицы A.
- Множитель d нужен для несмещенности: $\mathbb{E}\left[g^k \,\middle|\, x^k\right] = \nabla f\left(x^k\right)$.

Стохастический выбор столбца

- На итерации k равновероятно выбираем координату градиента $i_k \in \overline{1, d}$ и формируем оценку градиента как одну координату из вектора:

$$g^k = d\left\langle Ax^k - b, A_{:,i_k}\right\rangle e_{i_k},$$
$$x^{k+1} = x^k - \gamma_k g^k.$$

- Этот шаг использует только один столбец матрицы A.
- Множитель d нужен для несмещенности: $\mathbb{E}\left[g^k \,\middle|\, x^k\right] = \nabla f\left(x^k\right)$.
- Стоимость одной итерации в d раз дешевле, чем полный градиент, так как делается 1 скалярное произведение вместо d.

Координатный метод

Алгоритм Координатный спуск

Вход: стартовая точка $x^0 \in \mathbb{R}^d$, размеры шагов $\{\gamma_k\}_{k=0} > 0$, количество итераций K

1: **for** $k = 0, 1, \ldots, K-1$ **do**
2: Сгенерировать независимо $i_k \sim U\overline{(1, d)}$
3: $x^{k+1} = x^k - \gamma_k d \left[\nabla f\left(x^k\right)\right]_{i_k} e_{i_k}$
4: **end for**

Выход: x^K

Свойства стохастического градиента

Утверждение

Пусть индекс $i_k \in \overline{1, d}$ выбирается независимо и равновероятно на каждой итерации. Тогда для любой точки $x \in \mathbb{R}^d$ выполняется:

$$\mathbb{E}\left[d[\nabla f(x)]_{i_k} e_{i_k}\right] = \nabla f(x), \quad \mathbb{E}\left[\left\|d[\nabla f(x)]_{i_k} e_{i_k}\right\|_2^2\right] = d\left\|\nabla f(x)\right\|_2^2.$$

Свойства стохастического градиента

Утверждение

Пусть индекс $i_k \in \overline{1,d}$ выбирается независимо и равновероятно на каждой итерации. Тогда для любой точки $x \in \mathbb{R}^d$ выполняется:

$$\mathbb{E}\left[d[\nabla f(x)]_{i_k} e_{i_k}\right] = \nabla f(x), \quad \mathbb{E}\left[\left\|d[\nabla f(x)]_{i_k} e_{i_k}\right\|_2^2\right] = d\left\|\nabla f(x)\right\|_2^2.$$

Покажем первое равенство:

$$\mathbb{E}\left[d[\nabla f(x)]_{i_k} e_{i_k}\right] = \sum_{i=1}^{d} \frac{1}{d} d[\nabla f(x)]_i e_i = \nabla f(x).$$

Свойства стохастического градиента

Утверждение

Пусть индекс $i_k \in \overline{1,d}$ выбирается независимо и равновероятно на каждой итерации. Тогда для любой точки $x \in \mathbb{R}^d$ выполняется:

$$\mathbb{E}\left[d[\nabla f(x)]_{i_k} e_{i_k}\right] = \nabla f(x), \quad \mathbb{E}\left[\left\|d[\nabla f(x)]_{i_k} e_{i_k}\right\|_2^2\right] = d\left\|\nabla f(x)\right\|_2^2.$$

Покажем первое равенство:

$$\mathbb{E}\left[d[\nabla f(x)]_{i_k} e_{i_k}\right] = \sum_{i=1}^{d} \frac{1}{d} d[\nabla f(x)]_i e_i = \nabla f(x).$$

Покажем второе равенство:

$$\mathbb{E}\left[\left\|d[\nabla f(x)]_{i_k} e_{i_k}\right\|_2^2\right] = \sum_{i=1}^{d} \frac{1}{d} d^2 [\nabla f(x)]_i^2 \left\|e_i\right\|_2^2 = d\left\|\nabla f(x)\right\|_2^2.$$

Сходимость

По определению итерации:

$$\left\|x^{k+1} - x^*\right\|_2^2 = \left\|x^k - x^*\right\|_2^2 - 2\gamma\left\langle d\left[\nabla f\left(x^k\right)\right]_{i_k} e_{i_k}, x^k - x^*\right\rangle$$
$$+ \gamma^2\left\|d\left[\nabla f\left(x^k\right)\right]_{i_k} e_{i_k}\right\|_2^2.$$

Сходимость

По определению итерации:

$$\left\|x^{k+1} - x^*\right\|_2^2 = \left\|x^k - x^*\right\|_2^2 - 2\gamma\left\langle d\left[\nabla f\left(x^k\right)\right]_{i_k} e_{i_k}, x^k - x^*\right\rangle + \gamma^2\left\|d\left[\nabla f\left(x^k\right)\right]_{i_k} e_{i_k}\right\|_2^2.$$

Возьмем условное математическое ожидание по случайности на шаге k:

$$\mathbb{E}\left[\left\|x^{k+1} - x^*\right\|_2^2 \middle| x^k\right] = \left\|x^k - x^*\right\|_2^2 - 2\gamma\left\langle \mathbb{E}\left[d\left[\nabla f\left(x^k\right)\right]_{i_k} e_{i_k} \middle| x^k\right], x^k - x^*\right\rangle + \gamma^2\mathbb{E}\left[\left\|d\left[\nabla f\left(x^k\right)\right]_{i_k} e_{i_k}\right\|_2^2 \middle| x^k\right].$$

Сходимость

Воспользуемся свойством стохастического градиента:

$$\mathbb{E}\left[\left\|x^{k+1}-x^*\right\|_2^2 \middle| x^k\right] = \left\|x^k-x^*\right\|_2^2 - 2\gamma\left\langle \nabla f\left(x^k\right), x^k-x^*\right\rangle + d\gamma^2\left\|\nabla f\left(x^k\right)\right\|_2^2.$$

Сходимость

Воспользуемся свойством стохастического градиента:

$$\mathbb{E}\left[\left\|x^{k+1}-x^*\right\|_2^2 \middle| x^k\right] = \left\|x^k-x^*\right\|_2^2 - 2\gamma\left\langle \nabla f\left(x^k\right), x^k-x^*\right\rangle + d\gamma^2\left\|\nabla f\left(x^k\right)\right\|_2^2.$$

Воспользуемся μ–сильной выпуклостью и L–гладкостью:

$$\mathbb{E}\left[\left\|x^{k+1}-x^*\right\|_2^2 \middle| x^k\right] \leq (1-\mu\gamma)\left\|x^k-x^*\right\|_2^2 - 2\gamma(1-d\gamma L)\left(f\left(x^k\right)-f^*\right).$$

Сходимость

Воспользуемся свойством стохастического градиента:

$$\mathbb{E}\left[\left\|x^{k+1}-x^*\right\|_2^2 \middle| x^k\right] = \left\|x^k-x^*\right\|_2^2 - 2\gamma\left\langle \nabla f\left(x^k\right), x^k-x^*\right\rangle + d\gamma^2\left\|\nabla f\left(x^k\right)\right\|_2^2.$$

Воспользуемся μ–сильной выпуклостью и L–гладкостью:

$$\mathbb{E}\left[\left\|x^{k+1}-x^*\right\|_2^2 \middle| x^k\right] \leq (1-\mu\gamma)\left\|x^k-x^*\right\|_2^2 - 2\gamma(1-d\gamma L)\left(f\left(x^k\right)-f^*\right).$$

При $\gamma \leq \frac{1}{dL}$ последнее слагаемое неположительно, и остаётся

$$\mathbb{E}\left[\left\|x^{k+1}-x^*\right\|_2^2 \middle| x^k\right] \leq (1-\mu\gamma)\left\|x^k-x^*\right\|_2^2.$$

Сходимость

Воспользуемся свойством стохастического градиента:

$$\mathbb{E}\left[\left\|x^{k+1}-x^*\right\|_2^2 \,\middle|\, x^k\right] = \left\|x^k-x^*\right\|_2^2 - 2\gamma\left\langle \nabla f\left(x^k\right), x^k-x^*\right\rangle + d\gamma^2\left\|\nabla f\left(x^k\right)\right\|_2^2.$$

Воспользуемся μ–сильной выпуклостью и L–гладкостью:

$$\mathbb{E}\left[\left\|x^{k+1}-x^*\right\|_2^2 \,\middle|\, x^k\right] \leq (1-\mu\gamma)\left\|x^k-x^*\right\|_2^2 - 2\gamma(1-d\gamma L)\left(f\left(x^k\right)-f^*\right).$$

При $\gamma \leq \frac{1}{dL}$ последнее слагаемое неположительно, и остаётся

$$\mathbb{E}\left[\left\|x^{k+1}-x^*\right\|_2^2 \,\middle|\, x^k\right] \leq (1-\mu\gamma)\left\|x^k-x^*\right\|_2^2.$$

Возьмем полное математическое ожидание и раскроем рекурсию:

$$\mathbb{E}\left[\left\|x^k-x^*\right\|_2^2\right] \leq (1-\mu\gamma)^k\left\|x^0-x^*\right\|_2^2.$$

Сходимость

Теорема

Пусть задача безусловной оптимизации с L–гладкой и μ–сильно выпуклой целевой функцией f решается с помощью координатного спуска. Тогда при $\gamma_k = \gamma \leq \frac{1}{dL}$ справедлива следующая оценка сходимости:

$$\mathbb{E}\left[\left\|x^k - x^*\right\|_2^2\right] \leq (1 - \mu\gamma)^k \left\|x^0 - x^*\right\|_2^2.$$

Итог

- Подставив $\gamma = \frac{1}{dL}$, получаем следующую итерационную сложность:

$$\mathcal{O}\left(\frac{dL}{\mu}\log\frac{1}{\varepsilon}\right).$$

Итог

- Подставив $\gamma = \frac{1}{dL}$, получаем следующую итерационную сложность:

$$\mathcal{O}\left(\frac{dL}{\mu}\log\frac{1}{\varepsilon}\right).$$

Вопрос: есть ли улучшения по сравнению с обычным градиентным спуском?

Итог

- Подставив $\gamma = \frac{1}{dL}$, получаем следующую итерационную сложность:

$$\mathcal{O}\left(\frac{dL}{\mu}\log\frac{1}{\varepsilon}\right).$$

Вопрос: есть ли улучшения по сравнению с обычным градиентным спуском? В общем случае нет.

Итог

- Подставив $\gamma = \frac{1}{dL}$, получаем следующую итерационную сложность:

$$\mathcal{O}\left(\frac{dL}{\mu}\log\frac{1}{\varepsilon}\right).$$

  Вопрос: есть ли улучшения по сравнению с обычным градиентным спуском? В общем случае нет.
- Координатный метод часто хорошо себя показывает на практике.

Итог

- Подставив $\gamma = \frac{1}{dL}$, получаем следующую итерационную сложность:

$$\mathcal{O}\left(\frac{dL}{\mu}\log\frac{1}{\varepsilon}\right).$$

  Вопрос: есть ли улучшения по сравнению с обычным градиентным спуском? В общем случае нет.
- Координатный метод часто хорошо себя показывает на практике.
- Результат обобщается и на случай выбора нескольких координат.

Итог

- Подставив $\gamma = \frac{1}{dL}$, получаем следующую итерационную сложность:

$$\mathcal{O}\left(\frac{dL}{\mu}\log\frac{1}{\varepsilon}\right).$$

  Вопрос: есть ли улучшения по сравнению с обычным градиентным спуском? В общем случае нет.
- Координатный метод часто хорошо себя показывает на практике.
- Результат обобщается и на случай выбора нескольких координат.
- Возможно ускорение с помощью двух моментумов.