

- Итерационная схема (17 в. Хоренс)

$$t^* : \varphi(t^*) = 0$$

$$\varphi: \mathbb{R} \rightarrow \mathbb{R}$$

→ $t^0 \in \mathbb{R}$ - начальная точка

цель: найти Δt : $t^0 + \Delta t \approx t^*$

в ряд в окрестности t^0

$$\underline{\varphi(t^0 + \Delta t) = \varphi(t^0) + \varphi'(t^0)\Delta t + o(\Delta t)}$$

О-бозначаем:

$$\varphi(t^0 + \Delta t) \approx \varphi(t^*) = 0 \Rightarrow \varphi(t^0) + \varphi'(t^0)\Delta t \approx 0$$

$$\Delta t \approx - \frac{\varphi(t^0)}{\varphi'(t^0)}$$

$$t^1 = t^0 + \Delta t = t^0 - \frac{\varphi(t^0)}{\varphi'(t^0)}$$

$$t^{k+1} = t^k - \frac{\varphi(t^k)}{\varphi'(t^k)}$$

итерационный
метод Хоренса

Пример работы:

$$\varphi(t) = \frac{t}{\sqrt{1+t^2}}$$

$$t^* = 0 \quad \varphi'(t) = \frac{1}{(1+t^2)^{3/2}}$$

$$\text{н. Хоренса: } t^{k+1} = t^k - \frac{\varphi(t^k)}{\varphi'(t^k)} = t^k - \frac{\frac{t^k}{(1+(t^k)^2)^{1/2}}}{\frac{1}{(1+(t^k)^2)^{3/2}}}$$

$$= t^k - t^k(1+(t^k)^2) = -(t^k)^3$$

$$1) |t^k| > 1 \quad \text{расходится}$$

$$2) |t^k| = 1 \quad \text{колеблется} \quad 1 \rightleftharpoons -1$$

$$3) |t^k| < 1 \quad \text{сходится}$$

Сходимость метода в окрестности

• Обращение к оптимизации

$$\min_{x \in \mathbb{R}^d} f(x)$$

$$\text{нужно } \nabla f(x^*) = 0$$

Метод Ньютона для задачи оптимизации

$$x^{k+1} = x^k - (\nabla^2 f(x^k))^{-1} \nabla f(x^k)$$

Другая интерпретация (с помощью разложения)

$$\underbrace{f(x)}_{\text{целевая } f(x)} \approx \underbrace{f(x^k) + \langle \nabla f(x^k); x - x^k \rangle + \frac{1}{2} \langle x - x^k; \nabla^2 f(x^k)(x - x^k) \rangle}_{\text{многомерное квадратное приближение}}$$

$$\nabla f(x^k) + \nabla^2 f(x^k)(x - x^k) = 0$$

$$x^{k+1} = x^k - (\nabla^2 f(x^k))^{-1} \nabla f(x^k)$$

приближение к методу ньютона

для квадратичной задачи сводится за 1 итерацию,
но только (ограничение метода)

Свойства невязки Ньютона

- f - μ -многообразия $\nabla^2 f(x) \in \mu I$
- $\nabla^2 f$ - M -линейный $\|\nabla^2 f(x) - \nabla^2 f(y)\| \leq M \|x - y\|_2$
↑
линейность

Доказательство свойства:

$$x^{k+1} - x^* = x^k - (\nabla^2 f(x^k))^{-1} \nabla f(x^k) - x^*$$

Применяя H -л (критерию невязки):

$$\nabla f(x^k) - \nabla f(x^*) = \int_0^1 \nabla^2 f(x^* + \tau(x^k - x^*)) (x^k - x^*) d\tau$$

Применяем

$$x^{k+1} - x^* = x^k - x^* - (\nabla^2 f(x^k))^{-1} \int_0^1 \nabla^2 f(x^* + \tau(x^k - x^*)) (x^k - x^*) d\tau$$

линейность $\nabla^2 f(x) - \nabla^2 f(y)$

линейность "1"

$$x^{k+1} - x^* = \underbrace{(\nabla^2 f(x^k))^{-1} \nabla^2 f(x^k)}_1 (x^k - x^*)$$

$$- \underbrace{(\nabla^2 f(x^k))^{-1} \int_0^1 \nabla^2 f(x^* + \tau(x^k - x^*)) (x^k - x^*) d\tau}_{\text{линейность}}$$

линейность и линейность

$$x^{k+1} - x^* = (\nabla^2 f(x^k))^{-1} \left[\nabla^2 f(x^k) - \int_0^1 \nabla^2 f(x^* + \tau(x^k - x^*)) d\tau \right] (x^k - x^*)$$

Переносим \int

$$x^{k+1} - x^* = (\nabla^2 f(x^k))^{-1} \left[\int_0^1 (\nabla^2 f(x^k) - \nabla^2 f(x^* + \tau(x^k - x^*))) d\tau \right] (x^k - x^*)$$

Оценки погрешности

$$\begin{aligned}\|x^{k+1} - x^*\|_2 &= \|(\nabla^2 f(x^k))^{-1} \left[\int_0^1 (\nabla^2 f(x^k) - \nabla^2 f(x^* + \tau(x^k - x^*))) d\tau \right] (x^k - x^*)\|_2 \\ &\leq \|(\nabla^2 f(x^k))^{-1}\|_2 \left\| \int_0^1 (\nabla^2 f(x^k) - \nabla^2 f(x^* + \tau(x^k - x^*))) d\tau \right\|_2 \|x^k - x^*\|_2 \\ &\leq \|(\nabla^2 f(x^k))^{-1}\|_2 \left\| \int_0^1 (\nabla^2 f(x^k) - \nabla^2 f(x^* + \tau(x^k - x^*))) d\tau \right\|_2 \|x^k - x^*\|_2\end{aligned}$$

$(\nabla^2 f(x^k))^{-1}$ ограничен? $\nabla^2 f(x^k) \succeq \mu I \Rightarrow (\nabla^2 f(x^k))^{-1} \preceq \frac{1}{\mu} I$

$$\leq \frac{\|x^k - x^*\|_2}{\mu} \left\| \int_0^1 (\nabla^2 f(x^k) - \nabla^2 f(x^* + \tau(x^k - x^*))) d\tau \right\|_2 \quad (1)$$

Покажем $\leq \|f\|_2$

$$\left\| \int_0^1 (\nabla^2 f(x^k) - \nabla^2 f(x^* + \tau(x^k - x^*))) d\tau \right\|_2 \leq \int_0^1 \|\nabla^2 f(x^k) - \nabla^2 f(x^* + \tau(x^k - x^*))\|_2 d\tau$$

M -лимитная оценка

$$\begin{aligned}&\leq \int_0^1 M \tau \|x^k - x^*\|_2 d\tau \\ &= M \|x^k - x^*\|_2 \int_0^1 \tau d\tau \\ &= \frac{M}{2} \|x^k - x^*\|_2^2 \quad (2)\end{aligned}$$

Объединяем (1) и (2)

$$\begin{aligned}\|x^{k+1} - x^*\|_2 &\leq \frac{\|x^k - x^*\|_2}{\mu} \cdot \frac{M}{2} \|x^k - x^*\|_2 \\ &= \frac{M}{2\mu} \|x^k - x^*\|_2^2\end{aligned}$$

Сходимость метода Ньютона за 1 итерацию:

$$\|X^{k+1} - X^*\|_2 \leq \frac{M}{2\mu} \|X^k - X^*\|_2^2$$

Анализ сходимости:

тогда $\|X^1 - X^*\|_2 < \|X^0 - X^*\|_2$

Если $\|X^0 - X^*\|_2 < \frac{2\mu}{M}$, тогда получим, то тогда

Пример: $M=1$ $\mu=\frac{1}{2}$

$$\|X^{k+1} - X^*\|_2 \leq \|X^k - X^*\|_2^2$$

$$\|X^0 - X^*\|_2 = \frac{1}{3} \Rightarrow \|X^1 - X^*\|_2 = \left(\frac{1}{3}\right)^2 \Rightarrow \left(\left(\frac{1}{3}\right)^2\right)^2 \Rightarrow \left(\left(\left(\frac{1}{3}\right)^2\right)^2\right)^2$$

квадратичная сходимость

Умови:

+ квадратичная сходимость

- локальная сходимость

- хорошая инициализация

Брекен с квадратной сходимостью

• Деннотация

$$X^{k+1} = X^k - \gamma_k \underbrace{(\nabla^2 f(X^k))^{-1} \nabla f(X^k)}_{\substack{\uparrow \text{гобелум мар} \\ \uparrow -p^k}}$$


$$\gamma_k = \arg \min_{\gamma \in \mathbb{R}} f(X^k + \gamma p^k) \leftarrow \begin{array}{l} \text{выбор по } f \\ \text{(чем } f \text{ больше)} \\ \text{↓} \\ \text{шаг / размер} \\ \text{сетки} \end{array}$$

- Бенчмарк GD, невыпукло GD с шагом $\frac{1}{L}$


$$x^{k+1} = \arg \min_{x \in \mathbb{R}^d} \left(f(x^k) + \langle \nabla f(x^k); x - x^k \rangle + \frac{L}{2} \|x - x^k\|_2^2 \right)$$

$$x^{k+1} = x^k - \frac{1}{L} \nabla f(x^k)$$

Мат GD - минимизация квадратичной формы (L-линейная)



=>



Теорема: $f(x) \approx \underbrace{f(x^k) + \langle \nabla f(x^k); x - x^k \rangle}_{\text{минимизируемая}} + \frac{M}{6} \|x - x^k\|_2^3$ минимизация ∞

Анализ для 2-го порядка

$$x^{k+1} = \arg \min_{x \in \mathbb{R}^d} \left(f(x^k) + \langle \nabla f(x^k); x - x^k \rangle + \frac{1}{2} \langle x - x^k; \nabla^2 f(x^k)(x - x^k) \rangle + \frac{M}{6} \|x - x^k\|_2^3 \right)$$

минимизация квадратичной формы M-линейная

Рядовое невяз (Торон, Кемперов)

Теорема: горизонт, результат

$$x^{k+1} = x^k - \underbrace{H_k}_{\text{матрица } d \times d} \nabla f(x^k)$$

В итоге $H_k = (\nabla^2 f(x^k))^{-1}$

Матрица H_k зависит от $\nabla^2 f$, то есть от второго порядка

→ результат в раз (в раз x^{k+1})

$$\nabla f(x^k) = \nabla f(x^{k+1}) + \nabla^2 f(x^{k+1})(x^k - x^{k+1}) + o(\|x^{k+1} - x^k\|_2)$$

$$\underbrace{x^{k+1} - x^k}_{s^k} \approx \underbrace{(\nabla^2 f(x^{k+1}))^{-1}}_{H^{k+1}} \underbrace{(\nabla f(x^{k+1}) - \nabla f(x^k))}_{y^k}$$

- Квазиотомовские ур-е:

$$s^k = H_{k+1} y^k$$

- Симметричность: $H_{k+1}^+ = H_{k+1}$

Сравнить решение y квазиотомовского уравнения?
Бесконечно много

цель квазиотомовских методов - решить уравнение
 "хорошо" с точки зрения метода

Численные методы:

- SR1 / Broyden

$$H_{k+1} = H_k + \underbrace{\mu_k}_{\in \mathbb{R}} \underbrace{(g^k)}_{\in \mathbb{R}^d} \underbrace{(g^k)^T}_{\in \mathbb{R}^d}$$

генерация орто-примитивов гессиана

генерация g^k и μ^k

$$\begin{aligned} s^k = H_{k+1} y^k &= H_k y^k + \mu_k g^k \underbrace{(g^k)^T y^k}_{\in \mathbb{R}} \\ &= H_k y^k + \mu_k (g^k)^T y^k g^k \end{aligned}$$

$$s^k - H_k y^k = \underbrace{\mu_k (g^k)^T y^k}_{\in \mathbb{R} = 1} g^k$$

$$g^k = s^k - H_k y^k$$

$$H_k = \frac{1}{(g^k)^T y^k}$$

- BFGS - аналог метода Зейделя

$$H_{k+1} = \arg \min_{H \in \mathbb{R}^{d \times d}} \|H - H_k\|_F^2$$

$$\text{s.t. } H y^k = s^k$$

$$H^T = H$$

модификация
(метод Зейделя)
вычисления
новой матрицы

В BFGS \rightarrow вычисление произв. матрицы:

$$\|A\|_W = \|W^{1/2} A W^{1/2}\|_F \quad W y^k = s^k$$

$$H_{k+1} = (I - g_k s^k (y^k)^T) H_k (I - g_k y^k (s^k)^T) + g_k s^k (s^k)^T$$

$$g_k = \frac{1}{(y^k)^T s^k}$$

Как выбрать по-другому?

$$B_{k+1} = H_{k+1}^{-1} \quad (B \approx \nabla^2 f)$$

Квази-симметричные матрицы B :

$$B_{k+1} s^k = y^k$$

SR1 для B_{k+1} :

$$B_{k+1} = B_k +$$

$$\frac{(y^k - B_k s^k)(y^k - B_k s^k)^T}{(y^k - B_k s^k)^T s^k}$$

$$y^k (y^k)^T$$

$$\cancel{B_k s^k (y^k)^T}$$

матрица

$$B_k s^k (B_k s^k)^T$$

нормальное 2x-ранговое обновление:

$$B_{k+1} = B_k + \mu_{k,1} y^k (y^k)^T + \mu_{k,2} B_k y^k (B_k y^k)^T$$

нормальное вложенное грейду $\mu_{k,1}, \mu_{k,2}$:

$$B_{k+1} = B_k + \frac{y^k (y^k)^T}{(y^k)^T s^k} + \frac{B_k y^k (B_k y^k)^T}{(s^k)^T B_k s^k}$$

$$H_{k+1} = B_{k+1}^{-1} \quad (\text{из метода Маркуссен-Буденга})$$

можно H_{k+1} из BFGS

Алгоритм BFGS:

$$H_{k+1} = (I - g_k s^k (y^k)^T) H_k (I - g_k y^k (s^k)^T) + g_k s^k (s^k)^T$$

Здесь есть перемножение \times перемножение? Если $g_k \Rightarrow O(d^2)$
обратное скалярное

$$H_{k+1} = H_k - g_k \underbrace{s^k (y^k)^T H_k}_{\substack{\text{vec} \times \text{mat} \\ \text{vec} \times \text{vec}}} - g_k \underbrace{H_k y^k (s^k)^T}_{\substack{\text{vec} \times \text{mat} \\ \text{vec} \times \text{vec}}} + g_k^2 \underbrace{s^k (y^k)^T H_k y^k (s^k)^T}_{\text{аналогично}}$$

то же самое $O(d^2)$

Минусы не вложенности:

- + добавление суперлинейное сложение
- + генерация вложенности (по сравнению с Броденга)
- генерация (по сравнению с GD)
- сложная сложность к макс. минимизации в пред. задачах