

- Задача макс. минимизации

$$\min_{x \in \mathbb{R}^d} \left[\mathcal{F}(x) := \mathbb{E}_{\xi \sim D} [\mathcal{F}(x, \xi)] \right]$$

- Zagawa ML:

$$f(x) := \mathbb{E}_{\mathbf{g} \sim \mathcal{D}} \left[\mathcal{L} \left(g(x, \mathbf{g}_a), \mathbf{g}_b \right) \right]$$

Значения f и ∇f известны

• Что делаем?

1) Opinion essay:

$\nabla f(x, \xi)$ - gradient w.r.t. x

11

$$\nabla_x (g(x, f^a), f^b)$$

$$\mathbb{E}_{f \sim D} [\rho f(x, f)] = \rho f(x)$$

2) Агрегация признаков: y — это класс объектов $\{x_i\}_{i=1}^n$

amorphous $E_g \sim 0$:

$$\min_{x \in \mathbb{R}^d} \left[f(x) = \frac{1}{n} \sum_{i=1}^n \ell(g(x, f_{i,a}), f_{i,b}) \right]$$

more common ∇f

① *guzo*

- ⊖ переобучение при малом ρ

⊕ Изменения происходят по плану работы (См.р)

• Стохастический градиентный спуск

$$x^{k+1} = x^k - \gamma \nabla f(x^k, \xi^k)$$

↑
объем выборки
(регуляризатор регуляризатор
и регуляризатор)

• Регуляризатор: $E_{\xi}[\nabla f(x^k, \xi^k)]$

• Регуляризатор: $E_{\xi}[\nabla f(x^k, \xi^k)] =$ (регуляризатор регуляризатор)

$$= \sum_{i=1}^n \underbrace{P_{\xi \xi^k = \xi_i}}_{\text{регуляризатор}} \nabla f(x^k, \xi_i) =$$

$$= \sum_{i=1}^n \frac{1}{n} \nabla f(x^k, \xi_i) = \frac{1}{n} \sum \nabla f(x^k, \xi_i) = \nabla f(x^k)$$

• Уровневые неметрические операции

$$E[\cdot | x^k] = E[\cdot | \mathcal{F}_k]$$

\mathcal{F}_k - σ -алгебра, порожд. $x^0, \xi^0, \dots, \xi^{k-1}$

$$E[E[X|Y]] = E[X]$$

• f - μ -интеграл

• $f(x, \xi)$ - L -функция

• $E_{\xi}[\nabla f(x, \xi)] = \nabla f(x)$

Докажем эквивалентно:


$$\begin{aligned}\|x^{k+1} - x^*\|_2^2 &= \|x^k - \gamma \nabla f(x^k, \xi^k) - x^*\|_2^2 \\ &= \|x^k - x^*\|_2^2 - 2\gamma \langle \nabla f(x^k, \xi^k); x^k - x^* \rangle \\ &\quad + \gamma^2 \|\nabla f(x^k, \xi^k)\|_2^2\end{aligned}$$

$$\|\nabla f(x^k, \xi^k)\|_2^2:$$

$$\|\nabla f(x^k, \xi^k)\|_2^2 = \|\nabla f(x^k, \xi^k) - \nabla f(x^*, \xi^k) + \nabla f(x^*, \xi^k)\|_2^2$$

$\neq 0$

$$\nabla f(x^*) = 0 \Rightarrow \cancel{\nabla f(x^*, \xi^k) = 0}$$



к511

$$\leq 2\|\nabla f(x^k, \xi^k) - \nabla f(x^*, \xi^k)\|_2^2 + 2\|\nabla f(x^*, \xi^k)\|_2^2$$

L -линейно $f(\cdot, \xi)$

$$\begin{aligned}\leq 4L \left(f(x^k, \xi^k) - f(x^*, \xi^k) + \langle \nabla f(x^*, \xi^k); x^k - x^* \rangle \right) \\ + 2\|\nabla f(x^*, \xi^k)\|_2^2\end{aligned}$$

$\neq 0$

Продолжим:

$$\begin{aligned}\|x^{k+1} - x^*\|_2^2 &\leq \|x^k - x^*\|_2^2 - 2\gamma \langle \nabla f(x^k, \xi^k); x^k - x^* \rangle \\ &\quad + \gamma^2 \cdot 4L \left(f(x^k, \xi^k) - f(x^*, \xi^k) \right. \\ &\quad \left. + \langle \nabla f(x^*, \xi^k); x^k - x^* \rangle \right) \\ &\quad + 2\gamma^2 \|\nabla f(x^*, \xi^k)\|_2^2\end{aligned}$$

Здесь и т.д.

$$\mathbb{E} [\|x^{k+1} - x^*\|_2^2] \leq \mathbb{E} [\|x^k - x^*\|_2^2]$$

$$\begin{aligned} & - 2\gamma \mathbb{E} [\langle \nabla f(x^k, \xi^k), x^k - x^* \rangle] \\ & + \gamma^2 4L \mathbb{E} [f(x^k, \xi^k) - f(x^*, \xi^k) \\ & \quad + \langle \nabla f(x^*, \xi^k); x^k - x^* \rangle] \\ & + 2\gamma^2 \mathbb{E} [\|\nabla f(x^*, \xi^k)\|_2^2] \end{aligned}$$

Tower property $\mathbb{E}[\] = \mathbb{E}[\mathbb{E}[\] | x^k]$

$$\begin{aligned} \mathbb{E} [\|x^{k+1} - x^*\|_2^2] & \leq \mathbb{E} [\|x^k - x^*\|_2^2] \\ & - 2\gamma \mathbb{E} [\mathbb{E} [\langle \nabla f(x^k, \xi^k), x^k - x^* \rangle | x^k]] \\ & + 4\gamma^2 L \mathbb{E} [\mathbb{E} [f(x^k, \xi^k) - f(x^*, \xi^k) \\ & \quad - \langle \nabla f(x^*, \xi^k); x^k - x^* \rangle | x^k]] \\ & + 2\gamma^2 \mathbb{E} [\mathbb{E} [\|\nabla f(x^*, \xi^k)\|_2^2 | x^k]] \end{aligned}$$

независимость ξ

$$= \mathbb{E} [\|x^k - x^*\|_2^2]$$

$$\begin{aligned} & - 2\gamma \mathbb{E} [\langle \mathbb{E} [\nabla f(x^k, \xi^k) | x^k], x^k - x^* \rangle] \\ & + 4\gamma^2 L \mathbb{E} [\mathbb{E} [f(x^k, \xi^k) | x^k] - \mathbb{E} [f(x^*, \xi^k) | x^k] \\ & \quad + \langle \mathbb{E} [\nabla f(x^*, \xi^k) | x^k], x^k - x^* \rangle] \\ & + 2\gamma^2 \mathbb{E} [\mathbb{E} [\|\nabla f(x^*, \xi^k)\|_2^2 | x^k]] \end{aligned}$$

равносильно к

$$= E [\|x^k - x^*\|_2^2]$$

$$- 2\gamma E [\langle \nabla f(x^k); x^k - x^* \rangle]$$

$$+ 4\gamma^2 L E [f(x^k) - f(x^*)]$$

$$+ 4\gamma^2 L E [\langle \nabla f(x^k); x^k - x^* \rangle]$$

$$+ 2\gamma^2 E \left[\frac{1}{n} \sum_{i=1}^n \underbrace{\|\nabla f(x^k, \xi_i)\|_2^2}_{\sigma_*^2} \right]$$

Получаем:

$$E [\|x^{k+1} - x^*\|_2^2] \leq E [\|x^k - x^*\|_2^2]$$

$$- 2\gamma E [\langle \nabla f(x^k); x^k - x^* \rangle]$$

$$+ 4\gamma^2 L E [f(x^k) - f(x^*)]$$

$$+ 2\gamma^2 \sigma_*^2$$

μ -сильное сходимости f :

$$E [\|x^{k+1} - x^*\|_2^2] \leq E [\|x^k - x^*\|_2^2]$$

$$- 2\gamma E \left[\frac{\mu}{2} \|x^k - x^*\|_2^2 + f(x^k) - f(x^*) \right]$$

$$+ 4\gamma^2 L E [f(x^k) - f(x^*)]$$

$$+ 2\gamma^2 \sigma_*^2$$

$$\begin{aligned}
&= (1-\gamma\mu) \mathbb{E} \|x^k - x^*\|_2^2 \\
&\quad + \underbrace{2\gamma(2\gamma L - 1) \mathbb{E} [f(x^k) - f(x^*)]}_{\geq 0} \\
&\quad + 2\gamma^2 \sigma_*^2
\end{aligned}$$

$$\gamma \leq \frac{1}{2L}$$

$$\leq (1-\gamma\mu) \mathbb{E} [\|x^k - x^*\|_2^2] + 2\gamma^2 \sigma_*^2$$

$$\boxed{\mathbb{E} [\|x^{k+1} - x^*\|_2^2] \leq (1-\gamma\mu) \underbrace{\mathbb{E} [\|x^k - x^*\|_2^2]}_{R_k^2} + 2\gamma^2 \sigma_*^2}$$

R_{k+1}^2

Zusammen fassen

$$R_{k+1}^2 \leq (1-\gamma\mu) R_k^2 + 2\gamma^2 \sigma_*^2$$

$$\leq (1-\gamma\mu) [(1-\gamma\mu) R_{k-1}^2 + 2\gamma^2 \sigma_*^2] + 2\gamma^2 \sigma_*^2$$

$$= (1-\gamma\mu)^2 R_{k-1}^2 + 2\gamma^2 \sigma_*^2 [1 + (1-\gamma\mu)]$$

$$\dots \leq (1-\gamma\mu)^{k+1} R_0^2 + 2\gamma^2 \sigma_*^2 \sum_{i=0}^k (1-\gamma\mu)^i$$

$$\leq (1-\gamma\mu)^{k+1} R_0^2 + 2\gamma^2 \sigma_*^2 \underbrace{\sum_{i=0}^{\infty} (1-\gamma\mu)^i}_{\frac{1}{\gamma\mu}}$$


$$= (1-\gamma\mu)^{k+1} R_0^2 + \frac{2\gamma\sigma_*^2}{\mu} \quad \blacksquare$$

Сходимость SGD с перемен. шагом

$$\mathbb{E}[\|x^{k+1} - x^*\|_2^2] \leq (1-\gamma\mu)^{k+1} \mathbb{E}[\|x^0 - x^*\|_2^2] + \frac{2\gamma\sigma_*^2}{\mu}$$

⊕ сходимость линейная, как у GD

⊖ го. шаг. уменьш.: $\sim \gamma$, $\sim \sigma_*^2$



⊕ шумовой шум

• Как бороться со сред. и шумом?

1) γ уменьшать

$$\gamma \rightarrow \gamma_k \approx \frac{1}{k}; \quad \frac{1}{\sqrt{k}}$$

⊕ решает вопрос сходимости

⊖ требует линейно сходимости (можно исправить с помощью год. шума)

2) σ_*^2 уменьшать

$$\nabla f(x^k, \xi^k) \rightarrow \frac{1}{b} \sum_{\xi \in S_k} \nabla f(x^k, \xi)$$

S_k - набор объектов из од. базисной группы b

$$\mathbb{E}_{S_k} \left[\frac{1}{b} \sum \nabla f(x^k, \xi) \right] =$$

$$= \frac{1}{b} \sum \mathbb{E}_{\xi} [\nabla f(x^k, \xi)] = \frac{1}{b} \sum \nabla f(x^k) = \nabla f(x^k)$$

$$\bullet \mathbb{E}_{S^k} \left[\left\| \frac{1}{b} \sum_{\xi \in S^k} \nabla f(x^*, \xi) \right\|_2^2 \right] =$$

$$= \frac{1}{b^2} \mathbb{E}_{S^k} \left[\sum_{\xi \in S^k} \|\nabla f(x^*, \xi)\|_2^2 \right]$$

$$+ \frac{1}{b^2} \mathbb{E}_{S^k} \left[\sum_{\substack{\xi \neq \eta \\ \xi, \eta \in S^k}} \langle \nabla f(x^*, \xi), \nabla f(x^*, \eta) \rangle \right]$$

$$= \frac{1}{b^2} \sum_{\xi} \mathbb{E}_{\xi} \|\nabla f(x^*, \xi)\|_2^2 \leftarrow \frac{1}{b} \cdot \underbrace{\frac{1}{n} \sum_{i=1}^n \|\nabla f(x^*, \xi_i)\|_2^2}_{\sigma_*^2} = \frac{\sigma_*^2}{b}$$

$$+ \frac{1}{b^2} \mathbb{E}_{S^k} \left[\sum_{\substack{\xi \neq \eta \\ \xi, \eta \in S^k}} \langle \nabla f(x^*, \xi), \nabla f(x^*, \eta) \rangle \right]$$

результат

$$\mathbb{E} \langle \nabla f(x^*, \xi), \nabla f(x^*, \eta) \rangle$$

$$\langle \mathbb{E} \nabla f(x^*, \xi); \mathbb{E} \nabla f(x^*, \eta) \rangle$$

$$\langle \nabla f(x^*); \nabla f(x^*) \rangle = 0$$

$$= \boxed{\frac{\sigma_*^2}{b}} \leftarrow \text{эквивалентная дисперсия}$$

⊕ ординаты меньше b и b раз

⊖ уменьшение дисперсии