

С2 Матрично-векторное дифференцирование

В численных методах текущее приближение оптимума x^k обновляется за счёт сдвига вдоль некоторого направления d^k . В простейшем случае, Пример Л1.1, это выглядит как

$$x^{k+1} = x^k + \alpha d^k,$$

где α , d^k — длина и направление шага на k -й итерации. Чтобы такое обновление имело смысл, пространство параметров модели должно быть наделено линейной структурой, то есть быть замкнуто относительно сложения и действия некоторым полем чисел. Кроме того, для оценки качества методов на пространстве параметров должна быть задана норма.

Определение С2.1. *Линейным нормированным пространством (ЛНП) будем называть пару $(U, \|\cdot\|)$, где U — линейное пространство, а $\|\cdot\| : U \rightarrow \mathbb{R}$ — действующая на нём норма.*

Замечание С2.1. В основном мы будем рассматривать $\mathbb{R}^d$.

С2.1 Первый дифференциал

Самые распространённые на практике численные методы используют градиент (Алгоритм Л3.1, Алгоритм Л4.2) или гессиан (Алгоритм Л7.1) целевой функции для построения направления спуска. В этом разделе мы введём формальное определение дифференцирования в конечномерных ЛНП, а также определим градиент и гессиан функции. Кроме этого, мы также подробно поговорим о частных случаях — пространствах векторов и матриц.

Определение С2.2. Пусть U, V — конечномерные ЛНП. Линейный оператор $df(x)$ называется *производной отображения* $f : U \rightarrow V$ в точке $x \in \text{int } U$, если выполнено

$$f(x+h) = f(x) + df(x)[h] + o(\|h\|), \quad \|h\| \rightarrow 0.$$

Сама функция f в случае существования такого оператора называется *дифференцируемой по Фреше в точке*. $df(x)[h]$ называют *дифференциалом отображения* f в точке x .

Замечание С2.2. Если точка не является внутренней, то понятие дифференцируемости не определено.

Замечание С2.3. Иногда для приращения h будем пользоваться обозначением dx .

Определение С2.2 накладывает достаточно сильные условия на функцию. Оно проверяет существование единого линейного приближения вдоль всех направлений. Можно рассматривать более слабый вариант производной.

Определение С2.3. Пусть U, V — конечномерные ЛНП. Оператор $\tilde{d}f(x)$ называется *производной по направлению отображения* $f : U \rightarrow V$ в точке $x \in \text{int } U$, если существует предел

$$\tilde{d}f(x)[h] = \lim_{t \rightarrow 0} \frac{f(x+th) - f(x)}{t}, \quad \forall h \in U.$$

Сама функция f в случае существования такого оператора называется *диффе-*

ренцируемой по Гато в точке.

Замечание С2.4. $\tilde{d}f(x)[e_i]$ называется *частной производной* f в точке x .

Из дифференцируемости по Фреше следует дифференцируемость по Гато, однако обратное неверно.

Пример С2.1. Для функции $f : \mathbb{R}^2 \rightarrow \mathbb{R}$:

$$f(x) = \begin{cases} \frac{x_1^3 x_2}{x_1^4 + x_2^2}, & x \neq (0, 0)^\top, \\ 0, & x = (0, 0)^\top. \end{cases}$$

в точке $(0, 0)^\top$ существует производная по Гато, но не существует производной по Фреше.

Доказательство. Воспользуемся Определением С2.3. Поскольку $f(0) = 0$, то достаточно рассмотреть $\frac{f(th)}{t}$, распишем:

$$\frac{f(th)}{t} = \frac{1}{t} \frac{t^4 h_1^3 h_2}{t^4 h_1^4 + t^2 h_2^2} = t \frac{h_1^3 h_2^2}{t^2 h_1^4 + h_2^2} \rightarrow 0, \quad t \rightarrow 0.$$

Тогда производная по Гато — нулевое отображение. Если производная по Фреше существует, то она совпадает с производной по Гато и также равна нулевому отображению. Рассмотрим $h_2 = h_1^2$, $h_1 \rightarrow 0$:

$$\lim_{\|h\|_2 \rightarrow 0} \frac{f(h)}{\|h\|_2} = \lim_{h_1 \rightarrow 0} \frac{h_1^3 h_2}{\sqrt{h_1^2 + h_2^2} (h_1^4 + h_2^2)} = \lim_{h_1 \rightarrow 0} \frac{h_1^5}{2h_1^5} = \frac{1}{2}.$$

Пришли к противоречию. ■

Замечание С2.5. В дальнейшем, дифференцируемость функции будем понимать в смысле Фреше.

В $\mathbb{R}^d$ действие оператора производной единственным образом представляется через скалярное произведение.

Теорема С2.1. Пусть $df(x) : U \rightarrow \mathbb{R}$ — линейный функционал, действующий на конечномерном линейном пространстве U , снабжённом скалярным произведением. Тогда существует единственный $g_f \in U$, такой, что

$$df(x)[h] = \langle g_f, h \rangle.$$

Доказательство. Пусть $\{e_i\}_{i=1}^d$ — базис в U . Тогда любой элемент $h \in U$ представим в виде

$$h = \sum_{i=1}^d h_i e_i.$$

Поддействуем оператором $df(x)$ на h :

$$df(x)[h] = df(x) \left[\sum_{i=1}^d h_i e_i \right] = \sum_{i=1}^d h_i df(x)[e_i].$$

Обозначим $g_f^i = df(x)[e_i]$ и положим

$$g_f = \sum_{i=1}^d g_f^i e_i.$$

Тогда

$$df(x)[h] = \langle g_f, h \rangle.$$

■

Этот факт является частным случаем более общей теоремы Рисса о представлении для произвольного гильбертова пространства.

Замечание C2.6. В случае стандартного базиса g_f — вектор частных производных. Он называется *градиентом* функции и обозначается как ∇f .

Замечание C2.7. Рассмотрим $f : \mathbb{R}^d \rightarrow \mathbb{R}^n$. Представим

$$f(x) = (f_1(x), \dots, f_n(x))^T.$$

Каждая координатная функция — понятное с точки зрения производной отображение $\mathbb{R}^d \rightarrow \mathbb{R}$. Получается, производная отображения $\mathbb{R}^d \rightarrow \mathbb{R}^n$ — матрица Якоби ($J_{ij}(x) = \frac{\partial f_i}{\partial x_j}(x)$) этого отображения. В общем же случае отображения матрицы в матрицу для построения градиента достаточно найти все частные производные в виде тензора

$$\left\{ \frac{\partial f_{ij}}{\partial x_{kl}}(x) \right\}_{ijkl}.$$

Рассуждения, приведённые в Замечании C2.7, для наглядности сформулируем в виде таблицы.

Выход \ Вход	Скаляр $\mathbb{R}$	Вектор $\mathbb{R}^d$
Скаляр $\mathbb{R}$	$\nabla f(x)$ скаляр, h скаляр	$\nabla f(x)$ вектор, h скаляр
Вектор $\mathbb{R}^d$	$\nabla f(x)$ вектор, h вектор	$\nabla f(x)$ матрица, h вектор
Матрица $\mathbb{R}^{n \times d}$	$\nabla f(x)$ матрица, h матрица	$\nabla f(x)$ тензор, h матрица

Стоит отметить, что данная таблица верна для произвольных скалярных производных, а не только для стандартного.

Утверждение C2.1. Из формулы градиента верно, что

$$df(x) = (\nabla f(x))^T dx \iff \nabla f(x) = J_f^T(x).$$

Доказательство. Утверждение следует из покомпонентного представления градиента и матрицы Якоби. ■

C2.2 Второй дифференциал

Пусть U, V — конечномерные ЛНП. Пусть отображение $f : U \rightarrow V$ дифференцируемо в каждой точке $x \in \text{int } U$. Второй дифференциал будем определять, фиксируя приращение и рассматривая первый дифференциал как функцию от x :

$$g(x) = df(x)[h_1].$$

Определение С2.4. Если в некоторой точке x функция $g(x) = df(x)[h_1]$ дифференцируема, то билинейный оператор $dg(x)[h_2] = d(df(x)[h_1])[h_2]$ называется *оператором второй производной*.

Замечание С2.8. Оператор второй производной — билинейная форма, имеющая вид

$$d^2f(x)[h_1, h_2] = \langle G_f h_1, h_2 \rangle.$$

В случае стандартного базиса G_f — матрица вторых производных. Она называется гессианом отображения и обозначается $\nabla^2 f$.

Утверждение С2.2. Из формулы гессиана верно, что

$$d(\nabla f(x)) = (\nabla^2 f(x))^\top dx \iff \nabla^2 f(x) = J_{\nabla f}^\top.$$

Доказательство. Утверждение следует из покомпонентного представления градиента и матрицы Якоби. ■

С2.3 Примеры и задачи

В рамках этого пособия векторы обозначаются маленькими латинскими буквами, матрицы/тензоры — заглавными латинскими.

Известные из курса математического анализа правила дифференцирования (производная произведения, частного, композиции) сохраняются. Мы напомним их, не обращаясь к доказательствам.

Утверждение С2.3. Пусть U — нормированное ЛНП. Тогда для векторных и матричных дифференциалов справедливо:

1. $d(\alpha x) = \alpha dx, \alpha \in \mathbb{R}$;
2. $d(x + y) = dx + dy$;
3. $d\langle x, y \rangle = \langle dx, y \rangle + \langle x, dy \rangle$;
4. $d(f(x)g(x)) = d(f(x))g(x) + f(x)d(g(x))$ ($f : U \rightarrow \mathbb{R}, g : U \rightarrow \mathbb{R}$);
5. $d\left(\frac{f(x)}{\phi(x)}\right) = \frac{\phi(x)df(x) - f(x)d\phi(x)}{\phi^2(x)}$ ($f : U \rightarrow \mathbb{R}, \phi : \mathbb{R} \rightarrow \mathbb{R}$);
6. $d(g(f(x))) = dg(f(x))[df(x)]$ ($f : U \rightarrow f(U), g : f(U) \rightarrow \mathbb{R}$);
7. $J_{g \circ f}(x) = J_g(f(x))J_f(x)$ ($f : U \rightarrow f(U), g : f(U) \rightarrow \mathbb{R}$).

Для матричных дифференциалов справедливо:

1. $d(AXB) = A dx B$;
2. $d(XY) = (dX)Y + X(dY)$;
3. $d(X^\top) = (dX)^\top$.

Перед тем, как перейти к вычислению нетривиальных примеров, придётся воспользоваться определением и получить выражения для базовых градиентов.

Пример С2.2. Справедливы следующие выражения:

- $d\langle c, x \rangle = \langle c, dx \rangle \implies \nabla(\langle c, x \rangle) = c;$
- $d\langle Ax, x \rangle = \langle (A + A^\top)x, dx \rangle \implies \nabla(\langle Ax, x \rangle) = (A + A^\top)x;$
- $d(X^{-1}) = -X^{-1} dX X^{-1};$
- $d \det(X) = \langle \det(X) X^{-\top}, dX \rangle \implies \nabla(\det(X)) = \det(X) X^{-\top}.$

Доказательство.

- Для $f(x) = \langle c, x \rangle$ запишем

$$f(x+h) - f(x) = \langle c, x+h \rangle - \langle c, x \rangle = \langle c, h \rangle.$$

При этом $h \rightarrow \langle c, h \rangle$ — линейный оператор. То есть по определению

$$df(x)[h] = \langle c, h \rangle.$$

- Для $f(x) = \langle Ax, x \rangle$ запишем

$$f(x+h) - f(x) = \langle Ax + Ah, x+h \rangle - \langle Ax, x \rangle = \langle (A + A^\top)x, h \rangle + \langle Ah, h \rangle.$$

Заметим, что

$$\langle Ah, h \rangle \leq \|Ah\|_2 \|h\|_2 \leq \|A\|_2 \|h\|_2^2 = o(\|h\|_2),$$

где первое неравенство следует из Коши–Буняковского–Шварца (0.3), а второе — из подчинённости матричной нормы (Замечание С1.6). При этом $h \rightarrow \langle (A + A^\top)x, h \rangle$ — линейный оператор. То есть по определению

$$df(x)[h] = \langle (A + A^\top)x, h \rangle.$$

- Для $f(X) = X^{-1}$ запишем

$$\begin{aligned} f(X+H) - f(X) &= (X+H)^{-1} - X^{-1} = (X(I_d + X^{-1}H))^{-1} - X^{-1} \\ &= ((I_d + X^{-1}H)^{-1} - I_d)X^{-1}. \end{aligned}$$

Поскольку H можно выбрать так, чтобы $\|X^{-1}H\|_2 \leq \|X^{-1}\|_2 \|H\|_2 < 1$, то можно воспользоваться разложением в ряд Неймана (Параграф 3.3 [35]):

$$(I_d + X^{-1}H)^{-1} = I_d - X^{-1}H + \sum_{k=2}^{\infty} (-X^{-1}H)^k.$$

Оценим норму последнего слагаемого:

$$\begin{aligned} \left\| \sum_{k=2}^{\infty} (-X^{-1}H)^k \right\|_2 &\leq \sum_{k=2}^{\infty} \|(-X^{-1}H)^k\|_2 \leq \sum_{k=2}^{\infty} \|X^{-1}\|_2^k \|H\|_2^k \\ &= \frac{\|X^{-1}\|_2^2 \|H\|_2^2}{1 - \|X^{-1}\|_2 \|H\|_2} = o(\|H\|_2), \end{aligned}$$

где первое неравенство получается из неравенства треугольника в пределе, второе — из субмультипликативности матричной нормы (Замечание C1.3), а третье равенство — это сумма геометрической прогрессии. В итоге получаем разность

$$f(X + H) - f(X) = -X^{-1}HX^{-1} + o(\|H\|_2),$$

при этом $H \rightarrow -X^{-1}HX^{-1}$ — линейный оператор. То есть по определению

$$df(X)[H] = -X^{-1}HX^{-1}.$$

- Для $f(X) = \det(X)$ запишем

$$\begin{aligned} f(X + H) - f(X) &= \det(X + H) - \det(X) = \det(X(I_d + X^{-1}H)) - \det(X) \\ &= \det(X)(\det(I_d + X^{-1}H) - 1). \end{aligned}$$

Отдельно оценим $\det(I_d + X^{-1}H)$. Пусть $\lambda_i(X^{-1}H)$ — собственные числа матрицы $X^{-1}H$ (в произвольном порядке и, возможно, комплексные). Тогда собственными числами матрицы $I_d + X^{-1}H$ будут $1 + \lambda_i(X^{-1}H)$. Поэтому

$$\begin{aligned} \det(I_d + X^{-1}H) &= \prod_{i=1}^d [1 + \lambda_i(X^{-1}H)] \\ &= 1 + \sum_{i=1}^d \lambda_i(X^{-1}H) + \left(\sum_{1 \leq i \leq j \leq d} \lambda_i(X^{-1}H)\lambda_j(X^{-1}H) + \dots \right), \end{aligned}$$

где многоточие обозначает всевозможные тройки, четвёрки и так далее из $\lambda_i(X^{-1}H)$. Для произвольной матрицы $A \in \mathbb{R}^{d \times d}$ все её собственные числа по модулю не превосходят её операторную норму (Утверждение C1.2). Следовательно, всё выражение в скобках — $o(\|H\|_2)$, поскольку в каждом слагаемом больше одного собственного числа. Таким образом,

$$\det(I_d + X^{-1}H) = 1 + \sum_{i=1}^d \lambda_i(X^{-1}H) + o(\|H\|_2) = 1 + \text{Tr}(X^{-1}H) + o(\|H\|_2).$$

При этом $H \rightarrow \det(X) \text{Tr}(X^{-1}H)$ — линейный оператор. То есть по определению

$$df(X)[H] = \det(X) \text{Tr}(X^{-1}H) = \det(X) \langle X^{-\top}, H \rangle.$$

■

Замечание C2.9. Мы доказали формулу $d(\det(X)) = \det(X) \langle X^{-\top}, dX \rangle$ только для обратимых X . Однако выражение для $d(\det(X))$ можно получить и для произвольной матрицы из $\mathbb{R}^{d \times d}$. Эта формула называется *формулой Якоби* и записывается как

$$d(\det(X)) = \langle \text{Adj}(X)^{\top}, dX \rangle,$$

где $\text{Adj}(X)$ — присоединённая матрица к X . Она определяется как

$$\text{Adj}(X)_{ji} = (-1)^{(i+j)} M_{ij},$$

где M_{ij} — дополнительный минор — определитель матрицы, получившийся вычеркиванием i -ой строки и j -ого столбца из X . В случае невырожденной X выполнено

$\text{Adj}(X) = \det(X)X^{-1}$, и формулы переходят друг в друга. Вспомним формулу вычисления определителя через дополнительные миноры по i -ой строке

$$\det(X) = \sum_{j=1}^d x_{ij}(-1)^{(i+j)}M_{ij}.$$

Тогда градиент равен

$$\frac{\partial \det(X)}{\partial x_{ij}} = (-1)^{(i+j)}M_{ij} = \text{Adj}(X)_{ji}.$$

С2.3.1 Дифференцирование по вектору

В машинном обучении широко известен Метод Наименьших Квадратов (МНК). По матрице признаков $\tilde{A}$ и вектору параметров x требуется линейно приблизить целевой вектор $\tilde{b}$. Для решения этой задачи требуется вычислять градиент невязки

$$f(x) = \frac{1}{2}\|\tilde{A}x - \tilde{b}\|_2^2 = \frac{1}{2}\langle \tilde{A}x, \tilde{A}x \rangle - \langle \tilde{A}x, \tilde{b} \rangle + \frac{1}{2}\|\tilde{b}\|_2^2$$

Если мы введём обозначения $A = \tilde{A}^\top \tilde{A}$, $b = -\tilde{A}^\top \tilde{b}$, $c = \frac{1}{2}\|\tilde{b}\|_2^2$, то вычисление градиента невязки эквивалентно вычислению градиента функции

$$f(x) = \frac{1}{2}\langle Ax, x \rangle + \langle b, x \rangle + c.$$

Пример С2.3. Найдите $\nabla f(x)$ и $\nabla^2 f(x)$ функции $f: \mathbb{R}^d \rightarrow \mathbb{R}$:

$$f(x) = \frac{1}{2}\langle Ax, x \rangle + \langle b, x \rangle + c, \quad A \in \mathbb{R}^{d \times d}, \quad b \in \mathbb{R}^d, \quad c \in \mathbb{R}.$$

Решение. Найдём первый дифференциал

$$\begin{aligned} df(x) &= d\left(\frac{1}{2}\langle Ax, x \rangle + \langle b, x \rangle + c\right) = \frac{1}{2}\langle (A + A^\top)x, dx \rangle + \langle b, dx \rangle + 0 \\ &= \left\langle \frac{1}{2}(A + A^\top)x + b, dx \right\rangle. \end{aligned}$$

Приведя к стандартному виду $df(x) = \langle \nabla f(x), dx \rangle$, получаем

$$\nabla f(x) = \frac{1}{2}(A + A^\top)x + b.$$

Для поиска гессиана фиксируем первое приращение dx_1 у первого дифференциала и берём уже от него ещё один дифференциал

$$d^2 f(x) = d\left\langle \frac{1}{2}(A + A^\top)x + b, dx_1 \right\rangle = \left\langle \frac{1}{2}(A + A^\top) dx, dx_1 \right\rangle.$$

Переносим и транспонируем матрицу в скалярном произведении, но поскольку $A + A^\top$ симметричная, то она не меняется:

$$d^2 f(x) = \left\langle dx, \frac{1}{2}(A + A^\top)^\top dx_1 \right\rangle = \left\langle \frac{1}{2}(A + A^\top) dx_1, dx \right\rangle.$$

Следовательно, приведя к стандартному виду $d^2 f(x) = \langle \nabla^2 f(x) dx_1, dx \rangle$, получаем гессиан

$$\nabla^2 f(x) = \frac{1}{2}(A + A^\top).$$

■

Замечание С2.10. Заметим, что в случае если A симметричная, то

$$\nabla f(x) = Ax + b, \quad \nabla^2 f(x) = A.$$

Пример С2.4. Найдите $\nabla f(x)$ и $\nabla^2 f(x)$ функции $f: \mathbb{R}^d \setminus \{0\} \rightarrow \mathbb{R}$:

$$f(x) = \log \langle Ax, x \rangle, \quad A \in \mathbb{S}_{++}^d.$$

Решение. Найдём первый дифференциал

$$df(x) = d \log \langle Ax, x \rangle = \frac{1}{\langle Ax, x \rangle} d \langle Ax, x \rangle = \frac{2 \langle Ax, dx \rangle}{\langle Ax, x \rangle} = \left\langle \frac{2Ax}{\langle Ax, x \rangle}, dx \right\rangle.$$

Приведя к стандартному виду $df(x) = \langle \nabla f(x), dx \rangle$, получаем

$$\nabla f(x) = \frac{2Ax}{\langle Ax, x \rangle}.$$

Теперь найдём дифференциал градиента

$$\begin{aligned} d \left(\frac{2Ax}{\langle Ax, x \rangle} \right) &= \frac{d(2Ax) \langle Ax, x \rangle - (2Ax) d \langle Ax, x \rangle}{\langle Ax, x \rangle^2} = \frac{2 \langle Ax, x \rangle A dx - 4Ax \langle Ax, dx \rangle}{\langle Ax, x \rangle^2} \\ &= \left(\frac{2A}{\langle Ax, x \rangle} - \frac{4Ax x^\top A}{\langle Ax, x \rangle^2} \right) dx = J_{\nabla f} dx. \end{aligned}$$

Поскольку $\nabla^2 f(x) = J_{\nabla f}^\top(x)$, а гессиан симметричен из-за непрерывности, то

$$\nabla^2 f(x) = \frac{2A}{\langle Ax, x \rangle} - \frac{4Ax x^\top A}{\langle Ax, x \rangle^2}.$$

■

Пример С2.5. Найдите $\nabla f(x)$ и $\nabla^2 f(x)$ функции $f: \mathbb{R}^d \setminus \{0\} \rightarrow \mathbb{R}$:

$$f(x) = \|x\|_2.$$

Решение. Найдём первый дифференциал

$$df(x) = d \langle x, x \rangle^{\frac{1}{2}} = \frac{d \langle x, x \rangle}{2 \langle x, x \rangle^{\frac{1}{2}}} = \left\langle \frac{x}{2 \langle x, x \rangle^{\frac{1}{2}}}, dx \right\rangle = \left\langle \frac{x}{\|x\|_2}, dx \right\rangle.$$

Приведя к стандартному виду $df(x) = \langle \nabla f(x), dx \rangle$, получаем

$$\nabla f(x) = \frac{x}{\|x\|_2}.$$

Теперь посчитаем второй дифференциал, зафиксировав приращение dx_1 первого

$$\begin{aligned} d^2 f(x) &= d \left\langle \frac{x}{\|x\|}, dx_1 \right\rangle = \left\langle \frac{dx \|x\|_2 - x d(\|x\|_2)}{\|x\|_2^2}, dx_1 \right\rangle \\ &= \left\langle \frac{dx}{\|x\|_2} - x \left\langle \frac{x}{\|x\|_2^3}, dx \right\rangle, dx_1 \right\rangle = \left\langle \left(\frac{I_d}{\|x\|_2} - \frac{xx^\top}{\|x\|_2^3} \right) dx, dx_1 \right\rangle. \end{aligned}$$

Поскольку $\nabla^2 f(x) = J_{\nabla f}^\top$, а гессиан симметричен

$$\nabla^2 f(x) = \frac{I_d}{\|x\|_2} - \frac{xx^\top}{\|x\|_2^3}.$$

■

Пример C2.6. Найдите $\nabla f(x)$ и $\nabla^2 f(x)$ функции $f: \mathbb{R}^d \setminus \{0\} \rightarrow \mathbb{R}$:

$$f(x) = \frac{1}{3} \|x\|_2^3.$$

Решение. Найдём первый дифференциал

$$df(x) = \frac{1}{3} d\langle x, x \rangle^{3/2} = \frac{1}{2} \langle x, x \rangle^{1/2} d\langle x, x \rangle = \langle x, x \rangle^{1/2} \langle x, dx \rangle = \langle x \|x\|_2, dx \rangle.$$

Приведя к стандартному виду $df = \langle \nabla f(x), dx \rangle$, получаем

$$\nabla f(x) = \|x\|_2 x.$$

Найдём второй дифференциал

$$\begin{aligned} d^2 f(x) &= d(\|x\|_2 \langle x, dx_1 \rangle) = \left\langle \frac{x}{\|x\|_2}, dx \right\rangle \langle x, dx_1 \rangle + \|x\|_2 \langle dx, dx_1 \rangle \\ &= \left\langle dx, \left(\frac{xx^\top}{\|x\|_2} + I_d \|x\|_2 \right) dx_1 \right\rangle. \end{aligned}$$

Получаем гессиан

$$\nabla^2 f(x) = \frac{xx^\top}{\|x\|_2} + I_d \|x\|_2.$$

■

Замечание C2.11. Заметим, что гессиан не определен в точке $x = 0$, поскольку мы дифференцировали норму, а её градиент не определен в 0. Тем не менее, можно найти производную отображения из условия в $x = 0$ по определению. Зафиксируем

приращение h_1 и рассмотрим

$$\begin{aligned} \lim_{\|h_2\|_2 \rightarrow 0} \frac{\|df(h_2)[h_1] - df(0)[h_1]\|_2}{\|h_2\|_2} &= \lim_{\|h_2\|_2 \rightarrow 0} \frac{|\langle \|h_2\|_2 h_2, h_1 \rangle|}{\|h_2\|_2} \\ &= \lim_{\|h_2\|_2 \rightarrow 0} \frac{\|h_2\|_2 |\langle h_2, h_1 \rangle|}{\|h_2\|_2} = \lim_{\|h_2\|_2 \rightarrow 0} |\langle h_2, h_1 \rangle| = 0. \end{aligned}$$

Следовательно, по определению вторая производная в точке $x = 0$ равна 0. Можно даже сказать, что отображение дважды непрерывно дифференцируемо, потому что

$$\lim_{\|x\|_2 \rightarrow 0} \left(\frac{xx^\top}{\|x\|_2} + I_d \|x\|_2 \right) = 0.$$

Далее рассмотрим модель логистической регрессии — модель машинного обучения для задачи разделения двух классов. Её обучение может сводиться к оптимизации функции

$$f(x) = \log(1 + \exp(\langle x, a \rangle)).$$

Пример C2.7. Найдите $\nabla f(x)$ и $\nabla^2 f(x)$ функции $f : \mathbb{R}^d \rightarrow \mathbb{R}$:

$$f(x) = \log(1 + \exp(\langle x, a \rangle)), \quad a \in \mathbb{R}^d.$$

Решение. Найдём первый дифференциал

$$\begin{aligned} df(x) &= d \log(1 + \exp(\langle x, a \rangle)) = \frac{1}{1 + \exp(\langle x, a \rangle)} d(1 + \exp(\langle x, a \rangle)) \\ &= \frac{\exp(\langle x, a \rangle)}{1 + \exp(\langle x, a \rangle)} d\langle x, a \rangle = \left\langle \frac{\exp(\langle x, a \rangle)}{1 + \exp(\langle x, a \rangle)} a, dx \right\rangle. \end{aligned}$$

Для удобства введём сигмоиду

$$\sigma(x) := \frac{1}{1 + \exp(-x)}.$$

При этом заметим, что $\sigma(-x) = 1 - \sigma(x)$ и $\sigma'(x) = \sigma(x)(1 - \sigma(x))$. После этого приведём $df(x)$ к стандартному виду и получим

$$\nabla f(x) = \sigma(\langle x, a \rangle) a.$$

Таким образом, градиент $\nabla f(x)$ — вектор, коллинеарный вектору a с коэффициентом $\sigma(\langle a, x \rangle) \in (0, 1)$. От точки x зависит лишь длина градиента, но не направление.

Теперь посчитаем второй дифференциал, зафиксировав приращение dx_1 первого. Имеем

$$\begin{aligned} d^2 f(x) &= d\langle \sigma(\langle x, a \rangle) a, dx_1 \rangle = \langle d\sigma(\langle x, a \rangle) a, dx_1 \rangle = \langle \sigma'(\langle x, a \rangle) d\langle x, a \rangle a, dx_1 \rangle \\ &= \langle \sigma(\langle x, a \rangle) (1 - \sigma(\langle x, a \rangle)) \langle dx, a \rangle a, dx_1 \rangle \\ &= \sigma(\langle x, a \rangle) (1 - \sigma(\langle x, a \rangle)) \langle \langle dx, a \rangle a, dx_1 \rangle \\ &= \sigma(\langle x, a \rangle) (1 - \sigma(\langle x, a \rangle)) (dx^\top a a^\top dx_1) \\ &= \sigma(\langle x, a \rangle) (1 - \sigma(\langle x, a \rangle)) \langle a a^\top dx_1, dx \rangle. \end{aligned}$$

Получим

$$\nabla^2 f(x) = \sigma(\langle x, a \rangle)(1 - \sigma(\langle x, a \rangle))aa^\top.$$

Заметим, что $\nabla^2 f(x)$ — одноранговая матрица, пропорциональная $aa^\top$ с коэффициентом $\sigma(\langle x, a \rangle)(1 - \sigma(\langle x, a \rangle)) \in (0, 0.25)$. Точка x влияет лишь на коэффициент. ■

С2.3.2 Дифференцирование по матрице

Для подсчёта градиентов по матрицам активно применяются производные таких функций, как $\det$, Tr , X^{-1} . Именно поэтому мы посвятили раздел их вычислению. Более того, очень полезным окажется след матрицы (Утверждение C1.5).

Пример C2.8. Найдите $\nabla f(X)$ функции $f : \mathbb{R}^{n \times d} \rightarrow \mathbb{R}$:

$$f(X) = \|AX - B\|_F, \quad A \in \mathbb{R}^{m \times n}, \quad B \in \mathbb{R}^{m \times d}.$$

Решение. Сначала отдельно вычислим $d\|X\|_F$:

$$d\|X\|_F = d\langle X, X \rangle^{1/2} = \frac{d\langle X, X \rangle}{2\langle X, X \rangle^{1/2}} = \left\langle \frac{2X}{2\langle X, X \rangle^{1/2}}, dX \right\rangle = \left\langle \frac{X}{\|X\|_F}, dX \right\rangle.$$

Тогда первый дифференциал

$$\begin{aligned} df(X) &= d\|AX - B\|_F = \left\langle \frac{AX - B}{\|AX - B\|_F}, d(AX - B) \right\rangle = \left\langle \frac{AX - B}{\|AX - B\|_F}, A dX \right\rangle \\ &= \text{Tr} \left(\frac{(AX - B)^\top}{\|AX - B\|_F} A dX \right) = \text{Tr} \left(\left(\frac{A^\top (AX - B)}{\|AX - B\|_F} \right)^\top dX \right) \\ &= \left\langle \frac{A^\top (AX - B)}{\|AX - B\|_F}, dX \right\rangle. \end{aligned}$$

Тогда градиент

$$\nabla f(X) = \frac{A^\top (AX - B)}{\|AX - B\|_F}.$$

■

Пример C2.9. Найдите $\nabla f(X)$ функции $f : \mathbb{R}^{d \times d} \rightarrow \mathbb{R}$:

$$f(X) = \text{Tr}(AXBX^{-1}), \quad A, B \in \mathbb{R}^{d \times d},$$

при $\det(X) \neq 0$.

Решение. Перепишем след через скалярное произведение:

$$f(X) = \langle I_d, AXBX^{-1} \rangle.$$

Найдём первый дифференциал

$$\begin{aligned}
 df(X) &= \langle I_d, d(AXBX^{-1}) \rangle = \langle I_d, A(dX)BX^{-1} + AXBd(X^{-1}) \rangle \\
 &= \langle I_d, A(dX)BX^{-1} - AXBX^{-1}(dX)X^{-1} \rangle \\
 &= \text{Tr}(A(dX)BX^{-1}) - \text{Tr}(AXBX^{-1}(dX)X^{-1}) \\
 &= \text{Tr}(BX^{-1}A(dX)) - \text{Tr}(X^{-1}AXBX^{-1}(dX)) \\
 &= \langle A^\top X^{-\top} B^\top - X^{-\top} B^\top X^\top A^\top X^{-\top}, dX \rangle.
 \end{aligned}$$

При работе со скалярными произведениями можно переходить к следу и обратно, используя таким образом его полезные свойства. Главное, не забывать о транспонировании.

Тогда градиент

$$\nabla f(X) = A^\top X^{-\top} B^\top - X^{-\top} B^\top X^\top A^\top X^{-\top}.$$

■

Пример С2.10. Найдите $\nabla f(X)$ функции $f : \mathbb{R}^{n \times d} \rightarrow \mathbb{R}$:

$$f(X) = \text{Tr}(AX^\top X), \quad A \in \mathbb{R}^{d \times d}.$$

Решение. Перепишем след через скалярное произведение

$$f(X) = \langle I_d, AX^\top X \rangle.$$

Найдём первый дифференциал

$$\begin{aligned}
 df(X) &= d\langle I_d, AX^\top X \rangle = \langle I_d, A d(X^\top X) \rangle = \langle I_d, A dX^\top X \rangle + \langle I_d, AX^\top dX \rangle \\
 &= \text{Tr}(A dX^\top X) + \langle XA^\top, dX \rangle = \text{Tr}(XA dX^\top) + \langle XA^\top, dX \rangle \\
 &= \langle XA, dX \rangle + \langle XA^\top, dX \rangle = \langle XA + XA^\top, dX \rangle.
 \end{aligned}$$

Тогда градиент

$$\nabla f(X) = XA + XA^\top.$$

■

Пример С2.11. Найдите $\nabla f(X)$ и $d^2 f(X)$ функции $f : \mathbb{S}_{++}^d \rightarrow \mathbb{R}$:

$$f(X) = \log(\det(X)).$$

Решение. Найдём первый дифференциал

$$df(X) = d\log(\det(X)) = \frac{d(\det(X))}{\det(X)} = \frac{\det(X)\langle X^{-\top}, dX \rangle}{\det(X)} = \langle X^{-1}, dX \rangle.$$

Тогда градиент

$$\nabla f(X) = X^{-1}.$$

Теперь посчитаем второй дифференциал, зафиксировав приращение dX_1 первого

$$d^2 f(X) = \langle dX^{-1}, dX_1 \rangle = -\langle X^{-1} dX X^{-1}, dX_1 \rangle.$$

Мы получили билинейную форму от dX, dX_1 , выписывать тензор производных в явном виде мы не будем. Вместо этого посмотрим, является ли эта форма отрицательно полуопределённой. По мере прохождения курса станет понятно, зачем мы проверяем это условие. Возьмём $H \in \mathbb{S}^d$ из исходного пространства. Поскольку $X \in \mathbb{S}_{++}^d$, то $X^{-1} \in \mathbb{S}_{++}^d$. Матрицу X^{-1} можно разложить на произведение двух одинаковых матриц, обозначим их $X^{-1/2}$, т.е. $X^{-1} = X^{-1/2} X^{-1/2}$. Такое разложение можно получить, перейдя в ортонормированный базис из собственных векторов V , который всегда существует для симметричных матриц, при этом все собственные значения будут положительными:

$$X^{-1} = V \Lambda V^\top \implies X^{-1/2} = V \sqrt{\Lambda} V^\top.$$

Тогда

$$\begin{aligned} d^2 f(X) [H, H] &= -\langle X^{-1} H X^{-1}, H \rangle = -\text{Tr}(X^{-1} H X^{-1} H) \\ &= -\text{Tr}(X^{-1/2} X^{-1/2} H X^{-1/2} X^{-1/2} H) \\ &= -\text{Tr}(X^{-1/2} H X^{-1/2} X^{-1/2} H X^{-1/2}) \\ &= -\langle X^{-1/2} H X^{-1/2}, X^{-1/2} H X^{-1/2} \rangle \\ &= -\|X^{-1/2} H X^{-1/2}\|_F^2 \leq 0. \end{aligned}$$

■

Пример C2.12. Найдите $\nabla f(X)$ функции $f : \mathbb{S}_{++}^d \rightarrow \mathbb{R}$:

$$f(X) = \det(AX^{-1}B), \quad A \in \mathbb{R}^{n \times d}, B \in \mathbb{R}^{d \times n},$$

при $\det(AX^{-1}B) \neq 0$.

Решение. Найдём первый дифференциал

$$\begin{aligned} df(X) &= d(\det(AX^{-1}B)) = \det(AX^{-1}B) \left\langle (AX^{-1}B)^{-\top}, d(AX^{-1}B) \right\rangle \\ &= \det(AX^{-1}B) \left\langle (AX^{-1}B)^{-\top}, A dX^{-1} B \right\rangle \\ &= -\det(AX^{-1}B) \left\langle (AX^{-1}B)^{-\top}, AX^{-1} dX X^{-1} B \right\rangle \\ &= -\det(AX^{-1}B) \text{Tr}\left((AX^{-1}B)^{-1} AX^{-1} dX X^{-1} B\right) \\ &= -\det(AX^{-1}B) \text{Tr}\left(X^{-1} B (AX^{-1}B)^{-1} AX^{-1} dX\right) \\ &= -\det(AX^{-1}B) \left\langle \left(X^{-1} B (AX^{-1}B)^{-1} AX^{-1}\right)^\top, dX \right\rangle. \end{aligned}$$

Тогда градиент

$$\nabla f(X) = -\det(AX^{-1}B) X^{-\top} A^\top (AX^{-1}B)^{-\top} B^\top X^{-\top}.$$

■

С2.3.3 Другие примеры

Помимо классических примеров, когда нужно продифференцировать функцию по вектору/матрице, проводя алгоритмические действия, бывают и менее тривиальные. В этом разделе мы посвятим их рассмотрению немного времени.

В нейронных сетях часто встречается функция softmax, которая позволяет отобразить вектор из d координат в распределение вероятностей на d исходах:

$$\text{softmax}(x) := \left(\frac{\exp(x_1)}{\sum_{i=1}^d \exp(x_i)}, \dots, \frac{\exp(x_d)}{\sum_{i=1}^d \exp(x_i)} \right)^\top.$$

Пример С2.13. Найдите матрицу Якоби $J(x)$ функции $s : \mathbb{R}^d \rightarrow \mathbb{R}^d$:

$$s(x) = \left(\frac{\exp(x_1)}{\sum_{i=1}^d \exp(x_i)}, \dots, \frac{\exp(x_d)}{\sum_{i=1}^d \exp(x_i)} \right)^\top.$$

Решение. Считаём частные производные по определению

- При $k \neq j$

$$\frac{\partial s_k}{\partial x_j} = \frac{\partial}{\partial x_j} \frac{\exp(x_k)}{\sum_{i=1}^d \exp(x_i)} = -\frac{\exp(x_k) \exp(x_j)}{(\sum_{i=1}^d \exp(x_i))^2} = -s_k \cdot s_j,$$

- при $k = j$

$$\begin{aligned} \frac{\partial s_j}{\partial x_j} &= \frac{\partial}{\partial x_j} \frac{\exp(x_j)}{\sum_{i=1}^d \exp(x_i)} = \frac{\exp(x_j)(\sum_{i=1}^d \exp(x_i)) - \exp(x_j) \frac{\partial}{\partial x_j} (\sum_{i=1}^d \exp(x_i))}{(\sum_{i=1}^d \exp(x_i))^2} \\ &= \frac{\exp(x_j)}{\sum_{i=1}^d \exp(x_i)} - \frac{\exp(x_j) \exp(x_j)}{(\sum_{i=1}^d \exp(x_i))^2} = s_j(1 - s_j). \end{aligned}$$

Таким образом, получаем

$$J_{k,j} = \begin{cases} -s_k \cdot s_j, & k \neq j; \\ s_j(1 - s_j), & k = j. \end{cases}$$

■

Не менее часто на практике приходится применять какую-либо функцию к выходу линейного слоя покоординатно, то есть для каждого отдельно взятого нейрона.

Пример С2.14. Найдите $\nabla f(x)$ и $\nabla^2 f(x)$ функции $f : \mathbb{R}^d \rightarrow \mathbb{R}$:

$$f(x) = h(g(x)),$$

где функция $g : \mathbb{R} \rightarrow \mathbb{R}$ действует поэлементно:

$$g(x) = \sin(x),$$

а функция $h : \mathbb{R}^d \rightarrow \mathbb{R}$:

$$h(u) = \sum_{i=1}^d u_i.$$

Решение. Вспомним правило матрицы Якоби сложной функции:

$$J_f(x) = J_h(u)J_g(x) \implies \nabla f(x) = J_g^\top(x)\nabla h(u).$$

Далее посчитаем матрицу Якоби функции вида $g(x) = \begin{pmatrix} g(x_1) \\ \vdots \\ g(x_d) \end{pmatrix}$. Получим

$$J_g(x) = \text{diag}(g'(x_1), \dots, g'(x_d)) = \text{diag}(g'(x)) = J_g^\top(x).$$

При умножении $J_g(x)$ на вектор удобно пользоваться поэлементным умножением матриц:

$$(A \odot B)_{ij} = A_{ij} \cdot B_{ij}.$$

Результат умножения $J_g(x)$ на вектор y равен

$$J_g(x)y = \begin{pmatrix} g'(x_1) \\ \vdots \\ g'(x_d) \end{pmatrix} \odot y = g'(x) \odot y.$$

Заметим, что эта операция является довольно быстро вычисляемой и легко поддаётся параллелизации. Теперь приступим непосредственно к примеру. Найдем $J_g(x)$:

$$J_g(x) = \text{diag}(\cos(x_1), \dots, \cos(x_d)) = \text{diag}(\cos(x)).$$

Теперь найдем $\nabla h(u)$:

$$\nabla h(u) = \mathbf{1}.$$

Тогда $\nabla f(x)$:

$$\nabla f(x) = J_g^\top(x)\nabla h(u) = \cos(x) \odot \mathbf{1} = \cos(x).$$

Выпишем гессиан функции:

$$\nabla^2 f(x) = J_{\nabla f}^\top(x) = \text{diag}(-\sin(x)).$$

■

Пример C2.15. Выразите $\phi'(\alpha)$ и $\phi''(\alpha)$ функции $\phi: \mathbb{R} \rightarrow \mathbb{R}$:

$$\phi(\alpha) = f(x + \alpha p), \quad x, p \in \mathbb{R}^d$$

через $\nabla f, \nabla^2 f$ дважды непрерывно дифференцируемой функции $f: \mathbb{R}^d \rightarrow \mathbb{R}$.

Решение. Важно помнить, что дифференцирование происходит не по стандартному вектору x , а по скаляру α со всеми вытекающими свойствами. Первый дифференциал

$$d\phi = \langle \nabla f(x + \alpha p), d(x + \alpha p) \rangle = \langle \nabla f(x + \alpha p), p \rangle d\alpha.$$

Заметим, что мы привели дифференциал к стандартному виду $d\phi = \phi'(\alpha) d\alpha$, то есть множитель перед $d\alpha$ — это производная:

$$\phi'(\alpha) = \langle \nabla f(x + \alpha p), p \rangle.$$

Дифференциал от первой производной:

$$\begin{aligned} d(\phi'(\alpha)) &= d\langle \nabla f(x + \alpha p), p \rangle = \left\langle (\nabla^2 f(x + \alpha p))^T d(x + \alpha p), p \right\rangle \\ &= \langle \nabla^2 f(x + \alpha p) p d\alpha, p \rangle = \langle \nabla^2 f(x + \alpha p) p, p \rangle d\alpha. \end{aligned}$$

Тогда вторая производная:

$$\phi''(\alpha) = \langle \nabla^2 f(x + \alpha p) p, p \rangle.$$

■

Теперь посмотрим на случай, когда функция переводит матрицу в вектор, и записать производные в компактном виде через матрицу или вектор не получается.

Пример С2.16. Найдите $\nabla f(X)$ функции $f: \mathbb{R}^{n \times d} \rightarrow \mathbb{R}^n$:

$$f(X) = Xa, \quad a \in \mathbb{R}^d.$$

Решение. Дифференциал найти достаточно просто:

$$df(X) = dX a.$$

Но вот записать производную в виде вектора или матрицы уже не выйдет — нужен тензор третьего порядка, имеющий вид

$$\frac{\partial f_k}{\partial X_{ij}}(X)$$

размерности $n \times n \times d$. Для этого выразим скалярную зависимость функции $f(X)$:

$$f_k(X) = \sum_{l=1}^d X_{kl} a_l.$$

Теперь возьмём производную $\frac{\partial}{\partial X_{ij}}$. Получим

$$\frac{\partial f_k}{\partial X_{ij}}(X) = \sum_{l=1}^d \frac{\partial (X_{kl} a_l)}{\partial X_{ij}} = \sum_{l=1}^d \delta(i=k, j=l) a_l = \delta(i=k) \sum_{l=1}^d \delta(j=l) a_l = \delta(i=k) a_j.$$

■

Пример С2.17. Рассмотрим прикладную задачу. Пусть имеется модель, которая для некоторого значения x возвращает y по правилу: $y = Ax + \varepsilon$, где $A \in \mathbb{R}^{n \times d}$ — некоторая матрица, а ε — некоторый шум. Чтобы не загромождать повествование техническими деталями, будем предполагать, что $\det(A^T A) \neq 0$. Имея дело с такой моделью, мы хотим решать задачу:

$$\hat{x} = \operatorname{argmin}_{x: \hat{y} = Ax + \varepsilon} \|\varepsilon\|_2^2.$$

Мы хотим определять, какой вход модели был наиболее вероятен, если она выдала значение $\hat{y}$. Тогда, выразив $\xi = \hat{y} - Ax$, будем искать минимум функции $\|\hat{y} - Ax\|_2^2$.

Для этого нужно посчитать градиент и приравнять его к 0. Запишем

$$\begin{aligned} d\|\hat{y} - Ax\|_2^2 &= d\langle \hat{y} - Ax, \hat{y} - Ax \rangle = -\langle A dx, \hat{y} - Ax \rangle - \langle \hat{y} - Ax, A dx \rangle \\ &= -2\langle \hat{y} - Ax, A dx \rangle = -2\langle A^\top (\hat{y} - Ax), dx \rangle. \end{aligned}$$

Отсюда получаем, что градиент равен $\nabla f(x) = -2A^\top (\hat{y} - Ax)$. Приравнивая его к 0, имеем

$$\hat{x} = (A^\top A)^{-1} A^\top \hat{y}.$$

С2.4 Автоматическое дифференцирование

С2.4.1 Граф вычислений

Настало время поговорить о том, как происходит подсчёт градиентов в реальной жизни. Чаще всего функции, с которыми приходится иметь дело на практике, представляют собой последовательность (дифференцируемых) параметрических преобразований. Таким образом, их можно представить в виде *вычислительного графа*, где промежуточным вершинам соответствуют преобразования, входящим стрелкам — входные переменные, а выходным стрелкам — результат преобразования. Этот граф должен быть ациклическим.




Рис. С2.1: Граф вычислений для логистической регрессии.

На Рисунке С2.1 сплошными линиями приведён вычислительный граф для логистической регрессии

$$f(x) = \log(1 + \exp(-b\langle x, a \rangle)),$$

где $a \in \mathbb{R}^d$, $b \in \{-1, 1\}$ — вход, а $x \in \mathbb{R}^d$ — параметр.

Вычисление значения функции по заданному входу называется *forward pass* (*прямым проходом*). На этом этапе происходит преобразование исходного вектора в целевой. Последовательно строятся промежуточные значения — результаты применения преобразований к предыдущим значениям слева направо. В случае линейного графа преобразование можно записать формулой

$$f(x) = u_n(u_{n-1}(\dots(u_1(x)))). \quad (\text{С2.1})$$

Но как же считать производные в таких графах? Ответ может дать правило вычисления дифференциала сложной функции. Рассмотрим одну конкретную вершину в графе вида $u(x_1, \dots, x_d)$ и её дифференциал

$$du = J_u dx,$$

причём каждый следующий дифференциал dx_i можно расписать через предыдущую вершину (если, конечно, x_i не являются искомыми переменными), двигаясь по рекурсии в графе от детей к родителям. В случае линейного графа (C2.1) получим итоговую формулу

$$\frac{\partial f}{\partial x}(x) = \frac{\partial u_1}{\partial x}(x) \cdot \frac{\partial u_2}{\partial u_1}(u_1) \cdot \dots \cdot \underbrace{\frac{\partial u_n}{\partial u_{n-1}}(u_{n-1})}_{\frac{\partial f}{\partial u_{n-1}}}. \quad (\text{C2.2})$$

C2.4.2 Backward propagation

Основная идея *backward propagation* (обратного распространения ошибки) заключается в подсчёте формулы (C2.2) **справа налево**.

В общем случае, пусть $u_1, \dots, u_n$ — вершины графа вычислений в топологическом порядке (т.е. родители идут перед потомками). Тогда общий алгоритм действий выглядит так

1. Произвести forward pass и сохранить все значения u_i как функции от их родителей;
2. Воспользоваться производной сложной функции:

$$J_f(u) = J_f J_u.$$

Или, что тоже самое, что для всех $i = \overline{n-1, 1}$ посчитать

$$\frac{\partial f}{\partial u_i} = \sum_{u_j \in \text{потомки}(u_i)} \frac{\partial u_j}{\partial u_i} \frac{\partial f}{\partial u_j}.$$

Вычисление backward propagation на Рисунке C2.1 показано пунктирными линиями.

Пример C2.18. Посчитайте backward propagation для графа, изображенного на Рисунке C2.2, где $x \in \mathbb{R}^d$ — вход, $\omega \in \mathbb{R}^d$, $b \in \mathbb{R}$ — параметры, а $\lambda, t \in \mathbb{R}$ — фиксированные константы.




Рис. С2.2: Граф вычислений для логистической регрессии с квадратичной ошибкой и ℓ_2 -регуляризацией.

Решение.

$$\begin{aligned}
 \frac{\partial \mathcal{L}}{\partial R} &= \frac{\partial \mathcal{L}}{\partial R} \frac{\partial \mathcal{L}}{\partial \mathcal{L}} = \lambda, \\
 \frac{\partial \mathcal{L}}{\partial L} &= \frac{\partial \mathcal{L}}{\partial L} \frac{\partial \mathcal{L}}{\partial \mathcal{L}} = 1, \\
 \frac{\partial \mathcal{L}}{\partial y} &= \frac{\partial L}{\partial y} \frac{\partial \mathcal{L}}{\partial L} = (y - t) \frac{\partial \mathcal{L}}{\partial L}, \\
 \frac{\partial \mathcal{L}}{\partial z} &= \frac{\partial y}{\partial z} \frac{\partial \mathcal{L}}{\partial y} = \sigma'(z) \frac{\partial \mathcal{L}}{\partial y}, \\
 \frac{\partial \mathcal{L}}{\partial \omega} &= \frac{\partial z}{\partial \omega} \frac{\partial \mathcal{L}}{\partial z} + \frac{\partial R}{\partial \omega} \frac{\partial \mathcal{L}}{\partial R} = x \frac{\partial \mathcal{L}}{\partial z} + \omega \frac{\partial \mathcal{L}}{\partial R}, \\
 \frac{\partial \mathcal{L}}{\partial b} &= \frac{\partial z}{\partial b} \frac{\partial \mathcal{L}}{\partial z} = \frac{\partial \mathcal{L}}{\partial z}.
 \end{aligned}$$

■

Это достаточно простой пример, в то время как на практике в основном встречаются отображения, действующие в пространствах матриц и векторов. Для лучшего понимания вычислим backward propagation в полносвязной нейронной сети.

Пример С2.19. Рассмотрим полносвязную нейронную сеть для задачи бинарной классификации с кросс-энтропийным лоссом:

$$\begin{aligned}
 \hat{y} &= \sigma(\sigma(XW_1)W_2), \\
 \mathcal{L}(y, \hat{y}) &= - \sum_{i=1}^n (y_i \log \hat{y}_i + (1 - y_i) \log(1 - \hat{y}_i)),
 \end{aligned}$$

где вход $X \in \mathbb{R}^{n \times d}$, $y \in \{0, 1\}^n$, параметры $W_1 \in \mathbb{R}^{d \times k}$, $W_2 \in \mathbb{R}^k$.




Рис. С2.3: Граф полносвязной нейронной сети.

Найдём производные по параметрам W_1, W_2 . Для удобства записи введём обозначения выходов промежуточных слоёв:

$$X_1 = XW_1, \quad X_2 = \sigma(X_1), \quad X_3 = X_2W_2.$$

1. Для начала найдём градиент функции потерь по $\hat{y}$ (все произведения покомпонентные):

$$\begin{aligned} d\mathcal{L}(\hat{y}) &= - \sum_{i=1}^n d(y_i \log \hat{y}_i + (1 - y_i) \log(1 - \hat{y}_i)) = \sum_{i=1}^n \left(-\frac{y_i}{\hat{y}_i} d\hat{y}_i + \frac{1 - y_i}{1 - \hat{y}_i} d\hat{y}_i \right) \\ &= \sum_{i=1}^n \frac{\hat{y}_i - y_i}{\hat{y}_i(1 - \hat{y}_i)} d\hat{y}_i. \end{aligned}$$

Тогда получаем:

$$\frac{\partial \mathcal{L}}{\partial \hat{y}_i} = \frac{\hat{y}_i - y_i}{\hat{y}_i(1 - \hat{y}_i)}.$$

2. Воспользуемся Примером C2.14 для нахождения производной по X_3 , положив g — кросс-энтропией, а h — сигмной:

$$\frac{\partial \mathcal{L}}{\partial X_3} = \sigma'(X_3) \odot \frac{\partial \mathcal{L}}{\partial \hat{y}} = \sigma(X_3)(1 - \sigma(X_3)) \odot \frac{\partial \mathcal{L}}{\partial \hat{y}}.$$

3. Отсюда уже можно найти $\frac{\partial \mathcal{L}}{\partial W_2}$:

$$\frac{\partial \mathcal{L}}{\partial W_2} = \frac{\partial X_3}{\partial W_2} \frac{\partial \mathcal{L}}{\partial X_3} = X_2^\top \frac{\partial \mathcal{L}}{\partial X_3}.$$

4. Аналогично можно найти $\frac{\partial \mathcal{L}}{\partial X_2}$:

$$\frac{\partial \mathcal{L}}{\partial X_2} = \frac{\partial X_3}{\partial X_2} \frac{\partial \mathcal{L}}{\partial X_3} = \frac{\partial \mathcal{L}}{\partial X_3} W_2^\top.$$

5. Снова ищем градиент для композиции с сигмной:

$$\frac{\partial \mathcal{L}}{\partial X_1} = \sigma'(X_1) \odot \frac{\partial \mathcal{L}}{\partial X_2} = \sigma(X_1)(1 - \sigma(X_1)) \odot \frac{\partial \mathcal{L}}{\partial X_2}.$$

6. Последний шаг проделываем по аналогии с 3:

$$\frac{\partial \mathcal{L}}{\partial W_1} = \frac{\partial X_1}{\partial W_1} \frac{\partial \mathcal{L}}{\partial X_1} = X^\top \frac{\partial \mathcal{L}}{\partial X_1}.$$

- Для подсчёта backward propagation необходимо хранить все промежуточные значения u_i на всех итерациях алгоритма. Это может быть существенным требованием к памяти, например в больших нейронных сетях.
- Необязательно полностью считать производную $\frac{\partial u_j}{\partial u_i}$, важно уметь быстро превращать градиент по выходу в градиент по входу. Об этом будет рассказано в секции C2.4.4.
- Отдельно стоит отметить нейронные сети, которые состоят из блоков. Одному блоку совершенно не надо знать, что происходит вокруг. То есть он может быть запрограммирован как отдельная сущность, умеющая внутри себя делать forward pass и backward propagation, после чего блоки механически, как кубики в конструкторе, собираются в большую сеть, которая работает как одно целое.

- Вычисление градиента можно представить через ещё один граф вычислений, тем самым, сделав уже backward propagation по графу градиента. Так можно считать гессианы и производные высших порядков.

C2.4.3 Forward propagation

Может возникнуть желание посчитать формулу (C2.2) не справа налево, а **слева направо**, распространяя производную в графе в направлении forward pass: от родителей к детям. Так производная по параметрам x будет считаться как

$$\frac{\partial u_i}{\partial x} = \sum_{u_j \in \text{родители}(u_i)} \frac{\partial u_j}{\partial x} \frac{\partial u_i}{\partial u_j}.$$

При этом можно совершать проход вместе с подсчётом u_i и нужно будет хранить только один слой графа.

Пример C2.20. Посчитайте forward propagation для графа из Примера C2.18.

Решение.

$$\begin{aligned} \frac{\partial R}{\partial \omega} &= \omega, & \frac{\partial z}{\partial b} &= 1, \\ \frac{\partial z}{\partial \omega} &= x, & \frac{\partial y}{\partial b} &= \frac{\partial z}{\partial b} \sigma'(z), \\ \frac{\partial y}{\partial \omega} &= \frac{\partial z}{\partial \omega} \sigma'(z), & \frac{\partial L}{\partial b} &= \frac{\partial y}{\partial b} \cdot (y - t), \\ \frac{\partial L}{\partial \omega} &= \frac{\partial y}{\partial \omega} \cdot (y - t), & \frac{\partial \mathcal{L}}{\partial b} &= \frac{\partial L}{\partial b}. \\ \frac{\partial \mathcal{L}}{\partial \omega} &= \frac{\partial L}{\partial \omega} + \lambda \frac{\partial R}{\partial \omega}. \end{aligned}$$

■

- У forward propagation есть нюанс — нужно хранить производные $\frac{\partial u_i}{\partial x}$, а в backward propagation — $\frac{\partial f}{\partial u_i}$.
- Если размерность входа x намного больше, чем размерность выхода $f(x)$, то на каждом шаге forward propagation нужно будет хранить и обсчитывать больше данных, чем в backward propagation.
- Если, наоборот, размерность выхода функции $f(x)$ намного больше, чем размерность входа x , то выгоднее использовать forward propagation.

C2.4.4 Умножение гессиана на вектор и якобиана на строку

Пусть дана дважды непрерывно дифференцируемая функция $f : \mathbb{R}^d \rightarrow \mathbb{R}$. Покажем, как можно эффективно считать

$$\nabla^2 f(x) \cdot u$$

для любого вектора $u \in \mathbb{R}^d$.

Считать полный гессиан и умножать его на вектор неэффективно, особенно при большой размерности d . Но заметим, что

$$d\langle \nabla f(x), u \rangle = \langle J_{\nabla f} dx, u \rangle = \langle \nabla^2 f(x) \cdot u, dx \rangle = \langle \nabla g(x), dx \rangle,$$

где $g(x) = \langle \nabla f(x), u \rangle$. Таким образом, вместо полного гессиана можно найти градиент функции вида $g(x)$, с которым могут справиться библиотеки автоматического дифференцирования `jax/autograd/pytorch/tensorflow`.

Аналогично для функции вида $f: \mathbb{R}^d \rightarrow \mathbb{R}^n$ и вектора $u \in \mathbb{R}^n$ считается значение $\nabla f(x) \cdot u$:

$$d\langle f(x), u \rangle = \langle J_f dx, u \rangle = \langle \nabla f(x) \cdot u, dx \rangle = \langle \nabla g(x), dx \rangle,$$

где $g(x) = \langle f(x), u \rangle$.

Именно поэтому backward propagation можно эффективно реализовать на практике.