

## C1 Пререквизиты из линейной алгебры

Линейная алгебра играет фундаментальную роль во многих областях математики. Её методы и концепции лежат в основе таких дисциплин, как численные методы, теория управления, анализ данных и, в том числе, теория оптимизации — предмет, которому посвящено пособие. В рамках этого параграфа обсуждаются пререквизиты из линейной алгебры, необходимые для успешного усвоения материала по оптимизации. В частности, обсуждаются векторные и матричные нормы, а также разложения матриц.

### C1.1 Векторные нормы

**Определение C1.1.** Рассмотрим функцию  $\|\cdot\| : \mathbb{R}^d \rightarrow \mathbb{R}$ . Она называется *векторной нормой*, если удовлетворяет следующим условиям:

- $\|x\| \geq 0$ ,  $\|x\| = 0 \iff x = 0$ ;
- $\|\lambda x\| = |\lambda| \|x\|$ ,  $\lambda \in \mathbb{R}$ ;
- $\|x + y\| \leq \|x\| + \|y\|$ .

**Пример C1.1.** Функция  $\|\cdot\| : \mathbb{R}^d \rightarrow \mathbb{R}$ , определённая как

$$\|x\|_p = \sqrt[p]{\sum_{i=1}^d |x_i|^p}, \quad p \geq 1,$$

является векторной нормой.

*Доказательство.* Первые два условия из Определения C1.1 не нуждаются в доказательстве. Покажем, что для произвольных  $x, y \in \mathbb{R}^d$  выполнено третье условие. Рассмотрим  $p \neq 1$ , поскольку случай  $p = 1$  тривиален. Нетрудно видеть, что

$$|x_i + y_i|^p \leq |x_i| |x_i + y_i|^{p-1} + |y_i| |x_i + y_i|^{p-1}.$$

Обозначив  $q = \frac{p}{p-1}$ , применим неравенство Гельдера (0.2) к каждому из слагаемых. Получим

$$\begin{aligned} \|x + y\|_p^p &= \sum_{i=1}^d |x_i + y_i|^p \leq \sum_{i=1}^d |x_i| |x_i + y_i|^{p-1} + \sum_{i=1}^d |y_i| |x_i + y_i|^{p-1} \\ &\leq \left( \sum_{i=1}^d |x_i|^p \right)^{\frac{1}{p}} \left( \sum_{i=1}^d |x_i + y_i|^p \right)^{\frac{1}{q}} + \left( \sum_{i=1}^d |y_i|^p \right)^{\frac{1}{p}} \left( \sum_{i=1}^d |x_i + y_i|^p \right)^{\frac{1}{q}}. \end{aligned}$$

Сократив обе части на  $\left( \sum_{i=1}^d |x_i + y_i|^p \right)^{\frac{1}{q}}$ , учитывая, что  $1 - \frac{1}{q} = \frac{1}{p}$ , имеем

$$\|x + y\|_p \leq \|x\|_p + \|y\|_p.$$

■

**Замечание C1.1.** Нормы, введённые в Примере C1.1, будем называть *гёльдеровыми нормами* или просто *p-нормами*.

В анализе некоторых алгоритмов иногда возникает так называемая  $\infty$ -норма.

**Определение С1.2.** Функцию  $\|\cdot\|_\infty : \mathbb{R}^d \rightarrow \mathbb{R}$ , определённую как

$$\|x\|_\infty = \max_{i=1,d} |x_i|,$$

будем называть  $\infty$ -нормой.

**Пример С1.2.**  $\infty$ -норма является предельным случаем гёльдеровых норм при  $p \rightarrow \infty$ .

*Доказательство.* Во-первых, известно, что  $|x_j| \leq \max_{i=1,d} |x_i|$ . Это означает, что

$$\|x\|_p \leq \left( d \max_{i=1,d} |x_i|^p \right)^{\frac{1}{p}} = d^{\frac{1}{p}} \max_{i=1,d} |x_i| \xrightarrow{p \rightarrow \infty} \|x\|_\infty.$$

С другой стороны, имеем

$$\|x\|_p \geq \left( \max_{i=1,d} |x_i|^p \right)^{\frac{1}{p}} = \max_{i=1,d} |x_i| = \|x\|_\infty.$$

По теореме о трех последовательностях (см. Теорему 2 Параграфа 5 в [27]), имеем

$$\lim_{p \rightarrow \infty} \|x\|_p = \|x\|_\infty.$$

■

Теперь, когда мы ввели в рассмотрение множество примеров векторных норм, закономерно возникает вопрос о том, как они соотносятся между собой. Действительно, показав сходимость численного метода в некоторой норме, мы хотели бы иметь уверенность, что он сходится и в других нормах тоже. Из курса математического анализа известно утверждение.

**Утверждение С1.1** (Теорема 2 Части 14 в [9]). Рассмотрим  $\|\cdot\|_A, \|\cdot\|_B : \mathbb{R}^d \rightarrow \mathbb{R}$ . Существуют такие  $c_1, c_2 > 0$ , что для любого вектора  $x$  из  $\mathbb{R}^d$  выполняется соотношение:

$$c_1 \|x\|_A \leq \|x\|_B \leq c_2 \|x\|_A.$$

Таким образом, в конечномерном вещественном пространстве все нормы эквивалентны. Доказательство утверждения не конструктивно, однако в ряде задач мы хотели бы конкретизировать значения  $c_1$  и  $c_2$ .

**Пример С1.3.** Для  $\|\cdot\|_1$  и  $\|\cdot\|_2$  выполнено соотношение:

$$\frac{1}{\sqrt{d}} \|x\|_1 \leq \|x\|_2 \leq \|x\|_1.$$

*Доказательство.* Начнём с верхней оценки. Запишем

$$\begin{aligned} \|x\|_2^2 &= |x_1|^2 + \dots + |x_d|^2 \leq |x_1|^2 + \dots + |x_d|^2 + 2|x_1||x_2| + \dots + 2|x_{d-1}||x_d| \\ &= (|x_1| + \dots + |x_d|)^2 = \|x\|_1^2. \end{aligned}$$

Таким образом,

$$\|x\|_2 \leq \|x\|_1.$$

Заметим, что неравенство переходит в равенство на векторе  $x = e_1$ . Чтобы оценить  $\|x\|_2$  снизу, воспользуемся неравенством Гельдера (0.2), положив один из векторов в скалярном произведении равным единице:

$$\|x\|_1^2 = \left( \sum_{i=1}^d 1|x_i| \right)^2 \leq \left( \sum_{i=1}^d 1^2 \right) \left( \sum_{i=1}^d |x_i|^2 \right) = d\|x\|_2^2.$$

Заметим, что неравенство переходит в равенство на векторе  $x = \mathbf{1}$ , где  $\mathbf{1}$  — вектор из всех единиц. Комбинируя результаты, получаем

$$\frac{1}{\sqrt{d}} \|x\|_1 \leq \|x\|_2 \leq \|x\|_1.$$

■

## C1.2 Матричные нормы

В анализе численных методов помимо векторов также приходится работать с матрицами. Существует естественное обобщение определения нормы.

**Определение C1.3.** Рассмотрим функцию  $\|\cdot\| : \mathbb{R}^{n \times d} \rightarrow \mathbb{R}$ . Она называется *матричной нормой*, если удовлетворяет следующим условиям:

- $\|A\| \geq 0, \quad \|A\| = 0 \iff A = 0;$
- $\|\lambda A\| = |\lambda| \|A\|, \quad \lambda \in \mathbb{R};$
- $\|A + B\| \leq \|A\| + \|B\|.$

**Замечание C1.2.** Для матриц помимо сложения также определена операция умножения. Ключевым для анализа численных методов является свойство

$$\|AB\| \leq \|A\| \|B\|.$$

Тем не менее, оно выполнено не для всех матричных норм. Рассмотрим норму:

$$\|A\| = \max_{\substack{i=1, \dots, n \\ j=1, \dots, d}} |a_{ij}|$$

и матрицы

$$A = \begin{pmatrix} 1 & 1 \\ 1 & 1 \end{pmatrix}, \quad B = \begin{pmatrix} 1 & 1 \\ 1 & 1 \end{pmatrix}.$$

Получим, что  $\|AB\| = 2, \|A\| = 1, \|B\| = 1$ , то есть свойство не выполняется.

**Замечание C1.3.** Если для  $\|\cdot\| : \mathbb{R}^{n \times d} \rightarrow \mathbb{R}$  выполнено

$$\|AB\| \leq \|A\| \|B\|,$$

то её называют *субмультпликативной* матричной нормой.

Может показаться, что мы вынуждены вручную проверять субмультипликативность, сталкиваясь с новой матричной нормой. Эту проблему можно решить, рассматривая более узкий класс норм, для которых это свойство выполняется автоматически. В дальнейшем окажется, что наиболее часто используемые матричные нормы принадлежат этому классу.

**Определение C1.4.** Рассмотрим  $A \in \mathbb{R}^{n \times d}$ , норму  $\|\cdot\|_\alpha : \mathbb{R}^d \rightarrow \mathbb{R}$  и норму  $\|\cdot\|_\beta : \mathbb{R}^n \rightarrow \mathbb{R}$ . Матричной нормой, *подчинённой*  $\|\cdot\|_\alpha$  и  $\|\cdot\|_\beta$ , называется функция  $\|\cdot\|_{\alpha,\beta} : \mathbb{R}^{n \times d} \rightarrow \mathbb{R}$ , заданная как

$$\|A\|_{\alpha,\beta} = \sup_{\|x\|_\alpha=1} \|Ax\|_\beta.$$

**Замечание C1.4.** Мы будем рассматривать только случай, когда  $\alpha = \beta$ , тогда определение можно переписать следующим образом:

$$\|A\| = \sup_{\|x\|=1} \|Ax\|.$$

**Замечание C1.5.** Определение C1.4 можно переформулировать, представив единичный  $x$  как некоторый вектор после нормировки на единичную сферу. Тогда имеем

$$\|A\| = \sup_{\|x\|=1} \|Ax\| = \sup_{x \neq 0} \frac{\|Ax\|}{\|x\|}.$$

**Замечание C1.6.** Из Замечания C1.5 следует неравенство

$$\frac{\|Ax\|}{\|x\|} \leq \|A\| \implies \|Ax\| \leq \|A\| \|x\|.$$

Это очень полезное свойство, которое будет неоднократно использовано в дальнейшем изложении.

**Пример C1.4.** Подчинённая матричная норма всегда субмультипликативна.

*Доказательство.* Рассмотрим матрицы  $A$  и  $B$ , имеющие правильные размерности. Записав определение подчинённой нормы, получим

$$\|AB\| = \sup_{\|x\|=1} \|ABx\| \leq \sup_{\|x\|=1} \|A\| \|Bx\| \leq \sup_{\|x\|=1} \|A\| \|B\| \|x\| = \|A\| \|B\|.$$

■

Использование подчинённой нормы также позволяет оценивать спектральный радиус матрицы.

**Утверждение C1.2.** Рассмотрим  $A \in \mathbb{S}^d$ , где  $\mathbb{S}^d$  — множество симметричных матриц. Обозначим  $\rho(A) = \max_{i=1,d} |\lambda_i(A)|$  — *спектральный радиус*, где  $\lambda_i(A)$  — собственные числа матрицы  $A$ . Тогда

$$\rho(A) \leq \|A\|,$$

где  $\|\cdot\|$  — подчинённая норма.

*Доказательство.* Запишем уравнение на собственные векторы матрицы  $A$ :

$$Ax = \lambda x \implies \|Ax\| = |\lambda| \|x\|.$$

В Замечании C1.6 было получено неравенство

$$\|Ax\| \leq \|A\| \|x\|.$$

Тогда можем утверждать, что

$$|\lambda| \leq \|A\|.$$

Отсюда очевидно следует, что

$$\rho(A) = \max_{i=1,d} |\lambda_i(A)| \leq \|A\|.$$

Заметим, что на  $I_d$  достигается равенство. ■

Помимо собственных чисел часто оказывается удобным использовать сингулярные. Например, если работаем с прямоугольной матрицей.

**Определение C1.5.** Сингулярным числом матрицы  $A \in \mathbb{R}^{n \times d}$  называется

$$\sigma_i(A) = \sqrt{\lambda_i(A^\top A)}.$$

На практике часто приходится работать с квадратными симметричными матрицами. В этом случае сингулярные числа имеют более удобный вид.

**Утверждение C1.3.** Пусть  $A \in \mathbb{S}^d$ . Тогда сингулярные числа имеют вид

$$\sigma_i(A) = |\lambda_i(A)|.$$

*Доказательство.* Собственные векторы вещественной симметричной матрицы  $A$  ортогональны (см. Теорему 1 Параграфа 3 Главы 6 в [26]). Рассмотрев их в качестве базиса, можно привести  $A$  к диагональному виду. Запишем её преобразование при переходе от стандартного базиса в базис собственных векторов:

$$A = V \Lambda V^\top,$$

где  $V \in \mathbb{R}^{d \times d}$  — ортогональная матрица, составленная из собственных векторов  $A$ ,  $\Lambda = \text{diag}(\lambda_1(A), \dots, \lambda_d(A))$ . Теперь запишем

$$A^\top A = A^2 = (V \Lambda V^\top)(V \Lambda V^\top) = V \Lambda^2 V^\top.$$

Таким образом, доказали, что  $\lambda_i(A^\top A) = \lambda_i(A)^2$ , откуда следует, что  $\sigma_i(A) = |\lambda_i(A)|$ . ■

Таким образом, подчинённая матричная норма определена достаточно удачно и имеет ряд хороших свойств. Более того, она даёт связь с векторными нормами. Оказывается, что Определение C1.4 позволяет давать аналитические выражения для подсчета матричных норм.

**Пример C1.5.** Рассмотрим  $A \in \mathbb{R}^{n \times d}$ . Для подчинённых норм  $\|\cdot\|_\infty, \|\cdot\|_1, \|\cdot\|_2 : \mathbb{R}^{n \times d} \rightarrow \mathbb{R}$ , имеем следующие выражения:

- $\|A\|_\infty = \max_{i=1,n} \sum_{j=1}^d |a_{ij}|$  — максимум сумм по строкам,
- $\|A\|_1 = \max_{j=1,d} \sum_{i=1,n} |a_{ij}|$  — максимум сумм по столбцам.
- $\|A\|_2 = \max_{i=1,d} \sqrt{\lambda_i(A^\top A)} = \max_{i=1,d} \sigma_i(A)$  — максимальное сингулярное число.

*Доказательство.* Будем доказывать в том же порядке, в котором утверждения приведены в формулировке примера.

- Распишем:

$$\begin{aligned} \|Ax\|_\infty &= \max_{i=1,n} \left| \sum_{j=1}^d a_{ij} x_j \right| \leq \max_{i=1,n} \sum_{j=1}^d |a_{ij} x_j| \leq \max_{k=1,d} |x_k| \max_{i=1,n} \sum_{j=1}^d |a_{ij}| \\ &= \|x\|_\infty \max_{i=1,n} \sum_{j=1}^d |a_{ij}|. \end{aligned}$$

Пусть максимум правой части достигается при  $i = i_0$ . Рассмотрим вектор  $x = \left( \frac{a_{i_0 1}}{|a_{i_0 1}|}, \dots, \frac{a_{i_0 d}}{|a_{i_0 d}|} \right)^\top$ . Тогда, подставляя его в выражение, выше получаем равенство. Таким образом, существует вектор, на котором верхняя грань достигается.

- Будем расписывать почти как в предыдущем примере:

$$\|Ax\|_1 = \sum_{i=1}^n \left| \sum_{j=1}^d a_{ij} x_j \right| \leq \sum_{j=1}^d |x_j| \sum_{i=1}^n |a_{ij}| \leq \|x\|_1 \max_{j=1,d} \sum_{i=1}^n |a_{ij}|.$$

Пусть максимум правой части достигается при  $j = j_0$ . Рассмотрим вектор  $x = e_{j_0}$ . Тогда, подставляя его в выражение, выше получаем равенство. Таким образом, существует вектор, на котором верхняя грань достигается.

- Раскроем определение:

$$\|A\|_2 = \sup_{x \neq 0} \frac{\|Ax\|_2}{\|x\|_2} = \sup_{x \neq 0} \sqrt{\frac{\langle A^\top A x, x \rangle}{\langle x, x \rangle}}.$$

Разложим  $x$  по ортонормированному базису  $\nu_1, \dots, \nu_d$  собственных векторов, отвечающих собственным числам  $\lambda_1, \dots, \lambda_d$  матрицы  $A^\top A$ . Напомним, что собственные числа симметричной положительно полуопределённой матрицы неотрицательны. Тогда:

$$\|A\|_2 = \sup_{\|x\|_2=1} \sqrt{\frac{\sum_{j=1}^d \lambda_j c_j^2}{\sum_{j=1}^d c_j^2}} \leq \max_{i=1,d} \sqrt{\lambda_i} = \max_{i=1,d} \sigma_i(A),$$

где  $c_i$  — коэффициенты разложения  $x$  по базису  $\nu_1, \dots, \nu_d$ :

$$x = \sum_{i=1}^d c_i \nu_i.$$

Рассмотрим нормированный вектор, соответствующий максимальному собственному значению матрицы  $A^\top A$ . Тогда, подставляя его в выражение, выше получаем равенство. Таким образом, существует вектор, на котором верхняя грань достигается. ■

**Пример C1.6.** Матричные нормы  $\|\cdot\|_\infty$ ,  $\|\cdot\|_1$  и  $\|\cdot\|_2$  связаны соотношением:

$$\|A\|_2^2 \leq \|A\|_1 \|A\|_\infty.$$

*Доказательство.* Поскольку при транспонировании строки и столбцы меняем местами, верно равенство  $\|A\|_1 = \|A^\top\|_\infty$ . Запишем определение второй нормы матрицы и для того, чтобы ограничить собственное значение матрицы воспользуемся Утверждением C1.2:

$$\|A\|_2^2 = \max_{i=1,d} \lambda_i(A^\top A) \leq \|A^\top A\|_1 \leq \|A^\top\|_1 \|A\|_1 = \|A\|_1 \|A\|_\infty.$$

**Пример C1.7.** Матричная норма  $\|A\|_2$  может быть определена иначе:

$$\|A\|_2 = \sup_{\|x\|_2=1, \|y\|_2=1} |y^\top Ax|.$$

*Доказательство.* Ранее уже отмечалось, что для матричных норм верно неравенство  $\|Ax\| \leq \|A\| \|x\|$ . Пользуясь этим свойством и неравенством Коши-Буняковского-Шварца (0.3) для нормы  $p = 2$ , запишем:

$$|y^\top Ax| = |\langle y, Ax \rangle| \leq \|y\|_2 \|Ax\|_2 \leq \|y\|_2 \|A\|_2 \|x\|_2 = \|A\|_2.$$

Выберем единичный вектор  $x_*$ , на котором достигается  $\|A\|_2$  и определим  $y_* = \frac{Ax_*}{\|Ax_*\|_2}$ . Тогда:

$$|y_*^\top Ax_*| = \left| \frac{x_*^\top A^\top Ax_*}{\|Ax_*\|_2} \right| = \frac{\|Ax_*\|_2^2}{\|Ax_*\|_2} = \|Ax_*\|_2 = \|A\|_2.$$

Тем не менее, не все нормы, используемые на практике являются подчинёнными. Чтобы перейти к их рассмотрению, требуется ввести понятие ранга матрицы.

**Определение C1.6.** *Столбцовым рангом* матрицы  $A \in \mathbb{R}^{n \times d}$  называется число  $\text{rank}_c(A)$ , такое, что в  $A$  существует линейно независимая система из  $\text{rank}_c(A)$  столбцов и нет линейно независимой системы из большего числа столбцов.

**Замечание С1.7.** Существует множество способов определения ранга матрицы. Мы считаем известным из курса линейной алгебры утверждение об их эквивалентности (см. Теорему 1 Параграфа 3 Главы 5 в [25]). В связи с этим, будем пользоваться обозначением  $\text{rank}(A) = \text{rank}_c(A)$ .

**Пример С1.8.** Пусть  $A \in \mathbb{R}^{n \times d}$ . Матричная норма

$$\|A\|_F = \sqrt{\sum_{i=1}^{\text{rank}(A)} \sigma_i^2(A)}$$

не подчинена никакой векторной норме.

*Доказательство.* Если бы норма была подчинённой, то для единичной матрицы  $I_d$  выполнялось бы

$$\|I_d\|_F = \sup_{\|x\|=1} \|I_d x\| = \sup_{\|x\|=1} \|x\| = 1.$$

Однако

$$\|I_d\|_F = \sqrt{\sum_{i=1}^d 1} = \sqrt{d}.$$

Таким образом, предложенная норма не подчинена ни одной из векторных норм. ■

**Определение С1.7.** Пусть  $A \in \mathbb{R}^{n \times d}$ . Функцию  $\|\cdot\|_F : \mathbb{R}^{n \times d} \rightarrow \mathbb{R}$ , определённую как

$$\|A\|_F = \sqrt{\sum_{i=1}^{\text{rank}(A)} \sigma_i^2(A)},$$

будем называть *фробениусовой нормой*.

**Замечание С1.8.** Обратим внимание, что пространство матриц является конечномерным вещественным. Это означает, что матричные нормы эквивалентны как и векторные.

**Пример С1.9.** Для  $\|\cdot\|_2$  и  $\|\cdot\|_F$  выполнено соотношение:

$$\|A\|_2 \leq \|A\|_F \leq \sqrt{d} \|A\|_2.$$

*Доказательство.* Без ограничения общности расположим сингулярные числа в порядке убывания и положим  $\text{rank}(A) = r$ . Поскольку  $\|A\|_2 = \sigma_1$ , то по определению фробениусовой нормы имеем

$$\|A\|_2 \leq \|A\|_F.$$

С другой стороны,  $\|A\|_F \leq \sqrt{r} \sigma_1 \leq \sqrt{d} \sigma_1 = \sqrt{d} \|A\|_2$ . Объединяя неравенства, запишем

$$\|A\|_2 \leq \|A\|_F \leq \sqrt{d} \|A\|_2.$$

■

Фробениусова норма может показаться сложной для вычисления по сравнению с рассмотренными ранее. В дальнейшем выяснится, что можно дать простое эквивалентное определение. Для этого нам потребуется ряд вспомогательных утверждений.



**Теорема C1.1.** Матрица  $A \in \mathbb{R}^{n \times d}$  представима в виде SVD-разложения:

$$A = U \Sigma V^\top,$$

где  $U \in \mathbb{R}^{n \times n}$ ,  $V \in \mathbb{R}^{d \times d}$  — ортогональные,  $\Sigma \in \mathbb{R}^{n \times d}$  — диагональная матрица, составленная из сингулярных чисел  $A$ , расположенных в порядке убывания.

*Доказательство.*  $A^\top A$  неотрицательно определена и симметрична, поэтому её собственные числа неотрицательны и соответствующие им собственные векторы ортогональны. Отсюда из Утверждения C1.3 следует существование ортогональной матрицы  $V$ , такой что

$$V^\top A^\top A V = \text{diag}(\sigma_1^2, \dots, \sigma_d^2).$$

Без ограничения общности, будем считать  $\sigma_1^2 \geq \dots \geq \sigma_d^2 \geq 0$ . Поскольку  $\text{rank}(A) = r$ , имеем

$$\sigma_i = 0, \quad \forall i > r.$$

Обозначим  $V_r = (v_1, \dots, v_r)$ ,  $\Sigma_r = \text{diag}(\sigma_1, \dots, \sigma_r)$ . Тогда имеем

$$V_r^\top A^\top A V_r = \Sigma_r^2.$$

Умножив равенство слева и справа на  $\Sigma_r^{-1}$ , получим

$$(\Sigma_r^{-1} V_r^\top A^\top)(A V_r \Sigma_r^{-1}) = I.$$

Обозначим  $U_r = A V_r \Sigma_r^{-1}$ . Из написанного выше следует  $U_r^\top U_r = I$ , то есть  $U_r$  матрица с ортонормированными столбцами. Поскольку систему линейно независимых векторов можно дополнить до базиса, присоединим к  $U_r$  произвольные ортонормированные столбцы и получим новую матрицу  $U$ . Тогда

$$A = U \Sigma V^\top.$$

■

Теперь мы готовы дать эквивалентное определение фробениусовой нормы.

**Утверждение C1.4.** Для матрицы  $A \in \mathbb{R}^{n \times d}$  фробениусова норма может быть эквивалентно определена как

$$\|A\|_F^2 = \sum_{i=1}^n \sum_{j=1}^d |a_{ij}|^2.$$

*Доказательство.* Для простоты изложения введем обозначение:

$$\|A\|_S^2 = \sum_{i=1}^n \sum_{j=1}^d |a_{ij}|^2.$$

Будем работать с квадратными матрицами  $A \in \mathbb{R}^{d \times d}$ . Во-первых, заметим, что для ортогональной матрицы  $Q$  выполнено

$$\|QA\|_S = \|A\|_S.$$

Действительно, рассмотрим  $A$  как совокупность вектор-столбцов:  $A = (a_1, \dots, a_d)$ . Тогда имеем

$$\|QA\|_S^2 = \|(Qa_1, \dots, Qa_d)\|_S^2 = \sum_{i=1}^d \sum_{j=1}^d |(Qa_i)_j|^2 = \sum_{i=1}^d \|Qa_i\|_2^2 = \sum_{i=1}^d \|a_i\|_2^2 = \|A\|_S^2.$$

Аналогично проверяется инвариантность относительно умножения на  $Q$  справа. Воспользуемся SVD-разложением C1.1 и запишем  $\|A\|_S$ , применив эту идею. Получим

$$\|A\|_S^2 = \|U\Sigma V^\top\|_S^2 = \|\Sigma\|_S^2 = \sum_{i=1}^r \sigma_i^2 = \|A\|_F^2.$$

■

Теперь мы получили простой способ подсчёта фробениусовой нормы. Поскольку она не подчинена ни одной из векторных норм, выполнение субмультипликативного свойства надо проверять вручную.

**Пример C1.10.** Для матриц  $A \in \mathbb{R}^{d \times n}$  и  $B \in \mathbb{R}^{n \times k}$  фробениусова норма субмультипликативна:

$$\|AB\|_F \leq \|A\|_F \|B\|_F.$$

*Доказательство.* Пользуясь новым определением и неравенством Коши-Буняковского-Шварца (0.3), запишем

$$\begin{aligned} \|AB\|_F^2 &= \sum_{i=1}^d \sum_{j=1}^k \left| \sum_{t=1}^n a_{it} b_{tj} \right|^2 \leq \sum_{i=1}^d \sum_{j=1}^k \left( \sum_{t=1}^n |a_{it}|^2 \right) \left( \sum_{m=1}^n |b_{mj}|^2 \right) \\ &= \left( \sum_{i=1}^d \sum_{t=1}^n |a_{it}|^2 \right) \left( \sum_{m=1}^n \sum_{j=1}^k |b_{mj}|^2 \right) = \|A\|_F^2 \|B\|_F^2. \end{aligned}$$

■

Фробениусова норма широко используется в анализе методов наряду с подчинёнными. Действительно, её вычисление значительно проще, чем, например, второй нормы, при этом она субмультипликативна.

**Замечание C1.9.** Используя эквивалентное определение, можно заметить, что для квадратных матриц выполнено

$$\|A\|_F^2 = \text{Tr}(A^\top A),$$

где  $\text{Tr}(A) = \sum_{i=1}^d a_{ii}$  — *след матрицы*. Таким образом, мы говорим, что фробениусова норма порождена скалярным произведением матриц:

$$\langle A, B \rangle = \text{Tr}(A^\top B).$$

Это замечание окажется особенно полезным для дифференцирования функций, принимающих на вход матрицу. Напомним без доказательства ряд важных свойств следа.

**Утверждение C1.5.** Для  $\text{Tr} : \mathbb{R}^{d \times d} \rightarrow \mathbb{R}$  выполнены следующие равенства:

- $\text{Tr}(A^\top) = \text{Tr}(A)$ ,

- $\text{Tr}(A + B) = \text{Tr}(A) + \text{Tr}(B)$ ,
- $\text{Tr}(cA) = c \text{Tr}(A)$ ,
- $\text{Tr}(A_1 \dots A_n) = \text{Tr}(A_n A_1 \dots A_{n-1})$ .

### С1.3 Сопряжённые нормы

Если на исходном пространстве задана норма, то на сопряжённом пространстве задана сопряжённая норма.

**Определение С1.8.** Пусть в  $\mathbb{R}^d$  задана норма  $\|\cdot\|$ . Тогда *сопряжённая норма*  $\|\cdot\|_* : \mathbb{R}^d \rightarrow \mathbb{R}$  определяется как

$$\|y\|_* = \sup_{\|x\| \leq 1} x^\top y.$$

Введённая функция еще не обязана удовлетворять свойствам нормы, докажем их напрямую.

**Утверждение С1.6.**  $\|\cdot\|_*$  является нормой в  $\mathbb{R}^d$ .

*Доказательство.* Рассмотрим свойства нормы. Однородность очевидна, покажем положительную определенность: для произвольного  $y \neq 0$  можно взять  $x = \frac{y}{\|y\|}$ , для которого выполняется

$$x^\top y = \frac{y^\top y}{\|y\|} > 0.$$

А для  $y = 0$  имеем

$$\|0\|_* = \sup_{\|x\| \leq 1} x^\top 0 = 0.$$

Остается показать неравенство треугольника:  $\forall y_1, y_2 \in \mathbb{R}^d$ :

$$\|y_1 + y_2\|_* = \sup_{\|x\| \leq 1} x^\top (y_1 + y_2) \leq \sup_{\|x\| \leq 1} x^\top y_1 + \sup_{\|x\| \leq 1} x^\top y_2 = \|y_1\|_* + \|y_2\|_*.$$

Следовательно, сопряжённая норма является нормой. ■

**Пример С1.11.** Пусть  $\frac{1}{p} + \frac{1}{q} = 1$ , тогда сопряжённая норма к  $\|\cdot\|_p$  имеет вид  $\|\cdot\|_* = \|\cdot\|_q$ .

*Доказательство.* Для начала покажем, что  $\forall y \in \mathbb{R}^d$   $\|y\|_* \leq \|y\|_q$ . Из неравенства Гёльдера (0.2)  $\forall x, y \in \mathbb{R}^d$  :  $\|x\|_p \leq 1$ :

$$x^\top y \leq \|x\|_p \|y\|_q \leq \|y\|_q.$$

Покажем, что равенство достигается. Пусть  $y \neq 0$  и  $x \in \mathbb{R}^d$ , тогда:

$$x_i = \frac{|y_i|^{q-1} \cdot \text{sign}(y_i)}{\|y\|_q^{q-1}}$$

Нетрудно проверить, что  $\|x\|_p = 1$ , кроме того имеем

$$x^\top y = \frac{\sum_{i=1}^n |y_i|^q}{\|y\|_q^{q-1}} = \|y\|_q.$$

Таким образом,  $\forall y \in \mathbb{R}^d \quad \|y\|_* = \|y\|_q$ . ■

## C1.4 Квадратичные формы

Часто специальные свойства матриц играют ключевую роль в эффективности методов оптимизации и гарантируют некоторые теоретические оценки. Разберёмся с ними подробнее.

**Определение C1.9.** Пусть на  $\mathbb{R}^d$  задана симметричная билинейная (линейная по обоим аргументам) функция  $\alpha : \mathbb{R}^d \times \mathbb{R}^d \rightarrow \mathbb{R}$ , тогда соответствующая ей *квадратичная форма*  $Q : \mathbb{R}^d \rightarrow \mathbb{R}$  определяется следующим образом  $\forall x \in \mathbb{R}^d$ :

$$Q(x) = \sum_{i=1}^d \sum_{j=1}^d \alpha_{ij} x_i x_j, \quad \alpha_{ij} = \alpha_{ji}.$$

**Замечание C1.10.** Заметим, что любой квадратичной форме в соответствие можно поставить матрицу  $A \in \mathbb{S}^d$ . То есть  $A = \{\alpha\}_{ij}$ , и  $Q(x) = x^\top A x$ .

Далее мы будем отождествлять квадратичную форму и соответствующую ей симметричную матрицу.

**Определение C1.10.** Квадратичная форма  $A \in \mathbb{S}^d$  называется *положительно определённой (полуопределённой)*, если  $\forall x \in \mathbb{R}^d \setminus \{0\}$ :

$$x^\top A x \underset{(\geq)}{>} 0.$$

Аналогично определяются *отрицательная определённость (полуопределённость)*.

**Замечание C1.11.** Множество положительно полуопределённых матриц обозначается  $\mathbb{S}_+^d$ . Если  $A \in \mathbb{S}_+^d$ , то  $A \succeq 0$ . Множество положительно определённых матриц обозначается  $\mathbb{S}_{++}^d$ . Если  $A \in \mathbb{S}_{++}^d$ , то  $A \succ 0$ .

Полезными фактами о квадратичных формах, которые пригодятся нам в дальнейшем, являются критерии Сильвестра, которые позволяют проверять матрицы на положительную/отрицательную определённость и полуопределённость.

### Теорема C1.2. (Критерий Сильвестра)

- Квадратичная форма положительно определена  $\iff$  все угловые миноры соответствующей ей матрицы положительны.
- Квадратичная форма положительно полуопределена  $\iff$  все главные миноры соответствующей ей матрицы неотрицательны. *Главным минором* называется определитель подматрицы, симметричной относительно главной диагонали.

**Пример C1.12.** Покажите, что матрица

$$A = \begin{pmatrix} 2 & -1 & 0 \\ -1 & 2 & -1 \\ 0 & -1 & 2 \end{pmatrix}.$$

положительно определённая.

*Решение.* Угловой минор порядка 1:  $2 > 0$ . Угловой минор порядка 2:

$$\det \begin{pmatrix} 2 & -1 \\ -1 & 2 \end{pmatrix} = 5 > 0.$$

Угловой минор порядка 3:

$$\det \begin{pmatrix} 2 & -1 & 0 \\ -1 & 2 & -1 \\ 0 & -1 & 2 \end{pmatrix} = 4 > 0.$$

По критерию Сильвестра, матрица  $A$  положительно определена. ■

**Пример C1.13.** Покажите, что матрица

$$A = \begin{pmatrix} 2 & -1 & 1 \\ -1 & 1 & 0 \\ 1 & 0 & 1 \end{pmatrix}$$

положительно полуопределённая.

*Решение.* Заметим, что все диагональные элементы неотрицательны. Рассмотрим теперь миноры порядка 2:

$$\det \begin{pmatrix} 2 & -1 \\ -1 & 1 \end{pmatrix} = 3 \geq 0,$$

$$\det \begin{pmatrix} 2 & 1 \\ 1 & 1 \end{pmatrix} = 1 \geq 0,$$

$$\det \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix} = 1 \geq 0.$$

Теперь рассмотрим единственный главный минор порядка 3:

$$\det \begin{pmatrix} 2 & -1 & 1 \\ -1 & 1 & 0 \\ 1 & 0 & 1 \end{pmatrix} = 0.$$

По критерию Сильвестра матрица  $A$  положительно полуопределена. Заметим, что она не является положительно определённой. ■

**Замечание C1.12.** Отметим, что неотрицательности только лишь угловых миноров недостаточно для положительной полуопределённости. Действительно, рассмот-

рим матрицу

$$A = \begin{pmatrix} 0 & 0 \\ 0 & -1 \end{pmatrix}.$$

Нетрудно видеть, что все угловые миноры матрицы равны нулю. Тем не менее, она не является положительно полуопределённой. Действительно,

$$(0, 1)A(0, 1)^{\top} = (0, 1)(0, -1)^{\top} = -1.$$