

ЛЗ Градиентный спуск

Рассмотрим задачу безусловной оптимизации

$$\min_{x \in \mathbb{R}^d} f(x), \quad (\text{ЛЗ.1})$$

где функция $f(x)$ дифференцируема.

Алгоритм ЛЗ.1 Градиентный спуск

Вход: стартовая точка $x^0 \in \mathbb{R}^d$, размеры шагов $\{\gamma_k\}_{k=0} > 0$, количество итераций K

1: **for** $k = 0, 1, \dots, K - 1$ **do**


2: $x^{k+1} = x^k - \gamma_k \nabla f(x^k)$

3: **end for**

Выход: x^K

Метод был придуман в середине 19го века Огюстеном Коши [5] для решения систем уравнений $Ax = b$, что эквивалентно решению задачи $\min_{x \in \mathbb{R}^d} \|Ax - b\|_2^2$. Идея метода очень естественна и понятна: градиент показывает направление роста функции, тогда антиградиент — направление убывания. Поэтому давайте пойдем вдоль текущего антиградиента. Сразу же возникает вопрос: а насколько далеко вообще стоит идти по направлению, указанном антиградиентом? Кажется, что не особо далеко, потому что градиент дает только локальную информацию, поэтому совсем непонятно, что же происходит вдали от текущей точки.

Пример ЛЗ.1. Рассмотрим градиентный спуск с постоянным шагом $\gamma_k = \gamma$ для простейшей задачи оптимизации $\min_{x \in \mathbb{R}} x^2$. Пусть наш метод стартует из точки $x^0 = 1$. Попробуем различные шаги γ .



1. $\gamma = \frac{1}{100}$: медленная, но монотонная сходимость.
2. $\gamma = \frac{1}{2}$: оптимальный шаг — метод достигает минимума за одну итерацию.
3. $\gamma \approx \frac{1}{1.01}$: наблюдаются сильные колебания.

4. $\gamma = 1$: критический шаг — метод циклично возвращается в исходную точку.
5. $\gamma \approx \frac{1}{0.99}$: метод расходится.

Попробуем построить теорию, доказать сходимость метода градиентного спуска, а также понять допустимые диапазоны шагов γ_k .

Л3.1 Градиентный спуск для гладких сильно выпуклых задач

Отметим сразу, что мы не оформляем дальнейшие рассуждения в виде теоремы, так как они приведут к «топорному» результату. Это пример того, что анализ даже самых простых методов может быть выполнен не лучшим образом. Из Теоремы Л2.3 мы знаем, что для сильно выпуклых функций решение x^* уникально. Попытаемся оценить, как меняется расстояние до него. Используя итерацию градиентного спуска, получаем

$$\begin{aligned}\|x^{k+1} - x^*\|_2^2 &= \|x^k - \gamma_k \nabla f(x^k) - x^*\|_2^2 \\ &= \|x^k - x^*\|_2^2 - 2\gamma_k \langle \nabla f(x^k), x^k - x^* \rangle + \gamma_k^2 \|\nabla f(x^k)\|_2^2.\end{aligned}$$

Нужно как-то оценить полученное выражение. Вспоминаем, что у нас есть гладкость (Определение Л2.5):

$$\|\nabla f(x^k) - \nabla f(x^*)\|_2^2 \leq L^2 \|x^k - x^*\|_2^2$$

и μ -сильная выпуклость (Определение Л2.4):

$$f^* \geq f(x^k) + \langle \nabla f(x^k), x^* - x^k \rangle + \frac{\mu}{2} \|x^k - x^*\|_2^2.$$

Чтобы применить гладкость, достаточно вспомнить условие оптимальности $\nabla f(x^*) = 0$, тогда получаем:

$$\begin{aligned}\|x^{k+1} - x^*\|_2^2 &= \|x^k - x^*\|_2^2 - 2\gamma_k \langle \nabla f(x^k), x^k - x^* \rangle \\ &\quad + \gamma_k^2 \|\nabla f(x^k) - \nabla f(x^*)\|_2^2 \tag{Л3.2} \\ &\leq \|x^k - x^*\|_2^2 + 2\gamma_k \left(\frac{\mu}{2} \|x^k - x^*\|_2^2 + f^* - f(x^k) \right) \\ &\quad + \gamma_k^2 L^2 \|x^k - x^*\|_2^2 \\ &= (1 - \gamma_k \mu + \gamma_k^2 L^2) \|x^k - x^*\|_2^2 + 2\gamma_k (f^* - f(x^k)).\end{aligned}$$

Отбрасываем последнее слагаемое в силу того, что $f(x^k) \geq f^*$:

$$\|x^{k+1} - x^*\|_2^2 \leq (1 - \gamma_k \mu + \gamma_k^2 L^2) \|x^k - x^*\|_2^2.$$

Хочется, чтобы расстояние до решения уменьшалось, а именно, $(1 - \gamma_k \mu + \gamma_k^2 L^2) < 1$, а лучше вообще найти $\operatorname{argmin}_{\gamma_k} (1 - \gamma_k \mu + \gamma_k^2 L^2)$. Это несложно — минимизируем одномерную параболу по γ_k и получаем оптимальный шаг: $\gamma_k^* = \frac{\mu}{2L^2}$ и

$$1 - \gamma_k^* \mu + (\gamma_k^*)^2 L^2 = 1 - \frac{\mu^2}{4L^2}.$$

А значит,

$$\|x^{k+1} - x^*\|_2^2 \leq \left(1 - \frac{\mu^2}{4L^2}\right) \|x^k - x^*\|_2^2.$$

Это неравенство выполняется для всех $k = \overline{0, K-1}$. Подставим $k = K-1$:

$$\|x^K - x^*\|_2^2 \leq \left(1 - \frac{\mu^2}{4L^2}\right) \|x^{K-1} - x^*\|_2^2.$$

Теперь продолжим неравенство, подставляя $k = K-2$:

$$\|x^K - x^*\|_2^2 \leq \left(1 - \frac{\mu^2}{4L^2}\right) \left(1 - \frac{\mu^2}{4L^2}\right) \|x^{K-2} - x^*\|_2^2 = \left(1 - \frac{\mu^2}{4L^2}\right)^2 \|x^{K-2} - x^*\|_2^2.$$

И так можно продолжать, вплоть до $k = 0$. Запустим рекурсию:

$$\begin{aligned} \|x^K - x^*\|_2^2 &\leq \left(1 - \frac{\mu^2}{4L^2}\right) \|x^{K-1} - x^*\|_2^2 \leq \left(1 - \frac{\mu^2}{4L^2}\right)^2 \|x^{K-2} - x^*\|_2^2 \\ &\leq \left(1 - \frac{\mu^2}{4L^2}\right)^3 \|x^{K-3} - x^*\|_2^2 \leq \dots \leq \left(1 - \frac{\mu^2}{4L^2}\right)^K \|x^0 - x^*\|_2^2. \end{aligned}$$

Получили линейную сходимость (Определение Л1.5). Попробуем найти оценку на число итераций. Для дальнейшего анализа часто применяют неравенство (0.4)

$$(1 - \alpha)^k \leq \exp(-\alpha k),$$

где $\alpha \in [0, 1]$, $k \in \mathbb{N}$. Его можно получить, записав определение выпуклости $\exp(-x)$ в точке 0:

$$\exp(-x) \geq 1 - x,$$

после чего возвести неравенство в степень k , поскольку обе части неравенства неотрицательны.

Заметим, что $\mu \leq L$ (Теорема Л2.5 и Определение Л2.4), а значит

$$\|x^K - x^*\|_2^2 \leq \left(1 - \frac{\mu^2}{4L^2}\right)^K \|x^0 - x^*\|_2^2 \leq \exp\left(-\frac{\mu^2}{4L^2} \cdot K\right) \|x^0 - x^*\|_2^2.$$

Мы хотим гарантировать, что

$$\|x^K - x^*\|_2^2 \leq \exp\left(-\frac{\mu^2}{4L^2} \cdot K\right) \|x^0 - x^*\|_2^2 \leq \varepsilon^2.$$

Тогда логарифмируем и получаем

$$K \geq \frac{4L^2}{\mu^2} \log\left(\frac{\|x^0 - x^*\|_2^2}{\varepsilon^2}\right).$$

Но этот результат далеко не самый лучший. Анализ можно провести «тоньше».

Теорема Л3.1. Пусть задача безусловной оптимизации (Л3.1) с L -гладкой, μ -сильно выпуклой целевой функцией f решается с помощью градиентного спуска (Алгоритм Л3.1). Тогда при $\gamma_k \leq \frac{1}{L}$ справедлива следующая оценка сходимости:

$$\|x^K - x^*\|_2^2 \leq \left(\prod_{k=0}^{K-1} (1 - \mu\gamma_k)\right) \|x^0 - x^*\|_2^2. \quad (\text{Л3.3})$$

Доказательство. Начинаем с применения итерации градиентного спуска и условия оптимальности $\nabla f(x^*) = 0$:

$$\begin{aligned}\|x^{k+1} - x^*\|_2^2 &= \|x^k - \gamma_k \nabla f(x^k) - x^*\|_2^2 \\ &= \|x^k - x^*\|_2^2 - 2\gamma_k \langle \nabla f(x^k), x^k - x^* \rangle + \gamma_k^2 \|\nabla f(x^k)\|_2^2 \\ &= \|x^k - x^*\|_2^2 + 2\gamma_k \langle \nabla f(x^k), x^* - x^k \rangle + \gamma_k^2 \|\nabla f(x^k) - \nabla f(x^*)\|_2^2.\end{aligned}$$

Для точек x^k и x^* воспользуемся сильной выпуклостью (Определение Л2.4):

$$f^* \geq f(x^k) + \langle \nabla f(x^k), x^* - x^k \rangle + \frac{\mu}{2} \|x^k - x^*\|_2^2$$

и гладкостью (Теорема Л2.5):

$$\frac{1}{2L} \|\nabla f(x^k) - \nabla f(x^*)\|_2^2 \leq f(x^k) - f^* - \langle \nabla f(x^*), x^k - x^* \rangle.$$

Тогда после подстановки неравенств, имеем:

$$\begin{aligned}\|x^{k+1} - x^*\|_2^2 &\leq \|x^k - x^*\|_2^2 - 2\gamma_k \left(\frac{\mu}{2} \|x^k - x^*\|_2^2 + f(x^k) - f^* \right) \\ &\quad + \gamma_k^2 \|\nabla f(x^k) - \nabla f(x^*)\|_2^2 \\ &\leq \|x^k - x^*\|_2^2 - 2\gamma_k \left(\frac{\mu}{2} \|x^k - x^*\|_2^2 + f(x^k) - f^* \right) \\ &\quad + 2\gamma_k^2 L (f(x^k) - f^* - \langle \nabla f(x^*), x^k - x^* \rangle) \\ &= (1 - \mu\gamma_k) \|x^k - x^*\|_2^2 + 2\gamma_k(\gamma_k L - 1)(f(x^k) - f^*).\end{aligned}\tag{Л3.4}$$

Воспользуемся тем, что $\gamma_k \leq \frac{1}{L}$, а $f(x^k) \geq f^*$, и откинем второе слагаемое:

$$\|x^{k+1} - x^*\|_2^2 \leq (1 - \mu\gamma_k) \|x^k - x^*\|_2^2.$$

Запустим рекурсию:

$$\begin{aligned}\|x^K - x^*\|_2^2 &\leq (1 - \mu\gamma_{K-1}) \|x^{K-1} - x^*\|_2^2 \\ &\leq (1 - \mu\gamma_{K-1})(1 - \mu\gamma_{K-2}) \|x^{K-2} - x^*\|_2^2 \\ &\leq \dots \leq \left(\prod_{k=0}^{K-1} (1 - \mu\gamma_k) \right) \|x^0 - x^*\|_2^2.\end{aligned}$$

■

Проведем анализ полученной оценки. Исходя из неравенства (Л3.3), можем заключить, что шаг γ_k следует брать максимально допустимым. В условии теоремы было наложено ограничение $\gamma_k \leq \frac{1}{L}$, поэтому, сформулируем утверждение о скорости сходимости при $\gamma_k = \frac{1}{L}$.

Утверждение Л3.1. Пусть задача удовлетворяет условиям Теоремы Л3.1 и выбрано значение шага $\gamma_k = \frac{1}{L}$. Тогда справедлива следующая оценка сходимости:

$$\|x^K - x^*\|_2^2 \leq \left(1 - \frac{\mu}{L}\right)^K \|x^0 - x^*\|_2^2.$$

Более того, чтобы добиться точности ε по аргументу ($\|x^K - x^*\|_2 \leq \varepsilon$), необходимо

$$K = \mathcal{O}\left(\frac{L}{\mu} \log \frac{\|x^0 - x^*\|_2}{\varepsilon}\right) = \tilde{\mathcal{O}}\left(\frac{L}{\mu}\right) \text{ итераций.}$$

Доказательство. Запишем оценку сходимости из Теоремы Л3.1:

$$\|x^K - x^*\|_2^2 \leq \left(\prod_{k=0}^{K-1} (1 - \mu\gamma_k)\right) \|x^0 - x^*\|_2^2.$$

При $\gamma_k = \frac{1}{L}$ получаем:

$$\|x^K - x^*\|_2^2 \leq \left(1 - \frac{\mu}{L}\right)^K \|x^0 - x^*\|_2^2.$$

Получили линейную сходимость (Определение Л1.5). Найдем оценку на число итераций. Заметим, что $\mu \leq L$ (Теорема Л2.5 и Определение Л2.4), а значит

$$\|x^K - x^*\|_2^2 \leq \left(1 - \frac{\mu}{L}\right)^K \|x^0 - x^*\|_2^2 \leq \exp\left(-\frac{\mu}{L} \cdot K\right) \|x^0 - x^*\|_2^2.$$

Мы хотим гарантировать, что

$$\|x^K - x^*\|_2^2 \leq \exp\left(-\frac{\mu}{L} \cdot K\right) \|x^0 - x^*\|_2^2 \leq \varepsilon^2.$$

Тогда логарифмируем и получаем

$$K \geq \frac{L}{\mu} \log\left(\frac{\|x^0 - x^*\|_2^2}{\varepsilon^2}\right).$$

■

Замечание Л3.1. Мы будем использовать $\mathcal{O}$ -нотацию, чтобы «убирать» численные факторы и $\tilde{\mathcal{O}}$ -нотацию, чтобы «убирать» еще и лог-факторы (более формально все факторы вида $\log(\text{poly}(L, \mu, \varepsilon, \dots))$, где $\text{poly}(L, \mu, \varepsilon, \dots)$ — полиномы).

Но и этот анализ можно еще немного улучшить. Для этого понадобится следующее утверждение.

Утверждение Л3.2. Пусть непрерывно дифференцируемая функция $f: \mathbb{R}^d \rightarrow \mathbb{R}$ является μ -сильно выпуклой и L -гладкой, тогда для любых $x, y \in \mathbb{R}^d$ выполнено следующее неравенство:

$$\langle \nabla f(x) - \nabla f(y), x - y \rangle \geq \frac{\mu L}{\mu + L} \|x - y\|_2^2 + \frac{1}{\mu + L} \|\nabla f(x) - \nabla f(y)\|_2^2.$$

Доказательство. Рассмотрим функцию $\phi(x) = f(x) - \frac{\mu}{2} \|x\|_2^2$. Докажем, что эта функция является выпуклой и $(L - \mu)$ -гладкой. Выпуклость проверим по Определению Л2.3:

$$\begin{aligned} \phi(y) - \phi(x) - \langle \nabla \phi(x), y - x \rangle &= f(y) - \frac{\mu}{2} \|y\|_2^2 - f(x) + \frac{\mu}{2} \|x\|_2^2 - \langle \nabla f(x) - \mu x, y - x \rangle \\ &= f(y) - f(x) - \langle \nabla f(x), y - x \rangle \\ &\quad + \frac{\mu}{2} (\|x\|_2^2 - \|y\|_2^2 + 2\langle x, y - x \rangle) \\ &= f(y) - f(x) - \langle \nabla f(x), y - x \rangle - \frac{\mu}{2} \|y - x\|_2^2 \geq 0. \end{aligned}$$

Последнее в стиле сильной выпуклости f (Определение Л2.4).

Для нахождения константы гладкости воспользуемся L -гладкостью f и неравенством (Л2.3) из Теоремы Л2.5:

$$f(y) - f(x) - \langle \nabla f(x), y - x \rangle \leq \frac{L}{2} \|y - x\|_2^2.$$

Тогда, комбинируя два неравенства выше, получаем для ϕ :

$$\phi(y) - \phi(x) - \langle \nabla \phi(x), y - x \rangle \leq \frac{L - \mu}{2} \|x - y\|_2^2.$$

Теперь для выпуклой и $(L - \mu)$ -гладкой функции ϕ воспользуемся неравенством (Л2.5) из Теоремы Л2.5:

$$(L - \mu) \langle \nabla \phi(x) - \nabla \phi(y), x - y \rangle \geq \|\nabla \phi(x) - \nabla \phi(y)\|_2^2.$$

Преобразуем обе части неравенства, подставив $\phi(x) = f(x) - \frac{\mu}{2} \|x\|_2^2$. Для левой части получим:

$$\begin{aligned} (L - \mu) \langle \nabla \phi(x) - \nabla \phi(y), x - y \rangle &= (L - \mu) \langle \nabla f(x) - \mu x - \nabla f(y) - \mu y, x - y \rangle \\ &= (L - \mu) \langle \nabla f(x) - \nabla f(y), x - y \rangle - (L - \mu) \mu \|x - y\|_2^2. \end{aligned}$$

Теперь для правой части неравенства:

$$\begin{aligned} \|\nabla \phi(x) - \nabla \phi(y)\|_2^2 &= \|\nabla f(x) - \mu x - \nabla f(y) - \mu y\|_2^2 \\ &= \|\nabla f(x) - \nabla f(y)\|_2^2 - 2\mu \langle \nabla f(x) - \nabla f(y), x - y \rangle + \mu^2 \|x - y\|_2^2. \end{aligned}$$

Подставляем обе части:

$$\begin{aligned} (L - \mu) \langle \nabla f(x) - \nabla f(y), x - y \rangle - (L - \mu) \mu \|x - y\|_2^2 \\ \geq \|\nabla f(x) - \nabla f(y)\|_2^2 - 2\mu \langle \nabla f(x) - \nabla f(y), x - y \rangle + \mu^2 \|x - y\|_2^2. \end{aligned}$$

После небольшого упрощения:

$$(L + \mu) \langle \nabla f(x) - \nabla f(y), x - y \rangle - L\mu \|x - y\|_2^2 \geq \|\nabla f(x) - \nabla f(y)\|_2^2.$$

Приведём к требуемому виду:

$$\langle \nabla f(x) - \nabla f(y), x - y \rangle \geq \frac{\mu L}{\mu + L} \|x - y\|_2^2 + \frac{1}{\mu + L} \|\nabla f(x) - \nabla f(y)\|_2^2.$$

■

Используя доказанное утверждение, можно получить следующий результат.

Теорема Л3.2. [Теорема 2.1.15. из [29]] Пусть задача безусловной оптимизации (Л3.1) с L -гладкой, μ -сильно выпуклой целевой функцией f решается с помощью градиентного спуска (Алгоритм Л3.1). Тогда при $\gamma_k \leq \frac{2}{\mu + L}$ справедлива следующая оценка сходимости:

$$\|x^K - x^*\|_2^2 \leq \left(\prod_{k=0}^{K-1} \left(1 - \frac{2\gamma_k \mu L}{\mu + L} \right) \right) \|x^0 - x^*\|_2^2.$$

Доказательство. Пойдем по уже известному пути (Л3.2):

$$\begin{aligned}\|x^{k+1} - x^*\|_2^2 &= \|x^k - x^*\|_2^2 - 2\gamma_k \langle \nabla f(x^k) - \nabla f(x^*), x^k - x^* \rangle \\ &\quad + \gamma_k^2 \|\nabla f(x^k) - \nabla f(x^*)\|_2^2.\end{aligned}$$

Теперь используем результат Утверждения Л3.2, чтобы оценить скалярное произведение:

$$\begin{aligned}\|x^{k+1} - x^*\|_2^2 &= \|x^k - x^*\|_2^2 - 2\gamma_k \langle \nabla f(x^k) - \nabla f(x^*), x^k - x^* \rangle \\ &\quad + \gamma_k^2 \|\nabla f(x^k) - \nabla f(x^*)\|_2^2 \\ &\leq \|x^k - x^*\|_2^2 - 2\gamma_k \left(\frac{\mu L}{\mu + L} \|x^k - x^*\|_2^2 + \frac{1}{\mu + L} \|\nabla f(x^k) - \nabla f(x^*)\|_2^2 \right) \\ &\quad + \gamma_k^2 \|\nabla f(x^k) - \nabla f(x^*)\|_2^2 \\ &= \left(1 - \frac{2\gamma_k \mu L}{\mu + L} \right) \|x^k - x^*\|_2^2 + \gamma_k \left(\gamma_k - \frac{2}{\mu + L} \right) \|\nabla f(x^k) - \nabla f(x^*)\|_2^2.\end{aligned}$$

Выбрав $\gamma_k \leq \frac{2}{\mu + L}$, имеем

$$\|x^{k+1} - x^*\|_2^2 \leq \left(1 - \frac{2\gamma_k \mu L}{\mu + L} \right) \|x^k - x^*\|_2^2.$$

Запустив рекурсию, получаем

$$\|x^K - x^*\|_2^2 \leq \left(\prod_{k=0}^{K-1} \left(1 - \frac{2\gamma_k \mu L}{\mu + L} \right) \right) \|x^0 - x^*\|_2^2.$$

■

Как и в случае с предыдущей оценкой сходимости с произвольным достаточно малым шагом, сформулируем утверждение с теоретически максимально допустимым значением шага $\gamma_k = \frac{2}{\mu + L}$.

Утверждение Л3.3. Пусть задача удовлетворяет условиям Теоремы Л3.2 и выбрано значение шага $\gamma_k = \frac{2}{\mu + L}$. Тогда справедлива следующая оценка сходимости:

$$\|x^K - x^*\|_2^2 \leq \left(1 - \frac{4\mu L}{(\mu + L)^2} \right)^K \|x^0 - x^*\|_2^2.$$

Более того, чтобы добиться точности ε по аргументу ($\|x^k - x^*\|_2 \leq \varepsilon$), необходимо

$$K = \mathcal{O}\left(\frac{L}{\mu} \log \frac{\|x^0 - x^*\|_2}{\varepsilon}\right) = \tilde{\mathcal{O}}\left(\frac{L}{\mu}\right) \text{ итераций.}$$

Доказательство. Запишем оценку сходимости из Теоремы Л3.2:

$$\|x^K - x^*\|_2^2 \leq \left(\prod_{k=0}^{K-1} \left(1 - \frac{2\gamma_k \mu L}{\mu + L} \right) \right) \|x^0 - x^*\|_2^2.$$

Возьмем постоянный шаг $\gamma_k = \frac{2}{\mu+L}$ и применим неравенство $(1 - \alpha)^x \leq \exp(-\alpha x)$:

$$\begin{aligned}\|x^K - x^*\|_2^2 &\leq \left(1 - \frac{4\mu L}{(\mu + L)^2}\right)^K \|x^0 - x^*\|_2^2 \\ &\leq \exp\left(-\frac{4\mu L}{(\mu + L)^2} K\right) \|x^0 - x^*\|_2^2.\end{aligned}$$

Хотим потребовать точность ε по аргументу ($\|x^K - x^*\|_2 \leq \varepsilon$), для этого оцениваем все сверху:

$$\|x^K - x^*\|_2^2 \leq \exp\left(-\frac{4\mu L}{(\mu + L)^2} K\right) \|x^0 - x^*\|_2^2 \leq \varepsilon^2.$$

Откуда

$$K \geq \frac{(L + \mu)^2}{4\mu L} \log\left(\frac{\|x^0 - x^*\|_2^2}{\varepsilon^2}\right).$$

■

Сравним результаты Теорем ЛЗ.1 и ЛЗ.2. С точки зрения $\mathcal{O}$ -оценок, результаты одинаковы, но можно сравнить $(1 - \frac{\mu}{L})$ и $(1 - \frac{4\mu L}{(\mu+L)^2})$. Легко заметить, что

$$\left(1 - \frac{4\mu L}{(\mu + L)^2}\right) < \left(1 - \frac{\mu}{L}\right)$$

при $\mu \neq L$, а значит, результаты Теоремы ЛЗ.2 лучше. Однако, более классическим является первый результат. Отчасти это из-за того, что оптимальное значение шага для той оценки $\gamma_k = \frac{1}{L}$ не требует от нас знания константы сильной выпуклости. В Примере ЛЗ.1 можно видеть, что лучшая сходимость при $\gamma_k = \gamma = \frac{1}{L} = \frac{2}{\mu+L} = \frac{1}{2}$. Построим график сходимости градиентного спуска при шагах из Теорем ЛЗ.1 и ЛЗ.2 (Рисунок ЛЗ.1).




Рис. ЛЗ.1: Сравнение сходимости градиентного спуска при различных шагах.

Л3.2 Градиентный спуск для гладких выпуклых задач

В данном разделе x^* — некоторая (необязательно единственная, но существующая) точка глобального минимума.

Докажем сперва вспомогательное утверждение о том, что значение функции убывает от итерации к итерации.

Утверждение Л3.4. Пусть задача безусловной оптимизации (Л3.1) с L -гладкой, выпуклой целевой функцией f решается с помощью градиентного спуска (Алгоритм Л3.1). Тогда при $\gamma_k \in (0, \frac{2}{L})$ справедливо, что $f(x^{k+1}) \leq f(x^k)$.

Доказательство. Воспользуемся L -гладкостью (Теорема Л2.5):

$$f(x^{k+1}) \leq f(x^k) + \langle \nabla f(x^k), x^{k+1} - x^k \rangle + \frac{L}{2} \|x^{k+1} - x^k\|_2^2.$$

Подставим итерационный шаг градиентного спуска:

$$\begin{aligned} f(x^{k+1}) &\leq f(x^k) - \gamma_k \|\nabla f(x^k)\|_2^2 + \frac{L\gamma_k^2}{2} \|\nabla f(x^k)\|_2^2 \\ &= f(x^k) - \gamma_k \left(1 - \frac{L\gamma_k}{2}\right) \|\nabla f(x^k)\|_2^2. \end{aligned} \quad (\text{Л3.5})$$

Если $\gamma_k \in (0, \frac{2}{L})$, то $f(x^{k+1}) \leq f(x^k)$. ■

Это предложение не просто является вспомогательным фактом, оно отражает и физику градиентного спуска. Шаг метода подбирается исходя из верхней ограничивающей квадратичной функции/параболы, возникающей из-за гладкости. Как и в Примере Л3.1, нам нельзя делать большие шаги, иначе мы перескочим на противоположную ветвь параболы относительно оптимума и можем оказаться выше той точки, где находились до этого. Поэтому и подбирается шаг «осторожно», исходя из худшего варианта скорости/резкости роста функции (верхней оценки). При этом можно заметить, что если $\gamma_k = \frac{1}{L}$, то мы минимизируем выражение

$$f(x^k) - \gamma_k \|\nabla f(x^k)\|_2^2 + \frac{L\gamma_k^2}{2} \|\nabla f(x^k)\|_2^2,$$

т.е. каждый раз мы минимизируем локальную верхнюю ограничивающую параболу на поведение нашей функции (Рисунок Л3.2).

Теорема Л3.3. Пусть задача безусловной оптимизации (Л3.1) с L -гладкой, выпуклой целевой функцией f решается с помощью градиентного спуска (Алгоритм Л3.1). Тогда при $\gamma_k \leq \frac{1}{2L}$ справедлива следующая оценка сходимости:

$$f(x^K) - f^* \leq \frac{\|x^0 - x^*\|_2^2}{\sum_{k=0}^{K-1} \gamma_k}.$$

В данной теореме приводится сходимость только по функции, то есть, решение может быть не уникально (Пример Л2.1). А также предполагается существование решения (для конечности $\|x^0 - x^*\|_2^2$).




Рис. 13.2: Иллюстрация шага градиентного спуска с оптимальным $\gamma_k = \frac{1}{L}$.

Доказательство. Начнем доказательство с оценки (Л3.4) с $\mu = 0$:

$$\|x^{k+1} - x^*\|_2^2 \leq \|x^k - x^*\|_2^2 + 2\gamma_k(\gamma_k L - 1)(f(x^k) - f^*).$$

Учтем, что $\gamma_k L - 1 \leq -\frac{1}{2}$ из-за ограничения на размер шага $\gamma_k \leq \frac{1}{2L}$:

$$\begin{aligned} \|x^{k+1} - x^*\|_2^2 &\leq \|x^k - x^*\|_2^2 + 2\gamma_k(\gamma_k L - 1)(f(x^k) - f^*) \\ &\leq \|x^k - x^*\|_2^2 - \gamma_k(f(x^k) - f^*). \end{aligned}$$

Перетасуем неравенство:

$$\gamma_k(f(x^k) - f^*) \leq \|x^k - x^*\|_2^2 - \|x^{k+1} - x^*\|_2^2.$$

Суммируя по всем итерациям от 0 до $K - 1$:

$$\begin{aligned} \sum_{k=0}^{K-1} \gamma_k(f(x^k) - f^*) &\leq \sum_{k=0}^{K-1} (\|x^k - x^*\|_2^2 - \|x^{k+1} - x^*\|_2^2) \\ &= \|x^0 - x^*\|_2^2 - \|x^K - x^*\|_2^2 \leq \|x^0 - x^*\|_2^2. \end{aligned}$$

Воспользуемся Утверждением Л3.4 и заметим, что $f(x^K) \leq f(x^k)$, $k = \overline{0, K}$:

$$(f(x^K) - f^*) \sum_{k=0}^{K-1} \gamma_k \leq \|x^0 - x^*\|_2^2.$$

Откуда получаем, что

$$f(x^K) - f^* \leq \frac{\|x^0 - x^*\|_2^2}{\sum_{k=0}^{K-1} \gamma_k}.$$

■

Утверждение Л3.5. Пусть задача удовлетворяет условиям Теоремы Л3.3 и выбрано значение шага $\gamma_k = \frac{1}{2L}$. Тогда справедлива следующая оценка сходимости:

$$f(x^K) - f^* \leq \frac{2L\|x^0 - x^*\|_2^2}{K}.$$

Более того, чтобы добиться точности ε по функции ($f(x^K) - f^* \leq \varepsilon$), необходимо

$$K = \mathcal{O}\left(\frac{L\|x^0 - x^*\|_2^2}{\varepsilon}\right) \text{ итераций.}$$

Доказательство. Начнем с оценки из Теоремы Л3.3:

$$f(x^K) - f^* \leq \frac{\|x^0 - x^*\|_2^2}{\sum_{k=0}^{K-1} \gamma_k}.$$

Подставим фиксированный шаг $\gamma_k = \frac{1}{2L}$, получим требуемое:

$$f(x^K) - f^* \leq \frac{\|x^0 - x^*\|_2^2}{\sum_{k=0}^{K-1} \gamma_k} = \frac{2L\|x^0 - x^*\|_2^2}{K}.$$

Это сублинейная сходимость (Определение Л1.5). Чтобы получить оценку на число итераций, отметим, что мы хотим гарантировать:

$$f(x^K) - f^* \leq \frac{2L\|x^0 - x^*\|_2^2}{K} \leq \varepsilon.$$

Тогда получаем

$$K \geq \frac{2L\|x^0 - x^*\|_2^2}{\varepsilon}.$$

■

Как и в сильно выпуклом случае, данный анализ можно немного улучшить.

Теорема Л3.4. Пусть задача безусловной оптимизации (Л3.1) с L -гладкой, выпуклой целевой функцией f решается с помощью градиентного спуска (Алгоритм Л3.1). Тогда при $\gamma_k \in [0, \frac{1}{L}]$ справедлива следующая оценка сходимости:

$$f(x^K) - f(x^*) \leq \frac{\|x^0 - x^*\|_2^2}{2 \sum_{k=0}^{K-1} \gamma_k}.$$

Доказательство. Начинаем уже привычным образом:

$$\begin{aligned} \|x^{k+1} - x^*\|_2^2 &= \|x^k - \gamma_k \nabla f(x^k) - x^*\|_2^2 \\ &= \|x^k - x^*\|_2^2 - 2\gamma_k \langle \nabla f(x^k), x^k - x^* \rangle + \gamma_k^2 \|\nabla f(x^k)\|_2^2. \end{aligned}$$

Воспользуемся выпуклостью: $f(y) \geq f(x) + \langle \nabla f(x), y - x \rangle$ (Определение Л2.3). Тогда с учетом $\nabla f(x^*) = 0$ имеем

$$\|x^{k+1} - x^*\|_2^2 \leq \|x^k - x^*\|_2^2 - 2\gamma_k(f(x^k) - f^*) + \gamma_k^2 \|\nabla f(x^k)\|_2^2. \quad (\text{Л3.6})$$

Далее применим результат (Л3.5), а именно оценим $\|\nabla f(x^k)\|_2^2$:

$$\|\nabla f(x^k)\|_2^2 \leq \frac{2}{\gamma_k(2 - L\gamma_k)}(f(x^k) - f(x^{k+1})).$$

Здесь учитывается, что $\gamma_k \in (0, \frac{2}{L})$. Объединяя два предыдущих выражения, получаем

$$\|x^{k+1} - x^*\|_2^2 \leq \|x^k - x^*\|_2^2 - 2\gamma_k(f(x^k) - f^*) + \frac{2\gamma_k}{2 - L\gamma_k}(f(x^k) - f(x^{k+1})).$$

Продолжим цепочку неравенств, взяв во внимание $f^* \leq f(x^{k+1}) \leq f(x^k)$ (Утверждение Л3.4):

$$\begin{aligned} \|x^{k+1} - x^*\|_2^2 &\leq \|x^k - x^*\|_2^2 - 2\gamma_k(f(x^k) - f^*) + \frac{2\gamma_k}{2 - L\gamma_k}(f(x^k) - f(x^{k+1})) \\ &= \|x^k - x^*\|_2^2 - 2\gamma_k\left(1 - \frac{1}{2 - L\gamma_k}\right)f(x^k) - \frac{2\gamma_k}{2 - L\gamma_k}f(x^{k+1}) + 2\gamma_k f^* \\ &\leq \|x^k - x^*\|_2^2 - 2\gamma_k\left(1 - \frac{1}{2 - L\gamma_k}\right)f(x^{k+1}) - \frac{2\gamma_k}{2 - L\gamma_k}f(x^{k+1}) + 2\gamma_k f^* \\ &= \|x^k - x^*\|_2^2 - 2\gamma_k(f(x^{k+1}) - f^*). \end{aligned}$$

После небольшой перестановки:

$$2\gamma_k(f(x^{k+1}) - f^*) \leq \|x^k - x^*\|_2^2 - \|x^{k+1} - x^*\|_2^2.$$

Суммируем по всем k от 0 до K , имеем:

$$\begin{aligned} 2 \sum_{k=0}^{K-1} \gamma_k(f(x^{k+1}) - f^*) &\leq \sum_{k=0}^{K-1} (\|x^k - x^*\|_2^2 - \|x^{k+1} - x^*\|_2^2) \\ &= \|x^0 - x^*\|_2^2 - \|x^K - x^*\|_2^2 \leq \|x^0 - x^*\|_2^2. \end{aligned}$$

Из Утверждения Л3.4 следует, что $f(x^K) \leq f(x^{K-1}) \leq \dots \leq f(x^0)$. Воспользуемся этим в оценке:

$$2(f(x^K) - f^*) \sum_{k=0}^{K-1} \gamma_k \leq \|x^0 - x^*\|_2^2.$$

Откуда получаем, что

$$f(x^K) - f^* \leq \frac{\|x^0 - x^*\|_2^2}{2 \sum_{k=0}^{K-1} \gamma_k}.$$

■

Подберем оптимальное значение шага. Как видно из оценки, шаг стоит выбирать максимальным из возможных. Сформулируем отдельное утверждение для $\gamma_k = \frac{1}{L}$.

Теорема Л3.5. Пусть задача удовлетворяет условиям Теоремы Л3.4 и выбрано значение шага $\gamma_k = \frac{1}{L}$. Тогда справедлива следующая оценка сходимости:

$$f(x^K) - f^* \leq \frac{L\|x^0 - x^*\|_2^2}{2K}.$$

Более того, чтобы добиться точности ε по функции ($f(x^K) - f^* \leq \varepsilon$), необходимо

$$K = \mathcal{O}\left(\frac{L\|x^0 - x^*\|_2^2}{\varepsilon}\right) \text{ итераций.}$$

Доказательство. Выпишем оценку из Теоремы Л3.4 и подставим $\gamma_k = \frac{1}{L}$:

$$f(x^K) - f^* \leq \frac{\|x^0 - x^*\|_2^2}{2 \sum_{k=0}^{K-1} \gamma_k} \leq \frac{L\|x^0 - x^*\|_2^2}{2K}.$$

Чтобы получить оценку на число итераций, отметим, что мы хотим гарантировать:

$$f(x^K) - f^* \leq \frac{L\|x^0 - x^*\|_2^2}{2K} \leq \varepsilon.$$

Тогда

$$K \geq \frac{L\|x^0 - x^*\|_2^2}{2\varepsilon}.$$

■

Сравним результаты Теорем Л3.3 и Л3.4. С точки зрения $\mathcal{O}$ -оценок, результаты одинаковы, но численный фактор в Теореме Л3.4 лучше.

Л3.3 Градиентный спуск для гладких невыпуклых задач

Теорема Л3.6. Пусть задача безусловной оптимизации (Л3.1) с L -гладкой целевой функцией f решается с помощью градиентного спуска (Алгоритм Л3.1). Тогда при $\gamma_k = \frac{1}{L}$ справедлива следующая оценка сходимости:

$$\|\nabla f(\hat{x}^K)\|_2^2 \leq \frac{2L(f(x^0) - f^*)}{K},$$

где $\hat{x}^K$ — некоторая специально выбранная точка из $\{x^k\}$. Более того, чтобы добиться точности ε по норме градиента ($\|\nabla f(x^K)\|_2 \leq \varepsilon$), необходимо

$$K = \mathcal{O}\left(\frac{2L(f(x^0) - f^*)}{\varepsilon^2}\right) \text{ итераций.}$$

Здесь f^* — глобальный минимум функции.

В данной теореме есть сходимость только к стационарной точке (для невыпуклых функций нет гарантий, что это экстремум), и предполагается существование конечного глобального минимума f^* .

Доказательство. Воспользуемся L -гладкостью (Теорема Л2.4):

$$f(x^{k+1}) \leq f(x^k) + \langle \nabla f(x^k), x^{k+1} - x^k \rangle + \frac{L}{2} \|x^{k+1} - x^k\|_2^2.$$

Подставим итерационный шаг градиентного спуска:

$$\begin{aligned} f(x^{k+1}) &\leq f(x^k) - \gamma_k \|\nabla f(x^k)\|_2^2 + \frac{L\gamma_k^2}{2} \|\nabla f(x^k)\|_2^2 \\ &\leq f(x^k) - \gamma_k \left(1 - \frac{L\gamma_k}{2}\right) \|\nabla f(x^k)\|_2^2. \end{aligned}$$

Возьмем $\gamma_k = \frac{1}{L}$. Тогда

$$f(x^{k+1}) \leq f(x^k) - \frac{1}{2L} \|\nabla f(x^k)\|_2^2,$$

или после небольших перестановок:

$$\|\nabla f(x^k)\|_2^2 \leq 2L(f(x^k) - f(x^{k+1})).$$

Суммируя по всем итерациям от 0 до $K-1$, получаем:

$$\sum_{k=0}^{K-1} \|\nabla f(x^k)\|_2^2 \leq 2L(f(x^0) - f(x^K)) \leq 2L(f(x^0) - f^*).$$

Здесь мы еще воспользовались существованием глобального минимума f^* . Усредняя по K :

$$\frac{1}{K} \sum_{k=0}^{K-1} \|\nabla f(x^k)\|_2^2 \leq \frac{2L(f(x^0) - f^*)}{K}.$$

Из левой части непонятно, для какой точки мы получили гарантии сходимости. С такой мы проблемой еще не сталкивались, есть несколько способов ее решить:

- Случайный выбор $\hat{x}^K$ из $x_0, \dots, x_{K-1}$:

$$\mathbb{E} [\|\nabla f(\hat{x}^K)\|_2^2] = \frac{1}{K} \sum_{k=0}^{K-1} \|\nabla f(x^k)\|_2^2 \leq \frac{2L(f(x^0) - f^*)}{K};$$

- Выбор точки с минимальным по норме градиентом $\hat{x}^K = \operatorname{argmin}_{k \in \{0, K-1\}} \|\nabla f(x^k)\|_2^2$:

$$\|\nabla f(\hat{x}^K)\|_2^2 = \min_{k \in \{0, K-1\}} \|\nabla f(x^k)\|_2^2 \leq \frac{1}{K} \sum_{k=0}^{K-1} \|\nabla f(x^k)\|_2^2 \leq \frac{2L(f(x^0) - f^*)}{K}.$$

Это сублинейная сходимость (Определение Л1.5). Чтобы получить оценку на число итераций, потребуем

$$\|\nabla f(\hat{x}^K)\|_2^2 \leq \frac{2L(f(x^0) - f^*)}{K} \leq \varepsilon^2.$$

Тогда получаем

$$K \geq \frac{2L(f(x^0) - f^*)}{\varepsilon^2}.$$

■

Л3.4 Выбор шага градиентного спуска

До этого момента мы доказывали сходимость градиентного спуска для L -гладких функций при достаточно малом шаге γ_k , а затем формулировали утверждения, в которых фиксировали максимально допустимый шаг. Однако, в реальных задачах мы не всегда знаем, как подбирать шаг. Во-первых, это может происходить, поскольку нам может не быть известно, является ли функция L -гладкой, но это не означает, что градиентный спуск не будет работать. Во-вторых, нам может быть неизвестна константа липшицевости градиента L , от которой зависит теоретическое значение оптимального размера шага. Начнем с метода, который опирается на L -гладкость функции.

Л3.4.1 Линейный поиск значения L

Обратимся к результатам Утверждения Л3.4. В ходе доказательства мы получили оценку (Л3.5) на значение функции f на следующей итерации:

$$f(x^{k+1}) \leq f(x^k) + \underbrace{\left(\frac{L\gamma^2}{2} - \gamma \right)}_{\rightarrow \min} \|\nabla f(x^k)\|_2^2 = \left[\gamma = \frac{1}{L} \right] = f(x^k) - \frac{1}{2L} \|\nabla f(x^k)\|_2^2.$$

Из оценки выше сразу же появляется идея для линейного поиска L : увеличиваем L в ρ раз, пока условие выше не начинает выполняться.

Алгоритм Л3.2 Линейный поиск значения L

Вход: стартовая точка $x^k \in \mathbb{R}^d$, начальное значение $L > 0$, параметр $\rho > 1$
1: $x^{k+1} = x^k - \frac{1}{L} \nabla f(x^k)$
2: **while** $f(x^{k+1}) > f(x^k) - \frac{1}{2L} \|\nabla f(x^k)\|_2^2$ **do**
3: $L = \rho \cdot L$
4: $x^{k+1} = x^k - \frac{1}{L} \nabla f(x^k)$
5: **end while**
Выход: L

Полученный алгоритм можно встроить в метод градиентного спуска (Алгоритм Л3.1), добавив запуск его на каждой итерации. Более того, в процедуру поиска L можно добавить кусок с уменьшением L , чтобы на каждой итерации иметь оценку на L максимально близкую к истинной локальной константе гладкости.

Замечание Л3.2. При использовании адаптивного подбора L к итоговой оракульной и итерационной сложности метода добавляется лишь логарифмическое слагаемое.

Замечание Л3.3. Для μ -сильно выпуклых L -гладких функций можно построить критерий выбора шага, зависящий одновременно от μ и от L , но поиск пары (μ, L) становится двумерным и несколько усложняет процедуру. При этом при выборе $\gamma_k = \frac{1}{L}$ линейный характер сходимости сохраняется, хотя может наблюдаться потеря в константной эффективности.

Л3.4.2 Степенной шаг

Также можно использовать убывающий с номером итерации шаг:

$$\gamma_k := \frac{\gamma}{\delta + k^p}, \quad \gamma > 0, \delta > 0, p > 0.$$

Наиболее часто применяются на практике $\gamma_k = \frac{1}{k+1}$ и $\gamma_k = \frac{1}{\sqrt{k+1}}$.

Л3.4.3 Наискорейший спуск

Итерация градиентного спуска выглядит следующим образом:

$$x^{k+1} = x^k - \gamma_k \nabla f(x^k).$$

Посмотрим на значение целевой функции после сделанного шага как на функцию от одного аргумента γ_k :

$$\phi(\gamma_k) := f(x^k - \gamma_k \nabla f(x^k)). \quad (\text{Л3.7})$$

Поскольку стоит задача минимизации f , то будем выбирать шаг γ_k так, чтобы минимизировать значение функции $\phi(\gamma_k)$:

$$\gamma_k^* = \operatorname{argmin}_{\gamma_k > 0} \phi(\gamma_k) = \operatorname{argmin}_{\gamma_k > 0} f(x^k - \gamma_k \nabla f(x^k)).$$

Получим важное свойство шага наискорейшего спуска γ_k^* . Выпишем необходимое условие оптимума:

$$\begin{aligned} \phi'(\gamma_k^*) &= \left. \frac{\partial f(x^k - \gamma_k \nabla f(x^k))}{\partial \gamma_k} \right|_{\gamma_k = \gamma_k^*} = -\langle \nabla f(x^k - \gamma_k^* \nabla f(x^k)), \nabla f(x^k) \rangle \\ &= -\langle \nabla f(x^{k+1}), \nabla f(x^k) \rangle = 0. \end{aligned}$$

Итак, свойство заключается в следующем: градиент в точке, куда мы шагаем, ортогонален направлению, вдоль которого мы шагаем. Действительно, если бы это было не так, то можно было бы сделать шаг в направлении градиента, чтобы уменьшить значение функции, что противоречит определению шага наискорейшего спуска. Рисунок Л3.3 иллюстрирует это свойство. В качестве целевой функции взята квадратичная функция на $\mathbb{R}^2$, эллипсами показаны линии уровня этой функции. Градиенты в каждой точке направлены ортогонально линии уровня, проходящей через эту точку.




Рис. Л3.3: Наискорейший градиентный спуск для квадратичной задачи.

Поиск оптимального значения γ_k можно осуществлять методами одномерной оптимизации. Причем, зачастую достаточно приближенного решения.

Методы одномерной оптимизации не требуют липшицевости и даже выпуклости минимизируемой функции скалярного аргумента. Потребуем, чтобы ϕ была унимодальной на рассматриваемом отрезке.

Определение Л3.1. Одномерная функция $\phi : [a, b] \rightarrow \mathbb{R}$ называется *унимодальной* на $[a, b]$, если существует $c^* \in [a, b]$ такое, что:

1. Для произвольных $x, y \in [a, c^*]$, таких что $x < y$, выполнено $\phi(x) > \phi(y)$;
2. Для произвольных $x, y \in [c^*, b]$, таких что $x < y$, выполнено $\phi(x) < \phi(y)$.

Замечание Л3.4. Если функция f является сильно выпуклой, то полученная в точке $x^k \neq x^*$ функция ϕ (Уравнение (Л3.7)) будет унимодальной.

Первым методом для поиска минимума унимодальных функций будет метод дихотомии. Дополнительно предположим, что нам известен отрезок $[a_0, b_0]$, на котором находится оптимум ϕ . В случае с градиентным спуском, это может быть отрезок $[0, \frac{2}{L}]$, если нам известна константа гладкости, либо $[0, b]$, где b взята достаточно большим, если L нам неизвестна. Будем искать $\gamma^* = \operatorname{argmin}_{\gamma \in [a, b]} \phi(\gamma)$.

Алгоритм Л3.3 Вычисление γ_k с помощью метода дихотомии

Вход: отрезок поиска $[a_0, b_0]$, количество итераций K

```

1: for  $k = 0, \dots, K - 1$  do
2:    $\gamma_k = \frac{a_k + b_k}{2}$ 
3:    $\delta_k = \frac{a_k + b_k}{4}$ 
4:    $x_1 = \gamma_k - \delta_k$ 
5:    $x_2 = \gamma_k + \delta_k$ 
6:   if  $\phi(x_1) < \phi(x_2)$  then
7:      $a_{k+1} = a_k$ 
8:      $b_{k+1} = x_2$ 
9:   else
10:     $a_{k+1} = x_1$ 
11:     $b_{k+1} = b_k$ 
12:   end if
13: end for
Выход:  $\gamma_K = \frac{a_K + b_K}{2}$ 

```

Упражнение 12.1. Докажите корректность метода дихотомии и получите оценку сходимости метода по аргументу.

Другой метод для поиска минимума унимодальной функции — метод золотого сечения. Постановка задачи такая же: ищем $\gamma^* = \operatorname{argmin}_{\gamma \in [a, b]} \phi(\gamma)$. Отличие от метода дихотомии заключается в том, в каких точках мы смотрим значения функции.

Вход: отрезок поиска $[a_0, b_0]$, число итераций K

```

1:  $\varphi = \frac{\sqrt{5}-1}{2}$ 
2:  $x_1 = b_0 - \varphi(b_0 - a_0)$ 
3:  $x_2 = a_0 + \varphi(b_0 - a_0)$ 
4: for  $i = 1, \dots, K$  do
5:   if  $\phi(x_1) < \phi(x_2)$  then
6:      $a_{k+1} = a_k$ 
7:      $b_{k+1} = x_2$ 
8:      $x_1 = b_{k+1} - \varphi(b_{k+1} - a_{k+1})$ 
9:      $x_2 = x_1$ 
10:  else
11:     $a_{k+1} = x_1$ 
12:     $b_{k+1} = b_k$ 
13:     $x_2 = a_{k+1} + \varphi(b_{k+1} - a_{k+1})$ 
14:     $x_1 = x_2$ 
15:  end if
16: end for
Выход:  $\gamma_k = \frac{a_K + b_K}{2}$ 
    
```

Разбиение с помощью золотого сечения позволяет нам переиспользовать точки с предыдущей итерации: это заметно по строкам 7 и 11 алгоритма. Это приводит к уменьшению количества обращений к функции.

Упражнение 12.2. Докажите корректность алгоритма золотого сечения и получите оценку сходимости метода по аргументу.

Упражнение 12.3. Сравните алгоритмы метода дихотомии и золотого сечения. Какой из них быстрее сходится с точки зрения количества итераций? А с точки зрения обращений к функции?

ЛЗ.4.4 Шаг Поляка — Шора

Рассмотрим другой подход к выбору шага, основанный на минимизации верхней оценки на расстояние до решения, полученной ранее. В ходе доказательства Теоремы ЛЗ.4 о сходимости градиентного спуска для гладких выпуклых функций мы получили неравенство (ЛЗ.6):

$$\|x^{k+1} - x^*\|_2^2 \leq \|x^k - x^*\|_2^2 - 2\gamma_k(f(x^k) - f^*) + \gamma_k^2 \|\nabla f(x^k)\|_2^2.$$

Правая часть неравенства является квадратичной функцией относительно шага γ_k . Попробуем выбрать γ_k так, чтобы минимизировать эту верхнюю оценку. Для этого найдем производную по γ_k и приравняем ее к нулю:

$$-2(f(x^k) - f^*) + 2\gamma_k \|\nabla f(x^k)\|_2^2 = 0.$$

Отсюда получаем оптимальное значение шага, минимизирующее данную оценку:

$$\gamma_k^* = \frac{f(x^k) - f^*}{\|\nabla f(x^k)\|_2^2}.$$

Этот выбор шага известен как *шаг Поляка — Шора*. В общем виде шаг Поляка — Шора записывается с параметром $\alpha > 0$:

$$\gamma_k^* := \frac{f(x^k) - f^*}{\alpha \|\nabla f(x^k)\|_2^2}.$$

Значение функции в оптимуме часто неизвестно, поэтому в формуле вместо f^* используют некоторую нижнюю оценку. Например, для задачи наименьших квадратов целевая функция неотрицательна $f(x) = \|Ax - b\|_2^2 \geq 0$. При использовании оценки параметр α позволяет корректировать шаг в зависимости от точности оценки минимума.

Л3.4.5 Стратегия бэктрекинга для подбора размера шага

Введем в рассмотрение $\phi(\gamma_k) = f(x^k + \gamma_k h^k)$ и некоторые константы β_1, β_2 , удовлетворяющие условию $0 < \beta_1 < \beta_2 < 1$ (Обычно $0 < \beta_1 < 0.3$, $0.9 < \beta_1 < 1$). Сформулируем несколько условий, которые будут полезными при выборе размера шага:

- **Условие достаточного убывания** гарантирует, что функция в точке x^{k+1} не превосходит линейной аппроксимации с коэффициентом наклона β_1 :

$$f(x^{k+1}) \leq f(x^k) + \beta_1 \gamma_k \langle \nabla f(x^k), h^k \rangle,$$

что эквивалентно

$$\varphi(\gamma_k) \leq \varphi(0) + \beta_1 \gamma_k \varphi'(0).$$

- **Условие существенного убывания** гарантирует, что функция в точке x^{k+1} не меньше линейной аппроксимации с коэффициентом наклона β_2 :

$$f(x^{k+1}) \geq f(x^k) + \beta_2 \gamma_k \langle \nabla f(x^k), h^k \rangle,$$

что эквивалентно

$$\varphi(\gamma_k) \geq \varphi(0) + \beta_2 \gamma_k \varphi'(0).$$

- **Условие кривизны** гарантирует, что угол наклона касательной в точке x^{k+1} не меньше, чем угол наклона касательной в точке x^k , умноженный на β_2 :

$$\langle \nabla f(x^{k+1}), h^k \rangle \geq \beta_2 \langle \nabla f(x^k), h^k \rangle,$$

что эквивалентно

$$\varphi'(\gamma_k) \geq \beta_2 \varphi'(0).$$

Различным наборам условий обычно дают собственные имена:

- Армихо (достаточное убывание).

Алгоритм Л3.5 Вычисление γ_k с помощью правила Армихо

Вход: стартовая точка $x^0 \in \mathbb{R}^d$, начальное значение $\gamma_k > 0$, $0 < \beta_1 < 1$, $0 < \rho < 1$,
 $\langle \nabla f(x^k), h^k \rangle < 0$
1: $x^{k+1} = x^k + \gamma_k h^k$
2: **while** $f(x^{k+1}) > f(x^k) + \beta_1 \gamma_k \langle \nabla f(x^k), h^k \rangle$ **do**
3: $\gamma_k = \rho \cdot \gamma_k$
4: $x^{k+1} = x^k + \gamma_k h^k$
5: **end while**
Выход: $\frac{\gamma_k}{\rho}$




Рис. Л3.4: Иллюстрация условия Армихо.

- Вольфа (достаточное убывание + кривизна).

Алгоритм Л3.6 Вычисление γ_k с помощью правила Вольфа

Вход: стартовая точка $x^0 \in \mathbb{R}^d$, начальное значение $\gamma_k > 0$, $l = 0$, $u = \infty$, $\varepsilon > 0$, $0 < \beta_1 < \beta_2 < 1$, $\langle \nabla f(x^k), h^k \rangle < 0$

```

1: while  $u - l > \varepsilon$  do
2:   if  $f(x^{k+1}) > f(x^k) + \beta_1 \gamma_k \langle \nabla f(x^k), h^k \rangle$  then
3:      $u = \gamma_k \frac{l+u}{2}$ 
4:      $\gamma_k = \frac{l+u}{2}$ 
5:   else
6:     if  $\langle \nabla f(x^{k+1}), h^k \rangle < \beta_2 \langle \nabla f(x^k), h^k \rangle$  then
7:        $l = \gamma_k$ 
8:       if  $u = \infty$  then
9:          $\gamma_k = 2 \cdot l$ 
10:      else
11:         $\gamma_k = \frac{l+u}{2}$ 
12:      end if
13:    end if
14:  end if
15: end while

```

В этом случае условие на строке 6 в Алгоритме Л3.6 заменяется на

$$\left| \langle \nabla f(x^{k+1}), h^k \rangle \right| \leq \beta_2 \left| \langle \nabla f(x^k), h^k \rangle \right|, \quad \beta_2 \in (0, 1).$$

Иллюстрация условий на Рисунке Л3.5.

- Усиленные Вольфа (достаточное убывание + кривизна с двух сторон).

Иллюстрация условий на Рисунке Л3.6.

- Гольдштейна (достаточное убывание + существенное убывание):

Рассматриваются $\beta_2 = 1 - \beta_1$ и $\beta_1 \in (0, \frac{1}{2})$. В этом случае условие на строке 6 в Алгоритме Л3.6 заменяется на

$$f(x^{k+1}) < f(x^k) + (1 - \beta_1) \gamma_k \langle \nabla f(x^k), h^k \rangle.$$

Иллюстрация условий на Рисунке ЛЗ.7.




Рис. ЛЗ.5: Иллюстрация условия Вольфа.




Рис. 13.6: Иллюстрация усиленного условия Вольфа.




Рис. 13.7: Иллюстрация условия Гольдштейна.