

Седловые задачи Методы оптимизации

Александр Богданов

Московский физико-технический институт

4 марта 2026



Лагранжиан

Рассмотрим задачу условной оптимизации вида:

$$\begin{aligned} \min_{x \in \mathbb{R}^d} \quad & f_0(x) \\ \text{s.t.} \quad & f_i(x) \leq 0, \quad i = \overline{1, m} \\ & Ax = b, \end{aligned}$$

где $A \in \mathbb{R}^{n \times d}$ и $b \in \mathbb{R}^n$. Дополнительно ещё можно было обобщить постановку и добавить, что $x \in \mathcal{X}$, но мы предполагаем, что $\mathcal{X} \in \mathbb{R}^d$.

Лагранжиан

Определение

Функция Лагранжа для этой задачи строится следующим образом:

$$\mathcal{L}(x, \lambda, \nu) = f_0(x) + \sum_{i=1}^m \lambda_i f_i(x) + \nu^\top (Ax - b).$$

Двойственная функция

Двойственная функция:

$$g(\lambda, \nu) = \inf_{x \in \mathbb{R}^d} \mathcal{L}(x, \lambda, \nu).$$

Двойственная функция

Двойственная функция:

$$g(\lambda, \nu) = \inf_{x \in \mathbb{R}^d} \mathcal{L}(x, \lambda, \nu).$$

Для всех $\lambda \succeq 0$ и $\nu \in \mathbb{R}^n$ верно:

$$g(\lambda, \nu) \leq f(x^*).$$

Условие Слейтера

Утверждение

Рассмотрим задачу с выпуклыми функциями $f_0, \dots, f_m$. Если существует такой $\bar{x} \in \mathbb{R}^d$, что выполняется условие Слейтера:

$$f_i(\bar{x}) < 0, \quad i = \overline{1, m}, \quad A\bar{x} = b,$$

то для этой задачи выполняется сильная двойственность:

$$\sup_{\substack{\lambda \succeq 0 \\ \nu \in \mathbb{R}^n}} g(\lambda, \nu) = f_0(x^*).$$

Седловая точка

Определение

Точка $(x^*, \lambda^*, \nu^*) \in \mathbb{R}^d \times \mathbb{R}_+^m \times \mathbb{R}^n$ называется **седловой** для функции $\mathcal{L}(x, \lambda, \nu)$, если для любых $(x, \lambda, \nu) \in \mathbb{R}^d \times \mathbb{R}_+^m \times \mathbb{R}^n$ выполнено

$$\mathcal{L}(x, \lambda^*, \nu^*) \geq \mathcal{L}(x^*, \lambda^*, \nu^*) \geq \mathcal{L}(x^*, \lambda, \nu).$$

Теорема о седловой точке Куна–Таккера

Теорема

Пусть для задачи оптимизации с выпуклыми функциями $f_0, \dots, f_m$ выполняется условие Слейтера. Тогда следующие утверждения эквивалентны:

- Для x^* существует $\lambda^* \succeq 0$ и $\nu^* \in \mathbb{R}^n$ такие, что (x^*, λ^*, ν^*) — седловая точка функции Лагранжа,
- x^* — глобальное решение задачи оптимизации с ограничениями.

Доказательство

⊕ Пусть для $x^* \in \mathbb{R}^d$ существует $\lambda^* \succeq 0$, $\nu^* \in \mathbb{R}^n$ такие, что (x^*, λ^*, ν^*) — седловая точка функции Лагранжа:

$$\mathcal{L}(x, \lambda^*, \nu^*) \geq \mathcal{L}(x^*, \lambda^*, \nu^*) \geq \mathcal{L}(x^*, \lambda, \nu).$$

Доказательство

⊕ Пусть для $x^* \in \mathbb{R}^d$ существует $\lambda^* \succeq 0$, $\nu^* \in \mathbb{R}^n$ такие, что (x^*, λ^*, ν^*) — седловая точка функции Лагранжа:

$$\mathcal{L}(x, \lambda^*, \nu^*) \geq \mathcal{L}(x^*, \lambda^*, \nu^*) \geq \mathcal{L}(x^*, \lambda, \nu).$$

Для начала удостоверимся, что x^* удовлетворяет ограничениям. Если нет, то либо $Ax^* \neq b$, либо $f_i(x^*) > 0$. Рассмотрим случай, когда нарушается ограничение вида неравенства. Тогда

$$\sup_{\substack{\lambda \succeq 0 \\ \nu \in \mathbb{R}^n}} \mathcal{L}(x^*, \lambda, \nu) = +\infty,$$

Аналогично разбирается случай, когда нарушается $Ax^* \neq b$.

Доказательство

⊕ Пусть для $x^* \in \mathbb{R}^d$ существует $\lambda^* \succeq 0$, $\nu^* \in \mathbb{R}^n$ такие, что (x^*, λ^*, ν^*) — седловая точка функции Лагранжа:

$$\mathcal{L}(x, \lambda^*, \nu^*) \geq \mathcal{L}(x^*, \lambda^*, \nu^*) \geq \mathcal{L}(x^*, \lambda, \nu).$$

Для начала удостоверимся, что x^* удовлетворяет ограничениям. Если нет, то либо $Ax^* \neq b$, либо $f_i(x^*) > 0$. Рассмотрим случай, когда нарушается ограничение вида неравенства. Тогда

$$\sup_{\substack{\lambda \succeq 0 \\ \nu \in \mathbb{R}^n}} \mathcal{L}(x^*, \lambda, \nu) = +\infty,$$

Аналогично разбирается случай, когда нарушается $Ax^* \neq b$.

Теперь поскольку решение x^* удовлетворяет всем ограничениям, то

$$f_0(x^*) = \sup_{\substack{\lambda \succeq 0 \\ \nu \in \mathbb{R}^n}} \mathcal{L}(x^*, \lambda, \nu).$$

Доказательство

Второе неравенство в определении седловой точки даёт:

$$\mathcal{L}(x^*, \lambda^*, \nu^*) = f_0(x^*).$$

Доказательство

Второе неравенство в определении седловой точки даёт:

$$\mathcal{L}(x^*, \lambda^*, \nu^*) = f_0(x^*).$$

Первое неравенство из определения седловой точки даёт:

$$f_0(x) + \sum_{i=1}^m \lambda_i^* f_i(x) + (\nu^*)^\top (Ax - b) \geq \mathcal{L}(x^*, \lambda^*, \nu^*) = f_0(x^*).$$

Доказательство

Второе неравенство в определении седловой точки даёт:

$$\mathcal{L}(x^*, \lambda^*, \nu^*) = f_0(x^*).$$

Первое неравенство из определения седловой точки даёт:

$$f_0(x) + \sum_{i=1}^m \lambda_i^* f_i(x) + (\nu^*)^\top (Ax - b) \geq \mathcal{L}(x^*, \lambda^*, \nu^*) = f_0(x^*).$$

Остаётся заметить, что для допустимых x ограничения выполнены, а λ_i^* неотрицательные. Поэтому получаем, что левая часть не превосходит $f_0(x)$:

$$f_0(x) \geq f_0(x) + \sum_{i=1}^m \lambda_i^* f_i(x) + (\nu^*)^\top (Ax - b) \geq f_0(x^*).$$

Доказательство

⊖ Пусть x^* — глобальное решение задачи с ограничениями. Условие Слейтера нам даёт:

$$f_0(x^*) = g(\lambda^*, \nu^*).$$

Доказательство

⊖ Пусть x^* — глобальное решение задачи с ограничениями. Условие Слейтера нам даёт:

$$f_0(x^*) = g(\lambda^*, \nu^*).$$

С одной стороны, поскольку x^* — допустимое решение, то оно удовлетворяет всем ограничениям. Поэтому выполняется неравенство:

$$f_0(x^*) \geq f_0(x^*) + \sum_{i=1}^m \lambda_i f_i(x^*) + \nu^\top (Ax^* - b) = \mathcal{L}(x^*, \lambda, \nu).$$

Доказательство

⊖ Пусть x^* — глобальное решение задачи с ограничениями. Условие Слейтера нам даёт:

$$f_0(x^*) = g(\lambda^*, \nu^*).$$

С одной стороны, поскольку x^* — допустимое решение, то оно удовлетворяет всем ограничениям. Поэтому выполняется неравенство:

$$f_0(x^*) \geq f_0(x^*) + \sum_{i=1}^m \lambda_i f_i(x^*) + \nu^\top (Ax^* - b) = \mathcal{L}(x^*, \lambda, \nu).$$

С другой стороны, по определению двойственной функции:

$$g(\lambda^*, \nu^*) = \inf_{x \in \mathbb{R}^d} \mathcal{L}(x, \lambda^*, \nu^*) \leq \mathcal{L}(x^*, \lambda^*, \nu^*).$$

$\lambda_i^* f_i(x^*) = 0$ и $Ax^* - b = 0$, поэтому $\mathcal{L}(x^*, \lambda^*, \nu^*) = f_0(x^*)$.

Доказательство

⊖ Пусть x^* — глобальное решение задачи с ограничениями. Условие Слейтера нам даёт:

$$f_0(x^*) = g(\lambda^*, \nu^*).$$

С одной стороны, поскольку x^* — допустимое решение, то оно удовлетворяет всем ограничениям. Поэтому выполняется неравенство:

$$f_0(x^*) \geq f_0(x^*) + \sum_{i=1}^m \lambda_i f_i(x^*) + \nu^\top (Ax^* - b) = \mathcal{L}(x^*, \lambda, \nu).$$

С другой стороны, по определению двойственной функции:

$$g(\lambda^*, \nu^*) = \inf_{x \in \mathbb{R}^d} \mathcal{L}(x, \lambda^*, \nu^*) \leq \mathcal{L}(x^*, \lambda^*, \nu^*).$$

$\lambda_i^* f_i(x^*) = 0$ и $Ax^* - b = 0$, поэтому $\mathcal{L}(x^*, \lambda^*, \nu^*) = f_0(x^*)$.

Собираем все неравенства вместе:

$$\mathcal{L}(x, \lambda^*, \nu^*) \geq g(\lambda^*, \nu^*) = f_0(x^*) = \mathcal{L}(x^*, \lambda^*, \nu^*) \geq \mathcal{L}(x^*, \lambda, \nu).$$

Седловая задача и игры

Седловые задачи — это больше, чем просто функция Лагранжа. Это отдельный и более общий класс задач, который имеет свои приложения.

Седловая задача и игры

Седловые задачи — это больше, чем просто функция Лагранжа. Это отдельный и более общий класс задач, который имеет свои приложения.

Абстрогируемся от функции Лагранжа. Пусть есть некоторая функция:

$$\mathcal{L}(x, \lambda) : \mathcal{X} \times \Lambda \rightarrow \mathbb{R}.$$

Седловая задача и игры

Седловые задачи — это больше, чем просто функция Лагранжа. Это отдельный и более общий класс задач, который имеет свои приложения.

Абстрогируемся от функции Лагранжа. Пусть есть некоторая функция:

$$\mathcal{L}(x, \lambda) : \mathcal{X} \times \Lambda \rightarrow \mathbb{R}.$$

Рассмотрим следующую игровую интерпретацию:

- Пусть есть два игрока: первый выбирает $x \in \mathcal{X}$, а второй — $\lambda \in \Lambda$. В конкретной задаче это может означать, например, распределение ресурсов или выбор стратегии.

Седловая задача и игры

Седловые задачи — это больше, чем просто функция Лагранжа. Это отдельный и более общий класс задач, который имеет свои приложения.

Абстрогируемся от функции Лагранжа. Пусть есть некоторая функция:

$$\mathcal{L}(x, \lambda) : \mathcal{X} \times \Lambda \rightarrow \mathbb{R}.$$

Рассмотрим следующую игровую интерпретацию:

- Пусть есть два игрока: первый выбирает $x \in \mathcal{X}$, а второй — $\lambda \in \Lambda$. В конкретной задаче это может означать, например, распределение ресурсов или выбор стратегии.
- Функция $\mathcal{L}(x, \lambda)$ описывает значение прибыли, зависящей от выбранных x и λ . Первый игрок выплачивает второму сумму $\mathcal{L}(x, \lambda)$.

Седловая задача и игры

Седловые задачи — это больше, чем просто функция Лагранжа. Это отдельный и более общий класс задач, который имеет свои приложения.

Абстрогируемся от функции Лагранжа. Пусть есть некоторая функция:

$$\mathcal{L}(x, \lambda) : \mathcal{X} \times \Lambda \rightarrow \mathbb{R}.$$

Рассмотрим следующую игровую интерпретацию:

- Пусть есть два игрока: первый выбирает $x \in \mathcal{X}$, а второй — $\lambda \in \Lambda$. В конкретной задаче это может означать, например, распределение ресурсов или выбор стратегии.
- Функция $\mathcal{L}(x, \lambda)$ описывает значение прибыли, зависящей от выбранных x и λ . Первый игрок выплачивает второму сумму $\mathcal{L}(x, \lambda)$.
- **Вопрос:** чего хочет первый, а чего хочет второй?

Седловая задача и игры

Седловые задачи — это больше, чем просто функция Лагранжа. Это отдельный и более общий класс задач, который имеет свои приложения.

Абстрогируемся от функции Лагранжа. Пусть есть некоторая функция:

$$\mathcal{L}(x, \lambda) : \mathcal{X} \times \Lambda \rightarrow \mathbb{R}.$$

Рассмотрим следующую игровую интерпретацию:

- Пусть есть два игрока: первый выбирает $x \in \mathcal{X}$, а второй — $\lambda \in \Lambda$. В конкретной задаче это может означать, например, распределение ресурсов или выбор стратегии.
- Функция $\mathcal{L}(x, \lambda)$ описывает значение прибыли, зависящей от выбранных x и λ . Первый игрок выплачивает второму сумму $\mathcal{L}(x, \lambda)$.
- **Вопрос:** чего хочет первый, а чего хочет второй? Первый хочет платить меньше, а второй хочет получить больше.

Седловая задача и игры

- Задача заключается в поиске равновесия между игроками, поскольку экстремальные стратегии не всегда оказываются оптимальными. Например, если второй игрок знает, что при некотором $\tilde{x}$ первый особенно уязвим, он может подобрать $\lambda(\tilde{x})$, при котором его выигрыш будет очень велик. Однако если при других $x \neq \tilde{x}$ та же стратегия $\lambda(\tilde{x})$ не приносит выгоды, первый игрок просто перестанет выбирать $\tilde{x}$. С другой стороны, может существовать стратегия $\tilde{\lambda}$, обеспечивающая второму игроку небольшой, но стабильный выигрыш при любых x . В этом случае $\tilde{\lambda}$ окажется более рациональным выбором.

Седловая задача и игры

- Задача заключается в поиске равновесия между игроками, поскольку экстремальные стратегии не всегда оказываются оптимальными. Например, если второй игрок знает, что при некотором $\tilde{x}$ первый особенно уязвим, он может подобрать $\lambda(\tilde{x})$, при котором его выигрыш будет очень велик. Однако если при других $x \neq \tilde{x}$ та же стратегия $\lambda(\tilde{x})$ не приносит выгоды, первый игрок просто перестанет выбирать $\tilde{x}$. С другой стороны, может существовать стратегия $\tilde{\lambda}$, обеспечивающая второму игроку небольшой, но стабильный выигрыш при любых x . В этом случае $\tilde{\lambda}$ окажется более рациональным выбором.
- С точки зрения седловой задачи, равновесие (x^*, λ^*) является седловой точкой функции $\mathcal{L}$. То есть для любых значений $x \in \mathcal{X}$, $\lambda \in \Lambda$:

$$\mathcal{L}(x, \lambda^*) \geq \mathcal{L}(x^*, \lambda^*) \geq \mathcal{L}(x^*, \lambda).$$

Седловая задача и игры

- **Вопрос:** одинаковый ли будет результат игры, если
 - 1 Сначала выбирает первый игрок, а затем второй;
 - 2 Сначала выбирает второй игрок, а затем первый?

Седловая задача и игры

- **Вопрос:** одинаковый ли будет результат игры, если
 - 1 Сначала выбирает первый игрок, а затем второй;
 - 2 Сначала выбирает второй игрок, а затем первый?
- Нет, если первым ходит игрок 1, он рассуждает так: если я выберу некоторое x , то второй игрок сразу после этого выберет λ , максимизирующую его выигрыш: $\sup_{\lambda \in \Lambda} \mathcal{L}(x, \lambda)$. Значит, мне нужно выбрать x так, чтобы минимизировать свои потери:

$$\inf_{x \in \mathcal{X}} \sup_{\lambda \in \Lambda} \mathcal{L}(x, \lambda).$$

В противоположной ситуации, когда первым выбирает игрок 2, результат определяется выражением

$$\sup_{\lambda \in \Lambda} \inf_{x \in \mathcal{X}} \mathcal{L}(x, \lambda).$$

Седловая задача и игры

- Используя эту интуицию, можно понять, что в общем случае выполняется неравенство

$$\sup_{\lambda \in \Lambda} \inf_{x \in \mathcal{X}} \mathcal{L}(x, \lambda) \leq \inf_{x \in \mathcal{X}} \sup_{\lambda \in \Lambda} \mathcal{L}(x, \lambda).$$

- Формально это следует из следующего рассуждения:

$$\begin{aligned} \inf_{\tilde{x} \in \mathcal{X}} \mathcal{L}(\tilde{x}, \lambda) &\leq \mathcal{L}(x, \lambda) \quad \forall x \in \mathcal{X} \\ \implies \sup_{\lambda \in \Lambda} \inf_{\tilde{x} \in \mathcal{X}} \mathcal{L}(\tilde{x}, \lambda) &\leq \sup_{\lambda \in \Lambda} \mathcal{L}(x, \lambda) \quad \forall x \in \mathcal{X}, \end{aligned}$$

откуда действительно следует

$$\sup_{\lambda \in \Lambda} \inf_{x \in \mathcal{X}} \mathcal{L}(x, \lambda) \leq \inf_{x \in \mathcal{X}} \sup_{\lambda \in \Lambda} \mathcal{L}(x, \lambda).$$

Седловая задача и игры

Как две игры: $\sup_{\lambda \in \Lambda} \inf_{x \in \mathcal{X}} \mathcal{L}(x, \lambda)$ и $\inf_{x \in \mathcal{X}} \sup_{\lambda \in \Lambda} \mathcal{L}(x, \lambda)$ связаны с седловой точкой?

Седловая задача и игры

Как две игры: $\sup_{\lambda \in \Lambda} \inf_{x \in \mathcal{X}} \mathcal{L}(x, \lambda)$ и $\inf_{x \in \mathcal{X}} \sup_{\lambda \in \Lambda} \mathcal{L}(x, \lambda)$ связаны с седловой точкой?

Теорема (о седловой точке)

Множество седловых точек функции $\mathcal{L} : \mathcal{X} \times \Lambda \rightarrow \mathbb{R}$ непустое тогда и только тогда, когда обе задачи $\sup_{\lambda \in \Lambda} \inf_{x \in \mathcal{X}} \mathcal{L}(x, \lambda)$ и $\inf_{x \in \mathcal{X}} \sup_{\lambda \in \Lambda} \mathcal{L}(x, \lambda)$ имеют решения и эти решения совпадают.

Седловая задача и игры

Теорема (Сиона–Какутани)

Пусть $\mathcal{X}, \Lambda$ выпуклые компактные множества, пусть также $\mathcal{L} : \mathcal{X} \times \Lambda \rightarrow \mathbb{R}$ непрерывна, выпукла по x (для любого фиксированного λ) и вогнута по λ (для любого фиксированного x). Тогда $\mathcal{L}$ имеет седловые точки на $\mathcal{X} \times \Lambda$.

Седловая задача и игры

Теорема (Сиона–Какутани)

Пусть $\mathcal{X}$, Λ выпуклые компактные множества, пусть также $\mathcal{L} : \mathcal{X} \times \Lambda \rightarrow \mathbb{R}$ непрерывна, выпукла по x (для любого фиксированного λ) и вогнута по λ (для любого фиксированного x). Тогда $\mathcal{L}$ имеет седловые точки на $\mathcal{X} \times \Lambda$.

Теорема (Сиона–Какутани)

Пусть $\mathcal{X}$, Λ выпуклые множества, и $\mathcal{X}$ или Λ дополнительно компактно, пусть также $\mathcal{L} : \mathcal{X} \times \Lambda \rightarrow \mathbb{R}$ непрерывна, выпукла по x (для любого фиксированного λ) и вогнута по λ (для любого фиксированного x). Тогда (гарантий существования тут нет)

$$\sup_{\lambda \in \Lambda} \inf_{x \in \mathcal{X}} \mathcal{L}(x, \lambda) = \inf_{x \in \mathcal{X}} \sup_{\lambda \in \Lambda} \mathcal{L}(x, \lambda).$$

Седловая задача

- Оптимизация функции Лагранжа — седловая задача.

Седловая задача

- Оптимизация функции Лагранжа — седловая задача.
- Седловые задачи возникают как отдельный большой класс задач.

Седловая задача

- Оптимизация функции Лагранжа — седловая задача.
- Седловые задачи возникают как отдельный большой класс задач.
- Будем рассматривать следующую задачу:

$$\min_{x \in \mathbb{R}^d} \max_{\lambda \in \mathbb{R}^d} \mathcal{L}(x, \lambda),$$

где $\mathcal{L}$ непрерывно дифференцируема по обеим группам переменных и выпукла–вогнута: выпукла по x (для любого фиксированного λ) и вогнута по λ (для любого фиксированного x), а также градиенты $\nabla_x \mathcal{L}$ и $\nabla_\lambda \mathcal{L}$ липшицевы с константой $\frac{L}{\sqrt{2}}$:

$$\begin{aligned} \|\nabla_x \mathcal{L}(x_1, \lambda_1) - \nabla_x \mathcal{L}(x_2, \lambda_2)\|_2^2 &\leq \frac{L^2}{2} \left(\|x_1 - x_2\|_2^2 + \|\lambda_1 - \lambda_2\|_2^2 \right), \\ \|\nabla_\lambda \mathcal{L}(x_1, \lambda_1) - \nabla_\lambda \mathcal{L}(x_2, \lambda_2)\|_2^2 &\leq \frac{L^2}{2} \left(\|x_1 - x_2\|_2^2 + \|\lambda_1 - \lambda_2\|_2^2 \right). \end{aligned}$$

Ищем решение седловой задачи

- Идея спуска-подъема неплохая и часто рабочая.

Ищем решение седловой задачи

- Идея спуска-подъема неплохая и часто рабочая.
- Он бывает одновременный (Simultaneous Gradient Descent–Ascent):

Алгоритм Sim-GDA

Вход: стартовая точка $(x^0, \lambda^0) \in \mathbb{R}^d \times \mathbb{R}^n$, размеры шагов $\{\gamma_k\}_{k=0} > 0$, количество итераций K

- 1: **for** $k = 0, 1, \dots, K - 1$ **do**
- 2: $x^{k+1} = x^k - \gamma_k \nabla_x \mathcal{L}(x^k, \lambda^k)$
- 3: $\lambda^{k+1} = \lambda^k + \gamma_k \nabla_\lambda \mathcal{L}(x^k, \lambda^k)$
- 4: **end for**

Выход: x^K, λ^K

Ищем решение седловой задачи

- Он бывает поочерёдный (Alternating Gradient Descent–Ascent):

Алгоритм Alt–GDA

Вход: стартовая точка $(x^0, \lambda^0) \in \mathbb{R}^d \times \mathbb{R}^n$, размеры шагов $\{\gamma_k\}_{k=0} > 0$, количество итераций K

- 1: **for** $k = 0, 1, \dots, K - 1$ **do**
 - 2: $x^{k+1} = x^k - \gamma_k \nabla_x \mathcal{L}(x^k, \lambda^k)$
 - 3: $\lambda^{k+1} = \lambda^k + \gamma_k \nabla_\lambda \mathcal{L}(x^{k+1}, \lambda^k)$
 - 4: **end for**
- Выход:** x^K, λ^K
-


Ищем решение седловой задачи

- Интуиция подсказывает, что у него есть не самые приятные аспекты.
- Рассмотрим задачу $\min_{x \in \mathbb{R}} \max_{\lambda \in \mathbb{R}} x\lambda$. Стартовая точка $(1, 1)$.
Вопрос: где решение?

Ищем решение седловой задачи

- Интуиция подсказывает, что у него есть не самые приятные аспекты.
- Рассмотрим задачу $\min_{x \in \mathbb{R}} \max_{\lambda \in \mathbb{R}} x\lambda$. Стартовая точка $(1, 1)$.
Вопрос: где решение? Точка $(0, 0)$.

Ищем решение седловой задачи



Ищем решение седловой задачи

- Alt-GDA начал двигаться по кругу, а Sim-GDA вообще стал расходиться.

Ищем решение седловой задачи

- Alt-GDA начал двигаться по кругу, а Sim-GDA вообще стал расходиться.
- В сильно выпуклых–сильно вогнутых задачах оба алгоритма сходятся гарантированно. Одновременный с итерационной скоростью $\mathcal{O}\left(\frac{L^2}{\mu^2}\right)$, а поочерёдный со скоростью $\mathcal{O}\left(\frac{L}{\mu}\right)$, что является оптимальным результатом.

Ищем решение седловой задачи

- Alt-GDA начал двигаться по кругу, а Sim-GDA вообще стал расходиться.
- В сильно выпуклых–сильно вогнутых задачах оба алгоритма сходятся гарантированно. Одновременный с итерационной скоростью $\mathcal{O}\left(\frac{L^2}{\mu^2}\right)$, а поочерёдный со скоростью $\mathcal{O}\left(\frac{L}{\mu}\right)$, что является оптимальным результатом.
- Идея поочерёдного спуска–подъёма проста в понимании, реализации, и вполне неплохо работает, но с рядом упомянутых выше проблем. Все они решаются в экстраградиентном методе.

Экстраградиентный метод

Алгоритм Экстраградиентный метод

Вход: стартовая точка $(x^0, \lambda^0) \in \mathbb{R}^d \times \mathbb{R}^n$, размеры шагов $\{\gamma_k\}_{k=0} > 0$, количество итераций K

- 1: **for** $k = 0, 1, \dots, K - 1$ **do**
- 2: $x^{k+1/2} = x^k - \gamma_k \nabla_x \mathcal{L}(x^k, \lambda^k)$
- 3: $\lambda^{k+1/2} = \lambda^k + \gamma_k \nabla_\lambda \mathcal{L}(x^k, \lambda^k)$
- 4: $x^{k+1} = x^k - \gamma_k \nabla_x \mathcal{L}(x^{k+1/2}, \lambda^{k+1/2})$
- 5: $\lambda^{k+1} = \lambda^k + \gamma_k \nabla_\lambda \mathcal{L}(x^{k+1/2}, \lambda^{k+1/2})$
- 6: **end for**

Выход: $\frac{1}{K} \sum_{k=0}^{K-1} x^{k+1/2}, \frac{1}{K} \sum_{k=0}^{K-1} \lambda^{k+1/2}$

Вспомогательное утверждение

Утверждение

Пусть $z, u \in \mathbb{R}^d$, и $z^+ = z - u$, тогда для любого $u \in \mathbb{R}^d$:

$$\|z^+ - u\|_2^2 = \|z - u\|_2^2 - 2\langle y, z^+ - u \rangle - \|z^+ - z\|_2^2.$$

Тут достаточно обычных алгебраических преобразований:

$$\begin{aligned}\|z^+ - u\|_2^2 &= \|z^+ - z + z - u\|_2^2 \\&= \|z - u\|_2^2 + 2\langle z^+ - z, z - u \rangle + \|z^+ - z\|_2^2 \\&= \|z - u\|_2^2 + 2\langle z^+ - z, z - z^+ + z^+ - u \rangle + \|z^+ - z\|_2^2 \\&= \|z - u\|_2^2 + 2\langle z^+ - z, z^+ - u \rangle - \|z^+ - z\|_2^2 \\&= \|z - u\|_2^2 - 2\langle y, z^+ - u \rangle - \|z^+ - z\|_2^2.\end{aligned}$$

Доказательство

- Для удобства введём вектор переменных z и оператор:

$$z = \begin{pmatrix} x \\ \lambda \end{pmatrix}, \quad F(z) = F(x, \lambda) = \begin{pmatrix} \nabla_x \mathcal{L}(x, \lambda) \\ -\nabla_\lambda \mathcal{L}(x, \lambda) \end{pmatrix}.$$

Доказательство

- Для удобства введём вектор переменных z и оператор:

$$z = \begin{pmatrix} x \\ \lambda \end{pmatrix}, \quad F(z) = F(x, \lambda) = \begin{pmatrix} \nabla_x \mathcal{L}(x, \lambda) \\ -\nabla_\lambda \mathcal{L}(x, \lambda) \end{pmatrix}.$$

- Если $\nabla_x \mathcal{L}$ и $\nabla_\lambda \mathcal{L}$ L -липшицевы, то F — L -липшицев и оператор F . Как проявляется выпуклость по x и вогнутость по λ увидим позже.

Доказательство

- Для удобства введём вектор переменных z и оператор:

$$z = \begin{pmatrix} x \\ \lambda \end{pmatrix}, \quad F(z) = F(x, \lambda) = \begin{pmatrix} \nabla_x \mathcal{L}(x, \lambda) \\ -\nabla_\lambda \mathcal{L}(x, \lambda) \end{pmatrix}.$$

- Если $\nabla_x \mathcal{L}$ и $\nabla_\lambda \mathcal{L}$ L -липшицевы, то L -липшицев и оператор F . Как проявляется выпуклость по x и вогнутость по λ увидим позже.
- **Вопрос:** как экстраградиентный метод будет выглядеть в новых обозначениях?

Доказательство

- Для удобства введём вектор переменных z и оператор:

$$z = \begin{pmatrix} x \\ \lambda \end{pmatrix}, \quad F(z) = F(x, \lambda) = \begin{pmatrix} \nabla_x \mathcal{L}(x, \lambda) \\ -\nabla_\lambda \mathcal{L}(x, \lambda) \end{pmatrix}.$$

- Если $\nabla_x \mathcal{L}$ и $\nabla_\lambda \mathcal{L}$ L -липшицевы, то L -липшицев и оператор F . Как проявляется выпуклость по x и вогнутость по λ увидим позже.
- **Вопрос:** как экстраградиентный метод будет выглядеть в новых обозначениях?

$$\begin{aligned} z^{k+1/2} &= z^k - \gamma F(z^k), \\ z^{k+1} &= z^k - \gamma F(z^{k+1/2}). \end{aligned}$$

Доказательство

Применим Утверждение два раза:

- Для $z = z^k$, $y = \gamma F(z^{k+1/2})$ и $z^+ = z^{k+1}$:

$$\|z^{k+1} - u\|_2^2 = \|z^k - u\|_2^2 - 2\gamma \langle F(z^{k+1/2}), z^{k+1} - u \rangle - \|z^{k+1} - z^k\|_2^2.$$

Доказательство

Применим Утверждение два раза:

- Для $z = z^k$, $y = \gamma F(z^{k+1/2})$ и $z^+ = z^{k+1}$:

$$\|z^{k+1} - u\|_2^2 = \|z^k - u\|_2^2 - 2\gamma \langle F(z^{k+1/2}), z^{k+1} - u \rangle - \|z^{k+1} - z^k\|_2^2.$$

- Для $z = z^k$, $y = \gamma F(z^k)$ и $z^+ = z^{k+1/2}$:

$$\|z^{k+1/2} - \tilde{u}\|_2^2 = \|z^k - \tilde{u}\|_2^2 - 2\gamma \langle F(z^k), z^{k+1/2} - \tilde{u} \rangle - \|z^{k+1/2} - z^k\|_2^2.$$

Доказательство

Применим Утверждение два раза:

- Для $z = z^k$, $y = \gamma F(z^{k+1/2})$ и $z^+ = z^{k+1}$:

$$\|z^{k+1} - u\|_2^2 = \|z^k - u\|_2^2 - 2\gamma \langle F(z^{k+1/2}), z^{k+1} - u \rangle - \|z^{k+1} - z^k\|_2^2.$$

- Для $z = z^k$, $y = \gamma F(z^k)$ и $z^+ = z^{k+1/2}$:

$$\|z^{k+1/2} - \tilde{u}\|_2^2 = \|z^k - \tilde{u}\|_2^2 - 2\gamma \langle F(z^k), z^{k+1/2} - \tilde{u} \rangle - \|z^{k+1/2} - z^k\|_2^2.$$

Подставим вместо $\tilde{u} = z^{k+1}$ и сложим:

$$\begin{aligned} \|z^{k+1} - u\|_2^2 + \|z^{k+1/2} - z^{k+1}\|_2^2 &= \|z^k - u\|_2^2 - 2\gamma \langle F(z^{k+1/2}), z^{k+1} - u \rangle \\ &\quad - 2\gamma \langle F(z^k), z^{k+1/2} - z^{k+1} \rangle - \|z^{k+1/2} - z^k\|_2^2. \end{aligned}$$

Доказательство

Перегруппируем слагаемые:

$$\begin{aligned} \|z^{k+1} - u\|_2^2 + \|z^{k+1/2} - z^{k+1}\|_2^2 &= \|z^k - u\|_2^2 \\ &+ 2\gamma \langle F(z^{k+1/2}) - F(z^k), z^{k+1/2} - z^k \rangle \\ &- 2\gamma \langle F(z^{k+1/2}), z^{k+1/2} - u \rangle - \|z^{k+1/2} - z^k\|_2^2. \end{aligned}$$

Доказательство

Перегруппируем слагаемые:

$$\begin{aligned}\|z^{k+1} - u\|_2^2 + \|z^{k+1/2} - z^{k+1}\|_2^2 &= \|z^k - u\|_2^2 \\ &+ 2\gamma \langle F(z^{k+1/2}) - F(z^k), z^{k+1/2} - z^k \rangle \\ &- 2\gamma \langle F(z^{k+1/2}), z^{k+1/2} - u \rangle - \|z^{k+1/2} - z^k\|_2^2.\end{aligned}$$

Оценим первое скалярное произведение:

$$\begin{aligned}\|z^{k+1} - u\|_2^2 + \|z^{k+1/2} - z^{k+1}\|_2^2 &\leq \|z^k - u\|_2^2 + \gamma^2 \|F(z^k) - F(z^{k+1/2})\|_2^2 \\ &+ \|z^{k+1/2} - z^{k+1}\|_2^2 - 2\gamma \langle F(z^{k+1/2}), z^{k+1/2} - u \rangle \\ &- \|z^{k+1/2} - z^k\|_2^2.\end{aligned}$$

Доказательство

Слагаемое $\|z^{k+1/2} - z^{k+1}\|_2^2$ уничтожается с обеих сторон:

$$\begin{aligned} \|z^{k+1} - u\|_2^2 &\leq \|z^k - u\|_2^2 + \gamma^2 \|F(z^k) - F(z^{k+1/2})\|_2^2 \\ &\quad - 2\gamma \langle F(z^{k+1/2}), z^{k+1/2} - u \rangle - \|z^{k+1/2} - z^k\|_2^2. \end{aligned}$$

Доказательство

Слагаемое $\|z^{k+1/2} - z^{k+1}\|_2^2$ уничтожается с обеих сторон:

$$\begin{aligned}\|z^{k+1} - u\|_2^2 &\leq \|z^k - u\|_2^2 + \gamma^2 \|F(z^k) - F(z^{k+1/2})\|_2^2 \\ &\quad - 2\gamma \langle F(z^{k+1/2}), z^{k+1/2} - u \rangle - \|z^{k+1/2} - z^k\|_2^2.\end{aligned}$$

Используем L -липшицевость F :

$$\begin{aligned}\|z^{k+1} - u\|_2^2 &\leq \|z^k - u\|_2^2 + \gamma^2 L^2 \|z^k - z^{k+1/2}\|_2^2 \\ &\quad - 2\gamma \langle F(z^{k+1/2}), z^{k+1/2} - u \rangle - \|z^{k+1/2} - z^k\|_2^2 \\ &= \|z^k - u\|_2^2 - 2\gamma \langle F(z^{k+1/2}), z^{k+1/2} - u \rangle \\ &\quad + (\gamma^2 L^2 - 1) \|z^{k+1/2} - z^k\|_2^2.\end{aligned}$$

Доказательство

Возьмём $\gamma \leq \frac{1}{L}$ и откинем последнее слагаемое:

$$\|z^{k+1} - u\|_2^2 \leq \|z^k - u\|_2^2 - 2\gamma \langle F(z^{k+1/2}), z^{k+1/2} - u \rangle.$$

Доказательство

Возьмём $\gamma \leq \frac{1}{L}$ и откинем последнее слагаемое:

$$\|z^{k+1} - u\|_2^2 \leq \|z^k - u\|_2^2 - 2\gamma \langle F(z^{k+1/2}), z^{k+1/2} - u \rangle.$$

Эквивалентная запись неравенства:

$$2\gamma \langle F(z^{k+1/2}), z^{k+1/2} - u \rangle \leq \|z^k - u\|_2^2 - \|z^{k+1} - u\|_2^2.$$

Доказательство

Возьмём $\gamma \leq \frac{1}{L}$ и откинем последнее слагаемое:

$$\|z^{k+1} - u\|_2^2 \leq \|z^k - u\|_2^2 - 2\gamma \langle F(z^{k+1/2}), z^{k+1/2} - u \rangle.$$

Эквивалентная запись неравенства:

$$2\gamma \langle F(z^{k+1/2}), z^{k+1/2} - u \rangle \leq \|z^k - u\|_2^2 - \|z^{k+1} - u\|_2^2.$$

Рассмотрим левую часть, оценим её снизу:

$$\begin{aligned} & \langle F(z^{k+1/2}), z^{k+1/2} - u \rangle \\ &= \left\langle \begin{pmatrix} \nabla_x \mathcal{L}(x^{k+1/2}, \lambda^{k+1/2}) \\ -\nabla_\lambda \mathcal{L}(x^{k+1/2}, \lambda^{k+1/2}) \end{pmatrix}, \begin{pmatrix} x^{k+1/2} \\ \lambda^{k+1/2} \end{pmatrix} - \begin{pmatrix} u_x \\ u_\lambda \end{pmatrix} \right\rangle \\ &= \langle \nabla_x \mathcal{L}(x^{k+1/2}, \lambda^{k+1/2}), x^{k+1/2} - u_x \rangle \\ & \quad + \langle -\nabla_\lambda \mathcal{L}(x^{k+1/2}, \lambda^{k+1/2}), \lambda^{k+1/2} - u_\lambda \rangle. \end{aligned}$$

Доказательство

Применим выпуклость по x и вогнутость по λ :

$$\begin{aligned}\left\langle F(z^{k+1/2}), z^{k+1/2} - u \right\rangle &= \left\langle \nabla_x \mathcal{L}(x^{k+1/2}, \lambda^{k+1/2}), x^{k+1/2} - u_x \right\rangle \\ &\quad + \left\langle -\nabla_\lambda \mathcal{L}(x^{k+1/2}, \lambda^{k+1/2}), \lambda^{k+1/2} - u_\lambda \right\rangle \\ &\geq \mathcal{L}(x^{k+1/2}, \lambda^{k+1/2}) - \mathcal{L}(u_x, \lambda^{k+1/2}) \\ &\quad - \mathcal{L}(x^{k+1/2}, \lambda^{k+1/2}) + \mathcal{L}(x^{k+1/2}, u_\lambda).\end{aligned}$$

Доказательство

Применим выпуклость по x и вогнутость по λ :

$$\begin{aligned}\left\langle F(z^{k+1/2}), z^{k+1/2} - u \right\rangle &= \left\langle \nabla_x \mathcal{L}(x^{k+1/2}, \lambda^{k+1/2}), x^{k+1/2} - u_x \right\rangle \\ &\quad + \left\langle -\nabla_\lambda \mathcal{L}(x^{k+1/2}, \lambda^{k+1/2}), \lambda^{k+1/2} - u_\lambda \right\rangle \\ &\geq \mathcal{L}(x^{k+1/2}, \lambda^{k+1/2}) - \mathcal{L}(u_x, \lambda^{k+1/2}) \\ &\quad - \mathcal{L}(x^{k+1/2}, \lambda^{k+1/2}) + \mathcal{L}(x^{k+1/2}, u_\lambda).\end{aligned}$$

В итоге получаем:

$$2\gamma \left(\mathcal{L}(x^{k+1/2}, u_\lambda) - \mathcal{L}(u_x, \lambda^{k+1/2}) \right) \leq \|z^k - u\|_2^2 - \|z^{k+1} - u\|_2^2.$$

Доказательство

Суммируем по всем k от 0 до $K - 1$ и делим на $2\gamma K$:

$$\begin{aligned} \frac{1}{K} \sum_{k=0}^{K-1} \left(\mathcal{L}(x^{k+1/2}, u_\lambda) - \mathcal{L}(u_x, \lambda^{k+1/2}) \right) &\leq \frac{\|z^0 - u\|_2^2 - \|z^K - u\|_2^2}{2\gamma K} \\ &\leq \frac{\|z^0 - u\|_2^2}{2\gamma K}. \end{aligned}$$

Доказательство

Суммируем по всем k от 0 до $K - 1$ и делим на $2\gamma K$:

$$\begin{aligned}\frac{1}{K} \sum_{k=0}^{K-1} \left(\mathcal{L}(x^{k+1/2}, u_\lambda) - \mathcal{L}(u_x, \lambda^{k+1/2}) \right) &\leq \frac{\|z^0 - u\|_2^2 - \|z^K - u\|_2^2}{2\gamma K} \\ &\leq \frac{\|z^0 - u\|_2^2}{2\gamma K}.\end{aligned}$$

Неравенство Йенсена для выпуклой и вогнутой функции даёт:

$$\mathcal{L}\left(\frac{1}{K} \sum_{k=0}^{K-1} x^{k+1/2}, u_\lambda\right) - \mathcal{L}\left(u_x, \frac{1}{K} \sum_{k=0}^{K-1} \lambda^{k+1/2}\right) \leq \frac{\|z^0 - u\|_2^2}{2\gamma K}.$$

Сходимость экстраградиентного метода

Теорема

Пусть седловая задача с L -гладкой выпукло-вогнутой функцией $\mathcal{L} : \mathbb{R}^d \times \mathbb{R}^n \rightarrow \mathbb{R}$ решается с помощью экстраградиентного метода. Тогда при $\gamma_k = \gamma \leq \frac{1}{L}$ для любого $u \in \mathbb{R}^d \times \mathbb{R}^n$ справедлива следующая оценка сходимости:

$$\mathcal{L}\left(\frac{1}{K} \sum_{k=0}^{K-1} x^{k+1/2}, u_\lambda\right) - \mathcal{L}\left(u_x, \frac{1}{K} \sum_{k=0}^{K-1} \lambda^{k+1/2}\right) \leq \frac{\|z^0 - u\|_2^2}{2\gamma K}.$$

Сходимость экстраградиентного метода

Теорема

Пусть седловая задача с L -гладкой выпукло-вогнутой функцией $\mathcal{L} : \mathbb{R}^d \times \mathbb{R}^n \rightarrow \mathbb{R}$ решается с помощью экстраградиентного метода. Тогда при $\gamma_k = \gamma \leq \frac{1}{L}$ для любого $u \in \mathbb{R}^d \times \mathbb{R}^n$ справедлива следующая оценка сходимости:

$$\mathcal{L}\left(\frac{1}{K} \sum_{k=0}^{K-1} x^{k+1/2}, u_\lambda\right) - \mathcal{L}\left(u_x, \frac{1}{K} \sum_{k=0}^{K-1} \lambda^{k+1/2}\right) \leq \frac{\|z^0 - u\|_2^2}{2\gamma K}.$$

Вопрос: что подставлять в качестве $u = (u_x, u_\lambda)$?

Как измерять сходимость?

- Ожидаемый вариант:

$$\mathcal{L}\left(\frac{1}{K} \sum_{k=0}^{K-1} x^{k+1/2}, \lambda^*\right) - \mathcal{L}\left(x^*, \frac{1}{K} \sum_{k=0}^{K-1} \lambda^{k+1/2}\right),$$

где x^* и λ^* — решение седловой задачи.

Как измерять сходимость?

- Ожидаемый вариант:

$$\mathcal{L}\left(\frac{1}{K} \sum_{k=0}^{K-1} x^{k+1/2}, \lambda^*\right) - \mathcal{L}\left(x^*, \frac{1}{K} \sum_{k=0}^{K-1} \lambda^{k+1/2}\right),$$

где x^* и λ^* — решение седловой задачи.

- Покажем, почему такой выбор не самый удачный. Для этого рассмотрим простую седловую задачу:

$$\min_{x \in \mathcal{X}} \max_{\lambda \in \Lambda} (x - 1)(\lambda + 1).$$

Как измерять сходимость?

- Ожидаемый вариант:

$$\mathcal{L}\left(\frac{1}{K} \sum_{k=0}^{K-1} x^{k+1/2}, \lambda^*\right) - \mathcal{L}\left(x^*, \frac{1}{K} \sum_{k=0}^{K-1} \lambda^{k+1/2}\right),$$

где x^* и λ^* — решение седловой задачи.

- Покажем, почему такой выбор не самый удачный. Для этого рассмотрим простую седловую задачу:

$$\min_{x \in \mathcal{X}} \max_{\lambda \in \Lambda} (x - 1)(\lambda + 1).$$

Предположим, что $1 \in \mathcal{X}$, $-1 \in \Lambda$, тогда решение этой задачи — $x^* = 1$, $\lambda^* = -1$ и $\mathcal{L}(1, -1) = 0$. Значение полученного критерия получится следующим: $\mathcal{L}(x, \lambda^*) - \mathcal{L}(x^*, \lambda) = 0$.

Как измерять сходимость?

- Ожидаемый вариант:

$$\mathcal{L}\left(\frac{1}{K} \sum_{k=0}^{K-1} x^{k+1/2}, \lambda^*\right) - \mathcal{L}\left(x^*, \frac{1}{K} \sum_{k=0}^{K-1} \lambda^{k+1/2}\right),$$

где x^* и λ^* — решение седловой задачи.

- Покажем, почему такой выбор не самый удачный. Для этого рассмотрим простую седловую задачу:

$$\min_{x \in \mathcal{X}} \max_{\lambda \in \Lambda} (x - 1)(\lambda + 1).$$

Предположим, что $1 \in \mathcal{X}$, $-1 \in \Lambda$, тогда решение этой задачи — $x^* = 1$, $\lambda^* = -1$ и $\mathcal{L}(1, -1) = 0$. Значение полученного критерия получится следующим: $\mathcal{L}(x, \lambda^*) - \mathcal{L}(x^*, \lambda) = 0$.

- Такой критерий не подходит для выпукло-вогнутых седел, но подходит для сильно выпукло-сильно вогнутых. Но в сильно выпуклом-сильно вогнутом случае можно доказать линейную сходимость по аргументу, что более сильный результат.

Как измерять сходимость?

- Нужный вариант: $\max_{\lambda \in \Lambda} \mathcal{L}(x^k, \lambda) - \min_{x \in \mathcal{X}} \mathcal{L}(x, \lambda^k)$.

Как измерять сходимость?

- Нужный вариант: $\max_{\lambda \in \Lambda} \mathcal{L}(x^k, \lambda) - \min_{x \in \mathcal{X}} \mathcal{L}(x, \lambda^k)$.
- Если $\min_{x \in \mathcal{X}} \max_{\lambda \in \Lambda} (x-1)(\lambda+1)$ и $\mathcal{X} = \mathbb{R}$, $\Lambda = \mathbb{R}$, то **вопрос**: что можно сказать про $\max_{\lambda \in \Lambda} \mathcal{L}(x^k, \lambda) - \min_{x \in \mathcal{X}} \mathcal{L}(x, \lambda^k)$?

Как измерять сходимость?

- Нужный вариант: $\max_{\lambda \in \Lambda} \mathcal{L}(x^k, \lambda) - \min_{x \in \mathcal{X}} \mathcal{L}(x, \lambda^k)$.
- Если $\min_{x \in \mathcal{X}} \max_{\lambda \in \Lambda} (x - 1)(\lambda + 1)$ и $\mathcal{X} = \mathbb{R}$, $\Lambda = \mathbb{R}$, то **вопрос**: что можно сказать про $\max_{\lambda \in \Lambda} \mathcal{L}(x^k, \lambda) - \min_{x \in \mathcal{X}} \mathcal{L}(x, \lambda^k)$? $= +\infty$.
- Поэтому критерий вида: $\max_{\lambda \in \Lambda} \mathcal{L}(x^k, \lambda) - \min_{x \in \mathcal{X}} \mathcal{L}(x, \lambda^k)$, формально можно рассматривать только на компактах.

Как измерять сходимость?

- Нужный вариант: $\max_{\lambda \in \Lambda} \mathcal{L}(x^k, \lambda) - \min_{x \in \mathcal{X}} \mathcal{L}(x, \lambda^k)$.
- Если $\min_{x \in \mathcal{X}} \max_{\lambda \in \Lambda} (x - 1)(\lambda + 1)$ и $\mathcal{X} = \mathbb{R}$, $\Lambda = \mathbb{R}$, то **вопрос**: что можно сказать про $\max_{\lambda \in \Lambda} \mathcal{L}(x^k, \lambda) - \min_{x \in \mathcal{X}} \mathcal{L}(x, \lambda^k)$? $= +\infty$.
- Поэтому критерий вида: $\max_{\lambda \in \Lambda} \mathcal{L}(x^k, \lambda) - \min_{x \in \mathcal{X}} \mathcal{L}(x, \lambda^k)$, формально можно рассматривать только на компактах.
- Кажется, что это означает, что выпукло-вогнутые седловые задачи можно решать только на компактах (об этом говорила теорема Сиона–Какутани).

Как измерять сходимость?

- Нужный вариант: $\max_{\lambda \in \Lambda} \mathcal{L}(x^k, \lambda) - \min_{x \in \mathcal{X}} \mathcal{L}(x, \lambda^k)$.
- Если $\min_{x \in \mathcal{X}} \max_{\lambda \in \Lambda} (x - 1)(\lambda + 1)$ и $\mathcal{X} = \mathbb{R}$, $\Lambda = \mathbb{R}$, то **вопрос**: что можно сказать про $\max_{\lambda \in \Lambda} \mathcal{L}(x^k, \lambda) - \min_{x \in \mathcal{X}} \mathcal{L}(x, \lambda^k)$? $= +\infty$.
- Поэтому критерий вида: $\max_{\lambda \in \Lambda} \mathcal{L}(x^k, \lambda) - \min_{x \in \mathcal{X}} \mathcal{L}(x, \lambda^k)$, формально можно рассматривать только на компактах.
- Кажется, что это означает, что выпукло-вогнутые седловые задачи можно решать только на компактах (об этом говорила теорема Сиона–Какутани).
- Такую же проблему встречали и в выпуклой минимизации (на $\mathbb{R}^d$ выпуклая задача может не иметь решения).

Как измерять сходимость?


- Нужный вариант: $\max_{\lambda \in \Lambda} \mathcal{L}(x^k, \lambda) - \min_{x \in \mathcal{X}} \mathcal{L}(x, \lambda^k)$.
- Если $\min_{x \in \mathcal{X}} \max_{\lambda \in \Lambda} (x - 1)(\lambda + 1)$ и $\mathcal{X} = \mathbb{R}$, $\Lambda = \mathbb{R}$, то **вопрос**: что можно сказать про $\max_{\lambda \in \Lambda} \mathcal{L}(x^k, \lambda) - \min_{x \in \mathcal{X}} \mathcal{L}(x, \lambda^k)$? $= +\infty$.
- Поэтому критерий вида: $\max_{\lambda \in \Lambda} \mathcal{L}(x^k, \lambda) - \min_{x \in \mathcal{X}} \mathcal{L}(x, \lambda^k)$, формально можно рассматривать только на компактах.
- Кажется, что это означает, что выпукло-вогнутые седловые задачи можно решать только на компактах (об этом говорила теорема Сиона–Какутани).
- Такую же проблему встречали и в выпуклой минимизации (на $\mathbb{R}^d$ выпуклая задача может не иметь решения).
- В выпуклой минимизации предполагали, что решение существует.

Как измерять сходимость?

- Нужный вариант: $\max_{\lambda \in \Lambda} \mathcal{L}(x^k, \lambda) - \min_{x \in \mathcal{X}} \mathcal{L}(x, \lambda^k)$.
- Если $\min_{x \in \mathcal{X}} \max_{\lambda \in \Lambda} (x - 1)(\lambda + 1)$ и $\mathcal{X} = \mathbb{R}$, $\Lambda = \mathbb{R}$, то **вопрос**: что можно сказать про $\max_{\lambda \in \Lambda} \mathcal{L}(x^k, \lambda) - \min_{x \in \mathcal{X}} \mathcal{L}(x, \lambda^k)$? $= +\infty$.
- Поэтому критерий вида: $\max_{\lambda \in \Lambda} \mathcal{L}(x^k, \lambda) - \min_{x \in \mathcal{X}} \mathcal{L}(x, \lambda^k)$, формально можно рассматривать только на компактах.
- Кажется, что это означает, что выпукло-вогнутые седловые задачи можно решать только на компактах (об этом говорила теорема Сиона-Какутани).
- Такую же проблему встречали и в выпуклой минимизации (на $\mathbb{R}^d$ выпуклая задача может не иметь решения).
- В выпуклой минимизации предполагали, что решение существует.
- Здесь можно сделать то же самое: предположим, что решение существует и лежит в некотором компактном множестве $\mathcal{X}_* \times \Lambda_*$, тогда в критерии сходимости можно брать $\Lambda = \Lambda_*$ и $\mathcal{X} = \mathcal{X}_*$.

Экстраградиентный метод

Как итоговую точку можно использовать не среднее всех полученных точек, а лишь последнюю. Но сходимость будет хуже — $\mathcal{O}\left(\frac{1}{\sqrt{K}}\right)$.



Прямо–двойственный алгоритм

Рассмотрим задачу минимизации с регуляризатором:

$$\min_{x \in \mathbb{R}^d} f(x) + h(Ax).$$

Прямо-двойственный алгоритм

Рассмотрим задачу минимизации с регуляризатором:

$$\min_{x \in \mathbb{R}^d} f(x) + h(Ax).$$

Заметим, что для выпуклой и замкнутой функции:

$$h(Ax) = h^{**}(Ax) = \max_{\lambda \in \mathbb{R}^n} \{(Ax)^\top \lambda - h^*(\lambda)\} = \max_{\lambda \in \mathbb{R}^n} \{-\lambda^\top Ax - h^*(-\lambda)\},$$

тогда, если взять $g(\lambda) = h^*(-\lambda)$, то исходную задачу можно свести к следующей:

$$\min_{x \in \mathbb{R}^d} \max_{\lambda \in \mathbb{R}^n} \mathcal{L}(x, \lambda) = f(x) - \lambda^\top Ax - g(\lambda).$$

Дополнительно потребуем, чтобы функция f была L_f -гладкой и выпуклой, а функция g была L_g -гладкой и выпуклой.

Прямо-двойственный алгоритм

Алгоритм Прямо-двойственный алгоритм

Вход: стартовая точка $x^0 \in \mathbb{R}^d$, размеры шагов $\{\gamma_k\}_{k=0} > 0$, количество итераций K

- 1: **for** $k = 0, 1, \dots, K - 1$ **do**
- 2: $x^{k+1} = x^k - \gamma_k (\nabla f(x^k) - A^\top \lambda^k)$
- 3: $\lambda^{k+1} = \lambda^k - \gamma_k (\nabla g(\lambda^k) + A(2x^{k+1} - x^k))$
- 4: **end for**

Выход: $\frac{1}{K} \sum_{k=1}^K x^k, \frac{1}{K} \sum_{k=1}^K \lambda^k$

Прямо-двойственный алгоритм

Алгоритм Прямо-двойственный алгоритм

Вход: стартовая точка $x^0 \in \mathbb{R}^d$, размеры шагов $\{\gamma_k\}_{k=0} > 0$, количество итераций K

- 1: **for** $k = 0, 1, \dots, K - 1$ **do**
- 2: $x^{k+1} = x^k - \gamma_k (\nabla f(x^k) - A^\top \lambda^k)$
- 3: $\lambda^{k+1} = \lambda^k - \gamma_k (\nabla g(\lambda^k) + A(2x^{k+1} - x^k))$
- 4: **end for**

Выход: $\frac{1}{K} \sum_{k=1}^K x^k, \frac{1}{K} \sum_{k=1}^K \lambda^k$

Если вместо $(2x^{k+1} - x^k)$ подставить просто x^k получится просто спуск-подъём. В $(2x^{k+1} - x^k)$ зашита «экстраградиентность».

Доказательство

Распишем разность:

$$\begin{aligned}\mathcal{L}(x^{k+1}, \lambda^{k+1}) - \mathcal{L}(x, \lambda^{k+1}) &= f(x^{k+1}) - f(x) - (\lambda^{k+1})^\top A(x^{k+1} - x) \\ &= f(x^{k+1}) - f(x^k) + f(x^k) - f(x) \\ &\quad - (\lambda^{k+1})^\top A(x^{k+1} - x).\end{aligned}$$

Доказательство

Распишем разность:

$$\begin{aligned}\mathcal{L}(x^{k+1}, \lambda^{k+1}) - \mathcal{L}(x, \lambda^{k+1}) &= f(x^{k+1}) - f(x) - (\lambda^{k+1})^\top A(x^{k+1} - x) \\ &= f(x^{k+1}) - f(x^k) + f(x^k) - f(x) \\ &\quad - (\lambda^{k+1})^\top A(x^{k+1} - x).\end{aligned}$$

Воспользуемся выпуклостью и гладкостью f :

$$f(x^{k+1}) - f(x^k) \leq \langle \nabla f(x^k), x^{k+1} - x^k \rangle + \frac{L_f}{2} \|x^{k+1} - x^k\|_2^2.$$

Доказательство

Распишем разность:

$$\begin{aligned}\mathcal{L}(x^{k+1}, \lambda^{k+1}) - \mathcal{L}(x, \lambda^{k+1}) &= f(x^{k+1}) - f(x) - (\lambda^{k+1})^\top A(x^{k+1} - x) \\ &= f(x^{k+1}) - f(x^k) + f(x^k) - f(x) \\ &\quad - (\lambda^{k+1})^\top A(x^{k+1} - x).\end{aligned}$$

Воспользуемся выпуклостью и гладкостью f :

$$f(x^{k+1}) - f(x^k) \leq \langle \nabla f(x^k), x^{k+1} - x^k \rangle + \frac{L_f}{2} \|x^{k+1} - x^k\|_2^2.$$

Воспользуемся выпуклостью f :

$$f(x^k) - f(x) \leq \langle \nabla f(x^k), x^k - x \rangle.$$

Доказательство

Объединяя полученные результаты, получаем:

$$\begin{aligned}\mathcal{L}(x^{k+1}, \lambda^{k+1}) - \mathcal{L}(x, \lambda^{k+1}) &\leq \left\langle \nabla f(x^k) - A^\top \lambda^k, x^{k+1} - x \right\rangle \\ &\quad + \frac{L_f}{2} \|x^{k+1} - x^k\|_2^2 \\ &\quad - (\lambda^{k+1} - \lambda^k)^\top A(x^{k+1} - x).\end{aligned}$$

Доказательство

Объединяя полученные результаты, получаем:

$$\begin{aligned}\mathcal{L}(x^{k+1}, \lambda^{k+1}) - \mathcal{L}(x, \lambda^{k+1}) &\leq \left\langle \nabla f(x^k) - A^\top \lambda^k, x^{k+1} - x \right\rangle \\ &\quad + \frac{L_f}{2} \|x^{k+1} - x^k\|_2^2 \\ &\quad - (\lambda^{k+1} - \lambda^k)^\top A(x^{k+1} - x).\end{aligned}$$

Подставим шаг:

$$\left\langle \nabla f(x^k) - A^\top \lambda^k, x^{k+1} - x \right\rangle = \frac{1}{\gamma} \langle x^k - x^{k+1}, x^{k+1} - x \rangle.$$

Доказательство

Объединяя полученные результаты, получаем:

$$\begin{aligned}\mathcal{L}(x^{k+1}, \lambda^{k+1}) - \mathcal{L}(x, \lambda^{k+1}) &\leq \left\langle \nabla f(x^k) - A^\top \lambda^k, x^{k+1} - x \right\rangle \\ &\quad + \frac{L_f}{2} \|x^{k+1} - x^k\|_2^2 \\ &\quad - (\lambda^{k+1} - \lambda^k)^\top A(x^{k+1} - x).\end{aligned}$$

Подставим шаг:

$$\left\langle \nabla f(x^k) - A^\top \lambda^k, x^{k+1} - x \right\rangle = \frac{1}{\gamma} \langle x^k - x^{k+1}, x^{k+1} - x \rangle.$$

В итоге имеем:

$$\begin{aligned}\mathcal{L}(x^{k+1}, \lambda^{k+1}) - \mathcal{L}(x, \lambda^{k+1}) &\leq \frac{1}{\gamma} \langle x^k - x^{k+1}, x^{k+1} - x \rangle + \frac{L_f}{2} \|x^{k+1} - x^k\|_2^2 \\ &\quad - (\lambda^{k+1} - \lambda^k)^\top A(x^{k+1} - x).\end{aligned}$$

Доказательство

Распишем разность:

$$\begin{aligned}\mathcal{L}(x^{k+1}, \lambda) - \mathcal{L}(x^{k+1}, \lambda^{k+1}) &= g(\lambda^{k+1}) - g(\lambda) - (x^{k+1})^\top A^\top (\lambda - \lambda^{k+1}) \\ &= g(\lambda^{k+1}) - g(\lambda^k) + g(\lambda^k) - g(\lambda) \\ &\quad - (x^{k+1})^\top A^\top (\lambda - \lambda^{k+1}).\end{aligned}$$

Доказательство

Распишем разность:

$$\begin{aligned}\mathcal{L}(x^{k+1}, \lambda) - \mathcal{L}(x^{k+1}, \lambda^{k+1}) &= g(\lambda^{k+1}) - g(\lambda) - (x^{k+1})^\top A^\top (\lambda - \lambda^{k+1}) \\ &= g(\lambda^{k+1}) - g(\lambda^k) + g(\lambda^k) - g(\lambda) \\ &\quad - (x^{k+1})^\top A^\top (\lambda - \lambda^{k+1}).\end{aligned}$$

Воспользуемся выпуклостью и гладкостью g :

$$g(\lambda^{k+1}) - g(\lambda^k) \leq \langle \nabla g(\lambda^k), \lambda^{k+1} - \lambda^k \rangle + \frac{L_g}{2} \|\lambda^{k+1} - \lambda^k\|_2^2.$$

Доказательство

Распишем разность:

$$\begin{aligned}\mathcal{L}(x^{k+1}, \lambda) - \mathcal{L}(x^{k+1}, \lambda^{k+1}) &= g(\lambda^{k+1}) - g(\lambda) - (x^{k+1})^\top A^\top (\lambda - \lambda^{k+1}) \\ &= g(\lambda^{k+1}) - g(\lambda^k) + g(\lambda^k) - g(\lambda) \\ &\quad - (x^{k+1})^\top A^\top (\lambda - \lambda^{k+1}).\end{aligned}$$

Воспользуемся выпуклостью и гладкостью g :

$$g(\lambda^{k+1}) - g(\lambda^k) \leq \langle \nabla g(\lambda^k), \lambda^{k+1} - \lambda^k \rangle + \frac{L_g}{2} \|\lambda^{k+1} - \lambda^k\|_2^2.$$

Воспользуемся выпуклостью g :

$$g(\lambda^k) - g(\lambda) \leq \langle \nabla g(\lambda^k), \lambda^k - \lambda \rangle.$$

Доказательство

Объединяя полученные результаты, получаем:

$$\begin{aligned}\mathcal{L}(x^{k+1}, \lambda) - \mathcal{L}(x^{k+1}, \lambda^{k+1}) &\leq \left\langle \nabla g(\lambda^k) + A(2x^{k+1} - x^k), \lambda^{k+1} - \lambda \right\rangle \\ &\quad + \frac{L_g}{2} \|\lambda^{k+1} - \lambda^k\|_2^2 \\ &\quad + (x^k - x^{k+1})^\top A^\top (\lambda^{k+1} - \lambda).\end{aligned}$$

Доказательство

Объединяя полученные результаты, получаем:

$$\begin{aligned}\mathcal{L}(x^{k+1}, \lambda) - \mathcal{L}(x^{k+1}, \lambda^{k+1}) &\leq \left\langle \nabla g(\lambda^k) + A(2x^{k+1} - x^k), \lambda^{k+1} - \lambda \right\rangle \\ &\quad + \frac{L_g}{2} \|\lambda^{k+1} - \lambda^k\|_2^2 \\ &\quad + (x^k - x^{k+1})^\top A^\top (\lambda^{k+1} - \lambda).\end{aligned}$$

Подставим шаг:

$$\left\langle \nabla g(\lambda^k) + A(2x^{k+1} - x^k), \lambda^{k+1} - \lambda \right\rangle = \frac{1}{\gamma} \langle \lambda^k - \lambda^{k+1}, \lambda^{k+1} - \lambda \rangle.$$

Доказательство

Объединяя полученные результаты, получаем:

$$\begin{aligned}\mathcal{L}(x^{k+1}, \lambda) - \mathcal{L}(x^{k+1}, \lambda^{k+1}) &\leq \left\langle \nabla g(\lambda^k) + A(2x^{k+1} - x^k), \lambda^{k+1} - \lambda \right\rangle \\ &\quad + \frac{L_g}{2} \|\lambda^{k+1} - \lambda^k\|_2^2 \\ &\quad + (x^k - x^{k+1})^\top A^\top (\lambda^{k+1} - \lambda).\end{aligned}$$

Подставим шаг:

$$\left\langle \nabla g(\lambda^k) + A(2x^{k+1} - x^k), \lambda^{k+1} - \lambda \right\rangle = \frac{1}{\gamma} \langle \lambda^k - \lambda^{k+1}, \lambda^{k+1} - \lambda \rangle.$$

В итоге имеем:

$$\begin{aligned}\mathcal{L}(x^{k+1}, \lambda) - \mathcal{L}(x^{k+1}, \lambda^{k+1}) &\leq \frac{1}{\gamma} \langle \lambda^k - \lambda^{k+1}, \lambda^{k+1} - \lambda \rangle + \frac{L_g}{2} \|\lambda^{k+1} - \lambda^k\|_2^2 \\ &\quad + (x^k - x^{k+1})^\top A^\top (\lambda^{k+1} - \lambda).\end{aligned}$$

Доказательство

Просуммируем два полученных неравенства:

$$\begin{aligned}\mathcal{L}(x^{k+1}, \lambda) - \mathcal{L}(x, \lambda^{k+1}) &\leq \begin{pmatrix} x^k - x^{k+1} \\ \lambda^k - \lambda^{k+1} \end{pmatrix}^\top \begin{pmatrix} \frac{1}{\gamma} I_d & A^\top \\ A & \frac{1}{\gamma} I_n \end{pmatrix} \begin{pmatrix} x^{k+1} - x \\ \lambda^{k+1} - \lambda \end{pmatrix} \\ &\quad + \frac{L_g}{2} \|\lambda^{k+1} - \lambda^k\|_2^2 + \frac{L_f}{2} \|x^{k+1} - x^k\|_2^2.\end{aligned}$$

и введем обозначение:

$$P = \begin{pmatrix} \frac{1}{\gamma} I_d & A^\top \\ A & \frac{1}{\gamma} I_n \end{pmatrix}.$$

Доказательство

Получаем:

$$\begin{aligned}\mathcal{L}(x^{k+1}, \lambda) - \mathcal{L}(x, \lambda^{k+1}) &\leq \langle z^k - z^{k+1}, z^{k+1} - z \rangle_P \\ &\quad + \frac{\max(L_g, L_f)}{2} \|z^{k+1} - z^k\|_2^2 \\ &= \frac{1}{2} \|z^k - z\|_P^2 - \frac{1}{2} \|z^{k+1} - z\|_P^2 \\ &\quad - \frac{1}{2} \|z^{k+1} - z^k\|_P^2 \\ &\quad + \frac{\max(L_g, L_f)}{2} \|z^{k+1} - z^k\|_2^2.\end{aligned}$$

Доказательство

Просуммируем по k от 0 до $K - 1$:

$$\begin{aligned} \sum_{k=0}^{K-1} \left(\mathcal{L}(x^{k+1}, \lambda) - \mathcal{L}(x, \lambda^{k+1}) \right) &\leq \frac{1}{2} \|z^0 - z\|_P^2 - \frac{1}{2} \|z^K - z\|_P^2 \\ &+ \sum_{k=0}^{K-1} \left(\frac{\max(L_g, L_f)}{2} \|z^{k+1} - z^k\|_2^2 - \frac{1}{2} \|z^{k+1} - z^k\|_P^2 \right). \end{aligned}$$

Доказательство

Просуммируем по k от 0 до $K - 1$:

$$\begin{aligned} \sum_{k=0}^{K-1} \left(\mathcal{L}(x^{k+1}, \lambda) - \mathcal{L}(x, \lambda^{k+1}) \right) &\leq \frac{1}{2} \|z^0 - z\|_P^2 - \frac{1}{2} \|z^K - z\|_P^2 \\ &+ \sum_{k=0}^{K-1} \left(\frac{\max(L_g, L_f)}{2} \|z^{k+1} - z^k\|_2^2 - \frac{1}{2} \|z^{k+1} - z^k\|_P^2 \right). \end{aligned}$$

Потребуем $P \succ \max(L_g, L_f)I_{d+n}$, чтобы избавиться от последней строки и оставить $\|z^0 - z\|^2$. Это достигается при $\gamma \leq \frac{1}{\max(L_g, L_f) + \|A\|_2}$.

Доказательство

Делим на K и получаем

$$\frac{1}{K} \sum_{k=0}^{K-1} \left(\mathcal{L}(x^{k+1}, \lambda) - \mathcal{L}(x, \lambda^{k+1}) \right) \leq \frac{1}{2K} \|z^0 - z\|_P^2.$$

Доказательство

Делим на K и получаем

$$\frac{1}{K} \sum_{k=0}^{K-1} \left(\mathcal{L}(x^{k+1}, \lambda) - \mathcal{L}(x, \lambda^{k+1}) \right) \leq \frac{1}{2K} \|z^0 - z\|_P^2.$$

Неравенство Йенсена для выпуклой и вогнутой функции даёт

$$\mathcal{L}\left(\frac{1}{K} \sum_{k=0}^{K-1} x^{k+1}, \lambda\right) - \mathcal{L}\left(x, \frac{1}{K} \sum_{k=0}^{K-1} \lambda^{k+1}\right) \leq \frac{1}{2K} \|z^0 - z\|_P^2.$$

Сходимость прямо–двойственного метода

Теорема

Пусть седловая задача с выпуклой L_f –гладкой функцией $f : \mathbb{R}^d \rightarrow \mathbb{R}$ и выпуклой L_g –гладкой функцией $g : \mathbb{R}^n \rightarrow \mathbb{R}$ решается с помощью прямо–двойственного метода. Тогда при $\gamma_k = \gamma \leq \frac{1}{\max(L_g, L_f) + \|A\|_2}$ для любых $u = (x, \lambda) \in \mathbb{R}^d \times \mathbb{R}^n$ справедлива следующая оценка сходимости:

$$\mathcal{L}\left(\frac{1}{K} \sum_{k=0}^{K-1} x^{k+1}, u_\lambda\right) - \mathcal{L}\left(u_x, \frac{1}{K} \sum_{k=0}^{K-1} \lambda^{k+1}\right) \leq \frac{\|z^0 - u\|_P^2}{2K}.$$