

Л5 Стохастический градиентный спуск

Стохастическая оптимизация возникает в тех случаях, когда точный градиент функции либо невозможно вычислить, либо его вычисление слишком дорого. В таких случаях мы используем приближённые градиенты, построенные на основе случайной информации о функции.

Придём к этой идее через пример из Параграфа Л1, а именно через оптимизацию в машинном обучении Л1.1.5. В этом примере мы приходили к задаче минимизации эмпирического риска, которую можно записать как

$$\min_{x \in \mathbb{R}^d} \left[f(x) := \frac{1}{n} \sum_{i=1}^n f_i(x) = \frac{1}{n} \sum_{i=1}^n l(g(x, \xi_i^a), \xi_i^b) \right],$$

где введены обозначения:

- $\xi_i = (\xi_i^a, \xi_i^b)$ — элементы выборки: ξ_i^a — объект (картинка, текст) и ξ_i^b — метка (ответ) на i -м объекте,
- g — модель машинного обучения (линейная модель, нейросеть), принимает на вход объект и настраиваемые веса x ,
- l — функция потерь (штрафует модель за несовпадения с реальной меткой ξ_b).

Такую постановку называют *оффлайн* (данные фиксированы, а не поступают в режиме реального времени).

В оффлайн постановке можно считать градиент целевой функции f , но в машинном обучении часто не используют полные честные градиенты. Основная причина — их дорого и долго считать, поэтому вместо полного градиента вызывают градиент по случайному элементу выборки: $\nabla f_i(x, \xi_i)$, где i генерируется независимо и равномерно из $\overline{1, n}$.

Теперь продемонстрируем чуть более общий подход. До этого мы рассматривали задачи, где все вычисления были детерминированными:

$$\min_{x \in \mathbb{R}^d} f(x).$$

А сейчас пусть целевая функция — это математическое ожидание от случайной величины ξ из распределения $\mathcal{D}$:

$$\min_{x \in \mathbb{R}^d} [f(x) := \mathbb{E}_{\xi \sim \mathcal{D}} [f(x, \xi)]] \quad (\text{Л5.1})$$

Цель: «подстроиться» под природу, чтобы потери модели в среднем по всему распределению были наименьшими, то есть модель наилучшим образом аппроксимировала зависимость ξ^b от ξ^a .

Проблема: Функция f , а также градиенты и более старшие производные не считаются, так как не знаем $\mathcal{D}$, да даже если и знаем, интеграл часто не взять так просто.

Решение проблемы: Возникает потребность в методе, который может оперировать с $\nabla f(x, \xi)$ (градиентом по конкретному объекту из распределения данных). То есть хотим работать в *онлайн* режиме: поступают данные, мы их обрабатываем (можем считать градиент).

Замечание Л5.1. Всякого рода рандомизированные подходы, основанные на сэмплинге, называются *Монте-Карло подходами*.

Оффлайн постановка — это Монте-Карло аппроксимация исходного интеграла (математического ожидания). С ростом количества элементов в выборке, аппроксимация через конечную сумму будет стремиться к реальному интегралу (при определенных предположениях).

Л5.1 Стохастический градиентный спуск

Идея — модифицировать градиентный спуск, заменив полный градиент на стохастический.

Алгоритм Л5.1 Стохастический градиентный спуск

Вход: стартовая точка $x^0 \in \mathbb{R}^d$, размеры шагов $\{\gamma_k\}_{k=0} > 0$, количество итераций K

- 1: **for** $k = 0, 1, \dots, K - 1$ **do**
- 2: Сгенерировать независимо $\xi^k \sim \mathcal{D}$
- 3: $x^{k+1} = x^k - \gamma_k \nabla f(x^k, \xi^k)$
- 4: **end for**

Выход: x^K

Для доказательства сходимости напомним определение условного математического ожидания и закон полного математического ожидания.

Определение Л5.1. *Условное математическое ожидание:*

$$\mathbb{E} \left[\cdot \mid x^k \right] = \mathbb{E} \left[\cdot \mid \mathcal{F}_k \right],$$

где $\mathcal{F}_k$ — σ -алгебра, порождённая $x^0, \xi^0, \dots, \xi^{k-1}$.

Суть — фиксируем всю случайность, которая произошла до k итерации и ожидаем только по случайности, которая осталась размороженной. Такое математическое ожидание дает на выходе что-то, зависящее от случайных величин $x^0, \xi^0, \dots, \xi^{k-1}$.

Теорема Л5.1 (Закон полного математического ожидания (Утверждение G из части 4 Параграфа 7 из [35])).

$$\mathbb{E} [\mathbb{E} [X \mid Y]] = \mathbb{E} [X].$$

Перейдём к описанию предположений, которые будут использованы при доказательстве сходимости. На функцию f оставляем предположения об L -гладкости и μ -сильной выпуклости. Ранее градиент функции был детерминированным. В контексте стохастического градиентного спуска, когда стохастический градиент — это случайная величина, нам потребуются два предположения на стохастический градиент.

Предположение Л5.1 (Несмещённость стохастического градиента). Положим $\{\mathcal{F}\}_{k \geq 0}$ — семейство вложенных σ -алгебр. Случайная величина x^0 — $\mathcal{F}_0$ -измерима, и для любых $x^k \in \mathbb{R}^d$ и $k \in \mathbb{N}$ случайная величина $\nabla f(x^k, \xi^k)$ является $\mathcal{F}_k$ -измеримой и выполняется

$$\mathbb{E} \left[\nabla f(x^k, \xi^k) \mid x^{k-1} \right] = \nabla f(x^k).$$

Предположение Л5.2 (Ограниченность дисперсии стохастического градиента). Существует $\sigma^2 \in \mathbb{R}_+$, такое, что для любых $x^k \in \mathbb{R}^d$ и $k \in \mathbb{N}$:

$$\mathbb{E} \left[\left\| \nabla f(x^k, \xi^k) - \nabla f(x^k) \right\|_2^2 \mid x^{k-1} \right] \leq \sigma^2.$$

Теперь можем доказывать сходимость. Начнем как обычно с сильно выпуклого случая.

Теорема Л5.2. Пусть задача безусловной стохастической оптимизации (Л5.1) с L -гладкой, μ -сильно выпуклой целевой функцией f решается с помощью стохастического градиентного спуска (Алгоритм Л5.1) с $\gamma_k = \gamma \leq \frac{1}{L}$ в предположениях несмещённости (Предположение Л5.1) и ограниченности дисперсии стохастического градиента (Предположение Л5.2). Тогда справедлива следующая оценка сходимости

$$\mathbb{E} \left[\|x^K - x^*\|_2^2 \right] \leq (1 - \gamma\mu)^K \mathbb{E} \left[\|x^0 - x^*\|_2^2 \right] + \frac{\gamma\sigma^2}{\mu}. \quad (\text{Л5.2})$$

Доказательство. Начиная, как и раньше:

$$\|x^{k+1} - x^*\|_2^2 = \|x^k - x^*\|_2^2 - 2\gamma \langle \nabla f(x^k, \xi^k), x^k - x^* \rangle + \gamma^2 \|\nabla f(x^k, \xi^k)\|_2^2.$$

Вспомним, что мы знаем предположения про функцию f , а в выражении выше её нет (есть только её стохастический градиент). Значит, надо как-то перейти к этой функции в неравенствах. Для этого берем условное математическое ожидание по случайности только на итерации k (важно, что x^k — это неслучайная величина относительно условного математического ожидания по разбиению $\mathcal{F}_k$, случайными здесь будут только величины x^{k+1} и градиент $\nabla f(x^k, \xi^k)$):

$$\begin{aligned} \mathbb{E} \left[\|x^{k+1} - x^*\|_2^2 \mid x^k \right] &= \|x^k - x^*\|_2^2 - 2\gamma \mathbb{E} \left[\langle \nabla f(x^k, \xi^k), x^k - x^* \rangle \mid x^k \right] \\ &\quad + \gamma^2 \mathbb{E} \left[\|\nabla f(x^k, \xi^k)\|_2^2 \mid x^k \right]. \end{aligned} \quad (\text{Л5.3})$$

Рассмотрим $\mathbb{E} \left[\langle \nabla f(x^k, \xi^k), x^k - x^* \rangle \mid x^k \right]$ и воспользуемся линейностью условного математического ожидания, а также Предположением Л5.1:

$$\begin{aligned} \mathbb{E} \left[\langle \nabla f(x^k, \xi^k), x^k - x^* \rangle \mid x^k \right] &= \left\langle \mathbb{E} \left[\nabla f(x^k, \xi^k) \mid x^k \right], x^k - x^* \right\rangle \\ &= \langle \nabla f(x^k), x^k - x^* \rangle. \end{aligned}$$

Рассмотрим $\mathbb{E} \left[\|\nabla f(x^k, \xi^k)\|_2^2 \mid x^k \right]$, добавим и вычтем градиент, после чего раскроем квадрат нормы:

$$\begin{aligned} \mathbb{E} \left[\|\nabla f(x^k, \xi^k)\|_2^2 \mid x^k \right] &= \mathbb{E} \left[\|\nabla f(x^k, \xi^k) - \nabla f(x^k) + \nabla f(x^k)\|_2^2 \mid x^k \right] \\ &= \mathbb{E} \left[\|\nabla f(x^k, \xi^k) - \nabla f(x^k)\|_2^2 \mid x^k \right] + \mathbb{E} \left[\|\nabla f(x^k)\|_2^2 \mid x^k \right] \\ &\quad + 2\mathbb{E} \left[\langle \nabla f(x^k, \xi^k) - \nabla f(x^k), \nabla f(x^k) \rangle \mid x^k \right] \end{aligned} \quad (\text{Л5.4})$$

Теперь мы можем воспользоваться Предположением Л5.1 и Предположением Л5.2:

$$\begin{aligned} \mathbb{E} \left[\|\nabla f(x^k, \xi^k)\|_2^2 \mid x^k \right] &= \mathbb{E} \left[\|\nabla f(x^k, \xi^k) - \nabla f(x^k)\|_2^2 \mid x^k \right] + \|\nabla f(x^k)\|_2^2 \\ &\quad + 2\left\langle \mathbb{E} \left[\nabla f(x^k, \xi^k) \mid x^k \right] - \nabla f(x^k), \nabla f(x^k) \right\rangle \\ &\leq \sigma^2 + \|\nabla f(x^k)\|_2^2. \end{aligned}$$

Объединим все промежуточные шаги, подставим в (Л5.3) и получим:

$$\mathbb{E} \left[\|x^{k+1} - x^*\|_2^2 \mid x^k \right] \leq \|x^k - x^*\|_2^2 - 2\gamma \langle \nabla f(x^k), x^k - x^* \rangle + \gamma^2 \|\nabla f(x^k)\|_2^2 + \gamma^2 \sigma^2.$$

Выглядит похоже на то, что было в градиентном спуске, только появляется $\gamma^2\sigma^2$. Поэтому далее воспользуемся L -гладкостью (Теорема Л2.5) и μ -сильной выпуклостью (Определение Л2.4):

$$\begin{aligned}\mathbb{E} \left[\|x^{k+1} - x^*\|_2^2 \middle| x^k \right] &\leq \|x^k - x^*\|_2^2 - 2\gamma \left(f(x^k) - f^* + \frac{\mu}{2} \|x^k - x^*\|_2^2 \right) \\ &\quad + 2\gamma^2 L (f(x^k) - f^*) + \gamma^2 \sigma^2 \\ &= (1 - \gamma\mu) \|x^k - x^*\|_2^2 - 2\gamma(1 - \gamma L) (f(x^k) - f^*) + \gamma^2 \sigma^2.\end{aligned}$$

При выборе $\gamma \leq \frac{1}{L}$ слагаемое $-2\gamma(1 - \gamma L) (f(x^k) - f^*)$ отрицательно и от него можно избавиться:

$$\mathbb{E} \left[\|x^{k+1} - x^*\|_2^2 \middle| x^k \right] \leq (1 - \gamma\mu) \|x^k - x^*\|_2^2 + \gamma^2 \sigma^2.$$

Сейчас запустить рекурсию мешает то, что слева и справа стоят случайные величины, причем оценок на $\|x^k - x^*\|_2$ у нас нет. Чтобы перейти к неслучайным величинам, в неравенстве выше берем полное математическое ожидание и применяем результат Теоремы Л5.1:

$$\mathbb{E} \left[\|x^{k+1} - x^*\|_2^2 \right] \leq (1 - \gamma\mu) \mathbb{E} \left[\|x^k - x^*\|_2^2 \right] + \gamma^2 \sigma^2.$$

Разворачиваем рекурсию:

$$\begin{aligned}\mathbb{E} \left[\|x^K - x^*\|_2^2 \right] &\leq (1 - \gamma\mu) \mathbb{E} \left[\|x^{K-1} - x^*\|_2^2 \right] + \gamma^2 \sigma^2 \\ &\leq (1 - \gamma\mu)^2 \mathbb{E} \left[\|x^{K-2} - x^*\|_2^2 \right] + (1 - \gamma\mu) \gamma^2 \sigma^2 + \gamma^2 \sigma^2 \\ &\leq (1 - \gamma\mu)^K \mathbb{E} \left[\|x^0 - x^*\|_2^2 \right] + \gamma^2 \sigma^2 \sum_{i=0}^{K-1} (1 - \gamma\mu)^i.\end{aligned}$$

Второе слагаемое — сумма первых k членов геометрической прогрессии, оценим её:

$$\sum_{i=0}^{K-1} (1 - \gamma\mu)^i \leq \sum_{i=0}^{+\infty} (1 - \gamma\mu)^i = \frac{1}{\gamma\mu}.$$

После подстановки в выражение выше:

$$\mathbb{E} \left[\|x^K - x^*\|_2^2 \right] \leq (1 - \gamma\mu)^K \mathbb{E} \left[\|x^0 - x^*\|_2^2 \right] + \frac{\gamma\sigma^2}{\mu}.$$

■

Этот результат похож на линейную сходимость к решению для градиентного спуска. Однако, добавляется второе слагаемое — это некоторая неточность, зависящая от γ , σ и μ . Её метод преодолеть не может и начинает осциллировать, больше не приближаясь к решению. В таком случае говорят, что имеет место сходимость к окрестности решения x^* .

Теперь рассмотрим выпуклый случай.

Теорема Л5.3. Пусть задача безусловной стохастической оптимизации (Л5.1) с L -гладкой, выпуклой целевой функцией f решается с помощью стохастического градиентного спуска (Алгоритм Л5.1) с $\gamma_k = \gamma \leq \frac{1}{2L}$ в предположениях несмещённости (Предположение Л5.1) и ограниченности дисперсии стохастического градиента (Предположение Л5.2). Тогда справедлива следующая оценка сходи-




Рис. Л15.1: Характерная «дрожь» сходимости стохастического градиентного спуска.

МОСТИ

$$\mathbb{E} \left[f \left(\frac{1}{K} \sum_{k=0}^{K-1} x^k \right) - f^* \right] \leq \frac{\|x^0 - x^*\|_2^2}{\gamma K} + \gamma \sigma^2.$$

Доказательство. Как и раньше, разложим квадрат нормы:

$$\|x^{k+1} - x^*\|_2^2 = \|x^k - x^*\|_2^2 - 2\gamma \langle \nabla f(x^k, \xi^k), x^k - x^* \rangle + \gamma^2 \|\nabla f(x^k, \xi^k)\|_2^2.$$

Берём условное ожидание по $\mathcal{F}_k$ и пользуемся несмещённостью стохастического градиента (Предположение Л15.1):

$$\mathbb{E} \left[\|x^{k+1} - x^*\|_2^2 \mid x^k \right] = \|x^k - x^*\|_2^2 - 2\gamma \langle \nabla f(x^k), x^k - x^* \rangle + \gamma^2 \mathbb{E} \left[\|\nabla f(x^k, \xi^k)\|_2^2 \mid x^k \right].$$

Аналогично сильно выпуклому случаю, воспользуемся оценкой на второй момент градиента (Л15.4):

$$\mathbb{E} \left[\|\nabla f(x^k, \xi^k)\|_2^2 \mid x^k \right] \leq \sigma^2 + \|\nabla f(x^k)\|_2^2.$$

Подставим в неравенство:

$$\mathbb{E} \left[\|x^{k+1} - x^*\|_2^2 \mid x^k \right] \leq \|x^k - x^*\|_2^2 - 2\gamma \langle \nabla f(x^k), x^k - x^* \rangle + \gamma^2 \|\nabla f(x^k)\|_2^2 + \gamma^2 \sigma^2.$$

Вспомним определение выпуклой функции (Определение Л2.3):

$$\langle \nabla f(x^k), x^k - x^* \rangle \geq f(x^k) - f^*.$$

и неравенство для L -гладкой функции (неравенство (Л2.4) из Теоремы Л2.5):

$$\|\nabla f(x^k)\|_2^2 \leq 2L(f(x^k) - f^*).$$

Продолжим основное неравенство:

$$\begin{aligned}\mathbb{E} \left[\|x^{k+1} - x^*\|_2^2 \mid x^k \right] &\leq \|x^k - x^*\|_2^2 - 2\gamma(f(x^k) - f^*) + 2\gamma^2 L(f(x^k) - f^*) + \gamma^2 \sigma^2 \\ &= \|x^k - x^*\|_2^2 - 2\gamma(1 - \gamma L)(f(x^k) - f^*) + \gamma^2 \sigma^2.\end{aligned}$$

Возьмём $\gamma \leq \frac{1}{2L}$, чтобы $1 - \gamma L \geq \frac{1}{2}$, тогда:

$$\mathbb{E} \left[\|x^{k+1} - x^*\|_2^2 \mid x^k \right] \leq \|x^k - x^*\|_2^2 - \gamma(f(x^k) - f^*) + \gamma^2 \sigma^2.$$

Берем полное математическое ожидание и суммируем по всем k от 0 до K :

$$\mathbb{E} \left[\|x^K - x^*\|_2^2 \right] \leq \|x^0 - x^*\|_2^2 - \gamma \sum_{k=0}^{K-1} \mathbb{E} [f(x^k) - f^*] + \gamma^2 \sigma^2 K.$$

Так как $\mathbb{E} \left[\|x^K - x^*\|_2^2 \right]$ — неотрицательное, то:

$$\sum_{k=0}^{K-1} \mathbb{E} [f(x^k) - f^*] \leq \frac{\|x^0 - x^*\|_2^2}{\gamma} + \gamma \sigma^2 K.$$

Воспользуемся линейностью математического ожидания и неравенством Йенсена (0.1):

$$\begin{aligned}\mathbb{E} \left[f \left(\frac{1}{K} \sum_{k=0}^{K-1} x^k \right) - f^* \right] &\leq \mathbb{E} \left[\frac{1}{K} \sum_{k=0}^{K-1} f(x^k) - f^* \right] = \frac{1}{K} \sum_{k=0}^{K-1} \mathbb{E} [f(x^k) - f^*] \\ &\leq \frac{\|x^0 - x^*\|_2^2}{\gamma K} + \gamma \sigma^2.\end{aligned}$$

■

Результат теоремы похож на классическую оценку для градиентного спуска из Теоремы Л3.3 с точностью до добавки в виде дисперсии решения $\gamma \sigma^2$.

Утверждение Л5.1. Пусть задача удовлетворяет условиям Теоремы Л5.3 и выбрано значение шага $\gamma_k = \frac{1}{2L}$. Тогда справедлива следующая оценка:

$$\mathbb{E} \left[f \left(\frac{1}{K} \sum_{k=0}^{K-1} x^k \right) - f^* \right] \leq \frac{2L \|x^0 - x^*\|_2^2}{K} + \frac{\sigma^2}{2L}.$$

Чтобы добиться точности ε по функции $\left(\mathbb{E} \left[f \left(\frac{1}{K} \sum_{k=0}^{K-1} x^k \right) - f^* \right] \leq \varepsilon \right)$, необходимо

$$K = \mathcal{O} \left(\frac{L \|x^0 - x^*\|_2^2}{\varepsilon - \frac{\sigma^2}{2L}} \right) \text{ итераций.}$$

Доказательство. Подставим $\gamma = \frac{1}{2L}$ в оценку из Теоремы Л5.3 и потребуем, чтобы правая часть была не больше ε :

$$\mathbb{E} [f(\bar{x}^K) - f^*] \leq \frac{\|x^0 - x^*\|_2^2}{\gamma K} + \gamma \sigma^2 = \frac{2L \|x^0 - x^*\|_2^2}{K} + \frac{\sigma^2}{2L} \leq \varepsilon.$$

Выразим отсюда K :

$$K \geq \frac{2L\|x^0 - x^*\|_2^2}{\varepsilon - \frac{\sigma^2}{2L}}.$$

■

Л5.2 Модификации стохастического градиентного спуска

Стохастический градиентный спуск с постоянным шагом обладает существенным недостатком — сходимостью к окрестности решения. Как можно попробовать решить проблемы неточной сходимости? Рассмотрим простые техники для уменьшения дисперсии. Например, в работе [2] проведен анализ для уменьшающегося шага. Получим следствия из Теоремы 1 этой статьи.

Теорема Л5.4. Пусть задача безусловной стохастической оптимизации (Л5.1) с L -гладкой, μ -сильно выпуклой целевой функцией f решается с помощью стохастического градиентного спуска (Алгоритм Л5.1) с $\gamma_k = \frac{2}{\mu(k+1)}$ в предположениях несмещённости (Предположение Л5.1) и ограниченности дисперсии стохастического градиента (Предположение Л5.2). Тогда справедлива следующая оценка сходимости

$$\mathbb{E} \left[\|x^K - x^*\|_2^2 \right] \leq \frac{\exp(8L^2/\mu^2)}{K^2} \left(\mathbb{E} \left[\|x^0 - x^*\|_2^2 \right] + \frac{\sigma^2}{L^2} \right) + \frac{8\sigma^2 \log K}{\mu^2 K}.$$

При такой стратегии подбора шага дисперсия решения убывает сублинейно, но мы теряем в скорости сходимости (была линейная, стала сублинейная). Так происходит, потому что размер шага слишком быстро уменьшается ($\sim 1/k$). Можно получить оценку и для менее агрессивно убывающего γ_k .

Теорема Л5.5. Пусть задача безусловной стохастической оптимизации (Л5.1) с L -гладкой, μ -сильно выпуклой целевой функцией f решается с помощью стохастического градиентного спуска (Алгоритм Л5.1) с $\gamma_k = \frac{2}{\mu\sqrt{k+1}}$ в предположениях несмещённости (Предположение Л5.1) и ограниченности дисперсии стохастического градиента (Предположение Л5.2). Тогда справедлива следующая оценка сходимости

$$\mathbb{E} \left[\|x^K - x^*\|_2^2 \right] \leq 2K^{16L^2/\mu^2} \exp \left(-\frac{\sqrt{K}}{2} \right) \left(\mathbb{E} \left[\|x^0 - x^*\|_2^2 \right] + \frac{\sigma^2}{L^2} \right) + \frac{8\sigma^2}{\mu^2 \sqrt{K}}.$$

Сравнивая оценки для шагов $\gamma_k \sim 1/\sqrt{k}$ с $\gamma_k \sim 1/k$, наблюдаем, что дисперсия решения стала убывать медленнее, но сходимость первого слагаемого стала быстрее, хотя все еще остается сублинейной. Лучшие оценки сходимости были получены в работе [25].

Теорема Л5.6. Пусть задача безусловной стохастической оптимизации (Л5.1) с L -гладкой, μ -сильно выпуклой целевой функцией f решается с помощью стохастического градиентного спуска (Алгоритм Л5.1) в предположениях несмещённости (Предположение Л5.1) и ограниченности дисперсии стохастического гра-

диента (Предположение Л5.2). Тогда при выборе

$$\gamma_k = \begin{cases} \frac{1}{2L}, & k < \lceil \frac{K}{2} \rceil, \\ \frac{2}{\mu \left(\frac{4L}{\mu} + k - \lceil \frac{K}{2} \rceil \right)}, & k \geq \lceil \frac{K}{2} \rceil, \end{cases}$$

$$w_k = \begin{cases} 0, & k < \lceil \frac{K}{2} \rceil, \\ \left(\frac{4L}{\mu} + k - \lceil \frac{K}{2} \rceil \right)^2, & k \geq \lceil \frac{K}{2} \rceil, \end{cases}$$

справедлива следующая оценка сходимости

$$\mathbb{E} \left[f(\bar{x}^K) - f^* \right] + \mu \mathbb{E} \left[\|x^{K+1} - x^*\|_2^2 \right] \leq \min \left\{ 64LR^2 \exp \left(-\frac{\mu K}{4L} \right) + \frac{36\sigma^2}{\mu K}, \frac{2LR^2}{K} + \frac{2\sigma R}{\sqrt{K}} \right\},$$

где $R = \|x^0 - x^*\|_2$, $W_K = \sum_{i=1}^K w_i$, $\bar{x}^K = \frac{1}{W_K} \sum_{i=1}^K w_i x^i$.

Эта оценка сочетает в себе линейную сходимость первого слагаемого и сублинейный спад слагаемого с шумом. Стратегию выбора шагов спуска и весов для усреднения точек можно описать следующим образом: сначала делаем шаги с константным значением $\gamma = \frac{1}{2L}$ и не учитываем эти $\lceil \frac{K}{2} \rceil$ точек при усреднении, а затем берем уменьшающийся шаг, получаем сходимость к более точной окрестности, усредняем эти точки с ненулевыми возрастающими весами.

Другим подходом может быть уменьшение σ с помощью техники батчирования. Идея заключается в замене стохастической оценки градиента по одному сэмплу на среднее арифметическое по подвыборке:

$$\nabla f(x^k, \xi^k) \rightarrow \frac{1}{b} \sum_{j \in S^k} \nabla f(x, \xi_j),$$

где S^k — набор индексов из $\overline{1, n}$, $|S^k| = b$, и все индексы генерируются независимо друг от друга (возможны повторы).

Утверждение Л5.2. Пусть задача удовлетворяет условиям Теоремы Л5.2 и применена техника батчирования по b независимым сэмплам. Тогда справедлива следующая оценка сходимости:

$$\mathbb{E} \left[\|x^K - x^*\|_2^2 \right] \leq (1 - \gamma\mu)^K \mathbb{E} \left[\|x^0 - x^*\|_2^2 \right] + \frac{\gamma\sigma^2}{\mu b}.$$

Доказательство. Посмотрим, что становится со свойствами несмещённости и конечности дисперсии при замене стохастического градиента по 1 сэмплу на среднее значение по батчу размера b .

Несмещённость остается, так как у каждого сэмпла j есть несмещённость стохастического градиента и выполняется линейность математического ожидания:

$$\mathbb{E} \left[\frac{1}{b} \sum_{j \in S^k} \nabla f(x, \xi_j) \middle| x^k \right] = \nabla f(x).$$

А с дисперсией интереснее:

$$\begin{aligned} \mathbb{E} \left[\left\| \frac{1}{b} \sum_{j \in S^k} (\nabla f(x, \xi_j) - \nabla f(x)) \right\|_2^2 \middle| x^k \right] &\leq \frac{1}{b^2} \mathbb{E} \left[\sum_{j \in S^k} \left\| \nabla f(x, \xi_j) - \nabla f(x) \right\|_2^2 \middle| x^k \right] \\ &\leq \frac{\sigma^2}{b}. \end{aligned}$$

Остается лишь подставить оценки в (Л5.2) и получить требуемое. ■

Получается, дисперсию можно уменьшить в b раз, но тогда и вычисление стохастического градиента дорожает в b раз.

Если теперь объединить батчирование и стратегию подбора шага из Теоремы Л5.6, то получается добиться следующей оценки сходимости:

$$\mathbb{E} \left[\|x^K - x^*\|_2^2 \right] = \mathcal{O} \left(\frac{L}{\mu} \exp \left(-\frac{\mu}{4L} K \right) \|x^0 - x^*\|_2^2 + \frac{\sigma^2}{\mu^2 b K} \right).$$

Получается линейная сходимость по «детерминистической» части и сублинейная по «стохастической».

Оказывается, этот результат ускоряется. По аналогии с тем, как инерция в алгоритме Нестерова дает ускорение, можно ускорить и стохастический градиентный спуск. Если объединить батчирование и результат работы [1], то получается оценка:

$$\mathbb{E} \left[f(x^{K+1}) - f^* \right] = \mathcal{O} \left(\exp \left(-\frac{1}{2} \sqrt{\frac{\mu}{L}} K \right) (f(x^0) - f^*) + \frac{\sigma^2}{\mu b K} \right).$$

Л5.3 Нижние оценки

Ранее мы уже строили нижние оценки для задач оптимизации. При построении нижних оценок для задач стохастической оптимизации применим знания из математической статистики. Следующий результат был получен в работе [3].

Теорема Л5.7. Пусть задача безусловной стохастической оптимизации (Л5.1) с L -гладкой, μ -сильно выпуклой целевой функцией f решается методом с доступом к стохастическому оракулу первого порядка, для которого выполняются предположения несмещённости (Предположение Л5.1) и ограниченности дисперсии стохастического градиента (Предположение Л5.2). Тогда выполняется неравенство

$$\mathbb{E} \left[\|x^K - x^*\|_2^2 \right] = \Omega \left(\frac{\sigma^2}{\mu^2 K} \right).$$

Доказательство. Нам придется сконструировать не только «плохую» функцию, но и описать стохастический оракул. С одной стороны, задача стала сложнее: стало больше свободы. С другой же, можно не выдумывать сложную функцию, а всю «плохость» задачи сосредоточить в том, насколько зашумленные ответы будет выдавать оракул. Так и поступим — возьмём примитивную целевую функцию $f: \mathbb{R} \rightarrow \mathbb{R}$:

$$f(x) = \frac{\mu}{2} \|x - x^*\|_2^2.$$

Она μ -сильно выпуклая и μ -гладкая. Считаем, что x^* нам не известно, а имеется доступ к зашумленному оракулу первого порядка. На запрос в точке x оракул будет возвращать стохастический градиент

$$\nabla f(x, \xi) = \mu(x - x^* + \xi), \quad \xi \sim \mathcal{N} \left(0, \frac{\sigma^2}{\mu^2} \right).$$

Проверим, что выполняются предположения о стохастическом градиенте. Несмещённость:

$$\mathbb{E} [\nabla f(x, \xi)] = \mathbb{E} [\mu(x - x^* + \xi)] = \nabla f(x).$$

Ограниченность дисперсия:

$$\mathbb{E} [\|\nabla f(x, \xi) - \nabla f(x)\|_2^2] = \mathbb{E} [\|\mu(x - x^* + \xi) - \mu(x - x^*)\|_2^2] = \mathbb{E} [\mu^2 \|\xi\|_2^2] = \sigma^2.$$

Таким образом, все требования на функцию и стохастический градиент выполняются. Пусть мы обратились к оракулу в K точках $\{x^k\}_{k=0}^{K-1}$ и получили в ответ значения $y^k = \mu(x^k + \xi^k - x^*)$, где $\xi^k \sim \mathcal{N}(0, \sigma^2/\mu^2)$ независимы. Хотим получить наилучшую оценку на x^* , используя имеющиеся данные. Введём z^k :

$$z^k = x^k - y^k/\mu = x^* - \xi^k.$$

Тогда задачу можно переформулировать следующим образом: по набору значений $z^k \sim \mathcal{N}(x^*, \sigma^2/\mu^2)$ необходимо восстановить константу x^* . Это можно сделать с помощью оценки максимального правдоподобия:

$$\hat{x} = \frac{1}{K} \sum_{k=0}^{K-1} z^k \sim \mathcal{N}\left(x^*, \frac{\sigma^2}{\mu^2 K}\right).$$

Из математической статистики известно, что для квадратичной функции потерь оценка максимального правдоподобия является оптимальной в смысле минимизации максимального эмпирического риска, то есть, получить предсказание лучше оценки максимального правдоподобия невозможно. Из того, какое распределение на $\hat{x}$, мы сразу видим, что оценка является несмещенной, а ее дисперсия

$$\mathbb{E} [(\hat{x} - x^*)^2] = \frac{\sigma^2}{\mu^2 K}.$$

Остается заключить, что поскольку такое значение дисперсии достигается для оптимальной оценки, то все остальные будут не лучше, а значит, они лежат в $\Omega\left(\frac{\sigma^2}{\mu^2 K}\right)$. ■

Смысл этой нижней оценки в том, что дисперсия решения убывает не быстрее $1/K$. Следующий логичный вопрос: являются ли какие-то из ранее полученных оценок оптимальными? Обратимся к результатам Теоремы Л5.6. Из нее можно получить, что $\mathbb{E} [\|x^K - x^*\|_2^2] = \mathcal{O}\left(\frac{\sigma^2}{\mu^2 K}\right)$, то есть, стохастический градиентный спуск с описанным подбором шага является оптимальным в классе методов с доступом к зашумленному оракулу первого порядка.