

Стохастический градиентный спуск

Методы оптимизации

Александр Богданов

Московский физико-технический институт

25 марта 2026



Оффлайн постановка

Задачу обучения в машинном обучении можно записать в виде минимизации эмпирического риска:

$$\min_{x \in \mathbb{R}^d} \left[f(x) := \frac{1}{n} \sum_{i=1}^n f_i(x) = \frac{1}{n} \sum_{i=1}^n \ell(g(x, \xi_i^a), \xi_i^b) \right],$$

где введены обозначения:

- $\xi_i = (\xi_i^a, \xi_i^b)$ — элементы выборки: ξ_i^a — объект (картинка, текст) и ξ_i^b — метка (ответ) на i -м объекте,
- g — модель машинного обучения (линейная модель, нейросеть), принимает на вход объект и настраиваемые веса x ,
- ℓ — функция потерь (штрафует модель за несовпадения с реальной меткой ξ^b).

Оффлайн постановка

Задачу обучения в машинном обучении можно записать в виде минимизации эмпирического риска:

$$\min_{x \in \mathbb{R}^d} \left[f(x) := \frac{1}{n} \sum_{i=1}^n f_i(x) = \frac{1}{n} \sum_{i=1}^n \ell(g(x, \xi_i^a), \xi_i^b) \right],$$

где введены обозначения:

- $\xi_i = (\xi_i^a, \xi_i^b)$ — элементы выборки: ξ_i^a — объект (картинка, текст) и ξ_i^b — метка (ответ) на i -м объекте,
- g — модель машинного обучения (линейная модель, нейросеть), принимает на вход объект и настраиваемые веса x ,
- ℓ — функция потерь (штрафует модель за несовпадения с реальной меткой ξ^b).

Такую постановку называют **оффлайн** (данные фиксированы, а не поступают в режиме реального времени).

Онлайн постановка

Теперь продемонстрируем чуть более общий подход. До этого мы рассматривали задачу:

$$\min_{x \in \mathbb{R}^d} f(x).$$

Теперь сформулируем задачу следующим образом:

$$\min_{x \in \mathbb{R}^d} [f(x) := \mathbb{E}_{\xi \sim \mathcal{D}} f(x, \xi)]$$

Онлайн постановка

- Мы хотим «подстроиться» под природу, чтобы потери модели по всему распределению были наименьшими, то есть модель наилучшим образом аппроксимировала зависимость ξ^b от ξ^a .

Онлайн постановка

- Мы хотим «подстроиться» под природу, чтобы потери модели по всему распределению были наименьшими, то есть модель наилучшим образом аппроксимировала зависимость ξ^b от ξ^a .
- **Вопрос:** в чем проблема?

Онлайн постановка

- Мы хотим «подстроиться» под природу, чтобы потери модели по всему распределению были наименьшими, то есть модель наилучшим образом аппроксимировала зависимость ξ^b от ξ^a .
- **Вопрос:** в чем проблема? Функция f , а также градиенты и более старшие производные не считаются, так как не знаем $\mathcal{D}$, да даже если и знаем, интеграл часто не взять так просто.

Онлайн постановка

- Мы хотим «подстроиться» под природу, чтобы потери модели по всему распределению были наименьшими, то есть модель наилучшим образом аппроксимировала зависимость ξ^b от ξ^a .
- **Вопрос:** в чем проблема? Функция f , а также градиенты и более старшие производные не считаются, так как не знаем $\mathcal{D}$, да даже если и знаем, интеграл часто не взять так просто.
- Возникает потребность в методе, который может оперировать с $\nabla f(x, \xi)$ (градиентом по конкретному объекту из распределения данных). То есть хотим работать в **онлайн** режиме: поступают данные, мы их обрабатываем (можем считать градиент).

Онлайн постановка

- Мы хотим «подстроиться» под природу, чтобы потери модели по всему распределению были наименьшими, то есть модель наилучшим образом аппроксимировала зависимость ξ^b от ξ^a .
- **Вопрос:** в чем проблема? Функция f , а также градиенты и более старшие производные не считаются, так как не знаем $\mathcal{D}$, да даже если и знаем, интеграл часто не взять так просто.
- Возникает потребность в методе, который может оперировать с $\nabla f(x, \xi)$ (градиентом по конкретному объекту из распределения данных). То есть хотим работать в **онлайн** режиме: поступают данные, мы их обрабатываем (можем считать градиент).
- Оффлайн постановка — это Монте–Карло аппроксимация исходного интеграла (математического ожидания).

Стохастический градиентный спуск

Идея — модифицировать градиентный спуск, заменив полный градиент на стохастический.

Алгоритм Стохастический градиентный спуск

Вход: стартовая точка $x^0 \in \mathbb{R}^d$, размеры шагов $\{\gamma_k\}_{k=0} > 0$, количество итераций K

- 1: **for** $k = 0, 1, \dots, K - 1$ **do**
- 2: Сгенерировать независимо $\xi^k \sim \mathcal{D}$
- 3: $x^{k+1} = x^k - \gamma_k \nabla f(x^k, \xi^k)$
- 4: **end for**

Выход: x^K

Условное математическое ожидание

- В ходе доказательства сходимости потребуется ввести **условное математическое ожидание**:

$$\mathbb{E} \left[\cdot \mid x^k \right] = \mathbb{E} \left[\cdot \mid \mathcal{F}_k \right],$$

где $\mathcal{F}_k$ — σ -алгебра, порождённая $x^0, \xi^0, \dots, \xi^{k-1}$.

Условное математическое ожидание

- В ходе доказательства сходимости потребуется ввести **условное математическое ожидание**:

$$\mathbb{E} \left[\cdot \mid x^k \right] = \mathbb{E} \left[\cdot \mid \mathcal{F}_k \right],$$

где $\mathcal{F}_k$ — σ -алгебра, порождённая $x^0, \xi^0, \dots, \xi^{k-1}$.

- Суть — фиксируем всю случайность, которая произошла до k итерации, и ожидаем только по случайности, которая осталась размороженной.

Условное математическое ожидание

- В ходе доказательства сходимости потребуется ввести **условное математическое ожидание**:

$$\mathbb{E} \left[\cdot \mid x^k \right] = \mathbb{E} \left[\cdot \mid \mathcal{F}_k \right],$$

где $\mathcal{F}_k$ — σ -алгебра, порождённая $x^0, \xi^0, \dots, \xi^{k-1}$.

- Суть — фиксируем всю случайность, которая произошла до k итерации, и ожидаем только по случайности, которая осталась размороженной. **Вопрос:** такое математическое ожидание, что дает на выходе: что-то детерминистическое или случайное?

Условное математическое ожидание

- В ходе доказательства сходимости потребуется ввести **условное математическое ожидание**:

$$\mathbb{E} \left[\cdot \mid x^k \right] = \mathbb{E} \left[\cdot \mid \mathcal{F}_k \right],$$

где $\mathcal{F}_k$ — σ -алгебра, порождённая $x^0, \xi^0, \dots, \xi^{k-1}$.

- Суть — фиксируем всю случайность, которая произошла до k итерации, и ожидаем только по случайности, которая осталась размороженной. **Вопрос:** такое математическое ожидание, что дает на выходе: что-то детерминистическое или случайное? Такое математическое ожидание дает на выходе что-то, зависящее от случайных величин $x^0, \xi^0, \dots, \xi^{k-1}$.

Условное математическое ожидание

- В ходе доказательства сходимости потребуется ввести **условное математическое ожидание**:

$$\mathbb{E} [\cdot \mid x^k] = \mathbb{E} [\cdot \mid \mathcal{F}_k],$$

где $\mathcal{F}_k$ — σ -алгебра, порождённая $x^0, \xi^0, \dots, \xi^{k-1}$.

- Суть — фиксируем всю случайность, которая произошла до k итерации, и ожидаем только по случайности, которая осталась размороженной. **Вопрос:** такое математическое ожидание, что дает на выходе: что-то детерминистическое или случайное? Такое математическое ожидание дает на выходе что-то, зависящее от случайных величин $x^0, \xi^0, \dots, \xi^{k-1}$.
- Также понадобится закон полного математического ожидания (tower property):

$$\mathbb{E} [\mathbb{E} [X \mid Y]] = \mathbb{E} [X].$$

Сходимость

- Будем доказывать в случае, когда f является L -гладкой и μ -сильно выпуклой.

Сходимость

- Будем доказывать в случае, когда f является L -гладкой и μ -сильно выпуклой.

- **Несмещённость стохастического градиента.**

Положим $\{\mathcal{F}\}_{k \geq 0}$ — семейство вложенных σ -алгебр. Случайная величина x^0 — $\mathcal{F}_0$ -измерима, и для любых $x^k \in \mathbb{R}^d$ и $k \in \mathbb{N}$ случайная величина $\nabla f(x^k, \xi^k)$ является $\mathcal{F}_k$ -измеримой и выполняется

$$\mathbb{E} \left[\nabla f(x^k, \xi^k) \mid x^{k-1} \right] = \nabla f(x^k).$$

Сходимость

- Будем доказывать в случае, когда f является L -гладкой и μ -сильно выпуклой.
- **Несмещённость стохастического градиента.**
Положим $\{\mathcal{F}\}_{k \geq 0}$ — семейство вложенных σ -алгебр. Случайная величина x^0 — $\mathcal{F}_0$ -измерима, и для любых $x^k \in \mathbb{R}^d$ и $k \in \mathbb{N}$ случайная величина $\nabla f(x^k, \xi^k)$ является $\mathcal{F}_k$ -измеримой и выполняется

$$\mathbb{E} \left[\nabla f(x^k, \xi^k) \mid x^{k-1} \right] = \nabla f(x^k).$$

- **Ограниченность дисперсии стохастического градиента.**
Существует $\sigma^2 \in \mathbb{R}_+$, такое, что для любых $x^k \in \mathbb{R}^d$ и $k \in \mathbb{N}$:

$$\mathbb{E} \left[\left\| \nabla f(x^k, \xi^k) - \nabla f(x^k) \right\|_2^2 \mid x^{k-1} \right] \leq \sigma^2.$$

Доказательство

Начинаем, как и раньше:

$$\begin{aligned}\|x^{k+1} - x^*\|_2^2 &= \|x^k - x^*\|_2^2 - 2\gamma \langle \nabla f(x^k, \xi^k), x^k - x^* \rangle \\ &\quad + \gamma^2 \|\nabla f(x^k, \xi^k)\|_2^2.\end{aligned}$$

Доказательство

Начинаем, как и раньше:

$$\begin{aligned}\|x^{k+1} - x^*\|_2^2 &= \|x^k - x^*\|_2^2 - 2\gamma \langle \nabla f(x^k, \xi^k), x^k - x^* \rangle \\ &\quad + \gamma^2 \left\| \nabla f(x^k, \xi^k) \right\|_2^2.\end{aligned}$$

Берем условное математическое ожидание по случайности только на итерации k :

$$\begin{aligned}\mathbb{E} \left[\|x^{k+1} - x^*\|_2^2 \mid x^k \right] &= \|x^k - x^*\|_2^2 - 2\gamma \mathbb{E} \left[\langle \nabla f(x^k, \xi^k), x^k - x^* \rangle \mid x^k \right] \\ &\quad + \gamma^2 \mathbb{E} \left[\left\| \nabla f(x^k, \xi^k) \right\|_2^2 \mid x^k \right].\end{aligned}$$

Доказательство

Начинаем, как и раньше:

$$\begin{aligned}\|x^{k+1} - x^*\|_2^2 &= \|x^k - x^*\|_2^2 - 2\gamma \langle \nabla f(x^k, \xi^k), x^k - x^* \rangle \\ &\quad + \gamma^2 \left\| \nabla f(x^k, \xi^k) \right\|_2^2.\end{aligned}$$

Берем условное математическое ожидание по случайности только на итерации k :

$$\begin{aligned}\mathbb{E} \left[\|x^{k+1} - x^*\|_2^2 \mid x^k \right] &= \|x^k - x^*\|_2^2 - 2\gamma \mathbb{E} \left[\langle \nabla f(x^k, \xi^k), x^k - x^* \rangle \mid x^k \right] \\ &\quad + \gamma^2 \mathbb{E} \left[\left\| \nabla f(x^k, \xi^k) \right\|_2^2 \mid x^k \right].\end{aligned}$$

Рассмотрим $\mathbb{E} [\langle \nabla f(x^k, \xi^k), x^k - x^* \rangle \mid x^k]$:

$$\begin{aligned}\mathbb{E} \left[\langle \nabla f(x^k, \xi^k), x^k - x^* \rangle \mid x^k \right] &= \left\langle \mathbb{E} [\nabla f(x^k, \xi^k) \mid x^k], x^k - x^* \right\rangle \\ &= \left\langle \nabla f(x^k), x^k - x^* \right\rangle.\end{aligned}$$

Доказательство

Рассмотрим $\mathbb{E} \left[\left\| \nabla f(x^k, \xi^k) \right\|_2^2 \middle| x^k \right]$:

$$\begin{aligned} \mathbb{E} \left[\left\| \nabla f(x^k, \xi^k) \right\|_2^2 \middle| x^k \right] &= \mathbb{E} \left[\left\| \nabla f(x^k, \xi^k) - \nabla f(x^k) + \nabla f(x^k) \right\|_2^2 \middle| x^k \right] \\ &= \mathbb{E} \left[\left\| \nabla f(x^k, \xi^k) - \nabla f(x^k) \right\|_2^2 \middle| x^k \right] \\ &\quad + \mathbb{E} \left[\left\| \nabla f(x^k) \right\|_2^2 \middle| x^k \right] \\ &\quad + 2\mathbb{E} \left[\left\langle \nabla f(x^k, \xi^k) - \nabla f(x^k), \nabla f(x^k) \right\rangle \middle| x^k \right]. \end{aligned}$$

Доказательство

Продолжим:

$$\begin{aligned}\mathbb{E} \left[\left\| \nabla f(x^k, \xi^k) \right\|_2^2 \middle| x^k \right] &= \mathbb{E} \left[\left\| \nabla f(x^k, \xi^k) - \nabla f(x^k) \right\|_2^2 \middle| x^k \right] + \left\| \nabla f(x^k) \right\|_2^2 \\ &\quad + 2 \left\langle \mathbb{E} \left[\nabla f(x^k, \xi^k) \middle| x^k \right] - \nabla f(x^k), \nabla f(x^k) \right\rangle \\ &\leq \sigma^2 + \left\| \nabla f(x^k) \right\|_2^2.\end{aligned}$$

Доказательство

Продолжим:

$$\begin{aligned}\mathbb{E} \left[\left\| \nabla f(x^k, \xi^k) \right\|_2^2 \middle| x^k \right] &= \mathbb{E} \left[\left\| \nabla f(x^k, \xi^k) - \nabla f(x^k) \right\|_2^2 \middle| x^k \right] + \left\| \nabla f(x^k) \right\|_2^2 \\ &\quad + 2 \left\langle \mathbb{E} \left[\nabla f(x^k, \xi^k) \middle| x^k \right] - \nabla f(x^k), \nabla f(x^k) \right\rangle \\ &\leq \sigma^2 + \left\| \nabla f(x^k) \right\|_2^2.\end{aligned}$$

Объединим все промежуточные шаги и получим:

$$\begin{aligned}\mathbb{E} \left[\left\| x^{k+1} - x^* \right\|_2^2 \middle| x^k \right] &\leq \left\| x^k - x^* \right\|_2^2 - 2\gamma \left\langle \nabla f(x^k), x^k - x^* \right\rangle \\ &\quad + \gamma^2 \left\| \nabla f(x^k) \right\|_2^2 + \gamma^2 \sigma^2.\end{aligned}$$

Доказательство

Воспользуемся L -гладкостью и μ -сильной выпуклостью:

$$\begin{aligned}\mathbb{E} \left[\|x^{k+1} - x^*\|_2^2 \mid x^k \right] &\leq \|x^k - x^*\|_2^2 - 2\gamma \left(f(x^k) - f^* + \frac{\mu}{2} \|x^k - x^*\|_2^2 \right) \\ &\quad + 2\gamma^2 L \left(f(x^k) - f^* \right) + \gamma^2 \sigma^2 \\ &= (1 - \gamma\mu) \|x^k - x^*\|_2^2 - 2\gamma(1 - \gamma L) \left(f(x^k) - f^* \right) \\ &\quad + \gamma^2 \sigma^2.\end{aligned}$$

Доказательство

Воспользуемся L -гладкостью и μ -сильной выпуклостью:

$$\begin{aligned}\mathbb{E} \left[\|x^{k+1} - x^*\|_2^2 \mid x^k \right] &\leq \|x^k - x^*\|_2^2 - 2\gamma \left(f(x^k) - f^* + \frac{\mu}{2} \|x^k - x^*\|_2^2 \right) \\ &\quad + 2\gamma^2 L \left(f(x^k) - f^* \right) + \gamma^2 \sigma^2 \\ &= (1 - \gamma\mu) \|x^k - x^*\|_2^2 - 2\gamma(1 - \gamma L) \left(f(x^k) - f^* \right) \\ &\quad + \gamma^2 \sigma^2.\end{aligned}$$

При выборе $\gamma \leq \frac{1}{L}$ можно упростить:

$$\mathbb{E} \left[\|x^{k+1} - x^*\|_2^2 \mid x^k \right] \leq (1 - \gamma\mu) \|x^k - x^*\|_2^2 + \gamma^2 \sigma^2.$$

Доказательство

Чтобы перейти к неслучайным величинам возьмем полное математическое ожидание:

$$\mathbb{E} \left[\|x^{k+1} - x^*\|_2^2 \right] \leq (1 - \gamma\mu) \mathbb{E} \left[\|x^k - x^*\|_2^2 \right] + \gamma^2 \sigma^2.$$

Доказательство

Чтобы перейти к неслучайным величинам возьмем полное математическое ожидание:

$$\mathbb{E} \left[\|x^{k+1} - x^*\|_2^2 \right] \leq (1 - \gamma\mu) \mathbb{E} \left[\|x^k - x^*\|_2^2 \right] + \gamma^2 \sigma^2.$$

Разворачиваем рекурсию:

$$\begin{aligned} \mathbb{E} \left[\|x^K - x^*\|_2^2 \right] &\leq (1 - \gamma\mu) \mathbb{E} \left[\|x^{K-1} - x^*\|_2^2 \right] + \gamma^2 \sigma^2 \\ &\leq (1 - \gamma\mu)^2 \mathbb{E} \left[\|x^{K-2} - x^*\|_2^2 \right] + (1 - \gamma\mu) \gamma^2 \sigma^2 + \gamma^2 \sigma^2 \\ &\leq (1 - \gamma\mu)^K \mathbb{E} \left[\|x^0 - x^*\|_2^2 \right] + \gamma^2 \sigma^2 \sum_{i=0}^{K-1} (1 - \gamma\mu)^i. \end{aligned}$$

Доказательство

Второе слагаемое — сумма первых k членов геометрической прогрессии, оценим её:

$$\sum_{i=0}^{K-1} (1 - \gamma\mu)^i \leq \sum_{i=0}^{+\infty} (1 - \gamma\mu)^i = \frac{1}{\gamma\mu}.$$

Доказательство

Второе слагаемое — сумма первых k членов геометрической прогрессии, оценим её:

$$\sum_{i=0}^{K-1} (1 - \gamma\mu)^i \leq \sum_{i=0}^{+\infty} (1 - \gamma\mu)^i = \frac{1}{\gamma\mu}.$$

После подстановки в выражение выше:

$$\mathbb{E} \left[\|x^k - x^*\|_2^2 \right] \leq (1 - \gamma\mu)^k \|x^0 - x^*\|_2^2 + \frac{\gamma\sigma^2}{\mu}.$$

Сходимость стохастического градиентного спуска

Теорема

Пусть задача безусловной стохастической оптимизации с L -гладкой μ -сильно выпуклой целевой функцией f решается с помощью стохастического градиентного спуска с $\gamma_k = \gamma \leq \frac{1}{L}$ в предположениях несмещённости и ограниченности дисперсии стохастического градиента. Тогда справедлива следующая оценка сходимости

$$\mathbb{E} \left[\|x^K - x^*\|_2^2 \right] \leq (1 - \gamma\mu)^K \|x^0 - x^*\|_2^2 + \frac{\gamma\sigma^2}{\mu}.$$

Анализ

- Результат вида:

$$\mathbb{E} \left[\|x^K - x^*\|_2^2 \right] \leq (1 - \gamma\mu)^K \|x^0 - x^*\|_2^2 + \frac{\gamma\sigma^2}{\mu}.$$

похож на то, что мы уже видели для градиентного спуска.

Анализ

- Результат вида:

$$\mathbb{E} \left[\|x^K - x^*\|_2^2 \right] \leq (1 - \gamma\mu)^K \|x^0 - x^*\|_2^2 + \frac{\gamma\sigma^2}{\mu}.$$

похож на то, что мы уже видели для градиентного спуска.

- Первый член — линейная сходимость к решению

Анализ

- Результат вида:

$$\mathbb{E} \left[\|x^K - x^*\|_2^2 \right] \leq (1 - \gamma\mu)^K \|x^0 - x^*\|_2^2 + \frac{\gamma\sigma^2}{\mu}.$$

похож на то, что мы уже видели для градиентного спуска.

- Первый член — линейная сходимость к решению
- Второй член — говорит о том, что некоторую точность (зависящую от γ , σ и μ) метод преодолеть не может и начинает осциллировать, больше не приближаясь к решению.
- **Вопрос:** как можно попробовать решить проблемы неточной сходимости?

Анализ

- Результат вида:

$$\mathbb{E} \left[\|x^K - x^*\|_2^2 \right] \leq (1 - \gamma\mu)^K \|x^0 - x^*\|_2^2 + \frac{\gamma\sigma^2}{\mu}.$$

похож на то, что мы уже видели для градиентного спуска.

- Первый член — линейная сходимость к решению
- Второй член — говорит о том, что некоторую точность (зависящую от γ , σ и μ) метод преодолеть не может и начинает осциллировать, больше не приближаясь к решению.
- **Вопрос:** как можно попробовать решить проблемы неточной сходимости? Сделать шаг уменьшающимся.

Уменьшающийся шаг

Теорема

Пусть задача безусловной стохастической оптимизации с L -гладкой μ -сильно выпуклой целевой функцией f решается с помощью стохастического градиентного спуска. Тогда при выборе

$$\gamma_k = \begin{cases} \frac{1}{2L}, & k < \lceil \frac{K}{2} \rceil, \\ \frac{2}{\mu(\frac{4L}{\mu} + k - \lceil \frac{K}{2} \rceil)}, & k \geq \lceil \frac{K}{2} \rceil, \end{cases} \quad w_k = \begin{cases} 0, & k < \lceil \frac{K}{2} \rceil, \\ \left(\frac{4L}{\mu} + k - \lceil \frac{K}{2} \rceil \right)^2, & k \geq \lceil \frac{K}{2} \rceil, \end{cases}$$

справедлива следующая оценка сходимости

$$\begin{aligned} \mathbb{E} [f(\bar{x}^K) - f^*] + \mu \mathbb{E} [\|x^{K+1} - x^*\|_2^2] \\ \leq \min \left\{ 64LR^2 \exp \left(-\frac{\mu K}{4L} \right) + \frac{36\sigma^2}{\mu K}, \frac{2LR^2}{K} + \frac{2\sigma R}{\sqrt{K}} \right\}, \end{aligned}$$

где $R = \|x^0 - x^*\|_2$, $W_K = \sum_{i=1}^K w_i$, $\bar{x}^K = \frac{1}{W_K} \sum_{i=1}^K w_i x^i$.

Батчинг

Идея заключается в замене стохастической оценки градиента по одному сэмплу на среднее арифметическое по подвыборке:

$$\nabla f(x^k, \xi^k) \rightarrow \frac{1}{b} \sum_{j \in S^k} \nabla f(x, \xi_j),$$

где S^k — набор индексов из $\overline{1, n}$, $|S^k| = b$, и все индексы генерируются независимо друг от друга (возможны повторы).

Батчинг

Несмещённость остается, так как у каждого сэмпла j есть несмещённость стохастического градиента и выполняется линейность математического ожидания:

$$\mathbb{E} \left[\frac{1}{b} \sum_{j \in S^k} \nabla f(x, \xi_j) \middle| x^k \right] = \nabla f(x).$$

Батчинг

Несмещённость остается, так как у каждого сэмпла j есть несмещённость стохастического градиента и выполняется линейность математического ожидания:

$$\mathbb{E} \left[\frac{1}{b} \sum_{j \in S^k} \nabla f(x, \xi_j) \middle| x^k \right] = \nabla f(x).$$

А с дисперсией интереснее:

$$\begin{aligned} & \mathbb{E} \left[\left\| \frac{1}{b} \sum_{j \in S^k} (\nabla f(x, \xi_j) - \nabla f(x)) \right\|_2^2 \middle| x^k \right] \\ & \leq \frac{1}{b^2} \mathbb{E} \left[\sum_{j \in S^k} \left\| \nabla f(x, \xi_j) - \nabla f(x) \right\|_2^2 \middle| x^k \right] \leq \frac{\sigma^2}{b}. \end{aligned}$$

Батчинг

Утверждение

Пусть применена техника батчирования по b независимым сэмплам. Тогда справедлива следующая оценка сходимости:

$$\mathbb{E} \left[\|x^K - x^*\|_2^2 \right] \leq (1 - \gamma\mu)^K \|x^0 - x^*\|_2^2 + \frac{\gamma\sigma^2}{\mu b}.$$

Сходимость стохастического градиентного спуска

- Если теперь объединить батчирование и стратегию подбора шага, то получается добиться следующей оценки сходимости:

$$\mathbb{E} \left[\|x^K - x^*\|_2^2 \right] = \mathcal{O} \left(\frac{L}{\mu} \exp \left(-\frac{\mu}{4L} K \right) \|x^0 - x^*\|_2^2 + \frac{\sigma^2}{\mu^2 b K} \right).$$

Получается линейная сходимость по «детерминистической» части и сублинейная по «стохастической».

Сходимость стохастического градиентного спуска

- Если теперь объединить батчирование и стратегию подбора шага, то получается добиться следующей оценки сходимости:

$$\mathbb{E} \left[\|x^K - x^*\|_2^2 \right] = \mathcal{O} \left(\frac{L}{\mu} \exp \left(-\frac{\mu}{4L} K \right) \|x^0 - x^*\|_2^2 + \frac{\sigma^2}{\mu^2 b K} \right).$$

Получается линейная сходимость по «детерминистической» части и сублинейная по «стохастической».

- Ускорение Нестерова возможно:

$$\mathbb{E} \left[f(x^{K+1}) - f^* \right] = \mathcal{O} \left(\exp \left(-\frac{1}{2} \sqrt{\frac{\mu}{L}} K \right) (f(x^0) - f^*) + \frac{\sigma^2}{\mu b K} \right).$$

Сходимость стохастического градиентного спуска

- Если теперь объединить батчирование и стратегию подбора шага, то получается добиться следующей оценки сходимости:

$$\mathbb{E} \left[\|x^K - x^*\|_2^2 \right] = \mathcal{O} \left(\frac{L}{\mu} \exp \left(-\frac{\mu}{4L} K \right) \|x^0 - x^*\|_2^2 + \frac{\sigma^2}{\mu^2 b K} \right).$$

Получается линейная сходимость по «детерминистической» части и сублинейная по «стохастической».

- Ускорение Нестерова возможно:

$$\mathbb{E} \left[f(x^{K+1}) - f^* \right] = \mathcal{O} \left(\exp \left(-\frac{1}{2} \sqrt{\frac{\mu}{L}} K \right) (f(x^0) - f^*) + \frac{\sigma^2}{\mu b K} \right).$$

Важной деталью является ускорение только первого члена, второй член (который и возникает из-за стохастики) остался прежним. Оказывается, его нельзя изменить и результат выше является оптимальным.