

Л7 Метод Ньютона. Квазиньютоновские методы

Ранее мы рассматривали градиентные методы, которые благодаря низкой вычислительной стоимости шага остаются основным инструментом для задач с очень большой размерностью. Их скорость сходимости обычно линейная — этого достаточно во многих практических случаях. Но если использовать больше информации о целевой функции, можно продвигаться к решению быстрее. Методы второго порядка, такие как метод Ньютона, используют не только значения функции и градиента, но и информацию о гессиане, что позволяет достигать квадратичной скорости сходимости и существенно сокращать число итераций.

Л7.1 Задача поиска нуля

Рассмотрим задачу поиска «корня» функции. Формально требуется для непрерывно дифференцируемой функции $\varphi : \mathbb{R} \rightarrow \mathbb{R}$ найти точку t^* , для которой верно

$$\varphi(t^*) = 0.$$

Пусть мы находимся в точке t^0 и хотим найти такую поправку Δt , что $t^0 + \Delta t \approx t^*$. Разложим φ по формуле Тейлора до первого порядка:

$$\varphi(t^0 + \Delta t) = \varphi(t^0) + \varphi'(t^0)\Delta t + o(\Delta t).$$

Поскольку $t^0 + \Delta t \approx t^*$, то:

$$\varphi(t^0 + \Delta t) \approx \varphi(t^*) = 0 \implies \varphi(t^0) + \varphi'(t^0)\Delta t \approx 0.$$

Таким образом, $\Delta t \approx -\frac{\varphi(t^0)}{\varphi'(t^0)}$. Продолжая строить новые точки, получаем выражение для итерации метода, предложенного Ньютоном в 17-м веке [19]:

$$t^{k+1} = t^k - \frac{\varphi(t^k)}{\varphi'(t^k)}.$$

Замечание Л7.1. Важно отметить ключевую особенность предложенного метода — сходимость к решению только в некоторой его окрестности. В качестве примера можно рассмотреть $\varphi(x) = \frac{x}{\sqrt{1+x^2}}$. Выберем в качестве начального приближения некоторую точку t^0 . Тогда нетрудно видеть, что

- $|t^0| < 1$ — метод сходится;
- $|t^0| = 1$ — метод колеблется в точках -1 и 1 ;
- $|t^0| > 1$ — метод расходится.

Л7.2 Метод Ньютона

Вернемся к задаче безусловной минимизации:

$$\min_{x \in \mathbb{R}^d} f(x). \tag{Л7.1}$$

Ранее уже обсуждалось, что для выпуклой целевой функции она эквивалентна задаче поиска нуля градиента:

$$\nabla f(x^*) = 0,$$






Рис. Л7.1: Сходимость в зависимости от начального приближения.

где $\nabla f : \mathbb{R}^d \rightarrow \mathbb{R}^d$.

Мы ожидаем получить шаг:

$$x^{k+1} = x^k - (\nabla^2 f(x))^{-1} \nabla f(x).$$

Градиентный спуск работает с линейной аппроксимацией функции. Теперь будем минимизировать её квадратичную аппроксимацию:

$$f(x) \approx f(x^k) + \langle \nabla f(x^k), x - x^k \rangle + \frac{1}{2} \langle \nabla^2 f(x^k)(x - x^k), x - x^k \rangle.$$

Построим x^{k+1} как точку, где зануляется градиент квадратичной аппроксимации:

$$\nabla f(x^k) + \nabla^2 f(x^k)(x - x^k) = 0 \implies x^{k+1} = x^k - (\nabla^2 f(x^k))^{-1} \nabla f(x^k).$$

Действительно, получили то, что ожидали:

Алгоритм Л7.1 Метод Ньютона

Вход: стартовая точка $x^0 \in \mathbb{R}^d$, количество итераций K

1: **for** $k = 0, 1, \dots, K - 1$ **do**

2: $x^{k+1} = x^k - (\nabla^2 f(x^k))^{-1} \nabla f(x^k)$

3: **end for**

Выход: x^K

Пример Л7.1. Рассмотрим задачу:

$$\min_{x \in \mathbb{R}^d} \left[f(x) = \frac{1}{2} \langle x, Ax \rangle - \langle b, x \rangle + c \right],$$

где $A \in \mathbb{S}_+^d$.

Пусть x^* — решение задачи. Тогда нетрудно заметить, что

$$\nabla f(x^*) = Ax^* - b = 0,$$

то есть $x^* = A^{-1}b$. При этом также нетрудно заметить, что

$$(\nabla^2 f(x))^{-1} \nabla f(x) = A^{-1}(Ax - b) = x - A^{-1}b.$$

Таким образом, метод Ньютона для квадратичной задачи сходится за одну итерацию. Важно отметить, что вычислительная стоимость этой итерации очень велика, не только из-за использования гессияна, но еще и из-за его обращения за $\mathcal{O}(d^3)$.

Далее будем работать в предположении, что целевая функция в задаче безусловной минимизации является дважды непрерывно дифференцируемой, μ -сильно выпуклой, а также имеет M -Липшицев гессиян:

Определение Л7.1. Пусть дана дважды непрерывно дифференцируемая на $\mathbb{R}^d$ функция $f : \mathbb{R}^d \rightarrow \mathbb{R}$. Будем говорить, что данная функция имеет M -Липшицев гессиян, если для любых $x, y \in \mathbb{R}^d$ выполнено

$$\|\nabla^2 f(x) - \nabla^2 f(y)\|_2 \leq M \|x - y\|_2.$$

Утверждение Л7.1. Пусть функция f имеет M -Липшицев гессиан. Введем обозначение

$$G_k = \nabla^2 f(x^k) - \int_0^1 \nabla^2 f(x^* + \tau(x^k - x^*)) d\tau.$$

Тогда справедлива оценка:

$$\|G_k\|_2 \leq \frac{M}{2} \|x^k - x^*\|_2.$$

Доказательство.

$$\begin{aligned} \|G_k\|_2 &= \left\| \nabla^2 f(x^k) - \int_0^1 \nabla^2 f(x^* + \tau(x^k - x^*)) d\tau \right\|_2 \\ &= \left\| \int_0^1 (\nabla^2 f(x^k) - \nabla^2 f(x^* + \tau(x^k - x^*))) d\tau \right\|_2 \\ &\leq \int_0^1 \|\nabla^2 f(x^k) - \nabla^2 f(x^* + \tau(x^k - x^*))\|_2 d\tau \\ &\leq \int_0^1 M(1 - \tau) \|x^k - x^*\|_2 d\tau \\ &= M \|x^k - x^*\|_2 \int_0^1 (1 - \tau) d\tau \\ &= \frac{M}{2} \|x^k - x^*\|_2. \end{aligned}$$

■

Теперь можем сформулировать теорему о сходимости метода Ньютона.

Теорема Л7.1. Пусть задача безусловной оптимизации (Л7.1) с M -Липшицевым гессианом, μ -сильно выпуклой целевой функцией f , решается с помощью метода Ньютона (Алгоритм Л7.1) Тогда справедлива следующая оценка сходимости:

$$\|x^{k+1} - x^*\|_2 \leq \frac{M}{2\mu} \|x^k - x^*\|_2^2.$$

Доказательство. Будем изучать, как меняется расстояние до решения:

$$x^{k+1} - x^* = x^k - (\nabla^2 f(x^k))^{-1} \nabla f(x^k) - x^*.$$

Воспользуемся формулой Ньютона-Лейбница для интеграла вдоль кривой:

$$\nabla f(x^k) - \nabla f(x^*) = \int_0^1 \nabla^2 f(x^* + \tau(x^k - x^*)) (x^k - x^*) d\tau.$$

Зная, что $\nabla f(x^*) = 0$, получим:

$$x^{k+1} - x^* = x^k - x^* - (\nabla^2 f(x^k))^{-1} \int_0^1 \nabla^2 f(x^* + \tau(x^k - x^*)) (x^k - x^*) d\tau.$$

Используем «умную единицу»:

$$\begin{aligned} x^{k+1} - x^* &= x^k - x^* - (\nabla^2 f(x^k))^{-1} \int_0^1 \nabla^2 f(x^* + \tau(x^k - x^*)) (x^k - x^*) d\tau \\ &= (\nabla^2 f(x^k))^{-1} \nabla^2 f(x^k) (x^k - x^*) \\ &\quad - (\nabla^2 f(x^k))^{-1} \int_0^1 \nabla^2 f(x^* + \tau(x^k - x^*)) (x^k - x^*) d\tau. \end{aligned}$$

Заметим, что $x^k - x^*$ можно вынести за пределы интеграла:

$$\begin{aligned} x^{k+1} - x^* &= (\nabla^2 f(x^k))^{-1} \left(\nabla^2 f(x^k) - \int_0^1 \nabla^2 f(x^* + \tau(x^k - x^*)) d\tau \right) (x^k - x^*) \\ &= (\nabla^2 f(x^k))^{-1} G_k (x^k - x^*). \end{aligned}$$

Спектральная норма матрицы согласована с евклидовой нормой вектора. Таким образом:

$$\|x^{k+1} - x^*\|_2 \leq \|(\nabla^2 f(x^k))^{-1}\|_2 \|G_k\|_2 \|x^k - x^*\|_2.$$

Норму обратного гессиана оценим как $\|(\nabla^2 f(x^k))^{-1}\|_2 = \frac{1}{\lambda_{\min}(\nabla^2 f(x^k))} \leq \frac{1}{\mu}$. Остается лишь применить результат Утверждения Л7.1, и получим требуемое:

$$\|x^{k+1} - x^*\|_2 \leq \frac{M}{2\mu} \|x^k - x^*\|_2^2.$$

■

Замечание Л7.2. Сходимость является локальной. А именно, чтобы гарантировать

$$\|x^1 - x^*\|_2 < \|x^0 - x^*\|_2,$$

нужно предположить, что:

$$\|x^0 - x^*\|_2 < \frac{2\mu}{M}.$$

Приведем пример, когда метод Ньютона расходится при старте из плохого приближения.

Пример Л7.2. Рассмотрим функцию $f: \mathbb{R} \rightarrow \mathbb{R}$:

$$f(x) = \frac{x^2}{2} + 10 \log \cosh x.$$

Её минимум находится в точке $x^* = 0$.

Найдём константу сильной выпуклости μ и константу липшицевости гессиана M .

Первые три производные имеют вид:

$$\begin{aligned}f'(x) &= x + 10 \tanh x, \\f''(x) &= 1 + \frac{10}{\cosh^2 x}, \\f'''(x) &= -20 \frac{\tanh x}{\cosh^2 x}.\end{aligned}$$

Так как $\cosh^2 x \geq 1$, имеем

$$\mu = \min_{x \in \mathbb{R}} f''(x) = 1.$$

Для константы липшицевости гессиана в одномерном случае:

$$M = \sup_{x \in \mathbb{R}} |f'''(x)|.$$

Положим $t = \tanh x \in (-1, 1)$, тогда $\frac{1}{\cosh^2 x} = 1 - t^2$ и

$$|f'''(t)| = 20|t|(1 - t^2).$$

Это выражение достигает максимума при $t = \pm \frac{1}{\sqrt{3}}$, и, следовательно,

$$M = \frac{40}{3\sqrt{3}} \approx 7.692.$$

Согласно теоретическим оценкам, метод сходится при начальном приближении x^0 :

$$|x^0 - x^*| \leq \frac{2\mu}{M} = \frac{3\sqrt{3}}{20} \approx 0.260.$$

Однако, оценка достаточно грубая, поскольку использует всего 2 константы, связанных с функцией. Найдём точно, где метод начинает расходиться.

Итерация метода Ньютона имеет вид

$$x^{k+1} = x^k - \frac{x^k + 10 \tanh x^k}{1 + \frac{10}{\cosh^2 x^k}}.$$

Поскольку минимум находится в нуле, функция f чётная, то на границе области сходимости модуль следующей точки совпадает с текущим, а знак меняется:

$$x^{k+1} = -x^k.$$

Это условие даёт уравнение

$$2x = \frac{x + 10 \tanh x}{1 + \frac{10}{\cosh^2 x}},$$

положительный корень которого:


$$\bar{x} \approx 1.22258$$

и задаёт границу области сходимости.

Итого, поведение метода Ньютона:

- $|x^0| < \bar{x}$ — сходимость к 0 квадратичная.
- $|x^0| = \bar{x}$ — колебания.

- $|x^0| > \bar{x}$ — расходимость.



Замечание Л7.3. Существует несколько способов сделать сходимость метода Ньютона глобальной. Один из них — так называемый демпфированный метод с шагом

$$x^{k+1} = x^k - \gamma_k (\nabla^2 f(x^k))^{-1} \nabla f(x^k).$$

Стоит отметить, что на практике демпфированные методы сходятся медленнее.

Л7.3 Метод Ньютона с кубической регуляризацией

Вспомним идейно один из способов получить интуицию метода градиентного спуска. Пользуясь гладкостью градиента целевой функции, можно аппроксимировать её значение некоторым эллиптическим параболоидом. Далее можно явно выписать его минимум — это и будет шаг градиентного спуска. Попробуем распространить эту идею на методы высших порядков. Предположим, что целевая функция имеет M -липшицев гессиан. Тогда можно записать аппроксимацию второго порядка:

$$\xi_{2,x}(y) = f(x) + \langle \nabla f(x), y - x \rangle + \frac{1}{2} \langle \nabla^2 f(x)(y - x), y - x \rangle + \frac{M}{6} \|x - y\|_2^3.$$

Она устроена также, как и квадратичная парабола, которая мы строилась для L -гладких функций. Эта аппроксимация подпирает сверху целевую функцию, поэтому $f(y) \leq \xi_{2,x}(y)$. Построим итерационную схему, минимизирующую верхнюю оценку:

$$x^{k+1} = \operatorname{argmin}_{y \in \mathbb{R}^d} \xi_{2,x^k}(y).$$

Для простоты анализа определим

$$T_M(x) \in \operatorname{argmin}_{y \in \mathbb{R}^d} \left[\langle \nabla f(x), y - x \rangle + \frac{1}{2} \langle \nabla^2 f(x)(y - x), y - x \rangle + \frac{M}{6} \|x - y\|_2^3 \right].$$

Здесь константа Липшица гессиана будет параметром, чтобы иметь возможность варьировать шаг. Такой подход называется кубической регуляризацией метода Ньютона.

Алгоритм Л17.2 Метод Ньютона с кубической регуляризацией

Вход: стартовая точка $x^0 \in \mathbb{R}^d$, параметры $\{M_k\}_{k=0}^{K-1}$, количество итераций K
1: **for** $k = 0, \dots, K-1$ **do**
2: $x^{k+1} = T_{M_k}(x^k)$
3: **end for**
Выход: x^K

Далее мы предполагаем, что собственные значения Гессiana пронумерованы в порядке убывания.

Теорема Л17.2 (Теорема 3 из [18]). Пусть задача безусловной оптимизации (Л17.1) с M -липшицевым гессианом целевой функцией f решается с помощью метода Ньютона с кубической регуляризацией (Алгоритм Л17.2). Тогда при

$$\nabla^2 f(x^0) \succ 0, \quad \frac{M \|\nabla f(x^0)\|_2}{\lambda_d^2(\nabla^2 f(x^0))} \leq \frac{1}{4}$$

справедлива следующая оценка сходимости:

$$\|\nabla f(x^k)\|_2 \leq \lambda_d^2(\nabla^2 f(x^0)) \frac{9e^{3/2}}{16M} \left(\frac{1}{2}\right)^{2^k}.$$

Полученный метод представляет интерес, поскольку не требует выпуклости, только M -липшицевость гессиана и условия из теоремы в стартовой точке. Сходимость при этом квадратичная по норме градиента, то есть, очень быстрая.

Стоит отметить, что рассматриваемая задача поиска аргминимума, вообще говоря, не выпуклая из-за кубического члена и может иметь локальные минимумы, в то время как нам нужно отыскать глобальный. Тем не менее, эта задача эквивалентна задаче выпуклой одномерной оптимизации.

Теорема Л17.3 (Теорема 10 из [18]). Задача

$$\min_{y \in \mathbb{R}^d} \left[\langle \nabla f(x), y - x \rangle + \frac{1}{2} \langle \nabla^2 f(x)(y - x), y - x \rangle + \frac{M}{6} \|x - y\|_2^3 \right]$$

эквивалентна задаче

$$\min_{r \in \mathcal{D}} \left[\frac{1}{2} \left\langle \left(\nabla^2 f(x) + \frac{Mr}{2} I_d \right)^{-1} \nabla f(x), \nabla f(x) \right\rangle + \frac{M}{12} r^3 \right],$$

где

$$\mathcal{D} = \left\{ r \in \mathbb{R}_+ \mid \nabla^2 f(x) + \frac{Mr}{2} I_d \succ 0 \right\}.$$

Л17.4 Квазиньютоновские методы

Метод Ньютона обеспечивает быструю локальную сходимость, однако вычислительная стоимость одной итерации часто оказывается слишком высокой: требуется находить обратный гессиаан $(\nabla^2 f(x^k))^{-1}$. Идея квазиньютоновских методов заключается в том, чтобы заменить его на приближение H_k , сохраняющее ключевые свойства обратного гессиаана, но гораздо более дешёвое в обновлении.

Начнём с линейной аппроксимации приращения градиента:

$$\nabla f(x^{k+1}) - \nabla f(x^k) \approx \nabla^2 f(x^{k+1})(x^{k+1} - x^k).$$

Введём обозначения

$$s^k = x^{k+1} - x^k, \quad y^k = \nabla f(x^{k+1}) - \nabla f(x^k)$$

и положим

$$B_{k+1} \approx \nabla^2 f(x^{k+1}), \quad H_{k+1} \approx (\nabla^2 f(x^{k+1}))^{-1}.$$

Тогда аппроксимация выше принимает вид

$$y^k = B_{k+1}s^k \iff s^k = H_{k+1}y^k. \quad (\text{ЛП7.2})$$

Это уравнение называют *квазиньютоновским*.

Замечание ЛП7.4. Условие симметричности и квазиньютоновское уравнение дают

$$\frac{d(d-1)}{2} + d = \frac{d(d+1)}{2}$$

линейно независимых ограничений на $d \times d$ матрицу. Поскольку общее число элементов матрицы равно d^2 , остаётся $\frac{d(d-1)}{2}$ свободных параметров. Это означает, что множество допустимых приближений очень велико, и существует широкий спектр стратегий построения H_{k+1} или B_{k+1} . Ниже мы рассмотрим наиболее популярные из них.

Общая схема квазиньютоновских методов выглядит следующим образом:

Алгоритм ЛП7.3 Общая схема квазиньютоновских методов

Вход: стартовая точка $x^0 \in \mathbb{R}^d$, стартовая матрица H_0 , размеры шагов $\{\gamma_k\}_{k=0} > 0$, количество итераций K

- 1: **for** $k = 0, 1, \dots, K-1$ **do**
- 2: $x^{k+1} = x^k - \gamma_k H_k \nabla f(x^k)$
- 3: Обновить $H_k \rightarrow H_{k+1}$ так, чтобы выполнялось (ЛП7.2)
- 4: **end for**

Выход: x^K

Замечание ЛП7.5. Размеры шагов $\{\gamma_k\}_{k=0}^{K-1}$ могут выбираться с помощью процедуры линейного поиска. При этом можно как находить шаг наискорейшего спуска вдоль направления $H_k \nabla f(x^k)$, так и требовать выполнения условий Вольфа (Алгоритм ЛП3.6).

ЛП7.4.1 SR1

Будем использовать для обновления матрицы дешёвую с точки зрения вычислений симметричную одноранговую добавку (отсюда и название Symmetric Rank 1):

$$H_{k+1} = H_k + \mu_k q^k (q^k)^\top,$$

где $\mu_k \in \mathbb{R}$ и $q^k \in \mathbb{R}^d$. Их мы подбираем исходя из квазиньютоновского уравнения:

$$s^k = H_{k+1}y^k = \left(H_k + \mu_k q^k (q^k)^\top \right) y^k = H_k y^k + \mu_k \left((q^k)^\top y^k \right) q^k.$$

Откуда

$$\mu_k \left((q^k)^\top y^k \right) q^k = s^k - H_k y^k.$$

Возьмём $\mu_k = \frac{1}{(q^k)^\top y^k}$ и получим, что $q^k = s^k - H_k y^k$.

Итак, SR1 способ обновления матрицы H_k :

$$H_{k+1} = H_k + \frac{(s^k - H_k y^k)(s^k - H_k y^k)^\top}{(s^k - H_k y^k)^\top y^k}.$$

Л7.4.2 Broyden

Подойдем к задаче иначе. Запишем квазиньютоновское уравнение для матрицы B :

$$y^k = B_{k+1} s^k.$$

Потребуем минимальность фробениусовой нормы поправки при ограничении в виде квазиньютоновского уравнения:

$$\begin{aligned} B_{k+1} &= \operatorname{argmin}_{B \in \mathbb{R}^{d \times d}} \|B - B_k\|_F^2 \\ \text{s.t. } B s^k &= y^k. \end{aligned}$$

Иными словами, хотим найти наиболее близкую матрицу к B_k , которая будет удовлетворять квазиньютоновскому уравнению. Решением такой задачи будет формула обновления:

$$B_{k+1} = B_k + \frac{(y^k - B_k s^k)(s^k)^\top}{(s^k)^\top s^k}.$$

Обратим внимание, что полученная поправка является одноранговой, хотя явно мы этого не требовали. Однако, она не является симметричной, что плохо согласуется со свойствами гессиана, который мы хотим аппроксимировать.

Чтобы не обращаться матрицу B_{k+1} и не решать системы линейных уравнений, можем получить явную формулу для $H_{k+1} = B_{k+1}^{-1}$, используя формулу Шермана-Моррисона-Вудбери, впервые предложенную в [24].

Утверждение Л7.2. Пусть $A \in \mathbb{R}^{d \times d}$ — обратимая матрица, а $U, V \in \mathbb{R}^{d \times n}$. Тогда, если также обратима матрица $I_d + V^\top A^{-1} U$, то верна формула:

$$(A + UV^\top)^{-1} = A^{-1} - A^{-1} U (I_d + V^\top A^{-1} U)^{-1} V^\top A^{-1}.$$

После ее применения получаем обновление H_k :

$$H_{k+1} = H_k + \frac{(s^k - H_k y^k)(s^k)^\top H_k}{(s^k)^\top H_k y^k}.$$

Л7.4.3 DFP

Модифицируем задачу поиска B_{k+1} . Добавим требование на симметричность матрицы и заменим обычную норму Фробениуса на взвешенную:

$$\|A\|_W = \|W^{1/2} A W^{1/2}\|_F,$$

где W — произвольная матрица, для которой выполняется $W y^k = s^k$. Для определенности, такой матрицей может быть обратный усредненный гессиан $W = \bar{G}_k^{-1}$, определяющийся следующим образом:

$$\bar{G}_k = \int_0^1 \nabla^2 f(x^k - \tau \gamma_k H_k \nabla f(x^k)) d\tau.$$

Получим задачу оптимизации для поиска B_{k+1} :

$$\begin{aligned} B_{k+1} &= \operatorname{argmin}_{B \in \mathbb{R}^{d \times d}} \|B - B_k\|_W^2 \\ \text{s.t.} \quad B s^k &= y^k, \\ B^\top &= B. \end{aligned}$$

Решением этой задачи является формула обновления DFP (Davidon-Fletcher-Powell):

$$B_{k+1} = \left(I - \frac{y^k (s^k)^\top}{(y^k)^\top s^k} \right) B_k \left(I - \frac{s^k (y^k)^\top}{(y^k)^\top s^k} \right) + \frac{y^k (y^k)^\top}{(y^k)^\top s^k}.$$

Обращая ее по формуле Шермана-Моррисона-Вудбери, получаем выражение для H_{k+1} :

$$H_{k+1} = H_k - \frac{H_k y^k (y^k)^\top H_k}{(y^k)^\top H_k y^k} + \frac{s^k (s^k)^\top}{(s^k)^\top y^k}. \quad (\text{Л7.3})$$

Теорема Л7.4 (Теорема 4.2 из [23]). Пусть задача безусловной оптимизации (Л7.1) с M -липшицевым гессианом, L -гладкой, μ -сильно выпуклой целевой функцией f решается с помощью метода DFP (Алгоритм Л7.3 с формулой обновления (Л7.3)). Введем обозначение

$$\lambda_f(x) = \sqrt{\langle \nabla f(x), (\nabla^2 f(x))^{-1} \nabla f(x) \rangle}.$$

Тогда при выборе шагов $\gamma_k = 1$ и начальной точке x^0 достаточно близкой к решению, что выполняется

$$\lambda_f(x^0) \leq \frac{\log \frac{3}{2}}{4} \frac{\mu^{5/2}}{LM},$$

справедлива следующая оценка сходимости:

$$\lambda_f(x^K) \leq \left(\frac{11dL^2}{\mu^2 K} \right)^{K/2} \lambda_f(x^0).$$

Л7.4.4 BFGS

Поступим так же, как и в DFP, только будем решать задачу сразу для H . Она получена из таких же рассуждений, меняется только ограничение:

$$\begin{aligned} H_{k+1} &= \operatorname{argmin}_{H \in \mathbb{R}^{d \times d}} \|H - H_k\|_W^2 \\ \text{s.t.} \quad s^k &= H y^k, \\ H^\top &= H. \end{aligned}$$

Решением будет формула BFGS (Broyden-Fletcher-Goldfarb-Shanno):

$$H_{k+1} = \left(I_d - \frac{s^k (y^k)^\top}{(y^k)^\top s^k} \right) H_k \left(I_d - \frac{y^k (s^k)^\top}{(y^k)^\top s^k} \right) + \frac{s^k (s^k)^\top}{(y^k)^\top s^k}. \quad (\text{Л7.4})$$

Теорема Л17.5 (Теорема 4.2 из [23]). Пусть задача безусловной оптимизации (Л17.1) с M -липшицевым гессианом, L -гладкой, μ -сильно выпуклой целевой функцией f решается с помощью метода BFGS (Алгоритм Л17.3 с формулой обновления (Л17.4)). Введем обозначение

$$\lambda_f(x) = \sqrt{\langle \nabla f(x), (\nabla^2 f(x))^{-1} \nabla f(x) \rangle}.$$

Тогда при выборе шагов $\gamma_k = 1$ и начальной точке x^0 достаточно близкой к решению, что выполняется

$$\lambda_f(x^0) \leq \frac{\log \frac{3}{2}}{4} \frac{\mu^{5/2}}{LM},$$

справедлива следующая оценка сходимости:

$$\lambda_f(x^K) \leq \left(\frac{11dL}{\mu K} \right)^{K/2} \lambda_f(x^0).$$

Замечание Л17.6. Существует много способов инициализировать матрицу H_0 , но на практике достаточно брать $H_0 = I_d$.

Замечание Л17.7. Сложность всех арифметических операций на одной итерации квазиньютоновских методов $\mathcal{O}(d^2)$. Это дешевле обращения гессиана, но все еще довольно плохой результат для задач экстремально больших размерностей.

Л17.4.5 Сравнительная таблица

Соберем все формулы для рассмотренных методов в одном месте.

Метод	B^{new}	$H^{\text{new}} = (B^{\text{new}})^{-1}$
SR1	$B + \frac{(y-Bs)(y-Bs)^\top}{(y-Bs)^\top s}$	$H + \frac{(s-Hy)(s-Hy)^\top}{(s-Hy)^\top y}$
Broyden	$B + \frac{y-Bs}{s^\top s} s^\top$	$H + \frac{(s-Hy)s^\top H}{s^\top H y}$
DFP	$\left(I_d - \frac{ys^\top}{y^\top s}\right) B \left(I_d - \frac{sy^\top}{y^\top s}\right) + \frac{yy^\top}{y^\top s}$	$H + \frac{ss^\top}{s^\top y} - \frac{Hy y^\top H}{y^\top H y}$
BFGS	$B + \frac{yy^\top}{y^\top s} - \frac{Bss^\top B}{s^\top B s}$	$\left(I_d - \frac{sy^\top}{y^\top s}\right) H \left(I_d - \frac{ys^\top}{y^\top s}\right) + \frac{ss^\top}{y^\top s}$

Таблица 1: Обновления матриц B и H в различных квазиньютоновских методах. Здесь B , H , s и y соответствуют последней итерации, а B^{new} и H^{new} — их новые значения.

Л17.4.6 L-BFGS

При переходе от метода Ньютона к квазиньютоновским методам мы уже получили ускорение с $\mathcal{O}(d^3)$ до $\mathcal{O}(d^2)$ арифметических операций на итерацию. В памяти же в обоих подходах требуется хранить $\mathcal{O}(d^2)$ значений. Квадратичная стоимость итерации и по арифметическим операциям, и по памяти — это очень дорого для задач большой размерности.

Это подводит нас к следующему методу — L-BFGS из [13], где L означает Limited-memory. Базовая идея — вместо матрицы $H_k \in \mathbb{R}^{d \times d}$, аппроксимирующей Гессиян, хранить несколько подходящих векторов длины d . За улучшение по памяти приходится платить ухудшением скорости сходимости. Тем не менее, оказывается возможным показать линейную сходимость такого метода.

В случае BFGS имели следующее обновление матрицы после применения формулы Шермана–Маррисона–Вудберри:

$$H_{k+1} = V_k^\top H_k V_k + \frac{s^k (s^k)^\top}{(y^k)^\top s^k},$$

где $V_k = I_d - \frac{y^k (s^k)^\top}{(y^k)^\top s^k}$. Предлагается на итерации k выбирать некоторое начальное приближение Гессияна H_k^0 и затем последовательно применить (Л7.4) по последним m парам $\{s^k, y^k\}$:

$$\begin{aligned} H_{k+1} &= (V_{k-1}^\top \dots V_{k-m}^\top) H_k^0 (V_{k-m} \dots V_{k-1}) \\ &\quad + \rho^{k-m} (V_{k-1}^\top \dots V_{k-m+1}^\top) s^{k-m} (s^{k-m})^\top (V_{k-m+1} \dots V_{k-1}) \\ &\quad + \dots \\ &\quad + \rho^{k-1} s^{k-1} (s^{k-1})^\top. \end{aligned}$$

Здесь мы обозначили $\rho^k = \frac{1}{(y^k)^\top s^k}$. Экспериментальные результаты показывают, что m может быть выбрано относительно небольшим (меньше двадцати). Это дает существенное улучшение метода по памяти. Начальное приближение H_k^0 рекомендуется выбирать следующим образом:

$$H_k^0 = \frac{(s^{k-1})^\top y^{k-1}}{(y^{k-1})^\top y^{k-1}} I_d.$$

Множитель перед единичной матрицей реализует шкалирование матрицы вдоль последнего направления поиска. Для поиска шага для робастности важно использовать условия Вольфа (либо сильные условия Вольфа).

Основные недостатки метода L-BFGS заключаются в том, что он часто сходится медленно, особенно на плохо обусловленных задачах.

Л7.5 Trust-Region шаг

Методы линейного поиска основаны на поиске подходящего размера шага γ_k вдоль фиксированного направления p^k , которым может быть градиент $\nabla f(x^k)$ в случае градиентного спуска, или $(\nabla^2 f(x^k))^{-1} \nabla f(x^k)$ в случае демпфированного метода Ньютона.

Метод области доверия (Trust-Region) работает иначе. На каждом шаге алгоритма строится квадратичная модель m_k целевой функции f :

$$m_k(p) = f(x^k) + \langle \nabla f(x^k), p \rangle + \frac{1}{2} \langle p, B_k p \rangle,$$

где B_k — некоторая симметричная матрица, приближающая гессиян $\nabla^2 f(x^k)$. Например, в квазиньютоновских методах мы знаем аппроксимацию гессияна B_k .

Эта квадратичная модель совпадает с разложением Тейлора целевой функции f с точностью до первых двух членов. Если B_k в точности равна $\nabla^2 f(x^k)$, то совпадение в первых трех членах.

Чтобы получить шаг согласно стратегии Trust-Region решается подзадача

$$\begin{aligned} \min_{p \in \mathbb{R}^d} \quad & m_k(p) = f(x^k) + \langle \nabla f(x^k), p \rangle + \frac{1}{2} \langle p, B_k p \rangle \\ \text{s.t.} \quad & \|p\|_2 \leq \Delta_k, \end{aligned} \quad (\text{Л7.5})$$

где Δ_k — радиус области доверия. Эта подзадача является квадратичной: и целевая функция m_k , и ограничение, которое можно переписать как

$$\langle p, p \rangle \leq \Delta_k^2,$$

являются квадратичными.

Понять принцип Trust-Region шага можно при сравнении с демпфированным методом Ньютона со значением шага $\gamma_k = \frac{\Delta_k}{\|p^k\|}$.




Рис. Л7.2: Линии уровня квадратичной модели $m_k(p)$, область доверия ограничена пунктиром, показаны шаги Trust-Region и демпфированного метода Ньютона.

Демпфированный метод Ньютона делает шаг в направлении минимума построенной модели m_k , а Trust-Region минимизирует значение модели $m_k(p)$, оставаясь в области доверия $\|p\|_2 \leq \Delta_k$. Рисунок позволяет понять, почему эти шаги не эквивалентны. Trust-Region существенно учитывает ограничение на размер шага при его поиске.

В случае, когда

$$\|B_k^{-1} \nabla f(x^k)\|_2 \leq \Delta_k,$$

то решение (Л7.5) просто

$$p^k = -B_k^{-1} \nabla f(x^k).$$

В ином случае, решение не так очевидно, однако, может быть найдено не так дорого. Но зачастую достаточно найти лишь приближенное решение для хорошей сходимости на практике.

Поговорим о стратегии подбора радиуса Δ_k . Если выбирать его слишком маленьким, шаги в направлении оптимума будут небольшими, и метод сходиться будет медленно. Если же брать Δ_k чересчур большим, то построенная модель m_k будет плохо приближать целевую функцию f вдали от нуля. Шаги будут большими, но неточными, и можем получить расходимость. Чтобы численно описывать, насколько наша модель точно приближает целевую функцию, определим соотношение

$$\rho_k = \frac{f(x^k) - f(x^k + p^k)}{m_k(0) - m_k(p^k)}. \quad (\text{Л7.6})$$

Числитель этой дроби назовем *действительным убыванием*, а знаменатель — *предсказанным убыванием*. Поскольку p^k — точка оптимума t_k , то предсказанное убывание всегда неотрицательно. Отсюда следует, что если $\rho_k < 0$, то $f(x^k + p^k) > f(x^k)$, и такой шаг должен быть отклонен. С другой стороны, если $\rho_k \approx 1$, то модель и функция хорошо согласуются, и можно увеличивать доверительную область на последующих итерациях. Если ρ_k положительно, но не вблизи 1, то не изменяем Δ_k . Эту стратегию можно описать с помощью алгоритма.

Алгоритм Л7.4 Метод доверительной области

Вход: максимальное значение доверительного радиуса $\bar{\Delta} > 0$, начальный доверительный радиус $\Delta_0 \in (0, \bar{\Delta})$, ограничение снизу на отношение убываний $\eta \in [0, \frac{1}{4}]$

```

1: for  $k = 0, \dots, K - 1$  do
2:   Найти  $p_k$  (приблизённо) решением (Л7.5)
3:   Вычислить  $\rho_k$  по формуле (Л7.6)
4:   if  $\rho_k < \frac{1}{4}$  then
5:      $\Delta_{k+1} = \frac{1}{4} \|p_k\|_2$ 
6:   else
7:     if  $\rho_k > \frac{3}{4}$  and  $\|p_k\|_2 = \Delta_k$  then
8:        $\Delta_{k+1} = \min(2\Delta_k, \bar{\Delta})$ 
9:     else
10:       $\Delta_{k+1} = \Delta_k$ 
11:    end if
12:  end if
13:  if  $\rho_k > \eta$  then
14:     $x_{k+1} = x_k + p_k$ 
15:  else
16:     $x_{k+1} = x_k$ 
17:  end if
18: end for

```

В алгоритме мы дополнительно добавили ограничение на максимальный размер шага $\bar{\Delta}$, а также ограничение на минимальное значение отношения ρ_k , при котором совершается шаг, в виде константы η .

Более подробно про приближенное решение подзадачи (Л7.5) рассказано в работе [20].