

Л8 Негладкая оптимизация. Адаптивные методы

До сих пор мы рассматривали только безусловные гладкие выпуклые задачи оптимизации, то есть, задачи поиска минимума выпуклой функции с липшицевым градиентом на $\mathbb{R}^d$. Оказывается, что это достаточно сильные требования на целевую функцию, следующий пример это показывает.

Пример Л8.1. Рассмотрим функцию $f : \mathbb{R} \rightarrow \mathbb{R}$ следующего вида:

$$f(x) = |x|.$$

Эта функция достаточно простая и часто встречается, например, в виде ℓ_1 -регуляризатора. При этом из-за отсутствия дифференцируемости в нуле она не является гладкой. Более того, наше определение выпуклости (Определение Л2.3) работает только для дифференцируемых функций, то есть, не применимо для модуля.

Это подталкивает нас к развитию теории для негладких задач.

Л8.1 Негладкие задачи

Хотелось бы ослабить требования на функции, в частности перестать требовать дифференцируемость целевой функции. В Параграфе Л2 было введено определение выпуклости для дифференцируемой функции (Определение Л2.3). Теперь обобщим его, не требуя дифференцируемости.

Определение Л8.1. Рассмотрим функцию $f : \mathbb{R}^d \rightarrow \mathbb{R}$. Функция f называется *выпуклой*, если для любых $x_1, \dots, x_k \in \mathbb{R}^d$ и любых $\alpha_1, \dots, \alpha_k$, $\alpha_i \geq 0$, $\sum_{i=1}^k \alpha_i = 1$ выполняется

$$f\left(\sum_{i=1}^k \alpha_i x_i\right) \leq \sum_{i=1}^k \alpha_i f(x_i).$$

Замечание Л8.1. В Параграфе С4 более подробно изучаются различные определения выпуклых функций. В частности, в случае дифференцируемой функции показывается, что Определения Л2.3 и Л8.1 эквивалентны (Теорема С4.1).

Требование на дифференцируемость функции осталось только в гладкости. Заменим условие L -липшицевости градиента на M -липшицевость самой функции.

Определение Л8.2. Пусть дана функция $f : \mathbb{R}^d \rightarrow \mathbb{R}$. Будем говорить, что она является M -липшицевой, если для любых $x, y \in \mathbb{R}^d$ выполнено:

$$|f(x) - f(y)| \leq M \|x - y\|_2.$$

Мы отказались от дифференцируемости целевой функции. Однако, можно ввести новую сущность, которая будет обладать некоторыми такими же полезными свойствами, что и градиент для дифференцируемых выпуклых функций.

Определение Л8.3. Пусть дана выпуклая функция $f : \mathbb{R}^d \rightarrow \mathbb{R}$. Вектор $g \in \mathbb{R}^d$ будем называть *субградиентом* функции f в точке $x \in \mathbb{R}^d$, если для любого $y \in \mathbb{R}^d$ выполнено

$$f(y) \geq f(x) + \langle g, y - x \rangle.$$

Множество $\partial f(x)$ всех субградиентов f в точке x называется *субдифференциалом*.

Сформулируем критерий минимума выпуклой функции, по аналогии с тем, как было для дифференцируемых функций (Теорема Л2.1 и Теорема Л2.2).

Теорема Л8.1. Точка x^* — минимум выпуклой функции f тогда и только тогда, когда

$$0 \in \partial f(x^*).$$

Доказательство. $\Rightarrow$ Если $f(x) \geq f(x^*)$ для любых $x \in \mathbb{R}^d$, то для вектора 0 выполнено

$$f(x) \geq f(x^*) + \langle 0, x - x^* \rangle$$

для любого $x \in \mathbb{R}^d$. Следовательно,

$$0 \in \partial f(x^*).$$

Доказано по определению субградиента.

$\Leftarrow$ Пусть $0 \in \partial f(x^*)$. Тогда по определению субградиента (Определение Л8.3):

$$f(x) \geq f(x^*) + \langle 0, x - x^* \rangle = f(x^*)$$

для любого $x \in \mathbb{R}^d$. Доказано по определению минимума на множестве (Определение Л2.2). ■

Теорема Л8.2. Пусть дана выпуклая функция $f : \mathbb{R}^d \rightarrow \mathbb{R}$. Тогда функция f является M -липшицевой тогда и только тогда, когда для любого $x \in \mathbb{R}^d$ и $g \in \partial f(x)$ имеем $\|g\|_2 \leq M$.

Доказательство. $\Rightarrow$ Рассмотрим $g \in \partial f(x)$, тогда по определению субградиента (Определение Л8.3) для любого $y \in \mathbb{R}^d$:

$$f(y) - f(x) \geq \langle g, y - x \rangle.$$

Из M -липшицевости f (Определение Л8.2):

$$M\|y - x\|_2 \geq f(y) - f(x) \geq \langle g, y - x \rangle.$$

Возьмем $y = g + x \in \mathbb{R}^d$, тогда

$$M\|g\|_2 = M\|y - x\|_2 \geq \langle g, y - x \rangle = \|g\|_2^2.$$

Откуда и получаем:

$$\|g\|_2 \leq M.$$

$\Leftarrow$ Рассмотрим $g \in \partial f(x)$, тогда по определению субградиента (Определение Л8.3) для любого $y \in \mathbb{R}^d$:

$$f(x) - f(y) \leq \langle g, x - y \rangle.$$

Используем неравенством Коши–Буняковского–Шварца (0.3):

$$f(x) - f(y) \leq \|g\|_2 \|x - y\|_2.$$

Воспользуемся предположением об ограниченности нормы субградиента и получим:

$$f(x) - f(y) \leq M\|x - y\|_2.$$

Если переобозначить $x \rightarrow y$, $y \rightarrow x$, то можем записать:

$$f(y) - f(x) \leq M\|y - x\|_2.$$

Если объединить оба неравенства, то можем прийти к более краткой записи:

$$|f(y) - f(x)| \leq M\|x - y\|_2.$$

Это и есть свойство M -липшицевости f . ■

Л8.2 Субградиентный метод

Рассматриваем безусловную задачу:

$$\min_{x \in \mathbb{R}^d} f(x), \quad (\text{Л8.1})$$

где функция f выпуклая на $\mathbb{R}^d$ и M -липшицева.

Простая идея — снова модифицировать градиентный спуск, теперь вместо градиента используя какой-то субградиент в текущей точке:

Алгоритм Л8.1 Субградиентный метод

Вход: стартовая точка $x^0 \in \mathbb{R}^d$, размеры шагов $\{\gamma_k\}_{k=0} > 0$, количество итераций K

- 1: **for** $k = 0, 1, \dots, K - 1$ **do**
- 2: Вычислить $g^k \in \partial f(x^k)$
- 3: $x^{k+1} = x^k - \gamma_k g^k$
- 4: **end for**

Выход: $\frac{1}{K} \sum_{k=0}^{K-1} x^k$

Замечание Л8.2. Сходимость у субградиентного метода (Алгоритм Л8.1) по средней точке, а не по последней.

Теорема Л8.3. Пусть задача безусловной оптимизации с M -липшицевой выпуклой целевой функцией f решается с помощью субградиентного метода (Алгоритм Л8.1). Тогда при $\gamma_k = \gamma$ справедлива следующая оценка сходимости:

$$f\left(\frac{1}{K} \sum_{k=0}^{K-1} x^k\right) - f^* \leq \frac{\|x^0 - x^*\|_2^2}{2\gamma K} + \frac{\gamma M^2}{2}.$$

Доказательство. Начнем с рассмотрения квадрата нормы $\|x^{k+1} - x^*\|_2^2$. Подставим формулу обновления

$$x^{k+1} = x^k - \gamma g^k,$$

после чего раскроем квадрат нормы:

$$\begin{aligned} \|x^{k+1} - x^*\|_2^2 &= \|x^k - \gamma g^k - x^*\|_2^2 \\ &= \|x^k - x^*\|_2^2 - 2\gamma \langle g^k, x^k - x^* \rangle + \gamma^2 \|g^k\|_2^2. \end{aligned}$$

Из M -липшицевости f следует, что норма субградиента g^k ограничена M (Теорема Л8.2):

$$\|x^{k+1} - x^*\|_2^2 \leq \|x^k - x^*\|_2^2 - 2\gamma \langle g^k, x^k - x^* \rangle + \gamma^2 M^2.$$

Из определения субградиента (Определение Л8.3) оценим скалярное произведение:

$$\|x^{k+1} - x^*\|_2^2 \leq \|x^k - x^*\|_2^2 - 2\gamma (f(x^k) - f^*) + \gamma^2 M^2.$$

Перенесем разность значений функции f влево, а норму вправо:

$$2\gamma (f(x^k) - f^*) \leq \|x^k - x^*\|_2^2 - \|x^{k+1} - x^*\|_2^2 + \gamma^2 M^2.$$

Просуммируем по всем k от 0 до $K-1$:

$$2\gamma \sum_{k=0}^{K-1} (f(x^k) - f^*) \leq \sum_{k=0}^{K-1} (\|x^k - x^*\|_2^2 - \|x^{k+1} - x^*\|_2^2 + \gamma^2 M^2).$$

Раскроем телескопическую сумму справа, из которой остается только два слагаемых с нормой, а также разделим на $2\gamma K$:

$$\frac{1}{K} \sum_{k=0}^{K-1} (f(x^k) - f^*) \leq \frac{\|x^0 - x^*\|_2^2 - \|x^K - x^*\|_2^2}{2\gamma K} + \frac{\gamma M^2}{2}.$$

Можно откинуть неположительное $-\frac{\|x^K - x^*\|_2^2}{2\gamma K}$ в правой части, а также воспользоваться выпуклостью функции f (Определение Л8.1) в левой:

$$f\left(\frac{1}{K} \sum_{k=0}^{K-1} x^k\right) - f^* \leq \frac{1}{K} \sum_{k=0}^{K-1} (f(x^k) - f^*) \leq \frac{\|x^0 - x^*\|_2^2}{2\gamma K} + \frac{\gamma M^2}{2}.$$

■

Утверждение Л8.1. Пусть задача удовлетворяет условиям Теоремы Л8.3 и выбрано значение шага $\gamma_k = \frac{\|x^0 - x^*\|_2}{M\sqrt{K}}$. Тогда справедлива следующая оценка сходимости:

$$f\left(\frac{1}{K} \sum_{k=0}^{K-1} x^k\right) - f^* \leq \frac{M\|x^0 - x^*\|_2}{\sqrt{K}}.$$

Более того, чтобы добиться точности ε по функции $(f(\frac{1}{K} \sum_{k=0}^{K-1} x^k) - f^* \leq \varepsilon)$, необходимо

$$K = \mathcal{O}\left(\frac{M^2\|x^0 - x^*\|_2^2}{\varepsilon^2}\right) \text{ итераций.}$$

Доказательство. Запишем оценку сходимости из Теоремы Л8.3:

$$f\left(\frac{1}{K} \sum_{k=0}^{K-1} x^k\right) - f^* \leq \frac{\|x^0 - x^*\|_2^2}{2\gamma K} + \frac{\gamma M^2}{2}. \quad (\text{Л8.2})$$

Минимизируя правую часть оценки по $\gamma > 0$, находим оптимальное значение шага

$$\gamma^* = \frac{\|x^0 - x^*\|_2}{M\sqrt{K}}.$$

Подставим его в (Л8.2) и получим:

$$f\left(\frac{1}{K} \sum_{k=0}^{K-1} x^k\right) - f^* \leq \frac{M \|x^0 - x^*\|_2}{\sqrt{K}}.$$

Теперь потребуем точность ε по функции, ограничив правую часть неравенства:

$$\frac{M \|x^0 - x^*\|_2}{\sqrt{K}} \leq \varepsilon.$$

Решая это неравенство относительно K , приходим к

$$K \geq \left(\frac{M \|x^0 - x^*\|_2}{\varepsilon} \right)^2,$$

что и даёт заявленную оценку на число итераций. ■

Субградиентный метод является обобщением градиентного спуска на негладкие задачи. Его сходимость оказывается медленнее, чем у градиентного спуска. В общем случае результат для субградиентного метода является неулучшаемым для выпуклых и сильно выпуклых задач, то есть он оптимален.

Л8.3 Адаптивные методы

В полученной оценке для субградиентного метода шаг выбирается равным

$$\gamma = \frac{\|x^0 - x^*\|_2}{M\sqrt{K}}.$$

Однако такая формула требует знания заранее числа итераций K , константы Липшица M и расстояния $\|x^0 - x^*\|_2$ до решения. На практике эти параметры обычно неизвестны, и их использование существенно ограничивает применимость метода. Возникает естественный вопрос: как построить выбор шага, который не требует этих величин, но при этом сохраняет их смысл и обеспечивает аналогичное поведение алгоритма?

Л8.3.1 AdaGradNorm

Первым шагом можно избавиться от необходимости знать константу Липшица M . Согласно Теореме Л8.2 имеем неравенство:

$$\|g\|_2 \leq M$$

для всех $g \in \partial f(x)$ во всех точках $x \in \mathbb{R}^d$. Отсюда можно оценить

$$M \sim \|g\|_2.$$

Однако этого недостаточно: в оптимальном значении шага в знаменателе стоит $M\sqrt{K}$. Тогда мы можем брать норму не одного субградиента в какой-то точке, а суммировать по всем предыдущим:

$$M\sqrt{K} \sim \sqrt{\sum_{t=0}^{K-1} \|g^t\|_2^2}.$$

Неизвестным остается только расстояние до решения $\|x^0 - x^*\|_2$. Его можно оценить лишь какой-то константой D , на практике часто подбираемой эмпирически:

$$\|x^0 - x^*\|_2 \leq D.$$

Замечание Л8.3. Условие $\|x^0 - x^*\|_2 \leq D$ выглядит менее искусственным, если мы знаем, что решение x^* лежит в некотором ограниченном множестве $\mathcal{X}$. Тогда константу D можно оценить как диаметр множества:

$$D = \sup_{x, y \in \mathcal{X}} \|x - y\|_2.$$

Собирая все вместе, имеем шаг

$$\gamma_k = \frac{D}{\sqrt{\sum_{t=0}^k \|g^t\|_2^2 + \varepsilon}},$$

где для вычислительной устойчивости в знаменатель была добавлена константа ε , обычно выбирающаяся достаточно малой.

Таким образом шаг автоматически уменьшается по мере роста накопленной нормы градиента, и метод работает без знания M и K . Метод с таким адаптивным подбором шага называется AdaGradNorm [27].

Алгоритм Л8.2 AdaGradNorm

Вход: стартовая точка $x^0 \in \mathbb{R}^d$, сумма квадратов норм субградиентов $G^{-1} = 0$, параметры $\varepsilon \sim 10^{-8}$, $D > 0$, количество итераций K

- 1: **for** $k = 0, 1, \dots, K - 1$ **do**
- 2: Вычислить $g^k \in \partial f(x^k)$
- 3: $G^k = G^{k-1} + \|g^k\|_2^2$
- 4: $x^{k+1} = x^k - \frac{D}{\sqrt{G^k + \varepsilon}} g^k$
- 5: **end for**

Выход: $\frac{1}{K} \sum_{k=0}^{K-1} x^k$

Л8.3.2 DoG: Distance over Gradients

В методе AdaGradNorm шаг имеет вид

$$\gamma_k = \frac{D}{\sqrt{\sum_{t=0}^k \|g^t\|_2^2 + \varepsilon}},$$

где $D = \|x^0 - x^*\|_2$ остаётся неизвестным параметром. Для его замены предлагается использовать наблюдаемую величину

$$d_k = \max_{0 \leq t \leq k} \|x^t - x^0\|_2,$$

которая служит естественной оценкой D по траектории метода. В самом деле, мы заменили оценку на диаметр множества максимальным расстоянием, на которое удалялись от стартовой точки.

Подставляя эту оценку вместо D , получаем метод без гиперпараметров.

Алгоритм Л8.3 DoG (Distance over Gradients)

Вход: стартовая точка $x^0 \in \mathbb{R}^d$, сумма квадратов норм субградиентов $G^{-1} = 0$, оценка диаметра $d_{-1} > 0$, параметр $\varepsilon \sim 10^{-8}$, количество итераций K

- 1: **for** $k = 0, 1, \dots, K - 1$ **do**
- 2: Вычислить $g^k \in \partial f(x^k)$
- 3: $G^k = G^{k-1} + \|g^k\|_2^2$
- 4: $d_k = \max(d_{k-1}, \|x^k - x^0\|_2)$
- 5: $x^{k+1} = x^k - \frac{d^k}{\sqrt{G^k + \varepsilon}} g^k$
- 6: **end for**

Выход: $\frac{1}{K} \sum_{k=0}^{K-1} x^k$

Л8.3.3 AdaGrad

Следующий шаг — учесть неоднородность по координатам. Тогда оптимальный шаг для каждой i -ой компоненты зависит от своей константы Липшица M_i и своего расстояния $|x_i^0 - x_i^*|$. Вместо глобального масштаба можно адаптивно накапливать информацию о каждом направлении:

$$M_i \sqrt{K} \sim \sqrt{\sum_{t=0}^{K-1} (g_i^t)^2},$$

а также оценивать расстояние до решения по каждой координате:

$$|x_i^0 - x_i^*| \leq D_i.$$

Тогда шаг для каждой координаты берётся как

$$\gamma_{k,i} = \frac{D_i}{\sqrt{\sum_{t=0}^k (g_i^t)^2 + \varepsilon}}.$$

Такой метод учитывает частоту и величину обновлений в каждой компоненте и особенно эффективен при разреженных признаках. Этот алгоритм получил название AdaGrad [8].

Алгоритм Л8.4 AdaGrad

Вход: стартовая точка $x^0 \in \mathbb{R}^d$, суммы квадратов норм субградиентов $G_i^{-1} = 0$, параметры $\varepsilon \sim 10^{-8}$, $D_i > 0$, количество итераций K

- 1: **for** $k = 0, 1, \dots, K - 1$ **do**
- 2: Вычислить $g^k \in \partial f(x^k)$
- 3: $G_i^k = G_i^{k-1} + (g_i^k)^2$
- 4: $x_i^{k+1} = x_i^k - \frac{D_i}{\sqrt{G_i^k + \varepsilon}} g_i^k$
- 5: **end for**

Выход: $\frac{1}{K} \sum_{k=0}^{K-1} x^k$

Для алгоритма сформулируем и докажем теорему о сходимости.

Теорема Л8.4. Пусть задача оптимизации (Л8.1) с M -липшицевой выпуклой целевой функцией f решается с помощью AdaGrad (Алгоритм Л8.4). Тогда справедлива следующая оценка сходимости:

$$f\left(\frac{1}{K} \sum_{k=0}^{K-1} x^k\right) - f^* \leq \frac{3M\tilde{D}}{2\sqrt{K}},$$

где $\tilde{D} = \sum_{i=1}^d D_i$, $|x_i^k - x_i^*| \leq D_i$ для любых $i = \overline{1, d}$ и любых $k = \overline{0, K-1}$.

Более того, чтобы добиться точности ε по функции ($f(x^K) - f^* \leq \varepsilon$), необходимо

$$K = \mathcal{O}\left(\frac{M^2 \tilde{D}^2}{\varepsilon^2}\right) \text{ итераций.}$$

Доказательство. Начнем с квадрата ошибки по i -ой координате $(x_i^{k+1} - x_i^*)^2$. Подставим итерацию метода:

$$\begin{aligned} (x_i^{k+1} - x_i^*)^2 &= (x_i^k - \gamma_{k,i} g_i^k - x_i^*)^2 \\ &= (x_i^k - x_i^*)^2 - 2\gamma_{k,i} g_i^k (x_i^k - x_i^*) + \gamma_{k,i}^2 (g_i^k)^2. \end{aligned}$$

Откуда выражаем перекрестное слагаемое:

$$g_i^k (x_i^k - x_i^*) = \frac{1}{2\gamma_{k,i}} (x_i^k - x_i^*)^2 - \frac{1}{2\gamma_{k,i}} (x_i^{k+1} - x_i^*)^2 + \frac{\gamma_{k,i}}{2} (g_i^k)^2.$$

Собираем скалярное произведение, суммируя по всем координатам i от 1 до d :

$$\langle g^k, x^k - x^* \rangle = \frac{1}{2} \sum_{i=1}^d \left[\frac{1}{\gamma_{k,i}} (x_i^k - x_i^*)^2 - \frac{1}{\gamma_{k,i}} (x_i^{k+1} - x_i^*)^2 + \gamma_{k,i} (g_i^k)^2 \right].$$

Оцениваем левую часть, пользуясь определением субградиента (Определение Л8.3):

$$f(x^k) - f^* \leq \frac{1}{2} \sum_{i=1}^d \left[\frac{1}{\gamma_{k,i}} (x_i^k - x_i^*)^2 - \frac{1}{\gamma_{k,i}} (x_i^{k+1} - x_i^*)^2 + \gamma_{k,i} (g_i^k)^2 \right].$$

Суммируем по всем k от 0 до $K-1$ и усредняем, а также меняем порядок суммирования:

$$\begin{aligned} \frac{1}{K} \sum_{k=0}^{K-1} (f(x^k) - f^*) &\leq \frac{1}{2K} \sum_{k=0}^{K-1} \sum_{i=1}^d \left[\frac{1}{\gamma_{k,i}} (x_i^k - x_i^*)^2 - \frac{1}{\gamma_{k,i}} (x_i^{k+1} - x_i^*)^2 + \gamma_{k,i} (g_i^k)^2 \right] \\ &= \frac{1}{2K} \sum_{i=1}^d \sum_{k=0}^{K-1} \left[\frac{1}{\gamma_{k,i}} (x_i^k - x_i^*)^2 - \frac{1}{\gamma_{k,i}} (x_i^{k+1} - x_i^*)^2 + \gamma_{k,i} (g_i^k)^2 \right]. \end{aligned}$$

Следующим шагом будет приведение подобных слагаемых. Для этого сдвинем индекс суммирования k и аккуратно поработаем с крайними слагаемыми. Для удобства по-

ложим $\gamma_{-1,i} = +\infty$ и преобразуем:

$$\begin{aligned}
\frac{1}{K} \sum_{k=0}^{K-1} (f(x^k) - f^*) &\leq \frac{1}{2K} \sum_{i=1}^d \sum_{k=0}^{K-1} \left[\frac{1}{\gamma_{k,i}} (x_i^k - x_i^*)^2 + \gamma_{k,i} (g_i^k)^2 \right] \\
&\quad - \frac{1}{2K} \sum_{i=1}^d \sum_{k=0}^{K-1} \left[\frac{1}{\gamma_{k,i}} (x_i^{k+1} - x_i^*)^2 \right] \\
&= \frac{1}{2K} \sum_{i=1}^d \sum_{k=0}^{K-1} \left[\frac{1}{\gamma_{k,i}} (x_i^k - x_i^*)^2 + \gamma_{k,i} (g_i^k)^2 \right] \\
&\quad - \frac{1}{2K} \sum_{i=1}^d \sum_{k=0}^{K-1} \left[\frac{1}{\gamma_{k-1,i}} (x_i^k - x_i^*)^2 \right] - \frac{1}{2K} \sum_{i=1}^d \frac{1}{\gamma_{K-1,i}} (x_i^K - x_i^*)^2 \\
&\leq \frac{1}{2K} \sum_{i=1}^d \sum_{k=0}^{K-1} \left[\left(\frac{1}{\gamma_{k,i}} - \frac{1}{\gamma_{k-1,i}} \right) (x_i^k - x_i^*)^2 + \gamma_{k,i} (g_i^k)^2 \right].
\end{aligned}$$

В последнем переходе мы откинули неположительное слагаемое. Теперь воспользуемся константами $D_i : (x_i^k - x_i^*)^2 \leq D_i^2$:

$$\frac{1}{K} \sum_{k=0}^{K-1} (f(x^k) - f^*) \leq \frac{1}{2K} \sum_{i=1}^d \sum_{k=0}^{K-1} \left[\left(\frac{1}{\gamma_{k,i}} - \frac{1}{\gamma_{k-1,i}} \right) D_i^2 + \gamma_{k,i} (g_i^k)^2 \right].$$

Подставляем $\gamma_{k,i} = \frac{D_i}{\sqrt{\sum_{t=0}^k (g_i^t)^2}}$ и сворачиваем телескопическую сумму по k :

$$\begin{aligned}
\frac{1}{K} \sum_{k=0}^{K-1} (f(x^k) - f^*) &\leq \frac{1}{2K} \sum_{i=1}^d \sum_{k=0}^{K-1} \left[\left(\sqrt{\sum_{t=0}^k (g_i^t)^2} - \sqrt{\sum_{t=0}^{k-1} (g_i^t)^2} \right) D_i + \frac{D_i (g_i^k)^2}{\sqrt{\sum_{t=0}^k (g_i^t)^2}} \right] \\
&= \frac{1}{2K} \sum_{i=1}^d D_i \left[\sqrt{\sum_{t=0}^{K-1} (g_i^t)^2} + \sum_{k=0}^{K-1} \frac{(g_i^k)^2}{\sqrt{\sum_{t=0}^k (g_i^t)^2}} \right].
\end{aligned}$$

Воспользуемся техническим фактом, который говорит, что для любых неотрицательных чисел $\{a_k\} \geq 0$ выполнено:

$$\sum_{k=0}^{K-1} \frac{a_k^2}{\sqrt{\sum_{t=0}^k a_t^2}} \leq 2 \sqrt{\sum_{k=0}^{K-1} a_k^2}.$$

Применяем его для второго слагаемого в сумме, получаем:

$$\frac{1}{K} \sum_{k=0}^{K-1} (f(x^k) - f^*) \leq \frac{3}{2K} \sum_{i=1}^d D_i \sqrt{\sum_{t=0}^{K-1} (g_i^t)^2}.$$

Из неизвестных значений в правой части остается только $\sum_{t=0}^{K-1} (g_i^t)^2$. Оценим её с помощью свойства M -липшицевых функций (Теорема Л8.2):

$$\sum_{t=0}^{K-1} (g_i^t)^2 \leq \sum_{t=0}^{K-1} \|g^t\|_2^2 \leq KM^2.$$

Подставляем в основное неравенство:

$$\frac{1}{K} \sum_{k=0}^{K-1} (f(x^k) - f^*) \leq \frac{3}{2K} \sum_{i=1}^d D_i \sqrt{KM^2} = \frac{3M}{2\sqrt{K}} \sum_{i=1}^d D_i = \frac{3M\tilde{D}}{2\sqrt{K}}.$$

Чтобы получить оценку из условия, остается применить определение выпуклости функции (Определение Л8.1):

$$f\left(\frac{1}{K} \sum_{k=0}^{K-1} x^k\right) - f^* \leq \frac{3M\tilde{D}}{2\sqrt{K}}.$$

Чтобы получить оценку на количество итераций для достижения точности ε по функции $(f(\frac{1}{K} \sum_{k=0}^{K-1} x^k) - f^* \leq \varepsilon)$, ограничим правую часть:

$$\frac{3M\tilde{D}}{2\sqrt{K}} \leq \varepsilon.$$

Откуда и получаем:

$$K \geq \frac{9M^2\tilde{D}^2}{4\varepsilon^2}.$$

■

Замечание Л8.4. Константы D_i могут выглядеть немного искусственными, однако, их можно обосновать. Например, когда нам известно, что решение x^* лежит в ограниченном множестве $\mathcal{X}$, а стартовая и все последующие точки также лежат внутри этого множества.

Замечание Л8.5. Константы D_i можно также оценивать динамически. В частности, можно использовать идею DoG, адаптированную под координатную запись:

$$d_{k,i} = \max_{0 \leq t \leq k} |x_i^t - x_i^0|.$$

Л8.3.4 RMSProp

У AdaGrad знаменатель монотонно растёт, и шаг со временем может становиться слишком малым. Чтобы избежать затухания шага, вместо суммы используют экспоненциальное скользящее среднее квадратов градиентов:

$$G_i^k = \beta G_i^{k-1} + (1 - \beta)(g_i^k)^2,$$

где моментум $\beta \in [0, 1]$ выбирается порядка ~ 0.99 . Такой приём позволяет учитывать преимущественно недавнюю историю и адаптироваться к меняющейся геометрии задачи. Метод получил название RMSProp [26].

Алгоритм Л8.5 RMSProp

Вход: стартовая точка $x^0 \in \mathbb{R}^d$, сглаженные суммы квадратов норм субградиентов $G_i^{-1} = 0$, параметры $\varepsilon \sim 10^{-8}$, $D_i > 0$, $\beta \in [0, 1]$, количество итераций K

- 1: **for** $k = 0, 1, \dots, K - 1$ **do**
 - 2: Вычислить $g^k \in \partial f(x^k)$
 - 3: $G_i^k = \beta G_i^{k-1} + (1 - \beta)(g_i^k)^2$
 - 4: $x_i^{k+1} = x_i^k - \frac{D_i}{\sqrt{G_i^k + \varepsilon}} g_i^k$
 - 5: **end for**
- Выход:** $\frac{1}{K} \sum_{k=0}^{K-1} x^k$
-

Л8.3.5 Adam

Алгоритм Adam объединяет идеи RMSProp и момента. Помимо экспоненциального сглаживания квадратов градиентов, он усредняет сами градиенты:

$$\begin{aligned}v^k &= \beta_1 v^{k-1} + (1 - \beta_1) g^k, \\G_i^k &= \beta_2 G_i^{k-1} + (1 - \beta_2) (g_i^k)^2,\end{aligned}$$

где два моментума $\beta_1, \beta_2 \in [0, 1]$, обычно выбираются 0.9 и 0.999 соответственно. Чтобы устранить смещение на ранних итерациях, вводится коррекция:

$$\begin{aligned}\hat{v}^k &= \frac{v^k}{1 - \beta_1^{k+1}}, \\ \hat{G}^k &= \frac{G^k}{1 - \beta_2^{k+1}}.\end{aligned}$$

В итоге шаг получается

$$x_i^{k+1} = x_i^k - \frac{D_i}{\sqrt{\hat{G}_i^k} + \varepsilon} \hat{v}_i^k.$$

Такой метод даёт устойчивые шаги при шумных и разреженных градиентах и требует минимальной настройки гиперпараметров [10].

Алгоритм Л8.6 Adam

Вход: стартовая точка $x^0 \in \mathbb{R}^d$, сглаженные суммы квадратов норм субградиентов $G^{-1} = 0$, сглаженные суммы субградиентов $v^{-1} = 0$, параметры $\beta_1, \beta_2 \in [0, 1]$, $\varepsilon \sim 10^{-8}$, $D_i > 0$, количество итераций K

- 1: **for** $k = 0, 1, \dots, K - 1$ **do**
- 2: Вычислить $g^k \in \partial f(x^k)$
- 3: $v^k = \beta_1 v^{k-1} + (1 - \beta_1) g^k$
- 4: $\hat{v}^k = v^k / (1 - \beta_1^{k+1})$
- 5: $G_i^k = \beta_2 G_i^{k-1} + (1 - \beta_2) (g_i^k)^2$
- 6: $\hat{G}^k = G^k / (1 - \beta_2^{k+1})$
- 7: $x_i^{k+1} = x_i^k - \frac{D_i}{\sqrt{\hat{G}_i^k} + \varepsilon} \hat{v}_i^k$

8: **end for**

Выход: $\frac{1}{K} \sum_{k=0}^{K-1} x^k$

Л8.3.6 NAdam

Вариант NAdam сочетает Adam с идеей ускорения Нестерова. То есть, сначала делаем шаг по инерции, потом вычисляем субградиент и делаем шаг вдоль него [7].

Алгоритм Л8.7 NAdam

Вход: стартовая точка $x^0 \in \mathbb{R}^d$, сглаженные суммы квадратов норм субградиентов $G_i^{-1} = 0$, сглаженные суммы субградиентов $v^{-1} = 0$, параметры $\beta_1, \beta_2 \in [0, 1]$, $\varepsilon \sim 10^{-8}$, $D_i > 0$, количество итераций K

- 1: **for** $k = 0, 1, \dots, K - 1$ **do**
- 2: Вычислить $g^k \in \partial f(x^k)$
- 3: $v^k = \beta_1 v^{k-1} + (1 - \beta_1)g^k$
- 4: $\hat{v}^k = v^k / (1 - \beta_1^{k+1})$
- 5: $G_i^k = \beta_2 G_i^{k-1} + (1 - \beta_2)(g_i^k)^2$
- 6: $\hat{G}^k = G^k / (1 - \beta_2^{k+1})$
- 7: $m^k = \beta_1 \hat{v}^k + \frac{1 - \beta_1}{1 - \beta_1^{k+1}} g^k$
- 8: $x_i^{k+1} = x_i^k - \frac{D_i}{\sqrt{\hat{G}_i^k + \varepsilon}} m_i^k$
- 9: **end for**

Выход: $\frac{1}{K} \sum_{k=0}^{K-1} x^k$

Л8.3.7 AdamW

В классическом Adam если применяется ℓ_2 -регуляризация, то градиент от слагаемого $\frac{\lambda}{2} \|x\|_2^2$ добавляется в общий градиент и масштабируется адаптивным шагом, что делает её неэквивалентной классической регуляризации. AdamW отделяет регуляризацию: стягивание весов $-\lambda x^k$ добавляется отдельно от градиентного обновления. Это позволяет контролировать регуляризацию независимо от величины шага и улучшает обобщающую способность моделей [15].

Алгоритм Л8.8 AdamW

Вход: стартовая точка $x^0 \in \mathbb{R}^d$, сглаженные суммы квадратов норм субградиентов $G_i^{-1} = 0$, сглаженные суммы субградиентов $v^{-1} = 0$, параметры $\beta_1, \beta_2 \in [0, 1]$, $\lambda > 0$, $\varepsilon \sim 10^{-8}$, $D_i > 0$, количество итераций K

- 1: **for** $k = 0, 1, \dots, K - 1$ **do**
- 2: Вычислить $g^k \in \partial f(x^k)$
- 3: $v^k = \beta_1 v^{k-1} + (1 - \beta_1)g^k$
- 4: $\hat{v}^k = v^k / (1 - \beta_1^{k+1})$
- 5: $G_i^k = \beta_2 G_i^{k-1} + (1 - \beta_2)(g_i^k)^2$
- 6: $\hat{G}^k = G^k / (1 - \beta_2^{k+1})$
- 7: $x_i^{k+1} = x_i^k - \frac{D_i}{\sqrt{\hat{G}_i^k + \varepsilon}} \hat{v}_i^k - \lambda x_i^k$
- 8: **end for**

Выход: $\frac{1}{K} \sum_{k=0}^{K-1} x^k$

Л8.4 Проксимальный оператор

Негладкие задачи «более сложные» по сравнению с гладкими задачами. Но отсутствие гладкости может получиться «спрятать под ковер» с помощью проксимального оператора.

Определение Л8.4. Для функции $r : \mathbb{R}^d \rightarrow \mathbb{R} \cup \{+\infty\}$ проксимальный оператор

определяется следующим образом:

$$\text{prox}_r(x) = \underset{\tilde{x} \in \mathbb{R}^d}{\operatorname{argmin}} \left(r(\tilde{x}) + \frac{1}{2} \|x - \tilde{x}\|_2^2 \right).$$

Пока что мы не потребовали ничего от функции r и мало что можем сказать про проксимальный оператор. Оказывается, что если наложить на r условие выпуклости, то проксимальный оператор для нее становится однозначно определённым.

Утверждение Л8.2. Пусть $r : \mathbb{R}^d \rightarrow \mathbb{R} \cup \{+\infty\}$ — выпуклая функция. Если существует $\hat{x} \in \mathbb{R}^d$ с $r(\hat{x}) < +\infty$, то проксимальный оператор однозначно определен.

Доказательство. Проксимальный оператор возвращает минимум некоторой задачи оптимизации. Задача сильно выпуклая, так как целевая функция — это сумма выпуклой и сильно выпуклой функции. А значит существует строго один минимум (Теорема Л2.3). А существование $\hat{x}$ необходимо для того, чтобы $r(\tilde{x}) + \frac{1}{2} \|x - \tilde{x}\|_2^2$ хотя бы где-то принимала конечное значение. ■

Л8.4.1 Примеры проксимального оператора

Рассмотрим, какие операторы мы будем получать в зависимости от того, какую проксимальную функцию мы используем.

- **ℓ_1 -норма.**

Пусть $r(x) = \lambda \|x\|_1$, где $\lambda > 0$. Тогда

$$[\text{prox}_r(x)]_i = [|x_i| - \lambda]_+ \cdot \text{sign}(x_i),$$

что известно как *оператор трешхолдинга*.

Доказательство. Рассмотрим задачу

$$\begin{aligned} \text{prox}_r(x) &= \underset{\tilde{x} \in \mathbb{R}^d}{\operatorname{argmin}} \left(\lambda \|\tilde{x}\|_1 + \frac{1}{2} \|x - \tilde{x}\|_2^2 \right) \\ &= \underset{\tilde{x} \in \mathbb{R}^d}{\operatorname{argmin}} \sum_{i=1}^d \left(\frac{1}{2} (\tilde{x}_i - x_i)^2 + \lambda |\tilde{x}_i| \right). \end{aligned}$$

Задача распадается по координатам. Для каждой координаты условие оптимальности имеет вид

$$0 \in \tilde{x}_i^* - x_i + \lambda \cdot \partial |\tilde{x}_i^*|,$$

что приводит к правилу софт-трешхолдинга:

$$\tilde{x}_i^* = [|x_i| - \lambda]_+ \cdot \text{sign}(x_i).$$

- **ℓ_2 -норма.**

Пусть $r(x) = \frac{\lambda}{2} \|x\|_2^2$, где $\lambda > 0$. Тогда

$$\text{prox}_r(x) = \frac{x}{1 + \lambda}.$$

Доказательство. Рассмотрим

$$\text{prox}_r(x) = \underset{\tilde{x} \in \mathbb{R}^d}{\operatorname{argmin}} \left(\frac{\lambda}{2} \|\tilde{x}\|_2^2 + \frac{1}{2} \|x - \tilde{x}\|_2^2 \right).$$

Необходимое условие минимума (Теорема Л2.2):

$$\lambda \tilde{x}^* + \tilde{x}^* - x = 0.$$

Откуда и получаем решение:

$$\tilde{x}^* = \frac{x}{1 + \lambda}.$$

■

• **Индикатор множества.**

Пусть $r(x) = \mathbb{I}_{\mathcal{X}}(x)$ для замкнутого множества $\mathcal{X} \subseteq \mathbb{R}^d$, где

$$\mathbb{I}_{\mathcal{X}}(x) = \begin{cases} 0, & x \in \mathcal{X}, \\ +\infty, & x \notin \mathcal{X}. \end{cases}$$

Тогда

$$\text{prox}_r(x) = \underset{\tilde{x} \in \mathcal{X}}{\operatorname{argmin}} \frac{1}{2} \|x - \tilde{x}\|_2^2.$$

Смысл такого оператора в том, что он возвращает ближайшую к x точку из множества $\mathcal{X}$.

Доказательство. Имеем

$$\begin{aligned} \text{prox}_r(x) &= \underset{\tilde{x} \in \mathbb{R}^d}{\operatorname{argmin}} \left(\mathbb{I}_{\mathcal{X}}(\tilde{x}) + \frac{1}{2} \|x - \tilde{x}\|_2^2 \right) \\ &= \underset{\tilde{x} \in \mathcal{X}}{\operatorname{argmin}} \frac{1}{2} \|x - \tilde{x}\|_2^2. \end{aligned}$$

■

Л8.4.2 Свойства проксимального оператора

Для последующего теоретического анализа алгоритмов на основе проксимального оператора, докажем полезные свойства.

Утверждение Л8.3. Пусть $r : \mathbb{R}^d \rightarrow \mathbb{R} \cup \{+\infty\}$ — выпуклая функция. Тогда для любых $x, y \in \mathbb{R}^d$ следующие три условия являются эквивалентными:

1. $\text{prox}_r(x) = y$,
2. $x - y \in \partial r(y)$,
3. $\langle x - y, z - y \rangle \leq r(z) - r(y)$ для любого $z \in \mathbb{R}^d$.

Доказательство. Запишем первое условие по определению проксимального оператора (Определение Л8.4):

$$y = \operatorname{argmin}_{\tilde{x} \in \mathbb{R}^d} \left(r(\tilde{x}) + \frac{1}{2} \|x - \tilde{x}\|_2^2 \right).$$

Из условия оптимальности для выпуклой функции r (Теорема Л8.1) это эквивалентно

$$0 \in \partial \left(r(\tilde{x}) + \frac{1}{2} \|x - \tilde{x}\|_2^2 \right) \Big|_{\tilde{x}=y} = \partial r(y) + y - x.$$

Получили эквивалентность первого и второго условий.

Теперь свяжем второе и третье. Из определения субдифференциала (Определение Л8.3), для любого субградиента $g \in \partial f(y)$ и для любого $z \in \mathbb{R}^d$:

$$\langle g, z - y \rangle \leq r(z) - r(y).$$

В частности справедливо и для $g = x - y \in \partial r(y)$ по предположению:

$$\langle x - y, z - y \rangle \leq r(z) - r(y).$$

Получили следствие из 2 в 3. Теперь в обратную сторону. Пусть выполняется соотношение 3:

$$\langle x - y, z - y \rangle \leq r(z) - r(y).$$

Но это же означает, что $x - y$ является субградиентом r в точке y , то есть, $g \in \partial r(y)$. ■

Этим свойством мы связали действие проксимального оператора и субградиент. Следующее утверждение позволит работать с действиями проксимального оператора под знаками скалярного произведения и норм.

Утверждение Л8.4. Пусть $r : \mathbb{R}^d \rightarrow \mathbb{R} \cup \{+\infty\}$ — выпуклая функция. Тогда для любых $x, y \in \mathbb{R}^d$ выполнено следующее:

- $\langle x - y, \operatorname{prox}_r(x) - \operatorname{prox}_r(y) \rangle \geq \|\operatorname{prox}_r(x) - \operatorname{prox}_r(y)\|_2^2,$
- $\|\operatorname{prox}_r(x) - \operatorname{prox}_r(y)\|_2 \leq \|x - y\|_2.$

Доказательство. Для удобства обозначим $u = \operatorname{prox}_r(x), v = \operatorname{prox}_r(y)$. Начнем с неравенства из Утверждения Л8.3. Запишем для троек точек (x, u, v) и (y, v, u) :

$$\langle x - u, v - u \rangle \leq r(v) - r(u),$$

$$\langle y - v, u - v \rangle \leq r(u) - r(v).$$

Сложим неравенства, справа получим 0:

$$\langle x - u - (y - v), v - u \rangle \leq 0.$$

Разнесем слагаемые в разные стороны:

$$\langle x - y, u - v \rangle \geq \|u - v\|_2^2.$$

Это и есть первое свойство. Из него логично вытекает и второе свойство. Достаточно лишь применить к неравенству выше неравенство Коши–Буняковского–Шварца (0.3):

$$\|u - v\|_2^2 \leq \langle x - y, u - v \rangle \leq \|x - y\|_2 \|u - v\|_2.$$

Случай $u = v$ тривиален и удовлетворяет неравенству, так что имеем:

$$\|u - v\|_2 \leq \|x - y\|_2.$$

■

Л8.4.3 Проксимальный градиентный метод

Настало время применить проксимальный оператор для построения метода оптимизации. Рассмотрим следующую задачу:

$$\min_{x \in \mathbb{R}^d} [f(x) + r(x)], \quad (\text{Л8.3})$$

где f является L -гладкой выпуклой функцией, а r — просто выпуклой. Она не обязана быть гладкой, но должна быть проксимально-дружественной, то есть, для нее должен считаться проксимальный оператор. Задача (Л8.3) называется *композиционной*. Вновь модифицируем градиентный спуск: добавим применение проксимального оператора $\text{prox}_{\gamma r}$ после градиентного шага $-\gamma_k \nabla f(x^k)$.

Алгоритм Л8.9 Проксимальный градиентный метод

Вход: стартовая точка $x^0 \in \mathbb{R}^d$, размеры шагов $\{\gamma_k\}_{k=0} > 0$, количество итераций K

1: **for** $k = 0, 1, \dots, K - 1$ **do**
 2: $x^{k+1} = \text{prox}_{\gamma_k r}(x^k - \gamma_k \nabla f(x^k))$
 3: **end for**

Выход: x^K

Покажем, какую физику несёт метод. Для этого воспользуемся результатами Утверждения Л8.3, тогда $x^{k+1} = \text{prox}_{\gamma_k r}(x^k - \gamma_k \nabla f(x^k))$ эквивалентно записи:

$$x^k - \gamma_k \nabla f(x^k) - x^{k+1} \in \gamma_k \partial r(x^{k+1}).$$

Или, если переписать в более привычном виде:

$$x^{k+1} \in x^k - \gamma_k (\nabla f(x^k) + \partial r(x^{k+1})).$$

Получили неявную запись метода, из которой видно, что мы делаем шаг вдоль $\nabla f(x^k) + g$, где $g \in \partial r(x^{k+1})$.

Утверждение Л8.5. Пусть $f : \mathbb{R}^d \rightarrow \mathbb{R} \cup \{+\infty\}$, $r : \mathbb{R}^d \rightarrow \mathbb{R} \cup \{+\infty\}$ — выпуклые функции. Тогда x^* — решение композиционной задачи оптимизации тогда и только тогда, когда для любого $\gamma > 0$ выполнено:

$$x^* = \text{prox}_{\gamma r}(x^* - \gamma \nabla f(x^*)).$$

Доказательство. Обратимся к Утверждению Л8.3. Согласно нему, выражение

$$x^* = \text{prox}_{\gamma r}(x^* - \gamma \nabla f(x^*))$$

эквивалентно записи:

$$x^* - \gamma \nabla f(x^*) - x^* \in \gamma \partial r(x^*).$$

Сокращаем на $\gamma > 0$ и получаем условие оптимальности:

$$0 \in \nabla f(x^*) + \partial r(x^*).$$

■

Теперь мы готовы доказывать теорему о скорости сходимости.

Теорема Л8.5. Пусть композитная задача оптимизации (Л8.3) с L -гладкой μ -сильно выпуклой целевой функцией f и выпуклой (необязательно гладкой) проксимально дружественной функцией r решается с помощью проксимального градиентного метода (Алгоритм Л8.9). Тогда при $\gamma_k \leq \frac{1}{L}$ справедлива следующая оценка сходимости:

$$\|x^K - x^*\|_2^2 \leq \left(\prod_{k=0}^{K-1} (1 - \mu\gamma_k) \right) \|x^0 - x^*\|_2^2.$$

Доказательство. Рассматриваем $\|x^{k+1} - x^*\|_2^2$. Подставим итерацию метода:

$$\|x^{k+1} - x^*\|_2^2 = \|\text{prox}_{\gamma_k r}(x^k - \gamma_k \nabla f(x^k)) - x^*\|_2^2.$$

Воспользуемся Утверждением Л8.5:

$$\|x^{k+1} - x^*\|_2^2 = \|\text{prox}_{\gamma_k r}(x^k - \gamma_k \nabla f(x^k)) - \text{prox}_{\gamma_k r}(x^* - \gamma_k \nabla f(x^*))\|_2^2.$$

А теперь применяем неравенство из Утверждения Л8.4:

$$\|x^{k+1} - x^*\|_2^2 \leq \|(x^k - \gamma_k \nabla f(x^k)) - (x^* - \gamma_k \nabla f(x^*))\|_2^2.$$

Раскрываем квадрат нормы:

$$\|x^{k+1} - x^*\|_2^2 \leq \|x^k - x^*\|_2^2 - 2\gamma_k \langle x^k - x^*, \nabla f(x^k) - \nabla f(x^*) \rangle + \gamma_k^2 \|\nabla f(x^k) - \nabla f(x^*)\|.$$

Оценим последнее слагаемое, используя свойство L -гладкой выпуклой f (неравенство (Л2.5) из Теоремы Л2.5):

$$\begin{aligned} \|x^{k+1} - x^*\|_2^2 &\leq \|x^k - x^*\|_2^2 - 2\gamma_k \langle x^k - x^*, \nabla f(x^k) - \nabla f(x^*) \rangle \\ &\quad + \gamma_k^2 L \langle \nabla f(x^k) - \nabla f(x^*), x^k - x^* \rangle \\ &= \|x^k - x^*\|_2^2 - \gamma_k (2 - \gamma_k L) \langle \nabla f(x^k) - \nabla f(x^*), x^k - x^* \rangle. \end{aligned}$$

Два раза запишем определение μ -сильной выпуклости f (Определение Л2.4):

$$\begin{aligned} f(x^k) &\geq f(x^*) + \langle \nabla f(x^*), x^k - x^* \rangle + \frac{\mu}{2} \|x^k - x^*\|_2^2, \\ f(x^*) &\geq f(x^k) + \langle \nabla f(x^k), x^* - x^k \rangle + \frac{\mu}{2} \|x^* - x^k\|_2^2. \end{aligned} \tag{Л8.4}$$

Сложим их и получим:

$$\langle \nabla f(x^k) - \nabla f(x^*), x^k - x^* \rangle \geq \mu \|x^k - x^*\|_2^2.$$

Подставляем в основное неравенство (Л8.4):

$$\begin{aligned} \|x^{k+1} - x^*\|_2^2 &\leq \|x^k - x^*\|_2^2 - \mu\gamma_k (2 - \gamma_k L) \|x^k - x^*\|_2^2 \\ &= (1 - \mu\gamma_k (2 - \gamma_k L)) \|x^k - x^*\|_2^2. \end{aligned}$$

Поскольку $\gamma_k \leq \frac{1}{L}$, то $2 - \gamma_k L > 1$. Продолжая цепочку неравенств, имеем:

$$\|x^{k+1} - x^*\|_2^2 \leq (1 - \mu\gamma_k) \|x^k - x^*\|_2^2.$$

Остается лишь развернуть рекурсию с K -ой итерации по нулевую:

$$\begin{aligned}
 \|x^K - x^*\|_2^2 &\leq (1 - \mu\gamma_{K-1}) \|x^{K-1} - x^*\|_2^2 \\
 &\leq (1 - \mu\gamma_{K-1})(1 - \mu\gamma_{K-2}) \|x^{K-2} - x^*\|_2^2 \\
 &\leq \dots \\
 &\leq \left(\prod_{k=0}^{K-1} (1 - \mu\gamma_k) \right) \|x^0 - x^*\|_2^2.
 \end{aligned}$$

■

Утверждение Л8.6. Пусть задача удовлетворяет условиям Теоремы Л8.5 и выбрано значение шага $\gamma_k = \frac{1}{L}$. Тогда справедлива следующая оценка сходимости:

$$\|x^K - x^*\|_2^2 \leq \left(1 - \frac{\mu}{L}\right)^K \|x^0 - x^*\|_2^2.$$

Более того, чтобы добиться точности ε по аргументу ($\|x^K - x^*\|_2 \leq \varepsilon$), необходимо

$$K = \mathcal{O}\left(\frac{L}{\mu} \log \frac{\|x^0 - x^*\|_2}{\varepsilon}\right) \text{ итераций.}$$

Доказательство. Повторяет доказательство Утверждения Л3.1. ■

Замечание Л8.6. Проксимальный градиентный спуск для композитной задачи с L -гладкой μ -сильно выпуклой функцией f и выпуклой проксимально-дружественной функцией g имеет такую же скорость сходимости, что и метод градиентного спуска для функции f (Теорема Л3.1). Свойства гладкости/негладкости g при этом не влияют.

Кажется, что положив $f \equiv 0$, с помощью такого метода можно решать любую негладкую задачу. Действительно, если разрешить приближенное вычисление проксимального оператора, то формально можно решать любую выпуклую негладкую задачу. Однако с теоретической точки зрения это не приводит к преимуществам по сравнению с субградиентным методом: для нахождения значения проксимального оператора приходится решать подзадачу, которая сама по себе требует использования дополнительного метода (например, того же субградиентного спуска).