

Метод Ньютона. Квазиньютоновские методы

Методы оптимизации

Александр Богданов

Московский физико-технический институт

1 апреля 2026



Задача поиска нуля

- Рассмотрим задачу поиска «корня» функции. Формально требуется для непрерывно дифференцируемой функции $\varphi : \mathbb{R} \rightarrow \mathbb{R}$ найти точку x^* , для которой верно

$$\varphi(x^*) = 0.$$

Задача поиска нуля

- Рассмотрим задачу поиска «корня» функции. Формально требуется для непрерывно дифференцируемой функции $\varphi : \mathbb{R} \rightarrow \mathbb{R}$ найти точку x^* , для которой верно

$$\varphi(x^*) = 0.$$

- Пусть мы находимся в точке x^0 и хотим найти такую поправку Δx , что $x^0 + \Delta x \approx x^*$.

Задача поиска нуля

- Рассмотрим задачу поиска «корня» функции. Формально требуется для непрерывно дифференцируемой функции $\varphi : \mathbb{R} \rightarrow \mathbb{R}$ найти точку x^* , для которой верно

$$\varphi(x^*) = 0.$$

- Пусть мы находимся в точке x^0 и хотим найти такую поправку Δx , что $x^0 + \Delta x \approx x^*$.
- Разложим φ по формуле Тейлора до первого порядка:

$$\varphi(x^0 + \Delta x) = \varphi(x^0) + \varphi'(x^0)\Delta x + o(\Delta x).$$

Задача поиска нуля

- Рассмотрим задачу поиска «корня» функции. Формально требуется для непрерывно дифференцируемой функции $\varphi : \mathbb{R} \rightarrow \mathbb{R}$ найти точку x^* , для которой верно

$$\varphi(x^*) = 0.$$

- Пусть мы находимся в точке x^0 и хотим найти такую поправку Δx , что $x^0 + \Delta x \approx x^*$.
- Разложим φ по формуле Тейлора до первого порядка:

$$\varphi(x^0 + \Delta x) = \varphi(x^0) + \varphi'(x^0)\Delta x + o(\Delta x).$$

- Поскольку $x^0 + \Delta x \approx x^*$, то:

$$\varphi(x^0 + \Delta x) \approx \varphi(x^*) = 0 \implies \varphi(x^0) + \varphi'(x^0)\Delta x \approx 0.$$

Задача поиска нуля

- Таким образом, $\Delta x \approx -\frac{\varphi(x^0)}{\varphi'(x^0)}.$

Задача поиска нуля

- Таким образом, $\Delta x \approx -\frac{\varphi(x^0)}{\varphi'(x^0)}$.
- Продолжая строить новые точки, получаем выражение для итерации метода, предложенного Ньютоном в 17-м веке:

$$x^{k+1} = x^k - \frac{\varphi(x^k)}{\varphi'(x^k)}.$$

Локальная сходимость

- **Вопрос:** какие есть вопросы к интуиции получения итерации метода Ньютона?

Локальная сходимость

- **Вопрос:** какие есть вопросы к интуиции получения итерации метода Ньютона? Важно, что x^0 из «хорошей окрестности» x^* .

Локальная сходимость

- **Вопрос:** какие есть вопросы к интуиции получения итерации метода Ньютона? Важно, что x^0 из «хорошей окрестности» x^* .
- Рассмотрим $\varphi(x) = \frac{x}{\sqrt{1+x^2}}$. **Вопрос:** какое решение?

Локальная сходимость

- **Вопрос:** какие есть вопросы к интуиции получения итерации метода Ньютона? Важно, что x^0 из «хорошей окрестности» x^* .
- Рассмотрим $\varphi(x) = \frac{x}{\sqrt{1+x^2}}$. **Вопрос:** какое решение? $x^* = 0$.

Локальная сходимость

- **Вопрос:** какие есть вопросы к интуиции получения итерации метода Ньютона? Важно, что x^0 из «хорошей окрестности» x^* .
- Рассмотрим $\varphi(x) = \frac{x}{\sqrt{1+x^2}}$. **Вопрос:** какое решение? $x^* = 0$.
- Производная: $\varphi'(x) = \frac{1}{(1+x^2)^{3/2}}$.

Локальная сходимость

- **Вопрос:** какие есть вопросы к интуиции получения итерации метода Ньютона? Важно, что x^0 из «хорошей окрестности» x^* .
- Рассмотрим $\varphi(x) = \frac{x}{\sqrt{1+x^2}}$. **Вопрос:** какое решение? $x^* = 0$.
- Производная: $\varphi'(x) = \frac{1}{(1+x^2)^{3/2}}$. Итерация метода Ньютона:

$$x^{k+1} = x^k - \frac{\varphi(x^k)}{\varphi'(x^k)} = -(x^k)^3.$$

Локальная сходимость

- **Вопрос:** какие есть вопросы к интуиции получения итерации метода Ньютона? Важно, что x^0 из «хорошей окрестности» x^* .
- Рассмотрим $\varphi(x) = \frac{x}{\sqrt{1+x^2}}$. **Вопрос:** какое решение? $x^* = 0$.
- Производная: $\varphi'(x) = \frac{1}{(1+x^2)^{3/2}}$. Итерация метода Ньютона:

$$x^{k+1} = x^k - \frac{\varphi(x^k)}{\varphi'(x^k)} = -(x^k)^3.$$

- **Вопрос:** что можем сказать о сходимости к решению?

Локальная сходимость

- **Вопрос:** какие есть вопросы к интуиции получения итерации метода Ньютона? Важно, что x^0 из «хорошей окрестности» x^* .
- Рассмотрим $\varphi(x) = \frac{x}{\sqrt{1+x^2}}$. **Вопрос:** какое решение? $x^* = 0$.
- Производная: $\varphi'(x) = \frac{1}{(1+x^2)^{3/2}}$. Итерация метода Ньютона:

$$x^{k+1} = x^k - \frac{\varphi(x^k)}{\varphi'(x^k)} = -(x^k)^3.$$

- **Вопрос:** что можем сказать о сходимости к решению?
 - $|x^0| < 1$ — метод сходится;

Локальная сходимость

- **Вопрос:** какие есть вопросы к интуиции получения итерации метода Ньютона? Важно, что x^0 из «хорошей окрестности» x^* .
- Рассмотрим $\varphi(x) = \frac{x}{\sqrt{1+x^2}}$. **Вопрос:** какое решение? $x^* = 0$.
- Производная: $\varphi'(x) = \frac{1}{(1+x^2)^{3/2}}$. Итерация метода Ньютона:

$$x^{k+1} = x^k - \frac{\varphi(x^k)}{\varphi'(x^k)} = -(x^k)^3.$$

- **Вопрос:** что можем сказать о сходимости к решению?
 - $|x^0| < 1$ — метод сходится;
 - $|x^0| = 1$ — метод колеблется в точках -1 и 1

Локальная сходимость

- **Вопрос:** какие есть вопросы к интуиции получения итерации метода Ньютона? Важно, что x^0 из «хорошей окрестности» x^* .
- Рассмотрим $\varphi(x) = \frac{x}{\sqrt{1+x^2}}$. **Вопрос:** какое решение? $x^* = 0$.
- Производная: $\varphi'(x) = \frac{1}{(1+x^2)^{3/2}}$. Итерация метода Ньютона:

$$x^{k+1} = x^k - \frac{\varphi(x^k)}{\varphi'(x^k)} = -(x^k)^3.$$

- **Вопрос:** что можем сказать о сходимости к решению?
 - $|x^0| < 1$ — метод сходится;
 - $|x^0| = 1$ — метод колеблется в точках -1 и 1
 - $|x^0| > 1$ — метод расходится.

Локальная сходимость

- **Вопрос:** какие есть вопросы к интуиции получения итерации метода Ньютона? Важно, что x^0 из «хорошей окрестности» x^* .
- Рассмотрим $\varphi(x) = \frac{x}{\sqrt{1+x^2}}$. **Вопрос:** какое решение? $x^* = 0$.
- Производная: $\varphi'(x) = \frac{1}{(1+x^2)^{3/2}}$. Итерация метода Ньютона:

$$x^{k+1} = x^k - \frac{\varphi(x^k)}{\varphi'(x^k)} = -(x^k)^3.$$

- **Вопрос:** что можем сказать о сходимости к решению?
 - $|x^0| < 1$ — метод сходится;
 - $|x^0| = 1$ — метод колеблется в точках -1 и 1
 - $|x^0| > 1$ — метод расходится.
- Метода Ньютона имеет локальную сходимость (только в окрестности решения).

Метод Ньютона

- Рассмотрим задачу безусловной оптимизации с выпуклой дважды непрерывно дифференцируемой целевой функцией:

$$\min_{x \in \mathbb{R}^d} f(x).$$

- **Вопрос:** для такой задачи мы тоже ищем 0, но чего?

Метод Ньютона

- Рассмотрим задачу безусловной оптимизации с выпуклой дважды непрерывно дифференцируемой целевой функцией:

$$\min_{x \in \mathbb{R}^d} f(x).$$

- **Вопрос:** для такой задачи мы тоже ищем 0, но чего? $\nabla f(x^*) = 0$.

Метод Ньютона

- Рассмотрим задачу безусловной оптимизации с выпуклой дважды непрерывно дифференцируемой целевой функцией:

$$\min_{x \in \mathbb{R}^d} f(x).$$

- Вопрос:** для такой задачи мы тоже ищем 0, но чего? $\nabla f(x^*) = 0$.
Откуда метод Ньютона:

Алгоритм Метод Ньютона

Вход: стартовая точка $x^0 \in \mathbb{R}^d$, количество итераций K

- for** $k = 0, 1, \dots, K - 1$ **do**
 - $x^{k+1} = x^k - (\nabla^2 f(x^k))^{-1} \nabla f(x^k)$
 - end for**
- Выход:** x^K
-

Метод Ньютона и градиентный спуск

- Градиентный спуск работает с линейной аппроксимацией в текущей точке, метод Ньютона — с квадратичной:

$$f(x) \approx f(x^k) + \langle \nabla f(x^k), x - x^k \rangle + \frac{1}{2} \langle \nabla^2 f(x^k) (x - x^k), x - x^k \rangle.$$

Метод Ньютона и градиентный спуск

- Градиентный спуск работает с линейной аппроксимацией в текущей точке, метод Ньютона — с квадратичной:

$$f(x) \approx f(x^k) + \langle \nabla f(x^k), x - x^k \rangle + \frac{1}{2} \langle \nabla^2 f(x^k)(x - x^k), x - x^k \rangle.$$

Построим x^{k+1} как точку, где зануляется градиент квадратичной аппроксимации:

$$\nabla f(x^k) + \nabla^2 f(x^k)(x - x^k) = 0.$$

Метод Ньютона и градиентный спуск

- Градиентный спуск работает с линейной аппроксимацией в текущей точке, метод Ньютона — с квадратичной:

$$f(x) \approx f(x^k) + \langle \nabla f(x^k), x - x^k \rangle + \frac{1}{2} \langle \nabla^2 f(x^k)(x - x^k), x - x^k \rangle.$$

Построим x^{k+1} как точку, где зануляется градиент квадратичной аппроксимации:

$$\nabla f(x^k) + \nabla^2 f(x^k)(x - x^k) = 0.$$

Тогда:

$$x^{k+1} = x^k - \left(\nabla^2 f(x^k) \right)^{-1} \nabla f(x^k).$$

Постановка задачи

- Стоимость итерации значительно возрастает (по сравнению с градиентным спуском) не только из-за гессиана, но и его обращения.

Постановка задачи

- Стоимость итерации значительно возрастает (по сравнению с градиентным спуском) не только из-за гессиана, но и его обращения. **Вопрос:** за сколько итераций метод Ньютона сойдется для квадратичной задачи с положительно определенной матрицей?

Постановка задачи

- Стоимость итерации значительно возрастает (по сравнению с градиентным спуском) не только из-за гессиана, но и его обращения. **Вопрос:** за сколько итераций метод Ньютона сойдется для квадратичной задачи с положительно определенной матрицей? за 1 (но дорогую).

Постановка задачи

- Стоимость итерации значительно возрастает (по сравнению с градиентным спуском) не только из-за гессиана, но и его обращения. **Вопрос:** за сколько итераций метод Ньютона сойдется для квадратичной задачи с положительно определенной матрицей? за 1 (но дорогую).
- То, что для квадратичной задачи метод Ньютона сходится за 1 итерацию, наталкивает на мысль о том, что при всех своих минусах (локальная сходимость, дороговизна итерации) ключевым плюсом является скорость сходимости.

Постановка задачи

- Стоимость итерации значительно возрастает (по сравнению с градиентным спуском) не только из-за гессиана, но и его обращения. **Вопрос:** за сколько итераций метод Ньютона сойдется для квадратичной задачи с положительно определенной матрицей? за 1 (но дорого).
- То, что для квадратичной задачи метод Ньютона сходится за 1 итерацию, наталкивает на мысль о том, что при всех своих минусах (локальная сходимость, дороговизна итерации) ключевым плюсом является скорость сходимости.
- Пусть целевая функция в задаче безусловной минимизации является дважды непрерывно дифференцируемой, μ -сильно выпуклой и имеет M -Липшицев гессиан, то есть для любых $x, y \in \mathbb{R}^d$ выполнено

$$\|\nabla^2 f(x) - \nabla^2 f(y)\|_2 \leq M\|x - y\|_2.$$

Сходимость

Утверждение

Пусть функция f имеет M -Липшицев гессиан. Введем обозначение

$$G_k = \nabla^2 f(x^k) - \int_0^1 \nabla^2 f\left(x^* + \tau(x^k - x^*)\right) d\tau.$$

Тогда справедлива оценка:

$$\|G_k\|_2 \leq \frac{M}{2} \|x^k - x^*\|_2.$$

Сходимость

$$\begin{aligned}\|G_k\|_2 &= \left\| \nabla^2 f(x^k) - \int_0^1 \nabla^2 f(x^* + \tau(x^k - x^*)) d\tau \right\|_2 \\&= \left\| \int_0^1 (\nabla^2 f(x^k) - \nabla^2 f(x^* + \tau(x^k - x^*))) d\tau \right\|_2 \\&\leq \int_0^1 \|\nabla^2 f(x^k) - \nabla^2 f(x^* + \tau(x^k - x^*))\|_2 d\tau \\&\leq \int_0^1 M(1 - \tau) \|x^k - x^*\|_2 d\tau \\&= M \|x^k - x^*\|_2 \int_0^1 (1 - \tau) d\tau = \frac{M}{2} \|x^k - x^*\|_2.\end{aligned}$$

Сходимость

Будем изучать, как меняется расстояние до решения:

$$x^{k+1} - x^* = x^k - \left(\nabla^2 f(x^k) \right)^{-1} \nabla f(x^k) - x^*.$$

Сходимость

Будем изучать, как меняется расстояние до решения:

$$x^{k+1} - x^* = x^k - \left(\nabla^2 f(x^k) \right)^{-1} \nabla f(x^k) - x^*.$$

Снова вспомним формулу Ньютона–Лейбница для интеграла вдоль кривой:

$$\nabla f(x^k) - \nabla f(x^*) = \int_0^1 \nabla^2 f\left(x^* + \tau(x^k - x^*)\right) (x^k - x^*) \, d\tau.$$

Сходимость

Будем изучать, как меняется расстояние до решения:

$$x^{k+1} - x^* = x^k - \left(\nabla^2 f(x^k) \right)^{-1} \nabla f(x^k) - x^*.$$

Снова вспомним формулу Ньютона–Лейбница для интеграла вдоль кривой:

$$\nabla f(x^k) - \nabla f(x^*) = \int_0^1 \nabla^2 f\left(x^* + \tau(x^k - x^*)\right) (x^k - x^*) \, d\tau.$$

Зная, что $\nabla f(x^*) = 0$, получим:

$$x^{k+1} - x^* = x^k - x^* - \left(\nabla^2 f(x^k) \right)^{-1} \int_0^1 \nabla^2 f\left(x^* + \tau(x^k - x^*)\right) (x^k - x^*) \, d\tau.$$

Сходимость

Используем «умную единицу»:

$$\begin{aligned}x^{k+1} - x^* &= x^k - x^* - (\nabla^2 f(x^k))^{-1} \int_0^1 \nabla^2 f(x^* + \tau(x^k - x^*)) (x^k - x^*) d\tau \\&= (\nabla^2 f(x^k))^{-1} \nabla^2 f(x^k) (x^k - x^*) \\&\quad - (\nabla^2 f(x^k))^{-1} \int_0^1 \nabla^2 f(x^* + \tau(x^k - x^*)) (x^k - x^*) d\tau.\end{aligned}$$

Сходимость

Используем «умную единицу»:

$$\begin{aligned}x^{k+1} - x^* &= x^k - x^* - (\nabla^2 f(x^k))^{-1} \int_0^1 \nabla^2 f(x^* + \tau(x^k - x^*)) (x^k - x^*) d\tau \\&= (\nabla^2 f(x^k))^{-1} \nabla^2 f(x^k) (x^k - x^*) \\&\quad - (\nabla^2 f(x^k))^{-1} \int_0^1 \nabla^2 f(x^* + \tau(x^k - x^*)) (x^k - x^*) d\tau.\end{aligned}$$

Заметим, что $x^k - x^*$ можно вынести за пределы интеграла:

$$\begin{aligned}x^{k+1} - x^* &= (\nabla^2 f(x^k))^{-1} \left(\nabla^2 f(x^k) - \int_0^1 \nabla^2 f(x^* + \tau(x^k - x^*)) d\tau \right) (x^k - x^*) \\&= (\nabla^2 f(x^k))^{-1} G_k (x^k - x^*).\end{aligned}$$

Сходимость

Спектральная норма матрицы согласована с евклидовой нормой вектора. Таким образом:

$$\|x^{k+1} - x^*\|_2 \leq \left\| \left(\nabla^2 f(x^k) \right)^{-1} \right\|_2 \|G_k\|_2 \|x^k - x^*\|_2.$$

Сходимость

Спектральная норма матрицы согласована с евклидовой нормой вектора. Таким образом:

$$\|x^{k+1} - x^*\|_2 \leq \left\| \left(\nabla^2 f(x^k) \right)^{-1} \right\|_2 \|G_k\|_2 \|x^k - x^*\|_2.$$

Вопрос: как оценить $\left\| \left(\nabla^2 f(x^k) \right)^{-1} \right\|_2$?

Сходимость

Спектральная норма матрицы согласована с евклидовой нормой вектора. Таким образом:

$$\|x^{k+1} - x^*\|_2 \leq \left\| \left(\nabla^2 f(x^k) \right)^{-1} \right\|_2 \|G_k\|_2 \|x^k - x^*\|_2.$$

Вопрос: как оценить $\left\| \left(\nabla^2 f(x^k) \right)^{-1} \right\|_2$? Оценим как

$$\left\| \left(\nabla^2 f(x^k) \right)^{-1} \right\|_2 = \frac{1}{\lambda_{\min}(\nabla^2 f(x^k))} \leq \frac{1}{\mu}.$$

Сходимость

Спектральная норма матрицы согласована с евклидовой нормой вектора. Таким образом:

$$\|x^{k+1} - x^*\|_2 \leq \left\| \left(\nabla^2 f(x^k) \right)^{-1} \right\|_2 \|G_k\|_2 \|x^k - x^*\|_2.$$

Вопрос: как оценить $\left\| \left(\nabla^2 f(x^k) \right)^{-1} \right\|_2$? Оценим как

$$\left\| \left(\nabla^2 f(x^k) \right)^{-1} \right\|_2 = \frac{1}{\lambda_{\min}(\nabla^2 f(x^k))} \leq \frac{1}{\mu}. \text{ Тогда применяя результат}$$

Утверждения, получаем:

$$\|x^{k+1} - x^*\|_2 \leq \frac{M}{2\mu} \|x^k - x^*\|_2^2.$$

Сходимость

Теорема

Пусть задача безусловной оптимизации с M -Липшицевым гессианом, μ -сильно выпуклой целевой функцией f , решается с помощью метода Ньютона. Тогда справедлива следующая оценка сходимости:

$$\|x^{k+1} - x^*\|_2 \leq \frac{M}{2\mu} \|x^k - x^*\|_2^2.$$

Сходимость

Теорема

Пусть задача безусловной оптимизации с M -Липшицевым гессианом, μ -сильно выпуклой целевой функцией f , решается с помощью метода Ньютона. Тогда справедлива следующая оценка сходимости:

$$\|x^{k+1} - x^*\|_2 \leq \frac{M}{2\mu} \|x^k - x^*\|_2^2.$$

Мы уже знаем, что такого рода оценки дают квадратичную скорость сходимости.

Сходимость

- Сходимость, как и в случае первородного метода Ньютона, является локальной.

Сходимость

- Сходимость, как и в случае первоначального метода Ньютона, является локальной. А именно, чтобы гарантировать $\|x^1 - x^*\|_2 < \|x^0 - x^*\|_2$, нужно предположить, что

$$\|x^0 - x^*\|_2 < \frac{2\mu}{M}.$$

Сходимость

- Сходимость, как и в случае первоначального метода Ньютона, является локальной. А именно, чтобы гарантировать $\|x^1 - x^*\|_2 < \|x^0 - x^*\|_2$, нужно предположить, что

$$\|x^0 - x^*\|_2 < \frac{2\mu}{M}.$$

- Поймем насколько быстро сходится метод. Пусть $M = 2$, $\mu = 1$, а $\|x^0 - x^*\|_2 = \frac{1}{2}$.

Сходимость

- Сходимость, как и в случае первоуродного метода Ньютона, является локальной. А именно, чтобы гарантировать $\|x^1 - x^*\|_2 < \|x^0 - x^*\|_2$, нужно предположить, что

$$\|x^0 - x^*\|_2 < \frac{2\mu}{M}.$$

- Поймем насколько быстро сходится метод. Пусть $M = 2$, $\mu = 1$, а $\|x^0 - x^*\|_2 = \frac{1}{2}$. Тогда мы можем гарантировать, что $\|x^1 - x^*\|_2 = \frac{1}{2}$, $\|x^2 - x^*\|_2 \leq \frac{1}{(2^2)^2}$ и так далее.

Модификации

- Пытаемся решить проблему локальной сходимости. Действуем по аналогии с градиентным спуском. **Вопрос:** идеи?

Модификации

- Пытаемся решить проблему локальной сходимости. Действуем по аналогии с градиентным спуском. **Вопрос:** идеи?
- Идея первая — шаг:

$$x^{k+1} = x^k - \gamma_k \left(\nabla^2 f(x^k) \right)^{-1} \nabla f(x^k).$$

Такой метод называется **демпфированный** метод Ньютона.
Вопрос: как выбирать шаг?

Модификации

- Пытаемся решить проблему локальной сходимости. Действуем по аналогии с градиентным спуском. **Вопрос:** идеи?
- Идея первая — шаг:

$$x^{k+1} = x^k - \gamma_k \left(\nabla^2 f(x^k) \right)^{-1} \nabla f(x^k).$$

Такой метод называется **демпфированный** метод Ньютона.

Вопрос: как выбирать шаг? Много разных способов, например, линейный поиск:

$$\underset{\gamma}{\operatorname{argmin}} f(x^k + \gamma p_k), \quad \text{где } p_k = - \left(\nabla^2 f(x^k) \right)^{-1} \nabla f(x^k).$$

Модификации

- Идея вторая — «оценки сверху». В основе анализа градиентного спуска лежала оптимизация «оценки сверху» на функцию:

$$x^{k+1} = \operatorname{argmin}_{x \in \mathbb{R}^d} \left(f(x^k) + \langle \nabla f(x^k), x - x^k \rangle + \frac{L}{2} \|x - x^k\|_2^2 \right).$$

Модификации

- Идея вторая — «оценки сверху». В основе анализа градиентного спуска лежала оптимизация «оценки сверху» на функцию:

$$x^{k+1} = \operatorname{argmin}_{x \in \mathbb{R}^d} \left(f(x^k) + \langle \nabla f(x^k), x - x^k \rangle + \frac{L}{2} \|x - x^k\|_2^2 \right).$$

Вопрос: чему равно x^{k+1} ?

Модификации

- Идея вторая — «оценки сверху». В основе анализа градиентного спуска лежала оптимизация «оценки сверху» на функцию:

$$x^{k+1} = \operatorname{argmin}_{x \in \mathbb{R}^d} \left(f(x^k) + \langle \nabla f(x^k), x - x^k \rangle + \frac{L}{2} \|x - x^k\|_2^2 \right).$$

Вопрос: чему равно x^{k+1} ? $x^{k+1} = x^k - \frac{1}{L} \nabla f(x^k)$.

Модификации

- Идея вторая — «оценки сверху». В основе анализа градиентного спуска лежала оптимизация «оценки сверху» на функцию:

$$x^{k+1} = \operatorname{argmin}_{x \in \mathbb{R}^d} \left(f(x^k) + \langle \nabla f(x^k), x - x^k \rangle + \frac{L}{2} \|x - x^k\|_2^2 \right).$$

Вопрос: чему равно x^{k+1} ? $x^{k+1} = x^k - \frac{1}{L} \nabla f(x^k)$. Запишем, похожее для аппроксимации 2-го порядка:

$$\begin{aligned} x^{k+1} = \operatorname{argmin}_{x \in \mathbb{R}^d} & \left(f(x) + \langle \nabla f(x), y - x \rangle \right. \\ & \left. + \frac{1}{2} \langle \nabla^2 f(x)(y - x), y - x \rangle + \frac{M}{6} \|x - y\|_2^3 \right). \end{aligned}$$

Такой метод называется **кубический метод Ньютона**.

Квазиньютоновское уравнение

- Запишем метод Ньютона следующим образом:

$$x^{k+1} = x^k - \gamma_k H_k \nabla f(x^k)$$

Квазиньютоновское уравнение

- Запишем метод Ньютона следующим образом:

$$x^{k+1} = x^k - \gamma_k H_k \nabla f(x^k)$$

В случае метода Ньютона вместо H_k стоит $(\nabla^2 f(x^k))^{-1}$.

- Хочется заменить $(\nabla^2 f(x^k))^{-1}$ на что-то более дешевое с точки зрения вычислений.

Квазиньютоновское уравнение

- Запишем метод Ньютона следующим образом:

$$x^{k+1} = x^k - \gamma_k H_k \nabla f(x^k)$$

В случае метода Ньютона вместо H_k стоит $(\nabla^2 f(x^k))^{-1}$.

- Хочется заменить $(\nabla^2 f(x^k))^{-1}$ на что-то более дешевое с точки зрения вычислений.
- Идея — выудить какие-то свойства, присущие гессиану.

Квазиньютоновское уравнение

- Запишем метод Ньютона следующим образом:

$$x^{k+1} = x^k - \gamma_k H_k \nabla f(x^k)$$

В случае метода Ньютона вместо H_k стоит $(\nabla^2 f(x^k))^{-1}$.

- Хочется заменить $(\nabla^2 f(x^k))^{-1}$ на что-то более дешевое с точки зрения вычислений.
- Идея — выудить какие-то свойства, присущие гессиану.
- Связь градиента и гессиана:

$$\nabla f(x^{k+1}) - \nabla f(x^k) \approx \nabla^2 f(x^{k+1})(x^{k+1} - x^k).$$

Квазиньютоновское уравнение

- Запишем метод Ньютона следующим образом:

$$x^{k+1} = x^k - \gamma_k H_k \nabla f(x^k)$$

В случае метода Ньютона вместо H_k стоит $(\nabla^2 f(x^k))^{-1}$.

- Хочется заменить $(\nabla^2 f(x^k))^{-1}$ на что-то более дешевое с точки зрения вычислений.
- Идея — выудить какие-то свойства, присущие гессиану.
- Связь градиента и гессиана:

$$\nabla f(x^{k+1}) - \nabla f(x^k) \approx \nabla^2 f(x^{k+1})(x^{k+1} - x^k).$$

Введём обозначения

$$s^k = x^{k+1} - x^k, \quad y^k = \nabla f(x^{k+1}) - \nabla f(x^k)$$

и положим

$$B_{k+1} \approx \nabla^2 f(x^{k+1}), \quad H_{k+1} \approx (\nabla^2 f(x^{k+1}))^{-1}.$$

Квазиньютоновское уравнение

- Квазиньютоновское уравнение:

$$y^k = B_{k+1}s^k \iff s^k = H_{k+1}y^k.$$

Квазиньютоновское уравнение

- Квазиньютоновское уравнение:

$$y^k = B_{k+1}s^k \iff s^k = H_{k+1}y^k.$$

- Ещё потребуем, чтобы H_{k+1} была симметричной: $H_{k+1}^\top = H_{k+1}$.

Квазиньютоновское уравнение

- Квазиньютоновское уравнение:

$$y^k = B_{k+1}s^k \iff s^k = H_{k+1}y^k.$$

- Ещё потребуем, чтобы H_{k+1} была симметричной: $H_{k+1}^\top = H_{k+1}$.
- Вопрос:** сколько решений имеет система уравнений $s^k = H_{k+1}y^k$ относительно H_{k+1} при условии, что $H_{k+1}^\top = H_{k+1}$?

Квазиньютоновское уравнение

- Квазиньютоновское уравнение:

$$y^k = B_{k+1}s^k \iff s^k = H_{k+1}y^k.$$

- Ещё потребуем, чтобы H_{k+1} была симметричной: $H_{k+1}^\top = H_{k+1}$.
- Вопрос:** сколько решений имеет система уравнений $s^k = H_{k+1}y^k$ относительно H_{k+1} при условии, что $H_{k+1}^\top = H_{k+1}$?
 $\frac{d(d-1)}{2} + d = \frac{d(d+1)}{2}$ уравнений. Поскольку общее число элементов матрицы равно d^2 , остаётся $\frac{d(d-1)}{2}$ свободных параметров. Это означает, что множество допустимых приближений очень велико и существует широкий спектр стратегий построения H_{k+1} или B_{k+1} .

SR1 (Symmetric Rank 1)

- Идея первая — одно-ранговая добавка:

$$H_{k+1} = H_k + \mu_k q^k (q^k)^\top,$$

где $\mu_k \in \mathbb{R}$ и $q^k \in \mathbb{R}^d$ нужно подобрать.

SR1 (Symmetric Rank 1)

- Идея первая — одно-ранговая добавка:

$$H_{k+1} = H_k + \mu_k q^k (q^k)^\top,$$

где $\mu_k \in \mathbb{R}$ и $q^k \in \mathbb{R}^d$ нужно подобрать.

- Подбираем исходя из квазиньютоновского уравнения:

$$s^k = H_{k+1} y^k = \left(H_k + \mu_k q^k (q^k)^\top \right) y^k = H_k y^k + \mu_k \left((q^k)^\top y^k \right) q^k.$$

SR1 (Symmetric Rank 1)

- Идея первая — одно-ранговая добавка:

$$H_{k+1} = H_k + \mu_k q^k (q^k)^\top,$$

где $\mu_k \in \mathbb{R}$ и $q^k \in \mathbb{R}^d$ нужно подобрать.

- Подбираем исходя из квазиньютоновского уравнения:

$$s^k = H_{k+1} y^k = \left(H_k + \mu_k q^k (q^k)^\top \right) y^k = H_k y^k + \mu_k \left((q^k)^\top y^k \right) q^k.$$

Откуда

$$\mu_k \left((q^k)^\top y^k \right) q^k = s^k - H_k y^k.$$

SR1 (Symmetric Rank 1)

- С предыдущего слайда:

$$\mu_k \left(\left(q^k \right)^\top y^k \right) q^k = s^k - H_k y^k.$$

- **Вопрос:** что можно сказать про вектор q^k ?

SR1 (Symmetric Rank 1)

- С предыдущего слайда:

$$\mu_k \left(\left(q^k \right)^\top y^k \right) q^k = s^k - H_k y^k.$$

- Вопрос:** что можно сказать про вектор q^k ? Коллинеарен $s^k - H_k y^k$.

SR1 (Symmetric Rank 1)

- С предыдущего слайда:

$$\mu_k \left((q^k)^\top y^k \right) q^k = s^k - H_k y^k.$$

- Вопрос:** что можно сказать про вектор q^k ? Коллинеарен $s^k - H_k y^k$. Пусть

$$q^k = s^k - H_k y^k,$$

тогда

$$\mu_k = \frac{1}{(q^k)^\top y^k}.$$

SR1 (Symmetric Rank 1)

- С предыдущего слайда:

$$\mu_k \left((q^k)^\top y^k \right) q^k = s^k - H_k y^k.$$

- Вопрос:** что можно сказать про вектор q^k ? Коллинеарен $s^k - H_k y^k$. Пусть

$$q^k = s^k - H_k y^k,$$

тогда

$$\mu_k = \frac{1}{(q^k)^\top y^k}.$$

- Получаем SR1 способ подсчета матриц H :

$$H_{k+1} = H_k + \frac{(s^k - H_k y^k) (s^k - H_k y^k)^\top}{(s^k - H_k y^k)^\top y^k}.$$

Broyden

- Подойдем к задаче иначе. Запишем квазиньютоновское уравнение для матрицы B :

$$y^k = B_{k+1}s^k.$$

Broyden

- Подойдем к задаче иначе. Запишем квазиньютоновское уравнение для матрицы B :

$$y^k = B_{k+1}s^k.$$

- Потребуем минимальность фробениусовой нормы поправки при ограничении в виде квазиньютоновского уравнения:

$$\begin{aligned} B_{k+1} &= \operatorname{argmin}_{B \in \mathbb{R}^{d \times d}} \|B - B_k\|_F^2 \\ \text{s.t. } &Bs^k = y^k. \end{aligned}$$

Broyden

- Подойдем к задаче иначе. Запишем квазиньютоновское уравнение для матрицы B :

$$y^k = B_{k+1} s^k.$$

- Потребуем минимальность фробениусовой нормы поправки при ограничении в виде квазиньютоновского уравнения:

$$\begin{aligned} B_{k+1} &= \operatorname{argmin}_{B \in \mathbb{R}^{d \times d}} \|B - B_k\|_F^2 \\ \text{s.t. } & B s^k = y^k. \end{aligned}$$

- Получаем:

$$B_{k+1} = B_k + \frac{(y^k - B_k s^k) (s^k)^\top}{(s^k)^\top s^k}.$$

DFP (Davidon–Fletcher–Powell)

- Добавим требование на симметричность матрицы и заменим обычную норму Фробениуса на взвешенную:

$$\|A\|_W = \|W^{1/2}AW^{1/2}\|_F,$$

где W — матрица, для которой выполняется $Wy^k = s^k$.

DFP (Davidon–Fletcher–Powell)

- Добавим требование на симметричность матрицы и заменим обычную норму Фробениуса на взвешенную:

$$\|A\|_W = \|W^{1/2}AW^{1/2}\|_F,$$

где W — матрица, для которой выполняется $Wy^k = s^k$.

- Задача оптимизации для поиска B_{k+1} :

$$B_{k+1} = \underset{B \in \mathbb{R}^{d \times d}}{\operatorname{argmin}} \|B - B_k\|_W^2$$

$$\text{s.t. } Bs^k = y^k,$$

$$B^\top = B.$$

DFP (Davidon–Fletcher–Powell)

- Добавим требование на симметричность матрицы и заменим обычную норму Фробениуса на взвешенную:

$$\|A\|_W = \|W^{1/2}AW^{1/2}\|_F,$$

где W — матрица, для которой выполняется $Wy^k = s^k$.

- Задача оптимизации для поиска B_{k+1} :

$$B_{k+1} = \underset{B \in \mathbb{R}^{d \times d}}{\operatorname{argmin}} \|B - B_k\|_W^2$$

$$\text{s.t. } Bs^k = y^k,$$

$$B^\top = B.$$

- Получаем:

$$B_{k+1} = \left(I_d - \frac{y^k (s^k)^\top}{(y^k)^\top s^k} \right) B_k \left(I_d - \frac{s^k (y^k)^\top}{(y^k)^\top s^k} \right) + \frac{y^k (y^k)^\top}{(y^k)^\top s^k}.$$

BFGS (Broyden–Fletcher–Goldfarb–Shanno)

- Поступим так же, как и в DFP, только будем решать задачу сразу для H :

$$\begin{aligned} H_{k+1} &= \operatorname{argmin}_{H \in \mathbb{R}^{d \times d}} \|H - H_k\|_W^2 \\ \text{s.t.} \quad &s^k = Hy^k, \\ &H^\top = H. \end{aligned}$$

BFGS (Broyden–Fletcher–Goldfarb–Shanno)

- Поступим так же, как и в DFP, только будем решать задачу сразу для H :

$$\begin{aligned} H_{k+1} &= \operatorname{argmin}_{H \in \mathbb{R}^{d \times d}} \|H - H_k\|_W^2 \\ \text{s.t.} \quad & s^k = Hy^k, \\ & H^\top = H. \end{aligned}$$

- Получаем:

$$H_{k+1} = \left(I_d - \frac{s^k (y^k)^\top}{(y^k)^\top s^k} \right) H_k \left(I_d - \frac{y^k (s^k)^\top}{(y^k)^\top s^k} \right) + \frac{s^k (s^k)^\top}{(y^k)^\top s^k}.$$

BFGS (Broyden–Fletcher–Goldfarb–Shanno)

- **Вопрос:** чтобы посчитать новую матрицу нужно $\mathcal{O}(d^2)$ операций. Кажется, что в BFGS подсчет дороже (есть перемножение трех матриц). Так ли это?

$$H_{k+1} = \left(I_d - \frac{s^k (y^k)^\top}{(y^k)^\top s^k} \right) H_k \left(I_d - \frac{y^k (s^k)^\top}{(y^k)^\top s^k} \right) + \frac{s^k (s^k)^\top}{(y^k)^\top s^k}.$$

BFGS (Broyden–Fletcher–Goldfarb–Shanno)

- **Вопрос:** чтобы посчитать новую матрицу нужно $\mathcal{O}(d^2)$ операций. Кажется, что в BFGS подсчет дороже (есть перемножение трех матриц). Так ли это?

$$H_{k+1} = \left(I_d - \frac{s^k (y^k)^\top}{(y^k)^\top s^k} \right) H_k \left(I_d - \frac{y^k (s^k)^\top}{(y^k)^\top s^k} \right) + \frac{s^k (s^k)^\top}{(y^k)^\top s^k}.$$

- Нужно раскрыть скобки в матричном умножении. В подсчете $s^k (y^k)^\top H_k$ нужно сначала умножить $(y^k)^\top H_k$, а потом вектор на вектор. Аналогично для $H_k y^k (y^k)^\top$. Получается, что сложность BFGS есть $\mathcal{O}(d^2)$ операций (не учитывая подсчет градиентов).

BFGS (Broyden–Fletcher–Goldfarb–Shanno)

- **Вопрос:** чтобы посчитать новую матрицу нужно $\mathcal{O}(d^2)$ операций. Кажется, что в BFGS подсчет дороже (есть перемножение трех матриц). Так ли это?

$$H_{k+1} = \left(I_d - \frac{s^k (y^k)^\top}{(y^k)^\top s^k} \right) H_k \left(I_d - \frac{y^k (s^k)^\top}{(y^k)^\top s^k} \right) + \frac{s^k (s^k)^\top}{(y^k)^\top s^k}.$$

- Нужно раскрыть скобки в матричном умножении. В подсчете $s^k (y^k)^\top H_k$ нужно сначала умножить $(y^k)^\top H_k$, а потом вектор на вектор. Аналогично для $H_k y^k (y^k)^\top$. Получается, что сложность BFGS есть $\mathcal{O}(d^2)$ операций (не учитывая подсчет градиентов).
- При инициализации матрицу H_0 достаточно брать равно единичной. Есть и более хитрые способы, но особо разницы нет.

Переход от B_{k+1} к H_{k+1}

Чтобы не обращаться матрицу B_{k+1} и не решать системы линейных уравнений, можем получить явную формулу для $H_{k+1} = B_{k+1}^{-1}$, используя формулу Шермана-Моррисона-Вудбери.

Утверждение

Пусть $A \in \mathbb{R}^{d \times d}$ — обратимая матрица, а $U, V \in \mathbb{R}^{d \times n}$. Тогда, если также обратима матрица $I_d + V^\top A^{-1} U$, то верна формула:

$$(A + UV^\top)^{-1} = A^{-1} - A^{-1}U(I_d + V^\top A^{-1}U)^{-1}V^\top A^{-1}.$$

Сравнительная таблица

Метод	B^{new}	$H^{\text{new}} = (B^{\text{new}})^{-1}$
SR1	$B + \frac{(y-Bs)(y-Bs)^{\top}}{(y-Bs)^{\top}s}$	$H + \frac{(s-Hy)(s-Hy)^{\top}}{(s-Hy)^{\top}y}$
Broyden	$B + \frac{y-Bs}{s^{\top}s} s^{\top}$	$H + \frac{(s-Hy)s^{\top}H}{s^{\top}Hy}$
DFP	$\left(I_d - \frac{ys^{\top}}{y^{\top}s}\right) B \left(I_d - \frac{sy^{\top}}{y^{\top}s}\right) + \frac{yy^{\top}}{y^{\top}s}$	$H + \frac{ss^{\top}}{s^{\top}y} - \frac{Hy y^{\top} H}{y^{\top} Hy}$
BFGS	$B + \frac{yy^{\top}}{y^{\top}s} - \frac{Bss^{\top}B}{s^{\top}Bs}$	$\left(I_d - \frac{sy^{\top}}{y^{\top}s}\right) H \left(I_d - \frac{ys^{\top}}{y^{\top}s}\right) + \frac{ss^{\top}}{y^{\top}s}$

Метод Ньютона и квазиньютоновские методы

- Квазиньютоновские методы не требуют подсчет гессиана и его обращение. Сложность всех арифметических операций на одной итерации $\mathcal{O}(d^2)$, что дешевле обращения гессиана за $\mathcal{O}(d^3)$.

Метод Ньютона и квазиньютоновские методы

- Квазиньютоновские методы не требуют подсчет гессиана и его обращение. Сложность всех арифметических операций на одной итерации $\mathcal{O}(d^2)$, что дешевле обращения гессиана за $\mathcal{O}(d^3)$.
- Квазиньютоновские методы имеют глобальную сверхлинейную скорость сходимости. Это медленнее, чем метод Ньютона, но не нужна «хорошая» окрестность решения.

Метод Ньютона и квазиньютоновские методы

- Квазиньютоновские методы не требуют подсчет гессиана и его обращение. Сложность всех арифметических операций на одной итерации $\mathcal{O}(d^2)$, что дешевле обращения гессиана за $\mathcal{O}(d^3)$.
- Квазиньютоновские методы имеют глобальную сверхлинейную скорость сходимости. Это медленнее, чем метод Ньютона, но не нужна «хорошая» окрестность решения.
- Квазиньютоновские методы используют только градиент, но в теории сходятся быстрее ускоренного градиентного метода.
Вопрос: почему так, ведь метод Нестерова оптимальный?

Метод Ньютона и квазиньютоновские методы

- Квазиньютоновские методы не требуют подсчет гессиана и его обращение. Сложность всех арифметических операций на одной итерации $\mathcal{O}(d^2)$, что дешевле обращения гессиана за $\mathcal{O}(d^3)$.
 - Квазиньютоновские методы имеют глобальную сверхлинейную скорость сходимости. Это медленнее, чем метод Ньютона, но не нужна «хорошая» окрестность решения.
 - Квазиньютоновские методы используют только градиент, но в теории сходятся быстрее ускоренного градиентного метода.
- Вопрос:** почему так, ведь метод Нестерова оптимальный? В определении класса задач, для которого метод Нестерова оптимальный не разрешены векторные произведения.

Метод Ньютона и квазиньютоновские методы

- Квазиньютоновские методы не требуют подсчет гессиана и его обращение. Сложность всех арифметических операций на одной итерации $\mathcal{O}(d^2)$, что дешевле обращения гессиана за $\mathcal{O}(d^3)$.
- Квазиньютоновские методы имеют глобальную сверхлинейную скорость сходимости. Это медленнее, чем метод Ньютона, но не нужна «хорошая» окрестность решения.
- Квазиньютоновские методы используют только градиент, но в теории сходятся быстрее ускоренного градиентного метода.
Вопрос: почему так, ведь метод Нестерова оптимальный? В определении класса задач, для которого метод Нестерова оптимальный не разрешены векторные произведения.
- Метод Ньютона и квазиньютоновские методы на практике быстро находят точный локальный минимум. Их спокойно можно использовать в качестве «дорешивателей». Квазиньютоновские методы и как «стартовый» метод.