

Негладкая оптимизация. Адаптивные методы

Методы оптимизации

Александр Богданов

Московский физико-технический институт

15 апреля 2026



Негладкие задачи

- **Вопрос:** функция $f(x) = |x|$ выпукла?

Негладкие задачи

- **Вопрос:** функция $f(x) = |x|$ выпукла? По нашему определению с начала курса — нет. А почему?

Негладкие задачи

- **Вопрос:** функция $f(x) = |x|$ выпукла? По нашему определению с начала курса — нет. А почему? Потому что мы требовали дифференцируемость.
- Обобщим определение выпуклости

Определение

Рассмотрим функцию $f : \mathbb{R}^d \rightarrow \mathbb{R}$. Функция f называется **выпуклой**, если для любых $x_1, \dots, x_k \in \mathbb{R}^d$ и любых $\alpha_1, \dots, \alpha_k$, $\alpha_i \geq 0$, $\sum_{i=1}^k \alpha_i = 1$ выполняется

$$f\left(\sum_{i=1}^k \alpha_i x_i\right) \leq \sum_{i=1}^k \alpha_i f(x_i).$$

Негладкие задачи

- **Вопрос:** функция $f(x) = |x|$ выпукла? По нашему определению с начала курса — нет. А почему? Потому что мы требовали дифференцируемость.
- Обобщим определение выпуклости

Определение

Рассмотрим функцию $f : \mathbb{R}^d \rightarrow \mathbb{R}$. Функция f называется **выпуклой**, если для любых $x_1, \dots, x_k \in \mathbb{R}^d$ и любых $\alpha_1, \dots, \alpha_k$, $\alpha_i \geq 0$, $\sum_{i=1}^k \alpha_i = 1$ выполняется

$$f\left(\sum_{i=1}^k \alpha_i x_i\right) \leq \sum_{i=1}^k \alpha_i f(x_i).$$

- Получается, что даже довольно простые выпуклые задачи могут быть негладким. До этого мы смотрели только на гладкие задачи.

Негладкие задачи

- Будем рассматривать следующее предположение вместо гладкости:

Определение

Пусть дана функция $f : \mathbb{R}^d \rightarrow \mathbb{R}$. Будем говорить, что она является M -липшицевой, если для любых $x, y \in \mathbb{R}^d$ выполнено:

$$|f(x) - f(y)| \leq M \|x - y\|_2.$$

Субградиент и субдифференциал

Если функция не дифференцируема в точке, то значит градиента нет.
Что может существовать вместо градиента?

Субградиент и субдифференциал

Если функция не дифференцируема в точке, то значит градиента нет.
Что может существовать вместо градиента?

Определение

Пусть дана выпуклая функция $f : \mathbb{R}^d \rightarrow \mathbb{R}$. Вектор $g \in \mathbb{R}^d$ будем называть **субградиентом** функции f в точке $x \in \mathbb{R}^d$, если для любого $y \in \mathbb{R}^d$ выполнено

$$f(y) \geq f(x) + \langle g, y - x \rangle.$$

Множество $\partial f(x)$ всех субградиентов f в точке x называется **субдифференциалом**.

Условие оптимальности

Теорема

Точка x^ — минимум выпуклой функции f тогда и только тогда, когда*

$$0 \in \partial f(x^*).$$

Условие оптимальности

Теорема

Точка x^* — минимум выпуклой функции f тогда и только тогда, когда

$$0 \in \partial f(x^*).$$

⇒ Если $f(x) \geq f(x^*)$ для любых $x \in \mathbb{R}^d$, то для вектора 0 выполнено

$$f(x) \geq f(x^*) + \langle 0, x - x^* \rangle$$

для любого $x \in \mathbb{R}^d$. Следовательно, $0 \in \partial f(x^*)$.

Условие оптимальности

Теорема

Точка x^* — минимум выпуклой функции f тогда и только тогда, когда

$$0 \in \partial f(x^*).$$

⇒ Если $f(x) \geq f(x^*)$ для любых $x \in \mathbb{R}^d$, то для вектора 0 выполнено

$$f(x) \geq f(x^*) + \langle 0, x - x^* \rangle$$

для любого $x \in \mathbb{R}^d$. Следовательно, $0 \in \partial f(x^*)$.

⇐ Пусть $0 \in \partial f(x^*)$. Тогда по определению субградиента:

$$f(x) \geq f(x^*) + \langle 0, x - x^* \rangle = f(x^*)$$

для любого $x \in \mathbb{R}^d$.

Свойство M -липшицевой функции

Теорема

Пусть дана выпуклая функция $f : \mathbb{R}^d \rightarrow \mathbb{R}$. Тогда функция f является M -липшицевой тогда и только тогда, когда для любого $x \in \mathbb{R}^d$ и $g \in \partial f(x)$ имеем $\|g\|_2 \leq M$.

Свойство M -липшицевой функции

Теорема

Пусть дана выпуклая функция $f : \mathbb{R}^d \rightarrow \mathbb{R}$. Тогда функция f является M -липшицевой тогда и только тогда, когда для любого $x \in \mathbb{R}^d$ и $g \in \partial f(x)$ имеем $\|g\|_2 \leq M$.

⊕ Рассмотрим $g \in \partial f(x)$, тогда по определению субградиента:

$$f(y) - f(x) \geq \langle g, y - x \rangle.$$

Свойство M -липшицевой функции

Теорема

Пусть дана выпуклая функция $f : \mathbb{R}^d \rightarrow \mathbb{R}$. Тогда функция f является M -липшицевой тогда и только тогда, когда для любого $x \in \mathbb{R}^d$ и $g \in \partial f(x)$ имеем $\|g\|_2 \leq M$.

⊖ Рассмотрим $g \in \partial f(x)$, тогда по определению субградиента:

$$f(y) - f(x) \geq \langle g, y - x \rangle.$$

Из M -липшицевости f :

$$M\|y - x\|_2 \geq f(y) - f(x) \geq \langle g, y - x \rangle.$$

Свойство M -липшицевой функции

Теорема

Пусть дана выпуклая функция $f : \mathbb{R}^d \rightarrow \mathbb{R}$. Тогда функция f является M -липшицевой тогда и только тогда, когда для любого $x \in \mathbb{R}^d$ и $g \in \partial f(x)$ имеем $\|g\|_2 \leq M$.

⊕ Рассмотрим $g \in \partial f(x)$, тогда по определению субградиента:

$$f(y) - f(x) \geq \langle g, y - x \rangle.$$

Из M -липшицевости f :

$$M\|y - x\|_2 \geq f(y) - f(x) \geq \langle g, y - x \rangle.$$

Возьмем $y = g + x \in \mathbb{R}^d$, тогда

$$M\|g\|_2 = M\|y - x\|_2 \geq \langle g, y - x \rangle = \|g\|_2^2.$$

Свойство M -липшицевой функции

Теорема

Пусть дана выпуклая функция $f : \mathbb{R}^d \rightarrow \mathbb{R}$. Тогда функция f является M -липшицевой тогда и только тогда, когда для любого $x \in \mathbb{R}^d$ и $g \in \partial f(x)$ имеем $\|g\|_2 \leq M$.

⊕ Рассмотрим $g \in \partial f(x)$, тогда по определению субградиента:

$$f(y) - f(x) \geq \langle g, y - x \rangle.$$

Из M -липшицевости f :

$$M\|y - x\|_2 \geq f(y) - f(x) \geq \langle g, y - x \rangle.$$

Возьмем $y = g + x \in \mathbb{R}^d$, тогда

$$M\|g\|_2 = M\|y - x\|_2 \geq \langle g, y - x \rangle = \|g\|_2^2.$$

Откуда и получаем: $\|g\|_2 \leq M$.

Доказательство

⊖ Рассмотрим $g \in \partial f(x)$, тогда по определению субградиента:

$$f(x) - f(y) \leq \langle g, x - y \rangle.$$

Доказательство

⊖ Рассмотрим $g \in \partial f(x)$, тогда по определению субградиента:

$$f(x) - f(y) \leq \langle g, x - y \rangle.$$

Используем неравенство Коши–Буняковского–Шварца:

$$f(x) - f(y) \leq \|g\|_2 \|x - y\|_2.$$

Доказательство

⊖ Рассмотрим $g \in \partial f(x)$, тогда по определению субградиента:

$$f(x) - f(y) \leq \langle g, x - y \rangle.$$

Используем неравенство Коши–Буняковского–Шварца:

$$f(x) - f(y) \leq \|g\|_2 \|x - y\|_2.$$

Воспользуемся предположением об ограниченности нормы субградиента и получим:

$$f(x) - f(y) \leq M \|x - y\|_2.$$

Доказательство

⊖ Рассмотрим $g \in \partial f(x)$, тогда по определению субградиента:

$$f(x) - f(y) \leq \langle g, x - y \rangle.$$

Используем неравенство Коши–Буняковского–Шварца:

$$f(x) - f(y) \leq \|g\|_2 \|x - y\|_2.$$

Воспользуемся предположением об ограниченности нормы субградиента и получим:

$$f(x) - f(y) \leq M \|x - y\|_2.$$

Если переобозначить $x \rightarrow y$, $y \rightarrow x$, то можем записать:

$$f(y) - f(x) \leq M \|y - x\|_2.$$

Доказательство

⊖ Рассмотрим $g \in \partial f(x)$, тогда по определению субградиента:

$$f(x) - f(y) \leq \langle g, x - y \rangle.$$

Используем неравенство Коши–Буняковского–Шварца:

$$f(x) - f(y) \leq \|g\|_2 \|x - y\|_2.$$

Воспользуемся предположением об ограниченности нормы субградиента и получим:

$$f(x) - f(y) \leq M \|x - y\|_2.$$

Если переобозначить $x \rightarrow y$, $y \rightarrow x$, то можем записать:

$$f(y) - f(x) \leq M \|y - x\|_2.$$

Если объединить оба неравенства, то можем прийти к более краткой записи:

$$|f(y) - f(x)| \leq M \|x - y\|_2.$$

Субградиентный метод

Рассматриваем безусловную задачу:

$$\min_{x \in \mathbb{R}^d} f(x),$$

где функция f выпуклая на $\mathbb{R}^d$ и M -липшицева.

Субградиентный метод

Рассматриваем безусловную задачу:

$$\min_{x \in \mathbb{R}^d} f(x),$$

где функция f выпуклая на $\mathbb{R}^d$ и M -липшицева.

Простая идея — снова модифицировать градиентный спуск, теперь вместо градиента используя какой-то субградиент в текущей точке:

Алгоритм Субградиентный метод

Вход: стартовая точка $x^0 \in \mathbb{R}^d$, размеры шагов $\{\gamma_k\}_{k=0} > 0$, количество итераций K

- 1: **for** $k = 0, 1, \dots, K - 1$ **do**
- 2: Вычислить $g^k \in \partial f(x^k)$
- 3: $x^{k+1} = x^k - \gamma_k g^k$
- 4: **end for**

Выход: $\frac{1}{K} \sum_{k=0}^{K-1} x^k$

Сходимость

Раскроем квадрат нормы:

$$\begin{aligned}\|x^{k+1} - x^*\|_2^2 &= \|x^k - \gamma g^k - x^*\|_2^2 \\ &= \|x^k - x^*\|_2^2 - 2\gamma \langle g^k, x^k - x^* \rangle + \gamma^2 \|g^k\|_2^2.\end{aligned}$$

Сходимость

Раскроем квадрат нормы:

$$\begin{aligned}\|x^{k+1} - x^*\|_2^2 &= \|x^k - \gamma g^k - x^*\|_2^2 \\ &= \|x^k - x^*\|_2^2 - 2\gamma \langle g^k, x^k - x^* \rangle + \gamma^2 \|g^k\|_2^2.\end{aligned}$$

Из M -липшицевости f следует, что норма субградиента g^k ограничена:

$$\|x^{k+1} - x^*\|_2^2 \leq \|x^k - x^*\|_2^2 - 2\gamma \langle g^k, x^k - x^* \rangle + \gamma^2 M^2.$$

Сходимость

Раскроем квадрат нормы:

$$\begin{aligned}\|x^{k+1} - x^*\|_2^2 &= \|x^k - \gamma g^k - x^*\|_2^2 \\ &= \|x^k - x^*\|_2^2 - 2\gamma \langle g^k, x^k - x^* \rangle + \gamma^2 \|g^k\|_2^2.\end{aligned}$$

Из M -липшицовости f следует, что норма субградиента g^k ограничена:

$$\|x^{k+1} - x^*\|_2^2 \leq \|x^k - x^*\|_2^2 - 2\gamma \langle g^k, x^k - x^* \rangle + \gamma^2 M^2.$$

Из определения субградиента оценим скалярное произведение:

$$\|x^{k+1} - x^*\|_2^2 \leq \|x^k - x^*\|_2^2 - 2\gamma (f(x^k) - f^*) + \gamma^2 M^2.$$

Сходимость

Раскроем квадрат нормы:

$$\begin{aligned}\|x^{k+1} - x^*\|_2^2 &= \|x^k - \gamma g^k - x^*\|_2^2 \\ &= \|x^k - x^*\|_2^2 - 2\gamma \langle g^k, x^k - x^* \rangle + \gamma^2 \|g^k\|_2^2.\end{aligned}$$

Из M -липшицовости f следует, что норма субградиента g^k ограничена:

$$\|x^{k+1} - x^*\|_2^2 \leq \|x^k - x^*\|_2^2 - 2\gamma \langle g^k, x^k - x^* \rangle + \gamma^2 M^2.$$

Из определения субградиента оценим скалярное произведение:

$$\|x^{k+1} - x^*\|_2^2 \leq \|x^k - x^*\|_2^2 - 2\gamma (f(x^k) - f^*) + \gamma^2 M^2.$$

Перенесем разность значений функции f влево, а норму вправо:

$$2\gamma (f(x^k) - f^*) \leq \|x^k - x^*\|_2^2 - \|x^{k+1} - x^*\|_2^2 + \gamma^2 M^2.$$

Сходимость

Просуммируем по всем k от 0 до $K - 1$:

$$2\gamma \sum_{k=0}^{K-1} \left(f(x^k) - f^* \right) \leq \sum_{k=0}^{K-1} \left(\|x^k - x^*\|_2^2 - \|x^{k+1} - x^*\|_2^2 + \gamma^2 M^2 \right).$$

Сходимость

Просуммируем по всем k от 0 до $K - 1$:

$$2\gamma \sum_{k=0}^{K-1} \left(f(x^k) - f^* \right) \leq \sum_{k=0}^{K-1} \left(\|x^k - x^*\|_2^2 - \|x^{k+1} - x^*\|_2^2 + \gamma^2 M^2 \right).$$

Раскроем телескопическую сумму и воспользуемся выпуклостью f :

$$f\left(\frac{1}{K} \sum_{k=0}^{K-1} x^k\right) - f^* \leq \frac{\|x^0 - x^*\|_2^2 - \|x^K - x^*\|_2^2}{2\gamma K} + \frac{\gamma M^2}{2}.$$

Сходимость

Просуммируем по всем k от 0 до $K - 1$:

$$2\gamma \sum_{k=0}^{K-1} \left(f(x^k) - f^* \right) \leq \sum_{k=0}^{K-1} \left(\|x^k - x^*\|_2^2 - \|x^{k+1} - x^*\|_2^2 + \gamma^2 M^2 \right).$$

Раскроем телескопическую сумму и воспользуемся выпуклостью f :

$$f\left(\frac{1}{K} \sum_{k=0}^{K-1} x^k\right) - f^* \leq \frac{\|x^0 - x^*\|_2^2 - \|x^K - x^*\|_2^2}{2\gamma K} + \frac{\gamma M^2}{2}.$$

Минимизируя правую часть, при $\gamma^* = \frac{\|x^0 - x^*\|_2}{M\sqrt{K}}$, получаем:

$$f\left(\frac{1}{K} \sum_{k=0}^{K-1} x^k\right) - f^* \leq \frac{M\|x^0 - x^*\|_2}{\sqrt{K}}.$$

Сходимость

Теорема

Пусть задача безусловной оптимизации с M -липшицевой выпуклой целевой функцией f решается с помощью субградиентного метода.

Тогда при $\gamma_k = \frac{\|x^0 - x^*\|_2}{M\sqrt{K}}$ справедлива следующая оценка сходимости:

$$f\left(\frac{1}{K} \sum_{k=0}^{K-1} x^k\right) - f^* \leq \frac{M\|x^0 - x^*\|_2}{\sqrt{K}}.$$

Итог

- Обобщение градиентного спуска на негладкие задачи.

Итог

- Обобщение градиентного спуска на негладкие задачи.
- Оценки сходимости в выпуклом случае: $\sim \frac{1}{\sqrt{K}}$, в сильно выпуклом случае: $\sim \frac{1}{K}$. **Вопрос:** какие были у градиентного спуска в гладком случае?

Итог

- Обобщение градиентного спуска на негладкие задачи.
- Оценки сходимости в выпуклом случае: $\sim \frac{1}{\sqrt{K}}$, в сильно выпуклом случае: $\sim \frac{1}{K}$. **Вопрос:** какие были у градиентного спуска в гладком случае? $\sim \frac{1}{K}$ и линейная соответственно. Сходимость медленнее.

Итог

- Обобщение градиентного спуска на негладкие задачи.
- Оценки сходимости в выпуклом случае: $\sim \frac{1}{\sqrt{K}}$, в сильно выпуклом случае: $\sim \frac{1}{K}$. **Вопрос:** какие были у градиентного спуска в гладком случае? $\sim \frac{1}{K}$ и линейная соответственно. Сходимость медленнее.
- Может возможно улучшить результат? Например, улучшить анализ или использовать моментум.

Итог

- Обобщение градиентного спуска на негладкие задачи.
- Оценки сходимости в выпуклом случае: $\sim \frac{1}{\sqrt{K}}$, в сильно выпуклом случае: $\sim \frac{1}{K}$. **Вопрос:** какие были у градиентного спуска в гладком случае? $\sim \frac{1}{K}$ и линейная соответственно. Сходимость медленнее.
- Может возможно улучшить результат? Например, улучшить анализ или использовать моментум. В общем случае результат для субградиентного метода является неулучшаемым для выпуклых и сильно-выпуклых задач, то есть он оптимален.

Итог

- Обобщение градиентного спуска на негладкие задачи.
- Оценки сходимости в выпуклом случае: $\sim \frac{1}{\sqrt{K}}$, в сильно выпуклом случае: $\sim \frac{1}{K}$. **Вопрос:** какие были у градиентного спуска в гладком случае? $\sim \frac{1}{K}$ и линейная соответственно. Сходимость медленнее.
- Может возможно улучшить результат? Например, улучшить анализ или использовать моментум. В общем случае результат для субградиентного метода является неулучшаемым для выпуклых и сильно-выпуклых задач, то есть он оптимален. **Вопрос:** а что в невыпуклом случае?

Итог

- Обобщение градиентного спуска на негладкие задачи.
- Оценки сходимости в выпуклом случае: $\sim \frac{1}{\sqrt{K}}$, в сильно выпуклом случае: $\sim \frac{1}{K}$. **Вопрос:** какие были у градиентного спуска в гладком случае? $\sim \frac{1}{K}$ и линейная соответственно. Сходимость медленнее.
- Может возможно улучшить результат? Например, улучшить анализ или использовать моментум. В общем случае результат для субградиентного метода является неулучшаемым для выпуклых и сильно-выпуклых задач, то есть он оптимален. **Вопрос:** а что в невыпуклом случае? С этого мы начинали курс — лучше, чем полный перебор ничего не придумать.

Адаптивные методы

В полученной оценке для субградиентного метода шаг выбирается равным

$$\gamma = \frac{\|x^0 - x^*\|_2}{M\sqrt{K}}.$$

Вопрос: какие есть проблемы у такого шага?

Адаптивные методы

В полученной оценке для субградиентного метода шаг выбирается равным

$$\gamma = \frac{\|x^0 - x^*\|_2}{M\sqrt{K}}.$$

Вопрос: какие есть проблемы у такого шага? Такая формула требует знания заранее числа итераций K , константы Липшица M и расстояния $\|x^0 - x^*\|_2$ до решения. На практике эти параметры обычно неизвестны, и их использование существенно ограничивает применимость метода.

AdaGradNorm

- Избавимся от необходимости знать константу Липшица M .

AdaGradNorm

- Избавимся от необходимости знать константу Липшица M . Так как субградиент ограничен, то M можем оценить $M \sim \|g\|_2$.

AdaGradNorm

- Избавимся от необходимости знать константу Липшица M . Так как субградиент ограничен, то M можем оценить $M \sim \|g\|_2$.
- Однако этого недостаточно: в оптимальном значении шага в знаменателе стоит $M\sqrt{K}$. Тогда мы можем брать норму не одного субградиента в какой-то точке, а суммировать по всем предыдущим:

$$M\sqrt{K} \sim \sqrt{\sum_{t=0}^{K-1} \|g^t\|_2^2}.$$

AdaGradNorm

- Избавимся от необходимости знать константу Липшица M . Так как субградиент ограничен, то M можем оценить $M \sim \|g\|_2$.
- Однако этого недостаточно: в оптимальном значении шага в знаменателе стоит $M\sqrt{K}$. Тогда мы можем брать норму не одного субградиента в какой-то точке, а суммировать по всем предыдущим:

$$M\sqrt{K} \sim \sqrt{\sum_{t=0}^{K-1} \|g^t\|_2^2}.$$

- Неизвестным остается только расстояние до решения $\|x^0 - x^*\|_2$. Его можно оценить лишь какой-то константой D , на практике часто подбираемой эмпирически:

$$\|x^0 - x^*\|_2 \leq D.$$

AdaGradNorm

Алгоритм AdaGradNorm

Вход: стартовая точка $x^0 \in \mathbb{R}^d$, сумма квадратов норм субградиентов $G^{-1} = 0$, параметры $\varepsilon \sim 10^{-8}$, $D > 0$, количество итераций K

- 1: **for** $k = 0, 1, \dots, K - 1$ **do**
- 2: Вычислить $g^k \in \partial f(x^k)$
- 3: $G^k = G^{k-1} + \|g^k\|_2^2$
- 4: $x^{k+1} = x^k - \frac{D}{\sqrt{G^k + \varepsilon}} g^k$
- 5: **end for**

Выход: $\frac{1}{K} \sum_{k=0}^{K-1} x^k$

DoG: Distance over Gradients

В методе AdaGradNorm шаг имеет вид

$$\gamma_k = \frac{D}{\sqrt{\sum_{t=0}^k \|g^t\|_2^2 + \varepsilon}},$$

где $D = \|x^0 - x^*\|_2$ остаётся неизвестным параметром.

DoG: Distance over Gradients

В методе AdaGradNorm шаг имеет вид

$$\gamma_k = \frac{D}{\sqrt{\sum_{t=0}^k \|g^t\|_2^2 + \varepsilon}},$$

где $D = \|x^0 - x^*\|_2$ остаётся неизвестным параметром.

Для его замены предлагается использовать наблюдаемую величину

$$d_k = \max_{t=\overline{0,k}} \|x^t - x^0\|_2.$$

DoG: Distance over Gradients

Алгоритм DoG (Distance over Gradients)

Вход: стартовая точка $x^0 \in \mathbb{R}^d$, сумма квадратов норм субградиентов $G^{-1} = 0$, оценка диаметра $d_{-1} > 0$, параметр $\varepsilon \sim 10^{-8}$, количество итераций K

- 1: **for** $k = 0, 1, \dots, K - 1$ **do**
- 2: Вычислить $g^k \in \partial f(x^k)$
- 3: $G^k = G^{k-1} + \|g^k\|_2^2$
- 4: $d_k = \max(d_{k-1}, \|x^k - x^0\|_2)$
- 5: $x^{k+1} = x^k - \frac{d_k}{\sqrt{G^k + \varepsilon}} g^k$

6: **end for**

Выход: $\frac{1}{K} \sum_{k=0}^{K-1} x^k$

AdaGrad

Следующий шаг — учесть неоднородность по координатам. Тогда шаг для каждой координаты берётся как

$$\gamma_{k,i} = \frac{D_i}{\sqrt{\sum_{t=0}^k (g_i^t)^2 + \varepsilon}}.$$

AdaGrad

Алгоритм AdaGrad

Вход: стартовая точка $x^0 \in \mathbb{R}^d$, суммы квадратов компонент субградиентов $G_i^{-1} = 0$, параметры $\varepsilon \sim 10^{-8}$, $D_i > 0$, количество итераций K

- 1: **for** $k = 0, 1, \dots, K - 1$ **do**
- 2: Вычислить $g^k \in \partial f(x^k)$
- 3: $G_i^k = G_i^{k-1} + (g_i^k)^2$
- 4: $x_i^{k+1} = x_i^k - \frac{D_i}{\sqrt{G_i^k + \varepsilon}} g_i^k$
- 5: **end for**

Выход: $\frac{1}{K} \sum_{k=0}^{K-1} x^k$

Сходимость

Распишем шаг по каждой координате:

$$\begin{aligned}(x_i^{k+1} - x_i^*)^2 &= (x_i^k - \gamma_{k,i} g_i^k - x_i^*)^2 \\ &= (x_i^k - x_i^*)^2 - 2\gamma_{k,i} g_i^k (x_i^k - x_i^*) + \gamma_{k,i}^2 (g_i^k)^2.\end{aligned}$$

Сходимость

Распишем шаг по каждой координате:

$$\begin{aligned}(x_i^{k+1} - x_i^*)^2 &= (x_i^k - \gamma_{k,i} g_i^k - x_i^*)^2 \\ &= (x_i^k - x_i^*)^2 - 2\gamma_{k,i} g_i^k (x_i^k - x_i^*) + \gamma_{k,i}^2 (g_i^k)^2.\end{aligned}$$

Откуда выражаем перекрестное слагаемое:

$$g_i^k (x_i^k - x_i^*) = \frac{1}{2\gamma_{k,i}} (x_i^k - x_i^*)^2 - \frac{1}{2\gamma_{k,i}} (x_i^{k+1} - x_i^*)^2 + \frac{\gamma_{k,i}}{2} (g_i^k)^2.$$

Сходимость

Распишем шаг по каждой координате:

$$\begin{aligned}(x_i^{k+1} - x_i^*)^2 &= (x_i^k - \gamma_{k,i} g_i^k - x_i^*)^2 \\ &= (x_i^k - x_i^*)^2 - 2\gamma_{k,i} g_i^k (x_i^k - x_i^*) + \gamma_{k,i}^2 (g_i^k)^2.\end{aligned}$$

Откуда выражаем перекрестное слагаемое:

$$g_i^k (x_i^k - x_i^*) = \frac{1}{2\gamma_{k,i}} (x_i^k - x_i^*)^2 - \frac{1}{2\gamma_{k,i}} (x_i^{k+1} - x_i^*)^2 + \frac{\gamma_{k,i}}{2} (g_i^k)^2.$$

Собираем скалярное произведение, суммируя по всем координатам i от 1 до d :

$$\langle g^k, x^k - x^* \rangle = \frac{1}{2} \sum_{i=1}^d \left[\frac{1}{\gamma_{k,i}} (x_i^k - x_i^*)^2 - \frac{1}{\gamma_{k,i}} (x_i^{k+1} - x_i^*)^2 + \gamma_{k,i} (g_i^k)^2 \right].$$

Сходимость

Оцениваем левую часть, пользуясь определением субградиента:

$$f(x^k) - f^* \leq \frac{1}{2} \sum_{i=1}^d \left[\frac{1}{\gamma_{k,i}} (x_i^k - x_i^*)^2 - \frac{1}{\gamma_{k,i}} (x_i^{k+1} - x_i^*)^2 + \gamma_{k,i} (g_i^k)^2 \right].$$

Сходимость

Оцениваем левую часть, пользуясь определением субградиента:

$$f(x^k) - f^* \leq \frac{1}{2} \sum_{i=1}^d \left[\frac{1}{\gamma_{k,i}} (x_i^k - x_i^*)^2 - \frac{1}{\gamma_{k,i}} (x_i^{k+1} - x_i^*)^2 + \gamma_{k,i} (g_i^k)^2 \right].$$

Суммируем по всем k от 0 до $K - 1$ и усредняем, а также меняем порядок суммирования:

$$\begin{aligned} & \frac{1}{K} \sum_{k=0}^{K-1} (f(x^k) - f^*) \\ & \leq \frac{1}{2K} \sum_{k=0}^{K-1} \sum_{i=1}^d \left[\frac{1}{\gamma_{k,i}} (x_i^k - x_i^*)^2 - \frac{1}{\gamma_{k,i}} (x_i^{k+1} - x_i^*)^2 + \gamma_{k,i} (g_i^k)^2 \right] \\ & = \frac{1}{2K} \sum_{i=1}^d \sum_{k=0}^{K-1} \left[\frac{1}{\gamma_{k,i}} (x_i^k - x_i^*)^2 - \frac{1}{\gamma_{k,i}} (x_i^{k+1} - x_i^*)^2 + \gamma_{k,i} (g_i^k)^2 \right]. \end{aligned}$$

Сходимость

Сдвинем индекс суммирования k и положим $\gamma_{-1,i} = +\infty$:

$$\begin{aligned}
 & \frac{1}{K} \sum_{k=0}^{K-1} (f(x^k) - f^*) \\
 & \leq \frac{1}{2K} \sum_{i=1}^d \sum_{k=0}^{K-1} \left[\frac{1}{\gamma_{k,i}} (x_i^k - x_i^*)^2 + \gamma_{k,i} (g_i^k)^2 \right] \\
 & \quad - \frac{1}{2K} \sum_{i=1}^d \sum_{k=0}^{K-1} \left[\frac{1}{\gamma_{k,i}} (x_i^{k+1} - x_i^*)^2 \right] \\
 & = \frac{1}{2K} \sum_{i=1}^d \sum_{k=0}^{K-1} \left[\frac{1}{\gamma_{k,i}} (x_i^k - x_i^*)^2 + \gamma_{k,i} (g_i^k)^2 \right] \\
 & \quad - \frac{1}{2K} \sum_{i=1}^d \sum_{k=0}^{K-1} \left[\frac{1}{\gamma_{k-1,i}} (x_i^k - x_i^*)^2 \right] - \frac{1}{2K} \sum_{i=1}^d \frac{1}{\gamma_{K-1,i}} (x_i^K - x_i^*)^2 \\
 & \leq \frac{1}{2K} \sum_{i=1}^d \sum_{k=0}^{K-1} \left[\left(\frac{1}{\gamma_{k,i}} - \frac{1}{\gamma_{k-1,i}} \right) (x_i^k - x_i^*)^2 + \gamma_{k,i} (g_i^k)^2 \right].
 \end{aligned}$$

Сходимость

Воспользуемся константами $D_i : (x_i^k - x_i^*)^2 \leq D_i^2$:

$$\frac{1}{K} \sum_{k=0}^{K-1} \left(f(x^k) - f^* \right) \leq \frac{1}{2K} \sum_{i=1}^d \sum_{k=0}^{K-1} \left[\left(\frac{1}{\gamma_{k,i}} - \frac{1}{\gamma_{k-1,i}} \right) D_i^2 + \gamma_{k,i} (g_i^k)^2 \right].$$

Сходимость

Воспользуемся константами $D_i : (x_i^k - x_i^*)^2 \leq D_i^2$:

$$\frac{1}{K} \sum_{k=0}^{K-1} (f(x^k) - f^*) \leq \frac{1}{2K} \sum_{i=1}^d \sum_{k=0}^{K-1} \left[\left(\frac{1}{\gamma_{k,i}} - \frac{1}{\gamma_{k-1,i}} \right) D_i^2 + \gamma_{k,i} (g_i^k)^2 \right].$$

Подставим $\gamma_{k,i} = \frac{D_i}{\sqrt{\sum_{t=0}^k (g_i^t)^2}}$ и свернём телескопическую сумму:

$$\frac{1}{K} \sum_{k=0}^{K-1} (f(x^k) - f^*) \leq \frac{1}{2K} \sum_{i=1}^d D_i \left[\sqrt{\sum_{t=0}^{K-1} (g_i^t)^2} + \sum_{k=0}^{K-1} \frac{(g_i^k)^2}{\sqrt{\sum_{t=0}^k (g_i^t)^2}} \right].$$

Сходимость

Воспользуемся техническим фактом, который говорит, что для любых неотрицательных чисел $\{a_k\} \geq 0$ выполнено:

$$\sum_{k=0}^{K-1} \frac{a_k^2}{\sqrt{\sum_{t=0}^k a_t^2}} \leq 2 \sqrt{\sum_{k=0}^{K-1} a_k^2}.$$

Сходимость

Воспользуемся техническим фактом, который говорит, что для любых неотрицательных чисел $\{a_k\} \geq 0$ выполнено:

$$\sum_{k=0}^{K-1} \frac{a_k^2}{\sqrt{\sum_{t=0}^k a_t^2}} \leq 2 \sqrt{\sum_{k=0}^{K-1} a_k^2}.$$

Применяем его для второго слагаемого в сумме, получаем:

$$\frac{1}{K} \sum_{k=0}^{K-1} \left(f(x^k) - f^* \right) \leq \frac{3}{2K} \sum_{i=1}^d D_i \sqrt{\sum_{t=0}^{K-1} (g_i^t)^2}.$$

Сходимость

Из неизвестных значений в правой части остается только $\sum_{t=0}^{K-1} (g_i^t)^2$.
Оценим её с помощью свойства M -липшицевых функций:

$$\sum_{t=0}^{K-1} (g_i^t)^2 \leq \sum_{t=0}^{K-1} \|g^t\|_2^2 \leq KM^2.$$

Сходимость

Из неизвестных значений в правой части остается только $\sum_{t=0}^{K-1} (g_i^t)^2$.
Оценим её с помощью свойства M -липшицевых функций:

$$\sum_{t=0}^{K-1} (g_i^t)^2 \leq \sum_{t=0}^{K-1} \|g^t\|_2^2 \leq KM^2.$$

Подставляем в основное неравенство:

$$\frac{1}{K} \sum_{k=0}^{K-1} \left(f(x^k) - f^* \right) \leq \frac{3}{2K} \sum_{i=1}^d D_i \sqrt{KM^2} = \frac{3M}{2\sqrt{K}} \sum_{i=1}^d D_i = \frac{3M\tilde{D}}{2\sqrt{K}}.$$

Сходимость

Из неизвестных значений в правой части остается только $\sum_{t=0}^{K-1} (g_i^t)^2$.
Оценим её с помощью свойства M -липшицевых функций:

$$\sum_{t=0}^{K-1} (g_i^t)^2 \leq \sum_{t=0}^{K-1} \|g^t\|_2^2 \leq KM^2.$$

Подставляем в основное неравенство:

$$\frac{1}{K} \sum_{k=0}^{K-1} \left(f(x^k) - f^* \right) \leq \frac{3}{2K} \sum_{i=1}^d D_i \sqrt{KM^2} = \frac{3M}{2\sqrt{K}} \sum_{i=1}^d D_i = \frac{3M\tilde{D}}{2\sqrt{K}}.$$

Чтобы получить оценку из условия, остается применить определение выпуклости функции:

$$f\left(\frac{1}{K} \sum_{k=0}^{K-1} x^k\right) - f^* \leq \frac{3M\tilde{D}}{2\sqrt{K}}.$$

Сходимость

Теорема

Пусть задача оптимизации с M -липшицевой выпуклой целевой функцией f решается с помощью AdaGrad. Тогда справедлива следующая оценка сходимости:

$$f\left(\frac{1}{K} \sum_{k=0}^{K-1} x^k\right) - f^* \leq \frac{3M\tilde{D}}{2\sqrt{K}},$$

где $\tilde{D} = \sum_{i=1}^d D_i$, $|x_i^k - x_i^*| \leq D_i$.

Более того, чтобы добиться точности ε по функции, необходимо

$$K = \mathcal{O}\left(\frac{M^2 \tilde{D}^2}{\varepsilon^2}\right) \text{ итераций.}$$

RMSPProp

- Проблема AdaGrad, что старые градиенты в шаге могут быть уже не особо релевантны. **Вопрос:** как можно попробовать их «забывать»?

RMSPProp

- Проблема AdaGrad, что старые градиенты в шаге могут быть уже не особо релевантны. **Вопрос:** как можно попробовать их «забывать»?
- Чтобы избежать затухания шага, вместо суммы используют экспоненциальное скользящее среднее квадратов градиентов:

$$G_i^k = \beta G_i^{k-1} + (1 - \beta)(g_i^k)^2,$$

где моментум $\beta \in [0, 1]$ выбирается порядка ~ 0.99 .

RMSPProp

Алгоритм RMSPProp

Вход: стартовая точка $x^0 \in \mathbb{R}^d$, сглаженные суммы квадратов компонент субградиентов $G_i^{-1} = 0$, параметры $\varepsilon \sim 10^{-8}$, $D_i > 0$, $\beta \in [0, 1]$, количество итераций K

- 1: **for** $k = 0, 1, \dots, K - 1$ **do**
- 2: Вычислить $g^k \in \partial f(x^k)$
- 3: $G_i^k = \beta G_i^{k-1} + (1 - \beta)(g_i^k)^2$
- 4: $x_i^{k+1} = x_i^k - \frac{D_i}{\sqrt{G_i^k + \varepsilon}} g_i^k$
- 5: **end for**

Выход: $\frac{1}{K} \sum_{k=0}^{K-1} x^k$

Adam

- Алгоритм Adam объединяет идеи RMSProp и момента. Помимо экспоненциального сглаживания квадратов градиентов, он усредняет сами градиенты:

$$v^k = \beta_1 v^{k-1} + (1 - \beta_1) g^k,$$

$$G_i^k = \beta_2 G_i^{k-1} + (1 - \beta_2) (g_i^k)^2,$$

где два момента $\beta_1, \beta_2 \in [0, 1]$ обычно выбираются 0.9 и 0.999.

Adam

- Алгоритм Adam объединяет идеи RMSProp и момента. Помимо экспоненциального сглаживания квадратов градиентов, он усредняет сами градиенты:

$$v^k = \beta_1 v^{k-1} + (1 - \beta_1) g^k,$$

$$G_i^k = \beta_2 G_i^{k-1} + (1 - \beta_2) (g_i^k)^2,$$

где два момента $\beta_1, \beta_2 \in [0, 1]$ обычно выбираются 0.9 и 0.999.

- Чтобы устранить смещение на ранних итерациях, вводится коррекция:

$$\hat{v}^k = \frac{v^k}{1 - \beta_1^{k+1}},$$

$$\hat{G}^k = \frac{G^k}{1 - \beta_2^{k+1}}.$$

Adam

Алгоритм Adam

Вход: стартовая точка $x^0 \in \mathbb{R}^d$, сглаженные суммы квадратов компонент субградиентов $G_i^{-1} = 0$, сглаженные суммы субградиентов $v^{-1} = 0$, параметры $\beta_1, \beta_2 \in [0, 1]$, $\varepsilon \sim 10^{-8}$, $D_i > 0$, количество итераций K

- 1: **for** $k = 0, 1, \dots, K - 1$ **do**
- 2: Вычислить $g^k \in \partial f(x^k)$
- 3: $v^k = \beta_1 v^{k-1} + (1 - \beta_1) g^k$
- 4: $\hat{v}^k = v^k / (1 - \beta_1^{k+1})$
- 5: $G_i^k = \beta_2 G_i^{k-1} + (1 - \beta_2) (g_i^k)^2$
- 6: $\hat{G}^k = G^k / (1 - \beta_2^{k+1})$
- 7: $x_i^{k+1} = x_i^k - \frac{D_i}{\sqrt{\hat{G}_i^k + \varepsilon}} \hat{v}_i^k$

8: **end for**

Выход: $\frac{1}{K} \sum_{k=0}^{K-1} x^k$

Итог

- Суть — подбирать шаг, исходя из локальных свойств задачи, что кажется более эффективным и удобным подходом.

Итог

- Суть — подбирать шаг, исходя из локальных свойств задачи, что кажется более эффективным и удобным подходом.
- Подбор параметров все еще нужен: шаги D_i , моменты β_1, β_2 .
- Часто рекомендуют брать $\beta_1 = 0.9$, $\beta_2 = 0.99$ и $D_i = D$ для всех i , но все равно нужно подбирать D .

Итог

- Суть — подбирать шаг, исходя из локальных свойств задачи, что кажется более эффективным и удобным подходом.
- Подбор параметров все еще нужен: шаги D_i , моменты β_1, β_2 .
- Часто рекомендуют брать $\beta_1 = 0.9$, $\beta_2 = 0.99$ и $D_i = D$ для всех i , но все равно нужно подбирать D .
- Сейчас и эта проблема решена в так называемых parameter-free методах. Они вообще не требуют подбора, а запускаются из «коробки».

Итог

- Суть — подбирать шаг, исходя из локальных свойств задачи, что кажется более эффективным и удобным подходом.
- Подбор параметров все еще нужен: шаги D_i , моменты β_1, β_2 .
- Часто рекомендуют брать $\beta_1 = 0.9$, $\beta_2 = 0.99$ и $D_i = D$ для всех i , но все равно нужно подбирать D .
- Сейчас и эта проблема решена в так называемых parameter-free методах. Они вообще не требуют подбора, а запускаются из «коробки».
- Adam и его модификации являются самым популярным методами решения задач оптимизации, лежащих в основе обучения нейронных сетей.

Проксимальный оператор

Негладкие задачи «более сложные» по сравнению с гладкими задачами. Но отсутствие гладкости может получиться «спрятать под ковер» с помощью проксимального оператора.

Определение

Для функции $r : \mathbb{R}^d \rightarrow \mathbb{R} \cup \{+\infty\}$ **проксимальный оператор** определяется следующим образом:

$$\text{prox}_r(x) = \operatorname{argmin}_{\tilde{x} \in \mathbb{R}^d} \left(r(\tilde{x}) + \frac{1}{2} \|x - \tilde{x}\|_2^2 \right).$$

Свойства проксимального оператора

Утверждение

Пусть $r : \mathbb{R}^d \rightarrow \mathbb{R} \cup \{+\infty\}$ — выпуклая функция. Если существует $\hat{x} \in \mathbb{R}^d$ с $r(\hat{x}) < +\infty$, то проксимальный оператор однозначно определен.

Свойства проксимального оператора

Утверждение

Пусть $r : \mathbb{R}^d \rightarrow \mathbb{R} \cup \{+\infty\}$ — выпуклая функция. Если существует $\hat{x} \in \mathbb{R}^d$ с $r(\hat{x}) < +\infty$, то проксимальный оператор однозначно определен.

Проксимальный оператор возвращает минимум некоторой задачи оптимизации. Задача сильно выпуклая, так как целевая функция — это сумма выпуклой и сильно выпуклой функции. А значит, существует строго один минимум. А существование $\hat{x}$ необходимо для того, чтобы $r(\tilde{x}) + \frac{1}{2}\|x - \tilde{x}\|_2^2$ хотя бы где-то принимала конечное значение.

Примеры проксимального оператора

- ℓ_1 -норма.

Пусть $r(x) = \lambda \|x\|_1$, где $\lambda > 0$. Тогда

$$[\text{prox}_r(x)]_i = [|x_i| - \lambda]_+ \cdot \text{sign}(x_i),$$

что известно как **оператор трешхолдинга**.

Примеры проксимального оператора

- ℓ_1 -норма.

Пусть $r(x) = \lambda \|x\|_1$, где $\lambda > 0$. Тогда

$$[\text{prox}_r(x)]_i = [|x_i| - \lambda]_+ \cdot \text{sign}(x_i),$$

что известно как **оператор трешхолдинга**.

- ℓ_2 -норма.

Пусть $r(x) = \frac{\lambda}{2} \|x\|_2^2$, где $\lambda > 0$. Тогда

$$\text{prox}_r(x) = \frac{x}{1 + \lambda}.$$

- Индикатор множества.

Пусть $r(x) = \mathbb{I}_{\mathcal{X}}(x)$ для замкнутого множества $\mathcal{X} \subseteq \mathbb{R}^d$. Тогда

$$\text{prox}_r(x) = \underset{\tilde{x} \in \mathcal{X}}{\text{argmin}} \frac{1}{2} \|x - \tilde{x}\|_2^2.$$

Свойства проксимального оператора

Утверждение

Пусть $r : \mathbb{R}^d \rightarrow \mathbb{R} \cup \{+\infty\}$ — выпуклая функция. Тогда для любых $x, y \in \mathbb{R}^d$ следующие три условия являются эквивалентными:

- 1 $\text{prox}_r(x) = y,$
- 2 $x - y \in \partial r(y),$
- 3 $\langle x - y, z - y \rangle \leq r(z) - r(y)$ для любого $z \in \mathbb{R}^d.$

Свойства проксимального оператора

Утверждение

Пусть $r : \mathbb{R}^d \rightarrow \mathbb{R} \cup \{+\infty\}$ — выпуклая функция. Тогда для любых $x, y \in \mathbb{R}^d$ следующие три условия являются эквивалентными:

- 1 $\text{prox}_r(x) = y$,
- 2 $x - y \in \partial r(y)$,
- 3 $\langle x - y, z - y \rangle \leq r(z) - r(y)$ для любого $z \in \mathbb{R}^d$.

Запишем первое условие по определению проксимального оператора:

$$y = \operatorname{argmin}_{\tilde{x} \in \mathbb{R}^d} \left(r(\tilde{x}) + \frac{1}{2} \|x - \tilde{x}\|_2^2 \right).$$

Свойства проксимального оператора

Утверждение

Пусть $r : \mathbb{R}^d \rightarrow \mathbb{R} \cup \{+\infty\}$ — выпуклая функция. Тогда для любых $x, y \in \mathbb{R}^d$ следующие три условия являются эквивалентными:

- 1 $\text{prox}_r(x) = y$,
- 2 $x - y \in \partial r(y)$,
- 3 $\langle x - y, z - y \rangle \leq r(z) - r(y)$ для любого $z \in \mathbb{R}^d$.

Запишем первое условие по определению проксимального оператора:

$$y = \operatorname{argmin}_{\tilde{x} \in \mathbb{R}^d} \left(r(\tilde{x}) + \frac{1}{2} \|x - \tilde{x}\|_2^2 \right).$$

Из условия оптимальности для выпуклой функции r это эквивалентно

$$0 \in \partial \left(r(\tilde{x}) + \frac{1}{2} \|x - \tilde{x}\|_2^2 \right) \Big|_{\tilde{x}=y} = \partial r(y) + y - x.$$

Получили эквивалентность первого и второго условий.

Доказательство

Теперь свяжем второе и третье. Из определения субдифференциала, для любого субградиента $g \in \partial f(y)$ и для любого $z \in \mathbb{R}^d$:

$$\langle g, z - y \rangle \leq r(z) - r(y).$$

В частности, справедливо и для $g = x - y \in \partial r(y)$ по предположению:

$$\langle x - y, z - y \rangle \leq r(z) - r(y).$$

Получили следствие из второго в третье. Теперь в обратную сторону. Пусть выполняется соотношение три:

$$\langle x - y, z - y \rangle \leq r(z) - r(y).$$

Но это же означает, что $x - y$ является субградиентом r в точке y , то есть $g \in \partial r(y)$.

Свойства проксимального оператора

Утверждение

Пусть $r : \mathbb{R}^d \rightarrow \mathbb{R} \cup \{+\infty\}$ — выпуклая функция. Тогда для любых $x, y \in \mathbb{R}^d$ выполнено следующее:

- $\langle x - y, \text{prox}_r(x) - \text{prox}_r(y) \rangle \geq \|\text{prox}_r(x) - \text{prox}_r(y)\|_2^2,$
- $\|\text{prox}_r(x) - \text{prox}_r(y)\|_2 \leq \|x - y\|_2.$

Свойства проксимального оператора

Утверждение

Пусть $r : \mathbb{R}^d \rightarrow \mathbb{R} \cup \{+\infty\}$ — выпуклая функция. Тогда для любых $x, y \in \mathbb{R}^d$ выполнено следующее:

- $\langle x - y, \text{prox}_r(x) - \text{prox}_r(y) \rangle \geq \|\text{prox}_r(x) - \text{prox}_r(y)\|_2^2,$
- $\|\text{prox}_r(x) - \text{prox}_r(y)\|_2 \leq \|x - y\|_2.$

Для удобства обозначим $u = \text{prox}_r(x)$, $v = \text{prox}_r(y)$. Начнем с неравенства из прошлого утверждения. Запишем для троек точек (x, u, v) и (y, v, u) :

$$\langle x - u, v - u \rangle \leq r(v) - r(u),$$

$$\langle y - v, u - v \rangle \leq r(u) - r(v).$$

Свойства проксимального оператора

Утверждение

Пусть $r : \mathbb{R}^d \rightarrow \mathbb{R} \cup \{+\infty\}$ — выпуклая функция. Тогда для любых $x, y \in \mathbb{R}^d$ выполнено следующее:

- $\langle x - y, \text{prox}_r(x) - \text{prox}_r(y) \rangle \geq \|\text{prox}_r(x) - \text{prox}_r(y)\|_2^2,$
- $\|\text{prox}_r(x) - \text{prox}_r(y)\|_2 \leq \|x - y\|_2.$

Для удобства обозначим $u = \text{prox}_r(x)$, $v = \text{prox}_r(y)$. Начнем с неравенства из прошлого утверждения. Запишем для троек точек (x, u, v) и (y, v, u) :

$$\langle x - u, v - u \rangle \leq r(v) - r(u),$$

$$\langle y - v, u - v \rangle \leq r(u) - r(v).$$

Сложим неравенства, справа получим 0:

$$\langle x - u - (y - v), v - u \rangle \leq 0.$$

Доказательство

Разнесем слагаемые в разные стороны:

$$\langle x - y, u - v \rangle \geq \|u - v\|_2^2.$$

Это и есть первое свойство. Из него логично вытекает и второе свойство.

Доказательство

Разнесем слагаемые в разные стороны:

$$\langle x - y, u - v \rangle \geq \|u - v\|_2^2.$$

Это и есть первое свойство. Из него логично вытекает и второе свойство. Достаточно лишь применить к неравенству выше неравенство Коши–Буняковского–Шварца:

$$\|u - v\|_2^2 \leq \langle x - y, u - v \rangle \leq \|x - y\|_2 \|u - v\|_2.$$

Доказательство

Разнесем слагаемые в разные стороны:

$$\langle x - y, u - v \rangle \geq \|u - v\|_2^2.$$

Это и есть первое свойство. Из него логично вытекает и второе свойство. Достаточно лишь применить к неравенству выше неравенство Коши–Буняковского–Шварца:

$$\|u - v\|_2^2 \leq \langle x - y, u - v \rangle \leq \|x - y\|_2 \|u - v\|_2.$$

Случай $u = v$ тривиален и удовлетворяет неравенству, так что имеем:

$$\|u - v\|_2 \leq \|x - y\|_2.$$

Композитная задача

Рассмотрим следующую задачу:

$$\min_{x \in \mathbb{R}^d} f(x) + r(x),$$

где f является L -гладкой выпуклой функцией, а r — просто выпуклой.

Композитная задача

Рассмотрим следующую задачу:

$$\min_{x \in \mathbb{R}^d} f(x) + r(x),$$

где f является L -гладкой выпуклой функцией, а r — просто выпуклой. Она не обязана быть гладкой, но должна быть проксимально-дружественной, то есть для нее должен считаться проксимальный оператор. Задача называется **композитной**.

Проксимальный градиентный метод

Алгоритм Проксимальный градиентный метод

Вход: стартовая точка $x^0 \in \mathbb{R}^d$, размеры шагов $\{\gamma_k\}_{k=0} > 0$, количество итераций K

- 1: **for** $k = 0, 1, \dots, K - 1$ **do**
- 2: $x^{k+1} = \text{prox}_{\gamma_k r}(x^k - \gamma_k \nabla f(x^k))$
- 3: **end for**

Выход: x^K

- Запишем условие оптимальности

$$x^k - \gamma_k \nabla f(x^k) - x^{k+1} \in \gamma_k \partial r(x^{k+1}).$$

Проксимальный градиентный метод

Алгоритм Проксимальный градиентный метод

Вход: стартовая точка $x^0 \in \mathbb{R}^d$, размеры шагов $\{\gamma_k\}_{k=0} > 0$, количество итераций K

- 1: **for** $k = 0, 1, \dots, K - 1$ **do**
 - 2: $x^{k+1} = \text{prox}_{\gamma_k r}(x^k - \gamma_k \nabla f(x^k))$
 - 3: **end for**
- Выход:** x^K
-

- Запишем условие оптимальности

$$x^k - \gamma_k \nabla f(x^k) - x^{k+1} \in \gamma_k \partial r(x^{k+1}).$$

- Или, если переписать в более привычном виде:

$$x^{k+1} \in x^k - \gamma_k \left(\nabla f(x^k) + \partial r(x^{k+1}) \right).$$

Свойство проксимального оператора

Утверждение

Пусть $f : \mathbb{R}^d \rightarrow \mathbb{R} \cup \{+\infty\}$, $r : \mathbb{R}^d \rightarrow \mathbb{R} \cup \{+\infty\}$ — выпуклые функции. Тогда x^* — решение композитной задачи оптимизации тогда и только тогда, когда для любого $\gamma > 0$ выполнено:

$$x^* = \text{prox}_{\gamma r}(x^* - \gamma \nabla f(x^*)).$$

Выражение из условия эквивалентно записи:

$$x^* - \gamma \nabla f(x^*) - x^* \in \gamma \partial r(x^*).$$

Свойство проксимального оператора

Утверждение

Пусть $f : \mathbb{R}^d \rightarrow \mathbb{R} \cup \{+\infty\}$, $r : \mathbb{R}^d \rightarrow \mathbb{R} \cup \{+\infty\}$ — выпуклые функции. Тогда x^* — решение композитной задачи оптимизации тогда и только тогда, когда для любого $\gamma > 0$ выполнено:

$$x^* = \text{prox}_{\gamma r}(x^* - \gamma \nabla f(x^*)).$$

Выражение из условия эквивалентно записи:

$$x^* - \gamma \nabla f(x^*) - x^* \in \gamma \partial r(x^*).$$

Сокращаем на $\gamma > 0$ и получаем условие оптимальности:

$$0 \in \nabla f(x^*) + \partial r(x^*).$$

Сходимость

Подставим итерацию метода:

$$\|x^{k+1} - x^*\|_2^2 = \left\| \text{prox}_{\gamma_k r} \left(x^k - \gamma_k \nabla f(x^k) \right) - x^* \right\|_2^2.$$

Сходимость

Подставим итерацию метода:

$$\|x^{k+1} - x^*\|_2^2 = \left\| \text{prox}_{\gamma_k r} \left(x^k - \gamma_k \nabla f(x^k) \right) - x^* \right\|_2^2.$$

Воспользуемся доказанным выше Утверждением:

$$\|x^{k+1} - x^*\|_2^2 = \left\| \text{prox}_{\gamma_k r} \left(x^k - \gamma_k \nabla f(x^k) \right) - \text{prox}_{\gamma_k r} \left(x^* - \gamma_k \nabla f(x^*) \right) \right\|_2^2.$$

Сходимость

Подставим итерацию метода:

$$\|x^{k+1} - x^*\|_2^2 = \left\| \text{prox}_{\gamma_k r} \left(x^k - \gamma_k \nabla f(x^k) \right) - x^* \right\|_2^2.$$

Воспользуемся доказанным выше Утверждением:

$$\|x^{k+1} - x^*\|_2^2 = \left\| \text{prox}_{\gamma_k r} \left(x^k - \gamma_k \nabla f(x^k) \right) - \text{prox}_{\gamma_k r} \left(x^* - \gamma_k \nabla f(x^*) \right) \right\|_2^2.$$

Сходимость

Подставим итерацию метода:

$$\|x^{k+1} - x^*\|_2^2 = \left\| \text{prox}_{\gamma_k r} \left(x^k - \gamma_k \nabla f(x^k) \right) - x^* \right\|_2^2.$$

Воспользуемся доказанным выше Утверждением:

$$\|x^{k+1} - x^*\|_2^2 = \left\| \text{prox}_{\gamma_k r} \left(x^k - \gamma_k \nabla f(x^k) \right) - \text{prox}_{\gamma_k r} (x^* - \gamma_k \nabla f(x^*)) \right\|_2^2.$$

Применим неравенство свойство:

$$\|x^{k+1} - x^*\|_2^2 \leq \left\| \left(x^k - \gamma_k \nabla f(x^k) \right) - \left(x^* - \gamma_k \nabla f(x^*) \right) \right\|_2^2.$$

Сходимость

Подставим итерацию метода:

$$\|x^{k+1} - x^*\|_2^2 = \left\| \text{prox}_{\gamma_k r} \left(x^k - \gamma_k \nabla f(x^k) \right) - x^* \right\|_2^2.$$

Воспользуемся доказанным выше Утверждением:

$$\|x^{k+1} - x^*\|_2^2 = \left\| \text{prox}_{\gamma_k r} \left(x^k - \gamma_k \nabla f(x^k) \right) - \text{prox}_{\gamma_k r} (x^* - \gamma_k \nabla f(x^*)) \right\|_2^2.$$

Применим неравенство свойство:

$$\|x^{k+1} - x^*\|_2^2 \leq \left\| \left(x^k - \gamma_k \nabla f(x^k) \right) - \left(x^* - \gamma_k \nabla f(x^*) \right) \right\|_2^2.$$

Раскроем квадрат нормы:

$$\begin{aligned} \|x^{k+1} - x^*\|_2^2 &\leq \|x^k - x^*\|_2^2 - 2\gamma_k \langle x^k - x^*, \nabla f(x^k) - \nabla f(x^*) \rangle \\ &\quad + \gamma_k^2 \left\| \nabla f(x^k) - \nabla f(x^*) \right\|_2^2. \end{aligned}$$

Сходимость

Оценим последнее слагаемое, используя свойство L -гладкой выпуклой функции:

$$\begin{aligned}\|x^{k+1} - x^*\|_2^2 &\leq \|x^k - x^*\|_2^2 - 2\gamma_k \langle x^k - x^*, \nabla f(x^k) - \nabla f(x^*) \rangle \\ &\quad + \gamma_k^2 L \langle \nabla f(x^k) - \nabla f(x^*), x^k - x^* \rangle \\ &= \|x^k - x^*\|_2^2 - \gamma_k(2 - \gamma_k L) \langle \nabla f(x^k) - \nabla f(x^*), x^k - x^* \rangle.\end{aligned}$$

Сходимость

Оценим последнее слагаемое, используя свойство L -гладкой выпуклой функции:

$$\begin{aligned}\|x^{k+1} - x^*\|_2^2 &\leq \|x^k - x^*\|_2^2 - 2\gamma_k \langle x^k - x^*, \nabla f(x^k) - \nabla f(x^*) \rangle \\ &\quad + \gamma_k^2 L \langle \nabla f(x^k) - \nabla f(x^*), x^k - x^* \rangle \\ &= \|x^k - x^*\|_2^2 - \gamma_k(2 - \gamma_k L) \langle \nabla f(x^k) - \nabla f(x^*), x^k - x^* \rangle.\end{aligned}$$

Два раза запишем определение μ -сильной выпуклости f :

$$\begin{aligned}f(x^k) &\geq f(x^*) + \langle \nabla f(x^*), x^k - x^* \rangle + \frac{\mu}{2} \|x^k - x^*\|_2^2, \\ f(x^*) &\geq f(x^k) + \langle \nabla f(x^k), x^* - x^k \rangle + \frac{\mu}{2} \|x^* - x^k\|_2^2.\end{aligned}$$

Сходимость

Сложим их и получим:

$$\left\langle \nabla f(x^k) - \nabla f(x^*), x^k - x^* \right\rangle \geq \mu \|x^k - x^*\|_2^2.$$

Сходимость

Сложим их и получим:

$$\langle \nabla f(x^k) - \nabla f(x^*), x^k - x^* \rangle \geq \mu \|x^k - x^*\|_2^2.$$

Подставляем в основное неравенство:

$$\begin{aligned} \|x^{k+1} - x^*\|_2^2 &\leq \|x^k - x^*\|_2^2 - \mu\gamma_k(2 - \gamma_k L) \|x^k - x^*\|_2^2 \\ &= (1 - \mu\gamma_k(2 - \gamma_k L)) \|x^k - x^*\|_2^2. \end{aligned}$$

Сходимость

Сложим их и получим:

$$\langle \nabla f(x^k) - \nabla f(x^*), x^k - x^* \rangle \geq \mu \|x^k - x^*\|_2^2.$$

Подставляем в основное неравенство:

$$\begin{aligned} \|x^{k+1} - x^*\|_2^2 &\leq \|x^k - x^*\|_2^2 - \mu\gamma_k(2 - \gamma_k L) \|x^k - x^*\|_2^2 \\ &= (1 - \mu\gamma_k(2 - \gamma_k L)) \|x^k - x^*\|_2^2. \end{aligned}$$

Возьмём $\gamma_k \leq \frac{1}{L}$, тогда $2 - \gamma_k L > 1$. Продолжая цепочку неравенств, имеем:

$$\|x^{k+1} - x^*\|_2^2 \leq (1 - \mu\gamma_k) \|x^k - x^*\|_2^2.$$

Остается лишь развернуть рекурсию с K -ой итерации по нулевую:

$$\|x^K - x^*\|_2^2 \leq \dots \leq \left(\prod_{k=0}^{K-1} (1 - \mu\gamma_k) \right) \|x^0 - x^*\|_2^2.$$

Сходимость

Теорема

Пусть композитная задача оптимизации с L -гладкой μ -сильно выпуклой целевой функцией f и выпуклой (необязательно гладкой) проксимально-дружественной функцией g решается с помощью проксимального градиентного метода. Тогда при $\gamma_k \leq \frac{1}{L}$ справедлива следующая оценка сходимости:

$$\|x^K - x^*\|_2^2 \leq \left(\prod_{k=0}^{K-1} (1 - \mu\gamma_k) \right) \|x^0 - x^*\|_2^2.$$

Итог

- Проксимальный градиентный спуск для композитной задачи с L -гладкой выпуклой функцией f и выпуклой проксимально дружественной функцией r имеет такую же сходимость, что и метод градиентного спуска для функции f . Свойства гладкости/негладкости r при этом не влияют.

Итог

- Проксимальный градиентный спуск для композитной задачи с L -гладкой выпуклой функцией f и выпуклой проксимально дружественной функцией r имеет такую же сходимость, что и метод градиентного спуска для функции f . Свойства гладкости/негладкости r при этом не влияют.
- Кажется, что положив $f \equiv 0$, с помощью такого метода можно решать любую негладкую задачу.

Итог

- Проксимальный градиентный спуск для композитной задачи с L -гладкой выпуклой функцией f и выпуклой проксимально дружественной функцией r имеет такую же сходимость, что и метод градиентного спуска для функции f . Свойства гладкости/негладкости r при этом не влияют.
- Кажется, что положив $f \equiv 0$, с помощью такого метода можно решать любую негладкую задачу. **Вопрос:** так ли это?

Итог

- Проксимальный градиентный спуск для композитной задачи с L -гладкой выпуклой функцией f и выпуклой проксимально дружественной функцией r имеет такую же сходимость, что и метод градиентного спуска для функции f . Свойства гладкости/негладкости r при этом не влияют.
- Кажется, что положив $f \equiv 0$, с помощью такого метода можно решать любую негладкую задачу. **Вопрос:** так ли это? Если разрешить считать проксимальный оператор неточно (численно), то и правда можно решать любую задачу негладкой оптимизации.

Итог

- Проксимальный градиентный спуск для композитной задачи с L -гладкой выпуклой функцией f и выпуклой проксимально дружественной функцией r имеет такую же сходимость, что и метод градиентного спуска для функции f . Свойства гладкости/негладкости r при этом не влияют.
- Кажется, что положив $f \equiv 0$, с помощью такого метода можно решать любую негладкую задачу. **Вопрос:** так ли это? Если разрешить считать проксимальный оператор неточно (численно), то и правда можно решать любую задачу негладкой оптимизации. НО это с точки зрения теории не лучше, чем решать задачу субградиентным спуском, потому что при решении подзадачи проксимального используется какой-то вспомогательный метод (например, тот же субградиентный спуск).