

Л10 Метод зеркального спуска

Обратимся к итерации метода градиентного спуска (Алгоритм Л3.1):

$$x^{k+1} = x^k - \gamma_k \nabla f(x^k).$$

Здесь точка x^k рассматривается как элемент банахова пространства $(E, \|\cdot\|)$. При этом градиент $\nabla f(x^k)$ принадлежит сопряжённому пространству $(E^*, \|\cdot\|_*)$, а не исходному $(E, \|\cdot\|)$. Таким образом, в общем случае итерация складывает объекты из разных пространств. В ситуации, когда $\|\cdot\| = \|\cdot\|_2$, это несоответствие не возникает: пространства совпадают, то есть $(E, \|\cdot\|) = (E^*, \|\cdot\|_*)$, и формула градиентного спуска корректна. Однако измерять расстояние вовсе не обязательно в евклидовой норме. Даже несмотря на то, что в конечномерных пространствах все нормы эквивалентны, для различных задач могут быть предпочтительны более «естественные» способы измерения расстояния. Например, при работе с распределениями вероятностей использование евклидовой нормы выглядит искусственным.

Эти соображения приводят к идее, предложенной А. Немировским и Д. Юдиным [17]: выполнять шаг градиентного спуска не в исходном пространстве, а в сопряжённом. Для этого вводится отображение $\varphi : E \rightarrow E^*$, и итерация метода принимает вид

$$\varphi(x^{k+1}) = \varphi(x^k) - \gamma \nabla f(x^k),$$

где обратное отображение $\varphi^{-1} : E^* \rightarrow E$ возвращает результат обратно в исходное пространство E .

Замечание Л10.1. Пространство E^* в этом контексте называют «зеркальным». Именно в нём выполняется шаг градиентного спуска, а затем с помощью φ^{-1} результат отображается обратно в исходное пространство. Для практического применения метода необходимо иметь явную форму для вычисления x^{k+1} .

Л10.1 Дивергенция Брэгмана

Обобщим Определение Л2.4 μ -сильной выпуклости на случай произвольной нормы.

Определение Л10.1. Пусть дана непрерывно дифференцируемая на выпуклом множестве $\mathcal{X}$ функция $d : \mathcal{X} \rightarrow \mathbb{R}$. Будем говорить, что она является μ -сильно выпуклой относительно нормы $\|\cdot\|$ на множестве $\mathcal{X}$, если для любых $x, y \in \mathcal{X}$ выполнено

$$d(x) \geq d(y) + \langle \nabla d(y), x - y \rangle + \frac{\mu}{2} \|x - y\|^2.$$

Теперь можем ввести один из основных инструментов этой лекции.

Определение Л10.2. Пусть дана дифференцируемая 1-сильно выпуклая относительно нормы $\|\cdot\|$ на множестве $\mathcal{X}$ функция d . Дивергенцией Брэгмана, порожденной функцией d на множестве $\mathcal{X}$, называется функция двух аргументов $V(x, y) : \mathcal{X} \times \mathcal{X} \rightarrow \mathbb{R}$ такая, что для любых $x, y \in \mathcal{X}$ выполняется

$$V(x, y) = d(x) - d(y) - \langle \nabla d(y), x - y \rangle.$$

Глядя на определение μ -сильной выпуклости становится понятно, откуда взялось выражение для $V(x, y)$.

Замечание Л10.2. Дивергенцию Брэгмана можно воспринимать как расстояние между векторами, но стоит обратить внимание, что она не является метрикой и даже не симметрична относительно перестановки переменных.

Рассмотрим несколько примеров $V(x, y)$, в том числе какими функциями $d(x)$ они порождаются.

Пример Л10.1. Квадрат евклидовой нормы $d : \mathbb{R}^d \rightarrow \mathbb{R}$:

$$d(x) = \frac{1}{2} \|x\|_2^2.$$

1-сильная выпуклость относительно $\|\cdot\|_2$ тривиальна. Подставляем в определение дивергенции Брэгмана (Определение Л10.2):

$$\begin{aligned} V(x, y) &= \frac{1}{2} \|x\|_2^2 - \frac{1}{2} \|y\|_2^2 - \langle y, x - y \rangle = \frac{1}{2} (\|x\|_2^2 - \|y\|_2^2 - 2\langle y, x \rangle + 2\|y\|_2^2) \\ &= \frac{1}{2} (\|x\|_2^2 - 2\langle y, x \rangle + \|y\|_2^2) = \frac{1}{2} \|x - y\|_2^2. \end{aligned}$$

Получили просто квадрат евклидова расстояния.

Пример Л10.2. Энтропия Шеннона $d : \Delta_{d-1} \rightarrow \mathbb{R}$:

$$d(x) = \sum_{i=1}^d x_i \log x_i,$$

где

$$\Delta_{d-1} = \left\{ x \in \mathbb{R}^d \mid \sum_{i=1}^d x_i = 1, x_i > 0 \right\}.$$

Градиент d в точке y :

$$[\nabla d(y)]_i = 1 + \log y_i,$$

Подставляем в определение дивергенции Брэгмана (Определение Л10.2):

$$\begin{aligned} V(x, y) &= \sum_{i=1}^d x_i \log x_i - \sum_{i=1}^d y_i \log y_i - \sum_{i=1}^d (1 + \log y_i)(x_i - y_i) \\ &= \sum_{i=1}^d x_i (\log x_i - \log y_i) - \sum_{i=1}^d (x_i - y_i) = \sum_{i=1}^d x_i \log \frac{x_i}{y_i}. \end{aligned}$$

Слагаемое $\sum_{i=1}^d (x_i - y_i) = 0$, так как $x, y \in \Delta_{d-1}$ и $\sum_{i=1}^d x_i = \sum_{i=1}^d y_i = 1$. Получили дивергенцию Кульбака–Лейблера (KL-дивергенцию).

Здесь же можем показать 1-сильную выпуклость энтропии относительно $\|\cdot\|_1$. Согласно неравенству Пинскера получим:

$$V(x, y) = d(x) - d(y) - \langle \nabla d(y), x - y \rangle = \sum_{i=1}^d x_i \log \frac{x_i}{y_i} \geq \frac{1}{2} \|x - y\|_1^2.$$

Пример Л10.3. Энтропия фон Неймана $d : \mathbb{S}_1^d \rightarrow \mathbb{R}$:

$$d(X) = \text{Tr}(X \log X),$$

где

$$\mathbb{S}_1^d = \left\{ X \in \mathbb{S}_{++}^d \mid \text{Tr}(X) = 1 \right\},$$

а $\log X$ — матричный логарифм, определяется как отображение, обратное матричной экспоненте e^X . Также для него верно разложение в ряд для матриц:

$$\log X = \sum_{k=1}^{\infty} (-1)^{k+1} \frac{(X - I_d)^k}{k}, \quad \|I_d - X\|_2 < 1.$$

Покажем, почему $\|I_d - X\|_2 \leq 1$ выполняется для матриц $X \in \mathbb{S}_1^d$. Известно, что матрица X положительно определена. Значит, все ее собственные числа $\lambda_i(X)$, $i \in \overline{1, d}$ больше нуля. При этом, известен след матрицы:

$$\text{Tr } X = \sum_{i=1}^d \lambda_i(X) = 1.$$

Откуда следует, что каждое из собственных значений X лежит на интервале: $\lambda_i(X) \in (0, 1)$, $i \in \overline{1, d}$. Но тогда имеем, что $1 - \lambda_i(X) \in (0, 1)$, а это спектр матрицы $I_d - X$. Вторая норма для симметричной матрицы $I_d - X$ выражается как:

$$\|I_d - X\|_2 = \max_{i=1, d} \lambda(I_d - X) < 1.$$

Следовательно, можем применять формулу через ряд при поиске дифференциала:

$$d \text{Tr}(X \log X) = \text{Tr}((dX) \log X) + \text{Tr}(X d(\log X)).$$

С последним слагаемым поработаем отдельно:

$$\begin{aligned} \text{Tr}(X d(\log X)) &= \text{Tr} \left(X d \left(\sum_{k=1}^{\infty} (-1)^{k+1} \frac{(X - I_d)^k}{k} \right) \right) \\ &= \text{Tr} \left(X \sum_{k=1}^{\infty} (-1)^{k+1} \frac{d((X - I_d)^k)}{k} \right) \\ &= \text{Tr} \left(X \sum_{k=1}^{\infty} (-1)^{k+1} \frac{k(X - I_d)^{k-1} dX}{k} \right) \\ &= \text{Tr} \left(X \sum_{k=0}^{\infty} (I_d - X)^k dX \right). \end{aligned}$$

При переходе от $d((X - I_d)^k)$ к $k(X - I_d)^{k-1} dX$ существенно, что X и $X - I_d$ коммутируют, а под знаком Tr можно циклически переставлять матрицы. Далее можно воспользоваться рядом Неймана:

$$(I_d - T)^{-1} = \sum_{k=0}^{\infty} T^k, \quad \max_{i=1, d} \lambda(T) < 1.$$

Применяем его для матрицы $I_d - X$:

$$\text{Tr}(X d(\log X)) = \text{Tr} \left(X (I_d - (I_d - X))^{-1} dX \right) = \text{Tr}(I_d dX).$$

Собираем изначальный дифференциал:

$$d \text{Tr}(X \log X) = \text{Tr}((dX) \log X) + \text{Tr}(I_d dX) = \text{Tr}((I_d + \log X) dX).$$

Следовательно, градиент $\nabla d(Y)$ равен:

$$\nabla d(Y) = I_d + (\log Y)^\top.$$

Теперь находим дивергенцию Брэгмана V , порождаемую d :

$$\begin{aligned} V(X, Y) &= \text{Tr}(X \log X) - \text{Tr}(Y \log Y) - \langle I_d + (\log Y)^\top, X - Y \rangle \\ &= \text{Tr}(X \log X - Y \log Y - (X - Y) - X \log Y + Y \log Y) \\ &= \text{Tr}(X \log X - X \log Y) \end{aligned}$$

Слагаемое $\text{Tr}(X - Y) = 0$, поскольку $\text{Tr} X = \text{Tr} Y = 1$. Получили выражение для дивергенции фон Неймана.

Пример Л10.4. Логарифмический барьер $d : \mathbb{S}_{++}^d \rightarrow \mathbb{R}$:

$$d(X) = -\log(\det X).$$

Вычислим дифференциал:

$$d(-\log(\det X)) = -\frac{1}{\det X} d(\det X) = -\frac{1}{\det X} \det X \langle X^{-\top}, dX \rangle = -\langle X^{-\top}, dX \rangle.$$

Подставляем в определение дивергенции Брэгмана (Определение Л10.2):

$$\begin{aligned} V(X, Y) &= -\log(\det X) + \log(\det Y) - \langle -Y^{-\top}, X - Y \rangle \\ &= -\log(\det X / \det Y) + \text{Tr}(XY^{-1} - I_d) \\ &= \text{Tr}(XY^{-1} - I_d) - \log \det(XY^{-1}). \end{aligned}$$

Изучим подробнее свойства нового объекта.

Утверждение Л10.1. Пусть $\mathcal{X}$ — выпуклое множество. Дивергенция Брэгмана в общем случае обладает следующими свойствами:

1. Асимметричность: не всегда верно $V(x, y) = V(y, x)$.
2. Ограниченность снизу:

$$V(x, y) \geq \frac{1}{2} \|x - y\|^2 \text{ для всех } x, y \in \mathcal{X}.$$

3. Неотрицательность: $V(x, y) \geq 0$ для всех $x, y \in \mathcal{X}$.
4. 1-сильная выпуклость по первому аргументу.
5. По второму аргументу может не быть выпуклости.

Доказательство. Кратко поясним каждый пункт.

1. В качестве примера асимметричной дивергенции Брегмана можем рассмотреть KL-дивергенцию (Пример Л10.2). Из записи видно отсутствие симметрии:

$$V(x, y) = \sum_{i=1}^d x_i \log \frac{x_i}{y_i}.$$

2. Ограниченность снизу получается из Определения Л10.2 и 1-сильной выпуклости d :

$$V(x, y) = d(x) - d(y) - \langle \nabla d(y), x - y \rangle \geq \frac{1}{2} \|x - y\|^2 \text{ для всех } x, y \in \mathcal{X}.$$

3. Неотрицательность следует из предыдущего пункта. Также можем утверждать, что равенство нулю $V(x, y) = 0$ достигается тогда и только тогда, когда аргументы равны: $x = y$.
4. Относительно x дивергенция Брэгмана является суммой 1-сильно выпуклой d и линейной функции, то есть, 1-сильно выпуклой функцией.
5. Рассмотрим функцию $d(x) = -\log x$, $x > 0$. Соответствующая дивергенция Брэгмана имеет вид

$$V(x, y) = d(x) - d(y) - d'(y)(x - y) = -\log x + \log y + \frac{x}{y} - 1.$$

Зафиксируем $x = 1$ и введём функцию

$$g(y) = V(1, y) = \log y + \frac{1}{y} - 1, \quad y > 0.$$

Запишем определение выпуклости:

$$\log x + \frac{1}{x} \geq \log y + \frac{1}{y} + \left(\frac{1}{y} - \frac{1}{y^2} \right) (x - y).$$

Возьмём $y = 2$:

$$\log x + \frac{1}{x} - \frac{x}{4} \geq \log 2.$$

А теперь возьмём $x = 16$:

$$3 \log 2 + \frac{1}{16} - 4 \geq 0.$$

Получили противоречие. ■

Утверждение Л10.2 (Равенство параллелограмма/теорема Пифагора).

Пусть $\mathcal{X}$ — выпуклое множество. Для любых точек $x, y, z \in \mathcal{X}$ выполняется

$$V(z, x) + V(x, y) - V(z, y) = \langle \nabla d(y) - \nabla d(x), z - x \rangle.$$

Доказательство. Распишем :

$$\begin{aligned} V(z, x) + V(x, y) &= d(z) - d(x) - \langle \nabla d(x), z - x \rangle + d(x) - d(y) - \langle \nabla d(y), x - y \rangle \\ &= d(z) - d(y) - \langle \nabla d(y), z - y \rangle - \langle \nabla d(x) - \nabla d(y), z - x \rangle \\ &= V(z, y) - \langle \nabla d(x) - \nabla d(y), z - x \rangle. \end{aligned}$$
■

Л10.2 Зеркальный спуск

Решаем задачу оптимизации

$$\min_{x \in \mathcal{X}} f(x), \quad (\text{Л10.1})$$

где множество $\mathcal{X}$ выпуклое и замкнутое, функция f — выпуклая.

Обратимся к градиентному спуску (Алгоритм Л3.1). Мы записывали его итерацию в готовом виде:

$$x^{k+1} = x^k - \gamma_k \nabla f(x^k).$$

Но можно зайти и с точки зрения оптимизации. Рассмотрим задачу:

$$\operatorname{argmin}_{x \in \mathbb{R}^d} \left\{ f(x^k) + \langle \nabla f(x^k), x - x^k \rangle + \frac{1}{2\gamma_k} \|x - x^k\|_2^2 \right\}.$$

В самом деле, Теоремы Л2.1 и Л2.2 дают нам необходимое и достаточное условия глобального минимума выпуклой функции:

$$\nabla_x \left(f(x^k) + \langle \nabla f(x^k), x - x^k \rangle + \frac{1}{2\gamma_k} \|x - x^k\|_2^2 \right) = \nabla f(x^k) + \frac{1}{\gamma_k} (x - x^k) = 0,$$

откуда и получается формула для итерации градиентного спуска.

В этом параграфе мы ввели понятие дивергенции Брэгмана, которая имеет смысл расстояния. Используя его, можем построить метод на решении модифицированной задачи оптимизации: заменим $\frac{1}{2} \|x - x^k\|_2^2$ на $V(x, x^k)$, множество $\mathbb{R}^d$ заменим на выпуклое и замкнутое $\mathcal{X} \subseteq \mathbb{R}^d$:

$$\operatorname{argmin}_{x \in \mathcal{X}} \left\{ f(x^k) + \langle \nabla f(x^k), x - x^k \rangle + \frac{1}{\gamma_k} V(x, x^k) \right\}.$$

Можно упростить запись, избавившись от константы $f(x^k)$ и домножив целевую функцию на положительное γ_k . Получим итеративный метод:

$$x^{k+1} = \operatorname{argmin}_{x \in \mathcal{X}} \left\{ \langle \gamma_k \nabla f(x^k), x - x^k \rangle + V(x, x^k) \right\}.$$

Это и есть формула итерации метода зеркального спуска.

Алгоритм Л10.1 Зеркальный спуск

Вход: стартовая точка $x^0 \in \mathcal{X}$, размеры шагов $\{\gamma_k\}_{k=0} > 0$, количество итераций K

1: **for** $k = 0, 1, \dots, K - 1$ **do**

2: $x^{k+1} = \operatorname{argmin}_{x \in \mathcal{X}} \left\{ \langle \gamma_k \nabla f(x^k), x - x^k \rangle + V(x, x^k) \right\}$

3: **end for**

Выход: $\frac{1}{K} \sum_{k=1}^K x^k$

Рассмотрим, какие методы будут получаться при выборе различных дивергенций Брэгмана.

Пример Л10.5. Квадрат евклидовой нормы $V : \mathcal{X} \times \mathcal{X} \rightarrow \mathbb{R}$:

$$V(x, y) = \frac{1}{2} \|x - y\|_2^2, \quad x, y \in \mathcal{X}.$$

Запишем итерацию зеркального спуска:

$$x^{k+1} = \operatorname{argmin}_{x \in \mathcal{X}} \left\{ \langle \gamma_k \nabla f(x^k), x - x^k \rangle + \frac{1}{2} \|x - x^k\|_2^2 \right\}.$$

Чтобы посчитать argmin , добавим слагаемые не зависящие от x и выделим квадрат нормы:

$$\begin{aligned} x^{k+1} &= \operatorname{argmin}_{x \in \mathcal{X}} \left\{ \frac{1}{2} \gamma_k^2 \|\nabla f(x^k)\|_2^2 + \langle \gamma_k \nabla f(x^k), x - x^k \rangle + \frac{1}{2} \|x - x^k\|_2^2 \right\} \\ &= \operatorname{argmin}_{x \in \mathcal{X}} \|x - (x^k - \gamma_k \nabla f(x^k))\|_2^2 = \Pi_{\mathcal{X}}(x^k - \gamma_k \nabla f(x^k)). \end{aligned}$$

Получился градиентный спуск (Алгоритм Л9.1) с евклидовой проекцией.

Пример Л10.6. Дивергенция Кульбака-Лейблера $V : \triangle_{d-1} \times \triangle_{d-1} \rightarrow \mathbb{R}$:

$$V(x, y) = \sum_{i=1}^d x_i \log \frac{x_i}{y_i}, \quad x, y \in \triangle_{d-1}.$$

Запишем итерацию зеркального спуска как задачу с ограничениями:

$$\begin{aligned} \min_{x \in \mathbb{R}^d} \quad & \langle \gamma_k \nabla f(x^k), x \rangle + V(x, x^k) \\ \text{s.t.} \quad & -x_i \leq 0 \\ & \sum_{i=1}^d x_i - 1 = 0. \end{aligned}$$

Лагранжиан для такой задачи:

$$\begin{aligned} \mathcal{L}(x, \lambda, \nu) &= \langle \gamma_k \nabla f(x^k), x \rangle + V(x, x^k) - \sum_{i=1}^d \lambda_i x_i + \nu \left(\sum_{i=1}^d x_i - 1 \right) \\ &= \sum_{i=1}^d \left(\gamma_k [\nabla f(x^k)]_i + \log \frac{x_i}{x_i^k} - \lambda_i + \nu \right) x_i - \nu. \end{aligned}$$

Условие оптимальности по x_i :

$$\frac{\partial \mathcal{L}}{\partial x_i}(x, \lambda, \nu) = 1 + \gamma_k [\nabla f(x^k)]_i + \log \frac{x_i}{x_i^k} - \lambda_i + \nu = 0.$$

Отсюда находим x , доставляющий минимум лагранжиана:

$$x_i = x_i^k \exp(-1 - \gamma_k [\nabla f(x^k)]_i + \lambda_i - \nu), \quad i = \overline{1, d}.$$

Из условия дополняющей нежесткости получаем:

$$x_i = x_i^k \exp(-1 - \gamma_k [\nabla f(x^k)]_i - \nu), \quad i = \overline{1, d}.$$

Чтобы записать выражение для ν , вспомним ограничения задачи $\sum_{i=1}^d x_i = 1$. Отсюда получаем нормировку и можно записать:

$$x_i^{k+1} = x_i^k \frac{\exp(-\gamma_k [\nabla f(x^k)]_i)}{\sum_{i=1}^d x_i^k \exp(-\gamma_k [\nabla f(x^k)]_i)}.$$

Это и есть итерации зеркального спуска для симплекса.

Замечание Л10.3. В случае симплекса и КЛ-дивергенции можно получить выигрыш в $\frac{d}{\log d}$ раз по сравнению с градиентным спуском с евклидовой проекцией.

Чтобы добавить интуиции и понимания, покажем, как соотносятся зеркальный спуск и идея шага в сопряженном пространстве.

Пример Л10.7. Рассмотрим метод при $\mathcal{X} = \mathbb{R}^d$ и некоторой d :

$$\begin{aligned} x^{k+1} &= \operatorname{argmin}_{x \in \mathcal{X}} \{ \langle \gamma_k \nabla f(x^k), x - x^k \rangle + V(x, x^k) \} \\ &= \operatorname{argmin}_{x \in \mathbb{R}^d} \{ \langle \gamma_k \nabla f(x^k), x - x^k \rangle + d(x) - d(x^k) - \langle \nabla d(x^k), x - x^k \rangle \}. \end{aligned}$$

Запишем условие оптимальности (Теорема Л2.2):

$$\gamma_k \nabla f(x^k) + \nabla d(x) - \nabla d(x^k) = 0.$$

Это и есть идея Немировского и Юдина, идея «зеркальности».

$$\nabla d(x^{k+1}) = \nabla d(x^k) - \gamma_k \nabla f(x^k).$$

То есть, $\nabla d : E \rightarrow E^*$ и есть то преобразование φ , переносящее в зеркальное пространство.

Замечание Л10.4. С помощью такого инструмента, как дивергенция Брэгмана, мы научились переходить от задачи в «зеркальном» пространстве к простому поиску argmin , который во многих случаях либо имеет аналитическое решение, либо может быть найден численно с хорошей точностью.

Прежде чем переходить к доказательству сходимости, обобщим некоторые свойства:

Определение Л10.3. Пусть дана непрерывно дифференцируемая на выпуклом множестве $\mathcal{X}$ функция $f : \mathcal{X} \rightarrow \mathbb{R}$. Будем говорить, что данная функция имеет *L-Липшицев градиент* (является *L-гладкой*) относительно нормы $\|\cdot\|$ на $\mathcal{X}$, если для любых $x, y \in \mathcal{X}$ выполнено

$$\|\nabla f(x) - \nabla f(y)\|_* \leq L\|x - y\|.$$

Теорема Л10.1. Пусть $\mathcal{X}$ — выпуклое множество. Для *L-гладкой* относительно нормы $\|\cdot\|$ функции $f : \mathcal{X} \rightarrow \mathbb{R}$ выполнено

$$|f(y) - f(x) - \langle \nabla f(x), y - x \rangle| \leq \frac{L}{2} \|x - y\|^2.$$

Доказательство. Используем (Страница 84 из [30]) формулу Ньютона-Лейбница для криволинейного интеграла второго рода по кривой, заданной вектор функцией $r(\tau)$:

$$\int_a^b \langle \nabla f(r(\tau)), dr(\tau) \rangle = f(r(b)) - f(r(a)).$$

В нашем случае выберем кривую следующим образом $r(\tau) = x + \tau(y - x)$, где $\tau \in [0, 1]$.

Тогда

$$\begin{aligned} f(y) - f(x) &= \int_0^1 \langle \nabla f(x + \tau(y - x)), y - x \rangle d\tau \\ &= \langle \nabla f(x), y - x \rangle + \int_0^1 \langle \nabla f(x + \tau(y - x)) - \nabla f(x), y - x \rangle d\tau. \end{aligned}$$

Переместив скалярное произведение влево и взяв модуль от обеих частей, получим:

$$\begin{aligned} |f(y) - f(x) - \langle \nabla f(x), y - x \rangle| &= \left| \int_0^1 \langle \nabla f(x + \tau(y - x)) - \nabla f(x), y - x \rangle d\tau \right| \\ &\leq \int_0^1 |\langle \nabla f(x + \tau(y - x)) - \nabla f(x), y - x \rangle| d\tau. \end{aligned}$$

В последнем переходе мы использовали факт, что модуль суммы не превосходит сумму модулей слагаемых. Далее воспользуемся неравенством Гёльдера (0.2), а затем L -гладкостью относительно нормы $\|\cdot\|$ (Определение Л10.3):

$$\begin{aligned} |f(y) - f(x) - \langle \nabla f(x), y - x \rangle| &\leq \int_0^1 \|\nabla f(x + \tau(y - x)) - \nabla f(x)\|_* \|y - x\| d\tau \\ &\leq L \|y - x\|^2 \int_0^1 \tau d\tau = \frac{L}{2} \|x - y\|^2. \end{aligned}$$

■

Теперь мы готовы перейти к доказательству сходимости зеркального спуска.

Теорема Л10.2. Пусть задача оптимизации на выпуклом замкнутом множестве $\mathcal{X}$ (Л10.1) с L -гладкой относительно нормы $\|\cdot\|$ выпуклой целевой функцией f решается с помощью зеркального спуска (Алгоритм Л10.1). Тогда при $\gamma_k = \gamma \leq \frac{1}{L}$ справедлива следующая оценка сходимости:

$$f\left(\frac{1}{K} \sum_{k=1}^K x^k\right) - f^* \leq \frac{V(x^*, x^0)}{\gamma K}.$$

Доказательство. Начнем с итерации зеркального спуска:

$$\begin{aligned} x^{k+1} &= \operatorname{argmin}_{x \in \mathcal{X}} \{ \langle \gamma \nabla f(x^k), x - x^k \rangle + V(x, x^k) \} \\ &= \operatorname{argmin}_{x \in \mathcal{X}} \{ \langle \gamma \nabla f(x^k), x - x^k \rangle + d(x) - d(x^k) - \langle \nabla d(x^k), x - x^k \rangle \}. \end{aligned}$$

Запишем условие оптимальности на выпуклом множестве $\mathcal{X}$ (Теорема Л9.1) для функции под argmin :

$$\langle \gamma \nabla f(x^k) + \nabla d(x^{k+1}) - \nabla d(x^k), x - x^{k+1} \rangle \geq 0$$

для всех $x \in \mathcal{X}$. Далее применяем равенство параллелограмма для дивергенции Брэгмана (Утверждение Л10.2):

$$V(x, x^{k+1}) + V(x^{k+1}, x^k) - V(x, x^k) = \langle \nabla d(x^k) - \nabla d(x^{k+1}), x - x^{k+1} \rangle.$$

Подставляем в неравенство выше, учитывая знак, получаем:

$$\langle \gamma \nabla f(x^k), x^{k+1} - x \rangle + V(x, x^{k+1}) + V(x^{k+1}, x^k) - V(x, x^k) \leq 0. \quad (\text{Л10.2})$$

Теперь запишем свойство L -гладкости (Теорема Л10.1):

$$f(x^{k+1}) - f(x^k) - \langle \nabla f(x^k), x^{k+1} - x^k \rangle \leq \frac{L}{2} \|x^k - x^{k+1}\|^2. \quad (\text{Л10.3})$$

Сложим неравенство (Л10.2) и домноженное на γ неравенство (Л10.3):

$$\begin{aligned} \langle \gamma \nabla f(x^k), x^{k+1} - x \rangle + V(x, x^{k+1}) + V(x^{k+1}, x^k) - V(x, x^k) \\ + \gamma(f(x^{k+1}) - f(x^k) - \langle \nabla f(x^k), x^{k+1} - x^k \rangle) \leq \frac{\gamma L}{2} \|x^k - x^{k+1}\|^2. \end{aligned}$$

Перепишем, оставив слева только слагаемые с f :

$$\begin{aligned} \langle \gamma \nabla f(x^k), x^k - x \rangle + \gamma(f(x^{k+1}) - f(x^k)) \leq V(x, x^k) - V(x, x^{k+1}) \\ - V(x^{k+1}, x^k) + \frac{\gamma L}{2} \|x^k - x^{k+1}\|^2. \end{aligned} \quad (\text{Л10.4})$$

Из определения выпуклости (Определение Л2.3) можно оценить:

$$f(x^k) - f(x) + \langle \nabla f(x^k), x - x^k \rangle \leq 0. \quad (\text{Л10.5})$$

Домножим неравенство (Л10.5) на γ и сложим с неравенством (Л10.4) (скалярное произведение $\langle \gamma \nabla f(x^k), x^k - x \rangle$ и $f(x^k)$ сокращаются):

$$\gamma(f(x^{k+1}) - f(x)) \leq V(x, x^k) - V(x, x^{k+1}) - V(x^{k+1}, x^k) + \frac{\gamma L}{2} \|x^k - x^{k+1}\|^2. \quad (\text{Л10.6})$$

Запишем второе свойство дивергенции Брэгмана из Утверждения Л10.1:

$$\frac{1}{2} \|x^{k+1} - x^k\|^2 \leq V(x^{k+1}, x^k).$$

и подставим его в неравенство (Л10.6):

$$\gamma(f(x^{k+1}) - f(x)) \leq V(x, x^k) - V(x, x^{k+1}) + (\gamma L - 1)V(x^{k+1}, x^k).$$

Воспользуемся тем, что $\gamma \leq \frac{1}{L}$ и откинем последнее слагаемое:

$$\gamma(f(x^{k+1}) - f(x)) \leq V(x, x^k) - V(x, x^{k+1}).$$

Усредним по всем k от 0 до $K - 1$:

$$\frac{\gamma}{K} \sum_{k=0}^{K-1} (f(x^{k+1}) - f(x)) \leq \frac{1}{K} \sum_{k=0}^{K-1} (V(x, x^k) - V(x, x^{k+1})).$$

Справа свернем телескопическую сумму:

$$\frac{1}{K} \sum_{k=0}^{K-1} (f(x^{k+1}) - f(x)) \leq \frac{1}{\gamma K} (V(x, x^0) - V(x, x^K)) \leq \frac{V(x, x^0)}{\gamma K}.$$

Для левой части применяем неравенство Йенсена (Неравенство (0.1))

$$f\left(\frac{1}{K} \sum_{k=1}^K x^k\right) - f(x) \leq \frac{V(x, x^0)}{\gamma K}.$$

В силу произвольности x , можем взять $x = x^*$:

$$f\left(\frac{1}{K} \sum_{k=1}^K x^k\right) - f^* \leq \frac{V(x^*, x^0)}{\gamma K}.$$

■

Сформулируем следствие о сходимости и оценке на количество итераций при оптимальном значении шага.

Утверждение Л10.3. Пусть задача удовлетворяет условиям Теоремы Л8.3 и выбрано значение шага $\gamma_k = \frac{1}{L}$. Тогда справедлива следующая оценка сходимости:

$$f\left(\frac{1}{K} \sum_{k=1}^K x^k\right) - f^* \leq \frac{LV(x^*, x^0)}{K}.$$

Более того, чтобы добиться точности ε по функции ($f(\frac{1}{K} \sum_{k=1}^K x^k) - f^* \leq \varepsilon$), необходимо

$$K = \mathcal{O}\left(\frac{LV(x^*, x^0)}{\varepsilon}\right) \text{ итераций.}$$

Доказательство. Выпишем оценку из Теоремы Л10.2 и подставим $\gamma = \frac{1}{L}$:

$$f\left(\frac{1}{K} \sum_{k=1}^K x^k\right) - f^* \leq \frac{V(x^*, x^0)}{\gamma K} = \frac{LV(x^*, x^0)}{K}.$$

Чтобы получить оценку на число итераций, отметим, что мы хотим гарантировать:

$$f\left(\frac{1}{K} \sum_{k=1}^K x^k\right) - f^* \leq \frac{LV(x^*, x^0)}{K} \leq \varepsilon.$$

Тогда

$$K \geq \frac{LV(x^*, x^0)}{\varepsilon}.$$

■

Полученный результат сходимости зеркального спуска по форме аналогичен оценке для градиентного спуска. Это объясняется тем, что зеркальный спуск является обобщением градиентного спуска. Но зеркальный спуск может давать лучшие оценки скорости сходимости при более благоприятных значениях константы гладкости L и дивергенции Брэгмана V .

Константа L определяется через условие гладкости функции:

$$\|\nabla f(x) - \nabla f(y)\|_q \leq L\|x - y\|_p,$$

где $p, q \in [1, +\infty]$ образуют гёльдеровскую пару, то есть, $\frac{1}{p} + \frac{1}{q} = 1$.

Выбор нормы в этом определении влияет на значение L . Если $1 \leq p \leq 2$, то выполняются соотношения

$$\|z\|_q \leq \|z\|_2 \leq \|z\|_p,$$

что влечёт $L \leq L_2$. В удачных случаях константа L может быть существенно меньше евклидовой константы гладкости L_2 .

При $1 \leq p \leq 2$ для дивергенции Брэгмана справедлива нижняя оценка (Утверждение Л10.1):

$$V(x, y) \geq \frac{1}{2} \|x - y\|_p^2 \geq \frac{1}{2} \|x - y\|_2^2.$$

Здесь ситуация противоположная: дивергенция Брэгмана не меньше квадрата нормы, что может ухудшить оценку.

Следовательно, преимущество зеркального спуска проявляется тогда, когда уменьшение константы гладкости компенсирует рост дивергенции Брэгмана. Более точно, выигрыш достигается в случае

$$\frac{L_2}{L} \gg \sup_{x, y \in \mathcal{X}} \frac{2V(x, y)}{\|x - y\|_2^2}.$$