

Метод зеркального спуска

Методы оптимизации

Александр Богданов

Московский физико-технический институт

22 апреля 2026



Историческая мотивация

- Посмотрим на итерацию градиентного спуска:

$$x^{k+1} = x^k - \gamma \nabla f(x^k).$$

Историческая мотивация

- Посмотрим на итерацию градиентного спуска:

$$x^{k+1} = x^k - \gamma \nabla f(x^k).$$

- Точка x^k рассматривается как элемент конечномерного линейного нормированного пространства $E = (U, \|\cdot\|)$. **Вопрос:** а что можем сказать про $\nabla f(x^k)$?

Историческая мотивация

- Посмотрим на итерацию градиентного спуска:

$$x^{k+1} = x^k - \gamma \nabla f(x^k).$$

- Точка x^k рассматривается как элемент конечномерного линейного нормированного пространства $E = (U, \|\cdot\|)$. **Вопрос:** а что можем сказать про $\nabla f(x^k)$? В общем случае $\nabla f(x^k)$ лежит в $E^* = (U, \|\cdot\|_*)$, а не в исходном. Тогда с чего мы вдруг начали складывать векторы из абсолютно разных пространств...

Историческая мотивация

- Посмотрим на итерацию градиентного спуска:

$$x^{k+1} = x^k - \gamma \nabla f(x^k).$$

- Точка x^k рассматривается как элемент конечномерного линейного нормированного пространства $E = (U, \|\cdot\|)$. **Вопрос:** а что можем сказать про $\nabla f(x^k)$? В общем случае $\nabla f(x^k)$ лежит в $E^* = (U, \|\cdot\|_*)$, а не в исходном. Тогда с чего мы вдруг начали складывать векторы из абсолютно разных пространств...
- Ничего страшного тут нет в случае когда $\|\cdot\| = \|\cdot\|_2$, тогда $E = E^*$ и все что мы делали было валидно.

Историческая мотивация

- Посмотрим на итерацию градиентного спуска:

$$x^{k+1} = x^k - \gamma \nabla f(x^k).$$

- Точка x^k рассматривается как элемент конечномерного линейного нормированного пространства $E = (U, \|\cdot\|)$. **Вопрос:** а что можем сказать про $\nabla f(x^k)$? В общем случае $\nabla f(x^k)$ лежит в $E^* = (U, \|\cdot\|_*)$, а не в исходном. Тогда с чего мы вдруг начали складывать векторы из абсолютно разных пространств...
- Ничего страшного тут нет в случае когда $\|\cdot\| = \|\cdot\|_2$, тогда $E = E^*$ и все что мы делали было валидно.
- Хотим попробовать выйти за пределы евклидовости. Расстояние не обязательно мерить в евклидовой норме. «Геометрия» задачи может подталкивать использовать другие способы измерения расстояния. Зачем, например, мерить расстояние между распределениями вероятности в евклидовой норме, есть более «физические» способы.

Историческая мотивация

- А. Немировский и Д. Юдин предложили:

$$x^{k+1} = \nabla d^{-1} \left(\nabla d(x^k) - \gamma \nabla f(x^k) \right),$$

где обратное отображение $d^{-1} : E^* \rightarrow E$ возвращает результат в исходное пространство E .

Историческая мотивация

- А. Немировский и Д. Юдин предложили:

$$x^{k+1} = \nabla d^{-1} \left(\nabla d(x^k) - \gamma \nabla f(x^k) \right),$$

где обратное отображение $d^{-1} : E^* \rightarrow E$ возвращает результат в исходное пространство E .

- Получается мы переходим в «зеркальное» пространство E^* , там делаем шаг градиентного спуска, а потом с помощью d^{-1} возвращаемся к x^{k+1} из E .

Историческая мотивация

- А. Немировский и Д. Юдин предложили:

$$x^{k+1} = \nabla d^{-1} \left(\nabla d(x^k) - \gamma \nabla f(x^k) \right),$$

где обратное отображение $d^{-1} : E^* \rightarrow E$ возвращает результат в исходное пространство E .

- Получается мы переходим в «зеркальное» пространство E^* , там делаем шаг градиентного спуска, а потом с помощью d^{-1} возвращаемся к x^{k+1} из E .
- Это и есть идея «зеркальности» градиентного спуска.

Дивергенция Брэгмана

Определение

Пусть дана непрерывно дифференцируемая на выпуклом множестве $\mathcal{X}$ функция $d : \mathcal{X} \rightarrow \mathbb{R}$. Будем говорить, что она является μ -**сильно** выпуклой относительно нормы $\|\cdot\|$ на множестве $\mathcal{X}$, если для любых $x, y \in \mathcal{X}$ выполнено

$$d(x) \geq d(y) + \langle \nabla d(y), x - y \rangle + \frac{\mu}{2} \|x - y\|^2.$$

Дивергенция Брэгмана

Определение

Пусть дана непрерывно дифференцируемая 1-сильно выпуклая относительно нормы $\|\cdot\|$ на множестве $\mathcal{X}$ функция d . **Дивергенцией Брэгмана**, порожденной функцией d на множестве $\mathcal{X}$, называется функция двух аргументов $V(x, y) : \mathcal{X} \times \mathcal{X} \rightarrow \mathbb{R}$ такая, что для любых $x, y \in \mathcal{X}$ выполняется

$$V(x, y) = d(x) - d(y) - \langle \nabla d(y), x - y \rangle.$$

Примеры

- Квадрат евклидовой нормы $d : \mathbb{R}^d \rightarrow \mathbb{R}$:

$$d(x) = \frac{1}{2} \|x\|_2^2 \quad V(x, y) = \frac{1}{2} \|x - y\|_2^2.$$

Примеры

- Квадрат евклидовой нормы $d : \mathbb{R}^d \rightarrow \mathbb{R}$:

$$d(x) = \frac{1}{2} \|x\|_2^2 \quad V(x, y) = \frac{1}{2} \|x - y\|_2^2.$$

- Энтропия Шеннона $d : \Delta_{d-1} \rightarrow \mathbb{R}$:

$$d(x) = \sum_{i=1}^d x_i \log x_i \quad V(x, y) = \sum_{i=1}^d x_i \log \frac{x_i}{y_i}.$$

Примеры

- Квадрат евклидовой нормы $d : \mathbb{R}^d \rightarrow \mathbb{R}$:

$$d(x) = \frac{1}{2} \|x\|_2^2 \quad V(x, y) = \frac{1}{2} \|x - y\|_2^2.$$

- Энтропия Шеннона $d : \Delta_{d-1} \rightarrow \mathbb{R}$:

$$d(x) = \sum_{i=1}^d x_i \log x_i \quad V(x, y) = \sum_{i=1}^d x_i \log \frac{x_i}{y_i}.$$

- Энтропия фон Неймана $d : \mathbb{S}_1^d \rightarrow \mathbb{R}$:

$$d(X) = \text{Tr}(X \log X) \quad V(X, Y) = \text{Tr}(X \log X - X \log Y).$$

Примеры

- Квадрат евклидовой нормы $d : \mathbb{R}^d \rightarrow \mathbb{R}$:

$$d(x) = \frac{1}{2} \|x\|_2^2 \quad V(x, y) = \frac{1}{2} \|x - y\|_2^2.$$

- Энтропия Шеннона $d : \Delta_{d-1} \rightarrow \mathbb{R}$:

$$d(x) = \sum_{i=1}^d x_i \log x_i \quad V(x, y) = \sum_{i=1}^d x_i \log \frac{x_i}{y_i}.$$

- Энтропия фон Неймана $d : \mathbb{S}_1^d \rightarrow \mathbb{R}$:

$$d(X) = \text{Tr}(X \log X) \quad V(X, Y) = \text{Tr}(X \log X - X \log Y).$$

- Логарифмический барьер $d : \mathbb{S}_{++}^d \rightarrow \mathbb{R}$:

$$d(X) = -\log(\det X) \quad V(X, Y) = \text{Tr}(XY^{-1} - I_d) - \log \det(XY^{-1}).$$

Свойства дивергенции Брэгмана

Утверждение

Пусть $\mathcal{X}$ — выпуклое множество. Дивергенция Брэгмана в общем случае обладает следующими свойствами:

- 1 Асимметричность: в общем случае $V(x, y) \neq V(y, x)$.

Свойства дивергенции Брэгмана

Утверждение

Пусть $\mathcal{X}$ — выпуклое множество. Дивергенция Брэгмана в общем случае обладает следующими свойствами:

- 1 Асимметричность: в общем случае $V(x, y) \neq V(y, x)$.
- 2 Ограниченность снизу:

$$V(x, y) \geq \frac{1}{2} \|x - y\|^2 \text{ для всех } x, y \in \mathcal{X}.$$

Свойства дивергенции Брэгмана

Утверждение

Пусть $\mathcal{X}$ — выпуклое множество. Дивергенция Брэгмана в общем случае обладает следующими свойствами:

- 1 Асимметричность: в общем случае $V(x, y) \neq V(y, x)$.
- 2 Ограниченность снизу:

$$V(x, y) \geq \frac{1}{2} \|x - y\|^2 \text{ для всех } x, y \in \mathcal{X}.$$

- 3 Неотрицательность: $V(x, y) \geq 0$ для всех $x, y \in \mathcal{X}$.

Свойства дивергенции Брэгмана

Утверждение

Пусть $\mathcal{X}$ — выпуклое множество. Дивергенция Брэгмана в общем случае обладает следующими свойствами:

- 1 Асимметричность: в общем случае $V(x, y) \neq V(y, x)$.
- 2 Ограниченность снизу:

$$V(x, y) \geq \frac{1}{2} \|x - y\|^2 \text{ для всех } x, y \in \mathcal{X}.$$

- 3 Неотрицательность: $V(x, y) \geq 0$ для всех $x, y \in \mathcal{X}$.
- 4 1-сильная выпуклость по первому аргументу.

Свойства дивергенции Брэгмана

Утверждение

Пусть $\mathcal{X}$ — выпуклое множество. Дивергенция Брэгмана в общем случае обладает следующими свойствами:

- 1 Асимметричность: в общем случае $V(x, y) \neq V(y, x)$.
- 2 Ограниченность снизу:

$$V(x, y) \geq \frac{1}{2} \|x - y\|^2 \text{ для всех } x, y \in \mathcal{X}.$$

- 3 Неотрицательность: $V(x, y) \geq 0$ для всех $x, y \in \mathcal{X}$.
- 4 1-сильная выпуклость по первому аргументу.
- 5 По второму аргументу может не быть выпуклости.

Равенство параллелограмма/теорема Пифагора

Утверждение

Пусть $\mathcal{X}$ — выпуклое множество. Для любых точек $x, y, z \in \mathcal{X}$:

$$V(z, x) + V(x, y) - V(z, y) = \langle \nabla d(y) - \nabla d(x), z - x \rangle.$$

Равенство параллелограмма/теорема Пифагора

Утверждение

Пусть $\mathcal{X}$ — выпуклое множество. Для любых точек $x, y, z \in \mathcal{X}$:

$$V(z, x) + V(x, y) - V(z, y) = \langle \nabla d(y) - \nabla d(x), z - x \rangle.$$

$$\begin{aligned} V(z, x) + V(x, y) &= d(z) - d(x) - \langle \nabla d(x), z - x \rangle \\ &\quad + d(x) - d(y) - \langle \nabla d(y), x - y \rangle \\ &= d(z) - d(y) - \langle \nabla d(y), z - y \rangle \\ &\quad - \langle \nabla d(x) - \nabla d(y), z - x \rangle \\ &= V(z, y) - \langle \nabla d(x) - \nabla d(y), z - x \rangle. \end{aligned}$$

Метод зеркального спуска

Решаем задачу

$$\min_{x \in \mathcal{X}} f(x),$$

где множество $\mathcal{X}$ выпуклое и замкнутое, а функция f — выпуклая.

Метод зеркального спуска

Решаем задачу

$$\min_{x \in \mathcal{X}} f(x),$$

где множество $\mathcal{X}$ выпуклое и замкнутое, а функция f — выпуклая.

- Итерация градиентного спуска:

$$x^{k+1} = x^k - \gamma_k \nabla f(x^k).$$

Метод зеркального спуска

Решаем задачу

$$\min_{x \in \mathcal{X}} f(x),$$

где множество $\mathcal{X}$ выпуклое и замкнутое, а функция f — выпуклая.

- Итерация градиентного спуска:

$$x^{k+1} = x^k - \gamma_k \nabla f(x^k).$$

- С точки зрения оптимизации данная итерация является решением следующей задачи:

$$\operatorname{argmin}_{x \in \mathbb{R}^d} \left\{ f(x^k) + \left\langle \nabla f(x^k), x - x^k \right\rangle + \frac{1}{2\gamma_k} \|x - x^k\|_2^2 \right\}.$$

Метод зеркального спуска

Решаем задачу

$$\min_{x \in \mathcal{X}} f(x),$$

где множество $\mathcal{X}$ выпуклое и замкнутое, а функция f — выпуклая.

- Итерация градиентного спуска:

$$x^{k+1} = x^k - \gamma_k \nabla f(x^k).$$

- С точки зрения оптимизации данная итерация является решением следующей задачи:

$$\operatorname{argmin}_{x \in \mathbb{R}^d} \left\{ f(x^k) + \langle \nabla f(x^k), x - x^k \rangle + \frac{1}{2\gamma_k} \|x - x^k\|_2^2 \right\}.$$

- Заменим евклидову норму $\frac{1}{2} \|x - x^k\|_2^2$ на $V(x, x^k)$:

$$\operatorname{argmin}_{x \in \mathcal{X}} \left\{ f(x^k) + \langle \nabla f(x^k), x - x^k \rangle + \frac{1}{\gamma_k} V(x, x^k) \right\}.$$

Метод зеркального спуска

Алгоритм Зеркальный спуск

Вход: стартовая точка $x^0 \in \mathcal{X}$, размеры шагов $\{\gamma_k\}_{k=0} > 0$, количество итераций K

- 1: **for** $k = 0, 1, \dots, K - 1$ **do**
- 2: $x^{k+1} = \operatorname{argmin}_{x \in \mathcal{X}} \{ \langle \gamma_k \nabla f(x^k), x - x^k \rangle + V(x, x^k) \}$
- 3: **end for**

Выход: $\frac{1}{K} \sum_{k=1}^K x^k$

Примеры

Квадрат евклидовой нормы $V : \mathcal{X} \times \mathcal{X} \rightarrow \mathbb{R}$:

$$V(x, y) = \frac{1}{2} \|x - y\|_2^2, \quad x, y \in \mathcal{X}.$$

Примеры

Квадрат евклидовой нормы $V : \mathcal{X} \times \mathcal{X} \rightarrow \mathbb{R}$:

$$V(x, y) = \frac{1}{2} \|x - y\|_2^2, \quad x, y \in \mathcal{X}.$$

Чтобы посчитать argmin , добавим слагаемые не зависящие от x и выделим квадрат нормы:

$$\begin{aligned} x^{k+1} &= \operatorname{argmin}_{x \in \mathcal{X}} \left\{ \frac{1}{2} \gamma_k^2 \left\| \nabla f(x^k) \right\|_2^2 + \left\langle \gamma_k \nabla f(x^k), x - x^k \right\rangle + \frac{1}{2} \|x - x^k\|_2^2 \right\} \\ &= \operatorname{argmin}_{x \in \mathcal{X}} \left\| x - \left(x^k - \gamma_k \nabla f(x^k) \right) \right\|_2^2 = \Pi_{\mathcal{X}} \left(x^k - \gamma_k \nabla f(x^k) \right). \end{aligned}$$

Получился градиентный спуск с евклидовой проекцией.

Примеры

Рассмотрим метод при $\mathcal{X} = \mathbb{R}^d$ и некоторой d :

$$\begin{aligned}x^{k+1} &= \operatorname{argmin}_{x \in \mathcal{X}} \{ \langle \gamma_k \nabla f(x^k), x - x^k \rangle + V(x, x^k) \} \\&= \operatorname{argmin}_{x \in \mathbb{R}^d} \{ \langle \gamma_k \nabla f(x^k), x - x^k \rangle + d(x) - d(x^k) - \langle \nabla d(x^k), x - x^k \rangle \}.\end{aligned}$$

Примеры

Рассмотрим метод при $\mathcal{X} = \mathbb{R}^d$ и некоторой d :

$$\begin{aligned} x^{k+1} &= \operatorname{argmin}_{x \in \mathcal{X}} \{ \langle \gamma_k \nabla f(x^k), x - x^k \rangle + V(x, x^k) \} \\ &= \operatorname{argmin}_{x \in \mathbb{R}^d} \{ \langle \gamma_k \nabla f(x^k), x - x^k \rangle + d(x) - d(x^k) - \langle \nabla d(x^k), x - x^k \rangle \}. \end{aligned}$$

Запишем условие оптимальности:

$$\gamma_k \nabla f(x^k) + \nabla d(x) - \nabla d(x^k) = 0.$$

Рассмотрим метод при $\mathcal{X} = \mathbb{R}^d$ и некоторой d :

$$\begin{aligned} x^{k+1} &= \operatorname{argmin}_{x \in \mathcal{X}} \{ \langle \gamma_k \nabla f(x^k), x - x^k \rangle + V(x, x^k) \} \\ &= \operatorname{argmin}_{x \in \mathbb{R}^d} \{ \langle \gamma_k \nabla f(x^k), x - x^k \rangle + d(x) - d(x^k) - \langle \nabla d(x^k), x - x^k \rangle \}. \end{aligned}$$

Запишем условие оптимальности:

$$\gamma_k \nabla f(x^k) + \nabla d(x) - \nabla d(x^k) = 0.$$

Это и есть идея Немировского и Юдина, идея «зеркальности».

$$\nabla d(x^{k+1}) = \nabla d(x^k) - \gamma_k \nabla f(x^k).$$

Примеры

Дивергенция Кульбака–Лейблера $V : \Delta_{d-1} \times \Delta_{d-1} \rightarrow \mathbb{R}$:

$$V(x, y) = \sum_{i=1}^d x_i \log \frac{x_i}{y_i}, \quad x, y \in \Delta_{d-1}.$$

Примеры

Дивергенция Кульбака–Лейблера $V : \Delta_{d-1} \times \Delta_{d-1} \rightarrow \mathbb{R}$:

$$V(x, y) = \sum_{i=1}^d x_i \log \frac{x_i}{y_i}, \quad x, y \in \Delta_{d-1}.$$

Запишем итерацию зеркального спуска как задачу с ограничениями:

$$\begin{aligned} \min_{x \in \mathbb{R}^d} \quad & \left\langle \gamma_k \nabla f(x^k), x \right\rangle + V(x, x^k) \\ \text{s.t.} \quad & -x_i \leq 0 \\ & \sum_{i=1}^d x_i - 1 = 0. \end{aligned}$$

Примеры

Лагранжиан для такой задачи:

$$\begin{aligned}\mathcal{L}(x, \lambda, \nu) &= \langle \gamma_k \nabla f(x^k), x \rangle + V(x, x^k) - \sum_{i=1}^d \lambda_i x_i + \nu \left(\sum_{i=1}^d x_i - 1 \right) \\ &= \sum_{i=1}^d \left(\gamma_k \left[\nabla f(x^k) \right]_i + \log \frac{x_i}{x_i^k} - \lambda_i + \nu \right) x_i - \nu.\end{aligned}$$

Примеры

Лагранжиан для такой задачи:

$$\begin{aligned}\mathcal{L}(x, \lambda, \nu) &= \langle \gamma_k \nabla f(x^k), x \rangle + V(x, x^k) - \sum_{i=1}^d \lambda_i x_i + \nu \left(\sum_{i=1}^d x_i - 1 \right) \\ &= \sum_{i=1}^d \left(\gamma_k \left[\nabla f(x^k) \right]_i + \log \frac{x_i}{x_i^k} - \lambda_i + \nu \right) x_i - \nu.\end{aligned}$$

Условие оптимальности по x_i :

$$\frac{\partial \mathcal{L}}{\partial x_i}(x, \lambda, \nu) = 1 + \gamma_k \left[\nabla f(x^k) \right]_i + \log \frac{x_i}{x_i^k} - \lambda_i + \nu = 0.$$

Примеры

Лагранжиан для такой задачи:

$$\begin{aligned}\mathcal{L}(x, \lambda, \nu) &= \langle \gamma_k \nabla f(x^k), x \rangle + V(x, x^k) - \sum_{i=1}^d \lambda_i x_i + \nu \left(\sum_{i=1}^d x_i - 1 \right) \\ &= \sum_{i=1}^d \left(\gamma_k \left[\nabla f(x^k) \right]_i + \log \frac{x_i}{x_i^k} - \lambda_i + \nu \right) x_i - \nu.\end{aligned}$$

Условие оптимальности по x_i :

$$\frac{\partial \mathcal{L}}{\partial x_i}(x, \lambda, \nu) = 1 + \gamma_k \left[\nabla f(x^k) \right]_i + \log \frac{x_i}{x_i^k} - \lambda_i + \nu = 0.$$

Отсюда находим x , доставляющий минимум лагранжиана:

$$x_i = x_i^k \exp \left(-1 - \gamma_k \left[\nabla f(x^k) \right]_i + \lambda_i - \nu \right), \quad i = \overline{1, d}.$$

Примеры

Из условия дополняющей нежесткости получаем:

$$x_i = x_i^k \exp \left(-1 - \gamma_k \left[\nabla f(x^k) \right]_i - \nu \right), \quad i = \overline{1, d}.$$

Примеры

Из условия дополняющей нежесткости получаем:

$$x_i = x_i^k \exp \left(-1 - \gamma_k \left[\nabla f(x^k) \right]_i - \nu \right), \quad i = \overline{1, d}.$$

Чтобы записать выражение для ν , вспомним ограничения задачи $\sum_{i=1}^d x_i = 1$. Отсюда получаем нормировку и можно записать:

$$x_i^{k+1} = x_i^k \frac{\exp(-\gamma_k [\nabla f(x^k)]_i)}{\sum_{i=1}^d x_i^k \exp(-\gamma_k [\nabla f(x^k)]_i)}.$$

Обобщение L -гладкости

Определение

Пусть дана непрерывно дифференцируемая на выпуклом множестве $\mathcal{X}$ функция $f : \mathcal{X} \rightarrow \mathbb{R}$. Будем говорить, что данная функция имеет L -Липшицев градиент (является L -гладкой) относительно нормы $\|\cdot\|$ на $\mathcal{X}$, если для любых $x, y \in \mathcal{X}$ выполнено

$$\|\nabla f(x) - \nabla f(y)\|_* \leq L\|x - y\|.$$

Свойство L -гладкой функции

Теорема

Пусть $\mathcal{X}$ — выпуклое множество. Для L -гладкой относительно нормы $\|\cdot\|$ функции $f : \mathcal{X} \rightarrow \mathbb{R}$ выполнено

$$|f(y) - f(x) - \langle \nabla f(x), y - x \rangle| \leq \frac{L}{2} \|x - y\|^2.$$

Доказательство

Используем формулу Ньютона–Лейбница для криволинейного интеграла второго рода по кривой, заданной вектор функцией $r(\tau)$:

$$\int_a^b \langle \nabla f(r(\tau)), dr(\tau) \rangle = f(r(b)) - f(r(a)).$$

Доказательство

Используем формулу Ньютона–Лейбница для криволинейного интеграла второго рода по кривой, заданной вектор функцией $r(\tau)$:

$$\int_a^b \langle \nabla f(r(\tau)), dr(\tau) \rangle = f(r(b)) - f(r(a)).$$

В нашем случае выберем кривую следующим образом $r(\tau) = x + \tau(y - x)$, где $\tau \in [0, 1]$. Тогда

$$\begin{aligned} f(y) - f(x) &= \int_0^1 \langle \nabla f(x + \tau(y - x)), y - x \rangle d\tau \\ &= \langle \nabla f(x), y - x \rangle + \int_0^1 \langle \nabla f(x + \tau(y - x)) - \nabla f(x), y - x \rangle d\tau. \end{aligned}$$

Доказательство

Переместив скалярное произведение влево и взяв модуль от обеих частей, получим:

$$\begin{aligned} |f(y) - f(x) - \langle \nabla f(x), y - x \rangle| &= \left| \int_0^1 \langle \nabla f(x + \tau(y - x)) - \nabla f(x), y - x \rangle d\tau \right| \\ &\leq \int_0^1 |\langle \nabla f(x + \tau(y - x)) - \nabla f(x), y - x \rangle| d\tau. \end{aligned}$$

Доказательство

Переместив скалярное произведение влево и взяв модуль от обеих частей, получим:

$$\begin{aligned} |f(y) - f(x) - \langle \nabla f(x), y - x \rangle| &= \left| \int_0^1 \langle \nabla f(x + \tau(y - x)) - \nabla f(x), y - x \rangle d\tau \right| \\ &\leq \int_0^1 |\langle \nabla f(x + \tau(y - x)) - \nabla f(x), y - x \rangle| d\tau. \end{aligned}$$

Далее воспользуемся неравенством Гёльдера, а затем L -гладкостью относительно нормы $\|\cdot\|$:

$$\begin{aligned} |f(y) - f(x) - \langle \nabla f(x), y - x \rangle| &\leq \int_0^1 \|\nabla f(x + \tau(y - x)) - \nabla f(x)\|_* \|y - x\| \, d\tau \\ &\leq L \|y - x\|^2 \int_0^1 \tau \, d\tau = \frac{L}{2} \|x - y\|^2. \end{aligned}$$

Сходимость

Начнем с итерации зеркального спуска:

$$\begin{aligned}x^{k+1} &= \operatorname{argmin}_{x \in \mathcal{X}} \{ \langle \gamma \nabla f(x^k), x - x^k \rangle + V(x, x^k) \} \\&= \operatorname{argmin}_{x \in \mathcal{X}} \{ \langle \gamma \nabla f(x^k), x - x^k \rangle + d(x) - d(x^k) - \langle \nabla d(x^k), x - x^k \rangle \}.\end{aligned}$$

Сходимость

Начнем с итерации зеркального спуска:

$$\begin{aligned}x^{k+1} &= \operatorname{argmin}_{x \in \mathcal{X}} \{ \langle \gamma \nabla f(x^k), x - x^k \rangle + V(x, x^k) \} \\&= \operatorname{argmin}_{x \in \mathcal{X}} \{ \langle \gamma \nabla f(x^k), x - x^k \rangle + d(x) - d(x^k) - \langle \nabla d(x^k), x - x^k \rangle \}.\end{aligned}$$

Запишем условие оптимальности на выпуклом множестве $\mathcal{X}$ для функции под argmin :

$$\langle \gamma \nabla f(x^k) + \nabla d(x^{k+1}) - \nabla d(x^k), x - x^{k+1} \rangle \geq 0$$

для всех $x \in \mathcal{X}$.

Сходимость

Применим равенство параллелограмма для дивергенции Брэгмана:

$$V(x, x^{k+1}) + V(x^{k+1}, x^k) - V(x, x^k) = \langle \nabla d(x^k) - \nabla d(x^{k+1}), x - x^{k+1} \rangle.$$

Сходимость

Применим равенство параллелограмма для дивергенции Брэгмана:

$$V(x, x^{k+1}) + V(x^{k+1}, x^k) - V(x, x^k) = \langle \nabla d(x^k) - \nabla d(x^{k+1}), x - x^{k+1} \rangle.$$

Подставляем в неравенство выше, учитывая знак, получаем:

$$\langle \gamma \nabla f(x^k), x^{k+1} - x \rangle + V(x, x^{k+1}) + V(x^{k+1}, x^k) - V(x, x^k) \leq 0.$$

Сходимость

Применим равенство параллелограмма для дивергенции Брэгмана:

$$V(x, x^{k+1}) + V(x^{k+1}, x^k) - V(x, x^k) = \langle \nabla d(x^k) - \nabla d(x^{k+1}), x - x^{k+1} \rangle.$$

Подставляем в неравенство выше, учитывая знак, получаем:

$$\langle \gamma \nabla f(x^k), x^{k+1} - x \rangle + V(x, x^{k+1}) + V(x^{k+1}, x^k) - V(x, x^k) \leq 0.$$

Запишем свойство L -гладкости:

$$f(x^{k+1}) - f(x^k) - \langle \nabla f(x^k), x^{k+1} - x^k \rangle \leq \frac{L}{2} \|x^k - x^{k+1}\|^2.$$

Сходимость

Сложим основное неравенство и предыдущее неравенство домноженное на γ :

$$\begin{aligned} & \left\langle \gamma \nabla f(x^k), x^{k+1} - x^k \right\rangle + V(x, x^{k+1}) + V(x^{k+1}, x^k) - V(x, x^k) \\ & + \gamma \left(f(x^{k+1}) - f(x^k) - \left\langle \nabla f(x^k), x^{k+1} - x^k \right\rangle \right) \leq \frac{\gamma L}{2} \|x^k - x^{k+1}\|^2. \end{aligned}$$

Сходимость

Сложим основное неравенство и предыдущее неравенство домноженное на γ :

$$\begin{aligned} & \left\langle \gamma \nabla f(x^k), x^{k+1} - x \right\rangle + V(x, x^{k+1}) + V(x^{k+1}, x^k) - V(x, x^k) \\ & + \gamma \left(f(x^{k+1}) - f(x^k) - \left\langle \nabla f(x^k), x^{k+1} - x^k \right\rangle \right) \leq \frac{\gamma L}{2} \|x^k - x^{k+1}\|^2. \end{aligned}$$

Перепишем, оставив слева только слагаемые с f :

$$\begin{aligned} & \left\langle \gamma \nabla f(x^k), x^k - x \right\rangle + \gamma \left(f(x^{k+1}) - f(x^k) \right) \leq V(x, x^k) - V(x, x^{k+1}) \\ & - V(x^{k+1}, x^k) + \frac{\gamma L}{2} \|x^k - x^{k+1}\|^2. \end{aligned}$$

Сходимость

Из определения выпуклости можно оценить:

$$f(x^k) - f(x) + \langle \nabla f(x^k), x - x^k \rangle \leq 0.$$

Сходимость

Из определения выпуклости можно оценить:

$$f(x^k) - f(x) + \langle \nabla f(x^k), x - x^k \rangle \leq 0.$$

Домножим предыдущее неравенство на γ и сложим с основным неравенством:

$$\begin{aligned} \gamma \left(f(x^{k+1}) - f(x) \right) &\leq V(x, x^k) - V(x, x^{k+1}) - V(x^{k+1}, x^k) \\ &\quad + \frac{\gamma L}{2} \|x^k - x^{k+1}\|^2. \end{aligned}$$

Сходимость

Запишем второе свойство дивергенции Брэгмана:

$$\frac{1}{2} \|x^{k+1} - x^k\|^2 \leq V(x^{k+1}, x^k).$$

Сходимость

Запишем второе свойство дивергенции Брэгмана:

$$\frac{1}{2} \|x^{k+1} - x^k\|^2 \leq V(x^{k+1}, x^k).$$

Подставим его в основное неравенство:

$$\gamma \left(f(x^{k+1}) - f(x) \right) \leq V(x, x^k) - V(x, x^{k+1}) + (\gamma L - 1) V(x^{k+1}, x^k).$$

Сходимость

Запишем второе свойство дивергенции Брэгмана:

$$\frac{1}{2} \|x^{k+1} - x^k\|^2 \leq V(x^{k+1}, x^k).$$

Подставим его в основное неравенство:

$$\gamma \left(f(x^{k+1}) - f(x) \right) \leq V(x, x^k) - V(x, x^{k+1}) + (\gamma L - 1) V(x^{k+1}, x^k).$$

Возьмём $\gamma \leq \frac{1}{L}$ и откинем последнее слагаемое:

$$\gamma \left(f(x^{k+1}) - f(x) \right) \leq V(x, x^k) - V(x, x^{k+1}).$$

Сходимость

Усредним по всем k от 0 до $K - 1$:

$$\frac{\gamma}{K} \sum_{k=0}^{K-1} (f(x^{k+1}) - f(x)) \leq \frac{1}{K} \sum_{k=0}^{K-1} (V(x, x^k) - V(x, x^{k+1})).$$

Сходимость

Усредним по всем k от 0 до $K - 1$:

$$\frac{\gamma}{K} \sum_{k=0}^{K-1} (f(x^{k+1}) - f(x)) \leq \frac{1}{K} \sum_{k=0}^{K-1} (V(x, x^k) - V(x, x^{k+1})).$$

Справа свернем телескопическую сумму:

$$\frac{1}{K} \sum_{k=0}^{K-1} (f(x^{k+1}) - f(x)) \leq \frac{1}{\gamma K} (V(x, x^0) - V(x, x^K)) \leq \frac{V(x, x^0)}{\gamma K}.$$

Сходимость

Усредним по всем k от 0 до $K - 1$:

$$\frac{\gamma}{K} \sum_{k=0}^{K-1} (f(x^{k+1}) - f(x)) \leq \frac{1}{K} \sum_{k=0}^{K-1} (V(x, x^k) - V(x, x^{k+1})).$$

Справа свернем телескопическую сумму:

$$\frac{1}{K} \sum_{k=0}^{K-1} (f(x^{k+1}) - f(x)) \leq \frac{1}{\gamma K} (V(x, x^0) - V(x, x^K)) \leq \frac{V(x, x^0)}{\gamma K}.$$

Для левой части применяем неравенство Йенсена

$$f\left(\frac{1}{K} \sum_{k=1}^K x^k\right) - f(x) \leq \frac{V(x, x^0)}{\gamma K}.$$

Сходимость

Усредним по всем k от 0 до $K - 1$:

$$\frac{\gamma}{K} \sum_{k=0}^{K-1} (f(x^{k+1}) - f(x)) \leq \frac{1}{K} \sum_{k=0}^{K-1} (V(x, x^k) - V(x, x^{k+1})).$$

Справа свернем телескопическую сумму:

$$\frac{1}{K} \sum_{k=0}^{K-1} (f(x^{k+1}) - f(x)) \leq \frac{1}{\gamma K} (V(x, x^0) - V(x, x^K)) \leq \frac{V(x, x^0)}{\gamma K}.$$

Для левой части применяем неравенство Йенсена

$$f\left(\frac{1}{K} \sum_{k=1}^K x^k\right) - f(x) \leq \frac{V(x, x^0)}{\gamma K}.$$

В силу произвольности x , можем взять $x = x^*$:

$$f\left(\frac{1}{K} \sum_{k=1}^K x^k\right) - f^* \leq \frac{V(x^*, x^0)}{\gamma K}.$$

Сходимость

Теорема

Пусть задача оптимизации на выпуклом замкнутом множестве $\mathcal{X}$ с L -гладкой относительно нормы $\|\cdot\|$ выпуклой целевой функцией f решается с помощью зеркального спуска. Тогда при $\gamma_k = \gamma \leq \frac{1}{L}$ справедлива следующая оценка сходимости:

$$f\left(\frac{1}{K} \sum_{k=1}^K x^k\right) - f^* \leq \frac{V(x^*, x^0)}{\gamma K}.$$

Итог

- Результат очень похож на сходимость градиентного спуска и обобщает его.

Итог

- Результат очень похож на сходимость градиентного спуска и обобщает его.
- **Вопрос:** а может ли оценка зеркального спуска быть лучше, чем для градиентного? Где проявится этот эффект?

Итог

- Результат очень похож на сходимость градиентного спуска и обобщает его.
- **Вопрос:** а может ли оценка зеркального спуска быть лучше, чем для градиентного? Где проявится этот эффект? В L и V .
- Если $1 \leq p \leq 2$, то $\|\cdot\|_2 \leq \|\cdot\|_p$, $\|\cdot\|_q \leq \|\cdot\|_2$.

Итог

- Результат очень похож на сходимость градиентного спуска и обобщает его.
- **Вопрос:** а может ли оценка зеркального спуска быть лучше, чем для градиентного? Где проявится этот эффект? В L и V .
- Если $1 \leq p \leq 2$, то $\|\cdot\|_2 \leq \|\cdot\|_p$, $\|\cdot\|_q \leq \|\cdot\|_2$.
- **Вопрос:** что тогда можно сказать про отношение L и L_2 ?

Итог

- Результат очень похож на сходимость градиентного спуска и обобщает его.
- **Вопрос:** а может ли оценка зеркального спуска быть лучше, чем для градиентного? Где проявится этот эффект? В L и V .
- Если $1 \leq p \leq 2$, то $\|\cdot\|_2 \leq \|\cdot\|_p$, $\|\cdot\|_q \leq \|\cdot\|_2$.
- **Вопрос:** что тогда можно сказать про отношение L и L_2 ? $L \leq L_2$, а в хорошем случае L значительно меньше.

Итог

- Результат очень похож на сходимость градиентного спуска и обобщает его.
- **Вопрос:** а может ли оценка зеркального спуска быть лучше, чем для градиентного? Где проявится этот эффект? В L и V .
- Если $1 \leq p \leq 2$, то $\|\cdot\|_2 \leq \|\cdot\|_p$, $\|\cdot\|_q \leq \|\cdot\|_2$.
- **Вопрос:** что тогда можно сказать про отношение L и L_2 ? $L \leq L_2$, а в хорошем случае L значительно меньше.
- **Вопрос:** с дивергенций тоже всё хорошо?

Итог

- Результат очень похож на сходимость градиентного спуска и обобщает его.
- **Вопрос:** а может ли оценка зеркального спуска быть лучше, чем для градиентного? Где проявится этот эффект? В L и V .
- Если $1 \leq p \leq 2$, то $\|\cdot\|_2 \leq \|\cdot\|_p$, $\|\cdot\|_q \leq \|\cdot\|_2$.
- **Вопрос:** что тогда можно сказать про отношение L и L_2 ? $L \leq L_2$, а в хорошем случае L значительно меньше.
- **Вопрос:** с дивергенцией тоже всё хорошо? Там ситуация обратная для $1 \leq p \leq 2$:

$$V(x, y) \geq \frac{1}{2} \|x - y\|_p^2 \geq \frac{1}{2} \|x - y\|_2^2.$$

Итог

- Результат очень похож на сходимость градиентного спуска и обобщает его.
- **Вопрос:** а может ли оценка зеркального спуска быть лучше, чем для градиентного? Где проявится этот эффект? В L и V .
- Если $1 \leq p \leq 2$, то $\|\cdot\|_2 \leq \|\cdot\|_p$, $\|\cdot\|_q \leq \|\cdot\|_2$.
- **Вопрос:** что тогда можно сказать про отношение L и L_2 ? $L \leq L_2$, а в хорошем случае L значительно меньше.
- **Вопрос:** с дивергенцией тоже всё хорошо? Там ситуация обратная для $1 \leq p \leq 2$:

$$V(x, y) \geq \frac{1}{2} \|x - y\|_p^2 \geq \frac{1}{2} \|x - y\|_2^2.$$

- Выигрыш будет, если

$$\frac{L_2}{L} \gg \sup_{x, y \in \mathcal{X}} \frac{2V(x, y)}{\|x - y\|_2^2}.$$