

Л11 Метод штрафов. ADMM

До этого параграфа мы рассматривали лишь безусловные задачи и задачи оптимизации на множестве. Между тем, общая постановка оптимизационной задачи (Л1.1) включает ограничения вида неравенств и равенств, методы для которой нами ещё не были разработаны. Этот параграф посвящён построению подходов к таким задачам, в частности — методу штрафов.

Л11.1 Штрафная функция

Рассмотрим следующую задачу с ограничениями:

$$\begin{aligned} \min_{x \in \mathbb{R}^d} \quad & f(x) \\ \text{s.t.} \quad & h_j(x) = 0, \quad j = \overline{1, m}. \end{aligned} \quad (\text{Л11.1})$$

Возьмем некоторое $\rho > 0$ и немного модифицируем нашу задачу:

$$\begin{aligned} \min_{x \in \mathbb{R}^d} \quad & f(x) + \rho \cdot \frac{1}{2} \sum_{j=1}^m h_j^2(x) \\ \text{s.t.} \quad & h_j(x) = 0, \quad j = \overline{1, m}. \end{aligned}$$

Замечание Л11.1. Можно заметить, что новая задача эквивалентна старой, так как для x , удовлетворяющих ограничениям, «добавка» равна 0.

Теперь запишем безусловную задачу с такой же целевой функцией:

$$\min_{x \in \mathbb{R}^d} \left[f_\rho(x) = f(x) + \rho \cdot \frac{1}{2} \sum_{j=1}^m h_j^2(x) \right]. \quad (\text{Л11.2})$$

Легко проверить, что полученная задача не эквивалентна исходной: безусловный минимум $f_\rho(x)$ вообще не обязан удовлетворять ограничениям.

Задача с ограничениями стала задачей без ограничений, такое мы уже умеем решать. При таком переходе f_ρ называют *штрафной функцией*, а ρ — *параметром штрафа*. Попробуем увеличить штраф за нарушение ограничений. Предельный переход по ρ :

$$\lim_{\rho \rightarrow +\infty} f_\rho(x) = \begin{cases} f(x), & h_j(x) = 0, \quad j = \overline{1, m} \\ +\infty, & \text{иначе} \end{cases}$$

Замечание Л11.2. Есть надежда, что минимизируя f_ρ при решении штрафной задачи для достаточно большого ρ , мы получим неплохое решение и для исходной задачи.

Добавим еще ограничения вида неравенств:

$$\begin{aligned} \min_{x \in \mathbb{R}^d} \quad & f(x) \\ \text{s.t.} \quad & g_i(x) \leq 0, \quad i = \overline{1, n} \\ & h_j(x) = 0, \quad j = \overline{1, m}. \end{aligned}$$

Как их добавить в штраф? Сделаем это с помощью положительной «срезки»:

$$f_\rho(x) = f(x) + \rho \cdot \frac{1}{2} \sum_{j=1}^m h_j^2(x) + \rho \cdot \frac{1}{2} \sum_{i=1}^n (g_i^+(x))^2,$$

где $y^+ = \max\{y, 0\}$. Штраф активируется только тогда, когда нарушено неравенство.

Л11.2 Свойства решений штрафной задачи

Утверждение Л11.1. Пусть x^* — решение исходной задачи (Л11.1), а x_ρ^* — решение соответствующей штрафной задачи (Л11.2) с $\rho > 0$, тогда

$$f(x^*) \geq f(x_\rho^*).$$

Доказательство. Воспользуемся тем, что x^* удовлетворяет ограничениям, а x_ρ^* — безусловный минимум f_ρ :

$$f(x^*) = f_\rho(x^*) \geq \min_{x \in \mathbb{R}^d} f_\rho(x) = f_\rho(x_\rho^*) \geq f(x_\rho^*).$$

■

Этот результат говорит о том, что либо $f(x^*) = f(x_\rho^*)$, либо мы нарушаем ограничения. Но за счет ρ с этим можно бороться. Следующие два свойства посвящены этому.

Утверждение Л11.2. С увеличением параметра штрафа ρ решения штрафной задачи (Л11.2), при его существовании, гарантированно не ухудшают степень нарушения ограничений, то есть, для $\rho_1 > \rho_2$ следует, что

$$\sum_{j=1}^m h_j^2(x_{\rho_2}^*) \geq \sum_{j=1}^m h_j^2(x_{\rho_1}^*),$$

где $x_{\rho_1}^*$ и $x_{\rho_2}^*$ — решения соответствующих штрафных задач.

Доказательство. Пользуемся тем, что $x_{\rho_1}^*$ и $x_{\rho_2}^*$ — решения соответствующих штрафных задач:

$$\begin{aligned} f(x_{\rho_2}^*) + \rho_1 \cdot \frac{1}{2} \sum_{j=1}^m h_j^2(x_{\rho_2}^*) &\geq f(x_{\rho_1}^*) + \rho_1 \cdot \frac{1}{2} \sum_{j=1}^m h_j^2(x_{\rho_1}^*) \\ f(x_{\rho_1}^*) + \rho_2 \cdot \frac{1}{2} \sum_{j=1}^m h_j^2(x_{\rho_1}^*) &\geq f(x_{\rho_2}^*) + \rho_2 \cdot \frac{1}{2} \sum_{j=1}^m h_j^2(x_{\rho_2}^*) \end{aligned}$$

Складываем и делим на $\rho_1 - \rho_2 > 0$ и получаем:

$$\sum_{j=1}^m h_j^2(x_{\rho_2}^*) \geq \sum_{j=1}^m h_j^2(x_{\rho_1}^*).$$

■

Утверждение Л11.3. Пусть функция f и функции h_j являются непрерывными для всех $j = \overline{1, m}$. Пусть X^* — множество решений исходной условной задачи оптимизации (Л11.1) и для $x^* \in X^*$ ограничено множество

$$U = \left\{ x \in \mathbb{R}^d \mid f(x) \leq f(x^*) \right\}.$$

Тогда для любого $\epsilon > 0$ существует $\rho(\epsilon) > 0$ такое, что множество решений штрафной задачи (Л11.2) X_ρ^* для любых $\rho \geq \rho(\epsilon)$ содержится в

$$X_\epsilon^* = \left\{ x \in \mathbb{R}^d \mid \exists x^* \in X^* : \|x - x^*\|_2 \leq \epsilon \right\}.$$

Замечание Л11.3. Ограниченность U нужна для того, чтобы гарантировать, что вне ограничений функция f ведет себя «адекватно» и штрафная функция просто не улетит в $-\infty$. По факту это и гарантирует существование и непустоту x_ρ^* .

Доказательство. Доказательство проведём от противного. Пусть существует такие $\epsilon > 0$ и последовательность $\{\rho_i\} \rightarrow \infty$, что $X_{\rho_i}^*$ не содержатся в X_ϵ^* , то есть, существуют

$$x_i^* \in X_{\rho_i}^* \setminus X_\epsilon^*. \quad (\text{Л11.3})$$

Согласно Утверждению Л11.1:

$$f(x^*) \geq f(x_i^*), \quad (\text{Л11.4})$$

а значит все x_i^* лежат в ограниченном множестве U .

По теореме Больцано–Вейерштрасса (Теорема 2 Параграфа 9 Главы 1 из [29]) из ограниченной последовательности можно выделить сходящуюся подпоследовательность:

$$\tilde{x}_i^* \rightarrow \tilde{x}^*.$$

Посмотрим, что мы можем сказать про $\tilde{x}^*$. Используя непрерывность f , можем перейти к пределу в неравенстве (Л11.4):

$$f(x^*) \geq \lim_{i \rightarrow \infty} f(\tilde{x}_i^*) = f(\tilde{x}^*).$$

Покажем, что дополнительно $\tilde{x}^*$ удовлетворяет исходным ограничениям h . От противного: пусть для какого-то $k \in \overline{1, m}$, ограничение h_k не выполняется:

$$h_k(\tilde{x}^*) \neq 0.$$

В силу непрерывности h_k , можно заметить, что, начиная с достаточно большого номера i , выполнено

$$|h_k(\tilde{x}_i^*)| \geq \frac{1}{2} |h_k(\tilde{x}^*)| > 0.$$

Но тогда в пределе $\tilde{\rho}_i \rightarrow +\infty$ для последовательности штрафных функций верно:

$$f_{\tilde{\rho}_i}(\tilde{x}_i^*) = f(\tilde{x}_i^*) + \tilde{\rho}_i \cdot \frac{1}{2} \sum_{j=1}^m h_j^2(\tilde{x}_i^*) \rightarrow +\infty.$$

Пришли к противоречию, так как $f_{\tilde{\rho}_i}(\tilde{x}_i^*) \leq f(x^*)$. Значит $\tilde{x}^*$ удовлетворяет всем ограничениям, а значит, $\tilde{x}^* \in X^*$. Но тогда по определению предела последовательности, начиная с некоторого номера i , будет выполняться

$$\tilde{x}_i^* \in \left\{ x \in \mathbb{R}^d \mid \|x - \tilde{x}^*\|_2 \leq \epsilon \right\} \subseteq X_\epsilon^*.$$

Пришли к противоречию с (Л11.3). ■

Замечание Л11.4. Резюмируя, получаем следующие выводы по методу штрафной функции:

- Условная задача превращена в безусловную.
- Увеличение ρ приближает решение штрафной задачи к решению исходной.
- Даже при большом ρ наблюдается нарушение ограничений, что подходит не для всех задач.
- Увеличение ρ влечет за собой увеличение обусловленности задачи, поскольку константа Липшица градиента будет сильно расти. А значит задачу будет сложнее решать.

Л11.3 Двойственный подъем и аугментация

Рассмотрим задачу с ограничениями

$$\begin{aligned} \min_{x \in \mathbb{R}^d} \quad & f(x) \\ \text{s.t.} \quad & Ax = b, \end{aligned} \tag{Л11.5}$$

где $A \in \mathbb{R}^{n \times d}$, $b \in \mathbb{R}^n$. Лагранжиан (Определение C7.1) для неё записывается как:

$$\mathcal{L}(x, \lambda) = f(x) + \lambda^\top (Ax - b).$$

Зная лагранжиан, можем перейти к двойственной функции (Определение C7.2):

$$g(\lambda) = \inf_{x \in \mathbb{R}^d} \mathcal{L}(x, \lambda).$$

Двойственная задача записывается следующим образом:

$$\max_{\lambda \in \mathbb{R}^n} g(\lambda).$$

Тогда запустим градиентный подъем с шагом α для максимизации двойственной функции g :

$$\lambda^{k+1} = \lambda^k + \alpha \nabla_{\lambda_k} \left(\inf_{x \in \mathbb{R}^d} [f(x) + \lambda_k^\top (Ax - b)] \right).$$

Перепишем иначе:

$$\begin{aligned} x^{k+1} &= \operatorname{argmin}_{x \in \mathbb{R}^d} [f(x) + \lambda_k^\top (Ax - b)] = \operatorname{argmin}_{x \in \mathbb{R}^d} \mathcal{L}(x, \lambda^k) \\ \lambda^{k+1} &= \lambda^k + \alpha \nabla_{\lambda_k} (f(x^{k+1}) + \lambda_k^\top (Ax^{k+1} - b)) = \lambda^k + \alpha (Ax^{k+1} - b). \end{aligned}$$

То есть, на каждой итерации считается новый x^{k+1} для λ^k и обновляется по нему λ^{k+1} . Такой метод называется *двойственный подъем*.

Перейдем к аугментации, другими словами — к добавлению штрафа. Уже знаем, что такая «добавка» не меняет задачу:

$$\begin{aligned} \min_{x \in \mathbb{R}^d} \quad & f(x) + \frac{\rho}{2} \|Ax - b\|_2^2 \\ \text{s.t.} \quad & Ax = b. \end{aligned}$$

Лагранжиан аугментированной задачи:

$$\mathcal{L}_\rho(x, \lambda) = f(x) + \lambda^\top (Ax - b) + \frac{\rho}{2} \|Ax - b\|_2^2.$$

Процедура двойственного подъема для аугментированной задачи:

$$\begin{aligned} x^{k+1} &= \operatorname{argmin}_{x \in \mathbb{R}^d} \mathcal{L}_\rho(x, \lambda^k) \\ \lambda^{k+1} &= \lambda^k + \rho (Ax^{k+1} - b). \end{aligned}$$

Замечание Л11.5. Использование аугментации позволяет не устремлять ρ к бесконечности.

Замечание Л11.6. Шаг α специально заменен на ρ , чтобы подбирать один параметр для метода.

Теперь можно перейти к следующему методу.

Л11.4 ADMM

Пусть в задаче (Л11.5) целевая функция и ограничения распадаются на две группы переменных. Иначе говоря, пусть задача имеет вид:

$$\begin{aligned} \min_{\substack{x \in \mathbb{R}^{d_x} \\ y \in \mathbb{R}^{d_y}}} \quad & f(x) + g(y) \\ \text{s.t.} \quad & Ax + By = c, \end{aligned} \tag{Л11.6}$$

где $A \in \mathbb{R}^{n \times d_x}$, $B \in \mathbb{R}^{n \times d_y}$, $c \in \mathbb{R}^n$. Перейдем к аугментированной задаче:

$$\begin{aligned} \min_{\substack{x \in \mathbb{R}^{d_x} \\ y \in \mathbb{R}^{d_y}}} \quad & f(x) + g(y) + \frac{\rho}{2} \|Ax + By - c\|_2^2 \\ \text{s.t.} \quad & Ax + By = c. \end{aligned}$$

Лагранжиан аугментированной задачи:

$$\mathcal{L}_\rho(x, y, \lambda) = f(x) + g(y) + \lambda^\top (Ax + By - c) + \frac{\rho}{2} \|Ax + By - c\|_2^2.$$

Для задачи такого вида можно записать метод *двойственного подъёма*, он же Alternating Direction Method of Multipliers (ADMM):

Алгоритм Л11.1 ADMM

Вход: стартовые точки $y^0 \in \mathbb{R}^{d_y}$, $\lambda^0 \in \mathbb{R}^n$, параметр $\rho \in \mathbb{R}$, количество итераций K

- 1: **for** $k = 0, 1, \dots, K - 1$ **do**
- 2: $x^{k+1} = \operatorname{argmin}_{x \in \mathbb{R}^{d_x}} \mathcal{L}_\rho(x, y^k, \lambda^k)$
- 3: $y^{k+1} = \operatorname{argmin}_{y \in \mathbb{R}^{d_y}} \mathcal{L}_\rho(x^{k+1}, y, \lambda^k)$
- 4: $\lambda^{k+1} = \lambda^k + \rho(Ax^{k+1} + By^{k+1} - c)$
- 5: **end for**

Выход: $\frac{1}{K} \sum_{k=1}^K x^k$, $\frac{1}{K} \sum_{k=1}^K y^k$, $\frac{1}{K} \sum_{k=1}^K \lambda^k$

Поясним смысл названия ADMM:

- Alternating Direction: минимизация по x и y происходит не одновременно, а последовательно, одна за другой.
- Multipliers: наличие двойственных множителей Лагранжа λ .

Замечание Л11.7. В доказательстве сходимости будем использовать версию алгоритма с другим порядком обновления точек:

$$y^{k+1} = \operatorname{argmin}_{y \in \mathbb{R}^{d_y}} \mathcal{L}_\rho(x^k, y, \lambda^k) \tag{Л11.7}$$

$$\lambda^{k+1} = \lambda^k + \rho(Ax^k + By^{k+1} - c) \tag{Л11.8}$$

$$x^{k+1} = \operatorname{argmin}_{x \in \mathbb{R}^{d_x}} \mathcal{L}_\rho(x, y^{k+1}, \lambda^{k+1}). \tag{Л11.9}$$

Теорема Л11.1. Пусть задача оптимизации (Л11.6) с выпуклыми и дружественными с точки зрения вычислений argmin функциями f и g решается с помощью

ADMM (Алгоритм Л11.1 с обновлением (Л11.7)–(Л11.9)). Тогда справедлива следующая оценка сходимости:

$$\mathcal{L}_0\left(\frac{1}{K}\sum_{k=1}^K x^k, \frac{1}{K}\sum_{k=1}^K y^k, \lambda\right) - \mathcal{L}_0\left(x, y, \frac{1}{K}\sum_{k=1}^K \lambda^k\right) \leq \frac{1}{2K}\|z - z^0\|_P^2,$$

где $\mathcal{L}_0$ — Лагранжиан без аугментации и

$$P = \begin{pmatrix} \rho A^\top A & 0 & A^\top \\ 0 & 0 & 0 \\ A & 0 & \frac{1}{\rho} I_n \end{pmatrix}, \quad z = \begin{pmatrix} x \\ y \\ \lambda \end{pmatrix}, \quad z^0 = \begin{pmatrix} x^0 \\ y^0 \\ \lambda^0 \end{pmatrix}.$$

Замечание Л11.8. Определение P -нормы приводилось в Параграфе Л6 (Определение Л6.2).

Доказательство. Запишем условие оптимальности для уравнения (Л11.7):

$$\nabla g(y^{k+1}) + B^\top \lambda^k + \rho B^\top (Ax^k + By^{k+1} - c) = 0. \quad (\text{Л11.10})$$

Формула обновления λ^{k+1} (уравнение (Л11.8)):

$$\lambda^{k+1} - \lambda^k = \rho(Ax^k + By^{k+1} - c). \quad (\text{Л11.11})$$

Условие оптимальности для уравнения (Л11.9):

$$\nabla f(x^{k+1}) + A^\top \lambda^{k+1} + \rho A^\top (Ax^{k+1} + By^{k+1} - c) = 0. \quad (\text{Л11.12})$$

Используя равенства (Л11.10), (Л11.11) и (Л11.12), выразим градиент $\mathcal{L}_0$ в точке $z^{k+1} = (x^{k+1}, y^{k+1}, \lambda^{k+1})^\top$. Для удобства и единообразия записи, градиент по λ будем брать со знаком минус:

$$\begin{aligned} \nabla \mathcal{L}_0(z^{k+1}) &= \begin{pmatrix} \nabla_x \mathcal{L}_0(x^{k+1}, y^{k+1}, \lambda^{k+1}) \\ \nabla_y \mathcal{L}_0(x^{k+1}, y^{k+1}, \lambda^{k+1}) \\ -\nabla_\lambda \mathcal{L}_0(x^{k+1}, y^{k+1}, \lambda^{k+1}) \end{pmatrix} = \begin{pmatrix} \nabla f(x^{k+1}) + A^\top \lambda^{k+1} \\ \nabla g(y^{k+1}) + B^\top \lambda^{k+1} \\ -(Ax^{k+1} + By^{k+1} - c) \end{pmatrix} \\ &= -\begin{pmatrix} \rho A^\top (Ax^{k+1} + By^{k+1} - c) \\ -B^\top (\lambda^{k+1} - \lambda^k) + \rho B^\top (Ax^k + By^{k+1} - c) \\ \frac{1}{\rho} (\lambda^{k+1} - \lambda^k) + A(x^{k+1} - x^k) \end{pmatrix}. \end{aligned}$$

Воспользуемся тем, что $\rho(Ax^k + By^{k+1} - c) = \lambda^{k+1} - \lambda^k$ (уравнение (Л11.11)):

$$\nabla \mathcal{L}_0(z^{k+1}) = -\begin{pmatrix} A^\top (\lambda^{k+1} - \lambda^k) + \rho A^\top A(x^{k+1} - x^k) \\ 0 \\ \frac{1}{\rho} (\lambda^{k+1} - \lambda^k) + A(x^{k+1} - x^k) \end{pmatrix}.$$

Обозначим

$$P = \begin{pmatrix} \rho A^\top A & 0 & A^\top \\ 0 & 0 & 0 \\ A & 0 & \frac{1}{\rho} I_n \end{pmatrix}.$$

Заметим, что матрица симметричная и положительно полуопределённая. Запишем:

$$\nabla \mathcal{L}_0(z^{k+1}) = -P \begin{pmatrix} x^{k+1} - x^k \\ y^{k+1} - y^k \\ \lambda^{k+1} - \lambda^k \end{pmatrix} = -P(z^{k+1} - z^k).$$

Тогда, переписывая в терминах P -нормы $\|z\|_P = \langle z, Pz \rangle$ (Определение Л6.2), получаем:

$$\begin{aligned} \langle \nabla \mathcal{L}_0(z^{k+1}), z^{k+1} - z \rangle &= -\langle P(z^{k+1} - z^k), z^{k+1} - z \rangle \\ &= \frac{1}{2} \left(\|z^k - z\|_P^2 - \|z^{k+1} - z\|_P^2 - \|z^{k+1} - z^k\|_P^2 \right) \\ &\leq \frac{1}{2} \left(\|z^k - z\|_P^2 - \|z^{k+1} - z\|_P^2 \right). \end{aligned}$$

Суммируем по всем k от 0 до $K-1$, усредняем и сворачиваем телескопическую сумму справа:

$$\frac{1}{K} \sum_{k=0}^{K-1} \langle \nabla \mathcal{L}_0(z^{k+1}), z^{k+1} - z \rangle \leq \frac{1}{2K} \left(\|z^0 - z\|_P^2 - \|z^K - z\|_P^2 \right) \leq \frac{\|z^0 - z\|_P^2}{2K}. \quad (\text{Л11.13})$$

Воспользуемся тем, что $\mathcal{L}_0$ выпукла по (x, y) и вогнута по λ . Тогда для любого $z = (x, y, \lambda)$ и каждого k верно

$$\mathcal{L}_0(x^{k+1}, y^{k+1}, \lambda) - \mathcal{L}_0(x, y, \lambda^{k+1}) \leq \langle \nabla \mathcal{L}_0(z^{k+1}), z^{k+1} - z \rangle. \quad (\text{Л11.14})$$

Применим неравенство Йенсена (0.1) к выпуклой и вогнутым частям, получим:

$$\mathcal{L}_0\left(\frac{1}{K} \sum_{k=1}^K x^k, \frac{1}{K} \sum_{k=1}^K y^k, \lambda\right) - \mathcal{L}_0\left(x, y, \frac{1}{K} \sum_{k=1}^K \lambda^k\right) \leq \frac{1}{K} \sum_{k=1}^K (\mathcal{L}_0(z^k) - \mathcal{L}_0(z)).$$

Совмещаем с оценкой через скалярное произведение (Неравенство (Л11.14)):

$$\mathcal{L}_0\left(\frac{1}{K} \sum_{k=1}^K x^k, \frac{1}{K} \sum_{k=1}^K y^k, \lambda\right) - \mathcal{L}_0\left(x, y, \frac{1}{K} \sum_{k=1}^K \lambda^k\right) \leq \frac{1}{K} \sum_{k=1}^K \langle \nabla \mathcal{L}_0(z^k), z^k - z \rangle.$$

Остается подставить более раннюю оценку (Л11.13):

$$\mathcal{L}_0\left(\frac{1}{K} \sum_{k=1}^K x^k, \frac{1}{K} \sum_{k=1}^K y^k, \lambda\right) - \mathcal{L}_0\left(x, y, \frac{1}{K} \sum_{k=1}^K \lambda^k\right) \leq \frac{\|z^0 - z\|_P^2}{2K}.$$

■

ADMM является одним из ключевых и популярных методов оптимизации. Реализован во многих солверах и часто используется, как метод по умолчанию. Нестандартная формулировка самой задачи, для которой придуман ADMM оказывается вбирает в себя много важных частных случаев. «Непривычная» переменная y часто играет роль вспомогательной переменной.